云计算技术系列丛书

私有云计算

整合、虚拟化和面向服务的基础设施

Private Cloud Computing

Consolidation, Virtualization, and Service-Oriented Infrastructure

（美）Stephen R. Smoot
Nam K. Tan 著

潘怡 译

资深云计算专家撰写，深刻揭示私有云工作原理，系统讲解私有云的设计、架构、部署的方法和技术细节，包含精心设计的经典案例，能为构建私有云平台提供绝佳指导

机械工业出版社
China Machine Press

云计算技术系列丛书

私有云计算

——整合、虚拟化和面向服务的基础设施

Private Cloud Computing: Consolidation, Virtualization, and Service-Oriented Infrastructure

[美]斯穆特（Smoot, S. R.） 著

潘怡 译

ISBN：978-7-111-40481-1

本书纸版由机械工业出版社于2013年出版，电子版由华章分社（北京华章图文信息有限公司）全球范围内制作与发行。

版权所有，侵权必究

客服热线：+ 86-10-68995265

客服信箱：service@bbbvip.com

官方网址：www.hzmedia.com.cn

新浪微博 @研发书局

腾讯微博 @yanfabook

目　录

译者序

前言

谁应读本书
谁不应读此书
致谢

第1章　未来IT发展趋势

1.1　面向服务的基础设施框架层次展现
1.2　功能模块：云模块
　　1.2.1　服务器模块
　　1.2.2　存储模块
　　1.2.3　光纤模块
　　1.2.4　WAN模块
　　1.2.5　I型终端用户（分支机构）
　　1.2.6　II型终端用户（移动客户端）
1.3　云计算的特征
1.4　云计算分类
　　1.4.1　部署模式
　　1.4.2　服务模型
　　1.4.3　尝试所有组合
1.5　小结

第2章　未来数据中心的架构及技术

2.1　数据中心整合及虚拟化的主要方法
2.2　服务器整合驱动
　　2.2.1　经典服务器散乱综合症
　　2.2.2　应用烟囱和数据孤立
2.3　服务器虚拟化
　　2.3.1　虚拟机和监视器
　　2.3.2　VMware网络定时器
　　2.3.3　Cisco Nexus 1000V交换机
　　2.3.4　ESX服务器存储网络概略
2.4　存储虚拟化
　　2.4.1　块汇聚

2.4.2 同步及异步存储虚拟化
2.5 Layer-2演化
2.5.1 虚拟端口通道：STP的改造者
2.5.2 vPC设计概要
2.5.3 vPC和Nexus 1000V
2.6 统一数据中心光纤
2.6.1 10千兆以太网
2.6.2 以太网重装上阵
2.6.3 FCoE解决方案
2.6.4 FCoE数据平面
2.6.5 FCoE控制平面
2.6.6 FCoE与I/O整合
2.7 小结
第3章 下一代WAN及服务集成
3.1 数据中心的服务集成
3.1.1 防火墙虚拟化
3.1.2 服务器负载均衡及虚拟化
3.2 基础设施分段
3.3 未来的企业WAN
3.3.1 MPLS VPN序曲
3.3.2 服务提供商的MPLS VPN服务
3.3.3 L2层上的MPLS
3.3.4 DMVPN概述
3.3.5 DMVPN per VRF
3.3.6 DMVPN之上的MPLS VPN（仅用于集中星型网络）
3.4 小结
第4章 分支整合及WAN优化
4.1 何为WAN性能挑战
4.1.1 头号挑战：有限带宽
4.1.2 问题2：WAN连接中的巨大延迟
4.1.3 WAN优化解决方案
4.2 WAN优化的好处
4.2.1 借助压缩和重复数据删除节约带宽
4.2.2 应用层加速

4.2.3 TCP加速
4.3 WAN优化实施的要求
4.3.1 流量拦截
4.3.2 确定优化的合作者
4.3.3 优化好的数据流像什么
4.3.4 监测和优先级别的传输优化实现
4.4 虚拟远程办公方案
4.5 小结

第5章 会话拦截设计及部署

5.1 拦截机制选择
5.1.1 选址决议
5.1.2 操作影响
5.1.3 可控性
5.2 深入探索WCCP
5.2.1 WCCP定义
5.2.2 WCCP控制平面消息
5.2.3 WCCP服务组
5.2.4 WCCP拦截操作
5.2.5 WCCP重定向机制
5.2.6 WCCP分配算法
5.2.7 WCCP返回方法
5.2.8 WAN优化器的egress方法
5.2.9 WCCP服务平台选择
5.2.10 WCCP方案样例
5.2.11 WCCP配置样例
5.3 In-path部署简介
5.4 PBR部署概述
5.5 小结

第6章 私有云上的WAN优化

6.1 云对WAN优化的要求
6.2 VM层拦截
6.3 使用VRF感知的WCCP实现云拦截
6.4 使用非VRF感知WCCP实现云拦截
6.4.1 VRF选择
6.4.2 WCCPv2双向连接的挑战

6.4.3 Not-So-VRF方案
6.4.4 Not-So-VRF说明
6.5 在服务汇聚层实施拦截
6.5.1 对服务器机箱的要求
6.5.2 Admin上下文
6.5.3 User上下文访问管理
6.5.4 ACESM拦截：桥接模式
6.5.5 ACESM拦截：路由模式
6.5.6 WAN优化器集群冗余
6.6 小结

第7章 SAN扩展及IP存储

7.1 SAN扩展概述
7.1.1 数据恢复机制
7.1.2 关键的设计原则
7.2 光纤网络方案
7.2.1 暗光纤
7.2.2 DWDM
7.2.3 CWDM
7.3 SONET/SDH服务
7.4 FCIP
7.4.1 FCIP入门
7.4.2 FCIP拓扑
7.4.3 FCIP HA
7.4.4 FCIP性能调整
7.4.5 FCIP安全
7.5 iSCSI
7.5.1 iSCSI协议概述
7.5.2 iSCSI部署
7.5.3 iSCSI HA
7.5.4 iSCSI安全
7.6 所有方法汇总
7.7 小结

第8章 云基础设施即服务

8.1 云安全
8.1.1 虚拟交换机安全
8.1.2 端点安全

8.1.3 虚拟VMZ
8.2 统一计算系统
8.2.1 UCS使能技术
8.2.2 UCS组件
8.3 云管理
8.3.1 分级管理
8.3.2 基于策略的管理
8.3.3 管理调整
8.3.4 自动化
8.3.5 用户自助服务
8.3.6 XML-ization
8.4 云IaaS：巨幅画卷
8.4.1 应用软件子模块
8.4.2 虚拟机器子模块
8.4.3 虚拟接入层子模块
8.4.4 计算子模块
8.4.5 存储阵列子模块
8.4.6 SAN子模块
8.4.7 SAN扩展子模块
8.4.8 接入层子模块
8.4.9 汇聚层子模块
8.4.10 核心层子模块
8.4.11 对等子模块
8.4.12 未来的WAN子模块
8.4.13 WAN优化
8.4.14 云基础设施管理平台
8.4.15 终端用户负载及应用
8.4.16 云IaaS覆盖
8.5 小结

第9章 案例分析

9.1 虚拟接入层设计学习
9.1.1 Nexus 1000V组件
9.1.2 设计样例
9.2 ERSPAN案例学习
9.2.1 ERSPAN源接口
9.2.2 ERSPAN设计样例

9.2.3 ERSPAN基本配置
9.2.4 部署指南及限制
9.3 WAN优化案例学习
9.4 统一光纤案例学习
9.5 架顶式体系结构案例学习
9.5.1 使用Nexus 5000和2000进行ToR设计
9.5.2 ToR设计样例：附加1GE服务器
9.5.3 FEX基本配置
9.6 基础vPC设计学习
9.7 SAN扩展设计案例学习
9.8 面向服务的基础设施设计学习
9.8.1 虚拟接入层高级设计
9.8.2 计算子模块高级设计
9.8.3 存储子模块高级设计
9.8.4 光纤模块高级设计
9.8.5 服务汇聚层高级设计
9.8.6 WAN模块高级设计
9.8.7 设计评价
9.9 小结

附录 术语及缩略语

参考文献

译者序

正如两位作者Stephen R.Smoot和Nam K.Tan在前言中提出："5分钟的Web服务仅收费5美元"这句话颇具诱惑力，云计算开创了软件即服务、平台即服务、基础设施即服务等全新IT服务模式，为企业带来了工作方式和商业模式的根本性改变。尽管云计算也曾因市场炒作而备受误解，但不可否认的是，自诞生之日起，它就在IT界兴起了一股势头强劲且愈演愈烈的云旋风。

本书从未来云数据中心的架构及技术着手，探讨了如下几方面内容：虚拟化，包括服务器、存储以及网络虚拟化，它们是私有云解决方案的基石；WAN优化，借助重复数据删除、压缩、TCP加速及应用加速等措施，对云平台最脆弱的环节进行了有效巩固；云存储，它是实现云数据中心的前提；以及其他诸如数据中心整合等云解决方案的关键技术。

Stephen R.Smoot和Nam K.Tan均为多年来工作在企业网络平台架构及实施领域的专家，在本书的翻译过程中，他们深厚的理论基础和丰富的实践经验给我留下了深刻印象。在本书中，两位作者向读者清晰阐述了云计算基础设施架构的理论知识，并对每章难以理解的部分重点标注，更令人兴奋的是，他们将自己数十年来所积累的宝贵的实际经验，通过大量且详尽的案例分析和包括配置过程的样例说明，向读者一一进行了展示，哪怕是菜鸟级的新人，也能够快速理解并掌握企业构建面向服务的基础设施所必需的各项技术，具备设计及部署私有云解决方案的基础能力。

本书适合网络工程师、云计算方案架构师、互联网专业人士、IT经理、CIO、服务提供商，以及任何希望了解掌握私有云构建与管理最新解决方案的朋友们。

感谢机械工业出版社引进了这本优秀的图书。感谢策划编辑吴怡老师，没有她的信任与鼓励，仅凭我一己之力，难以完成这样艰巨的翻译工作。感谢编辑秦健，他的仔细审查和及时沟通，是本书翻译能够顺利完成的保证。感谢我的朋友张波，是他的推荐才让我有幸与本书结缘。

感谢我的家人，他们的爱，让我所有的努力充满了意义。

最后，鉴于译者本人的知识局限，译稿中一定存在错误和遗漏之处，谨向原书作者表示歉意，并敬请广大读者批评指正。

潘怡

前言

建筑空中城堡没有原则可循。

——G.K.切斯特顿（Chesterton）

“5分钟的Web服务仅收费5美元”是云计算最诱人之处吗？

IT企业的领导者很快就发现，服务平台领域最新的游戏规则是使用云，有了云，你不但可以像个外行一样毫无顾虑地削减IT成本，还可以提高企业创新速度。企业的架构师也正是被这其中利益所驱动转而思考该如何为企业搭建一个私有云平台。

我们正处在这样一个时代的开端，网络设计师通过整合物理及虚拟设备来创造下一代云服务。网络虚拟化是这一解决方案的基石，通过虚拟网络技术，我们可以将千差万别的网络整合成一个虚拟整体，形成构建所有面向服务架构的基础设施。而利用虚拟服务器，企业可以按客户需求弹性调度IT资源（也即私有云服务）而无须额外增加新的设备或设施。从商业角度看，云不仅节约了企业运营成本，同时也提高了企业快速应对各种商务需求变化的敏捷性，从而更灵活地协调成本控制和业务发展行为间的矛盾。

目前虚拟技术关注的焦点在数据中心，因为它们占用了绝大多数服务器的资源。为了充分实现云的美好愿景，架构师必须放眼区域内及下属分支机构以找到更多可被合法利用的服务资源，并确保服务性能令企业满意。在构建云平台时，WAN（广域网）可能是其中最脆弱的一环，它固有的缺陷，例如用户失去服务连接、传输延时、丢包、网络拥堵或带宽限制等，都将对云的性能产生挑战。在大公司云计算的部署方案中，用户的计算和存储单元距离遥远，由此而产生的传输延时和带宽不足都会对系统性能及效率产生影响。WAN优化可以解决该问题，优化后的网络能够消除性能瓶颈，使得网络效率和局域网相差无几。

WAN优化方面的技术文献非常多，《Next-generation data centers,and virtualization》（未来数据中心及虚拟化）这本书最先从云计算发展趋势角度出发，将三者结合在一起进行讨论。作者沿着建设基于面向服务基础设施SOI云计算平台的思路，探讨了如何利用数据中心融合技术、网络优化技术以及包括服务

器虚拟、存储虚拟和网络虚拟等各类虚拟化技术来得到优化效率的新结构。数据中心融合的另一关键因素是冗余，为了确保商业可靠性目标而必需的冗余，本书讨论了通过数据复制进行灾难恢复所面临的挑战以及相应解决方案。

云计算安全对任何企业都非同小可，我们将研究在云框架下如何保证数据安全，同时以Cisco Unified Computing System（Cisco统一计算系统）为例探讨具体方案。总而言之，本书将结合案例分析和样例来说明企业如何构建面向服务的基础设施。

谁应读本书

人生目的地绝非一个地点，而是一种看事物的新方式。

——亨利·米勒（Henry Miller）

本书适合网络工程师、方案架构师、互联网专业人士、IT经理、CIO、服务提供商，以及任何希望了解掌握私有云构建与管理最新解决方案的朋友们。本书将会指导读者如何将数据中心和遥远的分支机构办公室整合在一起，要阅读本书，读者需要了解基本的TCP/IP网络协议知识，我们将由易到难安排学习内容，并对每章难以理解的部分重点标注，同时会提供案例分析以及配置样例以帮助读者更好地理解和掌握。如果读者希望了解私有云的工作原理，本书将是你的正确选择。

谁不应读此书

博克农（Bokonon）告诉我们，“要警惕一种人：他们努力学习一样东西，学到手后，却发现自己并没有变得比以前更聪明。这种人对那些天生的蠢人充满了诛之而后快的憎恶。”

——库尔特·冯内古特（Kurt Vonnegut）

本书适合想深入探索私有云构建理论的读者，而非那些只想掌握EC2使用方法的人们。要提醒大家，我们将大量时间专注于这一行业技术和商业带头人——Cisco公司的路由和交换技术、VMware公司的虚拟化技术，以及Riverbed公司的WAN优化技术，尽管其他公司也有类似产品，但因篇幅有限而无法详细讨论，只能一笔带过。最后想说，云平台自动化构建也是必学之课，但不在本书讨论范围之内。

致谢

曾经很多次，我们对“给那些开始接触云的人一些建议会是个好主意吗”犹豫，纠结了足够久后，我们终于觉得应该这样做。在本书编写过程中，很多人给予我们帮助，我们希望能向他们一一表示谢意。本书中所介绍的某些内容可能跟不上厂家技术更新的步伐，因此本书中任何错误或纰漏都是作者自己的原因。

首先要感谢Mark Day博士、Alan Saldich和Steve McCanne博士，他们为本书第1～4章的某些观点提供了很好的论述材料，他们的观点和启示对我们试图阐述的一些问题具有强大的说服力。编辑Karyn Goldstein不知疲倦地帮助我们组织语言、润色稿件，她的努力给本书增色不少。

还要感谢我们的同事和朋友，他们从技术等各方面对本书提出了宝贵的修改意见。谢谢Larry Rowe、Lance Berc和Kand Ly博士，是他们提议我们开始这一写作，Ricky Lin、Joshua Tseng和Nick Amato反复阅读本书并提出了修改意见，最后要感谢Michel Demmer、BillQuigley、Bruno Raimondo、Chiping Hwang、Paul Griffiths、Tandra De、Kand Ly和Phil Rzewski全面把关本书涉及的技术。特别感谢Emilio Casco帮助我们完成了第4章中的插图，感谢Claire Mosher的编辑和指导。感谢所有曾经给予我们指导和支持的人们，是他们帮助我们完成了这一工作。

第1章　未来IT发展趋势

建筑是通向真理的桥梁。

——路易斯·卡恩

简介

本书探讨了未来IT基础设施的建设。要弄明白这一问题，首先要了解当前IT基础设施的架构方式，不过，该怎样做才能达成目的呢？回顾历史，追溯计算的本源，有助于我们找到正确的答案。

计算技术发展早期，用户、计算机和应用程序之间的结合非常紧密，虽然用户和硬件设备不一定在一个房间内，但往往都在同一栋大楼里，每个应用程序具体在哪台机器上运行也是非常明确的。通常，人们会将“早期年代”的定义与ENIAC、IBM.360或Apple II这类大型机系统正当其道的时代等同起来。

自那时起，企业和IT组织就不断地运用网络技术来支持各种形式的分离。网络存储便是其中之一，借助网络存储技术能够实现计算机和支持应用的存储彼此分离，提高了操作效率及操作灵活性。另一种技术名为局域网技术，它支持用户能够连接到一定范围内（如校园）的计算资源。而最后还有一种WAN（广域网）技术，支持用户和计算资源间的距离能够延长至好几百英里，甚至相隔半个地球也没问题。在实际工作中，人们更习惯使用它们的缩写：SAN（Storage Networking，网络存储）、LAN（Local Area Network，局域网）以及WAN（Wide Area Network，广域网）。Internet是大家最熟悉的WAN例子，尽管与某些WAN群组或骨干传输网这些人们所熟知的WAN分支相比，Internet由于个性十足会让人觉得它更像是另外一种新技术。

有必要再更详细了解一点这些不同分离的意义。毫无疑问，网络的价值在于能够将原本不可能实现的通信变为现实，例如，用户身处A地，设备却在B地，无论是将用户运送到B地，还是将设备运到A地，都不如采用网络更实际。但显然，远距离传输并非网络存储的目标，因为一般情况使用网络存储的对象通常位于同一个数据中心范围内，如何将服务器/存储系统进行分割并重新部署成服务器汇聚及存储汇聚，然后实现彼此连接才是网络存储所考虑的问题。

通过分割和整合将有可能提高工作效率，下面通过一个例子来对该问题进行说明。假设，一个企业拥有5台服务器，而每台服务器都只使用了20%的存储资源，根据经验，买小硬盘显然是不划算的，比较经济的做法是只买2～3个磁盘让5台服务器共享，而不是买5个硬盘。实际上还可以将这些硬盘组织成一个独立磁盘冗余阵列（Redundant Array of Independent Disk,RAID），这样共享磁盘就能够在不影响数据可获得性前提下处理好单个磁盘故障，从而保证了5台服务器都不会因某个磁盘发生故障而停止工作，那种为每台服务器单独配置一个磁盘的方案是无法获得这样的可靠性的。尽管实现细节千差万别，但当已连接好的设备需要并能够被分割再整合时，往往会采用这类工作模式，在降低成本的同时也提高了性能。

尽管这几类网络技术（SAN、LAN、WAN）彼此之间或多或少都是独立发展及演变，但任何一种网络大致相同，都是将二进制数据从起点传送至终点，所以将来如果有一天它们在发展中相互借鉴或有些重叠甚至融合并不会让人感到奇怪。现在，LAN和SAN之间的界限已经因为厂商们提出的“融合”或者是“统一”数据中心网络的概念变得模糊。受“WAN优化”或“虚拟私有LAN服务”这类技术的鼓舞，人们也正在重新审视LAN和WAN之间的差异。

独立于网络技术的演化发展，IT企业已经越来越多地使用虚拟化技术来建立另一类分散。虚拟化能够让用户产生一种错觉，即当前程序看起来占用了整个企业的硬件平台，而实际上却由多个程序共享企业的物理硬件资源。虚拟化支持将逻辑服务器（负责程序执行）与物理服务器（计算机硬件）完全分离，借助虚拟化可以使多个逻辑服务器——原本操作系统可能根本无法兼容——共享同一物理服务器，甚至当它们的负载发生变化时还可以彼此相互转移任务，由此显著提高IT组织的灵活性。

一部分是受Internet技术兴起的影响，一部分是虚拟化技术发展的结果，还有第三种技术与我们的分析相关。云计算通过IP协议提供对计算和存储资源的访问，使得计算和存储资源不仅与云终端用户同时也与企业数据中心实现了分离。

云应该能够提供弹性并自动的服务，即无需人工介入就能自动实时地增加服务实例，自然也应支持服务计费和服务退出

自动化，否则这些环节就会成为云服务的业务瓶颈。为了实现自动服务、计费及服务退出自动化，基础设施必须具备最大限度的敏捷性和灵活性。

如果我们希望构建一个云服务——无论是公有云还是私有云，也无论它是面向应用还是面向基础设施——我们都必须尽可能地结合目前最好的技术理念，诸如扩展、关注点分离、整合共享功能等，本书针对这些技术展开探讨，并研究如何将它们组织在一起搭建可行的工作云。

本书接下来的内容分成两种组织形式，一种是从层次化角度出发，而另外一种则可以采用模块化方法组织，分别如下两小节所示。

1.1 面向服务的基础设施框架层次展现

构建未来基础设施涉及了太多方面的难题，按层次结构来划分将更有益于对这些解决方法的理解。系统顶层向终端用户提供了各种各样令人惊叹的、强大的、难以置信的、灵活的服务，底层则由各式各样现成的硬件构成的集合，包括服务器、存储设备、网络路由和交换器及远距离电信服务。中间层对底层相对原始的设备进行组合，以构建一组新的更高级的设备。

这种独特的层次模型就是如图1-1所示的面向服务的基础设施SOI（Service-Oriented Infrastructure,SOI），紧挨着物理硬件之上的这一层主要负责虚拟化——因使用特定型号的计算机、特殊尺寸的磁盘以及其他类似特殊硬件设备而产生的局限性在这一层将尽可能地被减少或消除。其上一层主要关注管理和服务开通——连接下层优化好的虚拟资源以及上层用户需求。在管理及维护层之上一层负责输出，通过各类网络接口将这些自动功能优化组合，使得无论是更高一级的云软件及服务（Software as a Service,SaaS），还是更低一级的云基础设施（Infrastructure as a Service,IaaS）都能同等地使用这些资源。

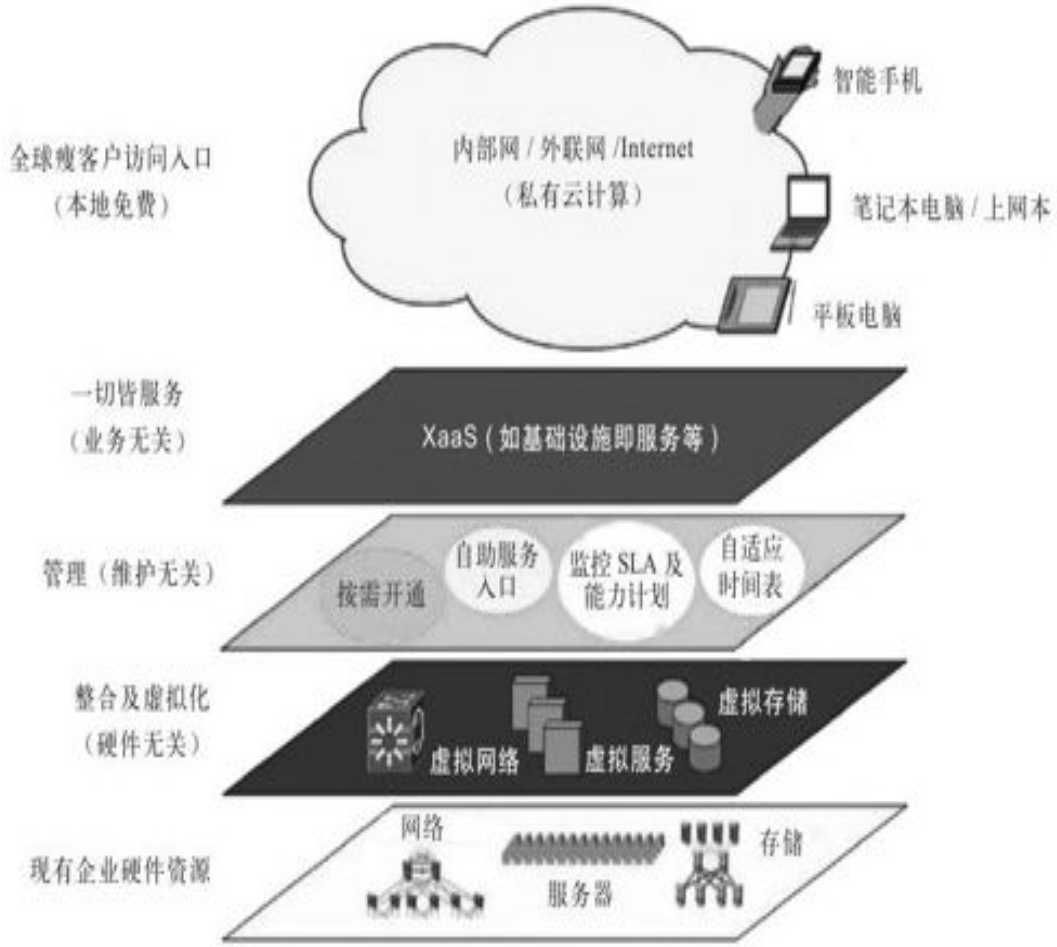


图　1-1　SOI框架

在后面讨论不同的选择以及对方案的权衡折衷时，将更详细地解释这些层的概念。

1.2　功能模块：云模块

虽然整本书都在讨论SOI框架，但我们并没按这个模式安排章节内容。假使我们以类似传统计算机那样的模块化形式来对比分析云计算机的结构，那么我们所熟悉的CPU、RAM、总线、磁盘等这些功能模块在云计算机中将转换成如图1-2所示的几个部分：

·服务器模块

·存储模块

·光纤模块

·WAN模块

·I型终端用户（分支机构）

·II型终端用户（移动客户端）

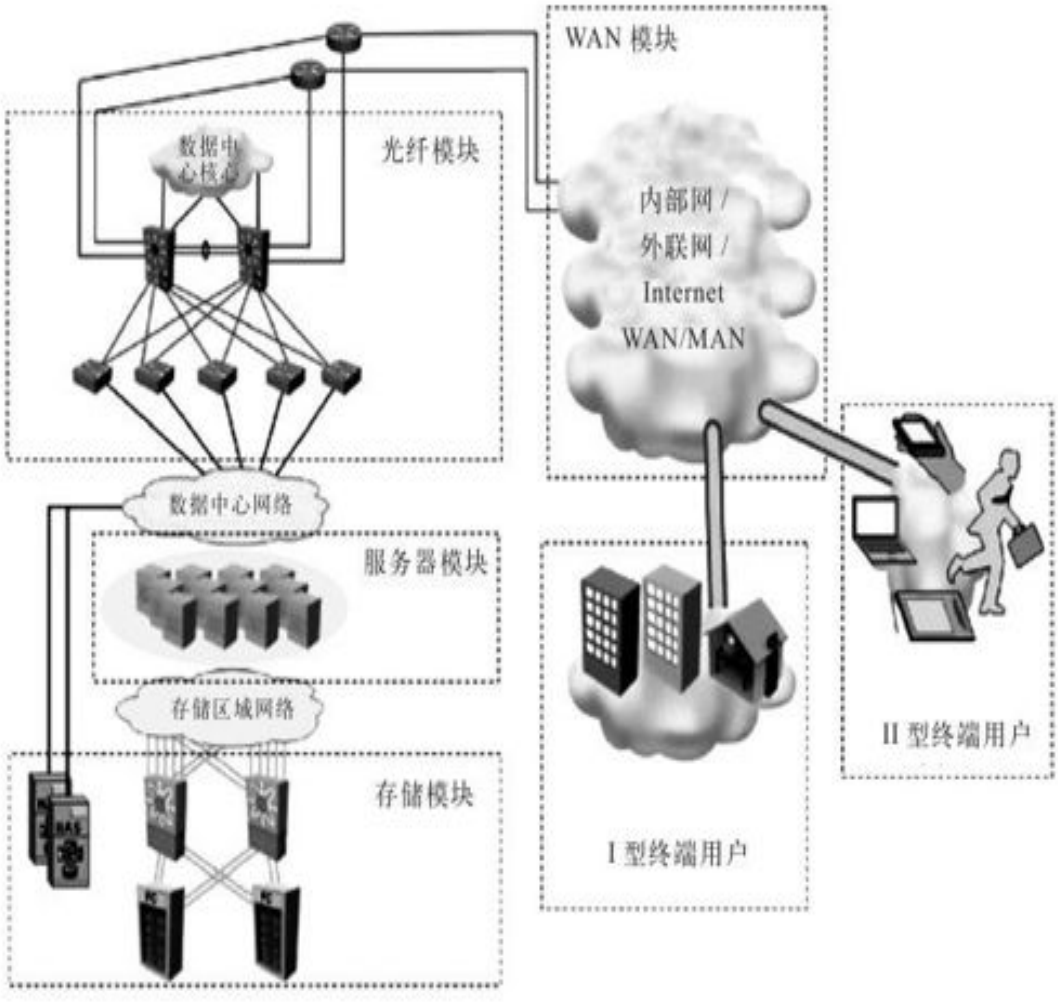


图　1-2　云计算机构件

1.2.1　服务器模块

服务器模块就好比云计算机中的CPU，物理的服务器或服务器组组成了云计算的核心处理器，就像一块“三明治”，被“夹在”数据中心网络和存储网络中间。

如前所述，服务器虚拟化支持多台逻辑服务器或虚拟机器（Virtual Machine,VM）运行在同一台物理服务器上。每个虚拟机都像一台独立的服务器，但是不同虚拟机在监控设备管理下，可以共享彼此的硬件资源（例如处理器、磁盘、网卡以及内存），通常我们把管理这些虚拟机的监控设备（Virtual Machine Monitor,VMM）称为虚拟机管理器。虚拟机管理器将来自用户操作系统的访问发送至虚拟机上，并且负责监控这些任务的执行情况，这样不同的操作系统包括统一操作系统的不同实例，也能共享物理服务器的硬件资源。一个简单的虚拟机结构如图1-3所示。

服务器虚拟化实现了数据中心物理服务单元的压缩和整合，同时也提高了这些服务器的平均使用效率。如果希望了解更多有关服务器整合和虚拟化细节，请参考第2章相关内容。



图　1-3　简化的虚拟机架构

1.2.2 存储模块

存储模块负责为云计算机提供数据存储功能。它由SAN及存储子系统构成，包括JBOD磁盘簇、磁盘阵列以及RAID等。更多基于SAN的虚拟化技术，请参见本书第2章相关内容。

SAN扩展

如图1-2所示，当系统中包括1个或1个以上的存储单元时，需要考虑借助SAN扩展技术以穿过WAN上的“云”，实现远程数据复制、备份及镜像等需求。SAN扩展方案包括密集波分复用网络（Wave-Division Multiplexing,WDM）、时分复用网络（Time-Division Multiplexing,TDM）以及基于IP的光纤通道（Fibre Channel over IP,FCIP）。更多关于SAN扩展方案的资料请参见本书第7章。

1.2.3 光纤模块

光纤模块好比云计算机的总线系统，负责在不同的云计算模块间数据的传输。如图1-2所示，服务器群就像一块三明治，被夹在数据中心网络（通常是以太网）和SAN中间，SAN实际上是一种光纤通道（Fibre Channel,FC）。SAN也是一种孤立的光纤拓扑，常称为SAN孤岛，因为光纤通道所使用的协议栈与TCP/IP所使用的协议栈完全不同。

研究光纤模块的主要动机源自希望能够将这种孤立的光纤拓扑（Isolated Fabric Topology,IFT）转换成统一的光纤拓扑（Unified Fabric Topology,UFT）。那么该如何实现这种统一性呢？简单说就是扩展，或者具体来说就是将光纤通道封装在以太网之上，得到光纤通道以太网（Fibre Channel over Ethernet,FCoE）。过去，以太网的有限带宽限制了它成为统一光纤拓扑基础的可能，现在随着10G以太网的研发，已有足够的带宽可以实现各种网络类型的灵活连接，有关FCoE的更多内容请参考本书第2章。

1.2.4 WAN模块

WAN模块连接了企业内联网（内部访问）、外网（B-to-B访问）、Internet（公共访问）以及城域网（Metropolitan-Area Network,MAN）。从云计算用户的角度来看，WAN模块提供了到云的访问，其主要功能是使得云计算机可以被扩展连接至本地或远程的校园、分支机构办公室，而远程工作者、居家办公人员、移动用户以及旅行者也可以通过WAN享受云服务。可以通过各种不同网络技术来实现WAN，包括长距光纤网络或者是类似802.11那样的无线以太网技术。

网络虚拟化

由于每个终端用户及用户与计算资源之间都需要一定程度的相互隔离，因此云计算环境的核心要求之一就是能够在共享的物理网络基础设施之上，搭建能够跨越WAN的独立或孤立的逻辑传输路径。

第3层（IP层）的虚拟化提供了要求的端到端的网络分段及终端用户间的单独连接，这一层的虚拟化也就是我们熟知网络虚拟化，可以通过多虚拟路径转发（Virtual Routing and Forwarding,VRF）以及多协议标签交换（Multiprotocol Label Switching,MPLS）技术实现。网络虚拟化的原理如图1-4所示，将企业单一的物理网络基础设施在逻辑上划分成不同的相互隔离的子网，但终端用户并不能觉察出划分得到的逻辑子网与原来物理网络的差别。第3章将对网络虚拟化进行更详细地说明。

WAN优化

就在数据存储和处理因云计算的诞生而越来越趋于集中时，通过“云”间协作也能向远程用户提供和局域网络相差无几的响应时间成为新的挑战。更多的情况下，即便WAN资源存在局限，例如，网络延迟和有限带宽，也必须提升用户满意度，不能因为响应速度慢而降低远程终端对云计算机访问的效率。这也是为什么WAN优化是云体系结构的关键因素。WAN优化可以使用更有效的数据展现模式以及协议对在WAN内传输的数据进行整合，因此可以弥补带宽有限的不足并降低网络时延。网络优化经常被应用在光纤和WAN模块以及终端用户与WAN模块间。更多有关WAN优化技术的内容，请参考本书第4～6章。

1.2.5　I型终端用户（分支机构）

I型终端用户的位置相对固定——通常为本地或远程的校园、分支机构、远程办公及家庭办公用户，可以通过有线或无线网络（偶尔也会使用3G/4G模式）访问云。

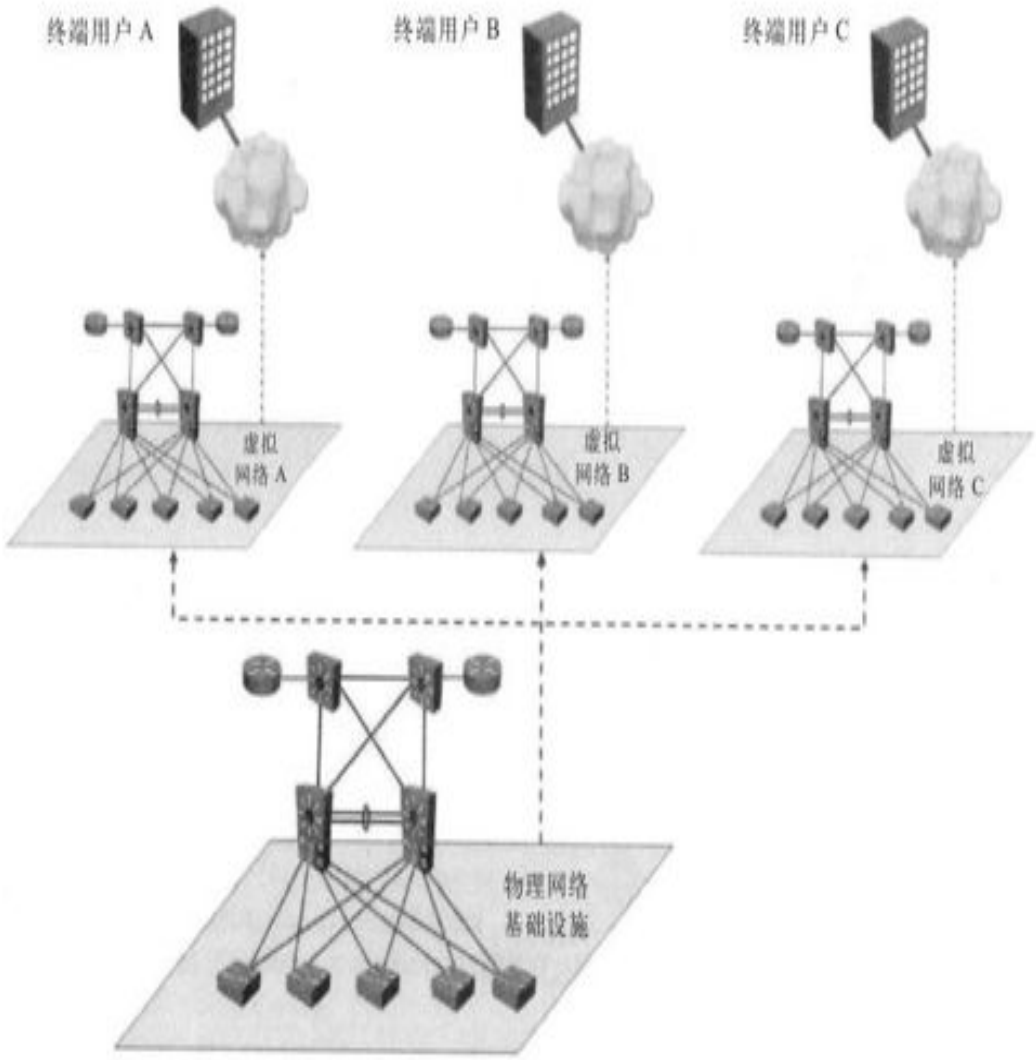


图　1-4　网络虚拟化样例

在分布式计算比较流行的年代，远程分支机构（Remote Branch Office,RBO）可以拥有本地文件和应用服务器以及本地存储设备。当采用云计算集中模式时，这些分支机构的资源，包括光纤、服务器以及存储单元都会被重新安排在一个集中的数据中心里。可以使用WAN优化确保用户满意度在RBO整合后不受影响。随着本地存储也迁移到数据中心，RBO上的主机（源头）可以使用iSCSI存储技术访问位于存储单元上的存储子

系统（目标）。而在本书中当我们提及云计算终端用户时，通常是指I型用户。有关WAN优化的详细内容，请参考本书第4～6章。关于iSCSI存储技术的细节，请参考本书第7章。

1.2.6 II型终端用户（移动客户端）

II型终端用户属于没有固定工作地点的移动用户，借助移动设备通过无线网络访问云是这类用户常见工作模式。下一代移动宽带网络（已超过本书讨论范围）在这方面具有举重若轻的地位。一般情况下，移动设备的功率都不如传统PC，因此更容易以瘦客户端方式工作。

1.3 云计算的特征

整合和虚拟化如图1-3所示的各种云计算的构件的主要目的是取得具有如下特征的SOI系统。

·按需自助服务：消费者可以按需自主开通计算资源，诸如，服务器设置和网络存储，不需要服务供应商进行人工交互。

·统一的网络访问方式：诸如手机、便携式电脑、上网本、平板、掌上电脑（Personal Digital Assistant,PDA）等，无论是异构的瘦客户端还是胖客户端，均可以通过网络，按照标准方式获取服务。

·资源池：云计算以资源池形式向不同终端用户提供多租户模式资源服务，各种物理或虚拟资源可以根据终端用户需求灵活地加载或卸除。常见资源池类型包括存储资源池等、处理资源池、内存资源池、网络带宽资源池以及虚拟机资源池等。用户与资源池在物理上是相互自由和独立的，无论用户是内部员工还是外部机构，都可以分别通过企业内网或者是Internet访问相应资源，因此终端用户通常无需关心所使用资源的具体位置，实现了位置无关性。

·快速可伸缩性：可以迅速、弹性地提供服务（某些情况下可以实现自动服务），能快速扩展，也可以快速释放实现快速缩小。对终端用户来说，可以租用的资源看起来似乎是无限的（或无界）。

在认识了云计算的基本特征后，接下来我们将深入研究千差万别的云计算部署和服务模型了。

1.4 云计算分类

云计算不是一个完全崭新的概念，值得一提的是最初的云雏形源自对TCP/IP的抽象，以Internet为标志。随着超文本传送协议（HyperText Transfer Protocol,HTTP）的诞生，万维网（World Wide Web,WWW）数据抽象在第一代云基础上创建了第二代云。新兴的云技术提倡由服务器、应用程序、数据以及异构平台组成一个抽象的基础设施，处于比前二者更底层的位置。

根据美国国家技术与标准局（National Institute of Stardard and Technology,NIST）对云计算的定义分类，种类繁多的云均可以被涵盖在四个发布模型和三个服务模型之内。

1.4.1 部署模式

按部署模式不同，可以将云系统分成以下四种：

·公有云（public cloud）：云基础设施属于某些提供云服务的经营组织，并向公众或大型企业群体销售。用户通常通过Internet灵活按需获取资源，中小型企业（Small and Medium Enterprise,SME）能借助公有云尽可能降低由于数据中心不断增长带来的投入成本而获益。

·社区云（community cloud）：云基础设施被一些组织共享，并为一个有共同关注点的社区或大机构服务（例如，任务、安全要求、政策和准则等），社区云的维护通常由这些组织或第三方合作者完成，社区可以自己构建或租用云。

·私有云（private cloud）：云基础设施只对某单一组织开放，可以通过自有或租用方式获得，维护工作可以交给该组织或第三方机构。简而言之，私有云是公有云的一种演变，仅架构在私有网络上为某一个组织而非多个组织提供服务。

·混合云（hybrid cloud）：云基础设施是由两种或以上的云（私有云、社区云或公有云）组成，每种云仍然保持独立实体，但用标准的或专有的技术将它们组合起来，具有数据和应用程序的可移植性（例如，可以通过负载均衡技术来应对处理突发负载）。

公有云和私有云之间的界限非常清晰，因为这是由该云资源的拥有者以及终端用户，而非构建云所使用的技术决定的。

本书主要探讨私有云，即仅面向某个单一组织的云计算，此处所说的组织通常是指一个大型企业。

相比社区云和公有云，组织对私有云的安全架构拥有更多的决定权。换句话说，私有云用户所面对的数据暴露威胁要比行业云和公有云小，能更好地满足正在兴起的监控需求。公有云引起了人们非常多的对安全的关注，这也是本书将焦点放在私有云计算的另一原因。

基础设施除了能够实现基于机密性、完整性、可获取性（Confidentiality,Integrity,and Availability,CIA）三位一体的安全控制，还应该采用基于多租户的服务形式，以便在类似计算资源和终端用户之间能够实现安全分离与获取。更多关于云安全问题请参考第8章。

1.4.2 服务模型

NIST给出了以下三种云计算的服务模型：

·云软件即服务（Software as a Service,SaaS）：顾客可以使用供应商构建于云基础设施之上的应用，从不同的客户端设备通过类似Web浏览器这样的瘦客户端接口获得应用程序。顾客不需要对底层云基础设施，包括网络、服务器、操作系统、存储，甚至单独的应用程序进行管理维护，除非某些客户定制业务需要特别配置参数时会偶有例外，Web邮件是一个成功的SaaS案例。

·云平台即服务（Platform as a Service,PaaS）：顾客可以在云基础设施之上部署自己的应用程序，这些程序可以是由顾客使用供应商提供的开发工具或语言自行开发的应用程序或者直接从供应商处购买的程序。顾客不需要对底层云基础设施，包括网络、服务器、操作系统、存储进行管理和维护，也无权管理部署好的应用程序，或者是应用程序主机驻留环境配置。顾客向主机供应商购买Web页面所需的服务器空间是PaaS应用的一个例子。

·云基础设施即服务（Infrastructure as a Service,IaaS）：顾客可以获得处理器、存储、网络以及其他基础计算资源，能够部署和运行任意软件，包括操作系统和应用程序。顾客不需管理维护云基础设施，但是可以管理操作系统、存储、部署好的程序或者是有限的网络模块（譬如防火墙和负载平衡模块）。在私有云框架上提供组织范围内IaaS是本书的主题。

图1-5解释了三种不同的云计算服务模式。每一种服务模式都可以相互独立直接运行在云基础设施之上，也可以像沙盒一样互相叠加。例如，SaaS构建在PaaS之上，而PaaS又相应构建在IaaS之上。

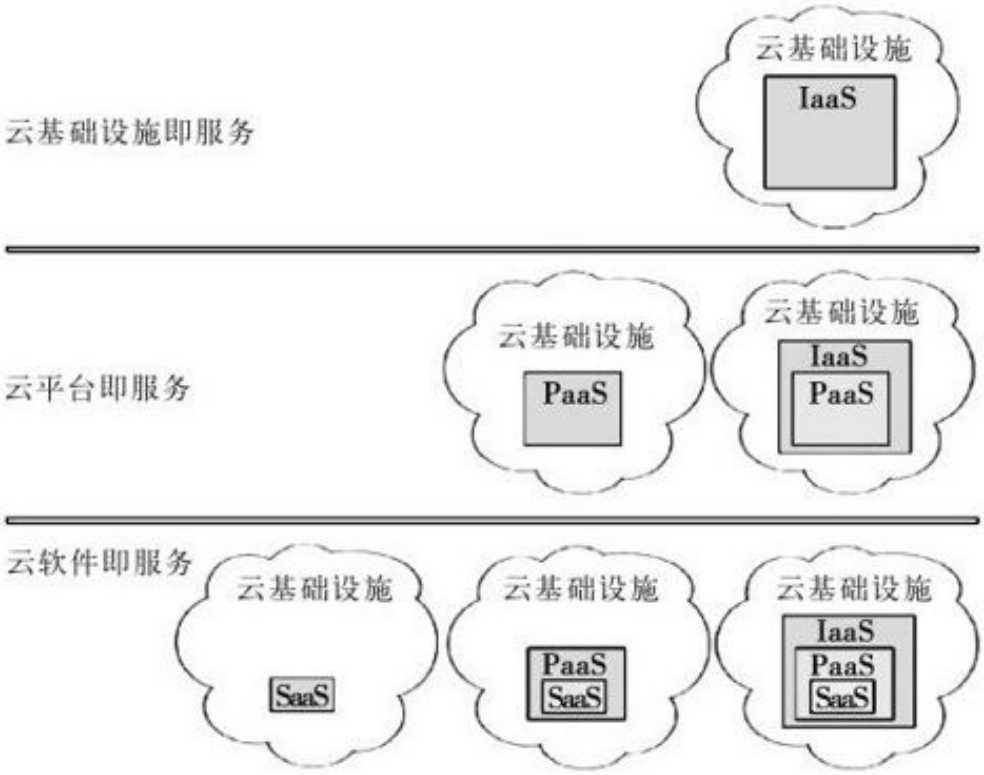


图　1-5　云计算服务模型

IaaS是三种模式中最急需的一种模式，因为它是传统的企业数据中心向完全虚拟的私有云发展过程中产生的一个自然转折点，其核心目标是建立一个提供完备IaaS的云基础设施，并且实现对现有计算资源和硬件资源，包括服务器、存储、网络等的整合和虚拟化，以获得前文所提的那些效益。更多关于云IaaS的详细资料请参考本书第8章相关内容。

1.4.3 尝试所有组合

仅了解这些抽象概念是不够的，更重要的是我们需在实践中使用这些技术。为此，第9章的全部内容都是相关案例学习，范围涉及了前文所讨论的很多内容。同时考虑到书中引用了大量资料，在书的末尾列出了所有的参考文献。最后，由于云计算是一个如此活跃发展的领域，我们专门建立了一个网站，反馈及勘误请访问http：//www.pcc-cvsoi.com/。

1.5 小结

本书介绍了关于构建支持私有云服务的未来基础设施的技术和方法，这些技术对现代IT实现模式有着深远的影响，可以认为是未来网络和虚拟化技术发展的方向。

第2章　未来数据中心的架构及技术

鉴以往事，有资于后人治道。

——格言

简介

在第1章，我们探讨了以下几个抽象层概念：

·硬件

·服务

·商业实现

·位置

为了实现私有云计算，我们必须首先确定现有企业基础设施已经包含了这些抽象层（参见图1-1），换句话说，大型企业的数据中心必须进化成私有云。千里之行始于跬步，从云计算角度出发，这关键的一步就是虚拟化。构建私有云基础设施最好的方法是，在继续利用现有企业IT资源的同时，随着时间的发展，逐步将完全虚拟化的未来数据中心（Data Center,DC）迁移。

本章主要讨论数据中心虚拟化，特别是服务器及存储设备的虚拟化，同时也涉及了虚拟服务层访问设计、无回路Layer-2（L2）设计、服务器I/O整合以及数据中心统一光纤。本章将重点探讨通过新兴未来数据中心体系结构及技术，在数据中心构建面向服务的基础设施SOI，实现云基础设施即服务（Infrastructure-as-a-Service,IaaS）。

图2-1是有关云计算各层（子模块）的预览。

·服务器模块

·应用软件层

·虚拟机器层

·虚拟接入层

·计算层

·存储模块

·存储阵列

·SAN层

·SAN扩展

·光纤模块

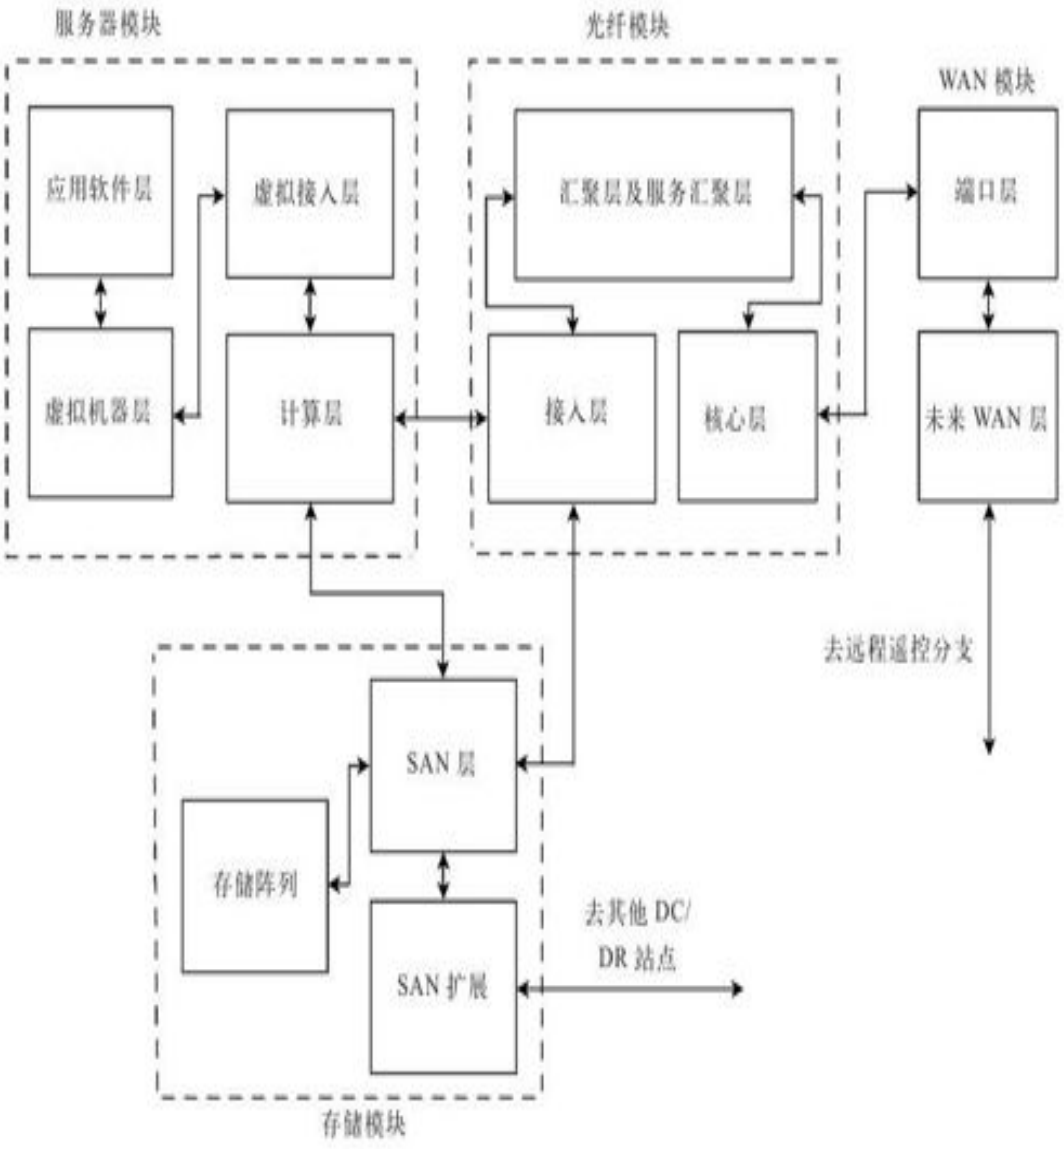


图　2-1　私有云内的各组成模块

·接入层

·汇聚层及服务汇聚层

·核心层

·WAN模块

·对等层

·未来WAN层

第2章内容涵盖了服务器、存储以及光纤模块。有关各层（子模块）功能的更详细介绍，请参见8.4节的内容。

服务器虚拟化有助于将物理服务器整合成虚拟机（Virtual Machine,VM），这些虚拟机必须与某些形式的L2虚拟接入层（参见图2-1）互通。首先需要建立虚拟接入层，更多有关该过程的细节请参见2.3节的相关内容。

实现虚拟接入层后，接下来需要借助SAN（参见图2-1）将存储访问连接到VM。读者也可以借此机会使用各种存储虚拟化技术来整合存储设备。更多存储虚拟化技术的细节信息请参考2.4节的相关内容。

之后是DC LAN的整合，特别是汇聚层和核心层（参见图2-1），现在有很多技术都能完成这一任务，例如，在汇聚层/核心层建立多层交换机的集群，让终端设备感觉就像在访问一台虚拟交换机。更多新兴的L2技术及整合资料请参考2.5节的相关内容。

最后一步是DC LAN和DC SAN的物理访问层之间的整合（参见图2-1）。这里需要实现以太网和光纤通道，传输介质/协议都完全不同的两类网络的融合。我们可以通过整合“无损”10千兆以太网和光纤通道以太网（Fibre Channel over Ethernet,FCoE）得到一个统一的DC光纤。有关服务器I/O整合的更多细节请参考2.6节的相关内容。

2.1 数据中心整合及虚拟化的主要方法

图2-2展示了对DC实施整合及虚拟化的方法。为了便于理解和降低设计复杂度，我们一次只讨论一个主题和模块。图2-2是对图2-1介绍的服务器、存储以及光纤模块更抽象的描述。数据中心通常分成三个部分，关于这些模块的整合和虚拟化将在本章一一介绍。

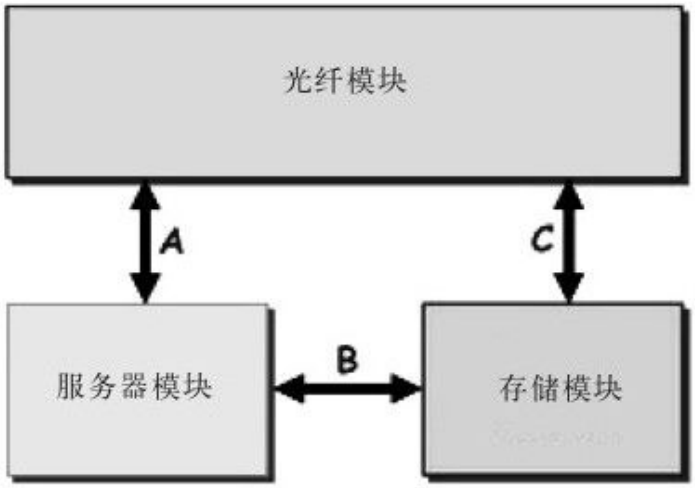


图 2-2 数据中心整合及虚拟化工作流

此外，上述模块之间的接口将被简化成“ABC”，其中，A表示服务器模块与光纤模块之间的接口，B表示服务器模块与存储模块间接口，C表示光纤模块与存储模块之间的接口。后续章节将介绍模块间的连接与附着点。

2.2 服务器整合驱动

尽管实施服务器整合的因素很多，最根本的两个原因在于：服务器散乱以及应用程序“烟囱林立”而产生的数据孤岛。实施新应用的传统模式是——一台服务器运行一个应用，存储子系统相互隔离采用并行方式部署，从长远来看，因为DC和其相关的组件会随着数据规模的不断增长而无限增加，所以这样的模式存在扩展问题。

2.2.1 经典服务器散乱综合症

“服务器散乱”一词是指DC的物理设备所占用的CPU周期、内存、存储等内部系统资源超过了实际所需，并且这些物理设备过度消耗了电能、冷却能量以及设备安置空间的情况。

大多数传统工作模式是一个应用运行在一个服务器上。例如，为了满足开发、测试、备份等需求等产生的新应用都需要增加相应的服务器，因此将新的物理服务器增加到现有DC时，都将相应地提高存储、网络以及安全控制的复杂度。

2.2.2 应用烟囱和数据孤立

如图2-3所示，传统模式中，DC采用独特的烟囱筒仓，即应用程序与各自的服务器和存储设备自成一体，这类应用筒仓模式的架构方式导致了数据间的孤立。

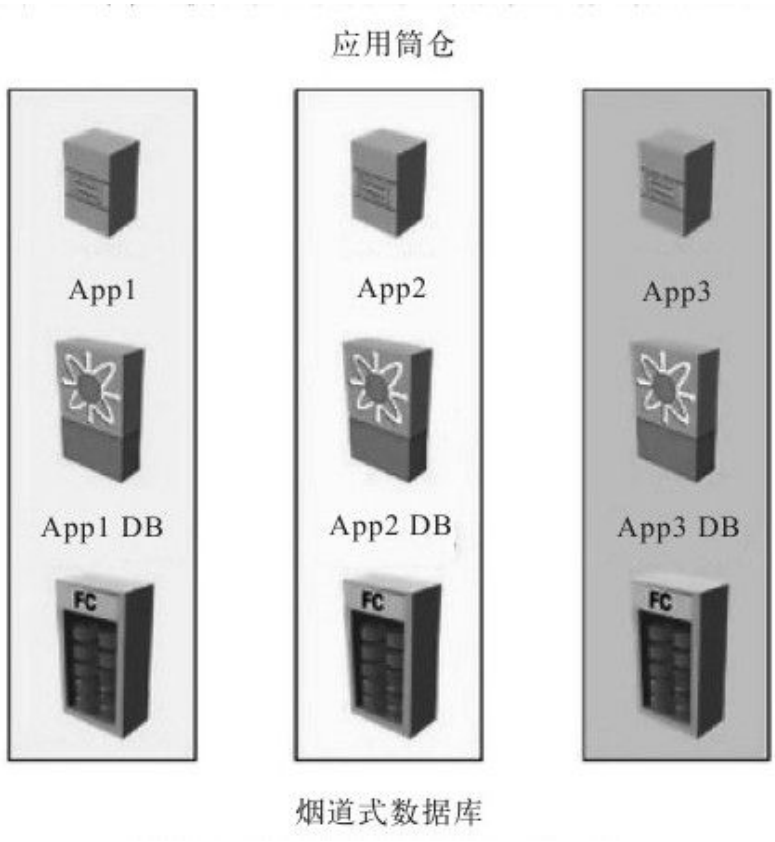


图 2-3 应用筒仓及烟道式数据库

应用筒仓和数据孤立给企业的发展套上了紧箍咒，像这类高度定制设备结构是很难与新应用相结合的，因此也限制了企业为适应业务需求发展而必需的灵活调整能力以及快速为新兴市场提供服务能力，基于这些原因，烟囱式系统不适合私有云计算环境。

说明：从计算角度而言，烟囱式系统是那些紧密绑定进行交互的元素堆积在一起的历史遗留产物，在这样的系统中，无法识别单个元素并对其进行升级或重新部署，这样的系统通常会被保留着直到有一个新系统能整体取代它们。

2.3 服务器虚拟化

虽然解决服务器散乱问题存在许多种方式，但是服务器虚拟化是当前既成事实的标准方法。借助虚拟化技术，一个物理服务器可以变身成很多个逻辑服务器，这也意味着DC内一大堆未充分利用的服务器可以被转换成一个无缝的计算池，与此同时能够将应用程序从它们的烟囱中拆离出来，因此也可以完全废弃烟囱式存储子系统。

服务器虚拟化后最直接的效果如图2-4所示，通过服务器虚拟化可以完成DC物理服务器的整合，减少数据中心所需的物理服务器整体数量，由此而降低的成本让人无法抗拒。而服务器虚拟化减少了物理服务器的数量，意味着更低的能源开销，包括服务器以及冷却系统的能源开销，也因此降低了操作代价（Operation Expenditure,OPEX）和未来DC在硬件设备上或固定资产（Capital Expenditure,CAPEX）上的投入。服务器虚拟化也大大降低了对托管空间的需求，使得企业能够以最小代价获得发展空间。另外，从服务器整合和管理角度出发，服务器、存储和网络相互交织在一起而产生的复杂性也得到相应简化。

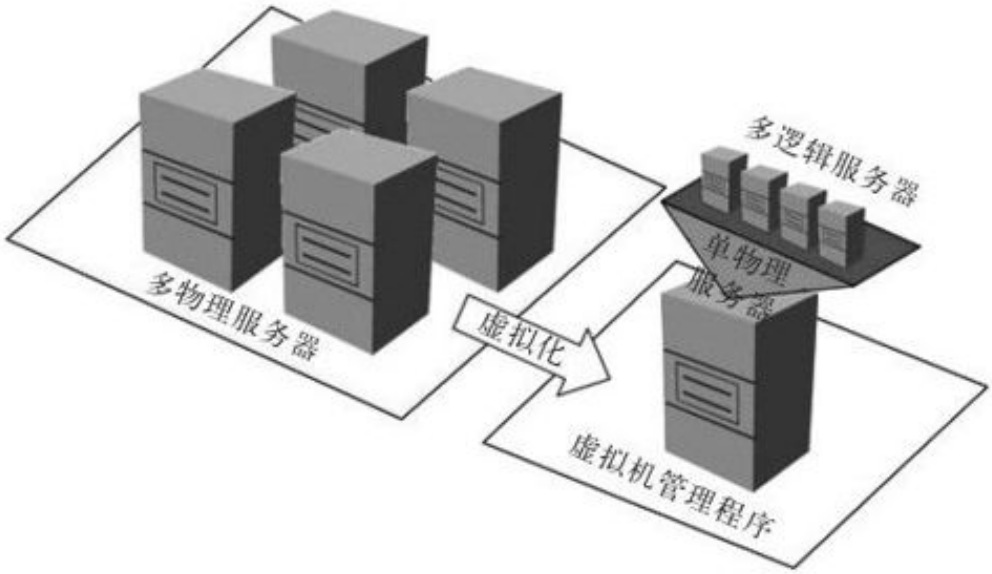


图 2-4 虚拟化下的服务器整合

向云计算迁移并不是一次性的彻底革新，它是一个向完全虚拟化DC渐进式的转移和演变，而现在正是开始这一进程的最佳时机。

2.3.1 虚拟机和监视器

服务器虚拟化采取的是“一对多”的模式，即一个单独的物理服务器被划分后，看起来就像多个相互独立的逻辑服务器一样。每个逻辑服务器分别对应着一个VM，提供一个完整的服务平台，能够支持一个完整操作系统所需的所有工作。一旦划分好物理服务器，每一个逻辑服务器将自动运行相应的操作系统和应用。由于客户端的操作系统不一定相同，因此在同一个物理服务器上以安全可控的模式同时运行几个操作系统和应用程序是可行的。

为支持虚拟环境而研发的更强壮的x86平台，包括了多核CPU、AMD虚拟化（AMD Virtualization,AMD-V）应用和Intel公司虚拟化技术（Intel Virtualization Technology,Intel VT），让服务器虚拟化更加可行。

市场上存在各种各样的虚拟化软件，其中最广为人知的是VMware、XEN和Hyper-V。尽管它们的结构和特性都有所不同，但都是基于VM与VM相互共享硬件资源（CPU、内存、磁盘和单台硬件服务器的I/O设备）这样的概念。一般情况下，虚拟化软件是通过直接在计算机硬件或者主机操作系统之上增加一个精简软件层而实现，这样的软件抽象层一般被称为虚拟机管理程序或者是虚拟机监视器（Virtual Machine Monitor,VMM）。

虚拟机管理程序将基础的物理硬件（如CPU、内存、磁盘和I/O系统）与OS剥离，把实际的物理服务器硬件资源隐藏在分布的VM之后，使得用户感觉好像存在一个逻辑资源池，这些VM能够共享池中资源。虚拟机管理程序的功能包括：

·创建VM；

·将物理服务器硬件资源的虚拟池中的“硬件资源”分配给VM；

·监视VM的状态；

·负责将VM从一个系统迁移到另一系统中。

存在两种类型的监视器：

·I型（又称本地、裸机）虚拟机管理程序：I型虚拟机管理程序直接运行在服务器硬件平台之上，负责硬件控制及用户OS

监控，用户OS运行在硬件之上的第2层。

·II型（又称宿主）虚拟机管理程序：II型虚拟机管理程序作为第2层软件，在监控器层的常规OS环境中运行，而用户OS运行在硬件之上的第3层。

本章服务器虚拟化部分将对两种类型的虚拟机管理程序分别进行探讨。

2.3.2 VMware网络定时器

要了解服务器虚拟化，首先要懂得虚拟机管理程序的网络基础，它属于图2-2中所示的“互连端点A”部分。本章选择VMware ESX服务器作为I型虚拟机管理程序平台的代表，ESX服务器主机通过一个软件虚拟交换机，连接到本地VM以及网络（光纤模块）中。

ESX服务器网络组件

VMware虚拟化环境中的网络接口卡（Network Interface Card,NIC），是一个比物理硬件单元含义更广的术语。确切地说，vmnic是指主机服务器硬件中的物理网络适配器，而vNIC代表虚拟NIC，它是由VMware的硬件抽象层（Hardware Abstraction Layer,HAL）提供给VM的虚拟硬件设备。Vmnic用于通往物理DC光纤模块的上行链路中，在用户OS看来，vNIC和物理NIC一样。VMware能够模仿几种常见的NIC（vlance和Intel e1000），因而用户OS可以对这些vNIC使用标准的设备驱动。图2-5展示了ESX主机的各类接口，在物理主机（ESX服务器）上有4个vmnic以及4个VM，每个VM都单独配置了一个vNIC,vmnic及vNIC均通过虚拟交换机进行连接。

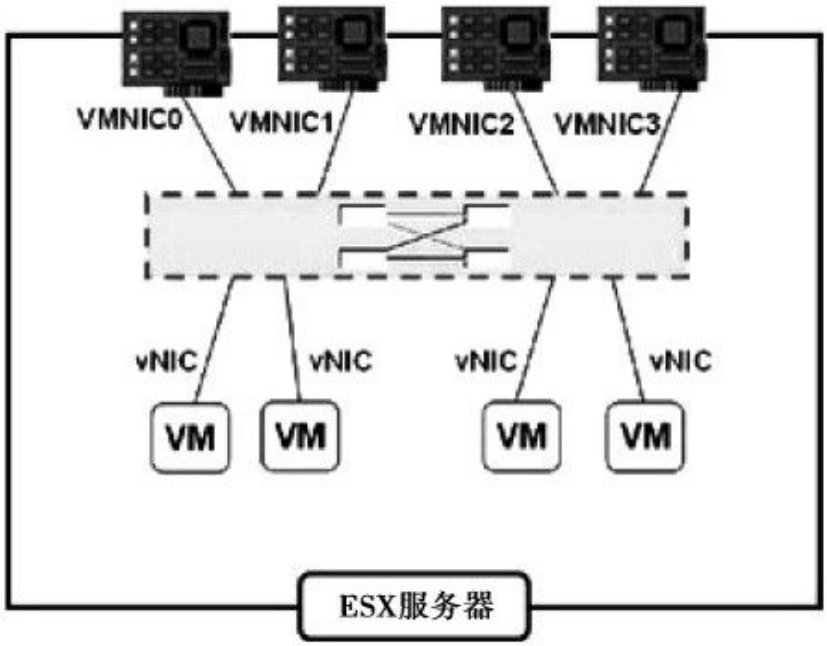


图 2-5 ESX服务器接口

主机上运行的VMware ESX带有一个虚拟管理端口vswif，也称为服务控制接口，ESX服务器使用该接口与VMware vCenter服务器进行通信，管理与VMware vSphere客户直接交互的主机，也可以使用安全外壳（Secure Shell,SSH）登录到主机的命令行接口（Command-Line Interface,CLI）。VMware ESXi主机因为没有服务控制OS，所以不会使用vswif接口。

说明：服务控制OS是一个更新的Red Hat企业linux OS版本，默认安装并运行在每个ESX服务器上。

每个主机都拥有一个或多个虚拟端口，称为虚拟机器核心NIC（Virtual Machine Kernel NIC,vmknic），VMware ESX分别使用这些端口为Internet SCSI（iSCSI）、网络文件系统（network file system,NFS）访问、VMware VMotion提供服务。Vmknics还可以用于VMware ESXi系统中，与VMware vCenter服务器进行通信。

说明：与传统（完备）ESX相比，ESXi属于“瘦”虚拟机管理程序，因为它没有服务控制功能。由于ESXi相对轻便，安装和启动都比ESX要快得多，因此，可以将ESXi嵌入到物理服务器的flash芯片，或者主板等中间。

VMware提供了两种类型的软件虚拟交换机：vNetwork标准交换机（vNetwork Standard Switch,vSS，也称为vSwitch）以及VMware vNetwork分布式交换机（vNetwork Distributed Switch,vDS）。每个主机都会单独配备一个vSS。另一方面，vDS在一组物理主机之间提供了一致的虚拟交换机，这将有助于减少网络维护工作，同时借助网络VMware VMotion就能够实现VM在任意主机间的迁移，而不会对网络协议带来影响或对基本连通性产生破坏。

每一个vNIC都通过端口组连接到标准的vSS或者vDS，每个端口组都属于某个特定的vSS或者vDS，系统也将定义一个VLAN或一组VLAN供vNIC使用。此外，端口组能够指明其他网络属性，比如速率限制以及端口安全等。在随后创建VM的阶段中，编辑VM属性时，可以将VM分配给端口组。

Cisco Nexus 1000也属于vDS，本章将把它作为分布式虚拟交换机平台的样例，更多有关Nexus 1000的详细内容，请参考2.3.3节的相关内容。

vNIC MAC地址及VM迁移

ESX3.x版本的VM能够支持4个vNIC,ESX4.x版本的VM最多能够支持10个nNIC。大多数情况下，vNIC介质访问控制（Media Access Control,MAC）地址由ESX服务器自动生成，不过，管理员也可以静态地定义MAC地址以方便基于DHCP的服务器寻址环境，与静态指定的MAC地址关联的固定IP地址通常都会分配给同一VM。

如果VM之间产生了MAC冲突，ESX服务器主机能够检测到冲突并解决冲突。00：50：56：00：00：00到00：50：56：3F：FF：FF的地址范围是留给静态分配的VM MAC地址，管理员为VM分配的静态MAC地址不能超过该范围。

每个VM都拥有一个带有.vmx后缀的VM参数文件，包含了自动生成的MAC地址信息。文件中还包含了地址生成算法以及定位信息，所以如果移走该文件，VM的MAC地址也可能会发生变化。

使用Vmotion功能特性，ESX服务器可以在ESX服务器集群中将VM从一个物理的ESX服务器迁移到另一个服务器之上。VMotion迁移不会对MAC地址产生影响，如果一个VM使用VMotion从一个ESX服务器迁移到其他服务器上，该VM的MAC地址不会发生改变，因为VMware虚拟机器文件系统（Virtual Machine File System,VMFS）的卷位于SAN上，无论是源ESX主机还是目标ESX主机都能访问到这一信息。

vNetwork标准交换机的局限

VMware将vSS视为虚拟机管理程序的一部分，ESX3.5（作为vSwitch）、ESX4.0以及vSphere 4（作为vSS）都支持该功能。VM通过vNIC连接到vSS，如果两个VM分别带有一个vNIC并连接到同一个vSS，相互之间希望通信，vSS将直接承担起一个L2交换功能，不需要将网络传输流转发到物理或外部DC光纤模块完成。因为嵌入式vSS的主要优势就在于其简单，所以每个虚拟机管理程序都带有一个或更多的vSS的独立实例。不过，vSS的局限性则超过了它的优势：

·配置缺乏可扩展性：因为每个嵌入式vSS都代表了配置（对每个ESX服务器都具备局部重要性）中一个独立点，所以

当在DC中需要部署多个ESX服务器时，将遇到配置可扩展问题。

·贫乏的操作可控性：大多数情况下，网络管理员访问不到vSS，因此尽管vSS也是网络的一部分，但并不如其他DC基础设施一样易于管理，因而在由vSS（也同样被看成不受控的网络设备）创建的非受控网络上对VM进行维护和安全管理也逐渐成为服务器（或VM）管理员所面临的挑战，特别是当系统中VM数目不断增加时更是如此。vSS会在DC基础设施关键部位——服务器集群中引起严重的操作不一致性。

说明：当物理服务器散乱伴随着VM产生时，同样也会带来另一种散乱——VM散乱。因此简化VM配置的管理以及维护对服务器虚拟化非常重要。

分布式虚拟交换机

嵌入式vSS的局限性可采用分布式虚拟交换机（Distributed Virtual Switch,DVS）来克服，DVS能够同时支持多达64个ESX主机交换，而不需要像vSS一样对每个主机进行单独配置。DVS从根本上将嵌入式虚拟交换机的控制及数据平面分离，它支持由集中管理系统（控制平面）对多个、相互独立的vSS（数据平面）进行管理，有效地使服务器管理员从主机级别网络配置中抽身而出，转到ESX集群级别的网络连通性管理上。

VMware上实现的DVS也称为vNetwork分布式交换机（VNetwork Distributed Switch,vDS），可以通过VMware vCenter服务器完成vDS配置。Cisco使用Nexus 1000V系列交换机对DVS上的框架进行调整，ESX/i 4.0以及vSphere 4及以上版本均支持DVS。

总而言之，我们更推荐使用Nexus 1000V系列DVS，因为与vDS相比，前者功能更丰富，健壮性也更好。Nexus 1000V交换机是本章探讨DVS平台的样例，更多有关Nexus 1000V系列交换机的详细内容，请参考2.3.3节的相关内容。

2.3.3 Cisco Nexus 1000V交换机

Nexus 1000V（NX1KV）属于分布式软件交换机，能够跨越在运行VMware ESX/i 4.0的多个主机之间。它克服了vSS或vSwitch的缺点。NX1KV包括两个主要部分：

·虚拟监视器模块（Virtual Supervisor Module,VSM）：此模块组成了交换机的控制平面，是一个运行NX-OS的VM。

·虚拟以太网模块（Virtual Ethernet Module,VEM）：此模块组成了交换机的数据平面，通常系统中会部署1个或多个VEM。VEM本质上是一个虚拟线卡，被嵌入到每个ESX/i 4.0主机中，由它实现L2转发功能。每个ESX服务器主机只能安装一个单独的VEM。

这两个模块完成了对物理交换机的抽象：监视器模块是VSM，而线卡是每个ESX/i 4.0主机中运行的VEM。所有的配置都在VSM上进行，并传播给所有属于同一个域（更多细节，请参考后面“域ID”小节相关内容）的VEM。图2-6展示了NX1KV的组件。

在物理交换机中，监视器模块及线卡共用一个内部交换光纤来进行通信，在NX1KV中的监视器模块及线卡从物理上被分离开来，尽管它们在逻辑上看起来还像在同一个交换机中工作，但却是使用外部光纤（外部DC网络）而非内部光纤来完成彼此间通信。VEM上的物理NIC是通往外部光纤的上行链路，从VM vNIC到本地虚拟以太网端口间的数据传输由VEM负责转发，但是VEM并不会直接将数据转发给其他VEM。相反，源VEM将包发往上行链路，然后通过外部光纤将这些包转发给目标VEM。VSM不在数据路径中，并不参与实际的数据包转发。

虚拟接入层是服务器虚拟化的前端，可以使用NX1KV来构建虚拟接入层。更多有关使用NX1KV进行虚拟接入层设计的案例，请参考9.1节的相关内容。

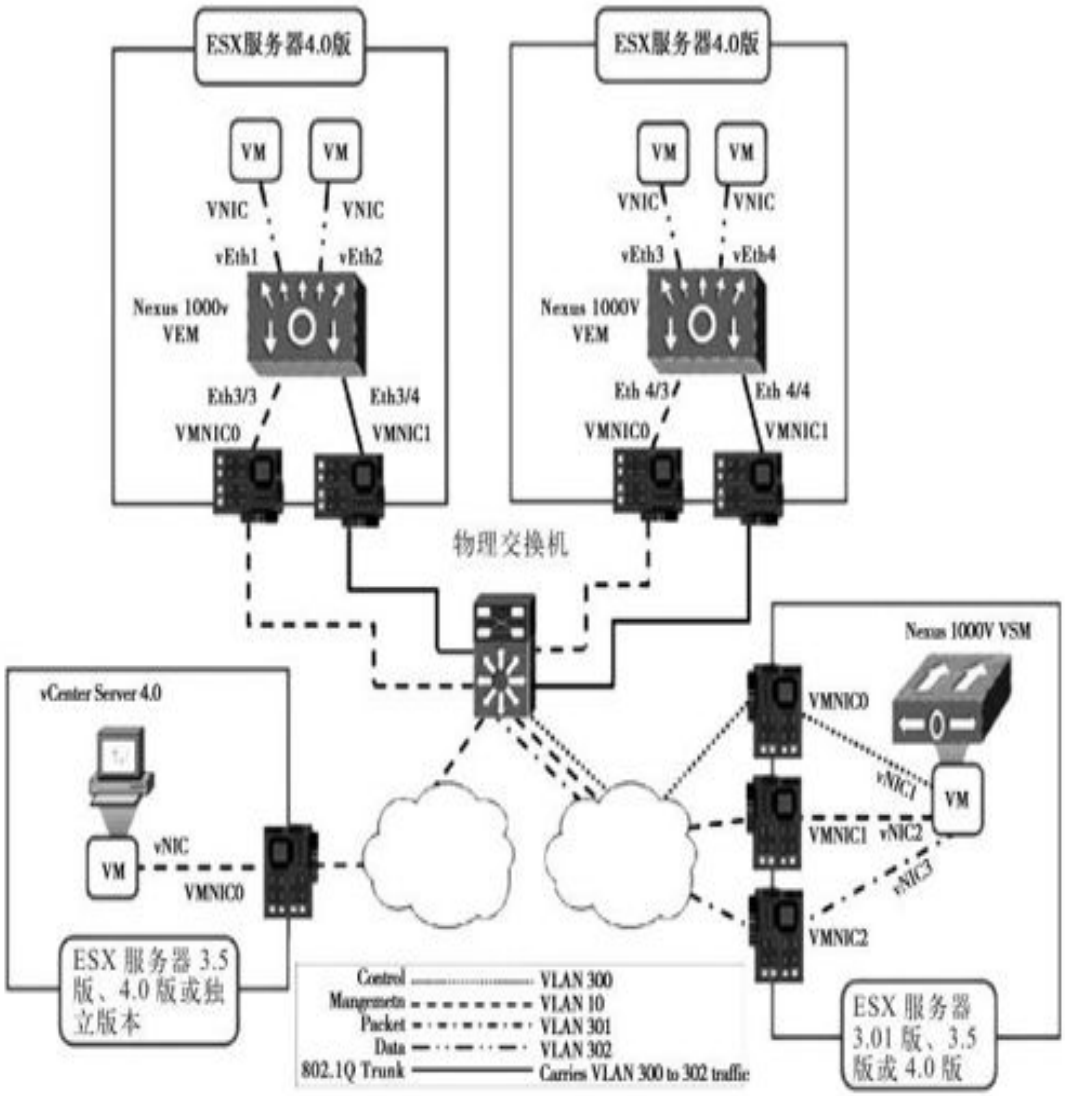


图　2-6　Nexus 1000V（NX1KV）组件

说明：为了遵守NX1KV VSM/VEM的惯例及术语，“包”与“帧”两个术语在本节及它的子章节中可以互换使用。

虚拟监视器模块

VSM建立了NX1KV的控制（管理）层，它为网络管理员提供了跨越多个VEM的单点配置管理。与传统交换机将控制平面集成到硬件中不同，VSM被部署成一个运行NX-OS的VM，也就是一个OS。即可以使用IOS文件也可以使用公开虚拟化格式模板（Open Virtualization Format,OVF）来安装VSM。

说明：作为在VM上运行VSM的替代，VSM也有一个物理设备实体——NX1010，用户能够使用Nexus 1010同时运行最多

4个NX1KV VSM。

安装了VSM/NX-OS的VM与其他OS拥有相似的基本系统需求。VSM要求有一个单独的虚拟CPU，2GB的指定RAM，以及3个vNIC，这3个vNIC需具备以下功能：

·控制接口：控制接口属于L2接口，VSM使用该接口与VEM进行通信。该接口负责处理低级别控制包，包括心跳以及任何需要在VSM及VEM之间进行交换的配置数据。控制接口通常是VEM的第一个接口，在VM网络属性中以“网络适配器1”身份进行注册。

·管理接口：在常见的Cisco交换机中，管理接口通常为mgmt0端口。为了便于管理，会为mgmt0分配一个IP地址。该接口负责建立并维护VSM与VMware vCenter服务器之间的连接。管理接口一般都是VSM上的第2个接口，在VM网络属性中以“网络适配器2”身份进行注册。

·包接口：包接口也是一个L2接口，只负责两种类型的控制流传输：Cisco发现协议（Cisco Discovery Protocol,CDP）及Internet组管理协议（Internet Group Management Protocol,IGMP）。当VEM接收到一个CDP包，VEM会将该包重新转发给VSM,VSM对包进行分析后，会将包转送到CDP入口。包接口同时还负责协调多个VEM间的IGMP。例如，当一个VEM接收到一个IGMP请求时，该请求将被发送给VSM，由VSM负责协调交换机上所有VEM之间的请求。包接口通常为VSM上的第三接口，在VM网络属性中以“网络适配器3”的身份进行注册。

说明：VSM VM的vNIC要求Intel e1000网络驱动，e1000网络驱动并不是建立VM时的默认驱动，因而有可能当定义VM时，OS并不一定能够支持它。不过，用户可以手动改变VM参数文件中的驱动器。使用“Other Linux 64-bit”作为OS，就可以激活e1000驱动器，并且将其设置成默认驱动。

NX1KV使用了虚拟机箱的概念来模仿一个66槽模块化以太网交换机，该交换机具有一些冗余功能：

·槽1是为活动VSM保留的。

·槽2是为双工监视器系统的从VSM保留的。

·当主机都接入到NX1KV交换机时，槽3～66以顺序方式分别分配给相应的VEM。换句话，一个VSM最多可以管理64个VEM。

说明：用户可以通过改变“host vmware id”配置顺序来更改VEM-到-槽-序号的映射关系，更多有关该命令的详细内容，请参考2.3.3节的内容。

高可获得性及VEM

一个VSM可以扮演如下角色：

·active：active角色负责系统控制，在mgmt0接口上进行配置。

·standby：standby角色监控active VSM的状态，如果发生交换机切换，则取而代之。

·standalone：standalone角色是没有其他active-standy配置时，VSM端默认配置模式。

说明：调用“system redundancy role{standalone/primary/secondary}”命令可以控制

VSM角色类型，调用“show system redundancy status”命令可以验证VSM的系统冗余状态。要记得执行“copy running-config startup-config”命令来保存配置信息，维持系统重启后的一致性。更多有关这些命令的细节信息，请参考2.3.3节的相关内容。

NX1KV交换机的高可获得性（High Availability,HA）部署更像是在物理机箱中配置双工监视器。在虚拟机箱中，两个VSM以active-standby方式配置，槽1留给active VSM，而槽2留给standby VSM。第一个VSM将承担active VSM角色，而其他VSM将默认为standby VSM。在固定间隔内，将对两个VSM的状态及配置信息进行同步，来保证在active VSM发生故障时，能够进行透明和稳定的交换机切换（Stateful Switchover,SSO），将工作移交给standby VSM。

VMware vCenter及Nexus 1000V

NX1KV交换机的实例在VMware vCenter服务器中被表示成vDS。借助vDS，一个虚拟交换机能跨越多个ESX主机的虚拟交换机。在建立VSM与vCenter服务器之间的链路时，可以使用

VMware虚拟基础架构方法体系（Virtual Infrastructure Methodology,VIM）应用程序接口（Application Programming Interface,API）在vCenter服务器上构建NX1KV交换机。

说明：VMware的管理体系被分隔成两个主要模块：DC和集群。DC包括了所有VMware部署组件，如主机、VM以及网络交换机，像NX1KV。在VMware DC内，一组主机与VM所组成的CPU及内存资源池构成了一个集群，用户可以创建一个或多个集群，然后在集群内创建VM或在属于该集群的主机间任意迁移VM。主机和VM不一定必须是集群的一部分，它们也可以驻留在DC上。

Nexus 1000V vCenter服务器扩展

vCenter服务器支持第三方管理插件对vCenter服务器功能及它的图形化用户界面（Graphical User Interface,GUI即vSphere客户端进行扩展。NX1KV交换机使用vCenter服务器扩展来展示NX1KV及其在vSphere客户端的主要组件。NX1KV扩展是一个小的XML文件（cisco_nexus_1000v_extension.xml），可以使用Web浏览器从VSM的管理IP地址上下载，插件必须在VSM之前安装，才能建立一个到vCenter服务器的链路。

Opaque数据

Opaque数据包含了一组NX1KV配置参数信息，由VSM进行维护，当VSM与vCenter服务器之间的链路成功建立后，将传播给vCenter服务器。Opaque数据还包含了每个VEM所需的配置信息，当安装VEM时，VEM可以利用这些配置信息建立与VSM间的连接。这些信息包括：

·交换机域ID

·交换机名称

·控制及包VLAN ID

·系统端口属性文件

当一个新的VEM加入后，无论是初始化安装后还是当ESX主机重启后，VEM均类似于一个未编程线卡。vCenter服务器将自动向VEM发送opaque数据，随后VEM将利用这些信息与VSM建立连接，然后下载正确的配置数据。

VSM到vCenter的通信

VSM与vCenter之间的链路负责保持vCenter服务器内的NX1KV交换机定义，同时负责传播端口参数文件（参见后面的“端口参数文件”的内容）。当NX1KV vCenter服务器插件安装完毕，链路也随之定义成功。连接包括了以下参数：

·vCenter服务器IP地址

·通信协议——HTTP之上的VMware VIM

·ESX主机驻留的VMware DC名称

当连接建成后，除了链路外，还在vCenter服务器内创建了一个NX1KV交换机。每个VSM都通过一个唯一的扩展键连接到vCenter服务器。在创建交换机实例的过程中，VSM将把之前定义好的所有端口参数文件及opaque数据传播给vCenter服务器，opaque数据向VEM提供了规定好的配置信息，使得VEM安装后就能与VSM通信。

如果VSM和vCenter服务器之间的连接发生故障，一旦连接恢复，VSM将必须确保故障期间所有配置更改信息都必须及时告知vCenter服务器，VSM与vCenter服务器之间的链路也将负责在连接建成后，传播新的端口参数文件以及任何对现有系统的更改信息。

虚拟以太网模块

VEM的作用类似模块化交换平台中的线卡，从转发的角度来看，每一个VEM都是一台独立的交换机。不同于VSM,VEM将作为核心组件，按照在每一个ESX主机而非VM上。VEM的存储空间是固定的（大约需要6.4MB的磁盘空间），而它的RAM使用是可变的。

常规配置方案中，每一个VEM需要10～50MB的RAM，而如果要求能够充分发挥VEM的扩展性，则最多需要150MB空间。每一个NX1KV实例交换机包括66个槽——2个留给VSM，剩下的64个留给VEM。最低配置是一个VSM（无法实现VSM高可获得性）加一个VEM，而最高配置是2个VSM（一个为active，一个为standby）加64个VEM。

VEM交换机端口分类

VEM能够支持如下类型的交换机端口：

·虚拟以太网（Virtual Ethernet,vEth）：该端口负责连接到VM的vNIC上，或者是某个指定类型接口，诸如vswif或vmknic接口。vEth接口属于没有关联物理组件的虚拟端口，vEth接口可以表示成vEth Y，这里的Y代表具体的端口序号。借助VMotion，标注对VM是透明的，即不论相关联的VM的具体位置，接口名称都是一样的。当创建好一个新的VM后，与该VM所关联的vNIC的vEth接口也相应被创建。vEth接口与VM拥有同样的生命周期，如果某个VM被临时性关闭（用户OS关闭了），vEth接口将仍然保持活动状态，并且映射到原来的VM上，如果删除该VM，系统将释放与之连接的vEth接口资源，以便它能够为新加入的VM提供服务。

·以太网（Ethernet,Eth）：接口代表了某个VMNIC（物理NIC），可以表示成EthX/Y，其中X代表模块序号，而Y代表模块上的端口序号。这些Eth接口分别对应着特定的模块。

·端口通道（PortChannel,Po）：端口通道是同一VEM的多个Eth接口汇聚之处，它不能由系统默认生成，必须显式说明。

端口参数文件

NX1KV提供了一个名为端口参数文件的功能特性，这是一些网络协议，VMware使用它来简化网络服务。端口参数文件是一组接口级配置命令，被加工整理成一个完整的网络协议。VSM负责制定端口参数文件，并通过VMware-VIM API将它传播（输出）到vCenter服务器，在NX1KV上配置好的端口参数文件看起来就像分布在vSphere客户端的一个VMware分布式虚拟端口组，类似一个标准的vDS。一个新加入或现有的VM能够拥有独立的vNIC，并分配到正确的虚拟端口组，这些端口组继承了端口参数文件的设置。

当认可一个新加入的VM后，系统将选择合适的端口参数文件，NX1KV会基于该端口参数文件定义的协议创建一个新的交换机端口，可以通过重用端口参数文件来降低类似VM服务的工作量。当新开通的VM启动后，NX1KV交换机将为VM带有的每个vNIC都创建一个vEth接口，这些vEth继承了之前所选定的端口参数文件的定义。代码清单2.1给出了一个vNIC端端口参数文件配置模板的样例。

代码清单2.1　vNIC端数据参数文件配置模板

```
port-profile type vEthernet data302
  description "Data profile for VM traffic"
  switchport mode access
  switchport access vlan 302
  no shutdown
  vmware port-group data302
  state enabled
```

端口参数文件属于动态协议，当网络需求发生改变时可以对其进行修改，对主端口参数文件的更新将被应用到使用该参数文件的每个交换机端口上。端口参数文件同样也负责管理ESX主机上的物理NIC（physical NIC,VMNIC），这些参数文件也称为上行链路端口参数文件，将分配给物理NIC，这一信息也包含在ESX主机安装VEM的工作中。当添加某个ESX主机到交换机中后，上行链路参数文件会同样分配给新加入VEM的物理NIC。代码清单2.2展示了一个VMNIC末端的端口参数文件配置模板样例。

代码清单2.2　VMNIC端上行链路参数文件配置模板

```
port-profile type Ethernet vm-uplink
  description "Uplink profile for VM traffic"
  capability uplink
  switchport mode trunk
  switchport trunk allowed vlan 300-302
  no shutdown
  vmware port-group vm-uplink
  state enabled
```

说明：如果配置某个参数文件为上行链路（调用可选“capability uplink”命令），就只能把它分配给物理端口（physical port,Eth），而不能再用它来配置虚拟端口（virtual prot,vEth）。

VM的整个生命周期中，都将通过端口参数文件来强化网络协议，而不论该VM是否会从一个服务器迁移到另一个服务器上，或者是挂起、休眠还是重启。在VM迁移中，诸如端口计数器以及流统计信息，所有VM所参与的网络传输检测活动，包括NetFlow、封装远程交换端口分析器（Encapsulated Remote Switched Port Analyzer,ERSPAN），在有了VMotion后都能不受

干扰地执行。而这一点正是云IaaS操作所需要的关键可管理性。

该谁了：服务器还是网络管理员

在典型的DC操作环境中，服务器管理员通常负责管理OS以及应用，而网络管理员则控制交换机以及相关协议。NX1KV交换机保留了网络管理员与服务器管理员不同的功能角色，同时还创建了一个新的角色，该角色综合了网络及服务器管理员的功能，这一点也是通过端口参数文件完成的（更多细节请参见本章的“端口参数文件”的相关内容）。

网络管理员负责定义端口参数文件，并将它们输出给vCenter服务器，端口参数文件在vCenter服务器中类似普通的VMware端口组。当系统为新加入的VM提供服务时，服务器管理员将挑选合适的端口参数文件，NX1KV将基于该参数文件创建新的交换机端口，服务器管理员也可以通过重用该参数文件来简化对其他类似VM的服务。

VEM到VSM的通信

类似VSM，每一个VEM都拥有一个控制和包接口。这些接口是不可控的，终端用户不能直接配置接口。VEM借助vCenter提供的opaque数据在合适的VLAN上完成对这些控制及包接口的配置工作，并将这些正确的上行链路参数文件应用到控制及包接口，以便和VSM之间建立连接。当VSM识别出VEM后，一个新模块将被虚拟地插入到NX1KV交换机的虚拟机箱中，VEM随后将被分配得到一个3～66中最小可得的模块序号，VEM首次启动时，VSM将会分配该模块序号给VEM，并在ESX服务器上使用全局唯一ID（Universally Unique ID,UUID）对该VEM进行追踪。UUID能够确保即使发生连接超时或电力故障使得ESX主机掉线，在故障解除后，VEM也能够保留它的模块序号。

VSM负责维持与它相关的VEM之间的心跳信号，信号每次传输间隔为2秒，如果VSM在8秒内没有接收到应答消息，VSM将认为该VEM已经被移除到虚拟机箱之外。如果VEM是因为连接问题而无法进行应答，VEM将在它最后的正常状态时间段中坚持转发包，当运行中的VEM与VSM之间的连接恢复后，VEM就不需要再次被重新编程。

系统VLAN

系统VLAN是端口参数文件中的可选部分，如果采用系统VLAN，该参数将把端口参数文件变成特定系统端口参数文件，然后包含在opaque数据中。使用系统端口参数文件的接口都是系统VLAN的成员，即使是ESX重启后VEM与VSM间还未建立起连接，接口也将被自动激活。这样一来，在ESX主机重启后还未与VSM建立连接也能保证关键VMNIC的可用性。可以手动地将控制及包VLAN也定义成系统VLAN，用在vswif以及vmknic的VLAN也可以看成系统VLAN。不过，传递普通VM数据的VLAN不能被当做系统VLAN处理。代码清单2.3给出了一个关键端口的端口参数配置模板。

代码清单2.3　关键端口的系统参数配置模板

```
port-profile type ethernet system-uplink
  description "System profile for critical ports"
  switchport mode trunk
  switchport trunk allowed vlan 300-302
  no shutdown
  system vlan 300-302
  vmware port group system-uplink
  state enabled
```

域ID

由于多个VSM及VEM之间可以共享相同的控制及包VLAN，因此系统必须要能够确定此VSM应与哪个VEM连接，使用域ID则可以将VSM绑定到VEM中。NX1KV交换机使用域ID参数用来确定VSM及其相关联的VEM，当系统首次安装VSM后，将创建一个域ID，并作为opaque数据的一部分传送给vCenter服务器，VSM向其关联的VEM所发出的每一条命令都带有域ID标识。

当VSM和VEM共享同一个域ID时，VEM将接受并响应该VSM的命令。VEM会自动忽略那些未包含正确域ID标识的命令或配置请求。如图2-7所示，域ID18“连接”了两个属于同一VSM的VEM，它们均属于同一个vDS，域28也属于相同情况。

交换转发

与带有集中转发引擎的物理交换机不同，每一个VEM都维护着一张单独的转发表，不同VEM之间的转发表不需要同步。

此外，也不存在从一个VEM的端口转发到另一个VEM的端口这样的概念，转发给非本地VEM的设备的包将首先被转发至外部网络交换机，然后再被转发给不同的VEM。

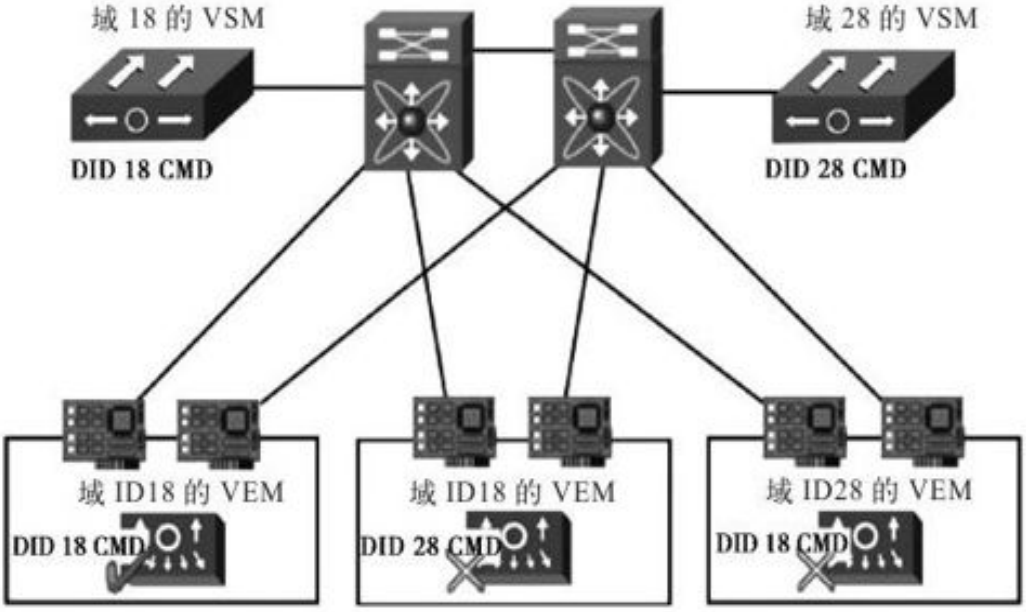


图　2-7　域ID样例

MAC地址学习

无论是静态方式还是动态方式，在一个NX1KV交换机中MAC地址都可能被多次学习。当VM运行在VEM上时，系统将自动生成静态入口，这些入口不会随时间失效。对于那些没有运行在VEM上的设备，VEM能够通过ESX主机上的物理NIC动态学习到MAC地址。换句话，与本地附加的VM有关的入口可以静态习得，而与上行链路有关的MAC入口地址可以动态习得。来自其他ESX主机的VEM都维护了一个单独的MAC地址表，因此，同一NX1KV交换机可能多次学习到同一给定MAC地址——每VEM一次。例如，某个VEM是直接连接到VM,VEM将静态得到该VM的MAC地址，而另外一个VEM，也属于同一NX1KV交换机，可能就是通过动态学习得到VM的MAC地址。

回路预防

NX1KV交换机不支持生成树协议（Spanning Tree Protocol,STP），也无法响应及生成桥接协议数据单元（Bridge Protocol Data Unit,BPDU），NX1KV交换机会丢弃所接收到的BPDU包。

NX1KV交换机使用一种简单的不需要STP的方法来预防回路产生。在以太网（Ethernet,Eth）接口所接收到的每个汇入包都需要检查其目的地址，以确保所有包的目标MAC地址都是指向VEM内部，如果目标MAC地址属于VEM外部范围，NX1KV交换机将丢弃这样的包，以防止指向物理网络的回路产生。

NX1KV交换机无须使用STP就能够防止VEM及第一跳接入层交换机之间的回路，不过，接入层交换机仍然需要激活STP，以防止物理拓扑上其他地方产生回路。

2.3.4 ESX服务器存储网络概略

如果读者能坚持读到此处，在继续之前应该给自己一些鼓励，现在你已经完成ESX服务器网络化的第一步，接下来该着手解决ESX服务器存储网络化的基础问题了。这部分内容对应图2-2中的“互联点B和C”部分，也就是连接服务器模块与存储模块（直接连接或通过光纤连接）的部分。

说明：互联点C通常不会采用光纤通道，服务器模块通过互联点A连接完成NAS和FCoE接入才会使用的技术。

ESX服务器存储组件

ESX服务器存储操作主要由以下5个存储组件完成：

·虚拟机器监视器（Virtual Machine Monitor,VMM）：VMM（或虚拟机监视程序）包含的层，能够在VM内模仿小型计算机系统接口（Small Computer System Interface,SCSI）设备。VMM提供了一个抽象层，能够隐藏并管理物理存储子系统之间差异。对每个VM内的应用及用户OS而言，存储就是一个SCSI磁盘，只不过该磁盘是连接到虚拟BusLogic或者是LSILogic SCSI主机总线适配器（Host Bus Adapter,HBA）上。

说明：VM使用BusLogic或LSILogic SCSI驱动，BusLogic意味着系统采用的是Mylex BusLogic BT-958，BT-958属于SCSI-3协议，支持Ultra SCSI（Fast-40）传输速率为每秒40MB。驱动模拟支持“SCSI自动配置”功能，例如，SCAM允许使用ID序号自动配置SCSI设备，因而不需要人工分配ID。

·虚拟SCSI层：虚拟SCSI层的首要任务是管理SCSI命令并负责VMM与虚拟存储系统之间的连接，这些虚拟存储系统既可以是虚拟机器文件系统（Virtual Machine File System,VMFS），也可能是网络文件系统（Network File System,NFS）。所有来自VM的SCSI命令必须经过虚拟SCSI层，这一层还负责管理I/O放弃和重置操作。在这一层，通过VMFS、NFS或原始设备映射（Raw Device Mapping,RDM），虚拟SCSI层将来自VM的I/O或SCSI命令传送到更低层。RDM支持两种模式：pass-through和nonpass-through。在pass-thruogh模式下，所有SCSI命令都能通过虚拟SCSI层，而不会受到阻拦。有关RDM的详细内容请参考本章后面的“裸设备映射”的相关内容。

· 虚拟机器文件系统（Virtual Machine File System,VMFS）：VMFS属于集群文件系统，能够协调共享存储支持多个ESX主机同时读写同一存储。VMFS支持磁盘分布式锁机制，能够确保同一个VM在同一时刻不会被多个服务器启动。在简单配置方案中，VM的磁盘将被看成VMFS中的文件。更多VMFS的内容请参考本章后面的“虚拟机器文件系统”的相关内容。

·SCSI中层：SCSI中层的主要作用是管理ESX服务器主机上的物理HBA，维护请求队列以及处理SCSI错误。此外，该层还包括自动重复扫描登录，可以发现逻辑单元号（Logical Unit Number,LUN）到ESX服务器主机间的映射变更。它同时还负责处理路径管理，包括自动路径选择、路径重叠、故障切换以及恢复到某个指定卷。

·虚拟SCSI HBA：在ESX服务器环境中，每个VM最多能够使用4个SCSI HBA，而虚拟SCSI HBA能够支持VM对逻辑SCSI设备的访问，对VM而言，虚拟SCSI HBA等同于一个物理HBA。

虚拟数据存储的概念

VM内的虚拟SCSI磁盘均由虚拟数据存储提供，这些虚拟数据存储源自物理存储系统。一个虚拟数据存储类似一个虚拟存储池，能够为VM内的虚拟磁盘提供存储空间，也能存储相应的VM定义。

虚拟磁盘（vmdk）是一个驻留在虚拟数据存储中由ESX管理的文件，虚拟数据存储属于VMFS卷，是实现基于块的存储（类似光纤通道SAN以及iSCSI）的基础，也是NAS存储（基于NFS的卷）的挂载点。VMFS卷通常由单个LUN组成，不过它也能跨越多个LUN。虚拟数据存储可以是如下任意一种文件格式：

· 虚拟机器文件系统（Virtual Machine File System,VMFS）：ESX服务器会在本地SCSI磁盘（DAS）、iSCSI卷或光纤通道卷上部署该类型的文件系统，为每个VM创建一个目录，在大多数虚拟数据存储中，都推荐使用VMFS。

·裸设备映射（Raw Device Mapping,RDM）：RDM支持VM把RDM当做代理来直接访问裸设备。一个RDM可以被理解成是

一条VMFS卷到RDM卷的象征链路。

·网络文件系统（Network File System,NFS）：ESX服务器能够使用NFS服务器（NAS设备）上一个指定的NFS卷，ESX服务器将挂载该NFS卷，并为每个VM创建一个目录。

总的来说，虚拟数据存储仅仅是一个VMFS卷或者一个NFS挂载目录。一个VMFS卷能够跨越多个物理存储子系统以便实现扩展。虚拟数据存储提供了一个简单的模型，无须将VM暴露在各式各样复杂的物理存储技术中，就能为每个VM分配存储空间。这些技术包括：

·FC SAN：由于FC SAN能够支持VMFS、RDM以及HA集群，因此是一种应用最广泛的部署选择。FC SAN还支持VMotion及ESX引导。

·iSCSI SAN：基于硬件的iSCSI SAN支持的功能类似FC SAN，如果使用了基于软件的iSCSI，则不能够支持从iSCSI SAN进行引导。

·NAS：这一种部署将使用NFS协议，基于NFS的存储不支持RDM、HA集群以及VMFS。按理说，通过NFS，比借助基于块的存储，更容易进行瘦管理、存储动态扩展/收缩，以及克隆，不过两者差别不大。

说明：DAS是一种合法部署，但由于它不提供共享，因此很少使用。

图2-8展示了一个ESX服务器存储体系结构，该结构中使用了VMFS卷和挂载NFS卷。每一个VM都被以一组文件形式存放在它自己的虚拟数据存储目录中。一个单独的VMFS卷能够包含一个或多个更小的卷，这些卷来自FC SAN磁盘或iSCSI SAN磁盘集群。新产生的卷可以被加在任意一个物理存储、子系统或随着存储子系统一起被扩展的ESX服务器能获悉的LUN中，并且将因为vCenter服务器向ESX服务器发送重新扫描的请求而被发现。

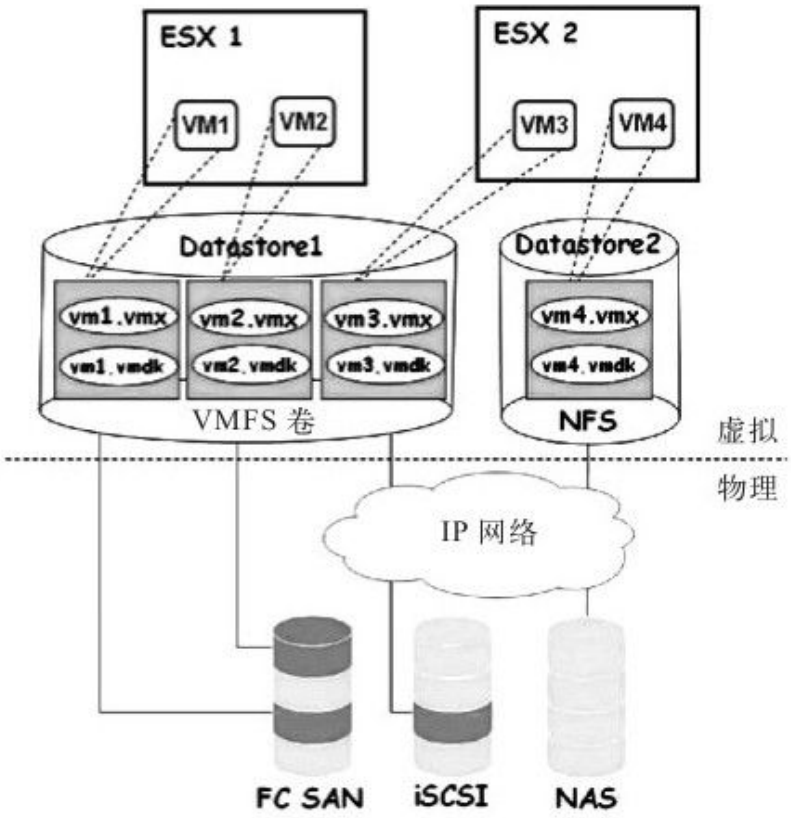


图　2-8　ESX服务器存储的体系结构

说明：在某种程度上，ESX服务器实现了基于主机（或服务器）的存储虚拟化，因为VMFS卷能够支持FC和iSCSI SAN的块级别虚拟化。

虚拟机器文件系统

VMFS存储了VM文件，包括磁盘映像、快照等，它属于聚簇文件系统，通过存储共享以支持多个物理服务器同时读写同一存储空间，同时对单独的VM上锁以预防发生冲突。VMFS提供了到磁盘的分布式锁机制以保证同一VM不会在同一时间被多个服务器占用。如果某个物理服务器发生故障，该服务器对VM加上的磁盘锁将被释放，以便其他物理服务器能够重新启动该VM。

通过将多个VMFS卷绑在一起，能够对VMFS卷进行逻辑扩展（例如，无损规模增长）。ESX服务器3.x以及vSphere 4.x支持VMFS版本3（VMFS3），它能够在文件系统中引入一种目录结构，更早一些的ESX服务器版本不支持对VMFS3卷的读写操作。自ESX 3以及VMFS3版本起，VM配置文件默认存放在

VMFS分区中。一个VMFS卷能够扩展到32个物理存储扩展（每个VMFS卷可拥有32个扩展卷），包括SAN卷及本地存储，这一功能特性能够满足VM对创建存储资源卷的灵活性及资源池的需求。

对VMFS进行优化是为了实现存储和访问大容量文件，由于使用了大尺寸块，VM磁盘性能与本地SCSI磁盘相差无几。VMFS磁盘越大，元数据存储所需的空间比例就越低，VMFS磁盘还能利用自有逻辑自动检测到LUN的变化。VMFS还能够支持诸如分布式日志、冲突一致性VM I/O路径以及机器状态快照等功能，从而能够实现对VM、物理服务器以及存储子系统的快速根本原因分析及恢复。

裸设备映射

VM使用裸设备时可以采用两种映射模式：

·虚拟模式：该模式下系统隐藏了被映射磁盘的实际物理特征，因此用户OS感觉被映射的磁盘像一个逻辑卷，或者虚拟文件系统。文件上锁可以对并发更新时数据进行隔离从而能够保护数据，写操作复制可以启动快照，由于虚拟模式支持虚拟磁盘文件的一致性行为，因而具备了存储硬件之间的可移动性。

·物理模式：该模式类似传递模式（pass-through），VMM绕过I/O虚拟化层（虚拟SCSI层），将所有I/O命令直接送给存储设备。所有底层存储设备的物理特性都将暴露给用户OS。该模式适用于用户在VM中使用了SAN感知设备的情况。不过，付出的代价就是VM以及物理节点RDM不能被复制，或者生成某个模板，也不能在有磁盘复制操作时进行迁移。该模式下系统不会提供锁机制来实现数据保护。

RDM为VM直接访问物理存储子系统（采用FC或iSCSI）上的卷提供了一定的灵活性，它在VMFS卷与裸卷之间提供了一个象征性的连接，VM配置中引用了RDM文件（非裸卷），包括了管理和重定向物理存储设备访问的元数据信息。

如图2-9所示，当一个卷对外开放后，VMFS完成了RDM文件到正确的物理存储设备的映射，以及卷访问之前必要的访问检查以及锁控制，因此，接下来无须通过RDM文件就可以对裸卷直接进行读写操作。

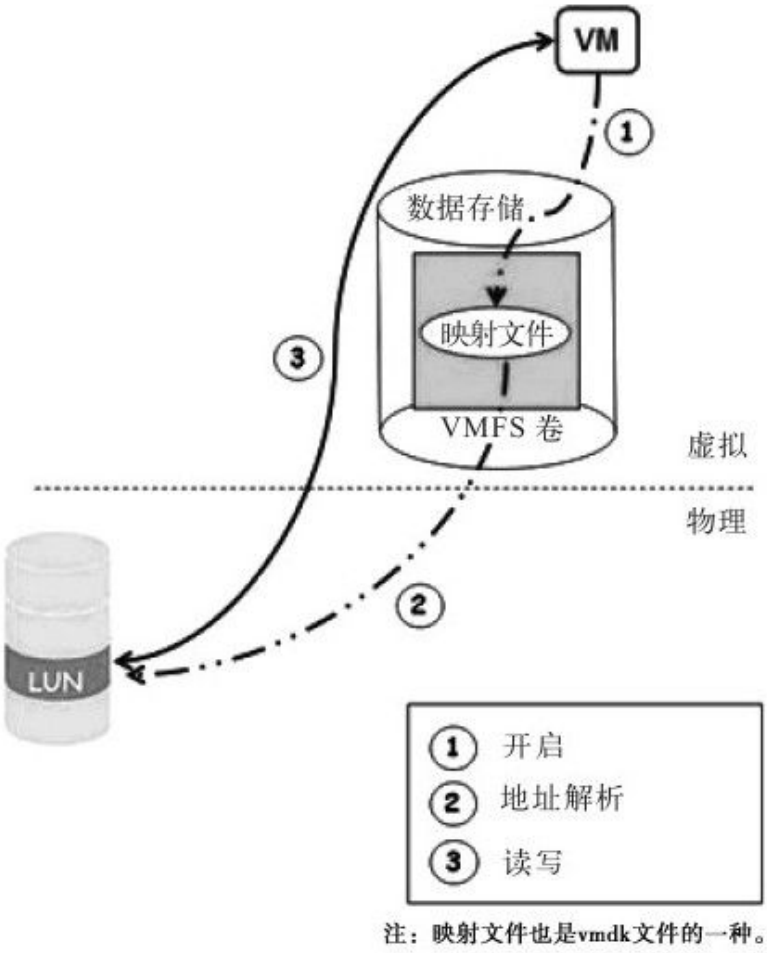


图　2-9　裸设备映射

RDM支持对物理存储设备的直接访问，同时又保留了VMFS中虚拟磁盘的优势，RDM一般适合于用户OS上的HA集群或基于SAN的备份这类应用。

2.4 存储虚拟化

存储虚拟化是存储模块的主要焦点（参见图2-2），它抽象了服务器应用访问数据时的逻辑表现与数据的物理位置，实现了位置无关性（云计算的基本特征之一）。虚拟系统负责管理卷到实际物理位置的映射过程，使逻辑实体以卷的形式展现给用户。虚拟化软件或虚拟化设备负责维护映射表，它也是元数据的一部分。映射粒度小至物理磁盘的一部分，大至整个物理磁盘，在这样的环境中，单个信息块由其LUN，也即物理磁盘，以及LUN内的偏移地址一起确定，这一偏移地址也称为逻辑块地址（Logical Block Address,LBA）。逻辑实体通常指虚拟磁盘，物理磁盘之间的地址空间映射由它们各自的LUN确定。

说明：物理磁盘也可以仅为存储的一部分，例如从底层磁盘子系统中的RAID阵列切出来的一块。

从另一个角度来看，传统存储管理通常采用到主机系统的DAS方式，主机拥有对DAS的唯一控制。SAN出现后，DAS被存储网络而替代，不过依然主要在RAID系统级别创建并维护存储，虚拟化是传统存储管理模型的下一逻辑步骤，虚拟化实现了集中的磁盘创建及维护的集中控制中心。

未进行虚拟化时，不同的主机系统拥有各自的烟囱式数据库或存储（参见图2-3），造成了资源的浪费，存储虚拟化实现了按需供应——资源池（而非特定的烟囱式数据库），使得无论应用来自哪个附加系统，需要多大量的资源，都能够获得满足。池式存储由各厂商的不同后端存储混合而成，能够实现对各类遗留及异构存储资源的整合和充分利用。

虚拟化也有助于调节可得资源的数量，而不再需要通过启用周期存储设备实现容量的增加或减少。主机系统也不用再负责卷的管理以及关注存储的变化，包括数据迁移或存储升级等。数据保护技术，诸如快照和复制，也被简化了，为不同应用分配不同类别的存储也变得简单了。此外，SAN存储虚拟化是对服务器虚拟化的补充，SAN存储虚拟化简化了VM在不同物理平台间迁移数据链路的关联。最后但也同样重要的是：存储虚拟化也简化了存储管理，降低了管理异构存储资源的成本，这也是现代DC的常见问题。

2.4.1 块汇聚

到目前为止，在这一章我们已经讨论了块级别的虚拟技术，通过对不同物理磁盘整合使得它们看起来就像一个逻辑设备一样。这样的技术通常也称为块汇聚，它与全球网络存储工业协会（Storage Networking Industry Association,SNIA）提出的L2共享存储模型有关。为什么在块一级进行虚拟化？最主要的原因是希望无须增加额外的智能应用，就能够克服个体设备的物理局限性，在应用看来是拥有了更大的磁盘，而实际上是通过增加一个虚拟磁盘来实现LBA容量扩展。

块汇聚是在主机（服务器）内部的存储设备（智能设备控制器）或在存储网络（基于网络的设备或FC交换机）上实现的，以下是三种常见的块一级虚拟化解决方案，它们各有利弊：

·基于主机的虚拟化。

·利：软件解决方案与存储平台或开发商无关，也与底层SAN技术、FC、iSCSI等无关。

·弊：基于主机的虚拟化通常需要为每个主机购买一个许可，因而整体成本比较高，虚拟化软件也有可能十分复杂，而且需要在访问到存储目标之前，必须对每一个帧都进行拦截及重定向处理。由于每个主机都需要独立控制，因此需要为每个主机都安装一个软件驱动程序。因为实际主机是基于VM的（更多细节请参考本章“虚拟数据存储概念”的相关内容），所以使用VMware VMFS能够解决其中一部分问题。

·基于设备的虚拟化。

·利：存储设备或子系统与主机平台及OS都无关，虚拟化是由与物理磁盘驱动器非常接近的设备控制器完成的，该解决方案能够提供更好的响应能力。

·弊：通常设备来自不同厂商，因而对异构存储资源的SAN环境进行管理十分困难，数据存储设备厂商通过将大量不同的物理存储技术，包括NFS、CIFS、iSCSI、FC以及FCoE，放在一起组成统一的存储体系架构来克服此问题。NetApp数据ONTAP 7G以及8.0，以及EMC公司的Celerra/CLARiiON，都是基于统一存储体系架构。

·基于网络的虚拟化。

·利：通过虚拟化设备或在FC交换机内可以实现基于网络的虚拟化，该解决方案完全独立于存储平台、主机平台以及OS。当连接到SAN后，基于网络的虚拟化可以访问所有相连的主机以及存储设备，并具备高性能及可扩展性。

·弊：基于网络的虚拟化技术通常与厂商相关，如果将虚拟设备以界内方式部署在数据路径上，它们往往会变成瓶颈，同样，基于网络的虚拟化技术也面临着可扩展性难题，需要采用聚集处理，以防止单点失效。通过基于交换机的虚拟化技术，可以访问到高性能的基架，从而增强了系统的可扩展性。这样的强化效果受制于用户所选择的特定类型的交换机及硬件，也有可能在未来系统升级时不得不全盘更新。因此，我们需要采用独立供应商的标准，例如使用光纤架构应用接口标准（Fabric Application Interface Standard,FAIS）来克服基于专有性交换机虚拟化的缺点。

说明：FAIS基于INCITS T11标准，其目标是为光纤应用创建一个与底层硬件平台无关的通用API，来帮助开发人员将存储和数据管理问题与应用、主机以及存储设备分离并集中到一个基于光纤的智能存储平台上。

2.4.2 同步及异步存储虚拟化

同步虚拟化属于基于网络的带内虚拟化部署方式，此时，数据及控制消息使用相同的路径，由一个集中的虚拟存储管理器负责所有的I/O及元数据路由。虚拟引擎通常为一个单独的网络设备，不过也可以将该设备作为特殊的模块嵌入到FC交换机中，或直接运行在服务器上。所有I/O都需要经过虚拟设备，这样会对能够利用的SAN拓扑有所限制，有可能产生瓶颈。利用缓存最大化虚拟引擎性能可以解决这一瓶颈问题。IBM SAN卷控制器（SAN Volume Controller,SVC）是基于网络的带内设备的样例。

图2-10给出了一个同步虚拟化的样例。在这个样例中，所有服务器端口都划分到虚拟设备的虚拟目标端口T区域，所有的存储端口均划分到虚拟设备的虚拟发起端口I_1。所有来自主机（发起者I）的数据及控制帧都将送往虚拟目标T，并在虚拟目标终止。SCSI CDB（命令描述块）以及LUN都将被重新映射，发起者（例如I_1）作为虚拟设备代理将发给物理目标T_1一个新帧。

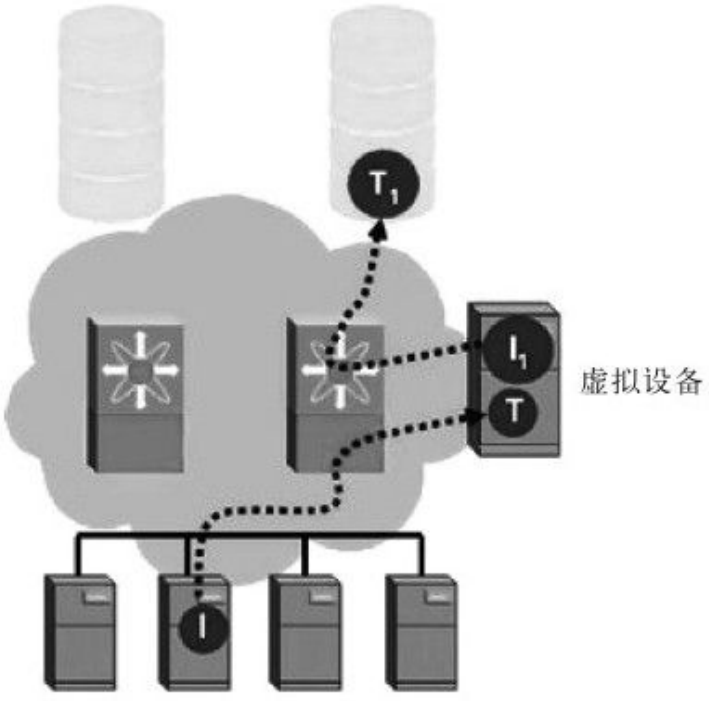


图　2-10　同步虚拟化

异步虚拟化方法属于基于网络的带外虚拟化部署，可以将I/O操作分成如下3个阶段：

1）服务器拦截下I/O请求块。

2）服务器要求元数据管理器确定数据的物理位置。

3）服务器存储或重新检索那些直接经过SAN的数据。

FC SAN上的元数据以带内方式进行传输，以太网链路上的元数据以带外方式传输。在SAN中，每个使用虚拟存储的服务器都必须使用特定接口或安装的代理与元数据管理器进行通信，完成从逻辑的数据访问到物理访问的转换，因此推荐使用带外以太网链路，因为它能够避免SAN中由于IP元数据传输产生的拥塞。

图2-11向我们揭示了异步虚拟化的原理，此时每一个服务器上都运行了一个虚拟化主机代理，负责拦截I/O请求块，并将元数据（CDB以及LUN）发送给带外LAN上的虚拟（元）管理器。虚拟管理器将对CDB以及LUN进行重映射，并将它们返回给服务器。服务器将修改后的帧发送到存储目标端口，所有之后的数据及响应帧都可以在发起者（I）以及目标端口（T）之间直接移动。

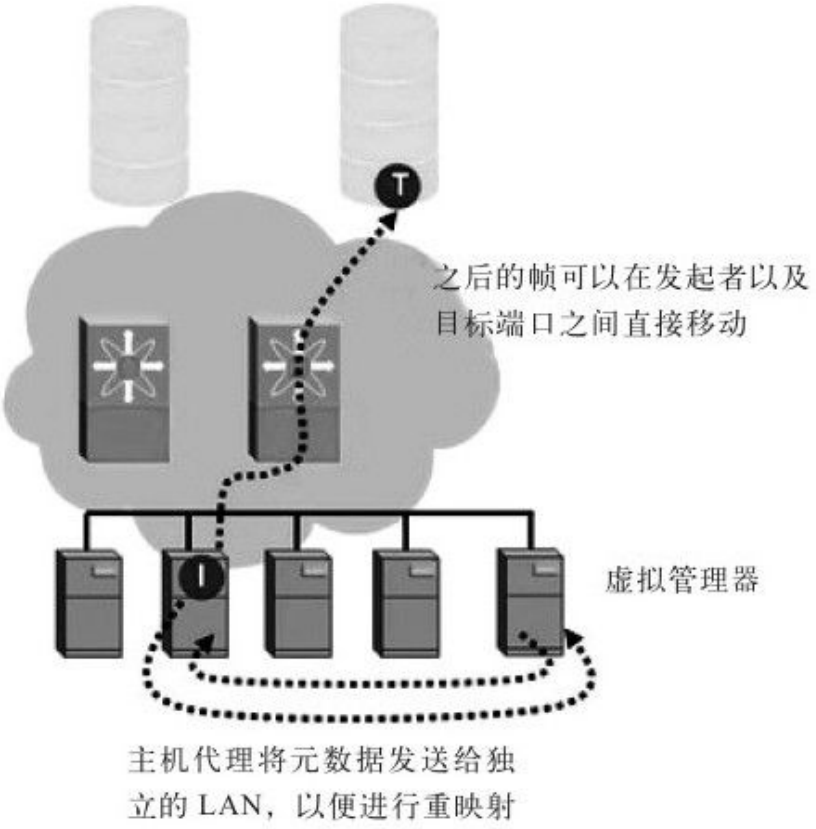


图　2-11　异步虚拟化

两种部署方式拥有各自的优缺点：

·同步虚拟化。

·优点：带内部署复杂性较低，因为它使用单点管理模式，整体结构更简单，也不需要主机代理。

·缺点：同步虚拟化增加了每一帧的时延，因为所有的帧都先被终止，然后再被设备重映射，最后才被转发到目标地点。所有的网络传输都经过设备，将增加潜在的单点故障以及性能瓶颈，借助集群解决方案以及大容量缓存解决这些问题，只是执行虚拟操作的集群虚拟化设备又会因元数据库同步产生新的一致性问题。

·异步虚拟化。

·优点：异步虚拟化的主要优势在于低时延。

·缺点：异步虚拟化属于带外操作，要求主机能够拦截控制帧，此外，虚拟（元数据）管理器有可能形成单点故障。

对基于网络的虚拟化而言，到底应选用哪一种部署方案：是带内部署还是带外部署？是否存在一种体系结构能够结合二者的优势，却又可以避免同步虚拟的瓶颈，也不需要异步虚拟中的主机代理呢？基于智能交换机的分离路径架构有可能是一种最佳方案。换句话说，也就是使用基于交换机的混合（分离路径）方法，控制路径采用效率更高的带外部署，而数据路径采用带内部署，这种方案从本质上避免性能瓶颈，也不需要使用主机代理。

在分离路径体系架构中，元数据管理器通常为一个控制路径处理器（Control Path Processor,CCP），嵌入在智能交换机中的特定刀片上，或者位于某个外部带外控制器（设备）上。CPP支持FAIS，负责设备恢复、卷配置（例如，管理LBA元数据、将主机映射到存储LUN上）以及I/O错误或意外处理。这些操作不要求CCP处在界内，也不要求CPP位于数据路径上。当卷信息（主机到存储的映射）确定后，将被委托给数据路径控制器（Data Path Controller,DPC）。DPC包含了高性能的I/O处理ASIC，也驻留在特定刀片上，负责复制等带内操作。当接收到来自CPP的卷信息后，DPC将独立开始工作，完成从虚拟到物理的I/O转换，并且将数据转发到正确的目的地。例如，MDS 9000系列上的Cisco存储设备服务模块（Storage Services Module,SSM）能够支持分离路径架构。SSM支持FAIS，允许集成第三方虚拟引擎（例如EMC Invista）将虚拟化控制数据转移给MDS交换机。

2.5 Layer-2演化

深入研究光纤模块之前，让我们想一下目前的优化技术已经克服了以往哪些DC技术缺陷，而当前DC技术还存在哪些可被优化的地方，显然后者比前者更重要，因为它将带来更好的技术效率和改善性能。有一个需要注意的问题是，冗余L2设计方案时生成树协议（Spanning Tree Protocol,STP）的副作用。尽管对STP（可以回溯到1985年）已经做了某些优化，但是这些优化仍然未能解决两个基本的L2设计问题：

·STP不支持特定VLAN下的L2多路径，同样每VLAN负载平衡允许使用接入层交换机的两条上行链路，但要求用户自己配置。之所以没有其他好的替换方案，是因为数据平面的STP要求必须这样做以防止产生回路。

·为了形成生成树拓扑使得数据平面对STP产生依赖，将导致收敛时延，并带来诸如网络泛洪、链路饱和等潜在危险。

说明：STP的优化措施包括快速生成树协议（Rapid Spanning Tree Protocol,RSTP）、每VLAN生成树（Per-VLAN Spanning Tree,PVST）、快速每VLAN生成树改进（shengRapid Per-VLAN Spanning Tree Plus,Rapid PVST+）以及多生成树协议（Multiple Spanning Tree Protocol）等。

围绕这些问题的解决方法之一是部署无回路L2接入拓扑，经典的L2回路拓扑中每个接入层交换机拥有一个上行链路。其他都是冗余链路或处在断开状态的链路。与经典L2回路拓扑相比，无回路拓扑没有生成树断开端口。图2-12展示了一个无回路L2接入设计方案，也称为无回U型以及无回反U型拓扑，两种方案在L2/L3分界之处有细微差别。

无回路U型拓扑设计方案提供了一条主上行链路，通过接入层交换机之间的内部交换机链路实现冗余，在每个接入层交换机，接入层交换机与相应的802.1Q上行链路间，802.1Q内部交换机链路上都配置了VLAN，但是汇聚层交换机没有配置VLAN以避免产生回路拓扑。由于系统中不存在回路，因此生成树不会阻塞端口。该方案主要不利之处为无法在接入对之外扩展VLAN，某些故障也有可能会产生黑洞。而如果采用在接入对之外扩展VLAN的方案，将形成一个通过汇聚层的回路，启动STP后，就会回到带阻塞链路的四点回路拓扑上。

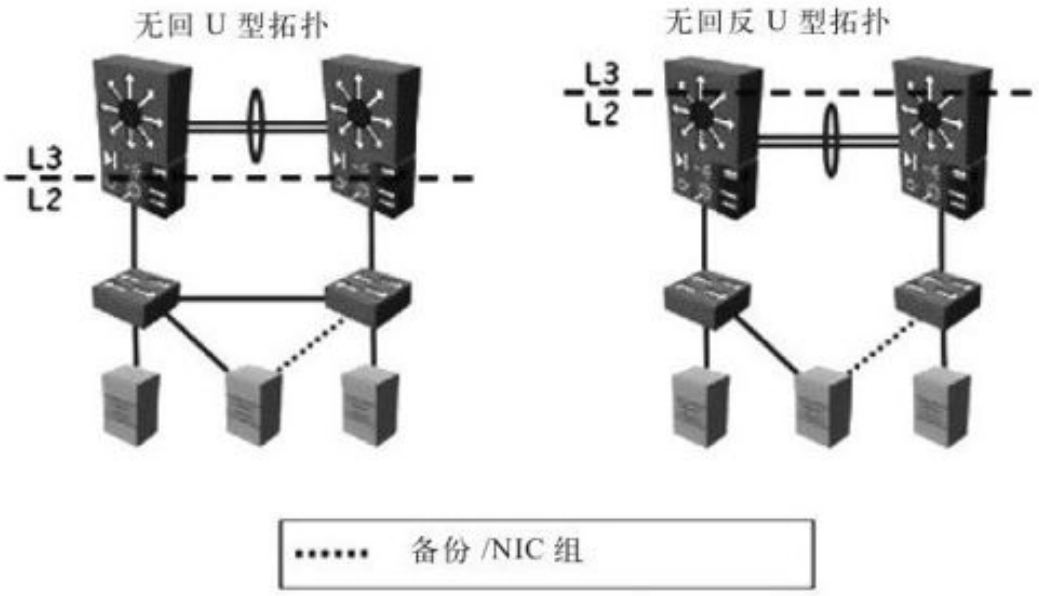


图　2-12　U型及反U型无回路接入拓扑

在无回路反U型拓扑中，在每个接入层交换机以及相应的802.1Q上行链路上都配置了VLAN，此外还扩展到汇聚层交换机之间。此时，为了防止回路，VLAN不会扩展到接入层交换机间。无回路反U型拓扑允许所有上行链路都作为主链路，为VLAN与汇聚层交换机连接提供支持，也支持VLAN扩展经过接入层，这种拓扑的不利之处在于当汇聚层交换机或者接入层交换机上行链路出现故障时，系统没有提供备用路径，因而可能形成黑洞或者是不可访问的服务器。

尽管在两种拓扑结构中都采用了无回路设计，为了确保安全，仍然需要运行STP以防止在发生线缆或配置错误时产生回路降低整个网络的性能。

虽然“U”型方案听起来比较新鲜，但该方案的影响以及局限性将使我们重新考虑传统的解决途径——L2回路接入拓扑。如图2-13所示，回路接入拓扑由一个三角形（也即V型）和一个正方形组成。

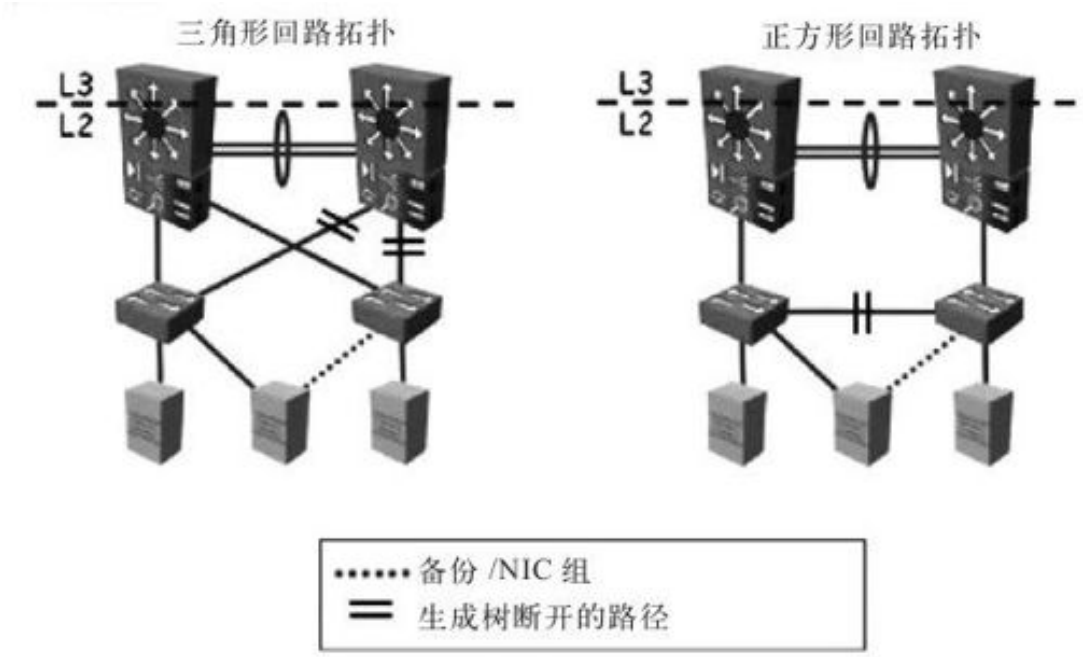


图　2-13　三角形与正方形回路接入拓扑

L2回路接入拓扑与L2设计方案在STP上拥有一样的问题——网络越大，收敛时间越长，同时缺乏L2多路径支持。使用端口通道可以保留数据平面的逻辑生成树，同时也不会使冗余性及负载平衡受到影响，尽管这一方法能够克服STP的局限性，但是仅有链路汇聚也无法建成一个完全冗余的DC，因为它无法处理单个交换机故障。Cisco公司的虚拟交换系统（Virtual Switching System,VSS）和虚拟端口通道（Virtual Port Channel,VPC）通过创建一个能够在两个不同物理交换机上分布的L2端口通道接口解决了上述问题。端口通道的优化特性也足够让整个DC摆脱对STP的依赖。本书只讨论了vPC，由于VSS及vPC技术差不多，更多有关vPC的详细内容，请参考2.5.1节。

借助在L2层对帧路由、多链接半透明互联（Transparent Interconnection of Lots of Link,TRILL）是能够完全突破经典基于生成树帧转发的领导性技术之一。IETF希望通过TRILL与中间系统到中间系统（Intermediate System to Intermediate System,IS-IS）的网络路由协议一起能够替代STP，从L2角度，实现一种更灵活、可扩展性更好的未来DC设计方案。借助TRILL，所有处于像IS-IS转发状态的链路都能计算转发表，去除STP后，系统中再也不存在被阻塞的端口，有助于L2多路径（L2 MultiPath,L2MP）转发，增加了系统等分带宽，使得负载偏低的路径能够转发对延迟敏感的帧。

由于IS-IS属于链路状态路由协议，因此其收敛时间远小于STP，借助内部域（级别1）与外部域（级别2）路由变量的概念，网络泛洪的可能性也大大降低。此外，也更容易发现性价比最高的路径来转发帧，到达目的地的中间跳的次数也减少了，从而缩短了整体时延。TRILL提供了一种获得“STP-less”DC的途径，而vPC则提供了一条到TRILL的转换路径。目前，TRILL依然还处于研究阶段，更多有关TRILL的讨论则已经超出了本书的范围。

2.5.1 虚拟端口通道：STP的改造者

借助vPC可以使物理连接两个不同交换机之间的链路，在第三方下行设备看起来就像一个单一设备一样，并使其成为一个端口通道的一部分。第三方设备可以是交换机、服务器或任意其他支持802.3ad端口通道的网络设备。只是这里概念与VSS中稍有不同，此时两个交换机仍然是相互独立的，拥有不同的控制及转发平面。本节讨论的vPC均在Cisco Nexus 7000（NX7K）以及Cisco Nexus 5000（NX5K）系列交换机上实现。

简而言之，vPC有助于对汇聚/核心层交换机进行整合/虚拟化，使它们成为一个单一逻辑实体。更多有关vPC的配置样例请参考9.6节的相关内容。

vPC要点

vPC设置包括以下部分：

·vPC域：一个vPC域组合了两个vPC对等交换机，每一个vPC拥有一个唯一的域ID。

·vPC对等交换机：vPC对等交换机是两个作为对等设备通过对等链路互相连接在一起的交换机，它们为vPC建立了一个单一逻辑终端，尽管只有两个交换机能够参与到对等连接中，但是这一简单特性已经足够克服经典STP的局限。

·vPC对等链路：vPC对等链路是vPC交换机之间的链路，通常称作多机箱以太通道（Multichassis EtherChannel,MEC）链路，该链路属于标准的IEEE 802.3ad端口通道，带有一个被修改的STP权重。对等链路的功能包括同步对等交换机之间的MAC地址，为组播传输提供必要的支持，并负责孤立端口间的通信。

·vPC成员端口：vPC成员端口是vPC中对等交换机的物理端口，一个运行中的vPC实例要求每个对等交换机上的vPC成员端口至少拥有一个端口通道。

·孤立端口：vPC拓扑将非vPC节点上的端口连接设备称为孤立端口。

·vPC对等心跳链路：对等心跳链路是一个运行在带外管理网络（不使用对等链路）上的逻辑链路，它提供了一个L3通信路径，用于辅助检测，确定远程peer工作是否正常。通过vPC对等心跳链路发送的帧（心跳消息），可以探测源交换机工作是否已经启动，vPC是否开始运行。数据或同步信息不会通过vPC对等心跳链路传送。系统使用对等心跳链路来处理双活故障（即vPC peer之间的peer链路发生故障）。

·Cisco光纤服务（Cisco Fabric Service,CFS）协议：CFS协议协议是为支持快速状态配置消息传送及同步而设计的一种可靠消息协议，vPC借助CFS来传递系统配置副本，完成MAC和两个vPC对等交换机之间的Internet管理协议（Internet Group Management Protocol,IGMP）状态信息的对比及同步处理。CFS协议同时还能够验证vPC成员端口的兼容性以建立端口通道，并监测vPC成员端口的状态。

如图2-14所示，SW01和SW02是两个vPC对等交换机（可以为NX7K或NX5K交换机），由它们组建了一个vPC域，通过普通的端口通道配置，将接入层交换机SW03和SW04以及服务器H2均连接到vPC对等交换机处在vPC拓扑中，负责连接非vPC节点中的设备到vPC拓扑的端口被称为孤立端口，连接到孤立端口的服务器被称为单宿主服务器，图2-14中的服务器H1和H3都属于单宿主服务器类型。H2、SW03、SW04均连接到vPC成员端口上。

说明：推荐所有接入层交换机均采用双重连接模式与vPC peer连接，如果不这样，那么那些只与一个vPC peer连接的交换机或主机将会占用对等链路宝贵的带宽资源，而在对等链路或vPC peer发生故障时，也会使得这些交换机或主机成为与网络隔离的孤立点。

STP不说再见

尽管vPC克服了STP的缺点，但并不能完全代替STP,vPC对运行在对等交换机上的生成树主要做了如下两方面改进：

·vPC确保了对等链路不会间断转发行为，而备份vPC对等交换机也会将对等链路看成至主vPC对等交换机的根端口。

·vPC确保了只有主vPC对等交换机才会转发vPC上的桥接协议数据单元（Bridge Protocol Data Unit,BPDU），使得从生成树角度出发，在其他连接到vPC系统或拓扑中的接入层交换机看来，两台对等交换机如同一个单一实体。这样的改变只适合vPC成员端口，当vPC成员端口上的备份vPC对等交换机接收到BPDU后，它们将通过把数据对等链路转发给主vPC对等交换机处理。

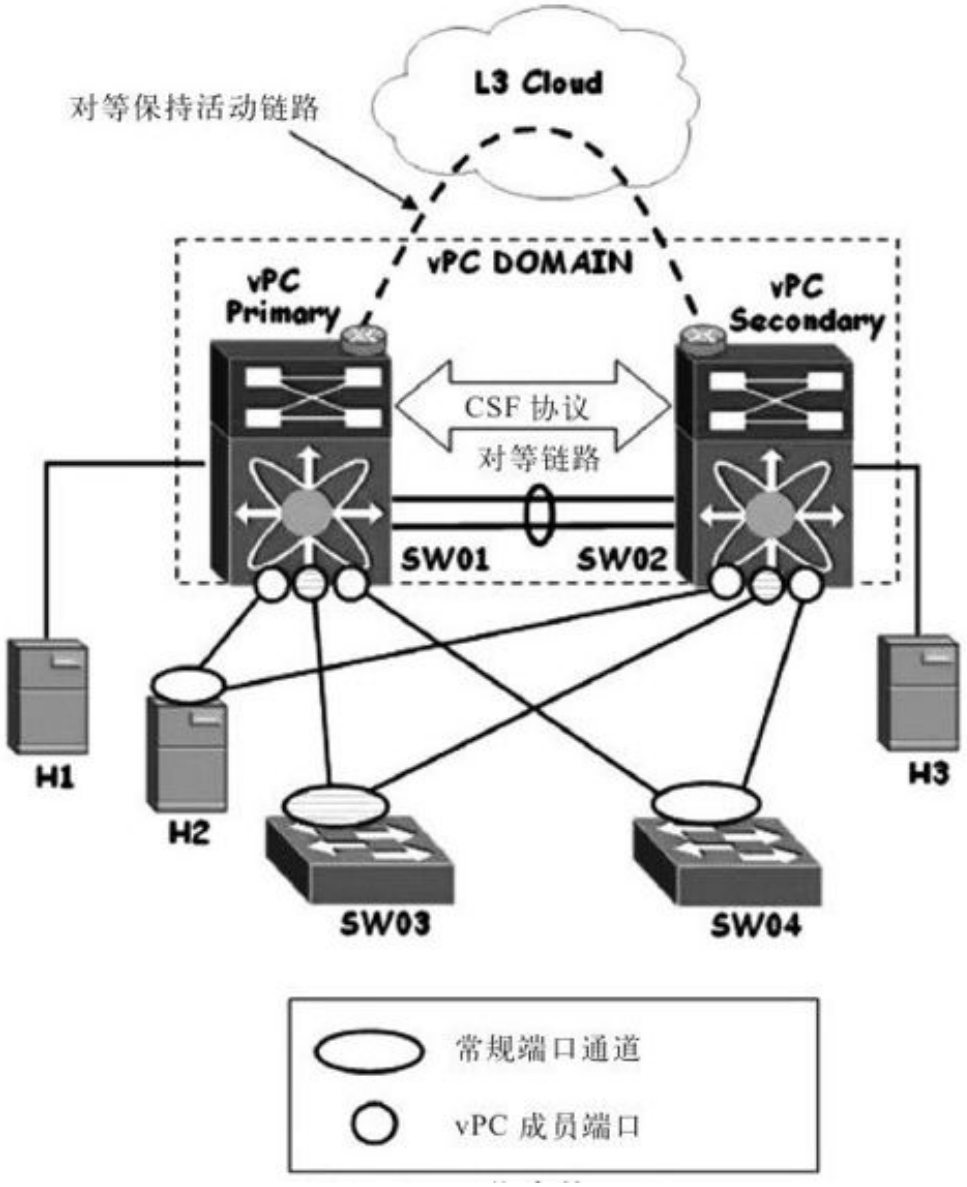


图　2-14　工作中的vPC

如果某个端口通道成员发生了故障，vPC方法会采用用端口通道恢复机制而非STP，这一做法在很大程度上减少了整体收敛时间。

说明：非vPC端口或孤立端口（通常为单宿主而非双宿主）的操作与普通端口一样，采用标准STP协议，包括MSTP及快速PVST+等。vPC专有功能仅适用于vPC成员端口。

2.5.2 vPC设计概要

本节从设计角度简要讨论如下vPC概念及组件：

·vPC角色及权限

·vPC对等链路

·vPC对等心跳

·vPC初始化

·vPC及HSRP

vPC角色及权限

必须调用“feature vpc”命令，才能在系统中使用vPC功能，配置vPC时，首先要确定域的ID（1～1000）及主从交换机角色，角色优先级为16位整数，默认值为32767。在vPC系统中，只有一台vPC对等交换机被确定为主交换机，另外一台交换机将会根据优先级被定义成从交换机。主对等交换机的值比从交换机的值低，因为较低的值优先级更高。代码清单2.4展示了一个vPC域及优先级配置模板。

代码清单2.4 vPC域及优先级配置模板

```
feature vpc
vpc domain 3
 role priority 300
```

说明：构建vPC系统的两个对等交换机其域ID必须匹配。

vPC对等链路

对等链路为连接对等交换机的端口通道，负责所有用户自定义接入VLAN。同时，对等链路还负责传送诸如BPDU、热备份路由协议（Hot Standby Router Protocol,HSRP）的hello消息以及对等交换机间MAC地址同步等控制信息。如果需要实现高可用性HA，必须将对等链路配置成冗余模式。NX7K交换机中，该端口通道必须被配置成特定的能跨越两个独立10千兆以太网线卡的10千兆以太网接口模式。代码清单2.5给出了一个vPC对等链路配置模板。

代码清单2.5 vPC对等链路配置模板

```
interface port-channel30
  switchport
  switchport mode trunk
  switchport trunk allowed vlan 201,205,252-258, 301-302
  vpc peer-link
  spanning-tree port type network
```

说明：连接vPC peer的端口通道（对等链路）只负责支持vPC成员端口需要的VLAN传输，如果孤立端口使用的VLAN也运行在同一链路上，一旦对等链路发生故障，孤立端口之间的通信就受到破坏。为了避免这一问题，推荐采用双重连接的服务器，一条端口通道为vPC成员端口服务，另一条端口通道连接到单个对等交换机上。

vPC对等心跳

vPC管理系统借助心跳消息来确定对等链路及远程对等交换机是否发生了故障。如果远程交换机工作状态正常（即双活模式下，即使对等链路发生故障，依然可以通过带外对等心跳链路响应心跳消息），vPC备份对等交换机将关闭其vPC成员端口，如果收不到对等心跳消息，系统会认为远程对等交换机出现了故障，此时，心跳消息的发起者将假定只有自己这方的对等交换机状态正常并负责数据转发。当对等链路或远程交换机故障解除后，系统会对在故障中获得的MAC地址重新进行同步处理并按正常状况转发。

不建议在与对等链路相关的VLAN上传递心跳消息，推荐通过路由基础设施（L3云）发送心跳信息。心跳信息包括目标IP地址（远程）、源IP地址（本地）以及负责对等链路传输的VRF。代码清单2.6给出了一个vPC对等心跳链路的配置模板。

代码清单2.6　vPC对等心跳链路配置模板

```
vrf context vpc-pklink
interface Ethernet8/13
  vrf member vpc-pklink
  ip address 172.16.3.1/24
  no shutdown
vpc domain 3
  peer-keepalive destination 172.16.3.2 source 172.16.3.1 vrf vpc-pklink
```

说明：当使用冗余监测器时，NX7K交换机每一时刻对给定vPC peer上只有一个活动管理接口，因此在两个NX7K对等交换机的管理接口之间不要采用直接背靠背连接，因为很难确定在某个给定时刻哪个监测器是活动的。对于带外连接，推荐通过槽5上的监测器及槽6上的监测器的mgmt0接口，将每个NX7K对等交换机连接到管理网络（L3云）上。

vPC初始化

在对等交换机上，如果调用“vpc < vpc_number > ”命令，vPC将被配置成普通端口通道，对等交换机上的成员端口（转发端口）也会与vPC关联，vPC对等交换机之间可以交换vpc序号，两个单独的本地端口通道配置也将被vPC对等交换机绑定到分布式vPC虚拟端口上。

如果vPC及对等链路能够实现静态链路汇聚，推荐使用链路汇聚控制协议（Link Aggregation Control Protocol,LACP）以避免发生配置错误，也能提供更精确的故障恢复控制。有了LACP，因配置错误而产生的不匹配端口之间将无法建立端口通道，此时，这些端口将被归到单个（Individual,I）状态，运行常规生成树。

LACP是由IEEE 802.3ad引入到基于标准的机制，通过LACP两个交换机之间能够协商建立端口通道。使用“channel-group”命令可以完成LACP配置，接口配置参数为“active”或“passive”。为了启动通道协商，至少有一方的端口通道连接必须设置成主动模式。代码清单2.7给出了vPC及vPC成员端口的配置模板。

代码清单2.7　vPC成员端口的配置模板

```
interface port-channel33
  switchport
  switchport mode trunk
  switchport trunk allowed vlan 320-329
  vpc 33
  spanning-tree port type network
interface Ethernet2/13
  switchport
  switchport mode trunk
  switchport trunk allowed vlan 320-329
  no shutdown
  channel-group 33 mode active
```

说明：vPC序号不一定要与端口通道序号一致，不过为了便于管理，推荐将它们设置成一样的值。

vPC和HSRP

NX7K上的HSRP具有一个值得一提的独特功能，假定两端的对等交换机均为NX7K，将其中一个配置成主HSRP peer，另外一个配置成从HSRP peer。优化后，主HSRP peer以及从HSRP peer的转发引擎都能进行本地L3转发，这样一来不需要对现有HSRP配置做任何更改，就能在实际上得到主/主HSRP配置。HSRP控制协议依然按照主/从对模式工作，只有一个主HSRP peer响应地址解析协议（Address Resolution Protocol,ARP）请求。如果来自服务器的（双重连接模式，一个端口通道连接到vPC成员端口，另一个连接到对等交换机）某个ARP到达从HSRP peer，将通过对等链路转发给主HSRP peer。相关对等交换机上的两个HSRP接口（主/从）都可以转发可路由网络传输。如果从HSRP peer接收到了源自同一服务器的网络流，将直接转发给下一跳（假设下一跳为合法地址）设备，不需要再通过对等链路将该网络流转发给主HSRP。

说明：推荐保留vPC主peer上的默认网关，为此，需要将该vPC主peer配置成所有VLAN的主HSRP peer。

2.5.3 vPC和Nexus 1000V

在大多数NX1KV设计方案中，要求端口通道能跨越多个接入层交换机，为了方便在交换机之间的跨越，NX1KV交换机提供了两种配置方式，这两种方法都不要求在上行交换机中配置端口通道：

·vPC主机模式（vPC HM）

·MAC绑定

vPC主机模式

在Vpc-HM模式中，NX1KV交换机上配置的端口通道被分成子群（更小的逻辑端口通道），每一个子群代表一条或多条连接一个上行物理交换机的上行链路（Eth接口），系统采用轮叫机制将VEM上的每个vEth接口（更多细节请参考2.3.3节的“VEM交换机端口分类”中的内容）映射到一个或两个子群上。相应地，所有来自vEth接口的网络传输都通过给定子群完成，如果某个给定子群发生故障，剩下的子群也不能再使用该vEth接口，但如果最初的指定子群恢复工作，网络传输将重新转移到该子群上。

图2-15展示了两个vPC-HM样例，图的左边为两个NIC共用一条端口通道。其中两个NIC都是端口通道1的一部分，配置成vPC-HM模式，分别连接到两个上行交换机，两个NIC共用一个上行链路配置文件，通过源MAC地址散列算法，将VM的负载平衡分布到两条上行链路中。

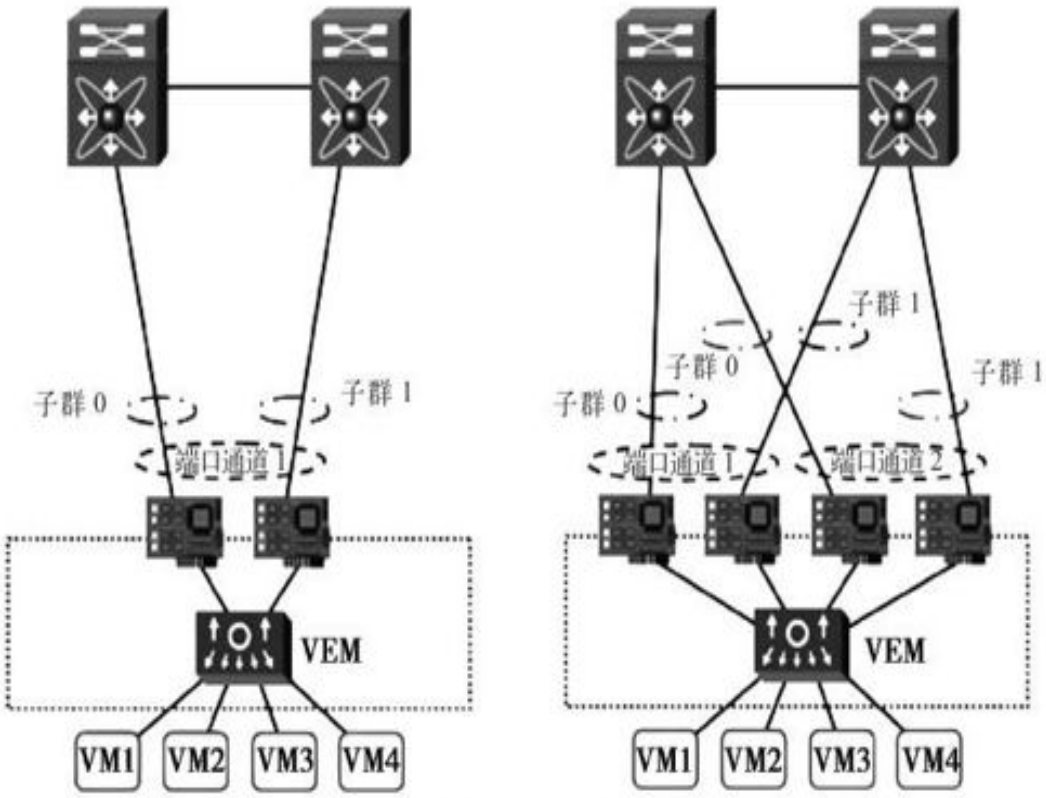


图　2-15　vPC-HM样例

说明：NX1KV交换机支持17种散列算法来平衡经过端口通道物理接口的负载。这些算法分成两类：基于源的散列和基于流的散列。基于源的散列算法确保不管端口通道中有多少条链路，一个MAC地址只会向下沿着其中一条链路进行传送。

图2-15的右边为4个NIC共用两条端口通道，每一个端口通道都拥有一个链路连接到上行交换机。此时，每一个vPC-HM子群都拥有一条单独的链路，因此不需要在上行交换机对端口通道进行配置，在该样例中，负载平衡处理依然采用了源MAC地址散列算法。

如果上行交换机支持CDP消息，则可以通过上行交换机返回到CDP消息，将端口通道中连接到同一上行交换机的Eth接口自动绑定在同一子群内。如果上行交换机不支持CDP消息，或者系统需要覆盖CDP消息，也可以通过接口级配置，人为地把接口分配到特定子群中。

当多个上行链路都汇聚在NX1K交换机中的同一子群时，上行链路需要一个端口通道被配置成能够将所有这些链路绑定在一起，该端口必须要选用“mode on”命令参数。图2-16展示了

另一个vPC-HM样例，这一次是4个NIC带1个端口通道，这个单独的基于vPC-HM的端口通道部署形式为将VM的负载分布到尽可能多的NIC上。此设计方案的主要优势在于VM数据传输可以利用所有4个NIC，并且能够灵活地支持基于流的散列算法。如果使用了基于流的散列，每一个上行交换机就必须配置一个端口通道，不过如果使用基于源的散列算法，就不要求采用这种配置。

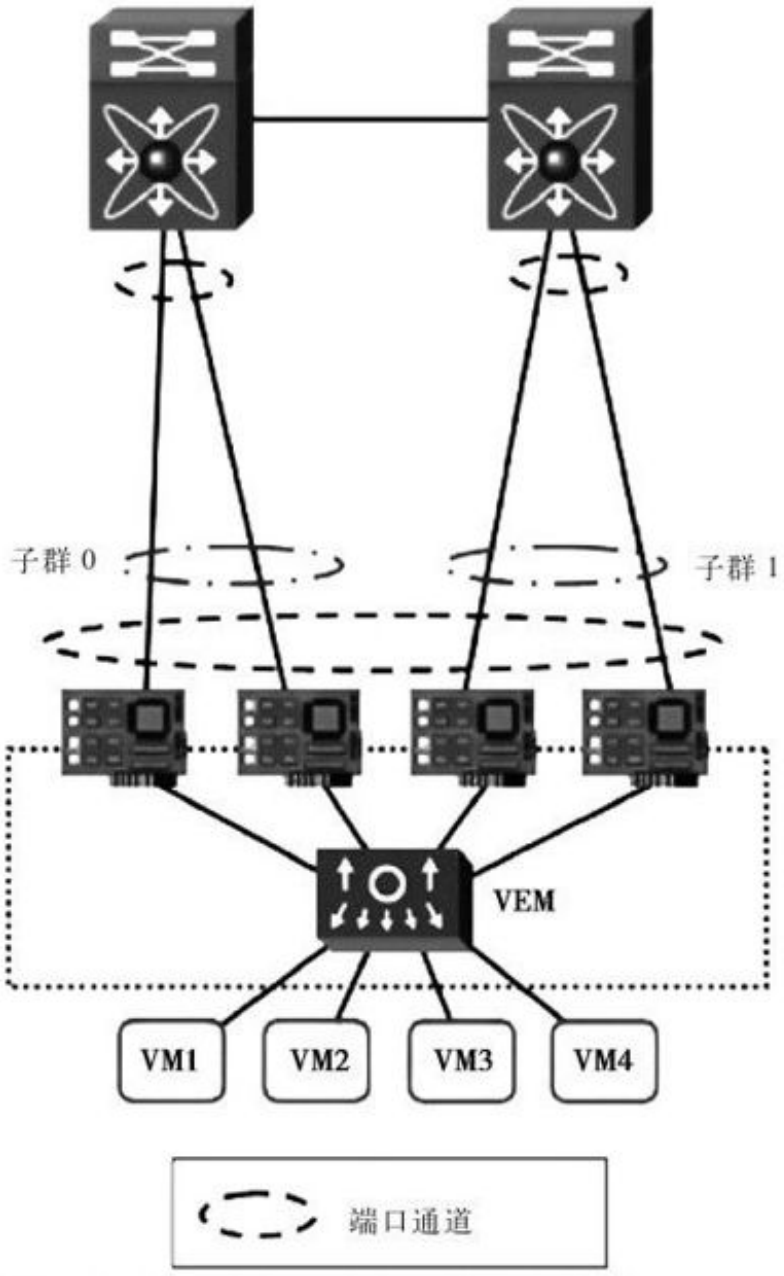


图　2-16　带有4个NIC及1个端口通道的vPC-HM

说明：基于流的散列可以使来自单个MAC地址的网络流同时分布到端口通道内多个链路上，提供了一种更精确的负载平

衡方法。增加了VM可得带宽，提高了端口通道中上行链路的利用效率。

MAC绑定

MAC绑定将所有来自服务器的上行链路（Eth接口）都当做单独的链路处理，并以轮询方式为这些链路分配来自不同Eth接口的MAC地址。如图2-17左边所示，MAC绑定方法能够确保上行交换机的多个接口均看不见VM的MAC地址。如果某个上行链路发生故障，NX1KV交换机将发送一个免费ARP消息来通知上行交换机，告知它从之前Eth接口所获得的vEth接口MAC地址将会被重新绑定到另外一个Eth接口上。该过程的说明如图2-17的右边部分所示。有了MAC绑定，VEM（或Eth接口）在连接上行交换机时可以不必再配置上行信息。

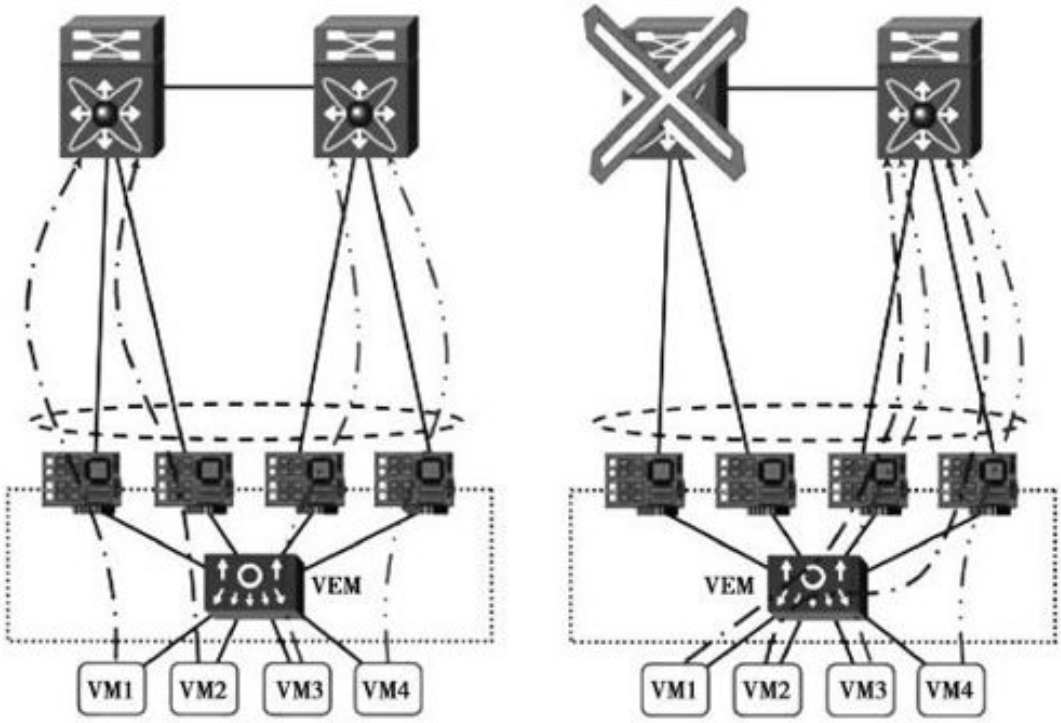


图　2-17　MAC绑定样例

2.6 统一数据中心光纤

透彻了解L2技术演化的实质后，我们该接着进入到下一课程——光纤模块。从私有云计算以及SOI角度出发，我们在该模块所获得的东西是DC光纤的统一。换句话说，也就是以太网和FC必须形成一个完整的光纤而非两个相互孤立的互联。为了实现该目标，必须对互联技术做一定优化或扩展。

自2008年10千兆以太网（10Gb Ethernet，10GE）问世以来，带宽的增加使得建设DC时，能够通过更少的链路传输更多的数据，提高了系统整体吞吐量。但是单凭高速10GE链路并不能超越FC，只有“无损”的以太网才能够与FC平分秋色。当前以太网对FC的某些特性进行了改造，包括基于优先级的流控制（Priority-based Flow Control,PFC）、增强传输选择（Enhanced Transmission Selection,ETS）带宽管理、数据中心桥接交换（Data Center Bridging Exchange,DCBX）的恢复协议以及量化拥塞通知（Quantized Congestion Notification）算法。而另一方面，FC借助FCoE技术已经扩展到新一代“无损”以太网领域，所有这些进化技术一起，促成了未来统一DC光纤的诞生。

2.6.1 10千兆以太网

目前，10GE（基于IEEE 802.3ae）技术日趋成熟，它对现代DC的重要性更是毫无疑问。10GE将是互联模块（参见图2-2）中DC光纤融合，或者诸如FC这样异构光纤融合，非常重要和基础的部分，任何希望创建一种无处不在的统一光纤应用都必须借助以太网，因此以太网是融合的方向且再没有其他方法。

10GE减少了服务器所需的千兆以太网适配器数量，改变了DC部署的规模。随着网络带宽的增加，现在已经能够实现对DC LAN存储网络的整合（更多详细内容请参考2.6.3节）。用户已经开始感受到从GE或GE端口通道迁移到10GE的优势，包括：

·增加了诸如iSCSI（更多详细内容，请参考第7章有关“iSCSI”技术的内容）这类基于IP的存储访问的部署灵活性。

·优化了NAS性能。

·借助10GE接入层上行链路，可以预先得知GE端口通道的实现方案，因而降低了对GE端口部署时通常必需的负载平衡散列算法的要求。

·改善了服务器备份以及恢复的效率。

多核处理器架构允许同一机器承受更大和多样的负载，而服务器虚拟化要求每个服务器能够得到更多的带宽，因此，多核CPU以及服务器虚拟化也受益于10GE所带来的额外带宽。例如，套接字的大小经常会对应用造成影响，通过虚拟化服务器，单个VM网络传输将被汇聚到同一NIC上，此时，就可以利用10GE。另外，VMotion迁移（动态VMotion迁移）可以利用带宽增加的优势同时完成多个VM之间的VMotion迁移。不管怎样10GE也最适合FCoE，因为它借助高带宽的优势弥补了以太网和FC之间的差距。

说明：以太网演化并未终止于10GE,IEEE 802.3ba已经批准了40GE及100GE的标准。

2.6.2 以太网重装上阵

仅凭10GE是不足以抗衡FC的，因为长帧在FC的世界中不受欢迎。因此，除了有高速带宽的支持外，以太网还必须具备无损性。不过真的能实现以太网的无损吗？答案是“可以”，不过要借助下列内在机制：

·基于优先级的流控制（Priority-based Flow Control,PFC）

·延迟删除

·增强传输选择（Enhanced Transmission Selection,ETS）

·数据中心桥接交换（Data Center Bridging Exchange,DCBE）

·拥塞通告

基于优先级的流控制

FC是不允许出现帧丢失现象的，它使用信用的概念来实现无损控制，在FC链路初始化时，会对每个链路的缓存数进行预定义，以便每个链路的终端能够跟踪可得或未被占用的缓存，这样的链路级流控制在FC中称为缓存到缓存（Buffer-to-Buffer,B2B）流控制。B2B流控制可以控制FC帧的传输速率，能够防止传输量超过接收者的缓存范围。B2B流控制使用缓存到缓存信用数（Buffer-to-Buffer Credit,BB_Credit）作为调整帧传输速率的单元，每发送一个帧，相应可用的BB_Credit都将减1。而另一方面，每收到一个接收者就绪（Receiver-Ready,R_RDY）信号，相应的BB_Credit又将加1，使得可以继续发送其他帧。当BB_Credit的值变成0时，就意味着除非收到新的R_RDY信号，否则发送端将中断帧发送。以太网则借助PAUSE帧（基于IEEE 802.3x）来达到这一目标。当接收端口（接收者）的缓存将耗尽时，它将发出一个PAUSE帧来阻止远程peer（传输者）继续发送，图2-18上部对PAUSE帧进行了说明。但是PAUSE帧机制是对整个链路进行一个PAUSE操作，不能体现粒度差别，当发送者接收到一个PAUSE帧后，它将停止该端口所有的传输行为，这样也并不符合统一DC光纤的目标。

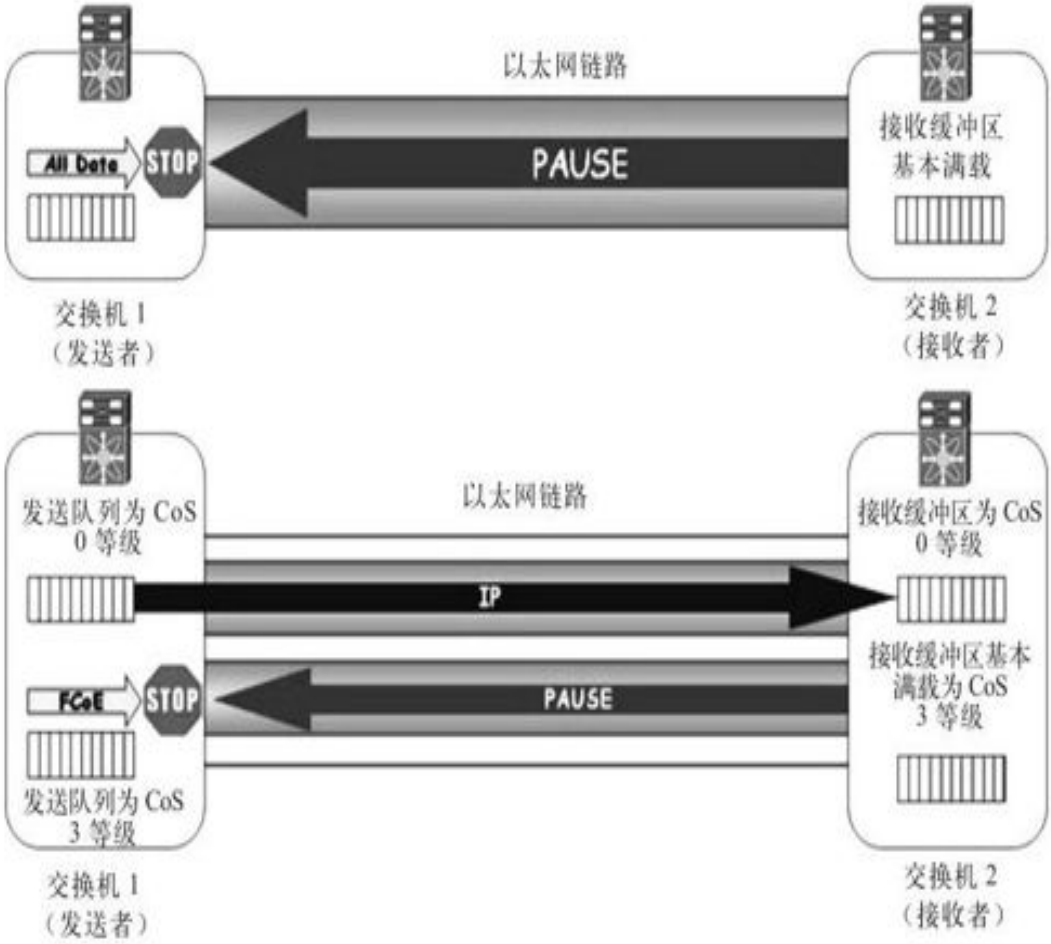


图　2-18　PAUSE帧及PFC比较

基于IEEE 802.1Qbb标准的PFC是对PAUSE机制的增强，它在PAUSE帧中增加了一个域来标识将对哪一个优先级别（IEEE 802.1p可以设置8个级别）进行PAUSE操作。换句话说，PFC在物理以太网链路上创建了8个单独的“虚拟链路”，任意一条虚拟链路都可以自主地被停止和重启。新增的优先级粒度允许我们为链路上不同的协议传输设置不同的服务等级（Classes of Service,CoS）。例如，像FCoE（更多有关FCoE的详细内容，请参考2.6.3节的相关内容）这样的协议，要求介质级别的可靠性，不能容忍帧丢失，因此可以被映射到无丢失（有PAUSE）等级，而诸如IP这样的协议能够接受尽力而为型的帧传送效率，就可以被映射到可丢失（无PAUSE）等级。

图2-18底部展示了一个简化的PFC样例，该样例中只设置了两个等级：IP传输为CoS 0等级，FCoE传输为CoS 3等级，只有FCoE对应的CoS（优先级为3）才启动了PAUSE帧，IP传输属于另外一个CoS等级，不会受到PAUSE的影响。如果出现拥塞，

不会对属于CoS 0级别的溢出帧进行PAUSE控制，这些帧会被简单丢弃，IP传输不要求无损以太网因为TCP或更高级别协议（如果使用了UDP）将会处理IP包丢失问题。

说明：PFC帧的以太域类型值为0x8808（与PAUSE帧的以太域类型值相同），Opcode的值为0x0101（PAUSE帧的Opcode值为0x0001）。

延迟删除

由于PFC将缓存需求返回给数据源，因此它不会区分网络流量的暂时性突发与长期拥塞。延迟删除位于传统以太网与PFC控制中间，它是另外一种以太网强化机制，差别在于：对于暂时性网络流量突发，延迟删除将采取PAUSE或PFC机制来减小帧丢失；而在处理长期拥塞时，则会通过帧丢弃触发更上一层拥塞控制，使得系统中只会存在短期流量突发，而不再有长期拥塞。

延迟删除可以采用每用户优先级激活，它使用代理队列来衡量网络流量突发的时间，在常规操作中，代理队列将效仿实际队列进行帧的增加或删除，当出现网络流量突发并导致实际队列达到特定阈值时，系统将向数据源发送一个PAUSE或PFC帧，此时，容量远超过实际队列的代理队列将继续接收帧，当代理队列也被填满后，系统将告知发送者释放PAUSE或PFC帧，此时，如果拥塞仍在持续，就会造成帧丢失，发生这一现象时，系统将触发TCP流量控制以保护长久流。

在出现暂时性网络流量突发状况时，实际及代理两条队列都应该快速消耗掉缓存空间以便实际队列自己能够释放PAUSE帧；如果出现持续拥塞，代理队列将贡献出所有缓存空间，并释放PAUSE帧。此时，实际队列将开始丢弃帧，并通过上层协议解决拥塞。借助延迟删除，在特定一段时间内可以使用指定的CoS流控制机制，如果超过该时间段，拥塞还依然持续，就可以采用传统的抛弃处理方法。延迟删除能够配合PFC一起对“短期拥塞”进行调节，而不必因此增加接口的物理缓存。

增强传输选择

PFC可以在一条物理链路上创建8个不同的虚拟链路类型，基于IEEE 802.Qaz的ETS能够启动对这些虚拟链路的带宽管理，它是对PFC的一个补充。ETS提供了基于带宽分配及延时的优先

级处理，即根据帧的优先级将它们分配到不同的组中，然后按照一定比例将物理链路的最大可得带宽分配给这些组，ETS的目的是实现一个带严格优先级高效的两级硬件亏损加权轮循（Deficit Weighted Round Robin,DWRR）调度算法。

图2-19展示了三类不同的应用传输：进程间通信（Inter-Processor Communication,IPC）、LAN及SAN（例如FCoE），这些应用传输类型拥有不同的优先级变量或CoS，比如，IPC的CoS为7，LAN传输包括了CoS 0、1、4～6，而SAN传输包括CoS2和CoS3。ETS不会关注有多少可得的传输等级，而是会将这些传输分成不同的优先级别组（Priority Group,PG），并为每个小组分配一个优先级组ID（Priority Group ID,PGID）。在我们给出的样例中，SAN传输等级（CoS 2和3）被映射到PGID 0，LAN传输等级（Cos 0、1、4～6）被映射到PGID 1，而IPC（CoS 7）的PGID则为15。

CoS到优先级组映射

优先级（CoS）	优先级组ID（PGID）	应用
7	15	IPC
6	1	LAN
5	1	LAN
4	1	LAN
3	0	SAN
2	0	SAN
1	1	LAN
0	1	LAN

带宽分配给优先级组

PGID	优先级组（PG）%	应用
15	-	IPC
1	50	LAN
0	50	SAN

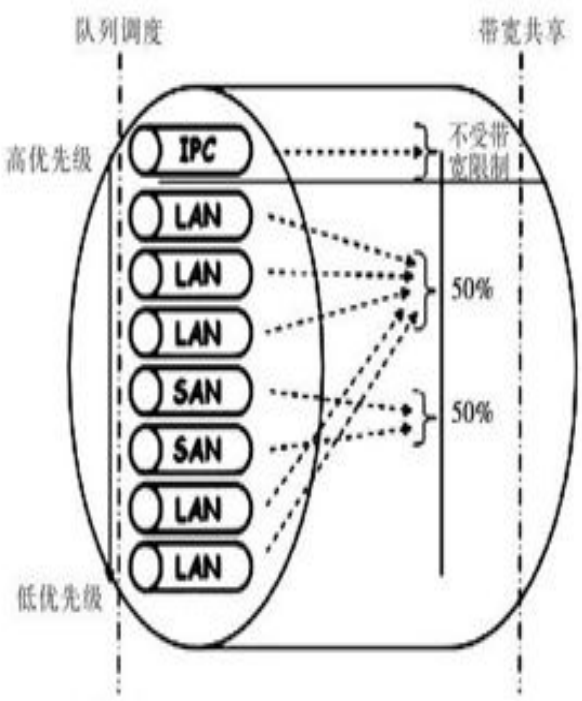


图　2-19　ETS样例

第一级调度在每个PG内部完成，第二级调度则基于分配给每个PG的带宽（BandWidth,BW）进行。本例中，50%的物理链路可得带宽被分配给了PGID 0，剩下的50%分配给了PGID 1，PGID 15是一个具有特殊意义的优先级组标号，它意味着该优先级组不受带宽限制，任何被映射到PGID 15的优先级都会使用严

格的优先级调度（不由ETS负责），本例中IPC（CoS 7）就属于这一类。

说明：PGID的范围为0～15，PGID为15的优先级组不能够分配任何PG%，属于这一组的优先级不受带宽限制，PGID 8～14的值属于保留值，0到7之间（包括7）的PGID必须用作带宽分配（或限制）配置。

数据中心桥接交换

基于IEEE 802.1Qaz的DCBX是IEEE 802.1数据中心桥接（Data Center Bridging,DCB）的管理协议，属于链路层发现协议（IEEE 802.1AB），支持以太网参数的自动交换以及交换机与终端之间的发现功能。可以被交换的以太网扩展和特性参数包括：

·PFC

·ETS中的优先级组

·拥塞通告

·应用（例如FCoE）

·逻辑下行链路

·网络接口虚拟化

DCBX能够发现链路两端设备的能力，并检测设备配置是否匹配，如果两端设备中有一个设备未配置同时也支持端到端的配置，DCBX可以对该设备进行基本配置。两端设备可以选择希望支持的特性，以及是否接受另一端设备的配置参数。简而言之，DCBX协议有助于保持链路配置的一致性，并降低了新以太网扩展功能配置开销，DBCX可以提供以太网功能强化，但同时配置开销更低，错误也更少。

拥塞通告

无损以太网有可能产生“传染性”拥塞，蔓延到整个网络，并导致有害的线头（head-of-line,HOL）阻塞，某些形式的L2端到端拥塞通告协议能够缓和这一问题。

IEEE 802.1Qau体系使用量化的拥塞通告（Quantized Congestion Notification,QCN）来定义拥塞点（Congestion Point,CP）以及重启点（Reaction Point,CP）。在模型中，在拥

塞点测量拥塞规模，在重启点进行限速或背压，以控制传输规模，降低拥塞的影响。RP应该尽可能地接近拥塞源头，当产生拥塞时，CP（发生拥塞的汇聚层交换机）将向拥塞源以及RP发出通告消息，告知其当前的拥塞状态，当接收到拥塞通告消息后，位于RP的限速器或流量控制器将开始工作，减缓网络的传输速率。拥塞通告的目的是将发生在网络核心区的拥塞转移到网络边缘，以避免拥塞蔓延到网络其他部分。在网络边缘进行拥塞控制相对容易些，因为网络边缘的流量远低于网络核心区，这意味着在网络边缘更容易确定并限制那些引起上行通道拥塞的网络流。

说明：拥塞通告消息包含了一个反馈质量，采用一个6位数对其“量化”，“量化”拥塞通告也是源自于此。

如图2-20所示的一台汇聚层交换机，类似CP的功能，向两台接入层交换机，此处为RP，发送拥塞通告消息，要求它们降低网络传输的速率，以缓和网络核心区域的拥塞，防止它蔓延到全网范围，而只会对接近拥塞源附近的区域造成影响。

说明：QCN信号与PAUSE之间的差别在于PAUSE是从一跳到下一跳，而QCN拥塞通告消息是端到端的，这些拥塞通告消息被传播到拥塞源头，MDS交换机在FC上实现了一个类似机制，称为光纤通道拥塞控制（Fibre Channel Congestion Control,FCC）。

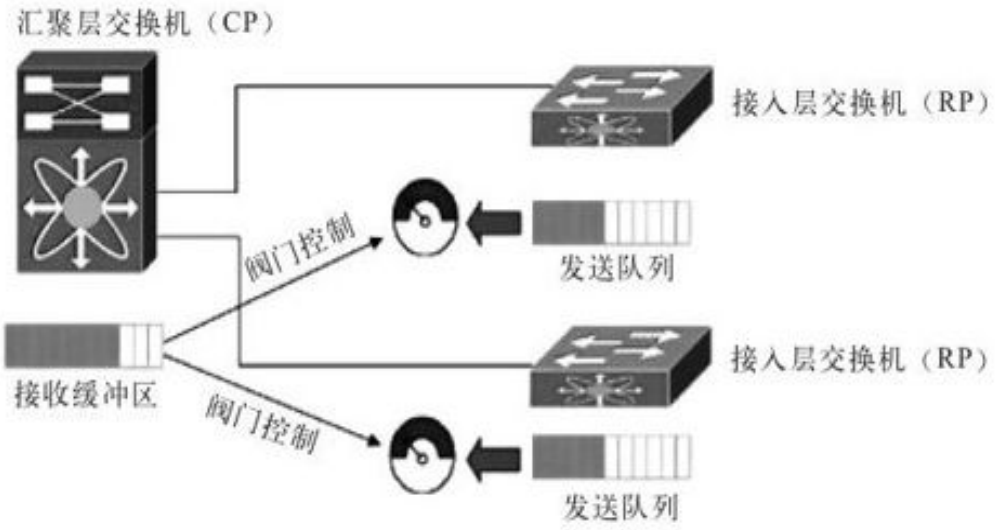


图　2-20　QCN信号

2.6.3 FCoE解决方案

有了10GE，再加上无损以太网的扩展功能，现在以太网已经有可能与FC分庭抗礼了，但是还存在一个问题：如何整合FC及新型无损以太网来创建一个统一DC光纤呢？答案就是FCoE。

FCoE以INCITS T11光纤通道骨干（Fibre Channel Backbone,FC-BB-5）标准为基础，它能够独立本地以太网转发机制，将本地光纤通道映射到以太网上。FCoE本质上是通过以太网发送本地FC帧，同时保留了所有FC的结构，确保现有FC管理方式保持不变，对操作的影响也降至最低。换句话说，FCoE能够对任何现有本地FC SAN环境进行互换操作，避免了完全翻新式升级。FCoE依靠由无损以太网支撑的可靠的底层网络互连，借助在同一物理线缆上传输不同类型的应用数据（例如，FC和以太网），FC实现了渐进式的I/O整合及I/O统一方法。从长远看，存储模块中的服务器模块（参见图2-2）除了借助直接本地FC接入通过互连点B访问FC SAN，也应该能够通过互连点A利用FCoE直接访问FC SAN。

为什么不使用iSCSI呢？更推荐使用FCoE的主要原因是受DC整合的影响。如果是从零开始建设DC，无疑iSCSI是最理想的选择，但大多数公司已经投资并建设好了本地DC接口，因此他们对渐进式方法更感兴趣。iSCSI使用了与现有FC不同的SCSI命令映射，将本地FC与iSCSI进行整合时要求采用状态网关功能，会带来单点故障、有限可扩展等问题。此外，现有FC管理模式也必须更改成其他不同模式。为了实现整合，将现有DC完全改造成全iSCSI是不太可能的，从这点看，渐进式方法更为通用，因此FCoE更有希望。而对于中小型商务市场（Small to Medium Business,SMB）领域，在建设新的DC时，iSCSI仍然是无可替代的选择，同时对纯IP SAN而言，iSCSI也是一个不错的候选方案（更多有关iSCSI的详细内容，请参考本书第7章）。

2.6.4 FCoE数据平面

FCoE实际包含两个不同的协议：FCoE协议及FCoE初始化协议（FCoE Initialization Protocol,FIP）。FCoE协议负责管理数据平面，FIP则属于控制平面协议。本节将探讨FCoE数据平面，更多FIP的内容请参考2.6.5节。

图2-21展示了一个简化的FCoE组件及架构：

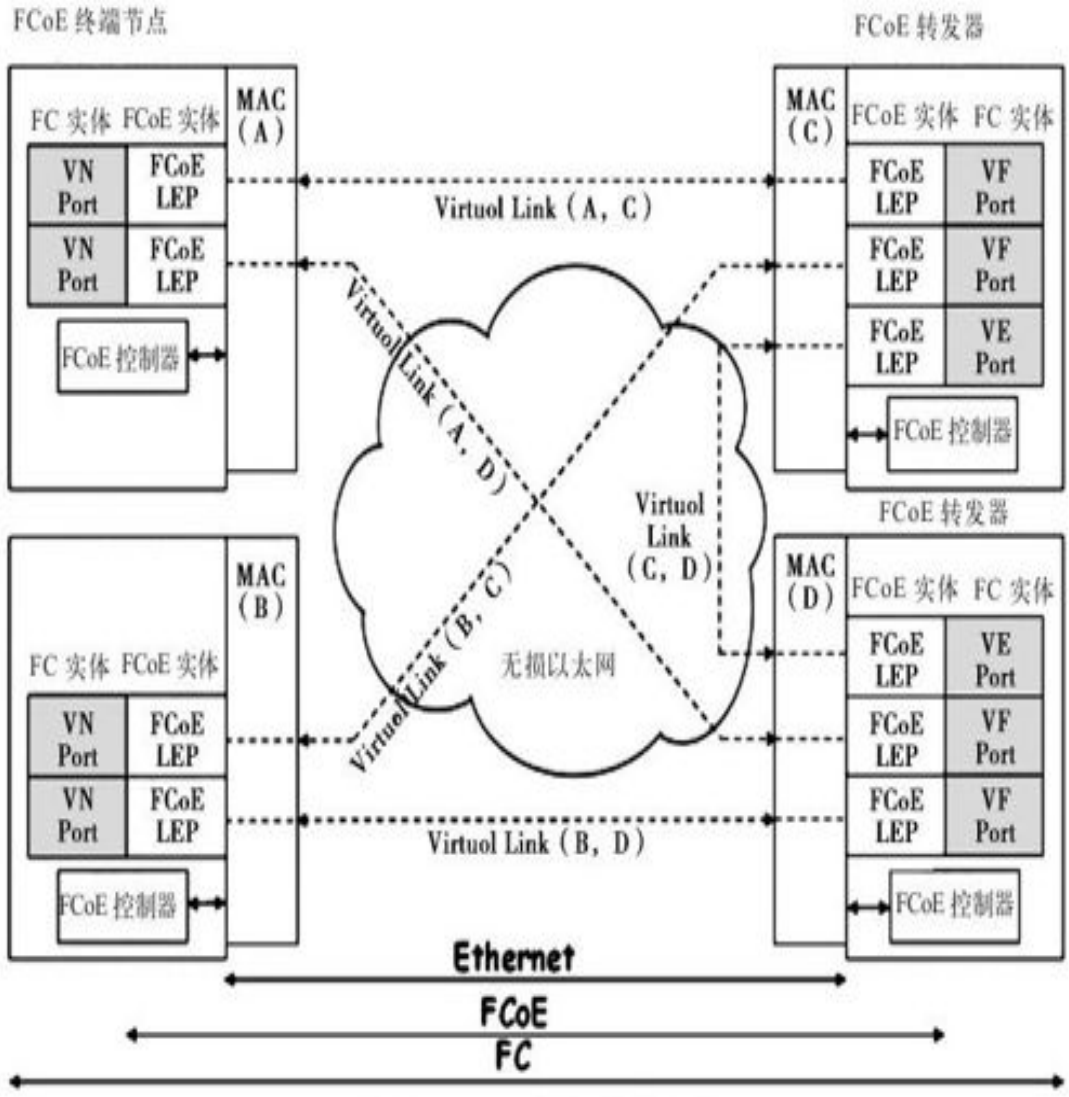


图 2-21 FCoE组件及简化架构

·FC实体（FC entity）：FC交换机元素（属于FCF）或FC栈（属于ENode）与FCoE实体之间的接口，每个FC实体包括一个单一实例，可以是VE_Port、VF_Port或VN_Port。

·FCoE实体（FC entity）：FC实体与无损以太网MAC之间的接口，每一个FCoE实体包括一个或多个FCoE_LEPs。

·FC交换机元素（未在图中显示）：属于体系结构实体，负责转发VF_Ports与VE_Ports之间的FC帧。

·无损以太网桥接元素（未在图中显示）：以太网桥接模块，支持无损以太网MAC的基本功能。

·无损以太网MAC：全双工以太网MAC，支持至少2.5KB的巨帧，并且具备拥塞扩展功能，能够避免丢失以太网帧（更多细节，请参考2.6.2节的相关内容）。

·无损以太网网络：由全双工链路、以太网MAC以及无损以太网桥接组件组成的以太网网络。

·虚拟F_Port（VF_Port）：FC实体中模仿F_Port的数据转发组件，在FLOGI交换成功完成后动态初始化，每一个VF_Port都与一个或多个FCoE_LEP配对。

说明：F_Port（光纤端口）是FC互连内对N_Port（节点端口）的附加端口。N_Port通过光纤登录（Fabric Login,FLOGI）建立到光纤的会话，光纤只接收那些完成登录的N_Port帧。

·虚拟N_Port（VN_Port）：FC实体中模仿N_Port的数据转发组件，当FLOGI或FDISC交换成功完成后被动态初始化，每一个VN_Port都与1个FCoE_LEP配对。

说明：N_Port是FC节点端口，是FC的连接点。N_Port ID虚拟化（N_Port ID Virtualization,NPIV）使用了发现光纤服务参数（Discover Fabric Service Parameter,FDISC），向光纤登录地址0xFFFFFE发送一个请求以获得一个新的N_Port ID。

·虚拟E_Port（VE_Port）：FC实体中模仿E_Port进行数据转发的组件，当ELP交换完成后被动态初始化，每一个VE_Port都与一个FCoE_LEP配对。

说明：E_Port（扩展端口）是FC交换机中通过内部交换机链路（Inter-switch Link,ISL）连接另一个FC交换机的端口。交换链路参数（Exchange Link Parameter,ELP）是FC交换机内部链路服务参数，用于交换机端口之间服务参数交换。

·FCoE链路端点（FCoE_LEP）：FCoE实体的数据转发组件，负责FC帧封装/解封以及通过单个虚拟链路发送/接收封装后的帧。EN_Node的FCoE_LEP仅支持VN_Port，而位于FCF的FCoE_LEP既支持VF_Port，也支持VE_Port。

·FCoE控制器：功能实体，与无损以太网MAC一起工作。与ENode相关的FCoE控制器其主要功能为实例化新的VN_Port并/或生成新FCoE_LEP；而与FCF-MAC相关的FCoE控制器其主要功能为实例化新的VE_Port并/或生成新FCoE_LEP。

·FCoE终端节点（ENode）：FCoE终端节点是一个带有一个或多个无损以太网MAC的FC节点，每一个节点都配备了一个FCoE控制器，它实际上是以太网NIC内的FC HBA，通常被称为CNA（聚合网络适配器），有两种“版本”的CNA：

·第一代（Gen-1）CNA：标准FC HBA与10GE NIC通过一种中间“胶合”ASIC连接在一起，在OS看来，CNA由两块独立的适配器，FC HBA以及以太网NIC组成，CNA无需改造就可以继续使用现有FC及以太网驱动器，Gen-1类型的CNA通常不具备FIP功能，因此被称为pre-FIP。

·第二代（Gen-2）CNA：Gen-2型CNA是首先方案，它由单块芯片构成，能够兼容FIP。

说明：读者也可以采用软件驱动器（更多细节，请参考http：//www.open-fcoe.org/）来实现FCoE，这对那些没有配备密集I/O负载但又需要经常访问FC存储阵列的服务器特别合适。

·FCoE转发器（FCoE forwarder,FCF）：FCF为FC交换组件，带有一个或多个无损以太网MAC，每一个都配备了相应的FCoE控制器。每个以太网MAC拥有一个MAC地址，称为FCF-MAC地址，可以为每个FCF-MAC配置一无损以太网桥接组件。也可以为FC交换机组件配置FC光纤接口，实现本地E_Port以及F_Port的连通。如果以太网目的地址是一个FCF，该FCoE帧将被转发至相应的FCF-MAC地址，然后由FCoE_LEP对封装了的FC帧解封，FC交换机组件将基于其相应的FC目的地址或FC目标ID（Destination ID,DID）转发解封后的FC帧。如果该FC帧需要经过一个以太网端口被转发出去，系统会将该FC帧封装在一个以太网帧中，附带以太网源地址与FCF-MAC的关联，以及以太网目标地址集与到正确目标MAC的映射等信息。FCF的功能本质上与带有一个或多个以太网端口的FC交换机类似，FCF也可以选择本地FC端口。

说明：如果FCF配备的是本地FC光纤接口，那些目标地址为本地FC的帧将被当做本地FC帧通过本地FC端口经由相关FC

链路转发。如果FCF-MAC配备了以太网桥（或以太网交换机），目标地址非FCF-MAC的以太网帧被接受后，将通过以太网桥按常规方式转发到相应的目标地址。

·虚拟链路（Virtual Link）：虚拟链路是在无损以太网上连接到两个FCoE_LEP的逻辑链路，如图2-21所示，虚拟链路由两个终端的MAC地址对确定。也可以将虚拟链路看成无损以太网上的一条隧道，将封装好的FC帧从源MAC地址转发至目标MAC地址。

FC包含由FC-0～FC-4，5个不同功能级别的层次，FCoE中将FC-2级进一步细化成3个子级，如图2-22左边上部所示，以便能够实现更灵活地虚拟化处理。

·FC-4定义了包括SCSI、IPV4及IPV6等不同上层协议（ULP）与FC的映射方式。

·FC-3定义了跨越多个节点间可选的常用服务或功能。

·FC-2V（FC-2——虚拟）定义了对FC帧处理，以支持上层应用。

·FC-M（FC-2——多路复用器）定义了如何将FC-2P子级实例的FC帧切分成FC-2V子级实例。

·FC-2P（FC-2——物理）定义了底层物理介质实际发送及接收帧的相关功能，包括帧发送及接收、CRC生成及校验以及链路级别（缓存到缓存）流量控制。

·FC-1定义了传输协议，包括连续编码、解码及错误控制。

·FC-0定义了系统的承载介质类型。

FC-2P、FC-1以及FC-0级别定义FC物理端口功能和行为说明，这些端口包括物理N_Port（Physical N_Port,PN_Port）、物理F_Port（Physical F_Port,PF_Port）以及物理E_Port（Physical E_Port,PE_Port）等。在FCoE环境中，如图2-22右边所示，这些功能则被FCoE_LEP以及无损以太网代替了。FCoE能够保证FC_2V以及其上更高层不受影响，也说明了对于OS而言FCoE是透明度，系统可以延续一样的FC操作及管理模型。

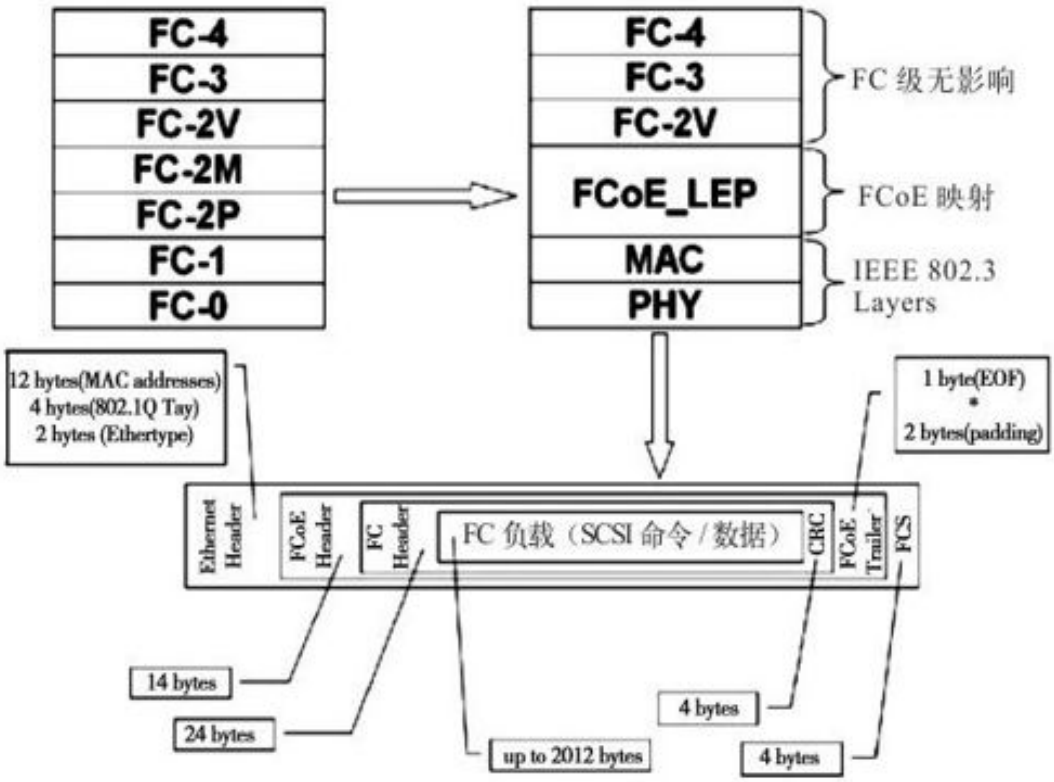


图　2-22　FCoE栈以及封装

FCoE封装如图2-22底部所示，其中FCoE的以太类型为8906h。FCoE为无状态封装及接封装备，不会影响实际FC帧，这也使得FCoE不需要网关就能与现有FC SAN集成。如果包括FCoE的帧检验序列（Frame Check Sequence,FCS）一起，则FCoE帧最大不超过2180个字节，如果不包括FCS，则最大不超过2176字节，而为了能够容纳下最大尺寸的FC帧，FCoE要求采用至少2.5KB的小巨帧。FCoE同时也能够满足以太网规定最小有效载荷不超过46KB的限制：14字节（FCoE头）+24字节（FC头）+0字节（FC有效负载）+4字节（CRC）+4字节（FCoE trailer）。固定的FCoE头及trailer字段保证了最小尺寸的FC帧总是能够产生合法的最小尺寸以太网帧。

说明：FC帧首（Start-of-Frame,SOF）定界符包含在FCoE头中，帧尾（End-of-Frame,EOF）定界符包含在FCoE trailer字段中。

2.6.5 FCoE控制平面

在本地FC环境中，N_Port仅在连接到FC光纤的点到点链路上发送FLOGI消息。在FCoE中，ENode需要知道FCF的MAC地址才能执行FLOGI，以太网采用多路访问介质，因此FCoE使用VN_Port与VF_Port之间的点到点虚拟链路来模仿本地FC环境。不过，通过手工配置来完成VN_Port与VF_Port之间的FCoE虚拟链路建设非常麻烦，如果能交给协议来完成就太好了。这也是FIP大显身手之处。FIP帧的概念与FCoE帧不同，它采用8914h以太类型封装在以太网帧中。FIP属于FCoE控制平面，因此FIP以太类型的帧将直接发送至以太网交换机（支持FCoE）以进行处理或拦截，而FCoE以太类型的帧将立即转发到数据平面。FIP能够在数据平面FCoE数据转发开始之前，完成以下属于控制阶段的任务：

·发现FCoE VLAN；

·发现FCoE实体；

·初始化虚拟链路；

·维护虚拟链路。

发现FCoE VLAN

FCoE VLAN发现协议使用了FIP VLAN请求以及FIP VLAN通告操作，协议由ENode MAC或FCF-MAC发起，FIP VLAN请求则借助任一可得（或默认）的VLAN传送。目标MAC地址为“ALL-FCF-MAC”多路访问地址，源MAC地址为发送者的ENode MAC或FCF-MAC地址。支持FIP VLAN发现协议的FCF会监听所有VLAN上的FIP VLAN请求，FIP VLAN通告消息将会向请求FCoE操作的发起者返回所有可得VLAN的列表。

说明：每个虚拟SAN（VSAN）的FCoE传输应使用不同的VLAN，这样管理员就能确定该VSAN上的FCoE传输，并且在以太网上对其进行管理。FCoE VLAN也应该仅为特定FCoE传输服务，即不应该再负责诸如IP等其他传输。

发现FCoE实体

当FIP发现FCoE VLAN后，就该ENode以及FCF借助FIP发现协议，通过FCoE VLAN来发现彼此了。FIP发现协议支持ENode发现FCF，以便建立VN_Port到VF_Port之间的虚拟链路，

也支持FCF发现ENode，以建立VF_Port到VN_Port之间的虚拟链路。在链路建立过程中，ENode和FCF都会使用发现邀请消息，FCF还会使用发现广播消息。

说明：FCF能够发送和接收发现邀请消息以及发现广播消息，ENode只能发送发现邀请消息，并接收发现广播消息。

虚拟链路初始化

一旦ENode发现了可得的FCF-MAC，就会执行FIP FLOGI以建立与FCF-MAC之间的虚拟链路，并要求获得一个FC地址（类似N_Port_ID或FC_ID）。当顺利完成FLOGI后，与FCF-MAC相关的FCoE控制器将会为该链路初始化一个VF_Port以及一个FCoE_LEP，而ENode上的FCoE控制器将会为链路初始化一个VE_Port以及一个FCoE_LEP。接下来的数据操作将使用FCoE协议以及普通的封装FC帧。

说明：在NPIV应用中，ENode能够发起一个FIP NPIV FDISC（类似FIP FLOGI）以获得额外的N_Port_ID，当某个已登录的ENode发起并与FCF-MAC相关的FCoE控制器成功完成FIP NPIV FDISC交换后，FCoE控制器将会初始化一个额外的FCoE_LEP。

另一方面，在FCF到FCD发现中，FCF-MAC将会发送一个FIP ELP给其他FCF-MAC，当成功完成ELP交换后，每个FCF-MAC的FCoE控制器也会未虚拟链路初始化一个VE_Port以及一个FCoE_LEP。

与VE_Port以及VF_Port相关的MAC地址，源自FCF协议，是由IEEE分配的全球唯一MAC地址。VN_Port能够选择两类MAC地址中的一种：服务器提供的MAC地址（Server-Provided MAC address,SPMA）或光纤提供的MAC地址（Fabric-Provided MAC address,FPMA）。如果使用SPMA，终端设备（服务器或存储）将会为每个VN_Port提供一个MAC地址；如果使用FPMA,FCF将会在FIP登录过程中（FIP FLOGI或FIP NPIV FDISC）为VN_Port分配MAC地址。推荐使用FPMA方式，该地址包括24位FCoE MAC地址前缀（MAC Address Prefix,FC-MAP）以及VN_Port的24位FC_ID的组合。例如，一个FC-MAP为0EFC00h以及FI_ID为040506h的地址组合在一起将产生一个值为0EFC00040506h的FPMA地址。

FC-MAP属于组织唯一标识符（Organization Unique Identifier,OUI），U/L位为1时表示其为本地地址，不具备全球唯一性，FC-MAP的推荐范围为0EFC00h～0EFCFFh（默认为0EFC00h）。之所以要如此确定FC-MAP的范围，是为了便于每个SAN可以分配不同的FC-MAP值，以确保能建立唯一的FPMA，从而防止了两个独立的SAN光纤在整合时会发生地址冲突。由于FC_ID是由SAN唯一确定的，因此所生成的新的FPMA在SAN也是唯一的。

维护虚拟链路

在FCoE中，VF_Port以及VN_Port或者两个VE_Port之间的虚拟链路有可能跨越了多个以太网链路以及交换机，当某个中间的以太网链路或交换机发生故障时，FCoE端口有可能并不能直接发现出现故障的链路或交换机。因为在虚拟链路中，某段物理链路的故障状态信息并不足以指明当前是否已经无法访问远程实体，因此需要启动某些增强的故障检测机制。FCoE控制器可以借助定时消息来完成虚拟链路的状态监测任务。

说明：FCoE控制器通过接收到的FIP发现消息并发送正确的FIP心跳消息来监测相关ENode中VN_Port到VF_Port间虚拟链路的状态，而对于具备VF_Port能力的FCF-MAC,FCoE控制则是通过接收到的FIP心跳消息并发送正确的FIP发现广播消息监测VN_Port到VF_Port间虚拟链路的状态。如果是具备VE_Port能力的FCF-MAC,FCoE控制则是通过接收及发送FIP发现消息监测VE_Port到VE_Port间虚拟链路的状态。

对于ENode，如果FCoE控制器能够持续接收到来自FCF的周期性组播发现公告，则认为该VF_Port正常。如果连续错过两次组播发现公告，则FCoE将认为该VF_Port已经发生故障，并反实例化相关的VF_Port/FCoE_LEP对。在FCF设备中，如果FCoE能够持续接收到来自VN_Port或ENode的周期性单播FIP心跳消息，将认为该VN_Port或ENode工作正常。如果连续错过两次FIP心跳消息，则FCoE将认为该VN_Port或ENode发生了故障，相关的FCoE_LEP也将被反实例化处理。

说明：对于ENode，当VN_Port注销后，相关的VF_Port/FCoE_LEP对也将被反实例化。如果是具备VF_Port能力的FCF-MAC，当VN_Port注销后，除非该FCoE_LEP是唯一与

VF_Port相连的FCoE_LEP，否则该VF_Port/FCoE_LEP也将被反实例化处理。

如果是VE_Port与VE_Port之间的虚拟链路，将使用主动组播公告，此外，FCF会使用FIP清理虚拟链路消息来显示反实例化远程VN_Port或VE_Port。

2.6.6 FCoE与I/O整合

如果读者认为前述FCoE内部工作机制过于复杂，希望本小节对你来说更容易理解一些，我们将在本小节讨论各类FCoE支持的I/O整合的过程和方案。当下的DC看起来与图2-23左边部分类似，存在以下局限：

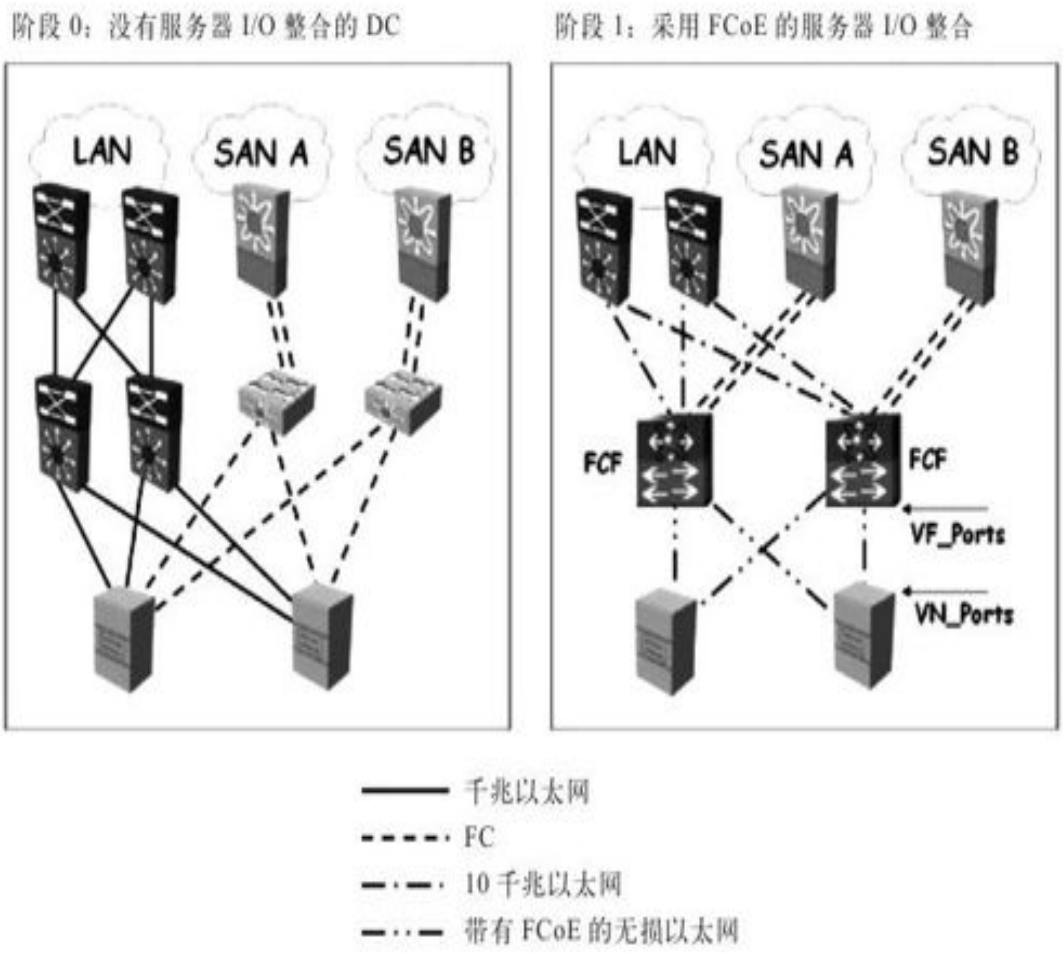


图 2-23 FCoE阶段1部署

·并行以太网LAN以及FC SAN基础设施均基于各种互连媒介和协议。以太网比FC更具“全球化”，而FC更具战略意义，因为它涉及了服务器I/O以及存储访问问题。

·服务器多重连接存在很多问题，包括：

·增加了适配器及线缆开销。

·每个连接都会增加光纤的故障点。

·增加了电力及冷却成本。

·增加了服务器开通的引导时间。

·管理复杂度，包括：

·需要不同的以太网以及FC接入层或架顶式（Top-of-Rack,ToR）交换机。

·以太网及FC的组合带来了多个容错管理域，增加了故障处理及诊断的复杂性。

·使用完全不同的以太网与FC设备，增加了固件升级、驱动补丁及版本配置的复杂性。

统一DC光纤实施的第1阶段（也是最实用的阶段）为服务器集群与接入层整合，如图2-23右边所示。我们已经了解了大部分利用服务器虚拟化技术（更多细节请参考2.3节）进行服务器整合的方法，接下来的本小节将对多适配器整合进行探讨。读者可以参照图2-23两部分进行“整合前后效果”比较。在阶段1未实施之前，每个服务器都配备了两块以太网NIC以及两块FC HBA。进行阶段1整合后，将4块服务器适配器缩减到2块CNA。而DC LAN以及SAN网络流传输也可以在同一10GE线缆上完成，不再需要使用不同线缆（1根用于以太网，1根用于本地FC）。因此原来需要8根线缆，经过整合缩减成4根，提高了高速带宽（10GE）链路的有效共享效率。

在接入层交换机这端，原来需要两个ToR以太网交换机以及两个ToR FC交换机，整合后被缩减到一对ToR交换机——一对FCF（FCoE交换机），由此简化了接入层及线缆，降低了系统总体拥有成本（Total Cost of Ownership,TCO）。同样因为从汇聚层角度（或上层）看，现有已安装好的LAN及SAN基础设施并未受到影响，保护了投资。现在由于所有服务器I/O已经整合至FCoE，并直接连接到FCoE接入层的交换机，使得接入层获得了操作一致性。来自接入层FCF到汇聚层以太网交换机的上行链路也已经升级成10GE链路。尽管阶段1仍然缺乏云IaaS所需的快速部署基础设施（统一DC光纤），但人们依然期望它成为最常见的FCoE部署起步。

图2-24展示了阶段2部署。此时，焦点已经转移到DC LAN的分布或汇聚层。原来的汇聚层交换机被迁移到服务汇聚层，被当做外部服务机箱，提供DC服务（例如，防火墙以及服务器负载平衡）。两个汇聚层FCF被安排在原来汇聚层交换机的位

置，负责将遗留的DC以太网LAN改造成具备FCoE能力的无损以太网。阶段2实施为访问存储阵列提供了一定的自由及冗余，既可以通过本地FC也可以借助无损以太网，使得我们离阶段3废除并行网络基础设施又近了一步。鉴于在阶段2DC光纤已经实现了某种程度的统一，因此基础设施部署会变得更加敏捷，其TCO成本也更低廉，而这也恰好是建立一个成功云计算所需要的。按需求基本快速部署非常接近自适应SOI，能够响应渐变商务需求，因而推荐在云IaaS的光纤模块（参见图2-2）完成阶段2。为了完成整个布局，服务机箱以及WAN汇聚路由都通过10GE链路连接到这个“半统一”DC光纤上，更多有关DC服务汇聚以及未来WAN的内容，请参考本书第3章。

图2-25展示了FCoE部署的第3个阶段，此时DC LAN以及SAN已经实现了网络范围统一光纤，本地FC交换机与FC存储阵列都被转换成了FCoE I/O接入。完全的统一光纤实现了一致的DC网络协议，又进一步降低了TCO。

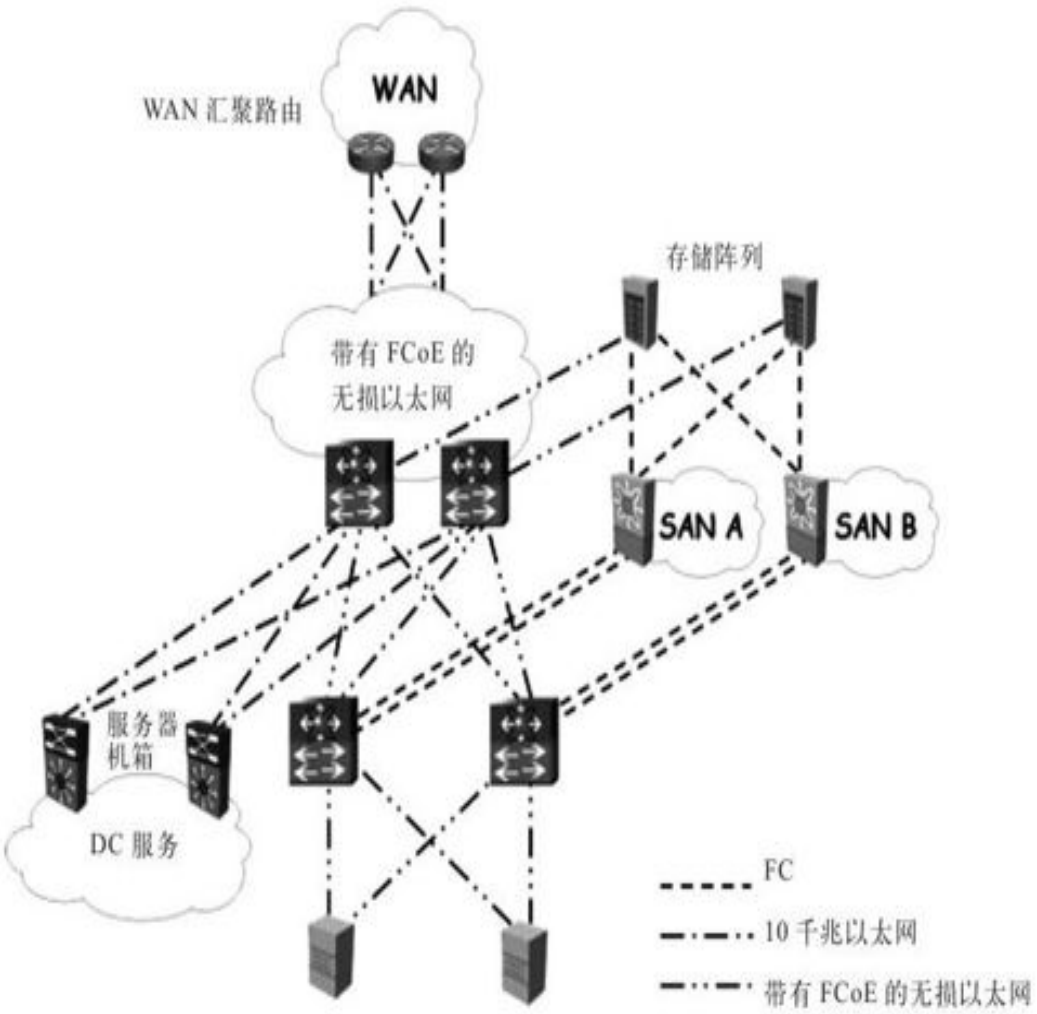


图　2-24　FCoE阶段2部署

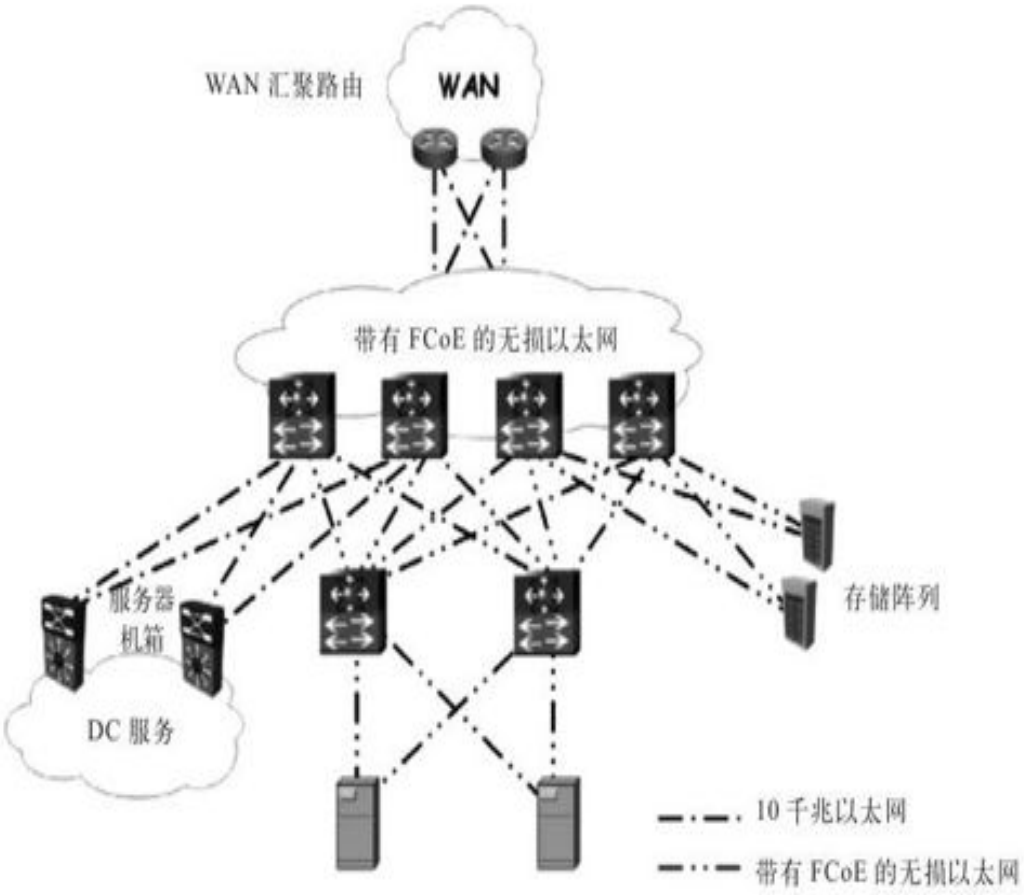


图　2-25　FCoE阶段3部署

尽管阶段3是云计算的理想场景，但某些技术仍然停留在测试阶段，在短期和中期内无论是基于感情因素还是节约投资的原因，都不可能完全废除现有的本地FC基础设施，因此阶段3也缺乏实际意义，但阶段3依然是云的理想目标，因为它代表了某些未来的目标。我们采取递增式方法，首先完成第1阶段的部署，紧接着完成第2阶段部署，最后是阶段3部署，实现最终目标。

从长远发展看，人们期望云IaaS供应商能够以他们自己的节奏从阶段2发展进入到阶段3，统一DC光纤最终有可能是阶段1及阶段2的混合，这将依赖于云IaaS服务对SOI的迫切需求究竟有几分。另一方面，新的企业DC建设可以直接进入第3阶段，实现统一的光纤网络基础以便迅速推动私有云计算服务发挥效用。更多有关FCoE的设计方案探讨请参考9.4节。

关于线缆的探讨

I/O整合对DC机架这一级带来了怎样的影响呢？适配器、交换机端口以及线缆需求的显著缩减，大大降低了电力消耗、冷却成本甚至设备占用空间，契合了绿色IT的初衷。在线缆接口这方面，已经从原来的小封装可插拔（Small Form-Factor Pluggable,SFP）技术升级到能够支持10Gbps数据速率的SFP+收发器。SFP+面板密度与SFP面板密度兼容，但能耗更低，更重要的是SFP+能够向下兼容SFP的光模块。

为了使DC机架能够适用于FCoE方案，推荐采用SFP+以及copper（CX-1）Twinax型线缆，该类线缆体积小（直径大约为6mm），能够灵活地放置在机架内，从而简化了线缆部署工作，缩短了部署时间。此外，线缆能耗更低，错误率基本可以忽略不计（10^{-15}），更重要的是线缆成本较低。尽管线缆的距离限制为10米（33英尺），但已经足够将服务器的几个机架（大约1～5个）连接到通用ToR交换机上。

说明：尽管SFP+CU Twinax线缆规范允许的连接距离为10米，但线缆连接距离的可选范围通常为1米、3米或5米。

机架技术

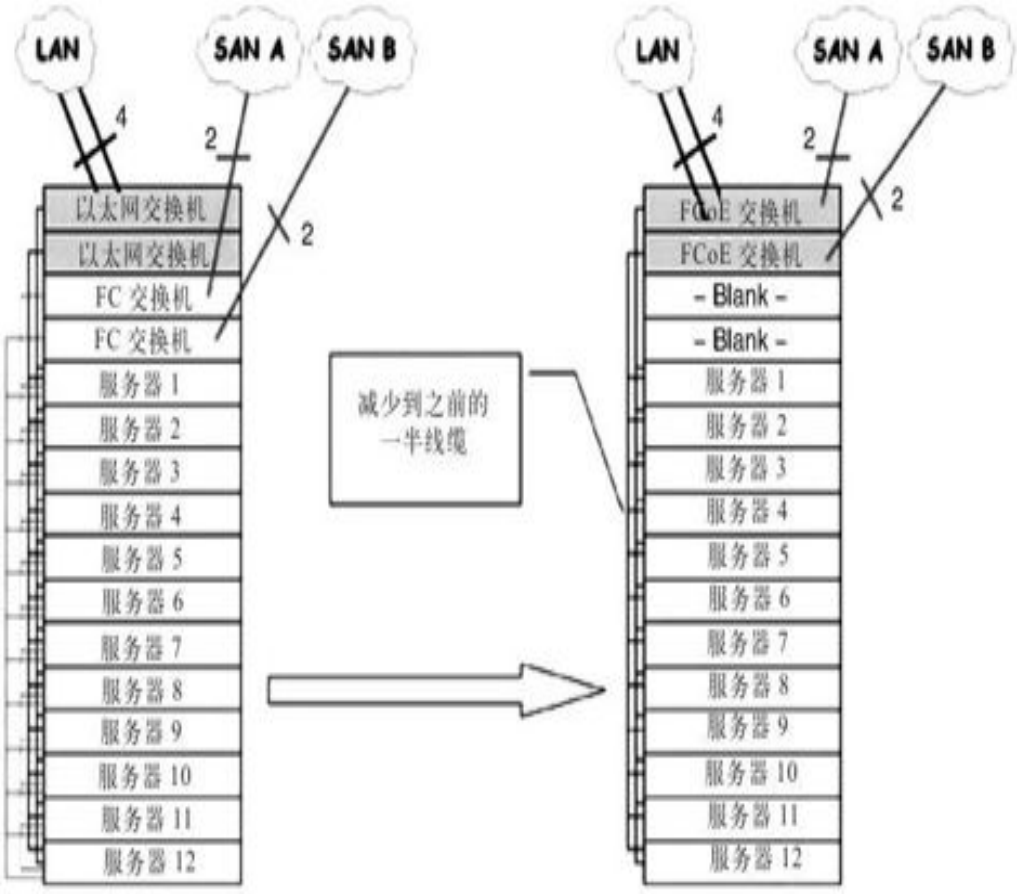
一个接入层构件被称为一个pod（机柜组），每个pod规定了连接到该网络汇聚模块的服务器数量，为了便于模块式组建，DC接入层被划分成多个pod。pod内部服务器连接由ToR接入层交换机在机架层完成，交换机再连接到网络汇聚层，这种方式有利于机架滚动式（rack-and-roll）部署，实现DC内快速服务器服务。Pod由服务器机架构成，与下述具体机架技术无关：

·列末（End-of-the-row）拓扑：列末拓扑将大型直接交换机设备放置在每列服务器机柜的末端，因而需要大量线缆绑定在一起将服务器机架连接到网络机架。列末拓扑的主要优势在于只要配置少数连接点（交换机）就能控制很多服务器端口。

·架顶（Top-of-the-rack）拓扑：架顶拓扑在每个服务器机架顶部放置1个或2个机架单元（Rack-Unit,RU）接入层交换机设备，实现每个机架之间服务器的连通。因为减少了机架到末端交换机之间的线缆，所以架顶拓扑的线缆利用率要优于列末拓扑，但由于架顶拓扑需要占用更多的ToR交换机，因此其管理负载要大于列末拓扑。

使用FCoE进行I/O整合缩减了服务器所需的适配器数量，也减少了服务器所需线缆数目，从而简化了列末拓扑中对线缆的管理。由于FCoE已经将本地FC扩展到了以太网，不再需要单独的ToR FC交换机，换句话说，也就是只采用一组同构的ToR FCoE交换机即可，因此这也减少了架顶拓扑中对ToR交换机的需求量。

图2-26展示了一个经过简化了的FCoE1阶段（参见图2-23）部署中采用的架顶拓扑，样例中使用了12个服务器，通过FCoE对I/O的整合，将总体线缆数从原来的56根缩减到现在的32根（缩减率大约为43%），单口适配器也从原来的48块缩减到现在的24块（50%的精简），ToR交换机从原来的4个减少到2个（50%的精简）——从DC整合观点来看不算坏，但如果放在私有云计算环境下显然很有优势。



12 服务器	以太网	FC	总数
适配器	24	24	48
交换机	2	2	4
线缆	28	28	56
管理点	2	2	4

12 服务器	以太网	FC	总数
适配器	24	0	24
交换机	2	0	2
线缆	28	4	32
管理点	2	0	2

图　2-26　FCoE带来的线缆精简

滚动式部署。更多有关ToR架构及设计的内容，请参考9.5节的内容。

说明：如果使用双口适配器，在进行FCoE阶段1改造前，总共需要24个单元，而经过整合，所需单元数减少到12个。

2.7 小结

当前，企业DC正经历着一场范式升级，私有云计算要求一个更灵活、更有效以及更可靠的基础设施，才能够动态自适应地商务需求变化。为了跟上这一趋势，已经建成的DC需要虚拟化技术，而新DC则需要采用模块化方法。通常鉴于虚拟化技术从根本上分离了底层物理设备与其逻辑展现，因此虚拟化在DC整合中扮演了重要的角色。特别地，企业虚拟化包含了服务器、存储以及网络虚拟化，这三大虚拟化领域组成了SOI的三点基石，能够为云IaaS服务提供动态服务平台。另外，因虚拟化而带来的好处还包括：能源消耗、冷却以及DC占用空间的显著降低，并增强了系统可靠性、服务性以及可控性，更重要的是更低的TCO、CAPEX和OPEX。

10GE基础设施已迅速成为主流应用，对更快的服务器以及内部交换机连通非常有利，不过由于经典以太网尽力而为的本质，单凭10GE网络本身并不能完成统一DC光纤的管理。只有完全不同的无损以太网才能与本地FC一试高低，为此一系列以太网扩展技术包括PFC、ETS、DCBX等纷纷出现，有了这些技术，本地FC就能通过FCoE扩展到以太网上，一个统一的DC光纤也因此展现希望。可以分3个阶段建设统一DC光纤，阶段1最保守，而阶段3最理想，阶段2则被期望成为目前主流技术的目标。作为DC革新的一部分，还必须考虑线缆基础设施以及机架拓扑，架顶式拓扑和线缆架构不但能够支持机架滚动部署模型、实现机架级的模块化，还为附加服务器提供了从1GE到10GE的平滑转换。

第3章　下一代WAN及服务集成

计算机科学并不只是关于计算机，就像天文学并不只是关于望远镜一样。

——E.W.迪科斯彻（Dijkstra）

简介

在第2章中，我们介绍了一种新型服务汇聚层，以便在当前DC LAN的分布或汇聚层实现FCoE整合。在继续深入探讨各种实现WAN模块（参见图1-2）的未来WAN技术之前，第3章将首先研究服务汇聚层智能服务元素的集成与虚拟化，包括防火墙、服务器负载均衡器（Server Load Balancer,SLB）等。

3.1 数据中心的服务集成

如果离开诸如防火墙、SLB等网络服务的支持，数据中心将无法实现SOI。在服务汇聚层实现防火墙和负载均衡器的集成非常合适，因为服务汇聚层是数据中心层2和层3自然的分界线，而且这些智能服务设备还可以在接入层通过多个交换机实现共享。有两种方式可以实现防火墙和SLB的集成：

·将单独的服务汇聚层交换机当做外部服务机箱使用，以容纳防火墙及SLB模块。

·使用独立辅助设备。

本书只讨论前一种方法。

一种部署服务机箱的方法是按照如图3-1所示的主/从机模式，一台作为活动服务机箱，其他服务机箱备用，活动机箱提供所有服务数据流的主要路径，当活动机箱不可用时则由备机提供备份路径。图3-1中汇聚1和汇聚2采用了增强以太网扩展，将服务机箱背部连接至第2章中提到的统一DC光纤上。

说明：Cisco Catalyst 6500系列交换机可以看成服务机箱的样例，它所包含的防火墙服务模块（Firewall Services Module,FWSM）相当于防火墙，应用控制引擎服务模块（Application Control Engine Service Module,ACESM）则类似SLB。Cisco Nexus 7000系列交换机可以看成汇聚1和汇聚2的样例。

当我们谈到设备虚拟化，服务机箱模式和独立辅助设备方法基本相似，只是服务机箱采用了服务模块插槽法，而独立设备模式则主要依靠外部物理设备实现管理。为什么防火墙和SLB的虚拟化很重要？因为单独的防火墙或者SLB无法实现资源、配置以及应用之间的相互隔离。可以将这些设备部署在工作区内来减缓我们之前所提及的限制。当然，采用这类方法也会引起其他的问题，例如，物理设备杂乱无章、设备和资源的使用效率下降等，这时虚拟化就显得非常重要，可以通过虚拟化技术满足并减少各种限制。服务设备实现虚拟分区和虚拟上下文有助于：

·资源、配置及应用相互间的隔离

·防止物理设备混乱

·通过更好地利用设备资源增强资源管理

·为实现云IaaS提供基于多租户形式的网络服务

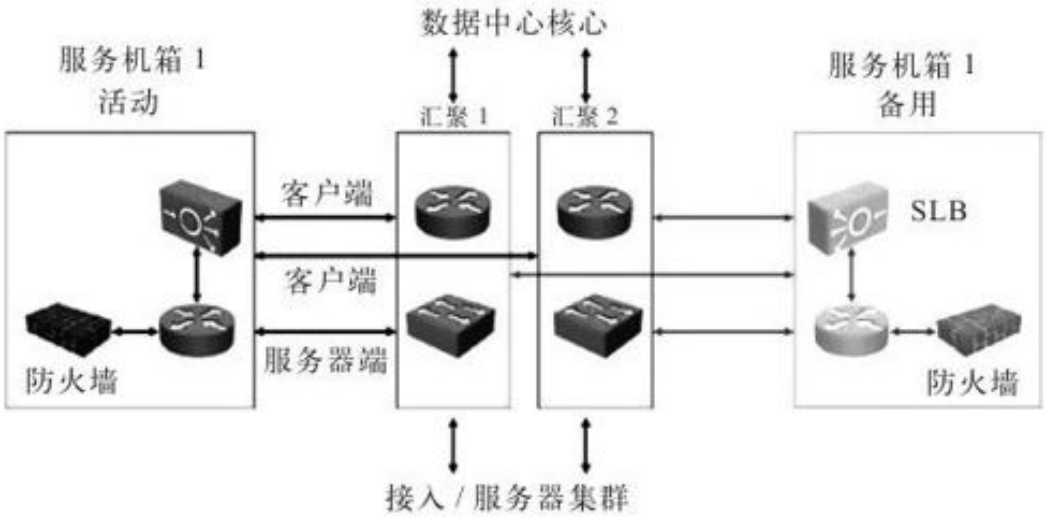


图　3-1　主/从服务机箱方式的网络流示意

详细的防火墙及SLB内部工作机制已经超出本书讨论范围，本书主要探讨通过虚拟环境（虚拟设备上下文），使这些设备能够以多租户形式支持云IaaS。

3.1.1　防火墙虚拟化

为了与服务器虚拟化保持一致，物理防火墙应该具备可虚拟化的能力，或者能够被划分至不同的（设备）上下文中，这样虚拟防火墙数量就能够随VM数量的增长而增长。从云安全角度来说，VM就像是物理服务器，而防火墙必须能够为VM提供足够的安全防护，如同保护普通IP主机一样。虚拟防火墙之间需共享物理防火墙实体的同一组资源，并且要能够像实际物理防火墙一样工作，因此从根本上需要进行一些适当的资源管理。资源管理给不同的上下文评定等级以限制在不同上下文中资源的使用，每一个上下文则根据自己的等级使用相应的资源。

图3-2展示了一个虚拟服务器集群（实际为一台ESX服务器主机），该服务器集群连接到一个防火墙，由防火墙上下文为不同VM提供各种各样的虚拟防火墙保护。虽然不同的防火墙环境彼此之间并没有完全分隔，但仍需依据相应的规则和顾客特点，例如多租户环境的特殊要求，保持一定的隔离性。

防火墙模式

如图3-3所示，按配置方式不同，防火墙可分成路由模式和透明模式两类。在路由模式下，防火墙被当做网络第3层的设备，它能够支持来自不同子网的接口并完成互联网络间的地址转换（Network Address Translation,NAT）。

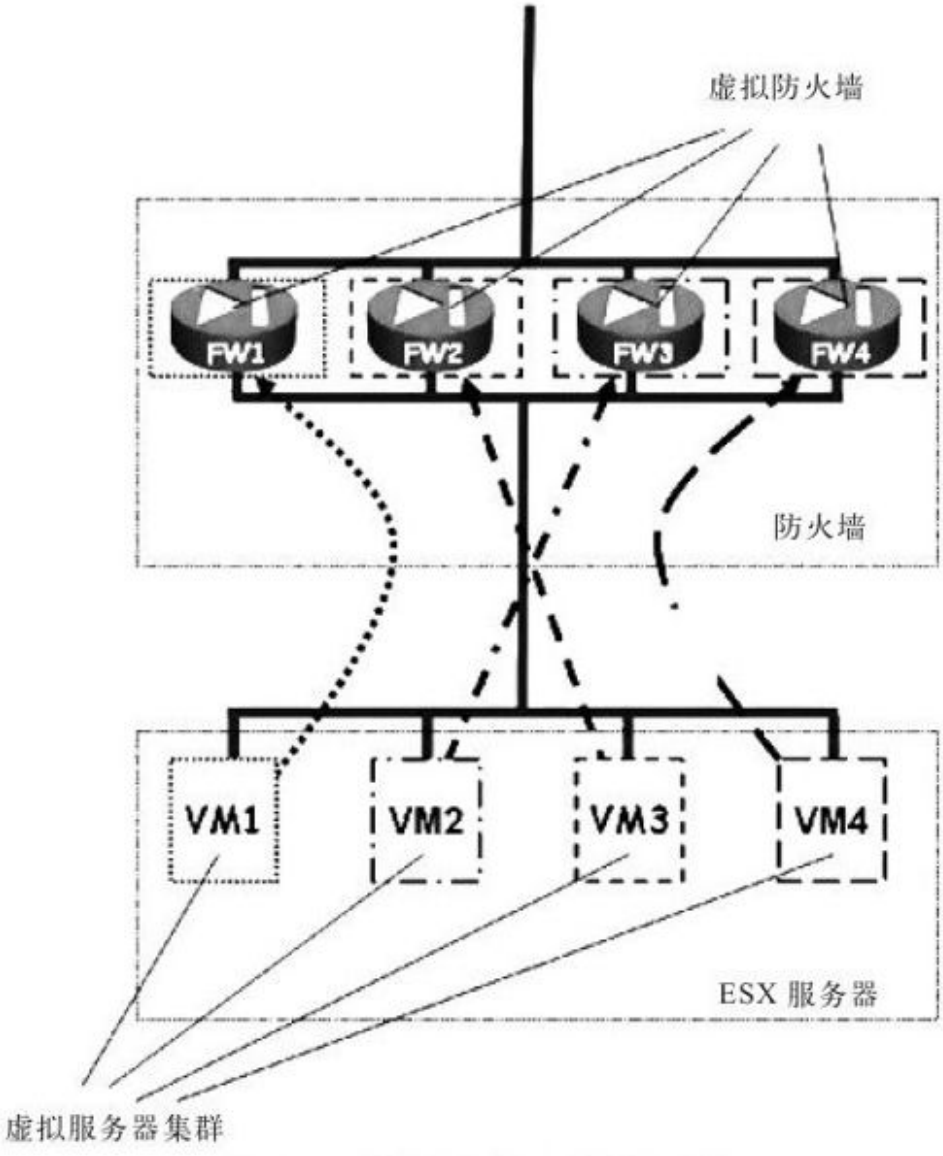


图　3-2　虚拟防火墙及虚拟上下文

在透明模式下，防火墙相当于网络第2层而非第3层的设备，也不再有路由跳数，因此透明模式下，防火墙不需要重新设置地址，就可以很容易地被安装到一个现成网络中。由于没有复杂的路由模式，也降低了故障发生的概率，使得防火墙的维护也变得相对简单。

每一个虚拟上下文中，防火墙内部连接的是同一个网络，外部则连接不同的端口，这样的连接对用户而言是透明的。防火墙可以同时支持多对这样的内外接口，就像一个桥的集合，每一桥组连至不同的网络。每一桥组需要一个指定的IP地址，透明防火墙将此地址当成从桥组发出来的包的源地址。指定地址必须属于所连接网络的子网范围内，有时透明模式也被称为“线缆中的块”（Bump in the Wire）模式。

说明：一个FWSM模式既可以支持桥模式也可以支持路由模式，但不能同时支持两种，桥所同时支持的接口对数最大不超过8。在透明模式下，不同虚拟上下文中的接口不能互享，因此在配置成透明模式时，不同的虚拟上下文要分别使用不同的接口。



图　3-3　防火墙模式

3.1.2 服务器负载均衡及虚拟化

SLB最重要的功能是将来自不同客户端的服务请求分配给当前的活动主机。SLB为每一个服务提供一个虚拟IP（Virtual IP,VIP）地址作为客户端的访问目标。当应答返回至SLB时，真实服务器的原始IP地址就被转换成VIP地址，给客户端的感觉则似乎所有请求都是在同一服务器上完成的。

基于负载和配置准则，SLB可以智能地将网络请求连接到真实服务器（也可以是VM）组成的服务器池中，过重的负载能被分散到多个实际的服务器上，SLB同时还负责监控实际服务器的运行状态和效率，这样当某台服务器需要离线维护，就可以直接从资源池中移出来，而SLB也能够利用剩下的活动服务器提供同样的支持。同理，当有需要时，也可以将新的服务资源扩充到资源池中。这些功能特性增强了DC和应用的可用性，也优化了它们的可扩展性，使SLB成为了DC中重要的集成组件。

但是，随着新的企业应用数量的增加，对SLB的需求也不断上升，因此数十台SLB组合所带来的“蛛网”现象在所难免，这些SLB上跑的可能是少数大型应用，也有可能是上百个小应用程序。如果一台物理设备上同时运行了上百个小应用，那么SLB的配置工作量会变得非常庞大也难以维护，这时在SLB上构建虚拟环境的优势就变得非常明显。图3-4证明了与其同时使用五台SLB物理设备（例如1号SLB一直到5号SLB）来分别管理DC中五个不同的应用（例如1号应用一直到5号应用），不如使用两台SLB就足够搭建5个虚拟环境（2个在SLB11上，另外3个在SLB12上）来管理这五个应用了。这样的整合可以显著降低机箱数量以及相应开销。

在SLB上构建虚拟环境后，同一台SLB可以处理来自不同的组（租客）或业务单元的应用，而不需要增加额外设备。虚拟化效应使得SLB的部署变得灵活而易扩展，同时又降低了单一配置的规模，从而相应地减小了故障处理和维护的难度。在通常情况下，SLB可以实现所有基于IP的设备间的负载均衡，包括防火墙、内存、WAN优化器等，虚拟SLB更使得这些工作的实施变得更加简单。

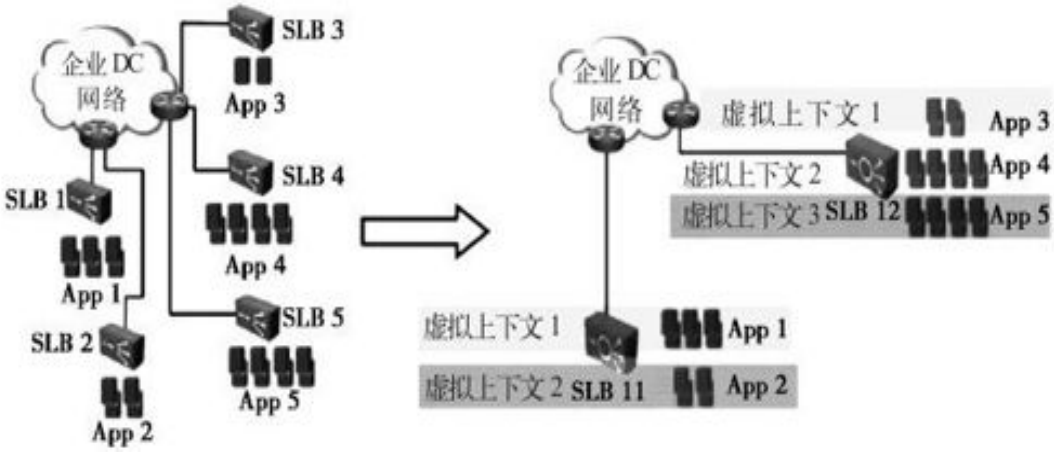


图　3-4　物理SLB与虚拟SLB上下文整合

SLB桥接模式和路由模式

SLB串联桥接模式的工作方式与防火墙透明模式类似，所起的作用有些类似“线缆中的块”（Bump in the Wire），或者连接服务器群至上行第3层设备（例如路由、第3层交换器、防火墙等）的数据流间的透明桥梁。图3-5上部是对SLB桥接模式的说明。在这种模式下，上行的VLAN和下行服务器群VLAN都位于同一IP的子网范围内，服务器集群中的实际服务器都属于同一个可路由的IP子网，服务器的虚拟IP地址则被处理成相同或不同的子网范围。每一个服务器集群需要一个不同的IP地址，SLB使用一个IP解析协议（Address Resolution Protocal,ARP）表来跟踪真实服务器的MAC地址。普通虚拟IP的MAC地址被转换成实际服务器的特定MAC地址，能够将数据流指向正确的实际服务器。在桥接模式中，实际服务器的默认网关将被配置成使用上行路由接口的IP地址。

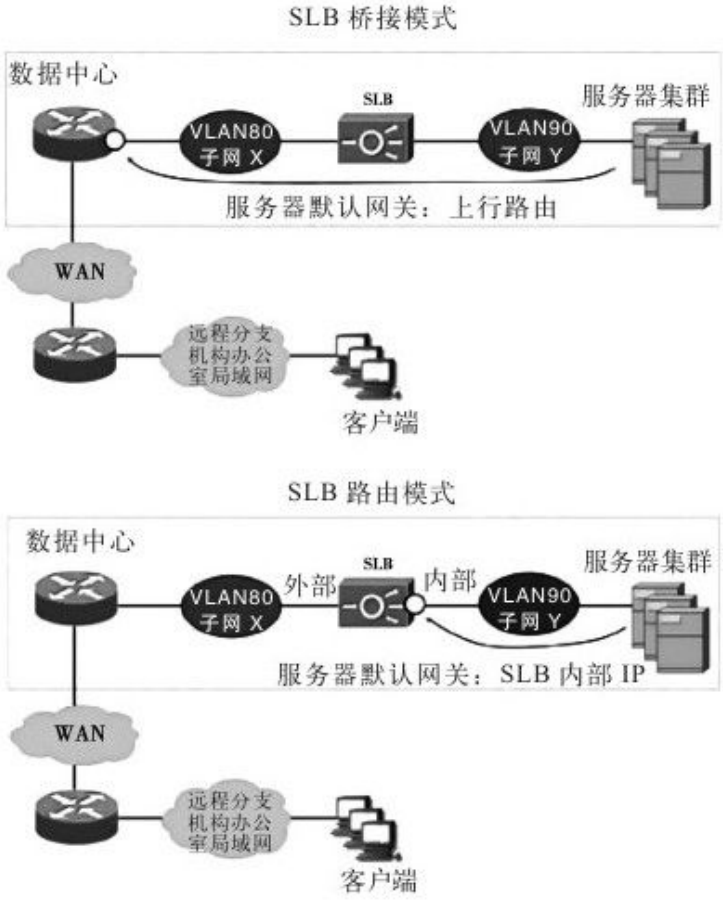


图　3-5　SLB桥接及路由模式

图3-5的下半部分是对路由模式的说明。SLB路由连接了内外子网，上行（外部）VLAN 80和服务器群90（内部）属于不同的子网。通常，服务的虚拟IP地址属于一个可路由的公开子网范围，而实际服务器则使用私有IP子网。这种模式使得每个服务器组都可以连接多个子网。SLB将来自外部子网的包按内部子网的MAC地址转发，实际服务器的默认网关则被配置成采用SLB内部接口的地址。

说明：在一个单独的ACESM环境中，没有对桥接或路由接口数量的限制，一个ACESM可以使用桥接模式连接两个接口，而同时使用路由模式连接其他接口。

SLB的单臂模式

图3-6是对SLB单臂模式的说明。SLB单臂模式并不是直接匹配到传输路径上，这样的带外数据方式能够支持扩展，而带内客户请求则通过路由访问SLB的虚拟IP地址。SLB可以通过计算得出应该将请求包发送给哪一个实际的服务器IP地址。

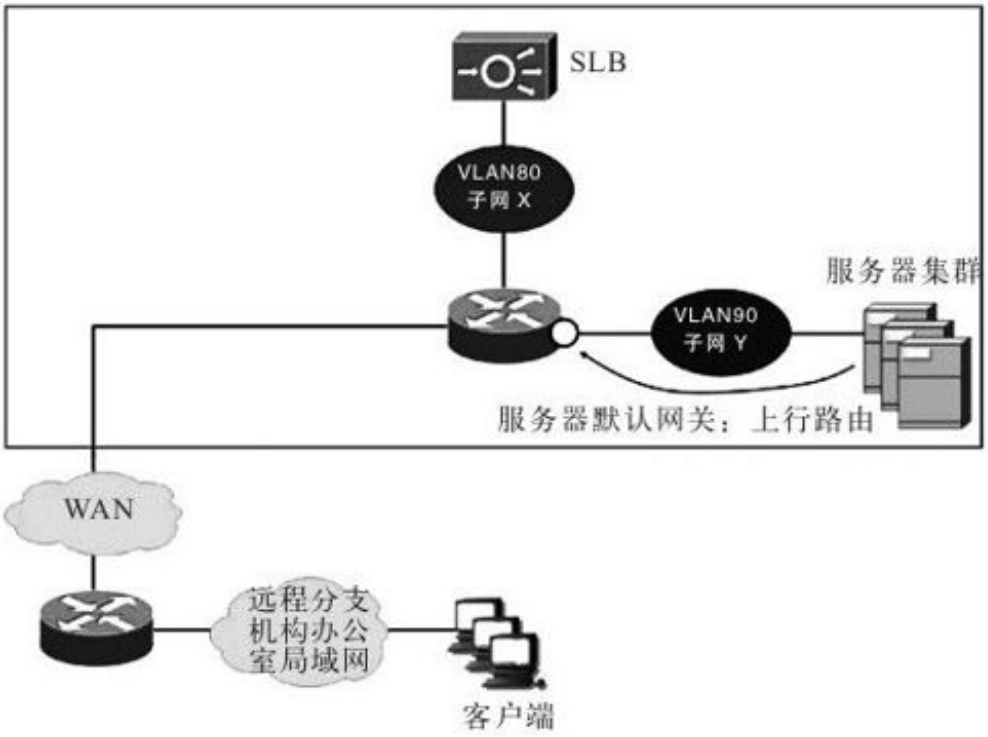


图　3-6　SLB单臂模式

使用单臂模式最需注意的问题就是返回流量也需要经过“离线”SLB，以下是一些用来确保返回流量能够通过SLB的方法：

·源（或客户）网络地址转换（NAT）：采用这种方式，客户端源地址将被SLB地址取代，服务器将它的返回结果送至SLB，由SLB重新将目标地址还原成客户端地址后转发数据包。

·策略路由（Policy-based routing,PBR）：将一些适合的对外服务器流量以下一跳方式重新定向到SLB上。

如果原始客户IP地址需要应用于客户使用跟踪、安全审计或者类似情况时，则不宜采用源NAT方式。PBR方式可以避免这些问题但也会有其他弊端，例如复杂路由或者异步路由等非负载均衡网络流量，而且基于虚拟路由转发VRF的接口也不支持PBR。如果是VRF联合单臂模式，则只能使用源NAT模式将数据流重新发至SLB。另一方面，单臂模式可以不用处理来自SLB的非负载均衡流量，因为这些流量不需要经过“离线”SLB而可以被直接抛弃，反而提高了单臂模式的效率。

说明：另外一种可以确保在单臂模式下数据也可以返回通过SLB的方法是将默认网关指向SLB而非路由器，不过这样一

来SLB的虚拟IP和实际服务器（服务器集群）的地址就必须在同一个VLAN或者子网内才行。

3.2 基础设施分段

在开始深入研究WAN模块（参见图1-2）之前，还需要在构建光纤模块时讨论一个问题：基础设施分段。基础设施分段是随着虚拟DC扩展至WAN而产生的，它与网络虚拟化的下列功能相关：

·确保网络传输仍然是在第3层被划分。

·网络传输是在相互独立的第3层分区上进行。

·在访问和服务的边缘，将第3层孤立的路径关联至VLAN。

换句话说，基础设施分段有助于实现一个多租户形式的基础设施，同时又能在虚拟共享的第3层基础设施上实现充分的隔离性。它是实现云基础设施即服务的重要组成部分。

第2层和第3层的分段

第一级基础设施分段利用VLAN从汇聚层开始，VLAN通常是基于网络第2层，考虑到可扩展性的需要，通常会在汇聚和访问层交换端口实现VLAN，参见图3-7的说明。在实际工作中，由VLAN提供的第2层分段也可以使用FCoE技术扩展至光纤通道虚拟存储局域网络（FC VSAN）（为了简单，在图3-7中未涉及这点）。关于FCoE的更多细节请参考2.6.3节。

在核心层与汇聚层使用的是第3层分段，而非端到端的VLAN，因为这类VLAN并不如它们在端到端广播领域那样流行，虚拟路由与转发（Virtual Routing and Forwarding,VRF）技术比较适合该层。从第3层角度看，VRF技术与VLAN的界限比较模糊。它们将一个路由“划分”成很多个路由和传送的实例，每个VRF都与某个特定接口（物理及/或逻辑）绑定，同一个接口不能在同一时刻连至同个VRF，也就是说，一个接口只能与一个VRF连接。

图3-7描述了一个多租户场景，其中租户A和租户B分别采用L2分段，被划分在VLAN-A和VLAN-B的汇聚层及接入层交换机中，VLAN-A和VLAN-B间通信通过802.1q trunk在核心和汇聚层交换机间实现连接。路由接口一般是核心层和汇聚层上的交换虚接口（Switch Virtual Interface,SVI），根据L3层分段被分配给VRF-A和VRF-B，如果能同时支持多个VRF，则是我们所熟悉的基于VRF的组播（multi-VRF）或多VRF客户边缘

（VRF-lite），这样通过L2和L3层的划分，租户A和租户B实现了彼此间完全独立。L2和L3层的分段可以同样被“映射”到虚拟设备上下文中，以支持诸如防火墙以及SLB这样的智能网络设备的多租户模式。

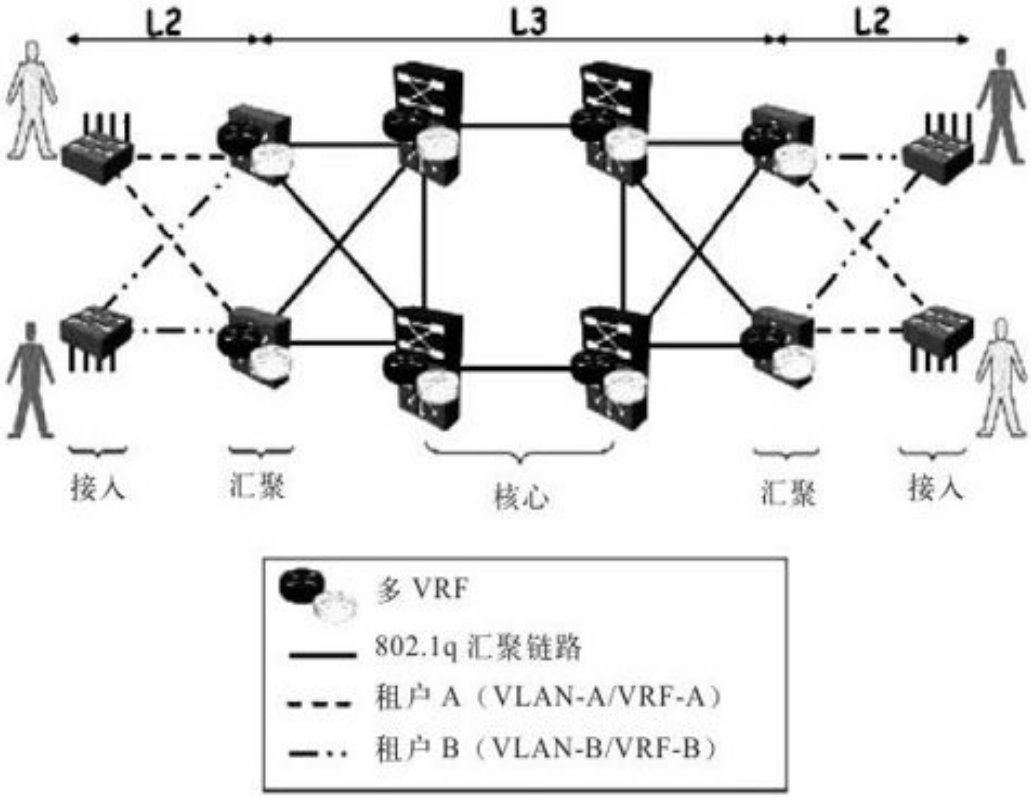


图　3-7　L2和L3层分段

说明：L3层的分段即俗称的网络虚拟化。

L3控制平面虚拟化：VRF方法

VRF到底是什么呢？简短回答即为L3控制平面虚拟化。其主要目的是在L3层实现闭合用户群（Closed User Group,CUG）特征。换句话说，虚拟专用网络（Virtual Private Network,VPN）或者虚拟网络（Virtual Network,VN）是控制平面虚拟化过程的一部分，这些虚拟网络之间是完全被划分开并相互隔离的。可以通过创建一个独立的控制转发实例或者VRF实例，在VN之间传播路由信息，为每个VN建立一个单独的IP路由空间。鉴于multi-VRF实例可以与同样的物理路由（或者是L3层交换机）单独共存，不同的VN可以使用相同的或重叠的IP地址空间而不会引发冲突。

当L3层设备实现了控制平面虚拟化后，不同设备的VRF实例必须连接在一起才能组建VN，理想情况下每一个VN都将使用单独的物理链路，但实际上这种做法不但效率低、成本高，同时也会带来可扩展性问题。基于此就必须实施不同VRF实例间数据路径的虚拟化，使得同一VN内的VRF实例间能够相互连通。如果希望虚拟后的L3层设备可以彼此直接连接，那么就必须进行链路或回路虚拟化。当L3层虚拟设备是多跳连接时，还需要一个隧道机制。有关数据路径虚拟化的更多内容请参见后面的“数据路径虚拟化：逐跳寻径或端到端寻径”一节。

图3-8左边部分是两个VRF实例间路由原理的一个逻辑示意：VRF黄和VRF蓝，其中子接口f1/0.101、f1/0.102和f1/0.103绑定了VRF黄表，子接口f1/1.201、f1/1.202和f1/1.203与VRF蓝表绑定。两者之间映射的接口地址是互斥的，例如f1/0.101已经与VRF黄表绑定，就不能再分配给VRF蓝表，同样，f1/1.201已经与VRF蓝表绑定，就不能再分配给VRF黄表。

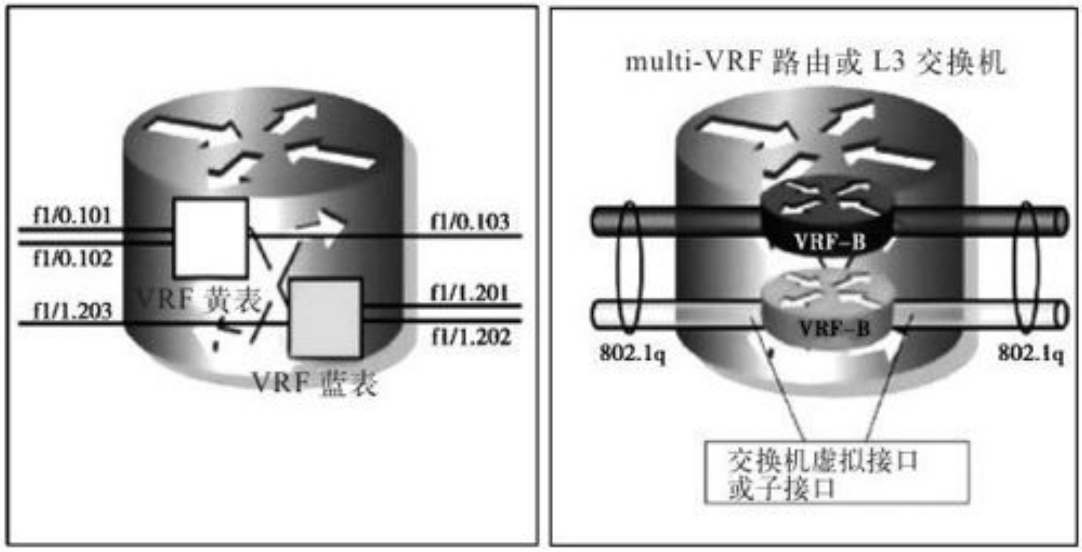


图　3-8　multi-VRF示例

图3-8右边是对图3-7中提到的multi-VRF中核心交换器的一个放大示意，在这个案例中已经实现了802.1q链路汇聚，因此每一个VRF都使用了一个SVI，代码清单3.1中的代码展示了某个L3层交换机上的multi-VRF配置模板。

代码清单3.1　L3交换机的multi-VRF配置模板

```
ip vrf VRF-A
 rd 100:100
!
ip vrf VRF-B
 rd 200:200
!
interface vlan 100
 description SVI for VRF-A
 ip vrf forwarding VRF-A
 ip address 10.100.100.9
!
interface vlan 200
 description SVI for VRF-B
 ip vrf forwarding VRF-B
 ip address 10.200.200.9
!
```

核心层交换机同时拥有上行和下行802.1q trunk，汇聚层上行使用802.1q trunk，下行使用接入链路。两层上的multi-VRF的配置差不多，不同之处是汇聚层配置multi-VRF时，需要同时完成VLAN到VRF的映射。按照3.1的配置方案，被分配给VLAN 100的汇聚层访问端口将被映射到VRF-A，而被分配给VLAN 200的汇聚层访问端口将被映射到VRF-B。

L3层设备需支持多种控制及转发实例，因此需要具备VRF感知能力，即L3协议要与IP服务相融合。路由协议是最基础的一步，因为要通过它们在VN间传递包。为了实现每一个VRF的路由功能，需要对一些现有路由协议进行扩充，包括距离矢量路由协议（Routing Information Protocol version 2，RIPv2）版本2、开放式最短路径优先（Open Shortest Path First,OSPF）协议以及边界网关（Border Gateway Protocol,BGP）协议等。有关这些VRF感知路由协议的细节将在本书稍后章节予以说明。

数据路径虚拟化——逐跳寻径或端到端寻径

L3控制平面虚拟化只是网络虚拟化的一部分，L3控制平面虚拟化支持的分段需要被扩展至数据路径级别。从根本上说，数据路径虚拟化在一个共享的物理拓扑结构上为不同的VN构造了相互独立的逻辑路径（或者称为路径隔离），实现方式通常

分为两种：逐跳寻径（Hop by Hop,HBE）或端到端寻径（End to End,E2E）。

最简单的L3 HBE数据路径虚拟化是借助图3-7提及的802.1链路汇聚，这种流行方法是在每一级L3节点，包括所有的核心层和汇聚层，实现multi-VRF，这些交换机上正确的SVI必须被分配到相应的VRF中，以获得良好的数据路径隔离效果。尽管这一方法在系统扩展及配置复杂性方面存在一定局限，但绝大多数企业的DC网络都还是采用该种隔离方案。

说明：如果打开trunk模式，802.1q trunk也可以当成L2层端口通道使用，如果使用了L3层端口，那么VRF的接口一般会选端口通道接口而非SVI。

图3-7给出的数据路径虚拟化设计配置可以被如图3-9所示的L3隧道临时取代。为了降低核心层交换机的配置负担，在图3-9中删除了交换机的multi-VRF配置。图3-9使用端到端方法，汇聚层交换机之间的通用路由协议封装（Generic Routing Encapsulation,GRE），完成L3层数据路径虚拟化，这种路径虚拟化是隧道多跳分离的，这样一来只需在汇聚层交换机部署multi-VRF，对核心层交换机则是透明的。

鉴于GRE隧道在汇聚层交换机之间是端到端形式，实际的multi-VRF配置则有点像被从汇聚层交换机一个“推到”另一个一样，也不再需要核心层交换机参与。但是对核心层交换机配置的简化却将引起另外的汇聚层交换机与GRE隧道间可扩展性问题。图3-9解释了两个分别服务VRF-A和VRF-B的隧道互相穿越的场景，从图中可知，当搭建一个新的VRF时，需要增加相应比例的隧道。由于隧道本身是点到点连接，因此将自然而然地产生可扩展性问题，这个问题在系统的设计要求具备更好的弹性或者要效仿LAN时会更加明显。

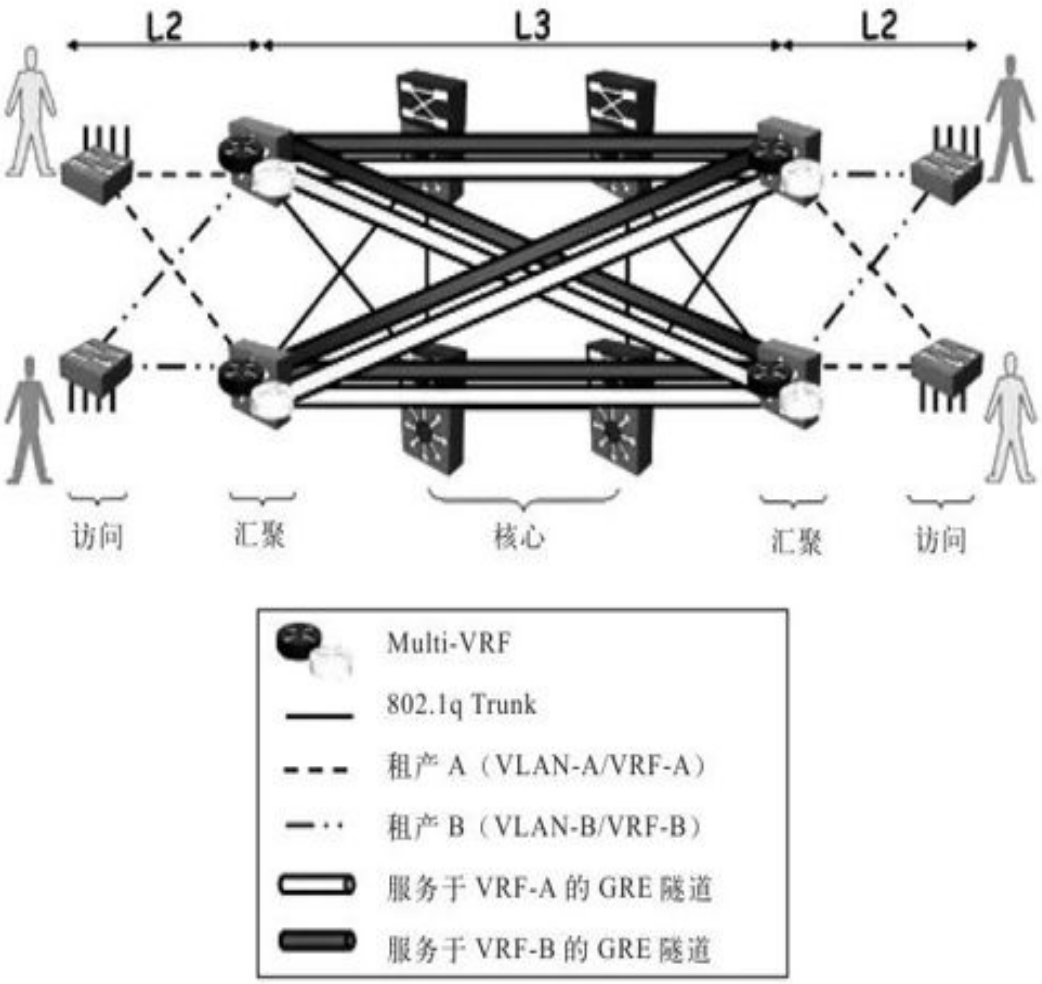


图　3-9　端到端数据路径虚拟化样例

3.3 未来的企业WAN

在本节我们将讨论WAN模型（参见图1-2）。目前供应商提供的WAN服务基本上以IP服务或L2回路为主，IP服务包括L3层VPN或Internet,L2线路包括时分复用（Time-Division Multiplexing,TDM）、帧中继（Frame Relay）、异步传输模式（Asynchronous Transfer Mode,ATM）或同步光纤网（Synchronous Optical Networking,SONET）等技术。为了维持端到端的multi-VRF租用，应该将在企业DC（光纤模式）中在这些WAN服务之上的L3分段扩展成端到端模式（参见图1-2），由此也带来了一系列未来WAN的革新技术。包括：

·与SP有关的multi-VPN技术

·L2层上的多协议标签交换技术（Multiprotocol Label Switching,MPLS）

·动态多点VPN（Dynamic Multipoint Virtual Private Network,DMVPN）

·DMVPN之上的MPLS VPN（仅用于集中星型网络，即Hub-and-spoke）

·运营商支持运营商（Carrier supporting Carrier,CsC）

·第2层隧道协议第3版（Layer 2 Tunneling Protocol version 3，L2TPv3）

在基于L2TPv3上部署CsC和MPLS VPN时会存在一些局限，例如运营商一般很少会对企业用户提供CsC支持，只有少数很小一部分企业产品生产线支持基于L2TPv3的MPLS VPN产品，所以这一方案未能得到广泛应用。我们将不会再继续深入讨论这两种特殊解决方案，本书讨论的范围只适用于从企业DC通过WAN连接到远程分支的部署方案，我们将在第7章详细说明。

3.3.1 MPLS VPN序曲

由于大多数未来WAN部署方案都涉及了MPLS和MPLS VPN技术，因此在进一步深入学习这些技术之前，我们有必要对MPLS VPN技术的一些基础知识做一个简单介绍。又考虑到MPLS本身涵盖范围广泛，所以只讨论其中最基础的内容。

MPLS源自数据路径虚拟化这把大伞之下，借助一个比方能更好地理解MPLS，即如果将MPLS比作ATM，则能够将一个MPLS云看成ATM云，ATM云里所有的ATM单元的转发都是基于虚拟路径标识/虚拟回路标识（Virtual Path Identifier/Virtual Circuit Identifier,VPI/VCI）实现的，所有被印上了MPLS标签的IP包在MPLS云内部是根据它们的标签被转发的。一个MPLS标签区域为32位，前20位数字标识的标签用来标记传送标签实际值，这些标签通常位于L2层封装头和IP层数据包之间。换句话说，MPLS的封装是当IP包进入ATM云时完成的。MPLS标签交换思想是希望将逐跳转发的IP转发模式转变成端到端的转发模式，这样的MPLS标签交换路径（Label Switched Path,LSP）类似于一个ATM的虚拟回路（Virtual Circuit,VC），或者也可以被比方成一条隧道。

MPLS云通常被称为MPLS域，MPLS域中L3层中的MPLS-aware设备通常被定义为标签交换路由器（Label Switch Router,LSR）。在所有LSR的接口上都能实现MPLS。在MPLS域的边缘是标签边缘路由器（Label Edge Router,LER），也有人称之为边缘LSR,LER拥有至少一个支持MPLS的接口。在一个MPLS域中，LER被当做网络的入口，而在一个非MPLS域中，LER被当做网络的出口。

在LER/LSR的控制平面，会使用诸如标签分发协议（Label Distribution Protocol,LDP）、多协议扩展边界网关协议（Multiprotocol BGP,MP-BGP）等标签协议来实现标签分发。LSR使用IP路由协议构建路由表，它和一个非MPLS网络中工作方式一样，不过LSR同时还将根据标签协议为路由表中的每一个目的地址分配一个标签，并且将标签与相应的转发等价类（label-to-Forwarding-Equivalence-Class,lable/FEC）绑定，并会向相邻的LSR告知这样的绑定信息。

说明：标签映射或绑定指将一个标签绑定到转发等价类（Forwarding Equivalence Class,FEC），这里FEC为整个MPLS域内的转发过程中以等价方式处理的一组数据分组。

MPLS也支持由LSP相互嵌套形成的嵌套-标签栈结构，当部署MPLS VPN时有可能需要这样的标签栈。当应用于MPLS VPN的场景时，LER被当做运营商边界（Provider Edge，

PE），LSR被看成运营商路由器，客户（Customer,C）网络或者是VPN上的客户边界路由将连接到PE上。

一个简单的MPLS VPN样例如图3-10所示，该例中应用了两类MPLS VPN中常见标签：

·VPN路由标签VPN路由标签被应用于寻找能够最好地与远程VPN内的包目的地址匹配的路由，它是VPN路由的底层标签。

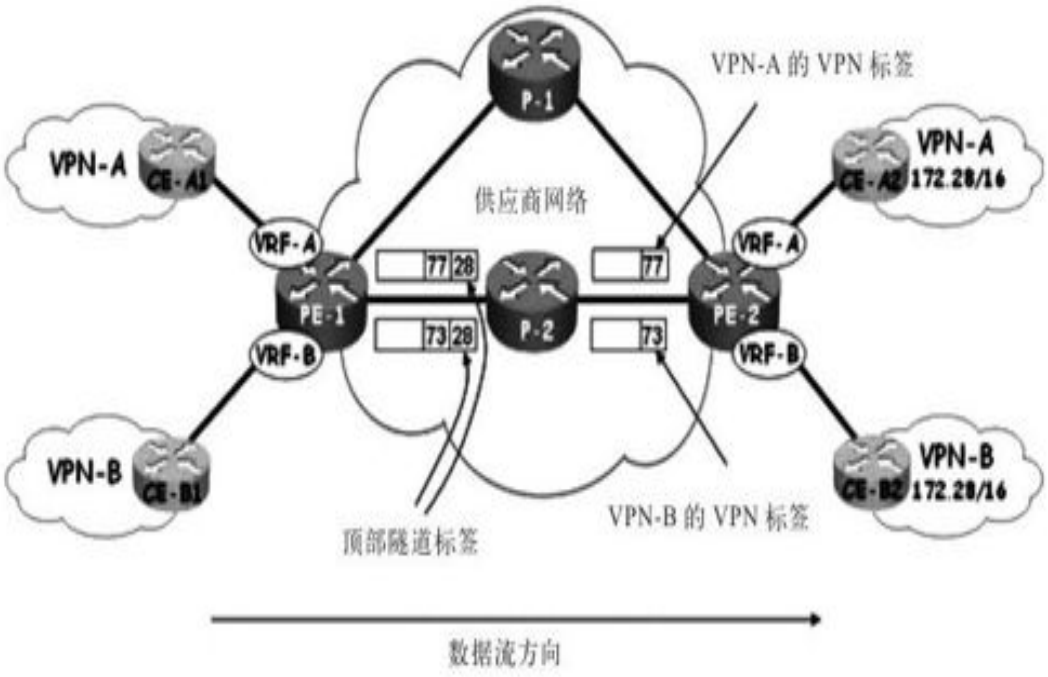


图　3-10　MPLS VPN样例

说明：VPN路由最开始是借助PE路由器中PE-CE路由协议以及多协议内部边界网关协议（Multiprotocol internal BGP,MP-iBGP）间已经成熟的路由重定向实现相应的VPN地址传播。它们使用VPNv4地址空间，通过MP-iBGP在运营商（P）网络上传播。VPNv4地址包括12位字节，头8个字节为路由标识符（Route Distinguisher,RD）信息，后4个字节为相应的客户IPv4地址信息。如果一个互相重叠Ipv4地址空间的RD唯一，那么拥有相同Ipv4地址空间的VPN也仍然是唯一的。

·隧道标签隧道标签被应用在MP-iBGP协议中寻找下一跳地址的最佳匹配，隧道标签位于包的顶部，这意味着VPN路由标签是“嵌套”在隧道标签的里面的。

说明：当PE设备处在不同的BGP自治系统间时，多协议外部BGP（Multiprotocol external BGP,MP-eBGP）将取代MP-iBGP。

VPN路由标签由MP-iBGP分发，只需在PE间配置（例如PE-1和PE-2）。隧道标签由LDP分发，可以在MPLS域或者运营商（P）网络中所有MPLS-aware设备上实现（例如P-1、P-2、PE-1和PE-2），还可以在P和PE路由间完成诸如OSPF或IS-IS这类基于Ipv4内部网关协议（Interior Gateway Protocol,IGP）的配置以实现全局Ipv4路由。

标记了VPN路由标签的数据包可以通过P网络中PE路由间的隧道转发，也使得所有VPN路由与P路由能够被分开。可以在PE路由为每一个相应的VPN配置VRF，基于这些PE路由上的VRF配置信息，PE和CE路由将支持像OSPF、BGP这类VRF-aware的PE-CE路由协议，从而完成选择一个合适的VRF进行IP寻址，根据包的最后标记将其发送至最终目的地。

说明：MPLS VPN有时也被称为2457 VPN，此称呼源自RFC2457，这是关于MPLS VPN功能的一个最初说明。RFC2457 bit也就是后来公开发布的RFC4364，是RFC关于MPLS VPN技术实现文档草稿的名称。

3.3.2 服务提供商的MPLS VPN服务

要想将企业DC的分段扩展至WAN上的远程分支，最简单的方法就是从服务提供商处订购多重L3层VPN服务，并将每一个内部VN一对一地映射到相应订购的L3层VPN上。通过这样的部署方式，远程分支机构将变成multi-VRF CE，而根据头端站点的不同设置方法，头端（或者是DC）路由器将转变成一个multi-VRF企业客户边界路由（Enterprise Customer Edge,E-CE）或者企业提供边界路由（Enterprise Provider Edge,E-PE）。

图3-11展现了三种不同的VRF或者是租户如何扩展成三个互相隔离的远程分支机构（Remote Branch Office,RBO）。在提供商的云中，每个租户都被映射到单独的IP VPN服务上。在E-CE/E-PE路由间，连接不同的企业VRF的不同子接口被映射成P-PE设备内多重订购VRF。这些连接实现了企业VRF和服务供应商VRF间一对一的映射。在企业供应商边界的子接口，企业和供应商的VRF实现了背靠背、连续的连接。E-CE1、E-CE2、E-CE3以及E-PE路由都支持multi-VRF，这些设备上也以P-PE路由或者是每一VRF为基础运行包括OSPF、BGP等相应的路由协议。

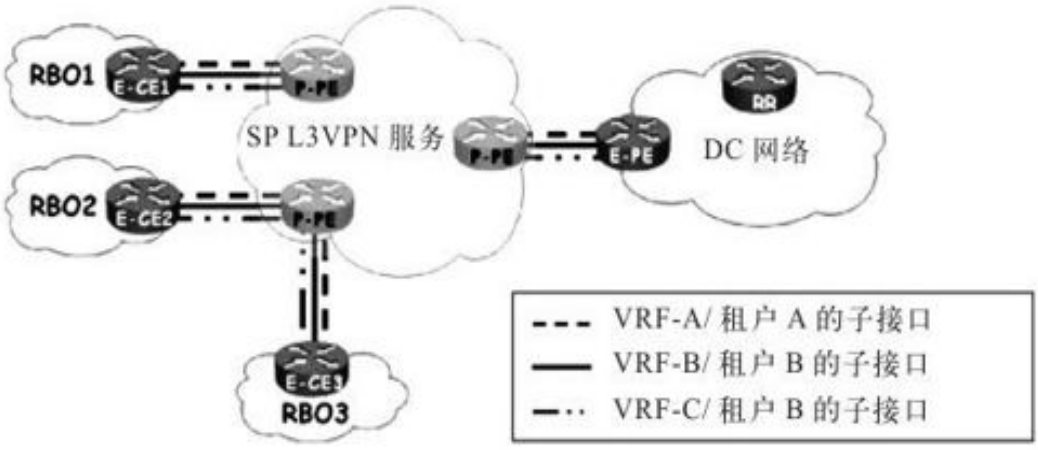


图 3-11 SP的multi-VPN样例

说明：在服务供应商的multi-VPN方案中，E-PE路由还拥有一个类似MP-iBGP发言人的附加功能，它可以在DC网络监视另一个MP-iBGP发言人（例如，另一个E-PE路由）。为了获得更好的扩展性，需要使用VPN路由反射器（Route-Reflector,RR）来监视发言人，这种方法确实能够消除MP-iBGP发言人间网状连接带来的监视负担。

简单是这种方案的最大优点，不过随着VRF和分支站点数量的增加，其未来的费用让人望而却步。从私有云的观点，相比完全的匿名控制和服务提供，这种方案因为过度依赖服务供应商才能获得L3 VPN服务而使得其吸引力相对降低。

3.3.3 L2层上的MPLS

在这种特殊的方法中，整个企业DC网络拥有现成的L2层服务，包括帧中继（Frame Relay）、ATM等。L2层的典型连接方式通常是集中星型模式或半饱和拓扑模式，spoke到spoke之间的连接是通过hub完成的。

如图3-12所示，企业DC的头端（或分支汇聚）路由转变成一个P路由（比如E-P1），接口支持MPLS功能，它包括L2 WAN链接或者是SP的L2层提供的虚拟电路。远程分支路由变成了PE路由（比如E-PE1、E-PE2、E-PE3和E-PE4），可以绑定VRF接口连接分支的LAN，以及绑定支持MPLS的接口（比如L2 WAN链接）面向头端路由连接到WAN。E-PE1、E-PE2、E-PE3以及E-PE4和E-P1一起建立起LDP和IGP会话，同样也能在它们和位于E-P1、E-P8和E-P9之后的路由反射器（如RR1和RR2）之间建立MR-iBGP会话。

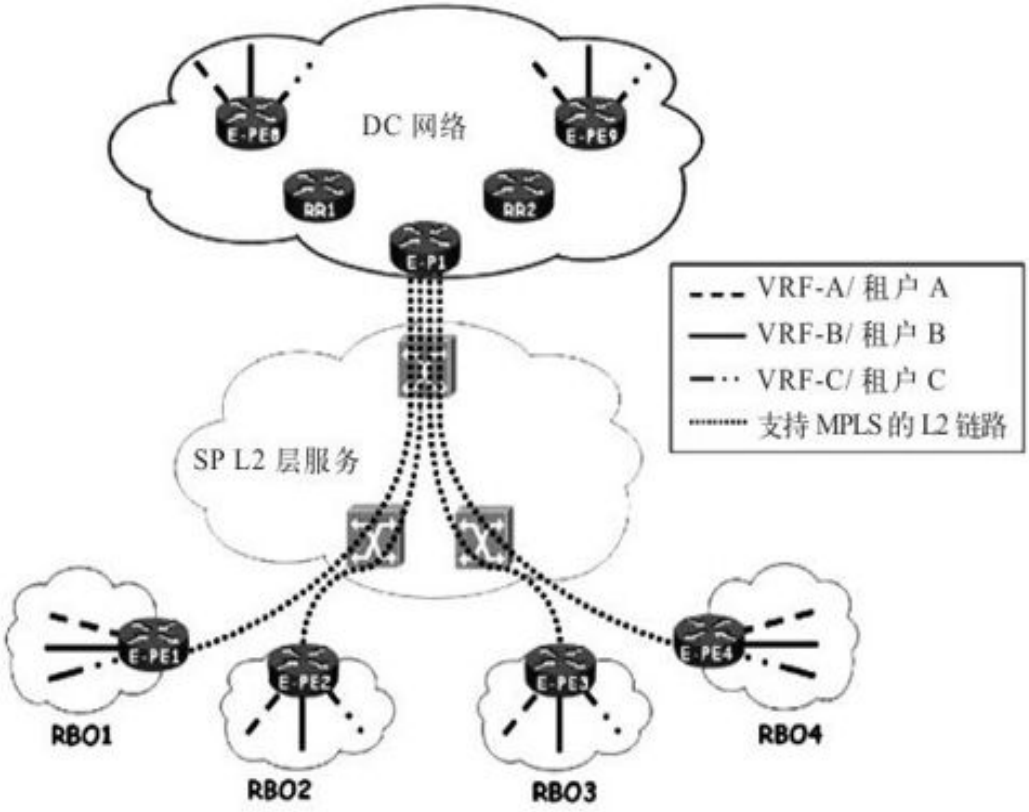


图 3-12 L2回路上的MPLS样例

有时某些远程分支机构的实例也可能不需要进行分段处理，此时这些站点上的分支机构不必在它们的L2 WAN连接启动

MPLS，特别当路由器使用P2P的方式来连接每一个远程分支时，因为可以为每一个P2P的子接口进行单独配置，所以减轻了企业DC头端路由的负担。如果头-尾路由采用的是点到多点而非P2P连接方式，那么支持MPLS的远程分支机构的连接必须要与那些不支持MPLS的远程分支机构区分开来。如果此时非MPLS远程分支机构已经存在了，头端路由器就必须被“折叠”成类似PE路由器一样，终止那些非MPLS分支机构连接至VPN（VRF）。

这类设计的主要优点企业对于整个IP基础设置实现了完全自主控制，不需要依赖SP来完成企业VN的扩展或者被限制使用某种特定技术，但如果设计方案真的要实现任意点到点的连接，就只能通过“全网”连接方式，如此一来系统整体成本将非常昂贵。目前，SP也正转向提供一些性价比更高的服务，例如IP VPN以及某些脱离L2层的服务，但如果企业如果想充分利用WAN上端到端的L2电路优势将变得有些困难，这是因为尽管L2回路通常是被认为私有的，但为了安全，在企业与远程站点间传递数据时都要对数据进行封装，要完成这样的封装就必须建立一个相互覆盖的隧道，因此增加了设计的难度，带来了新的挑战。

3.3.4 DMVPN概述

在开始讨论DMVPN之前，先复习一下GRE隧道的知识是个不错的主意，我们曾在前面3.2节中的“数据路径虚拟化——逐跳寻径或端到端寻径”小节中探讨过该问题。还记得GRE隧道天生的P2P特性给设计和部署的可扩展能力带来的挑战吗，多点GRE（mGRE）隧道突破了这一限制。例如，在集中星型拓扑结构中，在中心路由器上配置单个多点GRE隧道接口的工作取代了配置多个P2P GRE隧道接口的工作。

与P2P GRE隧道不同，当使用单个多点GRE隧道时，中心路由器的路由地址表会将所有spoke路由前缀映射到mGRE隧道接口，所以中心路由器只需一个单独的接口就能映射到所有的spoke路由器站点。不过通过单个mGRE隧道接口可以访问到多个spoke（隧道终点），因此在中心路由器需要有相应机制保证能够将mGRE隧道接口转发的包传送给正确的spoke，下一跳解析协议（Next Hop Resolution Protocol,NHRP）就是这样一类协议。

NHRP是L2层地址解析协议和缓存区，类似ARP和帧中继逆向ARP方法。当一个隧道接口是mGRE模式，NHRP将告知mGRE处理程序应该将包发给哪个地址正确的隧道（或者是spoke）。NHRP是一个客户/服务器型协议，分支路由是其中的客户，而中心路由则充当服务器角色。中心路由拥有一个NHRP数据库，登记了每个分支路由真实的物理地址（作为GRE隧道的目的地）和被赋给分支隧道接口的逻辑地址的关联，当一个分支首次连接到中心路由器时，将向中心路由器传送一个NHRP登记信息。分支会要求查看NHRP数据库以解析目标分支的真实地址以建立分支间的动态连接。

图3-13展示了一个在IP WAN之上的DMVPN样例。中心路由器与分支路由器之间建立了永久性的mGRE隧道，而分支路由之间的直接隧道则是动态组建的。NHRP解析请求和回应被应用在动态探测分支到分支间的消息映射，这种方式允许分支可以越过中心路由与其他分支建立直接连接。DMVPN能够支持一个全互联网络而无需提前探知所有连接的路径，这类网络被称为动态全网连接网络。在这样的网络中，要求一个分支能够支持与中心路由之间的有限隧道，同时能够支持与当前处于活动状态的其他分支的任意连接，如果一个分支不能够再支持更

多的分支到分支隧道，它仍然可以通过分支到中心隧道传送数据，因此即便是某个首选的下一条路径已不可得，仍然能够保持连接畅通。

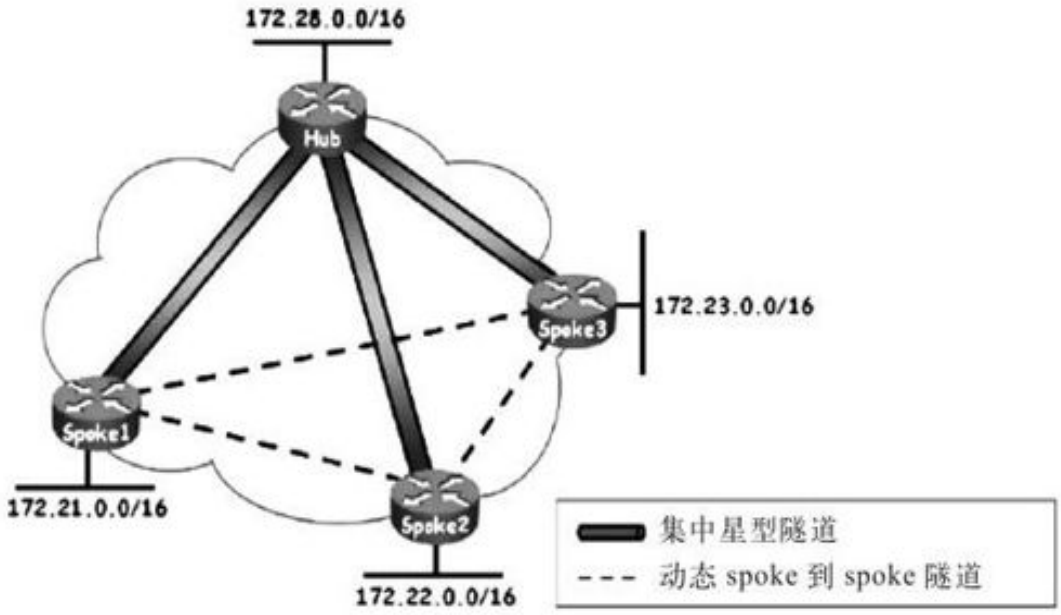


图　3-13　DMVPN样例

mGRE中心路由和NHRP机制仅是DMVPN的一部分，一个完全的DMVPN实现还包括涉及Intenet安全协议（Internet Protocol Security,IPSec）的元素封装机制。代码清单3.2探讨了一个简单DMVPN IPSec样例的配置模板。由于使用了DMVPN，因此无法提前预知哪个路由会建立到特定分支或中心路由的隧道，所以在Internet密钥交换（Internet Key Exchange,IKE）安全关联时使用了一个地址通配符（0.0.0.0 0.0.0.0），允许任意的IP地址初始化新到的IPSec会话。

代码清单3.2　DMVPN IPSec配置模板

```
!
crypto isakmp policy 10
 authentication pre-share
!
crypto isakmp key IaaS address 0.0.0.0 0.0.0.0
!
crypto ipsec transform-set CLOUD_SEC esp-3des esp-md5-hmac
!
!
crypto ipsec profile DMVPN
 set transform-set CLOUD_SEC
!
```

代码清单3.3解释了一个DMVPN中心路由样例的配置模板（与图3-13无关）。“ip nhrp network-id < value > ”命令激活mGRE接口的NHRP，此处value的值必须匹配某一个指定分支。“ip nhrp map multicast dynamic”命令确保在mGRE隧道上动态路由能与使用多点传送包的IGP一起正确工作。

代码清单3.3　DMVPN hub配置模板

```
!
interface Tunnel0
 bandwidth 1000
 ip address 10.10.1.1 255.255.255.0
 no ip redirects
 ip mtu 1440
 ip nhrp authentication abc123
 ip nhrp map multicast dynamic
 ip nhrp network-id 77
 tunnel source FastEthernet0/0
 tunnel mode gre multipoint
 tunnel key 100
 tunnel protection ipsec profile DMVPN
!
interface FastEthernet0/0
 ip address 192.168.100.19 255.255.255.0
!
```

代码清单3.4解释了一个DMVPN分支路由样例的配置模板（与图3-13无关）。分支到分支隧道可以随时根据需要建立在mGRE接口之上。因此，包可以越过中心路由直接通过直接的分支到分支隧道传输。对于分支路由器，增加了“ip nhrp nhs”命

令以定义NHRP服务器地址（例如中心路由），分支发送NHRP登记信息的频率默认是2400秒，可以使用“ship nhrp registration timeout”命令来减慢至最小60秒。这样当与中心路由间的连接被破坏需恢复时，确保重登记时间更短。

代码清单3.4　DMVPN spoke配置模板

```
!
interface Tunnel0
 bandwidth 1000
 ip address 10.10.1.2 255.255.255.0
 no ip redirects
 ip mtu 1440
 ip nhrp authentication abc123
 ip nhrp map multicast dynamic
 ip nhrp registration timeout 60
 ip nhrp map 10.10.1.1 192.168.100.19
 ip nhrp map multicast 192.168.100.19
 ip nhrp network-id 77
 ip nhrp nhs 10.10.1.1
 tunnel source FastEthernet0/0
 tunnel mode gre multipoint
 tunnel key 100
 tunnel protection ipsec profile DMVPN
!
interface FastEthernet0/0
 ip address 192.168.100.21 255.255.255.0
!
```

其他的考虑还包括：

·GRE隧道带宽：一个GRE隧道的默认带宽是9Kbps。因此，推荐改变GRE隧道接口的带宽配置，使其与实际链路的带宽值相吻合。

·IP最大传输单元（Maximum Transmission Unit,MTU）：MTU建议值是1400字节，这个传输量能够同时GRE和IPSec满负载的需求，避免了要截断包。

总而言之，DMVPN是：

·通过mGRE模式完全克服了中心路由的复杂性，只需要配置单独的多点隧道接口。借助mGRE只需单个子网就可以将中心路由与所有的分支相连。

·借助NHRP降低了全互联网络预先配置的要求。

·通过IP WAN和IPSec，提供了数据集成性和机密性。

3.3.5 DMVPN per VRF

采用此方法最主要的考虑是希望借助GRE隧道组成的网状连接，在VRF和企业DC及远程分支机构之间构建一个背靠背的专门连接。这种模式下，VRF归属不同的租户，与不同的逻辑隧道覆盖连接。每个租户的VN均拥有专属的隧道覆盖以及单独的VRF，这些VRF彼此之间完全隔离。企业可以要求供应商在L2层和L3层部署这样的架构，前提是企业必须从供应商处购买一个单独的L3 VPN或者是一组单独的L2回路，然后企业再混合使用multi-VRF和GRE隧道覆盖在VNs和购买的L3或L2层服务上。

图3-14展示了一个使用DMVPN per VRF方法部署的样例，企业DC的头端路由或者中心路由（例如E-PE）的每一个VRF配置了一个mGRE隧道，远程分支既可以采用mGRE模式也可以采用每一个VRF配置一个GRE隧道模式，但如果远程分支采用的是分支到分支的连接方式，就必须使用mGRE模式，否则可以使用单个GRE模式。DMVPN适合分支到分支的连接方式（或者是动态隧道组织模式）和大量封装（更多详细信息请参见DMVPN概述一节）的场景。基于per-VRF准则，mGRE隧道接口可以支持分支路由之间创建动态的隧道接口（也应由mGRE配置）。此外，当分支路由都被当做NHRP客户端对待时，中心路由将被配置成NHRP服务器。

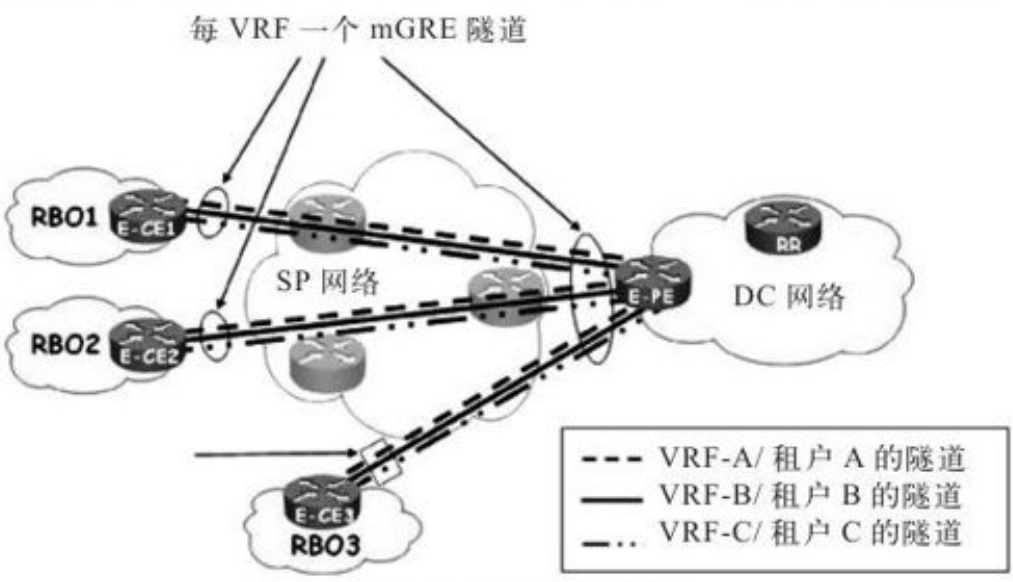


图　3-14　DMVPN样例

在大多数企业，大一点的站点需要以网状方式连接，而那些小的站点通常采用集中星型网络拓扑结构连接至头端路由，因而相对这类解决方案，其常规配置方法是在分支路由处采用GRE和mGRE的组合，如图3-14所示，分支路由E-CE1和E-CE2使用mGRE，而E-CE3使用GRE。中心路由E-PE是所有VRF（例如VRF-A、VRF-B和VRF-C）的主机，它可以采用平坦的multi-VRF跳转方式，如果企业DC支持MPLS VPN，还可以增加类似PE设备的功能。如果是类似PE设备那样的工作方式，中心路由将于企业DC的反射器间建立起MP-iBGP会话。

内置封装和简化的硬件设备及需求是这类方法的优点。此外，企业的操作人员一般都更熟悉将DMVPN当做分支汇聚的解决策略。尽管如此，这类方案的主要障碍仍然是可扩展性难题，DMVPN分支增长或者是mGRE隧道网状连接实例最终都将对系统路由设备性能产生限制，当租户数量增加以及远程分支站点增多时，也会对可控性产生不利影响。因此，这种方案比较适合那些远程分支较少或者租户或划分数量也不多的企业。

3.3.6 DMVPN之上的MPLS VPN（仅用于集中星型网络）

在DMVPN per VRF方式中，对于每一个VRF需要创建一个单独的DMVPN覆盖。基于DMVPN上的MPLS VPN只需一个DMVPN覆盖，所以可以避免上述方法的可扩展性问题。在这类架构方式中，GRE隧道构建在VRF之外，一个单独的DMVPN覆盖可以同时连接多个VRF。

图3-15探讨了基于DMVPN上的MPLS VPN方式的一个配置样例，中心路由器与一个mGRE隧道连接，分支路由器各自与单独的GRE隧道连接。中心路由器（例如E-P）起到P路由的作用，分支路由器（例如，E-PE1、E-PE2和E-PE3）则以PE路由模式工作。E-PE1、E-PE2和E-PE3与E-P间构建起LDP和IGP会话，如同企业DC网络中与路由反射器构建MP-iBGP会话一样。

说明：如果分支到分支的连接不是必须的，则分支路由器可以使用P2P的GRE隧道模式，否则就需要采用mGRE方式。

直接的分支到分支连接是不可能在基于DMVPN上的MPLS VPN模式下实现的，因为MPLS网络要求在发送至所有PE路由时都要采用标签交换方式。在这种方案中，远程分支路由（例如分支）类似PE路由，由它们完成标签排版和标签交换任务。如果在分支间能够直接建立动态的隧道，那么这样的隧道就无法实现标签排版，因此，所有的分支到分支的标签排版工作是在中心路由器完成的。尽管这种模式无法利用分支到分支动态连接的优势，它依然提供了一种更直接、更确定的分支到中心再到分支的标签交换路径（Label Switched Path,LSP），同时也更好地满足划分的要求。这类设计方案通常会被推荐给分支汇聚类场景中，即大多数连接是在中心路由与远程分支路由间，而非远程分支间直接相连。源码样例3.5给出了一个基于DMVPN上的MPLS VPN的中心路由配置模板样例。

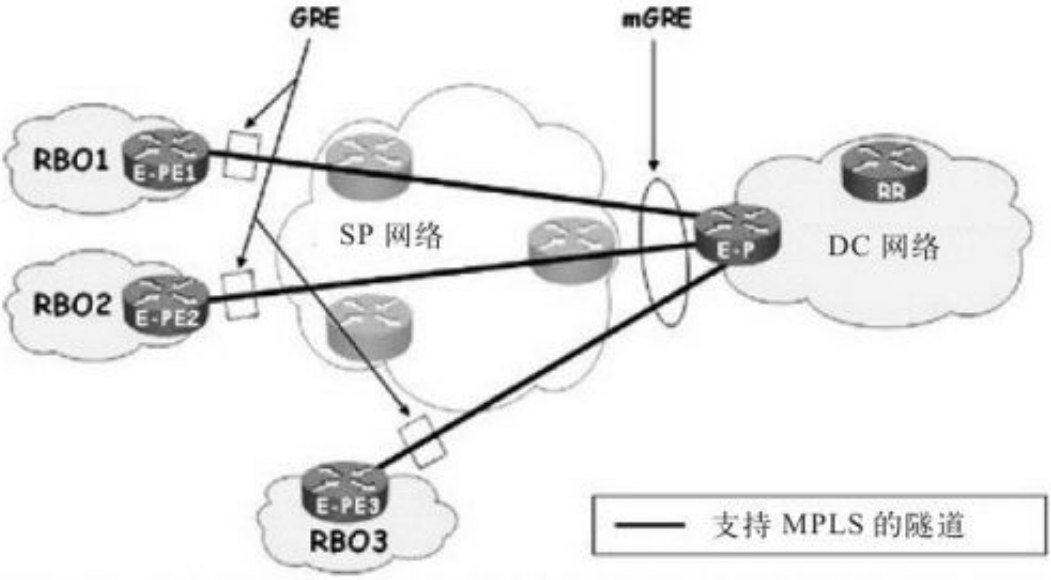


图　3-15　DMVPN之上的MPLS VPN（仅用于集中星型网络）样例

代码清单3.5　基于DMVPN的MPLS VPN中心路由配置模板

```
!
interface Tunnel1
 bandwidth 1500
 ip address 172.16.1.1 255.255.255.0
 no ip redirects
 ip mtu 1368
 ip nhrp authentication cloud9
 ip nhrp map multicast dynamic
 ip nhrp network-id 88
 mpls ip
 tunnel source 192.168.200.21
 tunnel mode gre multipoint
 tunnel key 200
 tunnel protection ipsec profile 2547oDMVPN
!
```

说明：对于隧道接口而言，最安全的（或者说最糟糕的）MTU是要避免单播数据流量以1400字节分片，组播数据流量以1376字节分片。考虑到每一个MPLS标签需要4个字节，因此一个2547oDVMPN隧道上最安全的MTU，单播应为1392字节，组播应为1368字节。

尽管这个方案更适合集中星型连接而不是任意端到端连接模式，但对那些已经部署了DMVPN的企业，因为私有云计算或者是云IaaS提供的，又希望将它们已分段的DC扩展至远程分支，这一方案也是值得采纳的。DMVPN对于将MPLS VPN扩展至远程分支具有两个主要优势：批量封装以及更重要的是，这样的方案中只需一个DMVPN覆盖。

冗余设计

有两种方法可以在基于DMVPN上的MPLS VPN部署方案中引入冗余：

·在头端站点使用双hub路由，这将形成一对DMVPN中心路由器，就像P路由一样工作。

·使用多个分支路由以及第一跳冗余路由协议，包括热备份路由协议（Hot Standby Router Protocol,HSRP）、虚拟路由冗余协议（Virtual Router Redundancy Protocol,VRRP）、网关负载均衡协议（Gateway Load Balancing Protocol,GLBP）以及在远程分支使用增强的对象跟踪（Enhanced Object Tracking,EOT）技术。

由于成本原因，在每一个远程分支都配置两个路由是不太现实的，一个务实的解决方案可以仅在一些大的远程分支机构实施这样的部署以获得高可靠性。在集中星型网络拓扑中，中心路由器属于单点故障易发之地，当中心路由产生故障时，将同时导致多个远程分支站点的故障。因此，在冗余设计中，每一个分支路由都必须通过GRE隧道同时连接到两个中心路由上，这些GRE隧道以主/从模式工作，可以通过控制路由器的metric参数来选择GRE隧道。尽管路由器以主/主模式工作有助于平衡网络负载，但主/从模式的隧道工作方式能够减轻分支路由工作量，更有效地管理路由器以便它们保持稳定的工作状态，也能提供更精确的网络传输路径特征。

图3-16展示了两个远程分支站点（路由）分别连接至两个中心路由（DC-P1和DC-P2）的样例，这里DC-P1为主路由，而DC-P2为备份路由，RBO1可以被看成是一个双层分支，代表一个拥有两个WAN路由（PE1A和PE1B）和两条DMVPN隧道以实现冗余效果的大型分支机构，HSRP协议加上EOT技术中则为分支的客户端提供了可靠连接。RBO2可以理解成一个单层分支，

它只拥有一个WAN路由（PE2）以及两条分别以DC-P1和DC-P2为终端的DMVPN隧道。当主隧道发生故障时，路由协议融合将使传输通过备份隧道完成。样例中还实现了两个VRF，分别为VRF-A（为租户A服务）和VRF-B（为租户B服务），路由反射器（RR1和RR2）与企业DC内所有PE设备间建立起MP-iBGP邻接，同时负责在PE设备（PE1A、PE1B、PE2和DC-PE）之间发布VPN路由信息。

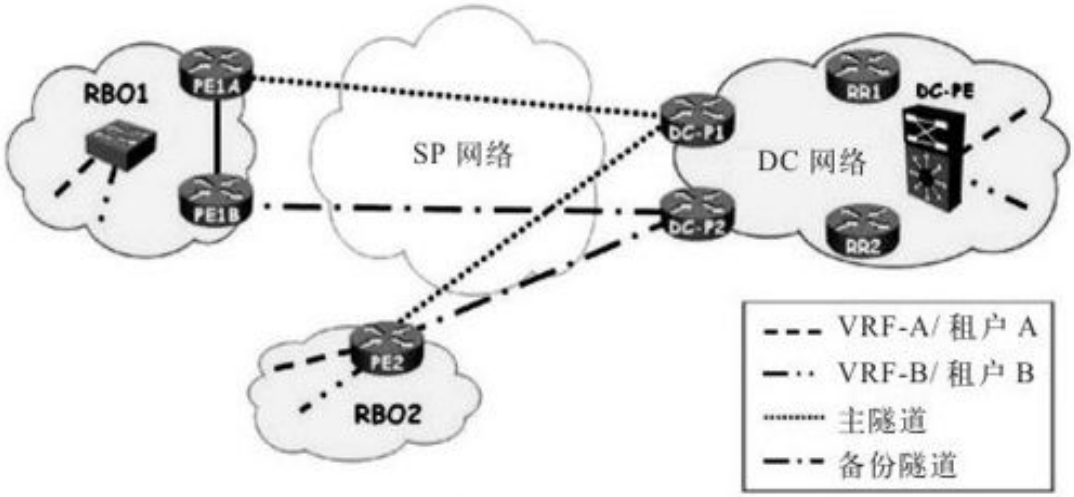


图　3-16　基于DMVPN的MPLS VPN冗余设计样例

3.4 小结

在私有云计算以及云IaaS中，防火墙能力、服务器负载平衡等都属于非常基础的智能网络服务，因此需在企业DC的SOI中引入服务机箱层，通过虚拟设备上下文或虚拟分区在物理防火墙或服务器负载平衡设备上实现防火墙设备和SLB的虚拟化及整合。

云IaaS能够支持基础设施分段，实现不同租户间的安全隔离。L2层分段通过VLAN很容易获得，而L3层分段在很多场景下更有优势。L3层分段主要包括两个主要部分：控制层面虚拟化和数据路径虚拟化，前者通过VRF实例实现，后者对VRF实例扩展可借助逐跳寻径或端到端方法实现。逐跳寻径数据路径虚拟化通常使用L2层内部连接类型，例如802.1trunk、端口隧道等，而端到端数据路径虚拟化采用L3层隧道实现。

企业DC的L3层划分以及虚拟化需要经WAN向远程分支扩展，为了实现这一目标，我们需要一种新的基于路径转发技术而非陈旧的面向HBH方法。MPLS以及MPLS VPN也因此在未来企业WANs中发挥作用，简而言之，企业可以选择从SP处订购multi-VPN服务通过WAN将L3层分段从DC扩展至远程分支。

不过，私有云计算要求企业具有自治及控制能力。企业也许反而希望考虑基于MPLS的自我管理网络，经由WAN再扩展至远程分支的L3层分段可以通过在L2层服务上的MPLS VPN、DMVPN per VRF，或者基于DMVPN之上的MPLS VPN实现，以上方法或者只使用multi-VRF实现，或者同时使用MPLS VPN和multi-VRF两种技术，无论哪一种方式都能够很容易地实现网络的虚拟化。独立网络的安全级别等同不要求SP介入的私有连接，也可以支持不同租户间的网络划分，至于最终采用何种方案，还是取决于能够获得什么类型的WAN服务以及企业硬件能够支持哪些技术，当然最重要的还是看随这些方案增加的成本到底有多高。

第4章　分支整合及WAN优化

不能把期待作为一种策略。

——佚名

简介

在学习完第3章服务汇聚层的服务虚拟化和集成的相关内容后，让我们转回头再来思索数据中心的目标是什么。数据中心不仅仅提出了一系列局域网虚拟化的难题，它更充当了企业其他部分的引擎。发展私有云的动力来自为商业雇员提供应用，为了充分发挥云的效率，如果访问来自数据中心之外，对这些运行在企业云（或数据中心）之上的应用程序性能要求十分严格。受有限带宽及相关链路的时延限制，要在WAN上获得高性能应用非常困难，云使得这一问题变得更富挑战性，因为即便是总部的终端用户也可能离他们的应用非常遥远。

鉴于本章已经离开了我们熟悉的DC设计领域，所以我们将首先从理论角度探讨WAN性能局限，再由此得出WAN优化解决方案的基本元素，也即WAN优化，涵盖内容非常广泛的一个领域，来解决WAN性能难题。在网络中实施WAN优化设备会遇到一些工程局限，我们将探讨这些限制以及它们对网络中其他系统的影响。最后，本章还将介绍优化后的WAN如何实现远程办公服务器整合、虚拟桌面以及其他可降低成本的架构。WAN优化的深入研究以及网络整合对DC带来的挑战都将在第5章和第6章中完成。

4.1 何为WAN性能挑战

如果能创建一个强大的私有云应用，使得人们无论是在乌兰巴托还是在火地岛，都能毫不费力地解决问题，该是多么令人惬意的事情啊，不幸在于现实往往不尽如人意。在过去十年里我们一直致力于为那些相隔遥远的人们发展集中式服务，因此你会经常听见有关“缩减数据中心”、“整合”以及增加使用友好的WAN程序架构（如基于web的服务）的讨论，以上努力源自对IT成本控制的驱动，包括简化备份、简化管理、压缩服务器规模等，此外规模经济也对应用质量提出了新要求。成本节约的关键是确保用户满意。事实上，友好的WAN这一词已经预示了问题所在——现有应用程序及协议大多是在LAN环境下开发的，直接移植到WAN环境时，将不可避免地遇到问题。WAN应用性能受到带宽和延迟这两个基本因素的限制。本节将首先探讨最基础也是最明显的问题：带宽，紧接着将分三方面介绍延迟对性能所带来的影响，WAN优化的任务就是解决上述四类网络瓶颈所造成的WAN性能困境。

4.1.1 头号挑战：有限带宽

端到端连接的带宽是由链路中速度最慢的部分决定的，一般来说，数据中心多为高速网络，但远程办公室或诸如机场休息室这样地点办公的用户就没法拥有像很多数据中心一样的千兆网了。当考虑接入节点的成本开销，或者某些站点不能订购高速网络，以及要为那些远程办公、身处旅途、居家办公及临时在某地办公的用户随时随地提供高速带宽是有难度的。又因为应用通常需要共享带宽，这也会影响应用可获得的实际网络带宽。拥挤的链路会导致丢包及TCP回退，又将更严重地降低网络质量。云架构中，如果没有考虑下节介绍的网络拥塞控制或者延迟策略，任何一个远程站点对服务器的访问都可能被上述这些最慢的连接阻塞。

4.1.2 问题2：WAN连接中的巨大延迟

网络延迟（数据包的“往返时延”）对Windows类协议如TCP协议，包括通用Internet文件系统（Common Internet File System,CIFS），它是Microsoft Windows用来实现主机间文件共享的一个协议或邮件撰写应用程序接口（Messaging Application Programming Interface,MAPI），被Microsoft Outlook/Exchange调用的一个协议，这样一些请求——响应类协议的性能及吞吐量有着直接影响。高往返时延会特别降低“聊天”类应用的性能，即便在每一个对话中实际传递的信息量并不是特别多。

当整体吞吐量有限而往返时延已经达到临界点，或者网络问题是由时延引起而与带宽无关时，靠增加带宽（或减少数据发送）并不能改善系统性能。由图4-1的说明可知，连接的性能最初与带宽线性相关，但当延时超过临界点时，性能将呈指数急剧下降。很容易从直观上来解释这个结果：C/S应用程序为串行执行方式，因此程序的效率与客户端到服务器端往返时延成反比，如果C/S应用程序被阻塞在某一串行化操作处（例如，聊天应用），这一阻塞将导致双倍时延，并使得整体性能双倍下降——每一步都将需要双倍时间完成（因为客户端在等待服务器端的响应，而服务器端也同样需等待客户端的请求）。

如果不是聊天类应用，而是基于Window的协议的C/S软件（如TCP），也会面临同样的命运。我们可以通过建立一个简单的往返时间（Round-Trip Time,RTT）与协议窗口（Window,W）之间的等式来解释。协议窗口的大小是发送者无需接收者确认而可以一次发送的最大数据量，一旦协议窗口写满了，发送者就必须等待直到它收到接收者确认信息。收到接收者确认信息需要耗费双倍往返时间，因此数据发送速率由窗口大小除以往返时延得到：

$$T = \frac{W}{RTT}$$

TCP协议必须要知道怎么确定窗口的大小，最佳方案要考虑以下几方面因素。为了很好地适应不同条件的网络状况，TCP将依据当前网络容量确定窗口W的大小，假设当前网络容量（或者TCP发起者共享带宽）大致为每秒B个字节，那么发送端窗口大小将被设置为B×RTT：

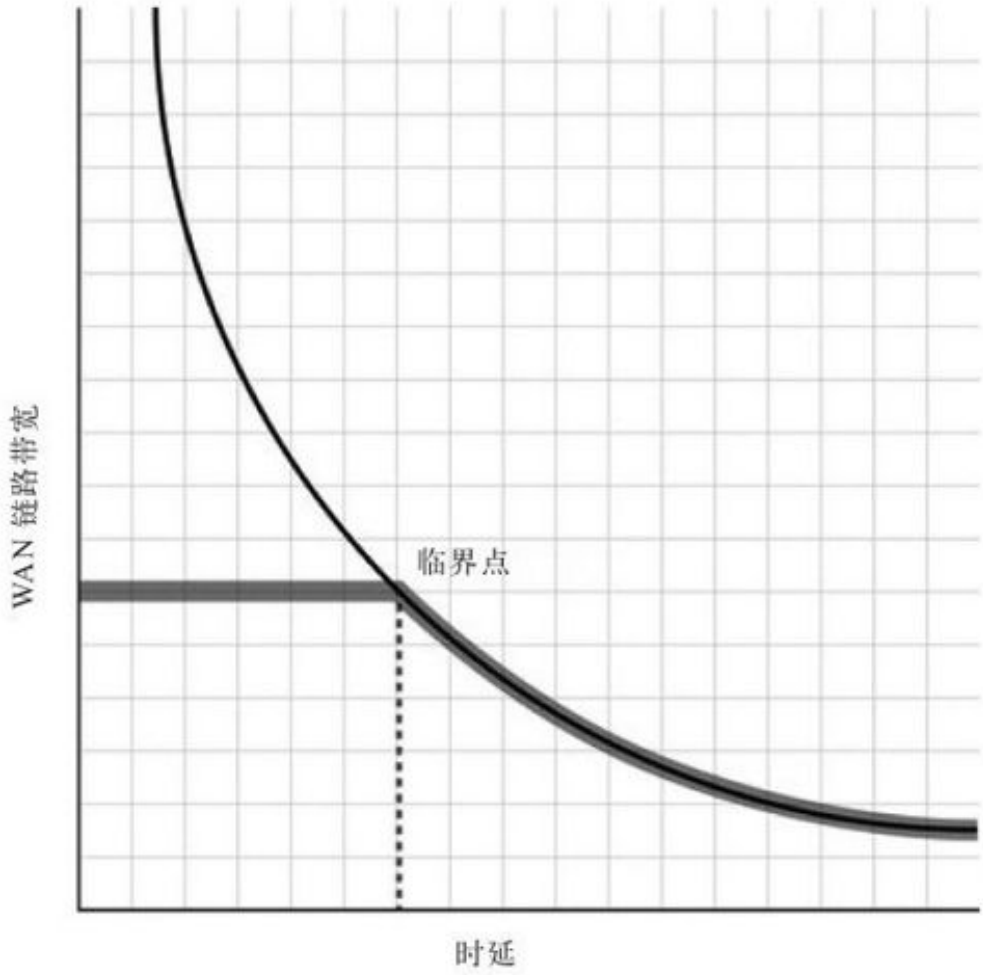


图　4-1　时延增加对连接性能的影响示意

$$T = \frac{B \times RTT}{RTT} = B$$

也即，网络吞吐量等同于可得速率。不幸的是现实并非如此简单。包括TCP和CIFS在内，很多协议其本身就已经确定了窗口大小的上界。比方说，在Windows操作系统中，CIFS规定请求上限为64KB。最早的TCP协议其头部通告窗口的大小为16字节，受限于此，TCP窗口大小上界也同样为64KB，现代TCP堆栈可通过应用RFC 1323标准窗口来突破这个限制，但是由于一些历史遗留原因，仍然有许多TCP产品在连接协商设置时并不支持窗口扩展。而更多的像CIFS这样一类协议，它们除了受到TCP窗口大小限制，还要受应用层的约束。在实际应用中，吞吐量由最大窗口尺寸决定（Maximum Window Size,MWS）：

$$T = \frac{\min(B \times RTT, MWS)}{RTT} \leqslant B$$

更麻烦的是吞吐量还要受其他源自TCP阻塞算法本身的因素限制。当WAN的带宽在千兆级之上时，就无法再忽视这类局限了。这也可能是为什么经常企业在对支干网络进行升级后，却看不到非聊天应用性能有明显的改善的关键原因。

性能有限的根源来自TCP阻塞算法与高时延环境的冲突。当探测到包丢失现象时，TCP将迅速做出反应，显然这将引起过度的安全顾虑（例如，为防止TCP连接过载形成网络阻塞）。为了探测可用带宽，TCP会动态调整传输速率，时不时地使网络偶尔处于丢包状态，然后又主动回退。在高时延环境中，缓慢的响应时间降低了吞吐量，直到最近这些年，研究人员才开始意识到这个问题，90年代晚期，人们找到了模拟由TCP引起的丢包率函数：

$$CWS = \frac{1.2 \times S}{\sqrt{\rho}} \leqslant B$$

此公式说明平均拥塞窗口大小基本可由包的大小（S）与丢包速率（P）确定，由此可得一个TCP上客户-服务器应用的实际吞吐量为：

$$T = \frac{W}{RTT} = \frac{\min(MWS, CWS, B \times RTT)}{RTT}$$

这个公式显示WAN的时延对性能的影响要比LAN的时延更为明显。通常，应用程序等待确认产生的时延会导致系统瓶颈，尽管效率高的应用可以通过调整TCP窗口尺寸来克服瓶颈问题。此外，如果系统中包含高带宽链接，拥塞控制机制也会限制单个链接的速度以填平链路间的速度鸿沟。这三类时延瓶颈将极大影响你的系统性能。图4-2解释了一个WAN上的应用是如何受制于四类主要因素的影响，一旦克服了这些障碍，应用程序的性能就将飞涨，用户效率也会更高。

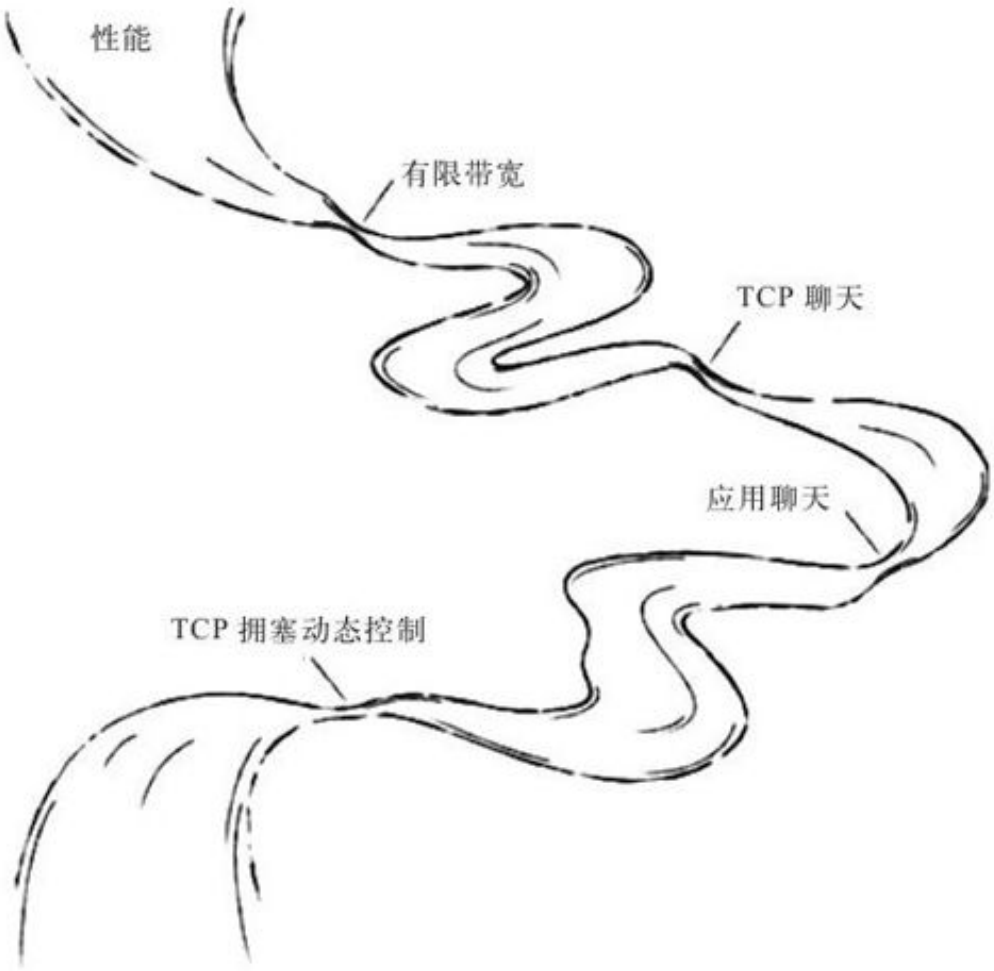


图　4-2　云应用的四个瓶颈

4.1.3 WAN优化解决方案

在2005年左右，Riverbed公司推出了Steelhead产品，它是首款不光克服了带宽局限，同时也能降低延迟，从整体上有效解决四个性能瓶颈的产品，其他厂商也随之提出了各自的解决方案，WAN优化这一应用领域开始为人们所知晓。接下来的章节将讨论这类产品如何克服瓶颈问题，以及应如何在您的网络中部署这些产品以提高应用的性能。向云的转移导致终端用户与服务器间距离更加遥远，但也带来了更多的可用带宽，WAN优化也因此成为不可或缺的必要。

4.2 WAN优化的好处

很难比较得出整合并维护一种新技术与仅仅是“购买更多带宽”这两类方法之间的优劣。为什么WAN优化值得我们费这么大力气？它又将如何克服上述瓶颈问题？本节将面向WAN优化技术以及这些技术如何充分发挥高性能云应用展开探讨。讨论将由问题的根本——节约带宽开始，接着转而探讨如何克服应用层延迟，一旦这个问题得以解决，网络性能将得到极大改善。并且，两者会产生一种叠加效应——减少延迟意味着防止网络发送冗余数据，网络负载也将随之降低。最后一节将分析哪些技术能单独应用于TCP层。

4.2.1 借助压缩和重复数据删除节约带宽

当带宽有限时，WAN优化者将在纯数据发送层使用两种调整技术：无损压缩和重复数据删除。

Lempel Ziv，简称LZ，是最具代表性的无损数据压缩算法，可以将要发送的数据压缩到原来大小的一半或三分之一左右（即客户端发送数据若为100KB，通过压缩，实际在WAN上的传输数据量只为30～50KB）。算法对内存和CPU要求都不高，适合底层实现以及数千并发连接同时工作的环境。LZ算法通常会单独应用在某些设备上，但这些设备主要任务并不是为了优化，例如面向QoS设备或那些希望节约少许字节的存储单元。

重复数据删除技术相对更复杂一些，它要求能够在识别出“从前”已经被发送过的那些数据实例，然后引用这些实例的位置，而不再重新发送原始数据，重复删除可以应用在不同的数据粒度级别。例如，细粒度的重复数据删除也许能够一个字节一个字节去判别两个文件的不同之处，而基于块的重复数据删除算法则只会注意两个块之间的差别。精细粒度重复数据删除可以识别只有几个字节长度的实例，而不用受到诸如块边界这样的限制，能够达到更高的数据压缩比率。WAN优化设备首先应用重复数据删除技术，然后再对处理后的无重复数据流进行压缩。

重复数据删除的一个示例

在各类重复数据删除算法中，最为人们熟悉的莫过Riverbed Steelhead产品提出的可扩展数据简化（Scalable Data

Referencing,SDR）算法，它为我们学习如何实现这一功能提供了一个很详细的案例。尽管试图用不到1章的篇幅完成对全部SDR算法内容的介绍并不可行，不过简单了解一下也有助我们理解重复数据删除与数据压缩之间的差别，以及为什么更复杂的重复数据删除能为整个企业网络带来良好的效果。

认真观察横跨企业WAN的数据流，你将发现其中充斥着大量冗余数据：同一份email被发送给不同的接收者，由于一点点细小的更改而使得文件不断重复备份至远程文件共享设备上，数以百计或成千上万雇员访问同一Web应用等。压缩可以减少一部分网络流量，但是它的应用范围仅局限于单个应用内，当遇到位于多个代理之间应用或者随时间变化的多个应用，压缩就无能为力了。假如能够对重复的数据进行并且以比LZ算法更好的压缩效率实现传输的话，将取得惊人的缩减效果。为了得到最好的性能，算法需识别数据流的细节，而不是仅仅针对消息整体，否则像因重复编辑导致的这类冗余就会被忽视。这样的匹配检索必须是持续的，而非只处理单个包或者是某一个网络连接生命周期内的数据。与此同时，不单只有因协议带来的缩减，还存在跨协议的缩减，例如编辑一个文件然后被Email或者上传至Microsoft SharePoint，再被其他用户下载。

设想一些简单操作产生的包的流动过程，例如，从Microsoft SharePoint下载一个文件，当包沿线缆传输时，从一个用户处下载文件到另一用户过程中产生的冗余能够被探测出来，但是这些探测会受到那些非冗余字节的干扰，比如TCP/IP协议的包头部分。可以将检测限制在仅仅对内容——数据有效负载的检索，而不必考虑头部的噪声（如顺序号）。但是有效负载内部也存在一些令人烦恼的噪声，譬如HTTP协议的包头。为了便于讨论，假设我们举起一只魔杖，使得我们可以只关注那些传输到某一方向的纯数据，而不必去考虑这些应用的头文件，在某种程度上，这就是文件自身，即通过对包的重组，将它们变成我们在服务器上能够直接读到的文件，我们可以想象已经将它存放在缓存中，稍后再进行检查。只是我们的目标是当这些文件被更新并再次发送后，能找到内容变化的部分，因此需要更深入地研究文件的内容。

假设我们能够使用分段算法以某种特定方式将文件分割成小的片段（例如，如果下一次文件内容未发生改变，算法能确保文件分割结果与前次相同），这样就可以检查这些片段并确

定它们之前是否已经传输过。如果片段足够小，那么在编辑过程中就较容易保持不变，并且即便确实有一部分字节流被修改，也很容易回溯回去并匹配到最近一次传输的片段。

有好几种技术可以完成这一任务。其中，比较简单的方法可以通过将文件内容划分成尺寸固定的区域或块，然后把每一块当成一个片段，但是，通常这种方法的压缩效率很低，因为一个很小的改变可能会产生级联效应。例如，在一个拥有1000个块的数据流第2位中插入一个字母，所有1000个数据块的内容都将发生因此改变，这意味着因为一个字符的变化，所有1000个块都将重传！

更好的解决方法是构建可视数据窗口，窗口大小可按需调整，由当前窗口内容变化情况确定判别函数的结果。如果数据没有发生变化，则函数值保持不变，即相同的数据片段会产生相同的“cut point”。如果数据发生了更新，就会影响到1个或更多数据片段，但当接下来没更新过的数据经过数据窗口时，系统会按照同样方法继续进行分段判断。基于窗口的类SDR方法中，窗口尺寸是不固定的，这使得在处理插入、删除及更新操作时，可以更加灵活地处理片段。

如何完成某个给定数据片段的重复删除呢？我们可以采用序号或标签方法对片段进行标注。尽管标注本身需要占用一定空间，但与存储数据片段相比，这些空间就变得微不足道了（例如，一个16字节的标签可以标注128个字节）。当判断两个数据片段相同时，为节约空间，系统只传输片段的标签。那么，片段和标签采用多少位存储合适呢？对于数据片段，有一个固有的平衡问题需要考虑。采用大尺寸数据片段，会得到很好的压缩效果，比如，假设用16字节标签来标注8000字节的数据片段，那么只传输片段标签的方法所能获得的压缩比则为512:1！但相应地，随着数据片段的规模不断增加，片段内数据更新的可能性也将不断增加，导致片段间匹配成功的概率将直线下降。如果片段尺寸足够小，数据片段匹配成功的概率会非常高，只是这种方法又会大大降低压缩比率。同时，我们还需考虑用来标签片段的标签范围应足够大，以免WAN优化器会发生溢出问题，所以标签算法应确保任何时候都能生成新标签，且不会与之前标签产生重复冲突。另外，也必须保证数据片段与标签间1：1的映射方式，在删除重复数据时不会影响正在传

输的数据，这样当标签全局唯一时，数据片段匹配判断也不再是个难题了。

那么该怎么办才能解决尺寸选择的困惑呢？数据片段的尺寸最好是既能足够小同时也能足够大，显然这是不可能的。可以从调整位置信息来提出解决方案。设想某个文件有两个内容看似相差甚远的版本，但只要有部分内容相同，这些数据片段的顺序一定是相同的。因此我们可以借助这样的位置信息，将小尺寸数据片段不断组合形成大尺寸数据片段，增大有效数据片段的规模。通过不断重复编码游戏就可以完成这一任务，首先取出数据片段的标签序列，将标签序列放入新的数据片段中，如果片段已经存在，就用标签代替它，否则为新片段生产一个新的标签并替代片段。当反复几次编码操作后，大量的原始数据将被一个简单的标签代替，即便原始数据片段非常小，也能得到一样的处理结果。

图4-3展示了一个十分简化的可扩展数据引用的样例，Alyssa发送的信息被分割成7个基本数据片段归至3档不同的数据片段层，分好层的数据片段被发送给文件服务器，Alyssa重新编辑该文件，原来的片段8和片段4可以被重用，系统会将它们重新打包成一个新的片段，Alyssa最后定稿时将产生一些新的数据片段。而对消息接收这方的Ben而言，他看见的是一个完整的只采用了一个标签标注的数据片段。

使用SDR机制后，原始数据将被转换成一组对原始数据的引用以及新的标签定义（如果传送内容是底层的原始数据，标准压缩LZ可以更进一步地缩减传输数据的规模）。为了保持数据压缩级别足够高，必须获得数据片段的相关信息，为此标签和片段之间的映射关系要在硬盘上保存。当系统发现已经被处理过的数据再次出现时，就可以通过引用删去重复。类似的，当数据被发送或返回时，其他Riverbed Steelhead设备也可以使用同样的标签来发现这些数据，从而节省了定义的空间。如果能在整个系统范围内，包括相同用户间不同的连接之间，不同的协议之间，不同的站点之间，以及不同时间段连接，都应用SDR机制，则可以获得重复数据删除的最佳效果。

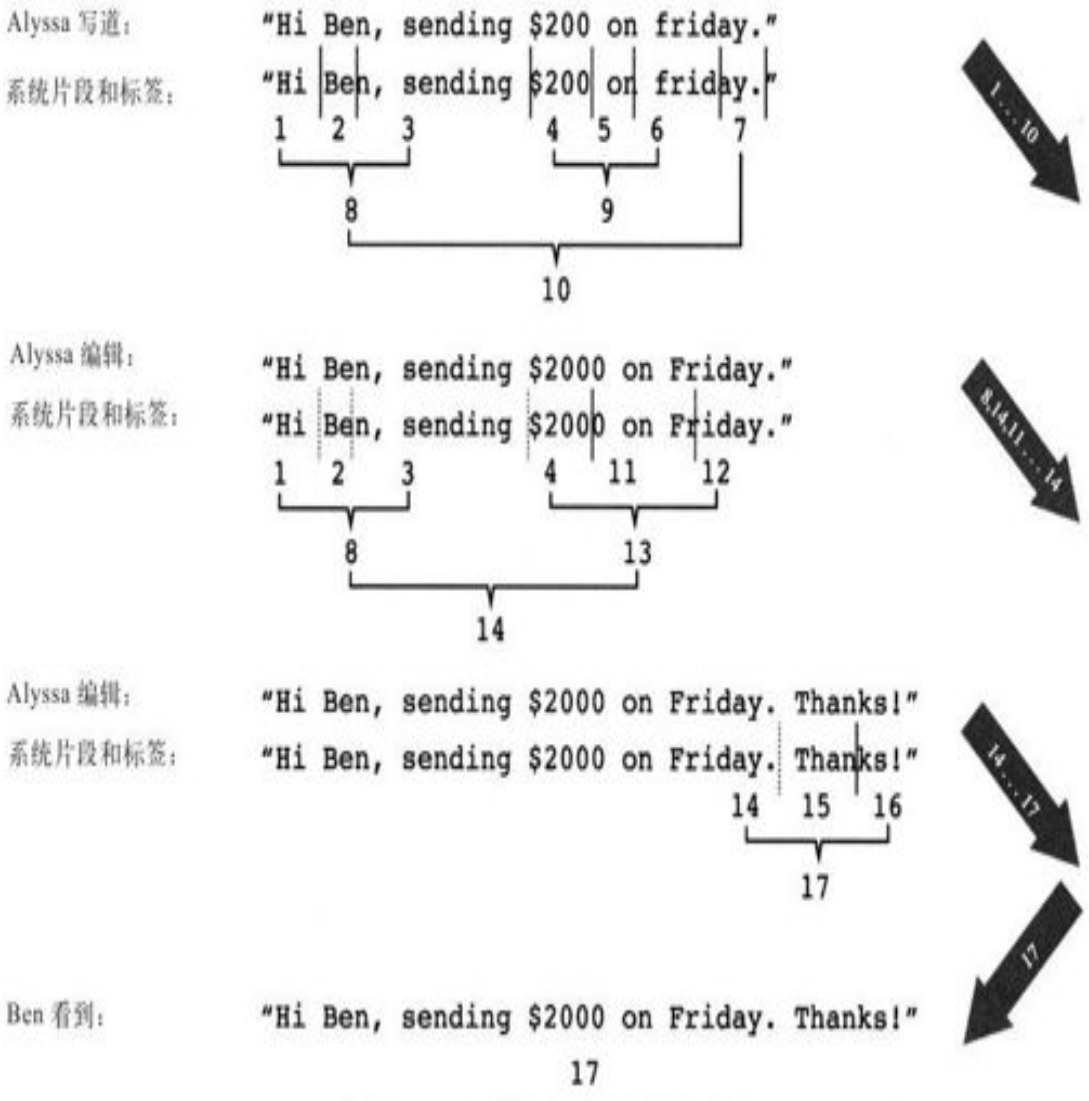


图　4-3　可扩展数据简化的简单示例

以上举措将对整个网络带来怎样的影响呢？最关键一点，重复的数据将不会再和原始数据混在一起，从而带来一些数据保护方面的优势，当然还有数据压缩方面的好处，但是这样也会影响到系统架构。例如，在已经消除重复的数据流之上不建议运行病毒检测或侵入探测程序，因为它们无法发现匹配的模式。同样，在处理后的无重复数据流之上使用Cisco基于网络的应用程序识别（Network Based Application Recognition,NBAR）实施深度包检测（deep packet inspection,DPI）对数据流分类也是没什么意义的。这些变化也适用于网络管理系统中监测及流量记录设备。其他像这样的附加设备，必须部署在能够探测到原始数据的网络环境中，因此要么将它们部署在网络优化范围之外，要么必须在WAN优化器中考虑集成设备的功能。

4.2.2 应用层加速

带宽缩减去掉了网络传输中每一个重复的字节，但仍然存在另外一个性能瓶颈，因光的传输速度所导致的一个内在时延，WAN优化器也必须能够应对这一类性能挑战。许多客户-服务器模式的应用程序和协议是为本地局域网设计的，这类环境中的时延往往较低，对性能影响并不明显，应用程序和协议因此并未专门针对高时延环境进行优化。往返应答模式在LAN环境中耗费的时间及性能代价并不高，因此早期开发人员并未考虑到当有效往返应答增多时将对吞吐量和应用程序性能带来怎样影响。当用户与服务器相距遥远时，聊天类的通信协议性能将产生非常严重的下滑。

在WAN环境中，依据每次连接的距离远近、跳转次数以及在路径中遇到的处理延时不同，单次往返应答需要大约30毫秒至1秒的时间完成，这样的时延是普通LAN环境中时延的千倍，将对文件系统或诸如CIFS、MAPI和NFS等协议性能带来极大破坏，导致这些服务变得非常缓慢甚至在某些情况下根本无法访问。为了解决这一网络性能难题，WAN优化器奇迹般地改变了协议的请求，优化了WAN延迟对性能的影响，为应用程序提供加速服务。

缓存策略

在端点或网络中间设备上实施缓存策略是最初用来缩减带宽以及加速应用程序策略之一。缓存机制能够识别对象及它们的元数据，并可以依据元数据判断出这些对象之前是否已经传输过，而不必再发出申请。HTTP是缓存机制应用最成功的案例，访问单个页面的一个简单HTTP请求比较合适拿来当做样例以说明此问题。HTTP协议将页面和一个HTTP头信息一起发送，在头包里可以存放如代码清单4.1所示的一些有关当前页面对象生命周期信息，用来告知缓存当前对象何时曾被修改，也可以存放显示的缓存指向位置信息，如代码清单4.2所示。服务器可以要求客户端不要缓存对象，当像PNG、JPEG、HTML页面等类型的对象被再次请求时，本地缓存检查核实对象存在合法副本后（要求副本未超过生命周期规定时间，且允许缓存），则可以应用缓存。

代码清单4.1　HTTP头包片段示例

```
Last-Modified: Sun, 27 Jul 2008 03:15:27 GMT
```

代码清单4.2　HTTP头包中缓存指向信息

```
Expires: Thu, 19 Nov 1981 08:52:00 GMT
Cache-Control: no-store, no-cache, must-revalidate, post-check=0, pre-check=0
Pragma: no-cache
```

要注意的是，这两组代码是2011年3月下载的，由此可以发现将缓存作为解决方案的一个风险：这个页面自2008年就再未更新过，而且头包是显示与缓存绑定的（缓存控制），这意味着此页面早就过期了。尽管这样，基本上每一个Web服务器都会采用缓存机制来帮助提高性能。

HTTP协议外的缓存机制又是怎样的呢？这些方法很难实现也很难有效使用。HTTP的优势在于它本身就是为远距离通信设计的，对缓存控制、过期时间等信息都有明确说明。而大多数非HTTP协议，比如文件系统是获取不到这样的信息的。比方说，当一个CIFS服务器通过Windows文件共享机制传输一个文件时，该怎么设置过期时间呢？有些文件从来未更新过，有些大概一年更新一次，而有的可能短短几个小时内就会发生多次更新。为了缓存某个文件，缓存控制机制要么假设某种场景，要么就要检查每一个访问。即便是有显示的元数据检查，还是得不到明确的结果，因为一般文件服务器只会提供时间戳和文件大小这些信息。这样的信息用来明确是用户还是程序访问过当前文件已经足够了（比如两个用户同时改变了文件内容但没影响文件大小这类行为的可能性有多大，而多个访问同一文件的程序，都由同样的外部事件触发，可能它们时间戳都相同，也不会改变文件的长度）。而且，很自然地，管理员通常会对缓存环境能提供的一致性有多可靠心存疑问，相当一部分数量的管理员更倾向得到一个响应慢一点但精确而非响应非常快但也可能并不正确的文件版本。下节将讨论一种能够得到响应快结果也精确的新型优化器。

缓存体系还面临另一个挑战，就是缓存到底是否需要为所有对象服务。这是个看起来并不起眼的小问题，但对工程实现却有着巨大的影响。举一个最简单的例子，可以要求用户使用本地缓存而非直接使用文件服务的缓存，不但要考虑许多配置

选项（包括像如何在每一个办公点完成配置，如何服务移动办公的用户，或者那些希望直接使用文件服务器缓存的用户，以及缓存出错时该怎么处理等），工程实现也面临更大的挑战。当把缓存控制器当成一个具备控制权威的服务器使用时，就必须百分百实现协议的所有部分，而如果是一个无须承担服务器角色的设备而言，则可以不用考虑很多没有太多价值的协议规则，这样能够极大简化实现（包括维护）的工作量。尽管这种差别看起来并不明显，但如果考虑到网络上所有可用协议，还是极有价值的。每一个想提速的协议，为了执行正确，基本上都应在缓存中实现所有的服务（更新产生时也是一样）。而某些类似服务的参数也必须为每一个缓存环境单独配置（例如Squid缓存服务有多至350个配置参数），这些对管理员都是操作时需要考虑的问题，在网络部门和服务器部门进行机构边界划分时会变得更为复杂。

端点用户之间可以通过多协议连接也暴露了缓存机制的另一效率问题。使用缓存避免重复的数据发送因而能够节约带宽，前提是能够识别对象元数据。假设用户通过email接收了文件，在windows文件共享环境中进行编辑和保存，并上传至Microsoft SharePoint的服务器——这意味着需要调用三级缓存（email、CIFS以及HTTP）。由于每一级缓存都是在对象级别单独地完成重复判别，因此三级缓存意味着对象要分别在每级缓存中被存储一次，共要存储三次。另外，如果缓存机制支持跨协议带宽缩减，这意味着系统将在所有缓存层之上再多存储一次对象，也就是一共存储四次，这种低效操作将给缓存设备的说明带来极大负担。

应用加速

毫无疑问，WAN控制器还有比缓存更好的办法来克服应用延迟。应用加速这类技术可以提前预测客户及服务的行为，当实际行为发生时，只需去掉预定义中不需要的操作，直接执行预定义好的事务。由于操作已经预先定义好，一旦客户端启动这些操作，马上就可以从本地得到操作的返回结果，从而避免了在WAN因为往返应答而产生的延迟。为了实现加速，WAN优化器必须充分深入理解协议才能明确哪些元素能被安全地修改。因为服务总是数据的权威来源，所以不同于缓存控制器，WAN优化器不需要实现协议的所有要求。为了更有效率，应用加速必须加载在像SDR这样具备高效重复数据删除和数据压缩

能力的平台之上，这样的平台将要负责大部分有效的数据传输，而不是仅仅依靠对缓存后的数据局部传输。

这种机制与之前讨论的传统缓存机制有着截然不同的功能，尽管在一个有着良好设计的应用加速系统，有时也可以看到缓存的影子。简单的缓存机制要求在本地存储大量的对象副本（如文件、文件块、HTTP对象、email消息等），然后通过安全协议、封锁策略等措施，保证多个客户端能访问和修改这些副本，且能与原始数据保持一致，使得整个系统结构变得复杂难以维护。在应用加速环境中，有时也可以结合缓存机制，例如一个完全封锁的文件，当用户正在使用当前文件时，如果WAN优化设备检索到这样的阻塞，就不需要再去服务器获取更新消息。

在多协议环境中实施应用加速，必须要求对每一个协议都编写说明代码，这个任务可以通过改变体系架构而被适当简化，例如将一些模糊不清的协议元素放到服务端处理，整个系统只存储一个公用数据副，在设备中则不用再存储多个数据副本。这种只存储一个统一的数据副本的方式，不但可以达到和原来一样甚至更好的协议加速及数据缩减，也简化了跨协议带宽的实现，同时还能降低对存储空间和RAM的占用。要知道WAN优化所面临的基本挑战之一就是能够支持更广范围的协议，以尽可能满足企业需要用到的所有协议。

说明：应用层的改变将可能获得非常棒的优化效果，使得云集中管理变为可能。设想一个MAPI（（Microsoft Exchange/Outlook协议）的场景，用户向它们的本地邻居发送接收Email，操作延时很小，但如果服务器移植集中到云平台，使用100毫秒RTT T1链路（1.5Mbps），一封发到邻居桌面的邮件就需耗时2分钟（假设附件大小为6.3M）。借助应用程序加速（数据有64%的压缩），耗时缩短至40秒左右，如果需要再次转发（比如，发给另外一个用户），SDR保证只需6秒钟就能完成（速度提高了近23倍）。

另一个挑战是如何处理通用型协议，像FTP或MAPI这样一些协议是与某些特定应用程序绑定的，而像CIFS和HTTP这类协议是为应用程序搭建了一个平台，应用加速设备如果只盯着HTTP协议本身，则对其上应用不会有任何改进。必须从跟不上了解应用是如何使用HTTP——特定的优化可能会极大提高某种

应用，而对另外的应用产生不良影响，比方说，如果能够研究Microsoft Office应用是怎么使用CIFS，那么就可能比使用一个通用的CIFS模块，对网络流量优化效果更好。因此，仅关注你的云平台所支持的协议的范围是不够的，还必须深入了解这其中的某些核心协议。

提前读应用加速案例

顺序读文件是一个简单但可以充分说明应用加速工作方式的案例。设想某一个应用需从文件中读取数据，进行计算后再写回文件尾部，使用广域文件协议，简化后的操作在某种程度上可以表示成如下几个步骤：

1.验证用户拥有访问文件的权限

2.封锁文件

3.读文件尺寸

4.打开文件

5.更新读时间属性

6.读数据库0

7.读数据库1

8.……

1000.读到文件尾部

1001.写数据块

1002.关闭文件

上述操作展示了两种不同的优化选择。图4-4展示了当一个文件被封锁时，服务器这端的网络在返回锁状态时，还能够同时检查文件的大小并返回。这是一种探测性的预报，检查文件尺寸没什么危害，而且还可以避免一次往返请求，就像这个案例一样。另外一个优化的时机是在打开和更新文件序列时，在这个协议中，有可能这些操作彼此都是关联的，如果这个协议在设计时比实现更注重普遍性，这样的情况是有可能发生的。WAN优化器知道这些操作总是一个接一个进行，因此能提前一次性完成。

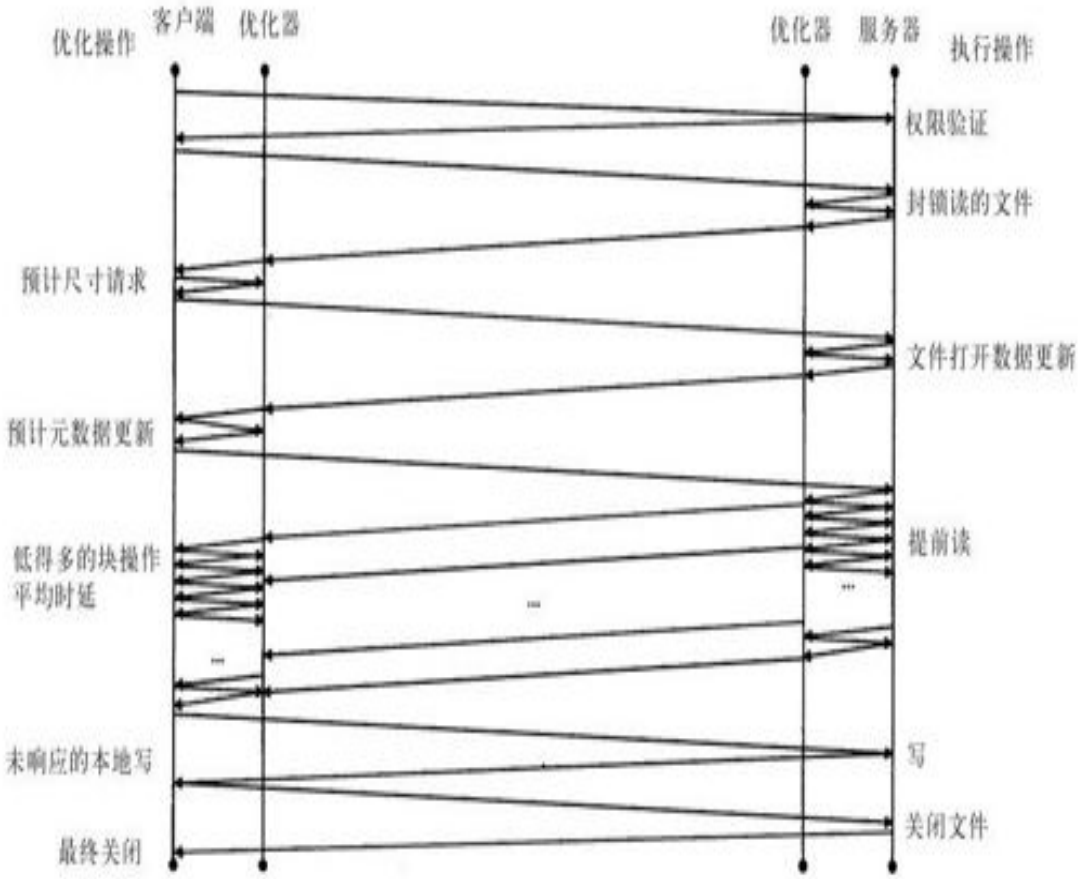


图　4-4　优化的文件读操作顺序图

最重要的环节是序列读操作优化，文件的读操作是同步顺序执行，如WAN连接中的高时延一节所介绍，这些相互依赖的序列请求会因窗口尺寸产生时延，并且当时延增大时将对系统性能带来潜在危害。如果对锁的权限进行监测，WAN优化器可以得知客户端对文件是排他占用，但在客户端操作开始前对文件读取是不受限的（因为没有其他客户端可以更改文件）。网络服务器这端的WAN优化器将一次性读取多个数据块，并一次性发送给客户端。如果窗口尺寸大到足以弥补WAN时延，那么操作性能将重新回到LAN级别。在极端情况下，一旦上锁，WAN优化器将可能读取整个文件内容，并通过网络发送给客户端，使得网络这头的客户端能够利用文件印象满足所有本地读操作的访问。

图4-4解释了上例中应用加速后事务序列，对客户端和服务器而言，看见的只是普通的WAN之上的操作序列，实际上这些操作都是预先交叉发送的，这种方法降低了用户实际等待时间。

应用加速后对结构的影响

为了启动加速技术，WAN优化器需要在WAN协议层改变传输内容，这样才能使客户端和服务端的WAN优化器就优化后的协议进行沟通，这类沟通有时称为协议翻译。理解了应用层的协议后，WAN优化器可以把数据和包头分开，如重复数据删除一节所述一样，和消除重复类似，经过优化后的网络流会发生一定变化，导致协议翻译设备将没法按正常情况进行翻译，例如，负责探测连接的防火墙软件会将优化后的HTTP协议作为非法HTTP流。例外，这样的紧密联系也会对操作产生限制。比方说，软件的版本信息需要保存在优化后的光纤或类似级别信息中，以确保更改后的协议能被正确理解。

4.2.3 TCP加速

尽管有海量的企业应用协议在使用TCP，但某些协议确实不具备聊天功能，或者不是通过聊天机制实现大批量数据传输，如果是这样，那么TCP层的协议颠簸就会因WAN环境变得更加明显。众所周知，由于TCP使用窗口算法来判断一次可以安全传输的数据大小，所以为了公平，也为了能够满足Internet上大量不同吞吐量和不同的硬件实现，TCP协议需要避免拥塞，因此当时延增加时，这样的颠簸会导致性能成指数下降。WAN优化器可以采用多种方式解决这一问题。

说明：本章焦点为基于TCP的协议以及使用这些协议的应用程序，因为大量的企业网络和基本上所有终端用户的应用程序，包括文件共享、email、FTP、远程桌面以及Web，都是基于TCP实现的。非TCP协议在企业网络中应用比较多的只有VOIP和网络流媒体直播传输这两种，其中，VOIP协议由于协议本身特性可以实现压缩处理，也不支持重复数据删除机制，唯一能优化的对象就是协议的包头部分，该协议底层为UDP，不会遇到本章所讨论的那些TCP协议会遇到的性能瓶颈，至少没有颠簸。流媒体直播与VOIP在许多方面都比较相似，唯一不同点在于流媒体直播通常会消耗大量网络带宽，甚至有可能要占用整条链路。可以使用一些处理视频的方法，比如将流划分给LAN内的多用户，达到类似重复数据删除的效果，对预先录制好的视频也可以采用本章介绍的重复数据删除（比如多个用户观看同一视频的情况）方法。

一般的复杂网络中都会存在多操作系统、多版本以及多型号设备问题，因此在设备之间，比如一台性能优化后的NAS服务器与一个已经工作了10年底工作组，存在极大性能差异，更不用提在过去十几年里，客户端设备的内存和CPU性能所发生的变化，均使得在不同的Microsoft Windows系统（或其他系统）上设备实施配置都不同。许多基于老版本TCP协议开发的设备，不支持新协议中减轻拥塞的功能，而WAN优化器因为是在广域范围的私有云服务之上工作，所以可以不受上述这些问题的影响。



图　4-5　WAN优化将一个端到端连接实际分成了三部分

WAN优化器将原来的TCP连接切割成3部分，使得这些新的WAN连接在各自范围内都能支持现代TCP操作。图4-5解释了WAN优化如何将客户端机器与云平台上的应用之间连接分割成3部分，使得WAN优化器调优后更具有有针对性，连接的WAN分支部分也可以节约更多的带宽并降低有效时延。我们没有必要在这详细探讨RFC的效率，总的一句话，不需要使用特殊的优化方法，就能依靠自身局部优化而显著提高整个广域范围网络性能。

TCP连接分割不但支持了现代TCP技术升级，TCP连接分割结合WAN连接上的数据缩减，也为网络提速带来了令人惊讶的可能。滑窗机制支持一次发送多个数据包，但发送的数据量不能超过当前窗口大小，除非收到接收端的确认消息，当时延增加时，窗口就不能及时滑动，所以发送方在一次往返应答中只能最多发送一个窗口大小的数据。因而，当WAN优化器对TCP连接实施分割后，在不同的连接上就可以产生很多新的有效窗口，LAN这端的连接就可以高速完成，持续支持WAN这端的数据发送，虽然WAN这端的连接仍然受限于窗口，但别忘记此时数据已经是经过压缩处理的，因此理论上系统吞吐量将更高（例如，一个有4倍压缩能力的64KB的WAN窗口，代表了来自客户和服务器端原始数据量为256KB，这种情况下，连接速度将是原来的4倍）。

说明：让我们简单了解一下采用TCP加速的客户端用户案例。一个制造企业希望将所有工业设计移植到云平台上，工作流非常简单：早上上班时，工程师通过FTP将任务从云端下载到本地工作站（封锁在PLM系统中），在本地开始工作，然后

在下午下班前再将结果上传（并解锁），但是存在性能问题。即便是物理位置最靠近云中心的办公室，用FTP传输一个200M左右的文件，需要5～25分钟时间，就算这行得通，但如果办公室在印度，就不行了（仅一个工程师需要3.5小时传输时间，还没考虑网络拥塞）。使用了Riverbed Steelhead设备后，在E1（2M）链路上，印度这边的客户端只需5分钟就可以完成传输（数据缩减了87%），而对本地用户，感觉不到1分钟就搞定了。这都是因为采用了重复数据删除或单独的TCP应用加速技术，因为FTP这一层时延并不明显。

最后，TCP连接通常不能满足在高速带宽链路上传输大量数据的需求，TCP性能受限的根本原因在于Van Jacobson最早提出的避免网络拥塞的算法与高带宽延时网络（这种网络有时被称为长肥网络或LFN）相互影响。因为每一次成功的往返应答只能处理一个包，所以拥塞避免机制增大了TCP的窗口规模，当窗口比较小时，增大单个包的尺寸是合理的，但是当窗口尺寸太大时（比如几百个包），每次附加往返应答都会对窗口尺寸有微弱的影响。当这样的累加达到一定次数时，若发生包丢失，要重新发送一个包所需的往返时延就变得非常庞大——导致TCP应答非常迟缓。例如，要维持一个吞吐量为1Gbps，延时为100毫秒的WAN网络能力，发送端TCP窗口大约应为8000个包，对半开的窗口尺寸为4000个包，所以在发送和接收端需要4000次成功的往返应答才能完成8000个包的传输，而每次100毫秒的延时，还要累加！

同样，WAN优化器提供了一个理想的平台来解决这个问题，即支持一种广域范围链路的“高速”模式将缓和或消除这个难题，此类方法特别适合需要往数据中心传输大量数据，或数据中心之间大量数据互相复制的情况，具体实现包括Riverbed Steelhead设备支持的高速TCP（RFC 36497/3742）、Citrix’s Branch Repeater VPX提出的硬启动或者是Cisco WAAS上的传输流优化（Transport Flow Optimization,TFO）。

QoS为TCP加速

只支持服务质量（Quality-of-Service,QoS）或者同时支持LZ压缩的QoS设备经常会被当成WAN优化设备，但是这种做法已经过时了，因为它们无法实现对应用层或LFN网络优化，这些设备只能够满足极小部分企业网络环境需求：中等带宽时延

链路，不需要使用聊天协议，拥塞也不明显。实际上，QoS自身并不具备优化功能，它只是简单地赋给队列前部的包较高的优先级而已，这种处理相应就会降低其他协议速度。QoS更适合被看成一个自身需要WAN优化的设备，我们将在4.3.4节中讨论这一问题。

4.3 WAN优化实施的要求

尽管大多数WAN网络通过WAN优化，性能都有明确和显著改善，但要实施WAN优化却并不像描述中的“即插即用”那样简单。为了要正确构建一个优化网络，你必须了解将优化设备添加到网络中需要满足哪些条件。每个厂商的要求都不同，但在对潜在局限和带来的利益方面大都相差无几（例如，任何优化方案都必须能观测到传输，它们都对网络传输产生一些影响等）。

本节我们将探讨那些与网络设计有关的最重要和普遍需要关注的问题。首先，我们将研究WAN优化器是如何拦截或抓取流量，以便能够对它们进行优化；接下来，WAN优化器需要确定网络另外一端哪个优化器连接；第三部分探讨优化后的网络传输在网络层看起来有什么差别，并通过网络可视化技术对它们进行观测；最后，我们要研究WAN传输过程中其他服务优化的实现。

4.3.1 流量拦截

为了从根本上改善TCP性能，必须改变那些链路中传输的包，因此有必要探讨一个设备该怎么插入到网络中某个位置以完成这样的优化。WAN优化器可以采用很多方法完成流量拦截，图4-6介绍了4类不同的WAN优化器部署方案：物理安置在通向服务器的路径中是最简单的也常用的方法。而借助基于策略的路由（Policy Based Routing,PBR）或者是WCCP协议，也可以只是实现逻辑上的路径连接，一个虚拟化设备可以在逻辑上访问路径，而且还可以引入其他虚拟机制或机关实现流量拦截。某些时候，这样的设备可以按代理服务器方法配置，拥有一个公开的地址。如果不需要使用实际的物理设备，譬如，基于软件的优化，就不需要完成这样的网络集成，但是仍然要考虑一些重要的配置问题。在下面的章节中，我们将介绍这些配置方案，而有关方案的实际部署将分别在第5章和第6章中讨论。

通常情况下，管理员希望能找到大量用户流量连接到WAN上的一个汇聚点，一般来说，它们通常位于本地网络与路由接口之间（例如，在WAN的汇聚层和核心层之间），这种配置被称为物理路径或inline模式。设备通常支持成对的接口，一个

LAN端和一个WAN端，数据接收后，要么进行处理要么转发，这些接口组通常位于具有自动旁路能力的硬件设备上，如果设备发生崩溃，仍然能够维持基本连接。使用设备简化了安装，因而路径模式适合大多数部署方案。

逻辑路径部署将包从普通路径重定向转发至WAN优化设备，这类重定向机制（如WCCPv2、PBR负载平和等）通过配置命令能改变网络拓扑，但也增加了目标机构的维护负担。此外，由于并不是所有软件都支持WCCP或者能够发出危险警告，因此重定向机制要求管理员要谨慎确定网络中路由和交换器上哪个软件具备这一功能。这类部署方案的细节将在第5章深入讨论。

第三类部署方法是在客户端运行优化软件（图4-6没有对此进行标注）。通常，软件都是运行在网络客户端，WAN优化器则运行在服务器端，这样的部署方法非常适合移动办公用户——他们可以把优化器带着随身跑。不过也可以在核心层服务器这端引入软件，流量拦截经常要利用同级别操作系统，与VPN软件发生关系（如果没有VPN，别尝试优化加密后的数据）。这类软件优化方案不利之处在于：必须要在多台客户机上安装并维护，降低了跨用户的效率，也降低了端点用户的可用CPU/内存/磁盘的性能。

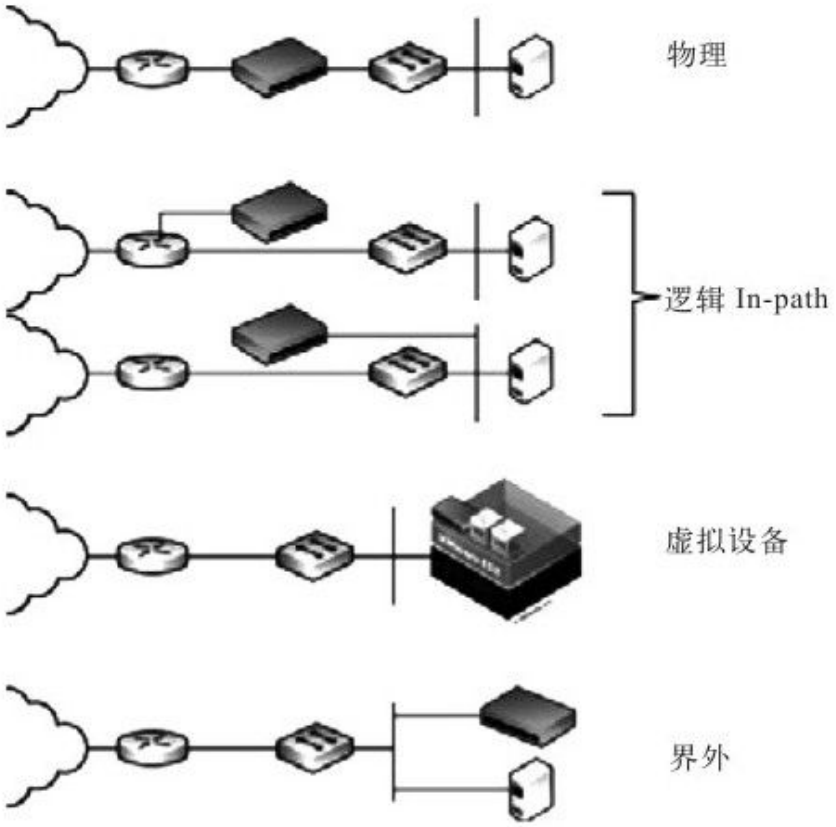


图　4-6　一些简单的WAN部署方案

一类逐渐增多的部署方案是以虚拟装置为中心，这类方案的架构中更多利用虚拟设备，“装置”这一说法看起来有点过时，应该用虚拟版本更合适些。这种情况在公有云这样由供应商为服务提供基础设施的环境中更常见。到目前为止，无论是功能还是属性，虚拟优化设备与它们的硬件装置结合得都非常紧密，而虚拟装置则为升级增加了更多的灵活性，能够采用分裂终端模式，利用功能更强大的基础硬件。大多数虚拟优化服务采用逻辑路径模式的集成技术，但如果控制不了路由基础设施就不能用这个方法。某些厂商将优化器分割成路径拦截VM和优化VM两部分，与此同时，为了实现集成，需要采用分裂终端方法来引入一小部分服务器端软件模块，将拦截到的包发给服务器。当把优化部分单独划分给另外一个VM（比如Riverbed云Steelhead产品），虚拟WAN优化部署将在第6章进一步探讨。

最后，某些WAN优化器（或虚拟设施）会部署在路径之外。在这种模式中，WAN优化器必须能被其他软件直接引用。最典型的路径外部署案例是客户端代理配置，这时web浏览器（或其他应用）利用配置的机会访问网络中其他节点而非服务

器。另一种形式是在客户端使用普通方式拦截，但用客户端WAN优化器的配置信息，实现与服务器端的WAN优化器进行定位和通信。这种与服务器进行通信的设施有点类似代理（例如，使用自己的IP地址而非一个透明的地址，详细的讨论请参见4.3.3节的“LAN传输”的相关内容）。

4.3.2 确定优化的合作者

现在已经完成了流量拦截，WAN将如何处理这些信息呢？假设只有一部分远程站点需要优化？数据中心该怎么保证下一步传输能正确完成呢？隧道和自我发现是两类不同的解决方案。

隧道差不多能完成所有用户希望的任务：本地配置确定好远程子网络或服务后，还负责指定应该使用哪条隧道完成传输，配置可以预先定义好，也可以人工调整，或者由一个集中式管理员通过监控再临时确定。隧道方法的缺点在于它有可能极大干扰WAN传输与广域范围的QoS或报告的集成，当增加或删除客户端与子网时，都需要更多网络管理。

为了实现自动发现优化时机，研究人员开发了自发现机制。利用TCP可以携带一组可选位数据的能力，自发现在申请连接时，增加了一组TCP优化定义操作。如果包直接访问服务器，服务器将忽略未知的操作，但是在路径中的优化设备能够识别这些操作并建立起端到端的优化连接。这使得系统可以直接忽略掉那些没有优化能力的站点，而大多数远程WAN则可以发现具备优化能力的站点。自发现机制不用处理隧道机制遇到的那些维护问题，但是安装自发现软件需要改变防火墙软件的配置，以允许执行这些操作。在某些极端情况下，例如TCP操作域没有更多空间来存放额外指令时，就不能采用自发现方法。

4.3.3 优化好的数据流像什么

在探讨WAN优化工作方式时我们已经隐含提到，经过优化处理后的数据流与原始数据流有一定差别，数据本身内容是肯定有差异的，但是包头又会发生什么变化呢？如4.3.2节中介绍的一样，一些优化器会使用隧道机制，而另外一些优化器会保留TCP连接以便它们能够匹配上预先定义好的包头。隧道可以实现在一条隧道中单点连接多个混合流操作，相反，TCP代理体系为每一个LAN连接维持一个基于WAN的TCP连接。当涉及加密以及在网络中实现包寻址操作也叫网络可视化等操作时，每种方法都有自己的优点，也有各自的不足。我们将对这些内容进行简单说明，探讨各种WAN优化器可以采用的寻址规则。要注意：许多WAN优化器支持多种可视化模式以及不同的终端，因此这是一个会让人产生困惑的领域。我们将在下节研究网络可视化操作问题，图4-7给出了一个简单的引导说明。前三种技术针对的是流行的TCP代理体系，紧跟着的是隧道机制。LAN传输在大多数环境中都不会发生变化，但是我们也会讨论某些例外。最后讨论软件究竟是安装在客户端还是安装在虚拟服务器环境中，这个问题没有统一答案，每种方法都有不同的取舍要考虑，我们将介绍虚拟模式，并简单探讨一下此方案的利弊。

网络透明寻址

某些网络可视化技术是为了保证包头不发生变化，也就是俗称的“透明”，在这种模式中，四部分（IP源地址、源端口、IP目标地址、目标端口）能够匹配上原始连接，此方法的最大优势在于它保留了WAN优化端拦截或控制设备的相似性。例如，在连接透明时，路由器的QoS实现不需要修改就可以使用IP地址和端口来区分不同的传输，类似地广播标准比如顶层会话或跟踪各部门退单，也不需要更改。这种模式最大的危险为包头有可能携带错误信息，IP网络的根本目的是根据包的不同地址将它们发往各自目的地，如果假设优化后的内容对终端主机毫无意义，透明发布就不应该支持这样的传输。通常终端连接的一致性是通过序列编号验证维护的，它有点像守门员。任何错误譬如未识别的异步路由，将导致终端用户会话被错误重置，维护人员却很难跟踪用户的这个抱怨而产生。在大多数情

况下，WAN能够意识并报告异步操作，但是这种部署方法就像一把锐利的刀——有用但存在潜在风险。

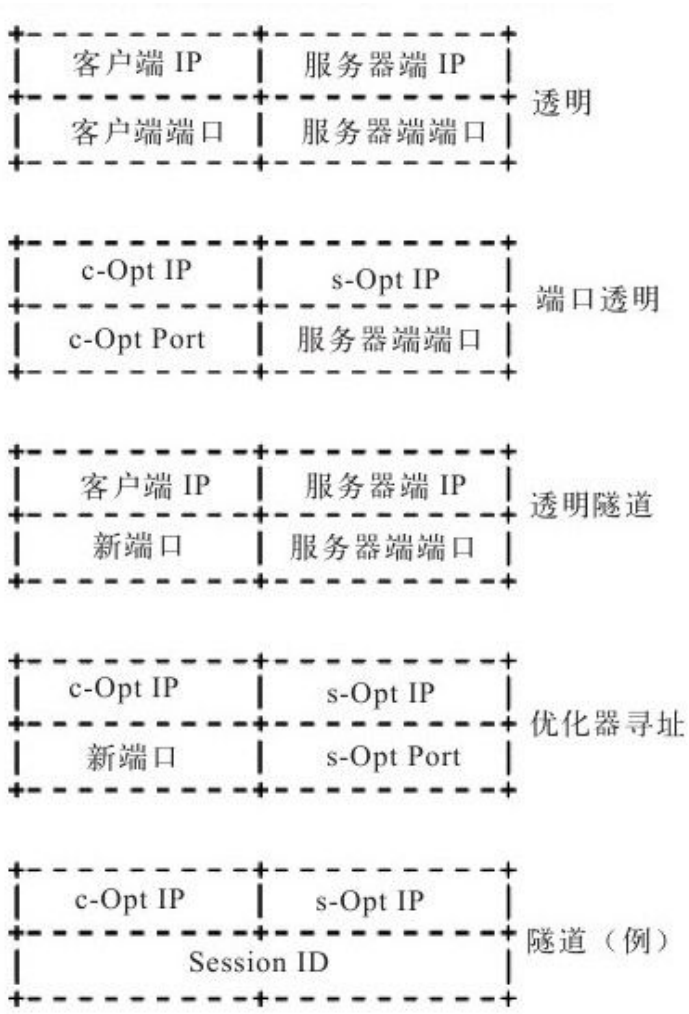


图　4-7　不同网络可视模式的包结构

端口透明和透明隧道

由于透明模式的风险，一些厂商开发了半透明模式产品，以保存部分四重端点的优势，但又不完全一样。

首先要完成IP地址与WAN优化器的匹配工作，除了端口与终端的匹配，这样的端口透明还支持包能够匹配一些规则，包括：QoS规则、大部分防火墙规则以及一些统计系统（尽管不是大多数）的规则，同时保留了包应被发送至它们所标签的地址这一性质。这一做法避免了异步或其他传输意外而产生的重置操作，减轻了部署的风险。但是这一方案仍然没有完全解决像顶层会话发布、指定IP的内部防火墙等这样一些控制问题，这些问题都与包有关。

另一解决方案是当在包头中保留端点IP地址时，改变端口个数（或者变成一个），此方法同样能够降低错误传送的概率（尽管有时候有可能匹配会出错，但出错概率很低）。如果服务器端口被保留下来，那么大多说WAN系统都能正常工作，包括基于IP端口的QoS、网络使用报告和防火墙，也不需要为优化环境改变什么。这类方法（某种程度上有些混乱）被某个厂商称为透明隧道。它的不利之处仍然是不应该根据IP头来决定包的发送地址，因为有时候目标客户/服务器无法识别这些信息。

说明：终端的WAN优化没有约定的术语表示，像in-path、inpath以及inline都可以互换使用，不同的厂商可能会使用像正确地址和隧道来表示同样的概念以及类似信息。使用者自己要注意。

优化器寻址

最直白的设计是利用WAN传输的头包来取得产生这一信息的设备地址。此时，WAN优化器将确定上述四项主要内容。优化器寻址方法的优点很多，首先也是最重要的，只要发送包是正确的，路由基础设施将永远执行正确的操作。此外，这种方式也为中间交换系统（如报文、QoS等）区别对待优化数据流与普通数据流创造了机会。不利之处在于需要对现有交换系统进行一些改造或移植，才能让它们处理数据流，例如，指定服务的QoS设置要移植到WAN优化器上，或者原本由中间路由收集的网络流信息将改为由WAN优化器完成，因为原始的统计信息在TCP头包里再也不是显而易见的了。

隧道解决方案

正如名字所隐含的一样，隧道解决方案是将原始包加密封装成新的包，对优化器寻址产生的影响也和之前所讨论的差不多，只是改变更大，多个数据流被封装进单一不透明的隧道中，原始数据流更加难以识别。以上所有探讨的网络可视化模式都是针对每一个原始LAN连接，在WAN上也有一个类似的会话，保证大量的网络功能可以正确执行——QoS能够识别会话，每个会话都能和其他会话公平竞争（至少和未优化前一样公平），防火墙可以阻止单个会话等。采用隧道后，这样的会话轮廓将消失，所有的会话都会被混合在一起，WAN端的智能处理将被强制移植到WAN优化器或LAN上。隧道的优势在于它

能够支持对网络传输进一步的优化，例如，一旦在隧道中创建了TCP/IP头包，还可以再次使用更少的字节重编码，此外，隧道简化了转发错误纠正技术，有助于如微波连接或战略卫星连接等松散连接环境提高效率。有了隧道，非TCP会话的优化也变得简单了，最后要解释的是隧道不用处理透明发送带来的问题。

不过，隧道也带来了一些之前未曾探讨过的潜在问题。首先，它将一个静态IP地址引入了一个动态网络。很显然优化器必须要被配置成能够识别哪个子网是在哪个地点，因此增加了网络管理者的负担。其次，在一个网状网络中，每一个站点之间都存在隧道，使得配置开销随着站点数目增加，以O（n^2）倍数增长。在动态基础设施上架构的相互交叉的隧道，尽管复杂性已经有所降低，但是要正确配置所有隧道的传输速率将是让人困惑的难题。集中式设置将能够起到很大作用，但也仍然不是万能的。为了快速理解配置的复杂度，设想一个简单的网络，区域机构拥有一个路由和两条上行链路：一条接到Hub，一条接到不定的卫星站点上。下行带宽与上行带宽需要分开计算，下行链路带宽既需要单独计算但又要计算汇聚带宽。如果两条链路都成为了站点的终端，而仅仅是上下通道的差别，情况就更糟糕了。此外，这些错误事件将占用一些正确的设计，导致多条隧道被迫建立在同一链路上，由于每个隧道都认为自己能够独占链路，从而导致了在隧道之间产生对带宽的争夺战。最后，别忘了那些仅仅临时借用路径的数据流，它们是否能够公平地与隧道竞争资源——未经过优化的能不能拥有和隧道相同的权重？隧道本身的权重应该和连接数目相关联吗？设备该怎么了解这些信息？当需要对一个隧道覆盖网络进行优化时，上述问题都需要仔细研究。

LAN传输

到目前为止，我们还未启动对LAN传输的讨论，在客户端与WAN优化器之间，几乎所有基于网络的WAN优化器都会保持LAN透明，也就是说头包信息与优化前状态是一致的（能想到的唯一例外就是一个显示定义的HTTP代理将被看成一个WAN优化器）。在服务器这端，类似地也可以把它当成一个代理，使用WAN优化器的地址与服务器通信。这看起来有点特别，但是当数据中心网络特别复杂时，WAN优化器将很难或根本无法拦截所有与WAN有关的数据流，这样的处理方法就具备很大的

优势。这一方法的不利之处在于服务器会把所有优化后的网络传输都看成来自WAN优化器，而潜在地增加了日志和授权操作的混乱。因此，如果需要在这样的环境中部署系统，这些情况都必须事先了解清楚。

软件WAN优化环境中的网络可视化

如果优化软件被装载在客户端自身，进行设备集成时，网络可视化的操作并不是特别麻烦。此时，优化软件寻址将会直接映射到客户端，因此至少在客户端不用为“如果包没有被正确转发给WAN优化器该怎么办”这样的问题操心。除了常见的分割优化器寻址模式外，建立一条或多条从客户端到远程WAN优化器间的隧道也是常见解决方法。

对于大多数终端客户优化软件而言，它们要面临的挑战并非寻址或端口重映射而是配置。大部分客户端优化解决方案会配置工作被“推送”到网络边缘完成。这样，管理员就有可能需要确定服务器方所有的WAN优化器、全部的潜在服务器子网，以及终端用户设备上所有需要优化的服务（难以置信吧）。有些时候由于无法识别不同配置组之间的差异，导致所有客户端不得不无视它们在位置、角色、硬件平台等方面的差别，而被迫共享一个统一的配置方案。因而，与厂商基于设备的解决方案相比，很多软件优化方案看起来更像是对各类基础代码的一个事后补救，这一任务非常棘手，因为与管理像WAN优化设备或VM这类固定的网络基础设施相比，管理众多相距遥远的客户端难度更大。

如果从云的视角考虑，基于软件的客户端优化解决方案要比利用硬件设备优化更合适云平台，基于软件的客户端优化解决方案提供了任意时间、任意地点接入云的可能性。不过，基于两点考虑，本章我们将更多关注WAN优化设备，一方面是因为通常WAN优化设备优化效果更好，优化设备可以利用用户操作来提高之后的访问速度，比方说，节约下来的带宽足够用来提高一个群发邮件的附件传输速度。另一方面是因为目前优化设备的销售总量已远远超过终端软件或VM，随着云科技与企业IT架构结合的愈加紧密以及企业中类型II终端用户的不断增加，探讨它们对部署方式的影响是件很有意思的事情。

综合考虑优化设备与现有优化软件，我们需要考虑一个架构问题：那些拥有优化软件的用户该如何接入或脱离带优化硬

件的LAN网络。首先，必须确保只有一个优化连接，要么是通过终端软件优化到服务器的连接，要么是利用硬件设备优化。从客户端到本地LAN的优化以及从本地LAN到远程WAN优化器的优化效率不高，通常也会产生性能问题，而更糟糕的是：这一方案阻止了终端到本地优化器之间的独立优化，使得WAN链路实际上变成非优化链路了。

某些WAN优化器厂商会通过加重配置要求的权重以确保正确优化能被强制进行，但是我们也可以找到更佳的解决方案。首先，自发现机制避免了在每一个终端用户PC机上都要标注隧道终端的做法。其次，自发现机制的探测算法使得优化软件能够发现本地的WAN优化器并且自动让位于它，不过虽然这种方法避免了双重优化，但是它也会生成一些奇怪的配置文件，这是因为当用户离开办公室后，手提电脑的WAN优化软件是识别不了局域网络的数据格式的。因此，为了防止移动办公的性能受到影响，需要增加一个探测附件，目前只有Riverbed公司能够提供，使得软件能够主动与优化设备交互，以掌握WAN的数据格式。当用户再出门时，网络性能就不会因为提前预约软件而重新配置。

说明：让我们用一个案例来说明上述所有相关技术。去办公室前，Ben下载了一个项目，一边喝咖啡一边工作（使用软件加速方法访问数据中心）；回到办公室，他把它上传至文件共享服务器，当天有三个同事修改了这份文件（使用本地LAN优化器加速）；Ben回到家，晚上继续工作，当他第一次在家里打开这份文件时，操作的速度仍然和在办公室一样快，就像软件优化器一直在关注这个优化连接一样；第二天午餐后，Ben完成了这个项目，通过email将结果发送个整个小组，由于文件共享机制，所以文件上传至邮件服务器的速度非常快，而因为WAN优化器通常都能识别这样的需求（同时通过协议和用户），所以30名接收者下载邮件的速度就像光速一样快。

虚拟环境寻址

直到最近，数据中心均采用基于硬件的WAN优化，基本上没什么必要需要在它们的服务器上运行优化软件，解决它们高标准性能需求的理想方法看起来就是采用专门的硬件设备，而且服务器管理员也因此不必考虑负载问题。然而，完全的虚拟环境不断增多改变了这一现象，能够实现虚拟环境集成任务的

新技术也随之出现。分割终端在VM上安装了一个叫“发现引擎”的小程序，这个代理能够探测到新出现的优化请求和当前的优化连接，还能将包重定向到另一VM的WAN器。在WAN中，这个连接看起来没什么特殊（上述说的每个连接），但是现在在WAN优化器和代理之间多了一个LAN跳，这个传输是不透明的，但是为了保证传输正确，它会在地址域保留服务器IP和优化器IP地址。代理可以在服务器软件发现包之前重新封装包的地址，因此在混合私有云这样比较难以或根本无法直接路由的环境中就可以实施有效集成。

4.3.4 监测和优先级别的传输优化实现

对包内容以及可能的网络寻址的改变将对网络管理和包优先级别产生深刻的影响，这是由于优化不但对包的内容改变颇多，还有可能改变寻址方式，在考虑到高级别监控以及优先级服务时，许多架构师会将WAN之间的网络当成黑盒处理，因此WAN优化器将是他们最后能获得诸如包的数量、包的接口信息等更多指引的来源。这给WAN优化器的厂商造成了巨大的压力，要求他们能够将所有高级别服务都能集成在一起，包括：网络流量统计、防火墙、QoS、路由优化、反病毒、网络入侵防范、IP地址管理、Web过滤、Web代理服务甚至多媒体传输中的流分割。如果仅仅是对传输中某些功能进行优化还是有可能的，但全部都实现可能不可能，也不值得这样费劲（例如，你可以实现一个简单的封锁端口的防火墙，但一个带负载监控的防火墙软件是不切实际的）。因此在进行WAN架构设计时，你必须非常小心确保你所需要的服务都已经考虑到了，有些服务（例如QoS）现在已经被认为是WAN优化的基本选项，时间久了之后，你也会发现这类服务将只增不减。

4.4 虚拟远程办公方案

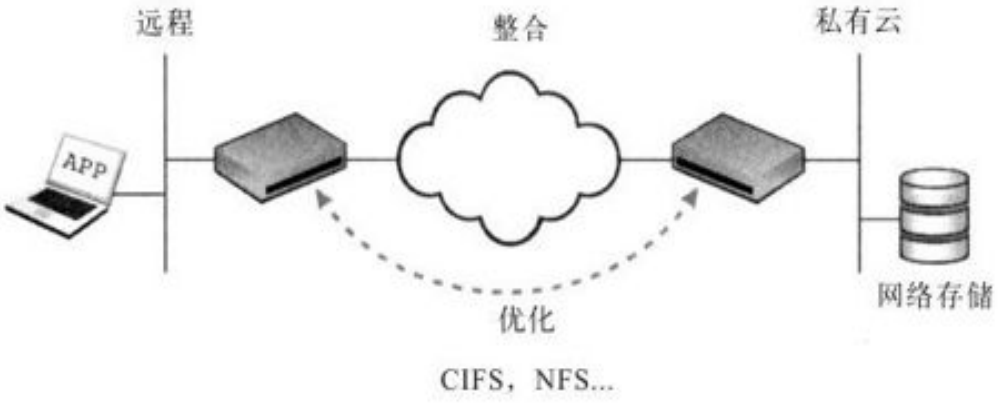
本章只关注了SOI实现的一个方面——办公室内的工作人员通过企业网络访问云平台的应用服务，实际上，这只是几种可能的工作方式中的一种。本章剩下的章节将简单研究三类WAN优化器部署体系的优缺点，我们称第一种为“固定”模式，这个名字反映了以往那些通过网络服务器提供的服务（譬如邮件服务器、数据库等）被集成到云基础设施中的方式。虚拟桌面基础设施（Virtual Desktop Infrastructure,VDI）是另外一种模式，这种架构也采用集中计算和集中存储，但使用Citrix ICA、VMware View或Microsoft RDP改变了接入方式。最后要讨论的是一种新兴结构，既能够处理一些无法集中管理的服务，也能提供某些类似整合的优势。

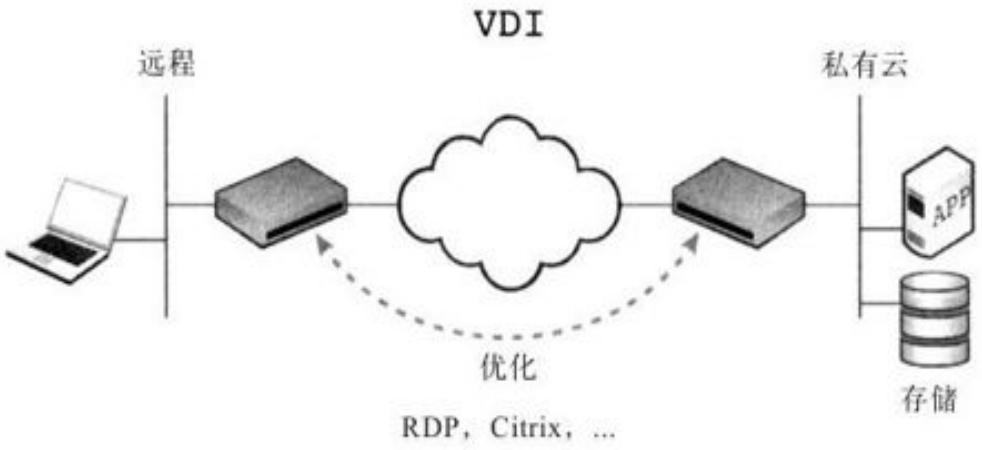
图4-8说明了这几类部署的不同之处，需要注意应用程序位置APP的变化，以及相应的在WAN上要优化的协议的改变。在VSI样例中，磁盘覆盖了远程优化器说明了它拥有的是存储权限，这是其他结构没有的。

像CIFS、MAPI、FTP、HTTP等位于WAN连接上的协议，在整合时会进行WAN优化，优化体系将保证整合的成功。整合能够为大多数机构带来利益，包括节省开支、简化管理、效率更高的备份、适应力更佳、服从性更优，这是一个列不完的清单。不过，整合最大的问题在于它需要依靠现有网络，其次应用程序所用的WAN协议也必须被优化，而有些是没法优化的。如果满足不了，WAN优化就会连原有的改善都实现不了。受到这两个因素的限制，大多数组织会意识到私有云的优势，并利用WAN优化来消除上述困扰。

VDI使IT能够在数据中心这端的网络整合也达到类似的优化，更进一步地它希望能降低远程桌面的管理开销并增强安全性。大多数部署都会通过封锁桌面图片来达到更好的效率与更可靠的安全性，但是像Citrix ICA、VMware View或Microsoft RDP这样的VDI体系，远程性能却成为了潜在杀手，由于端点的计算量很小，产生的时延和带宽受限将把VDI实现阻隔在几百米之外。在实际中，WAN优化可以从至少三方面解决这个距离问题，首先，很多企业都希望一次尽可能多地把用户封装成一个给定链路中，此时，WAN优化的消除重复数据方法将比VDI压缩性能更好（特别是处理跨用户网络传输时），它通常

能将原始应用带宽需求减少到原来的60%～80%；其次，一些WAN优化器可以针对VDI流实施QoS，提高键盘或鼠标事件的优先级，使得它们的优先级能超过网络传输，使得用户得到更加的图片响应；最后，传统的WAN优化技术还能扩展到打印、文件上传以及跨协议升级等操作。所以，综合看来，VDI设计不仅能为项目带来更好的ROI（例如，用户），还因为它们的应用响应更优而创造了更多有效的用户。





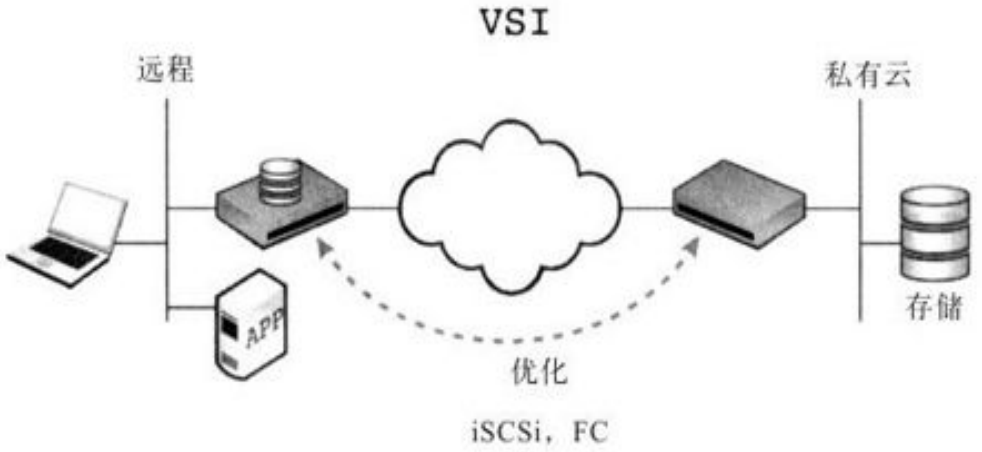


图　4-8　远程服务体系方案

VSI是一种应对存在整合困难服务器的新的解决方案，它是一个新概念（拥有一个新名称flux），集中存储不是建立在广域范围的文件系统协议之上，而是通过本地设备通过iSCSI或光纤通道向本地服务器（可以是VM）提供一个接口。借助VSI，应用程序看起来使用的是本地磁盘，但仍然体现了整合管理的优势。这种解决方案不仅节约了成本，同时也简化了对那些不适合采用集中存储的服务的管理，例如一些偏重图形的应用以及某些必须断开WAN连接的服务。

这一方案的关键是使用分支授权存储，同时保证存储变化能被有效复制到核心服务器上，基于封锁机制的协议与面向整合的协议一样，都是面向应用加速和节约带宽，授权磁盘支持快冷写以及断开连接操作，与核心存储的同步保证了DC动态备份以及本地维护（例如，关掉远程服务，启动DC，维护，关闭DC，在分支恢复时，按照需要进行封锁和更新）。

说明：应用（VSI一节中图4-8所标注为APP的部分）可以像说明的那样在本地服务器上运行，那些需利用本地硬件的系统会比较多地选择这一方案。除此之外，还可以将服务移植到WAN优化器的虚拟平台上，形成一个远程分支，在这个类似箱子的部署模式中，单独或冗余配置的服务器可以为本地用户提供所有服务，也可以相应提高其他远程用户的访问速度。一个远程VDI部署在WAN优化器上拥有一个桌面镜像，但是可以通过云的WAN链接来优化它们的存储和应用。

4.5 小结

本章探讨通过WAN优化来应对带宽和时延对私有云的挑战，借助重复数据删除、压缩、TCP加速及应用加速等措施，WAN优化可以克服以上网络瓶颈，但是由于负载、包头以及与其他网络整合而产生的变化使得WAN优化本身也需面对整合带来的挑战。为了满足各种企业商业需求，WAN优化支持采用不同设计和部署方式构建云服务，它们对远程分支网络的架构以及DC都将产生影响，接下来两章我们将探讨这些影响。

第5章　会话拦截设计及部署

谁若是想什么危险都没有了再航行，就永远出不了海。

——托马斯·福勒（Thomas Fuller）

简介

第4章探讨了WAN优化对私有云成功的重要意义，它能在保证高性能的同时提供非常棒的服务整合，并且将由来已久的WAN时延难题扼杀于萌芽状态，使集中式架构成为可能。只是，WAN必须要能够拦截下端点主机向WAN优化以及DC服务器发出的请求会话，才能实现优化。本章重点关注DC中各类WAN优化拦截及重定向方法，它们也是第6章云拦截技术的基石。

5.1 拦截机制选择

这世上是否存在一种最好的拦截机制呢？答案是：需视情况而定。DC部署时选择何种拦截机制要考虑到系统平台、常规操作、计划操作变更以及故障处理等很多因素，这些因素可以被归结为以下三方面：

·选址决议

·操作影响

·可控性

5.1.1 选址决议

有意思的是，选址决议或WAN优化器的位置比要考虑的拦截机制更重要，WAN优化器可以被部署在各类地点：

·WAN边缘/对等联接层

·核心/汇聚层

·接入层

·服务分布层

选址决议也相应确定了拦截部署所使用的特定平台（依赖于其拦截能力）。例如，汇聚层的平台有可能是Catalyst 6500（Cat6K）交换机，而在WAN边缘，这一平台就可能变成了ASR 1000（ASR1K）路由器等。

5.1.2 操作影响

企业DC最关心的问题是实施拦截部署后对操作的影响，一些典型的操作包括：

·拦截部署会破坏操作吗？什么级别的破坏是可接受的？

·需要维护窗口吗？如果需要，窗口尺寸应该设为多大？

·拦截机制的弹性有多大？

·如果拦截调度出错该怎么恢复？

·故障切换或回滚该怎么进行？

·IT管理人员通常会综合以上因素后再做决定。

5.1.3 可控性

拦截部署在可控性方面包含以下因素：

·可扩展性

·高可获得性（High Avlability,HA）

·支持基础设施虚拟化（例如，VRF、虚拟设备上下文等）

拦截部署的设计要依据企业DC和私有云的上下文决定，因此可扩展性和HA均不容忽视。

而鉴于基于云服务发布本身（例如，云基础设施即服务）多租户特性，也要求部署能够支持诸如VRF及虚拟设备上下文（VDC）这样的基础设施虚拟化技术，以确保各租户相互之间能够实现安全隔离。

5.2 深入探索WCCP

Web缓存通信协议第2版（Web-Cache CommunicationProtocol version 2，WCCPv2），可以满足上节中所提到的各种限制。支持WCCPv2的路由器或L3交换平台可以实现透明拦截，并且将需要WAN优化的TCP会话转发至合适的WAN优化器。在这种情况下，拦截设备（路由或L3交换机）采用物理径内（physical in-path）方式，而WAN优化器则采用物理径外（physical out-of-path）方法，在第4章中曾经讨论过这样的逻辑in-path设计。在大多数情况下，这类拦截设备是早已经存在的，因此不会导致操作故障。

说明：本章中所有谈到WCCP的地方都是指WCCPv2。

5.2.1 WCCP定义

要更多了解WCCP，有必要先学习一些在WCCP中常用的术语。

·WCCP客户端：WCCP客户端指缓存、Web缓存、缓存引擎、WAN优化器、设备、代理等。

说明：本章所提及的WCCP客户端专指WAN优化器。

·WCCP服务器：一个WCCP服务器是指支持WCCP的路由器或L3交换机，通常也被称为WCCP路由。WCCP路由会将“有趣的”数据流重新定向至WCCP客户端以进行优化，本章所提到的WCCP服务器或者是Cisco路由或者是L3交换机。

说明：“有趣的”数据流是指那些需要进行WAN优化的数据流。

·服务组（Service Group,SG）：一个SG是指一组由一个或多个路由以及由一个或多个WAN优化器组成的重定向设备，SG的特性由这些设备决定，每个SG是0～255之间的一个随机数，Web缓存是大家都比较熟悉的SG，它由0标识，剩下其他的SG都是动态的。

·集群或聚簇：一个缓存集群或聚簇是指由32个以上的缓存（或WCCP客户端）与在单个SG内的32个WCCP路由组成的组。

·指定缓存：当系统中存在一个以上的缓存或缓存集群时，IP地址最小的那个缓存被称为指定缓存或领袖缓存。指定缓存将指示WCCP路由器该如何在缓存集群之间完成流量重定向。

·优先级：WCCP优先级包括0～255个级别，它决定了当前WCCP路由接口的SG级别高低，尽管有多个SG可进行评估，但只有一个SG能被应用到接口上，通常高级别的SG要早于低级别SG完成评级。

·权重：对指定Web缓存的分配权重指示了在同一个SG中如何为Web缓存赋值。

5.2.2 WCCP控制平面消息

在完成网络拦截及重定向之前，支持WCCP的WAN优化器必须要能成功地注册到WCCP路由上，WCCP通过使用Here_I_AM（HIA）以及I_See_You（ISU）控制平面消息来完成注册。

说明：WCCP控制平面消息交换通过UDP2048端口完成。

每个WCCP客户端每隔10秒向同一SG内的WCCP路由器发送HIA消息，以加入该SG并维护其会员资格。HIA消息的Web缓存信息属性使用WAN优化器的IP地址来标识该优化器，HIA消息在服务信息属性中标明WAN优化器希望加入哪个SG。

每个WCCP客户端通过HIA消息里的Web缓存信息属性向外告知它所加入的SG视图，WCCP客户端会将这样的HIA消息发给相同SG的所有WCCP路由。这些信息包括一个WCCP路由器列表，包括了所有向WAN优化器发送了ISU消息的路由器信息，以及那些已经收到该ISU消息的WAN优化器列表。Web缓存视图信息属性还包括了变更编号（Changed Number,CN），当WCCP客户端的视图每发生一次变化，该CN的值就会递增。

说明：WCCP客户端通过Web缓存消息属性向外公示它们所连接的WCCP路由器的信息。

当WCCP路由器收到一个HIA消息时，将会回应一个ISU消息。ISU消息中路由器指定属性包含了WCCP路由ID（IP地址最大或者如果激活了loopback地址，则loopback地址最大的WCCP路由）、属于SG范围内的WAN优化器列表，列表范围之外的WAN优化器将忽略该ISU消息。

WCCP优化器通过HIA消息中的web缓存视图信息属性向外告知与它处在同一SG内的WCCP路由，该优化器的SG视图信息，属性参数包括WCCP路由可见的该SG内可用的WAN优化器列表以及从WAN优化器返回的HIA消息中的WCCP路由列表。当SG的成员信息发生变更时，该属性的成员信息变更序号（Membership Change Number,MCN）将由WCCP路由递增。

说明：当MCN递增时，ISU消息中的路由信息属性反映了最近的WCCP客户端信息。

说明：WCCP控制平面采用TLV（Type-Length-Value）格式编码时选用了不同的“要素”，每一要素标识作用不同，不是所有的要素都要包含在消息内，除了服务要素及安全信息要素，某些要素是可选的。

WAN优化器可以和WCCP路由协商以下内容：

·重定向（转发）方式

·分配方法

·返回方法

协商在一个WAN优化器加一个SG成对进行，因此一个WAN优化器可以和不同的SG路由协商重定向、分配以及返回方法。

WCCP路由将能够支持某SG的重定向、分配、返回方法封装在ISU消息的“能力”属性中进行广播，该属性的设置是可选的，如果WCCP路由没有指定重定向、分配及返回方法，则该路由默认支持GRE重定向方式、散列分配算法以及GRE返回方法。

WAN优化器会检查来自WCCP路由的ISU消息中关于重定向、分配以及返回方法的说明，如果WCCP路由公布方法中不包括该WAN优化器支持的算法，WAN优化器将会放弃加入该SG的行为，否则WAN优化器将会在WCCP路由公布的不同方法中选择一种，并且在它紧接着要发送的HIA消息的可选能力信息属性中标签好这些方法。如果在HIA消息中不包括以上方法的说明，则表明WAN优化器要求默认的GRE重定向算法、默认的散列分配算法以及默认GRE返回方法。

WCCP路由同样会检查来自WAN优化器对ISU消息进行回应的HIA消息中对这些方法的说明，如果WCCP路由不支持这些方法，WCCP路由将忽略该HIA消息，否则WCCP路由就将该WAN优化器作为可利用资源并将之添加到相应SG内。

在WCCPv2中，会使用“receive ID”来确认WCCP路由和WAN优化器间的双向联接，ISU消息中路由确认消息属性包含了“receive ID”域，由每个SG单独维护，每当WCCP路由向SG发送一个ISU消息，该值则累加一次。

WAN优化器收到由WCCP路由发送的“receive ID”消息后，将通过封装在HIA消息的Web缓存视图信息属性返回ID值，WCCP将检查从每一SG成员处返回的HIA消息，确认“receive ID”的值，如果该值与最后一次发往该成员的ISU消息中的值不匹配，WCCP路由将忽略该HIA消息。

只有当路由器确认它发往WAN优化器的ISU消息通过HIA消息返回，并且“receive ID”值正确无误后，才会将该WAN优化器纳入可利用的SG成员范围。

发往WCCP路由的散列/掩码分配情况表位于重定向分配消息（RA,Redirect_Assign）中，借助此表，可以知道SG中所有WAN优化器间的网络重定向传输方式。RA消息由指定或领导WAN优化器（在SG中选择地址最小的路由）发送到SG中所有WCCP路由上，包括一个分配键和分配变化号码（Assignment Change Number,ACN）。

图5-1左边部分说明了一个初始的WCCP握手序列。

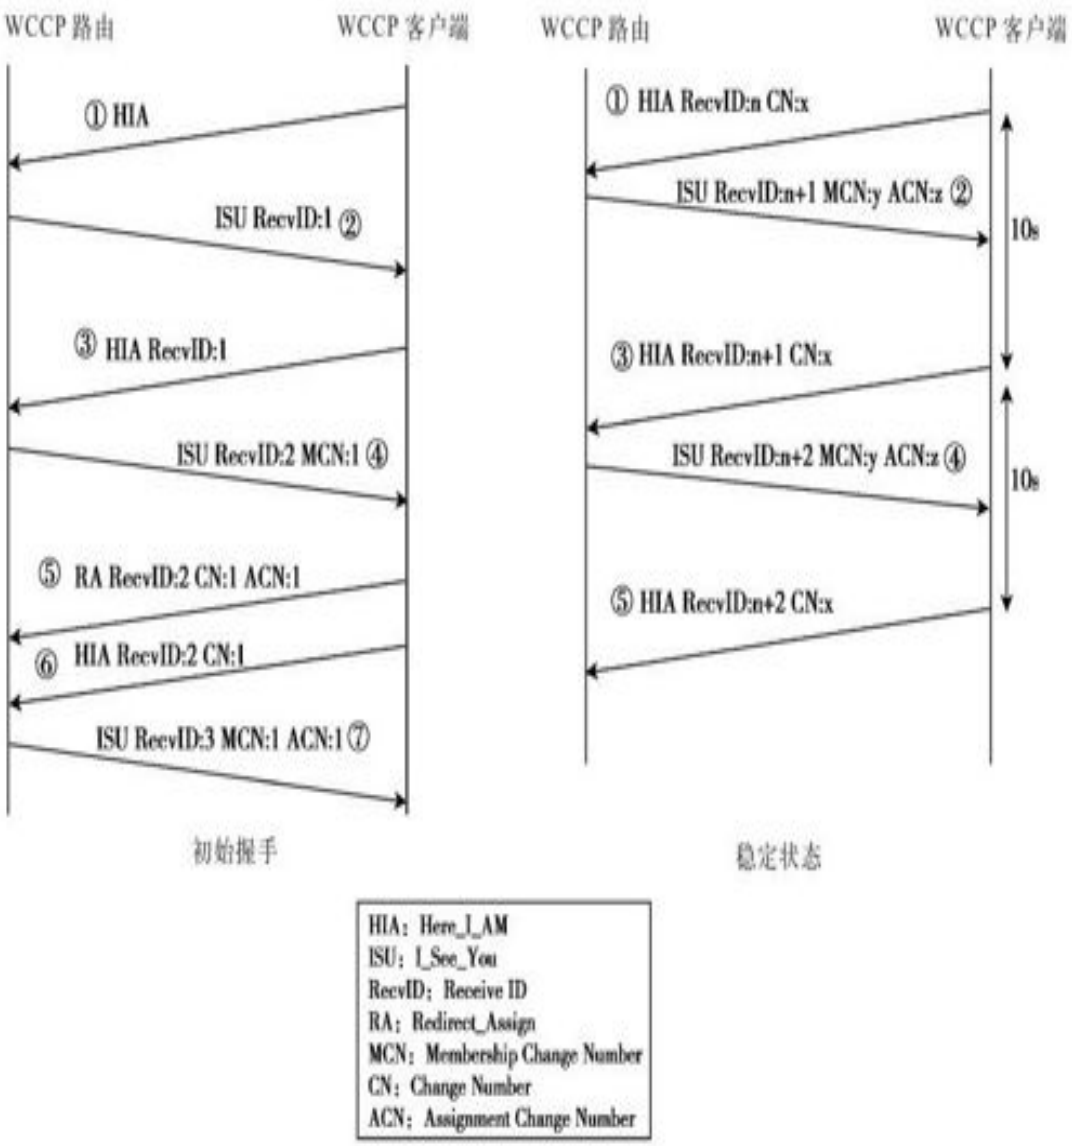


图　5-1　WCCP初始握手及稳定状态联接

·从WCCP客户端首次发往WCCP路由的HIA消息指明了SG属性；

·从WCCP路由首次发往WCCP客户端的ISU消息是对前次HIA消息的应答，接受了SG的设置，将receive ID的值初始化为1；

·第二次HIA消息的receive ID值为1，设置好了分配权重和状态；

·第二次ISU消息包括了路由视图中的WCCP客户端，将receive ID值加1变成2，将成员变化数目值（MCN）初始化为1；

·第一次RA消息的receive ID为2，设置散列/掩码表（由具体使用的方法确定），将CN和ACN的值都初始化为1；

·第三次HIA消息的receive ID为2，CN值保持不变，仍为1；

·第三次ISU消息将receive ID值累加1变成3，ACN值变为1，MCN值保持不变，仍为1。

图5-1右边部分说明了WCCP稳定状态序列：

·HIA消息的receive ID值为n,CN值仍然保持不变为x；

·下一ISU消息将receive ID值累加1，变为n+1，MCN值为y,ACN值为z，保持不变；

·下一HIA消息的receive ID值为n+1，CN值保持x不变；

·下一ISU消息将receive ID值累加1，变为n+2，MCN值为y,ACN值为z，保持不变；

·下一HIA消息的receive ID值为n+2，CN值保持x不变。

如果一个WCCP路由超过25秒后还没有从一个SG成员（WAN优化器）处收到HIA消息，它将向该成员发出一个是否还在的消息RQ（Removal_Query）进行询问。

如果一个WCCP路由超过30秒还没收到SG成员的HIA消息，将认为该优化器处于不可用状态，并将它移出SG,ISU消息的路由视图信息属性中也不会再包含该WAN优化器的信息。

图5-2是对WCCP客户端超时序列的说明：

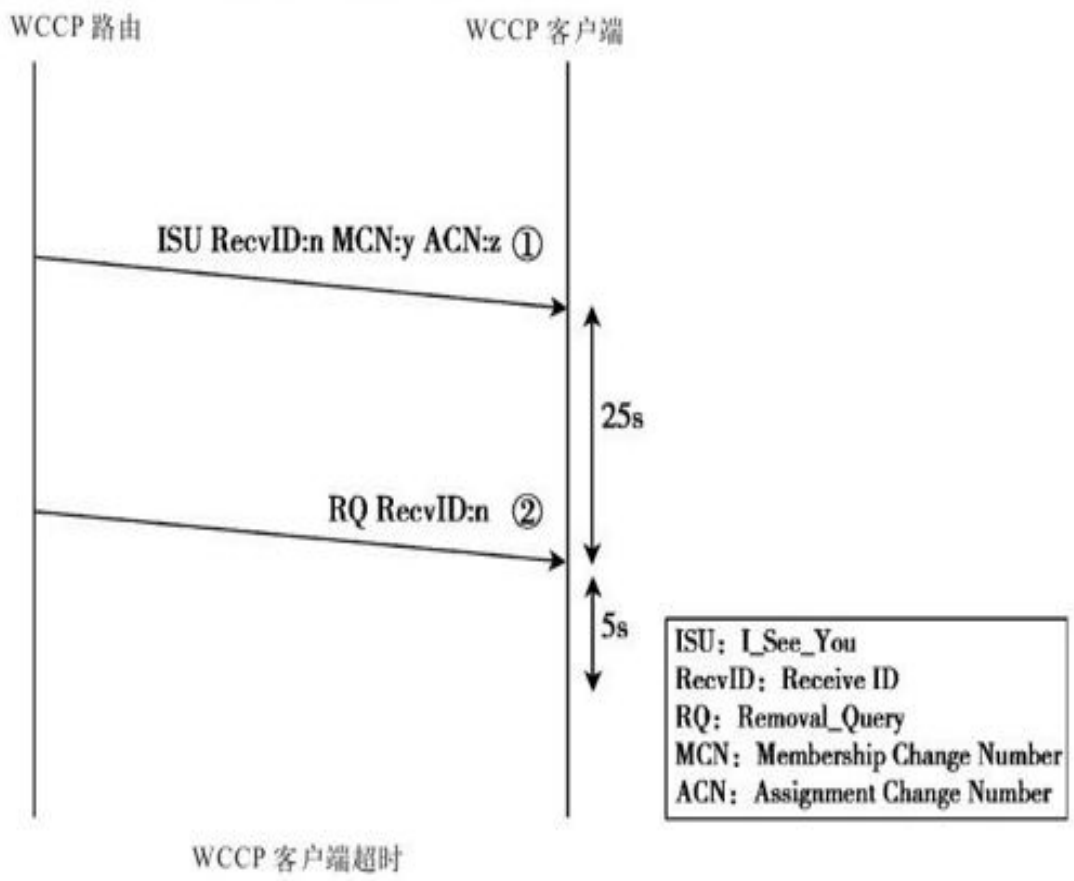


图　5-2　WCCP客户端超时

·WCCP路由器向WCCP客户端发消息；

·WCCP客户端未能在25秒内返回HIA消息；

·WCCP路由直接向WCCP客户端发RQ消息；

·WCCP客户端未能在5秒内对RQ消息作出应答；

·WCCP路由将该WCCP客户端移出它的散列/掩码表，更新路由视图信息，将MCN值累加1。

5.2.3 WCCP服务组

正如之前小节中讨论的一样，HIA消息的服务信息属性指明了WAN优化器希望加入哪个SG的信息，SG由服务类型和SG标识号确定，存在两类SG：

·常规服务

·动态服务

常规服务指那些WCCP路由和WCCP客户端都了解，不需要专门说明，只需要服务ID的SG服务，常规服务的SG标识号范围为0～255。目前，web缓存（HTTP）是唯一被确定的常规SG服务。与常规服务不同，WCCP路由需要得到对动态服务的完全说明，这一说明被封装在第一个加入SG的WCCP客户端的HIA消息中发送给WCCP路由，包括使用的协议、服务标识位以及服务信息域的端口域，一旦与客户端确认好了动态服务的内容，WCCP路由会抛弃其他客户端发送的与该服务描述冲突的HIA消息，WCCP路由同样也会抛弃那些描述的服务不能得到WCCP路由的支持的HIA消息。

图5-3列出了Cisco所定义的各种WCCP的服务组。

服务名称	服务组 ID	协议	端口	优先级
web-cache	0	tcp	80	240
dns	53	udp	53	202
ftp-native	60	tcp	21	200
tcp-promiscuous	61	tcp	*	34
tcp-promiscuous	62	tcp	*	34
https-cache	70	tcp	443	231
rtsp	80	tcp	554	200
wmt-mmst	81	tcp	1755	201
wmt-mmsu	82	udp	1755	201
rtspu	83	udp	554	201
cifs-cache	89	tcp	139,445	224
custom	90~97	tcp	用户定义	220~227
custom-web-cache	98	tcp	用户定义	230
reverse-proxy	99	tcp	80	235

图　5-3　Cisco WCCP服务组

在配置WCCP优化器集群或聚簇时，WCCP路由推荐使用两组相反的分配方式（例如一个方向为源地址散列，另一方向

为目标地址散列），这样可以确保响应包能够被重定向至相同的WAN优化器来处理，而不用考虑该包最初是被SG中哪个WCCP路由拦截的。

WCCP包重定向操作可以在入口、出口或双方的任何一个接口完成，且同一接口可以定义任意方向的多个SG，但每一方向只会根据定义好的SG优先级选择一个SG（图5-3列出了Cisco WCCP服务组及相应优先级别）。

说明：IOS和NX-OS提供了附加服务，该服务能够对同一接口上配置的SG依据其WCCP优先级评级（使用“ip wccp check service all”命令调用）。

说明：Cat6K不按WCCP SG优先级评级，它是按SG值从低到高排序（Web缓存SG 0总是处在第一位）。

5.2.4 WCCP拦截操作

WCCP拦截操作由拦截设备或采用物理in-path方式的WCCP服务器完成，拦截设备监视经过当前接口的网络流，根据拦截配置规则的定义，发现感兴趣的网络流并将之重定向到某一个WCCP服务组客户端以完成WAN优化，此时，WCCP客户端充当了WAN优化器的角色。

WCCP拦截可以在两个方向上进行：

·入口重定向（或称为界内拦截）：当接口接到入口拦截（“ip wccp < SG > redirect in”）命令后，WCCP路由将监控那些进入接口的网络流，确定其是否能够匹配当前任一SG的拦截规则。图5-4左边部分展示了一个WCCP入口拦截的样例。

·出口拦截（或称为界外拦截）：当接口接到出口拦截（“ip wccp < SG > redirect out”）命令后，WCCP路由将监控那些流出接口的网络流，确定其是否能够匹配当前任一SG的拦截规则。图5-4右边部分展示了一个WCCP入口拦截的样例。对于出口重定向，要求WAN优化器联接上的WCCP路由要具备exclude-in特征（“ip wccp exclude redirect in”命令），这是因为自WAN优化器返回的包是按普通方式进行路由，如果不指明它们不能再次通过那些连接到WAN优化器的路由，那么这些包就将被重复拦截，再经过路由重新定向到出口，形成一个重定向回路（例如，WCCP黑洞）。

说明：入口重定向在重定向之前不会执行一个搜索路由表的动作，而出口重定向则需要执行该项搜索，以确定界外接口，因此入口重定向相对效率更高，同时采用入口重定向方法时，WCCP设备对CPU负载要求也较出口重定向方法更低，因此应用更为广泛。

5.2.5 WCCP重定向机制

WCCP重定向机制或转发方法规定了交叉的网络流将如何被传送至某个指定的WAN优化器，现有重定向机制有如下两种：

·GRE重定向：

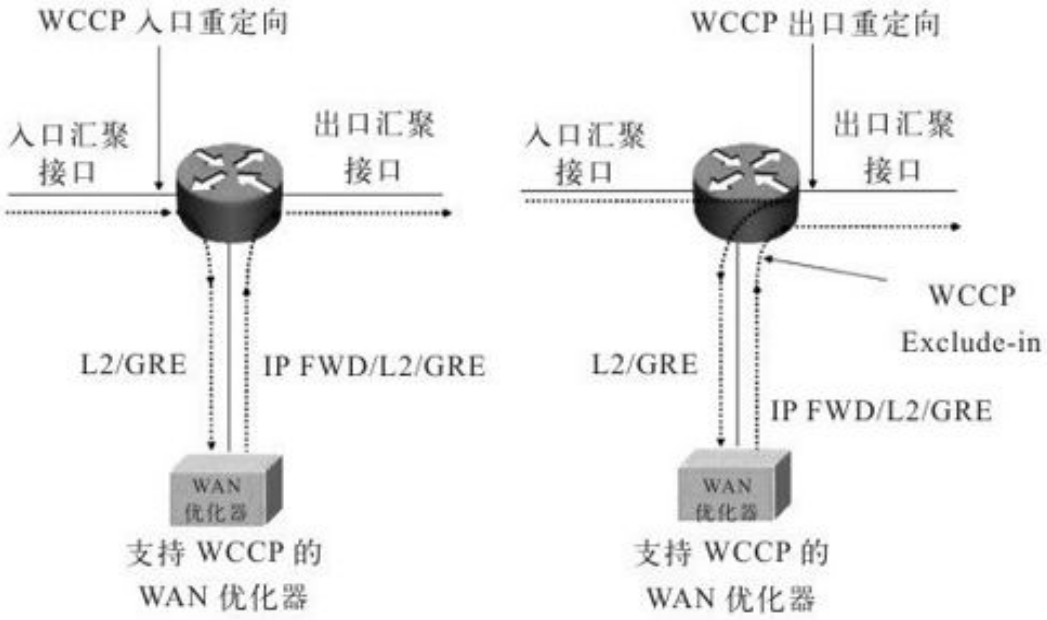


图 5-4 WCCP拦截说明

·GRE重定向机制中，GRE将包含路由信息的拦截包全部封转在GRE头包内，发送至特定WAN优化器，WAN优化器在优化时再对包解封装。

·当使用GRE封装方法时，WCCP将WCCP路由器ID作为源IP地址，WCCP路由ID是WCCP路由中回环地址最大的那个，如果没有配置该地址，则选择物理接口地址最大的那个。

·WCCP路由地址被作为包的源地址发送给WAN优化器，同样，在WAN优化器使用GRE返回时，该地址则是相应目标地址，指向相应WCCP路由地址（更多细节请参见5.2.7节）。

·GRE重定向机制能够保证即使在WAN优化器和WCCP路由器之间需要多跳才能到达的情况下，也能将拦截包传送至相应WAN优化器，这使得在只支持L3邻接性的系统中，能够灵活部署WAN优化器。

·GRE重定向机制中，由路由软件完全负责包的重定向任务，因此GRE重定向方法也是完全由软件路由（C7200和集成服务路由）和ASR1K控制。

说明：在WCCPv2协议中，WCCP路由ID由最大的IP地址或最大的loopback地址（如果配置了loopback地址）决定的。WCCP将自动完成这一任务，该值不能被人为修改。目前，只有运行IOS-XE 3.1S版本的ASR1K路由使用“ip wccp源-接口”全局命令，才能支持用户自定义WCCP路由ID。

·L2重定向：

·在L2重定向机制中，原始的Ethernet帧头的MAC地址将被特定WAN优化器的MAC地址代替，这样包含了拦截包的Ethernet帧将被重定向至WAN优化器。

·L2重定向要求系统支持L2邻接，在这种情况下，WAN优化器的WCCP路由ID配置，必须是引用直接连接WCCP路由的接口IP地址，而非loopback IP地址或者是其他在WCCP路由上配置的IP地址。

·L2重定向由硬件完成，像L3交换机包括Cat6K、C7600平台以及Nexus 7000交换机都能支持这一功能。

·由于L2重定向是基于硬件平台的，因此它对WCCP路由的CPU资源占用较少，基于此，L2重定向方法比GRE重定向方法应用更广。

说明：在L2重定向方法中，除非使用组播IP地址且支持组播路由，WCCP路由配置WAN优化器地址都要求引用直接与每一个WCCP路由相连的接口IP地址。

说明：L2重定向要求入口重定向。

5.2.6 WCCP分配算法

分配算法负责决定拦截网络流量该如何交叉分配到WCCP客户端，这些客户端都注册在同一SG上。分配算法由每一个WCCP路由与所有WCCP客户端按每SG方式协商形成，参与到多个SG的WCCP客户端可以和每个SG协商不同的分配算法，但是同一SG的不同WCCP客户端必须使用相同的分配算法。现有分配算法主要分成两类：散列分配和掩码分配。

散列分配

散列分配为默认分配算法，使用一个256桶的重定向散列表将网络流量交叉分布到SG的WCCP客户端上。拦截包的源/目的IP地址或源/目的端口（依SG配置而定）通过散列函数计算得到的索引值确定，该值将落在散列表的256个桶的范围内，每一个桶都指定了SG中对应的WCCP客户端，散列分配方法是软件IOS路由的默认分配算法。

图5-5解释了散列和桶的概念。

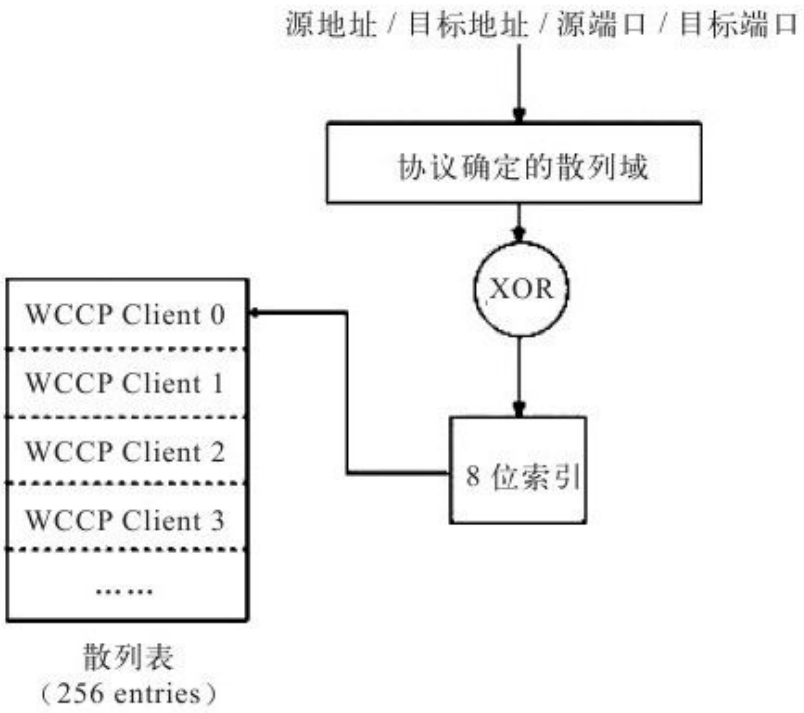


图　5-5　WCCP hash分配算法说明

当一个WAN优化器加入到某一SG时，将分配到部分桶址，如果只有一个WAN优化器，则所有的桶都将与该优化器关联；当有多个WAN优化器加入到SG中时，桶将被分成不同的段，默

认情况下，每一个WAN优化器都是被平均分配到相同的地址桶范围，如果指定了分配权重，将得到一个不平衡的分配结果。

说明："show ip wccp < service-group-ID > hash < dst-ip > < src-ip > < dst-port > < src-port > "IOS执行命令（隐藏）可以被用来验证使用了散列分配方法的WAN优化器，其给定src/dst IP地址及与端口的组合。例如，"show ip 90 hash 0.0.0.0 10.1.2.3 0 0"说明了源IP地址的目标WAN优化器为10.1.2.3。

掩码分配

掩码分配方法通过配置掩码值（最大为7位）将流量分布至SG内的WAN优化器。它支持在WCCP服务平台的硬件上完成拦截，当WCCP路由进行拦截时，掩码将按位与包的内容完成AND运算（特别是源/目的IP地址与端口），然后将结果与一串掩码值比较，并将包转发至与结果值匹配的WAN优化器上。

图5-6说明了掩码处理与赋值的概念。

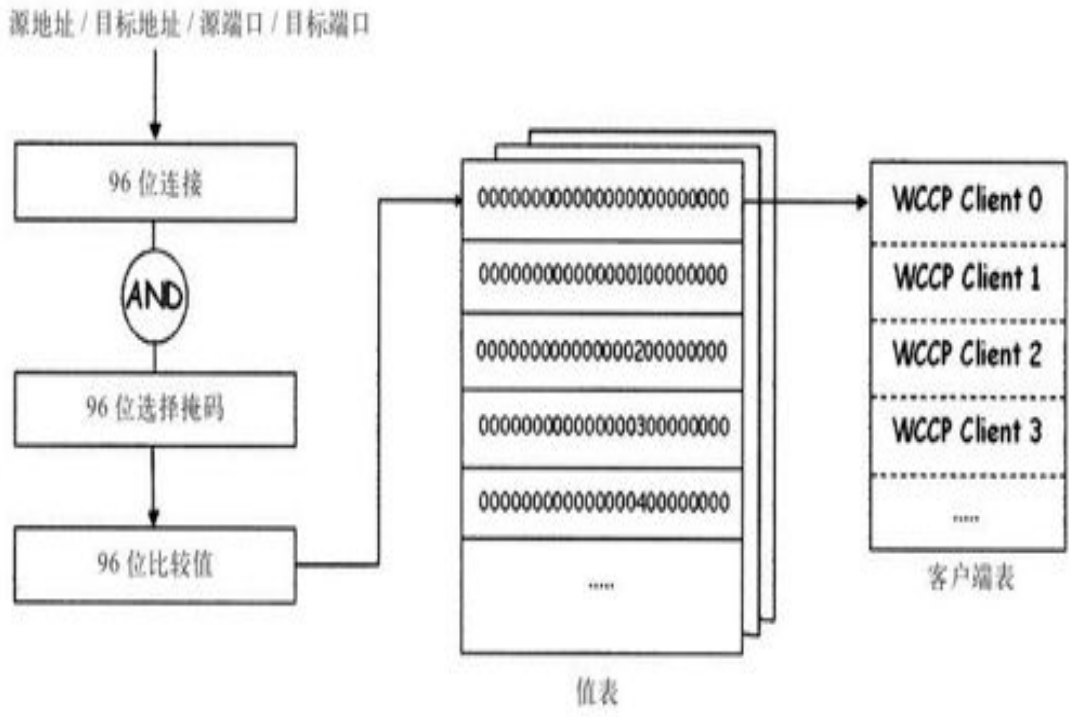


图　5-6　WCCP掩码分配说明

掩码值最大可以为7位（128个地址桶），掩码值位数由分配池中的地址桶个数决定。

例如，一个src-ip-mask值为0x7，能够创建8个地址桶（或者桶尺寸为8），可以使用分配权重来控制将这些桶分配至某一

WAN优化器。

下列一些数学术语被应用于桶的计算中：

·单元尺寸，总权重除以桶的尺寸得到的。

·可分配的桶，WAN优化器权重除以单元尺寸，然后取整。

举一个例子，假设当前SG中只有一个WAN优化器，权重为25，则：

·单元尺寸=8/100=0.08

·可分配的桶=round（25?0.08）=2

本例中，8个地址桶中只有2个被分配给WAN优化器，任意一个源IP地址最后的掩码值如果落入到其他六个桶之一的范围，将不会进行重定向操作，而是按照普通路由方式发送。

掩码选择

该使用什么样的掩码值呢？没有一个简单的答案。本小节将试图描述构造掩码的一些基本规则，但掩码的选择还是依赖于实际的配置环境和规模。

首先，掩码的位数必须能够提供足够的地址桶以分配给SG中的WAN优化器，同时还需考虑每个WAN优化器的不同权重。例如，1位掩码只能够支持2个WAN优化器（2^1=2），如果要最大程度地支持SG中的WAN优化器，至少需要一个5位（或更多位）的掩码，一个5位掩码就足够支持32个WAN优化器（2^5=32）。

IPv4地址采用点-十进制形式，由4个位组组成，当用十六进制表示地址时，每一个位组由2个范围为0到F的十六进制数代替。WCCP掩码通常采用十六进制表示，初始位的0则通常会被省略。譬如，假设IP地址为10.1.2.3，则相当于十六进制数0x0A010203，WCCP的掩码则为0x7（8个地址桶），当位的与操作完成后，得到结果0x3（0x0A010203AND0x00000007=0x00000003）。

默认源IP地址掩码为0x1741（默认目标IP地址掩码为0x0），虽然有默认值，但通常并不推荐使用默认值进行掩码分配，因为这样的掩码值在大多数情况下都不足以提供正确的负

载平衡。但当SG中只有一个WAN优化器时，掩码则与优化器无关，则能够使用默认值来分配。

在远程分支办公室中（RBO），源IP地址经常会由DHCP顺序分配，IP地址仅仅会在最后一个位组有区别，在这种情况下，可以通过根据部署在RBO上的WAN优化器的个数，确定一个范围为0x1到0x7F的WCCP掩码，使掩码分布得到充分利用。

一个区域性的企业DC通常会使用一个拥有/24掩码地址的IP子网，这些子网的IPv4地址的第三位组值互不相同。此时，WCCP掩码的地址为0xF00到0x7F00。核心企业DC通常使用/16掩码地址，这些子网的IPv4地址在第二位组互不相同，此时WCCP掩码地址范围是0xF0000到0x7F0000。

说明：如果系统规模很大，则IP地址中较高顺序的位组可以实现整个站点负载平衡，而不仅仅只是主机负载平衡。

很难将连接端口也组织成掩码的一部分，大多数连接都会至少使用一个“随机”的端口，也很少有协议能够在较小位数范围上提供很好的分布，你也许能够尝试着使用客户端端口的较低顺序的位作为随机数源。

5.2.7 WCCP返回方法

未被选中进行WAN优化的包（例如，符合某个WAN优化器绕行规则）将被返回至WCCP路由采用普通方法转发。WCCP返回方法（例如，绕行返回方法）将规定返回的规则。现有返回方法分为两类：

·GRE返回（或称为L3 GRE返回）：在GRE返回方法中，被封装返回给WAN优化器的包增加了一个GRE头部信息，在头部信息中，指明了目标WCCP路由ID。收到这一信息后，WCCP路由将解封GRE封装好的包，并依据普通方法转发该包。由于通常是在路由器的软件层完成GRE解封锁操作，因此GRE返回方法将有可能增加WCCP路由的CPU负担。

·L2返回（或称为L2重写返回）：L2返回方法会将原始Ethernet帧头中目标MAC地址替换成WCCP服务组路由的MAC地址，当收到包含返回包的帧后，路由将按常规方式进行路由，L2返回方法要求WAN优化器与WCCP路由是L2邻接的。

说明：WCCP返回方法不必与重定向机制相对应，每一服务组的WCCP路由与WAN优化器可自己协商确定，支持WCCP的Cisco路由将通过设置WCCP的ISU消息中可选支持信息属性来通知服务组所支持的包返回方法，如果省略该消息属性，则意味着路由仅默认支持GRE返回方法。

5.2.8 WAN优化器的egress方法

Egress方法决定了WAN优化器将如何将流量返回至WCCP路由，egress方法同时针对优化包及依据协议未实施优化的包两种类型流量，它与返回方法不同，返回方法只适用于未实施优化的包。

从WAN优化器到WCCP路由的egress方法有如下三个选项：

·IP转发

·协商返回

·普通GRE返回

IP转发

IP转发将优化后的包根据配置发往默认WAN优化器的网关。在使用IP转发方法时，WAN优化器不能被配置到与它要优化的客户端或服务器端相同的VLAN或子网内，否则egress网络流就将被WCCP路由重复拦截而产生一个重定向的回路。另外，IP转发egress方法也不能保证优化后的包将被返回至最初拦截它的WCCP路由。

大多数WAN优化器都会默认选择IP转发egress方法，这样会对WAN优化器部署形成挑战，例如，存在了多个路由或者冗余路径的情况，或者每个WAN优化器的默认网关由于使用了像GLBP、VRRP及HSRP这类首跳冗余协议而都指向了同一虚拟IP地址的情况。

在这样的部署环境中，WAN优化器将倾向将包发送给一个原来没有用于拦截和重定向的路由。协商返回和普通GRE返回这两类egress方法可以保证网络路径的共用性，它们可以保证离开WAN优化器的包能够通过同一转发路径回到实施拦截的WCCP路由处。

说明：Riverbed Steelhead设备使用“sticky-MAC”方法来保证网络路径共用性。

协商返回

协商返回egress方法决定了哪一个WCCP用来进行绕行返回，此WCCP也将用于WAN优化器的出口为优化后的包服务，

协商返回egress方法的行为特征与绕行返回方法类似（更多细节请参考5.2.7节）。

普通GRE返回

普通GRE返回egress方法通过在WCCP路由上手动配置的GRE隧道将包返回至最初的拦截路由上，与协商GRE返回方法不同，普通GRE返回被设计成允许在C7600路由以及Cat6K交换机（配备32/720监控器）等硬件上完成包处理（硬件加速设备），因此克服了利用软件完成包处理而带来高负载CPU的弊端。

除了确保网络路径的共用性，普通GRE返回egress方法也不需要单独为WAN优化器配置一个子网，使用普通GRE返回方法，WAN优化器可以被配置在与要优化的客户端及服务端相同的VLAN或子网中。

说明：Cisco WAAS（广域应用服务）设备支持协商返回以及普通GRE返回。

5.2.9 WCCP服务平台选择

本章讨论的焦点是WCCP服务器，它在基于WCCP的WAN优化器配置中非常关键，在不同的环境中选择正确的WCCP服务器是非常基础的任务。当前两类主要的WCCP平台分别是基于硬件的WCCP平台和基于软件的WCCP平台。

基于硬件的WCCP平台通常在性能、可扩展性以及对掩码分配方法的支持方面都相对较优，基于硬件的WCCP平台主要包括：

·Nexus 7000交换机

·ASR 1000路由器

·C7600路由器

·Cat6K Sup32/720交换机

基于软件的WCCP平台一般不适合规模较大的环境或者WCCP路由本身已经处理了大量网络流量的情况。每一平台能支持的最小IOS版本必须依据不同情况就事论事的决定。基于软件的WCCP平台通常支持散列分配方法，其中hashing算法是硬件编码完成，这样的平台主要包括：

·C7200路由器

·集成服务路由（ISR）

说明：本章WCCP服务平台选择一节是与云拦截及私有云计算相对应完成的，这是一个单独的讨论章节，也没有权威的结论。建议读者当评价产品、设计方案或实施商业行为时参考合适的官方文档。

Nexus 7000 WCCP兼容性

Nexus 7000（NX7K）的WCCP兼容性包括以下几方面：

·分配方法：NX7K仅支持掩码分配。

·重定向方法：NX7K支持硬件级别的L2重定向，要求WAN优化器直接连接至Nexus交换机，在本书写作之际，NX7K还不支持GRE重定向方法。

·绕行包返回：NX7K支持硬件级别的WCCP L2返回，不支持WCCP GRE返回。

·包egress：支持IP转发和协商L2返回的egress返回方法，NX7K不支持GRE返回（无论是协商还是普通方式）。

·接口分配：均支持入口和出口重定向，在大多数情况下，为了优化性能，推荐入口重定向方法。

·重定向列表：支持重定向访问控制列表（ACL）。

·支持VRF：NX7K为VRF感知的WCCP提供支持。

NX7K能够在硬件级别支持并实现VRF感知的WCCP，因此对云实施拦截，它是一个理想的WCCP服务平台。NX7K交换机通常位于企业DC的核心/汇聚层，这样，云拦截也将在核心/汇聚层进行。更多细节请参考6.3节。

说明：推荐使用重定向ACL方法（如果系统支持），因为它提供了显式的输入端扇入控制机制，能够将不必要的路由、重定向以及包处理降至最低。

C7600/Cat6K Sup32/720 WCCP兼容性

C7600/Cat6K Sup32/720 WCCP的兼容性包括以下几方面：

·分配方法：C7600/Cat6K Sup32/720同时支持散列和掩码分配。为了优化性能，只要有可能就应该使用掩码分配方法。

·重定向方法：C7600/Cat6K Sup32/720支持硬件级别的L2重定向以及软件级别的GRE重定向，推荐使用硬件级的L2重定向。

·绕行包返回：C7600/Cat6K Sup32/720支持硬件级别的WCCP L2返回，不支持WCCP GRE返回。

·包egress：C7600/Cat6K Sup32/720支持IP转发和协商返回以及普通GRE返回。通常不推荐IP转发，因为它无法在冗余的WCCP配置环境中保证网络路径共用性。如果绕行包返回方法是L2，那么也推荐使用协商L2返回方法，否则推荐使用普通GRE返回方法。

·接口分配：均支持入口和出口重定向。

·重定向列表：支持重定向访问控制列表（ACL）。

在撰写本书的时候，C7600的IOS 12.2（33）SRE支持VRF感知的WCCP。C7600路由通常部署在企业DC的WAN边缘/对等层，因此云拦截也一般放在WAN边缘/对等层完成。Cat6K平台

通常部署在汇聚/服务汇聚层交换机，此时，云拦截要么在汇聚层完成，要么在服务汇聚层完成。

就云拦截而言，现有平台的IOS最大的问题是缺乏对VRF感知的WCCP的支持。幸好这一缺陷能够通过使用非VRF方案（not-so-VRF,NSV）克服，更多细节请参考第6章的相关内容。

说明：Cat6K对硬件GRE重定向的支持可以通过Sup720协议特征卡3（Policy Feature Card 3，PFC3）完成。

说明：普通GRE返回在C7600以及Cat6K Sup32/720交换机的硬件上进行包处理。

说明：在“ip wccp < SG > ”全局命令中包含“accelerated”关键字后能够在Cat6K Sup32/720平台上强化L2重定向以及掩码分配方法。

说明：C7600/Cat6K的重定向清单应该是直接转发扩展的ACL，不带端口范围、DSCP匹配等。

ISR和C7200 WCCP兼容性

ISR和C7200 WCCP兼容性包括以下几方面：

·分配方法：在IOS 12.4（20）T.之前，ISR和C7200仅支持hash掩码分配，IOS 12.4（20）T.开始支持掩码分配方法。

·重定向方法：在IOS 12.4（20）T.之前，ISR和C7200仅支持GRE重定向方法，IOS 12.4（20）T.开始支持L2重定向。

·绕行包返回：在IOS 12.4（20）T.之前，ISR和C7200仅支持WCCP GRE返回，IOS 12.4（20）T.开始支持L2返回。

·包egress：在IOS 12.4（20）T.之前，ISR和C7200仅支持普通GRE返回，IOS 12.4（20）T.开始支持协商L2返回方法。

·接口分配：均支持入口和出口重定向。

·重定向列表：支持重定向访问控制列表（ACL）。

目前，ISR和C7200的IOS 15.x版本支持VRF感知WCCP。为了获得更好的WCCP重定向及返回性能，必须激活Cisco特快交换（Cisco Express Forwarding,CEF）。通常，ISR被当成WAN分支路由部署在远程分支机构（RBO）。

ASR 1000 WCCP兼容性

ASR 1000（ASR1K）WCCP兼容性包括以下几方面：

·分配方法：ASR1K目前仅支持掩码分配。

·重定向方法：ASR1K支持L2重定向以及GRE重定向。

·绕行包返回：ASR1K同时支持L2及GRE返回方法。

·包egress：ASR1K支持IP转发及协商返回。

·接口分配：ASR1K仅支持入口重定向。

·重定向列表：支持重定向访问控制列表（ACLs）

在本书写作之时，ASR1K的IOS-XE 3.0.1S版本支持VRF感知WCCP。通常ASR路由被部署在企业DC的边缘/对等层。此时，云拦截在WAN的边缘/对等层完成。

说明：ASR1K在其IOS-XE版本中引入了WCCP可变计时器功能，RFC草稿中并未定义WCCP可变计时器功能，它属于WCCPv2增强特征。可变计时器是用于改善（缩短）现有错误恢复时间（3×10秒），WCCP可变计时器默认激活，这将使得那些不支持这一新生功能的WAN优化器（WCCP客户端）在注册时产生问题，可以使用“no ip wccp variable-timers”（隐藏）命令关掉ASR1K路由的WCCP可变计时器功能。

5.2.10 WCCP方案样例

现在我们该来探讨在下列环境中的一些WCCP DC方案了：

·核心层

·WAN边缘/对等层

·汇聚/服务分布层

核心层：样例1

DC核心层位于汇聚层与WAN边缘/对等层中间，通常情况下是部署WCCP的理想场所。DC核心层通常是L3层方案的起点与L2层的终点。如图5-7所示，WAN优化器（1～4）与SW1和SW2间建立了L2邻接，并物理地连接到常规的子网/VLAN的两个交换机上。

此时，WAN优化器1和2至SW1间的连接为主线路，而WAN优化器1和2至SW2间的连接为从线路。另一方面，WAN优化器3和4至SW2间的连接为主线路，而WAN优化器3和4至SW1间的连接则为从线路。这样，来自链路1、3、5、7的待优化网络流将被重定向至WAN优化器1和2，而来自链路2、4、6、8的待优化网络流将被重定向至WAN优化器3和4，保证了N+1冗余。在SW1和SW2间的内核连接（例如链路9）不能部署WCCP。

说明：在样例1中，N+1冗余隐含了当一个WAN优化器出错时，只有另外一个WAN优化器来替换它。例如，当WAN优化器1发生故障时，将由WAN优化器2替换它。但如果1和2两个优化器同时产生故障，就没有多余的冗余（或备份）优化器可以顶替它们了。

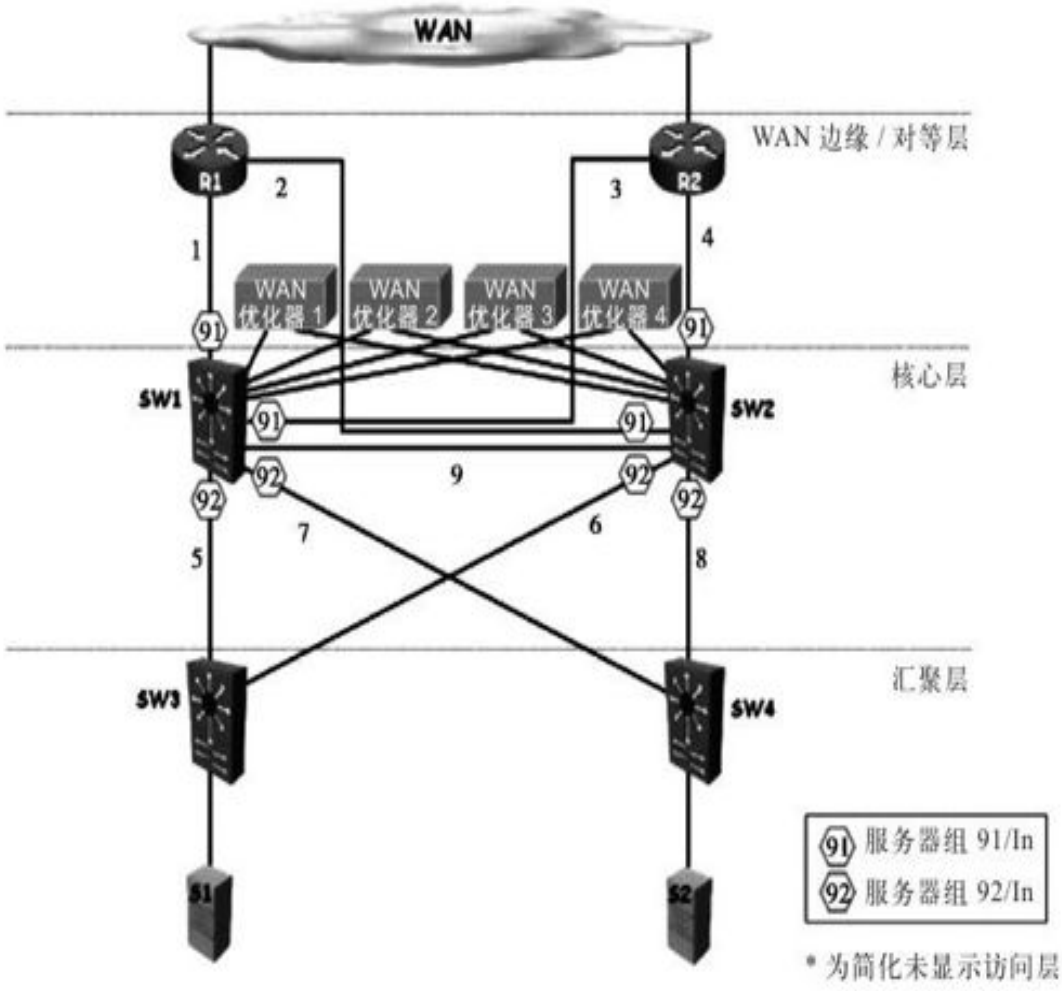


图　5-7　核心层L2　WCCP部署

说明：使用Riverbed Steelhead设备可以实现多接口WCCP，此时，WAN优化器（例如，Steelhead设备）上的链路都被当成主链路，形成了N+N冗余。

假设SW1和SW2是基于硬件平台（例如，C7600或Cat6K）实现的，则可支持的WCCP功能包括：

·注册：由于WCCP优化器与SW1和SW2建立了L2邻接，相应的WCCP路由ID就必须是直接连接至SW1和SW2的接口的IP地址。

·分配：出于性能优化考虑，推荐使用掩码分配。

·重定向：实现了L2重定向方法。

·WCCP SG 91入口重定向，源IP地址应用在SW1上的链路1和3，同时SW2的链路2和4则用于WAN-至-LAN的网络流重定向。

·WCCP SG 92入口重定向，目标IP地址应用在SW1上的链路5和7，同时SW2的链路6和8则用于LAN至WAN的网络流重定向。

·换句话说，为了实现图5-7核心层的所有拓扑路径，每一方向（例如WAN至LAN及LAN至WAN）都要求实现四端拦截（Four-Point-of-Interception,POI）。

·由于SG 91实现源IP地址负载平衡，而SG 92实现目标地址负载平衡，在WAN至LAN及LAN至WAN间的会话在优化时将返回至同一WAN优化器。

·返回：实现了L2返回方法。

·Egress：支持IP转发、协商L2返回及普通GRE返回。

说明：WCCP SG定义中的定位及定向是方案设计时需考虑的关键因素。

说明：尽管类似C7600/Cat6K这类基于硬件的平台支持协商返回及普通GRE返回，但为了保证能够利用这些egress方法，要求相应的WAN优化器也必须同时支持以上方法。

核心层：样例2

样例2与样例1分享了同样的网络拓扑，差别在于：WAN优化器（1～4）间与SW1和SW2间都建立了L3邻接。如图5-8所示，WAN优化器1和2分别通过指定的子网/VLAN连接至SW1，同样，WAN优化器3和4分别通过指定的子网/VLAN连接至SW2。

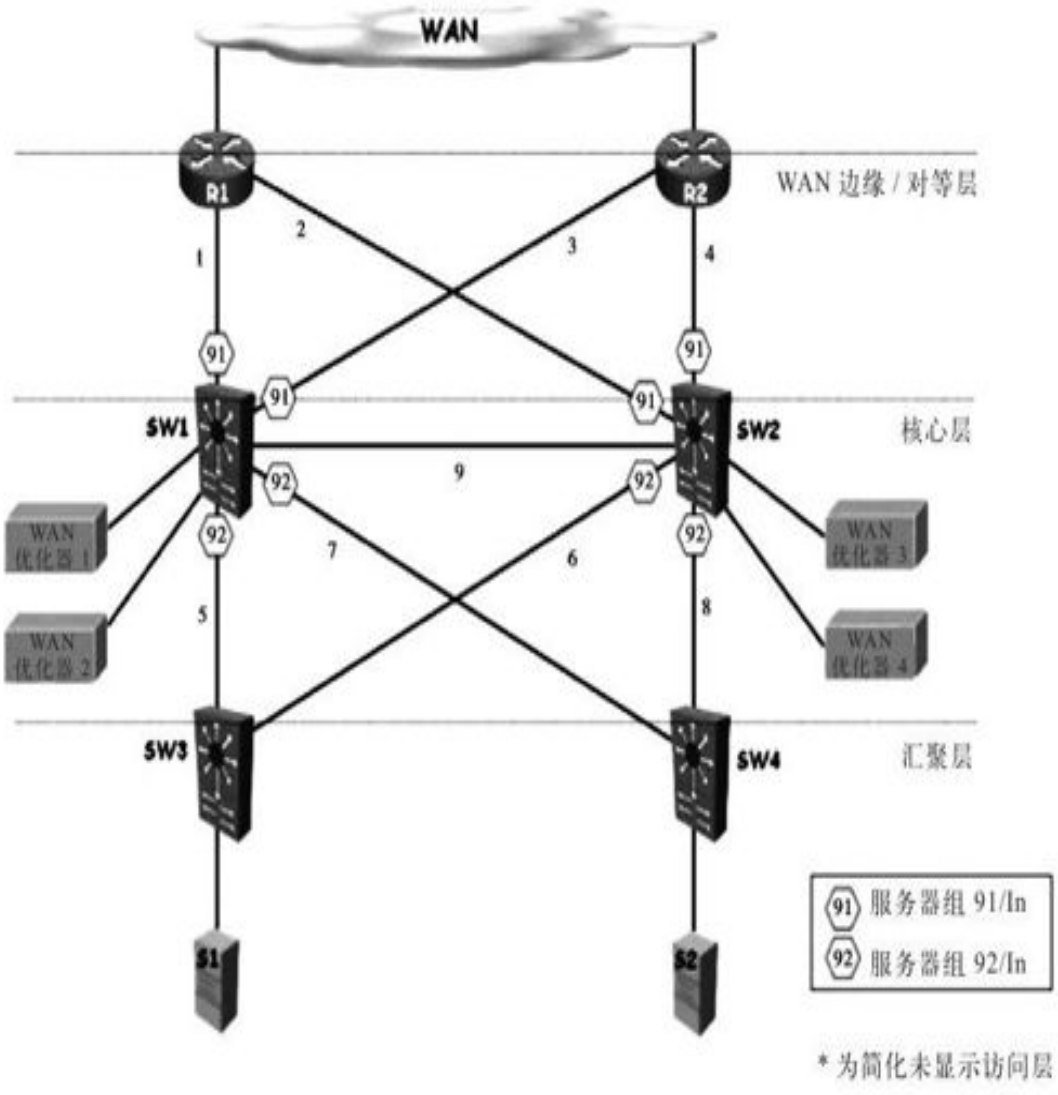


图　5-8　核心层L3 WCCP部署

本例中没有备份WAN优化器，每个WAN优化器的链路都是主链路。尽管WAN优化器1～4属于不同的子网，但它们组成了一个逻辑WCCP簇，实现了N+N冗余。这时，来自链路1到8的网络传输流将依据WCCP分配机制被重定向至WAN优化器1～4。在SW1和SW2间的内核连接（例如链路9）不能部署WCCP。

说明：在样例2中，N+N冗余意味着当一个WAN优化器发生故障时，同一SG内的其他任意WAN优化器都可以替换掉故障优化器。例如，当WAN优化器1出错时，可以由WAN优化器2替代它，而当WAN优化器1和2都出故障时，则可以由WAN优化器3或4来代替它们。

假设SW1和SW2仍然是基于硬件的平台（例如C7600/Cat6K），则可支持的WCCP功能包括：

·注册：由于WCCP优化器与SW1和SW2建立了L3邻接，相应的WCCP路由ID就必须是各交换机中loopback最大的IP地址。

·分配：出于性能优化考虑，推荐使用掩码分配。

·重定向：由于WAN优化器（1～4）和WCCP服务器（SW1和SW2）间建立了L3邻接，所以支持普通GRE重定向方法。WCCP端点拦截（POI）和SG配置与样例1相同。

·返回：实现了GRE返回方法。

·Egress：IP转发或普通GRE转发。

WAN边缘/对等层：样例3

样例3是由样例2直接变化而来。如图5-9示意的那样，WCCP POIs和SG配置是唯一需要更改的地方。此时，它们在DC WAN边缘/对等层的R1和R2完成。在本例中，WAN优化器（1～4）均与R1和R2建立了L3邻接。

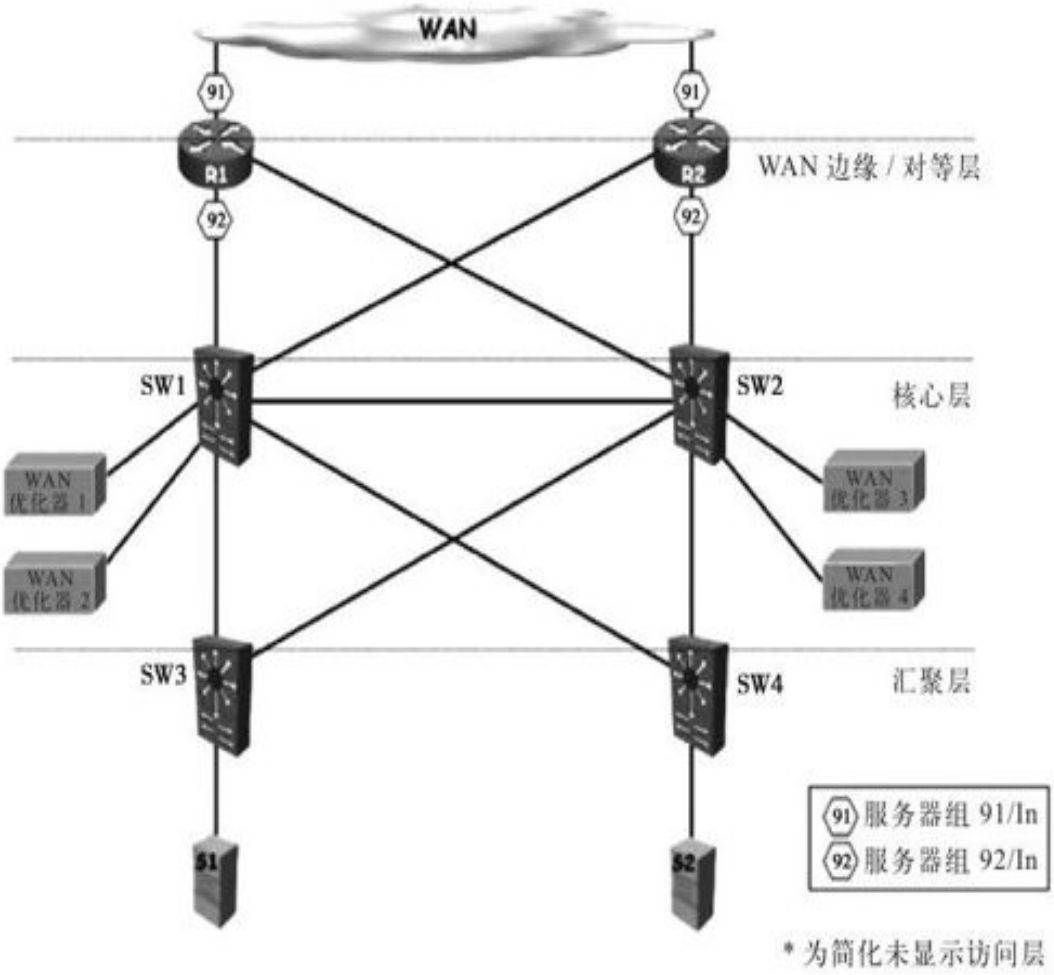


图　5-9　WAN边缘/对等层L3　WCCP部署

由于WCCP在所有WAN边缘/对等层实现，为了覆盖拓扑中的所有路径，与前述样例需要4个POI相比，每一方向只需要两个POI（例如，WAN到LAN及LAN到WAN）。

假设R1和R2是基于硬件实现平台（比方说C7600/ASR1K），可支持的WCCP功能包括：

·注册：由于WCCP优化器与R1和R2建立了L3邻接，相应的WCCP路由ID就必须是各路由器中loopback最大IP地址。

·分配：推荐使用掩码分配。

·重定向：由于WAN优化器（1～4）和WCCP服务器（R1和R2）间建立了L3邻接，因此支持普通GRE重定向方法。

·返回：实现了GRE返回方法。

·Egress：IP转发或普通GRE转发（如果是ASR1K则支持协商方法）。

说明：基于硬件的平台（ASR1K或C7600）倾向于在WAN边缘/对等层使用软件路由（例如C7200），如果使用了软件路由，就必须考虑WCCP性能对这些路由的影响。

两个数据中心间的WCCP部署：样例4

与只有单个DC不同，样例4更进一步，它探讨的是如何在两个DC间部署WCCP。如图5-10所示，系统中有两个DC：DC#1和DC#2，每个DC均拥有各自一个WAN边缘/对等层路由，两个核心层交换机以及两个汇聚/服务分布层交换机。

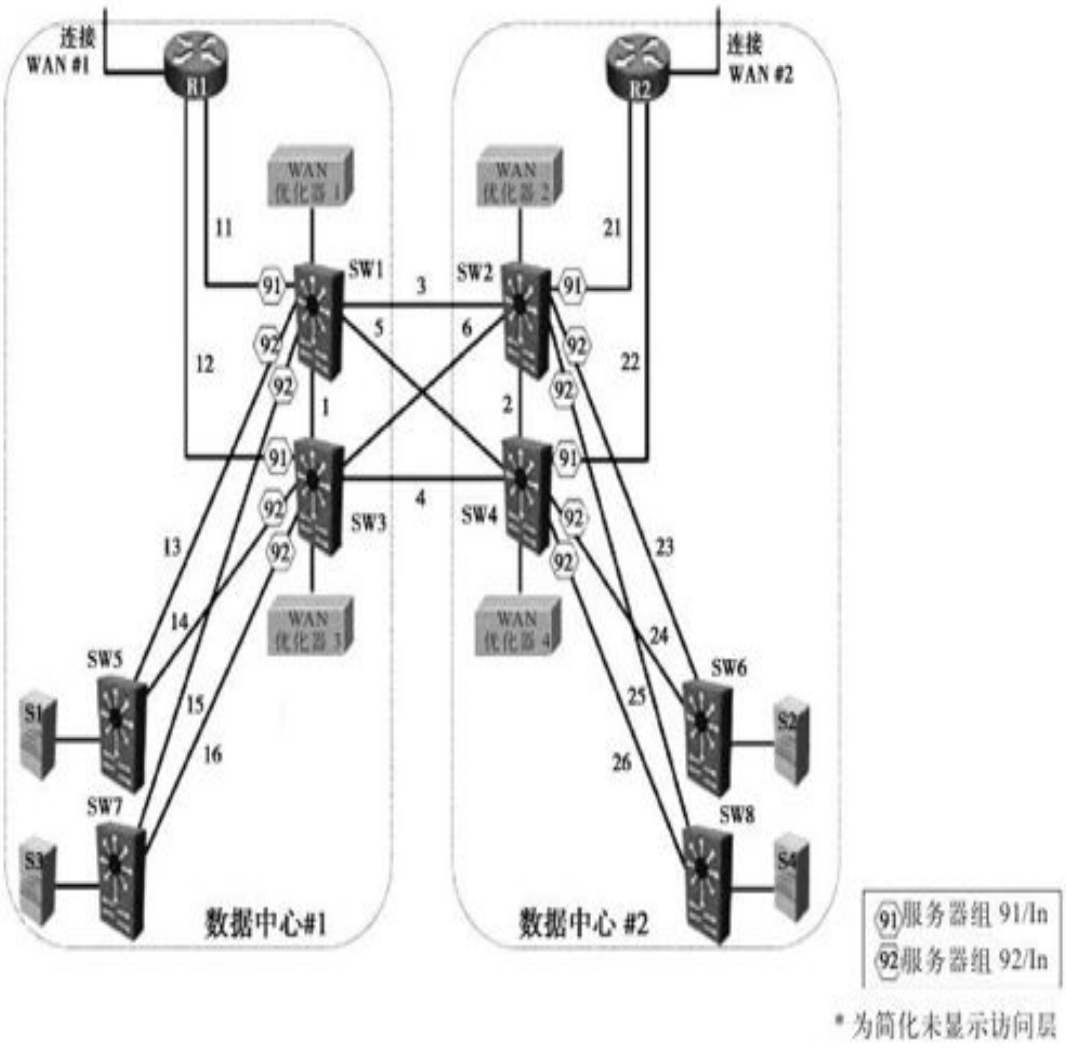


图　5-10　两个DC间核心层WCCP部署

在DC#1内，SW1和SW3属于核心层路由，通过链路11和12连至WAN边缘/对等层路由R1。WAN优化器1则通过指定子网/VLAN本地连接至SW1。同样，WAN优化器3过指定子网/VLAN本地连接至SW3。SW5和SW7属于汇聚/服务分布层交

换机。SW5通过链路13和14连接至SW1和SW2，而SW7通过链路15和16连接至SW1和SW2。服务器S1连接至SW5，服务器3连接至SW7。S1和S3构建了DC#1的服务器组。

在DC#2内，SW2和SW4属于核心层路由，通过链路21和22连至WAN边缘/对等层路由R2。WAN优化器2则通过指定子网/VLAN本地连接至SW2。同样，WAN优化器4过指定子网/VLAN本地连接至SW4。SW6和SW8属于汇聚/服务分布层交换机。SW6通过链路23和24连接至SW2和SW4，而SW8通过链路25和26连接至SW2和SW4。服务器S2连接至SW8，服务器4连接至SW8。S2和S4构建了DC#1的服务器组。

在SW1到SW4上均实现了WCCP端点拦截（Point-of-Interception,POI）及SG配置。WAN优化器（1～4）与SW1到SW4间建立了L3邻接。尽管WAN优化器1和3位于与WAN优化器2和4不同的DC站点上，但WAN优化器1到WAN优化器4组成了一个逻辑WCCP簇，实现了N+N冗余。来自链路11到16及链路21到26的待优化网络流依据WCCP分配方法被重定向到WAN优化器1到4处，在4个核心层交换机（SW1到SW4）间的混合连接（链路1～6）是不能部署WCCP的。

说明：WCCP在WAN优化器与两个DC的核心层交换机间交叉注册有助于预防可能引起异步路由的问题。

两个数据中心间的WCCP部署：样例5

样例5的网络拓扑直接改自样例4，如图5-11所示，WCCP POI向下移到了服务器组边缘，WCCP SG的配置在汇聚/服务分布层的SW5到SW8完成，实现了所有面向WAN及面向服务的链路。

在DC#1，WAN优化器1通过特定子网/VLAN本地连接至SW5，类似地，WAN优化器3通过特定子网/VLAN本地连接至SW7。在DC#2，WAN优化器2通过特定子网/VLAN本地连接至SW6，类似地，WAN优化器4通过特定子网/VLAN本地连接至SW8。

WAN优化器（1～4）与SW5到SW8建立了L3邻接，这样，WAN优化器1到4组成了一个逻辑WCCP簇，实现了N+N冗余。为了覆盖所有汇聚/服务分布层的网络传输路径，在WAN至LAN方向需要8个POI，在LAN至WAN方向需要4个POI。

说明：在汇聚/服务分布层实现WAN优化器及WCCP POI是另一种解决非对称路由问题的方法。

说明：Riverbed Steelhead设备的连接转发功能也可以缓和非对称路由问题。

假设SW5到SW8是基于硬件平台实现（例如C7600/Cat6K），可支持的WCCP功能包括：

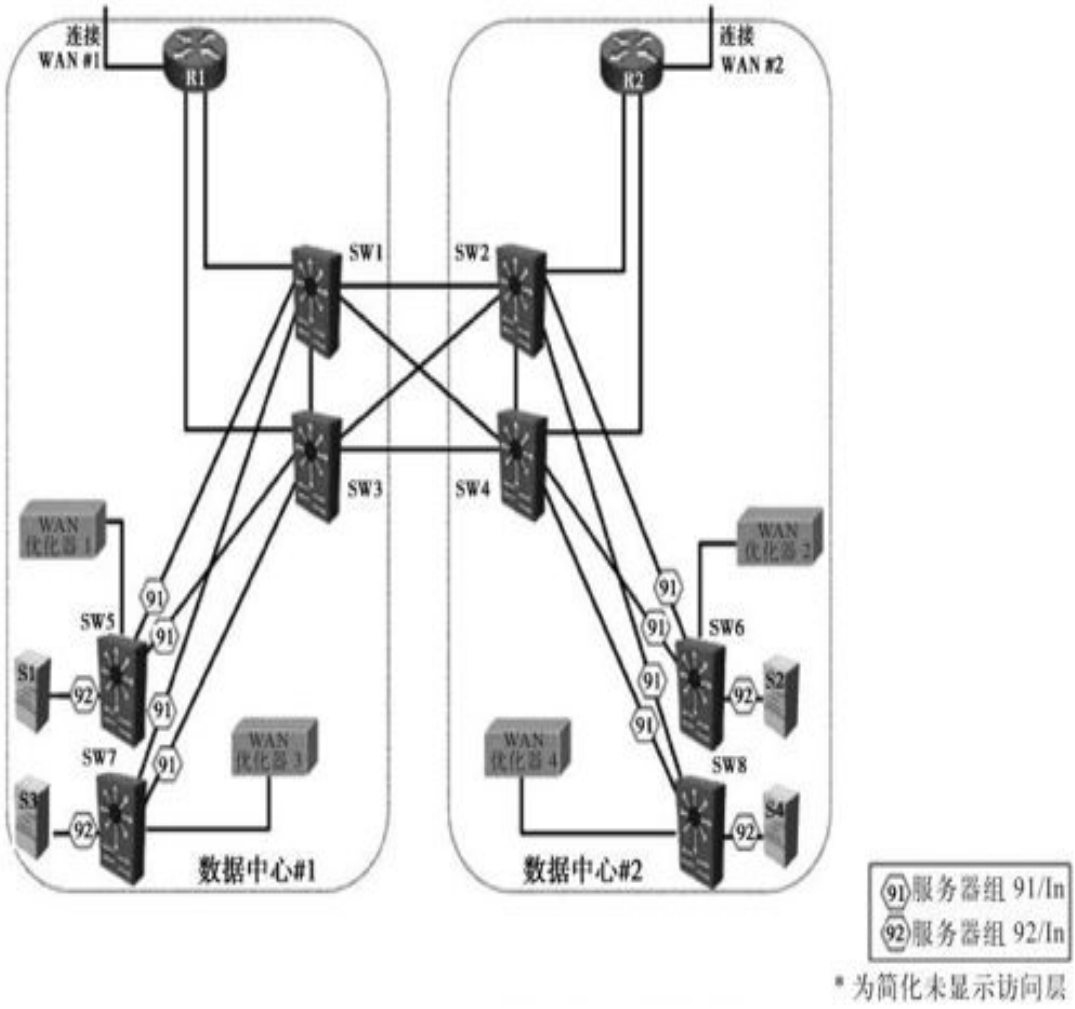


图　5-11　服务分布层的WCCP部署

·注册：由于WCCP优化器（1～4）与汇聚/服务分布层交换机（SW5到SW8）建立了L3邻接，相应的WCCP路由ID就必须是各路由器中loopback最大IP地址。

·分配：推荐使用掩码分配。

·重定向：由于WAN优化器（1～4）和WCCP服务器（SW5到SW8）间只建立了L3邻接，所以支持普通GRE重定向方法。

·返回：实现了GRE返回方法。

·Egress：IP转发或普通GRE转发。

5.2.11 WCCP配置样例

图5-12探讨了两个DC（DC-30和DC-31）间简化和缩小的WCCP部署案例：R30和R31作为WAN和MAN路由，分支机构到DC（BO-to-DC）以及DC分支机构（DC-to-BO）网络传输通过WAN完成，而DC内部网络传输通过MAN链路完成。MAN链路唯一要为BO-to-DC以及DC-to-BO网络传输服务的时候是任意一个DC WAN链路发生故障时。

每个DC的应用不同：DC-31运行文件备份（File backup,FTP），DC-31运行web应用程序（HTTP）。来自远程分支机构RBO-32的FTP流送至SERVER-31（10.3.38.31），来自远程分支机构RBO-32的HTTP流送至SERVER-30（10.3.39.30），WAN优化器将分别对在RBO-32和相应DC间的应用流进行优化。WAN优化器30通过特定子网/VLAN本地连接至R30，而WAN优化器31通过特定子网/VLAN本地连接至R31。

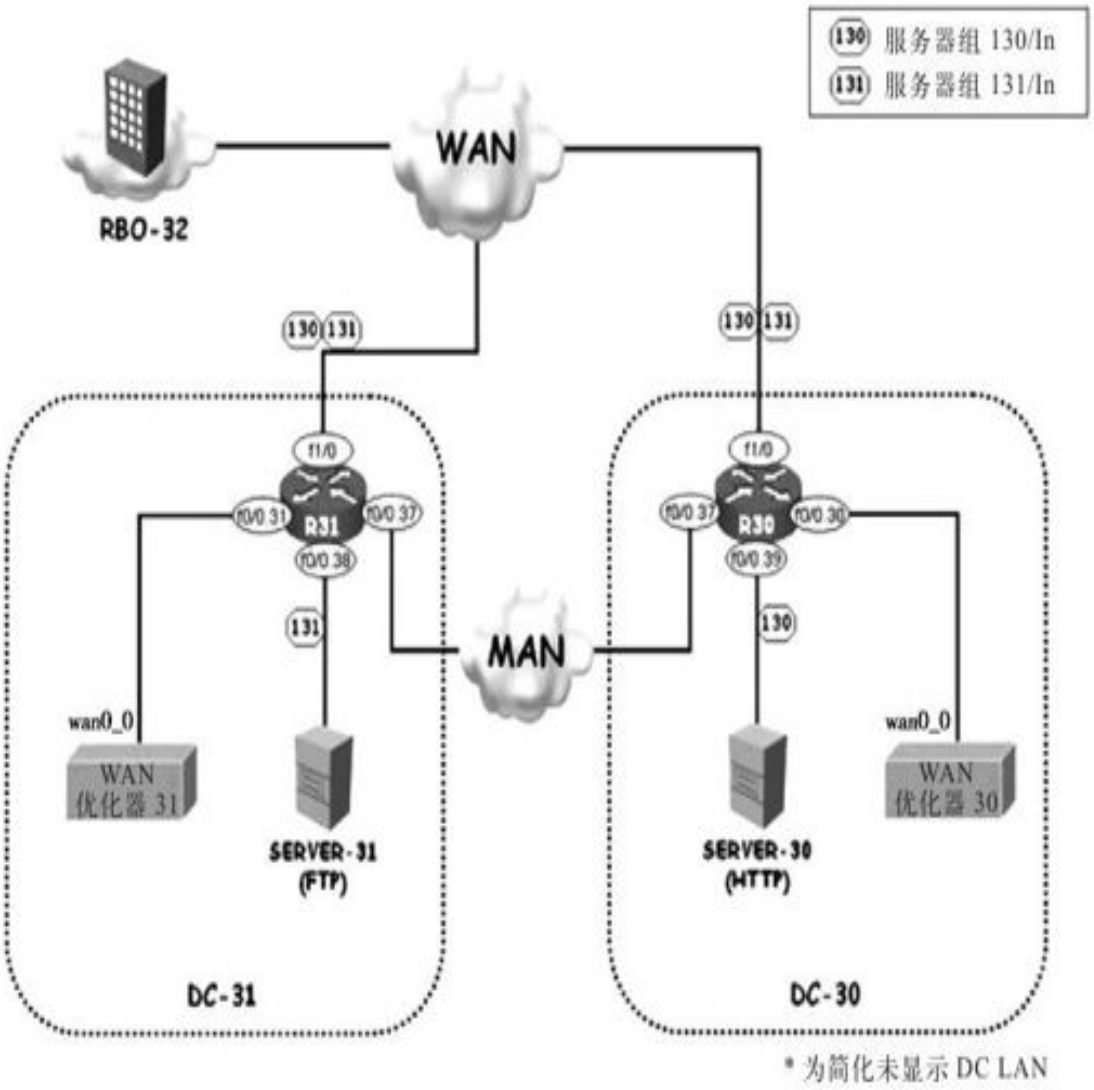


图　5-12　WAN边缘DC间的WCCP部署

WAN优化采取就近优先原则，即每一个WAN优化器都将为离它最近的应用服务器服务。因此，WAN优化器30为SERVER-30提供服务，而WAN优化器31则为SERVER-31提供服务。远程终端的WAN优化器通过MAN链路实现了冗余备份，换句话说，WAN优化器30是SERVER-31（FTP）的优化器31的备份，而相应的WAN优化器31则是SERVER-30（web服务）的优化器30的备份。

在本例中，R30和R31都是软件路由，IOS版本为12.4（15）T9。所支持的WCCP功能包括：

·注册：WAN优化器（30和31）与WAN边缘路由（R30和R31）建立了L3邻接，相应的WCCP路由ID就必须是各路由器中loopback最大IP地址。

·分配：使用散列分配，因为软件路由上的IOS版本为12.4（15）T9仅支持这一种特定分配方法。

·重定向：由于WAN优化器（30和31）与WCCP服务器（R30和R31）只建立了L3邻接，因此支持普通GRE重定向方法。

·WCCP HA冗余可以通过使用两个SG实现，每个SG的分配权重不同。

本例在源和目的IP地址分配均使用了散列分配方法，因此WAN至LAN和LAN至WAN方向均可以使用同样的WCCP SG。WAN优化器（30和31）均定义了SG 130和SG 131，WCCP SG 130用来为DC-30的网络流实现重定向，而WCCP SG 131则用来为DC-31的网络流实现重定向。

·WAN优化器30是DC-30的主优化器、DC-31的从优化器，可以给SG 130和SG 131分配不同的权重以实现这样的HA配置。样例中，给SG 130分配了100的权重（主），给SG 131分配了0的权重（从）。

·WAN优化器31是DC-31的主优化器、DC-30的从优化器，可以给SG 130和SG 131分配不同的权重以实现这样的HA配置。在样例中，给SG 130分配了0的权重（从），给SG 131分配了100的权重（主）。

·在DC-30的R30中，f1/0接口负责WCCP SG 130入口重定向，能够完成WAN至LAN的HTTP网络流重定向，而f0/0.39接口负责将LAN至WAN的HTTP网络流重定向至WAN优化器30的工作。如果DC-31的WAN链路出现故障，则WCCP SG 131入口重定向在其f1/0接口进行，负责将WAN至LAN的FTP网络流重定向至WAN优化器31。

·在DC-31的R31中，f1/0接口负责WCCP SG 130入口重定向，能够完成WAN至LAN的FTP网络流重定向，而f0/0.38接口负责将LAN至WAN的FTP网络流重定向至WAN优化器31的工作。此外，如果DC-30的WAN链路出现故障，则WCCP SG 130入口重定向在其f1/0接口进行，负责将WAN至LAN的HTTP网络流重定向至WAN优化器30。

·为了覆盖如图5-12所示的所有WAN边缘的网络路径，每一方向（例如，WAN至LAN及LAN至WAN）都要求一个POI（不

考虑从POI）。

·鉴于SG 130和SG131都是基于源及目的IP hash来实施负载平衡，相同的WAN至LAN及LAN至WAN TCP会话在优化时会返回到相同的WAN优化器。

·MAN必须是DC内部网络传输的最佳路径，在R30和R31中间，不能实施WCCP重定向。

·返回：实现了GRE返回方法。

·Egress：IP转发或普通GRE转发

说明：在本例中，SG 130和SG 131的WCCP优先级都被设置成250。

说明：在本例中部署的WAN优化器是Riverbed Steelhead设备（RiOS 5.x）。

WCCP客户端配置

代码清单5.1解释了WAN优化器30的WCCP配置（例如，Riverbed Steelhead设备）。为了方便将WAN优化器30设置为DC-30的主WAN优化器及DC-31的从WAN优化器，将WCCP SG 130的分配权重设为了100，而将SG 131的分配权重设置成0。

两个SG的优先级同为250。encap-scheme（重定向）设成“either”，这意味着WAN优化器30可以同时支持GRE及L2转发方法。类似地，assign scheme也被设置成“either”，同样意味着WAN优化器30能够支持hash及掩码两种分配方法。由于WCCP服务器是基于软件平台实现的，GRE重定向及hash分配将称为最终协商结果。

hash分配是基于源及目的IP的hash，因此一个SG可以同时应用在WAN到LAN及LAN到WAN方向。在考虑WCCP注册问题时，在WAN优化器30与拥有最大loopback的IP地址（WCCP路由ID）的WAN边缘路由（R30及R31）间建立了L3邻接，此时R30和R31的loopback IP地址分别为10.3.0.3以及10.3.0.1。

代码清单5.1　WAN优化器30的WCCP配置

```
## Network interface configuration
##
  interface inpath0_0 ip address 10.3.30.101 /24


##
## Routing configuration
##
  ip in-path-gateway inpath0_0 "10.3.30.3"


##
## Other IP configuration
##
  hostname "WANOPTIMIZER30"


##
## WCCP Service Groups
##
  wccp service-group 130 protocol tcp weight 100 encap-scheme either priority 250
flags dst-ip-hash,src-ip-hash routers 10.3.0.1,10.3.0.3 assign-scheme either
  wccp service-group 131 protocol tcp weight 0 encap-scheme either priority 250 flags
dst-ip-hash,src-ip-hash routers 10.3.0.1,10.3.0.3 assign-scheme either


##
## General Service
##
  in-path enable
  in-path module wccp-adjust-mss enable
  in-path oop enable
  wccp enable
```

说明：不要使用一个虚拟网关地址（来自HSRP、VRRP或GLBP）作为WCCP路由ID。

说明：“in-path module wccp-adjust-mss enable”命令可以在WCCP操作中，为Riverbed Steelhead设备调节正确的Mss尺寸，以避免当选择WCCP GRE重定向及返回方法时因包尺寸过大，产生不必要的包分段或丢包操作。

说明：Riverbed Steelhead设备允许对ICMP消息的WCCP重定向操作，以支持路径MTU发现（Path MTU Discovery,PMTUD）。

说明：PMTUD使用类型3的ICMP，子类型为4（需要分段及DF集）用来标记，它与在扩展ACLs上定义的“packet-too-big”ICMP消息等价。

代码清单5.2说明了WAN优化器31（例如Riverbed Steelhead）的WCCP配置。为了确保WAN优化器31设置为DC-30的从WAN优化器及DC-31的主WAN优化器，将WCCP SG 130的分配权重设成0，而将SG 131的分配权重设置成100，其余的WCCP配置工作于代码清单5.1类似。

代码清单5.2　WAN优化器31的WCCP配置

```
## Network interface configuration
##
  interface inpath0_0 ip address 10.3.31.101 /24


##
## Routing configuration
##
  ip in-path-gateway inpath0_0 "10.3.31.1"


##
## Other IP configuration
##
  hostname "WANOPTIMIZER31"


##
## WCCP Service Groups
##
  wccp service-group 130 protocol tcp weight 0 encap-scheme either 250 flags dst-ip-
hash,src-ip-hash routers 10.3.0.1,10.3.0.3 assign-scheme either
  wccp service-group 131 protocol tcp weight 100 encap-scheme either priority 250
flags dst-ip-hash,src-ip-hash routers 10.3.0.1,10.3.0.3 assign-scheme either
##
## General Service
##
  in-path enable
  in-path module wccp-adjust-mss enable
  in-path oop enable
  wccp enable
```

WCCP服务端配置

代码清单5.3说明了WCCP服务器R30的配置。WCCP路由ID为10.3.0.3，Loopback为0。WCCP SG 130负责完成来自远程分支机构RBO-32的CLIENT-32（10.3.32.99）至DC-30上的SERVER-30（10.3.39.30）的TCP网络传输重定向，同时还负责将SERVER-30的网络传输流返回至CLIENT-32。SG 130的WCCP POIs是快速以太网0/0.39及快速以太网1/0，SG 131负责当DC-31的WAN链路出现故障时，将CLIENT-32的TCP传输重定向至SERVER-31，SG 131的WCCP POI是快速以太网0/0.39及快速以太网1/0。

代码清单5.3　R30的WCCP配置

```
!
hostname R30
!
!
ip wccp check services all
ip wccp 130 redirect-list 130
ip wccp 131 redirect-list 131
!
!
interface Loopback0
 ip address 10.3.0.3 255.255.255.255
!
!
interface FastEthernet0/0.30
 encapsulation dot1Q 30
 ip address 10.3.30.3 255.255.255.0
!
!
interface FastEthernet0/0.37
 encapsulation dot1Q 37
 ip address 10.3.37.3 255.255.255.0
!
interface FastEthernet0/0.39
 encapsulation dot1Q 39
 ip address 10.3.39.3 255.255.255.0
 ip wccp 130 redirect in
!
interface FastEthernet1/0
 ip address 10.254.3.3 255.255.255.0
 ip wccp 130 redirect in
 ip wccp 131 redirect in
!
!
access-list 130 permit tcp host 10.3.32.99 host 10.3.39.30
access-list 130 permit tcp host 10.3.39.30 host 10.3.32.99
access-list 131 permit tcp host 10.3.32.99 host 10.3.38.31
!
```

说明：当接口中存在多个WCCP SG的配置时，将按SG的优先级来选择（Cat6K不适合此方法）直到某个SG的优先级与IP

包匹配成功。如果某个SG匹配上某个包，并且也配置了一个重定向ACL，则IP包再次检查重定向ACL，如果ACL拒绝包，该包将不会被传递到低优先级SG以进行更多的匹配，除非配置了“ip wccp check service all”命令，WCCP就会继续将该包与接口中剩余的低优先级SG进行匹配。

代码清单5.4说明了R31上的WCCP配置，此时WCCP路由ID为10.3.0.1，loopback为0。WCCP SG 131负责完成来自CLIENT-32（10.3.32.99）至DC-31上的SERVER-31（10.3.38.31）的TCP网络传输重定向，同时还负责将SERVER-31的网络传输流返回至CLIENT-32。SG 130的WCCP POIs是快速以太网0/0.38及快速以太网1/0，SG 130负责当DC-30的WAN链路出现故障时，将CLIENT-32的TCP传输重定向至SERVER-30，SG 130的WCCP POI是快速以太网0/0.39及快速以太网1/0。

代码清单5.4　R31的WCCP配置

```
!
hostname R31
!
!
ip wccp check services all
ip wccp 130 redirect-list 130
ip wccp 131 redirect-list 131
!
!
interface Loopback0
 ip address 10.3.0.1 255.255.255.255
!
!
interface FastEthernet0/0.31
 encapsulation dot1Q 31
 ip address 10.3.31.1 255.255.255.0
!
interface FastEthernet0/0.37
 encapsulation dot1Q 37
 ip address 10.3.37.1 255.255.255.0
!
interface FastEthernet0/0.38
 encapsulation dot1Q 38
 ip address 10.3.38.1 255.255.255.0
 ip wccp 131 redirect in
!
interface FastEthernet1/0
 ip address 10.254.3.1 255.255.255.0
 ip wccp 130 redirect in
 ip wccp 131 redirect in
!


!
access-list 130 permit tcp host 10.3.32.99 host 10.3.39.30
access-list 131 permit tcp host 10.3.32.99 host 10.3.38.31
access-list 131 permit tcp host 10.3.38.31 host 10.3.32.99
!
```

5.3 In-path部署简介

实现in-line WAN优化器部署并覆盖整个DC是一项富有挑战性的工作，仅适合某些而不是全部的DC设计方案。例如考虑到多个POI，无论是物理in-path或in-line部署都必须与实际的物理链路保持一致，才能够以某种特定方式覆盖整个DC的网络拓扑路径。在一个大型冗余DC网络拓扑中，随着链路增加（例如为了实现HA），in-path部署方式将带来可扩展性问题。看起来需要多个WAN优化器，而且这些优化器之间必须能够相互连接。这样的交叉连接（类似主-主防火墙）是必需的，因为在应用层，一台设备只能实现一个链路的合理优化。人们也许会认为in-path部署存在破坏性，因为在部署WAN优化器设备时不得不插入到现有链路的两个端点中间，因此在DC的WAN优化拦截时，通常不会选用in-path部署。

图5-13给出了位于两个站点A和B间的一个非常简单的in-path部署样例。WAN优化器通过诸如交换机和路由（或者防火墙）这样的网络设备在物理上被连接起来，并且具备相应的面向LAN或面向WAN接口。它将检测所有的网络传输并依据优化原则来决定哪些传输需要被优化。此时，拦截将同时在两个方向（例如，WAN至LAN及LAN至WAN）进行，非TCP传输将自动被忽视，而不需要进行优化的TCP传输将依据绕行原则确定是否会被忽略。

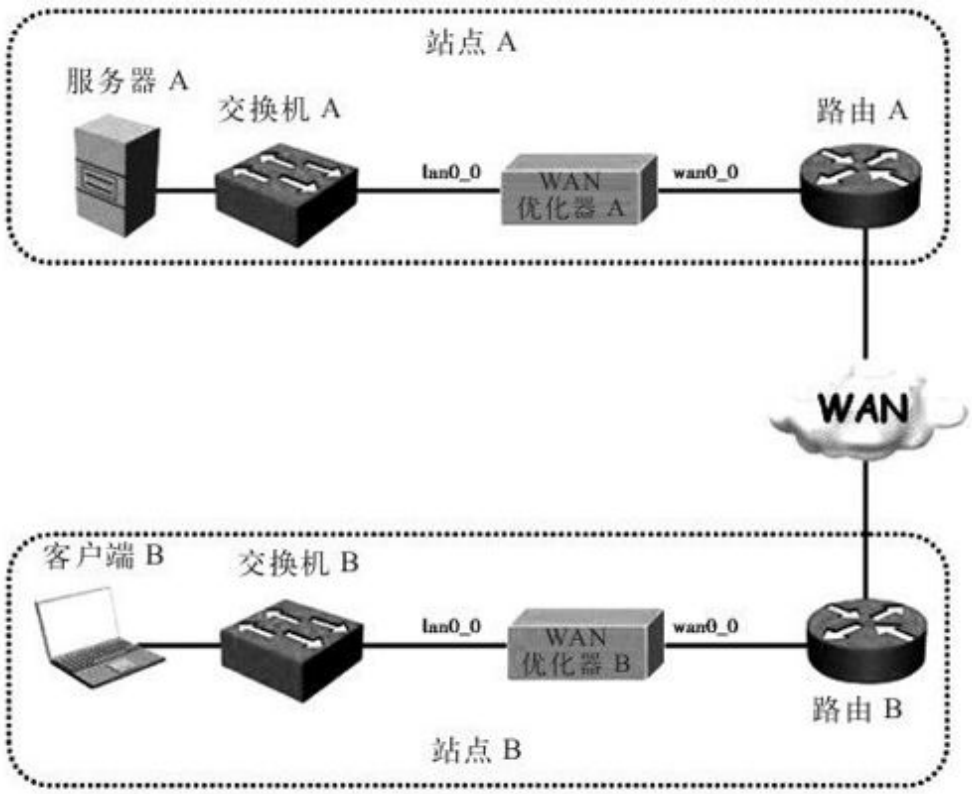


图　5-13　简单的物理in-path部署说明

说明：在物理in-path部署中，所有传输都将经过相应的WAN优化器，没有传输扇入数的控制。

当发生硬件、软件或动力故障时，单个物理in-path WAN优化器将形成单点故障，因此，通常需要为它同时配备一个固定的故障重写机制，以便当这些事件发生时，能够在面向LAN和面向WAN接口之间建立连接。最佳方案是WAN优化器数目能够与并行路由路径相符（例如，冗余WAN路由隐含了冗余的WAN优化器）。故障阻断（fail-to-block，当发现错误时，抛弃故障链路）策略支持单层WAN优化，使得启动交叉连接时，网络传输可以通过另一路径完成。而双层WAN优化则启用了故障告知（file-to-wire）策略，由第二层替代完成优化连接。这些级别的冗余一样要求WAN优化器能够相互连接以便维持优化状态（例如，向某个Riverbed Steelhead设备的转接）。

物理的in-path部署在远程分支机构RBO这样的小型站点上非常普遍，因此局域性DC也可以偶尔选用这一方式。它的优点之一是不需要对in-line网络部件（例如，交换机、路由、防火墙等）做任何改动，也不依赖其他平台的拦截能力。当WCCP不

可用时，物理in-path部署可以作为DC WAN优化器备用拦截方法。

5.4 PBR部署概述

基于策略的路由部署（Policy-Based Routing,PBR）中，WAN优化器通常采用out-of-path方式部署，就像实现WCCP一样。POI在像路由（或L3交换机）这样的in-line网络部件上实现，这些in-line设备还需要支持PBR。配置在拦截路由上的PBR负责监控网络传输，以发现与ACL匹配的网络流，并将这些网络流重定向至WAN优化器以进行优化。此时，WAN优化器位于L3的下一跳。

图5-14给出了DC上，为了实现WAN优化而进行的一个简单的PBR部署样例。WAN优化器101是主优化器，备份优化器是WAN优化器102，每个WAN优化器都通过特定子网本地连接至R1。PBR拦截放在POI A上实现，它是R1的面向WAN的接口，同时，在R1面向LAN的接口POI B和POI C上也实现了PBR拦截。

说明：PBR内部“拦截”方向为入口，换句话说，PBR只能处理通过接口的界内网络传输。

PBR不是DC中WAN优化拦截的首选方案，因为它的可扩展性并不好，不能够很好地处理多个WAN优化器间的负载平衡。与WCCP相比，PBR的配置也很繁琐，因为它实际上并不是一个协议，更像是行政上配置一个静态策略（“路由图”）。当WCCP不可用时，PBR可以作为DC WAN优化拦截的一个备选方案。

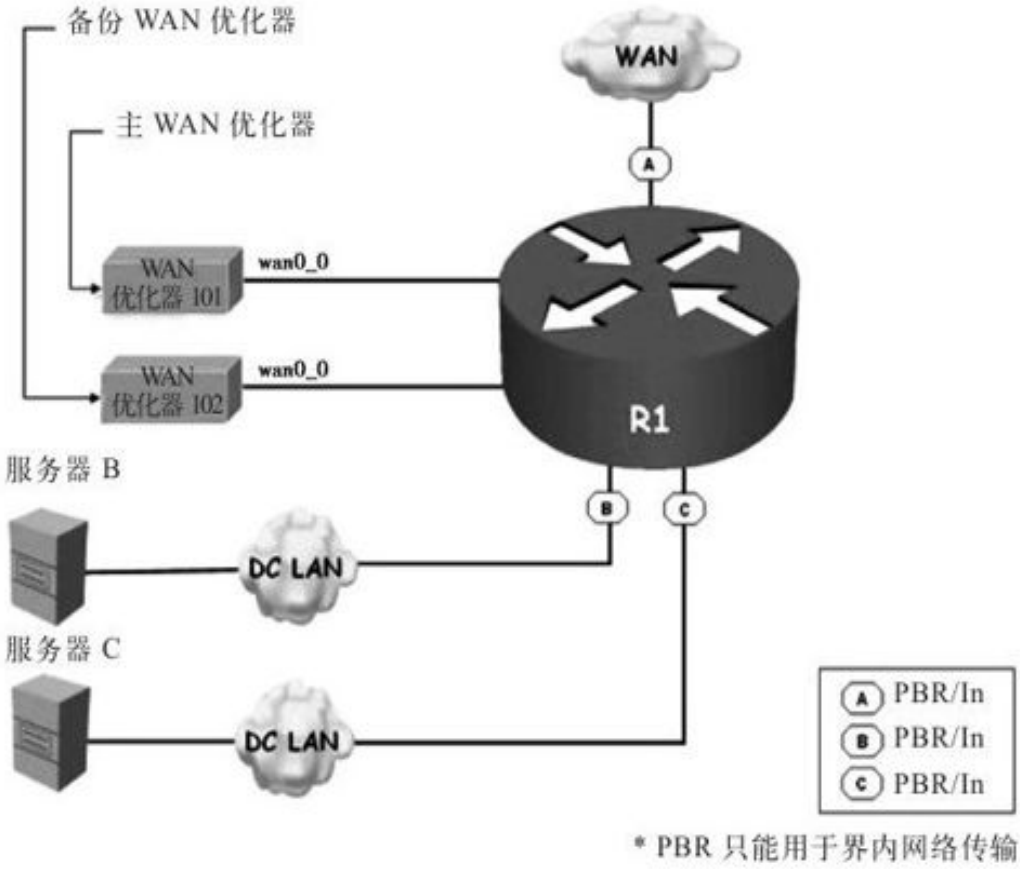


图　5-14　WAN优化中的简单PBR部署

PBR故障

如果定义了下一跳地址，WAN优化器的PBR部署能支持故障处理，下一跳地址与WAN优化器的IP地址相对应，这要求在WAN优化器上实现支持CDP的PBR或者能够具备对象跟踪能力。对象跟踪可以借助IP服务等级协议（Service-Level Agreement,SLA）对组件监控或探测完成，IP SLA探测通过执行活动健康监控保证了首要WAN优化器的活跃性。可以定义一个跟踪对象来追踪相应的IP SLA探测操作，如果该操作失败，首要WAN优化器（例如下一跳）就将被认为应“抛弃”（例如无法提供服务），需要优化的网络传输流就将被重定向至备选WAN优化器。

代码清单5.5描述了一个IP SLA样例以及对象跟踪配置模板。WAN优化器101和102的IP地址分别为10.10.10.101和10.20.20.102，IP SLA 101负责监控WAN优化器101的L3连接状态，同样，IP SLA 102负责监控WAN优化器102的L3连接状态。每5秒钟（频率为5）就会向每个WAN优化器发送一个

ICMP探测消息。为了持续监控，每一个IP SLA监控组件将被调度成持久运行（“forever”）并且是立即启动（“now”）。跟踪对象1（“track 1”）用来跟踪IP SLA 101（“rtr 101”）的操作状态（up/down），跟踪对象2（“track 2”）被用来跟踪IP SLA 102（“rtr 102”）的操作状态（up/down）。

说明：IP SLA默认探测频率为60秒。

代码清单5.5　IP SLA及对象跟踪配置

```
!
ip sla 101
 icmp-echo 10.10.10.101
 frequency 5
ip sla schedule 101 life forever start-time now
!
!
ip sla 102
 icmp-echo 10.20.20.102
 frequency 5
ip sla schedule 102 life forever start-time now
!
!
track 1 rtr 101 reachability
track 2 rtr 102 reachability
!
```

说明：某些IOS版本支持IP SLA操作，它们创建IP SLA操作的大多数方法基本相同，只在导航或创建方式上略有不同。问号（“？”）命令可以帮助发现相关IOS的正确命令，本节中的IP SLA和对象跟踪配置样例运行版本为IOS 12.4（15）T9。

说明：尽管样例中为了简便使用了ICMP探测，当需要监测WAN优化器时，推荐使用TCP探测。TCP探测能够同时监测L3和L4的连接问题，而ICMP探测只能发现L3连接问题。

代码清单5.6给出了一个简单的PBR对象跟踪路由图。路由图中“PBR”与ACL 100允许的网络传输匹配成功（出于简化考虑，代码中没有显示实际的ACL），路由图将与ACL 100匹配的网络传输唯一重定向到第一个可得的下一跳（序号为10），本例中，是WAN优化器的IP地址（10.10.10.101）。如果WAN优化器101的L3连接出现故障，则由ACL 100匹配的网络传输将

被顺序重定向至下一跳（序号为20），例如，WAN优化器102（10.20.20.102）。如果出现两个优化器都故障的情况，由ACL 100匹配的网络传输不会由PBR完成重定向，而是由路由器恢复到普通的基于目标的转发方式。

代码清单5.6　PBR对象跟踪路由图配置

```
!
route-map PBR permit 10
  match ip address 100
  set ip next-hop verify-availability 10.10.10.101 10 track 1
  set ip next-hop verify-availability 10.20.20.102 20 track 2
!
```

说明：因为CPU将为ICMP探测产生ICMP或者跟踪路由包，因此大量的IP SLA会话将会使得CPU激增，可以通过工作区将跟踪间隔设置（频率）成比较长的值，而不是使用像代码清单5.5中5秒那样的频率，读者可能也会将设置恢复到默认的60秒频率。此时，可以使用更慢的监测时间与下一跳故障间取得平衡。

5.5 小结

当设计和部署DC中WAN会话拦截时，必须考虑因素包括硬件平台、定位、可扩展性需求、负载平衡、高可获得性、操作影响以及可操作性。

WCCP是目前最全面的可行拦截解决方案之一，被广泛应用在大多数企业DC内，可以在很多平台上实施WCCP，它提供了很好的负载平衡，故障恢复以及可扩展性，只要具备支持WCCP的网络组件（例如，L3交换机、路由等），就可以在DC的大多数平面网络层实施WCCP，包括：

·WAN边缘/对等层

·核心/汇聚层

·接入层

·服务分布层

从路由器角度来看，物理in-path部署是最复杂性最小的内部拦截机制，但是为了满足DC对可靠性以及更新需求，在配置冗余和可扩展方式时必须要考虑仔细，因为in-path的优势体现在DC之外。有很多配置方法可以为一个小型DC构建一个in-path部署，由于负载平衡等原因，直接的in-path WAN优化器部署并不适合聚簇模式，尽管在实际中有人这样配置。

PBR是另外一种拦截方法。它可以应用在许多平台上，因此在DC定位方面提供了足够的灵活性。由于PBR没有考虑配置的复杂性，缺乏对负载平衡的可扩展性选项，因此推荐任何时候只要有可能都使用WCCP方案，只有当WCCP不可得时，才恢复物理in-path或PBR方案。

下一章（第6章）将从云拦截以及L3 VRF方面更深入讨论WCCP，同时，也从云拦截和网络虚拟化方面，更全面地探讨了应用控制引擎服务模块（Application Control Engine Module,ACESM），一个可扩展性更好的WCCP替代产品。

第6章　私有云上的WAN优化

如果一切尽在掌控之中，说明你迈的步子不够大。

——马里奥·安德烈蒂（Mario Andretti）

简介

在第4章我们探讨了WAN优化的必要性及优势，第5章则着重研究如何为企业DC寻找基于标准设备集成的WAN优化方案，然而，目前云部署已经从设备模式快速进化到虚拟私有云模式。私有云通常以在企业DC上协同定位为前提实施，而虚拟私有云可以由云服务供应商实施，使得企业能够以按需可调的方式扩展资源，但也因此产生了更多的延迟，更进一步增加了对WAN优化的需求。

说明：虚拟私有云是指位于共享或公共云内的私有云（例如云际云）。该术语源自大家都比较熟悉的虚拟私有网络（Virtual Private Network,VPN）概念，并被云计算领域所转用。

WAN优化消除了时延对WAN应用性能的不利影响，因而显然对用户私有云非常有价值，但如果将WAN优化作为云基础设施的一部分，私有和虚拟私有云服务供应商现在已经能够提供增值的云优化应用服务（例如，云IaaS），如果还能够再进一步消除WAN瓶颈对用户带来的麻烦，那么将更好地提升云服务的价值。在云计算中，WAN优化比之前具有更加重要的战略地位，因为它加速了云技术的应用。现在WAN优化已经成为基于云的服务发布体系或者是基于云的SOI不可或缺的部分。

本章将比第5章更深入地讨论部署在私有云计算结构（参见图2-1）之上的不同会话拦截技术。

6.1 云对WAN优化的要求

与普通的远程分支整合上应用的WAN优化技术相比，云对WAN优化提出了更多的要求，包括：

·自适应部署模式：在SOI顶层，以流行的模块化方式通过WAN优化服务来构建云服务项目（例如，云IaaS），能够让服务按照用户需求灵活重组。WAN优化是一个非常准确的服务区分者，使得云服务供应商有能力提供优化的应用服务，而不同于基础的计算服务。

·最低网络配置及故障：应该达到最低的网络配置，以便满足对新提交VM实例的优化要求，同时理想情况下，在整个WAN优化部署过程中不会发生网络故障。

·支持多租户环境：应该支持多租户环境，特别是云IaaS服务项目，目的是减少云服务供应商的CAPEX和OPEX。

·Vmotion感知：WAN优化服务应能忽略不同应用服务器VM的具体物理位置差别，为它们提供持久可靠的服务。

·弹性横向扩展：WAN优化服务要求采用弹性横向扩展的部署方式，使得当租户/子用户数目增加或减少时，也能够很好地适应服务需求的起伏变化。弹性横向扩展包括增加更多的WAN优化器以满足服务器增长需求，最好的方法是将这些WAN优化器放在一个虚拟机箱设备中。

·虚拟化部署：WAN优化服务应该基于虚拟设备而非物理设备部署，虚拟设备可以按需部署（例如，预先组装和定制的服务），而物理设备需要支撑机架、码放整齐及使用线缆接入。由于每个租户的硬件需求不同，在多租户环境中使用虚拟部署可以降低硬件成本，而当用户需求增大时，云供应商可以通过转移到更强大的平台上或为现有平台增加更多的资源来扩展虚拟设备的性能。

说明：虚拟设备一般是软件，它可以被当做一个逻辑实体或除物理设备之外的虚拟设备上下文（Virtual Device Context,VDC），不同于物理设备，虚拟设备通常不带硬件平台，因此需要用户自己提供平台。

6.2 VM层拦截

仅靠虚拟机箱中的WAN优化器是无法满足之前章节中所有要求的，必须将它与各种拦截方法结合才能发挥作用。本小节将简单介绍一种在VM层的“deep in the DC”的拦截方法（如图2-1所示）。

在应用主机层或VM层的拦截方法中，每一需要优化的租户VM拥有一个特殊的接口驱动或者安装了一个代理，用于对那些往返于租户VM与WAN优化器间的“感兴趣”的、需优化的网络流量进行拦截和重定向。尽管每一租户VM配一个主机代理的方法看起来有些令人乏味，但是这一特殊方法在实际中，能够不需要复杂的网络整合，就能满足在“6.1云拦截对WAN优化的要求”一节中提到绝大多数要求。图6-1说明了VM层拦截。

说明：Riverbed Cloud Steelhead设备能够实现VM层拦截，需优化的租户VM使用一个Discovery代理对送至Cloud Steelhead设备的网络流量进行拦截和重定向，可以采用优先级（默认）或轮询的负载平衡方法实现Cloud Steelhead设备聚簇。

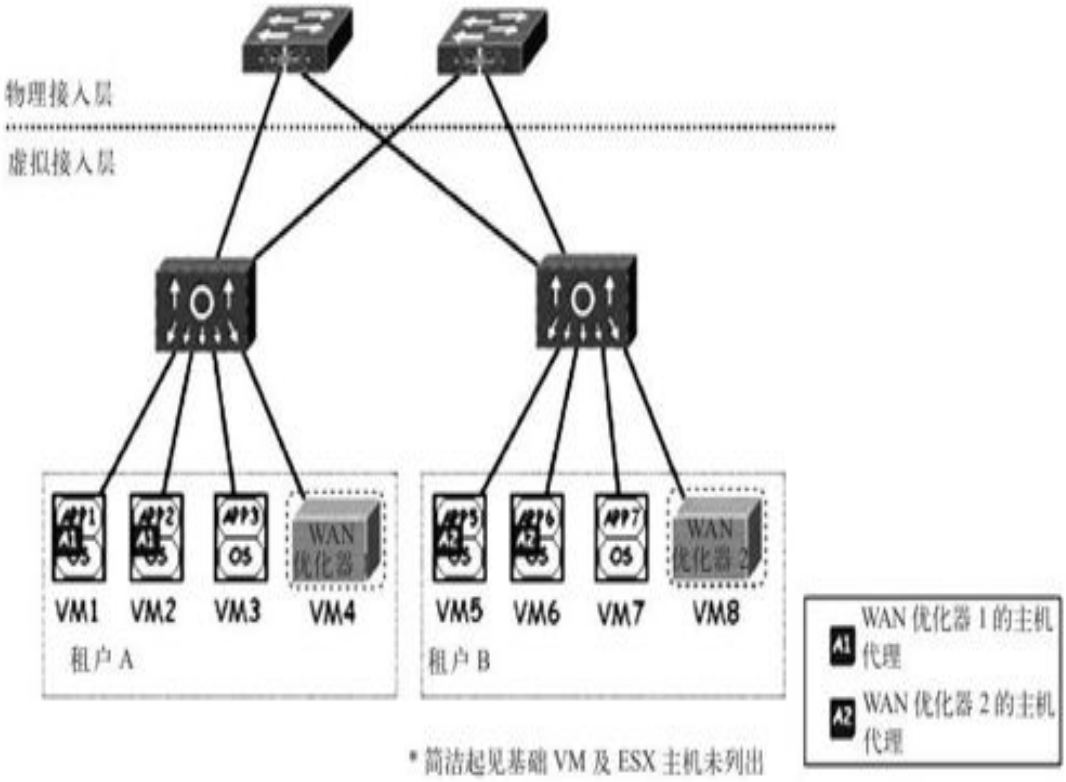


图 6-1 使用主机代理实现拦截

6.3 使用VRF感知的WCCP实现云拦截

在VM层进行拦截不仅仅只有“deep-in-DC”一种方式，传统的out-of-path拦截机制同样可以在私有云中远离服务集群（或VM）而靠近WAN边缘的位置进行部署。本小节关注私有云核心/汇聚层上更为传统的网络流量拦截及重定向方法部署，这一技术将借助VRF感知的WCCPv2（如图2-1所示）。

从SOI观点来看，DC的核心/汇聚层是实现WCCPv2拦截的理想地点，因为这是L2终结而L3开始的地方。VRF与L3设备在该层的接口关联是考虑的重点，而VRF配置意味着需要L3路径隔离（更多细节请参见3.2.1节），但是这对标准的WCCPv2部署造成了影响，标准WCCPv2部署要求全局采用IPv4路由表。

解决该问题的途径之一是使用VRF感知的WCCPv2，或者通过VRF路由泄露（请参考6.4节）。第5章简单介绍了各类WCCP服务器平台，其中能够直接支持WCCPv2的平台有：

·Nexus 7000

·C7200和ISR（IOS 15.x）

·C7600（IOS 12.2（33）SRE）

·ASR 1000（IOS-XE 3.1.0S）

Nexus 7000（NX7K）交换机将被当成案例平台用来进一步细化说明在多租户环境如何实现VRF感知的WCCPv2配置。图6-2展示了一个在NX7K交换机上的简单WAN优化配置，CORE-1位于DC核心层。WAN优化可以同时为租户B和租户C服务，CORE-1承担了一个multi-VRF L3交换机的功能，VRF租户B和VRF租户C则是相应租户。因为现在在CORE-1存在两个不同的VRF,VRF感知WCCPv2（或者是两个不同的WCCPv2实例）必须在CORE-1实现，以便能够正确拦截并将网络流量重定向至WAN优化器。往返至服务器S1的TCP网络流将被VRF租户B上的WCCPv2实例拦截，并重定向至WAN优化器“B”以实施优化；而往返至服务器S2的TCP网络流将被VRF租户C上的WCCPv2实例拦截，并重定向至WAN优化器“C”以实施优化。本例中的WAN优化器既可以是物理设备也可以是虚拟设备。

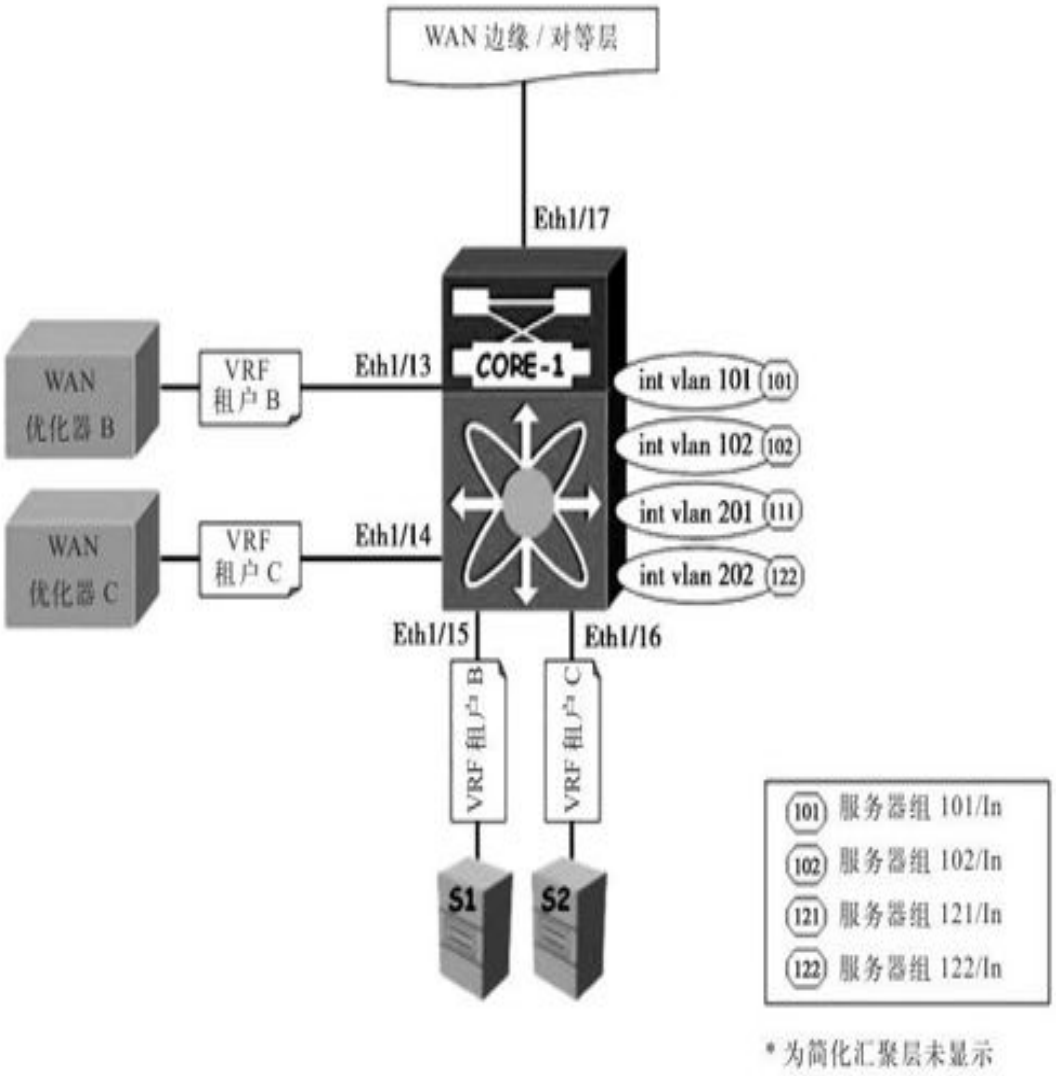


图　6-2　使用VRF感知的WCCPv2实现WAN优化

说明：在图6-2所示样例中，远程分支的网络流必须要穿过核心/汇聚/接入层，才能从WAN边缘/对等层到达服务器S1和S2。部署在DC的WAN优化器为Riverbed VSH-2050-H虚拟Steelhead设备，该设备能够支持WCCPv2技术。分支上的WAN优化器（为了简化，未在图中显示）为Riverbed SH-1050-H Steelhead设备，按物理in-path方式部署在远程分支上。

说明：尽管NX7K交换机支持VRF感知的WCCPv2，但如果在交换机上配置的不是VRF，而是虚拟设备上下文VDC，就不要求支持该功能。此时，WCCPv2采用普通的全局IPv4路由表。不过目前Nexus 7000交换机最多仅能支持包括默认VDC在内共4个VDC，所以当租户数目超过4时，仍然需要采用VRF。

另外，VDC和VRF可以同时使用，此时，可以将VRF当成VDC的子集，每一个VDC也可进一步虚拟化以支持VRF。

代码清单6.1描述了CORE-1（如图6-2所示）的L2基本配置。使用了5个端口：4个access端口，1个留作802.1Q trunk端口。在4个access端口中，两个（Eth1/13和Eth1/15）留给租户B，用来连接到WAN优化器“B”和服务器S1，另外两个（Eth1/14和Eth1/16）留给租户C，用来连接到WAN优化器“C”和服务器S2，trunk端口（Eth1/17）连接到某个WAN边缘/对等层的路由上（为了简化，未在图中显示）。

代码清单6.1　NX7K L2基本配置

```
vlan 10,20,101-102,201-202

interface Ethernet1/13
  description "Connects WAN Optimizer B"
  switchport
  switchport access vlan 10
  no shutdown
interface Ethernet1/14
  description "Connects WAN Optimizer C"
  switchport
  switchport access vlan 20
  no shutdown

interface Ethernet1/15
  description "Connects Server S1"
  switchport
  switchport access vlan 102
  no shutdown

interface Ethernet1/16
  description "Connects Server S2"
  switchport
  switchport access vlan 202
  no shutdown

interface Ethernet1/17
  description "802.1Q Trunk from Peering Layer"
  switchport
  switchport mode trunk
  switchport trunk allowed vlan 101,201
  no shutdown
```

说明：NX7K交换机的模块1，CORE-1（如图6-2所示）是拥有48个端口10/100/1000Mbps以太网模块（N7K-M148GT-11）。

代码清单6.2描述了CORE-1（如图6-2所示）的L3基本配置。以代码清单6.1所示的6个VLAN为基础，再加上6个相应的L3交换虚拟接口SVI。默认的VDC可以为VRF租户B和VRF租户C服务。SVIs Vlan-10，Vlan-101以及Vlan-102与VRF租户B相连，SVIs Vlan-20，Vlan-201以及Vlan-202与VRF租户C相连，

实例化了两个OSPFv2，一个（路由ospf 100）为VRF租户B服务，另一个（路由ospf 200）为VRF租户C服务。

代码清单6.2　NX7K L3基本配置

```
feature ospf
feature interface-vlan

vrf context Tenant-B
vrf context Tenant-C

interface Vlan10
  no shutdown
  vrf member Tenant-B
  ip address 10.1.10.1/24
  ip router ospf 100 area 0.0.0.0

interface Vlan101
  no shutdown
  vrf member Tenant-B
  ip address 10.1.101.1/24
  ip router ospf 100 area 0.0.0.0

interface Vlan102
  no shutdown
  vrf member Tenant-B
  ip address 10.1.102.1/24
  ip router ospf 100 area 0.0.0.0

interface Vlan20
  no shutdown
  vrf member Tenant-C
  ip address 10.2.20.1/24
  ip router ospf 200 area 0.0.0.0

interface Vlan201
  no shutdown
  vrf member Tenant-C
  ip address 10.2.201.1/24
  ip router ospf 200 area 0.0.0.0

interface Vlan202
  no shutdown
  vrf member Tenant-C
  ip address 10.2.202.1/24
  ip router ospf 200 area 0.0.0.0
```

```
router ospf 100
  vrf Tenant-B

router ospf 200
  vrf Tenant-C
```

代码清单6.3描述了CORE-1上VRF感知的WCCPv2（如图6-2所示）配置。为了方便NX7K交换机上WCCP掩码分配的实施，为每一租户都创建了2个WCCP服务组，每个服务组都采用基于界内定向方法完成WCCP拦截。更多NX7K交换机能够支持的WCCP功能的详细说明，可以参见本书5.2.8节中“Nexus 7000 WCCP兼容性”相关内容。

代码清单6.3　NX7K上VRF感知的WCCPv2配置

```
feature wccp

vrf context Tenant-B
  ip wccp 101 redirect-list 101
  ip wccp 102 redirect-list 102

vrf context Tenant-C
  ip wccp 121 redirect-list 121
  ip wccp 122 redirect-list 122

interface Vlan101
  no shutdown
  vrf member Tenant-B
  ip address 10.1.101.1/24
  ip router ospf 100 area 0.0.0.0
  ip wccp 101 redirect in

interface Vlan102
  no shutdown
  vrf member Tenant-B
  ip address 10.1.102.1/24
  ip router ospf 100 area 0.0.0.0
  ip wccp 102 redirect in

interface Vlan201
  no shutdown
  vrf member Tenant-C
  ip address 10.2.201.1/24
  ip router ospf 200 area 0.0.0.0
  ip wccp 121 redirect in

interface Vlan202
  no shutdown
  vrf member Tenant-C
  ip address 10.2.202.1/24
```

```
 ip router ospf 200 area 0.0.0.0
 ip wccp 122 redirect in

p access-list 101
 10 permit tcp 192.168.100.0/24 10.1.102.100/32
ip access-list 102
 10 permit tcp 10.1.102.100/32 192.168.100.0/24

ip access-list 121
 10 permit tcp 192.168.200.0/24 10.2.202.100/32

ip access-list 122
 10 permit tcp 10.2.202.100/32 192.168.200.0/24
```

说明：为了简便，代码清单6.3省略了诸如HA以及其他更复杂的WCCPc2配置内容。

如果是租户B这种情况，来自远程机构“B”（192.168.100.0/24）到服务器S1（10.1.102.100/32）的界内TCP网络流由服务组101拦截，重定向至WAN优化器“B”以进行优化。而来自服务器S1（10.1.102.100/32）至远程机构“B”（192.168.100.0/24）的界内TCP网路流将由服务组102拦截，重定向至WAN优化器“B”以进行优化。服务组101和102对VRF租户B而言都属本地。

如果是租户C这种情况，来自远程机构“C”（192.168.200.0/24）到服务器S2（10.1.202.100/32）的界内TCP网络流由服务组121拦截，重定向至WAN优化器“C”以进行优化。而来自服务器S2（10.2.202.100/32）至远程机构“C”（192.168.200.0/24）的界内TCP网路流将由服务组122拦截，重定向至WAN优化器“C”以进行优化。服务组121和122对VRF租户C而言都属本地。

说明：在VRF感知WCCPv2中，服务组对于VRF均为局部定义，换句话说，不同VRF内定义的服务组在逻辑上是相互隔离，意味着在不同的VRF中服务组ID可以重用（在代码清单6.3中未进行说明）。这样的处理方法在云服务供应商为不同的租户使用了相同的命名机制时特别有用。此时，相同的WCCPv2配置（包括重定向ACLs）可以实施在不同的租户上。

说明：NX7K交换机支持重定向访问控制列表（Access-Control List,ACL），代码清单6.3中的重定向ACLs假设当前在相关服务器上只有一个TCP应用需要优化。而在大多数情况下，推荐按照需要优化的TCP应用的数目，重新完善ACL，以获得更好的扇入控制。

6.4 使用非VRF感知WCCP实现云拦截

如果C7200、C7600及ASR 1000（ASR1K）的IOS（ASR1K为IOS-XE）版本能够直接支持VRF感知的WCCP，那么在这些设备上就能实现VRF感知的WCCPv2。但假使是在WAN边缘/对等层部署的是其他路由平台，又或者它们的IOS（或IOS-XE）版本根本不支持VRF感知的WCCP，又该怎么处理呢？

如果遇到不能直接实现VRF感知WCCPv2功能的设备时，WCCPv2和VRF同样可以交互进行。本小节将探讨一些VRF整合方法使得在核心/汇聚层以及WAN边缘/对等层（如图2-1所示）能够实现WCCPv2和VRF无缝交互（没有VRF感知WCCP功能）。

接下来的小节将要讨论的内容包括：

·VRF选择

·WCCP双向连接的挑战

·Not-So-VRF解决方案

·NSV实例

6.4.1 VRF选择

WCCPv2和VRF整合依赖于一项被称为VRF选择的技术。总的来说，VRF选择机制断开了VRF路由与接口之间的关联，在接口上应用VRF选择后，将使得该接口的全局IPv4路由表与VRF路由表之间产生一道“裂缝”，因此，如果接口配置了VRF选择属性，就将变成“Not-So-VRF”。

我们将VRF选择机制总结如下：

1.与将接口与VRF相关联相反，VRF选择配置定义了基于协议的路由（Policy-Based Routing,PBR），并在multi-VRF/WCCPv2路由的汇聚接口定义了“ip vrf receive”接口命令。

2.VRF选择将依据PBR路由定义的ACL列表来寻找感兴趣的包，如果匹配成功，则将选择（或设置）一个相应的VRF路由表。

3.VRF选择将在选好的VRF路由表中查找目标IP地址，决定相应的下一跳、输出接口以及邻接属性等。

说明：VRF选择只适用于界内定向。

说明：VRF选择功能通常被称为采用PBR的MPLS VPN VRF选择，能够支持该功能的路由C7200平台所需IOS版本为IOS 12.3（7）T,C7600平台所需IOS版本为12.2（33）SBR 1及更高，ASR1K平台则需要IOS XE 2.1.0及更高版本。

图6-3说明了VRF选择机制如何将路由CE10的接口f1/0与VRF租户A、租户B以及租户C分割开来，而尽管接口f1/0与这些VRF并不相连，来自HOST-A、HOST-B以及HOST-C的网络包，依然能够通过CE10f1/0入口的PBR路由映射，有效地转发至它们相应的远程分支。

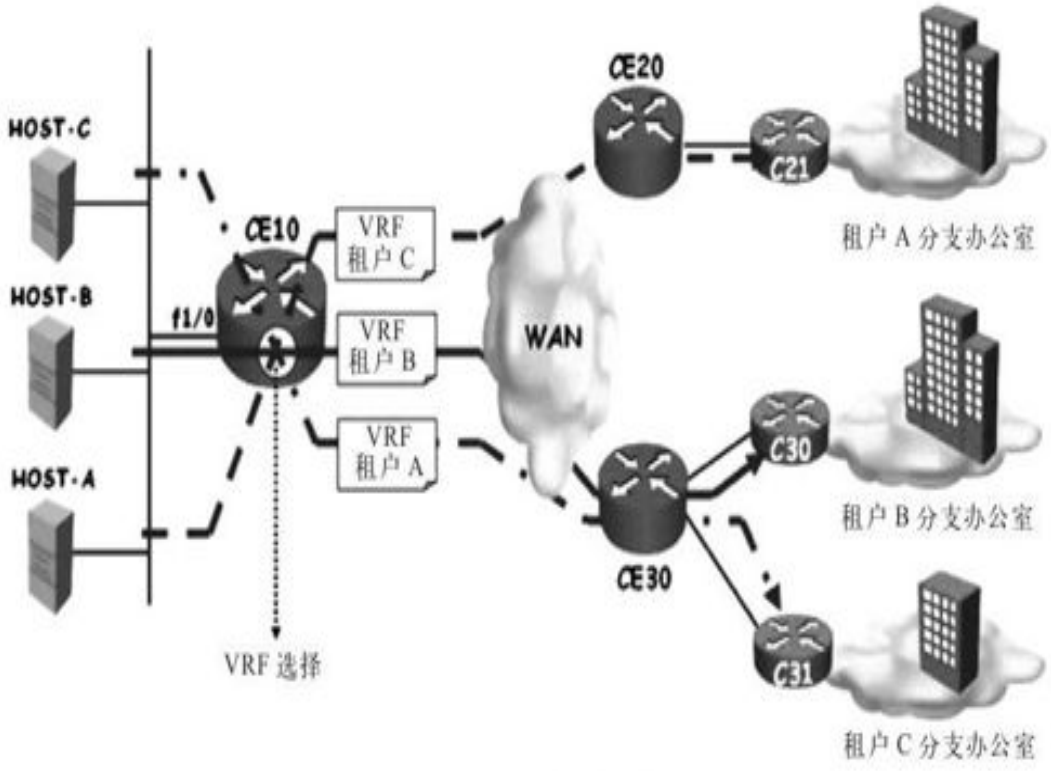


图　6-3　VRF选择样例

6.4.2 WCCPv2双向连接的挑战

建立一个成功的WCCPv2双向连接的两个主要准则如下：

·WCCPv2的路由ID必须是支持WCCPv2的WAN优化器能够访问的合法IPv4地址。

·WCCPv2路由必须了解如何通过其全局IPv4路由表到达相应支持WCCPv2的WAN优化器。

这些规则对WCCPv2与VRF的整合带来了一定挑战。支持WCCPv2的WAN优化器通常部署在特定的VRF地址空间，该空间只能通过相应的VRF路由表访问，而WCCPv2的路由ID则只能通过全局IPv4路由表访问。图6-4对这一难题进行了说明，由于全局IPv4路由表以及VRF路由表是相互隔离的，因此除非找到一个能解决这两个连接互通问题的替换方案，否则就无法成功建立WCCPv2的双向连接。

如图6-4所示，HIA消息来自支持WCCP的WAN优化器，SH10（一种Riverbed Steelhead设备）将永远无法访问到ID为10.10.10.10的WCCP路由，因为该设备使用的是租户D的路由表，而loopback10只能通过全局IPv4路由表访问获得。因此，如果SH10处于一个特殊的VRF地址空间，SH10必须通过相应的VRF路由表访问路由ID。要解决这一问题，只能是路由ID和SH10在VRF和全局IPv4路由表中都实现in-path地址可得。

此外，IOS操作的顺序要求如下：

·对于入口流量，WCCPv2重定向应在VRF路由表寻址前完成。

·对于出口流量，WCCPv2重定向应在VRF路由表寻址后进行。

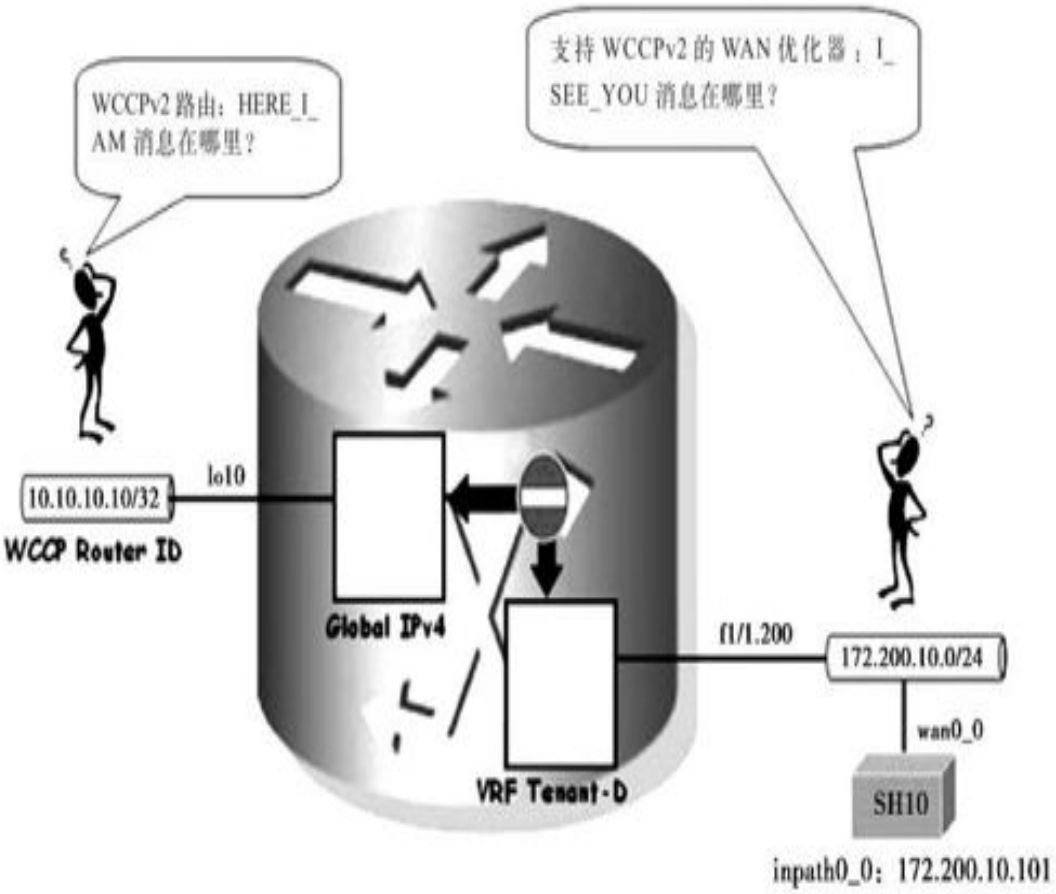


图　6-4　不同路由表之间的可达信息

以图6-4为例，可以得出4个结论：

·从WAN到LAN方向的WCCPv2入口重定向操作要通过全局IPv4路由表获得SH10的地址。

·从LAN到WAN方向的WCCPv2入口重定向操作需了解SH10在全局IPv4路由表中的位置。

·从WAN到LAN方向的WCCPv2出口重定向操作需要通过VRF租户D路由表获得SH10的地址。

·从LAN到WAN方向的WCCPv2出口重定向操作需了解SH10在VRF租户D路由表中的位置。

任何WCCPv2入口重定向操作都将同样面临以上提到的WCCPv2双向连接的问题，因此，走出这一困境的最佳方案是确保WCCPv2路由ID和SH10 in-path地址在全局IPv4路由表和VRF租户D路由表均可访问。

说明：保证在全局IPv4路由表和相应的VRF路由表都能访问到路由ID和WAN优化器，将防止双向连接解决方案破坏IOSWCCPv2重定向及VRF路由寻址操作的顺序。

6.4.3 Not-So-VRF方案

Not-So-VRF（NSV）方案解决了上一小节中WCCPv2双向连接面临的挑战难题。NSV替代方案依赖于VRF选择机制（相关细节请参见6.4.1节），如图6-5所示，当VRF选择机制被应用到loopback10（WCCP路由ID）时，loopback10将变成被租户D的VRF表可见。

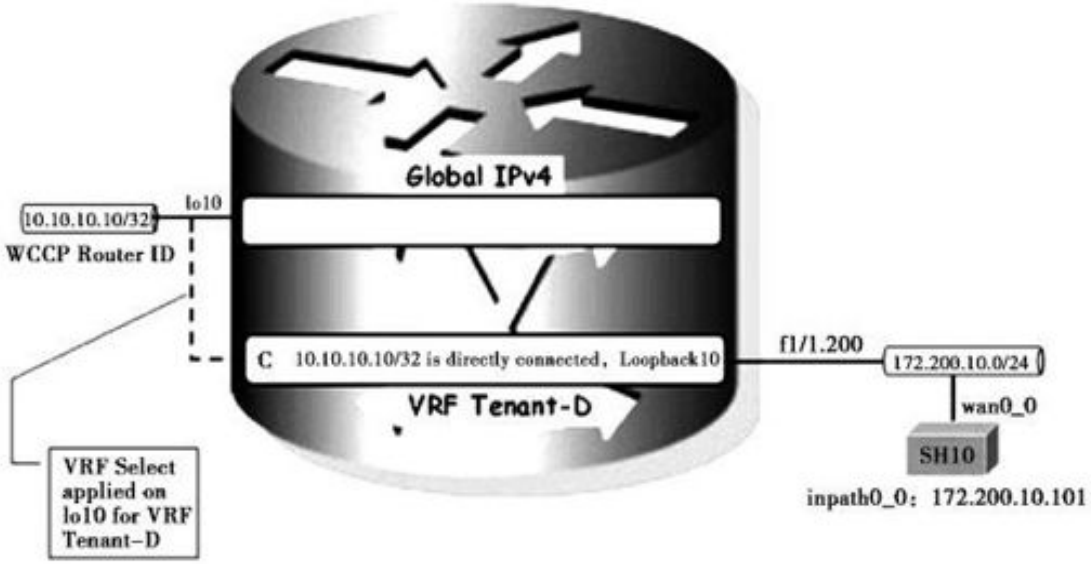


图 6-5 VRF路由表中的WCCP路由ID

尽管现在通过VRF租户D可以访问到WCCP路由ID，还有一个被忽略了的连接：WCCPv2路由又将如何通过全局IPv4路由表访问到SH10呢？图6-6解释了相关方法：在全局IPv4路由表中定义一个静态路由并指向SH10所在的子网。

说明：NSV方案使用了WCCP GRE重定向/返回，而使用WCCP L2重定向/返回方法的NSV不属于本书讨论范畴。

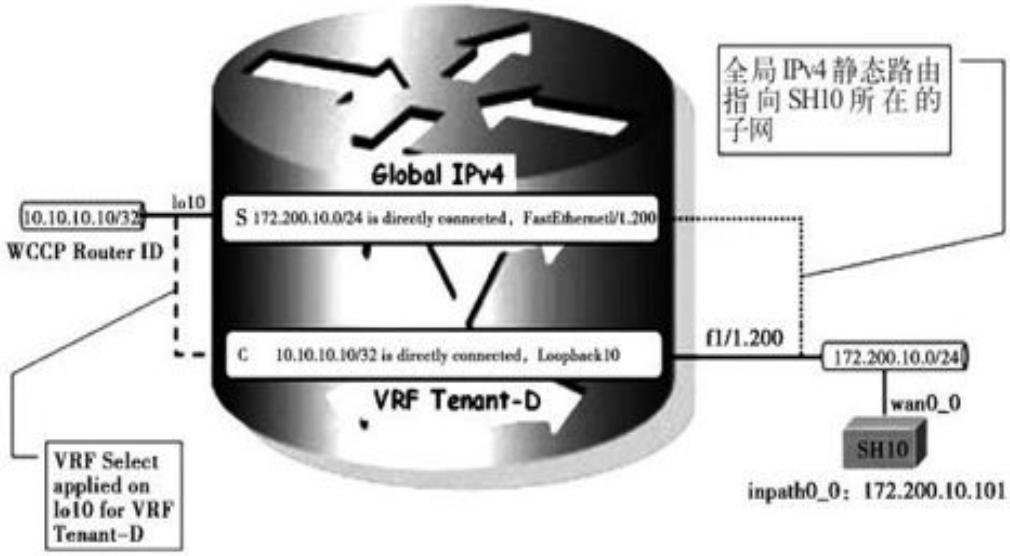


图　6-6　全局IPv4路由表中的WAN优化器子网

6.4.4 Not-So-VRF说明

图6-7给出了一个NSV样例的配置方案。本节随后将对基本图注及NSV实现的步骤进行说明，它们包括：

·在核心/汇聚层实现NSV

·VRF选择替换方案

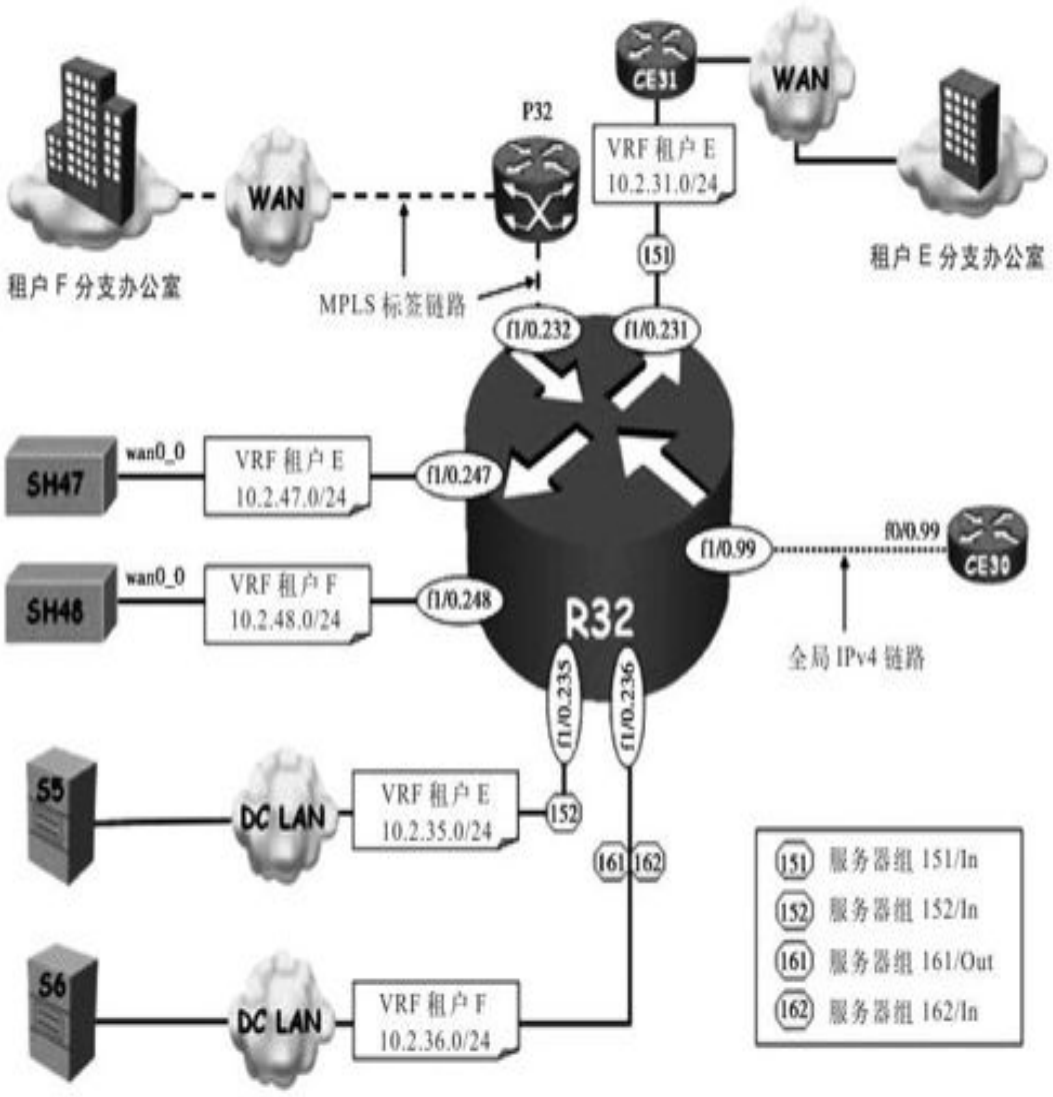


图 6-7 Not-So-VRF样例

·在WAN边缘/对等层实现NSV

前述小节中完成的NSV及WCCPv2配置（或代码）均基于图6-7描述的样例。

R32是图6-7所示NSV样例配置的主角，它担当了DC核心/汇聚层中租户E的multi-VRF路由，而在DC的WAN边缘/对等层

又变成了租户F的PE路由。

说明：R32的IOS版本为12.4（15）T9，该版本不支持VRF感知的WCCPv2功能，但支持VRF选择方法。

说明：本例应用的DC WAN优化器为Riverbed VSH-2050-H虚拟Steelhead设备，该设备支持WCCPv2，分支WAN优化器（为了简便，未在图中标注）为Riverbed SH-1050-H Steelhead设备，以物理in-path方式部署在远程分支上。

在核心/汇聚层实现NSV

本小节为租户E实现了NSV方案，此时，R32作为了DC核心/汇聚层的multi-VRF路由。整个操作分6步完成：

·Step1　定义WCCP路由ID。显然这是最基础的一步，因为WCCPv2经常选择路由上数值最大loopback接口的IPv4地址（如果没有配置loopback，将选择物理接口的最大IPv4地址）作为路由ID。

·Step2　可选操作，如果loopback或接口的IPv4地址均未获取，则创建一个最大的IPv4 loopback。进行这一步操作时要小心，因为它有可能对路由上所实施的其他协议的属性产生影响（例如，路由中的路由ID或类似操作）。代码清单6.4说明了在R32上如何创建了loopback2并作为WCCP路由ID。

代码清单6.4　创建最大IVv4 loopback

```
!
interface Loopback2
 ip address 10.2.100.32 255.255.255.255
!
```

说明：如果已有一个loopback存在，并且已经被当成WCCP路由ID使用，就不要再创建其他更大的IPv4 loopback地址。

·Step3　在最大IPv4 loopback（WCCP路由ID）上实现VRF选择机制，它是整个操作的关键所在。代码清单6.5解释了在VRF租户E的loopback2上配置VRF选择。“ip vrf receive”接口命令使得loopback2在VRF租户E的路由表内可见，不过调用该命令之前要求已经配置好了PBR。在NSV方案中，PBR路由映射的主要任务是确保“ip vrf receive”接口命令能够正确执行，因而

用到的PBR路由映射实际上也是一个空白路由映射（即一个摆样子的路由映射）。

代码清单6.5　在租户E IPv4 loopback上应用VRF选择

```
!
interface Loopback2
 ip address 10.2.100.32 255.255.255.255
 ip policy route-map dummy
 ip vrf receive Tenant-E
!
```

说明：用户不需要去创建一个“摆样子”的路由映射，因为本来就是需要一个空的路由映射。

VRF选择方法配置好后，loopback将会在VRF租户E的路由表中出现。代码清单6.6说明了该如何使用“show ip route vrf Tenant-E”命令来验证此步骤是否成功。

代码清单6.6　验证VRF租户E路由表中的IPv4 loopback

```
R32#show ip route vrf Tenant-E
[-----Snipped for brevity-----]
C 10.2.31.0/24 is directly connected, FastEthernet1/0.231

C 10.2.35.0/24 is directly connected, FastEthernet1/0.235
C 10.2.47.0/24 is directly connected, FastEthernet1/0.247
C 10.2.100.32/32 is directly connected, Loopback2
```

代码清单6.7描述了连接到SH47（如图6-7所示）子接口上已完成的配置。

代码清单6.7　连接至租户E WAN优化器的VRF接口

```
interface FastEthernet1/0.247
 encapsulation dot1Q 247
 ip vrf forwarding Tenant-E
 ip address 10.2.47.2 255.255.255.0
```

说明：如果发生了某个WAN优化器的out-of-path部署存在VLAN不可得的情况，用户通常可以在其相应的802.1Q端口新创建一个。

·Step4　通过激活全局IPv4路由泄露完成NSV方案。全局IPv4路由表必须要知道如何访问WAN优化器，VRF可以通过全局IPv4路由泄露实现。从代码清单6.7可知，SH47位于子网10.2.47.0/24，借助VRF租户E的路由表，可以通过接口f1/0.247访问。代码清单6.8解释了一个全局IPv4静态路由如何将这一可达信息泄露给全局IPv4路由表。

代码清单6.8　租户E上的VRF到全局IPv4的路由泄露

```
!
ip route 10.2.47.0 255.255.255.0 FastEthernet1/0.247
!
```

代码清单6.9　验证VRF租户E子网已进入全局IPv4路由表

```
R32#show ip route
S 10.2.47.0/24 is directly connected, FastEthernet1/0.247
C 10.2.100.32/32 is directly connected, Loopback2
```

代码清单6.9调用了“show ip route”命令，对子网10.2.47.0/24是否已经能够通过全局IPv4路由表可达进行验证。

当以上4个步骤都完成后，最初只在全局IPv4路由表中可见的WCCP路由ID 10.2.100.32，现在在VRF租户E的路由表中也变得可见了，而最初只能通过VRF租户E的路由表访问的子网10.2.47.0/24，也可以通过全局IPv4访问。步骤1～4圆满完成了NSV替换策略，剩下的步骤（Step5和6）都属于标准WCCPv2配置设置了。

说明：VRF到全局IPv4的路由泄露对R32而言是本地完成，而且只在WCCP路由ID和SH47间实现，对租户E上现有的L3路径隔离不会造成影响。SH47是一个透明的代理，因此实际的源及目的地址仍然只能够通过VRF租户E上的路由表进行访问。

·Step5　涉及了R32上租户E（参见图6-7）的WCCPv2全局配置，代码清单6.10中的重定向ACL假设此时在服务器S5（10.2.50.88）上只有一个TCP应用在运行，租户E分支办公室上的远程客户（10.2.10.78）可以访问到S5。

代码清单6.10　租户E上R32的WCCPv2全局配置

```
!
ip wccp 151 redirect-list 151
ip wccp 152 redirect-list 152
!
access-list 151 permit tcp host 10.2.10.78 host 10.2.50.88
access-list 152 permit tcp host 10.2.50.88 host 10.2.10.78
!
```

·Step6　如代码清单6.11所示，在相应接口（f1/0.231和f1/0.235）入口配置WCCPv2。子接口f1/0.231是面向WAN接口（连接租户E的远程分支）而子接口f1/0.235是面向DC LAN的接口（连接服务器S5），两个接口都基于VRF。

代码清单6.11　在R32上为租户E配置WCCPv2接口

```
!
interface FastEthernet1/0.231
 encapsulation dot1Q 231
 ip vrf forwarding Tenant-E
 ip address 10.2.31.2 255.255.255.0
 ip wccp 151 redirect in
!
interface FastEthernet1/0.235
 encapsulation dot1Q 235
 ip vrf forwarding Tenant-E
 ip address 10.2.35.2 255.255.255.0
 ip wccp 152 redirect in
!
```

SH47（参见图6-7）的配置在代码清单6.12中进行了简单说明。配置了基本的逻辑in-path，对租户E上R32的WCCPv2配置进行了回应。

代码清单6.12　SH47上租户E的WCCPv2配置

```
#
interface inpath0_0 ip address 10.2.47.101 /24
ip in-path-gateway inpath0_0 10.2.47.2
#
in-path enable
in-path oop enable
```

```
#
wccp enable
wccp service-group 151 routers 10.2.100.32
wccp service-group 152 routers 10.2.100.32
#
```

VRF选择技术的替代方案

如果用户的IOS或其他软件版本不支持VRF选择技术该怎么办呢？有一个非正规的方法可以解决该问题，但又需依赖另一种直接连至multi-VRF/WCCPv2路由的L3设备。在图3-7中，这样的L3设备为路由CE30，它是直接连接至R32（multi-VRF/WCCPv2路由）的“boomerang”路由。

代码清单6.13重现了上一节步骤3（参见“在核心/汇聚层实现NSV”部分）的过程，但这次不再使用VRF选择技术。尽管这样会使步骤3变得非常麻烦，不过因此放松了对IOS版本的要求还是值得的，支持WCCPv2的IOS就够用了。步骤3的替代方案如下：

·Step3b　代码清单6.13解释了如何新创建一个R32上的子接口f1/0.99以打开一个到CE30的Ipv4“裂缝”（或一条直接的Ipv4路径），紧接着通过使用一个指向CE30（10.2.99.30）的VRF静态路由将WCCP路由ID访问信息泄露给VRF租户E的路由表，该静态路由也是子接口f1/0.99的下一跳。

代码清单6.13　VRF选择的替代配置

```
!
hostname R32
!
interface Loopback2
 ip address 10.2.100.32 255.255.255.255
!
! --- Create IPv4 crack to boomerang router CE30
interface FastEthernet1/0.99
 encapsulation dot1Q 99
 ip address 10.2.99.32 255.255.255.0
!
! --- Bounce the location of WCCP Router ID to boomerang router CE30
ip route vrf Tenant-E 10.2.100.32 255.255.255.255 FastEthernet1/0.99 10.2.99.30
!
```

代码清单6.14展示了boomerang路由的配置，CE30的子接口（f0/0.99）配置与R32子接口（f1/0.99）配置相对应，Ipv4静态路由只简单地将任一目的地址为10.2.100.32（WCCP路由ID）的IP包返回至R32（10.2.99.32）。

代码清单6.14　Boomerang路由配置

```
!
hostname CE30

!
! - Create corresponding IPv4 crack to CE32
interface FastEthernet0/0.99
 encapsulation dot1Q 99
 ip address 10.2.99.30 255.255.255.0
!
! – Boomerang back
ip route 10.2.100.32 255.255.255.255 10.2.99.32
!
```

说明：替代方案仅对步骤3进行变更（参见“在核心/汇聚层实现NSV”部分），其他步骤都保持不变，只有R32（参见代码清单6.13）和CE30（参见代码清单6.14）的配置会发生变化。

在WAN边缘/对等层实现NSV

本小节将探讨在WAN边缘/对等层，使用相同路由R32（参见图6-7）的VRF租户F上实现NSV方案。由于增加了VRF租户F，现在系统中包含了两个VRF：VRF租户E和VRF租户F。别忘了WCCPv2只能在全局Ipv4地址空间中访问它的路由ID,NSV替代方案也不会改变这一点，因此在multi-VRF环境中（例如VRF租户E和VRF租户F），位于不同VRF地址空间内支持WCCPv2的WAN优化器，彼此之间仍然需要共享WCCP路由ID，因此，要重写步骤3到6：

·Step3c　由于WCCP路由ID（loopback 2）已经在代码清单6.4中定义好了，我们可以直接跳至步骤3，就如上一节“在核心/汇聚层实现NSV”中所描述的一样，由于PBR路由图在前面租户E的VRF选择配置（参见代码清单6.5）中已经完成，租户F只需要执行“ip vrf receive”接口命令即可，如代码清单6.15所示。

代码清单6.15　在租户F的Ipv4 loopback上应用VRF选择技术

```
!
interface Loopback2
 ip address 10.2.100.32 255.255.255.255
 ip policy route-map dummy
 ip vrf receive Tenant-E
 ip vrf receive Tenant-F
!
```

当配置好VRF选择机制后，相应的loopback应该出现在VRF租户F的路由表中。代码清单6.16解释了如何执行“show ip route vrf Tenant-F”命令来验证这一过程。

代码清单6.16　在VRF租户F路由表中验证Ipv4 loopback

```
R32#show ip route vrf Tenant-F
[----- Snipped for brevity-----]
C 10.2.36.0/24 is directly connected, FastEthernet1/0.236
C 10.2.48.0/24 is directly connected, FastEthernet1/0.248
C 10.2.100.32/32 is directly connected, Loopback2
```

代码清单6.17描述了连接至SH48（参见图6-7）子接口的当前配置。

代码清单6.17　连接至WAN优化器的VRF接口

```
interface FastEthernet1/0.248
 encapsulation dot1Q 248
 ip vrf forwarding Tenant-F
 ip address 10.2.48.2 255.255.255.0
```

·Step4c　由代码清单6.17可得，SH48位于子接口10.2.48.0/24，借助VRF租户F路由表信息，可知能通过接口f1/0.248访问到SH48。代码清单6.18（step 4c）对全局Ipv4静态路由将如何将这一可达信息泄露给全局Ipv4路由表进行了说明。

代码清单6.18　全局Ipv4路由VRF泄露给租户F

```
!
ip route 10.2.48.0 255.255.255.0 FastEthernet1/0.248
!
```

代码清单6.19将执行“show ip route”命令，来验证子网10.2.48.0/24是否已经能够通过全局Ipv4路由表可达。

代码清单6.19　验证VRF租户F子网是否已经在全局Ipv4路由表中

```
R32#show ip route
S 10.2.47.0/24 is directly connected, FastEthernet1/0.247
S 10.2.48.0/24 is directly connected, FastEthernet1/0.248
C 10.2.100.32/32 is directly connected, Loopback2
```

当步骤3c（参见代码清单6.15）和步骤4c（参见代码清单6.18）都完成后，WCCP路由ID10.2.100.32在租户F的路由表中已经可见了，而子网10.2.48.0/24现在也可以通过全局Ipv4路由表可达了。

·Step5c　代码清单6.20将探讨如何在R32上为租户F完成WCCPv2配置。在服务器S6（10.2.60.88）上运行的重定向ACL应用需要进行优化，租户F的远程办公室的远程客户（10.2.20.78）访问了它。

代码清单6.20　为R32上的租户F配置WCCPv2

```
!
ip wccp 161 redirect-list 161
ip wccp 162 redirect-list 162
!
access-list 161 permit tcp host 10.2.20.78 host 10.2.60.88
access-list 162 permit tcp host 10.2.60.88 host 10.2.20.78
!
```

说明：当IOS版本或其他系统版本不支持VRF感知的WCCPv2时，用户可以为不同的VRF配不同的服务组以作为备选方案。

·Step6c　如代码清单6.21所示，面向VRF的DC WAN接口f1/0.236已经实现了双向WCCPv2重定向，这种特殊的重定向被

称为服务隔离模式。该模式主要应用于需要对到某一接口实行严格重定向的场合，使得只有经过该接口并且能与WCCP重定向ACL匹配成果的网络流量才会实施重定向操作。

代码清单6.21　为租户F在R32配置WCCPv2接口

```
!
interface FastEthernet1/0.236
 encapsulation dot1Q 236
 ip vrf forwarding Tenant-F
 ip address 10.2.36.2 255.255.255.0
 ip wccp 161 redirect out
 ip wccp 162 redirect in
!
interface FastEthernet1/0.248
 encapsulation dot1Q 248
 ip vrf forwarding Tenant-F
 ip address 10.2.48.2 255.255.255.0
 ip wccp redirect exclude in
!
```

如图6-7所示，R32在WAN边缘/对等层，相当于租户F的PE路由，R32的面向WAN接口，子接口f1/0.232连接到P32（某个P路由），并且打上了MPLS标签。在代码清单6.21中应用了服务隔离模式，因为我们希望在已经打上MPLS标签的R32f1/0.232上跳过实现WCCPv2重定向这一操作。

在代码清单6.21中，为了防止R32f1/0.236的出口重定向操作重新拦截前面已经完成重定向处理的网络流（重复重定向）而形成重定向回路，在连接到SH48（参见图6-7）的接口R32f1/0.248上执行了“ip wccp redirect exclude in”命令。

说明：由于出口重定向技术必须要执行路由器表检索以访问到界外接口而完成出口重定向，因此何时采用服务隔离模式或使用WCCP出口重定向在于哪种机制能得到更高效的CPU利用率。

代码清单6.22对SH48（参见图6-7）配置进行了简单说明。它启动了逻辑in-path，并与R32上租户F的WCCPv2配置相对应。

代码清单6.22　在SH48上为租户F配置WCCPv2

```
#
interface inpath0_0 ip address 10.2.48.101 /24
ip in-path-gateway inpath0_0 10.2.48.2

#
in-path enable
in-path oop enable
#
wccp enable
wccp service-group 161 routers 10.2.100.32
wccp service-group 162 routers 10.2.100.32
#
```

说明：对于支持重叠支持技术的NSV解决方案而言，在每一个VRF都配备了指定的WAN优化器。此时，附加虚拟设施的WAN优化器最为关键。要注意，WAN优化器必须拥有一个唯一的IP地址，因为这一信息将被泄露给全局IPv4路由地址表，并在各VRF（例如VRF租户E和VRF租户F）间共享这一路由信息。

6.5 在服务汇聚层实施拦截

基于云的SOI中，服务汇聚层（参见第2章图2-1）是整合防火墙以及服务负载平衡SLB的理想位置，DC的服务汇聚层通常是L2和L3的交界处，它支持接入层的多个交换机之间共享智能服务设备（例如防火墙和SLB）。更多细节请参见3.1节。

为什么要在服务汇聚层实施拦截呢？一个简单的回答是：将云端对拦截过程的控制传递到租户或终端用户处，换句话说，从云拦截角度看，如果能在服务汇聚层实施拦截，云服务供应商就可以当甩手掌柜了。

由前述章节讨论内容可知，WCCPv2目前已经基本成为私有云环境中一个事实上的拦截技术，但是如果在终端用户控制时也采用WCCPv2，该租户将需要能够直接访问到L3提供WCCPv2服务的设备。在大多数情况下，L3设备实行多VRF以支持在不同租户间的L3路径隔离，如果在配置时已经将对L3设备的接入分配给某个特定租户，那么该租户将能够看见该L3设备上所有的multi-VRF配置信息，这样将破坏系统的安全。采用虚拟设备上下文（Virtual Device Contexts,VDC）是解决此问题的方法之一。

NX7K交换机和ACESM支持VDC，在本书撰写之际，NX7K最多支持包括默认VDC在内的4个VDC，如果将NX7K作为实现自我管理的WCCPv2服务平台，其有限的支持能力将对NX7K交换机的可扩展性提出挑战。另一方案是将ACESM部署在服务汇聚层，ACESM VDC将不被用于实现SLB，而是被实例化并为每个租户完成拦截和重定向网络流量的任务，在这个方案中，由租户对ACESM VDC进行管理。

本节重点研究在私有云的服务汇聚层，ACESM如何实现拦截功能以完成WAN优化。

接下来小节中将探讨以下内容：

·对服务器机箱的要求

·管理上下文

·用户上下文

·ACESM拦截：桥接模式

·ACESM拦截：路由模式

·利用探测器进行状态监控

·WAN优化器集群冗余

6.5.1 对服务器机箱的要求

应用控制引擎（Application Control Engine,ACE）有两种类型：服务器模块和物理应用，其中物理应用类型的ACE已经超越了本书讨论范围，而ACESM对服务器机箱的要求如下：

·任意Catalyst 6500系列机箱：

·Catalyst 6500系列Supervisor Engine 720或Supervisor Engine 720-10GE。

·Supervisor Engine 720运行IOS软件版本为12.2（18）SXF4

·Supervisor Engine720-10GE运行IOS软件版本为12.2（33）SXH4

·任意Catalyst 7600系列机箱：

·Catalyst 7600系列Supervisor Engine 720以及Route Switch Processor 720。

·Supervisor Engine 720运行IOS软件版本为12.2（18）SXF4或12.2（33）SRB。

·Route Switch Processor 720运行IOS软件版本为12.2（33）SRC。

ACESM将被看成支持交换矩阵的线卡并占用交换机一个插槽。

6.5.2 Admin上下文

通过配置VDC（或虚拟上下文），可以使ACESM支持虚拟化，网络资源将被指定给某一特定上下文或在上下文间共享。在讨论ACESM技术（以图6-8为例）时，我们将使用到以下设备：

·Catalyst 6506-E数据中心交换机（主机名“tl-tsw2”）为服务器机箱，IOS版本为12.2（33）SXH2a。

·在Catalyst 6506-E交换机（tl-tsw2）的第5个插槽安装了一个ACESM设备（主机名：“ACESM-123”），软件版本为3.0（0）A1（4a）。在完成IP连接和管理配置之前，可以通过在tl-tsw2上执行“session slot 5 processor 0”命令访问ACESM-123。默认的用户名/口令为admin/admin，可以使用该用户名和口令直接访问Admin上下文。

说明：admin和www用户都是系统默认用户，可以通过默认方法访问Admin上下文，其中admin是管理员的账户，主要完成管理任务，普通用户账户主要面向XML接口。如果将www用户删除，整个ACESM将无法启用XML接口。

代码清单6.23　展示了在交换机上执行“show module 5”命令以查看ACESM信息。

代码清单6.23　服务机箱的ACESM信息

```
tl-tsw2#show module 5
Mod Ports Card Type                              Model              Serial No.
--- ----- -------------------------------------- ------------------ ----------
  5     1  Application Control Engine Module      ACE20-MOD-K9       SAD111505C2

Mod MAC addresses                       Hw       Fw           Sw           Status
--- ----------------------------------  -------  -----------  -----------  -------
  5  001b.2a65.faac to 001b.2a65.fab3   2.1      8.6(0.252-En 3.0(0)A1(4a) Ok

Mod Online Diag Status
--- ------------------
  5 Pass
```

存在两种主要的上下文类型：Admin和User。Admin是默认创建的上下文，不能对其进行更名操作，也不能删除。User上

下文以及相应的资源配置，都由Admin上下文管理，换句话说，如果云服务供应商希望为特定租户提供User上下文，将需要从Admin上下文来配置它。

说明：ACESM基本代码的默认设置是一个Admin上下文带5个User上下文，不能对Admin进行更名操作，也不能删除Admin上下文。可以通过购买额外的许可来增加默认User上下文的数目，一个Admin模块最多可以扩展至250个User模块。

Admin上下文的基本配置包括：

·Admin上下文的VLAN管理

·Admin上下文的接入管理

·User上下文访问VLAN

·User上下文资源配置

Admin上下文的VLAN管理

为了建立IP连接，需要首先在交换机tl-tsw2创建一个VLAN管理器对ACESM Admin上下文进行管理，然后将同样的VLAN复制到ACESM-123的Admin上下文。这一过程需要6步完成：

·Step1　如代码清单6.24所示，激活tl-tsw2的多个SVI。默认的IOS代码确认只有一个为MSFC-路由功能而定义的SVI将被分配到一个服务模块，“svc multiple-vlan-interfaces”命令可以取消这一默认模式，或者为服务模块（例如ACESM-123）启动多SVI。

说明：寻址链路要求在ACESM和采用路由部署模式的MSFC间使用多SVI技术。

代码清单6.24　激活ACESM的多SVI

```
!
svclc multiple-vlan-interfaces
!
```

·Step2　比较简单，如代码清单6.25所示，创建VLAN管理器（例如VLAN 41）以及它在tl-tsw2上相应的SVI。

代码清单6.25　创建ACESM的VLAN管理器和相应的SVI

```
!
vlan 41
!
interface Vlan41
 ip address 10.41.1.1 255.255.255.0
!
```

·Step3　如代码清单6.26所示，将新创建的VLAN管理器（VLAN 41）分配给tl-tsw2上的一个SVCLC VLAN组（“123”）。调用“svclc vlan-group < group_number > < vlan_list >”命令可以将VLAN分配到一个服务线卡（Service Line Card,SVCLC）VLAN组。

代码清单6.26　将VLAN分配到SVCLC VLAN组

```
!
svclc vlan-group 123 41
!
```

说明：每一个SVCLC VLAN组都可以容纳多个VLAN，但是每一个VLAN只能属于一个SVCLC VLAN组。

·Step4　如代码清单6.27所示，将SVCLC VLAN组“123”与ACESM-123关联起来。可以使用“svclc module < slot-number > vlan group < group-list >”命令，将SVCLC VLAN组“123”被分配到tl-tsw2的第5个插槽，这也是存放ACESM-123的位置。

代码清单6.27　将SVCLC VLAN组与ACESM关联起来

```
!
svclc module 5 vlan-group 123
!
```

说明：多个ACESM可以共享同一个VLAN组。

·Step5　在ACESM-123的Admin上下文中创建SVI的管理器，如代码清单6.28所示。

代码清单6.28　在ACESM的Admin上下文中创建SVI管理器

```
!
interface vlan 41
 ip address 10.41.1.100 255.255.255.0
 no shutdown
!
```

说明：在ACESM上，创建的任意SVI默认都是“shut down”，要记得调用“no shut down”命令来撤销这一默认模式。

·Step6　如代码清单6.29所示，在ACESM-123的管理上下文中定义默认路由。默认定义好的路由的下一跳将指向tl-tsw2上相应的SVI IP（10.41.1.1）。

代码清单6.29　在ACESM的Admin上下文定义默认路由

```
!
ip route 0.0.0.0 0.0.0.0 10.41.1.1
!
```

Admin上下文的接入管理

所有指向ACESM-123 Admin上下文的网络流量都必须经过管理服务协议的显式允许，此过程包含以下3步：

代码清单6.30　创建ACESM Admin上下文的类图

```
!
class-map type management match-any REMOTE_ACCESS
 2 match protocol ssh any
 3 match protocol telnet any
 4 match protocol icmp any
 5 match protocol snmp any
 6 match protocol http any
!
```

·Step1　在ACESM-123的Admin上下文创建一个类映射，如代码清单6.30所示。类图中“REMOTE-ACCESS”定义了允许通向ACESM-123的Admin上下文的网络流量，包括SSH、TELNET、ICMP、SNMP以及HTTP。

·Step2　在ACESM-123Admin上下文创建协议映射，如代码清单6.31所示。协议映

射“REMOTE_MGMT_ALLOW_POLICY”定义了“允许”动作来确认Step1（参见代码清单6.30）中类图匹配成功的网络流量。为了实现接入管理，需要一个类型为“management”的协议映射。

代码清单6.31　在ACESM的Admin上下文中创建协议映射

```
!
policy-map type management first-match REMOTE_MGMT_ALLOW_POLICY
 class REMOTE_ACCESS
  permit
!
```

·Step3　将“REMOTE_MGMT_ALLOW_POLICY”协议映射应用到SVI管理器（参见代码清单6.28），可以在ACESM-123的Admin上下文中调用“service-policy input”命令，如代码清单6.32所示。

代码清单6.32　将协议映射应用到ACESM Admin上下文的SVI管理器

```
!
interface vlan 41
 service-policy input REMOTE_MGMT_ALLOW_POLICY
!
```

说明：目前，ACESM软件版本仅支持任意服务-协议的界内定向。

用户VLAN接入VLAN

通常，为了在ACESM上提供User上下文，要求服务器机箱支持三种VLAN接入：

·面向客户的VLAN

·面向服务器的VLAN

·为WAN优化器集群或簇特定的VLAN

为了解释这个问题，我们在tl-tsw2上创建VLAN7、VLAN9和VLAN30，如代码清单6.33所示。VLAN19属于面向客户的VLAN,VLAN 7属于面向服务器的VLAN，而VLAN30则为WAN

优化器集群服务。以上VLAN都被分配到SVCLC VLAN组123，而它又相应连接到ACESM-123。

代码清单6.33　User上下文的VLAN接入配置

```
!
svclc multiple-vlan-interfaces
!
vlan 7,19,30
!
svclc vlan-group 123 7,19,30
!
svclc module 5 vlan-group 123
!
```

用户上下文的资源分配

ACESM系统资源通过在Admin上下文配置的资源类分配给特定的User上下文。每一个User上下文也相应被赋予某个资源等级。

说明：每一个User上下文都属于一个名为“default”的资源类，只要资源可得（不能保证）这一类别拥有对系统资源的无限制访问权限。如果User上下文中没有用户自定义的资源类别，就可以使用默认资源类别，最多可以定义100个资源类别。

系统不同的资源类别都分配了一个最大和最小的资源比率，最小资源分配意味着一个有保证的资源分配，而最大资源分配既可以被认为是无限制资源使用也可以等同最小资源分配。如果用“unlimited”（例如100%）最大资源分配来定义一个资源等级，允许该资源组中其他的User上下文使用未被利用的那部分资源。

在代码清单6.34中，为“Tenant-G”的User上下文创建了一个名为“Tenant-G-RA”的资源等级，以便下一阶段（参见6.5.6节）能够使用它。这一资源等级能够保证2%（“最小2.0”）的ACESM系统资源，并且允许这一资源类别的其他User上下文可以访问剩下的未被利用或再分配（“最大unlimited”）的资源。

代码清单6.34　User上下文的资源分配配置

```
!
resource-class Tenant-G-RA
 limit-resource all minimum 2.00 maximum unlimited
!
```

代码清单6.35说明了如何在ACESM-123上调用“show resource allocation”命令来验证资源等级信息。

代码清单6.35　资源分配验证

```
ACESM-123/Admin# show resource allocation
-------------------------------------------------------------------
Parameter                 Min          Max          Class
-------------------------------------------------------------------
acl-memory                0.00%        100.00%      default
                          2.00%        100.00%      Tenant-G-RA

syslog buffer             0.00%        100.00%      default
                          2.00%        100.00%      Tenant-G-RA

conc-connections          0.00%        100.00%      default
                          2.00%        100.00%      Tenant-G-RA

mgmt-connections          0.00%        100.00%      default
                          2.00%        100.00%      Tenant-G-RA

proxy-connections         0.00%        100.00%      default
                          2.00%        100.00%      Tenant-G-RA
```

bandwidth	0.00%	100.00%	default
	2.00%	100.00%	Tenant-G-RA
connection rate	0.00%	100.00%	default
	2.00%	100.00%	Tenant-G-RA
inspect-conn rate	0.00%	100.00%	default
	2.00%	100.00%	Tenant-G-RA
syslog rate	0.00%	100.00%	default
	2.00%	100.00%	Tenant-G-RA
regexp	0.00%	100.00%	default
	2.00%	100.00%	Tenant-G-RA
sticky	0.00%	100.00%	default
	2.00%	100.00%	Tenant-G-RA
xlates	0.00%	100.00%	default
	2.00%	100.00%	Tenant-G-RA
ssl-connections rate	0.00%	100.00%	default
	2.00%	100.00%	Tenant-G-RA
mgmt-traffic rate	0.00%	100.00%	default
	2.00%	100.00%	Tenant-G-RA
mac-miss rate	0.00%	100.00%	default
	2.00%	100.00%	Tenant-G-RA

6.5.3 User上下文访问管理

云服务提供商需要在Admin上下文对以下功能（参见6.5.5节）进行管理：

·VLAN管理

·接入管理

·User上下文访问VLAN

·User上下文资源配置

另外，云服务供应商必须在将拦截和重定向配置移交给租户前，在Admin上下文中为指定租户管理User上下文。

为了说明该问题，在ACESM-123的Admin上下文中为租户G创建了User上下文，如代码清单6.36所示租户G的User上下文配置内容，调用“context < context_name > ”命令创建一个命名的User上下文，本处为“租户G”。

调用“allocate-interface vlan”命令将VLAN7、VLAN19和VLAN30（参见代码清单6.33）部署在租户G上，调用“member < resource_class_name > ”命令将“Tenant-G-RA”资源类别（参见代码清单6.34）添加到“租户G”的上下文。

代码清单6.36 User上下文配置

```
!
context Tenant-G
  allocate-interface vlan 7
  allocate-interface vlan 19
  allocate-interface vlan 30
  member Tenant-G-RA
!
```

说明：User上下文命名对大小写敏感。

代码清单6.37展现了如何调用“show context < context_name > ”命令在ACESM-123的Admin上下文中验证User上下文信息。

代码清单6.37 User上下文验证

```
ACESM-123/Admin# show context Tenant-G

Name: Tenant-G, Id: 1
Description:
Resource-class: Tenant-G-RA
Vlans: Vlan7, Vlan19, Vlan30
```

当定义好User上下文后，云服务供应商下一步就该配置User上下文的接入管理了。

User上下文接入管理

在代码清单6.36中已经创建了租户G的Uer上下文，不过为了方便终端用户（租户）登录，云服务供应商需要配置管理IP，最初可以在Admin上下文使用“changeto < context_name > ”命令来访问Use上下文。

由于User上下文没有默认用户，因此获得对租户G上下文访问后，必须为该上下文创建一个管理用户，必须如代码清单6.38中所示一样，显式创建一个这样的用户，用户口令长度要求至少8个字母（最多不超过24个字母），对应“Admin”角色。

代码清单6.38　在租户G上下文中创建管理用户

```
!
username admin password 12345678 role Admin
!
```

代码清单6.39　配置租户G访问控制

```
!
class-map type management match-any REMOTE_ACCESS
 2 match protocol ssh any
 3 match protocol telnet any
```

```
 4 match protocol icmp any
 5 match protocol snmp any
 6 match protocol http any
!
policy-map type management first-match REMOTE_MGMT_ALLOW_POLICY
  class REMOTE_ACCESS
   permit
!
service-policy input REMOTE_MGMT_ALLOW_POLICY
!
```

和Admin上下文类似，所有指向租户G上下文的管理网络流量必须要在相应管理协议映射中显式许可，代码清单6.30和6.31分别定义了租户G上下文的类映射和协议映射，这一过程的说明参见代码清单6.39。在下一节即将介绍的桥接模式中（详细说明请参见6.7节），BVI（桥接组虚拟接口）可以当做管理接口，但协议映射不能直接像在代码清单6.39中描述的那样，直接应用到BVI上，因为代码清单6.39中的协议图是全局适用。

说明：在User上下文对另一个VLAN实行界外管理比利用现有界内VLAN更容易，因此，对云服务供应商将任务移交给终端用户的做法非常容易理解，但是为了方便，我们不会在ACESM配置样例中讨论这一点。

6.5.4 ACESM拦截：桥接模式

从本小节开始，IaaS终端用户或租户将接管ACESM-123租户G的User上下文（ACESM-123/租户G）配置。

图6-8描述了在tl-tsw2（MSFC）、租户G上下文（ACESM-123/租户G）、SERVER 71以及由SH31和SH32组成的WAN优化器集群之间的互联关系，VLAN-19是面向客户的接口，负责将tl-tsw2（MSFC）的SVI连接到VLAN 19，VLAN 7是面向服务器的VLAN接口，具体连接到SERVER 71，VLAN 30负责WAN优化器、SH31、SH32连接至租户G上下文。

说明：图6-8中展示的DC WAN优化器为Riverbed VSH-2050-H虚拟Steelhead设备，支持逻辑in-path功能。分支WAN优化器（为了简便，未在图中显示）为Riverbed SH-1050-H Steelhead设备，以物理in-path方式部署在租户G的分支办公室。

在桥接模式中，租户G上下文采用物理in-path方式部署在面向客户VLAN 19和面向服务器VLAN 7间，所有位于这些VLAN间的网络流量都需要采用透明桥接模式。鉴于租户G上下文是采用物理in-path方式部署，它将担负对位于租户G分支机构的客户端与SERVER 71间网络流量进行拦截和重定向任务，以完成WAN优化。更多有关ACESM桥接模式的细节，请参见3.2.1节。

与使用桥接模式实施ACESM拦截相关内容包括以下小节：

·桥接模式接口配置

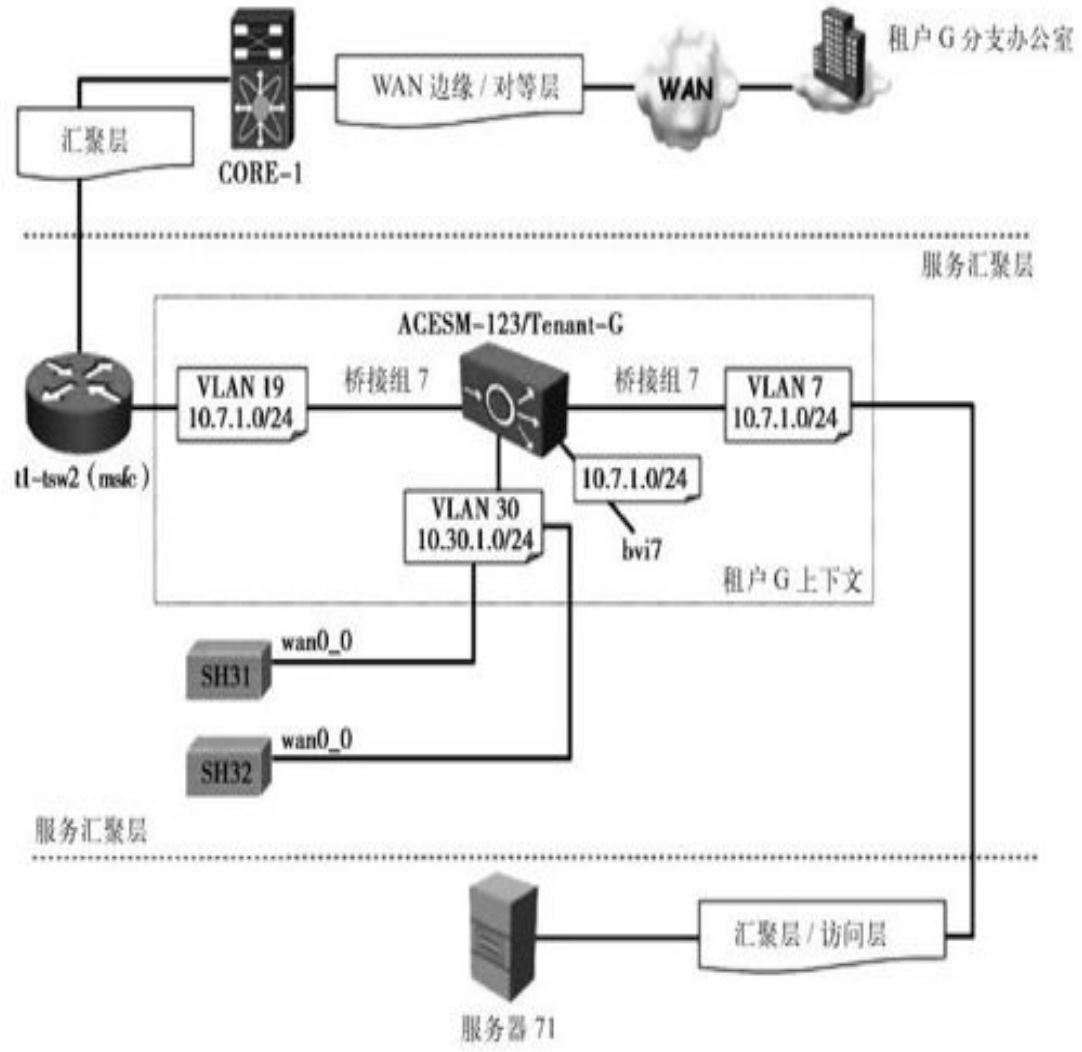


图　6-8　桥接模式的ACESM拦截

·路由和桥接集成

·配置实际服务器和服务器集群

·APR间隔

·为拦截和重定向配置服务策略

在下述章节中实现的配置（代码）都基于图6-8中的环境。

桥接模式接口配置

桥接模式中，ACESM通常会使用SVI接口。租户G上下文（参见图6-8）的桥接模式接口配置分成以下6个步骤：

·step1　创建属于VLAN 7的面向服务器SVI，如代码清单6.40所示。桥接模式实现过程中，面向服务器的SVI属于桥接接

口（更多细节请参考“路由和桥接集成”部分），桥接接口基于L2，不需要配置IP地址。

代码清单6.40　桥接模式中面向服务器SVI配置

```
!
interface vlan 7
 no shutdown
!
```

·step2　创建属于VLAN 19面向客户的SVI，如代码清单6.41所示。面向客户SVI也属于桥接接口（更多细节，请参考“路由和桥接集成”部分）。

说明：桥接类型只包括面向服务器和面向客户的SVI。

代码清单6.41　桥接模式中面向客户SVI配置

```
!
interface vlan 19
 no shutdown
!
```

·step3　为WAN优化器集群创建属于VLAN 30的SVI，如代码清单6.42所示。WAN优化器集群的SVI接口基于L3，需要配置IP地址。

代码清单6.42　WAN优化器集群的SVI配置

```
!
interface vlan 30
 ip address 10.30.1.123 255.255.255.0
 no shutdown
!
```

·step4　创建允许通过ACESM的访问控制列表ACL，如代码清单6.43所示。ACL如果命名为“any”则意味着允许任意网络流经过租户G上下文，调用“access-group input < ACL_name > ”命令可以被应用到全局的界内拦截。

代码清单6.43　配置租户G上下文的ACL

```
!
access-list any line 8 extended permit ip any any
!
access-group input any
!
```

·step5　对新创建的SVI接口禁用TCP归一化，如代码清单6.44所示。ACESM默认支持TCP归一化，这将对WAN优化器的自动发现过程（例如TCP可选值以及TCP序列号变更）产生干扰，为了保证WAN优化器能正确工作，必须禁用该ACE安全功能。

代码清单6.44　在租户G上下文中禁用TCP归一化

```
!
interface vlan 7
 no normalization
!
interface vlan 19
 no normalization
!
interface vlan 30
 no normalization
!
```

说明：Riverbed Steelhead设备的自动发现过程使用TCP选项76和78。

·step6　激活SVI的mac-sticky并与WAN优化器集群相连，如代码清单6.45所示。mac-sticky特性确保经过租户G上下文的返回网络流量将被送往同一WAN优化器。它在租户G上下文与WAN优化器间建立起L2邻接，并且负责处理最初的SYN包。mac-sticky特征一般放在部署了WAN优化器集群（不止一个WAN优化器）的SVI上配置。

代码清单6.45　为WAN优化器集群激活SVI的mac-sticky特征

```
!
interface vlan 30
 mac-sticky enable
!
```

说明：Riverbed Steelhead设备的连接转发功能也可以被看成ACESM mac-sticky特征的替代品。

路由和桥接集成

如果桥接模式实现了路由和桥接集成（Integrated Routing and Bridging,IRB），就可以借助PBR在桥接域和路由域间完成路由。BVI是ACESM内的一个虚拟接口，作为路由接口代表桥接组，BVI接口个数与BVI和配置好的桥接组间的联接链路数目相同。那些路由接口内的包，如果是指向桥接组某一片段的主机，都将被路由转发给BVI。然后再经过BVI被相应转发至某个与桥接组相连的桥接接口。

界内接口VLAN 7（参见代码清单6.40）以及接口VLAN 19（参见代码清单6.41）都属于桥接接口，这些SVI都与桥接组7相连，如代码清单6.46所示。当部署好桥接组后，VLAN 7和VLAN 19就实现了透明桥接。

代码清单6.46　将桥接组与相应SVI联系起来

```
!
interface vlan 7
 bridge-group 7
!
interface vlan 19
 bridge-group 7
!
```

代码清单6.47展示了BVI的配置。BVI自身是路由接口，需要配置IP地址。BVI接口序号为7，该序号源于桥接组7（参见代码清单6.46）。由于此时实现的是桥接（透明）模式，BVI 7，属于VLAN 19和VLAN 7的SVI均处在同一子网内10.7.1.0/24。

说明：SERVER 71的默认网关指向IP地址10.7.1.1（为了简化，未在图6-8中显示），这是tl-tsw2（MSFC）上VLAN 19的SVI。

代码清单6.47　定义桥接组的虚拟接口

```
!
interface bvi 7
 ip address 10.7.1.123 255.255.255.0
 no shutdown
!
```

说明：任何在ACESM上创建的BVI默认是关闭的。要记住使用“no shutdown”命令来更改默认设置。

ACESM并非路由，它需要一个默认路由（或某些特定静态路由）的配合来完成对那些超出它可达范围地址的访问。如图6-8所示，SERVER71的子网、SH31以及SH32都是再没有下一跳向下网络流量的子网，因而需要一个“默认”路由将来自这些子网的网络流量转发至“外部世界”。代码清单6.48展示了在租户G的上下文如何完成这一过程，样例中默认路由将向上网络流量送至IP地址10.7.1.1（为了简化，未在图6-8中显示）的SVI，该SVI属于tl-tsw2（MSFC）上的VLAN 19。

代码清单6.48　桥接模式的默认路由配置

```
!
ip route 0.0.0.0 0.0.0.0 10.7.1.1
!
```

配置实际的服务器和服务器集群

当在ACESM的User上下文中安装服务器负载平衡配置时，必须要定义实际的服务器实例即rservers。从WAN优化器的角度来看，这些rservers就是真正的WAN优化器。

如代码清单6.49所示，SH31和SH32（参见图6-8）都定义成rservers，要求调用“inservice”命令启动这些服务器。由于WAN优化器（SH31和SH32）担负着透明TCP代理的任务，不适用NAT，换句话而言，即必须要保留那些因重定向/负载平衡发至WAN优化器的网络流量的IP地址信息，在服务器集群定义时中需使用“transparent”关键字来启动这一特殊功能（分离模式）。调用“rservers < reserver_host_name > ”命令可以将reserver添加到服务器集群中。同样要记住调用“inservice”命令来激活服务器集群中的rservers。

说明：用户可以使用“no inservice”命令平缓关掉服务器。

代码清单6.49　实际服务器和服务器集群配置

```
!
rserver host SH31
 ip address 10.30.1.31
 inservice
rserver host SH32
 ip address 10.30.1.32
 inservice
!
serverfarm host SH-FARM-G
 transparent
 predictor hash address 255.255.255.255
 rserver SH31
  inservice
 rserver SH32
  inservice
!
```

负载平衡（Load Balance,LB）算法被认为是ACESM中的预言家，用来挑选一个rserver以处理新到达的连接。存在两类预测算法：负载预测以及网络传输模式预测。

负载预测包括以下负载平衡算法：

·最小连接，可选慢启动

·响应时间

·最小负载

·最小带宽

网络传输模式预测涵盖以下负载平衡算法：

·散列地址：源或目标或者两者都是，掩码可选

·散列cookie（适用于L7 LB）

·散列报头（适用于L7 LB）

·散列HTTP URL（适用于L7 LB）

·轮循，可选加权（如果在服务器集群定义时没有显式指明预测算法，则该算法为默认算法）

·散列layer 4负载均衡

推荐采用散列地址作为处理到WAN优化器的TCP连接的负载均衡的预测算法，它能够基于源IP地址、目标IP地址或同时基于这两种IP地址进行负载平衡，这样可以确保对每一个网络传输流实例都能够在一个WAN优化器上进行处理。代码清单6.49中应用了散列源以及目标地址，/32（255.255.255.255）掩码隐含了算法将检查和使用用来进行散列的IPv4地址的所有4个八位元组。

代码清单6.50　验证服务器集群中实际服务器的状态

```
ACESM-123/Tenant-G# show serverfarm SH-FARM-G
 serverfarm    : SH-FARM-G, type: HOST
 total rservers : 2
 ----------------------------
                                          ----------connections--------
      real                weight state       current    total
   ----+-----------------+-----+---------+--------+-----------------
   rserver: SH31
      10.30.1.31:0        8     OPERATIONAL 0          0
   rserver: SH32
      10.30.1.32:0        8     OPERATIONAL 0          0
```

代码清单6.50展示了如何调用“show serverfarm < serverfarm_name > ”命令来验证服务器集群中的reserver的状态。如代码清单6.50所示，rservers SH31和SH32都处于“OPERATIONAL”状态，也就是到目前为止一切正常。

ARP间隔

“arp interval”命令指明了ACESM向配置好的主机（例如，网关、rservers以及后发现的主机）发送ARP请求的时间间隔（以秒为单位），默认300秒，代码清单6.51将ARP间隔缩减至15秒以加速桥接模式下主机的发现速度。

代码清单6.51　缩减默认ARP间隔

```
!
arp interval 15
!
```

调用“show arp”命令可以检查ACESM的ARP表的信息。从代码清单6.52的命令输出可以看出，每一个rserver（例如，

SH31和SH32）都拥有一个ARP入口，默认网关（譬如可以是，默认路由的下一跳），以及后发现的主机（例如SERVER 71）。

代码清单6.52　ARP表验证

```
ACESM-123/Tenant-G# show arp

Context Tenant-G
------------------------------------------------------------------------
IP ADDRESS    MAC-ADDRESS        Interface  Type       Encap  NextArp(s) Status
------------------------------------------------------------------------
10.7.1.1      00.19.07.b8.5d.c0  vlan19     GATEWAY    26     11 sec     up
10.7.1.123    00.1b.2a.65.fa.ad  bvi7       INTERFACE  LOCAL  -          up
10.7.1.71     00.50.56.a7.1b.13  vlan7      LEARNED    34     9997 sec   up
10.30.1.31    00.0e.b6.84.eb.22  vlan30     RSERVER    32     13 sec     up
10.30.1.32    00.0e.b6.85.50.54  vlan30     RSERVER    33     6 sec      up
10.30.1.123   00.1b.2a.65.fa.ad  vlan30     INTERFACE  LOCAL  -          up
------------------------------------------------------------------------
Total arp entries 6
```

为拦截和重定向配置服务策略

ACESM负载平衡支持WAN优化器网络流量的拦截和重定向功能，对作为“服务器”的WAN优化器而言，拦截和重定向配置与定义ACESM负载平衡动作是等价的，配置拦截和重定向协议时应该考虑类匹配和协议匹配。

L4负载平衡的主要原则是需要配置一个虚拟IP（VIP）地址，然而从WAN优化器拦截和重定向观点来看，由于WAN优化器集群处于分离模式（更多细节请参考“实际服务器和服务器集群配置”一节），因此无法提供一个实际的IP地址。如果放宽条件范围，而不限制必须要能够匹配任意指定VIP，往返于实际服务器（例如，SERVER 71）和WAN优化器集群间（例如，SH31和SH32）的TCP会话将能够达到负载平衡（例如，拦截和重定向）。

代码清单6.53展示了在条件中定义“TCP-ANY”类匹配条件，以实现任意TCP传输都能匹配到任意的VIP地址。

代码清单6.53　桥接模式类匹配设置

```
!
class-map match-all TCP-ANY
  8 match virtual-address 0.0.0.0 0.0.0.0 tcp any
!
```

说明：代码清单6.53中的类匹配条件是假设当前在相应服务器上只有一个需要优化的TCP应用运行，而在大多数情况下，系统推荐根据需要优化的TCP应用个数以及TCP应用类型（例如，依据TCP目标端口）来细化匹配条件。

代码清单6.54　桥接模式负载平衡协议匹配设置

```
!
policy-map type loadbalance first-match LB-SH-G
  class class-default
   serverfarm SH-FARM-G
!
```

为了实现TCP会话的负载平衡（例如拦截和重定向），需要使用一个类型为“loadbalance”的协议匹配。代码清单6.54展示了创建负载平衡协议匹配“LB-SH-G”，由于样例中只存在一个名为“SH-FRAM-G”服务器集群（参见代码清单6.49），因此使用了内置类名“class-default”。

另外，还需要另一个类型为“multi-match”的协议匹配。代码清单6.55展示了如何创建名为“INTERCEPT”的multi-match协议匹配，此协议匹配的主要功能是与“TCP-ANY”（参见代码清单6.53）类匹配，以实现“LB-SH-G”协议匹配（参见代码清单6.54）的负载平衡，可以通过调用“loadbalance policy LB-SH-G”命令完成。为了保证负载平衡操作能正确实施，必须调用“loadbalance vip inservice”初始化VIP，然后再将multi-mathc应用到拦截的SVI上。所涉及的拦截SVI为VLAN 17的面向服务器SVI以及VLAN 19的面向客户SVI，调用“service-policy input”命令可以将“INTERCEPT”协议匹配应用到这些接口上。

代码清单6.55　桥接模式multi-match协议匹配设置

```
!
policy-map multi-match INTERCEPT
  class TCP-ANY
    loadbalance vip inservice
    loadbalance policy LB-SH-G
!
interface vlan 7
  service-policy input INTERCEPT
!
interface vlan 19
  service-policy input INTERCEPT
!
```

调用“show service-policy < multi-match_policy-map_name >”命令可以验证服务器协议的配置结果，由代码清单6.56中命令输出结果可知，当前配置好的服务协议处在“ACTIVE”状态，VIP为“INSERVICE”状态，这意味着租户G的上下文已经准备好对送至WAN优化器集群的待优化的网络流量进行拦截和重定向处理。

代码清单6.56 桥接模式服务器协议验证

```
ACESM-123/Tenant-G# show service-policy INTERCEPT

Status: ACTIVE
--------------------------------
Interface: vlan 7 19
  service-policy: INTERCEPT
class: TCP-ANY
     loadbalance:
       L7 loadbalance policy: LB-SH-G
       VIP Route Metric      : 77
       VIP Route Advertise   : DISABLED
       VIP ICMP Reply        : DISABLED
       VIP State: INSERVICE
       curr    conns    : 0   , hit count        : 0
       dropped conns    : 0
       client pkt count : 0   , client byte count: 0
       server pkt count : 0   , server byte count: 0
```

6.5.5 ACESM拦截：路由模式

除了桥接模式，终端用户也可以使用路由模式完成ACESM拦截部署。更多有关ACESM路由模式的细节请参考第3章的“SLB桥接和路由模式”。

在实现路由模式时，面向客户SVI和面向服务器SVI分别属于不同的广播或子网范围。如图6-9所示，VLAN 19的面向客户SVI现在位于子网10.19.1.0/24，而VLAN 7的面向服务器SVI位于子网10.7.1.0/24。子网10.19.1.0/24现在成为WAN优化器集群子网10.30.1.0/24以及SERVER 71子网10.7.1.0/24的中间子网。换句话说，为了转发往返SERVER 71的网络流量，租户G上下文变成了一个L3下一跳，这样才能实施拦截和重定向操作。

图6-9是ACESM路由模式拦截的一个基本部署，以下各章节中都要引用这一方案，包括：

·路由模式接口配置

·使用探测监控系统状态

·配置TCP探测器

·WAN优化器集群冗余

·WAN优化器集群冗余样例

上述小节中所实现的配置方案（或代码）都是基于图6-9的设置。

ACESM路由模式的配置方法绝大多数都与桥接模式相同，为了简便，在下一小节中，我们将只对路由模式接口配置进行详细说明。

路由模式接口配置

路由模式接口配置需要对面向客户SVI和面向服务器SVI在桥接模式配置（参见“桥接接口配置”的内容）基础之上再进行一些额外处理。

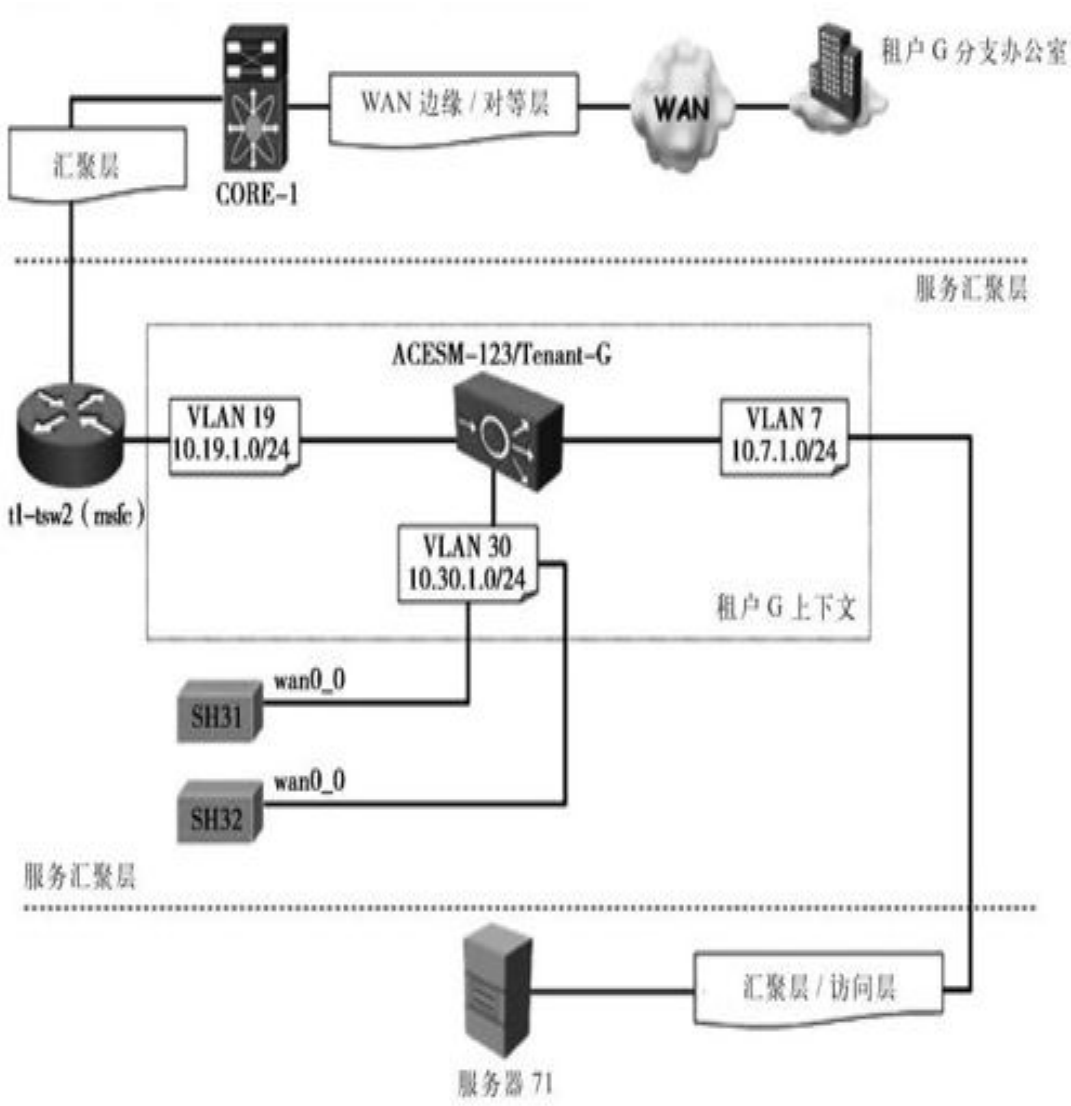


图　6-9　路由模式的ACESM拦截

如图6-9所示，在路由模式中对BVI不作要求，VLAN19的面向客户SVI的IP地址被设为10.7.1.123，代码清单6.57中对租户G上下文中的这些SVI更新配置进行了说明，当IP地址确定后，这些SVI变成了路由接口，默认路由的下一跳现在为10.19.1.1（为了简便，未在图6-9中展示），SVI的IP地址属于tl-tsw2（MSFC）的VLAN19。租户G上下文中这些SVI的更新配置如代码清单6.57所示。根据指定的IP地址，这些SVI变成了路由接口。此时，默认路由的下一跳为10.19.1.1（为了简便，未在图6-9中显示），即tl-tsw2（MSFC）上的VLAN 19的SVI的IP地址。

代码清单6.57　路由模式接口配置

```
!
interface vlan 7
 ip address 10.7.1.123 255.255.255.0
 no normalization
 service-policy input INTERCEPT
 no shutdown
!
interface vlan 19
 ip address 10.19.1.123 255.255.255.0
 no normalization
 service-policy input INTERCEPT
 no shutdown
!
ip route 0.0.0.0 0.0.0.0 10.19.1.1
!
```

说明：在路由模式中，直接可达L3下一跳或默认服务器网关将是ACESM自身，SERVER71默认网关IP地址为10.7.1.123（为了简便，未在图6-9中展示），位于租户G上下文的VLAN 7面向服务SVI上。

利用探测器实现系统监控

ACESM支持两种类型系统监控：被动和主动。本节重点讨论ACESM的主动系统监控方法，这一方法将向实际服务器发出间歇性请求即探测，如果服务器未在规定时间间隔内返回应答，就将它移出可用服务器。被动的系统监控技术超出了本书的探讨范围。

探测器定义了要发送的请求类型，希望得到的应答内容，以及重新请求的时间间隔和超时限制，探测器将与某个服务器或服务器集群相关。目前，ACESM拥有17个内置探测器类型：

·DNS

·DNS

·Echo

·Finger

·FTP

·HTTP

·HTTPS

·ICMP

·IMAP

·POP3

·RADIUS

·RTSP

·SIP

·SMTP

·SNMP

·TCP

·Telnet

·UDP

其他需要定制的探测器（例如，a.k.a脚本探测器）可以使用工具命令语言（Tool Command Language,TCL）创建，TCP探测器的配置将在下节讨论，其他类型的探测器则不在本书讨论范围。

TCP探测器配置

可以使用TCP探测器来监测WAN优化器的系统状态。代码清单6.58展示了如何创建名为“CHK-PORT-7800”的TCP探测器，并用来监视由SH31和SH32（参见图6-9）组成的“SH-FARM-G”（参见代码清单6.49）状况。由于7800端口是Riverbed Steelhead设备（SH31和SH32）的TCP优化服务端口，因此在TCP探测器“CHK-PORT-7800”将该端口定义为待监控端口。

通过调用“interval”命令，系统每隔5秒（默认设置为120秒）向SH31和SH32的7800端口发送一条探测信息，“passdetect interval”命令指明了向一个出现故障的WAN优化器发送探测消息的时间间隔为2秒（默认为300秒），“passdetect count”命令规定了连续成功的探测器响应次数（当将之前出现故障的WAN优化器状态重新变更成“SUCCESS”时，必须要求该参数）为2（默认为3）。当ACESM发出一个探测消息后，预期响应时间不超过10秒，在代码清单6.58中，使用“receive”命令，将该值设置成了15秒。

代码清单6.58　配置WAN优化器的TCP探测器

```
!
probe tcp CHK-PORT-7800
  port 7800
  interval 5
  passdetect interval 2
  passdetect count 2
  receive 15
!
serverfarm host SH-FARM-G
  transparent
  predictor hash address 255.255.255.255
  probe CHK-PORT-7800
  rserver SH31
    inservice
  rserver SH32
    inservice
!
```

说明：当ACESM将某个WAN优化器状态标记为“FAILED”之前，它必须确定已经有一连串的探测器失败了。默认情况下，当出现三次连续探测失败，ACESM会将该WAN优化器标记为“FAILED”。可以调用“faildetect < retry-count > ”命令来改变参数值。代码清单6.58中使用了默认的重复确认次数，因此不需要特别设置fail-detect参数。

代码清单6.59　WAN优化器的系统状态

```
ACESM-123/Tenant-G# show probe CHK-PORT-7800
probe        : CHK-PORT-7800
type         : TCP, state : ACTIVE
----------------------------------
  port       : 7800    address      : 0.0.0.0         addr type  : -
  interval : 5       pass intvl   : 2               pass count : 2
  fail count : 3       recv timeout : 15
                      ---------------- probe results ------------------
  probe association   probed-address   probes   failed   passed    health
  ------------------------------+--------+--------+--------+-------
  serverfarm  : SH-FARM-G
    real      : SH31[0]
                      10.30.1.31       6        0        6         SUCCESS
    real      : SH32[0]
                      10.30.1.32       13       13       0         FAILED
```

“show probe”命令可以查看SH31和SH32的系统状态，引发一个故障，人为地停止WAN优化器，然后使用“show probe”命令查看其状态，从代码清单6.59的命令输出可见，SH32的系统状态为“FAILED”。

说明：停掉WAN优化器不影响其IP连接，实际上，此时IP连接依然有效，因此，如果使用ICMP探测器，将显示系统依然为“SUCCESS”的状态。这也是为什么TCP探测器比ICMP探测器应用更广泛的原因，因为TCP探测器可以同时发现L3和L4两类连接问题。

6.5.6 WAN优化器集群冗余

除了提供冗余WAN优化器这样的增值（优惠）服务，云服务供应商还希望能够处理类似整个WAN优化器集群都发生故障的情况。换句话说，如果SH31和SH32（参见图6-9）组成的“SH-FRAM-G”（参见代码清单6.58）都出现故障而不可达时，该怎么办呢？如果系统没有备份服务器集群，在服务器集群故障后，实际的服务器SERVER 71将不可访问，有三种方法可以修复该类错误：

·多个WAN优化器集群：例如，“SH-FARM-G-1”处理“Server-Farm-1”上的WAN优化，“SH-FARM-G-2”处理“Server-Farm-2”的WAN优化，“SH-FARM-G-1”被配置成“SH-FARM-G-2”的备份，反过来也是一样，“SH-FARM-G-2”被配置成“SH-FARM-G-1”的备份。如果遇到多个服务器集群需要不同的WAN优化器集群进行优化时，这种特殊备份方法的代价十分惊人。它不适用于系统中只包含一个WAN优化器集群或者是很多服务器集群同时依靠唯一一个WAN优化器集群的情况。

·指定备份WAN优化器集群：使用一个特定的WAN优化器集群为某个现有集群做备份是比较好的一个解决方案，但是终端用户又必须为因此产生的额外开销买单。

·实际的服务器集群：实际服务器集群自身可以作为备份使用，但是前提是当WAN优化器集群发生故障后，实际服务器集群依然可访问。这是性价比最高的备份方案，尽管付出的代价就是在WAN优化器故障期间，系统将无法再进行WAN优化。

图6-9中，将实际服务器集群SERVER 71作为了WAN优化器的备份，更多细节请参考后续章节。

说明：通过一对ACESM来实现冗余（或容错）方法不在本书讨论范围之内。

WAN优化器冗余样例

代码清单6.60展示了使用实际服务器集群（SERVER 71）作为WAN优化器（SH-FRAM-G）的备份服务器的配置方案，它是接着代码清单6.58来的。SERVER 71（参见图6-9）在服务器集群“BACKUP-G”中被定义成rserver。由于SERVER 71此时为WAN优化器集群“SH-FRAM-G”（参见代码清单6.58）的备

份，“transparent”关键词依然可用。如代码清单6.60所示，可以在“policy-map type loadbalance first-match LB-SH-G”的下一行，调用带“backup”关键字的“serverfarm”命令，来定义备份服务器集群。

可以调用“show serverfarm”命令来验证当前系统的备份服务器集群状态。命令执行结果如代码清单6.61所示，并没有注册到当前任何连接上，因为WAN优化器集群“SH-FRAM-G”依然处在正常的工作状态。

代码清单6.60　WAN优化器备份集群配置

```
!
rserver host SERVER71
  ip address 10.7.1.71
  inservice
!
serverfarm host BACKUP-G
  transparent
  rserver SERVER71
    inservice
!
policy-map type loadbalance first-match LB-SH-G
  class class-default
      serverfarm SH-FARM-G backup BACKUP-G aggregate-state
!
```

代码清单6.61　在WAN优化器集群发生故障前的备份集群状态

```
ACESM-123/Tenant-G#  show serverfarm BACKUP-G
 serverfarm     : BACKUP-G, type: HOST
 total rservers  : 1
 ---------------------------
                                          ---------connections-----
      real            weight state        current     total
 ---+---------------+------+----------+---------+-------------
   rserver: SERVER71
      10.7.1.71:0     8      OPERATIONAL  0          0
```

为了人为制造WAN优化器集群故障，将SH31和SH32上的WAN优化器都变成不可用，然后调用“show probe”命令，如代

码清单6.62所示，SH31和SH32的系统状态都变成“FAILED”，此时整个WAN优化器集群也不可用。

代码清单6.62　当WAN优化器集群发生故障后验证系统状态

```
ACESM-123/Tenant-G# show probe CHK-PORT-7800

probe          : CHK-PORT-7800
 type          : TCP, state : ACTIVE
-------------------------------------
  port         : 7800    address     : 0.0.0.0         addr type : -
  interval     : 5       pass intvl  : 2              pass count : 2
  fail count   : 3       recv timeout: 15
                         ---------------- probe results ------------------
  probe association      probed-address  probes   failed     passed       health
  ---------------------  --------------+-------+---------+---------+------
  serverfarm : SH-FARM-G
    real       : SH31[0]
                         10.30.1.31        19919    780       19139        FAILED
    real       : SH32[0]
                         10.30.1.32        21361    3181      18180        FAILED
```

为了达到验证目的，从租户G（参见图6-9）的某个远程分支的客户端启动一个发送给SERVER71的HTTP会话，能够成功建立会话。

说明：Web服务器是唯一运行在SERVER71上需要WAN优化的TCP应用。

代码清单6.63使用“show serverfarm”命令提供了另外一种查看备份服务器集群状态的方法。命令输出中注册到一个现有连接，验证了WAN优化器集群的备份集群“BACKUP-G”已经开始工作。

代码清单6.63　在WAN优化器集群发生故障后的备份集群状态

```
ACESM-123/Tenant-G# show serverfarm BACKUP-G
 serverfarm     : BACKUP-G, type: HOST
 total rservers : 1
```

```
.............................
                                                ----------connections-------
   real                 weight state       current      total
---+--------------------+-----+---------+---------+--------------
rserver: SERVER71
    10.7.1.71:0         8     OPERATIONAL 1          1
```

说明：代码清单6.60所展示的WAN优化器备份集群配置工作在从客户端发起的TCP会话中进行，其他类型的配置（为了简化未展开讨论）则需要工作在从服务器端发起的TCOP会话中进行。

6.6 小结

由于WAN优化可以消除WAN时延的不利影响，进一步扩大云的应用领域，WAN优化已成为基于云的服务发布体系或SIO体系中一个重要的因素。考虑实现灵活性，确保WAN优化能够在云基础设施的不同层次中进行部署非常重要，这些层包括：

·虚拟机器层

·核心/汇聚层

·WAN边缘/对等层

·服务汇聚层

本章讨论了在不同基础设施层中的拦截技术，以实现对往返终端主机间的需要进行优化的网络流量进行拦截和重定向处理。在VM层，由于集中部署的缘由，可以使用一个特殊的接口驱动或主机代理完成拦截并具备可扩展性，但是这一方法对服务器的安装有新的要求，需要打破原始界限。

WCCPv2和ACESM在私有云部署中，是更为常规的网络拦截和重定向机制。WCCPv2被应用于核心/汇聚层，以及WAN边缘/对等层，因为它能够得到来自这些层上L3设备的支持。ACESM部署在服务汇聚层，提供服务负载平衡功能。在WAN优化器上下文中，由ACESM负载平衡处理完成网络流量的拦截和重定向任务。最后，本章还探讨了私有云的不同层中，WCCPv2部署的技术细节以及ACESM拦截技术。

第7章　SAN扩展及IP存储

任何时候都要给自己留条后路。

——米拉·库尼斯（Mila Kunis）

简介

在第4～6章，我们探讨了私有云的WAN优化，第7章将关注另外一个私有云构件——存储模块（参见图2-1）。本章将讨论SAN扩展设计及解决方案，以便能够在私有云计算的环境中实现多个存储模块的互联。正如一句俚语中提到的那样，“别把你所有的鸡蛋（数据/数据库）都放在同一个篮子（DC）里”，只需想象一下当整个全球性社区访问DC而对DC不同组件所产生的压力，就能够理解如果只有一个DC（或“云计算机”），峰值终端用户迟早会耗尽系统资源。在一个充满不确定性的时代，不论天灾（龙卷风、地震、洪灾等）还是人祸单独一个DC在面对灾难时总是非常脆弱的，因此在私有云环境中无疑需要不止一个DC分布在全球用户区域，确保业务持续性（Business Continuity,BC），并提供灾难恢复（Disaster Recovery,DR）。BC和DR都是面向服务基础设施SOI必不可少的一部分，由云IaaS管理。

在谈到BC、DR以及终端用户总数时，物理距离扮演了一个重要角色。随着物理距离的增加，可服务的用户总数也将增加（更大地理范围的结果），用户传输负载也增大了，服务质量可能下降，不可预计故障的处理责任也随之增大。可以同时支持BC和DR，又能更有效地实现终端用户传输负载平衡的方法之一，就是使用多个DC站点。

图7-1给出了DC和BR一个大概距离的示意，两难的抉择永远是：为了安全，站点要相隔足够远，而考虑到成本，距离又要足够近。为了支持BC，备份DC应该比较靠近（在城域网可以覆盖的范围内）主DC。不一定总需要单独的DR中心，从DC也可以是一个活动DC，拥有自己的服务对象，兼任另一个位于不同物理地点DC的DR。如果对DR有严格要求（遵守法规），推荐使用一个超出区域或国家范围，在另一个不同地理范围的远程DC。

采用多DC站点后，每一个DC可以拥有自己的应用服务器、网络设施、存储设备等，但还有另外一个问题需要考虑：

数据复制。位于不同DC上的数据库必须是一致的。别忘记了，合格的BC和DR是不允许孤立DC的存在的。用户怎样才能获得一致的远程复制呢？答案就是SAN扩展。

说明：本书中提及的DC/DR站点均指热备份站点，它拥有原始站点结构的复制，包括系统硬件信息以及基本完整的用户数据备份。

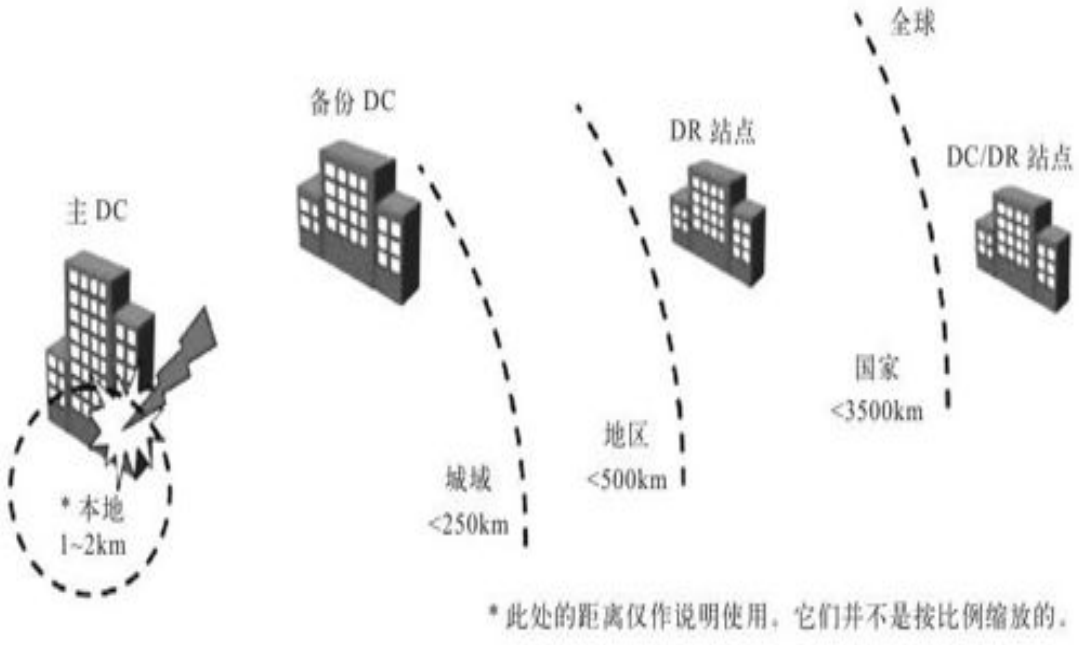


图　7-1　DC和DR站点间离范围

7.1 SAN扩展概述

SAN扩展为各种企业DC提供了互联，这些企业DC横跨了校园、城域或WAN，也可以对现有这些DC间的SAN片段进行扩展，SAN同时还是另一种整合技术，它能够将各种物理分离的DC连接起来组成一个虚拟DC集群，为终端用户提供更棒的访问能力，以及更强的可靠性、可获得性以及服务能力（Reliability、Availability and Serviceability,RAS）。

图7-2（源自图1-2）展示了在私有云计算环境中的两个存储模块间实施SAN扩展样例，两个存储模块位于不同的地区。两个DC间的距离可能是校园、城域或者比较广域的范围。SAN扩展解决方案包括：

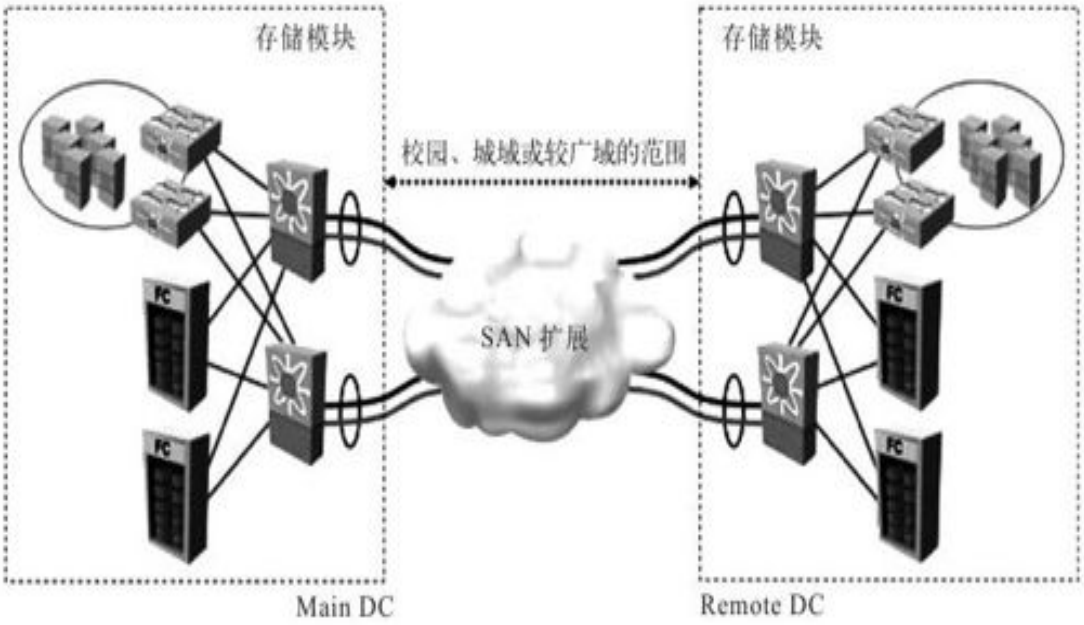


图 7-2 私有云上的SAN扩展

·导向光纤或暗光纤

·波长服务，例如，密集波分复用（Dense Wavelength Division Multiplexing,DWDM）和稀疏波分复用（Course Wavelength Division Multiplexing,CWDM）。

·同步光网络（Synchronous Optical Networking,SONET）以及同步数字系列（Synchronous Digital Hierarchy,SDH）。

·IP光纤通道（FCIP）

导向光纤（可达10km以上）、DWDM（通过放大，可达200km以上）以及CWDM（可达100km）都是连接城域或局部范围内的SAN片段（岛）的常用方法。SONET/SDH（数千公里）常用在国家级别而FCIP（数万公里距离）则面向更长的WAN距离范围。

说明：波长服务以及SONET/SDH服务均属于Layer-1（L1）服务，运行在L2或更高层次的更广范围的协议可以透明地使用这些L1服务。

7.1.1 数据恢复机制

设计一个健壮的SAN扩展系统，需要考虑两个基本的数据恢复原则：恢复点目标（Recovery Point Objective,RPO）以及恢复时间目标（Recovery Time Objective,RTO）。RPO标准定义了数据可以损失的比例，它由最近一次备份的时间或者标记为可用的数据起点决定。用户系统能允许的最长故障恢复时间由RTO标准定义。

RPO和RTO越小意味着恢复代价越高。其中，RTO偏低要求有连续的数据保护以及同步复制，而RTO偏低则要求具备聚簇或热备份系统，RPO和RTO越大意味着恢复代价越低。远程备份可以满足粗粒度RPO的要求，而冷备份系统则能够满足更大粒度RTO的需求。RPO和RTO随具体应用不同而不同，这些标准也会随着可丢失数据量的不同而波动（RPO低但是RTO高），例如金融和医疗保健类数据，或者是电子商务web服务器这类不能出现故障的实时系统（RPO高但是RTO低）。

说明：在第4章里我们重点探讨了WAN优化以确保云部署中终端用户的性能。WAN优化同样可以为降低RTO和提高RPO提供帮助，差不多所有的WAN优化生产厂商都为远程备份软件提供了改进措施，尽管不同厂商和设备的改进效果并不相同。Riverbed和Silver Peak在复制环境中非常强健，例如，Riverbed在应用层对SRDF/A就提供了改进方案。

7.1.2 关键的设计原则

除了RPO和RTO设置外，其他重要的SAN扩展设计原则还包括：

·远距离光纤通道FC流控制

·诸如以下各类应用，包括：

·远程备份

·镜像和快照

·同步及异步复制

远距离FC流控制

缓冲区至缓冲区信用数（Buffer-to-Buffer Credit,BB_Credit）机制提供了FC链路级别流控制。光纤登录（Fabric Login,FLOGI）过程将告知每一个N_端口t和F_端口可接收帧的BB_Credit峰值数目。同样，交换链路参数（Exchange Link Parameters,ELP）过程也将告知每一个E_端口可接收的BB_Credit峰值端口数目。

说明：有关更多的F_端口、N_端口、E_端口、FLOGI以及ELP的技术细节，请参见第2章的注释。

图7-3展示了在一个近距离FC发送端口与接收端口光纤连接上的BB_Credit操作。每当发送端口发送一个帧，端口就将接收端口的BB_Credit计数器减1，当接收端口处理完一个已接收的帧后，向发送端口发送一个接收器准备就绪消息（Receiver Ready,R_RDY），发送端口收到R_RDY消息后，会将相应接收端口的BB_Credit计数器加1，如果发送端口的BB_Credit计数器的值变为0，帧发送将被中断，直至接收端口再次发送一个R_RDY消息。这种特殊的BB_Credit机制保证了不会因链路级缓冲溢出而发生帧丢失。

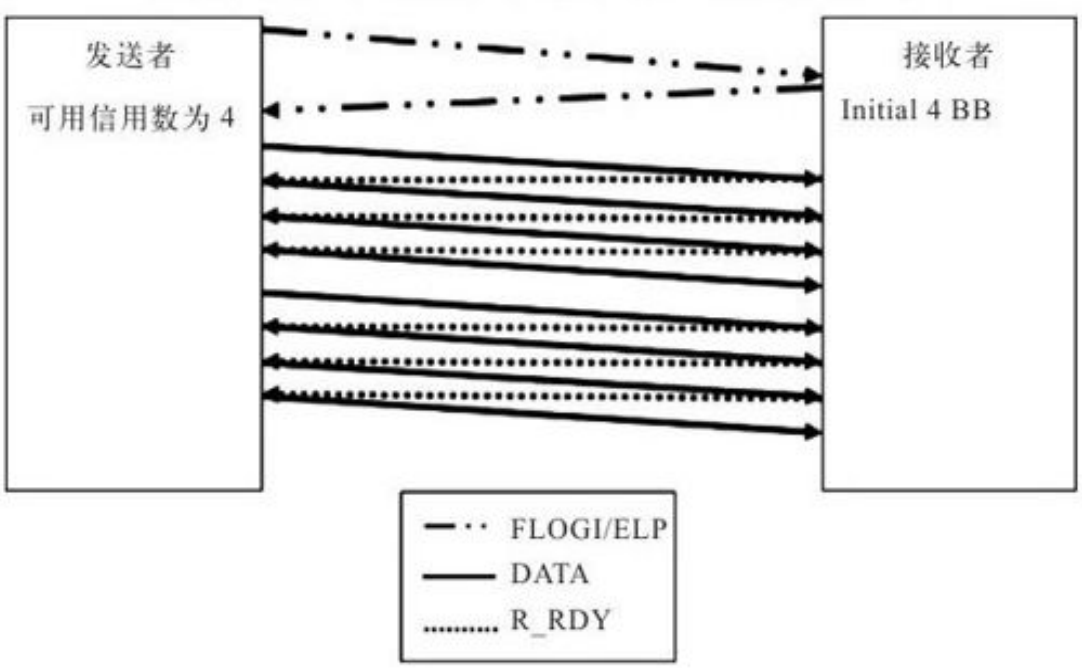


图　7-3　近距离FC BB_Credit操作

说明：R_RDY在FC术语中，也被称为原始信号。

每一个由发送端口送出的帧在接收端口返回R_RDY消息之前都被假设一直占用着接收端口缓冲区的空间，因此，如果超过特定距离的限制，受限于缓冲区容量或者是BB_Credit，系统就无法保证满（或线性）吞吐量，这不禁又使我们想起了第4章曾经讨论过的动态TCP吞吐限制。如何确定BB_Credit，使得指定距离范围内的光纤通道能得到充分利用，是实现SAN扩展之前就必须考虑的一个非常重要的设计问题。

由图7-4可知，随着距离的增加，发送端口收到来自接收端口R_RDY消息的时间也将跟着增加，一旦相应接收端口的BB_Credit变为0，发送端口就会形成一个“传输停滞-间隔”，端口在等待BB_Credit更新的过程中会耗尽发送端口所有可得的BB_Credit。因此，当光纤管道超过一定距离后，最大的稳定吞吐量将显著下降。这一现象被称为下垂。当光往返某个通道的时长超过了它携带足够多数据以填满接收端链路级缓冲区所需时间时，就会发生下垂。换句话说，也就是，必须有足够的BB_Credit才能保证特定距离的线路速率吞吐量。

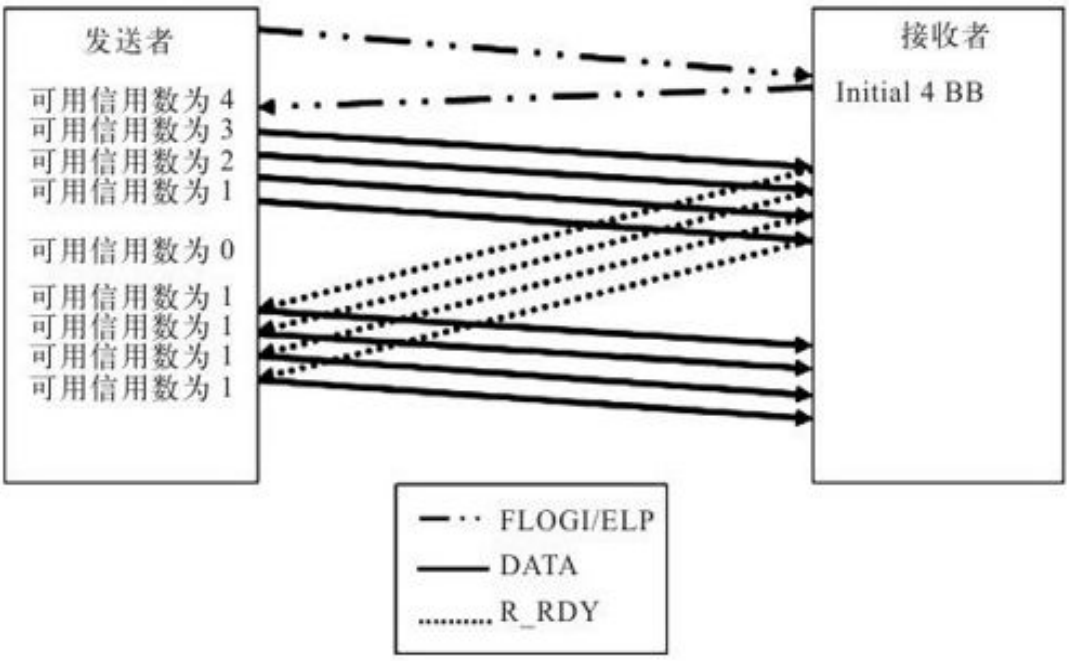


图　7-4　长距离下FC BB_Credit操作

可以利用下面的数学公式来计算特定距离下能够充分利用光纤管道的BB_Credit。

·当BB_Credit < RTT/SF时，下垂发生的条件为：

·RTT为往返一次的时长

·SF是数据帧的串行延迟

·RTT受串行化、传播、处理以及发送延迟的影响：

·RTT为SF、PF、SR以及PR的和：

-SF为一个数据帧串行处理所需的时间

-PF为一个数据帧的传播延时

-SR为R_RDY串行时间

-PR为R_RDY传播时延

说明：当计算RTT时，可以忽略处理延时，因为和其他类型的延时相比，它无足轻重。

图7-5展示了在一个距离为80km的2G FC线路速率的网络上，计算BB_Credit来避免发生下垂的样例。这些计算仅用于示范，还可以使用行业标准作为一个粗略的指南：

·1个BB_Credit在满吞吐量时只能支持1公里的2G FC，或

·1 BB_Credit在满吞吐量时只能支持2公里的1G FC，或

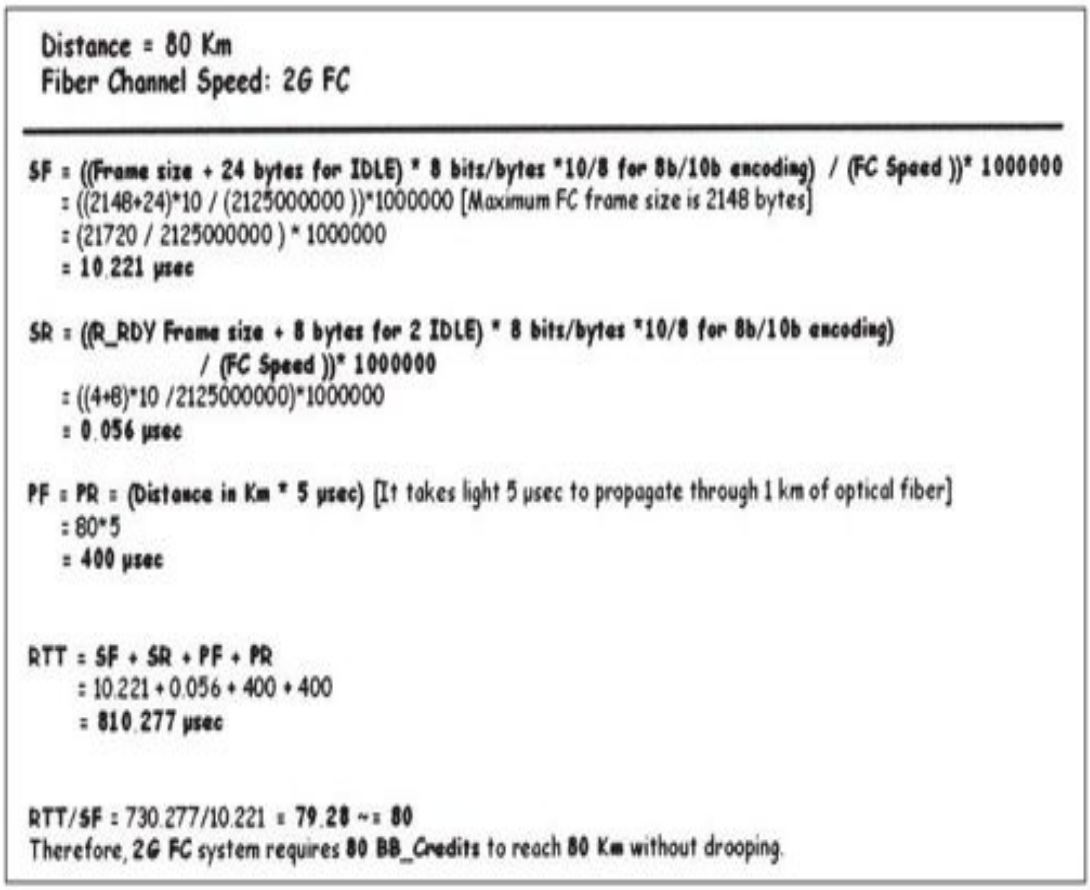


图　7-5　计算BB_Credit以避免下垂

·2 BB_Credit在满吞吐量时只能支持1公里的4G FC等。

说明：1G FC=1.0625 Gbps；2G FC=2.125 Gbps；4G FC=4.25 Gbps；10G FC=10.51875 Gbps。

实际的行业标准也源于图7-5公式的计算结果。由于物理端口对BB_Credit数量需求有较高要求，因此在长距离传输中很难得到满线路速率吞吐量。某些FC交换机厂商推出了FC交换机线卡，这些线卡能够支持每个端口拥有千个左右的BB_Credit，克服了硬件的局限。

说明：可以用R_RDY欺诈来扩展超过允许协议允许范围的缓冲区信用数。此时，R_RDY信号通常被FC交换机用于指示已经接收到一个帧，每一个经过FC交换机的帧都将被互联传输结点拦截并模仿。

远程备份

远程备份有时也被称为远程vaulting，它们通常比像磁带备份这样的标准离线站点备份速度要快得多。远程备份一般会借助标准备份设备进行数据备份，例如Symantec（原来叫Veritas）NetBackup，只是备份站点位于远处。备份或归档的文档也可以被存储在磁带上，以便在需要的时候进行恢复。

镜像和快照

镜像是对原始数据卷100%的拷贝，备份数据卷和原始数据卷大小一致，数据块位置也一模一样，也因此得到了相同的元数据。当数据复制完成后，既可以从原始卷读出来也可以从备份卷读得。

说明：元数据为指向卷内任意时间点数据块的指针，当对数据块进行写、更新和删除操作时，也会修改元数据。

对于复制而言，一旦完成了镜像，备份卷就会与原始卷分离开来单独存放，同时加上时间标记。然后就可以通过读分离的镜像，将数据复制到远程DC，并对其进行更新。整个复制过程中，其他应用可以继续对原始卷进行读写操作，复制不会对正在运行的应用性能产生影响。

镜像特性总结如下：

·对数据卷和元数据为完全备份；

·创建了冗余的备份数据卷；

·占用了更多的磁盘空间；

·更长的复制时间；

·只有当全部复制都完成，镜像才可用。

快照是一个对元数据的暂态复制，同时包括自上一快照完成后任何发生了更新的数据块的备份。通常不会将快照看成是冗余数据，因为它只涉及了数据的一个备份，同时，消耗空间更少，并且随时可用。

快照完成之后，就不能再修改元数据，快照的元数据内包含了指向原始数据卷中原始数据块位置的指针。此时，应用可以继续对原始数据卷进行读写操作，任何有更新的数据块将被写到另外一个区域。通过读原始数据卷，可以将数据复制到远

程DC，也可以将数据写到备份卷。不过，正在运行的应用和复制过程中访问原始卷的复制操作都将降低应用的性能。

快照特性总结如下：

·元数据按时间点复制；

·只复制有更新的数据块；

·只使用原始数据卷；

·占用空间较少；

·随时可用；

·支持按时间点回滚至最近一次快照。

说明：持续数据保护（Continuous Data Protection,CDP）可以在任意时间段回滚，因为尽管只有一个数据的备份，但所有的数据更新都被持续记录在日志中。

同步和异步复制

复制通常基于数组完成，一些基于数组的复制方法包括：

·EMC Symmetrix远程数据设备（Symmetrix Remote Data Facility,SRDF）

·Hitachi True备份

·IBM端到端远程复制（Peer-to-Peer Remote Copy,PPRC）

复制模式一般可以分成两种：同步和异步。当采用同步复制模式时，当远程复制完成后，本地主机系统才会收到一个SCSI写命令完成的信号。图7-6展示了一个同步复制的样例。

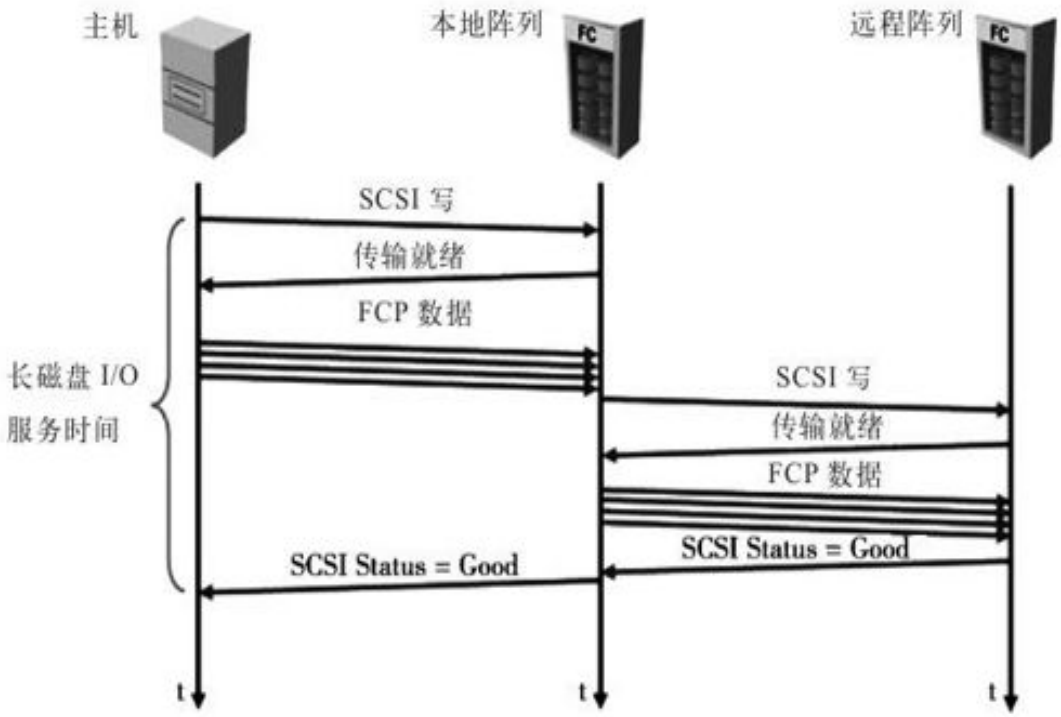


图　7-6　同步复制样例

同步复制优势在于它能够保证本地和远程FC磁盘阵列都能在本地主机系统继续下一个SCSI写之前完成更新，不利因素是主机必须要等待远程写完成。如果远程阵列位置比较远或者是通过高延时链路连接，性能将受到严重影响。

简单来说，采用同步复制模式时：

·当一个I/O操作完成后，数据必须被写到两个阵列上。

·两个阵列中的数据永远是完全同步，更新也一样。

·当谈到应用性能，首先要考虑站点间距离，因为随着距离增加，相应延时也会跟着变大。

使用异步复制模式时，本地主机在远程复制完成之前就会收到一个SCSI写命令完成的信号（远程复制将在稍后时间点进行异步更新）。图7-7展示了一个异步复制的样例。

异步复制模式的优势在于主机系统能够立刻收到本地FC磁盘阵列的应答，不用等待远程复制完成就可以紧接着进行后面的SCSI操作，不利之处为在远程复制完成之前，本地和远程数据备份是不一致。如果复制中有任何一个系统或链路发生故障，两个备份就不一定完全一样了。

简单来说，采用异步复制模式时：

·更新后的数据放在缓存中直到数据能够被复制为止；

·远程磁盘上的数据永远不会同步完成或同步更新；

·应用性能随着数据保护代价增加而增长；

·可以覆盖更远的物理距离范围，也可以容忍更高的延时。

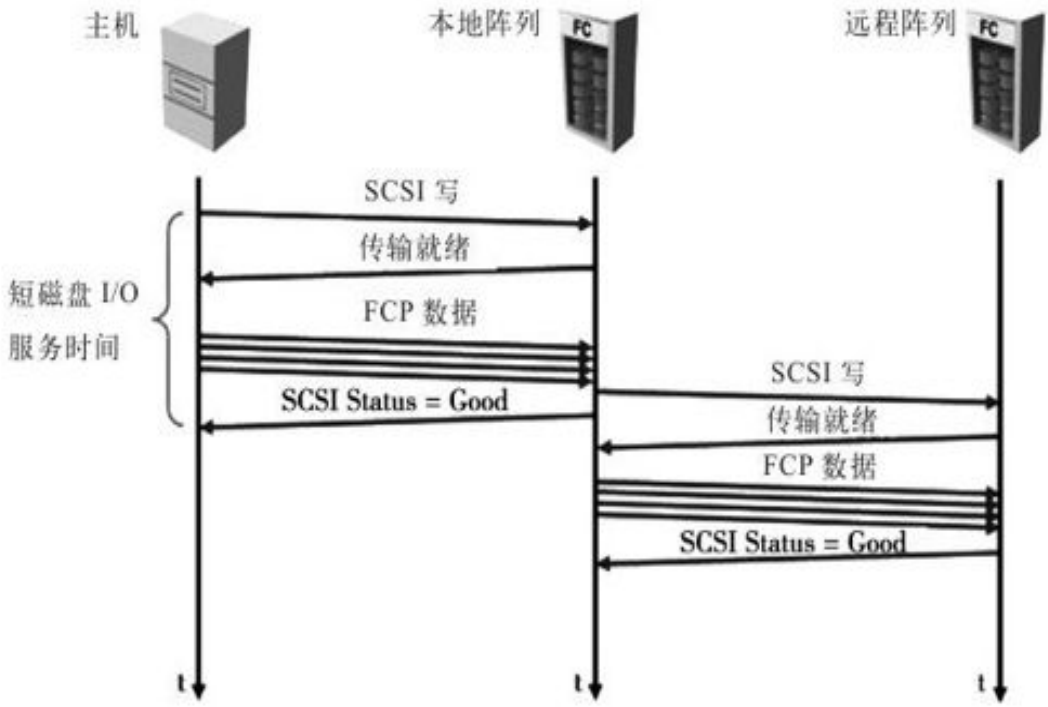


图　7-7　异步复制样例

私营企业必须对每一种复制模式进行利弊进行评估以确定哪种模式将更适合他们的DC云计算环境，需要衡量的因素包括：

·实施成本

·DR站点目标，包括与主SAN地理位置是否接近

·数据丢失成本（high PRO）

·冗长的恢复时间（high RTO）

·基于应用的异构方案

如果能将同步和异步模式混合，可能会比单独采用某一种方式能得到更好的效果。对备份站点采用同步复制模式，但是对一个更远的第三备份站点使用异步复制。以一个关系数据库

管理系统（Relational Database Management System,RDBMS）为例：

·使用同步复制，将重做日志备份到远程站点；

·使用异步复制，在特定时间点（夜间）或使用异步方式备份文件日志；

·固定地按时间点异步复制或备份数据和控制文件。

7.2 光纤网络方案

本节将探讨一些可以应用到SAN扩展的光纤网络解决方案，它们包括：

·暗光纤

·DWDM

·CWDM

7.2.1 暗光纤

暗光纤通常是指光纤网络供应商为了适应未来发展需求而在某地安装的额外或备用光纤，由于这些备用光纤通常在租用前未承载信号（无光），也常被称为熄灭了的光纤。可以使用暗光纤在一个校园网络（＜10km）范围内的两个FC SAN片段提供直接光纤互联，暗光纤所使用的光纤类型决定了FC端口连接的最大距离：

·9μm单模光纤支持10km内的1Gbps、2Gbps、4Gbps以及10Gbps传输速率。

·50μm多模光纤在500m内支持1Gbps传输速率，在300m内支持2Gbps传输速率，150m内支持4Gbps传输速率以及在82m内支持10Gbps传输速率。

·62.5μm多模光纤在350m内支持1Gbps传输速率，150m内支持2Gbps传输速率，而在75m内可支持4Gbps传输速率。

说明：9μm单模光纤的纤芯直径非常细，仅支持单一模式（或路径）传输，50μm多模或65.2μm多模光纤的纤芯直径则大得多，导致了模式色散，形成多重传播模式（路径）。这也可以说明为什么单模光纤比多模光纤的传输距离要远得多。

当两个FC交换机通过内部交换链路（Interswitch Link,ISL）连接后，它们的光纤将融合在一起，变成同一光纤的一部分，相互之间共享地址空间、服务，使用单一主交换机。当互联开始时，这将被认为是一个破坏性活动。FC路由协议，光纤最短路径优先（Fabric Shortest Path First,FSPF）也能够删除重建一个新路由表，并将其分布到光纤内的所有交换机上。

当某个链路发生故障时，单个光纤将分裂成两个独立的光纤，分布拥有自己的地址空间、FC服务以及主交换机。此时，

FSPF必须删除原来路由，然后为每个光纤分片再建一个路由表。图7-8解释了在SAN扩展部署时所需要的不同路径或多个暗光纤，以弥补之前提到的一些限制。有关更多HA技术详情，请参见FCIP HA一节。

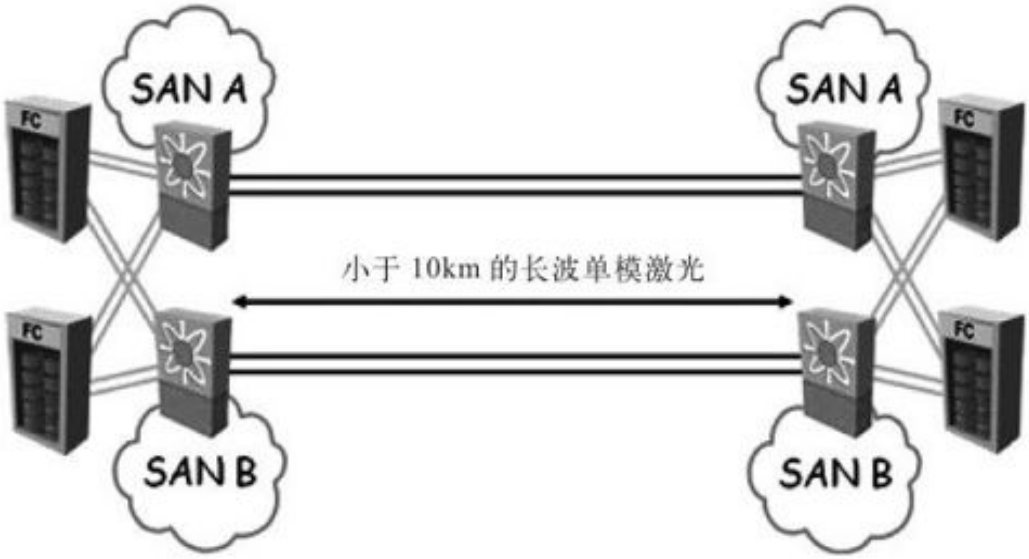


图　7-8　使用暗光线完成SAN扩展

如果企业希望将DC间的FC SAN扩展至大约10km的范围，可以租用暗光纤以避免直接光纤安装所面临的安装和使用权限等问题。不管怎么说，某些情况下，使用多重路径成本的非常高。

7.2.2 DWDM

如果使用光纤传输单股数据流成本昂贵，效率也不高。波分复用（Wavelength-Division Multiplexing,WDM）可以在单根光纤之上传输多股相互独立的数据流，能够更好地利用给定光纤的带宽。每一股数据流都可以在单根光纤上采用不同波长（aka lambda）传输。采用WDM技术，多个云IaaS租户可以共享一根光纤，密集地址波长能够在单根光纤上增加更多信道（带宽），DWDM就属于这样的技术。

DWDM定位

对于很多SAN工程师而言，DWDM是一种理想的SAN扩展机制，它可以实现：

·非常高的扩展性

·非常低，可预计的时延

·还算长的距离

DWDM也能满足管理系统连接（Enterprise System Connection,ESCON）解决方案的要求，还可以用在光纤连接（Fiber Connection,FICON）及FC上。虽然DWDM支持长距离FC SAN扩展，不过距离依然受到应用（更多细节，请参考7.1.2节中“同步和异步复制”的相关内容）和FC流控制机制（更多细节，请参考7.1.2节中“远距离光纤通道FC流控制”的相关内容）的限制。同步复制要求在长距离范围实现高带宽及低延时，DWDM能够满足这些要求，使得它非常合适于同步复制应用。

说明：除了DWDM,FCIP也支持FICON。

不过，财务总监将会发现DWDM的造价（主要的权衡）稍微有些高昂：

·DWDM设备比其他方案的设备更昂贵。

·租用暗光纤的成本较高。

·DWDM服务不如SONET或SDH应用广泛，如果采用DWDM，企业可能需要自己实现和管理DWDM体系。

·DWDM的健壮性不如SONET/SDH，这也会增加其管理成本。

DWDM功能回顾

ISL的两个FC交换机之间的单根光纤对只使用了两个交换机间的单个通道的波长，借助DWDM，用载波间距为0.4nm（50GHz）将1550nm波长范围的红外波段分成离散的波长或lambdas（λ），使得多个通道可以共享单根光纤对。每一DWDM lambdas能够支持全双工FC、ESCON、FICON或以太网通道（端口通道）。

说明：DWDM系统主要使用C-及/或L-band波段，工作波长在1500nm或更高的范围。波长（λ）的计算公式为λ=c/frequency,c为每秒光的速度，以米为单位，频率是Hertz，λ以米为单位。

基本的DWDM组件包括：发射器和（反）复用器。图7-9展示了一个简单的DWDM配置。DWDM发射器将每个信道转换成自己特定的lambda，然后复用到DWDM（反）复用器间的2.5Gbps、10Gbps或者40Gbps链路上。

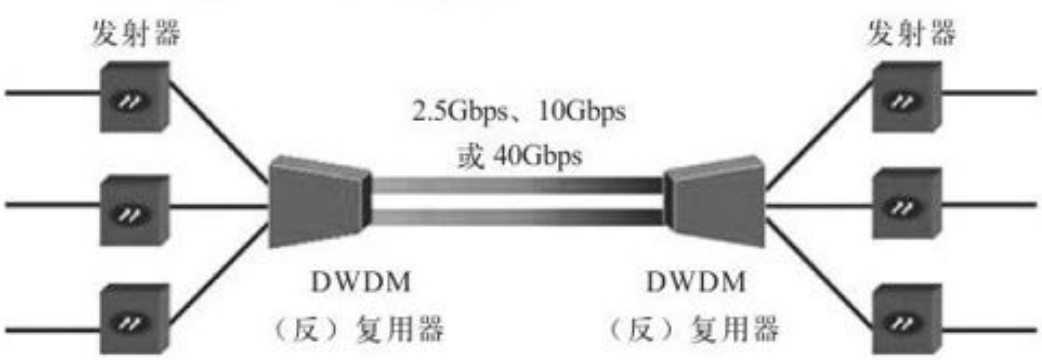


图　7-9　简化的DWDM网络

说明：100G波长有望2011年在某些产品网络中出现，到2012年，第一代100G DWDM光纤网络传输部署将进入商业化进程。

DWDM距离容量

在开始讨论各种可能DWDM容量限制因素之前，有必要研究一些光纤DWDM的组件，这些组件在增强或破坏距离容量方面扮演了重要角色。可选DWDM组件包括：

·光纤放大器：对于长距离而言，增益平坦光纤放大器能够增强信号至更远的范围或在信号离开本地站点前，预先对信号进行放大。最常见的光纤放大器是掺铒光纤放大器（Erbium-

Doped Fiber Amplifier,EDFA），常规EDFA的工作波长为1530nm～1563nm。

说明：Cisco ONS 15501属于EDFA设备，工作波长为1530 nm～1563nm。

·分散补偿单元（Dispersion Compensation Unit,DCU）：可使用DCU来阻止长距离中因光纤信号分散而产生的信号衰减。超过50km的10千兆以太网及FC，有可能需要部署DCU。

·光分插复用（Optical add drop multiplexer,OADM）：可以部署OADM以增加信号疏导的灵活性。OADM允许光纤上的特殊波长被分接出（去掉）并复接出（增加），同时也不会影响所有其他波长。经过一个OADM过滤器的波长将会经历少量的信号衰减。

·可调光衰减器（Variable Optical Attenuator,VOA）：DWDM环形拓扑结构使用OADM后需要增加VOA。OADM向环网注入一束新波长时，该波长的信号将会比环网当前点其他波长更强一些。VOA将会衰减（降低）新到来的波长的能量，使得它能够与其他波长能量进行匹配。

DWDM距离通常会被分成三类：办公室内部（0～300km）、长距离（300km～600km）以及超长距离（600km～2000km），但实际距离容量仍然受到以下因素限制：

·传输距离超过100km以上时，就需要进行放大或再生。

·通过放大操作，一个DWDM链路的端到端距离可以至200km，如果距离更长，二次放大将使得光纤信号发生变形。

·通过再生，一个DWDM链路的端到端距离可以变得更长，但再生过程中将会产生额外的延时。

·DWDM链路的最大距离依赖于链路使用的组件，包括光纤放大器、DCU、VOA、OADM等。

DWDM链型拓扑

要实现DWDM，最简单的方法是利用点到点拓扑。图7-10拓扑图展示了一个简单的未受到保护的点到点拓扑，拓扑连接主DC与远程DC，实现了数据镜像和快照应用，能够支持备份和DR应用。对于一个受保护的点到点拓扑（操作），两个站点必须通过两对光纤而不是仅通过一对光纤连接。

图7-10的底部展示了一个总线拓扑，此时多个站点通过链型模式相互连接。在中心站点与远程站点间使用了特定波长（或lambdas）。这种拓扑可以用来连接一个MAN网络中的多个部门，总线拓扑仅能提供有限的保护能力。

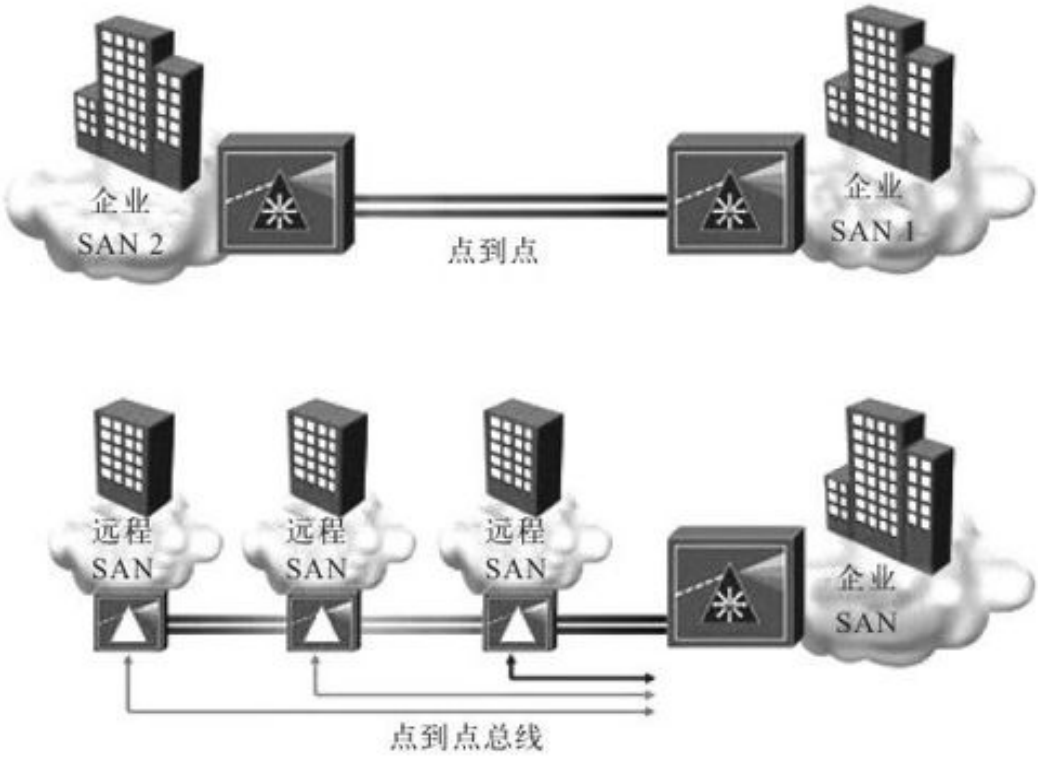


图　7-10　DWDM线性拓扑

DWDM环形拓扑

MAN网络通常会部署DWDM环形拓扑，它能够覆盖数十公里的范围。环形拓扑能支持任意点到任意点的传输（就像在网状环形中一样），也可以使用hub和星型结点（集中星型拓扑）。可以单向传输，也可以是双向传输。

图7-11左边展示了一个集中式的环形拓扑，使用DWDM将企业DC与三个远程站点连接起来，这样的拓扑也称为集中星型（hub and spoke），因为每一个分支结点逻辑上只和中心结点相连。在hubbed环形结构中，hub可以使用终端的复用/解复用设备，每个分支结点必须同时配备OADM模块。在图7-11左边，协作HQ站点为hub，远程站点使用了OADM，以便增加或减少指定波长。在分支结点，可以增加或去掉一个或多个波长，此时其他波长仍然可以透明地通过。

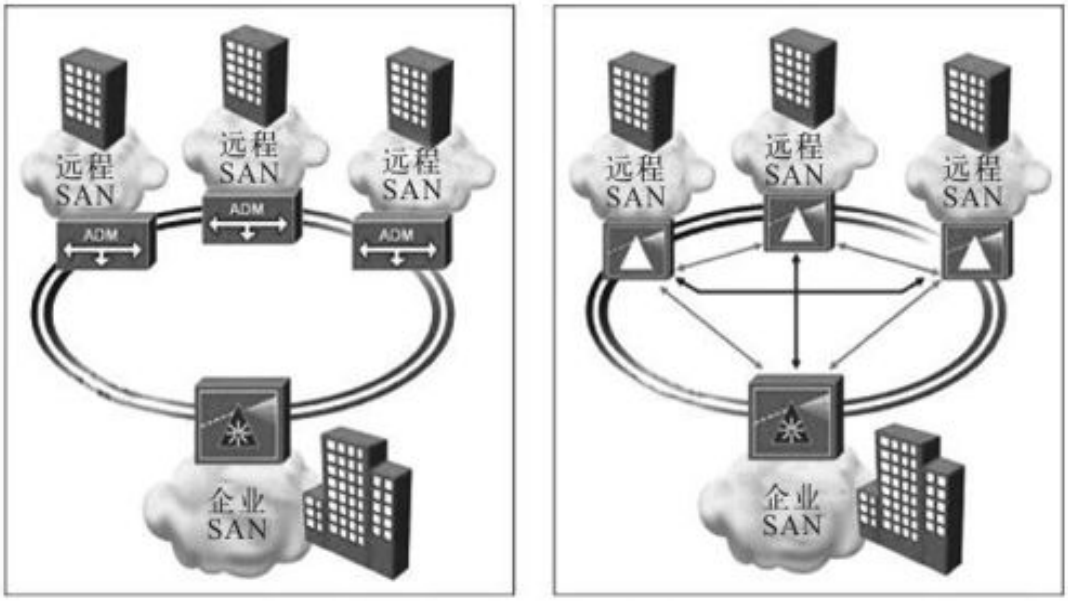


图　7-11　DWDM环形拓扑

这种网络拓扑借助环形交换容量，增强了系统的可靠性和可获得性。使用单信道无向连接路径交换或双向路径交换能够支持环形交换。如果任意站点间的光纤断掉了，站点间的通信不会因此而被破坏掉。不过，这时候还是不得不考虑成本问题。环形拓扑通常适合一个MAN网络或者是某个部门的环境，也可以通过放大和再生将它们扩展到很远的距离。

图7-11的右边展示了一个网状环形拓扑，此时每个站点都与某个DWDM（解）复用器相连。在这种配置方案中，每对站点间都使用特定波长（或lambdas）。网状环形提供了一个逻辑上的满网状，因而每个站点都可以与其他站点进行通信。如果不要求这一点，单独站点就只能通过特殊的lambdas与其他指定的站点或结点组，就成了部分网状结构。

7.2.3 CWDM

CWDM与DWDM类似，在单根光纤上使用多种波长来传输信号，但是，这两类技术在许多方面都不尽相同：

·CWDM使用20nm波长区间，比DWDM的0.4 nm区间宽的多，更宽的波长意味着CWDM拥有较低的产品开发成本。这也是CWDM比DWDM造价更低廉的原因之一。

说明：大多数DWDM设备工作范围在1470nm到1610nm之间。DWDM的频率栅格以及CWDM系统的波长栅格分别由国际电信联盟（International Telecommunications Union,ITU）的G.694.1标准和G.694.2标准定义。

·与DWDM相比，CWDM可以通过单光纤对为两个CWDM复用器提供最多8 lambdas，而DWDM可以在单光纤对支持32 lambdas（基于0.8nm或者100GHz波长空间）。

说明：一些长距离DWDM系统可以支持每光纤对160 lambdas。

·每一个CWDM信道使用一个特殊的千兆位电信号转换接口（Gigabit Interface Converter,GBIC）或者是小型可插拔式（Small Form-factor Pluggable,SPF）转换器。这些特殊的转换器俗称彩色GBIC和SPF。因为每一个lambdas在光谱中代表不同颜色，所以每一个CWDM信道使用一个不同的“彩色”GBIC或SPF，同时，客户端设备的本地GBIC或SPF也会相应使用相同色彩的GBIC或SPF。

·CWDM复用器通常是被动（例如，不带电）设备，拥有一个非常精确的棱镜，可以在单光纤对上将光复用分成8个单独波长。被动设备不能对信号进行再生或复制。

·基本不可能对CWDM进行放大，因为它的波长是无法使用EDFA设备进行放大的，因此，CWDM链路最大的连接距离约为100km。

说明：Cisco ONS 15501 EDFA波长范围为1530nm～1563nm，由光纤对复用出的8种信号，只有2种（1530nm和1563nm）能被15501 EDFA放大。

CWDM提供了一个DWDM的替代方案，能够满足同步复制应用提出的更少延时和更高带宽的要求。不过，DWDM的可扩

展性优于CWDM，并且DWDM比CWDM的距离容量更大，因为可以对DWDM进行放大操作。CWDM的唯一优势在于成本，它比DWDM更低廉，换句话说，CWDM的优势在成本，而DWDM的优势在带宽。对能够使用暗光纤只是对扩展有要求的的企业而言，CWDM是一种不算贵，也能满足低时延和DC间互联高带宽的解决方案。此外，CWDM方案在更低的安装复杂性、配置及操作方面都要优于DWDM。

CWDM拓扑

可以采用点到点、线性或光纤保护环形拓扑方式部署CWDM。如果使用点到点拓扑结构，以太网上的CWDM距离上限大约为120km，而2G FC上的CWDM距离上限大约为100km。比较常见的CWDM应用是用于扩展城域网或校园应用内的FC光纤。CWDM在单光纤组上只能够携带8lambdas，因而对能够抛弃及可以连接的站点个数都有所限制。环形或链型拓扑可以缩短的距离要依赖于CWDM信道上可以通过的OADM数目，因为每一个OADM都在网络中产生了额外的能量损耗。

可以在交换机与单个光纤之间的ISL连接中使用CWDM，因为它在连接两个城域网站点时需要的光纤更少，也可以将它的这一优势应用于交换机间的端口信道实现上。

简而言之，DWDM方案能够提供更多数目的连接以及更长的访问距离或扩展，不过成本也相对更高，而CWDM方案价格更有优势，更适合城域网或校园这类距离有限的环境。

7.3 SONET/SDH服务

SONET/SDH技术基于TDM，能够在一根单波长光纤上传输帧数据（或音频）。SONET是由ANSI提出的标准，SDH则是由ITU-T（最初由ETSI定义）提出的与SONET等价的标准。SONET与SDH之间的主要差别在于传输速率与某些帧头信息不相同，除了少数差异之外，可以将SDH看成是SONET的升级版。从企业的观点来看，SONET/SDH是L1层的主要传输技术，能够为其他更高层的连接提供支持。SONET/SDH具有以下优点：

·SONET/SDH服务拥有大量用户，在许多地区都易于获取。尽管一个点到点SONET/SDH链路（不带转发器）通常只能支持50km或更少的距离，但很多长距离光纤连接仍然采用了SONET/SDH技术，因为很多SP网络都已经部署了大量转发器，能够对信号进行放大处理完成长距离传输。因此，与诸如DWDM和CWDM这类纯光纤传输相比，SONET/SDH服务成本更低传输距离却更长。

·FCIP是另外一种面向长距离的SAN扩展方案，与FCIP相比，SONET/SDH服务的延时更短，综合考虑，可以将FCIP架构在L1 SONET/SDH服务之上。

·SONET/SDH可以提供更多的保护机制，包括N+1保护，这是一种比1+1保护性价比更高的方案，DWDM和CWDM都不支持N+1保护。另外，SONET/SDH故障恢复时间为小于秒级，仅需50ms，所以故障恢复对上层协议是透明的。相对于100ms的FC收发方超时值（Receiver Transmitter Timeout Value,R_T_TOV），SONET/SDH的故障恢复时间基本可以忽略不计。

说明：在1+1保护方案中，每个工作卡都要配备同型号的一个保护卡，当工作卡出现故障时，工作卡负责的网络传输将换到保护卡上完成，N+1保护方案支持一个保护卡同时为多个工作卡提供保护。

·SONET/SDH能够支持包括OC-3（155.52 Mbps）、OC-12（622.08Mbps）、OC-48（2.49 Gbps）、OC-192（9.95 Gbps）以及OC-768（39.81 Gbps）等在内的大范围传输速率。

说明：如果存在一个以上的2G FC或FICON通道，则要求使用OC-192及更高的速率。

通用成帧规程（Generic Framing Procedure,GFP）支持8b/10b编码数据流在SONET/SDH这类网络上的传输，SONET/SDH与GFP结合后，能够实现对FC和FCION的支持。GFP还可以携带千兆以太网、ESCON以及任意其他8b/10b封装数据。GFP技术细节已经超出了本书讨论范围。

说明：下一代SONET/SDH将通过升级现有L1网络扩展SONET/SDH技术的利用，它还包括了诸如虚拟级联（Virtual Concatenation,VCAT）、通用成帧规程GFP以及链路容量调整（Link Capacity Adjustment Scheme,LCAS）技术等。

SONET/SDH拓扑

可以使用多种拓扑方式完成SONET/SDH部署：

·点到点

·线性分插复用器（Add/Drop Multiplexer,ADM）

·双纤单向通道倒换环（Unidirectional Path Switch Ring,UPSR）

·双纤双向线性倒换环（Bidirectional Line Switch Ring,BLSR）

·四纤BLSR

·路径保护网

在城域网或更大地域范围中可以采用以上任意一种部署方式，最初的两个站点间采用点到点部署，当更多站点加入后，逐渐演变成环，即由一组相互连接的站点组成一个封闭的回路，此时将光纤作为链路。

UPSR保护采用复制、每回路多条物理路径等方法来防止光纤截断和结点故障。UPSR提供围绕环的双光纤路径，工作流沿顺时针方向流动，而保护工作流则以逆时针方向逆向流动。UPSR采用用路径（或扇出）交换，当工作流路径上发生光纤或结点故障时，接收结点会换到相反方向的路径上。UPSR上的一个连接/回路能使用整个环的容量，因为每一传输路径都是绕着

整个环完成，所以UPSR更适合集中星型网络（hub and spoke network），所有流都经过中心的hub。

BLSR采用双向线路（或环）交换保护机制，线路切换环使用SONET/SDH线路指示来初始化保护交换。BLSR结点可以中断来自环的任意一段的传输，适合分布式结点到结点传输应用，例如局间网和接入网。这种保护机制成本较高，但是它允许沿回路的带宽被重用，比UPSR的传输能力更高，因为UPSR的一个连接/回路只能利用两个结点间的传输容量。

4光纤BLSR与2光纤BLSR不同之处在于前者既允许路径（或扇出）交换，也支持线路（或环）交换，因而多加了一层保护，但是成本也相对更高。高带宽应用如果需要进行最好的传输保护，通常会使用4光纤BLSR。

SONET/SDH环上的节点为实际的分插复用器ADM，结点间使用两根光纤扇出完成连接，在环中形成了2条可得路径。图7-12左边展示了一个UPSR，扇出1.1、1.2、1.3、1.4、1.5和1.6是环的主路径，扇出2.1、2.2、2.3、2.4、2.5和2.6是保护路径。

结点A向结点C发送的数据将沿顺时针方向经过1.1和1.2到达，结点C向结点A发送的数据仍然会沿顺时针方向经过1.3、1.4、1.5和1.6到达，因此，从结点A到结点C和从结点C到结点A的信息传输会产生不同的延时。

图7-12的右边展示了一个BLSR，如果某个连接到结点A的用户希望能和连接到结点C的用户进行通信，请求消息将沿顺时针方向从A到C，如果结点C上的用户愿意向结点A返回一个应答消息，该应答消息将沿逆时针方向返回。

路径保护网状网络（Path-Protected Mesh Network,PPMM）由链型和环拓扑混合连接而成，如果方案需要考虑路由分集设计，PPMM将是比其他方案更理想的选择。

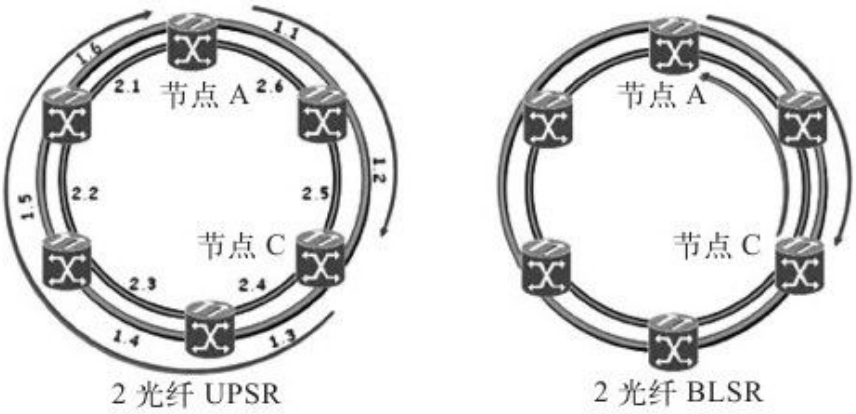


图　7-12　SONET/SDH环拓扑

7.4 FCIP

FCIP属于隧道协议，它支持SAN片段（岛）通过IP网络互连，这样的连接对本地FC是透明的，两个不同的SAN光纤通过FCIP链路连接形成了一个完全融合的FC光纤。FCIP使用TCP/IP封装FC帧，并在TCP/IP传输层完成拥塞控制和无错数据的有序分发。借助FCIP，企业能够对现有IP基础架构和管理资源进行升级，实现本地FC SAN的互联和扩展以支持私有云计算。另外，采用FCIP后，遥远的物理距离就再也不是问题了。

7.4.1 FCIP入门

本节探讨如下FCIP概念：

·FC帧封装

·虚拟边缘端口（Virtual Expansion Port,VE_Port）

·FCIP链路以及虚拟交换链路（virtual ISL）

FC帧封装

IETF FC帧封装标准（RFC3643）定义了FC帧的封装头，除了FCIP协议，RFC3643还对互联网光纤通道协议（Internet Fibre Channel Protocol,iFCP）进行了规定。头为28位（或7个字），包括一个时间戳、循环冗余校验码（Cyclic Redundancy Check,CRC）以及对FCIP特定帧（FCIP special frames,FSF）的约束。

说明：FSF协商（选择）提供了又一种安全认证机制，它将确定在连接开始FC模块初始化之前，是否要将新创建的TCP连接与正确的FCIP链路联系起来。从发起方到接收方的TCP连接请求的头几位字节都是FSF验证信息，既对发起方进行验证，也对发送者预期的接受者进行验证。如果该FSF内容无误且能被接收方认可，未经更改的FSF就会被回传至发送者。这样的发送/回应过程是允许使用TCP连接完成FC模块传输的唯一行为。

图7-13说明了一个封装在TCP包中的FC帧，不同上下层协议数据单元（Protocol Data Units,PDU）的嵌套关系。

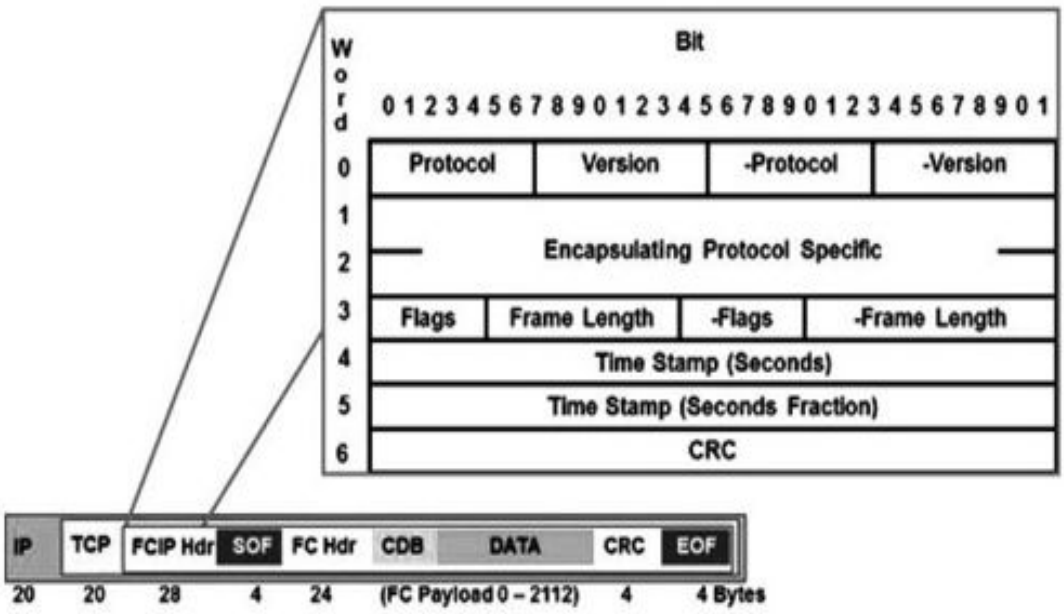


图　7-13　IETF FC帧封装

说明：FC的所有数据，包括FC标志头信息以及CRC，当移除IP封装后，这些信息不会受到影响，仍然可以继续在FC网络中使用。

VE_Port

FC链路使用IP网络为载体，将FC模块中两个单独的部分连接起来形成一个完整的FC模块，FC链路的每一个端点都关联着一个虚拟扩展端口（Virtual Expansion Port,VE_Port）。除了采用FCIP（基于TCP/IP）而非本地FC传输外，VE_Port实际类似一个标准的FC E_Port，系统通过一个8字节的唯一标示符VE_Port_Name来区分VE_Port。

说明：FCIP链路和FCIP隧道这两个术语表达的意思是相同的。

VE_port与FCIP链路端点（FCIP link endpoint,FCIP_LEP）相连，FCIP_LEP负责编排、封装FC帧并转发，封装好的FC帧在IP网络中就像TCP片段一样被传输。FCIP_LEP从它的VE_port接收按字节编码，由帧起始（Start-of-Frame,SOF）或帧结尾（End-of-Frame,EOF）界定的FC帧以及时间戳。

FC数据引擎（FCIP Data Engine,FCIP_DE）是FCIP_LEP进行数据转发的组件，它负责管理FCIP链路上所有FC帧的封转/解

封，以及对封装好的FC帧转发/接收。每个FCIP_LEP拥有一个或一个以上的FCIP_DE，它们分别负责不同的TCP连接。

FCIP链路以及虚拟交换链路

FCIP链路由两个FCIP_LEP中一个或多个TCP连接组成，每一个链路都载有封装好的FC帧。当一个FCIP链路成功建立后，也会在链路两端的VE_port间跟着建立起一个虚拟ISL。图7-14展示了一个简单的FCIP链路及虚拟ISL的样例。

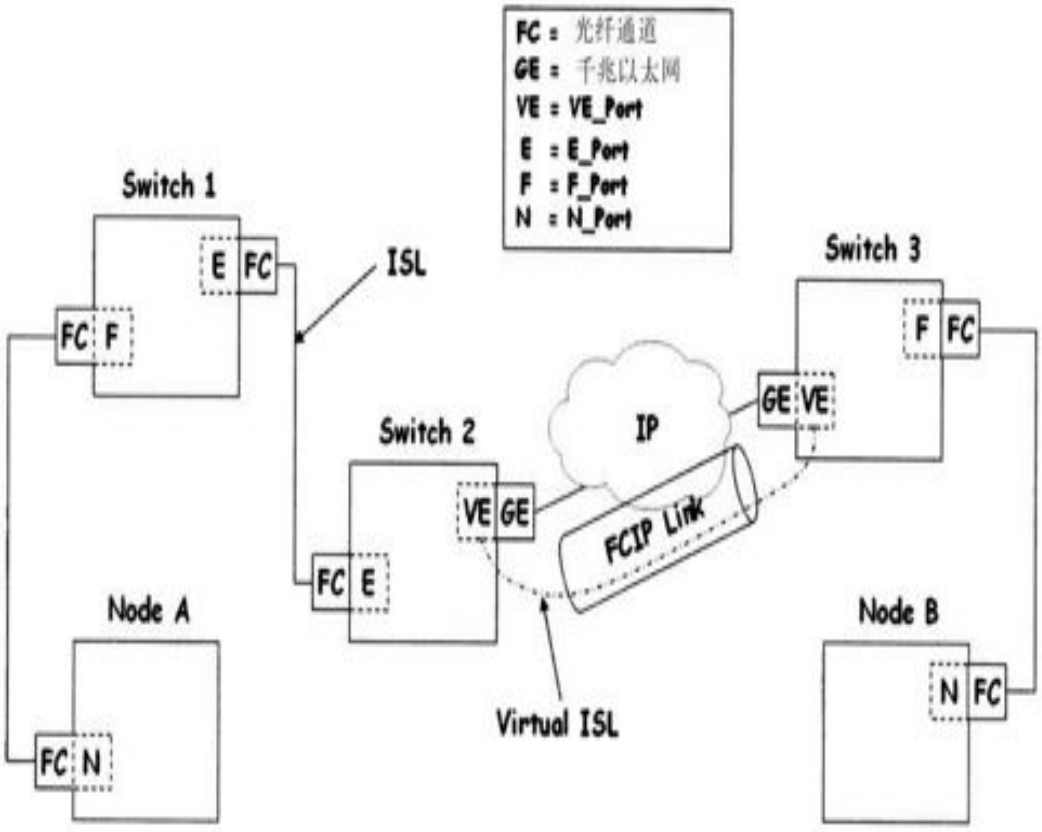


图　7-14　FCIP链路及虚拟ISL

说明：FC-BB-3标准为连接到IP网络的光纤通道骨干（Fibre Channel Backbone,FC_BB）定义了两个功能模型：VE_Port和B_Access。其中，集成了FCIP功能的FCIP交换机支持VE_Port，而B_Access可以通过连接了FC交换机的FCIP设备实现。能够支持B_Access功能模型的设备被称为FCIP桥，FCIP桥内部用来连接FC交换机的接口被称为B_port。术语虚拟ISL，在没有进行特别限制时，也可以指VE_port虚拟ISL以及B_Access虚拟ISL。

VE_port初始化操作和普通E_port初始化操作一样，与具体的链路类型是FCIP还是本地光纤通道并无关联。VE_port之间通过交换机内部链路服务（Switch Internal Link Services,SW_ILS）完成，包括交换链路参数（Exchange Link Parameter,ELP）、交换链路容量（Exchange Switch Capabilities,ESC）、组件光纤（Build Fabric,BF）、重配置光纤（Reconfigure Fabric,RCF）、光纤最短路径优先（Fabric Shortest Path First,FSPF）等。

IP网络上的FCIP链路使用3225端口在FCIP_LEP之间传送封装好的FC流，该端口是TCP默认为FCIP提供的知名端口（Well-Known Port,WKP），在两个FCIP_LEP同时建立一个以上的TCP连接是行得通的，例如Cisco MDS 9000系列存储交换机就可以为每个FCIP链路创建两个TCP连接。

·一个连接是为数据帧服务（类3）

·另一个连接只用于FC控制帧，即，内部交换帧（类F）。这样的安排降低了所有控制帧（ELP,ESC等）的延时。

说明：FC交换机之间使用类F在ISL上传输与光纤相关的信息，类3属于无连接服务类，不支持已发送或未发送确认信息。

说明：FC_BB_3说明要求所有FC骨干网络（包括FCIP）支持F类帧，可以有选择地支持2、3、4类帧，不支持1类和6类帧。不能通过FCIP链路传输FC原始信号、原始序列以及1类FC帧，因为它们无法应用FC帧封装技术进行编码。实际应用中，只用到3类（面向数据）和F类（面向控制）。

7.4.2 FCIP拓扑

FCIP拓扑相对比较简单，包括：

·点到点：点到点拓扑中，两个站点是通过一个特定FCIP隧道来连接。通常在一开始只有两个站点时会采用这种拓扑部署方案，随着站点数目的增加，可以将它扩展成集中星型拓扑。

·集中星型拓扑：可以将hub站点的相关SAN，通过基于IP的WAN扩展到多个远程spoke站点。这种拓扑方案是3.3节中提到的基于DMVPN的WAN方案的理想配备。

可以将MDS 900 IP存储服务（IP Storage Service,IPS）模块，特别是IPS-8模块，当做深入讨论集中星型FCIP配置的样例。在IP网络上以点对点模式在两个FCIP接口建立FCIP隧道，IPS-8模块上每个千兆位以太网端口最多可以支持3个FCIP接口，每个接口都能与远程站点的FCIP接口建立一个FCIP隧道，形成了一个集中星型的拓扑结构。由于每个IPS-8模块都有8个千兆位以太网端口，总共能够支持24个FCIP隧道。图7-15展示了在MDS交换机上使用IPS-8模块建立FCIP集中星型拓扑的简单样例。图中，企业DC端IPS-8模块上千兆位以太网端口的3个FCIP接口得到了充分利用，企业SAN扩展到3个远程集中星型站点，每个远程集中星型站点都使用一个单独的FCIP接口应答。

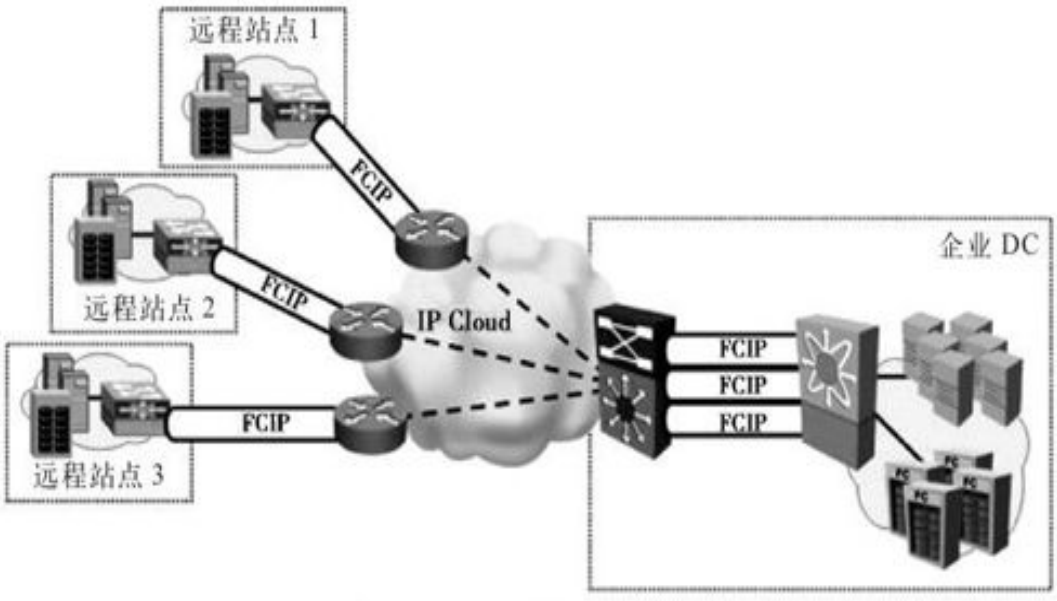


图 7-15 FCIP集中星型拓扑

说明：IP存储服务8端口模块提供了8个可热插拔的千兆位以太网端口来支持iSCSI和FCIP，这些端口属于SFP LC-型千兆位以太网接口。用户可以使用短或者长波长SFP配置模块，分别实现从550m到10km的连接。每个端口都可以配置成同时支持iSCSI和FCIP协议，换句话说，IPS-8模块属于MDS交换机的集成多协议（iSCSI和FCIP）网关。

以灵活性而言，FCIP部署都要优于光纤网络，只要在IP网络上实现FCIP，它就能独立于任意的底层L1/L2服务以及物理距离限制，FCIP可以部署在以下环境中：

·同步复制：这类应用要求高带宽和低延时。城域以太网加FCIP将是首选，如果面向同步复制的SONET/SDH基础设施能够提供高速带宽和低时延（＜1-5ms），也可以将SONET/SDN加FCIP作为备选。

·异步复制：这类应用能适应低带宽，也能够容忍更大的时延（大约100ms），此时，SONET/SDH加FCIP提供了一种性价比更高的解决方案，同时也能支持更远的距离。

·远程备份：远程备份是典型的标准备份应用，只是备份设备位于远程站点上。这样的备份应用对时延没有严格的要求，备份站点位置也相对较远，此时，SONET/SDH加FCIP是性价比最高的解决方案。

·基于主机镜像：基于主机镜像应用对带宽和时延的要求都较低，因此既可以考虑SONET/SDH加FCIP，也可以采用基于IP的WAN加FCIP方案。

7.4.3 FCIP HA

弹性化的FCIP部署自两个单独的MDS交换机上的IPS模块开始，并行FCIP隧道可以交叉连接两个SAN岛的不同交换机、PSPF、FC光纤使用的标准路径选择或路由协议是这种方案的实现基础。特别需要PSPF之处包括：

·在整个FC光纤范围内动态计算路由以选择任意两个FC交换机最短和最快路径。

·当某一给定路径失效时，确定替换路径。FSPF支持多路径，也可以替故障链路自动计算替换路径。当同时有两条路径可供选择时，它能挑选出相对较优的路径。

图7-16给出了一个基于FSPF的HA解决方案，交换机的两条FCIP隧道间网络传输实现了负载平衡，当遇到端口或链路故障时，FSPF将根据剩下隧道情况对当前网络传输重新进行路由。

通过建立多条FCIP隧道，并使用FSPF实现负载平衡，可以在端口或链路发生故障时仍然保持FC光纤的连接，但由于故障对FC光纤会产生一定影响，因此FSPF需要重新计算路径路由。

将FCIP隧道汇聚在一个端口通道内，可以避免因端口或链路故障而重新计算FSPF，换句话说，可以在基于FSPF的解决方案中引入端口通道实现无干扰故障恢复。端口通道具备以下能力：

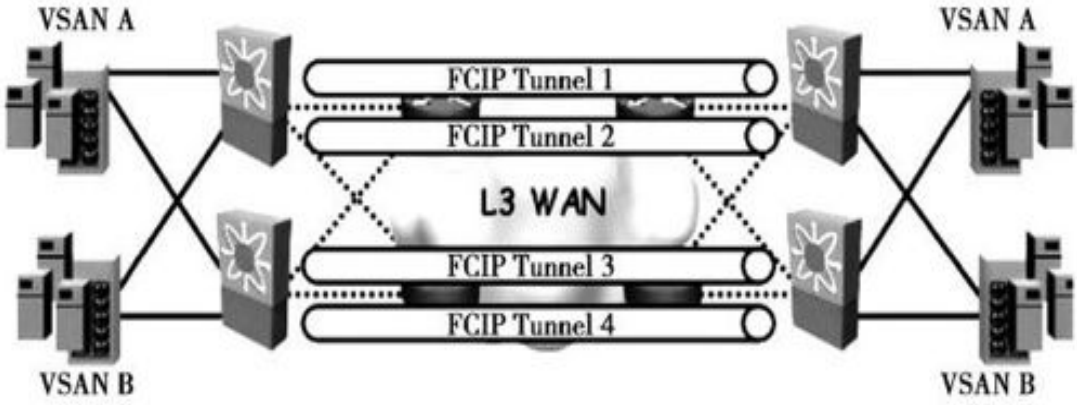


图 7-16 基于FSPF的HA解决方案

·在ISL或FCIP隧道上建立点对点连接，可以将多个链路绑定到一个端口通道内，网络传输就可以分散在通道内所有有效链路上完成，从而增加了整体汇聚带宽。

·在多链路上进行负载平衡能够保证带宽的优化使用，负载平衡本身基于源ID（source ID,S_ID）、目标ID（Destination ID,D_ID）和始发交换ID（Originator Exchange ID,OX_ID）实现。

·HA功能引入。如果某个链路发生故障，此前经过该链路的网络传输会被切换到剩下的其他链路完成，虽然带宽降低了，但切换过程对上层协议是透明的，FSPF路由表也不会受到故障影响。对于额外的HA，端口通道横跨了多个模块，因此某一个交换模块故障不会导致整个端口通道链路失效。

说明：端口通道负载平衡也可以只针对S_ID和D_ID,FICON要求使用这种配置。

说明：在某些情况下，端口通道链路失败可能会引起无序发送，诸如FICON这样的FC协议或应用无法处理无序帧发送，可以通过激活MDS交换机上的有序发送功能，支持配置了FICON的VSAN。

端口通道强化方案将恢复放在端口通道层而非FSPF路由层完成，可以实现速度更快点无干扰恢复。图7-17展示了一个强化了端口通道的基于FSPF HA强化方案样例。

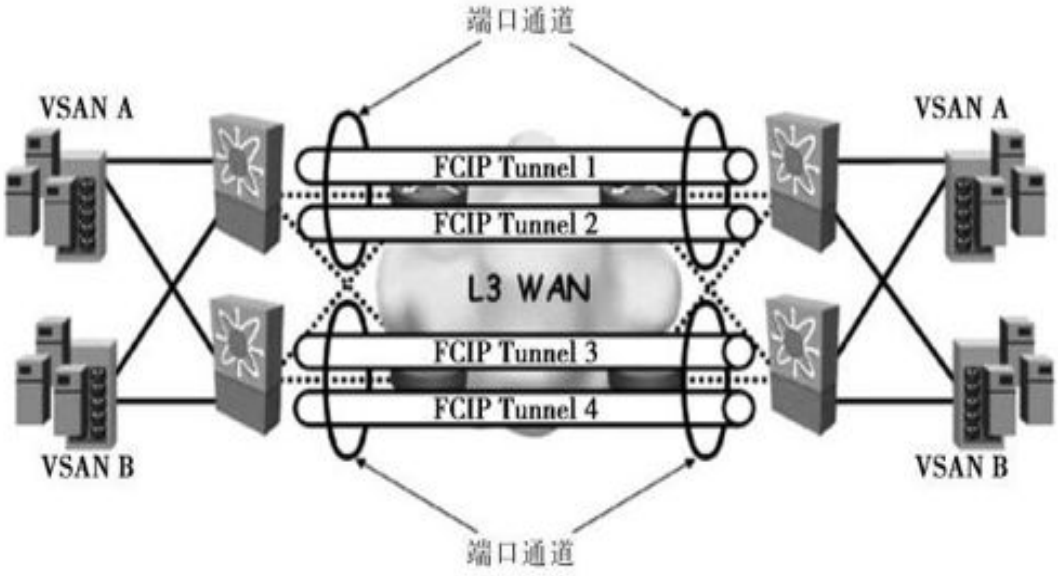


图　7-17　引入端口通道的基于FSPF的HA

FICP HA配置样例，可以参见9.7节中的“简单的FCIP设计样例”的内容。

说明：可以在不同物理路径的子网地址上创建FCIP隧道以实现IP层容错，如果某条路径发生故障，包含FCIP隧道的端口通道可以在其他路径上继续工作。

7.4.4 FCIP性能调整

FCIP性能调整参数包括：

·TCP超时

·TCP重传

·TCP应答

·MTU尺寸

·流控制

·数据包整形

·FCIP写加速

·FCIP磁带加速

·FCIP压缩

·IP QoS

以下小节将以带IPS模块的MDS交换机作为这些性能调整参数的样例平台。

说明：以下小节中提到的MDS交换机术语均值带有IPS模块的MDS交换机。

TCP超时

TCP超时指令定义了TCP连接来验证FICP链路工作是否正常的时间间隔，以确保FCIP链路故障能够被迅速探测到，即便此链路处于空闲状态。如果该TCP连接的空闲时间超过了规定的时间，将发送TCP指令包以验证该连接是否正常。MDS交换机调用“tcp keepalive-timeout”命令设置指令的超时范围（1～7200秒，默认60秒），以秒为单位。如果连接在规定的间隔内是闲置的，系统将以每秒1次的速度发送8个指令探测器，如果8个探测器都没有收到回复而连接也始终保持闲置状态，就会自动关闭这条FCIP链路。代码清单7.1展示了TCP超时指令配置模板的一个样例。

代码清单7.1　TCP超时指令配置模板

```
fcip enable
fcip profile 1
  tcp keepalive-timeout 30
```

TCP重传

TCP凭借在收到数据段后发送应答消息来保证系统可靠性。但是，数据片段和应答消息都有可能丢失，TCP通过数据发送中的重传超时机制来解决这个问题。如果时间期限已到，还未收到数据应答消息，TCP将重传这些数据。有两个参数用来确定TCP是否继续或终止数据发送：

·TCP最小重传时间

·TCP最大重传次数

“tcp minimum-retransmit-time”命令规定了TCP在重传之前的最大等待时间，最长不超过5000ms，最短不低于200ms，默认值为200ms。“tcp max-retransmissions”命令定义了在TCP决定关掉某个连接前，数据包最多可以被重传的次数，最少1次，最多8次，默认值为4次。代码清单7.2给出了一个TCP重传超时配置模板的样例。

代码清单7.2　TCP重传超时配置模板

```
fcip profile 1
  tcp max-retransmissions 6
  tcp min-retransmit-time 500
```

说明：如果遇到“脏”WAN链路，可以在FCIP配置文件中将“tcp max-retransmissions”值设为“1”，以加速flap探测，不用使用该命令时要非常小心。

TCP应答

通常情况下，TCP使用累加应答机制，因此只有有序数据片段才能收到应答。如果发生包丢失的情况，接收方即使成功接收了后续片段也不会返回应答，因此，当发生包丢失现象时，发送者无法了解当前窗口中正在传送的数据有哪些已经正确接收了。这样一来，发送方就只能在探测到重传超时后重传自丢失包开始的所有数据片段，这会导致系统将重传已经成功发送了的数据片段，从而产生不必要的网络带宽占用。重传超

时同时也会使得拥塞控制窗口尺寸产生很大缩减，导致后继传输速度比之前要慢。

接收方可以使用有选择地应答（SACK）机制，来有选择地对包丢失后收到的数据段进行应答，而发送方在收到这样的应答消息后，就能够只重传那些真正丢失了的数据片段。“tcp sack-enable”命令能激活SACK（默认为激活状态）。

MTU尺寸

最大传输单元（Maximum Transmission Unit,MTU）尺寸，有两难：

·MTU尺寸太大，如果遇到无法处理大尺寸包的下行流设备，就会导致包重传。

·MTU尺寸太小，包头数目增多，应答消息也随之增多，都会占用带宽。

FC帧的最大尺寸为2148，可以使用标准以太网MTU尺寸1518对FC帧进行划分。也可以使用巨帧，则FCIP有效负载可以提高到一个完整尺寸FC帧，而不需要将帧分割成小的片段。不过，如果要真正应用这样的方案，由FCIP连接的MDS交换机间整个IP基础设施都必须支持巨帧。

路径MTU（Path MTU,PMTU）是FCIP链路端点间的IP网络的最小MTU,TCP可以采用PMTU发现（PMTU discovery,PMTUD）机制动态确定PMTU的尺寸，并调整相应的最大TCP片段。理想情况下，PMTUD要和巨帧一起使用，MDS交换机将重启超时设为默认的3600秒，就能激活PMTUD，也可以调用“tcp pmtu-enable”命令激活（默认为激活状态）。

流控制

FCIP隧道的流控制与本地FC相比有少许不同，尽管它们都负责FC网络传输，但是它们不使用BB_Credit，因此也不受BB_Credit的局限。相反，会采用TCP流控制，一种借助端到端的滑动窗口实现流控制的机制。窗口的大小决定了是否能够达到理想吞吐量或维持现有数据流。在FC网络中，除了FCIP跳，每一跳都用到了BB_Credit,FC流控制将在FCIP隧道的VE_端口终止。

MDS交换机使用最大带宽参数、最小可得带宽参数以及动态测量到的往返时间自动计算自动计算得出理想的TCP窗口的尺寸，默认设置如下：

·最大带宽=1 Gbps

·最小可得带宽=500Mbps

·往返时延（RTT）=1ms

TCP最大窗口尺寸（Maximum Window Size,MWS）由（最大带宽/8）×RTT×0.9375+4-KB得到。

数据包整形

FC传输具有突发性，传统TCP会放大这样的突发性。如果使用传统TCP，网络必须要能通过交换机和路由的缓冲区消化这些突发流量，如果在传输结点没有足够的缓存空间，就会发生丢包。为了降低丢包概率，MDS上的FCIP TCP实现方案使用数据包整形技术以降低离开GE接口的TCP流量的突发性。

当正确配置完包整形，GE接口发送的包就能获得足够的空间，就不需要或只需要极少缓存就能在FCIP链路中的中转结点间直接转发。由于采用了每包整形以及TCP拥塞窗口监控（Congestion Window Monitoring,CWM）机制，TCP就不容易再超过下行流设备的处理能力，从而降低了丢包概率。

配置包整形时，需要知道最小可得带宽（由下行流路径决定），作为TCP慢启动的阈值。包整形器会将这一阈值放大到1个RTT，然后，MDS FCIP TCP栈将使用线性拥塞控制，以每RTT两个片段的速率增大吞吐量，直到达到MWS。如果发生拥塞，拥塞控制窗口会缩小到最小可得带宽那么大，恢复快慢与最小可得带宽配置成比例。也即，最小可得带宽参数决定了FCIP能够有多主动，如果参数值较大，将使得FCIP更主动，如果参数值较小，FCIP将变得更平均。

说明：整形器只在空闲期后的首个RTT时段有效，在首个RTT后，返回应答记载了以后包的发送时间。

说明：如果FCIP路径拥有1Gbps（或更多）可得指定点到点带宽，发送者就可以以千兆速度发送数据，而无须担心超过下行流路由或交换机的缓存能力。

要保证包整形器能正确工作，配置要求包括：

·最小可得带宽至少为最大带宽的1/20

·必须激活SACK

在配置包整形时，了解FCIP可得的最大和最小带宽非常重要，如果能够正确选择最小可得带宽，就很少会产生下行流路由和交换机溢出。代码清单7.3展示了一个简单的包整形配置模板。

代码清单7.3　包整形配置模板

```
fcip profile 1
  tcp max-bandwidth-mbps 900 min-available-bandwidth-mbps 300 round-trip-time-ms 10
```

FCIP写加速

常规的SCSI FC协议（FC Protocol,FCP）写操作需要在发起主机和目标阵列或磁带间往返两次完成：

·第1轮：发起者启动一个SCSI写命令（FCP_WRITE），目标调用FCP传输就绪命令（FCP transfer-ready command,FCP_XFER_RDY）进行应答。

·第2轮：发起者根据之前在就绪命令中指明的参数发送数据帧，如果I/O正确完成，目标将回应一个SCSI状态应答（FCP_RSP）帧。

两次往返增加了延时，如果应用I/O操作能力有限，例如磁带备份，这一问题将更加突出。使用FCIP写加速，可以减少每次SCSI FCP写操作的FCIP WAN往返次数。

FCIP写加速属于SCSI协议池机制，它能够缩短SCSI写I/O以及复制写I/O操作的时间，从而提高应用性能。FCIP写加速欺骗了XFER_RDY：

1.当发起者发起一个SCSI FCP写命令后，MDS交换机（目标到发起者的代理）将会立刻向发起者返回一个FCP_XFER_RDY。

2.发起者可以立刻通过FCIIP隧道向目标传送数据，数据由远程MDS交换机（发起者到目标的代理）接收并缓存。

3.在远程终端，目标并没有意识到写加速，响应FCP_XFER_RDY，远程MDS交换机将不会允许这个应答通过

WAN返回。

4.当远程MDS交换机收到FCP_XFER_RDY时，将允许数据发送到目标。

5.所有数据都接收完毕后，目标回应一个FCP_RSP应答或状态，确认操作已经完成（例如，FC Exchange）。

FCIP可以将常规FCP_WRITE操作两次往返减少到1次，它允许主机（发起者）无须等待WAN返回XFER_RDY的较长延时，就能发送待写入的数据。

说明：发起者/目标这样的MDS交换机代理将更改FC头包的OX_ID和RX_ID域，并创建一个新的RX_ID，但是这会违背原始的FC CRC校验，因此，如果与新的RX_ID产生冲突时，就需要重新创建一个新的FC CRC。

图7-18顶部展示了一个不带写加速的常规SCSI写操作，而底部图展示的是带写加速的SCSI写操作。

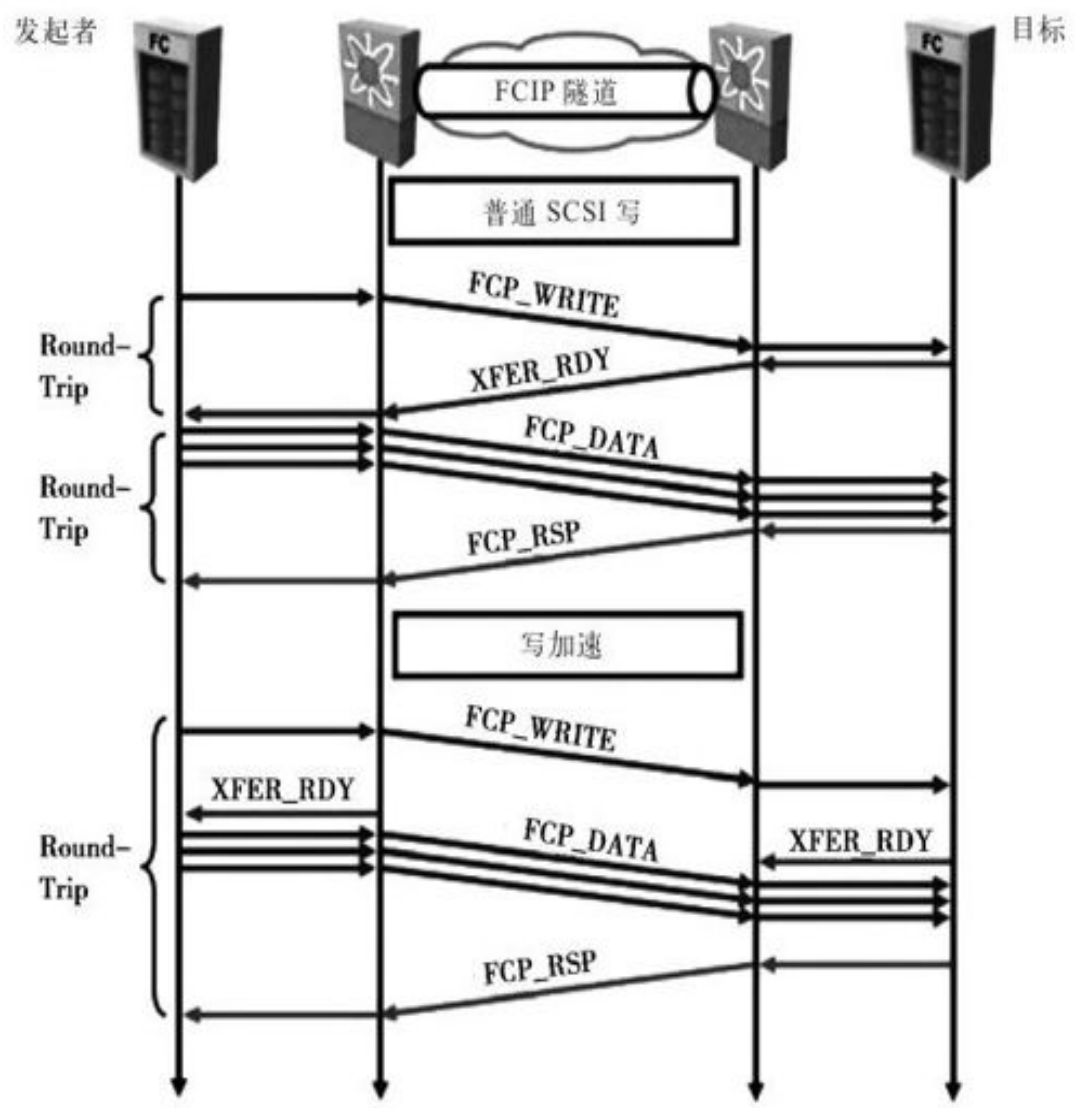


图　7-18　FCIP写加速前后

代码清单7.4给出了一个FCIP写加速配置模板样例。

代码清单7.4　FCIP写加速配置模板

```
interface fcip1
  write-accelerator
```

FCIP磁带加速

有限缓存是磁带设备的通用问题，经常不足以应对WAN时延。即便有了写加速，每个设备也仅能支持一个高效I/O操作，仅有写操作加速无法保证磁带流，它可以将一个写I/O缩短到只有全部RTT的一半，但是发起者在发送下一条FCP_WRITE指令前，仍然需要等待FCP_RSP。如果时延太高导致磁带设备未能

及时收到下一数据块，将使得磁带设备不得不停下来并倒放磁带。因此而产生的“擦鞋效应”不仅仅增加了设备完成备份任务的时间，同时也潜在地降低了磁带设备的使用周期。

FCIP磁带加速是对写加速的强化操作，可以扩展MDS交换机上磁带缓存，同时还带有流量控制机制，能够避免缓冲区溢出。图7-19展示一个写加速中的FCIP磁带加速样例。备份服务器发起一个到磁带库设备的写命令，本地MDS交换机对命令进行缓存，并且以代理身份发出一个XFER_RDY告知主机（实际的备份服务器）以开始数据传送。收到数据后，本地MDS交换机会将数据放入缓冲区，全部数据缓存完毕后，它会代理发送一个正常的STATUS消息，以表示SCSI写操作已成功完成。当主机收到这一消息后，会启动下一个SCSI写操作。与写加速不同，磁带加速通过代理发送STATUS消息和XFER_RDY，支持写命令的本地应答，与不带加速的磁带相比，强化（有磁带加速的写操作）后，在相同的时间段，能够通过FCIP隧道发送更多的数据。远程MDS交换机将命令和数据都放入缓存，数据转发前监听来自磁带设备的XFER_RDY消息，以赶上备份服务器的速度。

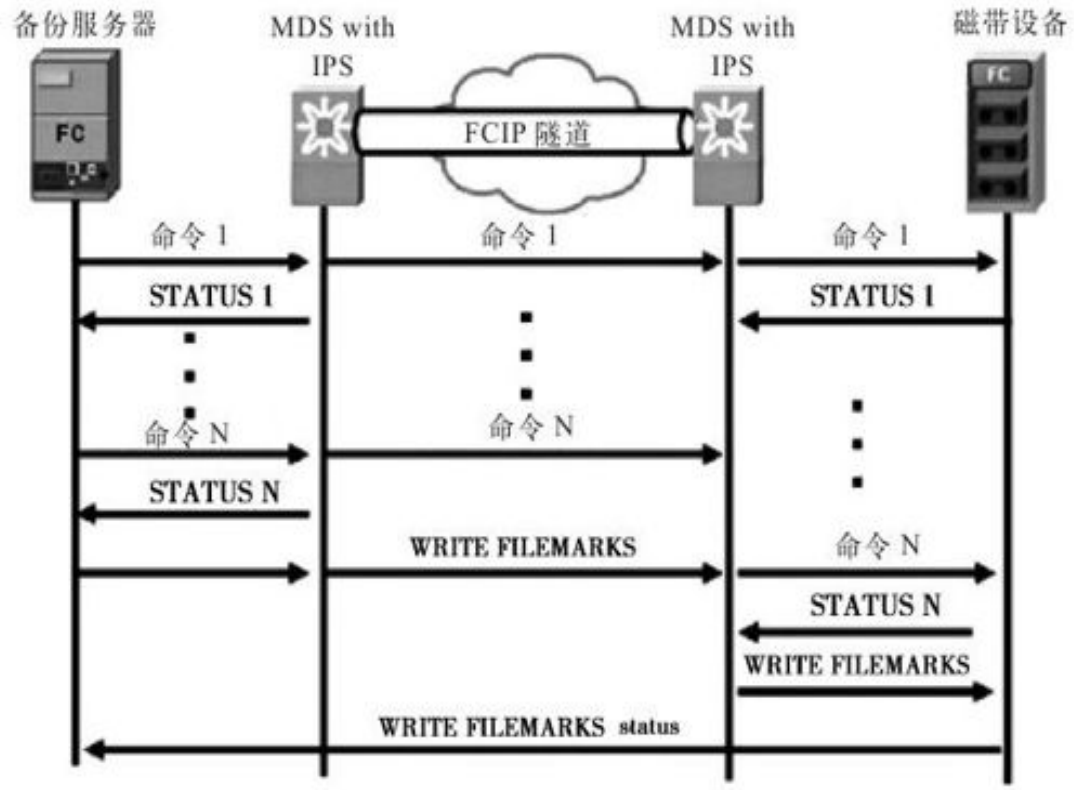


图　7-19　FCIP有磁带加速的写操作

说明：有磁带加速的写操作要求WRITE FILEMARKS操作以点对点而非代理模式进行，以维护写数据的一致性。WRITE FILEMARKS操作对缓冲区的数据和磁带库数据进行同步标识，当磁带介质故障被返回到备份服务器时，远程MDS交换机也会自动重试磁带忙错误。

WAN上进行数据恢复和从磁带设备读数据的应用所面临的性能问题各不相同。图7-20展示了一个应用FCIP磁带加速的写操作样例。恢复服务器向磁带库设备发起读操作，在整个恢复过程中，在磁带终端的远程MDS交换机，在等待更多来自主机（恢复服务器）的SCSI读操作同时，也会向磁带设备发出自己的SCSI读操作，并将提前读得的数据放入本地MDS交换机的缓冲区内，然后再根据收到的主机依次发出的SCSI写操作顺序，将已缓存的数据发送回主机。

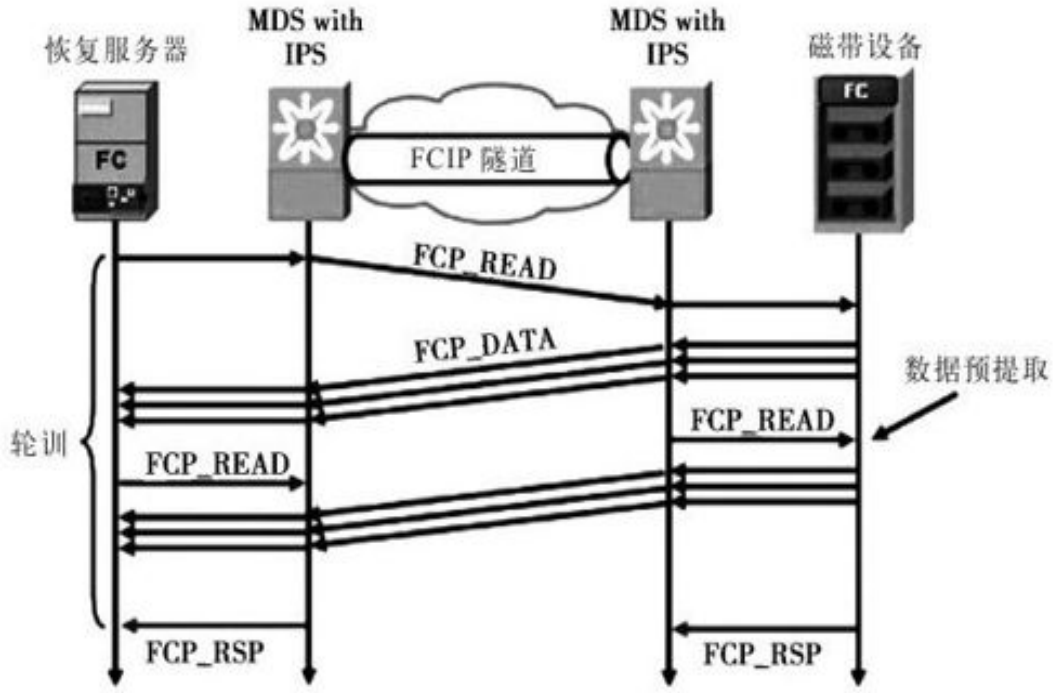


图　7-20　FCIP有磁带加速的写操作

通过提前获取数据并保持磁带正常移动，FCIP磁带读加速显著改善了WAN上磁带读写的效率。代码清单7.5展示了一个FCIP磁带加速配置模板样例。

代码清单7.5　FCIP磁带加速配置模板

```
interface fcip1
  write-accelerator tape-accelerator flow-control-buffer-size auto
```

磁带写加速需要首先激活写加速，默认流控制缓冲区使用自动方式，优化处理时会综合考虑WAN时延和磁带速度等因素，用户也可以自己定义流控制缓冲区尺寸（64-12，288KB）。

说明：磁带加速时，当远程MDS交换机积累一定缓冲数据后，本地MDS交换机将会对主机写操作实施流控制，不再代理XFER_RDY，只有当完成了一个写操作，缓冲区中某些数据被释放后，本地MDS才会继续启动代理。

FCIP压缩

压缩能够提高慢速WAN链路的整体吞吐量。MDS交换机支持IP有效负载压缩，采用Lempel-Ziv-Stac（IPPCP LZS）无损数据压缩算法。IPPCP LZS压缩内容包括IP的TCP头以及剩余的有效负载，有效负载中嵌套了FCIP帧，IPPCP LZS只对有效负载进行处理，IP头保持不变。这种特殊的IP包一样可以通过IP网络传输，同时仍然可以基于IP头部域信息完成ACL和QoS处理。IPPCP LZS算法的压缩效果依据数据流的数据类型而定，一般情况能达到2:1的压缩率。

可以使用下列任意一种模式配置FCIP压缩：

·模式1：对高带宽链路（＞25Mbps）采用快速压缩模式

·模式2：对中低带宽链路（10～25Mbps）采用普通速度压缩模式

·模式3：对低带宽链路（＜10Mbps）采用高度压缩模式

·自动（默认模式）：根据链路带宽，选择合适的压缩模式（自FCIP配置文件中TCP参数可得带宽信息）。

代码清单7.6展示了一个FCIP压缩配置模板样例。

代码清单7.6　FCIP压缩配置模板

```
interface fcip1
  ip-compression mode3
```

WAN加速（参见第4章）使用了重复数据删除技术，它能提供比LZS更高的压缩效率，只要可能，就应该优先以上压缩模式而使用。

IP QoS

MDS交换机通过对FCIP控制传输及数据传输中进行分类和优先级实现了QoS，采用了RFC2474和RFC2475标准定义的DiffServ模型，QoS参数采用差分服务代码点（Differentiated Services Code Point,DSCP）的值给每个IP包进行如下标记：

·将控制DSCP值用于所有控制TCP连接中的FCIP帧标记；

·将数据DSCP值用于所有数据TCP连接中的FCIP帧标记；

·如果FCIP隧道只有一种TCP连接，则将数据DSCP值用于TCP连接中所有包标记。

代码清单7.7展示了一个FCIP IP QoS配置模板样例。

代码清单7.7　FCIP IP QoS配置样例

```
interface fcip1
  qos control 34 data 26
```

7.4.5 FCIP安全

由于光纤本身就难以跟踪，所以通常认为DWDM/CWDM以及SONET/SDH链路是相对安全的，但FCIP本身并不支持任何一种基于IP的安全策略，因此Internet或公共网络上的FCIP隧道上数据传输存在很大的安全隐患。FCIP需要依赖IPSec实现基于IP的安全服务，用户可以在现有路由器或WAN边缘的VPN设备上激活IPSec实现对FCIP传输进行加密处理，这与第3章中的基于DMVPN的WAN解决方案是一致的。也可以使用另一种方法，利用FCIP网关产品中内置的IPSec功能（如果支持的话）。

说明：MDS 14/2端口多协议服务（MPS-14/2）模块拥有内置IPSec硬件加速。

说明：当FCIP链路已成功建立好了之后，FC虚拟ISL的安全由FC安全协议（FC Security Protocols,FC-SP）负责，例如Diffie Hellman-挑战握手认证协议（Diffie Hellman-Challenge Handshake Authentication Protocol,DH-CHAP）。

7.5 iSCSI

iSCSI将讨论又重新带回到我们所熟悉的技术世界——以太网和TCP/IP。SAN加上iSCSI多基于IP网络，也被称为iSCSI SAN。理想情况下，iSCSI启动器（主机）和iSCSI接收端（存储阵列）都被接入到现有以太网的交换机上，通信和数据传输就可以通过TCP/IP栈之上的iSCSI会话完成。这听起来非常简单，但再想想看，在FC上使用iSCSI的主要原因是什么？答案为：

·iSCSI可以与现有以太网基础设施无缝集成。

·当进行I/O传输时，iSCSI比TCP/IP有优势。

·iSCSI使用块I/O访问，因而可以通过SAN访问iSCSI存储阵列。

除了这些优点，更重要的是iSCSI便宜多了。如果这些都成立，那企业又为什么会先考虑使用成本更高的FC呢？关键原因在于那时的以太网最快也只有1Gbps，而FC HBAs却拥有2Gbps和4Gbps端口。尽管10GE已经克服了这一局限，对已经安装了大量FC设备的企业用户而言，实现iSCSI仍然具有很大困难，因为无法保留现有的FC管理和部署模型。因此，iSCSI更适合新成立的以及SMB型企业。那样的话，还是值得考虑iSCSI：

·可以作为替代FCoE（更多细节参见第2章）的存储整合

·对BC和DR的主机镜像或备份

·远程网络引导

7.5.1 iSCSI协议概述

本小节将讨论以下几个iSCSI概念：

·iSCSI包格式

·iSCSI组件

·iSCSI命名规则

·iSCSI会话类型

·iSCSI安全认证

·iSCSI请求和非请求数据传输

·iSCSI发送端机制和服务器虚拟化

iSCSI包格式

iSCSI能够通过TCP/IP网络实现发送端和接收端直接的块级访问，SCSI命令、数据以及状态信息都被封装在一个iSCSI PDU里，通过TCP进行SCSI（I/O）传输，可以保证大容量数据存储的有序可靠传输以及拥塞控制。此方案同样也克服了距离局限，使得IP主机能够访问到之前孤立的基于FC存储对象。图7-21展示了在建立iSCSI会话过程中，不同级别协议PDU如何通过嵌套构成了一个以太网的帧。

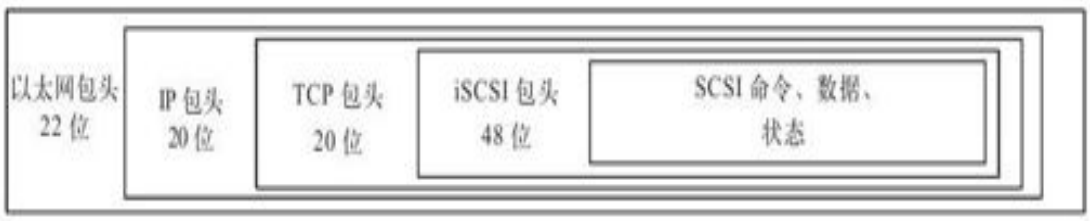


图　7-21　iSCSI封装

iSCSI包中的TCP有效负载部分了iSCSI PDU。所有iSCSI PDU包含一个或多个头段开始，然后紧跟着0个或1个数据段。第一段为基本头（Basic Head,BH）段，它是一个固定长度为48字节的头段，它后面可以是附加头段（Additional Header Segments,AHS），可选头部摘要，可选数据段以及可选数据摘要。

除了BH，所有头段都是可选的，可选头部摘要为CRC-32（32位循环冗余校验）值以检查相应片段（头部和数据）的正确性。除了专门指定了3260作为TCP目标端口，iSCSI看起来和其他IP包没有什么差别。从L2角度来看，iSCSI包和普通以太网帧并没有不同之处。

说明：iSCSI封装中过多的头部数据对系统吞吐量效率有一定影响，为了获得更好的吞吐量，应该激活巨帧功能。

iSCSI组件

图7-22展示了iSCSI的结构和组件，它们包括：



图　7-22　iSCSI结构和组件

·网络实体：网络实体代表一个可以从IP网络访问到的设备或者网关。网络实体必须拥有一个或多个端口，在一个网络实体中的ISCSI节点能够用其中的任意一个网络端口访问IP网络。

·iSCSI节点：一个iSCSI节点代表单个iSCSI启动器或iSCSI目标设备。在一个网络实体中可以存在一个或多个iSCSI节点，可以通过一个或多个网络端口访问这些节点，iSCSI节点都是通过它的iSCSI名称被唯一标识的。iSCSI名称与IP地址是分离的，这使得多个iSCSI节点可以共用一个IP地址，而一个iSCSI节点也可以使用多个IP地址。

·网络端口：网络端口负责实现TCP栈，iSCSI节点利用网络端口实现一个iSCSI会话连接。iSCSI启动器实体用IP地址给网络端口命名，iSCSI目标对象用IP地址和监听TCP端口定义网络端口。

·端口组（未在图中标出）：一个iSCSI节点内定义的多个网络端口组成了端口组，端口号范围从0到65535。每个iSCSI会话可以支持多个链路及多个TCP连接，也可以建立多条路径访问同一个iSCSI节点。iSCSI启动器和iSCSI目标对象都拥有各自的端口组，但是在iSCSI协议中，只能直接使用iSCSI目标对象端口组。

说明：一个或多个从启动器到目标对象的TCP连接构成了一个iSCSI会话，这些TCP连接既可以在同一物理链路上实现，但逻辑相互分离，也可以是不同物理链路上的不同连接。

iSCSI命名规则

每一个iSCSI节点无论是启动器还是目标对象，都是通过iSCSI名称进行区分，它同时也是iSCSI设备的名字，无论是目标对象到启动器的授权还是启动器到目标对象的授权，甚至包括存储资源的管理和验证均凭借iSCSI名称完成。

iSCSI名称与iSCSI节点而非iSCSI网络适配卡相关，这种命名原则保证了不会因更换网络适配卡而需要重新配置所有的SCSI和iSCSI位置信息，同时也可以达到iSCSI存储资源管理与其位置（地址）无关。iSCSI名称必须是全局唯一并且长期有效（例如，iSCSI启动器节点和目标节点在他们的生命周期内不能拥有相同的名称）。

目前，iSCSI节点名称分三类定义：iSCSI认证名称（iSCSI Qualified Name,IQN）、扩展唯一标识符（Extended Unique Identifier,EUI）以及网络地址授权（Network Address Authority,NAA）。

IQN串最大可达223个字符，包含内容按以下顺序排列（从左到右升序）：

1.字符串“iqn”

2.日期编码，采用“yyyy-mm”格式

3.点（.）

4.创立这个iSCSI名称的命名机构（个人或机构）的逆向完整认证域名（Fully Qualified Domain Name,FQDN）。

5.以（：）或（.）为前缀的授权字符串，长度和内容都必须经过域的所属者确认。在授权字符串中可以包括产品型号、序列号、主机标识或软件密钥（例如，可以利用“：”来分隔组织边界）。采用“：”号分隔后，域的所属者可以在逆向域名后赋任意值，iSCSI名称全球唯一性也必须由该命名组织负责，“：”符号可以划分组织内部子域以避免命名冲突。

例如，“Example Storage Arrays,Inc.”可能拥有“example.com.”，该组织可以定义如下一些IQN：

·iqn.2001-04.com.example：storage：diskarrays-sn-a8675309

·iqn.2001-04.com.example

·iqn.2001-04.com.example：storage.tape1.sys1.xyz

·iqn.2001-04.com.example.storage：tape1.sys1.xyz

·iqn.2001-04.com.example：storage.disk2.sys1.xyz

EUI型的iSCSI节点名称长度固定为20个字符，EUI格式名称包括两部分：类型定义符“eui.”，再紧跟着一个合法的IEEE

EUI-64字符串，为16进制的8个字节，例如：

eui.02004567A425678D

NAA型的iSCSI节点名称可以为20或36个字符，iSCSI NAA名称格式为“naa.”，后面跟着一个16进制的NAA标识符，例如，下面是一个带8位NAA值的iSCSI名称：

naa.52004567BA64678D

而一个带16位NAA值的iSCSI名称可以是：

naa.62004567BA64678D0123456789ABCDEF

说明：iSCSI协议并不会使用iSCSI完全验证地址，该地址是为应用程序服务的。可以采用类似统一资源定位符（Uniform Resource Locator,URL）形式来表示iSCSI节点的完全认证地址：< domain-name > [： < port >]/ < iSCSI-name > 。

iSCSI会话类型

iSCSI支持两类会话：普通会话和发现会话。发现会话只能使用一个TCP连接，而普通会话一次可以使用多个TCP连接以实现负载平衡和更好的容错性。所有的iSCSI会话的处理都分为两个主要阶段完成：登录阶段和工作阶段。登录处理包括两个子阶段：安全系数协商以及操作系数协商，这些子阶段均为可选操作，但是登录过程至少要实现其中一个。

iSCSI启动器可以通过三种方式发现iSCSI目标对象：

·人工配置（还未发现）；

·调用“SendTargets”命令（半人工配置）；

·“零配置”（自动配置）方法，例如，服务定位协议（Service Location Protocol,SLPv$_2$）以及Internet存储名称服务协议（Internet Storage Name Service,iSNS）。

为了方便解释，本节只讨论“SendTargets”命令。如果要调用“SendTargets”命令建立一个发现会话，需要手工配置启动器的IP地址以及目标对象的TCP端口序号。发现会话登录是为了确认启动器节点和目标对象以便对响应进行安全过滤，登录请求时需要知道启动器节点名称而非目标节点名称，因为在启动器开始发现操作之前是无从得知目标节点名称的。当登录完成后，发现会话进入到工作阶段，工作阶段能调用的命令只

有“SendTargets”命令。初步发现完成后，可以关闭或继续保持该发现会话。图7-23展示了一个发现会话样例。

如果是普通会话，启动器将需要在登录请求中指出目标节点名称，登录完成后，普通会话将进入到工作阶段，在这一阶段中，启动器可以调用也可以调用SCSI命令，也可以发送SCSI控制和数据信息。图7-24给出了一个普通会话样例。

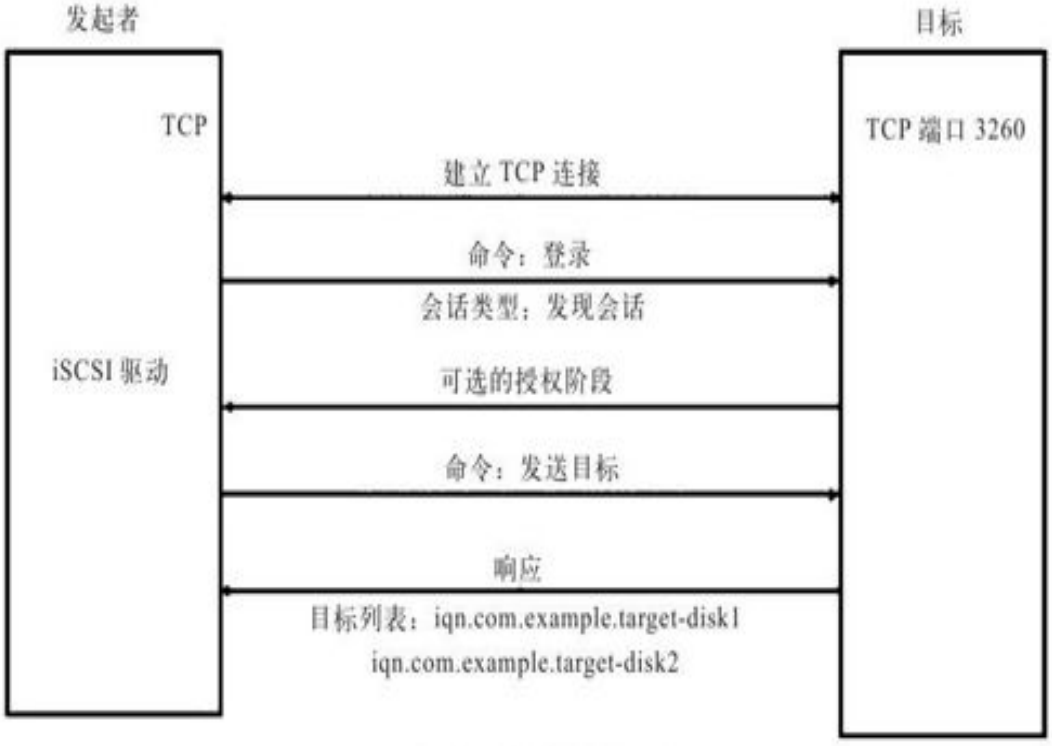


图　7-23　发现会话样例

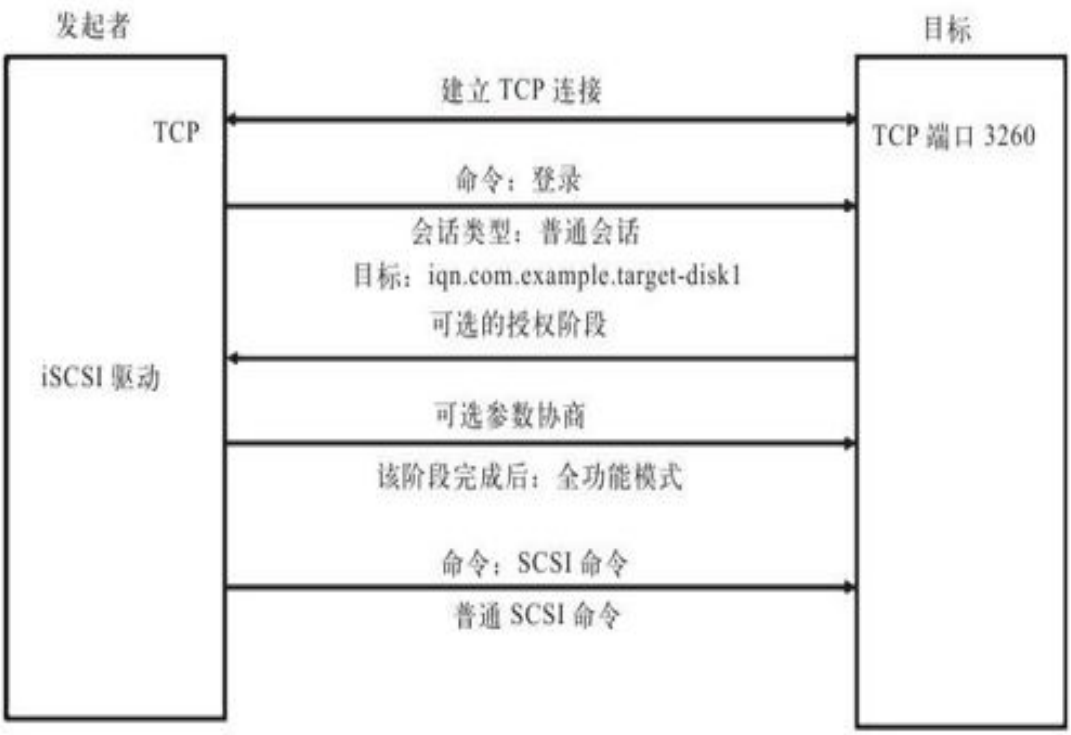


图　7-24　普通会话样例

iSCSI安全认证

当启动器进入安全认证阶段后，它将通过登录请求PDU中数据片段AuthMethod keyword-value组指明所支持的认证方式。所有支持的方法按先后顺序列表，如果参数值为“none”，则表明启动器希望跳过认证阶段。目标节点将从启动器提供的协议列表中挑选出第一个协议。

iSCSI一般要求要能够支持挑战握手认证协（Challenge Handshake Authentication Protocol,CHAP），绝大多数厂商都能满足这一要求。此外，iSCSI还可以支持远程密码安全（Secure Remote Password,SRP）、Kerberos 5、简单公共密钥机制（Simple Public Key Mechanism、SPKM-1 or SPKM-2）。

说明：MDS IPS模块支持使用本地密码库、一个RADIUS服务器以及THCACS+服务器以完成CHAP认证。

iSCSI请求和非请求数据传输

当成功完成登录和认证过程后，启动器和目标对象都将进入工作阶段。在这一阶段里，设备将交换普通命令以及数据PDU，两类基本的数据传输为：

·非请求数据传输：启动器发送的写命令PDU里的写操作后面将紧跟着数据输出PDU，不需要从目标对象那里等待返回一个R2T（传输就绪）PDU。目标对象可以通过设置登录数据段中FirstBurstLength键值大小，对能够接受的非请求数据写的大小进行限制。图7-25的左边展示了一个非请求数据传输的样例。

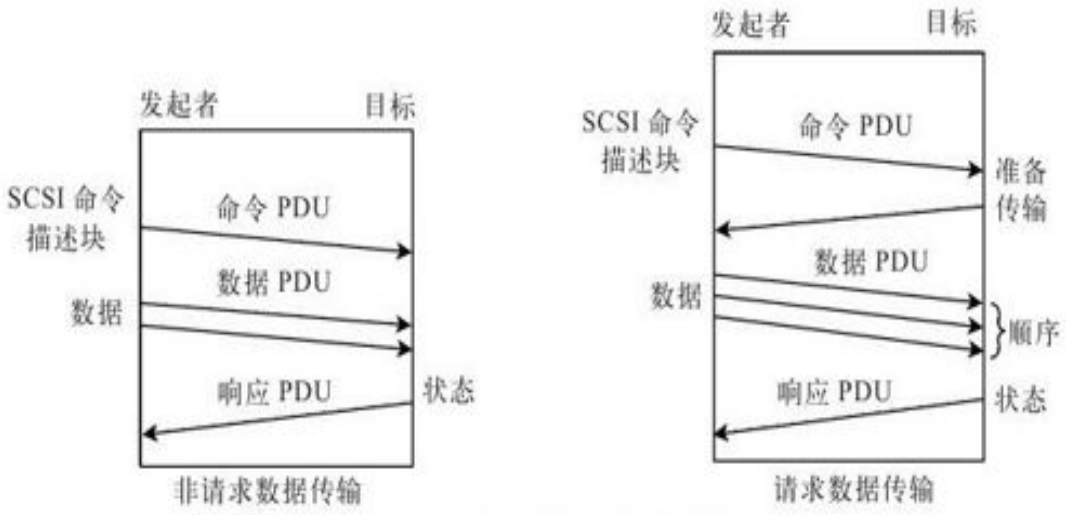


图　7-25　iSCSI请求和非请求数据传输写操作

说明：除了非请求数据传输，也可以将数据作为写命令PDU的一部分，这种方法称为立即数据传输。

·请求数据传输：启动器在PDU中加载写命令，然后等待来自目标对象的R2T PDU以及数据输入PDU。启动器和目标对象能够通过设置登录数据段中MaxBurstLength键值大小，限制请求传输写的尺寸。图7-25的右边给出了一个请求数据传输的样例。

说明：在请求数据传输中，iSCSI使用R2T PDU作为主要的流控制机制，控制整个写命令中的SCSI数据流。

iSCSI启动器机制和服务器虚拟化

iSCSI启动机制一般可以分成三类：

·带标准NIC的iSCSI软件驱动程序

·可降低CPU负载的含TCP卸载引擎（TCP offload engine,TOE）的NIC

·卸载了TCP和iSCSI操作的iSCSI HBA

回顾服务器虚拟化（细节内容请参见本书第2章）可知：iSCSI硬件平台（TOE或iSCSI HBA）能够在终止iSCSI的监控器上驻留，监控器为整个物理服务器或每一个VM都建立了单独的iSCSI会话，iSCSI软件（iSCSI驱动器）也可以在一个虚拟NIC的VM上运行。此时，iSCSI传输对监控器是透明的，监控器只能“看见”携带了iSCSI的PDU。

7.5.2 iSCSI部署

有两种主要的iSCSI部署方案：本地IP SAN和异构IP SAN。本地IP SANs为点到点部署，不需要网关，像IP主机、iSCSI HBA、千兆位以太网交换机、TCP/IP网络等都是适合iSCSI的组件。

而另一方面，异构IP SANs能够通过TCP/IP和FC互联进行iSCSI传输。因此，在IP和FC的分界点需要一个iSCSI网关设备，以承担双重角色。在iSCSI这一端，网关负责将FC目标转换成iSCSI目标对象发给IP主机，而在FC这一端，它又将每一个iSCSI主机转换成FC HBA（FC启动器）。有关更多的异构IP SANs iSCSI部署细节请参看后续内容。

iSCSI视角

MDS IPS模块集成了iSCSI网关的功能，我们将把它作为后面深入探讨的样例平台。在iSCSI这一端，IPS模块将物理FC目标看成虚拟的iSCSI目标，允许iSCSI主机访问它们。实现途径如下：

·动态目标映射：该方法自动地将所有FC目标设备/端口导入成为iSCSI设备，IPS模块将每一个物理FC目标映射成一个iSCSI目标（由VSAN和zoning管理）。换句话说，即所有能通过物理存储对象端口访问到的逻辑单元（Logical Units,LU），都被处理成带有相同逻辑单元序号的iSCSI LU。这种映射生成了一个自动的iSCSI目标名称。图7-26展示了一个动态目标映射的样例。

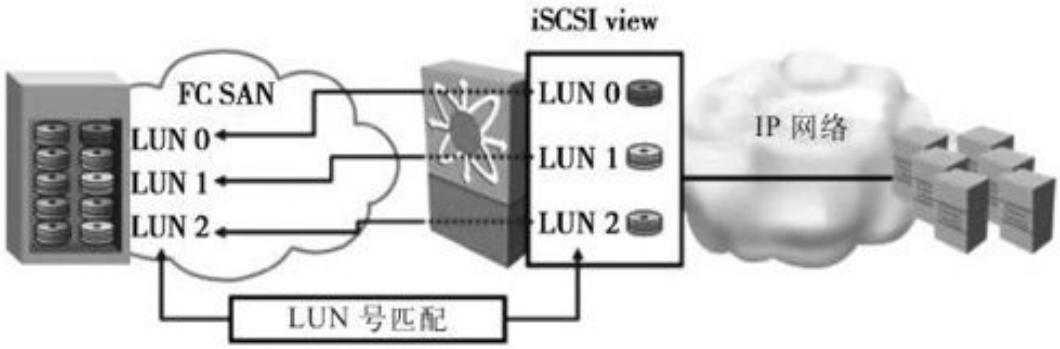


图 7-26 动态目标映射样例

·静态目标映射：这一方法为人工创立iSCSI目标设备，并将它们映射到全局FC目标的端口或FC LUN的子集上，映射时需

要获得唯一的iSCSI目标名称。当iSCSI主机需要被局限到FC目标的LU的逻辑子集范围内并且/或者需要对iSCSI进行访问控制时，将使用静态目标映射。静态导入也支持透明故障恢复，前提是冗余FC端口访问能够访问到FC目标的LU。

FC视角

在FC这一端，IPS模块可以使用两种模式将iSCSI主机转变成FC光纤中的FC目标：

·透明模式：在这一模式中，每一个iSCSI主机都被当初一个虚拟的FC主机，透明模式的优势在于它能够支持不同粒度级别的访问控制配置。由于从iSCSI到FC采用点到点映射，因此每个主机在FC目标上都拥有不同的zoning或者LUN访问控制，如果将iSCSI主机处理为透明模式，可以采用下列方法将iSCSI主机映射到虚拟FC主机上。

·动态映射（默认）：采用动态映射方法，一个iSCSI主机可以映射到动态生成的端口全局名（Port World Wide Name,PWWN）以及节点全局名（Node World Wide Name,NWWN），每次iSCSI主机连接时，都可以被映射到不同的WWN。如果不需要对FC目标设备进行访问控制，可以采用动态映射默认模式。

说明：用户可以调用“iscsi save-initiator”命令将动态iSCSI启动器映射到一个静态iSCSI启动器，这样就能够永久保存动态分配的NWWN/PWWN映射以便启动器再次登录时，能够使用相同的映射。

·静态映射：如果采用静态映射，一个iSCSI主机将被映射到指定的PWWN和NWWN，这个映射关系将被保存在永久存储中，以便每次iSCSI主机登录时，都能使用一样的WWN映射信息。如果需要对目标设备进行访问控制，就要求使用静态映射模式。可以通过以下方式实现这种映射：

·用户分配：由用户在系统配置时指定唯一的WWN。

·系统分配（推荐）：由交换机根据交换机的FC的WWN池确定WWN，并负责保持分配的持久性。

·代理-启动模式：在这一模式中，每个IPS端口只能创建一个虚拟主机N_端口（HBA端口），所有连接到该IPS端口的

iSCSI主机都使用同一个虚拟主机N_端口访问FC目标对象。如果FC存储设备要对每个主机实行显式LUN访问控制，则需使用透明启动模式（将iSCSI主机当初FC主机），因为显示控制意味着需要静态配置每个iSCSI主机，而每个iSCSI主机的配置任务都要分若干步才能完成。此时，使用代理-启动模式将能够简化配置。图7-27给出了一个代理启动样例。

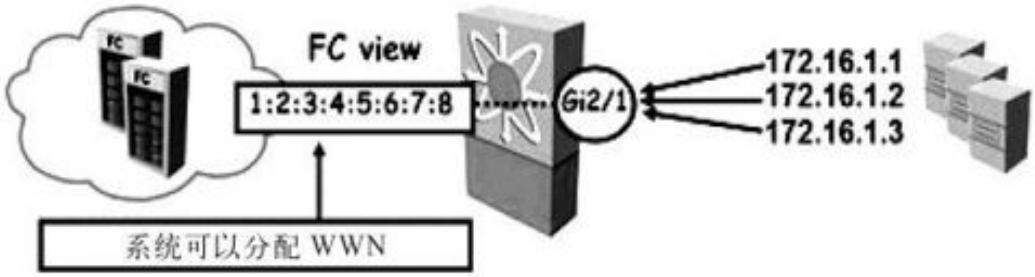


图　7-27　代理启动样例

说明：当使用代理启动模式时，FC存储阵列的LUN映射和赋值都必须被配置成能够允许代理的虚拟N_端口的PWWN能够访问所有的LUN，所有通过该IPS端口连接的iSCSI启动器也使用了这些LUN，然后通过配置静态目标映射（iSCSI虚拟目标和LUN映射）将LUN赋给每个iSCSI启动器以及MDS交换机上基于iSCSI的访问控制。

7.5.3 iSCSI HA

与FC的HA方案性比，iSCSI HA部署使用了更可靠且成本更低的功能，常见的iSCSI HA功能包括：

·适配器组合：适配器组合功能允许两个以太网网络接口能够使用相同的IP地址和相同的MAC地址，从逻辑上看起来就好像只有一个接口一样。适配器组合能够以两种模式运行：要么两个适配器都是主适配器，要么一个是主适配器，将另外一个当做从适配器。

·VRRN：VRRP提供冗余路由网关服务（首跳冗余）。如果IPS模块上的某个千兆位以太网端口发生故障，冗余IPS模块上的另外一个千兆位以太网端口将接管这个iSCSI服务（包括它的属性），为受到影响的iSCSI会话提供服务。

·以太网端口通道：以太网端口通道将两个物理千兆位以太网链路组织成拥有高带宽的一个逻辑链路。

说明：IPS模块上的以太网端口只允许两个连续的IPS端口被绑定到一条以太网端口通道内，如端口1-2、3-4等，这个限制只对以太网端口通道有效。

·目标多路径：目标多路径（也称为PWWN混淆）是通过静态导入iSCSI目标（静态目标映射）完成的，它同时还能够为每一个FC目标提供备选pWWN。如果物理FC目标被配置成拥有一个可见冗余端口均可见的LU，就需要使用这种配置方法。当活动端口发生故障时，备选端口将变成活动端口，iSCSI会话交换机将使用新的端口进行工作。

借助适配器组合、VRRP以及前端采用以太网端口结合后端通过目标多路径实现FC冗余，可以得到一个性价比高且性能稳定的iSCSI HA方案。图7-28展示了一个使用了以上功能组合的iSCSI HA样例。

7.5.4 iSCSI安全

鉴于此前我们已经讨论过iSCSI安全认证的问题，本节的重点将放在iSCSI访问控制方面。iSCSI设备可以从两个不同的角度来实现访问控制：

·基于分区的FC访问控制（在FC端）

·基于ACL的iSCSI访问控制（在iSCSI端）

可以将FC领域的FC分区扩展到iSCSI/IP领域，它使得FC和iSCSI都能够在异构SAN中支持统一的访问控制。可以在iSCSI发现、iSCSI会话及创建FC虚拟N_端口时，强化这两种访问控制机制。

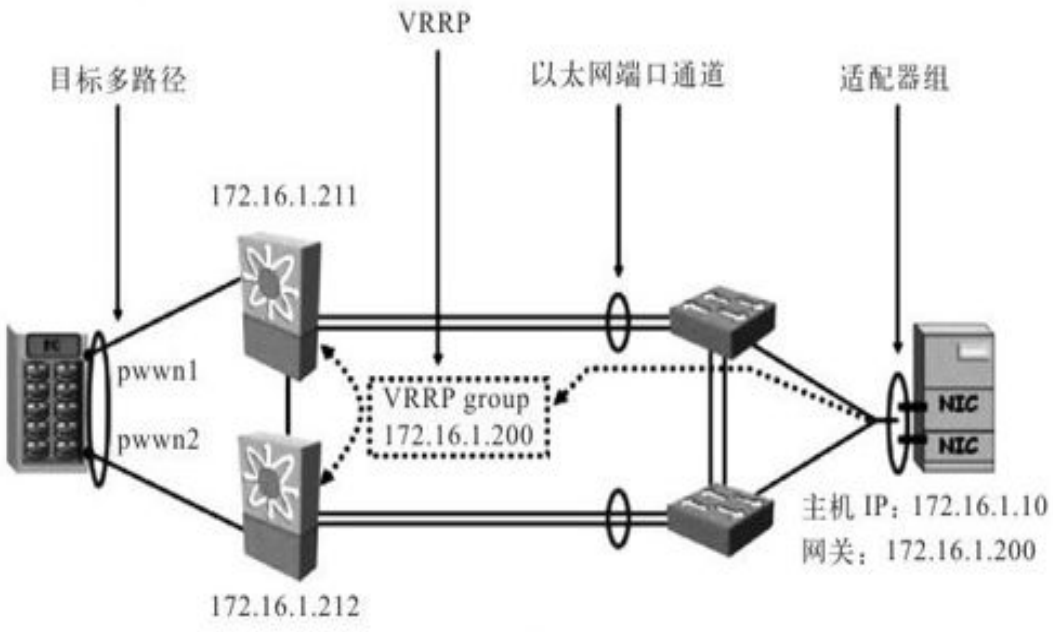


图 7-28 iSCSI HA样例

说明：FC分区属于FC光纤中提供访问控制的机制，它定义了端口之间可以相互访问的关系，也对FC设备之间的互相发现进行了限制。

存在两种FC分区访问控制方法：

·将iSCSI主机静态映射到FC虚拟N_端口以建立永久性的nWWN和pWWN，然后，将赋值了的pWWN配置到分区中，就像在分区中增加一个普通的FC主机的pWWN一样。

·如果iSCSI主机没有静态WWN映射，则可以将iSCSI主机启动器的IP地址或者是iSCSI节点名称加入到分区中，基于IP地址

的分区成员关系允许在一个命令行中通过子网掩码指定多个设备。具备静态WWN映射的iSCSI主机同样也可以使用iSCSI主机启动器的IP地址或iSCSI节点名称而非分区编号。

在代理启动模式中，所有连接到同一个IPS端口的iSCSI设备均通过单独的虚拟FC N_端口访问FC光纤，因此，基于iSCSI节点名称或者是IP地址的分区将不会产生任何效果。如果分区是基于pWWN，则所有连接到相应IPS端口的iSCSI设备都将被放入到同一分区中。此时，要求虚拟目标实现基于iSCSI的访问控制，以便在代理启动模式中完成对单个启动器的访问控制。

创立静态iSCSI虚拟目标是实现iSCSI访问控制的前提，对于一个静态iSCSI目标对象而言，可以配置多个允许访问目标对象的iSCSI启动器。可以通过以下方法来定义列表上的启动器：

·iSCSI节点名称

·Ipv4地址和子网

·Ipv6地址

说明：在默认情况下，iSCSI主机不能够访问任意静态iSCSI虚拟目标。用户必须显式配置访问性，才能够允许所有主机对iSCSI虚拟目标的访问。

除了认证和访问控制、iSCSI，就像FCIP一样，需要依靠IPSec以实现基于IP的安全服务，有关IPSec的深入讨论已超出了本书范围。

7.6 所有方法汇总

图7-29展示了到目前为止本章所讨论的，特定区域范围内多种私有云计算存储模块的互联和扩展方法，以满足BC和DR的目标。

在采用特定解决方案时，需要考虑的四个重要因素包括：带宽、时延、距离以及成本。应用需求决定了对带宽和时延的要求，例如，同步复制要求高带宽，而低时延而异步复制则只要求较少的带宽，也能够容忍较长的时延。而另外一方面，随着物理距离的增加，可得带宽将变得越来越小，相应的时延也会逐步增加，成本成为决定因素是因为高带宽和低时延是更加昂贵也很难满足的方案。

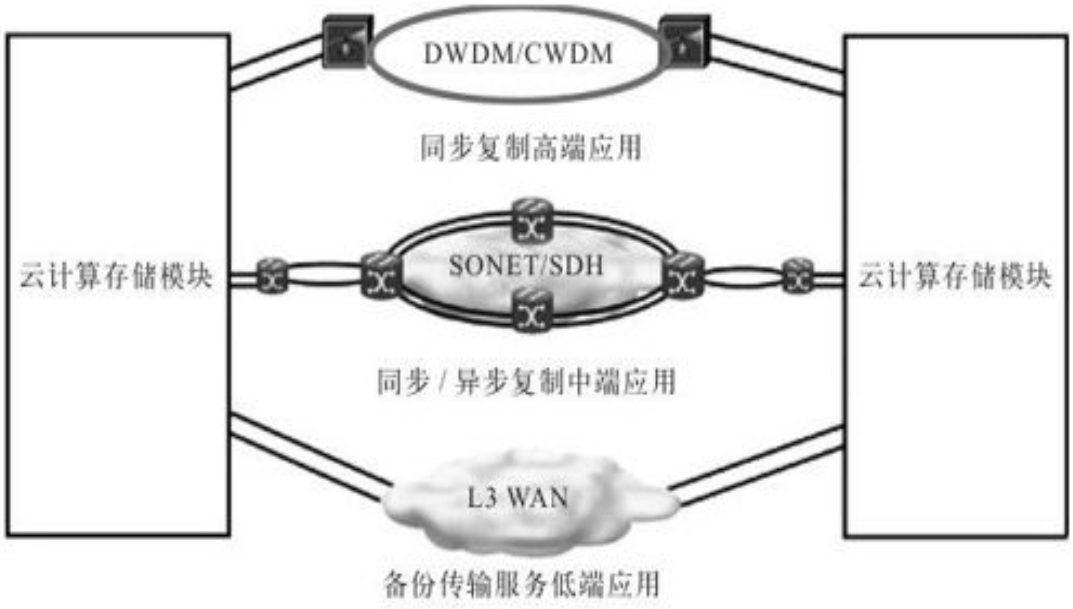


图 7-29 私有云计算的SAN扩展解决方案

以解决方案而言，L3 WAN适合低端应用，SONET/SDH更偏向中型应用，而DWDM/CWDM则是面向高端应用。尽管FCIP和iSCSI基于TCP/IP，物理媒介仍然可以是SONET/SDH以及或者为DWDM/CWDM，它们实际为L1服务。另外，采用正确的WAN优化技术和部署后（更多细节请参见第4章和第5章），也可以选择L3 WAN为中端应用。

说明：VMware VMotion也是一类对带宽和时延非常敏感的应用，DC间所需最低带宽至少为622Mbps，以及至少1Gbps链路，此外，源及目标间往返时延，VMware ESX服务器要求不

能超过5ms，目前，在光纤通道及有保证的网络时延条件下，能够支持的最大距离为400km。

7.7 小结

第7章讨论了私有云计算环境内，各种SAN扩展方案以及多种存储模块互联解决策略，不论建立何种DC，哪怕是私有云环境，都不可避免地要考虑BC和DR的影响。

SAN扩展技术和协议包括：DWDM/CWDM、SONET/SDH、FCIP和iSCSI。哪种协议最流行？当考虑到成本时，哪种策略价值最高？当需要选择一种SAN扩展解决方案时，最后取决于何种应用呢？这些问题可以被简单归纳为以下两个因素：带宽和时延，以及第三个不应被遗忘的非技术原因：成本。主流的SAN扩展技术和协议的主要优势如下：

·DWDM：可扩展性和低时延

·CWDM：成本低廉、时延较少

·SONET/SDH：长距离和中等程度的时延

·FCIP：长距离、成本低廉

·iSCSI：长距离、成本低廉、易于实现异构SAN集成

当处理BC和DR时，还需要考虑可靠性、可获得性以及可服务性（Reliability,Availability,and Serviceability,SDR），因此，需要在SAN扩展解决方案中融入HA技术。对于比较高层的协议，像FCIP和iSCSI，性能调整和安全需要在HA顶层处理。至于WAN，正确的WAN优化器配置能将L3 WAN变成适合中型应用的可能的SAN扩展选择。

最重要的是，以上这些SAN扩展解决方案使得存储网络或SAN片段可以在国家或国际范围内分布，让我们距离通过全球性私有云计算SOI来实现IaaS又近了一步。

第8章　云基础设施即服务

你不可能永远居于巅峰，你一定会再下来。所以，为什么一开始还要麻烦呢？无他，高处的知道低处的，低处的却不知道高处的。你爬，你看见，你超越；然后你又看不见，但你已经看过了。我们有一种方法，借着高处所见的记忆在低处引导自己。当一个人再也看不见的时候，至少他还是知道的。

——勒内·多马尔（Rene Daumal）

简介

紧跟前7章的决心在于如果你能坚持下来，本身就是一项令人惊异的壮举和成就。在第7章我们论述了SAN扩展，它实现了特定物理范围内多个私有云计算SAN互联以满足BC和DR的需求。第8章将对3个更必要的前提条件展开讨论：云安全、统一计算系统（Unified Computing System,UCS）以及云管理。

第8章从服务器虚拟化角度出发，探讨了实现云IaaS服务时应该考虑的各类安全问题，同时阐述了如何利用统一计算模型（Unified Computing System,UCS）来克服当前企业DC服务器部署的局限性，以及UCS能够成为私有云计算及云IaaS服务的理想平台的原因。这一章还分析了云管理与私有云计算以及云IaaS服务的关系，对面向服务基础设施（Service-Oriented Infrastructure,SOI）框架的多个组件进行了讨论，包括如何能够在SOI框架上直接部署云IaaS服务。

8.1 云安全

云安全听起来貌似一个全新的概念，但实际并非如此。好消息是如果对现有的安全基础设施以和安全技术进行一些细微调整并增加某些功能，它们将能够重新适用于云IaaS。重构从根本而言仍属服务器虚拟化（更多细节请参见2.3节）范畴，现有的防火墙、网络入侵预防、web应用防火墙、终端安全等在云安全中仍然能发挥作用，这些安全设备和机制能够像保护物理服务器一样为虚拟服务器提供保护。简括而言，本节将从服务器虚拟化视角出发探讨实现云IaaS服务所需的各类安全保护。

服务器虚拟化后，许多服务的位置将发生变化，特别是，一些以前驻留在隔离区的应用现在会转移到虚拟机上（Virtual Machine,VM），相应地，多个VM也会驻留在同一个物理服务器上。传统DMZ模式中，每一个接入端口都连接了一个物理服务器，来自任何其他服务器或两个服务器间，包括像防火墙或负载平衡这些附加设备的通信，都需要经过物理接入交换机。在虚拟服务器环境中，多VLAN、IP子网以及接入端口都能够作为虚拟接入层的一部分，驻留在同一物理服务器上，VM之间的网络传输可以只在一个物理服务器内部完成而不需要穿越物理接入交换机，因为一个虚拟交换机可以承担和传统物理接入层交换机一样的功能，配置好以后可以完成所有VM之间的连接工作。

由于无法再使用传统方法来收集同一物理服务器上VM间的网络流量信息，因此虚拟接入层安全面临着新的挑战，现有DMZ必须能够适应服务器虚拟化，才能应对这些挑战，可以基于虚拟接入层来设计一个虚拟的DMZ，也可以通过虚拟安全设备来完成这一任务。

专为虚拟网络安全而设计的虚拟安全设施，在虚拟环境内工作，它可以与某些安全应用（虚拟防火墙）预先集成在一起，运行在由虚拟机管理程序控制的硬件平台上，这样的工作方式意味着虚拟安全设施能够直接解决虚拟环境内的安全隔离、保护以及监测问题，而不需要依赖虚拟接入网络外部的物理安全和监测设备，有关虚拟安全设备的更多探讨已经超出了本书讨论范围。

说明：VMware vShield Zones是虚拟防火墙的样例，而NX1KV交换机的Cisco虚拟安全网关（Cisco Virtual Security Gateway,VSG）是虚拟安全设备的样例。

此外，由于所有的应用现在都驻留在同一物理服务器内的多个VM上，因而需要对那些与服务器虚拟化进程有关的物理服务器或硬件平台进行“加固”。平台安全的例子包括：

·1型虚拟机管理程序（裸虚拟机管理程序）：因为是裸机，所以1型管理程序不需要在硬件服务器上安装OS，因此从这个方面发动攻击并不容易。

·精简-虚拟机管理程序策略：精简型虚拟机管理程序压缩了软件占位面积，确保补丁更少，攻击区域也更小，更由于不能随意编写代码，提高了威胁的难度，VMmare ESXi属于精简虚拟机管理程序。

·内存保护：使用无执行（No Execute,NX）位和地址空间加载随机化（Address Space Layout Randomization,ASLR）提供内存保护。

·NX位：CPU使用NX位把内存区域分隔为只供储存处理器指令（代码）或只供存储数据。支持NX位的OS能够将内存的某部分空间标记为不可执行，处理器将根据标记拒绝执行在这部分内存空间中的任意代码。常见的技术，如可执行区域保护，能够防止某些恶意软件将自身代码插入到其他程序的数据存储区域后再运行而控制计算机。

·ASLR：ASLR随机地为关键数据区域安排加载区域，包括在进程的地址空间中确定可执行的基址，以及库、堆、栈等，ASLR增加了预测目标地址类攻击的难度，因为攻击者无法确定相关地址空间的信息。

·核心模块集成：当内核（例如Vmkernel）加载模块、驱动以及应用程序时，通过数字签名确保集成和可信。

·可信执行技术（Trusted Execution Technology,TXT）：Intel TXT技术将处理器、芯片以及可信平台模块（Trusted Platform Module,TPM）集成在一起完成验证，并/或防止基于软件的攻击，例如：

·企图在虚拟机管理程序中插入rootkit（例如，“蓝色药丸”病毒）

·从内存发起的对平台攻击

·BIOS和固件升级攻击

说明：Westmere-EP支持TXT,Westmere-EP是1-2 socket的代号，它最多可以拥有6个核心服务器/工作站处理器，面向Intel 5520芯片组平台（与Intel Xeon 5500平台兼容），Westmere-EP基于Intel微处理器架构（代号Nehalem），属于32nm家族成员之一。

除了平台方面的安全，还需要同时确保所有订购了云IaaS的多个租户的安全隔离，这一任务通常是通过基础设施计算资源虚拟化完成的，包括服务器虚拟化（更多细节请参考本书第2章）、存储虚拟化（更多细节请参考本书第2章）以及网络虚拟化（更多细节请参考本书第3章）。

由于虚拟接入网络与物理网络并无不同之处，它们也会遇到和物理网络一样的漏洞，比方说：

·某个VM的用户，可以访问同一虚拟网络上所有其他的VM。

·对虚拟网络中某个VM进行攻击后，以该VM为平台，能对同一网段上其他VM发动攻击。

·如果虚拟网络与某个物理网络相连或者连接到Internet上，那么虚拟网络上的VM就可以访问到外部资源（同样包括外部攻击），使得它们暴露在攻击之下。

·直接在VM之间传输，未经过安全设备的网络流量是未受监控的。

虚拟网络上同一VM内（或VM到VM）直接的网络传输几乎不可见，由此产生的问题与物理网络遇到的问题基本类似，并且因为包完全是在单个物理主机的硬件之内移动使得问题更为复杂：

·虚拟的网络传输没有超出物理主机的硬件范围，使得安全管理器无法对直接VM到VM的网络传输进行检查，既不能够实施拦截，也不清楚传输目的何在。

·在单个主机内对记录VM到VM网络活动的日志，以及对VM访问进行常规攻击检测都非常困难。

·无法检测或修复那些因直接VM到VM传输活动而产生的对网络资源不正确使用及带宽占用。

·无法检测出虚拟网络上或内部运行不正常的服务。

·VM流氓程序会耗尽整个主机物理资源（CPU周期、内存等），从而影响整个虚拟环境及其他VM的性能。

8.1.1 虚拟交换机安全

本章将以Nexus 1000V（NX1KV）交换机作为虚拟接入层交换机的代表。除了第2章提到的优点以外，NX1KV同样也继承了物理接入层交换机的很多安全特性，包括：

·VLAN

·私有VLAN

·访问控制列表（Access-control list,ACL）

·防欺诈功能，诸如：

·动态主机配置协议（Dynamic Host Configuration Protocol,DHCP）监听

·IP源防护

·动态ARP探测（Dynamic ARP Inspection,DAI）

·端口镜像

·NetFlow版本9

说明：NX1KV属于L2交换机，但是也配备了L3/L4的产品以支持ACL、NetFlow、QoS以及IGMP监听等功能。

VLAN

虚拟接入层能够支持VLAN，虚拟接入层交换机所支持的VLAN能够从L2的角度，提供可靠的网络传输分段方法，以保持L3的隔离路径，并将其扩展到虚拟接入层。VLAN加上ACL功能后，能够将数据流分配至不同的VM和设备上。VLAN安全措施是物理接入层交换机的最佳方案在虚拟环境中依然成立，依然适用于虚拟环境。

私有VLAN

驻留在同一VLAN内的VM之间仍然可以相互访问，和在物理环境中访问方式一样并没有区别，如果其中某一个VM受到攻击，会影响系统整体的安全性，因为可以从受到攻击的VM上向VLAN中的其他VM发起二次攻击，包括：特殊应用攻击、中间人攻击或那些以攻击系统破坏数据为目的的网络攻击。

虚拟交换环境使用私有VLAN（Private VLAN,PVLAN）来分离同一VLAN内的VM，也可以进一步将PVLAN再分成主VLAN和从VLAN，主VLAN负责完成接入，从VLAN与配置虚拟或物理交换机位于同一地点，每个从VLAN与一个主VLAN关联，一般的子网中，一个主VLAN可以与多个从VLAN关联。当配置PVLAN时，可以使用三种端口：

·混杂端口：混杂端口可以看成是PVLAN的“开放端口”，它能够与其他所有端口通信。混杂端口通常负责完成交换机上行链路及主VLAN的网络传输。设置混杂端口的目的是为了完成群体或隔离VLAN间的网络传输，也可以把混杂端口当成trunk端口或接入端口。

·群体端口：这些端口能够与同一群体内的群体端口或混杂端口进行信息交换。不同群体间的群体端口之间不能交互，换句话说，分配给某个群体VLAN的端口属于群体端口。

·隔离端口：孤立端口只能够与混杂端口交互，来自孤立端口的网络传输只会转发给混杂端口，也就是，分配给某个隔离VLAN的端口属于隔离端口。

主VLAN根据依据网络传输的相互关联，分别将来自混杂端口的流量转发给群体端口或隔离端口。从端口则会被分配给隔离端口或群体端口，也就是：从VLAN既可以是隔离VLAN，也可能是群体VLAN。当需要隔离虚拟基础设施中的两个VM时，可使用隔离VLAN，如果系统要求能够支持直接VM到VM机器通信或者系统使用了服务器集群时，群体VLAN将在此时承担非常重要的角色。

图8-1中，端口Eth3/3属于混杂端口，是主VLAN80的一部分，Eth3/3连接到一个默认网关上（为了简化，未在图中显示），端口vEth1和vEth2属于群体端口，同属于群体VLAN81，VM1和VM2之间可以直接交互，也可以访问默认网关。端口

Eth4和Eth4都是隔离VLAN82的隔离端口，此时，VM3只能连接默认网关，VM4也一样。

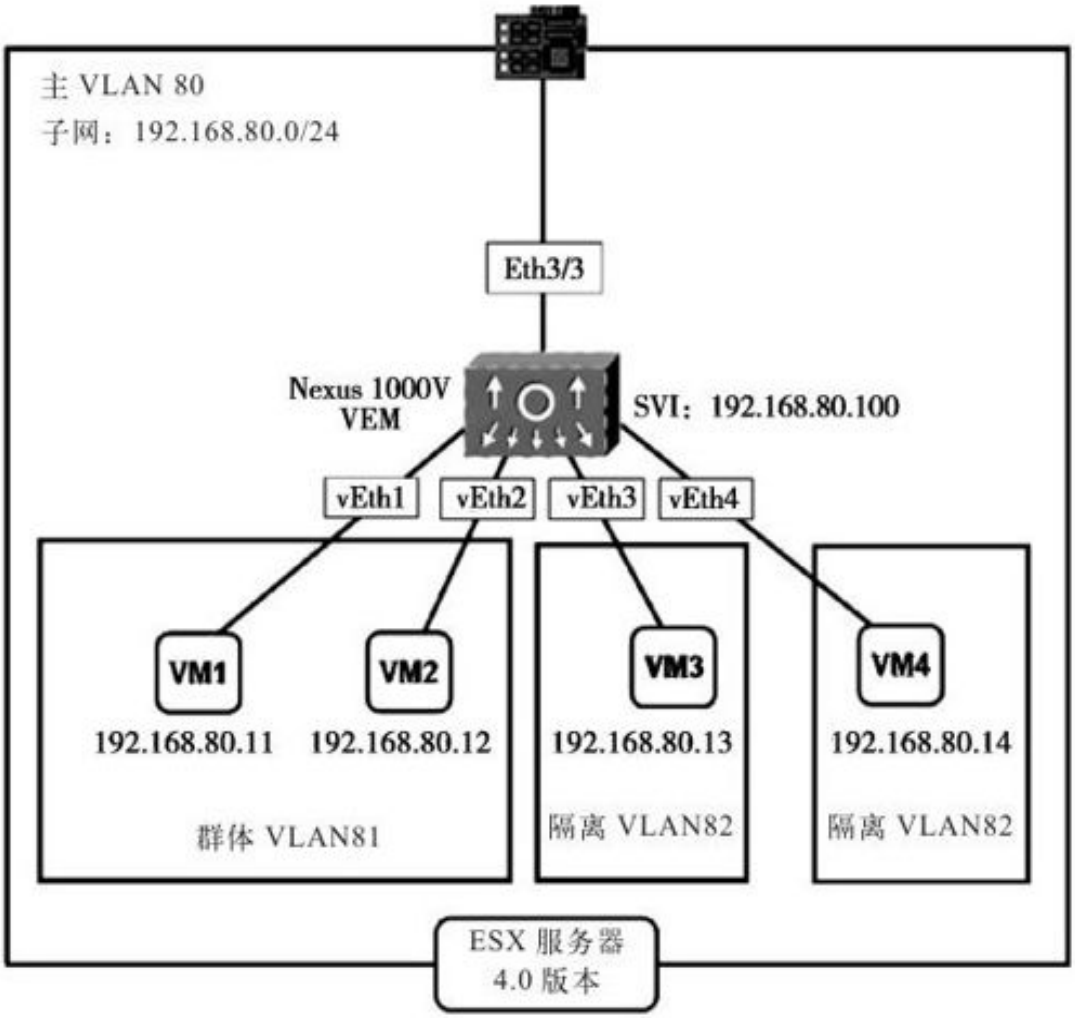


图　8-1　使用PVLAN实现VM隔离

访问控制列表

同一子网内分属于不同的云IaaS租户或终端用户的VM之间是不允许进行直接通信的。由于VM内部传输可以不用离开物理服务器，如果在相应虚拟交换机端口实现IP ACL，能够从L3提供另外一种对网络传输分段的方法。

如前所述，属于隔离VLAN的端口不能与其他隔离VLAN的端口直接通信，类似地，不同群体VLAN间的端口也不能与其他端口直接通信。为了完成互通，系统需要采用L3的方法，除了通过路由或其他L3设备，还必须使用ACL应用来判断是允许还是拒绝这些VLAN之间的通信。

如果需要控制不同子网之间VLAN通信，ACL将是合适的方法，ACL还能够保证产网络和管理网络（或VLAN）之间的相互隔离。

说明：NX1KV交换机通常会在I/O模块（VEM）部分完成对IP包的ACL处理，管理接口网络传输通常会在supervisor模块（Supervisor Module,VSM）上完成，这类操作通常耗时更长一些。

DHCP探测

DHCP探测能够伪造DHCP服务器攻击网络，它就像不可信主机和DHCP服务器间构筑起的一道逻辑防火墙，交换机负责建立和维护DCHCP绑定的数据库（例如，DHCP探测表），在数据库中保留了DHCP地址分配给端口的记录，它也能够从不可信端口中过滤出DHCP信息，如果来自不可信端口入站连接数据包源MAC地址与DHCP绑定数据库中任何一个MAC地址都不能成功匹配，这个包就将被丢弃。

IP源保护

在IP源绑定表中保存了与IP地址相对应的MAC地址和VLAN编号，IP源保护以DHCP探测绑定数据库或静态配置的IP源绑定信息为依据，对来自不可信L2端口的IP网络包进行过滤。对不可信L2端口同时使用IP源保护及DHCP探测技术，能够防止某个主机企图伪装成其他的IP地址发动IP欺骗式攻击。任何进入不可信L2端口的IP数据包，如果其源IP地址不是通过DHCP或静态配置得到的，都将被过滤掉。只有L2端口，包括接入和trunk端口，才能支持IP源保护功能。

动态ARP探测

一个恶意用户会广播伪造的ARP应答，在LAN分区上拦截发送给其他主机的数据包，并且破坏相连主机系统的ARP缓存。为了阻止这类攻击，L2交换机必须确保只对合法的ARP请求和应答进行转发。

交换机的DAI功能能够验证网络中ARP包的合法性。在将包转发到指定目的地之前，DAI会借助某个可信数据库（DHCP探测绑定数据库），验证IP到MAC地址的匹配合法性，对包的ARP合法性进行检查。DAI会删掉所有IP到MAC匹配不成功的

ARP包，但DAI只对入站数据包进行检测，不会管理出站数据包。

非DHCP环境中无法获得DHCP探测绑定数据库信息，DAI能够通过用户自定义的ARP ACL来验证ARP包的合法性，此时，在用户自定义的ARP ACL中保存了主机静态配置所得IP地址与其MAC地址之间的映射关系。一般推荐开启交换机的DAI功能，因为它能够防止网络遭受许多常见的中间人（Man-In-The-Middle,MITM）攻击。

端口镜像

借助服务器虚拟化技术，在同一物理服务器上不同VM之间的网络传输不再需要穿过物理接入层的交换机就能完成，由于虚拟接入层缺乏网络流量可视性，管理者如果不通过相应物理安全设备进行数据包转发操作，很难判断该VM是否已经被影响或者受到了攻击。

交换机端口分析器（Switched Port Analyzer,SPAN）以及封装远程SPAN（Encapsulated Remote SPAN,ERSPAN）是非常好的网络监控工具，能够得到虚拟接入层的网络流量信息。本地SPAN的源接口和目标接口都在同一设备上，网络分析器直接附加到SPAN目标端口上，SPAN源可以是某个端口，也可以是一个VLAN接口。SPAN目标，通常是某个端口，也可以是一个VLAN。本地SPAN能够监控源接口收到的所有网络流量，包括BPDU。

本地SPAN不能通过IP网络转发数据包，但ERSPAN能实现这一点。ERSPAN可以监控经过IP网络的多个网络设备上的流量，也可以通过GRE隧道将网络数据包转发到目标分析器上。换而言之，ERSPAN能够远程监控网络传输，ERSPAN源可以是端口也可以是VLAN。

NX1KV交换机能够激活ERSPAN功能，来自VM的网络流量可以被转发给外部设备，例如入侵防护系统（Intrusion Protection System,IPS）设备和网络分析模块（Network Analysis Module,NAM）。

说明：ERSPAN使用单独的源及目标会话，源及目标会话配置在不同的交换机上，ERSPAN源会话拷贝来自源端口或源

VLAN的会话信息，然后通过可路由的GRE封装包转发到ERSPAN目标会话，ERSPAN目标会话然后将包转发给目标。

图8-2中，NX1KV交换机的ERSPAN源会话将VM4（ERSPAN端口ID为104）的网络传输报文复制一份，然后转发给IPS设备，来自VM1（ERSPAN端口ID为101）的网络传输报文将被ERSPAN目标会话复制然后转发给NAM。ERSPAN目标会话的配置是在服务汇聚层交换机（为了简便，未在图中显示）完成的。ERSPAN目标会话一旦收到来自ERSPAN源会话的网络传输报文，将立刻将其转发至相应的接收目标端口。在本例中，源及目标分别为IPS设备和NAM。

在进行帧封装操作时，可以将ERSPAN端口ID（1-1023）信息附加到ERSPAN包头中，以便在目标端口能够区分不同ERSPAN网络数据流（在本例中，ERSPAN101代表NAM，而ERSPAN104代表IPS）。为每一个会话提供单独的ERSPAN ID，能够区分多个汇聚后的ERSPAN会话，如果这些会话指向的目标设备驻留在某个集中地点，例如，服务汇聚层的服务器机箱（Cat6K交换机），这样的区分方式就非常实用。有关更多ERSPAN配置的详细信息，请参见9.2.2节的相关内容。

说明：Cisco NX1KV NAM拥有一个驻留在Nexus 1010虚拟服务设备上的虚拟刀片（Virtual Service Blade,VSB），这意味着，源自NX1KV交换机的ERSPAN及NetFlow能够被定向到虚拟接入网络的NAM SAB，而不是定向到服务汇聚层的物理NAM上。

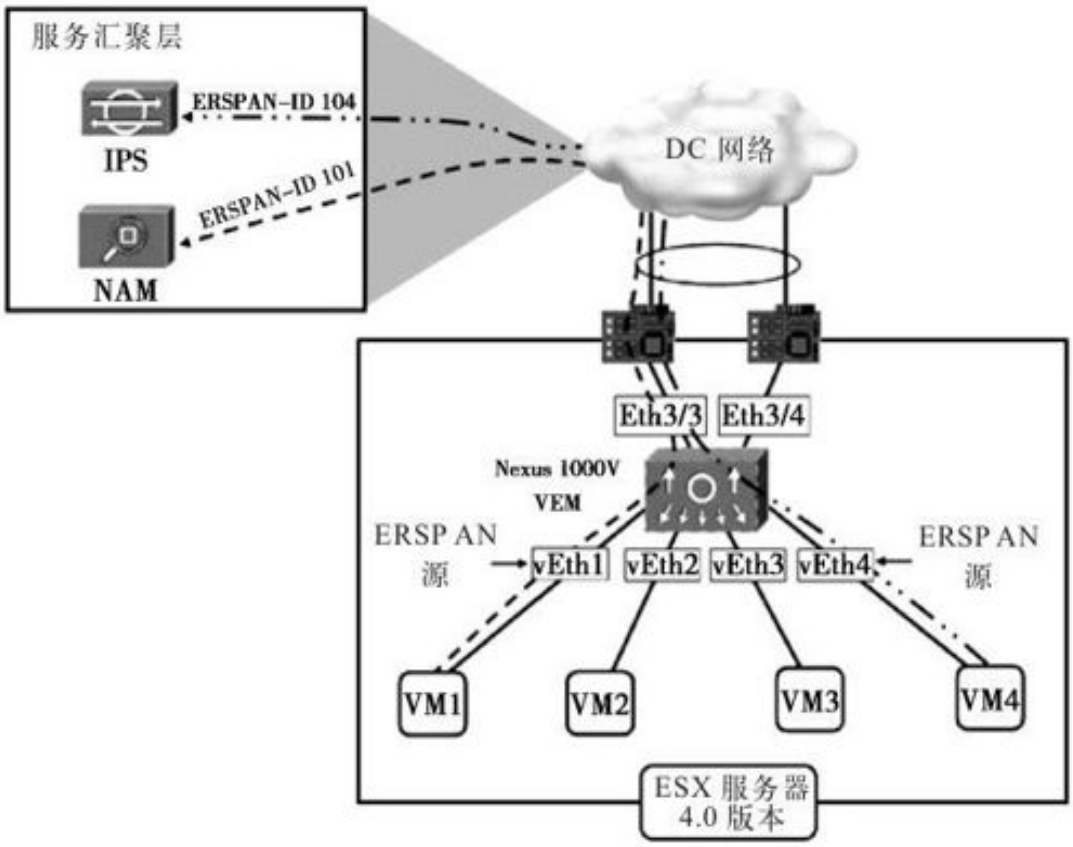


图　8-2　ERSPAN获得的可视性

NetFlow

网络监控、统计分析以及网络规划时，通常会采用NetFlow进行数据采集，NX1KV在虚拟接入层支持NetFlow，能够获取所主流VM的网络流量的相关信息，有利于对这些VM进行安全监控和统计分析。

一个flow是面向特定源接口（子接口）的单向序列包，这些包都必须符合某些匹配规则，拥有相同源/目标IP、源/目标端口、协议接口以及服务类型的包被聚集在同一个流中，并给包打上标记，大量网络信息浓缩在一起形成了NetFlow缓存数据库。

Flow记录记载了NetFlow收集到的信息内容，类似flow中的包，以及flow的统计信息，即可以使用新生成的flow记录也可以利用预先配置好的flow记录。NX1KV交换机支持NetFlow版本9（Version 9）以及下列这些预先配置的flow记录：

·NetFlow-Original：预定义的传统IPv4输入NetFlow，附带原始的AS序号

·NetFlow IPv4 Original-Input：预定义的传统IPv4输入NetFlow

·NetFlow IPv4 Original-Output：预定义的传统IPv4输入NetFlow

·NetFlow IPv4 Protocol-Port：预定义协议及端口汇聚规则

说明：为什么选择NetFlow V9？之所以优先考虑V9，是因为V5数据格式必须是定长，在NX-OS中使用16位表示32位接口索引，也不支持IPv6、L2以及MPLS域。

说明：本书撰写之际，NX1KV交换机已经不支持NetFlow Exporter V5的格式，虽然能够支持NetFlow Exporter V9的格式，但是不支持L2、IPv6域。

Flow的导出器定义了何时何地将NetFlow缓存中的flow记录送给消息服务器，也称为NetFlow收集器，导出器定义包括以下内容：

·目的IP地址

·源接口

·UPD端口序号（采集器监听端口）

·输出格式

需要为flow导出器创建一个与flow记录关联的Flow监视器，监视器会被应用到特定方向指定接口的网络监测。

说明：NX-OS支持两种NetFlow工作模式：全模式分析接口收到的所有数据包，抽样模式依据用户指定的抽样算法和抽样速率，对配置了NetFlow的接口数据包进行分析。本书写作时，NX1KV交换机还不支持NetFlow Sampler功能。

NetFlow收集器对输出流进行汇总，生成消息报文，供网络传输和安全监测分析使用。NetFlow导出器定期向NetFlow收集器发送信息，flow总是不断地被送入NetFlow缓存中，然后由定时器决定何时该输出到NetFlow收集服务器上。当满足下列条件之一，flow就将被输出：

·flow在某个指定时间段一直处于没有新包到达的非活动状态。

·flow的生存期超过了当前定时器长度，例如，大FTP下载。

·TCP标识（例如，连接完成FIN或被重置RST）标明该flow已经被终止。

·flow缓存满，为了给新到达flow提供空间，某些flow必须被删除。

说明：NX1KV交换机的活动定时器缺省设置为1800秒（允许范围为60～4092秒），非活动时间缺省为15秒（允许范围为15～4092秒）。

NX1KV交换机的报告中包含了很多细节信息，例如，驻留在NX1KV交换机上的虚拟以太网接口上每秒包的个数。流监测器能对来自与交换机相连的物理接口上的流进行监测，也能够监测VMkernel接口（vmknics）的流，例如VMotion网络传输。

将NetFlow传输转发给收集器时可以采用两种部署方式：带内部署和带外部署。带内部署模式中，收集器位于生产网络，NetFlow流将通过交换机的生产接口进行转发；带外部署模式中，收集器位于某个指定带外管理网络，NetFlow流将通过交换机的管理接口进行转发。

8.1.2 端点安全

回顾“端口镜像”小节内容，通过配置虚拟交换机的ERSPAN可以将来自VM的数据包转发至网络的IPS设备上，也可以通过基于主机的IPS完成这一功能。基于主机的IPS是保护端点免遭漏洞攻击和防范恶意软件的最有效方法之一，它能应对大多数已知攻击方法，在预防零日漏洞（zero-day）攻击方面也非常有效。

说明：术语“零日”指安全漏洞曝光的那一天，开发人员发现软件的安全漏洞后，还来得及在黑客发现该漏洞或者某个志愿者将漏洞公之于众之前修复漏洞，而“零日攻击”则早于或刚刚好就在漏洞发现的第一天，意味着开发人员没有任何机会向软件用户发布漏洞修复补丁。

基于主机的IPS将对攻击行为进行检查以防范新的攻击，无需安装IPS攻击签名就能够完成这项检查。大多数与网络IPS进行互联的DMZ和服务器集群环境中一般会使用基于主机的IPS技术，基于网络IPS和基于主机IPS的详细内容则超过了本书的讨论范围。

8.1.3 虚拟VMZ

简单来说，一个虚拟DMZ解决方案要求使用以下技术：

·带有防火墙的物理访问分段，以保持数据包状态监测，包括有效传输及无效传输（更多细节请参考3.1节）。

·端口配置文件实施责任划分（在服务器及网络管理者之间）以及协议增强（更多细节请参考第2章“该轮到谁了，服务器还是网络管理员”一节）。

·认证、授权和统计（例如AAA）模型，来确定访问权限并维护详细的日志。

·VLAN和PVLAN，以实现VM和应用之间的隔离（更多细节请参考“VLAN和PVLAN”一节）。

·ACL，以限制DMZ VM、生产网络和管理网络之间的连接（更多细节请参考“访问控制列表”一节）。

·ERSPAN和NetFlow，以增加虚拟DMZ环境可视化的可操作性（更多细节请参考端口镜像以及NetFlow的相关章节内容）。

·速率限制，以减小由那些已经遭受了攻击的VM或其他任意主机发起的拒绝服务式（DoS）等恶意攻击的影响。

此外，需要铭记于心的一些常用经验包括：

·保持物理非虚拟化环境的安全（例如，入侵检测和防范，使用防火墙来阻止无关访问，进行DoS预防等）。

·对虚拟和物理网络互连活动进行详尽的记录。

·强化明确定义了的变更管理控制。

·强化对角色和权限间清晰度的分离。

·强化持续审计（登录和审计）和持续监测。

8.2 统一计算系统

现有服务器部署模式通常分成两类：scale-up（纵向扩展）模式以增加更多的处理器、内存、I/O设备等资源对单个服务器的计算能力进行扩充；scale-out模式（横向扩展）模式则以增加服务器个数为基础。大多数企业DC更倾向于后者，因为它可以使用标准的计算组件，而这种更受欢迎的scale-out模式也催生了另外一种DC现象——服务蔓延。

服务器虚拟化对减少服务蔓延起着关键作用，被全球性机构广泛采用。通过虚拟化，一个物理服务器可以同时包含多个虚拟服务器，虚拟化软件更可以配备与物理交换机等同的虚拟接入层交换机（例如，NX1KV交换机）。该选择scale-up还是scale-out呢？或者同时选择两种模式，或者更好的，逆向思维转换？其实，我们更应该关注如何解决当前部署中遇到的局限而非辩论哪种模式更好，本章将以Cisco统一计算系统（Unified Computing System,UCS）作为样例平台进行深入探讨。

随着私有云计算应用越来越广泛，能够迅速转换职能的“匿名”服务器也快速成为企业用户的常见需求，这些新服务器必须能够支持大量的VM，能够灵活处理VM在不同服务器之间的转移，具备由协议驱动的管理系统，并能够向云软件提供丰富的接口API。

由于需要支持多租户，而每个租户又拥有自己的VM，所以物理服务器的RAM很可能在CPU资源枯竭之前就不够用了，因而许多企业DC在考虑云IaaS服务时一个关键需求是能够向服务器增加足够多的RAM。为此，UCS刀片服务器，使用了下一代CPU，内存扩展技术以及I/O技术，能够支持最多可扩展至384GB的大容量RAM。

为了简化服务器在DC间移动的配置工作，UCS没有把各类组件的标识信息（MAC地址、UUID等）固化到硬件中，而是放在配置文件里面，这也意味着：在某个DR站点重新建立一个相同的UCS，就和拷贝一个配置文件一样简单。

通常都是产品开发生命周期后期才加上管理工具，因此它们与整个受控单元并不是紧密集成在一起。UCS拥有一个嵌入管理处理器，能够对所有组成UCS的管理单元（元素）进行全局化管理，从而强化了控制，也提供了集成的管理和分析。

此外，UCS是按照ToR模式（更多细节请参考第2章的“支架拓扑”内容）设计的，所有属于UCS的服务器都连接到两个fabri上，被安放在某个或少数机架的顶端，服务器之间的通信按照统一架构（集中网络）方式（更多细节请参考第2章的“数据中心互连阵列”的相关内容），这种方法能够显著减少布线信道。

总而言之，UCS能够很好地克服当前企业DC中服务器部署局限，可以为私有云计算以及云IaaS服务提供理想的计算平台。

说明：本章探讨了UCS对私有云计算的可用性，这一节仅为临时性探讨，并不属于权威性引导，建议读者在进行与UCS相关的产品评估、方案设计或商务咨询时参阅合适的官方文档，本书作者对内容正确性概不负责，对任何错误或歧义也不承担法律责任。

8.2.1 UCS使能技术

UCS为一个系统而不仅仅只是一个服务器机架，UCS在DC中的汇聚端点在网络层，换句话说，也就是，UCS以网络作为关键平台，UCS的部分使能技术包括：

·FCoE（更多细节请参考2.6节）

·虚拟NIC标签（Virtual NIC Tag,VNTag）

·内存扩展

·统一管理

这些使能技术有效地去掉多余的交换机、适配器、电缆以及管理模块，为私有云计算环境带来了一个更好的流线型服务器部署方式。

VNTag

VNTag是一个6字节的以太网标签，添加在以太网帧的目的及源MAC地址对（MAC-DA和MAC-SA）之后。传统的以太网交换机不支持对源及目标MAC地址都在同一端口的帧的转发，所以也不支持对位于同一交换机端口的两个VM之间的帧的转发，VNTag为交换机上的每个VM创建了一个虚拟以太网（Virtual Ethernet,VEth）接口，解决了这个问题。

说明：IEEE MACsec（认证和封装）标签可以放在VNTag标签前面。

换句话说，VNTag将每个vEth接口与一个vNIC绑定，逆向操作也是一样。具备“VNTag感知”能力的交换机能够完成不同vEth接口的转发，实现位于同一物理端口上的VM之间的帧转发。系统通过VNTag标签中的目标虚拟接口标识（dst_vif，14位）和源虚拟接口标识（src_vif，12位）对这些VM进行区分。可以在带有VNTag标签功能的NIC或hypervisor的内置软件实现VNTag标签，也可以作为单独的盒子，当做光纤扩展器实现，承担面向以太网交换机的远程多路转换器责任。图8-3展示了两个连接到以太网交换机的光纤扩展器的样例，每一个光纤扩展器都拥有4×10GE上行以太网交换机以及48×1GE的连接服务器的下行端口，从光纤扩展器到以太网交换机的上行链路使用VNTag标签头部，48个下行1GE端口分别分配了一个虚拟接口（Virtual Interface,vif）标识。

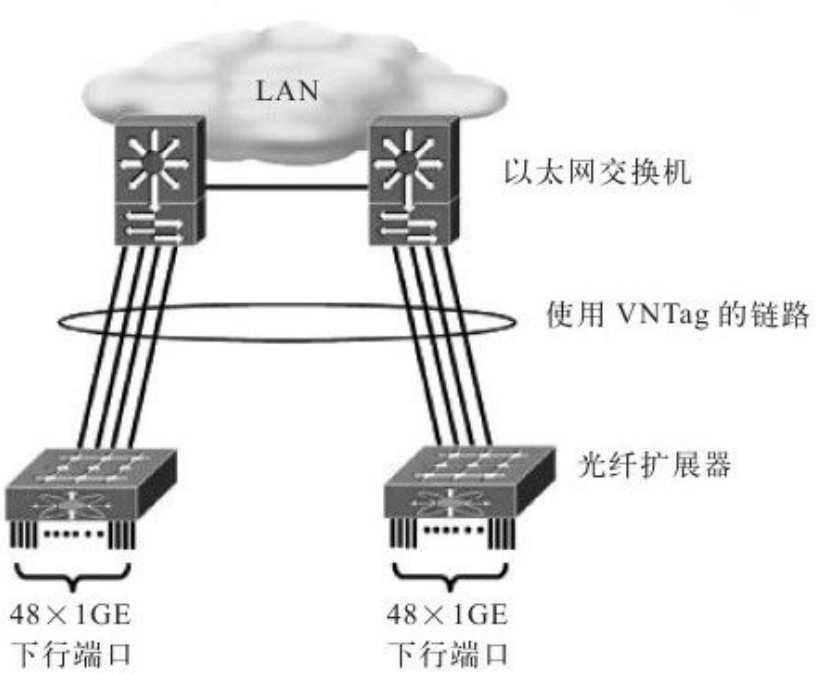


图　8-3　光纤扩展器

说明：Palo由Cisco开发的CNA，支持VNTag标签。

内存扩展

虚拟软件要求能够支持多个OS实例同时运行，因此需要占用大量内存空间，为了得到更大的内存容量，大多数IT机构都

不得不选择扩充到拥有4个socket的四路服务器，这样的服务器通常不但造价昂贵，能源消耗和监测成本都相应更高。

Cisco扩展内存技术选用标准的双倍速率同步动态随机存储器3（double-data-rate three,DDR3）型内存，通过逻辑上改变主存结构，实现CPU中的内存控制器能力扩展。采用这一技术后，能够将扩展内存刀片服务器上的每4个双列直插式存储模块（Dual In-line Memory Module,DIMM）映射为在CPU内存控制器眼中的单一逻辑DIMM，且存储能力是之前单个DIMM的4倍。例如，使用扩展内存技术后，原来4个标准的8G容量的DDR 3 DIMM，将变成一个单独的32GB DIMM。这种独特的内存扩展技术支持在2端口服务器上也能实现内存增量扩充，而不是一下子就必须叉车式升级到4路服务器。

对于需要大量内存的虚拟环境而言，选用更小容量的DIMM来代替8GB的DIMM，尽管不一定达到384GB容量，仍然可以节省很多成本，至少8个1GB的DIMM肯定要比1个8GB的DIMM要便宜。

统一管理

UCS管理器（UCS Manager,UCSM）属于嵌入式设备管理软件，通过直观的图形用户界面（GUI）、命令行界面（CLI）或基于XML的应用编程接口（XML API），以单一逻辑实体对UCS系统进行管理，它创建了一个统一的管理域，具备集中管理能力，使用服务配置文件和模板实现了基于策略和基于角色的管理。

可以将UCS的资源当成抽象资源，因为资源标识、I/O配置、MAC地址、WWN、固件版本号、BIOS启动顺序、网络属性（包括QoS配置、ACL、pin组、阈值策略）等信息都可以通过实时部署模型编程得到，UCSM将标识、连接信息、配置信息都放在服务配置文件中，可以在服务配置文件中根据特定软件堆栈需要提取资源属性信息。借助配置文件，可以实现管理域内从服务器到网络的移动，使得系统资源的使用变得非常灵活。可以在服务配置文件模板中对资源进行分级定义，并根据预定义池的内容给它们分配相应的资源标识。

说明：UCSM驻留在fabirc阵列（相关内容请参见8.2.2节）上，属于NX-OS模块（插件型），由运行在光纤阵列上的NX-

OS对它进行管理、监测以及控制。

此外，UCSM支持多租户环境，对内部客户端、终端用户处理也与单独商务实体相同。可以将系统逻辑划分后分配到不同的客户端或用户及管理者，看起来就像为这些用户建立了一个专属环境一样。

8.2.2 UCS组件

没有对硬件的整体控制，就希望制定一个类似UCS的解决方案是非常困难的事，要想更好地理解这类方案，就有必要简单探讨一下UCS的组件。Cisco试图开放UCS软件及管理，这也是当前大多数DC的主要需求，UCS包含了以下组件：

·UCS管理器

·光纤互联阵列

·刀片服务器机箱

·光纤扩展器

·I/O适配器

·刀片服务器

图8-4展示了一个常见的UCS拓扑。

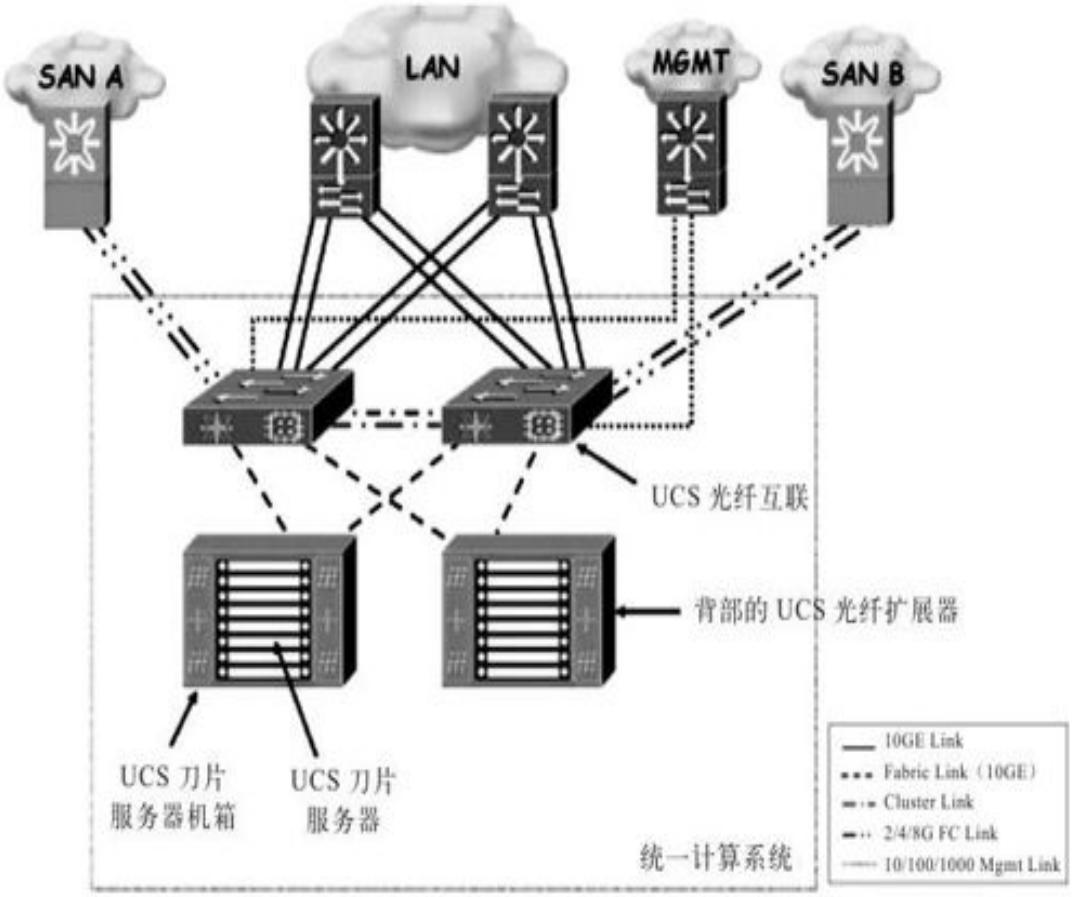


图　8-4　简化了的UCS拓扑

光纤互联阵列

UCS 6100 系列互联阵列使用“一次连接”将10GE/FcoE/SPF+端口（更多细节请参考第2章的“线缆注意事项”相关内容）及2/4/8G FC上行链路（通过一个扩展模块）组织成统一网络光纤作为连接服务器资源的汇聚端点。光纤互联阵列以主-主冗余配对方式部署，提供对存储阵列和其他网络资源的统一访问。

UCS 6100系列互联阵列以Nexus 5000生产线为基础，增加嵌入式UCS管理器实现了对UCS机箱的管理。光纤互联阵列能够支持vPC、MAC pinning等以太网连接（更多内容请参考2.5.3节的相关内容）。

说明：UCS 6120XP光纤互联阵列（1RU）拥有20个10GE/FCoE/SFP+端口，而

UCS 6140XP 光纤互联阵列（2RU）拥有40个10GE/FCoE/SFP+端口。

刀片服务器机箱

UCS 5108刀片服务器机箱（属于UCS 5100系列），高度为6个机架单元（Rack Unit,RU），机箱前端是8个半宽刀片服务器以及4个电源接口，能够支持半宽和全宽服务器刀片，机箱后端是8个热插拔风扇、2个光纤扩展器以及电源接入模块。

将每一对半宽刀片中间的金属隔板拿开，就可以将其变成全宽刀片，以下是刀片服务器组合都能达到8个半宽刀片服务器效果：

·8个半宽服务器刀片

·6个半宽服务器刀片以及1个全宽服务器刀片

·4个半宽服务器刀片以及2个全宽服务器刀片

·2个半宽服务器刀片以及3个全宽服务器刀片

·4个全宽服务器刀片

说明：本书撰写之际，市场上只有UCS 5108一种UCS刀片服务器机箱产品。

光纤扩展器

UCS 2100系列光纤扩展器（Fabric Extender,FEX）将统一阵列（unified fabric）引入到刀片服务器机箱中，在刀片服务器

和光纤互联阵列之间提供10GE以太网连接，从而简化了系统诊断、布线以及管理工作。

换句话说，UCS 2100系列光纤FEX扩展了UCS 6100系列光纤互联阵列以及UCS 5100系列刀片服务器机箱之间的I/O阵列，实现了FCoE光纤与所有刀片及机箱之间的无损耗、确定的连接。由于FEX与分布式线卡类似，不能进行任何交换操作，只能作为光纤互联阵列的扩展加以管理，因此使用FEX后，机箱也不再提供交换功能，从而降低了基础设施的整体复杂性，也可以将UCS扩展到多个机箱而不需要配备相应的交换机，所有的机箱能够以单一的管理域方式进行管理。UCS 2100系列FEX还能与互联阵列相结合，共同管理机箱环境（例如，电源供应、风扇、刀片等），因而也不需要单独的机箱管理模块。

UCS 2104XP FEX拥有8个下行端口，通过中间面板连接到机箱中的每个半宽插槽，它拥有4个10GE/FCoE/SFP+端口，用于将刀片机箱连接到互联阵列。从FEX到光纤互联阵列的上行链路使用了VNTag头，如果适配器支持VNTag标签，也可以在适配器和下行端口的FEX之间使用VNTag。就像在光纤互联阵列中一样，FEX通常都以成对方式进行部署以实现冗余。

说明：本书撰写之际，市场上只有一种UCS FEX产品：UCS 2104XP。

夹层I/O适配器（更多细节请参考“I/O适配器”一节）驻留在服务器刀片上，默认位于上行通道。图8-5展示了根据可得的上行链路数目预先固定好的服务器刀片插槽，在本书撰写之际，用户还无权设置这些属性。

从 FEX 到光纤互联的端口数	
上行链路	用于上行链路的槽
1	1，2，3，4，5，6，7，8
从 FEX 到光纤互联的端口数	
上行链路	用于上行链路的槽
1	1，3，5，7
2	2，4，6，8
从 FEX 到光纤互联的端口数	
上行链路	用于上行链路的槽
1	1，5
2	2，6
3	3，7
4	4，8

图　8-5　上行通道预连接

I/O适配器

UCS I/O适配器其实就是CNA（更多细节请参考2.6.4节的相关内容），CNA能够减少LAN与SAN连接时所需的适配器、线缆以及接入层交换机，从而降低了成本及操作开销、能源消耗以及管理负载。UCS刀片服务器使用的CNA属于mezzanine尺寸，基于10GBASE-KR标准，推荐参阅合适的UCS产品手册以获取所支持的各类I/O适配器信息。

说明：10GBASE-KR是应用于刀片服务器这一类背板应用中的背板以太网标准。

刀片服务器

UCS双槽刀片服务器包括：

·UCS B200双槽刀片服务器：UCS B200是一款半宽刀片服务器，拥有12个DIMM插槽，可支持高达96GB的内存，支持一个mezzanine适配器。

·UCS B250双槽扩展内存刀片服务器：UCS B250是一款全宽刀片服务器，拥有48个DIMM插槽，可支持高达384GB的内存，支持多达两个mezzanine适配器。

说明：双槽UCS刀片使用Nehalem-EP和Westmere-EP处理器。

说明：还有UCS B440四槽刀片服务器以及UCS C系列机架服务器，UCS C系列机架服务器既可以作为独立的标准服务器使用，也可以以混合方式配制与UCS内服务器互联（同时作为刀片和机架服务器）。

8.3 云管理

和云安全一样，云的管理听起来也很像新生事物，其实不然，现有网络管理策略和技术在云IaaS中仍然适用。其他内容，依然与服务器虚拟化相关，简而言之，本节的讨论将局限在与云IaaS服务相关的网络管理方面，讨论也将从常用方法出发。

从工作流角度出发，为了满足以指数速度增长的网络管理需求，必须采用超越基本manager-agent拓扑模式的分布式网络管理。大规模云IaaS部署中，应该考虑诸如分级管理模型、基于策略的管理、管理调节、自动化、用户自服务门户以及XML标准化等服务的质量。

8.3.1 分级管理

分级管理采用分级信息采集模式，使采集到的信息压缩比、集中程度以及抽象级别都更高。分级管理也是实现扩展的核心功能，当链路位于网络运行中心（Network Operations Center,NOC）之间，或者远程终端由低带宽信道组成时，如果能正确部署管理分级，可以将中心NOC的管理功能剥离，分配给更靠近待管理设备的企业分支站点上。

图8-6展示了一个经过简化的分级管理模型，其中部分下属管理（子管理）系统能够替

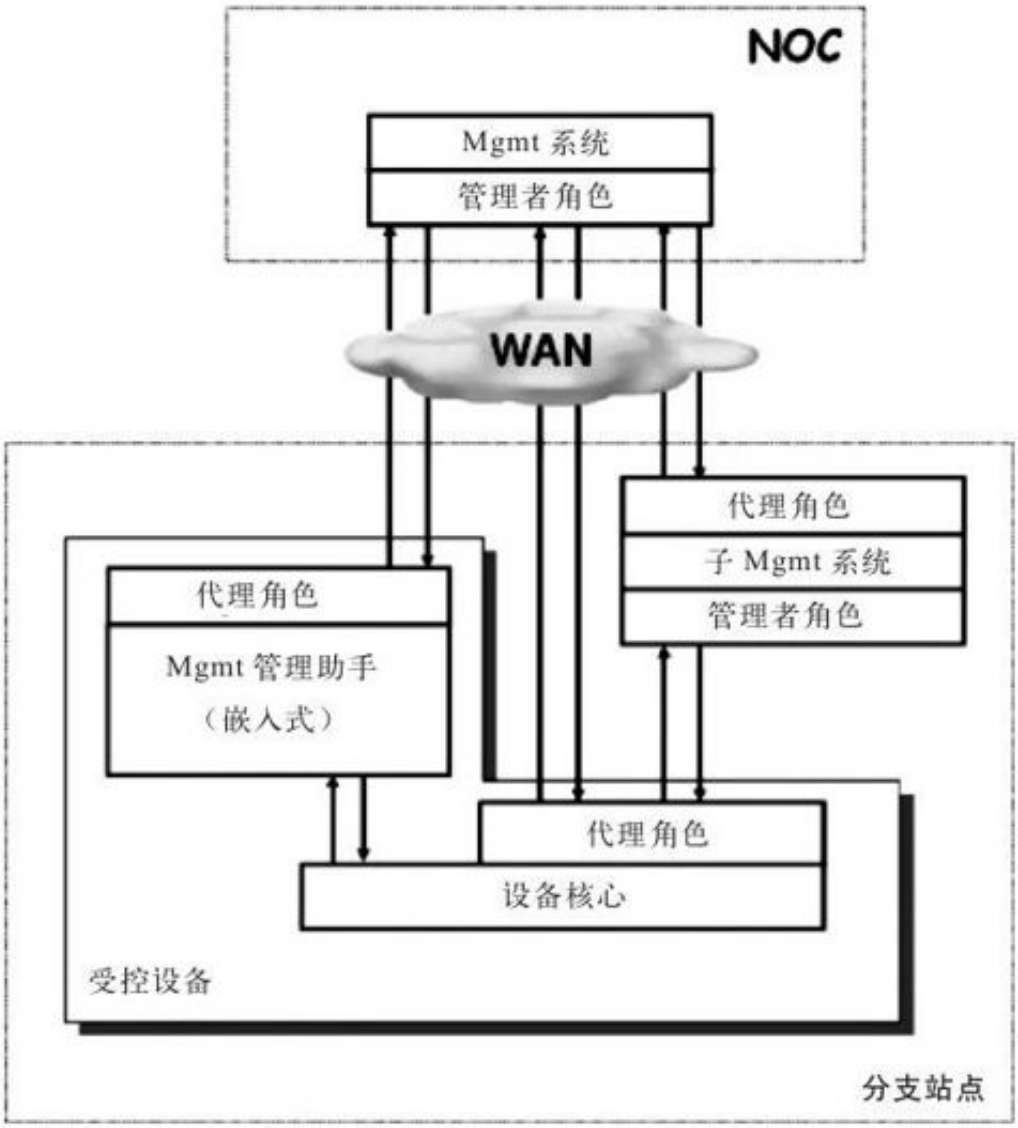


图　8-6　简化的分级管理模型

中心管理系统分担一些管理任务，在某种程度上，可以将子管理系统看成网络中能够管理单个网络组件（受控设备）的管理单元，负责查看和修改网络元素的配置、监测网络元素的预警信息、维护软/硬件等。某些类型的“管理助手”能够嵌入到设备中，通常将设备的这种额外管理功能称为嵌入式管理智能或称为自动系统。UCSM（更多细节请参考“统一管理”内容）是一个很好的嵌入式设备管理软件样例，嵌入式子管理系统或管理助手的主要功能是为受控设备提供额外的管理功能，而不需要再利用其他的外部管理应用来完成。

说明：单元管理源自电信管理网（Telecommunication Management Network,TMN）模型，TMN的管理层从低到高依

次分为：网元层、网元管理层、网络管理层、业务管理层和事务管理层。

8.3.2 基于策略的管理

有很多方法可以完成管理任务，而对于云IaaS服务来说，基于策略的管理则是最合适的方法之一。什么是基于策略的管理呢？初学者可以将它理解为一个管理系统，它为每一个下属管理（子管理）系统分别确立了不同的目标，然后子管理系统又将这些目标相应转换分解成更低一级的活动，确保目标能够完成。此时，更上一级的管理系统将只需要关注如何设置全局策略上，而子系统会将策略转换成相应行动。基于策略的网络管理技术主要面向分布式管理任务，能够尽可能地近地靠近管理网络的边缘。

图8-7给出了一个简化的基于策略的管理模型，基本组件包括：

·策略执行点（Policy Enforcement Point,PEP）：负责实际执行策略，即定义一组符合策略的条件，依据策略执行相应的活动。

·策略决策点（Policy Decision Point,PDP）：当PEP截获某个策略触发器后，由PDP决定该执行何种策略，PDP根据PEP报告的条件，从策略库中提取相关策略，将它翻译成一组执行动作，返回给PEP，然后由PEP负责执行。PDP通常与PEP驻留在同一系统内，也可以是一个外部（单独）控制器。

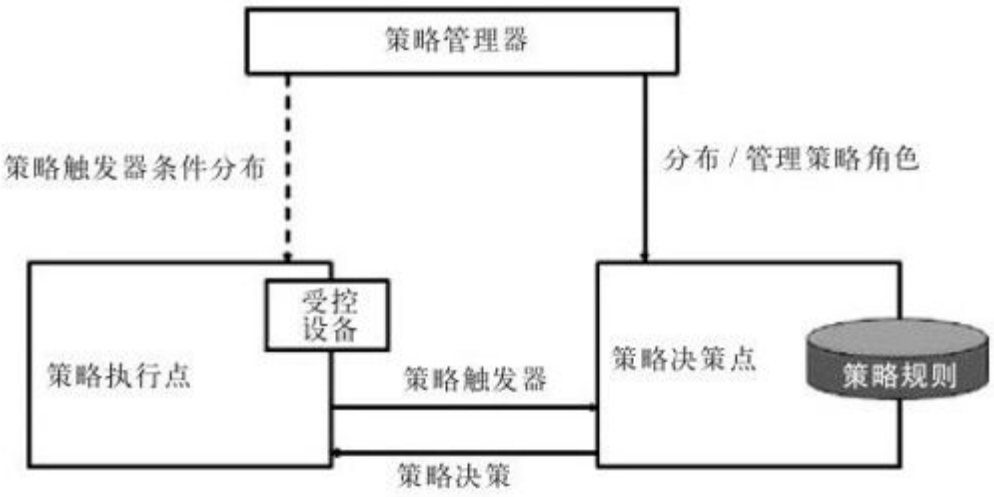


图　8-7　简化的基于策略管理模型

·策略管理工具：策略管理工具负责策略的定义和管理，建立好的策略必须要分布到各个PDP上，而能够触发某个策略规则的条件必须要分配到各个PEP上，使得PEP能够感知分析出符合预定义策略的事件和行为类型。

8.3.3 管理调整

随着各类管理接口和协议的激增，管理调整成为一种必然。调整带来了管理分级的各种变化，因此从属管理系统（中间层）必须通过网关函数来进一步保证策略执行，以弥补顶层管理工具与底层代理之间的差异。

管理调整有一项任务是要将一种协议的管理消息翻译成另外一类协议的管理消息，利用模板可以使这个工作变得非常简单。模板由一组叠加的规则组成，它不是依据消息的语法规则去解释消息，而是为每一种可能产生的消息都定义了相应的规则，也就是模板方法以模式匹配和文本替换为基础。当因响应CLI命令或系统日志消息时而产生管理调整时，比较适合采用模板方法。

如果完成合法翻译前，需要对管理信息进行深度分析，此时，管理调整将变得非常复杂，会牵涉到大量的应用复杂性，对管理调整的讨论超出了本书研究范围。

说明：管理调整的最简单形式是不需要对管理信息句法进行深入分析就能完成翻译工作，另外，有时候也可能需要进行语义调整，如果在转换之前，要求翻译操作有一个对管理信息的深入分析。

8.3.4 自动化

自动化属于云管理的重要部分之一，很大一部分基础DC操作都具备自动化能力，包括：

·变更和配置管理：为了优化应用或服务的可获取性及性能，确保系统配置能与时间变化保持一致，而不会偏离初始状态，必须能够自动探测到任何与预定义基准配置不符的变化，并且能够根据预定义的策略动作自动修复。

·服务模板：服务模板能够简化网络层在向服务器硬件层以及整个软件堆栈提供端到端服务的过程，同时也能提高过程的自动化程度。用户在创建和部署多个应用程序实例时，就不需要再复制通用的配置说明，使得创建和部署变得更轻松。

·随应用负载增长的服务自动化：如果某个应用因为负载过重而需要额外的资源，系统应该能够自动提供资源以改善应用性能。大多数情况下，应用服务是基于策略而非基于特定资源实现的，核心思想是要支持应用服务能够根据利用率/性能进行动态扩展或缩减，同样，当应用不再需要某些资源时，也要及时释放它们以供其他应用使用。·自动服务级管理：借助服务模板，系统能够提前定义服务所需的资源类型，包括处理器速度、内存容量以及其他与性能有关的参数等。

·自动灾难恢复：为了缩短重要应用的故障时间，必须要求自动地故障恢复，如果某个设备不能工作了，另一设备应能自动顶替并承担起故障设备的工作。

8.3.5 用户自助服务

到目前为止，本节已经花了大量篇幅从云IaaS供应商角度来讨论云管理的相关技术，可是对消费者、终端用户和租户而言又该怎样呢？答案就是：用户自助服务。事实上，IaaS供应商和IaaS用户之间的关系与房东和租客之间的关系有些类似，简单一点来说，当房东将房子出租给租客时，租客需要做一些相应的清洁整理工作以确保房东的利益，房东可以应租客的请求，将整栋大楼都出租，也可以只出租某个房间。从租客的角度出发，租用整栋大楼意味着能获得更多的控制权，但同时也要承担更多的家务管理劳动，而如果只租用几间房，家务劳动少了，可是相应的控制范围也减少了。而且，很显然两种租用方式的价格也相差甚远。

假设有个房东同时有整栋大楼和单独的房价要出租，此时，一个终端用户自主租赁系统对感兴趣的租客就能派上用场了，回顾一下云IaaS（更多细节请参照本书第1章中关于“服务模式”的内容），用户对底层云基础设施并没有实际的管理或控制权限，只对OS、应用部署及系统需求有发言权，因此，可以将计算平台设计成终端用户自助租用系统的一部分，让用户不需要直接求助IT客服工程师，就能够选择OS、设置系统需求、挑选应用等，我们可以通过下列操作样例来解释这个过程：

1.选择某个OS；

2.选择应用（单个或多个）；

3.指明系统需求；

4.指明租赁时间。

说明：如果是由应用来决定OS，可以颠倒OS和应用的先后顺序。例如，某些应用可能只能在Windows平台上运行。

就像实际生活中的租用合同只在有限时间内是有效的一样，当达到IaaS租用期限时，被当前用户占用的资源可以重新再分配给其他新用户。租用期间，用户要负责管理运行在计算平台上的应用，而供应商负责包括硬件在内的计算平台基础设施的正常运行。

高级网络组件，像防火墙、负载平衡器等，也可以放在自助租用系统中一起提供给用户，此时，防火墙和负载平衡器通

常属于虚拟设备上下文，只对特定用户（更多细节请参考3.1节的相关内容）开放。

8.3.6 XML-ization

对云中各类型号的设备和软件机器可读接口进行标准化并不容易，而从长远观点来看，大量的用户交互最终将带来隐患，很多时候可扩展标记语言（Extensible Markup Language,XML）已经变成事实上的一个标准编码准则。

XML使用标签来区分XML文档中不同信息片段，XML文档可以非常简单，仅由一组标签组成进行区分，例如，一个完整的配置文件XML也可以非常复杂，假使各种参数和属性都使用用户自己的标准化标签定义。在云环境中，不同厂商所开发的各类管理软件均可识别采用XML格式的管理信息。

8.4 云IaaS：巨幅画卷

私有云计算是一个通用术语，拥有三种不同的服务模式：SaaS、PaaS以及IaaS（更多细节请参考本书第1章中服务模式相关的内容）。实现SaaS或者PaaS通常需要应用或软件开发专家，而另一方面，IaaS是与应用无关的，并且能够提供一个快速且简单的到私有云计算世界的入口点。IaaS属于云服务“超集”，SaaS位于PaaS之上，而后者又位于IaaS之上（更多细节请参考本书第1章的服务模式相关的内容）。

大多数企业基于基础设施的服务都固定在物理基础设施之上，使得任何一种改造都变得非常费力，私有云计算和云IaaS联手后，将焦点从物理基础设施转移到了一个虚拟的基础设施上。虚拟化是当前的热门，整合通常要借助虚拟化才能完成，服务再也不是围机房的硬件条件、物理服务器、端口建立，而是围绕着VM镜像、应用实例、虚拟化存储以及虚拟网络而构成。换而言之，云IaaS使得用户能在企业的基础架构上运行任务，即云IaaS借助一些重构和插件，能够将现有的物理基础设施变成一个面向服务的基础设施（Service-Oriented Infrastructure,SOI），实现对虚拟环境的支持。云IaaS的核心思想是在SOI的顶层以模块化方式构建云IaaS服务，使得系统能够实现自适应调整以支持大量不同类型服务，响应用户需求的变化。SOI也能够支持非云和非虚拟化环境，因此必要时，私有云计算和云IaaS能够与使用相同基础设施的传统的分布式服务并存。利用某些现成设备能够降低整体开销和创建私有云环境的操作成本，同样也能提高对基础设施的利用率，某些时候也简化了DC的运营环境。

我们的讨论到目前为止，已经包括了IaaS这个拼图难题的大部分“碎片”，现在让我们重新回顾并将这些“碎片”汇总在一块，创建一幅完整的画面。回忆一下第1章的内容，我们提到了构建私有云计算的模块包括：

·服务模块

·存储模块

·光纤模块

·WAN模块

为了便于后继小节的讨论，这些模块可以进一步被细化成：

·服务模块：

·应用软件子模块

·虚拟机器子模块

·虚拟接入层子模块

·计算子模块

·存储模块：

·存储阵列子模块

·SAN子模块

·SAN扩展子模块

·光纤模块：

·接入层子模块

·汇聚层子模块

·核心层子模块

·WAN模块：

·对等子模块

·未来的WAN子模块

图8-8展示了构成SOI的不同模块，它们是组成企业中云IaaS服务的底层基础设施的基准。

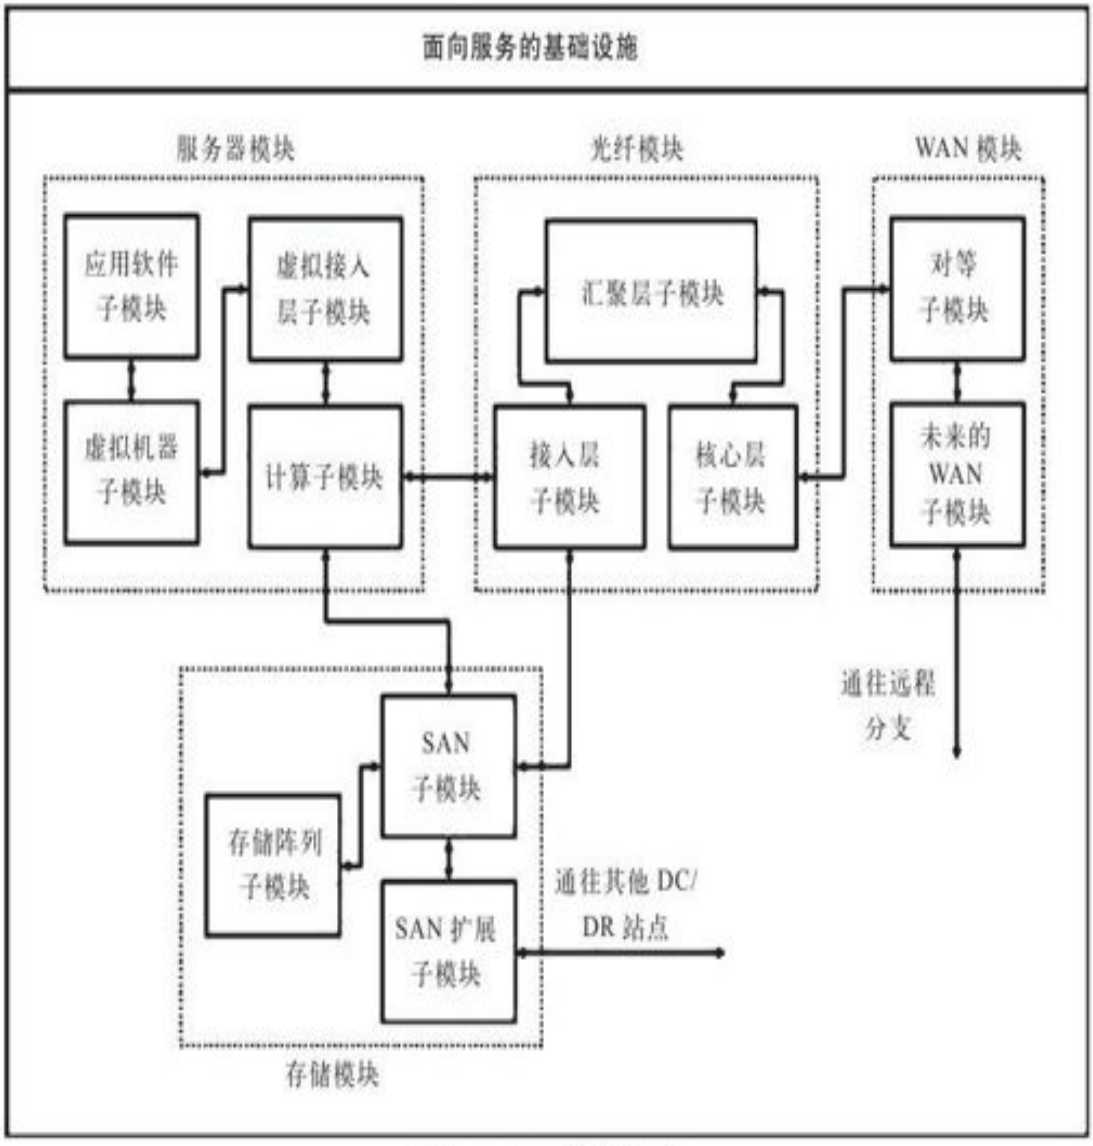


图　8-8　SOI扩展展示

8.4.1　应用软件子模块

在云计算的虚拟环境中，应用仍然有决定权，大多数情况下，应用以预配置的VM镜像方式由终端用户提供或提供给终端用户，企业用来实现对云IaaS的控制和管理的软件也可以被包括在应用的范围之内，例如，资源分配自动化、用户自助服务门户、云基础设施管理平台（Cloud Infrastructure Management Platform,CIMP）等。

8.4.2 虚拟机器子模块

VM是虚拟化环境的领袖，它们是服务器虚拟化的“产物”，运行在这些VM（逻辑主机）之上的应用之间，可以共享一个物理服务器的公共资源。虚拟机管理程序（例如，Vmware ESX）负责从物理服务器中抽象出虚拟计算环境并展示给终端用户，同时还对物理服务器公共资源的访问权进行裁决，更多有关服务器虚拟化的内容，请参考本书第2章的相关章节。

可以在UCS（更多细节请参考8.2节相关内容）上部署VM，也可以在第三方服务器上部署VM，更多内容请参考8.4.4节。

8.4.3 虚拟接入层子模块

物理服务器上的网络接口（vmnics）负责VM与环境其他部分的连接，如果需要建立一个点对点的从物理网络接口到VM的逻辑网络连接（Logical Network Connection,vNIC），就需解决可扩展性问题。为此，虚拟机管理程序通常会采用软件实现一个虚拟接入层交换机，完成多个VM到物理网络接口之间的多重转换。Vmware称之为虚拟网络标准交换机（vNetwork Standard Switch,vSS），之前也叫做vSwitch。

vSS的功能类似L2交换机，但是它不能完成其他的网络管理工作，因此当运行、管理、维护以及配置（Operations,Administration,Maintenance,and Provisioning,OAM&P）这些工作都需要在VM级实现时，对系统将是一个挑战。由于vSS属于非智能交换机，因此无法配置由云IaaS这样的服务交付环境授权的安全及服务级别功能，有关更多vSS的局限性，请参考本书第2章关于vNetwork标准交换机的局限性的内容。

vSphere 4操作系统支持Nexus 1000V（NX1KV）交换机，这是一款vSS的替代产品，拥有某些智能物理接入层交换机的基本功能，包括：PVLAN、唯一端口通道能力集、ACL、QoS、ERSPAN、NetFlow等。换言之，NX1KV将物理网络所期望的功能带入了虚拟环境领域，满足了IaaS终端用户的要求。在实际中，它能够建立传统非虚拟环境中所无法拥有的虚拟接入层，有关更多NX1KV的详细内容，请参考2.3.3节以及8.1.1节相关内容。

8.4.4 计算子模块

云IaaS服务能让终端用户产生一种错觉，即只要提出要求就能获得所需的各种规模的计算能力，且与实际的提供交付的物理基础设施无关。为了达到这一标准，IaaS供应商不仅要完成实际服务器的部署，还需要管理实际的处理器、内存以及网络接口。这些实际资源都是由计算子模块负责处理。

UCS能支持多种环境，即便要求非常苛刻也没关系。它通过网络将系统的服务虚拟软件、内存、存储以及内部服务架构汇聚在一起，建立了一个预集成系统，而除了利用FcoE（CNA之上）实现DC间的I/O整合，还使用NX1KV交换机透明地将网络智能扩展到虚拟环境中。更多有关UCS的详细内容，请参考8.2节相关内容。UCS以计算子模块为基础，简化了系统的集成和管理，不过UCS只是可选方案之一，除了UCS，现有服务器基础设施其他厂商生产的专门面向DC的服务器，如果拥有丰富DC功能都可以拿来构建私有云DC。像开放计算项目（Open Compute Project）这样的新项目也为私有云中DC设计带来了完全不同的新思路，如果能更好地完善其管理功能，也有可能用于私有云环境中。

8.4.5 存储阵列子模块

存储阵列子模块负责将存储从计算子模块中分离出来后再进行整合以尽可能最大化使用效率，分离的过程对云IaaS的虚拟环境非常重要，为了保证用户能够在企业DC任意一台物理服务器上的VM上执行任务，必须做到存储容量与某个特定服务器直接连接的物理存储设备（硬件设备）无关，否则就会对IaaS供应商的能力带来严重影响，包括处理能力按需扩展、克服少数设备存储能力的局限、向其他场景提供VM移动性等。大多数时候都可以使用存储虚拟化来解决问题，更多详细内容请参考2.4节的相关内容。

8.4.6 SAN子模块

由FC交换机组成的光纤构成了SAN子模块，负责连接起已经从计算子模块的处理单元中分离出来的存储单元（更多细节请参考8.4.4节的相关内容）。FC交换机光纤通常由FC导向器和交换机组成SAN负责存储阵列与计算子模块之间的互联，例如MDS 9000系列。

在传统模式中，SAN采用分层或核心——边缘体系。核心——边缘模型在光纤中心拥有两个或两个以上的交换机与光纤边缘两个或更多的边缘交换机相互连接，叠加——核心架构也属于核心——边缘架构，但是这种架构中用高速端口——计数导向器替代了核心——边缘模型中的核心及边缘交换机，存储设备则直接附加在这些导向器之后。就统一DC网络架构而言，更欢迎叠加——核心结构，因为它能够支持接入层子模块同时为存储和应用环境提供服务，更多细节请参考8.4.8节的相关内容。

8.4.7 SAN扩展子模块

SAN扩展子模块能够实现校园、城域网或WAN范围内多DC互联，同时也能将现有SAN分区连接到这些DC中。SAN扩展这样的整合技术，能够将多个地理上分布的DC连接成一个虚拟DC集群，为IaaS终端用户提供了更优的高可靠性、高可用性、高服务（Reliability,Availability,and Serviceability,RAS），它也是IaaS供应商的保护神，有了SAN扩展，业务连续性（Business Continuity,BC）就有了保证，而在意外发生时SAN扩展也能够实现灾难恢复（Disaster Recovery,DR）。更多SAN扩展的详细内容请参考本书第7章。

8.4.8 接入层子模块

接入层子模块实现了一个分布式交换基础设施以支持云IaaS服务横向扩展能力，实现云IaaS服务需要对各种网络进行部署以满足存储网络及应用网络的需求，统一网络架构是接入层子模块的基础部分，有了它，存储和应用流就能够使用形式统一的I/O及网络传输。统一网络还必须要保证这两种网络的性能要和传统模式下性能一致，这需要借助10GE、无损以太网以及FCoE等技术实现。有了FCoE,SAN就不再需要一个单独的接入层将两种网络（FC和以太网）合二为一，更多有关FcoE技术的内容请参考2.6节的相关内容。

8.4.9 汇聚层子模块

汇聚层子模块对构建一个高度可靠、可扩展的“中间层”至关重要，它绑定了来自接入层子模块的网络流，同时确保了物理资源的合理利用。汇聚层还是STP协议对vPC进行流线处理的地点，更多有关vPC和其他L2特点，请参见2.5节的相关内容。

另外，基于网络的虚拟服务，包括防火墙、服务负载平衡、入侵及匿名探测、深度封包检测、WAN优化以及其他上层服务，都集中于在汇聚层子模块，这些网络服务都可以在服务机箱中实现，例如Catalyst 6500系列交换机机箱。更多关于服务集成的内容请参考3.1节的相关内容。

8.4.10 核心层子模块

核心层子模块要负责解决大规模云IaaS部署要具备的高可扩展性能力，核心层子模块与汇聚层子模块及Peering子模块都是相互分离的，如果部署环境要求简单的层次划分，核心层可以与汇聚层子模块或Peering子模块或有部分设备重叠。

在核心层子模块上，借助虚拟设备上下文（Virtual Device Contexts,VDC）或者是核心层交换机上的VRF将L3分区从下一代WAN子模块扩展到DC中，从而保证了在L3基础设施之上的网络传输仍然是相互隔离的。L3分区也扩展到了汇聚层子模块，被L3所分隔的路径最终将在接入层子模块连接到各自的VLAN中，关于L3分区的更多细节请参考本书第3章基础设施分区相关内容。

8.4.11 对等子模块

对等子模块位于企业DC和WAN的边缘，L2和L3的基本功能都在这一层实现，包括各类LAN及WAN的操作和协议。对等子模块是专为配合诸如BGP、GRE隧道、IPSec等对等应用而设置的，这些应用通过供应商网络或整个Internet，向远程分支机构或终端用户提供服务。更多有关云IaaS SOI相关的对等应用请参看3.3节。

如果云IaaS服务所部署的环境支持现有的非云服务，在对等子模块上需实现物理和逻辑分离。例如，两个或更多的逻辑网络，一个用来支持之前非云环境，其余的则为私有云计算和云IaaS提供服务，可以在对等层对这些逻辑网络进行整合。

8.4.12 未来的WAN子模块

未来的WAN不属于企业DC的子模块，相反，它由很多网络组成，包括：服务供应商网络、合作者网络以及Internet。为了维持远程站点或终端用户间端到端路径间的相互隔离，需要将企业DC实施L3分区扩展到这些WAN上。这对很多下一代WAN技术都提出了改造要求，包括：

·来自服务供应商的multi-VPN服务

·L2交换机上的MPLS

·DMVPN每VRF

·DMVPN之上的MPLS VPN（只支持集中星型路由）

更多有关这些技术的详细内容，请参考3.3节的相关内容。

8.4.13 WAN优化

WAN优化的部署并不仅局限于之前所探讨的某一个子模块上，能够完成云拦截的子模块包括：

·虚拟机器子模块

·汇聚层子模块

·核心层子模块

·对等子模块

·下一代WAN

·连接远程分支的链路

更多有关WAN优化的内容，请参考本书第4～6章。

8.4.14 云基础设施管理平台

云基础设施管理平台（Cloud Infrastructure Management Platform,CIMP）是云IaaS服务的核心元素，通过CIMP,IaaS供应商能按终端用户需求提供任意规模，与物理基础设施无关，仿佛专为用户定制的虚拟环境。

基础设施管理平台并非单独的软件或硬件，它由不同厂商、第三方以及IaaS供应商内部管理功能服务组成，包括运行支持系统、企业计费系统、自助服务工具、元管理等。

SOI负责将云IaaS服务分布到终端用户处，可以像部署管理应用一样在同一SOI的VM子模块上部署基础设施管理平台，这种方式有助于提高环境的整体效率和可扩展性，降低因单独部署基础设施管理平台而带来的不必要的复杂性。有关云管理的概要内容可参考8.3节的相关内容。

8.4.15 终端用户负载及应用

由于云IaaS服务的核心就是为终端用户提供基础设施平台，使得终端用户能利用平台完成自己的任务或应用，因此在发布云IaaS服务时，除了云基础设施管理平台，不需要再增加额外的模块。对于终端用户而言，整个环境看起来就像专门为他们定制而成一样。

8.4.16 云IaaS覆盖

云IaaS服务可以部署在SOI的顶层，覆盖了之前提及的各功能子模块，图8-9展示了一个构建在SOI子模块之上的云IaaS服务覆盖样例。

我们的私有云计算之旅始于对服务器、存储以及网络资源的整合，虚拟化将底层物理设备与它们的上层逻辑展现分隔开来，使资源的利用和部署得到强化，再加上WAN优化技术后，现有的面向过程的DC基础设施能够转换成面向服务的基础设施（Service-Oriented Infrastructure,SOI），为私有云计算服务，特别是云IaaS服务所覆盖。

由图8-9所示的云IaaS覆盖可知，我们马上就要到达此次探索的终点了，不过还差一点，第9章才是终结篇，我们将重新以案例讨论的方式，对之前涉及的所有理论做一个回顾。

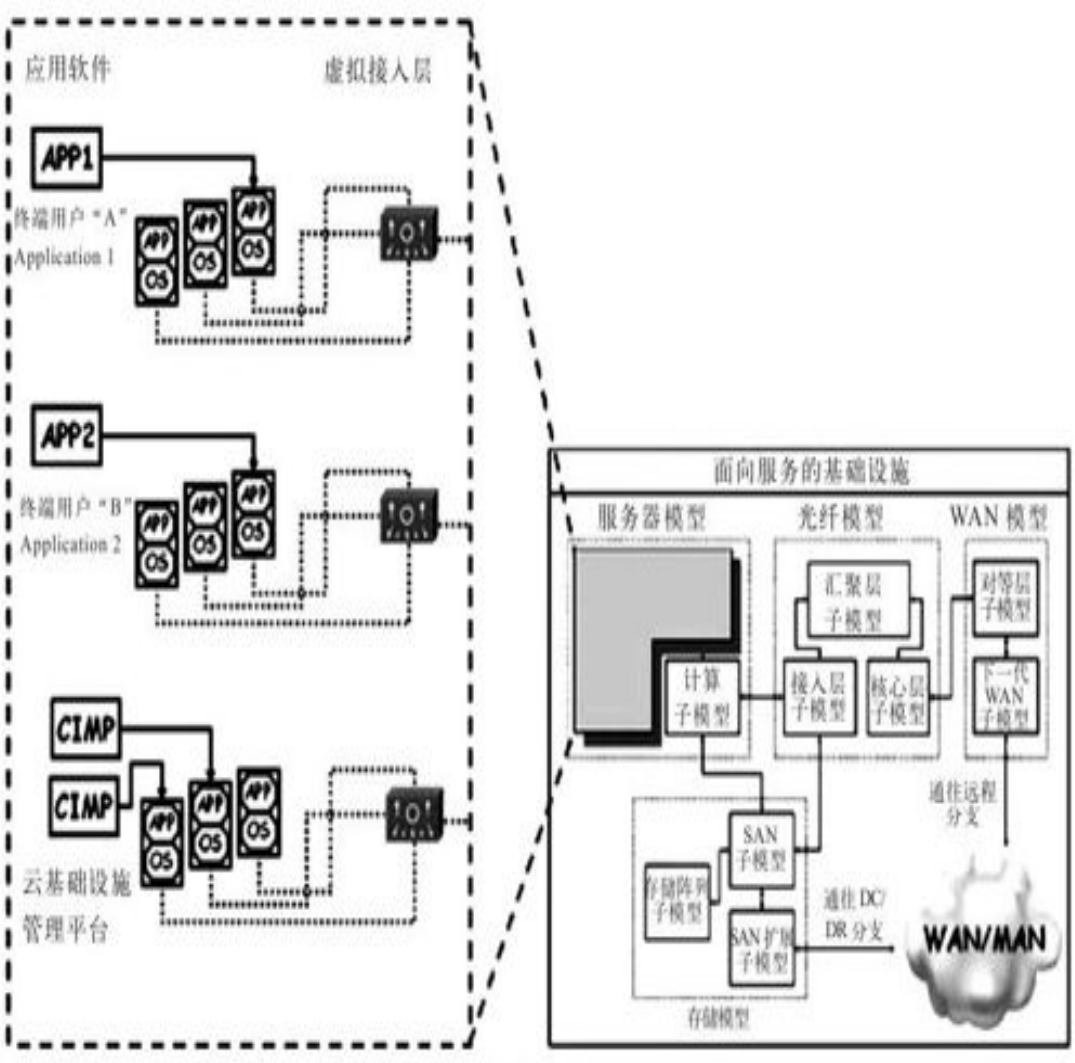


图　8-9　SOI之上的云IaaS服务覆盖

读者如果能够透彻理解第9章的内容，将对整合、虚拟化以及SOI这些私有云计算部署及云IaaS服务实施等基本理论有一个深入了解。

8.5 小结

云安全是本章的重点，除了在云计算环境中仍然适用的安全基础设施及技术，本章还涉及了私有云安全领域的其他内容，例如VM和VM驻留的额外的虚拟接入层，它们都属于服务器虚拟化的附属产物。虚拟接入层交换机是将物理基础设施的现形安全策略扩展到虚拟环境的理想实施地点，例如，借助NX1KV交换机，可以实现包括VLAN、PVLAN、DHCP监听、IP源保护、DAI、端口镜像以及NetFlow等多项安全策略。

人们期望私有云计算以及云IaaS服务能具备高度可扩展性，这使得大功率服务器成为一种战略需要，UCS在这里发挥了重要作用。尽管UCS价格不菲，但它确实能够提供灵活性及高服务水准，而从长远发展来看，UCS的整体资产购进成本（Total Cost of Ownership,TCO）将会有大幅下降，特别是再加上完全虚拟化的集成管理基础设施所能节省的线缆、内存以及人力成本这些因素，就更是如此。实际中，采用UCS技术后，降低了机架滚动部署的复杂性，更有利于机架级的模块化，以及在现有DC或绿场部署环境中提供快速服务能力。

云管理并不是像某些人想象的那样极度复杂，因为现有的网络管理策略和集成技术都能够在云IaaS服务中充分发挥作用，本章没有依赖实际的云基础设施管理平台，而是从一般方法的角度探讨了云管理技术。在大规模私有云计算部署中，还必须考虑诸如分级管理模型、基于策略的管理、管理调整、自动化、用户自助服务门户以及XML标准化等许多特性。

最后但也一样重要的是可以通过SOI的组件，包括应用软件、存储阵列、SAN、SAN扩展、接入层、汇聚层、核心层、对等以及下一代WAN等，将云IaaS服务直接部署在SOI之上，使得对每个终端用户而言，都好像它们的应用独享了整个服务器的资源一样。

第9章　案例分析

在理论上，理论和实践之间没有区别；在实践中，区别是存在的。

——劳伦斯·彼得·贝拉（Lawrence Peter Berra），阿尔伯特·爱因斯坦（Albert Einstein）

简介

第9章是本书的终结篇。我们将对之前章节所讨论的内容以案例设计学习方式进行总结，包括基于整合及虚拟化技术的私有云计算的设计及部署，以及面向服务的基础设施SOI之上的云IaaS服务。

本章的章节安排与前面几章稍有不同，主要采用案例学习方法来探讨部署、基本配置以及之前所介绍的一些比较复杂的概念等技术主题。

9.1 虚拟接入层设计学习

Nexus 1000V（NX1KV）交换机是服务器虚拟化处理过程中的基础部件，它将物理交换机的功能带入虚拟环境中，并实现了VM与物理网络的连接，NX1KV交换机建立了虚拟接入层，进而实现了从VM到物理网络的“多路连接”，获得了私有云环境所必需的可扩展性。更多有关虚拟接入层的性能介绍请参考8.4.3节的相关内容。

说明：NX1KV交换机支持虚拟以太网（virtual Ethernet,vEth）接口概念上的VN链路（虚拟网络链路）。

9.1.1 Nexus 1000V组件

在开始讨论各类NX1KV设计方案之前，以下小节将对NX1KV部件予以简要说明：

·虚拟管理程序模块（Virtual Supervisor Module,VSM）

·虚拟以太网模块（Virtual Ethernet Module,VEM）

·VMware vCenter

虚拟管理程序模块

VSM实际上是一个拥有三个vNIC（分别对应控制、管理及包接口）的ESX VM，每一个VSM都要求预留单独（非共享）的2GB RAM和1.5GHz CPU资源，VSM支持NX-OS 4.0.4及更高版本，该NX-OS操作系统支持x86 CPU架构。VSM负责系统管理、监控及配置，可以采用HA主/从模式配置两个VSM，但需要分别在两个不同的ESX主机上实现首要（活动）以及次要（从）VSM。

虚拟以太网模块

VEM是ESX主机上的VMware虚拟机管理程序的软件部分，由它负责实现虚拟机管理程序中分布式虚拟交换（Distributed Virtual Switch,DVS）功能，VEM的数据路径组件等同于一个L2交换机，由VSM配置完成。通常情况下，VEM间需要实现L2邻接以组成控制路径。一旦配置完成，在下次启动前，VEM即使没有与VSM连接，也能继续完成网络转发。VEM与VSM间的其他交互包括：

·每一个VEM在VSM中都表现为一个线卡。

·VSM使用ESX服务器的UUID来区分每一个VEM。

·在VEM注册时，VSM会为每个VEM分配一个槽位序号。

·VSM将VEM与槽位序号之间的映射关系存放在一个永久存储中，即使系统重启也不要紧。

·槽位1和槽位2是为VSM保留的，而槽位3到槽位66都可以分配给VEM。

·VEM通过在控制接口广播心跳帧，达到以下目的：

·检测是否存在新加入DVS的VEM。

·检测已经注册到VSM的VEM之间的连接状态。

VMware vCenter

vCenter是一个用来控制ESX主机的VM应用，它通过控制通道连接到每个ESX主机。VSM与vCenter之间使用SSL连接，并通过自签名证书来验证连接。VSM在vCenter会生成一个NX1KV DVS,vCenter管理员将ESX主机加入到该DVS中，使得ESX主机成为NX1KV DVS的成员之一。VSM还可以从vCenter上下载一些配置信息到VEM上。

VSM使用简单对象接入协议/Web服务描述语言（Simple Object Access Protocol Protocol/Web Services Description Language,SOAP/WSDL）应用程序接口来配置vCenter：

·在vCenter中生成NX1KV DVS以及dvPortGroups。

·存储DVS数据，这些数据将传送给那些已属于NV1KV DVS成员的ESX主机。

·从vCenter处检索信息（诸如DC、DVS、VM等）。

·负责周期性连接检测。

9.1.2 设计样例

当进行NX1KV设计时，需要牢记以下准则：

·与物理接入层交换机的连通：这通常要根据ESX主机上的NIC互连数目而定。

·可获得性、冗余以及负载平衡：它们涉及端口通道（以太通道）的使用以及相应的散列算法，有两类主要的端口通道散列算法。

·基于源散列：这类散列算法对来源相同且属于同一下行链路的网络传输进行散列，例如源MAC、VLAN、虚拟端口等。

·基于流散列：这类散列算法对每一股网络流采用不同的路径，要求上行流采用以太通道配置，任何使用包目的地散列算法、L4端口或组合了源地址、目标地址以及L4端口的算法都属于这一类。

·VMware和NX1KV传输：

·VM数据：指所有来自VM的数据，包括VSM，通常会与多VLAN有关。

·VM核心：负责VMotion和IP存储。

·服务器控制台：负责ESX管理。

·控制：NX1KV交换机控制传输。

·包：携带CDP和IGMP控制包。

我们将以上述设计因素为基础，探讨下列三种设计方案：

·双NIC配置

·4NIC配置

·6NIC配置

双NIC配置

“A”企业有一个小型的机架服务器以及带有1Gbps NIC的刀片服务器，“A”企业希望将现有这些服务器当做临时的ESX主机，快速实现服务器虚拟化。另外一方面，“B”企业早就借助FCoE实施了DC互联阵列统一化进程，刀片服务器配备了10Gbps的CNA，“B”企业希望通过采用机架滚动式方案。图9-1

展示了一个双NIC配置方案，该方案能够同时满足“A”、“B”两家企业的需求。

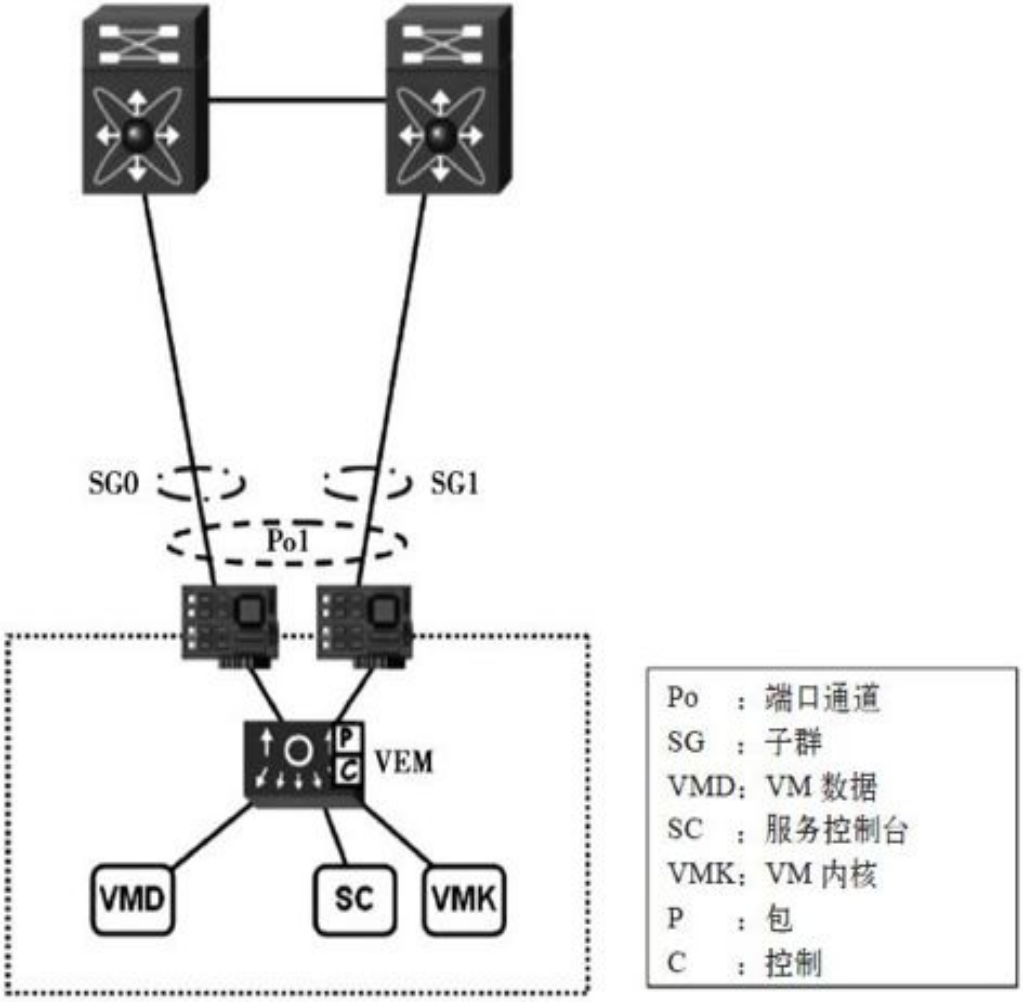


图 9-1 双NIC配置样例

双NIC配置内容如下：

·物理接入层交换机配置：

·Trunk端口

·不需要配置以太通道

·NX1KV端口通道1（Po1）：

·单个端口通道（PortChannel,PC）将使用vPC主机模式（vPC Host Mode,vPC-HM）。更多有关vPC-HM的内容，请参考2.5节的相关内容。

·VM数据传输、服务控制台、VM核心、控制以及包传输。

·VEM配置：

·基于源的散列

从NX1KV交换机角度来看，本方案是最简单的一种，由于两个NIC的配置差别很小，从而降低了系统整体设计难度。基于源的散列算法中，将首先考虑MAC地址散列而非VLAN散列。

VLAN散列可能更容易使得VM数据VLAN和VMotion（VM核心）VLAN被散列到同一上行链路端口，如果对VMotion进行初始化，在VMotion会话内的所有VM都将可能指望同一带宽，而在1Gbps NIC上，将产生不尽如人意的负载平衡结果，而如果是10Gbps的NIC，由于拥有足够的带宽，就可以忽略该因素。

源MAC地址散列将VM的负载更均匀地分布到两条上行链路上，因此当初始化VMotion时，争夺带宽的VM数目将减少。

4NIC配置方案1

“C”企业拥有一个中等规模的机架服务器，刀片服务器同样带有1Gbps的NIC，不过，“C”企业的需求与“A”、“B”两家企业都不同，它要求VMotion的网络传输要与VM数据分离。图9-2展示了一种能够满足“C”企业需求的4NIC配置方案。

4NIC配置方案1的内容如下：

·物理接入层交换机配置：

·Trunk端口；

·不需要配置以太通道。

·NX1KV端口通道1（Po1）：

·激活vPC-HM；

·携带VM数据。

·NX1KV端口通道2（Po2）：

·激活vPC-HM；

·携带服务控制台、VM核心、控制以及包传输。

·VEM配置：

·基于源的散列。

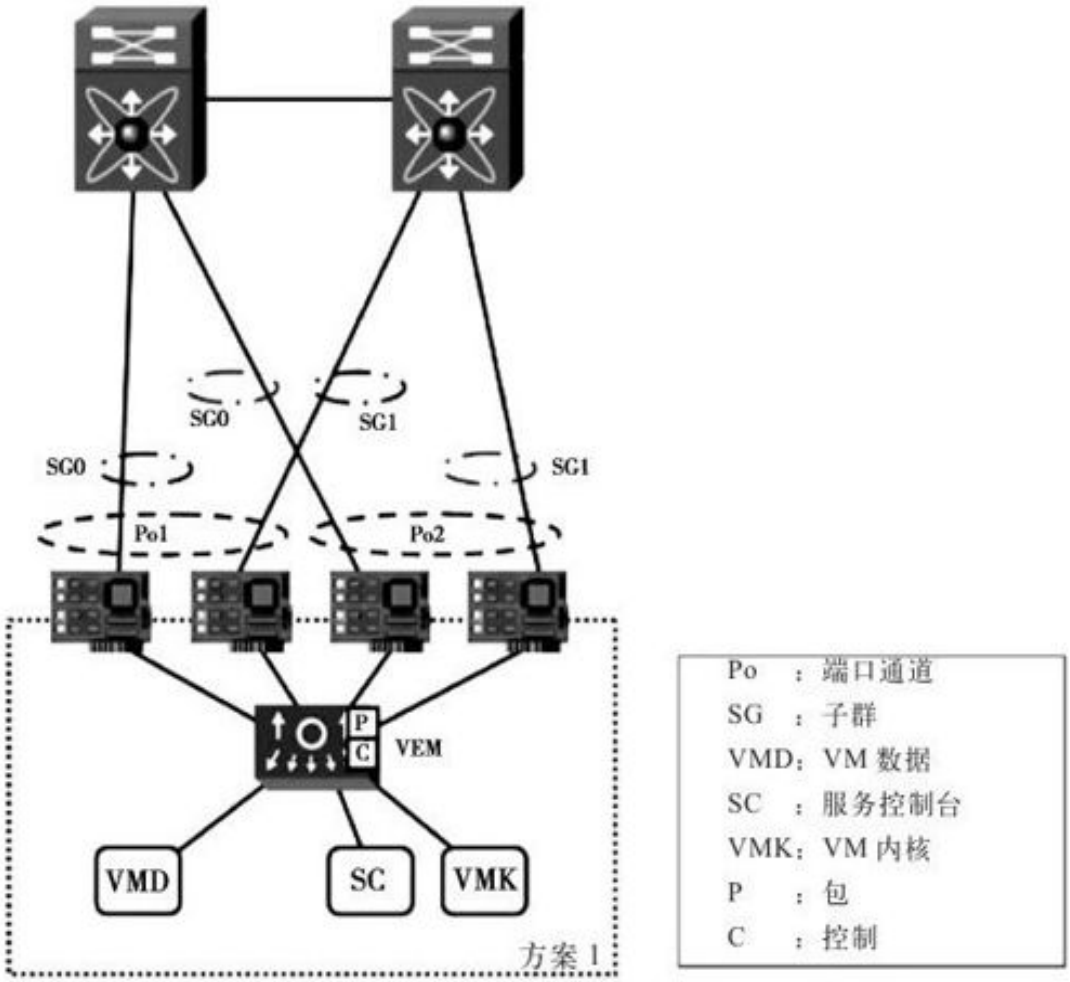


图 9-2 4NIC配置方案1

4NIC配置方案2和方案3

企业“D”和企业“E”在它们的两台Nexus 7000交换机之间都实现了vPC，承担了DC物理接入层的功能。更多有关vPC的详细内容，请参考2.5.1节。

企业“D”希望最大化VM的带宽，也允许VM数据和VMotion传输共享带宽。企业“E”，则刚好相反，要求严格分离VMotion和VM数据传输。图9-3左边的4NIC配置方案2能满足“D”企业的需求，而图右边的4NIC配置方案3则适合“E”企业的需求。

说明：为了实现vPC，本节中给出的4NIC配置方案都采用了交换机集群。

4NIC配置方案2的内容如下：

·物理接入层交换机配置：

·Trunk端口；

·单以太通道在两个物理接入层交换机中间穿插。

·NX1KV端口通道1（Po1）：

·配置标准的以太通道；

·携带VM数据、服务控制台、VM核心、控制以包传输。

·VEM配置：

·基于流的散列。

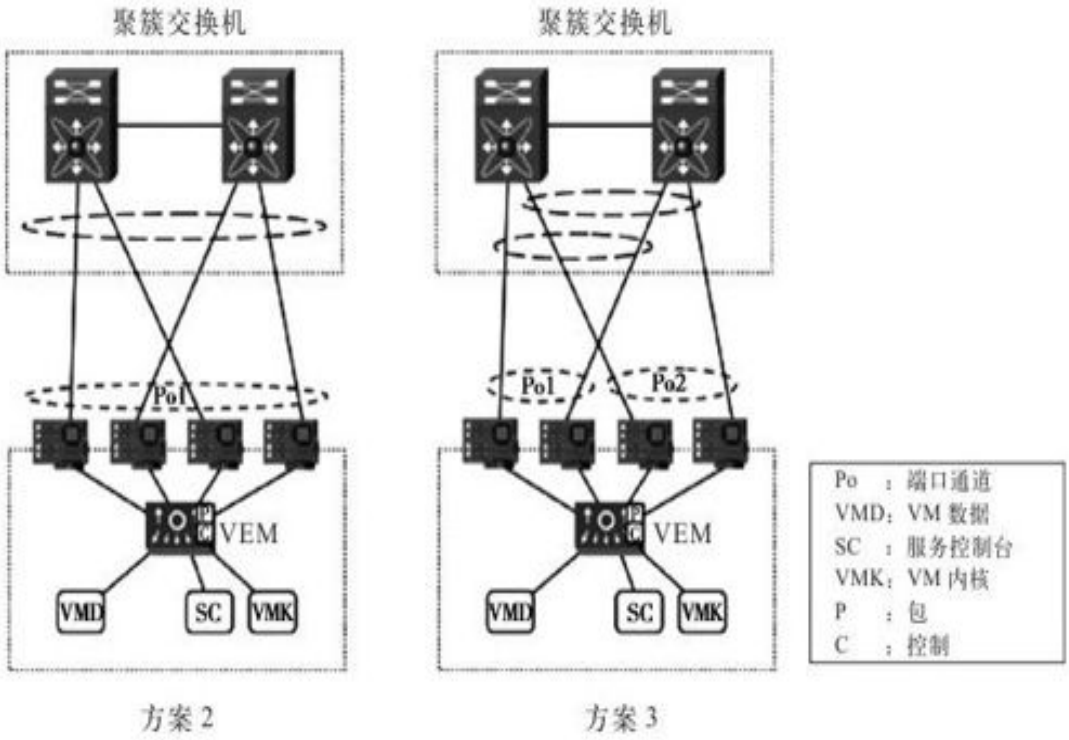


图　9-3　4NIC配置方案2和方案3

4NIC配置方案3的内容如下：

·物理接入层交换机配置：

·Trunk端口；

·两个以太通道在两个物理接入层交换机中间穿插。

·NX1KV端口通道1（Po1）：

·配置标准的以太通道；

·携带VM数据。

·NX1KV端口通道2（Po2）：

·配置标准的以太通道；

·携带VM数据、服务控制台、VM核心、控制以包传输。

·VEM配置：

·基于流的散列。

6NIC配置方案

企业“F”拥有高性能服务器（配1Gbps的NIC），所需VM带宽要高于1Gbps，还要求分隔VM数据和VMotion传输。图9-4展示了一个能满足以上要求的6NIC配置方案样例。

说明：为了简化整体设计，除了4NIC，用户还应该考虑迁移到具备10GE连接能力的环境中。

6NIC配置方案的内容如下：

·物理接入层交换机配置：

·Trunk端口；

·每个物理接入层交换机使用单独的以太通道连接至Po1。

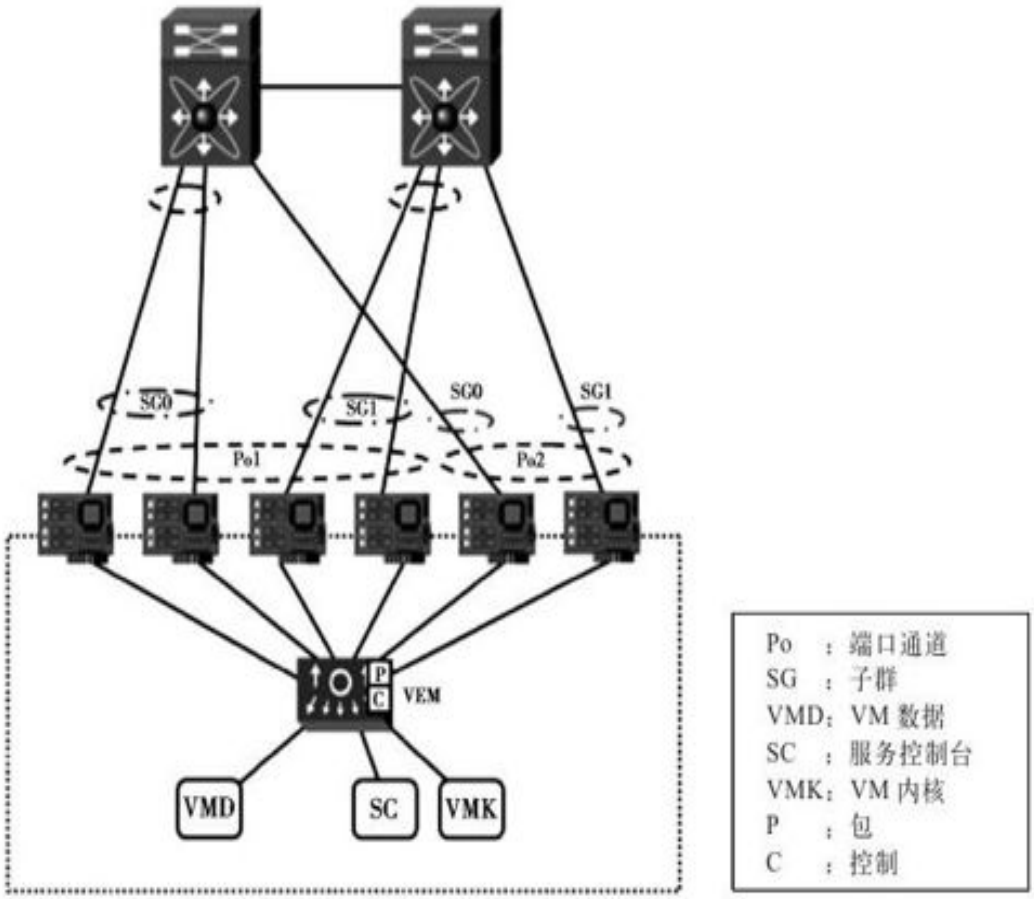


图　9-4　6NIC配置样例

·NX1KV端口通道1（Po1）：

·激活vPC-HM；

·携带VM数据。

·NX1KV端口通道2（Po2）：

·激活vPC-HM；

·携带VM数据、服务控制台、VM核心、控制以包传输。

·VEM配置：

·基于流的散列。

说明：最早的NX1KV产品，仅能支持两个子分组：0和1，4.0.4.SV1.2及更高版本可以支持多达32个子分组。

9.2 ERSPAN案例学习

我们在第8章中讨论了封装远程交换机端口分析器（Encapsulated Remote Switch Port Analyzer,ERSPAN），NX1KV交换机构成了虚拟接入层，ERSPAN能够简化对这些交换机的远程传输监控，是实现虚拟接入层网络传输流可视性的重要传输监控工具。ERSPAN可以监控端口以及VLAN的网络传输，它也能够在服务汇聚层镜像虚拟接入层到当前网络分析器（NAM或者IPS设备）的网络流，IaaS供应商利用ERSPAN来完成云IaaS环境中内部监听及安全监控的任务。

说明：一个本地SPAN会话的目标端口必须在同一主机VEM上，ERSPAN是一种本地SPAN扩展，能够将包传送到本地主机VEM之外的远程目标IP地址上。

9.2.1 ERSPAN源接口

ERSPAN监控的源接口包括如下类型：

·以太网

·虚拟以太网

·端口通道

·VLAN

以上源接口的特征包括：

·源接口不能作为本地SPAN会话的目标端口；

·可以配置源接口，使得它能够监控网络传输的方向：

·接收（汇入）

·传输（汇出）

·接收和传输

·源端口在同一或不同的VLAN中。

·如果是VLAN SPAN源，所有源VLAN的活动端口都被看成源端口，它们有可能在穿插在多个VEM中。

9.2.2 ERSPAN设计样例

企业“G”刚启动了一个小规模的服务器虚拟化工作，使用NX1KV交换机作为虚拟接入层，同时保留了现有的服务汇聚层的Cat6K交换机。企业“G”希望通过实现ERSPAN以获得新生成的虚拟接入层网络传输流的可视性。

图9-5展示了企业“G”的ERSPAN部署，此时，目标IP属于Cat6K交换机，ERSPAN目标会话也在Cat6K交换机上完成，能够将GRE封装包转发给其他附带了监听设备（也可以为NAM或IPS设施）的端口。

图9-5中ERSPAN到目标Cat6K的操作包括以下5个简单步骤：

步骤1：将某个ERSPAN源端口配置成Veth1，连接到VM1；

步骤2：如果上述ERSPAN源端口接收了GRE封装包，则将它们发送到目标IP；

步骤3：包将路由后发送至Cat6K上配置的目标IP；

步骤4：Cat6K配置了一个ERSPAN目标会话，将端口Fat4/1接收到的GRE封装包解封装，并转发到端口Fat4/2；

步骤5：连接到端口Fat4/2的外部网络截获了这些包以进行分析。

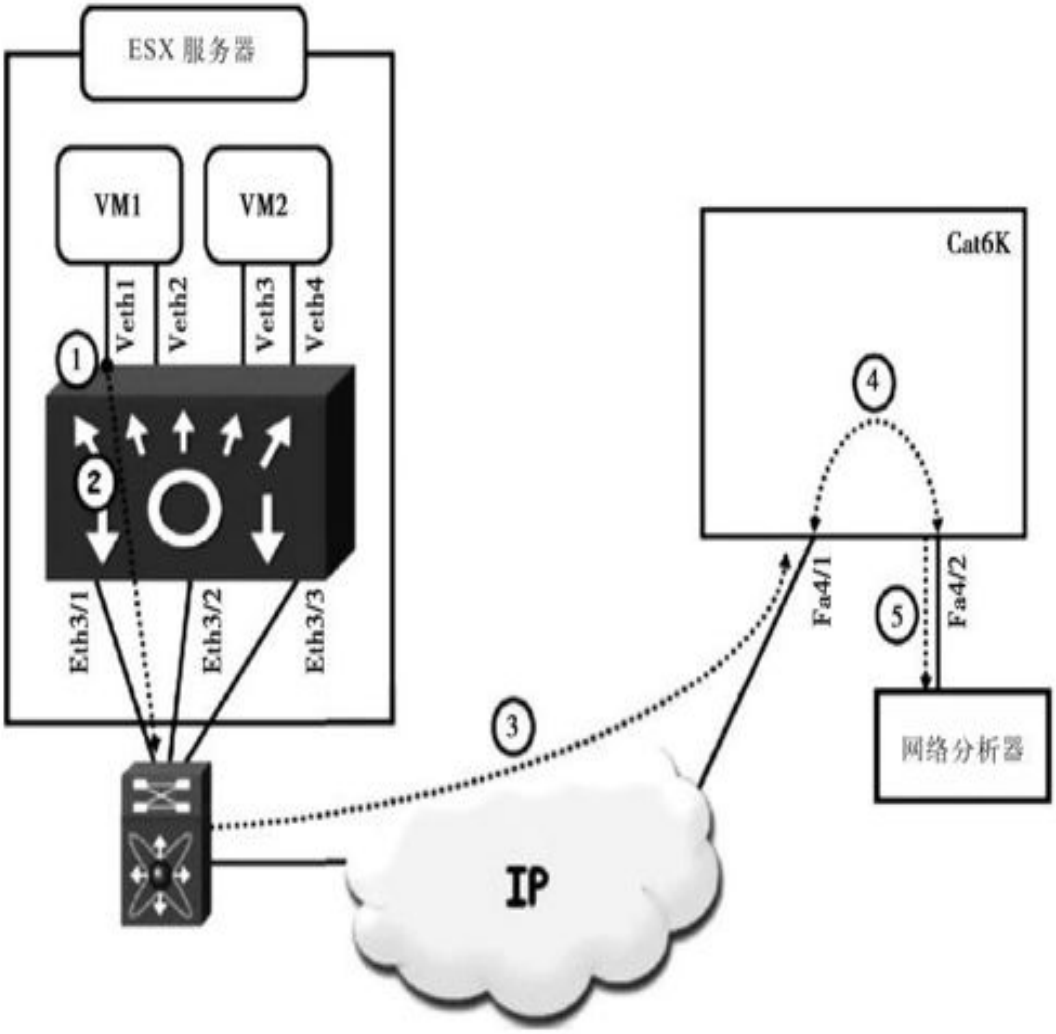


图　9-5　以L3交换机为目标的ERSPAN

说明：为了实现安全监控，读者可以采用IDS/IPS设备来代替外部网络分析器。

9.2.3 ERSPAN基本配置

当配置ERSPAN时，可以参照以下备忘：

·需要“l3control”-capable端口配置文件，代码清单9.1展示了一个“l3control”-capable端口属性文件配置，“l3control-capable”命令表明所创建的接口（vmknic）使用L3（IP）控制功能。VEM使用该L3端口发送包。

代码清单9.1 L3 control-capable端口属性文件配置样例

```
port-profile erspan
 capability l3control
 vmware port-group
 switchport mode access
 switchport access vlan 123
 no shutdown
 system vlan 123
 state enabled
```

·必须要在VEM主机上配置vmknic：

·vmknic将被添加到NX1KV DVS上。

·使用“l3control”-capable端口属性文件配置vmknic。

·要为vmknic配置一个源IP地址以完成ERSPAN。

·确保从VEM主机可以访问到目标IP。

·在VSM上配置ERSPAN源会话，代码清单9.2展示了一个源ERSPAN源会话样例。

代码清单9.2 ERSPAN源会话配置样例

```
monitor session 1 type erspan-source
 source interface vethernet23
 destination ip 10.123.123.1
 erspan-id 123
 no shut
```

·最后同样重要的是，在目标交换机（例如，Cat6K）上要配置一个相应的ERSPAN目标会话。

9.2.4 部署指南及限制

斟酌一下以下在NX1KV交换机上部署ERSPAN的指南及限制：

·NX1KV能配置的SPAN端口和ERSPAN会话总数为64，这也是SPAN和ERSPAN会话最大的并发数。

·一个端口可支持最多4个SPAN会话。

·每个会话可以支持最多32个源VLAN。

·每个会话可以支持最多128个源接口。

·从主机必须要能访问到目标IP地址。

·以VLAN为源时，要注意避免上行链路端口超负载。

9.3 WAN优化案例学习

如我们在第4章曾经讨论过的一样，WAN优化技术使得私有云可用，也是企业成功部署私有云的保证。“Q”企业在部署面向工程的云系统中采用了WAN优化，简而言之，除了LAN/WAN设计外，我们将探讨所有的商务及技术问题。

“Q”企业在寻找能够解决云部署面临的两个难题：内部和外部。他们的办公室遍及全州，需要将文档集中至相距1000km之遥的企业DC上，还需要向外部用户提供服务，也希望能向公司的合作伙伴提供私有云而非公有云服务。远程工程师采用大约600MB的数字模型文件集，在PLM系统中的多个文件和目录中进行项目文件传输。即便相隔较近的办公室具有较好的连接性（10Mbps，15ms延时），在访问DC上的集中资源时也会遇到较大的延时，例如，应用程序需要15分钟才能获得一个14MB的文件。远程办公室单击鼠标后到产生响应，通常会有30～60秒的延时，使得用户难以容忍。因此，“Q”企业研究了2套不同的VDI解决方案以及WAN优化方案。

第一种VDI解决方案需要消耗大量的带宽，超过了企业办公室现有的能力，可以通过提高带宽来解决这个问题，不过也会相应增加成本，并不适合企业的合作伙伴，因为这些企业的规模通常都要远小于企业“Q”。第二种VDI解决方案即便增加了带宽，也无法充分满足工程师用户提出的要求。

“Q”企业购买了一个WAN优化的双重策略，在第一阶段，选择15个办公室部署了Riverbed Steelhead设备，为企业合作伙伴的工程师以及它们的内部远程或移动工人提供了移动的Riverbed Steelhead设备。这一方案能在带宽缩减和应用加速间取得平衡，为项目成功提供保障，这一组合获得了期望中的性能加速：

·从中心办公室传输一个17MB文件，速度从原来的1分钟25秒提高到8秒钟。

·单个办公室原本需要从远程获取48.6GB的文件，可是通过WAN的重复数据删除及压缩，实际只需要传输2.2GB数据。

·远程站点在传输高峰时，能够在其10Mbps链路上观测到500Mbps的有效传输。

·由于对两种技术进行了组合，各类办公室应用均能获得10～25倍加速（1000%～2500%的加速）。

云实现集中处理的同时也获得了非技术利益，当办公室使用基于云的文件认证拷贝而非使用本地保存的文件（有可能是过时的信息）后，可以减少工程性错误，同时还因为合作和共享提速，获得了更快的工程性循环。实施这一方案后，预计能节约150万美元成本，同时还缩短了循环周期，降低了错误发生概率。

9.4　统一光纤案例学习

要构造一个统一互联阵列最实用的方法，莫过于从一个未对FC目录或企业DC的汇聚层交换机做任何更改的物理接入层开始。图9-6展示了一个简化了的企业DC样例，该DC未实施服务器I/O整合。服务器连接到两个独立的网络基础设施上——以太网LAN和FC SAN，本案例学习的首要目标是增加一个汇聚层，能够将这些独立的阵列“融合”在一起。

FCoE接入层设计

企业“I”现有的DC设计与图9-6所示方案类似，改进之处：使用了Nexus 7000交换机将10GE引入到现有的基础设施（核心及汇聚层）中。对企业“I”的管理正好证明了另一个下一代DC目的，将FCoE引进到接入层。完全实现FCoE的成本太高了，甚至某种程度上，会产生反作用。本方案希望引发对购买某些新设备的关注，使得新设备在报废前，生命周期能够延长到至少5年以上。对于自有FC装置，应该坚持用到没有任何折旧价值为止。新的FCoE接入层也需要为未来扩展和扩充提供空间，能够与新的技术革新如云IaaS一起协作。

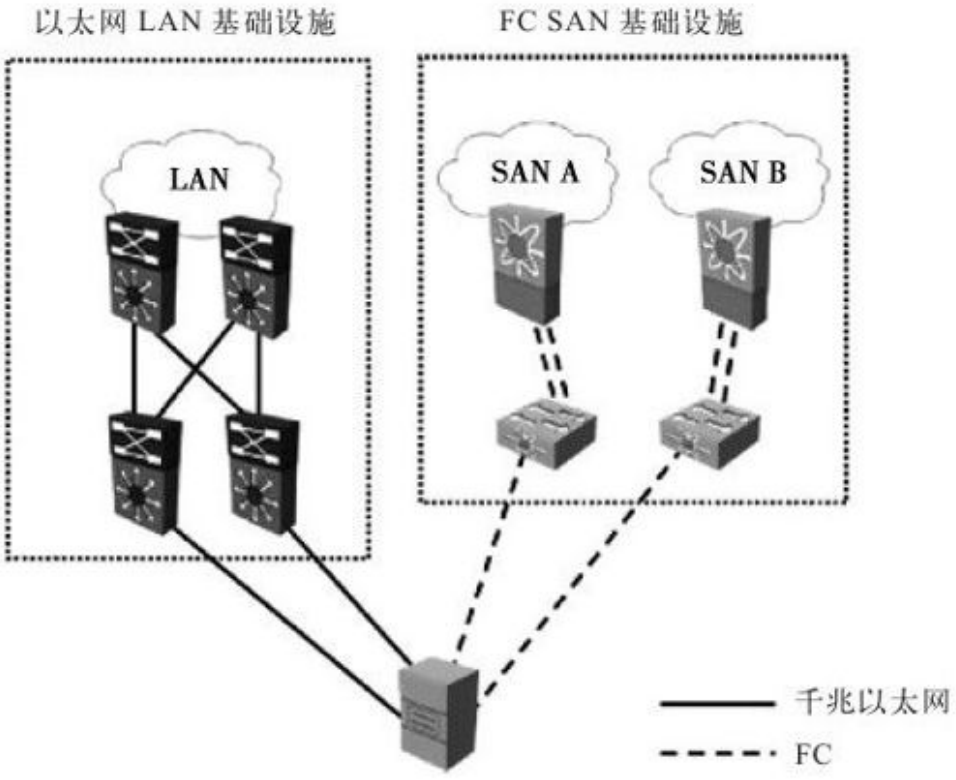


图　9-6　LAN和SAN基础设施分离的DC

图9-7推荐了一个简化的FCoE接入层设计方案。

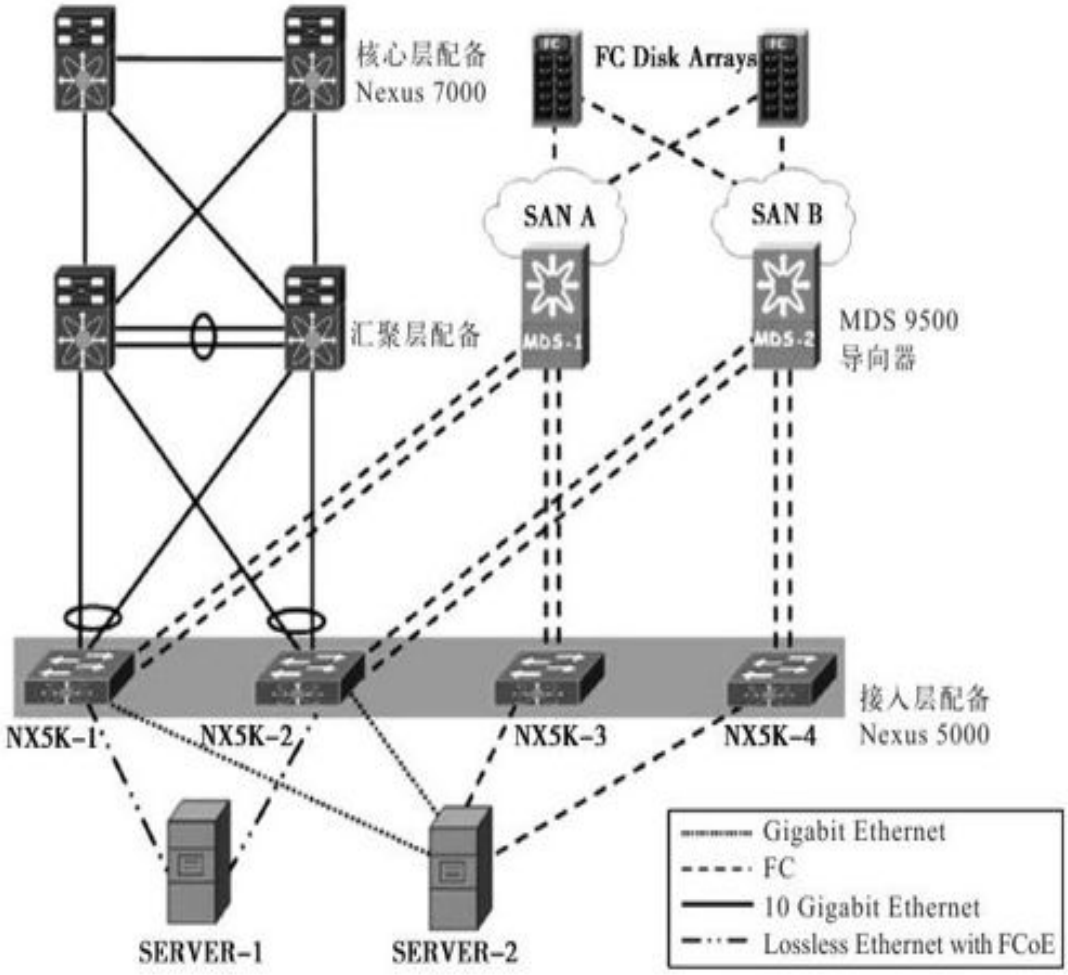


图　9-7　FCoE接入层设计

Nexus 5000（NX5K）交换机来自新的接入层，这些NX5K交换机（NX5K-1～NX5K-4）均采用以下方式设计：

·在接入层部署的NX5K交换机，要么为SAN A的一部分（连接NX5K-1和NX5K-3），要么属于SAN B（连接NX5K-2和NX5K-4），SAN A在VSAN 100，SAN B在VSAN 200。

·NX-5K3和NX-5K4承担了标准FC交换机的功能，本方案中，SERVER-2拥有2个HBA，分别使用一个4G FC链路，连接到SAN A和SAN B。SERVER-2同样通过2个GE NIC连接到网络的以太网这端。

·NX-5K1和NX-5K2承担了标准FCoE交换机（或者FCoE转发器）的功能，SERVER-1拥有双端口CNA，同时为LAN和SAN传输提供了2条10GE链路。

从接入层到FC SAN

NX5K-3和NX5K-4被当做标准FC交换机使用，它们实现了SERVER-2到核心FC导向器MDS-1（为SAN A提供服务）及MDS-2（为SAN B提供服务）的互联，既可以使用光纤模式，也可以使用N-Port虚拟化（N-Port Virtualization,NPV）模式。这两种选择采用不同方法来配置导向器和接入层交换机。

图9-8展示了光纤模式中的接入交换机，在FC导向器（MDS-1）和接入交换机（NX5K-3）之间的端口属于扩展端口，附加的FC主机（SERVER-2）通过连接光纤端口（F_Port）登录光纤，它同时还从该F_Port直接获得了一个FC标识（FC Identifier,FCID）。

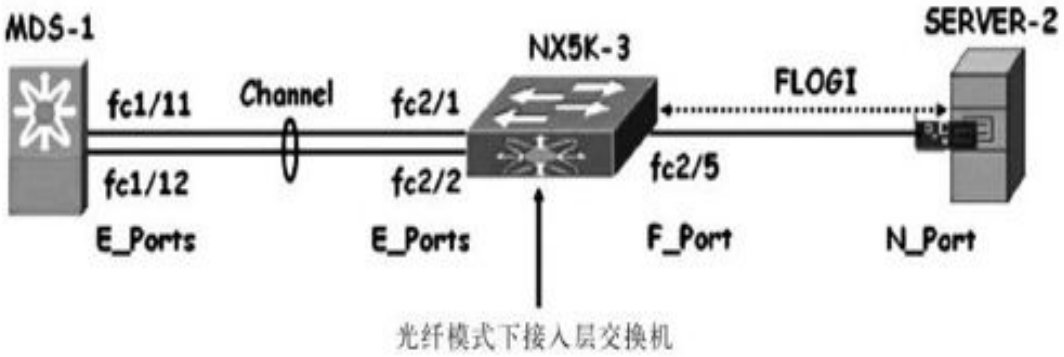


图　9-8　光纤模式下的接入交换机

由于节点端口（Node Ports,N_Port）之间FC传输由接入交换机直接进行转发，因此推荐在绑定了FC启动器，并且以接入层为目标的情况下，使用光纤模式。在该模式中，每一个接入交换机都将被分配一个FC域ID，通常从1～329，因而如果是从可扩展角度来看，也体现了接入层在采用光纤模式时，将对大型部署产生限制。

当以光纤模式部署接入交换机时，以下是一些很好的应考虑的实践经验：

·使用SAN端口通道提供接入交换机和FC导向器间的冗余连接，以及上行链路间的负载平衡，能最小化因链路故障而对光纤的破坏。

·不同于端口模式（E_Port、F_Port等）中让交换机自动谈判，对端口模式实施硬编码，将能确保链路能保持保持“down”状态，而不会因不正确的布缆产生不必要性。

代码清单9.3展示了在接入交换机（NX5K-3）上一个互联模式配置模板。

代码清单9.3　接入交换机光纤模式配置模板

```
vsan database
 vsan 100 interface san-port-channel 1

interface san-port-channel 1
 switchport mode E
 switchport trunk off

interface fc2/1
 switchport mode E
 channel-group 1
 no shutdown

interface fc2/2
 switchport mode E
 channel-group 1
 no shutdown
```

说明：NX5K交换机默认采用互连阵列模式。

NPV模式克服了域ID的局限（光纤），在NPV模式下，FC导向器在多个接入交换机间共享域ID。因而，接入交换机将对所有来自服务器端口（N_Port）的传输进行响应，转发给FC导向器。FC导向器提供了F_Port功能（例如，登录和端口安全）以及所有的FC交换功能。此时，边缘交换机（接入交换机）在FC导向器看起来就像一个FC主机，而在连接设备眼中，就像一个常规的FC交换机。

总而言之，NPV简化了大规模服务器环境下的部署和管理工作，理由如下：

·降低了对FC域ID数的需求。

·减少了与FC核心交换机（FC导向器）的交互工作量，特别是多厂商SAN环境下的交互工作量。

·去掉了服务器与SAN之间的协作和交互管理器。

图9-9展示了一个NPV模式的接入交换机。

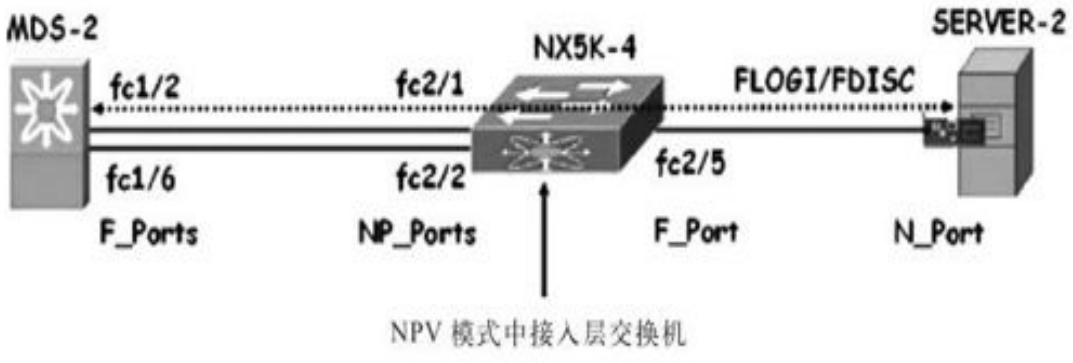


图　9-9　NPV模式的接入交换机

NPV由以下模块组成：

·服务器接口：服务器接口为接入交换机（NX5K-4）上的F_Port，可以连接到终端设备（样例中为SERVER-2）处。服务器接口自动分布到通往FC导向器（MDS-2）的上行链路中，所有连接到同一个服务器接口的终端设备都会映射到同一NP上行链路。

·NP链路：所有从接入交换机到FC导向器的接口都被配置成代理N_Port（proxy N_Ports,NP_Port）。一个NP上行链路连接了来自接入交换机（NX5K-4）上的NP_Port以及FC导向器（MDS-2）的F_Port。当NP上行链路创建成功后，接入交换机将往FC导向器发送一个互连阵列登录（Fabric Login,FLOGI）消息。如果FLOGI成功，接入交换机将会将自身注册到FC导向器的同一服务器上，随后来自终端设备的FLOGI都会被转换成光纤发现（Fabric Discovery,FDISC）消息。

说明：在NX5K交换机中，服务器接口可以是物理或虚拟的FC（Virtual FC,VFC）接口。

说明：服务器接口激活了N_Port标识虚拟化（N_Port Identifier Virtualization,NPIV）特性后，就能够支持多个终端设备。NPIV是FC链路服务（FC Link Services,FCLS）指南的一部分，由T11委员会定义，它提供了一种将多个FCID分配给单一的N_Port的方法，使得在每个物理端口能够进行多个登录，而非一对一的登录到端口的映射。

代码清单9.4展示了一个用于FC导向器（MDS-2）简单的NPV配置模板。FC导向器必须要能支持NPIV特性。如图中配置模板所示，FC导向器的2个F_Port都分配给了VSAN 200，本例中VSAN 200代表SAN B。

代码清单9.4　FC导向器NPV配置模板

```
npiv enable

vsan database
 vsan 200 interface fc1/2
 vsan 200 interface fc1/6

interface fc1/2
 switchport mode F
 no shutdown

interface fc1/6
 switchport mode F
 no shutdown
```

代码清单9.5展示了在接入交换机（NX5K-4）上的一个简单的NPV模式配置模板。上行链路（fc2/1和fc2/2）都被配置成NP端口，都分配给了VSAN 200。

代码清单9.5　接入交换机NPV模式配置模板

```
npv enable

vsan database
 vsan 200 interface fc2/1
 vsan 200 interface fc2/2

interface fc2/1
 switchport mode NP
 no shutdown

interface fc2/2
 switchport mode NP
 no shutdown
```

说明：“npv enable”配置命令会自动触发一个交换机重启动作，NPV模式适用范围是整个交换机，而不能基于每接口形式配置。

说明：当接入交换机运行在NPV模式下时，不再承担FC交换机功能，因此，接入交换机上也没有本地FLOGI以及命名服

务器注册数据库，有关这些数据库的更多详细内容应该参考FC导向器内容。

在接入交换机上配置NPV，应该参考以下指南及规则：

·NPV模式不要求数据必须按照顺序发布，因为两个终端设备间数据交换将经常占用从接入交换机到FC导向器的同一上行链路。

·可以为终端设备配置分区，以便终端设备能够使用FC导向器上所有可得的成员类型连接接入交换机。

·接入交换机可以连接多个FC导向器，换句话说，不同的NP端口可以被连接至不同的FC导向器上。

·NPV支持NPIV-capable服务器，这一特性被称为嵌入式NPIV。

·NPV使用负载平衡算法在首次初始化时，将VSAN里的终端设备自动分配到某个NP上行链路（也在同一VSAN内）中，如果某个上行链路发生故障，所有与该上行链路连接的终端设备都将失去连接，需要重新登录系统。

·只有执行NP上行链路分配时，才能对服务器接口实施处理。

·FC导向器及接入交换机之间的NP上行链路，不支持通道或链路聚集技术。

·接入交换机不是实施FC交换的地点，所有的网络传输都由FC导向器进行转发，如果两个终端设备间需要通信，也需要经过FC导向器转发才能完成。

以太LAN的接入层

图9-10展示了SERVER-1上的CNA和接入交换机，NX5K-1之间的FCoE连接，SERVER-1通过10GE连接至NX5K-1。在NX5K-1上定义了一个为FCoE服务的VLAN，在初始化时将通过FCoE初始化协议（FCoE Initialization Protocol,FIP）自动广播至FCoE终端节点（End Node,ENode）。ENode上的VN_Port必须连接到该VLAN上某个FCF（或者是FCoE交换机）的VF_Port。更多有关FCoE技术内容，以及诸如CNA、FIP、ENode、VN_Port、FCF这些概念的意义，请参考2.6节的相关内容。

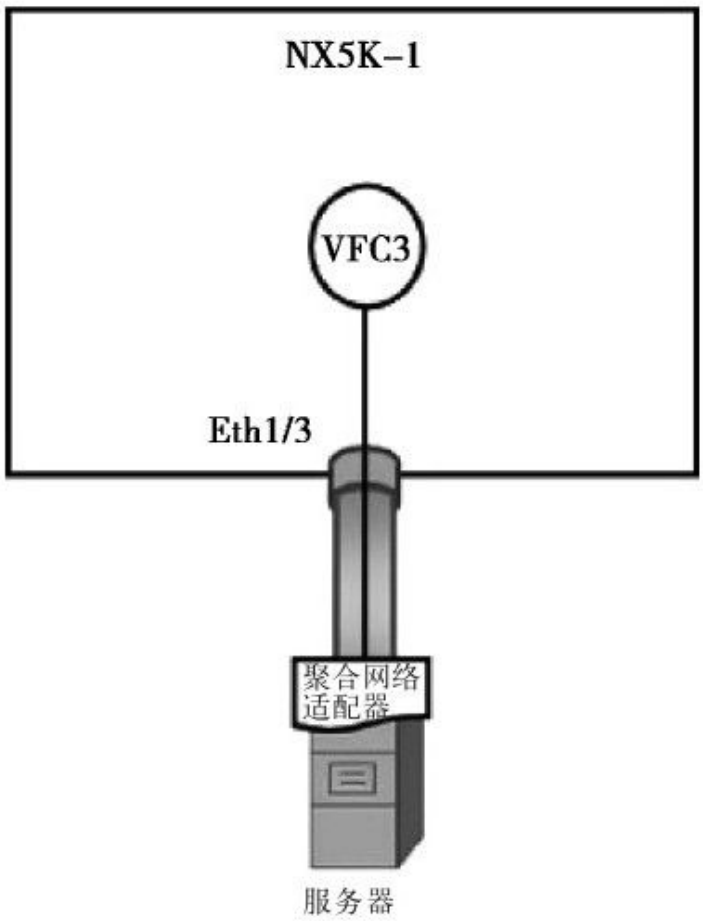


图　9-10　接入交换机与终端设备间的FCoE连接

NX5K-1是FCF（FCoE转发器），它支持为了转发而创建一个虚拟FC（virtual FC,VFC）接口。

如果要将VFC关联到指定终端设备（或ENode），可以采用如下两种方式：

· 服务器提供的MAC地址（Server-provided MAC address,SPMA）：VFC与某个特定ENode的MAC地址绑定在一起，此时，只有发往FCoE VLAN或者源自CNA的网络传输才会被转发给VFC。因为MAC地址配置需要在FCoE交换机（NX5K-1）上手动完成，所以这是一种配置密集型方法。

· 光纤提供的MAC地址（Fabric-provided MAC address,FPMA）：VFC与FCoE交换机的物理以太网接口绑定，此时，在相关物理以太网接口收到的所有FCoE网络流量（由VLAN和以太类型决定）都被转发到VFC处。该方法将在FIP登录过程中由FCoE交换机（NX5K-1）完成MAC地址分配，因此，不需要在FCoE交换机上来配置MAC地址，使得不需要额外

配置就能在终端设备（SERVER-1）上实现CNA交换，具备了更多的灵活性。通常会推荐使用FPMA方法。

更多有关SPMA以及FPMA的详细内容，请参见本书第2章的相关内容。

代码清单9.6给出了一个定义FCoE VLAN以及VFC的配置模板样例。

代码清单9.6　FCoE VLAN和VFC配置模板

```
feature fcoe

vlan 100
 fcoe vsan 100

interface vfc3
 bind interface Ethernet1/3
 no shutdown

vsan database
 vsan 100 interface vfc3

fcoe fcmap 0xefc0a

interface Ethernet1/3
 switchport mode trunk
 spanning-tree port type edge trunk
```

以下是在接入交换机上配置FCoE时，可以参考的一些配置指南：

·将VFC绑定到物理接口。为了降低人工配置的工作量，使用FPMA方法而非SPMA方法。

·交换机上配置的FCoE MAC地址前缀（FCoE MAC Address Prefix,FC-MAP），由其所连接的光纤决定。

·24位FC-MAP的推荐范围为0EFC00h～0EFCFFh（默认为0EFC00h），更多有关FC-MAP的详细内容，请参考本书第2章的相关内容。

·只使用FCoE VLAN来完成FCoE传输。

·对于某个FCoE VLAN而言，不要使用默认的VLAN，也就是VLAN 1。

·不同的光纤（例如SAN A和SAN B）应该使用互相分离的FCoE VLAN。

·FCoE传输必须使用802.1Q标签，因为802.1Q标签包含了一定用来定义服务等级（Class-of-Service,CoS）的域，需要使用无损以太网机制，比如说，基于优先级的流控制（PFC）以及增强的传输选择（ETS）。因此，有关的以太网接口应该被配置成trunk端口，更多有关PFC及ETS的详细内容，请参考2.6.2节的相关内容。

·为了确保FCoE传输使用802.1Q标签，以太网接口上的本地VLAN必须是非FCoE VLAN。·可以使用“spanning-tree port type edge trunk”命令，将连接到ENode接口配置为边缘接口（PortFast或TrunkFast），以实现生成树协议（Spanning Tree Protocol,STP）。此步骤属于基本配置，因为STP有可能会在汇聚过程中同步（例如，增加一个临时的放弃状态）该以太网接口，并对FCoE传输可能产生不尽如人意的影响。

说明：NX5K交换机希望从FIP T11一致的CNA接收到的帧能采用VLAN标签，以便实现FCoE VLAN，没有正确标记的帧都将被抛弃。交换机期望来自pre-FIP CNA的帧能够采用FCoE CoS值完成带优先级的标记，不过也仍然接收来自pre-FIP CNA的非标记帧。

设计方案说明

FCoE更像是一个FC，在设计和管理一个FC SAN时，并不会修改基本规则。由于FCoE强制固定必须是无损以太网，因此在接入层很容易实现这些规则。

借助FCoE在以太网上实现服务器I/O整合，可以生成一个统一的DC互连阵列，能够降低管理多个并行网络的成本，包括适配器、电缆以及交换机端口的缩减，都会有助于同时降低CAPEX和OPEX，相应地，也能在实际空间租用、电力及冷却方面带来更好的经济效益。这样的统一光纤还支持“一次连接”模式，降低了部署周期，而后者正是推广云IaaS服务的重要目标。

更重要的是引入FCoE并不需要对整个DC来个彻底翻修，在接入层实现FCoE，不但能获取统一互连阵列绝大多数的优势，同时也能无缝且无害地集成到现有的FC附加终端设备中。

9.5 架顶式体系结构案例学习

当私有云计算最开始还在地平线那端若隐若现时，企业就再也按捺不住对DC的灵活性及移动性的需求。当进行DC基础设施扩充或扩展时，时间不得不花在更多的设备或传输升级、更多的供电或冷却排放、更多的电线电缆、更多的设备租用空间占用等方面。未来企业需要的是模块式的DC基础设施，它们具备“rack-at-a-time”部署能力，能够在几个小时就完成组合而不是拖延到几天甚至几个星期才能完成。为了获得这样的能力，应该预先在机架中配置好服务器（例如，采用机架或刀片外形），以及预安装的供电系统、网络以及存储电缆。

架顶式（Top-of-Rack,ToR）体系结构定义了一种“机架滚动”式部署模式，将ToR交换机放置在每个机架中，使得服务器连接能够被汇聚在一起，并且只需通过少量的，连接至列末（End-of-Row,EoR）或列中（Middle-of-Row,MoR）交换机的线缆，就能实现与其余DC基础设施的互联。

9.5.1 使用Nexus 5000和2000进行ToR设计

ToR交换机在ToR模式中扮演了一个重要的角色，如果ToR仅仅是另一种类型的接入交换机，它将有可能被现有STP拓扑融合，导致比之前模式需要更多的设置工作量。而诸如可控制性及维护性这类操作问题也会随之产生。此时，ToR模式解决了一个难题，可是又制造了一个新问题。还有更好的方法吗？有。使用光纤扩展器（Fabric Extender,FEX）而非使用接入交换机。

有关FEX的简单介绍，可以参见8.2.1节。不过，你并不需要采用UCS来实现FEX功能。本案例使用了Nexus 5000（NX5K）来搭建ToR结构，期间也考虑了Nexus 2000（NX2K）FEX。从L2角度出发，NX5K交换机以及NX2K FEX一起组成了一个逻辑接入交换机，可以获得ToR灵活性而不会产生更大范围的STP拓扑。

说明：UCS采用了相同的NX5K和NX2K组合，只是NX2K FEX位于UCS机箱的背部模块，更多相关内容，请参考本书第8章8.2.2节中的“刀片服务器机箱”及“光纤扩展器”小节。

FEX结合了ToR及EoR两者的优点，在物理上，它驻留在每个机架的顶部，形成接入层在DC机架间的分布；在逻辑上，则

类似EoR接入设备，接受NX5K的管理。从管理角度而言，FEX则像NX5K交换机的一个远程线卡，将交换机接入到虚拟机箱中。FEX不是一个单独的管理实体，NX5K通过向内传输与FEX通信，完成FEX的配置。由于FEX是NX5K交换机的一种扩展，它能够提供高度可扩展性，却不会增加管理的复杂性，也不会增加管理的节点。

通过在接入层部署NX5K/NX2K组合，DC能够建立自给自足的机架服务器，该服务器要求系统能够提供1GE连接性能，服务器只需使用少量10GE光纤或者CX-1型铜接头，就能连接到一个EoR或者是MoR交换机（NX5K），减少了不必要的水平线缆布线。

说明：FEX不支持本地交换，转发是基于VNTag完成的，可以把VNTag看成是一个携带了“源/目标接口”信息的标示符。更多有关VNTag的信息，请参考第8章8.2.1节中的“VNTage”小节。

9.5.2 ToR设计样例：附加1GE服务器

NX5K是10Gbps交换机，为了适应那些还继续使用1Gbps进行LAN传输的老式LAN环境，以及那些拥有一个独立FC存储的环境，可以采用NX2K FEX将NX5K LAN交换光纤扩展至封装在外部FEX的1Gbps端口上，从而有效地将NX5K交换机转变成了一个高密度、1GE接入层交换机，在现有的企业LAN基础设施与云IaaS服务要求的面向服务的基础设施（Service-Oriented Infrastructure,SOI）之间提供了一条平滑的迁移路径。

企业“J”刚刚开启私有云计算，希望能够向频道合作伙伴以及外部顾客提供云IaaS服务，然而，DC中现有的1-Gbps服务器池，尽管还不到2年时间，但看起来似乎成了主要障碍。特别是里面有24个机架，每一个机架都存放了20台服务器，总共是480个服务器。IT管理部门非常了解FCoE和统一DC光纤的优势，但此刻这些服务器能够在一个单独的LAN和FC基础设施的支撑下运行。在3个月内，模块化/移动化现有的24个服务器机架以简化一个软件云IaaS展示是企业“J”当前的首要议题。

在本案例学习中，“J”企业采用了FEX直通（例如，单端口）部署方法。图9-11左边描绘了一个单独的NX5020交换机，该交换机拥有12个NX2148T FEX（等同于12×48=576主机接口）。图9-11右边展示了一个典型的冗余部署，该方案使用了2组和图9-11左边一样的设置（2×576主机接口），以及一个双端口服务器，该服务器拥有一条主活动链路以及一个从备份链路。

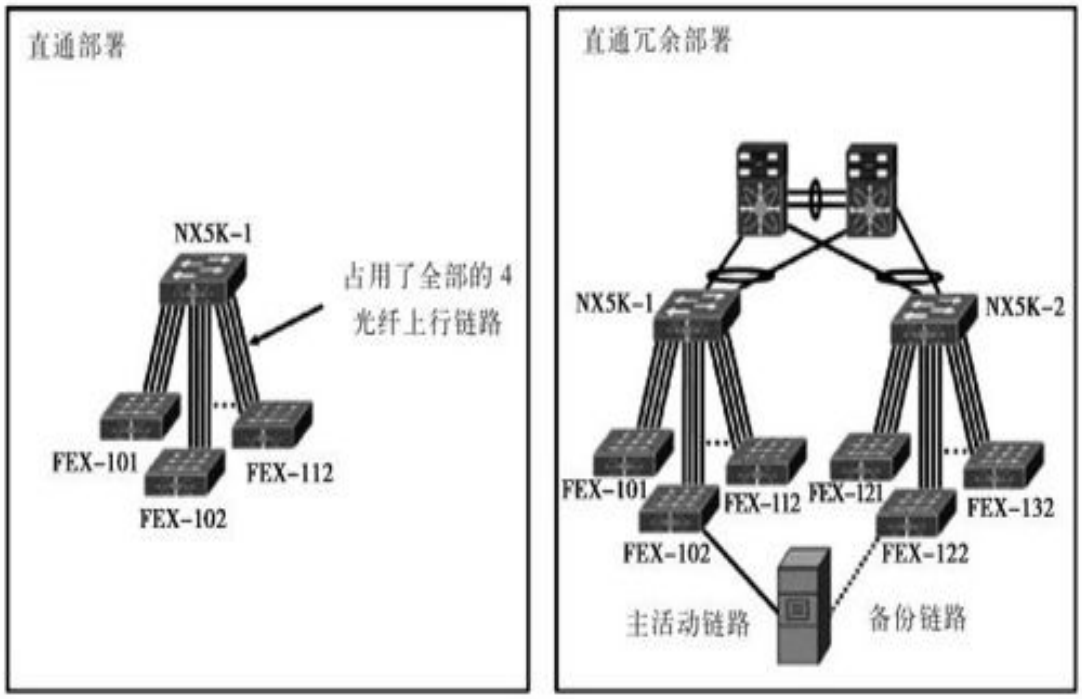


图　9-11　FEX直通部署

说明：NX2148T FEX能够同时提供多达4个SFP+10G上行链路，既可以支持10G SPF+光纤收发器，如果到NX5K交换机的距离小于10米，也可以使用CX-1直连铜缆组件。12个FEX如果利用所有的上行链路，需要占用NX5020上的48个10Gbps端口。NX5020拥有40个固定10Gbps端口以及2个扩展模块，为了满足本方案，2个扩展模块都需要被填满。例如，使用6端口10G以太网模块（N5K-M1600）来扩展每个扩展槽。

除了模块化和冗余要求，企业“J”的IT管理部门在每个机架顶部只需要一个FEX，以降低额外的硬件购买成本。图9-12展示了提议中的ToR FEX设计方案的物理拓扑，24个机架分布在两个扇区中：SECTOR-A和SECTOR-B，每一个扇区包括了12个机架，并被进一步分割成6个舱：POD-1到POD-6，每一个舱包含了2个机架，每个机架带有一个PEX。主1Gbps链路属于连接到每个舱中奇数号机架的FEX终端，而从1Gbps链路属于连接到每个舱中偶数好机架的FEX终端。每个FEX实际能够支持40个服务器/每舱，但不会发生超额认购，因为FEX上所有4个10GE上行链路都被利用了。

说明：每个机架的服务器都会分别通过单独的ToR FC交换机（MDS 9148）连接到FC SAN（SAN A和SAN B），为了简

便，没有在图中显示该部分。

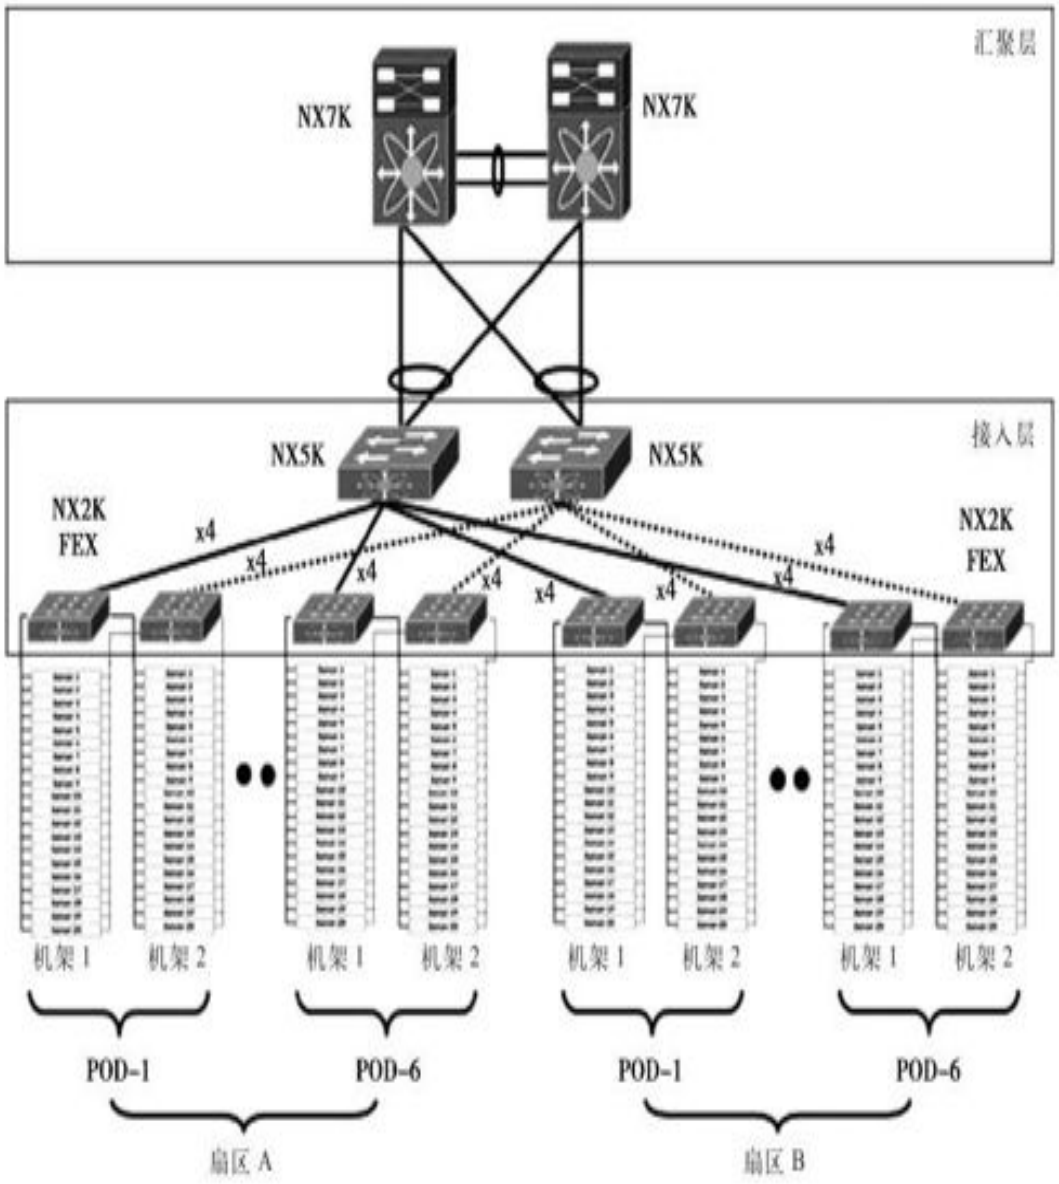


图　9-12　ToR FEX部署样例

图9-13给出了ToR FEX部署中机架的布局，每个机架当中的NX2148 FEX都连接到了两个NX5020交换机中的一个，这些交换机都被安装在EoR或MoR机架上。1GE附加服务器通过Cat5e RJ-45跳接电缆（为了简化，未在图中显示）连接到ToR FEX。光纤上行通道负责连接FEX和上行流NX5020交换机，由于所有4个FEX上行链路都派上了用场，因此从每个机架到EoR/MoR机架一共使用了4股光纤。

说明：如果读者还在怀疑，除了UCS还有特定的外部FEX能够支持10GE/FCoE主机接口吗？有。它就是Nexus 2232PP

FEX。它是一种特别的FEX，能够提供32个1/10GE/FCoE/SFP+主机接口以及8个10GE/FCoE/SFP+上行链路或者是光纤接口。

9.5.3 FEX基本配置

有2种方式能同时连接到NX2K FEX和NX5K交换机：

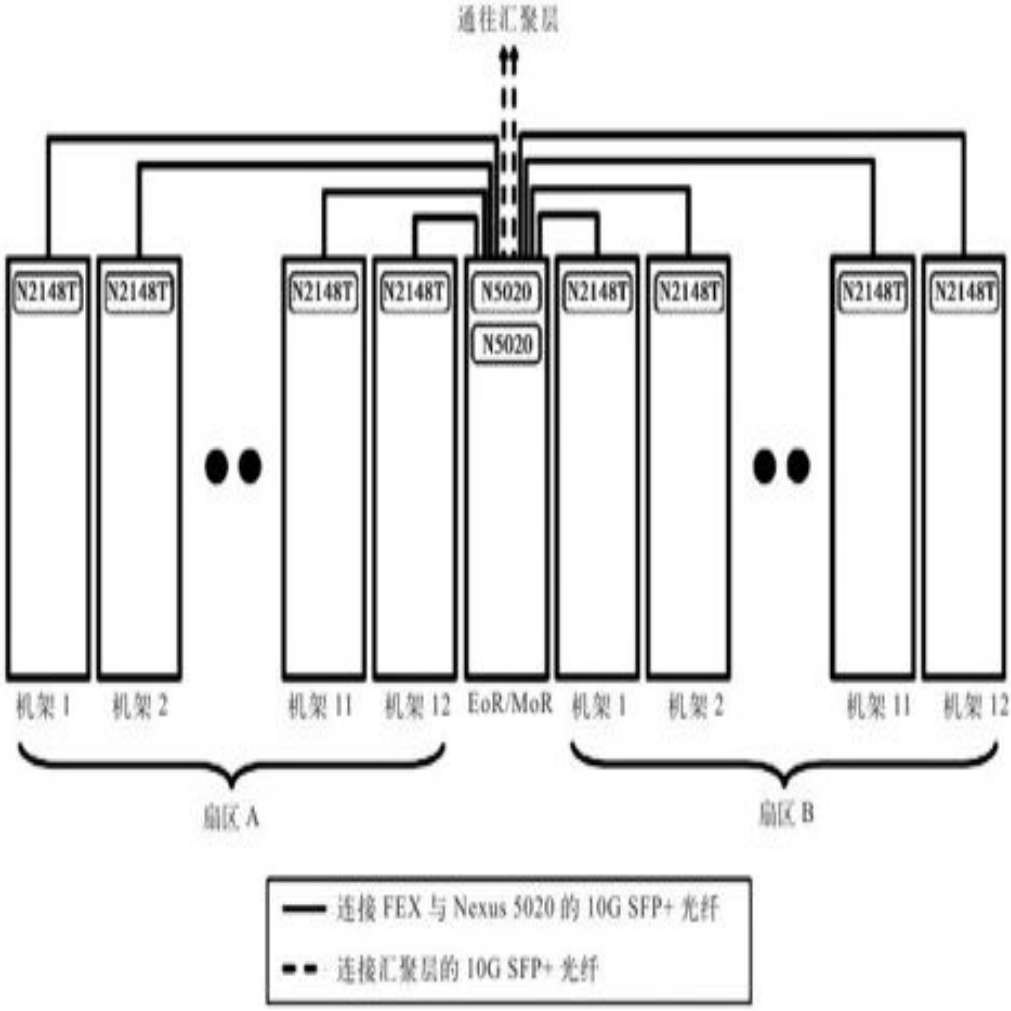


图 9-13 ToR FEX部署机架布局

·端口通道：将所有NX2K FEX与NX5K交换机之间的上行链路（最多为4）组织在一块作为端口通道，而FEX上所有的1G服务器端口（或主机接口）也都被绑定到该端口通道。网络传输将基于端口通道散列算法自动地使用剩下的上行链路，如果设计需求中要求考虑链路的可靠性及可获得性，就必须使用端口通道。

·静态绑定：NX2K FEX与NX5K交换机之间的每个上行链路都携带了FEX上一组1G服务器端口（或主机接口）数据，当上行链路发生故障时，相应的服务器端口也会保持“down”状态，直到上行链路再次恢复。

说明：在之前生成端口通道（以太网通道）时负载共享只实现了8个散列桶，如果上行链路是奇数个，则将产生非优化的负载共享。Nexus 5000和2000使用256个散列桶，使得在出现任意链路故障时，能够最小化链路之间的不平衡。可以基于L2/L3域进行散列（NX2148T就是采用这类方法的典型）。

图9-14解释了一个简单的NX5K/NX2K设置过程，每个FEX仅使用了2个上行链路（Eth1/17-18），每个FEX连接到一个主机，其中，HOST-1连接到FEX-101，HOST-2连接到FEX-121，FEX-101使用两条绑定在一起的上行链路作为连接NX5K-1的端口通道，而FEX-121也采用了同样2条上行链路，但是是以静态绑定方式连接到NX5K-2。

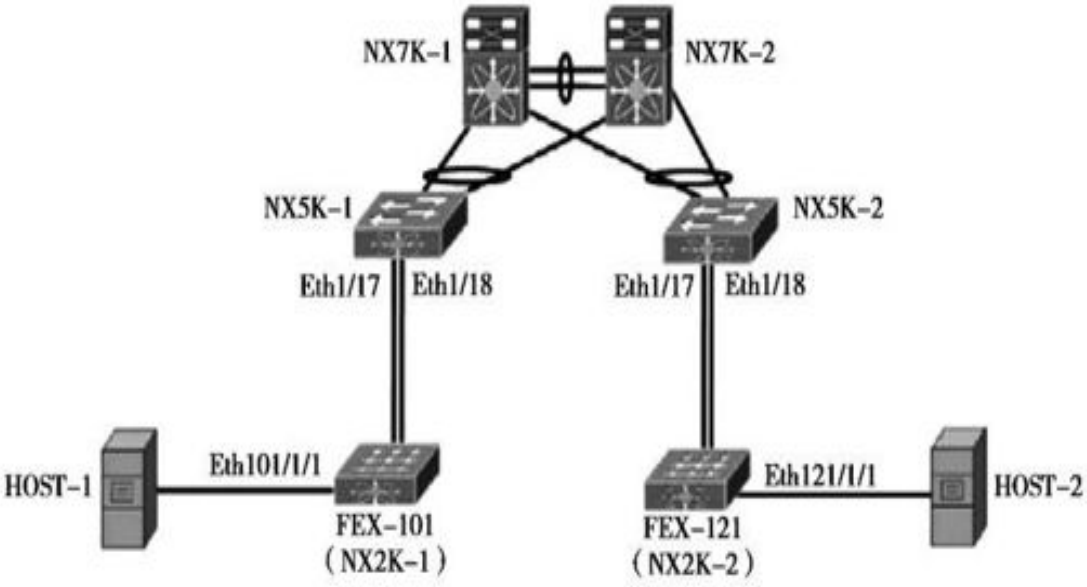


图　9-14　简单的NX5K/NX2K设置

说明：图9-14中，硬件平台由Nexus 5020P和Nexus 2148T FEX组成，Nexus 5020P交换机的操作系统为NX-OS 4.0（1a）N2（1a）。

FEX配置直接分两步完成：

·定义FEX（100-199）以及被该FEX使用的光纤上行链路（1～4）。

·配置相应的NX5K端口作为FEX-Fabric端口，并且关联到希望的FEX上。

代码清单9.7给出了一个FEX端口通道配置模板样例，“Pinning max-links”命令取值为1，因为一个端口通道被认为是单个逻辑链路。Eth1/17和Eth1/18被绑定到端口通道101，然后关联到FEX 101，FEX 101上的主机接口Ethernet101/1/1连接到VLAN 101中的HOST-1。

代码清单9.7　FEX端口通道配置模板

```
vlan 101

feature fex

fex 101
  pinning max-links 1

interface port-channel101
  switchport mode fex-fabric
  fex associate 101

interface Ethernet1/17
  switchport mode fex-fabric
  fex associate 101
  channel-group 101

interface Ethernet1/18
  switchport mode fex-fabric

  fex associate 101
  channel-group 101

interface Ethernet101/1/1
  switchport access vlan 101
```

代码清单9.8中的“show fex 101 detail”是一个输出命令，负责验证当前附加的FEX的状态。从命令输出的结果可知，FEX 101的状态为“在线”，连接到HOST-1的FEX端口（主机接口）Eth101/1/1状态也为“up”。

代码清单9.8　FEX状态验证

```
NX5K-1# show fex 101 detail
FEX: 101 Description: FEX0101   state: Online
[-----Snipped for brevity-----]
  Fabric interface state:
    Po101 - Interface Up. State: Active
    Eth1/17 - Interface Up. State: Active
    Eth1/18 - Interface Up. State: Active
  Fex Port        State  Fabric Port  Primary Fabric
      Eth101/1/1    Up      Po101       Po101
      Eth101/1/2  Down      Po101       Po101
      Eth101/1/3  Down      Po101       Po101
      Eth101/1/4  Down      Po101       Po101
      Eth101/1/5  Down      Po101       Po101
      Eth101/1/6  Down      Po101       Po101
      Eth101/1/7  Down      Po101       Po101
      Eth101/1/8  Down      Po101       Po101
      Eth101/1/9  Down      Po101       Po101
     Eth101/1/10  Down      Po101       Po101
     Eth101/1/11  Down      Po101       Po101
     Eth101/1/12  Down      Po101       Po101
     Eth101/1/13  Down      Po101       Po101
     Eth101/1/14  Down      Po101       Po101
     Eth101/1/15  Down      Po101       Po101
     Eth101/1/16  Down      Po101       Po101
     Eth101/1/17  Down      Po101       Po101
     Eth101/1/18  Down      Po101       Po101
     Eth101/1/19  Down      Po101       Po101
     Eth101/1/20  Down      Po101       Po101
     Eth101/1/21  Down      Po101       Po101
     Eth101/1/22  Down      Po101       Po101
     Eth101/1/23  Down      Po101       Po101
     Eth101/1/24  Down      Po101       Po101
     Eth101/1/25  Down      Po101       Po101
     Eth101/1/26  Down      Po101       Po101
     Eth101/1/27  Down      Po101       Po101
     Eth101/1/28  Down      Po101       Po101
     Eth101/1/29  Down      Po101       Po101
```

```
Eth101/1/30  Down      Po101      Po101
Eth101/1/31  Down      Po101      Po101
Eth101/1/32  Down      Po101      Pe101
Eth101/1/33  Down      Po101      Po101
Eth101/1/34  Down      Po101      Po101
Eth101/1/35  Down      Po101      Po101
Eth101/1/36  Down      Po101      Po101
Eth101/1/37  Down      Po101      Po101
Eth101/1/38  Down      Po101      Po101
Eth101/1/39  Down      Po101      Po101
Eth101/1/40  Down      Po101      Po101
Eth101/1/41  Down      Po101      Po101
Eth101/1/42  Down      Po101      Po101
Eth101/1/43  Down      Po101      Po101
Eth101/1/44  Down      Po101      Po101
Eth101/1/45  Down      Po101      Po101
Eth101/1/46  Down      Po101      Po101
Eth101/1/47  Down      Po101      Po101
Eth101/1/48  Down      Po101      Po101
[·····Snipped for brevity·····]
```

代码清单9.9调用了输出命令“show interface po101 fex-inf”来验证光纤接口与FEX接口（面向服务接口，也即主机接口）之间的传输映射状态。从命令输出结果可知，所有48个NX2K FEX接口都延展到了光纤端口通道101处。

代码清单9.10展示了一个FEX静态绑定配置模板样例。“pinning max-links”命令取值2，因为FEX 121采用静态绑定方法，将2条上行链路（Eth1/17和Eth1/18）连接到NX5K-2，FEX 121上的主机接口Ethernet 121/1/1连接到VLAN 121中的HOST-2。

代码清单9.11调用“show interface eth1/17 fex-intf”命令来展示光纤接口与FEX接口之间静态绑定的网络传输映射，从命令输出结果可知：FEX接口Eth121/1/1到Eth121/1/24都延展至光纤接口Eth1/17，而FEX接口Eth121/1/25到Eth121/1/48都延展至光纤接口Eth1/18。此时，连接到HOST-2的Eth121/1/1被“绑定”到光纤接口Eth1/17，这意味着：当上行链路Eth1/17“down”时，Eth121/1/1也会变成“down”状态，并一直保持该状态直到Eth1/17再次恢复为止。

代码清单9.9　端口通道方法的网络映射

```
NX5K-1# show interface po101 fex-intf
Fabric          FEX
Interface       Interfaces
---------------------------------------------
 Po101          Eth101/1/48   Eth101/1/47   Eth101/1/46   Eth101/1/45
                Eth101/1/44   Eth101/1/43   Eth101/1/42   Eth101/1/41
                Eth101/1/40   Eth101/1/39   Eth101/1/38   Eth101/1/37
                Eth101/1/36   Eth101/1/35   Eth101/1/34   Eth101/1/33
                Eth101/1/32   Eth101/1/31   Eth101/1/30   Eth101/1/29

                Eth101/1/28   Eth101/1/27   Eth101/1/26   Eth101/1/25
                Eth101/1/24   Eth101/1/23   Eth101/1/22   Eth101/1/21
                Eth101/1/20   Eth101/1/19   Eth101/1/18   Eth101/1/17
                Eth101/1/16   Eth101/1/15   Eth101/1/14   Eth101/1/13
                Eth101/1/12   Eth101/1/11   Eth101/1/10   Eth101/1/9
                Eth101/1/8    Eth101/1/7    Eth101/1/6    Eth101/1/5
                Eth101/1/4    Eth101/1/3    Eth101/1/2    Eth101/1/1
```

代码清单9.10　FEX静态绑定配置模板

```
vlan 121

feature fex

fex 121
  pinning max-links 2

interface Ethernet1/17
  switchport mode fex-fabric
  fex associate 121

interface Ethernet1/18
  switchport mode fex-fabric
  fex associate 121

interface Ethernet121/1/1
  switchport access vlan 121
```

代码清单9.11　静态绑定方法中的网络映射

```
NX5K-2# show interface eth1/17 fex-intf
Fabric         FEX
Interface      Interfaces
---------------------------------------------
 Eth1/17       Eth121/1/24   Eth121/1/23   Eth121/1/22   Eth121/1/21
               Eth121/1/20   Eth121/1/19   Eth121/1/18   Eth121/1/17
               Eth121/1/16   Eth121/1/15   Eth121/1/14   Eth121/1/13
               Eth121/1/12   Eth121/1/11   Eth121/1/10   Eth121/1/9
               Eth121/1/8    Eth121/1/7    Eth121/1/6    Eth121/1/5
               Eth121/1/4    Eth121/1/3    Eth121/1/2    Eth121/1/1
NX5K-2# show interface eth1/18 fex-intf
Fabric         FEX
Interface      Interfaces
---------------------------------------------
 Eth1/18       Eth121/1/48   Eth121/1/47   Eth121/1/46   Eth121/1/45
               Eth121/1/44   Eth121/1/43   Eth121/1/42   Eth121/1/41
               Eth121/1/40   Eth121/1/39   Eth121/1/38   Eth121/1/37
               Eth121/1/36   Eth121/1/35   Eth121/1/34   Eth121/1/33
               Eth121/1/32   Eth121/1/31   Eth121/1/30   Eth121/1/29
               Eth121/1/28   Eth121/1/27   Eth121/1/26   Eth121/1/25
```

9.6 基础vPC设计学习

大规模虚拟端口通道（Virtual PortChannel,vPC）设计相对比较复杂，因此本案例学习的范围将局限在vPC设计基础方面。所有复杂的设置都基于简单的部件，这一思想也适用于vPC。更多有关vPC基本概念的信息，请参考2.5.1节。本小节将直接探索有关vPC配置问题，但是在开始讨论之前，让我们快速回顾一下与本案例学习有关的一些vPC技术。

·vPC：vPC peer设备以及下行流设备间所绑定的端口通道。

·vPC peer设备：设备对中的一个设备连接到特定的端口通道，这样的端口通道也被称为vPC peer链路。

·vPC peer链路：用来对vPC peer设备之间进行状态同步的链路，链路两端都必须位于10GE接口上。

·vPC域：域由两个vPC peer设备组成，同时也可以作为配置模式，来配置某些vPC peer-keepalive链路的参数。

·vPC peer-keepalive链路：peer-keepalive链路是一个vPC peer设备之间的L3链路，能够确保两端设备都处于“up”状态。当网络为带外管理模式时，通过这样的备份或容错（FT）链路在vPC peer设备之间发送可配置的、周期性的keepalive消息。

·vPC成员端口：属于vPC的vPC peer设备的物理接口。

简言之，vPC克服了生成树协议（Spanning Tree Protocol,STP）的局限性（更多细节请参考2.5节的相关内容）。现有DC拓扑从基于STP模式迁移到基于vPC模式，能够获得以下好处：

·允许一个下行流设备使用单独的端口通道穿越两个上行流设备。

·不需要借助STP的帮助，就能实现无环拓扑。

·减少了被STP封锁的端口。

·能够利用所有可得的上行链路带宽，而这一点之前STP是无法办到的。

·如果有某个链路或设备（节点）发生故障，缩短了会聚时间（与STP相比）。

·确保链路级的可靠性及高可获得性。

基本的vPC配置

“K”企业希望从一个不同的角度来处理他们的私有云计算初始化问题，不同于直接从物理或虚拟接入层启动，“K”企业希望从汇聚层而非物理接入层开始工作。IT管理部门赞同采用vPC来改造企业现有STP的方案，长期以来，STP已经成为他们的噩梦，现在他们终于等到这一天了。企业“K”购买了一对Nexus 7010（NX7010）和Nexus 5020（NX5020）交换机，希望用NX7010交换机加上vPC来代替企业当前的Cat6K汇聚层交换机，并结合NX5020交换机一起构造一个支持10GE/FCoE的物理接入层。Cat6K交换机在服务汇聚层最后将被当做服务器机箱（更多细节请参考3.1节的相关内容）。

说明：除了汇聚层，也可以在核心层或接入层来实现vPC。

图9-15展示了利用两台Nexus7010和两台Nexus5020交换机构建一个简单vPC的样例。我们将以此图为基础，在后续章节中完成以下内容的讨论，包括：

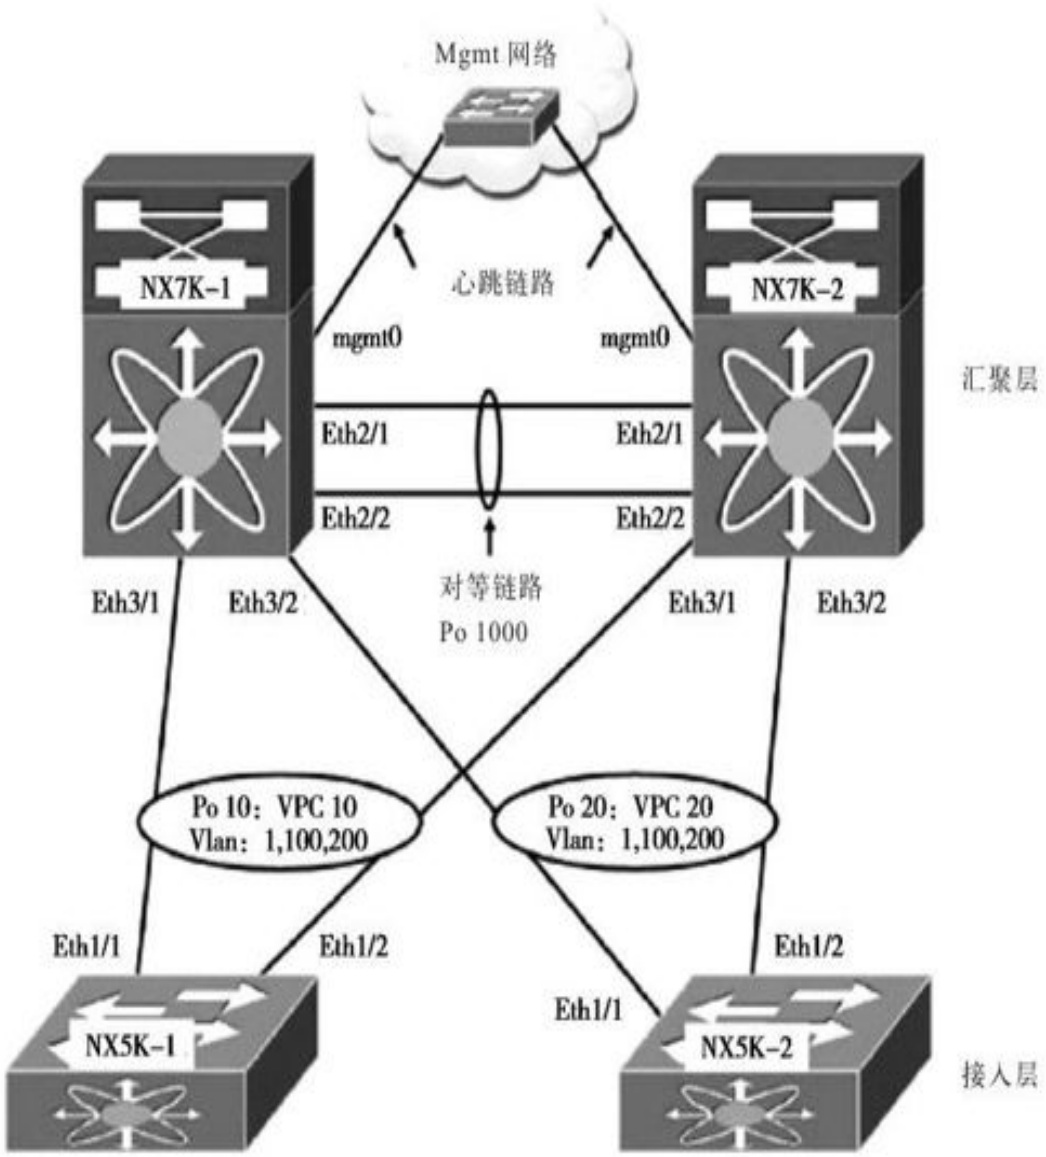


图　9-15　简单的vPC设置

·配置vPC域

·配置vPC peer链路

·配置vPC

上述配置（或代码）都基于图9-15的描述内容。

说明：图9-15中的两台Nexus 7010交换机的NX-OS版本为5.0（3）。

图9-15中，NX7K-1和NX7K-2均为vPC peer设备，端口通道1000是NX7K-1和NX7K-2之间的vPC peer链路，将接口Eth2/1和Eth2/2分别绑定到这些交换机上，在NX7K-1的管理接口

（mgmt0）和NX7K-2之间通过带外管理网络建立了一条vPC peer-keepalive链路。即可偶Eth3/1和Eth3/2构成了交换机之间vPC成员端口。

说明：在实现vPC时，vPC peer设备或物理节点最多为2个。

vPC部署的基本步骤包括：

1.在两个vPC peer交换机（NX7K-1和NX7K-2）上配置全局性的vPC域。

2.在两个vPC peer设备间配置并建立一个peer-keepalive链路。

3.在两个vPC peer交换机重用或新创建一个内部交换机端口通道。

4.将内部交换机端口通道配置成两个vPC peer设备间的peer链路（要保证这一步能正确执行）。

5.重用或重新创建端口通道，形成双附接下行流设备（NX5K-1和NX5K-2）。

6.配置一个唯一逻辑vPC，加入这些穿越在vPC peer交换机之间面向接入层的端口通道。

说明：为了确保能成功建立vPC域，peer-keepalive必须可控。

配置vPC域

代码清单9.12和代码清单9.13分别描绘了为NX7K-1和NX7K-2配置vPC域的过程。

代码清单9.12　配置NX7K-1的vPC域

```
feature vpc

vpc domain 10
  role priority 1000
  peer-keepalive destination 10.10.10.2 source 10.10.10.1

interface mgmt0
  ip address 10.10.10.1/24
```

代码清单9.13　配置NX7K-2的vPC域

```
feature vpc

vpc domain 10
  role priority 2000
  peer-keepalive destination 10.10.10.1 source 10.10.10.2

interface mgmt0
  ip address 10.10.10.2/24
```

可以调用“feature vpc”命令来激活交换机上的vPC，可以使用“vpc domain 10”命令在两台交换机上都创建一个vPC域10。

说明：vPC域的ID与多vPC层（多层vPC）不同，基于LACP的配置允许使用唯一的L2链路汇聚ID。

vPC域同时也是配置角色优先级以及keep alive的配置模式，当实现一个vPC时，一对vPC peer交换机会被当做一个STP实体，vPC角色定义了由两个vPC peer中的哪一个来处理BPDU？优先级较低的将取得控制权。如果是线路中断器，则较小的系统MAC地址会取得控制权。在本例中，NX7K-1被配置成主vPC peer，角色权限为1000，NX7K-2被配置成从vPC peer，角色权限为2000。如果发生peer-link故障，将由peer交换机的vPC角色来决定后续行为（更多细节请参考本书第2章的相关内容）。

说明：主vPC peer设备通常与STP根和主HSRP peer是同一设备。

在设置过程中，通过管理模块的管理接口（mgmt0），带外管理网络可以被用作成peer-keepalive（容错）链路连接，可以通过调用“peer-keepalive”命令实现NX7K-1和NX7K-2的IP地址对等处理实现这个功能。

说明：推荐使用独立端口，特别是1GE，作为连接vPC peer设备间（不一定需要直接链路）的peer-keepalive链路，这样的端口应该属于某个单独的VRF。管理接口（mgmt0）默认属于管理VRF，也是唯一被认可是该VRF的接口部分，NX-OS默认创建该管理VRF。

端口3200上的peer keepalive是一个UDP消息，长96字节（有效长度为32字节），包括了版本、时间戳、域ID以及本地及远程IP地址信息。它构成了两个vPC peer交换机之间的心跳，用于双活（非peer-link）检测。

vPC peer keepalive的过程分成三步：

·Keepalive间隔：vPC peer-keepalive消息的默认间隔为1s，可以配置范围为400ms～10s。

·Keepalive允许的超时范围：默认允许超时为3s（可配置范围为3～10s）。当vPC peer链路失效时，定时器开始计时，在这段超时范围内，从vPC peer设备将忽略vPC peer-keepalive消息，这种方法能够在vPC活动开始之前网络会聚。设置keepalive允许超时，是为了防止发生假阳情况。

·Keepalive超时：默认超时时间为5s（可配置成3～20s），当已经过了之前系统允许的超时时间后，定时器开始计时，在超时阶段开始后，从vPC peer设备将检查来自主vPC peer设备的vPC peer-keepalive hello消息，如果从vPC peer设备只收到一个hello消息，它将禁用从vPC peer设备上所有的vPC接口。

说明：默认keepalive定时器是允许修改的，可以作为“peer-keepalive”命令的附加参数，放在目标及源域后面。

如代码清单9.14所示，“show vpc peer-keepalive”命令可以验证peer keepalive链路是否处在可控状态，也可以检测某些vPC keepalive参数。

代码清单9.14　vPC keepalive状态和参数

```
vPC keep-alive status          : peer is alive
--Peer is alive for            : (8) seconds, (886) msec
--Send status                  : Success
--Last send at                 : 2010.11.29 12:20:47 5 ms
--Sent on interface            : mgmt0
--Receive status               : Success
--Last receive at              : 2010.11.29 12:20:46 753 ms
--Received on interface        : mgmt0
--Last update from peer        : (0) seconds, (807) msec

vPC Keep-alive parameters
--Destination                  : 10.10.10.1
--Keepalive interval           : 1000 msec
--Keepalive timeout            : 5 seconds
--Keepalive hold timeout       : 3 seconds
--Keepalive vrf                : management
--Keepalive udp port           : 3200
--Keepalive tos                : 192
```

当部署vPC peer-keepalive链路时还需要注意以下原则：

·不能在peer链路上路由keepalive消息。

·如果系统配有冗余的管理器，当使用管理器管理接口来传输vPC peer keepalive时，不要让它们在两个peer交换机之间进行连续连接，这是因为当前时刻只能有一个管理端口是活动端口，而管理器交换将可能破坏peer-keepalive链路的连接性。

·带外管理网络要配合管理接口，两者之间有一个管理交换机（如图9-15所示）。

vPC peer链路配置

代码清单9.15对NX7K-1和NX7K-2的vPC peer链路配置进行了说明，两台交换机上的peer链路配置是对称的，此外还包括了使用“vpc peer-link”命令进行常规端口通道配置。

在静态链路汇聚中，使用链路汇聚控制协议（Link Aggregation Control Protocol,LACP）来实现平滑的故障恢复以及错误配置保护。在接口配置时，可使用全局“feature lacp”命令激活该协议和带“active”关键字的“channel-group”命令激活（更多有关LACP的介绍，请参考2.5.2节的相关内容）。

代码清单9.15　vPC peer链路配置

```
feature lacp

interface port-channel1000
  switchport
  switchport mode trunk
  vpc peer-link
  switchport trunk allowed vlan 1,100,200
  spanning-tree port type network

interface Ethernet2/1
  switchport
  switchport mode trunk
  switchport trunk allowed vlan 1,100,200
  channel-group 1000 mode active
  no shutdown

interface Ethernet2/2
  switchport
  switchport mode trunk
  switchport trunk allowed vlan 1,100,200
  channel-group 1000 mode active
  no shutdown
```

说明：“spanning-tree port type network”命令能够激活链路的桥接保证（Bridge Assurance,BA）特性，BA促使交换机向所有可控端口发送BDUP信息，信息里包含了端口类型设置为“network”以及每次握手间隔的替换及备用端口信息。如果某个邻近端口拒绝接收BPDU，该端口将设置成“阻隔”状态，如果被阻隔的端口重新开始接收BPDU信息，则通过常规的快速VLAN生成树（Rapid-Per-VLAN-Spanning-Tree,RPVST）转换，将阻隔状态恢复到常态。这种双向握手机制能够避免由于无向链路或骨干交换机而引起的回路。

代码清单9.16中，NX7K-1调用“show vpc brief”命令来验证vPC peer链路的状态，从命令输出结果可知，端口通道1000（Po1000）工作正常。

代码清单9.16　vPC peer链路状态

```
NX7K-1# show vpc brief
[------Snipped for brevity------]

vPC domain id                     : 10
Peer status                       : peer adjacency formed ok
vPC keep-alive status             : peer is alive
Configuration consistency status: success
[------Snipped for brevity------]
vPC role                          : primary
[------Snipped for brevity-----]

vPC Peer-link status
---------------------------------------------------------------
id   Port   Status Active vlans
---  -----  --------------------------------------------------
1    Po1000 up     1,100,200
```

当进行vPC peer链路部署时，要注意以下规则和建议：

·尽管vPC peer链路属于标准的802.1Q汇聚，能够同时支持vPC和非vPC VLAN，我们更推荐将不同的内部交换机端口通道上的这两类链路分离开来。

·鉴于peer链路属于点到点模式，因此不应该在vPC peer之间插入其他设备。

·为了获得最好的可靠性，推荐在每个peer交换机上的分离模块中最少使用2个10GE端口。

·对于NX7K交换机上使用超额认购技术的模块（例如，32-port 10GE以太网模块），应该指定10GE端口，而不是共享这些端口（代码清单9.15使用了共享模式）。

更多有关vPC peer链路的详细内容，请参见2.5.3节。

说明：NX7K 32端口10GE以太网模块可以以线性速率分布8个端口，或最多允许32个端口共享80Gbps的带宽，这些端口被分成8个组，每组4个端口。在指定模式中，每组的第一个端口是主端口，拥有线性速率性能，其他3个端口都被禁用。在共享模式下，每个组的所有4个端口都是活动的。NX-OS支持每个组分别采用不同的配置模式，既可以是指明模式，也可以是共享模式。用户可以调用“show interface EthX/Y capabilites/include

Members”命令（X为模块序号，Y为端口号）来确定其他与EthX/Y相连的组成员，以及该端口组的第一个端口。

配置vPC

代码清单9.17展示了NX7K-1和NX7K-2的vPC配置，就像其他peer链路配置，两个peer交换机的vPC配置也是对称的。除了要配置标准的端口通道外，还需要调用“vpc < number > ”命令。代码清单9.17中，端口通道10（Po0）与VPC 10关联，而端口通道20（Po20）与VPC 20关联。

可以调用“channel-group 10”命令将Eth3/1加入到Po 10，成为与vPC 10关联的vPC成员端口。同样，也可以调用“channel-group 20”命令将Eth3/2加入到Po 20，成为与vPC 20关联的vPC成员端口。

说明：vPC成员端口应该属于10GE接口。

代码清单9.17　vPC配置

```
interface port-channel10
  switchport
  switchport mode trunk
  vpc 10
  switchport trunk allowed vlan 1,100,200

interface port-channel20
  switchport
  switchport mode trunk
  vpc 20
  switchport trunk allowed vlan 1,100,200
```

```
interface Ethernet3/1
  switchport
  switchport mode trunk
  switchport trunk allowed vlan 1,100,200
  channel-group 10 mode active
  no shutdown

interface Ethernet3/2
  switchport
  switchport mode trunk
  switchport trunk allowed vlan 1,100,200
  channel-group 20 mode active
  no shutdown
```

说明：为了避免产生不一致，vPC peer间的vPC成员端口配置必须要匹配，不过并不要求每个vPC peer的成员端口序号一致。

代码清单9.18和代码清单9.19分别展示了对NX5K-1及NX5K-2的标准端口通道配置，Eth1/1和Eth1/2分别与NX5K-1的端口通道10以及NX5K-2的端口通道20关联，NX5K-1和NX5K-2均为双附属连接至vPC域，Eth1/1连接到NX7K-1，Eth1/2连接到NX7K-2，尽管这些接口都被绑定到同一端口通道。这种方式能够确保在peer链路发生故障时对系统的危害性最小，并能持续保持vPC双活模式（更多有关双活模式场景，请参考2.5.2节的相关内容）。

代码清单9.18　NX5K-1端口通道配置

```
interface port-channel10
  switchport mode trunk
  switchport trunk allowed vlan 1,100,200

interface Ethernet1/1
  switchport mode trunk
  switchport trunk allowed vlan 1,100,200
  channel-group 10 mode active

interface Ethernet1/2
  switchport mode trunk
  switchport trunk allowed vlan 1,100,200
  channel-group 10 mode active
```

代码清单9.19　NX5K-2端口通道配置

```
interface port-channel20
  switchport mode trunk
  switchport trunk allowed vlan 1,100,200

interface Ethernet1/1
  switchport mode trunk
  switchport trunk allowed vlan 1,100,200
  channel-group 20 mode active

interface Ethernet1/2
  switchport mode trunk
  switchport trunk allowed vlan 1,100,200
  channel-group 20 mode active
```

如代码清单9.20所示，调用“show port-channel summary”命令来验证NX7K-1和NX7K-2上vPC成员端口的状态，在NX7K-1和NX7K-2重复“show vpc brief”命令，从命令的输出结果可知，vPC10/Po10以及vPC20/Po20工作状态正常。

代码清单9.20　vPC状态检测

```
NX7K-1# show port-channel summary
Flags:  D - Down         P - Up in port-channel (members)
        I - Individual   H - Hot-standby (LACP only)
        s - Suspended    r - Module-removed
        S - Switched     R - Routed
        U - Up (port-channel)
--------------------------------------------------------------------------------
Group Port-       Type     Protocol     Member Ports
      Channel
--------------------------------------------------------------------------------
10    Po10(SU)    Eth      LACP         Eth3/1(P)
20    Po20(SU)    Eth      LACP         Eth3/2(P)
1000  Po1000(SU)  Eth      LACP         Eth2/1(P)   Eth2/2(P)

NX7K-1# show vpc brief
[----Snipped for brevity----]

vPC domain id                     : 10
Peer status                       : peer adjacency formed ok
vPC keep-alive status             : peer is alive
Configuration consistency status: success
[----Snipped for brevity----]
vPC role                          : primary
Number of vPCs configured         : 2
[----Snipped for brevity----]
vPC Peer-link status
--------------------------------------------------------------------
id    Port   Status Active vlans
---   -----  --------------------------------------------------
1     Po1000 up     1,100,200

vPC status
----------------------------------------------------------------------------
id    Port   Status Consistency Reason                Active vlans
---   -----  --------------------------------------------------
10    Po10   up     success     success               1,100,200
20    Po20   up     success     success               1,100,200
```

9.7 SAN扩展设计案例学习

本节SAN扩展设计案例分析的焦点在FCIP，我们的目标是调整某企业当前IP基础设施及管理资源，使它们能够连接及扩展已有的本地FC SAN，提供私有云计算及云IaaS服务。FCIP解决方案同样克服了长距离物理（＞10，000km）限制，关于FCIP的简介，请参考7.4.1节的相关内容。

简单的FCIP设计样例

企业“L”决定采用另外一种私有云计算方式，企业采用从上至下的垂直管理模式，因此，企业可能在6个月之内需要将现在的伦敦总部与香港分部互换一下。

从企业角度出发，商业持续性（Business Continuity,BQ）及灾难恢复（Disaster Recovery,DR）比其他任何事情都重要，而IT管理部门更愿意首先解决从伦敦到香港的DC迁移，或者将现有FC SAN从企业DC扩展到区域DC。私有云计算及云IaaS实施将紧随SAN扩展之后。最初的IaaS用户对象将来自亚太（Asia Pacific,APAC）区。

在企业DC及区域DC间的FCIP最开始是点到点方式，在之后阶段，会有更多APAC站点加入，应该转移到集中星型拓扑（更多细节请参考7.4.2节的相关内容）。由于系统设备都采用了远程备份及主机镜像技术，因此对两个站点间的带宽及时延限制在此处并不像之前那样严格，将来也可以采取异步复制等机制，但此时并不重要。

只是企业“L”必须要严格保证实现短恢复时间的目标（更多细节，请参见7.1.1节）。换句话说，FCIP的设计方案必须要考虑到HA机制的健壮性，使得故障时间最短。此外，SAN扩展初期将只会牵涉到区域DC，并不会涉及总部DC的FC启动器以及FC目标。

图9-16给出了一个站点A（总部DC）与站点B（区域DC）之间的点到点FCIP设置的模拟示意图。JBOD-1（配备了6个磁盘），HOST-11和HOST-12都在VSAN 100内，连接到FC交换机MDS-1处，而HOST-21和HOST-22在VSAN 200内，连接到FC交换机MDS-2处。接下来的动作都将以图9-16展示的部署为基础：

·配置FICP HA

·配置VSAN和inter-VSAN路由

接下来这两小节的内容都将以图9-16部署为基础。

说明：这对MDS 9216A交换机在图9-16中承担了FC交换机功能，其SAN-OS版本为3.3（3），每个交换机都配备了8端口IP存储服务模块，以及一个16端口光纤通道交换机模块。

FCIP HA配置

MDS-1与MDS-2的FCIP HA配置如代码清单9.21与代码清单9.22所示。

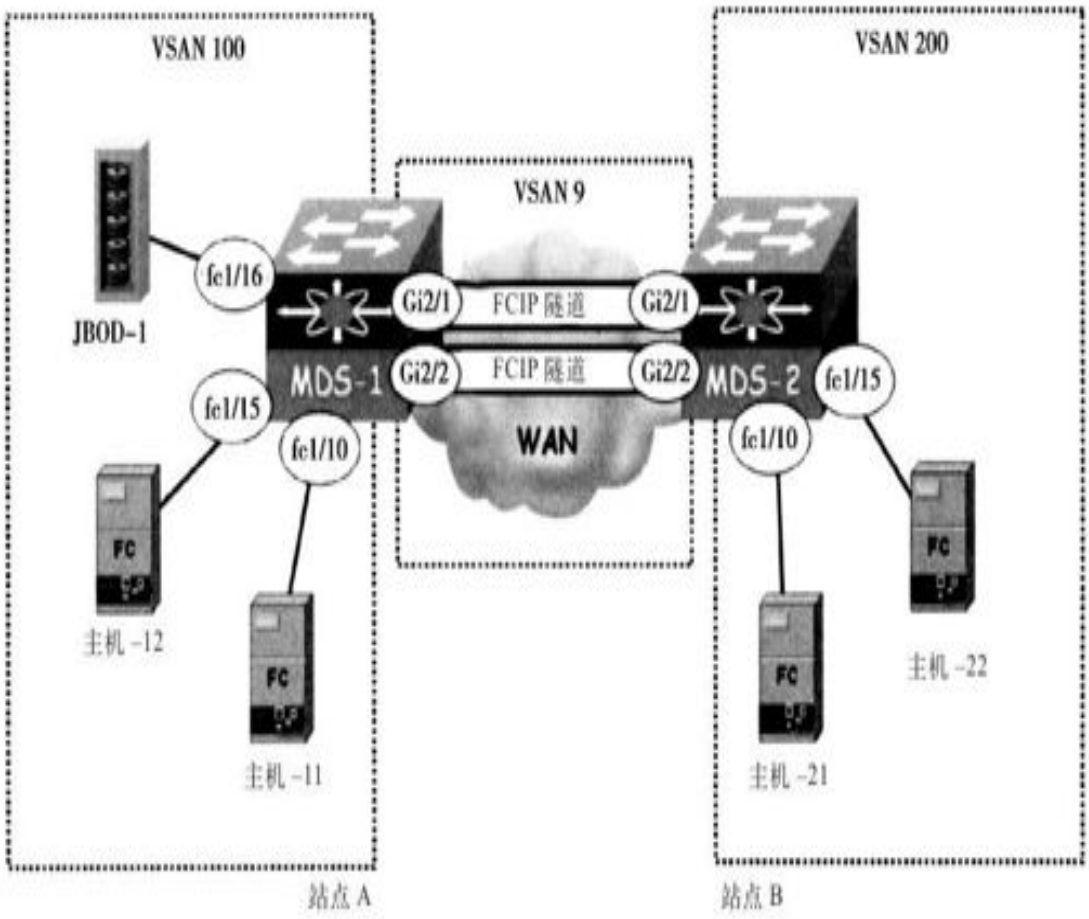


图　9-16　简单的点到点FCIP设置

代码清单9.21　MDS-1 FCIP HA配置

```
interface GigabitEthernet2/1
  ip address 172.16.100.1 255.255.255.0
  no shutdown

interface GigabitEthernet2/2
  ip address 172.16.200.1 255.255.255.0
  no shutdown

interface port-channel 10
  channel mode active

fcip enable

fcip profile 1
  ip address 172.16.100.1

fcip profile 2
  ip address 172.16.200.1

interface fcip1
  channel-group 10 force
  use-profile 1
  peer-info ipaddr 172.16.100.2
  no shutdown

interface fcip2
  channel-group 10 force
  use-profile 2
  peer-info ipaddr 172.16.200.2
  no shutdown
```

代码清单9.22　MDS-2 FCIP HA配置

```
interface GigabitEthernet2/1
  ip address 172.16.100.2 255.255.255.0
  no shutdown

interface GigabitEthernet2/2
  ip address 172.16.200.2 255.255.255.0
  no shutdown

interface port-channel 10
  channel mode active

fcip enable

fcip profile 1
  ip address 172.16.100.2

fcip profile 2
  ip address 172.16.200.2

interface fcip1
  channel-group 10 force
  use-profile 1
  peer-info ipaddr 172.16.100.1
  no shutdown

interface fcip2
  channel-group 10 force
  use-profile 2
  peer-info ipaddr 172.16.200.1
  no shutdown
```

标准的FCIP HA配置步骤如下所示：

·将千兆以太网接口配置分配给相应的FCIP参数文件，在代码清单9.21及代码清单9.22中，分别为Gig2/1与Gig2/2。

·创建端口通道，在代码清单9.21及代码清单9.22中，为端口通道10（Po10），调用“channel mode active”命令，将通道模式设置成活动模式。

·调用“fcip enable”命令，启动FCIP特性。

·配置FCIP参数文件，读者可以在文件中使用不同参数，在代码清单9.21及代码清单9.22中，FCIP参数文件1中本地IP地址为Gig2/1，FCIP参数文件2中本地IP地址为Gig2/2。

·配置FCIP接口，在代码清单9.21及代码清单9.22中，接口ficp1和fcip2接口配置如下：

·调用“channel-group 10”命令，将ficp1和fcip2添加到Po0。

·调用“use-profile”命令，将FCIP参数文件1分配到接口fcip1，FCIP参数文件2分配到接口fcip2。

·调用“peer-info ipaddr”命令，将相应的对等IP地址信息分配给接口ficp1和接口fcip2。

·调用“no shutdown”命令，启动fcip1和fcip2接口。

说明：FCIP接口为FCIP链路（或FCIP隧道）的本地端点以及VE_Port接口。所有FCIP与E_Port参数都在FCIP接口上下文中配置完成。更多细节，请参考本书第7章“VE_Port”与“FCIP链路与虚拟ISL”相关内容。

如代码清单9.23所示，执行“show fcip profile < id > ”命令后，可以得到当前配置好的FCIP参数文件的状态信息，对FCIP参数文件状态进行验证。

代码清单9.23　FCIP参数文件验证

```
MDS-1# show fcip profile 1
FCIP Profile 1
    Internet Address is 172.16.100.1  (interface GigabitEthernet2/1)
    Tunnels Using this Profile: fcip1
    Listen Port is 3225
[-----Snipped for brevity-----]

MDS-1# show fcip profile 2
FCIP Profile 2
    Internet Address is 172.16.200.1  (interface GigabitEthernet2/2)
    Tunnels Using this Profile: fcip2
    Listen Port is 3225
[-----Snipped for brevity-----]

MDS-2# show fcip profile 1
FCIP Profile 1
    Internet Address is 172.16.100.2  (interface GigabitEthernet2/1)
    Tunnels Using this Profile: fcip1
    Listen Port is 3225
[-----Snipped for brevity-----]

MDS-2# show fcip profile 2
FCIP Profile 2
    Internet Address is 172.16.200.2  (interface GigabitEthernet2/2)
    Tunnels Using this Profile: fcip2
    Listen Port is 3225
[-----Snipped for brevity-----]
```

还有一种比较便捷的方法能够验证本地MDS交换机上的FCIP接口状态信息，调用“show fcip summary”命令，如代码清单9.24所示。根据命令输出结果可知，隧道1（fcip1）和隧道2（fcip2）工作正常，并且启动了汇聚（结果显示为TRNK）功能。

代码清单9.24　FCIP接口状态信息

```
MDS-1# show fcip summary
--------------------------------------------------------------------------
Tun  prof   Eth-if   peer-ip      Status T W T Enc Comp  Bandwidth   rtt
                                        E A A           max/min    (us)
--------------------------------------------------------------------------
1    1    GE2/1     172.16.100.2    TRNK  Y N N  N   N   1000M/500M  1000
2    2    GE2/2     172.16.200.2    TRNK  Y N N  N   N   1000M/500M  1000
MDS-2# show fcip summary
--------------------------------------------------------------------------
Tun  prof   Eth-if   peer-ip      Status T W T Enc Comp  Bandwidth   rtt
                                        E A A           max/min    (us)
--------------------------------------------------------------------------
1    1    GE2/1     172.16.100.1    TRNK  Y N N  N   N   1000M/500M  1000
2    2    GE2/2     172.16.200.1    TRNK  Y N N  N   N   1000M/500M  1000
```

说明：TRNK状态意味着隧道工作在TE模式下，也就是说FCIP接口此时被当做了汇聚扩展端口（trunking expansion port,TE_Port）。其余的缩写包括WA（写加速）、TA（磁带加速）、Enc（封装）以及Comp（压缩）都属于高级的FCIP功能，在代码清单9.21及代码清单9.22中未激活。更多有关这些功能的详细内容，请参考7.4.4节的相关内容。

正如代码清单9.25展示的那样，调用“show port-channel database”命令，可以得到当前端口通道数据库中本地MDS交换机上已配置好的端口通道状态信息。从输出结果可知，ficp1和fcip2两个FCIP接口都注册为“up”状态，说明它们已成功地连接到Po10上，星号是指该端口味Po10中可操作的第一个端口。

代码清单9.25　FCIP端口通道数据库

```
MDS-1# show port-channel database
port-channel 10
    Administrative channel mode is active
    Operational channel mode is active
    Last membership update succeeded
    First operational port is fcip1
    2 ports in total, 2 ports up
    Ports:   fcip1    [up] *
             fcip2    [up]
```

VSANs配置与inter-VSAN路由

在端口通道配置FCIP接口不仅可以调节通过FCIP隧道的负载平衡，实现带宽优化，还能够融合HA功能。如果某条链路发生故障，此前由该链路负责的网络流将被切换到余下的其他链路上继续传输，而这些切换对上层协议都是透明的。FSPF路由表也不会被链路故障而影响，因此不但不会对故障恢复产生破坏，还可以提高故障恢复速度。

推荐将配置好的端口通道放在过路虚拟化存储区域网络（Virtual Storage Area Network,VSAN）内，而不是将它当做汇聚端口使用。这样可以确保任何与WAN相关的故障（例如，WAN链路摆动/故障）所产生的不利影响被限制在过路VSAN之内，而不会影响到本地VSAN。由于端口通道是非汇聚链路，并且位于单独的VSAN内（过路的VSAN），因此要求VSAN间路由（Inter-VSAN Routing,IVR）负责不同VSAN之间的FC帧路由转发。图9-16中，VSAN 9属于过路的VSAN，因此要在VSAN 9和VSAN 100和VSAN 200之间建立IVR。

说明：FC中的VSAN类似以太网中的VLAN，由一组相互连接的FC交换机的端口组成，并形成了一个虚拟的光纤。交换机内的端口可以被划分成不同的VSAN，但依然共享硬件资源。另外，多个FC交换机连接了多个端口，通过内部交换机链路（Inter-Switch Link,ISL）或者是强化ISL（Enhanced ISL,EISL），也可以组成了一个单独的VSAN，可以将EISL看成FC汇聚端口。

IVR要求使用一张VSAN重写表，每个支持IVR的交换机都维护了一张VSAN重写表，重写表以每个交换机域而非每个终端设备为单位，可以保存4096条信息。图9-17展示了一个简化的VSAN重写表样例，该样例是参照图9-16的设置而设计的。

VSAN 重写表

交换机	当前 VSAN	源域	目标域	下一跳 VSAN（重写 VSAN）
MDS-1	100	0x8f	0x2c	9
MDS-1	9	0x2c	0x8f	100
MDS-2	200	0x2c	0x8f	9
MDS-2	9	0x8f	0x2c	200

图　9-17　简化的VSAN重写表

利用如图9-17所示的VSAN重写表，假定当前从FC域0x8f要发送一个FC帧到FC域0x2c，在MDS-1上经过VSAN重写操作处理后，原来为100的VSAN标签被改写成9，而在MDS-2上，又将9改成200，逆操作是在返回路径上完成的。

说明：MDS交换机上实际的VSAN重写表可以调用“show ivr internal fcid-rewrite-list”命令查看。

回到IVR的实现上，首先要将Po10以及FCIP接口（fcip1和fcip2）从trunk模式改成notrunk模式，如代码清单9.26所示，调用“switchport trunk mode off”命令可以关闭Po10和FCIP接口（fcip1和fcip2）的trunking功能。MDS-1和MDS-2要分别调用该命令。

代码清单9.26　非trunk模式配置

```
interface port-channel 10
  switchport trunk mode off
[·····Snipped for brevity·····]

interface fcip1
  switchport trunk mode off
[·····Snipped for brevity·····]

interface fcip2
  switchport trunk mode off
[·····Snipped for brevity·····]
```

代码清单9.27展示了MDS-1上VSAN配置，其中，FC接口fc1/10、fc1/15、fc1/16将归于VSAN 100，端口Po10归于VSAN 9，可以调用“no shutdown”命令启动FC接口。

代码清单9.27　MDS-1的VSAN配置

```
vsan database
  vsan 9
  vsan 100
  vsan 9 interface port-channel 10
  vsan 100 interface fc1/10
  vsan 100 interface fc1/15
  vsan 100 interface fc1/16

interface fc1/10
  no shutdown

interface fc1/15
  no shutdown

interface fc1/16
  no shutdown
```

代码清单9.28展示了MDS-2上VSAN配置，其中，FC接口fc 1/10、fc1/15将归于VSAN 200，端口Po10归于VSAN 9，可以调用“no shutdown”命令启动FC接口。

现在是时候简单了解一下FLOGI以及FCNS数据库了。

在一个FC光纤中，每个主机（N_Port）或磁盘（NL_Port）都需要一个FCID，如果所要求的终端设备确实在FLOGI数据库里，则光纤登录就成功了。FLOGI数据库有所有登录到光纤（例如，本地MDS交换机）的终端设备信息。别名和分区的pWWN也可以查询FLOGI数据库得到。

代码清单9.28　MDS-2的VSAN配置

```
vsan database
  vsan 9
  vsan 200
  vsan 9 interface port-channel 10
  vsan 200 interface fc1/10
  vsan 200 interface fc1/15

interface fc1/10
  no shutdown

interface fc1/15
  no shutdown
```

代码清单9.29分别调用“show flogi database”展示了MDS-1和MDS-2的FLOGI数据库，从输出结果可知，JBOD-1、HOST-11和HOST-12都成功地登录到MDS-1上，同样HOST-21和HOST-22也成功登录到MDS-2上。

代码清单9.29　FLOGI数据库

```
MDS-1# show flogi database
--------------------------------------------------------------------------------
INTERFACE    VSAN    FCID           PORT NAME               NODE NAME
--------------------------------------------------------------------------------
fc1/10       100   0x8f0000  21:00:00:e0:8b:1f:92:30   20:00:00:e0:8b:1f:92:30
fc1/15       100   0x8f0100  21:00:00:e0:8b:1f:92:31   20:00:00:e0:8b:1f:92:31
fc1/16       100   0x8f02e0  c5:f8:00:1b:2b:09:00:05   c6:81:00:1b:2b:02:00:05
fc1/16       100   0x8f02e1  c5:f8:00:1b:2b:09:00:04   c6:81:00:1b:2b:02:00:04
fc1/16       100   0x8f02e2  c5:f8:00:1b:2b:09:00:03   c6:81:00:1b:2b:02:00:03
fc1/16       100   0x8f02e4  c5:f8:00:1b:2b:09:00:02   c6:81:00:1b:2b:02:00:02
fc1/16       100   0x8f02e8  c5:f8:00:1b:2b:09:00:01   c6:81:00:1b:2b:02:00:01
fc1/16       100   0x8f02ef  c5:f8:00:06:0d:09:00:00   c5:f8:00:06:0d:09:00:00

Total number of flogi = 8.

MDS-2# show flogi database
--------------------------------------------------------------------------------
INTERFACE    VSAN    FCID           PORT NAME               NODE NAME
--------------------------------------------------------------------------------
fc1/10       200   0x2c0000  21:01:00:e0:8b:3f:a9:ac   20:01:00:e0:8b:3f:a9:ac
fc1/15       200   0x2c0100  21:01:00:e0:8b:3f:a9:ad   20:01:00:e0:8b:3f:a9:ad

Total number of flogi = 2.
```

FC命名服务器（FC Name Server,FCNS）是一个小型数据库，就像一个大范围拓扑服务一样，存储了多交换机光纤中每个节点（FC启动器及/或目标）的信息，包括FCID、pWWN等。

代码清单9.30分别调用“show fcns database”命令展示了MDS-1和MDS-2上的FCNS数据库，此时还未实现IVR，因此命令的输出结果中只包含了连接到MDS-1和MDS-2的本地设备信息。

代码清单9.30　IVR之前的FCNS数据库

```
MDS-1# show fcns database
VSAN 100:
--------------------------------------------------------------------
FCID      TYPE  PWWN                    (VENDOR)      FC4-TYPE:FEATURE
--------------------------------------------------------------------
0x8f0000  N     21:00:00:e0:8b:1f:92:30 (Qlogic)      scsi-fcp:init
0x8f0100  N     21:00:00:e0:8b:1f:92:31 (Qlogic)      scsi-fcp:init
0x8f02e0  NL    c5:f8:00:1b:2b:09:00:05               scsi-fcp:target
0x8f02e1  NL    c5:f8:00:1b:2b:09:00:04               scsi-fcp:target
0x8f02e2  NL    c5:f8:00:1b:2b:09:00:03               scsi-fcp:target
0x8f02e4  NL    c5:f8:00:1b:2b:09:00:02               scsi-fcp:target
0x8f02e8  NL    c5:f8:00:1b:2b:09:00:01               scsi-fcp:target
0x8f02ef  NL    c5:f8:00:06:0d:09:00:00               scsi-fcp:target

Total number of entries = 8

MDS-2# show fcns database

VSAN 200:
--------------------------------------------------------------------
FCID      TYPE  PWWN                    (VENDOR)      FC4-TYPE:FEATURE
--------------------------------------------------------------------
0x2c0000  N     21:01:00:e0:8b:3f:a9:ac (Qlogic)      scsi-fcp:init
0x2c0100  N     21:01:00:e0:8b:3f:a9:ad (Qlogic)      scsi-fcp:init

Total number of entries = 2
```

JBOD-1（如图9-16所示）配备了6个磁盘（DISK-1到DISK-6），按计划是为每个主机配备一个磁盘，某些分区也要求配备磁盘。

代码清单9.31展示了MDS-1上VSAN 100的分区及配置信息。

代码清单9.31　MDS-1分区和分区集配置

```
zone name zone11 vsan 100
    member pwwn 21:00:00:e0:8b:1f:92:30
    member pwwn c5:f8:00:06:0d:09:00:00

zone name zone12 vsan 100
    member pwwn 21:00:00:e0:8b:1f:92:31
    member pwwn c5:f8:00:1b:2b:09:00:01

zoneset name zonelocal vsan 100
    member zone11
    member zone12

zoneset activate name zonelocal vsan 100
```

HOST-11和DISK-1被划分到分区11，HOST-12和DISK-2被划分到分区12，分区集“zonelocal”也会将zone11和zone12作为本分区成员。

说明：“show zoneset active”命令可以验证配置好分区（集），也可以验证本地分区（集）。

接下来，该配置MDS-1和MDS-2上的IVR了。代码清单9.32和代码清单9.33分别对此进行了说明。

代码清单9.32　MDS-1 IVR配置

```
ivr enable
ivr distribute
ivr nat
ivr vsan-topology auto


ivr zone name IvrZone21
  member pwwn 21:01:00:e0:8b:3f:a9:ac              vsan 200
  member pwwn c5:f8:00:1b:2b:09:00:02              vsan 100

ivr zone name IvrZone22
  member pwwn 21:01:00:e0:8b:3f:a9:ad              vsan 200
  member pwwn c5:f8:00:1b:2b:09:00:03              vsan 100

ivr zoneset name IvrZoneSet1
  member IvrZone21
  member IvrZone22

ivr zoneset activate name IvrZoneSet1 force
ivr commit
```

代码清单9.33　MDS-2 IVR配置

```
ivr enable
ivr distribute
```

IVR配置步骤如下：

·调用“ivr enable”命令，启动MDS-1和MDS-2上的IVR。

·IVR使用Cisco光纤服务（Cisco Fabric Service,CFS）基础设施完成自动IVR配置分布，并为整个（多交换机）光纤提供一个单独的配置点。MDS-1是主交换机，调用“ivr distribute”命令启动MDS-1和MDS-2上的IVR配置分布。

·调用“ivr nat”和“ivr vsan-topology auto”命令启动主交换机MDS-1上的IVR NAT以及自动VSAN拓扑发现功能。IVR NAT支持在IVR拓扑范围内的VLAN和交换机间采用非唯一性的FC域ID。

·调用“ivr zone”命令，配置主交换机MDS-1上的IVR分区，将HOST-21选定的端口成员（pWWN和相关的VSAN）以及DISK-3添加到新的IVR分区中，IvrZone21。同样，将HOST-22

的 pWWN 和 相 关 VSAN 和 DISK-4 增 加 到 新 IVR 分 区 ，IvrZone22。有关的pWWN及VSAN信息都可以查询FLOGI数据库得到。（参见代码清单9.29）

·调用“ivr zoneset”命令，配置MDS-1上的IVR分区集，将新增加的分区IvrZone21和IvrZone22添加到分区集IvrZoneSet1内。

·调用“ivr zoneset activate”命令激活主交换机MDS-1的分区IvrZoneSet1。

·调用“ivr commit”命令，在主交换机MDS-1上执行提交操作，将分区配置传播给所有的支持IVR的交换机（本例中，为MDS-2）。

说明：比起使用CLI命令行，使用Cisco光纤管理器（Fabric Manager,FM）GUI更容易完成IVR配置，而且也不容易出错。

有一个简单的方法可以验证Po10的trunk模式，即调用“show interface brief”命令，命令输出如代码清单9.34所示，此时Po10、ficp1、ficp2的trunk模式状态为“off”，Po10、ficp1、ficp2的可选模式为“E”而非“TE”，这也进一步这个命了链路汇聚被成功地关闭了。

代码清单9.34　非trunk端口通道验证

```
MDS-1# show interface brief
[·····Snipped for brevity·····]
--------------------------------------------------------------------------------
Interface          Vsan  Admin  Status     Oper     Oper    IP
                         Trunk             Mode     Speed   Address
                         Mode                       (Gbps)
--------------------------------------------------------------------------------
port-channel 10    9     off    up         E        2       --
--------------------------------------------------------------------------------
Interface Vsan Admin  Admin  Status   Oper Profile   Eth Int   Port-channel
             Mode   Trunk          Mode
                    Mode
--------------------------------------------------------------------------------
fcip1     9    auto   off    up       E    1 GigabitEthernet2/1  port-channel 10
fcip2     9    auto   off    up       E    2 GigabitEthernet2/2  port-channel 10
```

调用“show ivr vsan-topology”命令可以验证IVR VSAN拓扑配置结果。如代码清单9.35所示，过路的VSAN 9和VSAN 100

已经关联到MDS-1，而过路的VSAN 9和VSAN 200则关联到MDS-2，星号意味着这是本地交换机的名字（World Wide Name,WWN）。配置好了的（Configured,Cfg）域显示结果为“no”，这是因为VSAN拓扑是自动生成而非手动配置。

代码清单9.35　IVR VSAN拓扑状态

```
MDS-1# show ivr vsan-topology

AFID  SWITCH WWN                Active  Cfg. VSANS
------------------------------------------------
  1   20:00:00:0c:ce:6c:6c:40 *  yes     no  9,100
  1   20:00:00:0d:ec:0e:8e:80    yes     no  9,200

Total: 2 entries in active and configured IVR VSAN-Topology

MDS-2# show ivr vsan-topology
AFID  SWITCH WWN                Active  Cfg. VSANS
------------------------------------------------
  1   20:00:00:0c:ce:6c:6c:40    yes     no  9,100
  1   20:00:00:0d:ec:0e:8e:80 *  yes     no  9,200

Total: 2 entries in active and configured IVR VSAN-Topology
```

“show ivr zoneset active”命令能够验证活动IVR分区集，如代码清单9.36所示，由命令执行结果可知，MDS-1的分区配置信息已经成功地传给了MDS-2。

代码清单9.36　活动IVR分区集验证

```
MDS-2# show ivr zoneset active

zoneset name IvrZoneSet1
  zone name IvrZone21
    * pwwn 21:01:00:e0:8b:3f:a9:ac          vsan  200 autonomous-fabric-id  1
    * pwwn c5:f8:00:1b:2b:09:00:02          vsan  100 autonomous-fabric-id  1
  zone name IvrZone22
    * pwwn 21:01:00:e0:8b:3f:a9:ad          vsan  200 autonomous-fabric-id  1
    * pwwn c5:f8:00:1b:2b:09:00:03          vsan  100 autonomous-fabric-id  1
```

说明：自主光纤ID（Autonomous Fabric ID,AFID）能将两个逻辑和物理都是分离的VSAN区分开来，但是这些VSAN的VSAN ID的值却是一样的。本例中，AFID的值都为1（默认），因为设置中并没有覆盖VSAN ID的值。

代码清单9.37对完成IVR配置后的MDS-1的FCNS数据库进行了说明，过路的VSAN 9的pWWN目录中包括了DISK-3、DISK-4、HOST-21、HOST-22的信息。VSAN 100的pWWN目录中则包含了HOST-21、HOST-22的信息，IVR已经成功地将信息从VSAN 200（传递到VSAN 9，又从VSAN 9传给了VSAN 100）。

代码清单9.37　IVR完成后的MDS-1 FCNS数据库

```
MDS-1# show fcns database

VSAN 9:
--------------------------------------------------------------------
FCID      TYPE  PWWN                    (VENDOR)      FC4-TYPE:FEATURE
--------------------------------------------------------------------
0x58ce04  N     c5:f8:00:1b:2b:09:00:03               scsi-fcp:target
0x58ce05  N     c5:f8:00:1b:2b:09:00:02               scsi-fcp:target
0x8cdc35  N     21:01:00:e0:8b:3f:a9:ac  (Qlogic)     scsi-fcp:init
0x8cdd35  N     21:01:00:e0:8b:3f:a9:ad  (Qlogic)     scsi-fcp:init

Total number of entries = 4

VSAN 100:
--------------------------------------------------------------------
FCID      TYPE  PWWN                    (VENDOR)      FC4-TYPE:FEATURE
--------------------------------------------------------------------
0x8f0000  N     21:00:00:e0:8b:1f:92:30  (Qlogic)     scsi-fcp:init
0x8f0100  N     21:00:00:e0:8b:1f:92:31  (Qlogic)     scsi-fcp:init
0x8f02e0  NL    c5:f8:00:1b:2b:09:00:05               scsi-fcp:target
0x8f02e1  NL    c5:f8:00:1b:2b:09:00:04               scsi-fcp:target
0x8f02e2  NL    c5:f8:00:1b:2b:09:00:03               scsi-fcp:target
0x8f02e4  NL    c5:f8:00:1b:2b:09:00:02               scsi-fcp:target
0x8f02e8  NL    c5:f8:00:1b:2b:09:00:01               scsi-fcp:target
0x8f02ef  NL    c5:f8:00:06:0d:09:00:00               scsi-fcp:target
0xdbdc90  N     21:01:00:e0:8b:3f:a9:ac  (Qlogic)     scsi-fcp:init
0xdbdd90  N     21:01:00:e0:8b:3f:a9:ad  (Qlogic)     scsi-fcp:init

Total number of entries = 10
```

代码清单9.38展示了IVR配置后的MDS-2的FCNS数据库信息，与MDS-1类似，过路的VSAN 9的pWWN目录中包括了DISK-3、DISK-4、HOST-21、HOST-22的信息。VSAN 200的pWWN目录中则包含了DISK-3、DISK-4的信息。这意味着，IVR已经成功地将信息从VSAN 100（传递到VSAN 9，又从VSAN 9传给了VSAN 200）.

代码清单9.38　IVR完成后的MDS-2 FCNS数据库

```
MDS-2# show fcns database
VSAN 9:
--------------------------------------------------------------------
FCID      TYPE  PWWN                    (VENDOR)      FC4-TYPE:FEATURE
--------------------------------------------------------------------
0x58ce04   N    c5:f8:00:1b:2b:09:00:03               scsi-fcp:target
0x58ce05   N    c5:f8:00:1b:2b:09:00:02               scsi-fcp:target
0x8cdc35   N    21:01:00:e0:8b:3f:a9:ac  (Qlogic)     scsi-fcp:init
0x8cdd35   N    21:01:00:e0:8b:3f:a9:ad  (Qlogic)     scsi-fcp:init

Total number of entries = 4


VSAN 200:
--------------------------------------------------------------------
FCID      TYPE  PWWN                    (VENDOR)      FC4-TYPE:FEATURE
--------------------------------------------------------------------
0x2c0000   N    21:01:00:e0:8b:3f:a9:ac  (Qlogic)     scsi-fcp:init
0x2c0100   N    21:01:00:e0:8b:3f:a9:ad  (Qlogic)     scsi-fcp:init
0xb0cec3   N    c5:f8:00:1b:2b:09:00:03               scsi-fcp:target
0xb0cec4   N    c5:f8:00:1b:2b:09:00:02               scsi-fcp:target

Total number of entries = 4
```

9.8 面向服务的基础设施设计学习

本节的案例分析包含了各类面向服务的基础设施模块，这些模块我们在第8章曾探讨过。

企业“M”想以两个租户（供应商/终端用户）对云IaaS做一个简单测试，然后在以后的工作中再逐步增加更多的租户。租户A由内部终端用户组成，它们属于系统工程组，位于远程分支办公室A（RBO-A），租户B为供应商（合作伙伴），位于远程分支办公室B（RBO-B）。此时，企业“M”的管理团队申请了一个高级别项目启动设计（Project Initiation Design,PID），PID包括了以下高级别的设计内容：

·虚拟接入层

·计算子模块

·存储模块

·光纤模块

·服务汇聚层

·WAN模块

9.8.1 虚拟接入层高级设计

在虚拟接入层设计中，连接到虚拟接入层交换机的VM可以被分成两大类：基础设施和租户。属于基础设施部分的VM主要负责配置和维护云IaaS环境，它们通常是云IaaS管理平台，诸如，Vmware vCenter、NX1KV VSM、数据中心网络管理器（Data Center Network Manager,DCNM）、光纤管理器（Fabric Manager,FM）、UCS管理器（UCS Manager,UCSM）等。租户VM由租户的应用及用户拥有并负责管理。图9-18展示了虚拟接入层设计的一个高级视图。

说明：Cisco DCNM是Nexus交换机的管理平台，类似地，Cisco FM负责管理MDS交换机，UCSM负责管理UCS。

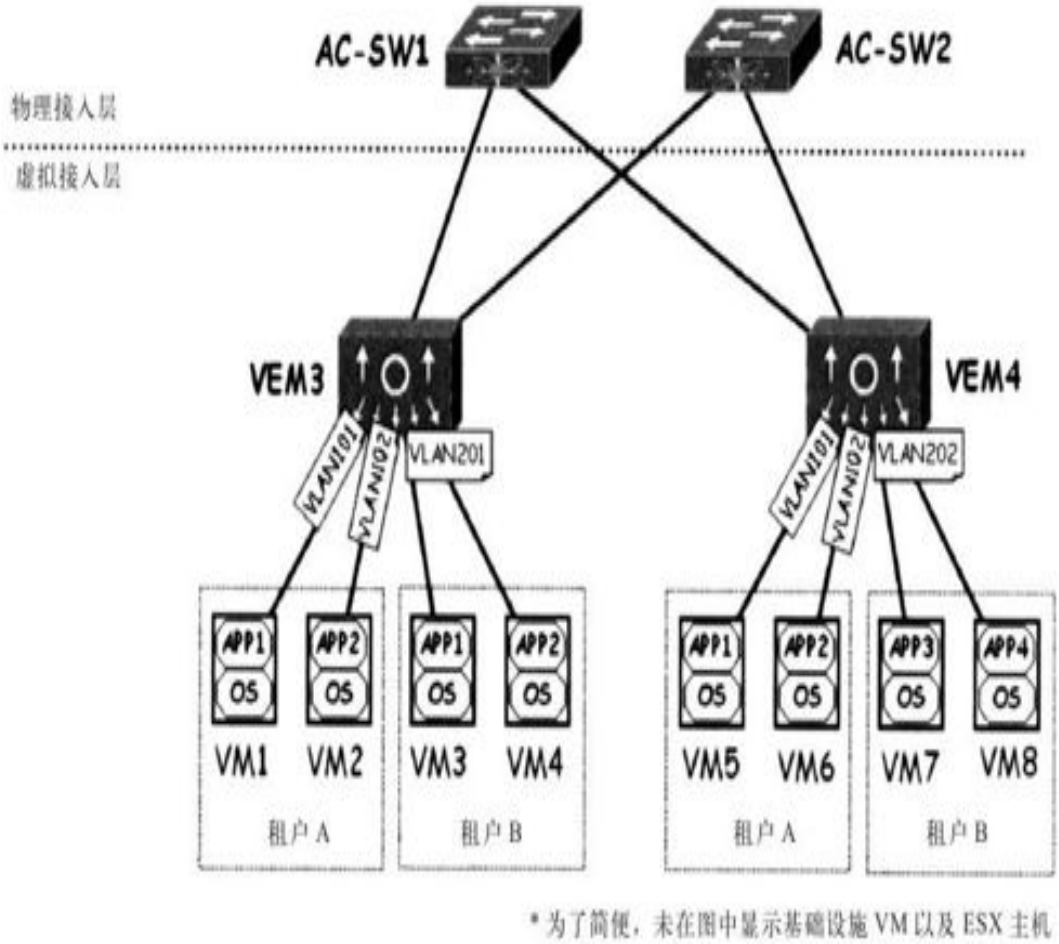


图　9-18　高级虚拟接入层设计

如图9-18所示的高级别虚拟接入层设计，包括了以下内容：

·8个租户VM,VM1～VM8。

·VM1、VM2、VM5和VM6被分配给租户A。

·VM3、VM4、VM7、VM8和VM6被分配给租户B。

·4种应用，APP1到APP4。

·APP1运行在VM1、VM3和VM5上。

·APP2运行在VM2、VM4和VM6上。

·APP3运行在VM7上。

·APP4运行在VM8上。

·两台ESX主机，ESX1和ESX2（为了简便，未在图中显示）。

·ESX1包括了VM1到VM4。

·ESX2包括了VM5和VM8。

·2台物理的接入层交换机：AC-SW1和AC-SW2，既可以是UCS 6140XP光纤互联，也可以是Nexus 5020交换机，由计算机子模块是由UCS还是普通机架服务器（更多细节，参见9.8.2节的相关内容）。

·2个NX1KV VEM,VEM3和VEM4。

·ESX1内，VM1到VM4连接到VEM3。

·ESX2内，VM5到VM8连接到VEM4。

·每个VEM配备2条10GE上行链路，一条连接AC-SW1，另一条连接AC-SW2。

·VEM均采用了在“2NIC配置”一节介绍的NX1KV设计方案。

·4个VLAN,VLANs 101、102、201和202。

·VM1和VM5位于VLAN 101内，这些VM上运行了租户A的应用APP1，目的是将APP1分布在两台ESX主机上，有利于形成服务链或实现SLB（更多详细内容，请参考“服务汇聚层高级设计”一节）。

·VM2和VM6位于VLAN 102内，这些VM上运行了租户A的应用APP2，同样也是为了将APP2分布在两台ESX主机上，有利于形成服务链或实现SLB（更多详细内容，请参考“服务汇聚层高级设计”一节）。

·VM3和VM4位于VLAN 201内。

·VM7和VM8位于VLAN 202内。

说明：服务控制台和Vmkernel同样也直接连接至NX1KV VEM（为了简便，未在图中显示）。

9.8.2　计算子模块高级设计

计算子模块设计方法很多，在本例中，我们将范围缩小到两种：使用UCS方法或者采用普通机架服务器方法。刀片或机架服务器就是虚拟接入层“生存之处”。图9-19展示了使用UCS的计算子模块高级设计视图，采用普通机架服务器方法的计算子模块设计则如图9-20所示。

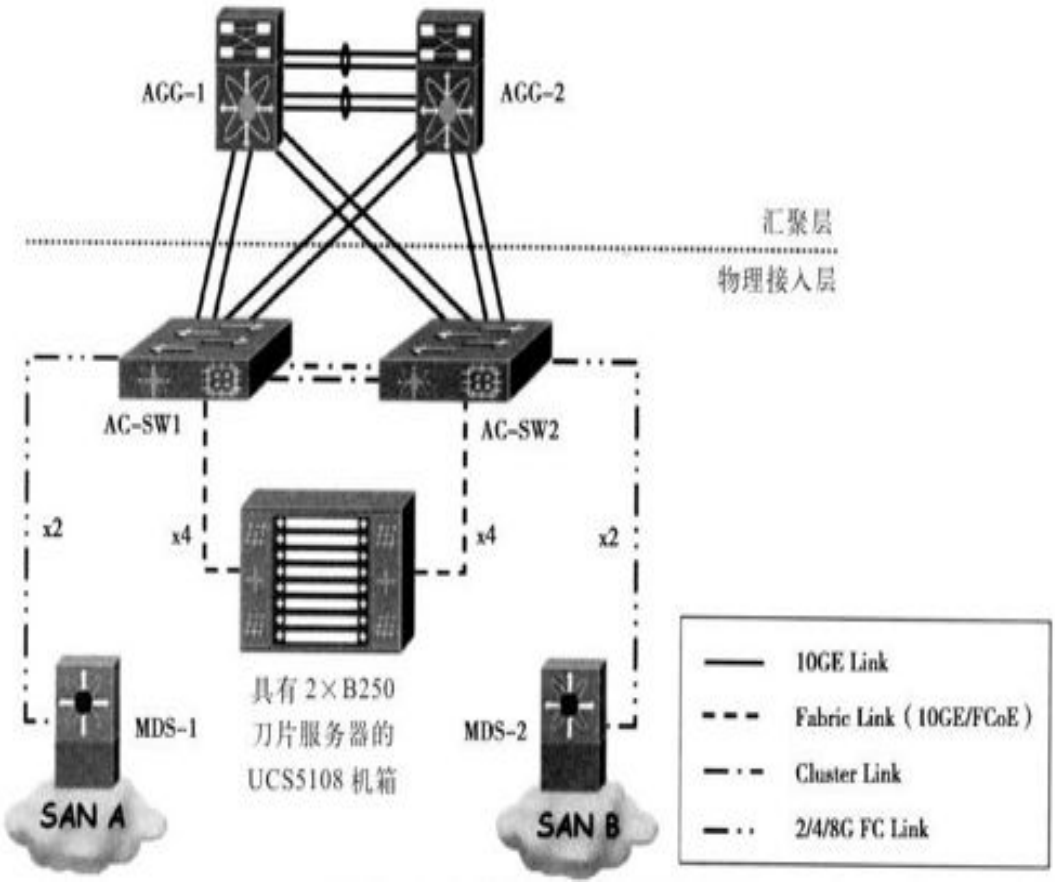


图　9-19　高级别计算子模块设计方案1

说明：UCS管理器（UCS Manager,UCSM）运行在UCS 6100系列光纤互联上，负责整个UCS系统的管理和配置。UCSM使用主/从体系结构，活动实例为主UCSM，备份实例被称为从UCSM。所有连接及连接数据库都由主UCSM实例负责，数据库备份存放在从UCSM上。主UCSM会将配置更改的信息发送给从UCSM实例，两个UCSM实例通过两个光纤互联间的双聚簇链路进行通信。

图9-19中展示的高级计算子模块设计方案1包括如下内容：

·两组UCS 6140X光纤互联，AC-SW1和AC-SW2（更多细节请参考第8章的内容）。

·AC-SW1有两对10GE上行链路：一对用于AGG-1，另一对用于AGG-2 AC-SW2也采用了同样配置。

·AC-SW1有4条10GE下行链路（光纤链路），连接至FEX-1（位于UCS机箱背部），同样AC-SW1有4个10GE下行链路，连接至FEX-2。由于本方案中只使用了2个刀片服务器，因此2条光纤链路就足够了。不过，为了今后的扩展，连接了（一次连接）所有4条上行链路。更多UCS FEX的详细内容，请参考本书第8章的内容。

·以上提到的光纤互联（AC-SW1和AC-SW2）的上行、下行链路都是10GE/FCoE/SFP+端口。

·两台UCS 2104XP FEX：FEX-1和FEX-2（均位于UCS机箱背部）。

·两台UCS B250刀片服务器（更多细节请参考第8章的内容）：一个给ESX1，另一个给ESX2。

·两个CNA：CNA-1和CNA-2。每台刀片服务器（UCS B250为全插槽刀片服务器，能够支持两个I/O适配器）：

·在ESX主机（ESX1和ESX2）和光纤互联（AC-SW1和AC-SW2）之间的CNA-1和CNA-2实现了10GE/FCoE。

·对于每个ESX主机，CNA-1通过FEX-1连接到AC-SW1，CNA-2通过FEX-2连接到AC-SW2。

·ESX主机通过CNA连接到DC以太网LAN和FC SAN（通过FCoE）。

·一台UCS 5108刀片服务器机箱，存放服务器刀片和FEX（更多细节，请参考本书第8章“刀片服务器机箱”一节）。

·ToR架构：

·UCS和FEX都放置在UCS机箱背部，所以不需要其他的ToR架构，光纤互留位于EoR机架上。

·ToR布局类似图9-13，只是没有采用ToR FEX。

·由于4条光纤上行链路在方案中都用于UCS FEX，因此从UCS服务器机架到EoR机架之间总共使用了8根光纤。

图9-20所示的高级计算子模块设计方案2包括了以下内容：

·两台Nexus 5020交换机，AC-SW1和AC-SW2：

·UCS和FEX都放置在UCS机箱背部，不需要其他的ToR架构，光纤互留位于EoR机架上。

·AC-SW1有两对10GE上行链路：一对用于AGG-1，另一对用于AGG-2，AC-SW2也采用了同样配置。

·AC-SW1有2条10GE/FCoE下行链路，一条连接至机架Rack Server-1，另一条连接至机架Rack Server-2，AC-SW2也采用了同样配置。

·以上提到的NX5K交换机的上下行链路都是10GE/FCoE/SFP+端口。

·AC-SW1有2个本地FC链路，连接到MDS-1（SAN A），AC-SW2也采用同样配置连接到MDS-2（SAN B）。

·两台UCS C200或普通机架服务器：一台（Rack Server-1）为ESX-1提供服务，另一台（Rack Server-2）为ESX-2提供服。

·每台机架服务器上配置了一个双端口CNA：

·在ESX主机（ESX1和ESX2）和NX5K交换机（AC-SW1和AC-SW2）之间的双端口CNA实现了10GE/FCoE。

·ESX主机（机架服务器），一个CNA端口连接了AC-SW1，另一个连接到AC-SW2。

·ESX主机利用双端口CAN同时连接到DC以太网LAN和FC SAN（通过FCoE）。

·ToR架构：

·两台NX5K交换机可以作为服务器机架的ToR交换机，服务器机架布局类似图2-26。

·两台NX5K交换机也可以放在一个ToR机架中，此时，ToR布局类似图9-13，只是比图9-13少了一个ToR FEX。

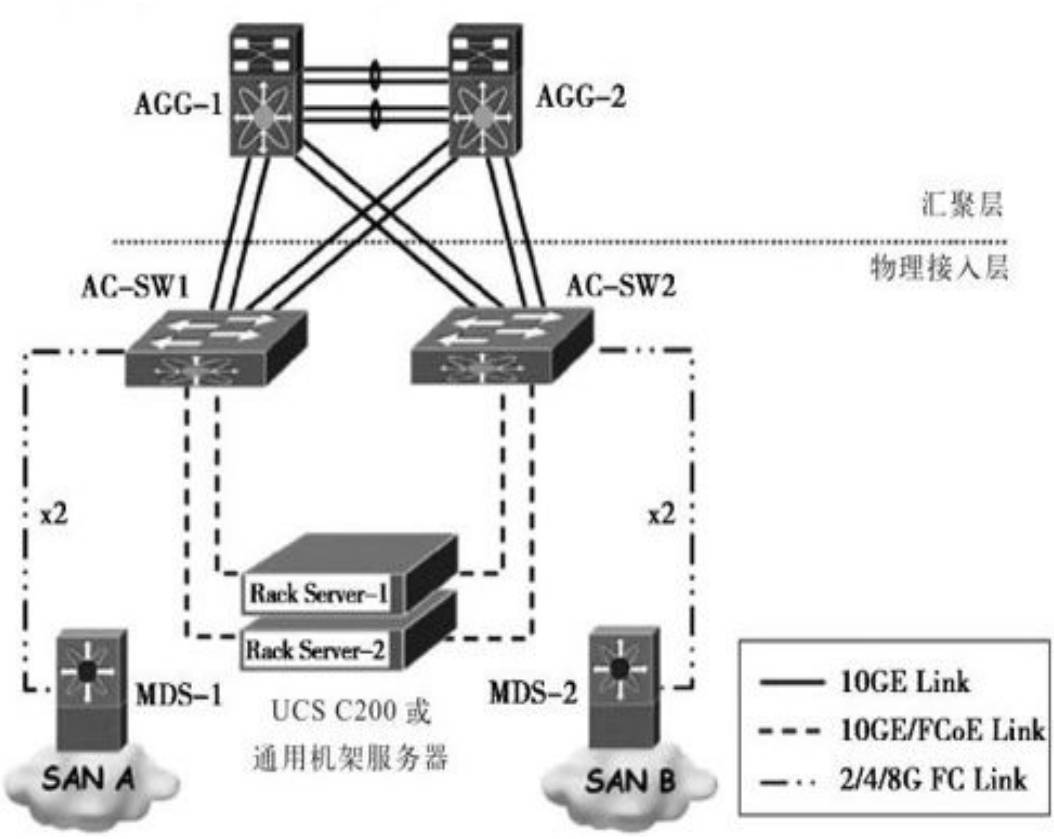


图　9-20　高级计算子模块设计2

9.8.3 存储子模块高级设计

SAN模块设计以整合核心架构为基础，存储设备直接连接到高端口数量FC导向器上，如图9-21所示。

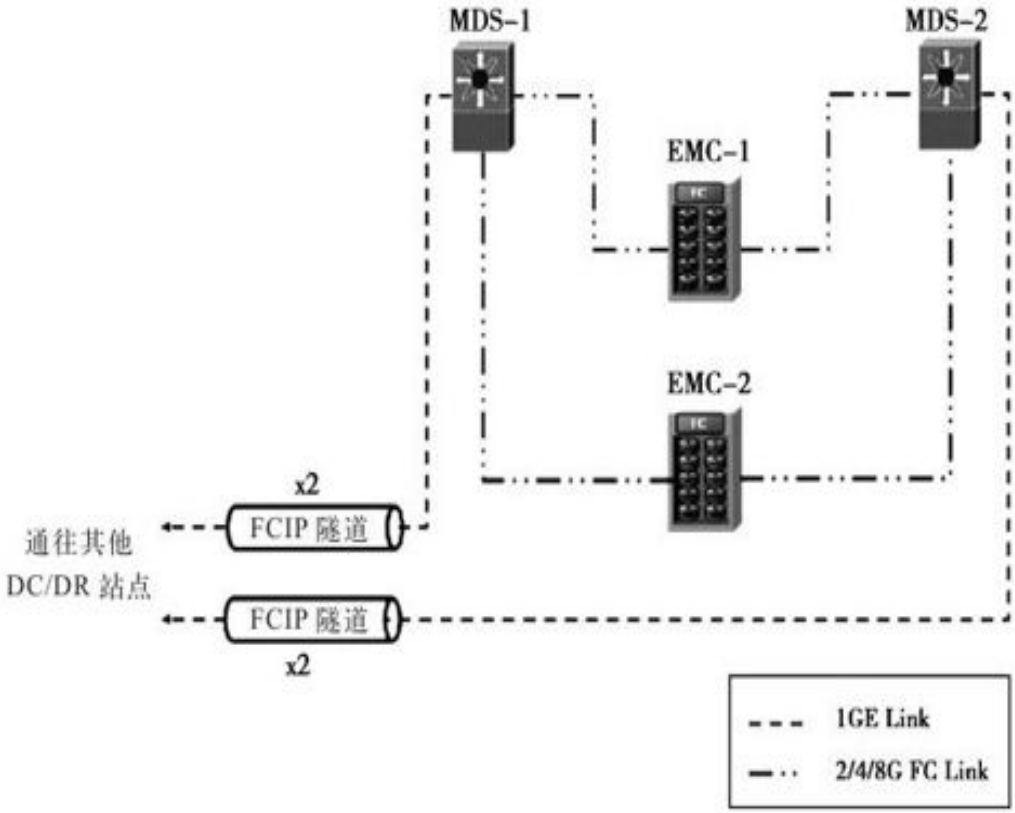


图 9-21 高级存储模块设计

图9-21中的高级存储模块设计包括以下内容：

·两台MDS 9506导向器，MDS-1和MDS-2：

·每个导向器配备了一个48端口，8Gbps的FC交换模块，用来进行本地FC连接。

·每个导向器另配一个16端口的存储服务节点，用来进行FCIP连接。

·两个EMC CLARiiON AX4驱动阵列：EMC-1和EMC-2。

·每个导向器拥有一对FCIP隧道，将现有SAN（SAN A和SAN B）进行扩展至WAN上的远程DC/DR站点。更多关于FCIP配置详细内容，请参考9.7节中“简单的FCIP设计样例”的内容。

说明：大多数情况下，存储模块属于现有DC SAN基础设施的一部分。

9.8.4 光纤模块高级设计

光纤模块覆盖了核心层、汇聚层以及接入层的组件，DC LAN基础设施被进一步地分割成不同的虚拟上下文，为租户A和租户B提供服务。通过这种方式，能够实现租户A与租户B之间必要的安全隔离，整体的物理拓扑如图9-22所示。链路1a到6a和11a到16a属于租户A，链路1b到6b和11b到16b属于租户B。另外，DC LAN以多域、多层vPC设计为基础，同时还包括从核心层到汇聚层，以及汇聚层到接入层的vPC扩展。

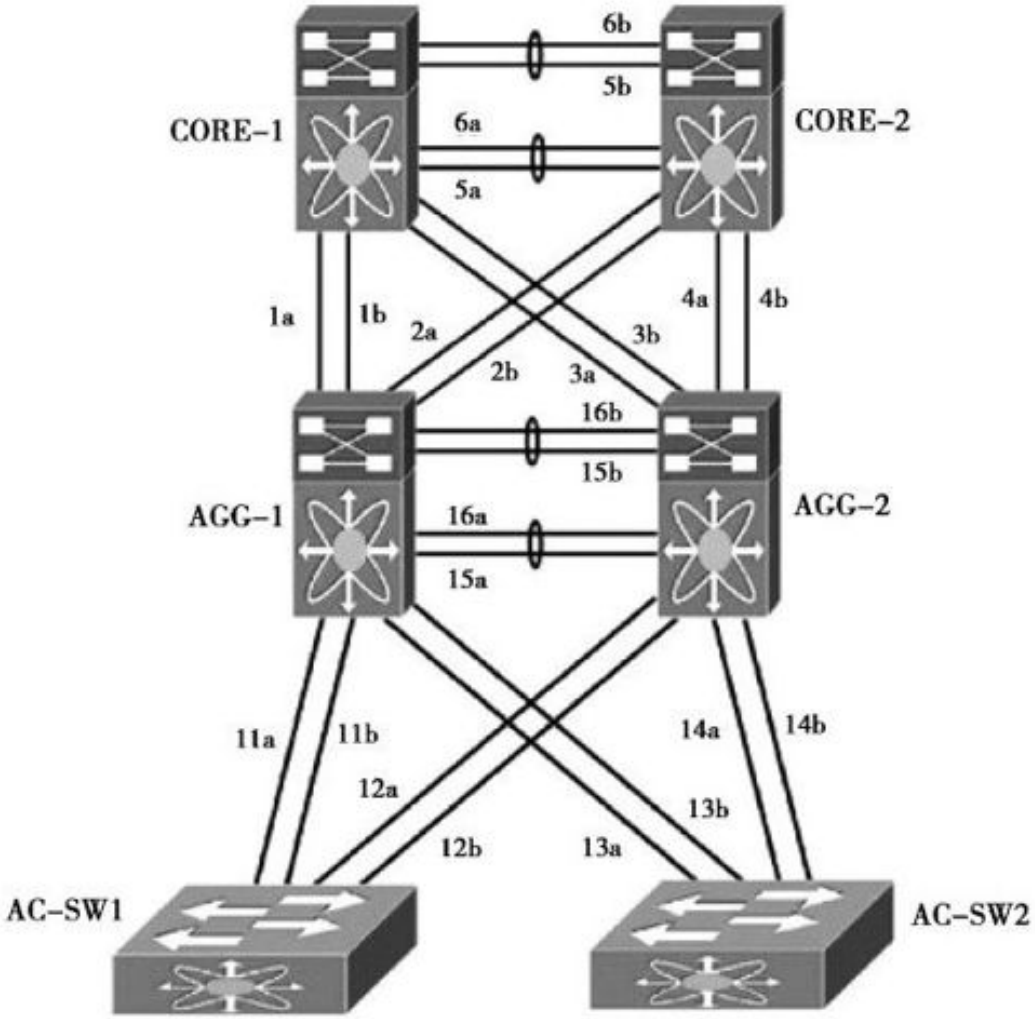


图 9-22 光纤模块物理拓扑

由于租户A都是内部终端用户，企业“M”的IaaS供应者（IT管理部门）更希望这些用户能够自己管理各自的DC LAN基础设施，而IaaS供应者将只负责汇聚层以及核心层交换机的最简单配置工作。终端用户自己需要负责管理这些交换机，并且在

需要时，进一步完善相关配置。图9-23展示了租户A的光纤模块高级设计视图。

图9-23中展示的租户A高级别光纤模块设计内容包括：

·4台“逻辑”Nexus 7010交换机：

·核心层交换机：CORE-1A和CORE-2A。

·汇聚层交换机：AGG-1A和AGG-2A。

·租户A的虚拟设备上下文（Virtual Device Context,VDC）：

·在CORE-1A和CORE-2A上。

·在AGG-1A和AGG-2A上。

·根据当前现有的4个物理交换机，租户A的VDC在逻辑上被划分成4个自主逻辑交换机，租户A能够直接管理这些交换机：

·CORE-1A源自物理交换机CORE-1，作为CORE-1内的独立逻辑实体运行。

·CORE-2A源自物理交换机CORE-2，作为CORE-2内的独立逻辑实体运行。

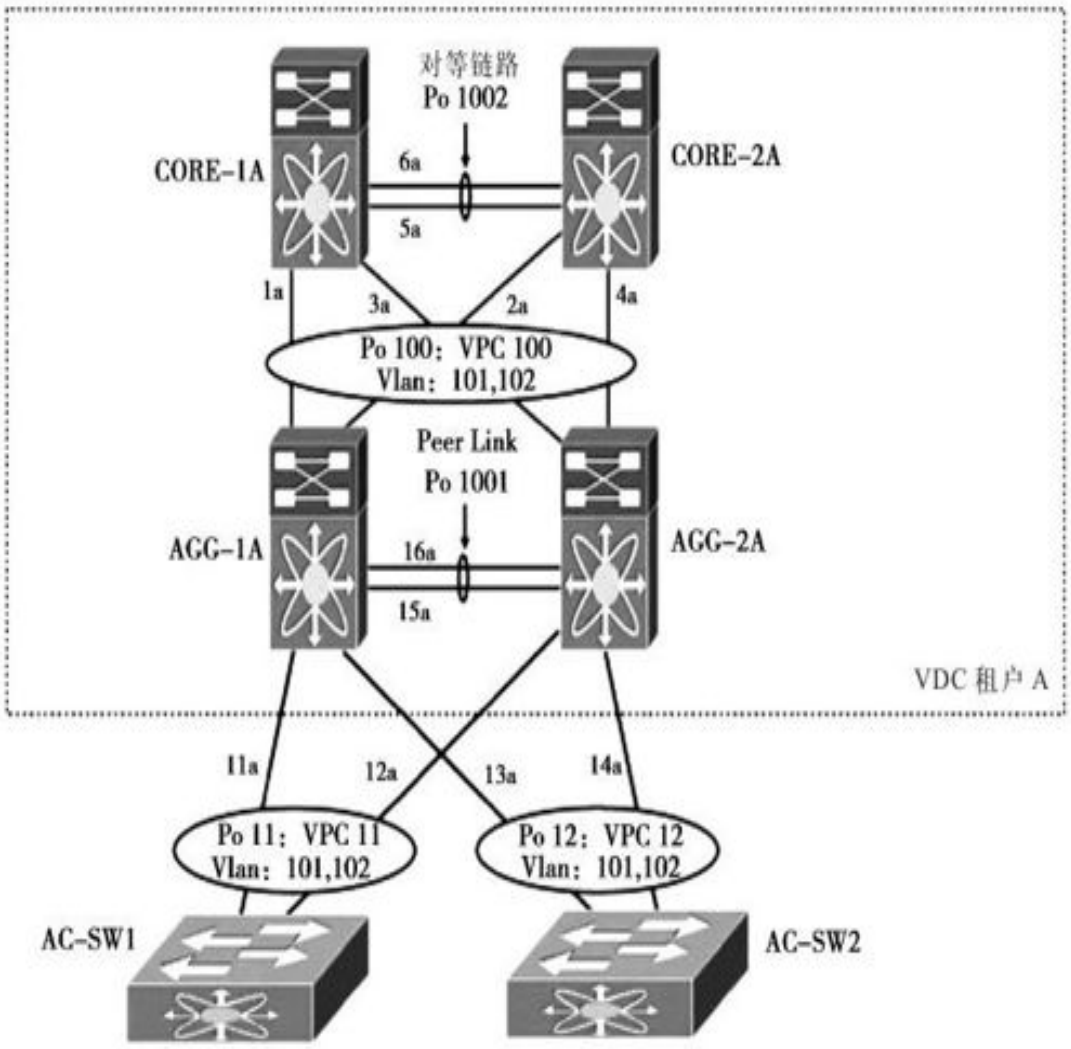


图　9-23　租户A的高级别光纤模块设计

·AGG-1A源自物理交换机AGG-1，作为AGG-1内的独立逻辑实体运行。

·AGG-2A源自物理交换机AGG-2，作为AGG-2内的独立逻辑实体运行。

·CORE-1A和CORE-2A上vPC配置如下：

·属于VPC Domain 101。

·CORE-1A和CORE-2A之间的2条链路（5a和6a）通过对等链路端口通道1002连接。

·CORE-1A和CORE-2A上的VPC 100（端口通道100），连接来自AGG-1A的两条上行链路（1a和2a）。

·CORE-1A和CORE-2A上的VPC 100（端口通道100），连接来自AGG-2A的两条上行链路（3a和4a）。更多有关vPC配置的详细内容，请参考9.6节中关于“基本vPC配置”的内容。

·AGG-1A和AGG-2A上vPC配置如下：

·属于VPC Domain 102。

·AGG-1A上的VPC 100（端口通道100）连接通往CORE-1A和CORE-2A的上行链路（1a和2a）。

·AGG-2A上的VPC 100（端口通道100）连接通往CORE-1A和CORE-2A的上行链路（3a和4a）。

·AGG-1A和AGG-2A上的对等链路端口通道1001，连接来自AGG-1A和AGG-2A之间的两条链路（15a和16a）。

·AGG-1A和AGG-2A上的VPC 11（端口通道11），连接来自AC-SW1的两条上行链路（11a和12a）。

·AGG-1A和AGG-2A上的VPC 12（端口通道12），连接来自AC-SW2的两条上行链路（13a和14a）。更多有关vPC配置的详细内容，请参考9.6节中“基本vPC配置”的内容。

·AC-SW1和AC-SW2端口通道配置如下：

·AC-SW1上的标准端口通道11连接通往AGG-1A和AGG-2A的上上行链路（11a和12a）。

·AC-SW2上的标准端口通道12连接通往AGG-1A和AGG-2A的上上行链路（13a和14a）。更多有关vPC配置的详细内容，请参考端口通道配置。

·所有的端口通道都为trunk模式，只负责传输VLAN 101（VM1和VM5）以及VLAN 102（VM2和VM6）上的网络流（参见图9-18）。

由于租户B属于外部用户，企业“M”的IaaS供应者（IT管理部门）决定不允许这些用户对其DC LAN基础设施拥有自主管理权限，所有管理都由IaaS供应商完成。图9-24展示了租户B的光纤模块设计高级视图。

图9-24中展示的租户B高级别光纤模块设计内容包括：

·4台“逻辑”Nexus 7010交换机：

·核心层交换机：CORE-1和CORE-2。

·汇聚层交换机：AGG-1和AGG-2。

·物理交换机总是配置了一个VDC，也是默认的VDC，在这一设计方案中，所有4个交换机都在默认VDC内。

·由于默认VDC负责管理物理交换机以及4个VDC，因此有必要对默认VDC做进一步划分。可以分别在租户B特定的CORE-1和CORE-2上，通过L3接口（或交换机虚拟接口）相关联的VRF（例如，使用VRF-B）完成。

说明：本书撰写之际，Nexus 7000系列交换机最多只能支持包括默认VDC的4个虚拟设备上下文（Virtual Device Context,VDC），企业“M”并不希望占用所有这些VDC，而是当发生租户B这类情况时，从中挑选一个实现L3的逻辑划分以便可以使用VRF而已。

·CORE-1和CORE-2上vPC配置如下：

·属于VPC Domain 201。

·CORE-1和CORE-2之间的2条链路（5b和6b）通过对等链路端口通道2002连接。

·CORE-1和CORE-2上的VPC 200（端口通道200），连接来自AGG-1的两条上行链路（1b和2b）。

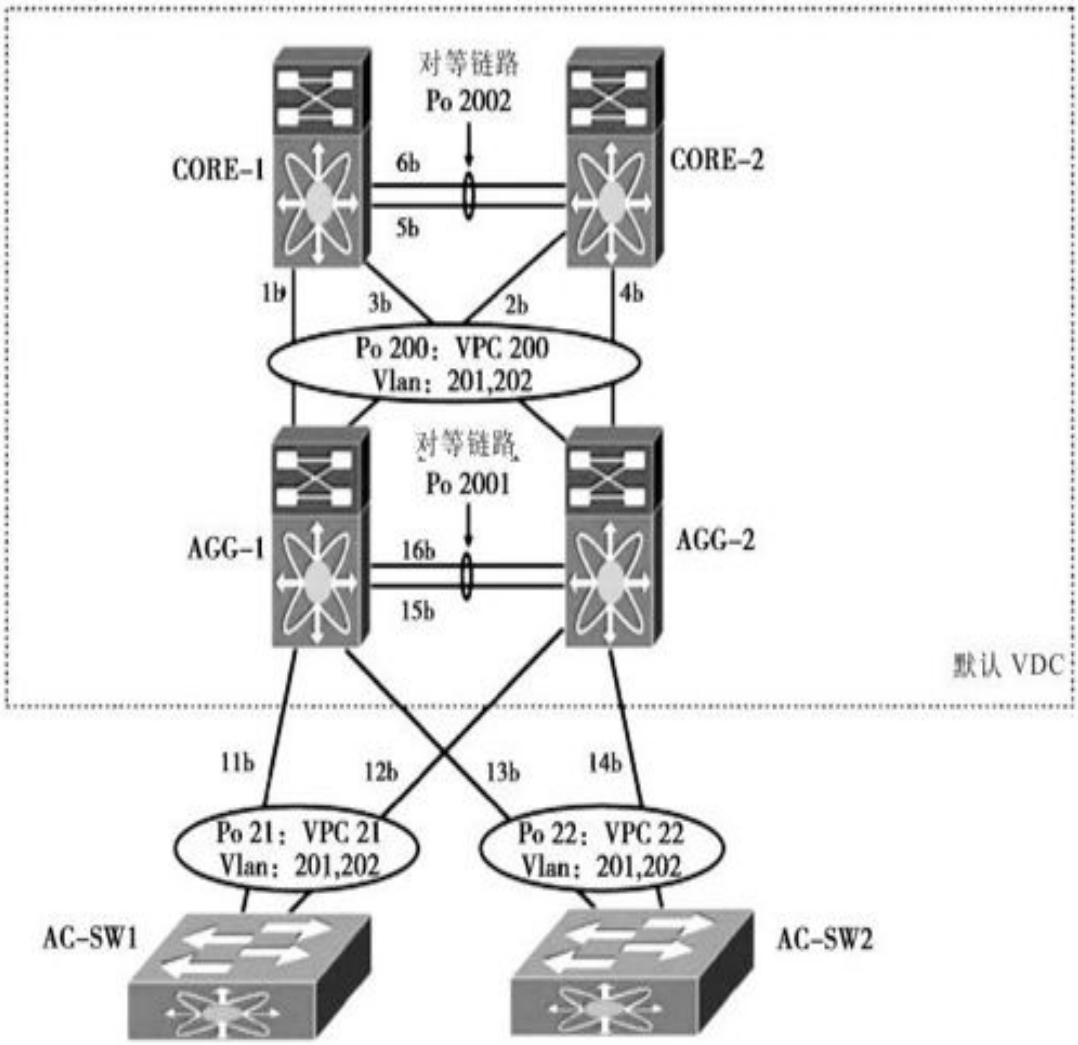


图　9-24　租户B的高级光纤模块设计

·CORE-1和CORE-2上的VPC 200（端口通道200），连接来自AGG-2的两条上行链路（3b和4b）。更多有关vPC配置的详细内容，请参考9.6节中“基本vPC配置”的内容。

·AGG-1和AGG-2上vPC配置如下：

·属于VPC Domain 202。

·AGG-1上的VPC 200（端口通道200）连接通往CORE-1和CORE-2的上行链路（1b和2b）。

·AGG-2上的VPC 200（端口通道200）连接通往CORE-1和CORE-2的上行链路（3b和4b）。

·AGG-1和AGG-2上的对等链路端口通道2001，连接来自AGG-1和AGG-2之间的两条链路（15b和16b）。

·AGG-1和AGG-2上的VPC 21（端口通道21），连接来自AC-SW1的两条上行链路（11b和12b）。

·AGG-1和AGG-2上的VPC 22（端口通道22），连接来自AC-SW2的两条上行链路（13b和14b）。更多有关vPC配置的详细内容，请参考9.6节中“基本vPC配置”的内容。

·AC-SW1和AC-SW2端口通道配置如下：

·AC-SW1上的标准端口通道21连接通往AGG-1和AGG-2的上上行链路（11b和12b）。

·AC-SW2上的标准端口通道22连接通往AGG-1和AGG-2的上上行链路（13b和14b）。更多有关vPC配置的详细内容，请参考端口通道配置。

·所有的端口通道都为trunk模式，只负责传输VLAN 201（VM3和VM4）以及VLAN 202（VM7和VM8）上的网络流（参见图9-18）。

9.8.5 服务汇聚层高级设计

在设计学习中，L3设计开始于核心层，它也是L2终止之处。服务汇聚层刚好就被安排在核心层之下，邻近汇聚层。图9-25描述了服务汇聚层设计的高级视图以及所有的物理拓扑情况。

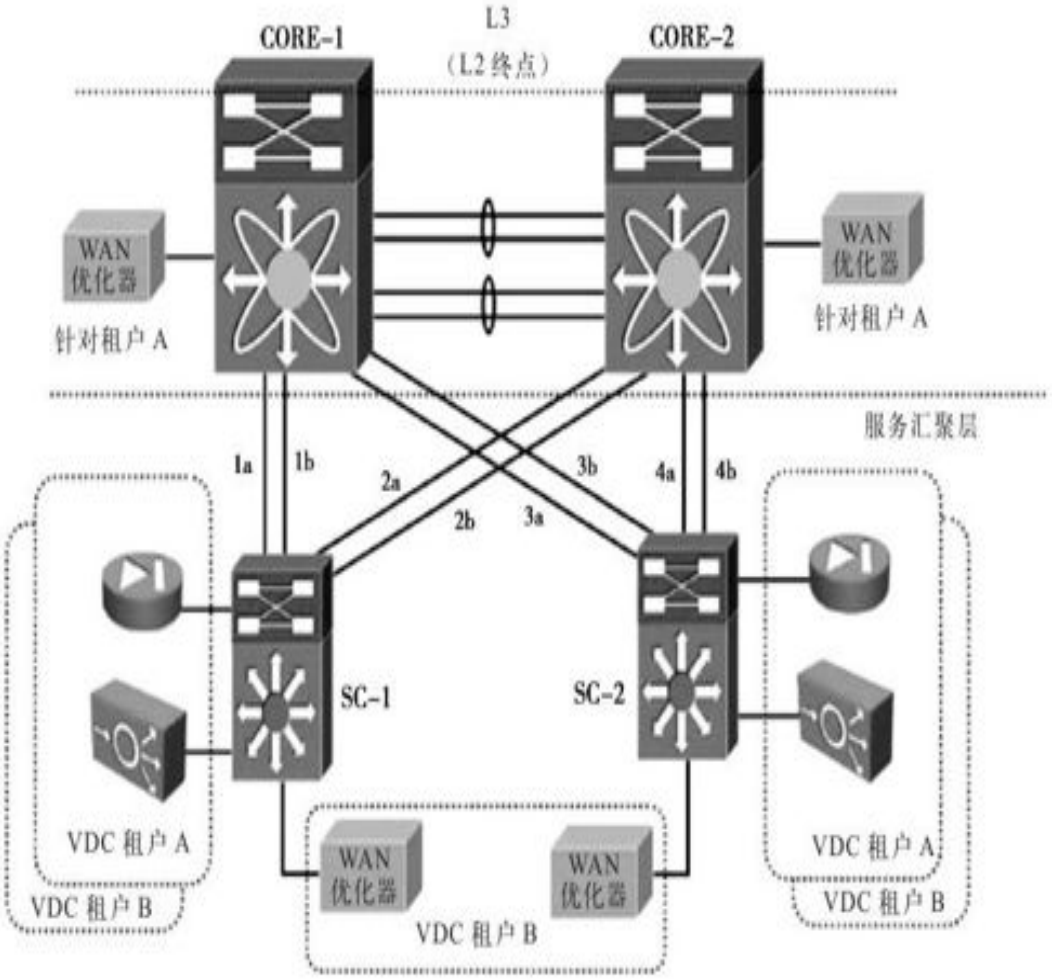


图 9-25 高级服务汇聚层设计

图9-25中展示的高级服务汇聚层设计包括以下内容：

·2台Cat6K服务机箱：SC-1和SC-2，每一台都配备了一个防火墙服务模块（Firewall Services Module,FWSM）以及一个应用控制引擎服务模块（Application Control Engine Service Module,ACESM）。

·在FWSM和ACESM模块上分别创建了2个VDC：

·租户A的VDC

·租户B的VDC

·现在分别将FWSM和ACESM的单独“逻辑实例”分配给每个租户的VDC。

·为了实现HA，每个租户上都分配了一对FWSM和ACESM。

·IaaS供应者只希望为这些FWSM和ACESM提供最基本的配置管理，其他VDC的管理任务将由租户自己完成，并且在必要时，完善相关配置。租户还需要确定FWSM和ACESM的工作模式，究竟采用透明模式，还是采用路由模式。

·FWSM VDC为特定租户提供基本必须的安全保护。

·租户A利用ACESM VDC来实现APP1服务链（VM1和VM5）上的负载平衡，以及APP2服务链（VM2和VM6）上的负载平衡。

·SC-1拥有4条上行链路：

·上行链路1a和2a分配给租户A的VDC。

·上行链路1b和2b分配给租户B的VDC。

·如果核心层交换机为这些链路配置了vPC，就需要配置相应的端口通道。

·SC-2拥有4条上行链路：

·上行链路3a和4a分配给租户A的VDC。

·上行链路3b和4b分配给租户B的VDC。

·如果核心层交换机为这些链路配置了vPC，就需要配置相应的端口通道。

·两对WAN优化器（Riverbed虚拟Steelhead设备VSH-2050-H）：

·CORE-1和CORE-2分别附加了一个WAN优化器，对租户A上的APP1和APP2网络传输进行优化（参见图9-18）。此时，由核心层交换机（CORE-1A和CORE-2A）上，租户A的VDC中运行的WCCPv2负责拦截和重定向。

·SC-1和SC-2分别附加了一个WAN优化器，对租户B上的APP1到APP4的网络传输进行优化（参见图9-18）。此时，由租

户B的ACESM VDC负责拦截和重定向。

·租户A使用WCCPv2进行网络流拦截，因为它们对支持WCCPv2的核心层交换机（CORE-1A和CORE-2A）拥有控制权。更多有关在NX7K交换机（CORE-1A和CORE-2A）上配置WCCPv2的信息，请参见6.3节。

·租户B使用ACESM VDC而非WCCPv2进行网络流拦截，因为它们对核心层交换机没有拥有控制权。更多有关配置ACESM VDC以及实施拦截的内容，请参见6.5节。

·租户上的WAN优化器，在逻辑上建立了一个WAN优化器集群，以达到HA/弹性目标。

·方案中，WAN优化器为UCS或通用服务器的VM上运行的虚拟设备，也可以是实际的物理设备。只是，与从云IaaS出发，虚拟设备比物理设备更容易实现，可扩展性也更好。

·IaaS供应者只会对这些WAN优化器进行最简单的配置，租户需要自己来管理各自的WAN优化器，在必要时，完善配置（包括HA的配置），租户还需要配置相应的拦截机制（租户A采用WCCPv2，而租户B采用ACESM），对正确的网络流（在租户A上是APP1到APP2，在租户B上是APP1到APP4）实施重定向优化。

说明：尽管Nexus 7000交换机支持WCCPv2功能，但是在本设计中并不做如此要求，因为已经为租户A分配了一个特定的核心层交换机VDC，换句话说，在核心层交换机CORE-1A和CORE-2A上，对租户A进行的WCCPv2配置可以被还原成普通的全局Ipv4地址空间。

·HSRP设置：

·租户A会将CORE-1A配置成主HSRP设备，将CORE-2A配置成从HSRP设备。

·IaaS供应者也会将CORE-1A配置成租户A的主HSRP设备，将CORE-2A配置成租户B的从HSRP设备。

·SC-1和SC-2（为了简便，未在图中标注）上的网络分析模块（Network Analysis Module,NAM）以及入侵检测系统服务模块（Intrusion Detection System Services Module,IDSM-2）：

·在虚拟接入层（参见图9-18）的NX1KV交换机上实现ERSPAN源会话，ERSPAN源会话执行GRE封装并转发镜像网络流（从VLAN101、102、201和202）到相应的SC-1和SC-2上的ERSPAN目标会话，ERSPAN目标会话执行GRE封装并将镜像网络流转发至相应的NAM和IDSM。更多ERSPAN配置的内容，请参考9.2.2节。

·本例中，IaaS供应商利用NAM和IDSM来实现内部审计和安全监控，它们对租户是透明的。

9.8.6 WAN模块高级设计

WAN模块将我们到目前为止的设计内容经WAN扩展至租户A和租户B的远程分支办公室（Remote Branch Offices,RBO）。此时，通过Internet而接入系统的租户A和租户B移动用户并没有最高优先级别，因而，不在本节讨论范围之内。企业“M”的IaaS供应者最迫切的需要是确保在两个远程分支站点上的云IaaS测试平台已经能够使用面向服务的基础设施（Service-Oriented Infrastructure,SOI）。图9-26展示了WAN模块设计的高级视图，在设计中涉及对等层以及未来WAN层。

图9-26中的高级WAN模块设计包括以下内容：

·企业DC内配备4个Cisco 7600路由：

·DC-PE1和DC-PE2构成对等层。

·DC-P1和DC-P2构成DMVPN hub（头端）路由。

·租户RBO上配备3个Cisco 2821路由：

·TA-PE1和TA-PE2位于租户A的RBO上。

·TB-PE1位于租户B的RBO上。

·分支路由均为IaaS提供并负责管理。

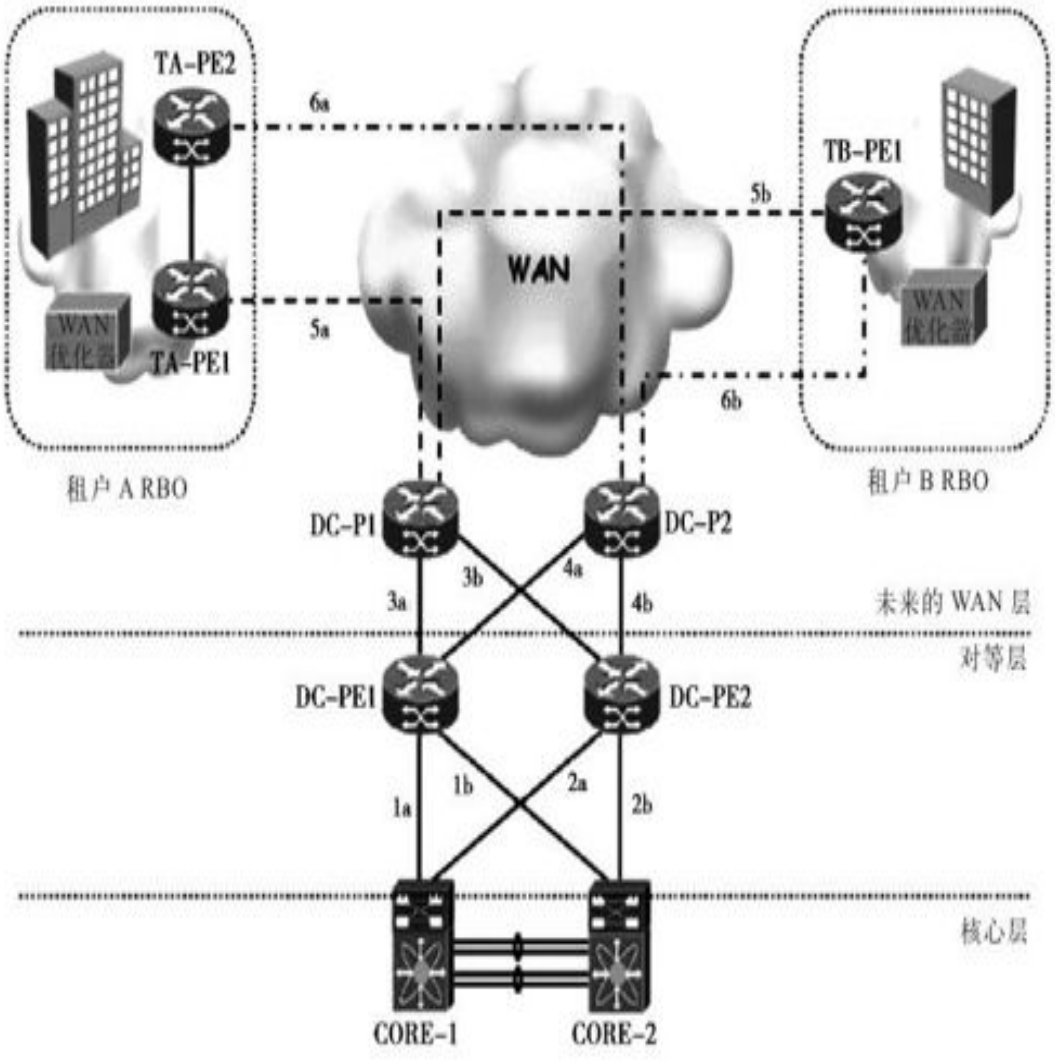


图　9-26　高级WAN模块设计

·集中星型DMVPN配置：

·DC-P1和DC-P2都是DMVPN hub路由，DC-P1为主hub,DC-P2为备份hub。

·TA-PE1、TA-PE2和TB-PE1都属于节点路由。

·DC-P1通过链路5a和5b连接TA-PE1和TB-PE1，相应地，分别为主（活动）GRE隧道。

·DC-P2通过链路6a和6b连接TA-PE2和TB-PE1，相应地，分别为备份（从）GRE隧道。

·这些GRE隧道都支持IPSec。

·设计中，通过控制路由参数来改变GRE隧道的主/从状态，降低了节电路由负载，能够更好地管理hub路由，获得稳定的性

能，同时也使得网络传输的路径更加清晰。更多有关DMVPN配置细节，请参考3.3.4节以及3.3.6节的相关内容。

·RBO上的冗余DMVPN配置：

·租户A拥有2个WAN（spoke）路由，TA-PE1和TA-PE2属于双层分支。相应地从TA-PE1到DC-P1以及从TA-PE2到DC-P2的DMVPN（GRE）隧道实现了必要的冗余。另一方面，TA-PE1和TA-PE2之间具备增强对象跟踪（Enhanced Object Tracking,EOT）功能的HSRP为分支上的终端用户提供了网络弹性。

·租户B只有1个WAN（spoke）路由TB-PE1，它属于单层分支。租户B拥有2条DMVPN（GRE）隧道，一条终点为DC-P1，另一条终点为DC-P2，如果主隧道发生故障，经过路由协议收敛，网络流传输将通过备份隧道完成。这样的设置没有考虑WAN路由器自身发生故障的情况。更多有关DMVPN冗余设计的细节，请参考本书第3章的相关内容。

·MPLS VPN的MPLS链路设计：

·链路3a、4a、5a（GRE隧道）以及6a（GRE隧道）

·链路3b、4b、5b（GRE隧道）以及6b（GRE隧道）

·多协议内部BGP（Multiprotocol internal BGP,MP-iBGP）对等配置：

·设计中，DC-P1和DC-P2一起作为路由反射器（Route-Reflectors,RR），组成了一个RR集群。

·DC-P1和DC-P2与所有的PE路由一起，包括DC-PE1、DC-PE2、TA-PE1，TA-PE2和TB-PE建立了MP-iBGP邻接，并负责将VPN路由分布到这些路由之间。

·DMVPN、MPLS以及MP-iBGP配置的整体目标是为每个租户建立一个DMVPN之上的MPLS，更多细节，请参考3.3.6节的相关内容。

·L3路径隔离的VRF配置：

·创建2个VRF：租户A的VRF-A以及租户B的VRF-B。

·链路1a、1b、2a和2b都属于802.1 trunk，在DC-PE1和DC-PE2上配置VRF-A，由它负责管理租户A传输子接口，配置

VRF-B，由它负责管理租户B传输子接口。

·核心层交换机（CORE-1和CORE-2）不需要配置VRF-A，因为系统早就为租户A的核心层交换机分配了VDC（CORE-1A和CORE-2A），更多细节请参考9.8.4节的相关内容。

·租户B的核心层交换机（CORE-1和CORE-2）需要配置VRF-B，此时，核心层交换机实际为多VRF路由。

·整个RBO中，只有TA-PE1和TA-PE2需要配置VRF-A，同样也只有TB-PE1需要配置VRF-B。

·最后，但也一样重要的是，IaaS供应者早已为每个租户在其相应的RBO上提供了一个WAN优化器（Riverbed Steelhead设备SH-1050-H），此时，租户需要决定安置WAN优化器的合适位置，并且完成相关的网络流拦截和重定向工作配置。

9.8.7 设计评价

要得到一个“10分”的设计总不是那么容易的，一个好的设计总是要受到来自不同技术和非技术因素的影响，以上介绍的各种方案希望能同时满足这两项要求。一方面，我们也希望能够避免某些烦人的细节而带来的信息冲击，另一方面，我们也力图使设计简洁而易于理解。这样的高级设计则有助于读者掌握整个云IaaS设计的原则。

我们的讨论从虚拟接入层开始，它正好也属于虚拟化的起步阶段，接下来我们探讨了计算子模块、存储模块、光纤模块、服务汇聚层，最终综合所有技术，通过WAN模块建立可靠的远程分支。

所有这些内容都有助于读者来理解成功建立一个面向服务的基础设施SOI所包含的基本概念，从而能够实现云IaaS服务。

9.9 小结

本章探讨了一系列设计方案，确保读者能够深入理解其中的内容，包括整合技术、虚拟化策略、SOI构造，最后能够完成私有云计算的部署工作，实现云IaaS服务。

初期的设计学习以虚拟接入层为主，因为它也是刚好是服务器虚拟化的前端。接下来，我们简单探讨了ERSPAN，以获得掩藏在虚拟接入层之后的网络流的可视性。然后，我们展示了一个简单的WAN优化案例，紧接着的内容与统一光纤设计有关，我们通过案例学习展示了在物理接入层，通过FCoE实现DC LAN与DC SAN统一的过程。这之后，讨论的主题转向了证明ToR架构能够促进“机架滚动”式服务器部署模型，vPC能够优化STP，而FCIP则能在WAN上提供健壮SAN扩展。我们将所有之前提到的零零碎碎的技术细节放在综合设计中，形成一张构建SOI的巨幅画卷（或完整地图），而在这之上就能够提供云IaaS服务了。

我们的私有云计算之旅终于要结束了，说再见之前，谢谢您一直忍受并陪伴着我们走完了这一段漫长而又不乏艰辛的路程。希望本书介绍的内容能够为您即将开始的云计算技术追寻带来帮助。

每一个终点同时也是一个新的起点。

——Cloud上尉，《Get Crazy》

附录　术语及缩略语

1GE（1 Gigabit Ethernet，1千兆以太网）

10GE（10 Gigabit Ethernet，10千兆以太网）

AAA（Authentication,Authorization and Accounting，认证、授权、审计）

ACE（Application Control Engine，应用控制引擎）

ACESM（Application Control Engine Service Module，应用控制引擎服务模块）

ACK（Acknowledge，应答）

ACL（Access Control List，访问控制列表）

ACN（Assignment Change Number，分配变更号）

ADM（Add/Drop Multiplexer，分插复用器）

AH（Additional Header，额外的标头）

AHS（Additional Header Segment，额外的标头片段）

AFID（Autonomous Fabric ID，自主光纤标识符）

ANSI（American National Standards Institute，美国国家标准学会）

API（Application Programming Interface，应用程序接口）

APP（Application，应用）

ARP（Address Resolution Protocol，地址解析协议）

AS（Autonomous System，自主系统）

ASIC（Application Specific Integrated Circuit，专用集成电路）

ASLR（Address Space Layout Randomization，地址空间加载随机化）

ASR1K（ASR 1000 Router,ASR 1000路由）

ATM（Asynchronous Transfer Mode，异步传输模式）

B2B（Buffer-to-Buffer，缓冲区到缓冲区）

BA（Bridge Assurance，桥接保证）

BB_Credit（Buffer-to-Buffer Credit，缓冲区到缓冲区信用数）

BC（Business Continuity，商业持久性）

BF（Build Fabric，构建光纤）

BGP（Border Gateway Protocol，边界网关协议）

BH（Basic Header，基本报头）

BIOS（Basic Input/Output System，基本输入/输出系统）

BLSR（Bidirectional Line Switch Ring，双向线路倒换环）

BPDU（Bridge Protocol Data Unit，桥协议数据单元）

BVI（Bridge-group Virtual Interface，桥组虚接口）

BW（Bandwidth，带宽）

C（Customer，顾客）

CAPEX（Capital Expenditures，资本支出）

CDB（Command Descriptor Block，命令描述符块）

CDP（Cisco Discovery Protocol,Cisco发现协议）

CE（Customer Edge，顾客边缘）

CEF（Cisco Express Forwarding,Cisco快速转发）

CFS（Cisco Fabric Services,Cisco光纤服务）

CHAP（Challenge Handshake Authentication Protocol，挑战握手认证协议）

CIA（Confidentiality,Integrity,and Availability，机密性、完整性、可用性）

CIFS（Common Internet File System，通用Internet文件系统）

CIMP（Cloud Infrastructure Management Platform，云基础设施管理平台）

CLI（Command Line Interface，命令行接口）

CN（Change Number，变更号）

CNA（Converged Network Adapter，聚合网络适配器）

CP（Congestion Point，拥塞点）

CPP（Control Path Processor，控制路径处理器）

CPU（Central Processing Unit，中央处理器）

CRC（Cyclic Redundancy Check，循环冗余校验）

CsC（Carrier support Carrier，运营商支持运营商）

CUG（Closed User Group，闭合用户群）

CWDM（Course Wavelength Division Multiplexing，稀疏波分复用）

CWM（Congestion Window Monitoring，拥塞窗口监控）

CoS（Class of Service，服务等级）

D_ID（Destination ID，目标ID）

DAI（Dynamic ARP Inspection，动态ARP探测）

DAS（Direct Attached Storage，直连式存储）

DC（Data Center，数据中心）

DCB（Data Center Bridging，数据中心桥接）

DCBX（Data Center Bridging Exchange，数据中心桥接交换）

DCNM（Data Center Network Manager，数据中心网络管理器）

DCU（Dispersion Compensation Unit，分散补偿单元）

DDR3（Double-Data-Rate 3，双倍速率同步动态随机存储器3）

DH-CHAP（Diffie Hellman Challenge Handshake Authentication Protocol,Diffie Hellman挑战握手认证协议）

DHCP（Dynamic Host Control Protocol，动态主机配置协议）

DiffServ（Differentiated Services，区分服务）

DIMM（Dual Inline Memory Module，双列直插式存储模块）

DMVPN（Dynamic Multipoint Virtual Private Network，动态多点虚拟私有网络）

DMZ（Demilitarized Zone，非军事化区）

DoS（Denial-of-Service，拒绝服务式）

DPC（Data Path Controller，数据路径控制器）

DPI（Deep Packet Inspection，深度包检测）

DR（Disaster Recovery，灾难恢复）

DSCP（Differentiated Services Code Point，差分服务代码点）

DST_VIF（Destination Virtual Interface Identifier，目标虚拟接口标识）

DVS（Distributed Virtual Switch，分布式虚拟交换机）

DWDM（Dense Wavelength Division Multiplexing，密集波分复用）

DWRR（Deficit Weighted Round Robin，亏损加权轮循）

E2E（End-to-End，端到端）

E-CE（Enterprise Customer Edge，企业——用户边缘）

E-PE（Enterprise Provider Edge，企业——供应商边缘）

E_Port（Expansion Port，扩展端口）

EDFA（Erbium-Doped Fibre Amplifier，掺铒光纤放大器）

ELP（Exchange Link Parameters，交换链路参数）

Enode（End Node，端节点）

EOF（End-of-Frame，帧尾）

EOT（Enhanced Object Tracking，增强的对象跟踪）

ERSPAN（Encapsulated Remote Switched Port Analyzer，封装远程交换端口分析器）

ESC（Exchange Switch Capabilities，交换机能力交互）

ESCON（Enterprise System Connection，管理系统连接）

Eth（Ethernet，以太网）

ETS（Enhanced Transmission Selection，增强传输选择）

ETSI（European Telecommunications Standards Institute，欧洲电信标准化协会）

EUI（Extended Unique Identifier，扩展唯一标识符）

F_Port（Fabric Port，光纤端口）

FAIS（Fabric Application Interface Standard，光纤架构应用接口标准）

FC（Fibre Channel，光纤通道）

FC-BB（Fibre Channel Backbone，光纤通道骨干）

FC-SP（Fibre Channel Security Protocols，光纤通道安全协议）

FCC（Fibre Channel Congestion Control，光纤通道拥塞控制）

FCF（FCoE Forwarder,FCoE转发器）

FCIP（Fibre Channel over IP,IP上的光纤通道）

FCIP_DE（FCIP Data Engine,FC数据引擎）

FCIP_LEP（FCIP Link End Point,FCIP链路端点）

FCNS（Fibre Channel Name Server,FC命名服务器）

FCP（FC Protocol,FC协议）

FCS（Frame Check Sequence，帧检验序列）

FCoE（Fibre Channel over Ethernet，光纤通道以太网）

FCoE_LEP（FCoE Link End Point,FCoE链路端点）

FC_ID（Fibre Channel Identifier，光纤通道标识符）

FC-MAP（FCoE MAC Address Prefix,FCoE MAC地址前缀）

FDISC（Discover Fabric Service Parameters，发现光纤服务参数）

FEC（Forwarding Equivalence Class，转发等价类）

FEX（Fabric Extender,FEX扩展器）

FICON（Fibre Connection，光纤连接）

FIP（FCoE Initialization Protocol,FCoE初始化协议）

FLOGI（Fabric Login，光纤登录）

FM（Fabric Manager，光纤管理器）

FPMA（Fabric Provided MAC Address，光纤提供的MAC地址）

FQDN（Fully Qualified Domain Name，完整认证域名）

FSF（FCIP Special Frames,FCIP特定帧）

FSPF（Fabric Shortest Path First，光纤最短路径优先）

FTP（File Transfer Protocol，文件传输协议）

FWSM（Firewall Service Module，防火墙服务模块）

GBIC（Gigabit Interface Converter，千兆位电信号转换接口）

Gbps（Gigabits per second，每秒千兆位）

GE（Gigabit Ethernet，千兆以太网）

GFP（Generic Framing Procedure，通用成帧规程）

GLBP（Gateway Load Balancing Protocol，网关负载均衡协议）

GRE（Generic Routing Encapsulation，通用路由协议封装）

GUI（Graphical User Interface，图形用户接口）

HA（High Availability，高可获得性）

HAL（Hardware Abstraction Layer，硬件抽象层）

HBA（Host Bus Adapter，主机总线适配器）

HBH（Hop-By-Hop，逐跳）

HIA（Here_I_Am，我在这里）

HOL（Head-Of-Line，线头）

HSRP（Hot Standby Router Protocol，热备份路由协议）

HTML（Hypertext Markup Language，超文本标记语言）

HTTP（Hypertext Transfer Protocol，超文本传输协议）

HTTPS（Hypertext Transfer Protocol Secure，超文本传输安全协议）

IaaS（Infrastructure-as-a-Service，基础设施即服务）

ICMP（Internet Control Message Protocol,Internet控制报文协议）

ID（Identifier，标识符）

IETF（Internet Engineering Task Force,Internet工程任务组）

Ifcp（Internet Fibre Channel Protocol，互联网光纤通道协议）

IFT（Isolated Fabric Topology，孤立的光纤拓扑）

IGMP（Internet Group Management Protocol,Internet组管理协议）

IGP（Interior Gateway Protocol，内部网关协议）

IKE（Internet Key Exchange,Internet密钥交换）

INCITS（International Committee for Information Technology Standards，国际信息技术标准委员会）

I/O（Input/Output，输入/输出）

IP（Internet Protocol,Internet协议）

IPC（Inter Processor Communication，进程间通信）

IPPCP（IP Payload Compression,IP有效负载压缩）

IPS（Intrusion Protection System，指令包含系统）

IPSec（Internet Protocol Security,IP安全协议）

IQN（iSCSI Qualified Name，认证名称）

IRB（Integrated Routing and Bridging，路由和桥接集成）

iSCSI（Internet Small Computer System Interface,Internet小型计算机系统接口）

ISL（Inter-Switch Link，内部交换机链路）

ISO（International Organization for Standardization，国际标准化组织）

ISR（Integrated Services Router，集成服务路由）

IS-IS（Intermediate System to Intermediate System，中间系统到中间系统）

iSNS（Internet Storage Name Service,Internet存储命名服务）

ISU（I_See_You，我看见你了）

IT（Information Technology，信息技术）

ITU（International Telecommunication Union，国际电信联盟）

ITU-T（ITU Telecommunication Standardization Sector，国际电信联盟远程通信标准化组）

IVR（Inter-VSAN Routing,VSAN间路由）

JBOD（Just a Bunch of Disks，磁盘簇）

JPEG（Joint Photographic Experts Group，联合图像专家小组）

L1（Layer 1，层1）

L2（Layer 2，层2）

L2MP（L2 Multi-Path,L2多路径）

L2TPv3（Layer 2 Tunneling Protocol version 3，第2层隧道协议第3版）

L3（Layer 3，层3）

LACP（Link Aggregation Control Protocol，链路汇聚控制协议）

LAN（Local Area Network，局域网）

LB（Load-Balancing，负载平衡）

LBA（Logical Block Address，逻辑块地址）

LCAS（Link Capacity Adjustment Scheme，链路容量调整）

LDP（Label Distribution Protocol，标签分布路径）

LER（Label Edge Router，标签边缘路由）

LSP（Label Switched Path，标签分布路径）

LSR（Label Switch Router，标签分布路由）

LU（Logical Unit，逻辑单元）

LUN（Logical Unit Number，逻辑单元号）

MAC（Media Access Control，介质访问控制）

MAC-DA（MAC Destination Address,MAC目标地址）

MAC-SA（MAC Source Address,MAC源地址）

MAN（Metro Area Network，城域网）

MAPI（Messaging Application Programming Interface，邮件撰写应用程序接口）

MCN（Membership Change Number，成员信息变更序号）

MEC（Multichassis EtherChannel，多机箱以太通道）

mGRE（Multipoint GRE，多点GRE）

MITM（Man-In-The-Middle，中间人）

MP-BGP（Multiprotocol BGP，多协议BGP）

MP-eBGP（Multiprotocol external BGP，多协议外部BGP）

MP-iBGP（Multiprotocol internal BGP，多协议内部BGP）

MPLS（Multiprotocol Label Switching，多协议标签交换）

MSFC（Multilayer Switch Feature Card，多层交换特性卡）

MTU（Maximum Transmission Unit，最大传输单元）

MWS（Maximum Window Size，最大窗口尺寸）

N_Port（Node Port，节点端口）

NAA（Network Address Authority，网络地址授权）

NAM（Network Analysis Module，网络分析模块）

NBAR（Network Based Application Recognition，基于网络的应用程序识别）

NAS（Network-Attached Storage，网络连接式存储）

NAT（Network Address Translation，网络地址转换）

NFS（Network File System，网络文件系统）

NHRP（Next Hop Resolution Protocol，下一跳解析协议）

NIC（Network Interface Card，网络接口卡）

NIST（National Institute of Standards and Technology，美国国家技术与标准局）

NOC（Network Operations Center，网络运行中心）

NPIV（N_Port ID Virtualization,N_PortID虚拟化）

NP_Port（Proxy N_Port，代理N_Port）

NSV（Not-So-VRF，非VRF）

nWWN（Node World Wide Name，节点全球名称）

NX（No Execute，不执行）

N_Port（Node Port，节点端口）

OADM（Optical Add Drop Multiplexer，光分插复用）

OAM & P（Operations,Administration,Maintenance and Provisioning，操作、管理、维护、服务）

OC（Optical Carrier，光载波）

OPEX（Operation Expenditures，操作代价）

OS（Operating System，操作系统）

OSPF（Open Shortest Path First，开放式最短路径优先）

OUI（Organization Unique Identifier，组织唯一标识符）

OVF（Open Virtualization Format，公开虚拟化格式模板）

OX_ID（Originator Exchange ID，始发交换ID）

P2P（Point-to-Point，点到点）

P（Provider，供应者）

PaaS（Platform-as-a-Service，平台即服务）

PBR（Policy-based Routing，策略路由）

PC（Personal Computer，个人电脑）

PDAs（Personal Digital Assistant，个人数字助理）

PDP（Policy Decision Point，策略决策点）

PDU（Protocol Data Unit，协议数据单元）

PE（Provider Edge，供应者边缘）

PEP（Policy Enforcement Point，策略强化点）

PE_Port（Physical E_Port，物理E端口）

PFC（Priority-based Flow Control，基于优先级的流控制）

PFC3（Policy Feature Card 3，协议特征卡3）

PF_Port（Physical F_Port，物理F端口）

PG（Priority Group，优先级组）

PGID（Priority Group ID，优先级组ID）

PLM（Product Lifecycle Management，产品生命周期管理）

PMTU（Path MTU，路径MTU）

PMTUD（Path MTU Discovery，路径MTU发现）

PNG（Portable Network Graphics，便携式网络图形）

PN_Port（Physical N_Port，物理N端口）

Po（Port Channel，端口通道）

POI（Point-of-Interception，拦截点）

PPMN（Path-Protected Mesh Network，路径保护网状网络）

PPRC（Peer-to-Peer Remote Copy，端到端远程复制）

PVLAN（Private VLAN，私有VLAN）

pWWN（Port World Wide Name，端口全局名）

QoS（Quality of Service，服务质量）

QCN（Quantized Congestion Notification，量化的拥塞通告）

R2T（Ready to Transfer，传输就绪）

R_RDY（Receiver Ready，接收方就绪）

R_T_TOV（Receiver Transmitter Time-Out Value，收发方超时值）

RA（Redirect_Assign，重定向分配）

RAID（Redundant Array of Independent Disks，独立磁盘冗余阵列）

RAM（Random Access Memory，随机存取存储器）

RAS（Reliability,Availability and Serviceability，可靠性、可获得性、可服务性）

RBO（Remote Branch Office，远程分支办公室）

RCF（Reconfigure Fabric，光纤冲配置）

RD（Route Distinguisher，路由标识符）

RDBMS（Relational Database Management System，关系数据库管理系统）

RDM（Raw Device Mapping，裸设备映射）

RDP（Remote Desktop Protocol，远程桌面协议）

RIPv2（Routing Information Protocol version 2，距离矢量路由协议版本2）

RP（Reaction Point，反应点）

RPO（Recovery Point Objective，恢复点目标）

RQ（Removal_Query,Removal_查询）

RR（Route Reflector，路由反射器）

RU（Rack Unit，机架单元）

RSP（Response，响应）

RTO（Recovery Time Objective，恢复时间目标）

RTT（Round-Trip Time，轮询时间）

RX_ID（Responder Exchange ID，响应者交换ID）

S_ID（Source ID，源ID）

SaaS（Software-as-a-Service，软件即服务）

SACK（Selective Acknowledgment，选择性确认）

SAN（Storage Area Network，存储网络）

SCSI（Small Computer System Interface，小型计算机系统接口）

SDH（Synchronous Digital Hierarchy，及同步数字系列）

SDR（Scalable Data Referencing，可扩展数据简化）

SFP（Small Form-Factor Pluggable，小封装可插拔）

SG（Service Group，服务组）

SLA（Service Level Agreement，服务等级协议）

SLB（Server Load-Balancer，服务负载平衡）

SLPv2（Service Location Protocol version 2，服务定位协议第2版）

SMB（Small to Medium Business，中小型商务领域）

SME（Small and Medium Enterprise，中小型企业）

SNIA（Storage Networking Industry Association，全球网络存储工业协会）

SOAP（Simple Object Access Protocol，简单对象接入协议）

SOF（Start-of-Frame，帧首）

SOI（Service-Oriented Infrastructure，面向服务的基础设施）

SONET（Synchronous Optical Networking，同步光纤网）

SP（Service Provider，服务提供者）

SPAN（Switched Port Analyzer，交换端口分析器）

SPKM（Simple Public Key Mechanism，简单公共密钥机制）

SPMA（Server Provided MAC Address，服务器提供的MAC地址）

SRC_VIF（Source Virtual Interface Identifier，源虚拟接口标识）

SRDF（Symmetrix Remote Data Facility，远程数据设备）

SRP（Secure Remote Password，远程密码安全）

SSH（Secure Shell，安全外壳）

SSO（Stateful Switchover，稳定的交换机切换）

STP（Spanning Tree Protocol，生成树协议）

SVI（Switch Virtual Interface，交换机虚拟接口）

SW_ILS（Switch Internal Link Services，交换机内部链路服务）

TCO（Total Cost of Ownership，总体拥有成本）

TFO（Transport Flow Optimization，传输流优化）

TCP（Transmission Control Protocol，传输控制协议）

TDM（Time-Division Multiplexing，时分复用）

TLV（Type-Length-Value，类型-长度-值）

TMN（Telecommunication Management Network，电信管理网）

TOE（TCP Offload Engine,TCP卸载引擎）

ToR（Top-of-Rack，架顶式）

TPM（Trusted Platform Module，可信平台模块）

TRILL（Transparent Interconnection of Lots of Links，多链接半透明互联）

TXT（Trusted Execution Technology，可信执行技术）

UCS（Unified Computing System，统一计算系统）

UCSM（UCS Manager,UCS管理器）

UFT（Unified Fabric Topology，统一光纤拓扑）

ULP（Upper Level Protocol，上层协议）

UPSR（Unidirectional Path Switch Ring，双纤单向通道倒换环）

URL（Uniform Resource Locator，统一资源定位符）

UUID（Unique User ID，唯一用户ID）

VC（Virtual Circuit，虚拟电路）

VCAT（Virtual Concatenation，虚拟级联）

VCI（Virtual Circuit Identifier，虚拟回路标识）

VDC（Virtual Device Context，虚拟设备上下文）

VDI（Virtual Desktop Infrastructure，虚拟桌面接口）

vDS（vNetwork Distributed Switch，虚拟网络分布式交换机）

VEM（Virtual Ethernet Module，虚拟以太网模块）

VE_Port（Virtual E_Port，虚拟E端口）

vEth（Virtual Ethernet，虚拟以太网）

VFC（Virtual Fibre Channel，虚拟光纤通道）

VF_Port（Virtual F_Port，虚拟F端口）

VIM（Virtual Infrastructure Methodology，虚拟基础架构方法体系）

VIP（Virtual IP，虚拟IP）

VLAN（Virtual LAN，虚拟LAN）

VM（Virtual Machine，虚拟机）

VMFS（Virtual Machine File System，虚拟机文件系统）

VMM（Virtual Machine Monitor，虚拟机监控器）

VN（Virtual Network，虚拟网络）

VNTag（Virtual NIC Tag，虚拟NIC标签）

VN_Port（Virtual N_Port，虚拟N端口）

VOA（Variable Optical Attenuator，可调光衰减器）

vPC（Virtual Port Channel，虚拟端口通道）

vPC HM（vPC Host Mode,vPC主机模式）

VPI（Virtual Path Identifier，虚拟路径标识）

VPN（Virtual Private Network，虚拟私有网络）

VRF（Virtual Routing and Forwarding，虚拟路由和转发）

VRRP（Virtual Router Redundancy Protocol，虚拟路由冗余协议）

VSAN（Virtual SAN，虚拟SAN）

VSB（Virtual Service Blade，虚拟服务器刀片）

VSG（Virtual Security Gateway，虚拟安全网关）

VSI（Virtual Storage Infrastructure，虚拟存储基础设施）

VSM（Virtual Supervisor Module，虚拟监视器模块）

vSS（vNetwork Standard Switch，虚拟网络标准交换机）

VSS（Virtual Switching Systems，虚拟交换系统）

WAAS（Wide Area Assplication Services，广域应用服务）

WAN（Wide Area Network，广域网）

WCCP（Web Cache Communication Protocol,web缓存通信协议）

WCCPv2（Web Cache Communication Protocol version 2，Web缓存通信协议第2版）

WDM（Wavelength Division Multiplexing，波分复用）

WKP（Well-Known Port，知名端口）

WSDL（Web Services Description Language,Web服务描述语言）

WWN（World Wide Name）

WWW（WorldWideWeb）

XFER_RDY（Transfer Ready，传输就绪）

XML（Extensible Markup Language，可扩展标记语言）

参考文献

以下是除本书之外的其他参考文献，按章节编号组织，以便读者能够更深入地了解某个主题。外，我们还为读者提供了一部分其他参考资源，供读者进一步阅读。

前言和作者简介

[1] Smoot, S. R. (1998). Maximizing Perceived Quality Given Bit-Rate Constraints in MPEG Encoding Through Content-Adaptivity. (Doctoral dissertation). University of California at Berkeley (NRLF). (T7.6.1998 S666).

[2] Tan, N. K. (1999). Configuring Cisco Routers for Bridging, DLSw+, and Desktop Protocols. McGraw-Hill.

[3] Tan, N. K. (2003). Building VPNs with IPSec and MPLS. McGraw-Hill Professional.

[4] Tan, N. K. (2004). MPLS for Metropolitan Area Networks. Auerbach Publications.

[5] Thomas, T. M., Aelmans, A., Houniet, F., and Tan, N. K. (2000). Building Scalable Cisco Networks. McGraw-Hill.

第1章

[1] RAID, http://en.wikipedia.org/wiki/RAID.

[2] Cloud Computing - A Primer Part 1, http://www.cisco.com/web/about/ac123/ac147/archived_issues/ipj_12-3/123_cloud1.html.

[3] The NIST Definition of Cloud Computing, http://csrc.nist.gov/groups/SNS/cloud-computing/cloud-def-v15.doc.

[4] CIA Triad, http://en.wikipedia.org/wiki/CIA_triad#Key_concepts.

[5] Sandbox, http://en.wikipedia.org/wiki/Sandbox_(computer_security).

其他参考资源

E.G. Nadhan, Service-Oriented Cloud Computing Infrastructure, HP Technology Forum & Expo, 2009.

Energy-Efficient Unified Fabrics: Transform the Data Center Infrastructure with Cisco Nexus Series, http://www.cisco.com/en/US/prod/collateral/switches/ps9441/ps9670/white_paper_c11-508518.pdf.

第2章

[1] AMD-V, http://en.wikipedia.org/wiki/AMD-V#AMD_virtualization_.28AMD-V.29.
[2] Xen, http://en.wikipedia.org/wiki/Xen.
[3] Hyper-V, http://en.wikipedia.org/wiki/Hyper-V.
[4] Virtual Networking Features of the VMware vNetwork Distributed Switch and Cisco Nexus 1000V Switches, http://www.vmware.com/files/pdf/technology/cisco_vmware_virtualizing_the_datacenter.pdf.
[5] NX-OS, http://en.wikipedia.org/wiki/NX-OS.
[6] ISO file, http://en.wikipedia.org/wiki/Iso_file.
[7] Open Virtualization Format, http://en.wikipedia.org/wiki/Open_Virtualization_Format.
[8] Cisco Discovery Protocol, http://en.wikipedia.org/wiki/Cisco_Discovery_Protocol.
[9] Internet Group Management Protocol, http://en.wikipedia.org/wiki/IGMP.
[10] Stateful Switchover, http://www.cisco.com/en/US/docs/ios/12_0s/feature/guide/sso120s.html.
[11] VMware Virtual Infrastructure Methodology, http://www.vmware.com/pdf/vim_datasheet.pdf.
[12] Extensible Markup Language, http://en.wikipedia.org/wiki/XML.
[13] Encapsulated Remote Switched Port Analyzer, http://www.cisco.com/en/US/docs/switches/datacenter/nexus1000/sw/4_2_1_s_v_1_4/system_management/configuration/guide/n1000v_system_9span.html#wp1054701.
[14] Universally Unique Identifier, http://en.wikipedia.org/wiki/Uuid.
[15] Bridge Protocol Data Unit, http://en.wikipedia.org/wiki/BPDU#Bridge_Protocol_Data_Units_.28BPDUs.29.
[16] Logical Block Address, http://en.wikipedia.org/wiki/Logical_block_addressing.
[17] Command Descriptor Block, http://en.wikipedia.org/wiki/SCSI_CDB.
[18] ASIC, http://en.wikipedia.org/wiki/Application-specific_integrated_circuit.
[19] Cisco Storage Services Module, http://www.cisco.com/en/US/prod/collateral/modules/ps5991/ps6293/product_data_sheet0900aecd802496f7_ps5991_Products_Data_Sheet.html.
[20] EMC Invista, http://en.wikipedia.org/wiki/EMC_Invista.
[21] Transparent Interconnect of Lots of Links, http://en.wikipedia.org/wiki/TRILL_(Computer_Networking).
[22] Intermediate System to Intermediate System, http://en.wikipedia.org/wiki/IS-IS.
[23] Bisectional Bandwidth, http://en.wikipedia.org/wiki/Bisection_bandwidth.
[24] Hot Standby Router Protocol, http://en.wikipedia.org/wiki/Hot_Standby_Router_Protocol.
[25] Virtual Routing and Forwarding, http://en.wikipedia.org/wiki/VRF.
[26] Gratuitous ARP, http://en.wikipedia.org/wiki/Address_Resolution_Protocol#ARP_announcements.
[27] Robert W. Kembel, Fibre Channel: A Comprehensive Introduction, Northwest Learning Associates, Inc., December 7, 2009.
[28] Deficit-Weighted Round Robin, http://en.wikipedia.org/wiki/Deficit_Weighted_Round_Robin.
[29] Head-of-Line Blocking, http://en.wikipedia.org/wiki/Head-of-line_blocking.
[30] Cyclic Redundancy Check, http://en.wikipedia.org/wiki/Cyclic_redundancy_check.

其他参考资源

Cisco Nexus 1000V Series Switches Deployment Guide, Version 2, http://www.cisco.com/en/US/prod/collateral/switches/ps9441/ps9902/guide_c07-556626.html.

Cisco Service Delivery Center Infrastructure 2.1 Design Guide, http://www.cisco.com/en/US/solutions/ns340/ns394/ns50/net_design_guidance0900aecd806fe4bb.pdf.

Data Center Design with VMware ESX 4.0 and Cisco Nexus 5000 and 1000V Series Switches, http://www.cisco.com/en/US/prod/collateral/switches/ps9441/ps9670/C07-572832-00_VMware_ESX4_Nexus_DG.pdf.

Data Center Bridging, http://www.cisco.com/en/US/solutions/collateral/ns340/ns517/ns224/ns783/at_a_glance_c45-460907.pdf.

Evolving Data Center Architectures: Meet the Challenge with Cisco Nexus 5000 Series Switches, http://www.cisco.com/en/US/solutions/collateral/ns340/ns517/ns224/ns783/white_paper_c11-473501.html.

Deploying 10 Gigabit Ethernet with Cisco Nexus 5000 Series Switches, http://www.cisco.com/en/US/prod/collateral/switches/ps9441/ps9670/white_paper_c27-489248_ns783_Networking_Solutions_White_Paper.html.

Data Center Top-of-Rack Architecture Design, http://www.cisco.com/en/US/prod/collateral/switches/ps9441/ps9670/white_paper_c11-522337.html.

FC-BB-5, http://www.t11.org/ftp/t11/pub/fc/bb-5/09-056v5.pdf.

S. Gai, C. DeSanti, I/O Consolidation in the Data Center, Cisco Press, September 18, 2009.

An Introduction to Fibre Channel over Ethernet, and Fibre Channel over Convergence Enhanced Ethernet, http://www.redbooks.ibm.com/redpapers/pdfs/redp4493.pdf.

R.W. Kembel, Fibre Channel over Ethernet (FCoE), Northwest Learning Associates, Inc., January 1, 2010.

VMware Infrastructure 3 in a Cisco Network Environment, http://www.cisco.com/application/pdf/en/us/guest/netsol/ns304/c649/ccmigration_09186a00807a15d0.pdf.

Cisco Nexus 1000V System Management Configuration Guide, http://www.cisco.com/en/US/docs/switches/datacenter/nexus1000/sw/4_2_1_s_v_1_4/system_management/configuration/guide/n1000v_system.html.

Cisco Nexus 1000V High Availability and Redundancy Configuration Guide, http://www.cisco.com/en/US/docs/switches/datacenter/nexus1000/sw/4_2_1_s_v_1_4/high_availability/configuration/guide/n1000v_ha_cfg.html.

Designing Cisco Storage Networking Solutions (DCSNS), v3.0, Student Courseware, Cisco Training.

第3章

[1] Closed User Group, http://en.wikipedia.org/wiki/Closed_User_Group_(CUG).
[2] Virtual Private Network, http://en.wikipedia.org/wiki/Vpn.
[3] Routing Information Protocol, Version 2, http://en.wikipedia.org/wiki/RIPv2.
[4] Open Shortest Path First, http://en.wikipedia.org/wiki/Ospf.
[5] Border Gateway Protocol, http://en.wikipedia.org/wiki/Bgp.
[6] Generic Routing Encapsulation, http://en.wikipedia.org/wiki/Generic_Routing_Encapsulation.
[7] Time-Division Multiplexing, http://en.wikipedia.org/wiki/Time-division_multiplexing.
[8] Asynchronous Transfer Mode, http://en.wikipedia.org/wiki/Asynchronous_Transfer_Mode.
[9] Synchronous Optical Networking, http://en.wikipedia.org/wiki/Synchronous_optical_networking.
[10] Multiprotocol Label Switching, http://en.wikipedia.org/wiki/Multiprotocol_Label_Switching.
[11] Dynamic Multipoint Virtual Private Network, http://en.wikipedia.org/wiki/Dmvpn.
[12] Carrier Supporting Carrier, http://www.cisco.com/en/US/docs/ios/12_0st/12_0st14/feature/guide/csc.html.
[13] Layer 2 Tunneling Protocol Version 3, http://en.wikipedia.org/wiki/L2TPv3.
[14] Label Distribution Protocol, http://en.wikipedia.org/wiki/Label_Distribution_Protocol.
[15] Multiprotocol Extensions for BGP-4, http://tools.ietf.org/html/rfc4760.
[16] Internet Protocol Security, http://en.wikipedia.org/wiki/Ipsec.
[17] Internet Key Exchange, http://en.wikipedia.org/wiki/Internet_Key_Exchange.
[18] Virtual Router Redundancy Protocol, http://en.wikipedia.org/wiki/Vrrp.
[19] Gateway Load Balancing Protocol, http://en.wikipedia.org/wiki/GLBP.
[20] Enhanced Object Tracking, http://www.cisco.com/en/US/docs/ios/12_2t/12_2t15/feature/guide/fthsrptk.html.

其他参考资源

Data Center Service Integration: Service Chassis Design Guide, http://www.cisco.com/en/US/docs/solutions/Enterprise/Data_Center/dc_servchas/service-chassis_design.html.
V. Moreno, K. Reddy, Network Virtualization, Cisco Press, July 29, 2006.
Network Virtualization—Path Isolation Design Guide, http://www.cisco.com/en/US/docs/solutions/Enterprise/Network_Virtualization/PathIsol.html.
Next-Generation Enterprise MPLS, VPN-Based WAN Design and Implementation Guide, http://www.cisco.com/en/US/docs/solutions/Enterprise/WAN_and_MAN/ngwane.pdf.
Service Module Design with ACE and FWSM, http://www.cisco.com/application/pdf/en/us/guest/netsol/ns376/c649/ccmigration_09186a008078de90.pdf.
Designing Cisco Network Service Architectures (ARCH), v2.0, Student Courseware, Cisco Training.

第4章

[1] V. Jacobson, R. Braden, TCP extensions for long-delay paths, IETF RFC 1323, http://www.ietf.org/rfc/rfc1072.txt, 1988.
[2] M. Mathis, J. Semke, J. Mahdavi, T. Ott, Macroscopic behavior of the TCP congestion avoidance algorithm, Computer Commun. Rev. 27 (1977) 67–82.
[3] J. Ziv, A. Lempel, Compression of Individual Sequences via Variable-Rate Coding, IEEE Transactions on Information Theory (1978).
[4] Squid Configuration Directives, http://www.squid-cache.org/Doc/config/.
[5] Microsoft® Exchange 2010®/Outlook 2010 Performance with Riverbed® WAN Optimization, Riverbed White Paper (2011).
[6] V. Jacobson, M. Karels, Congestion Avoidance and Control, Proc. Sigcomm '88 Symp 18 (4) (1988) 314–329.
[7] S. Floyd, HighSpeed TCP for Large Congestion Windows, IETF RFC 3649, (2003), http://www.ietf.org/rfc/rfc3649.txt.
[8] S. Floyd, Limited Slow-Start for TCP with Large Congestion Windows, IETF RFC 3742, (2003), http://www.ietf.org/rfc/rfc3742.txt.
[9] High-Speed TCP for Long Fat Networks, Riverbed White Paper (2010).
[10] Citrix Branch Repeater VPX 5.6, Citrix Product Manual, http://support.citrix.com/product/brrepeat/vVPX5.6/#tab-docCitrix.
[11] Cisco Wide Area Application Services Configuration Guide, Cisco Product Guide, http://www.cisco.com/en/US/docs/app_ntwk_services/waas/waas/v401/configuration/guide/intro.html.
[12] Riverbed Cloud Services Deployment Guide, Riverbed Product Manual, http://support.riverbed.com, 2001.

第5章

其他参考资源

BRKAPP-2021, Deploying and Troubleshooting Web Cache Communication Protocol (WCCP) for WAN Acceleration, Security and Content Delivery, Cisco Live 2010 Presentation.
Cisco WAAS Deployment Using Web Cache Communication Protocol, version 2 (WCCPv2), Cisco Public White Paper.
Configuring WCCP, http://www.cisco.com/en/US/partner/docs/ios/ipapp/configuration/guide/ipapp_wccp_ps6441_TSD_Products_Configuration_Guide_Chapter.html.
PBR Support for Multiple Tracking Options, http://www.cisco.com/en/US/partner/docs/ios/iproute_pi/configuration/guide/iri_prb_mult_track_ps6441_TSD_Products_Configuration_Guide_Chapter.html.
Web Cache Communication Protocol V2.0, https://tools.ietf.org/html/draft-wilson-wrec-wccp-v2-00.

第6章

其他参考资源

Administration Guide, Cisco ACE Application Control Engine Module, http://www.cisco.com/en/US/docs/interfaces_modules/services_modules/ace/vA4_1_0/configuration/administration/guide/admgd.html.
Cisco Nexus 7000 Series NX-OS Unicast Routing Configuration Guide, http://www.cisco.com/en/US/docs/switches/datacenter/sw/5_x/nx-os/unicast/configuration/guide/l3_cli_nxos.html.
Cisco Nexus 7000 Series NX-OS Virtual Device Context Configuration Guide, http://www.cisco.com/en/US/docs/switches/datacenter/sw/5_x/nx-os/virtual_device_context/configuration/guide/vdc_nx-os_cfg.html.
Cisco Virtual Wide Area Application Services: Cloud-Ready WAN Optimization Solution, http://www.cisco.com/en/US/prod/collateral/contnetw/ps5680/ps11231/solution_overview_c22-620028.html.
Cisco Virtual Wide Area Application Services: Technical Overview, http://www.cisco.com/en/US/prod/collateral/contnetw/ps5680/ps11231/technical_overview_c17-620098.html.
MPLS VPN VRF Selection Using Policy Based Routing, http://www.cisco.com/en/US/docs/ios/12_2s/feature/guide/fs_pbrsv.html#wp1043334.
Getting Started Guide, Cisco ACE Application Control Engine Module, http://www.cisco.com/en/US/docs/interfaces_modules/services_modules/ace/vA4_1_0/configuration/getting/started/guide/ACE_GSG.html.
Routing and Bridging Guide, Cisco ACE Application Control Engine Module, http://www.cisco.com/en/US/docs/interfaces_modules/services_modules/ace/vA4_1_0/configuration/rtg_brdg/guide/rtbrgdgd.html.
Security Guide, Cisco ACE Application Control Engine Module, http://www.cisco.com/en/US/docs/interfaces_modules/services_modules/ace/vA4_1_0/configuration/security/guide/securgd.html.
Server Load-Balancing Guide, Cisco ACE Application Control Engine Module, http://www.cisco.com/en/US/docs/interfaces_modules/services_modules/ace/vA4_1_0/configuration/slb/guide/slbgd.html.
Virtualization Guide, Cisco ACE Application Control Engine Module, http://www.cisco.com/en/US/docs/interfaces_modules/services_modules/ace/vA4_1_0/configuration/virtualization/guide/virtgd.html.
Designing Data Center Application Services (DCASD), v2.0, Student Courseware, Cisco Training.
Implementing Data Center Application Services (DCASI), v2.0, Student Courseware, Cisco Training.

第7章

[1] Dense Wavelength Division Multiplexing, http://en.wikipedia.org/wiki/Wavelength-division_multiplexing#Dense_WDM.
[2] Coarse Wavelength Division Multiplexing, http://en.wikipedia.org/wiki/Wavelength-division_multiplexing#Coarse_WDM.
[3] Synchronous Digital Hierarchy, http://en.wikipedia.org/wiki/Synchronous_Digital_Hierarchy.
[4] Fabric Shortest Path First, http://en.wikipedia.org/wiki/FSPF.
[5] Enterprise System Connection, http://en.wikipedia.org/wiki/ESCON.
[6] Fiber Connection, http://en.wikipedia.org/wiki/FICON.
[7] Gigabit Interface Converter, http://en.wikipedia.org/wiki/Gbic.
[8] Small Form-Factor Pluggable Transceiver, http://en.wikipedia.org/wiki/Small_form-factor_pluggable_transceiver.
[9] Generic Framing Procedure, http://en.wikipedia.org/wiki/Generic_Framing_Procedure.
[10] 8b/10b Encoding, http://en.wikipedia.org/wiki/8B/10B.
[11] Internet Fibre Channel Protocol, http://en.wikipedia.org/wiki/IFCP.
[12] R.W. Kembel, Fibre Channel Switched Fabric, Northwest Learning Associates, Inc., December 7, 2009.
[13] Fibre Channel Network Protocols, http://en.wikipedia.org/wiki/Fibre_Channel_network_protocols.
[14] Path MTU Discovery, http://en.wikipedia.org/wiki/Path_MTU_Discovery.
[15] IP Payload Compression Using LZS, http://tools.ietf.org/html/rfc2395.
[16] Service Location Protocol, http://en.wikipedia.org/wiki/Service_Location_Protocol.
[17] Internet Storage Name Service, http://en.wikipedia.org/wiki/ISNS.
[18] World Wide Port Name, http://en.wikipedia.org/wiki/World_Wide_Port_Name.

其他参考资源

Card Protection, http://www.cisco.com/en/US/docs/optical/15000r9_1/15454/sdh/reference/guide/454e91_card-protection.html.
Circuits and Tunnels, http://www.cisco.com/en/US/docs/optical/15000r6_0/15327/reference/guide/2760circ.html.
Cisco MDS 9000 Family CLI Configuration Guide, http://www.cisco.com/en/US/docs/storage/san_switches/mds9000/sw/rel_3_x/configuration/guides/cli_3_3/clibook.html.
Cisco MDS 9000 Family Cookbook, http://www.cisco.com/en/US/docs/storage/san_switches/mds9000/sw/rel_3_x/cookbook/MDScookbook31.pdf.
Designing Cisco Storage Networking Solutions (DCSNS), v3.0, Student Courseware, Cisco Training.
Fibre Channel Extension over Metropolitan DWDM, http://www.cisco.com/en/US/prod/collateral/optical/ps5725/ps2011/prod_white_paper0900aecd80181093.html.
Fibre Channel over IP, http://en.wikipedia.org/wiki/FCIP.

Fibre Channel over SONET/SDH, http://www.cisco.com/en/US/products/hw/modules/ps2710/products_white_paper09186a00801b97b3.shtml.
J.L. Hufferd, iSCSI: The Universal Storage Connection, Addison-Wesley Professional, November 15, 2002.
Implementing Advanced Cisco Storage Networking Solutions (IASNS), v3.0, Student Courseware. Cisco Training.
Implementing Cisco Storage Networking Solutions (ICSNS), v3.0, Student Courseware, Cisco Training.
Internet Small Computer System Interface, http://en.wikipedia.org/wiki/ISCSI.
SAN Extension over SONET/SDH Networks, http://www.cisco.com/en/US/products/hw/optical/ps2006/products_qanda_item09186a00801b97a4.shtml.
Storage Extension over Optical, http://www.cisco.com/en/US/prod/collateral/optical/ps5725/ps2011/ps2014/prod_presentation09186a008033a36a.ppt.

第8章

[1] Trusted Execution Technology, http://en.wikipedia.org/wiki/Trusted_Execution_Technology.
[2] DDR3 SDRAM, http://en.wikipedia.org/wiki/Ddr3.
[3] Dual In-Line Memory Module, http://en.wikipedia.org/wiki/Dimm.
[4] Network Operations Center, http://en.wikipedia.org/wiki/Network_operations_center.
[5] Open Compute Project, http://opencompute.org/.

其他参考资源

Cisco Nexus 1000V Layer 2 Switching Configuration Guide, http://www.cisco.com/en/US/docs/switches/datacenter/nexus1000/sw/4_2_1_s_v_1_4/layer_2_switching/configuration/guide/n1000v_l2.html.
Cisco Nexus 1000V Security Configuration Guide, http://www.cisco.com/en/US/docs/switches/datacenter/nexus1000/sw/4_2_1_s_v_1_4/security/configuration/guide/n1000v_security.html.
A. Clemm, Network Management Fundamentals, Cisco Press, December 1, 2006.
Cloud Computing, A Primer Part 2, http://www.cisco.com/web/about/ac123/ac147/archived_issues/ipj_12-4/124_cloud2.html.
Cloud Computing Overlay for Unified Service Delivery: Delivering Infrastructure-as-a-Service, http://www.cisco.com/en/US/solutions/collateral/ns341/ns525/ns951/solution_overview_c22-539404.html.
K. Corbin, et al., NX-OS and Cisco Nexus Switching, Cisco Press, June 20, 2010.
Deploying Secure Multi-Tenancy into Virtualized Data Centers, http://www.cisco.com/en/US/docs/solutions/Enterprise/Data_Center/Virtualization/securecldeployg.html.
Designing Secure Multi-Tenancy into Virtualized Data Centers, http://www.cisco.com/en/US/docs/solutions/Enterprise/Data_Center/Virtualization/securecldg.html.
DMZ Virtualization Using VMware vSphere 4 and the Cisco Nexus 1000V Virtual Switch, http://www.cisco.com/en/US/prod/collateral/switches/ps9441/ps9902/dmz_virtualization_vsphere4_nexus1000V.pdf.
S. Gai, et al., Cisco Unified Computing System (UCS), Cisco Press, June 11, 2010.

第9章

[1] Simple Object Access Protocol, http://en.wikipedia.org/wiki/Simple_Object_Access_Protocol.
[2] Web Services Description Language, http://en.wikipedia.org/wiki/Web_Services_Description_Language.
[3] Case Study: Hydro-Québec, Riverbed White Paper, http://www.riverbed.com/us/assets/media/documents/case_studies/CaseStudy-Riverbed-Hydro-Quebec.pdf, 2011.
[4] Using Cisco Fabric Services, http://www.cisco.com/en/US/docs/switches/datacenter/nexus5000/sw/configuration/guide/fm/cfs.pdf.
[5] World Wide Name, http://en.wikipedia.org/wiki/World_Wide_Name.

其他参考资源

Cisco MDS 9000 Family CLI Configuration Guide, http://www.cisco.com/en/US/docs/storage/san_switches/mds9000/sw/rel_3_x/configuration/guides/cli_3_3/clibook.html.
Cisco MDS 9000 Family Cookbook, http://www.cisco.com/en/US/docs/storage/san_switches/mds9000/sw/rel_3_x/cookbook/MDScookbook31.pdf.
Cisco Nexus 1000V Interface Configuration Guide, http://www.cisco.com/en/US/docs/switches/datacenter/nexus1000/sw/4_2_1_s_v_1_4/interface/configuration/guide/n1000v_if.html.
Cisco Nexus 1000V Port Profile Configuration Guide, http://www.cisco.com/en/US/docs/switches/datacenter/nexus1000/sw/4_2_1_s_v_1_4/port_profile/configuration/guide/n1000v_port_profile.html.
Cisco Nexus 1000V Series Switches Deployment Guide Version 2, http://www.cisco.com/en/US/prod/collateral/switches/ps9441/ps9902/guide_c07-556626.html.
Cisco Nexus 1000V System Management Configuration Guide, http://www.cisco.com/en/US/docs/switches/datacenter/nexus1000/sw/4_2_1_s_v_1_4/system_management/configuration/guide/n1000v_system.html.
Cisco Nexus 2000 Series Fabric Extender Software Configuration Guide, http://www.cisco.com/en/US/docs/switches/datacenter/nexus2000/sw/configuration/guide/Cisco_Nexus_2000_Series_Fabric_Extender_-Software_Configuration_Guide_Release_4_2_chapter3.html.
Cisco Nexus 5000 Series NX-OS Layer 2 Switching Configuration Guide, http://www.cisco.com/en/US/docs/switches/datacenter/nexus5000/sw/layer2/502_n2_1/b_Cisco_n5k_layer2_config_gd_rel_502_N2_1.html.
Cisco Nexus 5000 Series NX-OS SAN Switching Configuration Guide, http://www.cisco.com/en/US/docs/switches/datacenter/nexus5000/sw/san_switching/502_n2_1/b_Cisco_n5k_nxos_sanswitching_config_guide_rel502_n2_1.html.
Cisco Nexus 5000 Series NX-OS System Management Configuration Guide, http://www.cisco.com/en/US/docs/switches/datacenter/nexus5000/sw/system_management/502_n2_1/b_Cisco_n5k_system_mgmt_cg_rel_502_n2_1.html.
Cisco Nexus 7000 Series NX-OS Interfaces Configuration Guide, http://www.cisco.com/en/US/docs/switches/datacenter/sw/5_x/nx-os/interfaces/configuration/guide/if_cli.html.
Cisco Nexus 7000 Series NX-OS Layer 2 Switching Configuration Guide, http://www.cisco.com/en/US/docs/switches/datacenter/sw/5_x/nx-os/layer2/configuration/guide/b_Cisco_Nexus_7000_Series_NX-OS_Layer_2_Switching_Configuration_Guide_Release_5.x.html.
Data Center Design with VMware ESX 4.0 and Cisco Nexus 5000 and 1000V Series Switches, http://www.cisco.com/en/US/prod/collateral/switches/ps9441/ps9670/C07-572832-00_VMware_ESX4_Nexus_DG.pdf.
Data Center Top-of-Rack Architecture Design, http://www.cisco.com/en/US/prod/collateral/switches/ps9441/ps9670/white_paper_c11-522337.html.
Deploying 10 Gigabit Ethernet with Cisco Nexus 5000 Series Switches, http://www.cisco.com/en/US/prod/collateral/switches/ps9441/ps9670/white_paper_c27-489248_ns783_Networking_Solutions_White_Paper.html.
Implementing Cisco Storage Networking Solutions (ICSNS), v3.0, Student Courseware, Cisco Training.
Next-Generation Enterprise MPLS VPN-Based WAN Design and Implementation Guide, http://www.cisco.com/en/US/docs/solutions/Enterprise/WAN_and_MAN/ngwane.pdf.
Unified Fabric White Paper—Fibre Channel over Ethernet (FCoE), http://www.cisco.com/en/US/docs/solutions/Enterprise/Data_Center/UF_FCoE_final.pdf.

Table of Contents

译者序

前言

- 谁应读本书
- 谁不应读此书
- 致谢

第1章　未来IT发展趋势

- 1.1　面向服务的基础设施框架层次展现
- 1.2　功能模块：云模块
  - 1.2.1　服务器模块
  - 1.2.2　存储模块
  - 1.2.3　光纤模块
  - 1.2.4　WAN模块
  - 1.2.5　I型终端用户（分支机构）
  - 1.2.6　II型终端用户（移动客户端）
- 1.3　云计算的特征
- 1.4　云计算分类
  - 1.4.1　部署模式
  - 1.4.2　服务模型
  - 1.4.3　尝试所有组合
- 1.5　小结

第2章　未来数据中心的架构及技术

- 2.1　数据中心整合及虚拟化的主要方法
- 2.2　服务器整合驱动
  - 2.2.1　经典服务器散乱综合症
  - 2.2.2　应用烟囱和数据孤立
- 2.3　服务器虚拟化
  - 2.3.1　虚拟机和监视器
  - 2.3.2　VMware网络定时器
  - 2.3.3　Cisco Nexus 1000V交换机
  - 2.3.4　ESX服务器存储网络概略
- 2.4　存储虚拟化
  - 2.4.1　块汇聚

2.4.2 同步及异步存储虚拟化
2.5 Layer-2演化
2.5.1 虚拟端口通道：STP的改造者
2.5.2 vPC设计概要
2.5.3 vPC和Nexus 1000V
2.6 统一数据中心光纤
2.6.1 10千兆以太网
2.6.2 以太网重装上阵
2.6.3 FCoE解决方案
2.6.4 FCoE数据平面
2.6.5 FCoE控制平面
2.6.6 FCoE与I/O整合
2.7 小结
第3章 下一代WAN及服务集成
3.1 数据中心的服务集成
3.1.1 防火墙虚拟化
3.1.2 服务器负载均衡及虚拟化
3.2 基础设施分段
3.3 未来的企业WAN
3.3.1 MPLS VPN序曲
3.3.2 服务提供商的MPLS VPN服务
3.3.3 L2层上的MPLS
3.3.4 DMVPN概述
3.3.5 DMVPN per VRF
3.3.6 DMVPN之上的MPLS VPN（仅用于集中星型网络）
3.4 小结
第4章 分支整合及WAN优化
4.1 何为WAN性能挑战
4.1.1 头号挑战：有限带宽
4.1.2 问题2：WAN连接中的巨大延迟
4.1.3 WAN优化解决方案
4.2 WAN优化的好处
4.2.1 借助压缩和重复数据删除节约带宽
4.2.2 应用层加速

4.2.3　TCP加速
4.3　WAN优化实施的要求
4.3.1　流量拦截
4.3.2　确定优化的合作者
4.3.3　优化好的数据流像什么
4.3.4　监测和优先级别的传输优化实现
4.4　虚拟远程办公方案
4.5　小结
第5章　会话拦截设计及部署
5.1　拦截机制选择
5.1.1　选址决议
5.1.2　操作影响
5.1.3　可控性
5.2　深入探索WCCP
5.2.1　WCCP定义
5.2.2　WCCP控制平面消息
5.2.3　WCCP服务组
5.2.4　WCCP拦截操作
5.2.5　WCCP重定向机制
5.2.6　WCCP分配算法
5.2.7　WCCP返回方法
5.2.8　WAN优化器的egress方法
5.2.9　WCCP服务平台选择
5.2.10　WCCP方案样例
5.2.11　WCCP配置样例
5.3　In-path部署简介
5.4　PBR部署概述
5.5　小结
第6章　私有云上的WAN优化
6.1　云对WAN优化的要求
6.2　VM层拦截
6.3　使用VRF感知的WCCP实现云拦截
6.4　使用非VRF感知WCCP实现云拦截
6.4.1　VRF选择
6.4.2　WCCPv2双向连接的挑战

6.4.3 Not-So-VRF方案
6.4.4 Not-So-VRF说明
6.5 在服务汇聚层实施拦截
6.5.1 对服务器机箱的要求
6.5.2 Admin上下文
6.5.3 User上下文访问管理
6.5.4 ACESM拦截：桥接模式
6.5.5 ACESM拦截：路由模式
6.5.6 WAN优化器集群冗余
6.6 小结
第7章 SAN扩展及IP存储
7.1 SAN扩展概述
7.1.1 数据恢复机制
7.1.2 关键的设计原则
7.2 光纤网络方案
7.2.1 暗光纤
7.2.2 DWDM
7.2.3 CWDM
7.3 SONET/SDH服务
7.4 FCIP
7.4.1 FCIP入门
7.4.2 FCIP拓扑
7.4.3 FCIP HA
7.4.4 FCIP性能调整
7.4.5 FCIP安全
7.5 iSCSI
7.5.1 iSCSI协议概述
7.5.2 iSCSI部署
7.5.3 iSCSI HA
7.5.4 iSCSI安全
7.6 所有方法汇总
7.7 小结
第8章 云基础设施即服务
8.1 云安全
8.1.1 虚拟交换机安全
8.1.2 端点安全

8.1.3　虚拟VMZ
8.2　统一计算系统
8.2.1　UCS使能技术
8.2.2　UCS组件
8.3　云管理
8.3.1　分级管理
8.3.2　基于策略的管理
8.3.3　管理调整
8.3.4　自动化
8.3.5　用户自助服务
8.3.6　XML-ization
8.4　云IaaS：巨幅画卷
8.4.1　应用软件子模块
8.4.2　虚拟机器子模块
8.4.3　虚拟接入层子模块
8.4.4　计算子模块
8.4.5　存储阵列子模块
8.4.6　SAN子模块
8.4.7　SAN扩展子模块
8.4.8　接入层子模块
8.4.9　汇聚层子模块
8.4.10　核心层子模块
8.4.11　对等子模块
8.4.12　未来的WAN子模块
8.4.13　WAN优化
8.4.14　云基础设施管理平台
8.4.15　终端用户负载及应用
8.4.16　云IaaS覆盖
8.5　小结
第9章　案例分析
9.1　虚拟接入层设计学习
9.1.1　Nexus 1000V组件
9.1.2　设计样例
9.2　ERSPAN案例学习
9.2.1　ERSPAN源接口
9.2.2　ERSPAN设计样例

9.2.3　ERSPAN基本配置
9.2.4　部署指南及限制
9.3　WAN优化案例学习
9.4　统一光纤案例学习
9.5　架顶式体系结构案例学习
9.5.1　使用Nexus 5000和2000进行ToR设计
9.5.2　ToR设计样例：附加1GE服务器
9.5.3　FEX基本配置
9.6　基础vPC设计学习
9.7　SAN扩展设计案例学习
9.8　面向服务的基础设施设计学习
9.8.1　虚拟接入层高级设计
9.8.2　计算子模块高级设计
9.8.3　存储子模块高级设计
9.8.4　光纤模块高级设计
9.8.5　服务汇聚层高级设计
9.8.6　WAN模块高级设计
9.8.7　设计评价
9.9　小结
附录　术语及缩略语
参考文献