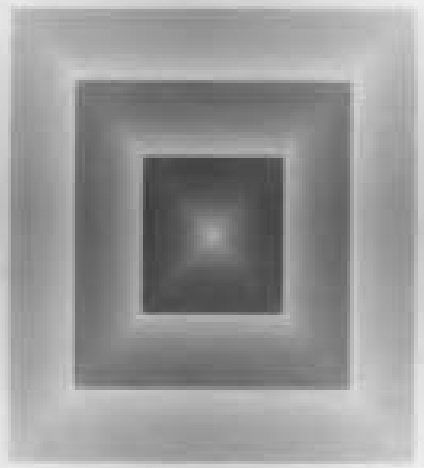
计算智能中的仿生学：理论与算法

西安交通大学数学研究生教学丛书

徐宗本　张讲社　郑亚林 编著



科学出版社
www.sciencep.com

(O-1679.0101)

计算智能中的仿生学：理论与算法

西安交通大学数学研究生教学丛书

计算力学	张　武等
计算智能中的仿生学：理论和算法	徐宗本等
数值计算的算法与分析	张可村等
统计推断导引	范金城等
抽象代数	盛德成
偏微分方程现代数值方法	黄艾香等
常微分方程定性与稳定性方法	马知恩等
随机逼近及自适应算法	聂赞坎等
近代优化方法	徐成贤等
应用非线性分析	陈红斌等
动力系统基础及其方法	陈绥阳等
粗糙集理论与方法	张文修等
计算机数学	陈志平等

科学出版社 高等教育分社
联系电话：010-64011132
e-mail:mph-edu@cspg.net

ISBN 7-03-010792-6

9 787030 107923 >

ISBN 7-03-010792-6
定 价：30.00 元

西安交通大学数学研究生教学丛书

计算智能中的仿生学：理论与算法

徐宗本　张讲社　郑亚林　编著

科学出版社

北京

内 容 简 介

计算智能是以模型(计算模型、数学模型)为基础、以分布并行计算为特征的模拟人的智能求解问题的理论与方法.本书系统讲述计算智能的基本内容、基本理论与基本方法.全书分三部分(章).第一章从模拟智能生成过程的观点讲述模拟进化计算理论;第二章从模拟智能结构的观点讲述人工神经网络理论;第三章从模拟智能行为的观点讲述模糊逻辑与模糊推理.全书突出基础(特别是数学基础),强调背景(特别是生物与工程背景),着眼研究与发展.

本书可作为应用数学、计算数学、运筹与控制、信息科学、计算机科学、系统科学等专业研究生教材使用,也可供各专业从事计算智能研究与应用的教师与研究人员参考.

图书在版编目(CIP)数据

计算智能中的仿生学:理论与算法/徐宗本,张讲社,郑亚林编著.—北京:科学出版社,2003.5
(西安交通大学数学研究生教学丛书)
ISBN 7-03-010792-6

Ⅰ.计… Ⅱ.①徐… ②张… ③郑… Ⅲ.计算—人工智能 Ⅳ.TP183

中国版本图书馆 CIP 数据核字(2002)第 077899 号

责任编辑:林 鹏 杨 波/责任校对:林青梅
责任印制:安春生/封面设计:高海英 王 浩

科学出版社 出版
北京东黄城根北街16号
邮政编码:100717
http://www.sciencep.com

漷海印刷有限责任公司 印刷

科学出版社发行 各地新华书店经销

*

2003 年 5 月第 一 版 开本:B5(720×1000)
2003 年 5 月第 一次印刷 印张:20 1/4
印数:1—3 000 字数:386 000

定价:30.00 元

(如有印装质量问题,我社负责调换(新欣))

前　言

信息技术被广泛认为是21世纪主导全球经济发展格局、引导社会发展进程的核心技术.信息技术的物质基础是光电子、微电子、传感器等,其载体是计算机,其核心是通讯技术,而其理论基础与支撑则是数学.数学技术不仅提供信息表示与编码的方式和语言,而且也提供信息处理(如转换、压缩、提取、加密等)、信息加工与信息利用的直接基础与核心算法.对于很多高、新信息技术而言,它们的本质是数学技术.

信息技术当今的发展以数字化、网络化、智能化为特征.所谓数字化是指信息的表示、储存、传输与处理以数字(特别是离散数字)为基准;网络化是指承载信息,乃至处理、加工、应用信息的主渠道是网络,或者说,是分布式并行信息处理系统;智能化则是指在信息处理的方式上溶入或模仿人的智能.让机器"听"懂人类语言、"看"清文字图像、与人"说"话,让信息处理系统像人那样具有综合、优化、联想、辩识、学习等能力,所有这些都是智能化信息技术努力追求的目标.虽然说,目前的信息技术还远未达到上述所期望的那样高度智能化水平,但在过去的几十年间,人们的确取得了大批令人振奋并极大推动了信息处理智能化进程的成果,计算智能(computational intelligence)正是这些突出成果中的一个典型代表.

计算智能是借助现代计算工具模拟人的智能求解问题(或处理信息)的理论与方法,它是人工智能(artificial intelligence)的深化与发展.如果说人工智能是以知识库(更确切些,专家规则库)为基础、以顺序离散符号推理为特征的,计算智能则是以模型(计算模型、数学模型)为基础,以分布、并行计算为特征.前者强调规则的作用与形成,而后者强调模型的建立与构成;前者依赖专家个人知识,而后者强调自组织、自学习与自适应.

模拟人的智能通常基于不同的观点与角度,例如,从模拟智能生成过程的观点,从模拟智能产生与作用所赖以存在的结构角度,从智能的表现行为角度等等.在所有这些方面,计算智能在近20多年的发展中都取得了巨大成就.本书编写目的是在上述诸方面的每一方面选择一个典型,以向读者系统介绍计算智能的基本理论、基本原理与基本方法.在智能生成过程模拟中,我们选择介绍了模拟进化计算;在智能结构模拟中,我们选择讲述了人工神经网络理论;在智能行为模拟中,我们则选择介绍了模糊逻辑与模糊推理.之所以如此选择,一是作者们多年在这方面工作,二是它们既能代表计算智能过去20多年间发展的最突出成果,又能反映计算智能的当前研究热点.

国内外已有多本著作专门论述上述之一或全部内容，但很可惜还没有一本能较好适用于数学系研究生和数学研究工作者阅读的著作．它们或者内容过于宽泛，或者过于偏重工程应用．而鉴于近年来在信息科学方向招收培养的数学研究生和投身于信息科学研究的数学工作者越来越多，编著一本适宜于对数学系研究生讲授而且能够引导青年数学工作者尽快进入计算智能领域的教材变得十分必要和紧迫，这即是编著本书的直接动机与原由．因此，本书的编著原则是：(1)突出基础(特别是数学基础)，尽可能以严密的理论和形式化的定义、定理、算法与模型的形式提出和表述问题，避免空泛；(2)强调背景．在注重形式化的数学表述基础上，突出介绍所述理论与方法的生物背景与工程应用背景，力求使读者对方法的"源头"和"流向"有明确的了解，对理论的价值与应用有直接的认识；(3)着眼于研究与发展．在内容的取舍上既考虑它们自身的理论与应用价值，也考虑它们的可研究性与可发展性，侧重介绍了那些既有重要理论与应用价值，又有广阔研究空间与发展前景的新理论与新方法．在每一章结束，我们也专节介绍了与之相关的发展动态与研究进展，特别提出具体的研究问题．所有这些旨在使读者能尽可能快地直接进入计算智能研究的相关前沿．

本书是在编著者们多年为西安交通大学数学系研究生开设《智能计算》与《计算智能中的仿生学》课程讲稿基础上，结合他们的研究成果编著而成．第一章由徐宗本教授编著，第二章由张讲社教授编著，第三章由郑亚林教授编著．书中插图分别由徐萍女士和研究生乔小明完成，作者对他们的辛勤劳动深表谢意．另外，本书第一章编著主要参考了周明、孙树栋所著《遗传算法原理及应用》(国防工业出版社，1999)和张文修、梁怡所著《遗传算法的数学基础》(西安交通大学出版社，2000)，第二章主要参考了 Bishop C M 著"Neural Networks for Pattern Recognition"(Clarendon Press, 1995)和焦李成著《神经网络系统理论》(西安电子科技大学出版社，1990)，第三章主要参考了王磊、王为民所著《模糊控制理论及应用》(国防工业出版社，1997)和张文修、梁广锡所著《模糊控制与系统》(西安交通大学出版社，1998)以及王国俊著《非经典数理逻辑与近似推理》(科学出版社，2000)和吴望名著《模糊推理的原理和方法》(贵州科技出版社，1994)，作者对这些著作的编著者们也深表感谢．

本书可作为应用数学、计算数学、信息科学、运筹与控制、计算机科学、系统科学等专业研究生教材使用，也可供从事计算智能研究与应用的各学科研究工作者参考．

编著者

目　　录

第一章　仿生过程算法：模拟进化计算 …… 1

§1.1　模拟进化计算技术 …… 1

1.1.1　什么是模拟进化计算技术？ …… 1

1.1.2　模拟进化计算的生物学基础 …… 2

1.1.3　模拟进化计算的一般框架 …… 4

1.1.4　典型例子：遗传算法、演化策略与进化程序 …… 7

1.1.5　模拟进化计算的本质优点与适用领域 …… 9

§1.2　模拟进化算法的基本要素与数学描述 …… 11

1.2.1　模拟进化算法的形式化描述 …… 11

1.2.2　编码格式(e) …… 13

1.2.3　适应度度量(J) …… 21

1.2.4　选择算子(S) …… 22

1.2.5　繁殖算子(E) …… 27

1.2.6　进化参数(Σ) …… 33

§1.3　模拟进化计算的典型执行技巧 …… 34

1.3.1　杰出者记录与"父子混合"选择策略 …… 34

1.3.2　适应值共享策略 …… 36

1.3.3　并行实现策略 …… 38

1.3.4　混合策略 …… 43

1.3.5　自适应策略 …… 48

§1.4　遗传算法的搜索机理 …… 53

1.4.1　种群增长方程 …… 53

1.4.2　交叉算子的搜索能力与可达域 …… 57

1.4.3　变异算子的搜索能力与可达域 …… 59

1.4.4　选择算子的搜索能力与速度 …… 63

1.4.5　遗传算法的搜索机制 …… 66

§1.5　遗传算法的收敛性理论 …… 66

1.5.1　种群序列的收敛性定义及性质 …… 67

1.5.2　遗传算法的马氏链分析 …… 69

1.5.3　遗传算法的公理化分析 …… 77

1.5.4　遗传算法的鞅分析 …… 87

§1.6　评注与展望 …… 97

1.6.1 有关理论基础研究 …… 97
1.6.2 有关算法设计方面 …… 102
1.6.3 有关模拟进化计算的应用 …… 105
第二章 仿生结构算法：人工神经网络 …… 107
§2.1 引言 …… 107
2.1.1 生物神经元和生物神经网络 …… 107
2.1.2 人工神经元和神经网络 …… 109
2.1.3 学习过程 …… 113
2.1.4 总结 …… 114
§2.2 感知器和单层前向网 …… 115
2.2.1 分类问题 …… 115
2.2.2 感知器 …… 117
2.2.3 单层前向网和最小二乘技巧 …… 120
2.2.4 单层前向网的限制 …… 123
2.2.5 总结 …… 124
§2.3 多层感知器 …… 124
2.3.1 前向网映射 …… 124
2.3.2 阈值神经元 …… 125
2.3.3 S形神经元 …… 126
2.3.4 多层网的逼近能力 …… 127
2.3.5 权重空间的对称性 …… 128
2.3.6 Kolmogonov 定理 …… 128
2.3.7 误差后向传播 …… 130
2.3.8 神经网络的学习算法 …… 138
§2.4 径向基函数 …… 139
2.4.1 精确插值 …… 139
2.4.2 径向基函数网 …… 140
2.4.3 网络训练 …… 142
2.4.4 正则化理论 …… 143
2.4.5 噪声插值理论 …… 144
2.4.6 与核回归的联系 …… 145
2.4.7 基函数的优化 …… 146
2.4.8 有导师训练 …… 147
§2.5 自组织特征映射 …… 148
2.5.1 大脑皮层的结构 …… 149

2.5.2 两个基本的特征映射模型 …… 149
2.5.3 侧向连接 …… 151
2.5.4 自组织特征映射算法 …… 151
2.5.5 矢量量化方法和聚类方法 …… 153
2.5.6 保拓扑性度量 …… 154
2.5.7 设计新的自组织特征映射算法 …… 155
§2.6 回归神经元网络 …… 155
2.6.1 逐次逼近法 …… 155
2.6.2 离散 Hopfield 网 …… 156
2.6.3 连续 Hopfield 网 …… 160
2.6.4 其他回归网 …… 162
§2.7 评注与展望 …… 163
2.7.1 神经网络模型是传统模型的推广 …… 163
2.7.2 目标函数的设计和学习算法 …… 164
2.7.3 神经网络的进一步发展 …… 165
第三章 仿生行为算法:Fuzzy 逻辑与 Fuzzy 推理 …… 167
§3.1 Fuzzy 逻辑的生物基础 …… 167
3.1.1 人脑具有 Fuzzy 思维功能 …… 167
3.1.2 Fuzzy 思维的神经元机制 …… 170
3.1.3 Fuzzy 思维的神经回路机制 …… 172
3.1.4 Fuzzy 思维的大脑生理机制 …… 174
§3.2 Fuzzy 集合及其运算 …… 176
3.2.1 Fuzzy 集合及其表示 …… 177
3.2.2 Fuzzy 集合的运算 …… 181
3.2.3 贴近度、择近原则与模式识别 …… 187
3.2.4 λ 截集与分解定理 …… 192
3.2.5 通常映射的 Fuzzy 扩张 …… 194
3.2.6 隶属函数的确定 …… 197
§3.3 Fuzzy 关系与 Fuzzy 矩阵 …… 204
3.3.1 通常关系 …… 204
3.3.2 Fuzzy 关系 …… 206
3.3.3 Fuzzy 矩阵 …… 209
3.3.4 Fuzzy 等价关系与 Fuzzy 分类 …… 212
3.3.5 Fuzzy 相似关系与 Fuzzy 分类 …… 218
3.3.6 Fuzzy 相似矩阵的确定 …… 225

§3.4 Fuzzy 推理的各种模型 …… 232
3.4.1 简单 Fuzzy 推理模型 …… 232
3.4.2 多维 Fuzzy 推理模型 …… 234
3.4.3 多重 Fuzzy 推理模型 …… 237
3.4.4 多重多维 Fuzzy 推理模型 …… 240
3.4.5 多重多维多输出 Fuzzy 推理模型 …… 244
§3.5 CRI 方案下的 Fuzzy 推理算法 …… 245
3.5.1 简单 Fuzzy 推理模型的 Mamdani 算法 …… 246
3.5.2 多维 Fuzzy 推理模型的 Mamdani 算法 …… 250
3.5.3 多重 Fuzzy 推理模型的 Mamdani 算法 …… 253
3.5.4 多重多维 Fuzzy 推理模型的 Mamdani 算法 …… 255
3.5.5 CRI 方案下 Fuzzy 推理的其他算法 …… 257
3.5.6 Fuzzy 推理算法的 MP 再现分析 …… 261
§3.6 3I 方案下的 Fuzzy 推理算法 …… 263
3.6.1 Fuzzy 推理的 FMP3I 方案 …… 264
3.6.2 Fuzzy 推理的 Zadeh 型 FMP3I 算法 …… 265
3.6.3 Fuzzy 推理的 θ_0 型 FMP3I 算法 …… 267
3.6.4 Fuzzy 推理的 FMPα-3I 方案与 θ_0 型 FMPα-3I 算法 …… 271
3.6.5 Fuzzy 推理的 FMT3I 方案与 θ_0 型 FMT3I 算法 …… 275
3.6.6 Fuzzy 推理的 FMTα-3I 方案与 θ_0 型 FMTα-3I 算法 …… 279
§3.7 应用举例:Fuzzy 逻辑控制 …… 281
3.7.1 Fuzzy 控制器的设计 …… 282
3.7.2 目标跟踪系统的 Fuzzy 控制 …… 285
3.7.3 还原炉氢气流量的 Fuzzy 控制 …… 288
3.7.4 Fuzzy 逻辑的硬件实现 …… 293
§3.8 评注与展望 …… 299
参考文献 …… 307

第一章　仿生过程算法：模拟进化计算

本章讲述一类从智能生成过程观点模拟生物智能的计算理论与方法——模拟进化计算(simulated evolutionary computation，简称 SEC)．§1.1 概述 SEC 的基本原理、生物基础、算法框架、本质优点与适用领域；§1.2 介绍 SEC 的基本要素，定义遗传编码、适应性度量、选择算子、交叉算子、变异算子等基本模拟演化操作；§1.3 更为细致地讲述 SEC 的一类最具代表性的执行策略——遗传算法(genetic algorithm，简称 GA)，介绍包括并行、混合、自适应、共享、适应值变换、效率加速等在内的各种算法执行技巧；§1.4 阐述 GA 的搜索机制；§1.5 介绍 GA 的收敛性理论．最后，§1.5 简述 SEC 的发展历史并指出 SEC 当前研究的热点问题．

§1.1　模拟进化计算技术

1.1.1　什么是模拟进化计算技术？

模拟进化计算(SEC)技术是模拟自然界生物进化过程与机制求解优化与搜索问题的一类自组织、自适应人工智能技术．

这类技术的核心思想源于这样的基本知识：生物进化过程(从简单到复杂，从低级向高级)本身是一个自然的、并行发生的、稳健的优化过程．这一优化过程的目的在于使生命体达到适应环境的最佳结构与效果，而生物种群通过“优胜劣汰”及遗传变异来达到进化(优化)的目的．曾经主宰地球的恐龙由于庞大的身躯跟不上环境的变迁而灭绝；长颈鹿为了觅食而长长了脖子；老鼠的机敏是为了生存而挣扎的结果；青蛙的存活则得益于其两栖式左右逢源的能力；人类解放出有力的双手，得益于类人猿求生的努力，而正是这一对不再用于行走的双手，使人类成了这个世界的主宰．所有这些无不显示出自然进化的神奇力量．然而，自然进化遵循着一种奇妙的规律，这一规律截然不同于人类自己发明的任何解析方法．我们知道，人体 36.8℃的恒定体温是至关重要的，0.5℃的偏差足以使人产生病态．那么在 0～100℃这样大的范围内，人体是如何求出如此精确的最佳体温呢？这绝不是诸如梯度下降法或模拟退火算法所能算出的，而我们也相信目前的解析方法远远无法完整描述体温、人体结构与环境间错综复杂的关系．自然进化的规律是达尔文(Darwin)发现的，它的核心思想是“物竞天择、适者生存”．它对人类的作用与影响可以说不亚于牛顿

(Newton)的万有引力学说,而奇怪的是这一理论时至今日才被应用于工程实践.

SEC是一种更为宏观意义下的仿生优化算法,它模仿的是一切生命与智能的生成与进化过程.它不仅模拟达尔文"优胜劣汰、适者生存"的进化原理激励好的结构,而且也通过模拟孟德尔等人的遗传变异理论在优化过程中保持已有的结构,同时寻找更好的结构.在下一小节,我们将进一步介绍有关遗传变异理论的要义,以使读者对SEC的生物学基础有一个较完整的认识.

从抽象的意义上说,SEC所处理的问题可描述作

$$\max_{X\in\Omega} f(X), \tag{1.1}$$

这里 Ω 是某个 n 维空间(例如 R^n)上的子集,$f:\Omega\to R^1$ 是一个可能毫无解析表达的函数(例如,X 取为人体的体温,$\Omega=[0℃,100℃]$,f 为人体在给定环境下的适应程度).(1.1)自然也可理解为常义的极大化问题,它特别包含各类数学规划、组合优化、随机优化等广泛类优化模型.

作为求解(1.1)的一类仿生优化算法,SEC的基本原理可概括为:(1)将问题(1.1)的目标函数 f(已知或未知)对应作某生物群体在给定环境下的适应性度量;(2)将(1.1)中的优化变量 X 对应作生物群体中的个体;(3)将SEC过程对应作所对应生物群体在给定环境下的演化进程.所以,为了理解和发展SEC,我们必须对自然进化与遗传变异理论本身有一个清晰的了解.

1.1.2 模拟进化计算的生物学基础

1.1.2.1 遗传变异理论

世间的生物从其亲代继承特征或性状,这种生命现象称之为遗传(heredity),研究这种生命现象与机理的科学即为遗传学(genetics).由于有遗传作用,自然界才有稳定的物种,人们种瓜得瓜,种豆得豆,之所以鱼至今还仍然会在水中遨游,鸟仍然还会在天空中飞翱都是这个缘由.

构成生物的基本结构与功能单位是细胞(cell).细胞中含有一种微小的丝状化合物称为染色体(chromosome),生物的所有遗传信息都包含在这个复杂而又微小的染色体中.遗传信息是由基因(gene)组成的,生物的各种性状由其相应的基因所决定,基因是遗传的基本单位.细胞通过分裂具有自我复制的能力,在细胞分裂过程中,其遗传基因也同时被复制到下一代,从而其性状也被下一代所继承.经过生物学家的研究,现在人们已经明白控制并决定生物遗传性状的染色体主要是由一种叫作脱氧核糖核酸(deoxyribonucleic acid,简称DNA)的物质所构成,除此之外,染色体中还含有大量蛋白质.DNA在染色体中有规则地排列着,它是个大分子的有机聚合物,其基本结构单位是核苷酸.每个核苷酸由四种称为碱基的环状有机化合物中的一种、一分子戊糖和磷酸

分子所组成.许多核苷酸通过磷酸二酯键相结合形成一个长长的链状结构,两个链状结构再通过碱基间的氢键互补成对地组合在一起,相互卷曲起来形成一种双螺旋结构(参见图1.1).另外,低等生物中还含有一种叫作核糖核酸

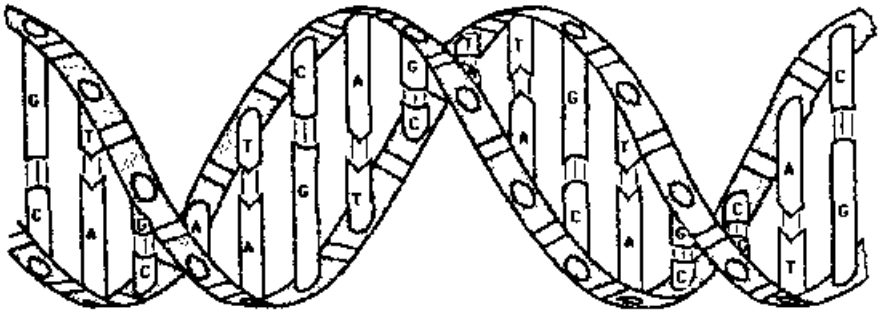


图1.1 DNA双螺旋结构示意图

(ribonucleic acid,简记RNA)的物质,它的作用与DNA类似.基因就是DNA或RNA长链中占有一定位置的基本遗传单位.生物的基因数量根据物种的不同也多少不一,小的病毒只含有几个基因,而高等动植物的基因却以数万计(例如人的基因在3~5万个之间).DNA中,遗传信息在一条长链上按一定的模式排列,亦即进行了遗传编码.一个基因或多个基因决定了蛋白质的20种氨基酸的组成比例及其排列顺序.遗传基因在染色体中所占据的位置称为基因座(locus),同一基因座可能有的全部基因称为等位基因(allele).一种生物所特有的基因及其构成形式称为该生物的基因型(genotype),而该生物在环境中所呈现出的相应性状被称为该生物的表现型(phenotype).一个细胞核中所有染色体所携带的遗传信息(即DNA)的全体称为一个基因组(genome).

细胞在分裂时,遗传物质DNA通过复制(reproduction)而转移到新产生的细胞中,新细胞就继承了旧细胞的基因.有性生殖生物在繁殖下一代时,两个同源染色体之间通过交叉(crossover)而重组,亦即在两个染色体的某一相同位置处DNA被切断,其前后两串分别交叉组合而形成两个新的染色体.另外,在进行细胞复制时,虽然概率很小,但也有可能产生某些复制差错,从而使DNA中的某些基因发生变异(mutation),产生出新的染色体.这些新的染色体表现出新的性状.如此这般,遗传基因或染色体在遗传的过程中由于各种各样的原因而发生变化.

1.1.2.2 进化论

生物在其延续生存的过程中,逐渐适应于其生存环境,使得其品质不断得到改良,这种生命现象称为进化(evolution).生物的进化是以集团的形式共同进行的,这样的团体称为群体(population),组成群体的单个生物称为个体(individual).每一个生物个体对其生存环境都有不同的适应能力,这种能力称为

个体的适应度(fitness).达尔文的自然选择学说(natural selection)构成了现代进化论的主体.自然选择学说认为,通过不同生物间的交配以及其他一些原因,生物的基因有可能发生变异而生成一种新的生物基因,这部分变异了的基因也将遗传到下一代.虽然这种变化的概率是可以预测的,但具体哪一个个体发生变化却是偶然的.这种新的基因依据其与环境的适应程度决定其增殖能力,有利于生存环境的基因逐渐增多,而不利于生存环境的基因逐渐减少.通过这种自然的选择,物种将逐渐地向适应于生存环境的方向进化(即进化趋势向上),从而产生出愈来愈适应环境的物种.

1.1.2.3 遗传与进化的系统观

虽然人们还未完全揭开遗传与进化的奥秘,既没有完全掌握其机制,也不完全清楚染色体编码和译码过程的细节,更不完全了解其控制方式,但遗传与进化的以下特征却为人们所共识:

(1) 生物的所有遗传信息(基因)都包含在染色体中,染色体决定个体的生物特征(表现型),而表现型决定个体对环境的适应度(因而生物个体与其所含染色体之间存在某种一一对应).

(2) 由于 DNA 的双螺旋结构及其双链之间存在恒定的碱基互补原则,生物体的基因在染色体上可认为呈线性排列(因而染色体可认为是由四种不同碱基的核苷酸序列所组成的一维字符串).所有遗传和进化过程都发生在染色体上.

(3) 生物的繁殖是由其基因的复制来完成的,在有性繁殖情形,基因复制的基本方式是交叉重组.

(4) 通过同源染色体之间的交叉或染色体上基因的变异产生新的物种,使生物体呈现新的性状(从而,变异是物种进化的根本保证).

(5) 自然依个体生物的适应度决定它在种群中是否存活,特别对环境适应性强的基因或染色体经常比适应性差的基因或染色体有更多的机会遗传到下一代.

(6) 生物群体及群体与群体之间存在竞争.竞争是规模无限扩大趋势的生物分享有限资源的直接结果,是物种进化的促进剂.

(7) 有竞争就必然有选择.自然选择是生物进化的最基本规律.

以上特征构成 SEC 模拟生物进化过程与机制的直接生物学基础.

1.1.3 模拟进化计算的一般框架

1.1.3.1 预备

为了模拟生物进化过程与遗传变异机制求解问题(1.1),SEC 必须首先将优化变量 $X=(x_1,x_2,\cdots,x_n)^T$ 对应到某生物种群中的个体,且指定相应

个体的适应度.

定义 1.1(遗传编码) 一个具有性质(1.2)的有限长字符串 $a_1a_2\cdots a_L$ 称为是优化变量 X 的一个**遗传编码**(或**染色体编码**)

$$A = a_1a_2\cdots a_L \Rightarrow X = (x_1, x_2, \cdots, x_n)^{\mathrm{T}}, \tag{1.2}$$

L 称为 X 的**编码长度**,$A = a_1a_2\cdots a_L$ 称为 X 的**编码**,记为 $e(X)$,而 X 称为字符串 A 的**解码**,记为 $X = e^{-1}(A)$.

依生物学术语,把每一 a_i 看作是一个遗传基因,它的所有可能取值(即 a_i 的取值范围)称为等位基因,则 $A = e(X)$ 可认为是由 L 个基因所组成的一个染色体,或者说是一个个体. 一般情况下,编码长度 L 是固定的,但对有些问题也可以是变化的.根据不同的情况,这里的等位基因可以是一组整数,也可以是某一范围内的实数,或者是纯粹的一组记号.最简单的等位基因由 0 和 1 这两个整数所组成,相应的染色体则为一个 L 长的二进制字符串.由编码 e 所形成的字符串 A 可认为是个体的基因型,而与它对应的解码 X 的值是个体的表现型.通常个体的表现型与其基因型是一一对应的(即编码 e 是可逆的),但有时也允许基因型与表现型是多对一的关系(此时 e^{-1} 应仅理解作记号).

对每一个个体 A,SEC 应按照一定规则指定其相应的适应度.常规地,适应度确定规则应使个体的适应度与其对应的个体表现型 X 的目标函数值 $f(X)$ 相关联,X 越接近于目标函数的全局极大值点,其适应度越大;反之,其适应度越小.这样的适应度指定规则通常可由下述定义 1.3 所定义的适应值函数产生.

定义 1.2(个体空间与种群空间) 设 Γ 表示等位基因,L 为给定的编码长度,集合

$$\boldsymbol{H}_L = \{A = a_1a_2\cdots a_L \mid a_i \in \Gamma, i = 1, 2, \cdots L\}$$

称为是**个体空间**.对任何正整数 m,乘积

$$\boldsymbol{H}_L^m = \underbrace{H_L \times H_L \times \cdots \times H_L}_{m\text{次}}$$

称为是 m **阶种群空间**;2 阶种群空间 $\boldsymbol{H}_L^2$ 称为是**母体空间**.$\boldsymbol{H}_L$ 中的任一元素称为**个体**,$\boldsymbol{H}_L^m$ 中的元素称为 m **阶种群**,$\boldsymbol{H}_L^2$ 中的元素称为一对**母体**.

定义 1.3(适应值函数) 设 $\boldsymbol{R}_0^+$ 表示正实数集.一个映射 $F: \Omega \to \boldsymbol{R}_0^+$ 称为是问题(1.1)的一个适应值函数,如果 F 与 f 有相同的全局极大值点,且满足:

$$f(X_1) \geqslant f(X_2) \geqslant 0 \Rightarrow F(X_1) \geqslant F(X_2). \tag{1.3}$$

显然存在无穷多可能的方法给出问题(1.1)的适应值函数,最简单地,例如定义 $F(X) = \exp(f(x))$ 或 $F(X) = af(x) + C$,这里 a 是某个固定正常数,C 是满足使 $af(X) + C \geqslant 0$ 的实数.给定(1.1)的任一适应值函数 F,如下

定义的 $J:\boldsymbol{H}_L\to R_0^+$

$$J(A)=F(e^{-1}(A)),\quad \forall A\in \boldsymbol{H}_L, \tag{1.4}$$

则自然给出个体 A 的一个适应度.由于这个原由,F 也常直接称为是一个适应度度量.

注意到,问题(1.1)的解空间为满足 $X\in\Omega$ 的优化变量集合(即 Ω 本身).SEC 求解这一问题则是通过对染色体 A 的搜索来完成的,从而个体空间 $\boldsymbol{H}_L$ 构成了其搜索空间.如果 $\boldsymbol{H}_L$ 中的个体之适应度进而由(1.1)的某个适应值变换 F 定义(例如通过(1.4)式),则我们可以看到:SEC 实质上是通过求解下述问题:

$$\max_{A\in \boldsymbol{H}_L} F(A) \tag{1.5}$$

来达到求解问题(1.1)的目的.

除了应用遗传编码与适应值变换这两个基本策略外,SEC 也应用群体搜索策略(对应于生物进化的群体方式).与生物一代一代地自然进化相类似,SEC 的运算过程也是一个反复迭代产生种群的过程.记第 t 代种群为 $\vec{X}(t)$,则通过一代遗传和进化后,得到第 $t+1$ 代种群,它们也是由多个个体组成的集合,记作 $\vec{X}(t+1)$.这个群体不断地经过遗传和进化,并且每次都按照优胜劣汰的规则将适应性强的个体更多地遗传到下一代,这样最终在群体中形成一个优良个体 A^*,它所对应的表现型 $e^{-1}(A^*)$ 将达到或接近于问题(1.1)的最优解 X^*.

生物的进化过程主要是通过选择与染色体之间的交叉和基因变异来完成的.与此相对应,SEC 搜索(1.5)的最优解也模仿生物的这个进化过程,使用所谓的**选择算子**(selection operator)、**交叉算子**(crossover operator)与**变异算子**(mutation operator)等来模拟进化,从而产生一代又一代种群 $\vec{X}(t)$.

(1) 选择算子:是模拟自然选择的操作,反映"优胜劣汰"原理.它根据每一个个体的适应度,按照一定规则或方法,从 t 代种群 $\vec{X}(t)$ 中选择出一些优良的个体(或作为母本,或让其遗传到下一代种群 $\vec{X}(t+1)$).

(2) 交叉算子:是模拟有性繁殖的基因重组操作,它将从群体 $\vec{X}(t)$ 所选择的每一对母体,依一定概率(称为交叉概率,crossover rate)交换它们之间的部分基因.

(3) 变异算子:是模拟基因突变的遗传操作,它对种群 $\vec{X}(t)$ 中的每一个个体,以一定概率(称为变异概率,mutation rate)改变某一个或某一些基因座上的基因值为其他的等位基因.

交叉算子与变异算子其作用都在于重组染色体基因,以生成新的个体,因而它们之一或复合也称为**繁殖(或重组)算子**.在 §1.2,我们将给出选择算子

与繁殖算子的进一步刻画与各种具体例子.

有了以上预备,我们可建立 SEC 的一般框架.

1.1.3.2 模拟进化算法(simulated evolutionary algorithms, 简记 SEA)

SEC 的一般过程如下:

步1(初始化) 确定种群规模 N 及终止准则(如设置最大进化代数或所望达到的近似解精度);随机生成 N 个个体作为初始种群 $\vec{X}(0)$;置进化代数计数器 $t\leftarrow 0$.

步2(个体评价) 计算或估价种群 $\vec{X}(t)$ 中每一个个体的适应度.

步3(种群进化)

3.1 **选择** 将选择算子作用于种群 $\vec{X}(t)$.

3.2 **繁殖** 将繁殖算子作用于选择后的种群,并生成下一代种群 $\vec{X}(t+1)$.

步4(终止检验) 如果 $\vec{X}(t+1)$ 满足终止准则,则输出 $\vec{X}(t+1)$ 中具有最大适应度的个体作为最优解,终止计算;否则置 $t\leftarrow t+1$,转步 2.

1.1.4 典型例子:遗传算法、演化策略与进化程序

1.1.4.1 遗传算法(GA)

遗传算法是由美国密执安大学的Holland教授(1969)提出,后经由De Jong(1975), Goldberg(1989)等归纳总结所形成的一类模拟进化算法(文献[21],[36],[44]). 依标准形式,它使用二进制遗传编码,即等位基因 $\Gamma=\{0,1\}$,个体空间 $\boldsymbol{I}_L=\{0,1\}^L$,且繁殖分为交叉与变异两个独立的步骤进行. GA 的运算过程如下:

步1(初始化) 确定种群规模 N,交叉概率 P_c,变异概率 P_m 和置终止进化准则;随机生成 N 个个体作为初始种群 $\vec{X}(0)$;置 $t\leftarrow 0$.

步2(个体评价) 计算或估价 $\vec{X}(t)$ 中各个体的适应度.

步3(种群进化)

3.1 **选择**(母体) 从 $\vec{X}(t)$ 中运用选择算子选择出 $M/2$ 对母体($M\geq N$).

3.2 **交叉** 对所选择的 $M/2$ 对母体,依概率 P_c 执行交叉,形成 M 个中间个体.

3.3 **变异** 对 M 个中间个体分别独立依概率 P_m 执行变异,形成 M 个候选个体.

3.4 **选择**(子代) 从上述所形成的 M 个候选个体中依适应度选择出 N 个个体组成新一代种群 $\vec{X}(t+1)$.

步4(终止检验) 如已满足终止准则,则输出 $\vec{X}(t+1)$ 中具有最大适应

度的个体作为最优解,终止计算,否则置 $t \leftarrow t+1$ 并转步 3.

上述标准遗传算法有各种推广与变形,我们将在以后各节中逐步介绍与讨论.

1.1.4.2 演化策略(ES)

演化策略(evolution strategy,简称 ES)是由德国数学家 I. Rechenberg 和 H.P. Schwefel 等于 20 世纪 60 年代所提出的一类数值优化算法(文献[86],[98]).它们使用随机变量遗传编码,或者,更具体地说,使用 $2n$ 维实数组 (X,σ)来编码实变量 $X \in R^n$,其中 $X=(x_1,x_2,\cdots,x_n)^{\mathrm{T}}$,$\sigma=(\sigma_1,\sigma_2,\cdots,\sigma_n)^{\mathrm{T}}$,而解码变换为

$$A=(X,\sigma) \Leftrightarrow X+N(0,\sigma) \Rightarrow X,$$

这里 $N(0,\sigma)$表示各分量相互独立、均值为 0,以 $\mathrm{diag}\{\sigma_1^2,\cdots,\sigma_n^2\}$为协方差的正态分布随机向量.ES 的个体空间 $\boldsymbol{H}_L=R^n\times(R_0^+)^n\subseteq R^{2n}$,而繁殖仅由变异操作完成,具体算法步骤如下:

步1(初始化) 设定进化终止准则并置时钟 $t\leftarrow 0$;随机生成 μ 个个体 $(X^{(i)},\sigma^{(i)})(i=1,2,\cdots,\mu)$组成初始种群

$$\vec{X}(0)=\{(X^{(i)},\sigma^{(i)})\mid i=1,2,\cdots,\mu\}.$$

步2(种群演化)

2.1 **变异** 随机从 $\vec{X}(t)$中选取 $\lambda(\lambda>\mu)$个个体执行变异操作,生成中间种群

$$\vec{X}'(t)=\{(X^{(j)},\sigma^{(j)})\mid j=1,2,\cdots,\lambda\}.$$

2.2 **选择** 从 $\vec{X}(t)$与 $\vec{X}'(t)$的并中依适应度大小选择出 μ 个个体作为新一代种群 $\vec{X}(t+1)$.

步3(终止检验) 如果进化终止准则满足,则输出 $\vec{X}(t+1)$中适应度最高的个体作为最优解,终止计算,否则置 $t\leftarrow t+1$ 并转步 2.

在上述 ES 中,变异是繁殖新个体的唯一操作.假设 $\vec{X}(t)$中某一个体 $A=(X,\sigma)$经过变异得到一个新的个体 $A'=(X',\sigma')$,则新个体 A'中的 $X'=(x'_1,x'_2,\cdots,x'_n)^{\mathrm{T}}$ 和 $\sigma'=(\sigma'_1,\sigma'_2,\cdots,\sigma'_n)^{\mathrm{T}}$ 分别定义为

$$\begin{cases} x'_i=x_i+N(0,\sigma'_i), \\ \sigma'_i=\sigma_i\exp[\tau N(0,1)+\tau' N(0,\sigma_i)], \quad i=1,2,\cdots,n, \end{cases} \tag{1.6}$$

其中 $N(0,\sigma_i)$表示均值为 0,方差为 σ_i 的正态分布随机变量;τ 和 τ' 是表示整体步长与分量步长的两个参数.

ES 中的选择操作有两种典型方式:一是父代种群 $\vec{X}(t)$不参与竞争(此时的选择称为**自然选择**),而直接从中间种群 $\vec{X}'(t)$中选择 μ 个适应度高的个体作为新一代种群;二是父代种群参与竞争(该种选择常称为**父子混合选择**),

$\vec{X}(t+1)$中的 μ 个个体是从$\vec{X}(t)\cup\vec{X}'(t)$中的 $\lambda+\mu$ 个个体所选择出的μ 个优秀个体.按照习惯,以第一种方式执行选择出的 ES 常称为(λ,μ)-**ES 演化策略**,而以第二种方式执行选择的 ES 则称为$(\mu+\lambda)$-**ES 演化策略**.

1.1.4.3 进化程序(EP)

进化程序(evolutionare programming,简称 EP)是由美国 L. J. Fogel 等(1966,1994)为求解预测问题所提出的一种有限状态机模型(文献[28],[31]),当应用到优化问题时,它与 ES 有大体相同的形式,但也有一系列重要的不同:

第一,EP 不使用随机变量编码,而直接用实数编码(换言之,X 既代表问题(1.1)中的实变量,也代表个体).

第二,如果说 ES(以及 GA)对生物进化的模拟是着眼于单个个体在其生存环境中的进化,强调的是"个体的进化过程",则 EP 着眼于整个群体的进化,强调"物种的进化过程".于是它不使用基于个体进化机制的交叉运算,而是使用具有很高一致性的变异操作.具体地说,假定群体 $\vec{X}(t)$中的某一个体 $X=(x_1,x_2,\cdots,x_n)^{\mathrm{T}}$ 经过变异操作而生成新的个体 $X'=(x'_1,x'_2,\cdots,x'_n)^{\mathrm{T}}$,则 EP 定义

$$\begin{cases} x'_i = x_i + \sigma_i N_i(0,1), \\ \sigma_i = \sqrt{\beta_i F(X) + \gamma_i}, \quad i = 1,2,\cdots,n, \end{cases} \tag{1.7}$$

这里 $N_i(0,1)$是对每个下标 i 都重新取值的均值为 0、方差为 1 的正态分布随机变量,系数 $\beta_i=1$, $\gamma_i=0$.

第三,EP 使用完全不同的选择算子.虽然 EP 也采用父子混合选择策略(即从 $\vec{X}(t)\cup\vec{X}'(t)$中选择),但不应用简单地依适应度排序的择优策略,而是应用如下随机——排序选择策略:对每一个体 $X_k\in\{\vec{X}(t)\cup\vec{X}'(t)\}$,从该集合中随机取 b 个其他个体(必须不同于 X_k,这里 b 为参数),比较这 b 个个体与 X_k 之间的适应度,以其中适应度比 X_k 的适应度高的个体数目作为个体 X_k 的得分 $w_k(k=1,2,\cdots,2\mu)$,然后依集合$\{\vec{X}(t)\cup\vec{X}'(t)\}$中每个个体得分 w_k 的大小对全部 2μ 个个体作降序排列,选择前 μ 个个体作为选择后的新一代种群$\vec{X}(t+1)$.

有关 EP 和 ES 的研究,可参见文献[28],[31],[86],[98].本章以下将主要介绍有关 GA 的基本理论与方法.

1.1.5 模拟进化计算的本质优点与适用领域

为了求解各种优化问题,人们已经发展了各种各样的优化算法,如单纯形法,梯度法,模拟退火算法、神经网络算法等.这些优化算法各有各的长处,各

有各的适用范围,也各有各的限制.相比于其他优化算法,SEC的主要优点是:

(1) 以优化变量的遗传编码为运算、搜索对象.传统的优化算法往往直接利用优化变量的实际值本身进行优化计算,但SEC(特别是遗传算法)不是直接以原优化变量的值,而是以优化变量的某种形式的遗传编码为运算对象.这种对优化变量的编码处理方式使得我们在优化计算过程中可以借鉴生物学中染色体和基因等概念,可以模仿自然界中生物进化机制与遗传变异原理,也使得我们可以方便地应用遗传、进化等操作算子.另外,对一些非数值概念或很难用数值概念而只能用代码的优化问题(这类问题称为非数值优化问题),SEC的这种处理方式显示其独特的优越性.

(2) 只应用"适应值"信息,而勿需应用目标函数的具体值及其他辅助信息.传统优化算法不仅依赖于直接应用目标函数的具体值,而且也往往需要应用目标函数的导数值等其他一些辅助信息来确定搜索方向.而SEC通常仅使用由目标函数变换来的适应度值指导搜索.注意到,评价个体的适应度可以不依赖于目标函数的恰好估值(例如只要知道排序关系),这使得SEC不仅可以方便地应用于那些有目标函数的,但很难求导数,或导数不存在的优化问题(特别如组合优化与非光滑优化问题),而且,更重要地,可应用于那些目标函数无明确表达,或有表达但不可精确估值的优化问题.

(3) 非单点操作,使用群体搜索策略.传统优化算法往往是从解空间中的一个初始点出发的单点迭代(从而形成解空间中的一条轨迹).单个点所提供的搜索信息毕竟不多,因而其搜索效率不高,有时甚至使搜索过程陷于局部极值而停滞不前.SEC是从由多个个体所组成的初始种群起始的种群空间中的迭代过程(从而形成个体空间中的多条轨迹),其搜索过程的每一步利用了种群中各个体所提供的信息(即群体信息).这些信息可以避免一些不必要搜索的点或区域,从而既提高了搜索效率,也更大程度上避免了陷于局部极值.另外,SEC的群体搜索机制使其具有自然的并行性,从而适宜于在当代或未来以分布、并行为特征的智能计算机上发挥潜能.

(4) 使用概率搜索机制.很多传统优化算法使用的是确定性的搜索方法,一个搜索点到另一个搜索点的转移有确定的转移关系,这种确定性使得算法的搜索具有定向性,从而很难达到问题的全局最优解,而且数值稳定性不好.SEC在计算的各个步骤使用概率转移规则,因而是一类导向的随机搜索技术(directed random search).特别是,其选择、繁殖(交叉、变异等)等操作都是以一种概率的方式进行的,采用的是"软"选择与"让步策略",它能以一定概率接受不一定好的个体,从而大大提高了算法跳出局部极值陷井的能力.另外,概率搜索机制的一个自然优点是相应算法的稳健性(robustness),SEC自然也具

有这一特征.

这样,概括起来说,SEC 具有通用、并行、稳健、简单与全局优化能力强等突出优点.

上述特别优点决定了 SEC 的适用范围应该是复杂、困难的全局优化问题,而不是通常的数值优化问题. 一个优化问题称为是复杂的,通常指它具有下述特征之一:

(1)目标函数没有明确解析表达(如非数值优化问题);

(2)目标函数虽有明确表达,但不可能恰好估值(如大部分最优控制问题,金融优化问题);

(3)目标函数有极多的峰值(multimodal)(如 DNA 计算,组合优化问题);

(4)多目标(multiobjective),即 f 是向量值.

优化问题(1.1)说成是困难的,则通常是指:或者 f 不连续、不可微、高度非线性,或者(1.1)是困难的组合问题. 对于这些复杂、困难的优化问题,已知的优化方法或者根本不可用,或者可应用但不有效. 相比之下,SEC 不但保证可应用,而且常常显得更为有效(文献[17],[69],[72]).

目前,SEC 已成功地应用到机器学习、模糊系统、人工神经网络训练、程序自动生成、专家系统的知识库维护、数据挖掘、大分子计算、蛋白质预测、基因比对、各种图论与网络中的组合问题、多目标规划等广泛复杂、困难优化问题的求解(文献[21],[36],[44],[17],[69],[72]).

另一方面,我们必须注意到,一个通用而又较少依赖于目标函数值与其他辅助信息的算法不可能比专用且充分利用目标函数及相关辅助信息的算法更为有效,而当一个问题有某些辅助信息可供利用时,舍弃应用本来可供应用的信息而去应用与这些信息无关的算法也不是一个聪明的选择. 所以,SEC 一般说并不适宜于应用到通常的数值优化问题(例如连续可微的数学规划问题),或者说,当应用到这样的问题时,SEC 不必须总能显示其优越性. 现有理论分析与大量数值实验均支持这一观点.

§1.2 模拟进化算法的基本要素与数学描述

本节抽象表述模拟进化算法(SEA)的形式化模型、所涉及的诸如选择算子、交叉算子、变异算子与遗传编码等基本要素,以及算法执行中所涉及的各种参数等.

1.2.1 模拟进化算法的形式化描述

设 $\boldsymbol{H}_I^N$ 是种群空间且在 1.1.3.2 节所定义的 SEA 步 3 中选择算子作用

于当前种群 $\vec{X}(t)$生成 M 个新个体(即选择结果形成一个 M 阶种群),让 S 表示选择算子(它是从 $\boldsymbol{H}_L^N$ 到 $\boldsymbol{H}_L^M$ 的一个随机映射),E 表示繁殖算子(是从 $\boldsymbol{H}_L^M$ 到 $\boldsymbol{H}_L^N$ 的随机映射),则由 1.1.3.2 节 SEA 的定义,一个一般的 SEA 可抽象表示作如下随机过程

$$\vec{X}(t+1) = E \circ S\vec{X}(t), \quad t = 0,1,\cdots \tag{1.8}$$

例 1.1(遗传算法) 在 1.1.4.1 节所定义的 GA 中,让 $S_1: \boldsymbol{H}_L^N \to \boldsymbol{H}_L^M$ 表示步 3.1 中选择母体的操作,$C: \boldsymbol{H}_L^M \to \boldsymbol{H}_L^M$ 表示步 3.2 中所执行的交叉操作,$M: \boldsymbol{H}_L^M \to \boldsymbol{H}_L^M$ 为步 3.3 中的变异操作,$S_2: \boldsymbol{H}^M \to \boldsymbol{H}_L^N$ 为步 3.4 中的选择子代的操作,则 GA 可表示作

$$\vec{X}(t+1) = S_2 \circ M \circ C \circ S_1\vec{X}(t), \quad t = 0,1,\cdots \tag{1.9}$$

令

$$S = S_1 \circ S_2 : \boldsymbol{H}_L^M \to \boldsymbol{H}_L^M, \tag{1.10}$$

$$E = M \circ C : \boldsymbol{H}_L^M \to \boldsymbol{H}_L^M, \tag{1.11}$$

并记 $\vec{Y}(t) = M \circ C \circ S_1\vec{X}(t)(t = 0,1,2,\cdots)$,则通过对(1.9)两边作用 $M \circ C \circ S_1$ 可知,(1.9)可等价地描述作

$$\vec{Y}(t+1) = E \circ S\vec{Y}(t), \quad t = 0,1,\cdots \tag{1.12}$$

由此可见,GA 可考虑作是 $N = M$ 时的 SEA.

例 1.2(演化策略) 设 $M_1: \boldsymbol{H}_L^\mu \to \boldsymbol{H}_L^\lambda$ 表示 ES(参见 1.1.4.2 节)的变异操作,$S_1: \boldsymbol{H}_L^\lambda \to \boldsymbol{H}_L^\mu$ 和 $S_2: \boldsymbol{H}^{\lambda+\mu} \to \boldsymbol{H}_L^\mu$ 分别表示(λ,μ)-ES 所使用的自然选择和$(\mu+\lambda)$-ES 所使用的父子混合选择.定义 $M_2: \boldsymbol{H}_L^\mu \to \boldsymbol{H}_L^{\lambda+\mu}$ 为

$$M_2\vec{X}(t) = M_1\vec{X}(t) \cup \vec{X}(t), \tag{1.13}$$

则根据 1.1.4.2 节定义,(λ,μ) ES 可描述作

$$\vec{X}(t+1) = S_1 \circ M_1\vec{X}(t), \quad t = 0,1,\cdots \tag{1.14}$$

或等价地,

$$Y_1(t+1) = M_1 \circ S_1 Y_1(t), \quad t = 0,1,\cdots \tag{1.15}$$

这里 $Y(t) = M_1\vec{X}(t)$.同样地,任何$(\mu+\lambda)$-ES 可表示作

$$\vec{X}(t+1) = S_2 \circ M_2\vec{X}(t), \quad t = 0,1,\cdots \tag{1.16}$$

或等价地,

$$Y_2(t+1) = M_2 \circ S_2 Y_2(t), \quad t = 0,1,\cdots \tag{1.17}$$

其中 $\vec{Y}_2(t) = M_2\vec{X}(t)$.于是,$(\lambda,\mu)$-ES 是对应 $E = M_1, S = S_1$ 的 SEA,$(\mu+\lambda)$-ES 是对应 $E = M_2, S = S_2$ 的 SEA.

显然,进化程序 EP 也可类似于(1.15)和(1.17)形式化表述.

由以上讨论可知,不同的 SEA 其区别只在于使用不同的选择算子 S 与

繁殖算子 E. 再加之 SEA 基于特定的染色体编码格式 e 和个体适应度度量求解问题, 且在 SEA 的执行中使用一系列可调参数. 如设这些可调参数构成集合 Σ, 则我们可表示

$$\mathrm{SEA}(e, J, S, E, \Sigma) \tag{1.18}$$

上述表示有三层含意. 第一, 编码格式 e, 适应度度量 J, 选择算子 S, 繁殖算子 E 和参数集 Σ 是 SEA 的基本构成要素, 不同的 SEA 以它所应用的 e, J, S, E, Σ 相区别; 第二, 对于确定的 e, J, S, E, Σ, 它表示一个特定的模拟进化算法; 第三, SEA 的性态是其构件 e, J, S, E, Σ 的函数(尽管这样的函数不可解析表达).

本节以下将分别给出 SEA 各构件的公理化描述与例子.

1.2.2 编码格式(e)

如 1.1.5 节所述, SEA 不对所求解问题的实际优化变量直接操作, 而是对表示可行解的遗传编码(即个体)作选择与繁殖运算, 通过这种进化操作来达到优化目的. 在 SEC 中, 把一个问题的可行解从其解空间转换到 SEC 所能处理的搜索空间(即个体空间)的转换方法称为是**编码**(encoding).

编码是 SEC(特别是 GA)解决问题的先决条件, 也是 SEA 设计的关键步骤. 其重要性主要体现在: (1)它不仅决定个体基因的排列形式(从而决定选择与繁殖等操作的作用方式), 而且也决定从搜索空间的基因型到解空间的表现型的解码方法(从而决定对 SEA 所获解的翻译与理解); (2)它决定 SEA 搜索的困难度与复杂性; (3)它相应决定对问题(1.1)的求解精度.

设 $\boldsymbol{H}_L = \{A = a_1 a_2 \cdots a_L \mid a_i \in \Gamma, i = 1, 2, \cdots, L\}$ 是个体空间, $\Omega = \{X = (x_1, x_2, \cdots, x_n)^{\mathrm{T}} \in R^n\}$ 是问题(1.1)的可行解空间.

定义 1.4 (i)一个**编码格式**(或简称**编码**)e 是从 $\boldsymbol{H}_L$ 到 Ω 的一个映射, 它使得对任何 $A \in \boldsymbol{H}_L$, 存在惟一 $X = e^{-1}(A) \in \Omega$ 与之对应(X 称为是 A 的**解码**).

(ii)编码格式 e 称为是**正则的**, 如果任何 $X \in \Omega$ 对应且惟一对应一个个体 A(此时, $A = e(X)$称为是 X 的编码).

(iii)如果 $A = a_1 a_2 \cdots a_L$ 是一个 L 码, $B = b_1 b_2 \cdots b_K$ 是一个 K 码, $A \vee B = a_1 a_2 \cdots a_L b_1 b_2 \cdots b_K$ 称为是 A 与 B 的一个**拼接**(对应地, A, B 称为是 $A \vee B = C$ 的一个分解).

(iv)一个编码 e 称为是**可拼接的**(splicing), 如果任何 L 码 A 和 K 码 B 的拼接 $A \vee B$ 仍有意义且是 $L + K$ 码; 一个编码 e 是**可分解的**(decomposiable), 如果任何 $C \in \boldsymbol{H}_L$ 可分解表示为 $C = A \vee B$, 其中 $A \in \boldsymbol{H}_\alpha, B \in \boldsymbol{H}_\beta$, α, β 是满足使 $\alpha + \beta = L$ 的任何正整数, 且 C 的解码在下述意义下是可分解的: 存在常数

a, b, c 使

$$e^{-1}(C) = e^{-1}(A \vee B) = ae^{-1}(A) + be^{-1}(B) + c. \tag{1.19}$$

根据上述定义，一个编码格式事实上是一个对 $\boldsymbol{H}_L$ 中个体的解码规则，它并不必须对可行解空间 Ω 中的任何 X 提供确切编码表示.然而，如果一个编码是正则的，则个体空间与可行解空间之间存在一一到上的对应，于是它不仅提供对个体的解码规则，也提供可行解的惟一编码表示.任一编码格式(即使是非正则的)对于 SEA 的应用而言是足够的，但使用正则编码可使得 SEA 在搜索中具有更强的直观，且能充分利用原问题可行解空间的结构与 f 的特有性质，使得搜索更为有效.另外，一个可拼接/可分解编码通常构成 SEA 自适应实现的基础，它为用“低精度计算”实现“高精度结果”、用“小算法”求解“大问题”提供框架(文献[63],[117]).

以下假定 Ω 是 R^n 的一个子集，$X = (x_1, x_2, \cdots, x_n)^{\mathrm{T}} \in \Omega$.如不特别指出，设 $x_i \in [a_i, b_i]$, $i = 1, 2, \cdots, n$.

例 1.3 (二进制编码) 二进制编码(binary encoding)是以二进制字符 0 和 1 为等位基因的定长字符串编码，是当今数字计算机所广泛采用的数字表示方法.给定编码精度 ε，取 m_i 是满足

$$\Delta_i = \frac{b_i - a_i}{2^{m_i} - 1} \leqslant \varepsilon, \quad i = 1, 2, \cdots, n \tag{1.20}$$

的最小整数，指定对应关系

$$\begin{array}{ccccc} 00000000 & \cdots & 00000000 & \to & a_i \\ 00000000 & \cdots & 00000001 & \to & a_i + \Delta_i \\ \vdots & & \vdots & & \vdots \\ 11111111 & \cdots & 11111111 & \to & b_i \end{array}$$

则任何 m_i 长的 0-1 字符串 $A_i = b_{m_i} b_{m_i - 1} \cdots b_2 b_1$ 惟一对应一个实数 x_i，定义为

$$x_i = e^{-1}(A_i) = a_i + \left(\sum_{j=1}^{m_i} b_j 2^{j-1} \right) \frac{b_i - a_i}{2^{m_i} - 1}. \tag{1.21}$$

现在令 $L = m_1 + m_2 + \cdots + m_n$.对任何 L 长的 0-1 字符串 $A \in \{0, 1\}^L$，表示

$$\begin{aligned} A &= A_1 \vee A_2 \vee \cdots \vee A_n \\ &= \underbrace{b_{1m_1} b_{1m_1 - 1} \cdots b_{12} b_{11}}_{A_1} \underbrace{b_{2m_2} b_{2m_2 - 1} \cdots b_{22} b_{21}}_{A_2} \cdots \underbrace{b_{nm_n} b_{nm_n - 1} \cdots b_{n2} b_{n1}}_{A_n}, \end{aligned}$$

并指定它的解码 $e^{-1}(A)$ 为

$$e^{-1}(A) = (e^{-1}(A_1), e^{-1}(A_2), \cdots, e^{-1}(A_n))^{\mathrm{T}}, \tag{1.22}$$

$e^{-1}(A)$显然给出 Ω 中惟一一个实数.

上述所定义的从 $\boldsymbol{H}_L$ 到 Ω 的对应显然是一个编码.但该编码不是正则的(因为 Ω 中不同的实数可以对应同一定长二进制表示).

二进制编码是通用、简明、易于各种进化操作的一种编码格式,但不具备正则性.特别地,这种编码格式往往破坏可行解空间的拓扑连续性:Ω 中两个靠近的点其编码可以非常的不靠近.例如说,在欧几里得(Euclid)度量下,整数集[0,10]中的数 7 和 8 是最邻近的,而它的 4 位二进制编码 0111 和 1000 在汉明(Hamming)距离(即取不同数值的位数)下是最远的.

下述灰度(gray)编码方法正是针对克服上述不保持拓扑连续性的缺陷所提出的.

例 1.4(*灰度编码*) 假定已有二进制编码 $A = a_L a_{L-1}\cdots a_2 a_1$,我们希望寻找一个修正(变换)的编码 $G = g_L g_{L-1}\cdots g_2 g_1$ 使得它保持原空间的拓扑连续性.为此,把 A 和 g 分别理解作 L 维向量,并在哈明空间 $\boldsymbol{H}_L$ 中考虑变换

$$G = TA \quad 或 \quad A = T^{-1}G \tag{1.23}$$

(注意,此时的加法在模 2 意义下进行).由计算机编码理论知,这样的变换 T 存在而且可具体为

$$T = \begin{pmatrix} 1 & 0 & 0 & \cdots & 0 \\ 1 & 1 & 0 & \cdots & 0 \\ 0 & 1 & 1 & \cdots & 0 \\ \vdots & \vdots & \vdots & & \vdots \\ 0 & 0 & 0 & \cdots & 1 \end{pmatrix}, \qquad T^{-1} = \begin{pmatrix} 1 & 0 & 0 & \cdots & 0 \\ 1 & 1 & 0 & \cdots & 0 \\ 1 & 1 & 1 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & 1 & 1 & \cdots & 1 \end{pmatrix}.$$

利用(1.23),我们容易推出二进制码到灰码的转换公式为

$$\begin{cases} g_L = a_L, \\ g_i = a_{i+1} \oplus a_i, \quad i = L-1, L-2, \cdots, 1. \end{cases} \tag{1.24}$$

而由灰码到二进制的转换公式为

$$\begin{cases} a_L = g_L, \\ a_i = a_{i+1} \oplus g_i, \quad i = L-1, L-2, \cdots, 1. \end{cases} \tag{1.25}$$

上述公式(1.24)~(1.25)中,$\oplus$表示异或运算符,即

$$a \oplus b = \begin{cases} 1, & a = b, \\ 0, & a \neq b. \end{cases}$$

作为例子,我们利用(1.24)可计算出:原二进制码 0 1 1 1(7),1 0 0 0(8),1 0 1 1(11),1 1 0 0(12)所对应的灰码分别是 0 1 0 0,1 1 0 0,1 1 1 0,1 0 1 0.灰度编码显然保持了原空间的拓扑连续性.

二进制及其灰度编码可进一步修改到一定意义下的正则编码,这即是下

述例 1.5 所给出的可分解/可拼接编码(文献[117]).

例 1.5（可分解/可拼接编码）　对于给定的求解精度 ε，让 l 是满足

$$\max_{1\leqslant i\leqslant n}\frac{b_i-a_i}{2^l}\leqslant\varepsilon \tag{1.26}$$

的正整数，并取 $L=nl$. 令

$$I=\{0,1,2,\cdots,2^l-1\},$$

$$\boldsymbol{H}(l)=(h_1(l),h_2(l),\cdots,h_n(l)),h_i(l)=\frac{b_i-a_i}{2^l},\quad i=1,2,\cdots,n,$$

对于任何 $X=(x_1,x_2,\cdots,x_n)^{\mathrm{T}}\in\Omega=\prod_{i=1}^{n}[a_i,b_i]$，我们以以下方式指定它的一个 L 位二进值编码 $e(X)$：

(1)首先获得每一分量 $x_i\in[a_i,b_i]$ 的 l 位编码 $e(x_i)=e_1(i)e_2(i)\cdots e_l(i)$. 方法如下：对分区间 $[a_i,b_i]$(图 1.2(a))，如果 x_i 位于 $[a_i,b_i]$ 的左半区间，则取 $e_1(i)=0$，否则取 $e(i)=1$(如恰位于中点，则恒取 1，以后同)，假定 X_i 位于一次对分剖分后的区间 $[a_i^{(1)},b_i^{(1)}]$ 内；对 $[a_i,b_i]$ 进行二次对分加细剖分(图 1.2(b))，于是 $[a_i^{(1)},b_i^{(1)}]$ 也自然被对分为两个区间，如果 X_i 位于这个区间的左半部分，令 $e_2(i)=0$，否则置 $e_2(i)=1$，假定 X_i 又位于这二次对分加细剖分后的区间 $[a_i^{(2)},b_i^{(2)}]$ 内；如此下去，直到已设定 $e_{l-1}(i)$ 的取值并断定 X_i 位于 $l-1$ 次对分加细剖分后的子区间 $[a_i^{(l-1)},b_i^{(l-1)}]$ 内；最后，对 $[a_i,b_i]$ 实行 l 次对分加细剖分，则 $[a_i^{(l-1)},b_i^{(l-1)}]$ 也必然被剖分为两个相等子区间(区间宽度为 $h_i(l)$)，如果 X_i 位于这个子区间的左半部，则取 $e_l(i)=0$，否则取 $e_l(i)=1$.

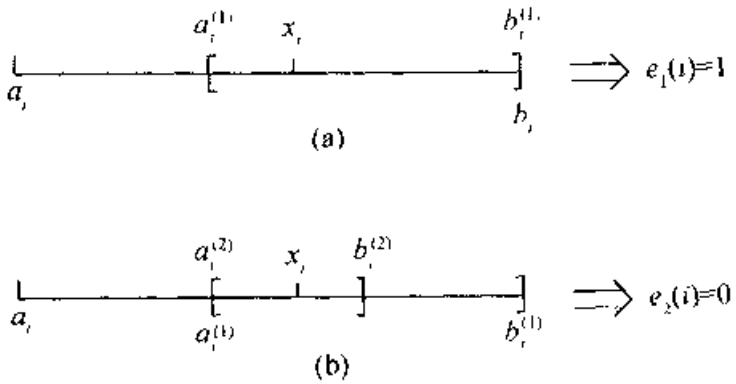


图 1.2　一维可分解/可拼接编码示意图

(2)将每一分量 x_i 的 l 位编码交叉拼接构成 X 的编码 $e(X)$：

$$e(X)=e_1(1)e_1(2)\cdots e_1(n)\mid e_2(1)e_2(2)\cdots e_2(n)\mid\cdots\mid$$

$$e_l(1)e_l(2)\cdots e_l(n). \tag{1.27}$$

注意,在上述编码中,前 n 位是 X 各分量的第一位编码拼接而成;第二组 n 个码是由 X 各分量的第二位编码拼接而成;余此类推.

上述形成 X 编码的过程本质上是通过对 Ω 沿各坐标实行 l 次渐细对分剖分,以使 Ω 分解成胞腔(cell)空间,然后记录渐细剖分过程的作法(参见图 1.3).事实上,对 Ω 作 l 次渐细对分剖分后,Ω 被分割为 2^{nl} 个如下形式的超立方体区域(称为胞腔,它们的边长均小于 ε):

$$\Omega = \bigcup \{\sigma(z), z \in \boldsymbol{I}^n\} := \Gamma(l), \tag{1.28}$$

其中,对任何 $z=(z_1,z_2,\cdots,z_n)$, $z_i\in \boldsymbol{I}$,

$$\sigma(z) = \{X = (x_1,x_2,\cdots,x_n) \in \Omega \mid z_i h_i(l) \leqslant x_i \quad a_i \leqslant (z_i+1)h_i(l), i = 1,2,\cdots,n\}.$$

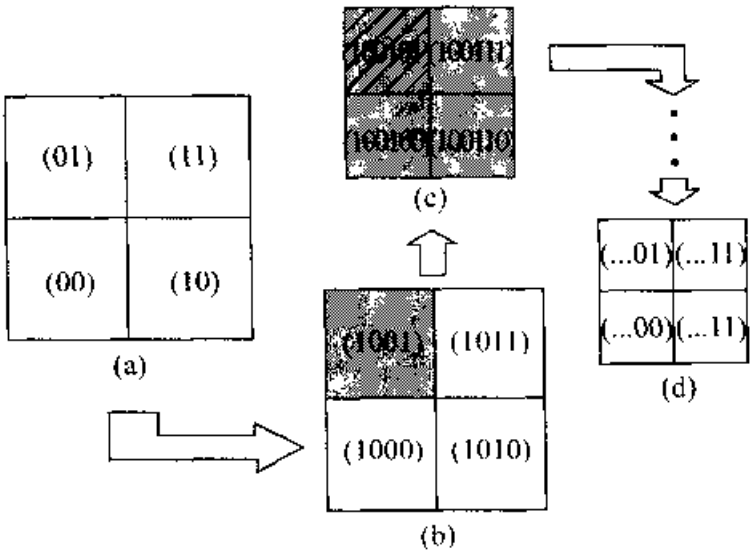


图 1.3 $n=2$ 时可分解/可拼接编码示意图

$\sigma(z)$的中心为

$$m(\sigma(z)) = ((z_1+\frac{1}{2})h_1(l),(z_2+\frac{1}{2})h_2(l),\cdots,(z_n+\frac{1}{2})h_n(l))^{\mathrm{T}}.$$

于是,$\Gamma(l)$中的任一胞腔 $\sigma(z)$可等价地表示为

$$\sigma(z) = \langle m(\sigma(z)), H(l)\rangle, \tag{1.29}$$

这里 $H(l)=(h_1(l),h_2(l),\cdots,h_n(l))^{\mathrm{T}}$ 为边长向量.

根据 Ω 的渐细对分剖分过程容易验证:如果 $X\in\sigma(z)$, x_i 的编码 $e(x_i)=e_1(i)e_2(i)\cdots e_l(i)$,则

$$z_i = \sum_{j=1}^{l} e_j(i)2^{l-j}, \quad i = 1,2,\cdots,n,$$

其

$$[m(\sigma(z))]_i = (z_i + \frac{1}{2})h_i(l)$$
$$= a_i + \left\{\sum_{j=1}^{l} e_i(i)\frac{1}{2^j} + \frac{1}{2^{l+1}}\right\}(b_i - a_i). \tag{1.30}$$

基于上述分析，我们可给出如下定义.

定义1.5（可拼接/可分解编码，简称S/D编码）　(i)对任何$X \in \Omega$，由(1.27)所定义的$e(X)$称为是X的**l-S/D码**；(ii)如果$L = nl$，$A = b_1 b_2 \cdots b_l \in \{0,1\}^l$是任一$L$长0-1字符串(即个体)，则它的解码$e^{-1}(A)$为

$$e^{-1}(A) = (e_1^{-1}(A), e_2^{-1}(A), \cdots, e_n^{-1}(A))^{\Gamma},$$

其中

$$e_i^{-1}(A) = a_i + \left\{\sum_{k=1;k=m+i}^{l} b_k \frac{1}{2^j} + \frac{1}{2^{l+1}}\right\}(b_i - a_i),$$
$$i = 1, 2, \cdots, n.$$

由上述定义所给出的可拼接/可分解编码具有以下特别优点：

(1)在后述意义下是正则的：视$\Omega = \Gamma(l)$为胞腔空间(参见(1.28))，则Ω与个体空间$\boldsymbol{H}_L$之间存在一一到上的对应. 事实上，根据定义1.5和(1.30)式，对任何$\sigma(z) \in \Gamma(l)$，$\boldsymbol{H}_L$中的个体$e(m(\sigma(z)))$(即$m(\sigma(z))$的l-S/D码)与之对应，不同的$\sigma(z)$也必对应不同的个体$e(m(\sigma(z)))$；而对任何个体$A \in \boldsymbol{H}_L$，它的解码$e^{-1}(A)$与边长向量$H(l)$一起构成胞腔$\langle e^{-1}(A), H(l)\rangle$，这个胞腔正是$\Gamma(l)$中的一个(参见图1.4). S/D编码的这种正则性蕴含一个重要的事实：$\boldsymbol{H}_L$中的字符串A不仅可代表个体，而且能代表一个无限种群(即无限多的个体)(因为如果A是$m(\sigma(z))$的S/D码，则它也必是$\sigma(z)$中任何元素X的S/D码)，因而A本质上代表了$\sigma(z)$中的所有元). 基于这一事实，S/D编码可应用来实现区间搜索(即以"区间"为基本单元的搜索).

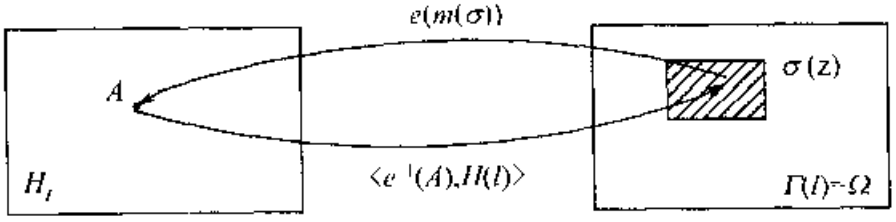


图1.4　可拼接/可分解编码的正则性

(2)S/D编码是可拼接和可分解的. 从S/D编码的构造过程中可看到：对给定的$X \in \Omega$，它的l-S/D码$e(X) = e_1(1)e_1(2)\cdots e_1(n) \mid e_2(1)e_2(2)\cdots e_2(n) \mid \cdots \mid e_l(1)e_l(2)\cdots e_l(n)$，其第一组$n$个码$e_1(1)e_1(2)\cdots e_1(n)$反映对

Ω 作一次对分剖分后X所位于的边长为$H(1)$的胞腔位置(可视为对 X 的 $\frac{1}{2}$精度定位),设包含 X 的这个$H(1)$胞腔为$\sigma(z^{(1)})$;第二组 n 个码 $e_2(1)e_2(2)\cdots e_2(n)$反映 X 所位于的对Ω 作二次对分加细剖分后的$H(2)$胞腔的位置(对 X 的$\frac{1}{2^2}$精度定位). 显然它等价于对 $\sigma(z^{(1)})$作一次对分剖分后对 X 的定位(即 X 在Ω 内的$\frac{1}{2^2}$精度定位等价于在 $\sigma(z^{(1)})$内的$\frac{1}{2^1}$精度定位)(参见图 1.3);类似地可解释 $e(X)$的每一组码值.一般,我们可以断言:对 X 的在Ω 内的$\frac{1}{2^k}$精度定位等价于先在Ω 内作$\frac{1}{2^{k_1}}$精度定位,找到所在的 $H(k_1)$ 胞腔 $\sigma(z^{(k_1)})$,然后在 $\sigma(z^{(k_1)})$内作$\frac{1}{2^{k_2}}$精度定位(这里 k_1,k_2 是满足 $k_1+k_2=k$ 的正整数).据此,我们容易看到,S/D 编码既是可拼接的,也是可分解的,特别成立下述结论.

定理 1.1 假定 $A\in \boldsymbol{H}_{L_1}$, $B\in \boldsymbol{H}_{L_2}$是任意两个 L_1-S/D 码和 L_2-S/D 码,$A\vee B$ 是A 与B 的拼接,则

(i) $A\vee B$ 是(L_1+L_2)-S/D 码(严格地说,是 $e^{-1}(A\vee B)$的(L_1+L_2)-S/D 码).

(ii) $\|e^{-1}(A)-e^{-1}(A\vee B)\|_\infty \leqslant \max\limits_{1\leqslant i\leqslant n}\dfrac{(b_i-a_i)}{2^{L_1}}$.

(iii)成立以下分解解码公式:

$$e_i^{-1}(A\vee B)=e_i^{-1}(A)+\frac{1}{2^{L_1}}e_i^{-1}(B)-\frac{b_i+a_i}{2^{L_1+1}},\qquad (1.31)$$

这里 $e^{-1}(A\vee B)=(e_1^{-1}(A\vee B),e_2^{-1}(A\vee B),\cdots,e_n^{-1}(A\vee B))^{\mathrm{T}}$.

上述 S/D 编码的可拼接/可分解性构成自适应 SEA 的实现基础.

(3)S/D 编码使其个体基因赋有清晰的几何意义.由上段的讨论可知,对于 X 的编码

$$e_1(1)e_1(2)\cdots e_1(n)\mid e_2(1)e_2(2)\cdots e_2(n)\mid\cdots\mid e_l(1)e_l(2)\cdots e_l(n),$$

其每一位都有明确的几何意义:它的第 k 组基因段$e_k(1)e_k(2)\cdots e_k(n)$是在前 $k-1$ 组已给出 X 的$\frac{1}{2^{k-1}}$精度定位 $X\in\sigma(z^{(k-1)})$后对 X 所提供的进一步加细定位(精度定位):$X\in\sigma(z^{(k)})\subseteq\sigma(z^{(k-1)})$,换言之,

$$X\in\sigma(z^{(k)})\subseteq\sigma(z^{(k-1)})\subseteq\cdots\subseteq\sigma(z^{(1)})\subseteq\Omega.\qquad (1.32)$$

这里胞腔 $\sigma(z^{(k-1)})$由 $e_k(1)e_k(2)\cdots e_k(n)$惟一确定(参见图 1.3).从这一观

察我们看到 X 的编码 $e(X)$ 从左至右：第一组负责对 X 的宏观定位 $\left\{\frac{1}{2}\text{精度}\right\}$，第二组负责次宏观的定位 $\left\{\frac{1}{2^2}\text{精度}\right\}$，…，第 k 组负责进一步 $\frac{1}{2^k}$ 精度的定位，如此等等，最后若干组依次提供越来越精细，越来越微观的定位．由此知，$e(X)$ 的基因从左至右其作用是不同的，或更确切地说，其重要程度是递减的．这一特征使得 S/D 编码非常适合于运用 SEA 对所给问题提供精度渐细的自适应计算（文献[63]～[117]），特别为运用“低精度”算法求“高精度”解，用“低维算法”求解“高维问题”带来了可能．

例 1.6（实数编码） 对于高维、连续优化问题，使用二进制编码常常是不便利的．这种不便利主要体现在：第一，存在连续量到二值量的离散化误差．这种误差的存在使得要么 SEA 很难求出高精度的解，要么必须在一个很长的染色体空间上进行搜索（即要求编码长度 L 很长）．由于 SEA 此时是通过解组合优化问题(1.5)来达到求解问题(1.1)的，在一个高维的空间上求解组合问题无疑十分困难．第二，二进制编码不便于反映所求问题的特定知识（特别是以连续性为基础的各种信息），也不便于开发针对问题专门知识的进化算子，人们在一些经典优化算法的研究中所积累的一些宝贵经验也就无法在这里加以利用．为改进这些二进制编码的缺陷，人们也常常使用实数值编码（如 ES 和 EP），即对任何 $X=(x_1,x_2,\cdots,x_n)\in\Omega$，或直接取染色体编码 $A=e(X)=x_1x_2\cdots x_n\in \boldsymbol{H}_n$，或取一个同胚映射 φ，定义 $A=e(X)=\varphi(X)=[\varphi(X)]_1\cdot[\varphi(X)]_2\cdots[\varphi(X)]_n$，这里 $[\varphi(X)]_i$ 是 $\varphi(X)$ 的第 i 个分量（$i=1,2,\cdots,n$）．

实数编码自然是正则编码，其最大优点是适合于高精度计算，且便于推广或溶合经典连续优化算法，但缺陷是只能对连续变量问题使用．

例 1.7（符号编码） 符号编码是指个体染色体中码值取自一个无数值含义，只有代码含义的符号集的编码．这个符号集可以是一个字母表，也可以是一个数字序号表，还可以是一个代码表等等．

最典型的例子莫过于人们已经习惯于用 A、T、G、C 四个字符来分别代表生物 DNA 核苷酸中的四种碱基化合物，腺嘌呤，胞腺嘧啶，鸟嘌呤和胞嘧啶，因而把生物 DNA 表示作由 A、T、G、C 组成的有限序列．例如，字符串

AATCTTGGGGAATACG……TAGCCC

可以代表某个生物的 DNA 序列．

另一个经常应用的例子是用 $\{0,1\}$ 表示图或网络中的路径．假定说考虑多源多目的地通讯问题[62]：给定一个由 n 个结点组成的通讯网络（结点集例如标记为 $N=\{1,2,\cdots,n\}$），指定其中若干个（例如设前 2 个）结点为源结点，若干（例如后 3 个）为目的地结点．寻求一条连接源结点到目的地结点的路径使

整个通讯代价最小. 为了求解这一问题, 我们可以用一个长度为 $n-5$ 的 0-1 字符串 $A=a_1a_2\cdots a_{n-5}$ 来表示任何一个可行路径(之所以长度为 $n-5$, 是由于只需考虑除去源与目的地结点的自由结点集 $\tilde{N}=N\setminus\{1,2,n-2,n-1,n\}$), 这里

$$a_i=\begin{cases}1, & \text{如果路径经过结点 } i+2,\\ 0, & \text{否则,}\end{cases}$$

$i=1,2,\cdots,n-5$.

再看一个例子. 考虑旅行商(TSP)问题: 一个商人希望走过 n 个城市(记为 $c_1,c_2,\cdots,c_n$), 从某城市出发并最后回到该城市且每个城市必须访问且只能访问一次. 为了求解这一问题, 将各城市的代号按其访问顺序连接在一起即构成一个旅行策略. 如 $A=c_3c_1\cdots c_n$ 表示顺序访问城市 $c_3,c_1,\cdots,c_n$ 的策略. 若将各个城市按其代号的下标进行编号, 这个策略也可表示为

$$A=3\,1\cdots n.$$

符号编码可用以处理各种非数值优化问题与组合优化问题, 优点是在 SEA 中便于利用所求问题的专门知识, 但缺点是设计进化操作相对困难(特别是在保证进化操作使得其结果具有合法性, 或者说, 满足约束条件方面).

总的说, 不同的编码方式具有不同的优缺点, 有不同的适用范围. 目前还不存在一套完整的理论可用以指导选择各类编码, 需要读者根据应用问题智慧选择.

1.2.3 适应度度量(J)

适应度(fitness)是生物学家在研究自然界中生物的遗传和进化现象时用以度量某个物种对其生存环境适应程度的术语. SEC 借用这个术语来量度个体作为(1.1)全局最优解的可接受程度, 它是 SEC 评价和选择个体的度量依据.

设 $\boldsymbol{H}_L$ 是个体空间, $A\in\boldsymbol{H}_L$ 的表现型记为 $e^{-1}(A)$(即 A 的解码).

定义1.6(适应度) $\boldsymbol{H}_L$ 上的一个**适应度**(适应度度量)是一个映射 $J:\boldsymbol{H}_L\to\boldsymbol{R}_0^+$, 它的取值与(1.1)的某一适应值函数(参见定义 1.3)成正比.

给定(1.1)的任一适应值函数 $F:\Omega\to\boldsymbol{R}_0^+$, $\boldsymbol{H}_L$ 上的一个常规适应度度量定义为 $J(A)=F(e^{-1}(A))$, $\forall A\in\boldsymbol{H}_L$(参见 1.1.4 节). 为了记号上的简便, 这一定义也常记作

$$J(A)=F(A),\qquad \forall A\in\boldsymbol{H}_L. \tag{1.33}$$

由于这一原由, 一个适应值函数通常也直接称作是一个适应度度量.

适应度度量的确定通常应该反映应用者对个体(候选解)的评价标准(甄别原则)和搜索原理. 例如说, 在 SEA 搜索的第 t 代, 为了避免对质量不高解

搜索的重复性,我们可以应用适应度

$$J_t(A)=\begin{cases}F(A), & \text{如果 } F(A)\geqslant F_{\max}^{(t-1)},\\ 0, & \text{否则,}\end{cases} \tag{1.34}$$

这里 $F_{\max}^{(t)}$ 表示 SEA 在 t 代之前所记录的最高个体适应值.又例如,在 SEA 运行初期阶段,通常种群中个体差异较明显,此时若按通常选择,某些特别优势个体将很快在后代种群中占据愈来愈多份额,从而导致种群多样性丧失而出现假收敛(prematrue convergence)(即算法稳定到一个非全局最优的状态).所以,此时我们应该对一些适应度较高的个体进行适当压制,降低其适应度与其他个体适应度的差异,而采用"缩小差异"的适应度度量.而相反,到 SEA 的运行后期,种群中个体差异缩小,缺乏足够的区别性,从而影响算法的精细搜索.此时就应该选择"扩大差异"的适应度度量.

这种"缩小差异"或"扩大差异"的适应度指定方法可通过对原有(或已知)适应度作适当变换(fitness scaling)的方法实现.常用的适应度变换有以下三种:

(1)线性尺度变换.假定 J 是原适应度度量,J' 是变换后的新适应度度量,则线性尺度变换的变换公式是

$$J'(A)=\alpha J(A)+\beta,\quad \forall A\in \boldsymbol{H}_L, \tag{1.35}$$

这里 α 是缩放因子,β 是平移参数.其变换效果取决于对参数 α,β 的选取.

(2)乘幂尺度变换.乘幂尺度变换的公式为

$$J'(A)=J^K(A),\quad \forall A\in \boldsymbol{H}_L, \tag{1.36}$$

即新的适应度是原有适应度的某个指定乘幂.幂指数 K 与变换目的及所求解的问题有关.

(3)指数尺度变换.指数尺度变换的公式为

$$J'(A)=\exp(-\beta J(A)),\quad \forall A\in \boldsymbol{H}_L, \tag{1.37}$$

即新的适应度是原有适应度的某个指数.(1.37)中的系数 β 决定了变换的缩放程度:β 越小,原有适应度的个体其新适应度就与其他个体适应度相差越大,反之,原有适应度高的个体在新适应度度量下与其他个体适应度的差异得到压缩.

1.2.4 选择算子(S)

选择算子是决定父代种群中那些个体、并能以多大可能性被挑选来复制或遗传到下一代的进化操作,它模拟的是"优胜劣汰、适者生存"的自然进化原理.选择算子以对个体的适应度评价为基础,其主要作用是对 SEA 的搜索提供导向:挑选最优秀个体,使算法避免无效搜索且能以快的速度搜索到问题

(1.1)的最优解.

设 $\vec{X}\in \boldsymbol{H}_L^N$, $\vec{Y}\in \boldsymbol{H}_L^M$ 表示种群, $\vec{X}=(X_1, X_2, \cdots, X_N)$, $\vec{Y}=(Y_1, Y_2, \cdots, Y_M)$. 让

$$B(\vec{X})=\{X_i \mid J(X_i)\geqslant J(X_j), j=1,2,\cdots,N\},$$
$$J_{\max}(\vec{X})=\max\{J(X_i)\mid i=1,2,\cdots,N\}$$

分别表示种群 $\vec{X}$ 中适应度最大个体的全体,及种群 $\vec{X}$ 的最大适应度. $B(\vec{X})$ 所含个体的数目用 $|B(\vec{X})|$ 表示(以后,对任何集合 A,用 $|A|$ 表示 A 中所含元素个数).

定义 1.7 (选择算子) 一个**选择算子** S 是一个随机映射 $S: \boldsymbol{H}_L^N\to \boldsymbol{H}_L^M$,它满足

(1) 对任何 $\vec{X}\in \boldsymbol{H}_L^N$, $S(\vec{X})\subseteq \vec{X}$.

(2) 对任何满足 $|B(\vec{X})|<N$ 的种群 $\vec{X}$ 有

$$P\{|B(S(\vec{X}))|+(N-M)>|B(\vec{X})|\}>0. \tag{1.38}$$

上述条件(1)是说被选择的个体应该是被选择种群的一部分,而(2)是说,除选择后个体与原种群个体数目差异外,选择算子的作用应该有可能增加种群中最优个体(即具有最高适应度的个体)的数目,只要被选择种群不是齐次种群(换句话说,其中个体具有完全相同的适应度). 这两条显然刻画了选择算子的最基本特征.

例 1.8 (比例选择) 给定种群 $\vec{X}\in \boldsymbol{H}_L^N$,以概率(1.39)独立、重复地从 $\vec{X}$ 中选择 M 个个体组成 $\vec{Y}=S(\vec{X})=(Y_1, Y_2, \cdots, Y_M)$:

$$P\{Y_i=X_j\}=\frac{n(X_j)J(X_j)}{\sum_{k=1}^{N}J(X_k)}, \tag{1.39}$$

这里 $i=1,2,\cdots,M$, $j=1,2,\cdots,N$, $n(X_j)$ 表示 X_j 在 $\vec{X}$ 中重复的次数. 容易看到: $S(\vec{X})\subseteq \vec{X}$,且只要 $\vec{X}$ 不是齐次种群(例如,不妨设 $X_1,\cdots,X_I$ 是 $\vec{X}$ 中的最优个体,而 $X_{I+1},\cdots,X_N$ 是非最优个体),则总有

$$\begin{aligned}&P\{|B(\vec{Y})|+(N-M)>|B(\vec{X})|\}\\&=P\{Y_i\neq X_j \mid i=1,2,\cdots,M, j\in\{I+1,I+2,\cdots,N\}\}\\&=\prod_{j=I+1}^{N}\left[1-\frac{n(X_j)J(X_j)}{\sum_{K=1}^{N}J(X_K)}\right]>0,\end{aligned}$$

于是上述定义 1.5 的(1)和(2)全部满足,即比例选择是选择算子.

目前已经发展出各种各样的选择算子. 这些算子就其选择机制而言可分为比例型(proportionate-based),排序型(ranking-based)和非单调型(nonmonotonic-based)三类.

1.2.4.1 比例型

例 1.9(带尺度变换的比例选择) 由例 1.8 所给出的比例选择可以一般化到**带尺度变换的比例选择算子**,即代替(1.39)式而使用概率分布

$$P\{Y_i = X_j\} = \frac{n(X_j)\sigma(J(X_j))}{\sum_{k=1}^{N}\sigma(J(X_k))}, \tag{1.40}$$

这里 $\sigma: R_0^+ \to R_0^+$ 为一个尺度变换,即是满足使 $\sigma(0)=0$ 的一个严格单调增正函数. 一个常用的比例型选择是**整体退火选择算子** S_T(global annealing selection),它对应于尺度 $\sigma(\lambda)=1/T$ 下的比例选择:

$$P\{Y_i = X_j\} = \frac{n(X_j)\exp(\frac{J(X_j)}{T})}{\sum_{k=1}^{N}\exp(\frac{J(X_k)}{T})}, \tag{1.41}$$

其中 T 称为**退火温度**. 另一个常用的比例选择算子是**乘幂适应值选择** S_α(power fitness value selection),它对应于尺度 $\sigma(\lambda)=\lambda^\alpha$ 的比例选择

$$P\{Y_i = X_j\} = \frac{n(X_j)J^\alpha(X_j)}{\sum_{k=1}^{N}J^\alpha(X_k)}. \tag{1.42}$$

例 1.10(杰出者选择) **杰出者选择**(elitist selection) $S_E: \boldsymbol{H}_L^N \to \boldsymbol{H}_L$ 是强制性(即以概率 1)选择种群中适应度最高个体的选择:它所对应的概率分布为

$$P\{Y_i = X_j\} = \begin{cases} 1, & \text{如果 } X_j \in B(\vec{X}), \\ 0, & \text{如果 } X_j \notin B(\vec{X}). \end{cases} \tag{1.43}$$

这种选择通常在 SEC 中的应用模式为:首先根据父代种群 $\vec{X}(t)$ 执行通常的繁殖(进化)操作 E_1,生成中间种群 $\vec{X}'(t)=E_1\vec{X}(t)$,然后从 $\vec{X}'(t)$ 中选择(例如以比例选择 S_P) $N-1$ 个个体,从 $\vec{X}(t)$ 中选择一个最优个体共同组成新一代种群 $X(t+1)$. 这种杰出者选择型 SEA 可抽象描述作

$$\vec{X}(t+1) = \begin{Bmatrix} S_P & 0 \\ 0 & S_E \end{Bmatrix} \cdot \begin{Bmatrix} E_1 & 0 \\ 0 & I \end{Bmatrix} \cdot L\vec{X}(t), \tag{1.44}$$

这里 $S_P: \boldsymbol{H}_L^N \to \boldsymbol{H}_L^{M-1}$ 是比例选择算子, $S_E: \boldsymbol{H}_L^N \to \boldsymbol{H}_L$ 是杰出者选择算子, $E_1: \boldsymbol{H}_L^N \to \boldsymbol{H}_L^M$ 是繁殖算子, I 是复制(copy)算子, $L: \boldsymbol{H}_L^N \to \boldsymbol{H}_L^{2N}$ 是扩展算子,定义为

$$LX = \begin{Bmatrix} X \\ X \end{Bmatrix}, \quad \forall X \in \boldsymbol{H}_L^M.$$

若定义

$$S = \begin{pmatrix} S_P & 0 \\ 0 & S_L \end{pmatrix}, \qquad E = \begin{pmatrix} E_L & 0 \\ 0 & I \end{pmatrix} \circ L,$$

分别是选择算子($S: \boldsymbol{H}_I^{2N} \to \boldsymbol{H}_L^N$)和繁殖算子($E: \boldsymbol{H}_L^N \to \boldsymbol{H}_L^{2N}$),则(1.44)可化为SEA的一般形式(1.8).

例 1.11(期望生存数选择) 这种选择基于对当前群体中每个个体在下一代种群中的**期望生存数**(expected survival number)作个体选择(随机地或确定地).具体方法是:

(1)计算种群 $\vec{X}$ 中各个体在下一代种群中的期望生存数:令

$$N_i = M \frac{J(X_i)}{\sum_{k=1}^{M} J(X_k)}, \quad i = 1, 2, \cdots, N,$$

X_i 在下一代的期望生存数取为 N_i 的整数部分 $\lfloor N_i \rfloor$.

(2)依据上述数目选择出 $\sum_{i=1}^{N} \lfloor N_i \rfloor$ 个个体(即如果 $\lfloor N_i \rfloor = k$,则选择 k 次 X_i).

(3)用其他方法选择出其他 $M - \sum_{i=1}^{N} \lfloor N_i \rfloor$ 个个体.例如可依据 N_i 的小数部分先对 $\vec{X}$ 中个体进行降序排序,顺序取前 $M - \sum_{i=1}^{N} \lfloor N_i \rfloor$ 个个体(这种方式称为**确定式采样选择**, deterministic sampling selection);也可以先对适应度作变换:

$$J'(X_i) = J(X_i) - \lfloor N_i \rfloor \cdot \sum_{j=1}^{M} J(X_j) \Big/ M, \tag{1.45}$$

而依据这一新的适应度度量而随机比例选择这 $M - \sum_{i=1}^{N} \lfloor N_i \rfloor$ 个个体(此种选择称为"**带替代余数的随机选择**(remainder stochastic with replacement)".

1.2.4.2 排序型

例 1.12(排序选择) 依 $\vec{X}$ 中个体之适应度作降序排序并分别指定其序号为 $1, 2, \cdots, N$.则 $\vec{Y} = S(\vec{X}) = (Y_1, Y_2, \cdots, Y_m)$ 的概率分布取为

$$P\{Y_i = X_j\} = q - (j-1)p, \quad j = 1, 2, \cdots, N, \tag{1.46}$$

这里 $q = (N-1)p/2$, $p \in [0, 2/N(N-1)]$ 为参数(线性排序选择),或取为

$$P\{Y_i = X_j\} = q(1-q)^{(j-1)}, \quad j = 1, 2, \cdots, N, \tag{1.47}$$

这里 $q \in (0, 1)$ 为参数(非线性排序选择).

例 1.13(锦标赛选择) **锦标赛选择**(tournament selection)是以体育联赛方式,以个体适应度比较为基础的选择个体策略.为了选择个体 Y_i,先指定一

个被称为竞赛规模的量 s,然后在 $\vec{X}$ 中以某种方式选取 s 个个体,依其适应度大小所排出的最优个体取为 $Y_i(i=1,2,\cdots,M)$.常用的选取参赛 s 个个体的方式是随机从 $\vec{X}$ 中选取(随机竞标赛选择),或在 X_i 的邻近 s 个个体中选取(确定型).

例 1.14 (Boltzmann 选择) **Boltzmann 选择**是整体退火选择的局部化,也可认为是竞标赛选择的"软"修正.它对应竞赛规模 $s=2$,并取 X_i 的相邻个体为参赛对象,但均以一定正概率接受每一参赛个体.这个搜索概率为

$$P\{Y_i=X_j\}=\frac{\exp(J(X_j)/T)}{\exp(J(X_{i-1})/T)+\exp(J(X_i)/T)} \tag{1.48}$$

(注意,令 $X_{N+1}=X_1$).

例 1.15 (EP 选择) 进化程序使用竞标赛选择与排序选择相混合的选择策略.首先通过随机取 $\vec{X}$ 中不同于 X_i 的 s 个个体,比较其适应度差异:比 X_i 适应度高的个体数目 w_i 被指定为 X_i 的得分;然后以 $\vec{X}$ 中个体的得分排序取前 M 个个体作为选择后的种群.

1.2.4.3 非单调型

以上例 1.8~例 1.15 所给出的选择算子在对应相应个体适应度的意义上是单调的,即个体被选择的概率在一定意义下是与它的适应度成正比的.下述例 1.16 给出一个非单调型选择算子的例子.

例 1.16 (Disruptive 选择) 对于给定的适应度度量 J,令

$$U(X_j)=|J(X_j)-\bar{J}(\vec{X})|,$$

其中 $\bar{J}(\vec{X})=\frac{1}{N}\sum_{k=1}^{N}J(X_k)$ 表示种群 $\vec{X}$ 的平均适应度,$U(X_j)$表示 X_j 与 $\vec{X}$ 的均值偏差度(normalized-by-mean fitness).**Disruptive 选择**依据种群偏差度实施选择,例如,X_j 被选择的概率取为

$$P\{Y_i=X_j\}=\frac{U(X_j)}{\sum_{k=1}^{N}U(X_k)},\quad i=1,2,\cdots,N,\ j=1,2,\cdots,M. \tag{1.49}$$

从几何上,这意味着:离平均适应度越远的个体越有高的被选择的机会(图 1.5),从而与个体的适应度对应不具有单调性.这一选择常被认为能带来种群的更大多样性.

单调型选择可认为是基于"择优"或"优胜"型的选择.实现"择优"的另一重要方法是"去劣"(或"劣汰").下述例 1.17 提供"去劣"型选择的一个例子.

例 1.17 (排除算子) 设 $\vec{X}=(X_1,X_2,\cdots,X_N)\in \boldsymbol{H}_L^N$ 且每一个体代表一个区域(例如用可拼接/可分解编码时).**排除算子**是依据(1.1)的某个可计算

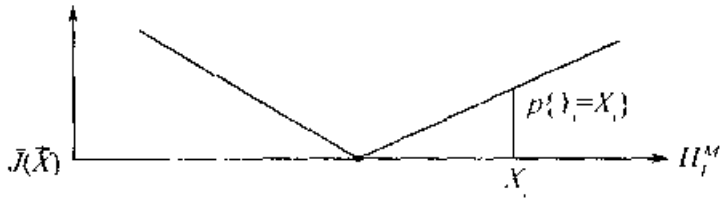


图 1.5 Disruptive 选择

存在性必要条件(或对应地,解不存在性可计算准则)而从 $\vec{X}$ 中淘汰个体的选择运算([117]).例如说,假定 $X_i=<m(X_i),H(l)>$ 是一个胞腔(参见公式(1.29))且(1.1)中的目标函数 f 是 lipschitz 连续的(即存在常数 $\alpha>0$ 使 $|f(X)-f(Y)|\leqslant\alpha\|X-Y\|_\infty$,则(1.1)在 X_i 内存在全局极大 X^* 的必要条件是

$$|f(m(X_i))-f(X^*)|\leqslant\alpha\|m(X_i)-X^*\|_\infty\leqslant\frac{\alpha}{2}\omega(X_i),$$

其中 $\omega(X_i)=\max_{1\leqslant l\leqslant n}h_i(l)$ 是胞腔 X_i 的宽度,从而对任何参考向量 $f(X_i)$ 必满足

$$f(X_i)\leqslant f(X^*)\leqslant f(m(X_i))+\frac{\alpha}{2}\omega(X_i). \tag{1.50}$$

这个必要条件对任何个体是可计算的,因而是一个可计算存在性必要条件.这个必要条件推出下述解不存在性可计算准则:如果(1.51)对胞腔 X_i 满足

$$f(X_i)>f(m(X_i))+\frac{\alpha}{2}\omega(X_i), \tag{1.51}$$

则(1.1)在 X_i 内必无整体极大值,故 X_i 可从 $\vec{X}$ 中删去.

排除算子常被应用来耦合 f 的某种性质来加速 SEA 收敛,有兴趣的读者可参见文献[63]和[117].

1.2.5 繁殖算子(E)

繁殖算子是 SEA 根据所选母体生成子代的操作,它模拟的是生物物种的繁衍过程与遗传变异机制.如果说在 SEA 中选择算子主要担负对 SEA 搜索的导向任务,则繁殖算子主要担负具体搜索任务.

为了抽象描述繁殖算子,我们先引进满意集(satisfactory set)的概念.

定义 1.8(满意集) 设 $\boldsymbol{H}_L$ 是个体空间,$\mathcal{P}=2^{\boldsymbol{H}_L}$ 是 $\boldsymbol{H}_L$ 的乘幂空间.一个子集 $B\in\mathcal{P}$ 称为是一个**满意集**,如果对任意 $X\in B$ 和 $Y\notin B$ 成立 $F(X)>F(Y)$.

根据上述定义,一个满意集 B 是 $\mathcal{P}$ 中这样的一个个体子集,它的每一个个体的适应度均大于它之外的个体适应度.显然问题(1.5)的全局最优解集

B^* 是满意集.对于任意给定的个体 X_0,

$$B(X_0) = \{X \in \boldsymbol{H}_L \mid F(X) \geqslant F(X_0)\} \tag{1.52}$$

为满意集(称为由 X_0 诱导的满意集).另外,容易验证,若 B_1, B_2 是两个满意集,则必有 $B_1 \subseteq B_2$ 或 $B_2 \subseteq B_1$ 成立,于是 $\mathcal{F}$ 上满意集的全体在集合包含的意义下是可序的(图 1.6),所以全局最优解集 B^* 是所有满意集的交,是最小的满意集.任何满意集可解释作最优解集 B^* 的邻域.

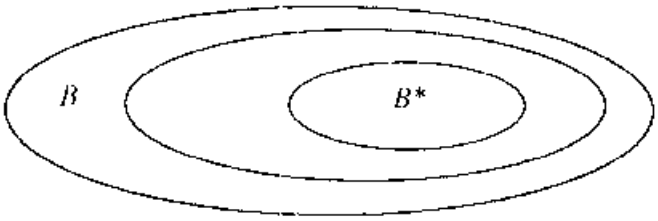


图 1.6　满意集的可序性

定义 1.9（种群满意集）　设 $\vec{X} \in \boldsymbol{H}_L^M$ 是任一种群,X_e 是 $\vec{X}$ 中的最优个体,由 X_e 诱导的满意集称为**由 $\vec{X}$ 诱导的满意集**,记为

$$B_e(\vec{X}) = \{X \in \boldsymbol{H}_L : F(X) \geqslant F(X_e)\}. \tag{1.53}$$

由种群 $\vec{X}$ 所诱导的满意集也称为是**$\vec{X}$ 的满意集**.

定义 1.10（繁殖算子）　一个随机映射 $E: \boldsymbol{H}_L^M \to \boldsymbol{H}_L^N$ 称为是一个**繁殖算子**(重组算子),如果对任意种群 $\vec{X} \in \boldsymbol{H}_L^M$,它满足

$$P\{E(\vec{X}) \cap B_e(\vec{X}) \neq \varnothing\} > 0. \tag{1.54}$$

上述定义是说,一个繁殖算子是这样一个操作,它作用在当前种群 $\vec{X}$ 上生成新的种群 $E(\vec{X})$,而新种群 $E(\vec{X})$ 中可能有比旧种群 $\vec{X}$ 中更满意的个体(否则产生退化).(1.54)刻画的是 E 作为繁殖算子的最基本要求,而对于保证 SEA 的收敛性而言,这一要求未必总是足够的.下述定义 1.11 和定义 1.12 进一步给出两类具有特别特征的繁殖算子.

1.2.5.1　变异算子

定义 1.11（变异算子）　一个随机映射 $M: \boldsymbol{H}_L^N \to \boldsymbol{H}_L^N$ 称为是一个**变异算子**(mutation operator),如果对任何种群 $\vec{X} \in \boldsymbol{H}_L^N$,

$$P\{M(\vec{X}) \cap B^* \neq \varnothing\} > 0. \tag{1.55}$$

由于对任何满意集 $B \in \mathcal{F}$ 有 $B^* \subseteq B$,条件(1.55)蕴含

$$P\{M(\vec{X}) \cap B\} > 0, \quad \forall B \in \mathcal{F}. \tag{1.56}$$

这推出:变异算子是繁殖算子.而注意到,条件(1.56)等价于下列两个条件:

(P1): $P\{E(\vec{X}) \cap B = \varnothing / \vec{X} \cap B \neq \varnothing\} < 1$.

(P2): $P\{E(\vec{X} \cap B \neq \varnothing / \vec{X} \cap B = \varnothing\} > 0$.

性质(P1)是说,如果当前种群含有满意个体,则变异后的种群不应该不含满意个体;(P2)是说,如果当前种群不含满意个体,则变异后的种群一定有可能包含满意个体.显然(P1)同样蕴含(1.54),故变异算子是具有更好进化性质的繁殖算子.

变异算子的作用方式是:独立地分别作用于种群 $\vec{X}$ 上的每一个个体 X_i,以某种概率方式生成变异后的个体 $M(X_i)$,从而

$$M(\vec{X}) = (M(X_1), M(X_2), \cdots, M(X_n)).$$

例 1.18(点变异) 设 $X = a_1 a_2 \cdots a_2 \in \boldsymbol{H}_L$ 是一个个体,Γ 为等位基因,$a_i \in \Gamma$.点变异是指以某一概率独立地改变 X 的各位基因取值的进化操作(生物上模拟基因突变).例如,对于二进制编码 $\Gamma = \{0, 1\}$,指定一个变异概率 $P_m > 0$,则 $M(X) = b_1 b_2 \cdots b_L \in \boldsymbol{H}_L$ 定义为

$$P\{b_i = a_i\} = 1 - P_m, \quad P\{b_i = 1 - a_i\} = P_m \tag{1.57}$$

(即改变的概率是 P_m,不改变的概率是 $1 - P_m$).所以,如定义 $Y = b_1 b_2 \cdots b_L \in \boldsymbol{H}_L$ 为任一个体,则

$$P\{M(X) = Y\} = (1 - P_m)^{L - d(X,Y)} P_m^{d(X,Y)}, \tag{1.58}$$

其中 $d(X, Y)$表示个体 X 与 Y 有不同基因的位数,也称为是它们之间的汉明距离.(1.57)推出:

$$P\{M(\vec{X}) \cap B^* \neq \varnothing\} = P\{\exists X^* \in B^* \text{ 使 } X^* \in M(\vec{X})\}$$
$$= \sum_{i=1}^{M} (1 - P_m)^{L - d(X_i, X^*)} P_m^{d(X_i, X^*)} > 0,$$

所以,由(1.57)所定义的变换是一个变异算子.

下述有关点变异算子的性质在以后讨论中将经常用到:

定理 1.2 设 M 是点变异算子,$\vec{X}, \vec{Y} \in \boldsymbol{H}_L^N$ 为 m 阶种群,则

$$P\{M(\vec{X}) = \vec{Y}\} = \prod_{i=1}^{N} (1 - P_m)^{L - d(X_i, Y_i)} P_m^{d(X_i, Y_i)}.$$

同样很容易证明下述例 1.19~例 1.21 所给出的变换均是变异算子.

例 1.19(均匀变异) **均匀变异**(uniform mutation)是这样一种变换,它分别用等位基因 Γ 内的均匀分布的随机数,以某一较小概率 P_m 来替代个体编码串各个基因座上的原有基因值.例如,当 $\Gamma = \{1, 2, \cdots, n\}$(例 1.7)时,对应于(1.57),变异 $M(X) = b_1 b_2 \cdots b_L$ 定义为

$$P\{b_i = a_i\} = 1 - P_m, \quad P\{b_i = j \neq a_i\} = P_m / n, \tag{1.59}$$

而当 $X = x_1 x_2 \cdots x_n$ 是实数编码(例 1.6)时,如 x_i 的定义域为 $[a_i, b_i]$,则均匀变异 M 对 X 的变异结果 $M(X) = Y_1 Y_2 \cdots Y_n$ 定义为

$$P\{Y_i = X_i\} = 1 - P_m, \quad P\{Y_i = \xi_i \neq X_i\} = P_m / (b_i - a_i), \tag{1.60}$$

上式中 $\xi_i \in [a_i, b_i]$. 注意到,这样的 ξ_i 可表示作

$$\xi_i = a_i + \alpha(b_i - a_i), \quad \alpha \in (0,1),$$

从而实编码情形的均匀变异也常称作是凸组合变异.

例 1.20(正态变异) **正态变异**用于实数编码,是用服从正态分布的随机数 $N(X_i, \sigma)$代替原基因 X_i 的变换. 例如,正像演化策略(ES)中所使用的那样,取

$$Y_i = X_i + N(0, \sigma), \tag{1.61}$$

正态变异通常被用作局部搜索(σ 较小时),其作用与均匀变异有显著不同(均匀变异的作用使在搜索空间中自由移动,从而增加种群多样性).

例 1.21(非一致变异) **非一致变异**(non uniform mutation)也是一种强化局部搜索,而且强调作用随演化过程调整的变异操作([69]). 设 $X(t) = X_1 X_2 \cdots X_N$ 是 SEA 在 t 代所产生的一个个体,$X_i \in [a_i, b_i]$,则非一致变异作用于 $X(t)$所产生的变异个体 $Y(t) = MX(t) = Y_1 Y_2 \cdots Y_N$ 定义为

$$Y_i = \begin{cases} X_i + \Delta(t, b_i - X_i), & \text{如果 random}(0,1) = 0, \\ X_i - \Delta(t, X_i - a_i), & \text{如果 random}(0,1) = 1, \end{cases} \tag{1.62}$$

式中 random(0,1)是(0,1)之内的随机数,$\Delta(t, y) \in [0, y]$ 是服从均匀分布的一个随机数,要求随着进化代数 t 的增加,$\Delta(t, y)$单调减且趋于0. 例如,$\Delta(t, y)$可按下式定义

$$\Delta(t, y) = y \cdot (1 - r^{(1-t/T)^b}), \tag{1.63}$$

其中 r 为[0,1]内符合均匀分布的一个随机数,T 是最大进化代数,b 是一个可调参数,它决定了随机扰动对进化代数 t 的依赖程度.

上述非一致变异的作用是使得 SEA 在运行的初始阶段(t 较小)进行均匀随机搜索,而在其后期(t 接近于 T 时)进行局部搜索.

1.2.5.2 交叉算子

在生物的自然进化过程中,两个同源染色体通过交配重组,形成新的染色体,从而产生出新的个体或物种. 模拟这种交配重组过程的进化操作即是交叉算子.

交叉算子的基本操作是从一对母体(A, B)生成一个或多个新的个体 $C(A, B)$(为表述方便,我们以下假定 $C(A, B)$只包含一个个体). 所以交叉算子 C 作用于种群 $\vec{X} = (X_1, X_2, \cdots, X_M) \in \boldsymbol{H}_l^M$ 的方式是:首先以某种特定方式对种群 $\vec{X}$ 中的个体进行配对(此步骤可在选择过程中自然实现),例如配对结果为

$$\vec{X} = \{(X_i, X_j) \mid i, j = 1, 2, \cdots, M/2, X_i, X_j \in \vec{X}\},$$

然后对任一母体对(X_i, X_j)独立重复地实施交叉基本操作生成子代个体

$C(X_i, X_j)$，于是对 $\vec{X}$ 实施交叉所生成的子代种群为

$$C(\vec{X}) = (C(X_i, X_j) : i, j = 1, 2, \cdots, M/2).$$

以下，假设 $\boldsymbol{U}$ 为齐次种群的全体，即 $\vec{X} \in \boldsymbol{U}$ 仅由一个个体(称为 $\vec{X}$ 的生成个体)重复组成. 如果齐次种群 $\vec{X}$ 由个体 X 所生成，我们表示 $\vec{X} = [X]$. 另外，我们用

$$n(\vec{X}) = |\vec{X} \cap B^*| \tag{1.64}$$

表示种群 $\vec{X}$ 中包含(1.5)全局最优个体的数目.

定义 1.12（交叉算子） 设 $M = 2N$. 一个随机映射 $C: \boldsymbol{H}_L^M \to \boldsymbol{H}_L^N$ 称为是一个**交叉算子**，如果它满足

(1) 对任何最优种群 $\vec{X}^*$（即 $n(\vec{X}^*) = M$）有

$$P\{n(C(\vec{X}^*)) = N\} > 0. \tag{1.65}$$

(2) 对任何齐次种群 $[X] \in \boldsymbol{U}$ 有

$$P\{C([X]) = [X]\} = 1. \tag{1.66}$$

例 1.22（单点交叉） **单点交叉**(one-point crossover)的基本操作是：等概率地随机指定一个基因位置作为交叉点，再把母体对中两个个体从交叉点分前后两个部分，以某个确定概率 $P_c > 0$ 交换两个个体的后半部分，得到两个新个体，取第一个个体为杂交结果. 例如，取 $P_c = 1$，交叉点为 K（$K = 0, 1, \cdots, L-1$），则对母体 (A, B) 实施杂交操作过程如下所示：

$$\begin{aligned} A &= a_1 a_2 \cdots a_K \quad a_{K+1} \cdots \quad a_L \\ B &= b_1 b_2 \cdots b_K \quad b_{K+1} \cdots \quad b_L \\ \hline C(A, B) &= a_1 a_2 \cdots a_K \quad b_{K+1} \cdots \quad b_L \end{aligned}$$

对于如上所定义的单点交叉，容易验证有如下性质：

定理 1.3 设 $(A, B) \in \boldsymbol{H}_L^2$ 为一对母体，$Y \in \boldsymbol{H}_L$ 为任一个体，则

$$P\{C(A, B) = Y\} = \begin{cases} \dfrac{kP_c}{L}, & \text{如果 } Y \neq A, \\ (1 - P_c) + \dfrac{kP_c}{L}, & \text{如果 } Y = A, \end{cases}$$

其中 $k = k(A, B, Y)$ 为用单点交叉 (A, B)（以概率 1）可以生成 Y 的交叉点个数（$k = 0, 1, 2, \cdots, L-1$）.

证明 先假设 $Y \neq A$. 由于交叉点可以在 $0, 1, 2, \cdots, L-1$ 中任选且机会均等，而每种交叉点的选择通过单点交叉可能是 Y，也可能不是 Y. 由于 k 表示的交叉点通过交叉后可生成 Y，于是 $P\{C(A, B) = Y\} = kP_c/L$.

当 $Y = A$ 时，A 与 B 不交叉自然生成 $Y = A$，此种情形发生的概率是 $(1 - P_c)$，所以依概率加法公式有

$$P\{C(A,B)=Y\}=(1-P_c)+kP_c/L.$$

根据上述定理,我们看到:对任何最优种群 $\dot{X}^*$ 有

$$P\{h(C(\vec{X}^*))=M\}\geqslant P\{C(\dot{X}^*)=[x_1^*]\}$$

$$\geqslant[(1-P_c)+kP_c/L]^N\geqslant[1-\frac{(L-1)P_c}{L}]^N>0,$$

而且自然满足 $P\{C([X])=[X]\}=1$. 所以单点交叉变换是交叉算子.

另外,由定理 1.3 知

$$P\{C(\vec{X})\cap Be(\vec{X})\neq\varnothing\}\geqslant P\{X_1\in C(\dot{X})\}$$

$$\geqslant P\{C(X_1,X_j)=X_1,j=2,\cdots,M\}\geqslant(1-P_c)+P_c/L>0,$$

这里 X_1 假定是 $\vec{X}$ 中的最优个体(从而 $X_1\in B(\vec{X})$). 于是,依定义 1.8,单点交叉算子也是繁殖算子.

对应于单点交叉算子,自然可定义多点交叉与均匀交叉算子.

例 1.23(多点交叉) **多点交叉**(multi-point crossover)的基本操作是:首先在母体对的基因串中随机设置多个交叉点,然后依一定概率在交叉点所分隔的基因段中进行段交换. 例如,两点杂交是将母体的基因串分成三部分,交换中间部分,即为杂交结果.

例 1.24(均匀交叉) **均匀交叉**(uniform crossover)是指对母体对的每一基因座上的基因都以相同的交叉概率 P_c 进行交换,从而形成新个体的操作. 容易验证均匀交叉用于母体 (A,B) 生成个体 Y 的概率是

$$P\{C(A,B)=Y\}=\prod_{j=1}^{L}[(1-P_c)(Y_j\oplus a_j)+P_c(Y_j\oplus b_j)], \tag{1.67}$$

这里 $A=a_1a_2\cdots a_L$, $B=b_1b_2\cdots b_L$, $Y=Y_1Y_2\cdots Y_L$, $\oplus$ 为"异或"运算.

例 1.25(算术交叉) **算术交叉**(arithmetic crossover)是指由两个个体的某种线性组合生成新个体的繁殖操作,它一般用于实数编码. 常见的,例如,可设

$$C(X_1,X_2)=\mu X_1+(1-\mu)X_2,$$

$\mu\in[0,1]$ 取为随机数时,称为凸组合交叉,而取

$$\mu=\begin{cases}\xi>1, & \text{当 } F(X_1)\geqslant F(X_2),\\ \xi<0, & \text{当 } F(X_1)<F(X_2)\end{cases}$$

时,称为线性交叉.

广义地说,一个交叉算子的基本操作 $C(A,B)$ 是个体 A 与 B 任何形式的重组(只要满足(1.65)~(1.66). 这样的重组(包括变异方式)可以是非常任意的,也可以是高度非线性的. 如何根据实际问题构造有效的重组(换句话说,

设计交叉算子与变异算子)是 SEC 的基本问题,它本质上决定了 SEC 的可应用性与有效性.

1.2.6 进化参数(Σ)

SEA 的运行依赖各种各样的参数.这些参数主要包括编码长度 L,种群规模 N,交叉概率 P_c,变异概率 P_m,终止进化代数 T,以及各种选择算子与繁殖算子所涉及的可调参数等.这些参数对于 SEA 的运行性能有重要影响,需认真选取.

(1)**编码长度** L.使用二进制编码时,L 通常由对问题的求解精度 ε 决定,但当使用可拼接/可分解编码时,预先设定的精度可通过一系列低精度的编码实现(例如可设 $\varepsilon = K\varepsilon_1$,而逐次依 ε_1 设置编码长度);使用实数编码时,$L = n$ 与问题的自变量维数相等;使用符号编码时,L 由对问题的编码方式来确定;另外,也可使用变长度的编码来表示个体.

(2)**种群规模** N.种群规模 N 表示每一代种群中所含个体数目.当 N 取值较小时,可提高 SEA 运算速度,但却降低种群的多样性,容易引起 SEA 早熟(即出现假收敛);而当 N 取值较大时,又会使得 SEA 效率降低.一般建议的取值范围是 20~100.

(3)**交叉概率** P_c.在 ES 和 EP 中,P_c 通常取为 0,即不采用交叉运算;在 GA 中交叉则被认为是主要搜索算子,因而一般取较大值.一般说,较大的 P_c 容易破坏群体中已形成的优良模式,使搜索具太大随机性,而较小的 P_c 使发现新个体(特别是优良新个体)的速度太慢.一般建议的取值范围是 0.4~0.99.一般,比较理想的方式是非一致地使用交叉概率:在 SEA 的前期使用较大的 P_c,或者随着 SEA 在线性能的提高而逐渐增大 P_c 的取值.

(4)**变异概率** P_m.较大的变异概率 P_m 使 SEA 在整个搜索空间中大步跳跃,而小的变异概率使 SEA 聚焦于特别区域作局部搜索.一般在不使用杂交算子的情形,P_m 取较大值(0.4~1);而在与交叉算子联合使用的情形,P_m 通常取较小值(0.0001~0.5).当变异算子用作核心搜索算子时,比较理想的是自适应设置变异概率,以实现 SEA 从"整体搜索"慢慢过渡到"局部搜索".例如说,当使用可拼接/可分解编码时,SEA 的变异概率可自适应地设置为[63]

$$P_m(l,t) = K\left\{\frac{t}{\beta T}\right\}^{\alpha_{\lfloor \frac{l}{n} \rfloor}}, \tag{1.68}$$

这里 $l \in \{1,2,\cdots,L\}$ 表示基因位,t 是进化代数,T 是终止代数(最大允许进化代数),$\{\alpha_i\}$ 是单调增的一给定数列,$\beta \in (0,1)\left\{\text{如 } \beta = \frac{1}{2}, \frac{1}{3}\right\}$,$\lfloor x \rfloor$ 为不大于 x 的最大整数,K 为平衡因子以使 $P_m(l,t) \in [0,1]$.这个设置是依据可拼接/可分解编码所赋于基因位的几何意义(前面组基因负责整体定位,后面组

基因负责局部定位),让整个进化的前 β 部分(即前 βT 步),变异概率随基因位成反比,而在进化的后($1-\beta$)部分,变异概率与基因位成正比,以此实现 SEA 从"整体搜索"到"局部搜索"的自适应过渡.实践说明,此种变异概率的自适应设置策略有很好的搜索效果[63].

(5)**终止进化代数** T.SEC 不同于传统优化算法,它很难有明确的搜索终止准则(特别对于非数值优化问题).于是通常需指定一个终止进化代数来终止算法.一般说,事先指定 T 通常只能找到问题(1.1)的在给定时限内所能寻求的相对满意解(通常设 $T\in[100,1000]$),但不一定是问题的最优解或较高精度的近似解.为了获得较高精度解,通常可依据种群适应度的稳定情况来适时调整 T 的设置.

到目前为止,对于 SEA 进化参数的设置还没有成熟的原则和方法,基本上依赖经验和对所求解问题的了解.

§1.3 模拟进化计算的典型执行技巧

上节所描述的模拟进化算法 SEA(e,J,S,E,Σ) 为我们提供了借喻生物进化与遗传变异机制求解问题的一个一般性框架,但要有效应用,特别是针对各种不同的应用目的而做到"有的放矢",则需要有一定技巧.本节以遗传算法为例,介绍若干典型的模拟进化计算执行技巧.

如不特别指出,本节以下假定所讨论的 SEA 为遗传算法而且算法使用交叉与变异复合的繁殖算子.

1.3.1 杰出者记录与"父子混合"选择策略

应用遗传算法的目的在于寻求优化问题(1.1)的全局最优解.为了达到这一目的,我们需要非常巧妙地设计选择与繁殖算子,以使相应遗传算法能尽可能快地收敛到所希望的全局最优解.然而,设计这样理想的选择与繁殖算子通常是极其困难的,于是人们常常代之以构造简单的选择与繁殖算子以使算法具有一定意义下的"遍历"性质,换句话说,算法有能力达到 $\boldsymbol{H}_L$ 中的每一个状态.对于这样具有遍历性质的遗传算法,只要对其搜索过程中所发现的最佳个体作适时"记录",则全局最优个体总能被找到.在遗传算法中耦合这种最佳个体记录的策略,被称之为**杰出者记录策略**(elitist stratagy).

假定 $\{\vec{X}(t)\}$ 是遗传算法 GA(e,J,S,E,Σ) 所生成的种群序列,则带杰出者记录策略的执行方案如下:

(1)随机生成初始种群 $\vec{X}(0)$,记 $\vec{X}(0)$ 中具最高适应值的个体为 $X^*(0)$(如有多个取其中之一),置 $t\leftarrow 0$.

(2)依据 GA(e, J, S, E, Σ)从 $\vec{X}(t)$生成 $\vec{X}(t+1)$,记 $\vec{X}(t+1)$中具最高适应值的个体为 $A(t+1)$.令

$$X^*(t+1) = \max\{X^*(t), A(t+1)\}. \tag{1.69}$$

(3)如果事先设定的终止准则满足,则输出 $X^*(t+1)$作为(1.1)的近似解,否则置 $t \leftarrow t+1$,转(2).

值得注意的是,杰出者记录策略(1.69)与杰出者选择是完全不同的概念,前者是一个独立于 GA 进化进程的、纯粹的记录策略,不要求所记录的最佳个体以概率 1 作为下一代种群中的个体,而后者则是一种进化机制,要求上一代的最佳个体必须无条件的被遗传到下一代.为了比较,我们列出杰出者选择遗传算法如下.

杰出者选择遗传算法(elitist selection GA):

步1(*初始化*) 置 $t \leftarrow 0$,随机产生初始种群

$$\vec{X}(0) = (X_1(0), X_2(0), \cdots, X_N(0)) \in \boldsymbol{I}_L^N.$$

步2(*种群进化*)

2.1 独立地从当前种群 $\vec{X}(t)$中选择出$(N-1)$对母体.

2.2 独立地对所选$(N-1)$对母体执行交叉运算,获得$(N-1)$个中间个体.

2.3 独立地对交叉后所产生的$(N-1)$个中间个体执行变异得到 $t+1$ 代种群的前$(N-1)$个个体

$$X_1(t+1), X_2(t+1), \cdots, X_{N-1}(t+1).$$

2.4 在 $\vec{X}(t)$中选择出一个最优个体 $X^*(t)$,并令 $t+1$ 代种群的第 N 个个体

$$X_N(t+1) = X^*(t).$$

步3(*终止检验*) 如果终止准则满足,则输出 $X^*(t+1)$作为问题(1.1)的近似解,否则,置 $t \leftarrow t+1$,转步 2.

另外,也值得注意,杰出者记录策略(1.69)表面上看是从父代与子代的混合种群中选择出的最佳个体,但实质上,它记录的是到目前为止,GA 所发现的最佳个体,因而适应值序列$\{J(X^*(t))\}$必然具有单调性.

除采用杰出者记录策略外,保证 GA 收敛性的另一常用策略是在进化过程中采用"父子混合"选择(参见定理 1.19).这种 GA 执行方案如下:

父子混合选择遗传算法(father-offspring combined selection GA):

步 1(*初始化*) 随机产生 M 对母体组成初始种群$\vec{X}(0)$,置 $t \leftarrow 0$.

步 2(*种群进化*)

2.1 独立地对 $\vec{X}(t)$中的 M 对母体执行交叉,生成中间种群 $\vec{Y}(t)$(由 M 个中间个体组成).

2.2 独立地对 $\vec{Y}(t)$ 中的每一个中间个体执行变异,生成子代种群 $\dot{Z}(t)$.

2.3 在父代种群 $\vec{X}(t)$ 与子代种群 $\dot{Z}(t)$ 的并 $\vec{X}(t)\cup\dot{Z}(t)$ 中选择 M 对母体作为新一代母体种群 $\vec{X}(t+1)$.

步 3(终止检验) 如果终止准则满足,停机并输出 $\vec{X}(t+1)$ 中的最佳个体作为(1.1)的近似解,否则置 $t\leftarrow t+1$ 并转步 2.

我们将在§1.5 中证明:带杰出者记录策略的遗传算法、杰出者选择遗传算法与父子混合选择遗传算法都是遗传算法保证收敛的执行策略。

1.3.2 适应值共享策略

适应值共享(fitness sharing)**策略**是模拟生物在小生境(niche)环境下进化,并能同时生成问题(1.1)多个最优解的计算策略,它常能有效应用于求解多目标(multiobjective)与多态(multimodal)优化问题。

在生物学中,小生境是指特定环境下的一种小环境.生物在其进化过程中,一般总是与自己同种的生物生活在一起,而且常常限定在某一特定地理区域(如热带鱼、大熊猫、袋鼠、北极熊等等).这种小生境使得不同物种、或同一物种下的不同群体具有不同的智能水平,但限定在小生境下,也都具有各自的优秀者.这种情形相当于说,在遗传算法的操作中,一个种群应该是由具有明显差异的若干个子种群组成,而运算结束,也应该能够输出多个、而不是一个有显著差异的近似解.

这种期望也来自求解多目标与多态优化问题的需要.我们知道,一个多目标优化问题可以描述作

$$\begin{aligned} &\text{V-min } F(X)=(f_1(X),f_2(X),\cdots,f_p(X))^{\mathrm{T}},\\ &\text{s.t.}\quad X\in\Omega\subseteq\boldsymbol{R}^N, \end{aligned}\tag{1.70}$$

这里 V-min 代表向量极小化,即需要寻求这样的最优解 X^*,它使得每一个目标 $f_k(1\leqslant k\leqslant p)$ 在 Ω 上取极小.这样的最优解在大多数情况下是不存在的,因为多目标问题的本质特征是:各个目标之间可以相互冲突,因而一个子目标的改善可能会引起另一个子目标性能的降低.于是,对于多目标优化问题,人们常常代之以寻找所谓的 Pareto 解,或非占优解(nondominated solution)(一个决策变量 $\tilde{X}$ 称为是问题(1.70)的 Pareto 解,是指不存在各个目标上都比 $\tilde{X}$ 更优的决策 X).一个多目标优化问题的 Pareto 解通常由一个集合组成,例如如图 1.7 所示.由于 Pareto 解之间不存在优劣之分,是不可比较的,故在应用中,通常需要找出问题的多个 Pareto 解(最好它们能在 Pareto 解集中均匀分布),以让决策者能依对所考虑问题的性质与个人偏好去作进一步综合与选择.另外,对于多态优化问题,目标函数存在大量局部与全局最优状态,这些状

态常常都有特定重要性(例如 NDA 计算与大分子计算),人们希望通过一个算法能同时找到这样的多个局部或全局最优状态.

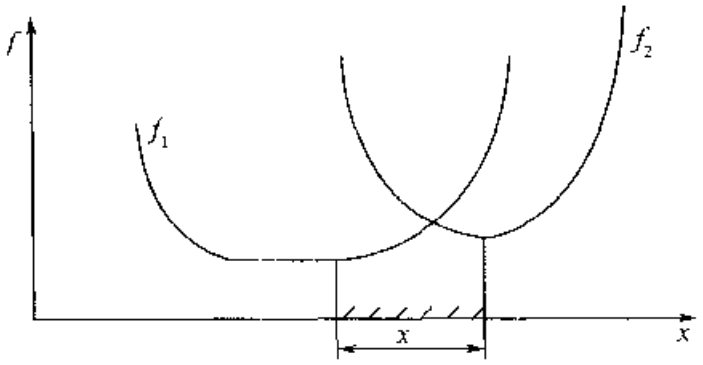


图 1.7 多目标优化问题的 Pareto 解集

适应值共享策略正是实现上述目的一个遗传算法执行策略,它由 Goldberg 和 Richardson(1987)首先提出,后经由众多学者完善与发展([19],[16],[26],[39],[43],[66],[70]).这一策略的基本思想是:在种群相似个体之间将适应性作为共享资源,利用个体在种群中相似个体的数目与相似程度重新调整其适应度,以达到既在相似个体中形成小生境进化环境,又在整体进化中逐渐压制相似个体的繁殖数目,以保持种群多样性的目的.具体作法是:

(1)引进一个所谓的**共享函数**(sharing function)$\mathrm{Sh}(d_{XY})$来度量种群中个体 X 与个体 Y 之间的相似程度.例如说,取 d_{XY} 为个体 X 与 Y 之间的某种距离(如二进制编码时取为汉明距离,实值编码时取为欧氏距离),而 $\mathrm{Sh}(d)$ 取为满足

(i) $0\leqslant \mathrm{Sh}(d)\leqslant 1$

(ii) $\mathrm{Sh}(0)=1$

(iii) $\lim\limits_{d\to\infty}\mathrm{Sh}(d)=0$

的任一单调递减函数,特别例如取

$$\mathrm{Sh}(d)=\begin{cases}1-\left(\dfrac{d}{\sigma}\right)^{\alpha}, & d\leqslant\sigma,\\ 0, & d>\sigma,\end{cases}\tag{1.71}$$

这里 α 是调节 sharing 函数性状的参数,σ 是调节小生境范围的参数.显然,当两个个体比较相似时,它们的共享函数值就较大;反之,当不太相似时,其共享函数值就较小(特别地,当共享函数取为(1.71)时,凡其距离超过 σ 的个体均被认为不相似,因而其共享函数取值为 0).

(2)对种群中的每一个体 X 赋以**共享度**(sharing degree)$m(X)$,它定义为个体 X 与群体内其他各个个体之间的共享函数值之和:

$$m(X) = \sum_{Y \in \vec{X}} \mathrm{Sh}(d_{XY}), \tag{1.72}$$

$m(X)$刻画在个体 X 附近存在多少种、多大程序上相似的个体，因而常称之为**小生境数**(niche count).

(3)利用小生境数调整种群中各个体的适应度。调整原则是：使小生境数较小(即与其相似个体较少)的个体能有更多机会被选中繁殖到下一代，而对小生境数相差不大的个体基本保持原有的竞争环境(即小生境环境)。调整方法例如是：

$$J'(X_i) = \frac{J(X_i)}{m(X_i)}, \quad i = 1, 2, \cdots, N, \tag{1.73}$$

这里 J 是原有适应度度量，而 J' 是调整后的适应度度量.

(4)依据调整后的适应度实施选择与繁殖操作.

耦合上述适应值共享策略的遗传算法执行步骤如下：

带适应值共享策略的遗传算法(sharing GA)：

步 1 (*初始化*) 随机生成初始种群 $\vec{X}(0)$，设定初始适应度度量 J_0，并计算 $X(0)$中每一个体的适应度；置 $t \leftarrow 0$.

步 2 (*种群进化*)

2.1 运用任何遗传算法 $\mathrm{GA}(e, J_t, S, E, \Sigma)$从父代种群 $\vec{X}(t)$产生子代种群 $\vec{X}(t+1)$.

2.2 计算 $\vec{X}(t+1)$中每一个体的共享度，并按(1.73)对其每一个体的适应度重新赋值，令

$$J_{t+1}(X) = J_t(X)/m(X).$$

步 3 (*终止检验*) 如果终止准则满足，停机并输出 $\vec{X}(t+1)$中各个体作为近似解集，否则，令 $t \leftarrow t+1$ 并转步 2.

适应值共享策略已成功地应用到各类多目标优化与多态优化问题的求解，有兴趣的读者可参见文献[19]，[20]，[38]，[39]，[66]，[70].

1.3.3 并行实现策略

遗传算法是以个体的集合——种群为运算对象的，而且对个体所进行的各种进化操作都有一定的独立性，因而它具有天然的并行结构，利用这种并行结构并在各种并行计算机或局域网上实现构成遗传算法有效执行的又一重要策略.

尽管实现遗传算法的并行化有多种可能，但最基本的当属基于群体分组和基于搜索空间分解的并行实现策略.

1.3.3.1 基于群体分组的并行策略

这种策略企图模拟生物进化中的共生(coevolution)现象：不同的物种在相互利用，相互竞争的过程中共同进化.按照生物学的观点，生物个体基因型的适应度是由生物种群密度、本身基因组成与该物种所处的环境所决定的.处于共生的物种其基因会随着生物种改变，而且相互竞争的物种将导致各物种相互适应性的增强，产生生物意义上的"军备竞赛".模拟这种生物进化共生现象，我们可以把遗传算法中的种群看作是由若干个物种(子种群)的共生，各个物种的进化让其独立地在不同的处理器上实现，然后在适当时候再以适当的方式交换信息，以相互促进，共同进化.

依这种共生方式实现遗传算法并行化需特别考虑以下两个方面的问题：

第一，子种群的划分方式，亦即如何将种群中的 N 个个体适当分组以构成不同的物种或子种群的问题.虽然，这种划分是可以任意的，但为了简单，人们习惯于将 N 个个体均分到所给定的 P 个子处理机上.于是，每一子种群的规模为

$$\mu = N/P. \tag{1.74}$$

若 $\mu = 1$，则每个处理机上只处理一个个体，这种最细的划分方式称为**细粒度**(fine-grained)**分配**；若 $\mu > 1$，则每个处理机处理多于一个的个体，这种分配方式称为**粗粒度**(coarse-grained)**分配**.

第二，各子种群间的信息交换问题.这又可细分为以下四个子问题：

(1)信息交换的对象问题，即哪几个处理机之间应该交换信息？显然有多种选择：可以是随机确定几个处理机之间进行信息交换(island 模型)，也可以是在物理上相互邻近的几个处理机上相互交换(stepping-stone model)，还可以是全部处理机间都相互交换信息.

(2)交换信息的内容.可以是交换随机选定的几个个体(即随机交换方式)，也可以是从较好的几个个体中任选一个进行交换，还可以是交换子种群中最好的个体(择优交换方式).

(3)交换的时间与频率，即何时、如何经常交换的问题.可以是以同步或异步的方式在每一代进化过程中都进行信息交换，也可以是在指定的时间间隔或进化代数间隔进行信息交换，或者是在子种群达到稳定态后进行信息交换.

(4)交换的信息量.可以是只交换一个个体，也可以交换多个个体.

根据对上述两个方面共 5 个问题的不同选择，可构成不同类型共生型并行遗传算法的执行方案.另外，考虑到各处理机亦可采用不同型的基本遗传算法，我们可形式化地把一个共生型并行遗传算法(coevolution type parallel GAs，简称 Co-PGA)描述作一个 6 元组：

$$\text{Co-PGA} = (\text{DMM}, I, Z, \Lambda, \Theta, \text{SGA}), \tag{1.75}$$

其中

DMM——实现并行遗传算法的并行机或局域网中各处理器 P_i 所组成的集合，即 DMM $=\{P_i \mid i=1,2,\cdots,P\}$；

I——各处理器信息交换对象所组成的集合．若与处理器 P_i 可以相互交换信息的处理器的集合为 $I^{(i)}$ 的话，则

$$I=\bigcup_{i=1}^{P} I^{(i)};$$

Z——信息交换的内容；

Δ——进行信息交换的时间间隔或频率；

Θ——信息交换时的个体替换操作算子；

SGA——各处理机上运行的基本遗传算法．

Co-PGA 的运算过程是：各个处理机运行各自的基本遗传算法 SGA，对它自身所带的存贮器中的 μ 个个体进行遗传进化操作；当达到一个预先指定的信息交换时间 T 时，每个处理机 P_i 发送需要交换的信息 Z 到其信息交换对象 $I^{(i)}$；同时，它也接受来自于 $I^{(i)}$ 的信息，用该信息来替换本处理器上的某一个或某一些个体．上述过程不断地迭代进行，直到满足某个终止条件为止．

若将第 i 个处理机 P_i 所产生的第 t 代子种群记为 $\vec{P}_i(t)$，P_i 所发出的信息记为 Z_i，且当 P_i 收到其他处理机所传递的信息 Z 后，P_i 以方式 $\Theta(\vec{P}_i(t), Z)$ 来替代 $\vec{P}_i(t)$ 中的某些个体而生成新子种群 $P_i(t+1)$，则运行在处理机 P_i 上的 Co-PGA 可描述如下：

共生并行遗传算法(Co-PGA)：

步 1（初始化） 随机生成初始种群 $\vec{P}_i(0)\in \boldsymbol{H}_i^{\mu}$，输入 $I^{(i)}$，Z_i，Δ，并置 $t\leftarrow 0$．

步 2（种群进化） 如果 $t \bmod(\Delta)=0$（即 t 是 Δ 的倍数），则转步 3，否则运用 SGA 由当前种群 $\vec{P}_i(t)$ 生成新一代种群 $\vec{P}_i(t+1)$，转步 4．

步 3（信息交换） 执行如下操作：

3.1 发送信息 Z_i 到处理机 P_j，$j\in I^{(i)}$．

3.2 从每一个 P_j，$j\in I^{(i)}$，中收取信息．

3.3 利用所收取的信息 $Z=\bigcup_{j\in I^{(i)}} Z_j$ 生成新一代种群 $\vec{P}_i(t+1)$，即

$$\vec{P}_i(t+1)=\Theta(\vec{P}_i(t), \bigcup_{j\in I^{(i)}} Z_j).$$

步 4（终止检验） 如果终止条件满足，停机并输出 $\vec{P}_i(t+1)$ 中的最佳个体或全体作为近似解之一；否则置 $t\leftarrow t+1$ 并转步 2．

共生并行遗传算法已有效地应用于广泛组合优化问题的求解，并已显示出有很高的效率加速能力．

1.3.3.2 基于搜索空间分解的并行策略

基于群体分组或共生进化的并行策略可认为是从个体表现型的层次上对遗传算法的并行实现，而基于搜索空间分解的并行策略则是从个体基因型层次上对遗传算法实现并行.

假定将个体空间 $\boldsymbol{H}_L$ 分解为 P 个子空间的拼接：

$$\boldsymbol{H}_L = \boldsymbol{H}_{L_1} \vee \boldsymbol{H}_{L_2} \vee \cdots \vee \boldsymbol{H}_{L_P}. \tag{1.76}$$

不失一般性，设 $L_1 = L_2 = \cdots = L_P = L/P = \mu$（这里 μ 仍称为划分粒度），则每一个体 $X = X_1X_2\cdots X_L \in \boldsymbol{H}_L$ 自然地分解为

$$\begin{aligned} X &= X_1X_2\cdots X_\mu \mid X_{\mu+1}X_{\mu+2}\cdots X_{2\mu} \mid \cdots \mid X_{(P-1)\mu+1}X_{(P-1)\mu+2}\cdots X_L \\ &= X^{(1)} \vee X^{(2)} \vee \cdots \vee X^{(P)}, \end{aligned} \tag{1.77}$$

其中 $X^{(i)} \in \boldsymbol{H}_\mu$. 对于种群 $\vec{X} = (X_1, X_2, \cdots, X_N) \in \boldsymbol{H}_L^N$，我们相应定义子种群

$$\vec{X}_j = (X_1^{(j)}, X_2^{(j)}, \cdots, X_N^{(j)}), \quad j = 1, 2, \cdots, P,$$

则 $\vec{X}$ 在(1.77)意义下可分解为

$$\vec{X} = \vec{X}^{(1)} \vee \vec{X}^{(2)} \vee \cdots \vee \vec{X}^{(P)}. \tag{1.78}$$

基于搜索空间分解的并行遗传算法(space decomposition based parallel GA，简称 Sp-PGA)其基本作法是：对每一个子种群 $\vec{X}^{(j)}$ 指定一个处理机独立地执行基本遗传操作 SGA，然后类似于 Co-PGA 定期作信息交换，以推动各子种群的共同进化.

不同于 Co-PGA，构造 Sp-PGA 必须考虑如何对子种群中的个体给出适应度估值的问题，这是因为，对于子种群 $\vec{X}^{(j)}$ 而言，其中的个体 $X_i^{(j)}$ 只是代表某个个体的部分基因，故无法对其适应度作出直接估值. 常用的指定 $X_i^{(j)}$ 的适应度方案包括：

(1)在缺省的部分随机取值. 换句话说，第 i 个处理机 P_i 上使用如下定义的适应度度量

$$J_i(X_i^{(j)}) = J(\xi^{(1)} \vee \cdots \vee \xi^{(j-1)} \vee X_i^{(j)} \vee \xi^{(j+1)} \vee \cdots \vee \xi^{(p)}), \tag{1.79}$$

这里 $\xi^{(k)}$ 为第 k 个处理机所生成的当前子种群 $\vec{X}^{(k)}$ 中的任一个体(随机选取)，J 为预先给定的适应度度量.

(2)缺省值取当前最优个体，即处理机 P_i 上使用的适应度度量定义为

$$J_i(X_i^{(j)}) = J(\bar{X}^{(1)} \vee \cdots \vee \bar{X}^{(j-1)} \vee X_i^{(j)} \vee \bar{X}^{(j+1)} \vee \cdots \vee \bar{X}^{(p)}), \tag{1.80}$$

这里 $\bar{X}^{(k)}(k \neq j)$ 是处理机 P 所生成当前子种群 $\vec{X}^{(k)}$ 的最佳个体(或杰出者个体).

(3)混合取值,即代替(1.80),定义

$$J_i(X_i^{(j)}) = J(X^{(1)} \vee \cdots \vee X^{(j-1)} \vee X_i^{(j)} \vee \xi^{(j+1)} \vee \cdots \vee \xi^{(p)}), \tag{1.81}$$

这里 $X^{(k)}$ 与 $\xi^{(k)}$ 如同(1.80)和(1.79)定义.

当使用可拼接/可分解编码格式(例 1.5)时,由于其基因位所具有的明确几何意义,我们可以采用直接截断后 $p\cdots j$ 段基因的方法对适应度估值,换句话说,对应于(1.81),可取

$$J_i(X_i^{(j)}) = J(\bar{X}^{(1)} \vee X^{(2)} \vee \cdots \vee X^{(j-1)} \vee X_i^{(j)}) \tag{1.82}$$

在这种编码格式下,如果进而划分粒度 $\mu = n$,则每一台处理机便赋予了非常清晰的搜索意义:第一台处理机 P_1 负责对最优解的 $\frac{1}{2}$ 精度定位(相当于确定东、南、西、北方位);第二台处理机 P_2 负责对最优解的 $\frac{1}{2^2}$ 精度定位,…,第 i 台处理机 P_i 负责对最优解的 $\frac{1}{2^i}$ 精度定位,如此等等.在这种解释下,Sp-PGA 的搜索原理可理解为:各处理机协同并行地、从整体定位到局部定位、由粗到细、步步细化地对(1.1)的最优解进行搜索.

值得指出的是,Co-PGA 可非常方便地利用"分而治之"(divide and conquer)的思想将一个大区域的搜索问题化归到若干小区域上的搜索,即化大区域到小区域(通过合适解码将子种群 $\dot{P}_i$ 限定在 Ω 的不同子区域,参见图 1.8);而 Sp-PGA 则可方便地实现用低维空间对高维空间的搜索(即化高维到低维.无论是化大区域到小区域,还是化高维到低维都是求解困难问题的重要技巧,由此可见遗传算法的并行实现为困难优化问题的求解提供了可行框架与途径.有兴趣的读者可进一步参见文献[26],[43],[91]和[100].

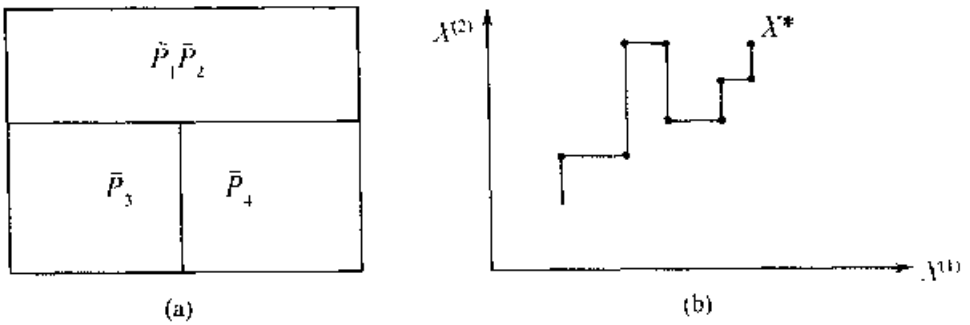


图 1.8 (a)Co-PGA 实验化大区域到小区域的搜索
(b)Sp-PGA 实现化高维空间到低维空间的搜索

1.3.4 混合策略

遗传算法由于其简单、通用、稳健等优良性能被应用到广泛领域.理论上可以证明(参见§1.5),遗传算法的许多执行策略能在概率意义上收敛到问题的全局最优解,故被广泛认为是一种稳健的全局搜索算法.但另一方面,应用实践表明,遗传算法通常收敛的速度并不快,而且局部寻优能力差,所产生的最优解一般精度不高.产生这些缺陷的主要原因之一是:它没用充分利用与问题相关的信息与领域知识.

我们知道,对于很多应用问题而言,存在许多专门针对该问题的知识型启发算法,这些专门算法虽然保证不了一定能找到问题的全局最优解,但通常计算效率比较高,而且有相当多的算法其局部寻优能力极强(例如神经网络算法、梯度下降法、列表寻优法等等).于是,一个自然的想法是:在遗传算法的搜索过程中溶合这些专门领域知识或快速局部搜索算法,以形成一种混合遗传算法(hybrid genetic algorithm,简称 Hybrid GA)执行策略.这无疑是提高遗传算法计算效率和求解质量的又一有效手段.

混合专门领域知识和局部搜索算法到遗传算法通常有以下途径:

第一,在编、解码过程、繁殖操作(交叉、变异)中溶合专门领域知识(或等价地说,在遗传算子的设计中溶入与问题相关的启发式信息).下述例 1.27 提供了这种混合方式的一个例子.

第二,在遗传算法的执行步骤中增加局部搜索步(通常紧跟变异操作),例

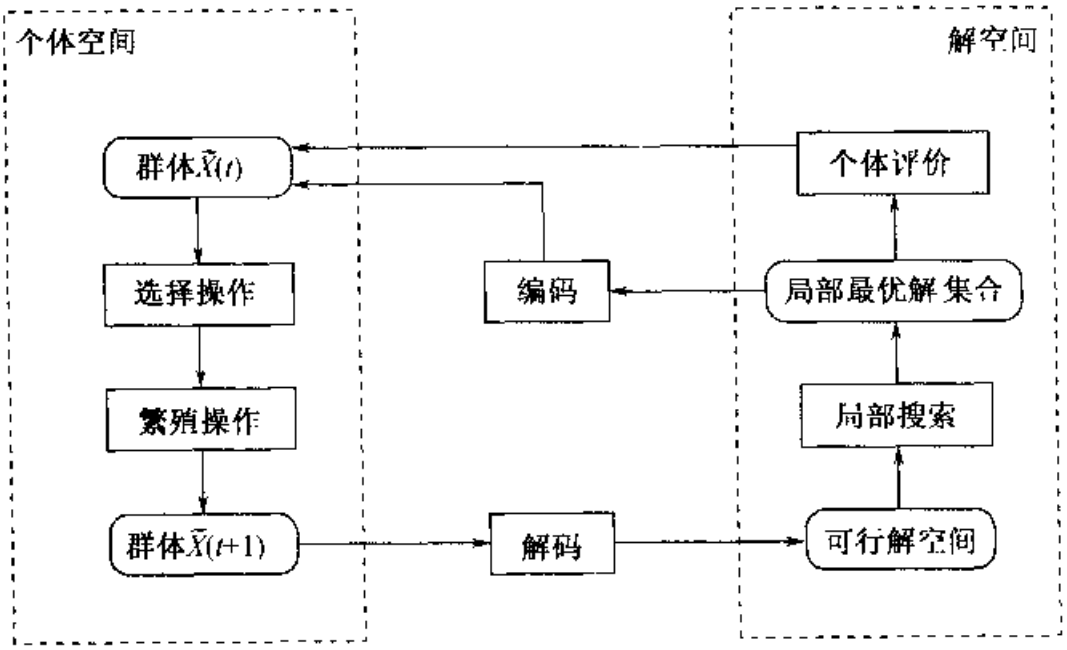


图 1.9 混合遗传算法框架

如如图 1.9 所示.由图 1.9 可以看出,这种混合遗传算法有两个特征:(1)引入了局部搜索过程.基于群体 $\vec{X}(t+1)$中各个个体所对应的表现型,进行局部搜索,从而接受为新一代个体的是 $\vec{X}(t+1)$中个体所对应在当前环境下的局部最优解;(2)增加了编码操作过程:对局部搜索过程所得到的局部最优解,需通过编码过程将它们变换到新的个体,以形成一个性能更优的新群体作为下一代遗传进化操作的基础.

图 1.9 所示的混合遗传算法执行策略以编码 e 的正则性为基础(注意,通常遗传算法只使用解码),而且由于使用了解码,它的计算效率很大程度上也依赖于解码变换实现的复杂程度.所以,作为一般原则,这种混合策略较适用于实数编码、符号编码、或编解码容易实现的遗传算法.

另外,局部搜索算法的选择在图 1.9 所示的混合遗传算法中也有相当的重要性.一般地说,这种局部搜索算法应该具有快速收敛、计算复杂性不高、且所涉及使用的辅助信息(如导数等)与所求解问题匹配(换句话说,所使用的辅助信息容易从问题中获得)等性态.

例 1.26 (*溶合神经网络的混合遗传算法*) 考虑由 TSP、集复盖、独立集问题、背包问题等困难组合优化问题所化归到的组合优化模型

$$\begin{cases} \min E(X) = -\dfrac{1}{2}\sum\limits_{i=1}^{n}\sum\limits_{j=1}^{n} w_{ij}x_i x_j + \sum\limits_{i=1}^{n} b_i x_i + C, \\ X = (x_1, x_2, \cdots, x_n) \in \{-1, 1\}^n, \end{cases} \tag{1.83}$$

其中 $w=(w_{ij})_{n\times n}$是一对称、对角元非负的实矩阵,$b=(b_1, b_2, \cdots, b_n)^{\mathrm{T}} \in R^n$ 是实向量,C 是常数.已知,在神经网络研究中,Hopfield 神经网络

$$x_i(t+1) = \begin{cases} \operatorname{sgn}\left\{\sum\limits_{j=1}^{n} w_{ij}x_j(t) - b_i\right\}, & i = I(t) \\ x_i(t), & i \neq I(t) \end{cases} \tag{1.84}$$

其中

$$\operatorname{sgn}(x) = \begin{cases} 1, & x \geqslant 0, \\ -1, & x < 0, \end{cases}$$

$$I(t) = \begin{cases} t \bmod(n), & t \bmod(n) \neq 0, \\ N, & t \bmod(n) = 0 \end{cases}$$

与问题(1.83)在下述意义下紧密相关:

(1)问题(1.83)的局部最优解与网络(1.84)的稳定态之间存在一一对应文献[24];

(2)从任何初始态 $X(0)$出发,网络(1.84)在有限步内必达到稳定态(即有限步内收敛到问题(1.83)的一个局部极小解)[115].

所以,我们可以认为 Hopfield 神经网络(1.84)是求解(1.83)的一个非常优秀的局部搜索算法(但实验证明,它很难找出问题(1.83)的全局最优).将这一局部搜索算法与标准遗传算法混合即可得出求解(1.83)的下述神经网络混合遗传算法:

步 1 (初始化) 随机生成初始种群 $\vec{X}(0)\in\{-1,1\}^N$,指定交叉概率 P_c,变异概率 P_m 及终止准则,设 $t\leftarrow 0$ 并定义适应度度量

$$J(X) = -E(X) \quad (E(X) \text{ 由(1.83) 定义}).$$

步 2 (种群进化)

2.1 依 $\vec{X}(t)$的适应度从 $\vec{X}(t)$中选择 N 对母体.

2.2 对所选出的每一对母体执行交叉运算生成 N 个中间个体.

2.3 对每一个中间个体执行变异,生成 M 个候选个体.

2.4 依每一个候选个体为初始态激活神经网络(1.84),产生 N 个局部最优态,这 N 个局部最优状态一起构成新一代种群 $\vec{X}(t+1)$.

步 3 (终止检验) 如终止准则满足,停机并输出 $\vec{X}(t+1)$中的最佳个体为(1.83)的近似解;否则置 $t\leftarrow t+1$ 并转步 2.

上述神经网络混合遗传算法已成功应用于独立集问题,显示出既比标准遗传算法有快得多的收敛速度,又比 Hopfield 神经网络能产生更高质量的全局最优解(文献[131]).

例 1.27 (背包问题的混合遗传算法) 背包问题(knapsack problem)的一般提法是:已知 n 个物品的容积及其价值分别为 $w_i(>0)$ 和 $c_i(>0)(i=1,2,\cdots,n)$,背包的容量假设为 $v(v>0)$,如何选择哪些物品装入背包以使在背包的容量限制之内所装物品的总价值最大?该问题的模型可表示为下述 0-1 规划问题:

$$\begin{cases} \max f(x_1,x_2,\cdots,x_n) = \sum_{i=1}^{n} c_i x_i, \\ \text{s.t. } x_i \in \{0,1\}, \quad i = 1,2,\cdots,n, \\ \sum_{i=1}^{n} w_i x_i \leqslant v. \end{cases} \tag{1.85}$$

这是熟知的 NP 完全问题,目前还不存在多项式时间算法.然而对该问题的求解无论是在理论上,还是在实践上都具有重要意义,如管理中的资源分配、投资决策、装载问题等均可建模为背包问题.背包问题的现存求解方法主要是一些启发式算法,也非常适合于用遗传算法求解.

求解(1.85)的**贪婪算法**(greedy algorithm)是这样一种启发式求解策略:如果将物品按价值密度 $\rho_i = c_i/w_i(i=1,2,\cdots,n)$的大小降序排列,则依该次序将相应的物品装入背包,直到超出背包的容量限制为止.运用这种贪婪算法

的确能求得背包问题的较好近似解,但不能保证一定能够找到最优解.用标准遗传算法求解时,当问题的规模不大时,可求出最优解或近似最优解,但当问题的规模较大时,求不出问题的高质量解(甚至在很多情形所得结果还不如由贪婪算法所产生的结果好).这主要是因为搜索空间太大的缘故,并且标准遗传算法所指示的搜索方向在如此大的搜索空间中效果不佳.因此,我们希望在标准遗传算法中溶入背包问题的专门知识,以帮助快速指导搜索并能产生高质量的解.

以下以溶入贪婪算法为例构造一个求解背包问题的混合遗传算法.我们所采用的混合方式是在遗传算子构造中溶入贪婪算法的思想.

(1)编码格式:采用符号编码,特别地,用 n 长度的0-1字符串代表一个装包策略,具体地说,个体 $X=a_1a_2\cdots a_n\in\{0,1\}^n$ 与装包的策略对应为:如果 $a_i=1$,则第 i 件物品装入袋中;如果 $a_i=0$,则第 i 件物品不装入袋中.这种编码显然是正则编码.

(2)混合繁殖算子:任取一种选择算子(例如简单的比例选择)S,一种交叉算子(例如单点交叉或两点交叉)和一种变异算子 M(例如点变异).注意到,对任何两个个体 $X_1,X_2\in\{0,1\}^n$,$C(X_1,X_2)$ 和 $M(X_1)$ 未必满足(1.85)中的约束条件,换言之,满足

$$C(X_1,X_2),M(X_1)\in\Omega=\left\{X\in\{0,1\}^n,\sum_{i=1}^{n}w_ix_i\leqslant v\right\}\quad(1.86)$$

而且即使满足(1.86),$C(X_1,X_2)$,$M(X_1)$ 也未必是较好的装袋策略.于是,我们引进背包问题已有的贪婪算法对这些繁殖算子作改进.方法是:首先引进一个**贪婪变换** $G:\{0,1\}^n\to\{0,1\}^n$,对任何 $X=x_1x_2\cdots x_n$,它定义为 $G(X)=y_1y_2\cdots y_n$,而 $y_i(i=1,2,\cdots,n)$ 由下述过程(算法)定义:

贪婪变换算法:

步1(排序) 对所有 $x_i=1$ 的物品,依它们的价值密度 $\rho_i=c_i/w_i$ 从大到小对物品序号排序,形成队列 $b(i)$(即 $b(1)$ 为价值密度最大的物品序号,$b(2)$ 为价值密度二次大的物品序号,等等).

步2(赋值)

2.1 置 $k=1$.

2.2 计算 $v_k=\sum_{i=1}^{k}w_{b(i)}$.

2.3 如果 $v_k\leqslant v$,令 $y_{b(k)}=1$(即第 $b(k)$ 号物品装袋),置 $k\leftarrow k+1$ 并转步2.2;否则转步2.4.

2.4 对于 $\{1,2,\cdots,n\}$ 中除 $\{b(1),b(2),\cdots,b(k)\}$ 之外的所有序号 j,令 $y_j=0$.

贪婪变换 G 显然把任意一个个体变换成可行解(即 $G(X)\in\Omega$). 其次,我们把贪婪变换与所选定的交叉与变异算子分别作复合,以形成我们的混合交叉与混合变异算子:

$$C_h = G\circ C, \qquad M_h = G\circ M. \tag{1.87}$$

(3) 适应度度量:由于所设计的混合交叉与变异算子均能自然保证繁殖子代的合法性(即是可行解),所以在对个体适应度的评价中无须再引入罚函数项,故我们直接取

$$f(X) = f(x_1, x_2, \cdots, x_n) = \sum_{i=1}^{n} c_i x_i.$$

具体应用上述所定义的编码格式、适应度度量、及混合的交叉算子与变异算子即可得到求解背包问题(1.85)的一个混合遗传算法.

作为一个应用的例子,让我们考虑由 50 件物品所组成的背包问题,其中物品的价值 $C=\{c_i\}$、容积 $W=\{w_i\}$ 和背包容量 v 分别为

$$\begin{aligned} C = \{&220, 208, 198, 192, 180, 180, 165, 162, 160, 158,\\ &155, 130, 125, 122, 120, 118, 115, 110, 105, 101,\\ &100, 100, 98, 96, 95, 90, 88, 82, 80, 77,\\ &75, 73, 72, 70, 69, 66, 65, 63, 60, 58,\\ &56, 50, 30, 20, 15, 10, 8, 5, 3, 1\},\\ W = \{&80, 82, 85, 70, 72, 70, 66, 50, 55, 25\\ &50, 55, 40, 48, 50, 32, 22, 60, 30, 32,\\ &40, 38, 35, 32, 25, 28, 30, 22, 50, 30,\\ &45, 30, 60, 50, 20, 65, 20, 25, 30, 10,\\ &20, 25, 15, 10, 10, 10, 4, 4, 2, 1\},\\ v = &1000. \end{aligned}$$

我们分别用单纯的贪婪算法、标准的遗传算法(即比例选择、单点交叉和点变异)和上述所构造的混合遗传算法求解,其中运行参数取为

$$\{M, T, P_c, P_m\} = \{80, 500, 0.6, 0.1\}\text{(标准、混合遗传算法)},$$

$$\{M, T, P_c, P_m\} = \{50, 500, 0.6, 0.05\}\text{(混合遗传算法)}$$

(这里 M 是种群规模,T 是终止进化代数),各算法独立运行 1000 次,然后对其结果进行统计,其统计结果如表 1.1 所示,最好结果如表 1.2 所示.

由表 1.1 和表 1.2 可看出,无论是在解的质量方面,还是在求解速度方面,混合遗传算法比标准遗传算法和贪婪算法都有非常大的改进. 其原因正在于我们在混合遗传算法中溶合了背包问题的专门知识——贪婪算法.

表 1.1 求背包问题的贪婪算法、标准遗传算法与混合遗传算法的比较(基于 1000 次试验)

算法及参数	结果超过贪婪算法的解的次数	结果超过贪婪算法解时的平均进化代数	最好求解结果(总价值/总重量)
标准遗传算法 {80,500,0.6,0.1}	17	132	3044/999
混合遗传算法 {80,500,0.6,0.1}	990	45	3094/999
标准遗传算法 {50,500,0.6,0.5}	206	238	3077/999
混合遗传算法 {50,500,0.6,0.5}	1000	35	3103/1000
贪婪算法	3036/999(总价值/总重量)		

表 1.2 标准遗传算法、混合遗传算法与贪婪算法求解 50 个物品背包问题的最好解比较

算 法	个体 X	求解结果(总价值/总重量)
标准遗传算法	11011011111010011011111111 10100000010100110000000011	3077/999
混合遗传算法	11010101111011011011011111 11101000010100110000001000	3103/1000
贪婪算法	11111111011010011011001111 10100000010100100000000001	3036/999

1.3.5 自适应策略

作为模拟生物进化过程的遗传算法，要求其具有**自适应性**(adaptiveness)是自然不过的事，因为生物进化本身是自适应的。遗传算法的性态依赖于构成它的基本要素，要使所设计的遗传算法有预期的效能与性态，自然要求能事先设计出理想的编码格式、适应度度量、选择算子、交叉算子、变异算子与各种遗传参数等，而要作到这一点无疑是很困难的。而代之，在遗传算法的运行过程中依据反馈实时对其构成要素与遗传参数作出修正可能是现实而实用的提高遗传算法效能的手段。

自适应地调整遗传算法的构成要素可以从环境、种群、个体、基因等不同

层次进行.从环境层次上的自适应主要是适时调整对个体的适应性度量,以求真实地度量个体对当前环境的适应度,以利筛选出更加优良的后代;种群层次上的自适应主要是考虑各种要素随进化代数演变的时变设置策略;个体层次上的自适性主要是开发针对个体差异而调整的参数设置(如交叉位置的自适应确定、变长度个体的解码等);而基因层次的自适应则主要依据个体基因位的意义调整参数的策略.

不同层次的自适应策略可以任意结合使用,但应用中最为普遍的是基于种群层次的自适应策略.这种情形的遗传算法可一般地表示为

$$\mathrm{GA}(e_t, J_t, S_t, C_t, M_t, \Sigma_t), \tag{1.88}$$

其中

e_t——第 t 代算法所使用的编码格式(含编码长度,解码规则等),

J_t——第 t 代算法所使用的适应度度量,

S_t——第 t 代算法所采用的选择操作,

C_t——第 t 代算法所采用的交叉操作(含交叉概率 $P_t(t)$),

M_t——第 t 代算法所采用的变异操作(含变异概率 $P_M(t)$),

Σ_t——第 t 代算法所使用的系统参数(如终止准则 T,种群规模 N_t 等).

从数学模型上来说,这时的遗传算法不再是一个时齐的,而是一个非时齐的随机过程:

$$\vec{X}(t+1) = M_t \circ C_t \circ S_t(\vec{X}(t)). \tag{1.89}$$

如果(1.88)中的各组成要素一代到一代的变化服从某个预定的规则,则称(1.88)为**稳态自适应遗传算法**(steady adaptive GA);反之,称(1.88)是**动态自适应遗传算法**(dynamicy adaptive GA).动态自适应遗传算法主要根据当前种群信息设置下一代种群生成过程中遗传算法所采用的编码与遗传操作.

例 1.28(自适应编码) 个体编码决定遗传算法的搜索空间与求解精度,而遗传算法的弱点是缺少局部寻优能力.所以当遗传算法所产生的种群进入某个最优解邻域时,它通常在此后的进化中再难产生更优的个体.为了推动种群的进一步进化,此时可考虑改变个体的编码.方法是:假定 GA 所产生的当前种群 $\vec{X}(t_1)$ 已大体稳定到了齐次种群 $[\bar{X}]$(或它的均值稳定到了 $\bar{X}$),则选取小参数 $\delta>0$,将此后的解码变换限定到 $e^{-1}: \boldsymbol{H}_L \to B(\bar{X}, \delta)$,这里

$$B(\bar{X}, \delta) = \{X : \| X - \bar{X} \|_\infty \leqslant \delta\}$$

是以 $\bar{X}$ 为中心以 2δ 为边长的超正方体(参见图 1.10).比如说,在使用二进制编码(例 1.3)情形,此即要求在 t_1 代之后使用解码变换

$$x_i = [e^{-1}(A)]_i = [e^{-1}(\bar{X})]_i + \left(\sum_{j=1}^{m_i} b_{ij} 2^{j-1}\right) \frac{2\delta}{2^{m_i}-1}, \tag{1.90}$$

参考(1.21),这里

$$A = b_{1m_1}b_{1m_1-1}\cdots b_{12}b_{11} \mid b_{2m_2}b_{2m_2-1}\cdots b_{22}b_{21} \mid \cdots \mid b_{nm_n}\cdots b_{n_2}b_{n1}$$

是 $\boldsymbol{H}_L$ 中的任一个体.这种编码调整相当于将遗传算法在 t_1 代之后的搜索限定在 $B(X,\delta)$ 之内(图 1.10).Schraudolph 和 Belew 的动态参数编码[97], Mathias 和 Whitely 的 δ 编码[110]等都属于这一类"动态编码"自适应策略.

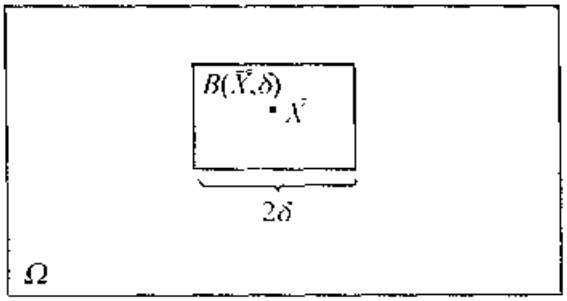


图 1.10 动态编码所对应的解码值域

Leung 等人所提出的"拼接编码"[63]也是实现逐步限定遗传算法搜索区域的自适应编码方案.不同于上述"动态编码"需要等待 GA 的种群趋于稳定(从而要应用种群的收敛信息),这种编码在 GA 的进化进程中每隔一定代数(具体些说,每当相邻若干代无太大变化时)就在原有个体的编码后拼接一定长度的基因串(拼接长度可以是固定的,例如 n),而解码应用可拼接/可分解解码公式(定理 1.1).由于可拼接/可分解编码的特有几何解释(详见例 1.5),这种自适应编码既实现了限定 GA 的搜索区域(由当前种群的个体决定),又实现了低维搜索(由新拼接的基因段决定)来实现高维搜索的效果.基于这种"拼接编码",任意高精度的解可通过在固定大小的低维空间上的搜索来拼接获得.

Goldberg 等人的**混乱编码**(messy GA)[37]也是一种非常有趣的自适应编码.这种编码的长度是不固定的,而是用基因座位置与相应基因值所组成的二元组序列来表示个体,其一般形式是

$$X = (i_1, v_1)(i_2, v_2)\cdots(i_k, v_k)\cdots(i_m, v_m),$$

这里 $i_k \in \{1,2,\cdots,L\}$ 表示基因在原常规染色体中的基因座编号,而 $v_k \in \Gamma$ 是对应的基因值.例如,若常规的一个个体基因型是

$$X = 1\ 0\ 0\ 1\ 0\ 1,$$

其编码长度是 $L=6$,则使用混乱编码格式时,该个体可以表示为

$$X = (1,1)(2,0)(4,1)(5,0)(3,0)(6,1).$$

在这种编码格式中,个体的基因长度可长可短,如

$$X_1 = (1,1)(2,0)(4,1)(3,0)(5,0)(6,1)(3,1)(1,0),$$
$$X_2 = (1,1)(4,1)(5,0)(6,1)$$

都是个体.上述 X_1 的这种指定方式称为是**过剩指定**,因为它对相同的基因座上指定了多过一种的基因,而 X_2 的指定方式则称为是**缺省指定**,因为它没有对所有基因座都赋与基因值.混乱编码对于处理不完全信息和模糊信息下的搜索有重要应用.此时的解码方法是:

(1)对于过剩指定的个体,取同一基因座上出现最多的基因为其代表值(如出现一样多,则取最左边的一组),然后用常规方法解码.

(2)对于缺省指定的个体,随机设定缺省基因座上的基因(例如从等位基因中随机取),然后用常规方法解码.

例 1.29 (自适应适应度调整) 为了引导 GA 的搜索朝着更接近(1.1)的全局最优解方向演化,适时利用 GA 搜索过程所获得的信息来调整个体的适应度度量是重要的.例如说,假定已经知道(如采用杰出者记录策略)GA 到目前代的进化中所发现的最佳个体是 $X^*(t)$,则在下一代的进化中采用适应度度量

$$J_{t+1}(X) = \begin{cases} J_t(X), & \text{如果 } J_t(X) \geqslant J(X^*(t)), \\ 0, & \text{否则,} \end{cases}$$

则可起到压制不优于已发现的 $X^*(t)$的个体重复复制的效果;取时变的适应度度量

$$J_t(X) = \exp(\alpha(t)F(X)) \tag{1.91}$$

(其中 F 是 f 的任一适应值函数,$|\alpha(t)|$是一单调递增的正实数序列),则可起到在 GA 的前期压制特别占优个体过渡繁殖,保持种群多样性,而在后期强化局部搜索保证收敛性的效果(参见 1.2.3 节的讨论).

另外,当处理约束优化问题(1.1)时(例如设 $\Omega = \{X \in R^n \mid g_i(X) = 0, i = 1,2,\cdots,K\}$),常常需要应用罚函数方法将约束问题化归到一个无约束问题求解,即通过求解

$$\max f_\alpha(X) = f(X) + \sum_{i=1}^{K} \alpha_i g_i^2(X)$$

来达到求解(1.1)的目的,这里 $\alpha = (\alpha_1, \alpha_2, \cdots, \alpha_K)$是一组非常大的正参数(称为罚因子).确切的罚因子通常是未知的,于是一个常用的办法是:取一组严格单调增加的正实数序列 $\alpha(t) = (\alpha_1(t), \alpha_2(t), \cdots, \alpha_K(t))$而逐次求解问题

$$\max f_t(X) = f(X) + \sum_{i=1}^{K} \alpha_i(t) g_i^2(X).$$

应用遗传算法实现上述求解原理时,很自然地,可取适应度度量为

$$J_t(X) = F(X) + \sum_{i=1}^{K} \alpha_i(t) g_i^2(X), \tag{1.92}$$

这里 F 是 f 的任一适应值变换.

当遗传算法应用于多目标规划问题(1.70)时,评价种群 $\vec{X}(t)$ 中个体之适应度通常随机取对应于 $f_1, f_2, \cdots, f_p$ 之一的适应值函数 F_i(文献[33]),这可视作是在个体层次上对适应度度量的自适应选择.

例 1.30(自适应选择) 基于自适应度量对个体进行评价自然产生自适应选择.例如,常见的稳态自适应选择包括:整体退火选择:

$$P\{Y_t = X_j(t)\} = \frac{n(X_j(t))\exp\left\{\dfrac{J(X_j(t))}{T_t}\right\}}{\sum_{k=1}^{N} \exp\left\{\dfrac{J(X_k(t))}{T_t}\right\}}, \tag{1.93}$$

其中 $\vec{X}(t) = (X_1(t), X_2(t), \cdots, X_N(t)) \in \boldsymbol{H}_L^N$ 为 GA 所产生的第 t 代种群,$\{T_t\}$ 为单调递减到 0 的退火温度序列(参见 1.41)、乘幂自适应选择

$$P\{Y_t = X_j(t)\} = \frac{n(X_j(t))J^{\alpha(t)}(X_j(t))}{\sum_{k=1}^{N} J^{\alpha(t)}(X_k(t))}, \tag{1.94}$$

其中 $\{\alpha(t)\}$ 是单调增加的正实数序列(参见(1.42))、以及动态 Boltzmann 选择

$$P\{Y_t = X_j(t)\} = \frac{\exp\{J(X_j(t))/T_t\}}{\exp(J(X_{j+1}(t))/T_t) + \exp(J(X_j(t))/T_t)} \tag{1.95}$$

等.作为动态自适应选择的例子,我们考虑用于二进制编码遗传算法如下父子混合选择算子的动态修正(文献[135]):设 $\vec{X}(t)$ 是父代种群,$\vec{X}'(t)$ 是子代种群(它经由 $\vec{X}(t)$ 的通常 GA 一步生成).令 $\lambda(\vec{X}(t))$ 表示向量 $\sum_{i=1}^{N} X_i(t)$ 取值非零和不等于 N 的个数(称为 $\vec{X}(t)$ 的多样度),$J_{op}(\vec{X}) = \max_{1 \leqslant j \leqslant N} J(X_j(t))$ 表示种群 $\vec{X}$ 的最佳适应度.令

$$C_t = \min\left\{1, \left\{\frac{\lambda(\vec{X}'(t))}{\lambda(\vec{X}(t))}\right\}^{\alpha} \left\{\frac{J_{op}(\vec{X}'(t))}{J_{op}(\vec{X}(t))}\right\}^{t}\right\}, \tag{1.96}$$

$$\vec{Y}(t) = \begin{cases} \vec{X}'(t), & \text{若 } \mathrm{random}(0,1) < C_t, \\ X(t), & \text{若 } \mathrm{random}(0,1) \geqslant C_t, \end{cases} \tag{1.97}$$

则动态父子混合选择 $S_{f\&s}(t): \boldsymbol{H}_L^N \times \boldsymbol{H}_L^M \to \boldsymbol{H}_L^M$ 定义为

$$S_{f\&s}(t)(\vec{X}(t) \vee \vec{X}'(t)) = S(\vec{Y}(t)), \tag{1.98}$$

这里 S 是任一确定的比例型选择算子.如此定义的动态父子混合选择能有效

克服 GA 的假收敛现象，相应遗传算法能依概率收敛到问题(1,1)的全局最优解[135].

例 1.31（自适应遗传算子） 由例 1.21 所给出的非一致变异是典型的种群层次上的自适应变异操作，而由(1.68)所定义的用于可拼接/可分解编码的变异率设置是典型的基因与种群结合层次上的自适应. 另外，由例 1.25 所给出的线性交叉算子是个体层次上的自适应交叉；文献[63]中所给出的在不同代种群中设置不同杂交窗(crossover window)的方法(在 t 代种群中，只允许在杂交窗内的基因段交换重组)可认为是种群层次上的自适应交叉操作.

使用任何一种或多种自适应构件的遗传算法形成一种具体形式的自适应遗传算法. 自适应遗传算法是目前改善遗传算法性态、提高收敛性的主要策略之一. 有兴趣的读者可进一步参见文献[99],[29],[30],[32],[40],[45]和[6].

§1.4 遗传算法的搜索机理

前三节我们主要从算法设计与应用的角度讲述了模拟进化计算的构成与执行技巧，从本节起，我们开始讨论模拟进化计算的基础理论问题. 为了深入，我们仍然以遗传算法为例展开.

遗传算法的基础理论问题主要涉及以下三个方面：第一，有关遗传算法的搜索机理，即回答究竟遗传算法是如何工作的？它是否是对自然进化的准确模拟？这一研究是算法进一步发展与修正的基础. 第二，有关算法的性态分析，例如回答：所给定的一个遗传算法执行策略是收敛的吗？它是进化到某个局部最优还是全局最优(收敛性问题)？如果一个遗传算法是收敛的，它需要多长时间收敛(收敛速度问题)？对哪一类问题遗传算法有效或不有效(有效性问题)？第三，有关算法的复杂性分析，特别如澄清遗传算法能解决(能有效解决)哪样一些特征的问题(能解性问题)？它将以多大的代价求解一个问题(难易度问题)等等. 有关遗传算法的所有这些基础问题已有大量研究并已取得丰富结果. 但限于篇幅，本书只重点介绍有关遗传算法的搜索机理与收敛性方面. 本节探讨有关遗传算法的搜索机理.

1.4.1 种群增长方程

种群增长方程是描述遗传算法搜索过程中，哪些个体较容易生存，哪些个体较容易被淘汰的一种估计理论与方法，它由 Holland(1975)等人[44]提出并发展.

这种估计方法使用模式(schema)这一基本概念. 为了理解什么叫一个模

式,让我们考虑个体空间

$$\boldsymbol{H}_L = \{0,1\}^L,$$

并把其中的每一个个体对应作 L 维立方体中的顶点(即把个体的基因对应作顶点的坐标,例如 $L=3$ 的情形见图 1.11).我们知道,一个超立方体由一系列维数不同的棱或面组成,这些棱或面可以统一地被看成是 L 维空间的"超平面".对于每一个"超平面",其上的一些坐标值是固定的(例如由(111)和(110)所决定的一维"超平面"上,所有前两个坐标是固定的,而由(111),(110),(101),(100)所确定的二维"超平面"上,所有第一个坐标固定),而且其固定坐标的个数决定该"超平面"的维数.模式即是对应于 $\boldsymbol{H}_L$ 的"超平面"上的个体全体.

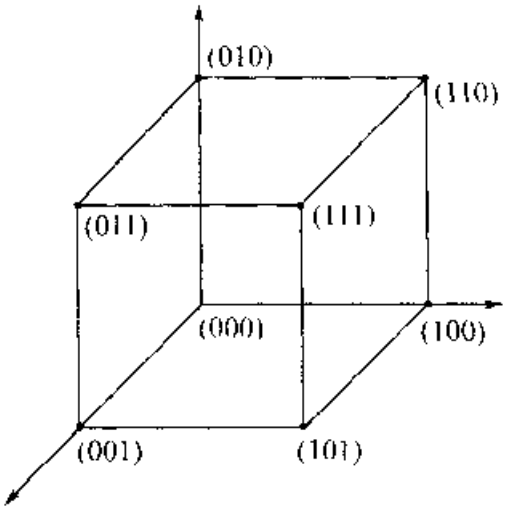


图 1.11 $L=3$ 时的个体空间 $\boldsymbol{H}_3$

定义 1.13(模式) 设 $a_{i_k} \in \{0,1\}$, $i_k \in \{1,2,\cdots,L\}$. $\boldsymbol{H}_L$ 上的一个**模式** S 是指 $\boldsymbol{H}_L$ 的一个"超平面",它可以表示作

$$S = \{X = x_1, x_2 \cdots x_L \in \boldsymbol{H}_L \mid x_{i_k} = a_{i_k}, k = 1,2,\cdots,K\}, \quad (1.99)$$

其中 K 称作模式 S 的**阶**,记作 $O(S)$;$\{i_1, i_2, \cdots, i_K\}$ 称作是 S 的**确定位**,$\{a_{i_1}, a_{i_2}, \cdots a_{i_k}\}$ 称为是 S 的**确定分量**;记

$$\delta(S) = i_K - i_1,$$

称 $\delta(S)$ 是模式 S 的**定义长度**(defining length).

根据上述定义,一个模式事实上是这样一些个体的集合,它们在某些基因座上的基因值是相同的,具有相同基因的个数即是该模式的阶,而从第一个确定基因位到最后一个确定基因位的距离即是这一模式的定义长度.例如,个体集合{(111),(110),(101),(100)}是 $\boldsymbol{H}_3$ 的一个模式,它可表示为

$$\mathcal{A}_1 = \{X = x_1x_2x_3 \in \boldsymbol{H}_3,\ x_1 = 1\}$$

或 $\mathcal{A}_1=(1\ *\ *)$，它的阶 $O(\mathcal{A}_1)=1$，而定义长度 $\delta(\mathcal{A}_1)=0$；而个体集合 $\{(010),(110)\}$ 也是 $\boldsymbol{H}_3$ 的一个模式，可表示为

$$\mathcal{A}_2 = \{X = x_1x_2x_3 \in \boldsymbol{H}_3 :\ x_2 = 1, x_3 = 0\}$$

或 $\mathcal{A}_2=(*\ 1\ 0)$，它的阶 $O(\mathcal{A}_2)=2$，定义长度 $\delta(\mathcal{A}_2)=1$.

以后，在不引起混淆的情况下，将模式(1.99)简记为 $\mathcal{A}(i_k, a_{i_k}); K]$，或直接写成一个等位基因为符号集 $\{0,1,*\}$ 上的 L 长染色体，其中不确定基因座的基因取值“*”.

定义 1.14（模式平均适应度） 设 $\mathcal{A}$ 是一个模式，$X\in\boldsymbol{H}_l$ 是一个个体，$\vec{X}\in\boldsymbol{H}_L^N$ 是一个种群. X 称为**与模式 $\mathcal{A}$ 相匹配**，如果 $X\in\mathcal{A}$；种群 $\vec{X}$ 中与模式 $\mathcal{A}$ 相匹配的个体全体记为 $\vec{X}\cap\mathcal{A}$；种群 $\vec{X}$ 相对于模式 $\mathcal{A}$ 的**平均适应度**（或直接称为 $\mathcal{A}$ 的平均适应度）$J_{av}(\vec{X}\cap\mathcal{A})$ 定义为

$$J_{av}(\vec{X}\cap\mathcal{A}) = \sum_{X_j\in\vec{X}\cap\mathcal{A}} J(X_j)/|\vec{X}\cap\mathcal{A}|; \tag{1.100}$$

种群 $\vec{X}$ 的**平均适应度** $J_{av}(\vec{X})$ 定义为

$$J_{av}(\vec{X}) = \sum_{X_j\in\vec{X}} J(X_j)/N. \tag{1.101}$$

定理 1.4（种群增长方程） 设 $\vec{X}(t)$ 表示由标准遗传算法所生成的第 t 代（随机）种群，$\mathcal{A}$ 是 $\boldsymbol{H}_l$ 中的任一模式，$\xi(\mathcal{A},t)=|\mathcal{A}\cap\vec{X}(t)|$ 是 $\vec{X}(t)$ 中与模式 $\mathcal{A}$ 相匹配的个体平均数，则

$$\xi(\mathcal{A},t+1) \geqslant \xi(\mathcal{A},t)\left[1 - P_c\frac{\delta(\mathcal{A})}{L-1}\right](1-O(\mathcal{A})P_m)\frac{J_{av}(\vec{X}(t)\cap\mathcal{A})}{J_{av}(\vec{X}(t))}. \tag{1.102}$$

证明 经比例选择作用后，$\vec{X}(t)\cap\mathcal{A}$ 中各个个体 X_j 能够平均复制 $N\cdot J(X_j)/\sum_{i=1}^{N}J(X_i)$ 个到下一代种群，所以 $\vec{X}(t)\cap\mathcal{A}$ 中个体通过选择被保留的平均数 N_1 是

$$N_1 = N\cdot\sum_{X_j\in\vec{X}(t)\cap\mathcal{A}} J(X_j)/\sum_{i=1}^{N}J(X_i)$$

$$= \xi(\mathcal{A},t)\frac{J_{av}(\vec{X}(t)\cap\mathcal{A})}{J_{av}(\vec{X}(t))}.$$

这些与 $\mathcal{A}$ 匹配的个体通过交叉操作可能被破坏而不再与 $\mathcal{A}$ 匹配. 由于为交叉操作而破坏匹配时，交叉点必须取在 $\mathcal{A}$ 的第一个确定位与最后一个确定位之间，而这种情形发生的平均数不超过 $\delta(\mathcal{A})/(L-1)$（由于随机点的产生是等

概率的)，再考虑到交叉操作是以概率 P_c 进行的，故经选择、交叉所生成的中间种群中与 $\mathcal{H}$ 匹配的数目 N_2 满足

$$N_2 \geqslant [1 - P_c \frac{\delta(\mathcal{H})}{L-1}]N_1.$$

这些与 $\mathcal{H}$ 匹配的个体还可能经过变异而进一步破坏，每一个这样的个体被变异破坏的可能性不大于 $P_m O(\mathcal{H})$(因为只有当变异位发生在与 $\mathcal{H}$ 确定位对应的基因座上时才有可能破坏)。于是，我们得出种群 $\vec{X}(t+1)$ 中与 $\mathcal{H}$ 相匹配的平均数 $\xi(\mathcal{H}, t+1)$ 满足

$$\begin{aligned}\xi(\mathcal{H}, t+1) &\geqslant [1 - P_m O(\mathcal{H})]N_2 \\ &\geqslant [1 - P_c \frac{\delta(\mathcal{H})}{L-1}][1 - P_m O(\mathcal{H})]N_1 \\ &= \xi(\mathcal{H}, t)[1 - P_c \frac{\delta(\mathcal{H})}{L-1}][1 - P_m O(\mathcal{H})] \frac{J_{av}(\vec{X}(t) \cap \mathcal{H})}{J_{av}(\vec{X}(t))},\end{aligned}$$

即(1.102)成立。

由种群增长方程(1.102)，我们能够分析哪样一些个体或模式在标准遗传算法作用下容易繁殖，而且以怎样的速率繁殖。事实上，如果 $O(\mathcal{H})$ 和 $\delta(\mathcal{H})$ 都很小，或者 $P_c/(L-1)$ 和 P_m 都很小，则我们从(1.102)可近似地推出

$$\xi(\mathcal{H}, t+1) \geqslant \frac{J_{av}(\vec{X}(t) \cap \mathcal{H})}{J_{av}(\vec{X}(t))} \xi(\mathcal{H}, t). \tag{1.103}$$

如果，再进一步，从某一代 t_0 起，种群 $\vec{X}(t)$ 相对于模式 $\mathcal{H}$ 的平均适应度 $J_{av}(\vec{X}(t) \cap \mathcal{H})$ 总是高于种群 $\vec{X}(t)$ 的平均适应度 C 倍，则(1.102)推出

$$\xi(\mathcal{H}, t+1) \geqslant (1+C)\xi(\mathcal{H}, t), \quad \forall t \geqslant t_0, \tag{1.104}$$

于是

$$\xi(\mathcal{H}, t+1) \geqslant (1+C)^{t-t_0}\xi(\mathcal{H}, t_0). \tag{1.105}$$

上式说明：**在标准遗传算法中，具有低阶、短定义长度、平均适应度高出种群平均适应度的模式将依指数级增长**(或者，如果编码长度很长而且变异概率很小，则平均适应度高出种群平均适应度的模式将指数增长)。

上述结论通常称为遗传算法的模式定理(文献[36]，[44]，[21]，[17]，[72]，[69]，[157])而模式定理中所表述的“具有低阶、短定义长度，且平均适应度高于种群适应度的模式”被称之为**基因块或积木块**(building block)。之所以将这样的模式称之为积木块，是人们认为：遗传算法的求解过程并不是在搜索空间中逐一地测试各个基因的枚举组合，而是通过一些较好的模式，像搭积木一样，将它们拼接在一起，从而逐渐地构造出适应度越来越高的个体编码串。这一认识被知之为**基因块假设**。

基因块假设是至今尚未得到严格证明的一种认识,既有大量的应用实践说明这一假设的真实性,但也有反例(即所谓的遗传算法**欺骗问题**(GA deceptive problem)说明这一假设的不真实性.

模式定理与基因块假设是人们早期对遗传算法搜索机理的说明.下节我们将从完全不同的角度来分析这一问题.

1.4.2 交叉算子的搜索能力与可达域

我们将从分析遗传算法的各个主要操作(选择、交叉、变异)的基本搜索能力入手,澄清遗传算法的搜索机理.

选择操作是作用在当前种群,而且其中的任何个体都能以正概率被选择的操作,所以选择算子的搜索能力十分明了.那么交叉算子与变异算子分别具有什么样的搜索能力呢?本小节回答交叉算子的搜索能力问题.

定义 1.15 (种群所诱导的模式,多样度、成熟度) 设 $\vec{X}=(X_1,X_2,\cdots,X_N)\in \boldsymbol{I}_L^N$ 是任一种群,个体 $X_1,X_2,\cdots,X_N$ 具有相同的基因位和取值 $\{(i_k,a_{i_k}),k=1,2,\cdots,\beta(\vec{X})\}$.称 $\mathcal{H}[(i_k,a_{i_k});\beta(\vec{X})]$ 是包含 $\vec{X}$ 的**极小模式**或是由种群 $\vec{X}$ **所诱导的模式**,记为 $\mathcal{H}(\vec{X})$;$\mathcal{H}(\vec{X})$ 的阶数 $\beta(\vec{X})$ 称为 $\vec{X}$ 的成熟度,而 $\lambda(\vec{X})=L-\beta(\vec{X})$ 称为 $\vec{X}$ 的**多样度**.

显然,模式 $\mathcal{H}(\vec{X})$ 中包含 $2^{L-\lambda(\vec{X})}$ 个不同个体.

对于给定的选择算子 S 和交叉算子 C,定义

$$\begin{cases} C(\vec{X},0)=\vec{X}, \\ C(\vec{X},k)=C\circ S(C(\vec{X},k-1)), \quad k=1,2,\cdots \end{cases} \tag{1.106}$$

定理 1.5 (杂交算子搜索能力刻画) 设 S 为选择算子,C 为交叉算子,$\mathcal{H}$ 为一个模式,$\mathcal{H}(\vec{X})$ 为包含 $\vec{X}$ 的极小模式,则

(i) $C\circ S(\vec{X})\subseteq\mathcal{H}$ 对任何 $\vec{X}\subseteq\mathcal{H}$.

(ii) $C\circ S(\vec{X})\subseteq\mathcal{H}(\vec{X})$.

(iii) $\mathcal{H}(\vec{X})=\bigcup_{k=0}^{\infty}C(\vec{X},k)$.

证明 对任意一对母体 $(X,Y)\subseteq\mathcal{H}$(即 $X\in\mathcal{H},Y\in\mathcal{H}$)和任何 $Z\notin\mathcal{H}$,对 (X,Y) 作交叉生成 Z 的可能性为 0,即

$$P\{C(X,Y)=Z\}=0,$$

所以由全概率公式推知

$$\begin{aligned} &P\{C\circ S(\vec{X})\subseteq\mathcal{H}/\vec{X}\subset\mathcal{H}\} \\ &=1-\sum_{Z\notin\mathcal{H}}P\{Z\in C(\vec{X})/\vec{X}\subseteq\mathcal{H}\} \\ &=1-\sum_{Z\notin\mathcal{H}}\sum_{(X,Y)\subseteq\mathcal{H}}P\{C(X,Y)=Z\}=1, \end{aligned}$$

这即推出(i)成立.

由于 $\mathcal{H}(\vec{X})$是包含 $\vec{X}$ 的极小模式,自然有 $\vec{X}\subseteq\mathcal{H}(\vec{X})$,从而(ii)是(i)的直接结果.下证(iii).

由 $\mathcal{H}(\vec{X})$的定义,显然有$C(\vec{X},0)\subseteq\mathcal{H}(\vec{X})$;如果假设$C(\vec{X},k-1)\subseteq\mathcal{H}(\vec{X})$,则由(ii)知

$$C(\vec{X},k)=C\circ S(C(\vec{X},k-1))\subseteq\mathcal{H}(\vec{X}),$$

于是由归纳法原理知,对任何 $k\geqslant 0$ 有

$$C(\vec{X},k)\subseteq\mathcal{H}(\vec{X}),$$

从而$\bigcup_{k=0}^{\infty}C(\vec{X},k)\subseteq\mathcal{H}(\vec{X})$.我们以下用反证法证明

$$\mathcal{H}(\vec{X})\subseteq\bigcup_{k=0}^{\infty}C(\vec{X},k),\tag{1.107}$$

于是(iii)成立.假定上述包含关系不成立,于是存在 $Y\in\mathcal{H}(\vec{X})\setminus\bigcup_{k=0}^{\infty}C(\vec{X},k)$,从而对任何 $k\geqslant 0$,$P\{Y\in C(\vec{X},k)\}=0$.我们以下说明,这是不可能的.

事实上,设 $Y=y_1y_2\cdots y_L\in\mathcal{H}(\vec{X})=\mathcal{H}[(i_k,a_{i_k});\beta(\vec{X})]$.由于$\beta(\vec{X})$是$\mathcal{H}(\vec{X})$的阶数,不失一般性,我们可设 $\vec{X}$ 中诸个体的前$\beta(\vec{X})$个基因取值相同.换言之,如设 $\vec{X}=(X_1,X_2,\cdots,X_N)$且 $X_i=x_{i1}x_{i2}\cdots x_{iL}(i=1,2,\cdots,L)$,则有

$$x_{ij}=y_j,\quad\forall\, i=1,2,\cdots,N,\ j=1,2,\cdots,\beta(\vec{X}).$$

由$\mathcal{H}(\vec{X})$阶的定义,对任何 $j=\beta(\vec{X})+1,\cdots,L$,必存在$\vec{X}$中的某一个体$X_p$,使其第 j 个基因值 $x_{pj}=y_j$.

首先考虑 $\lambda(\vec{X})=L-\beta(\vec{X})=1$ 的情形.此时 $\vec{X}$ 的所有个体的前$L-1$个基因取值相同,且

$$x_{ij}=y_j,\quad j=1,2,\cdots,L-1,\ i=1,2,\cdots,N.$$

由于 $Y\in\mathcal{H}(\vec{X})$,存在某个 $X_p\in\vec{X}$ 使$x_{pL}=y_{pL}$,即 $X_p=Y$,于是据定理1.4得

$$\begin{aligned}P\{Y\in C(\vec{X},1)\}&=P\{X_p\in C(\vec{X},1)\}\\&\geqslant\sum_{i=1}^{N}P\{C(X_p,X_i)=X_p\}\frac{J(X_p)J(X_i)}{[\sum_{j=1}^{N}J(X_j)]^2}\\&=\sum_{i=1}^{N}\left[(1-P_c)+\frac{P_c}{L}\right]\frac{J(X_p)J(X_i)}{[\sum_{j=1}^{N}J(X_j)]^2}\\&=\left[(1-P_c)+\frac{P_c}{L}\right]\frac{J(X_p)}{\sum_{j=1}^{N}J(X_j)}>0.\end{aligned}$$

此与 $P\{Y\in C(\vec{X},k)\}=0$ 对任何 k 成立矛盾.

现假设对于满足 $\lambda(\vec{X}_0)=m-1$ 的任一种群 $\vec{X}_0$，存在 $n'>0$ 使

$$P\{Y\in C(\vec{X},n')\}>0, \tag{1.108}$$

则我们往证对于满足 $\lambda(\vec{X})=m$ 的任意 $\vec{X}$，必存在 n 使

$$P\{Y\in C(\vec{X},n)\}>0, \tag{1.109}$$

于是与 $P\{Y\in C(\vec{X},k)\}=0$ 对任何 k 成立矛盾．依归纳法原理，此将证得(1.107)成立．

事实上，$\lambda_0(\vec{X})=m$ 的情形，$Y\in\mathcal{Y}(\vec{X})$ 推出

$$x_{ij}=y_j,\quad \forall j=1,2,\cdots,L\quad m,\ i=1,2,\cdots,N,$$

且必存在某个 $i_0(1\leqslant i_0\leqslant N)$ 使得 $x_{i_0L}=y_L$．取 $\vec{Z}(1)=(Z_1,Z_2,\cdots,Z_N)$ 满足

$$Z_{i_0}=X_{i_0},\quad Z_i=x_{i1}x_{i2}\cdots x_{i(L-1)}x_{i_0L},\quad \forall i\neq i_0,$$

则种群 $\vec{Z}(1)$ 的多样度为 $\lambda(\vec{Z}(1))=m\quad 1$，且 $Y\in\mathcal{Y}(\vec{Z}(1))$．由交叉与选择算子的定义，于是

$$P\{C(\vec{X},1)=\vec{Z}(1)\}\geqslant\left[\prod_{i\neq i_0}\frac{J(X_i)J(X_{i_0})}{\left|\sum_{j=1}^{N}J(X_j)\right|^2}\cdot\frac{P_c}{L}\right]\frac{J^2(X_{i_0})}{\left|\sum_{j=1}^{N}J(X_j)\right|^2}>0.$$

而根据归纳假设(1.108)存在 n' 使 $P\{Y\in C(\vec{Z}(1),n')\}>0$，故根据序列 $\{C(\vec{X},k)\}$ 的马氏性，对于 $n=n'+1$，我们获得

$$\begin{aligned}&P\{Y\in C(\vec{X},n)\}\\&\geqslant P\{Y\in C(\vec{Z}(1),n')\}\times P\{C(\vec{X},1)=\vec{Z}(1)\}>0,\end{aligned}$$

此即对任何满足 $\lambda(\vec{X})=m$ 的 $\vec{X}$，必存在 $n>0$ 使(1.109)成立．

定理 1.5 立刻推出下述推论．

推论 1.1 (1)对任何 $Y\in\mathcal{Y}(\vec{X})$，必存在某个 $n\geqslant 0$ 使 $Y\in C(\vec{X},n)$；(2)对任何 $Y\notin L(\vec{X})$，必不存在 $n\geqslant 0$ 使 $Y\in C(\vec{X},n)$．

推论 1.1 的一个等价说法是：存在 $n\geqslant 0$ 使 $Y\in C(\vec{X},n)$ 的充要条件是 $Y\in L(\vec{X})$．这意味着，对模式 $\mathcal{Y}(\vec{X})$ 中的任何个体，循环使用交叉与选择操作(或者说不带变异的遗传算法)必然在有限步内达到这一个体，而仅靠循环使用交叉与选择操作永远不可能搜寻到 $\mathcal{Y}(\vec{X})$ 之外的任何个体．

上述分析说明：由初始种群 $\vec{X}(0)$ 所决定的极小模式 $\mathcal{Y}(\vec{X}(0))$ 是交叉算子(严格的说，交叉与选择的复合)的精确搜索域(可达域)．注意到，选择算子只能在当前种群内搜索，故交叉算子的搜索能力限于且仅限于包含 $\vec{X}(0)$ 的极小模式 $\mathcal{Y}(\vec{X}(0))$．

这样，我们完全刻画了交叉算子的搜索能力．

1.4.3 变异算子的搜索能力与可达域

我们现在对变异算子的搜索能力进行刻画．首先，根据(1.58)，我们直接

可得出如下结论.

定理 1.6 设 M 是点变异算子，X，Y 是 $\boldsymbol{H}_L$ 中的任意两个个体，则 $P\{M(X)=Y\}>0$ 的必要充分条件是 $0<P_m<1$.

证明 由(1.58)，

$$P\{M(X)=Y\}=(1-P_m)^{L-d(X,Y)}P_m^{d(X,Y)}.$$

这推出：如果 $0<P_m<1$，则必有 $P\{M(X)=Y\}>0$；反之，若 $P_m=0$，则当 $X\neq Y$ 时有 $P\{M(X)=Y\}=0$；若 $P_m=1$，则当 $d(X,Y)\neq L$ 时有 $P\{M(X)=Y\}=0$，于是，若对任何 $X,Y\in\boldsymbol{H}_L$ 有 $P\{M(X)=Y\}>0$，则必有 $0<P_m<1$. 从而完成了证明.

上述定理说明变异算子有能力从任何个体出发搜索到 $\boldsymbol{H}_L$ 中的任何其他一个个体，即整个空间 $\boldsymbol{H}_L$ 是变异算子的搜索可达域. 那么变异算子对任何给定的初始种群，它能以多大的可能性搜索到 $\boldsymbol{H}_L$ 中的每一状态呢？为了对这一问题进行分析，我们把个体空间 $\boldsymbol{H}_L$ 中的个体一一列出，例如表示为

$$\boldsymbol{H}_L=\{0,1,2,\cdots,Q-1\},\qquad Q=|\boldsymbol{H}_L|,\tag{1.110}$$

于是任何一个种群 $\vec{X}$ 可由它在 $\boldsymbol{H}_L$ 上的概率分布来表征.

定义 1.16（随机个体、无限种群） $\boldsymbol{H}_L$ 上的随机变量 $\hat{X}$ 称为是一个**随机个体**(或**无限种群**). 让

$$a_i=P\{\hat{X}=i\in\boldsymbol{H}_L\},\quad i=0,1,\cdots,Q-1,\tag{1.111}$$

$$A=(a_0,a_1,\cdots,a_{Q-1}),\tag{1.112}$$

称 A 为 $\hat{X}$ 的**分布向量**，在不致混淆的情形，也称 A 为**随机个体**或**无限种群**.

通常的种群可以看作是随机个体的一个样本，从这个意义上，种群是无限种群的特殊情形. 例如，种群 $\vec{X}=(X_1,X_2,X_3,X_4)$，其中

$$X_1=011,\quad X_2=001,\quad X_3=110,\quad X_4=010.$$

可以认为是个体空间

$$\boldsymbol{H}_L=\{\underbrace{000}_{0},\underbrace{001}_{1},\underbrace{010}_{2},\underbrace{011}_{3},\underbrace{100}_{4},\underbrace{101}_{5},\underbrace{110}_{6},\underbrace{111}_{7}\}$$

上随机个体

$$A=(0,0.25,0.25,0.25,0,0,0.25,0)$$

的一个样本. 显然，通过研究更为广泛的随机个体在变异算子作用下的转移过程能对通常种群在变异算子作用下的演化过程给出更明确的刻画.

对于给定的随机个体 $\hat{X}$，设

$$\begin{cases}M(\hat{X},0)=\hat{X},\\ M(\hat{X},k)=M(M(\hat{X},k-1)),\quad k=1,2,\cdots\end{cases}\tag{1.113}$$

定理 1.7 设 $\hat{X}$ 是初始种群，则对于任意 $k \geqslant 1$ 有

$$P\{M(\hat{X},k)=i\}=\sum_{j\in H_L}a_j\prod_{m=1}^{L}\left[\frac{1}{2}+\left(\delta_{i_m j_m}-\frac{1}{2}\right)(1-2P_m)^k\right], \tag{1.114}$$

这里 $\delta_{ij}=0$ 如果 $i\neq j$，反之 $\delta_{ij}=1$ 如果 $i=j$.

证明 首先我们考虑变异使个体 i 转移到个体 j 的概率. 由于 i 的分量的变异是独立的，且

$$P\{(M(\hat{X}))_m=j_m/i_m\}=\begin{cases}1-P_m, & i_m=j_m,\\ P_m, & i_m\neq j_m,\end{cases}$$

于是

$$P\{(M(\hat{X}))_m=j_m/i_m\}=P_m+\delta_{i_m j_m}(1-2P_m), \tag{1.115}$$

从而

$$P\{M(\hat{X},k+1)=j/M(\hat{X},k)=i\}=\prod_{m=1}^{L}(P_m+\delta_{i_m j_m}(1-2P_m)). \tag{1.116}$$

我们用归纳法来证明(1.114). 当 $k=1$ 时，由(1.116)得

$$\begin{aligned}P\{M(\hat{X},1)=i\}&=\sum_{j\in H_L}a_jP\{M(\hat{X})=i/j\}\\&=\sum_{j\in H_L}a_j\prod_{m=1}^{L}(P_m+\delta_{i_m j_m}(1-2P_m))\\&=\sum_{j\in H_L}a_j\cdot\prod_{m=1}^{L}\left[\frac{1}{2}+\left(\delta_{i_m j_m}-\frac{1}{2}\right)(1-2P_m)\right],\end{aligned}$$

于是(1.114)对于 $k=1$ 成立. 若(1.114)对于 k 成立，则

$$\begin{aligned}&P\{M(\hat{X},K+1)=Z\}\\&=\sum_{i\in H_L}P\{M(\hat{X},k+1)=Z/M(\hat{X},k)=i\}\cdot P\{M(\hat{X},k)=i\}\\&=\sum_{j\in H_L}a_j\cdot\prod_{m=1}^{L}\sum_{i_m}(P_m+\delta_{i_m z_m}(1-2P_m)\cdot[(0.5+(\delta_{i_m j_m}-0.5)\\&\quad\cdot(1-2P_m)^k].\end{aligned} \tag{1.117}$$

我们将 i_m, j_m, z_m 分以下情况：

(a) $j_m=z_m$，这时有 $j_m=i_m$ 和 $j_m\neq i_m$ 两种可能.

(b) $j_m\neq z_m$，这时有 $z_m=i_m$，和 $j_m=i_m$ 但 $z_m\neq i_m$ 两种可能.

于是有

$$\begin{aligned}
&\sum_{i_m}(P_m+\delta_{i_m z_m}(1-2P_m)[0.5+(\delta_{i_m j_m}-0.5)(1-2P_m)^k]\\
&=\delta_{j_m z_m}[(1-P_m)(0.5+0.5(1-2P_m)^k)+P_m(0.5-0.5(1-2P_m)^k)]\\
&\quad+(1-\delta_{j_m z_m})[(1-P_m)(0.5-0.5(1-2P_m)^k)\\
&\quad+P_m(0.5+0.5(1-2P_m)^{k+1})]\\
&=\delta_{j_m z_m}(0.5+0.5(1-2P_m)^{k-1})+(1-\delta_{j_m z_m})(0.5-0.5(1-2P_m)^{k+1})\\
&=0.5+(\delta_{j_m z_m}-0.5)(1-2P_m)^{k+1},
\end{aligned}$$

代入(1.117)从而得

$$\begin{aligned}
&P\{M(\hat{X},k+1)=z\}\\
&=\sum_{j\in H_L}a_j\cdot\prod_{m=1}^{l}[0.5+(\delta_{j_m z_m}-0.5)(1-2P_m)^{k+1}],
\end{aligned}$$

即(1.113)对于 $k+1$ 亦成立.定理得证.

从定理 1.7,我们立即可推出下述结论.

定理 1.8(变异算子的搜索能力) 如果 $\hat{X}$ 是随机个体,$P_m<\frac{1}{2}$,则

$$\lim_{k\to\infty}P\{M(\hat{X},k)=i\}=\frac{1}{|H_L|}. \tag{1.118}$$

进而,如果 $\hat{X}$ 在 H_L 上均匀分布(即 $a_i=1/|H_L|$),则

$$\begin{aligned}
&\sum_{i\in H_L}\left|P\{M(\hat{X},k+1)=i\}-\frac{1}{|H_L|}\right|\\
&\leqslant\sum_{i\in H_L}\left|P\{M(\hat{X},k)=i\}-\frac{1}{|H_L|}\right|.
\end{aligned} \tag{1.119}$$

证明 当 $P_m<\frac{1}{2}$ 时,$1-2P_m<1$,下是定理 1.6 直接推出

$$\begin{aligned}
\lim_{k\to\infty}P\{M(\hat{X},k)=i\}&=\sum_{j\in H_L}a_j\prod_{k=1}^{L}\left(\frac{1}{2}\right)\\
&=\sum_{j\in H_L}a_j\cdot\left(\frac{1}{2}\right)^L=\left(\frac{1}{2}\right)^L=\frac{1}{|H_L|}.
\end{aligned}$$

进而,如果 $\hat{X}$ 是在 H_L 上服从均匀分布,则有

$$\begin{aligned}
&P\{M(\hat{X},k)=i\}\\
&=\frac{1}{|H_L|}\sum_{j\in H_L}\prod_{m=1}^{L}[0.5+(\delta_{i_m j_m}-0.5)(1-2P_m)^k]
\end{aligned}$$

$$= \frac{1}{|\boldsymbol{H}_L|}\prod_{m=1}^{L}\sum_{i_m}[0.5+(\delta_{i_m j_m}-0.5)(1-2P_m)^k]$$

$$= \frac{1}{|\boldsymbol{H}_L|}\prod_{m=1}^{L}[0.5+0.5(1-2P_m)^k+0.5-0.5(1-2P_m)^k]$$

$$= \frac{1}{|\boldsymbol{H}_L|},$$

于是

$$\sum_{i\in \boldsymbol{H}_L}\left|P\{M(\hat{X},k+1)=i\}-\frac{1}{|\boldsymbol{H}_L|}\right|$$

$$= \sum_{i\in \boldsymbol{H}_L}\left|\sum_{j\in \boldsymbol{H}_L}a_j(k)\cdot\prod_{m=1}^{L}[P_m+\delta_{i_m j_m}(1-2P_m)]-\frac{1}{|\boldsymbol{H}_L|}\right|$$

$$= \sum_{i\in \boldsymbol{H}_L}\left|\sum_{j\in \boldsymbol{H}_L}\left[a_j(k)-\frac{1}{|\boldsymbol{H}_L|}\right]\prod_{m=1}^{L}[P_m+\delta_{i_m j_m}(1-2P_m)]\right|$$

$$\leqslant \sum_{i\in \boldsymbol{H}_L}\left|a_j(k)-\frac{1}{|\boldsymbol{H}_L|}\right|\sum_{j\in \boldsymbol{H}_L}\prod_{m=1}^{L}(P_m+\delta_{i_m j_m}(1-2P_m))$$

$$= \sum_{j\in \boldsymbol{H}_L}\left|a_j(k)-\frac{1}{|\boldsymbol{H}_L|}\right|$$

$$= \sum_{j\in \boldsymbol{H}_L}\left|P\{M(\hat{X},k)=j\}-\frac{1}{|\boldsymbol{H}_L|}\right|.$$

得证(1.119).

定理 1.8 说明：无论初始无限种群 $\hat{X}$ 如何分布，$M(\hat{X},k)$ 的极限分布都是均匀分布.于是，变异算子的反复作用可以等概率地搜索到 $\boldsymbol{H}_L$ 中的任何一个个体.这说明了变异算子对全空间的搜索能力.然而，我们应该注意到，变异算子对全空间个体遍历的速度却取决于变异概率 P_m 的大小，事实上，由(1.58)我们看到，如果 P_m 取很小值，则处于 X 邻近的个体总以很大概率被变异到.所以，变异算子的搜索域是 $\vec{X}$ 的邻域，该邻域的大小由变异概率 P_m 确定.

1.4.4 选择算子的搜索能力与速度

我们进而应用无限种群框架对选择算子的搜索能力与搜索速度作出刻画.

对于给定的无限种群 $\hat{X}$，令

$$\begin{cases}S(\hat{X},0)=\hat{X},\\ S(\hat{X},k)=S(S(\hat{X},k-1)),\quad k=1,2,\cdots\end{cases}\tag{1.120}$$

记

$$N_0 = \{i \in \boldsymbol{H}_L : a_i > 0\},$$
$$N_1 = \{i \in N_0 : J(i) = \max_{j \in N_0} J(j)\}.$$

定理 1.9(选择算子搜索能力刻画) 对任何 $i \in \boldsymbol{H}_L$ 成立

$$\bar{a}_i := \lim_{k \to \infty} P\{S(\hat{X}, k) = i\} = \begin{cases} \dfrac{a_i}{\sum\limits_{j \in N_1} a_j}, & i \in N_1, \\ 0, & i \notin N_1. \end{cases} \tag{1.121}$$

证明 我们首先证明 $S(\hat{X}, k)$的分布向量 $A(k) = (a_0(k), a_1(k), \cdots, a_{Q-1}(k))$满足

$$a_i(k) = \frac{a_i J^k(i)}{\sum\limits_{j \in \boldsymbol{H}_L} a_j J^k(j)}. \tag{1.122}$$

据比例选择的定义,(1.122)对于 $k=1$ 自然满足,若该式对指标 k 满足,则由定义(1.120)有

$$a_i(k+1) = P\{[S(\hat{X}, k)], \text{被选择}\} = \frac{a_i(k) J(i)}{\sum\limits_{j \in \boldsymbol{H}_L} a_j(k) J(j)} = \frac{a_i J^{k-1}(i)}{\sum\limits_{j \in \boldsymbol{H}_L} a_j J^{k+1}(j)},$$

于是(1.122)对任何指标 k 满足.

由(1.122)即得

$$\lim_{k \to \infty} P\{S(\hat{X}, k) = i\} = \lim_{k \to \infty} \frac{a_i J^k(i)}{\sum\limits_{j \in \boldsymbol{H}_L} a_j J^k(j)}$$
$$= \lim_{k \to \infty} \frac{a_i}{\sum\limits_{j \in \boldsymbol{H}_L} a_j \left(\dfrac{J(j)}{J(i)}\right)^k} = \begin{cases} \dfrac{a_i}{\sum\limits_{j \in N_1} a_j}, & i \in N_1, \\ 0, & i \notin N_1, \end{cases}$$

即定理 1.9 得证.

定理 1.9 说明,选择算子的反复作用使得种群集中分布在由种群所决定的最优个体上.下述定理进一步说明,这种集中的速度由种群规模和最大适应值与次最大适应值之差别程度决定.

定理 1.10(选择算子收敛速度) 设 $\hat{X}$是一个无限种群,其分布向量 A

满足

$$a_i = \begin{cases} \dfrac{1}{N}, & i \in N_0, \quad |N_0| = N, \\ 0, & i \notin N_0, \end{cases}$$

则

$$\sum_{i \in H_L} |P\{S(\hat{X}, k) = i\} - \bar{a}_i| \leqslant 2\left(\frac{N}{|N_1|} - 1\right)\lambda^{-k},$$

其中

$$\bar{a}_i = \begin{cases} \dfrac{1}{|N_1|}, & i \in N_1, \\ 0, & i \notin N_1, \end{cases}$$

$$\lambda = \min\left\{\frac{J_{\max}}{J(i)} : i \in N_0\right\}.$$

证明 首先易证

$$\frac{J_{\max}^k}{\sum_{j \in N_0}(J(j))^k} = \frac{J^k}{|N_1| J_{\max}^k + \sum_{j \notin N_1}(J(j))^k} \leqslant \frac{1}{|N_1|},$$

于是

$$\begin{aligned}
&\sum_{i \in H_L} |P\{S(\hat{X}, k) = i\} - a_i| \\
&= \sum_{i \notin N_1} |P\{S(\hat{X}, k) = i\}| + \sum_{i \in N_1}\left|\frac{J_{\max}^k}{\sum_{i \in N_0}(J(j))^k} - \frac{1}{|N_1|}\right| \\
&= \sum_{i \notin N_1} |P\{S(\hat{X}, k) = i\}| + |N_1|\left|\frac{1}{|N_1|} - \frac{J_{\max}^k}{\sum_{i \in N_0}(J(j))^k}\right| \\
&= 1 + \sum_{i \notin N_1} |P\{S(\hat{X}, k) = i\}| - \sum_{i \in N_1} |P\{S(\hat{X}, k) = i\}| \\
&= 2 - 2\sum_{i \in N_1} |P\{S(\hat{X}, k) = i\}| \\
&= 2 - 2|N_1| \frac{J_{\max}^k}{\sum_{j \in N_0}(J(j))^k} \\
&= 2 - \frac{2|N_1|}{|N_1| + \sum_{i \notin N_1}\left(\dfrac{J(i)}{J_{\max}}\right)^k} \\
&\leqslant 2 - \frac{2|N_1|}{|N_1| + (|N_0| - |N_0|)\lambda^{-k}}
\end{aligned}$$

$$\leqslant \frac{2(|N_0| - |N_1|)}{|N_1|}\lambda^{-k}$$

$$= 2\left(\frac{N}{|N_1|} - 1\right)\lambda^{-k},$$

即证定理 1.10.

常义的有限种群显然满足定理 1.10 的假设,于是该定理推出:在重复选择作用下,种群会趋于该种群的最优个体(在这些最优个体上均匀分布),且趋于最优个体的快慢由种群最优适应值与次最优适应值之比决定.

上述分析说明:仅选择算子作用不能保证搜索出问题的最优解,除非最优解包含在当前种群之中.

1.4.5 遗传算法的搜索机制

总结前几小节的分析,我们可得出如下结论:

(1)遗传算法是由选择、交叉与变异操作重复作用而定义的种群迭代过程.选择是在当前种群中进行的,选择的结果仍在当前种群;交叉是在当前种群 $\vec{X}(t)$所决定的极小模式 $\mathcal{H}(\vec{X}(t))$中进行的,交叉结果仍在 $\mathcal{H}(\vec{X}(t))$中;变异是在个体的邻域中进行的,变异结果仍在个体邻域.选择算子作用仅限于 $\vec{X}(t)$,交叉算子作用仅限于 $\mathcal{H}(\vec{X}(t))$,而变异算子作用突破 $\mathcal{H}(\vec{X}(t))$限制使搜索扩大到更大的空间.因此,选择和交叉的作用是在"子空间"上搜索,而变异的作用是不断地改变子空间,从而扩大搜索范围(原则上可以扩大到整个空间),交互作用的选择、交叉和变异三者结合构成遗传算法的完整搜索机制.

(2)如果无变异作用,则遗传算法的精确搜索可达域是由初始种群 $\vec{X}(0)$所决定的极小模式 $\mathcal{H}(\vec{X}(t))$.所以,此时的遗传算法能找到问题的全局最优解当且仅当 $\mathcal{H}(\vec{X}(0))$含最优解.

(3)如果说选择与交叉算子是局部搜索算子,则变异算子可认为是全局搜索算子(因为它的作用在于扩大搜索空间,使遗传算法能在全空间搜索).由于如此,变异算子在遗传算法中的作用是不可低估的.特别是,从保证收敛性的角度,在遗传算法的运行初期应用大的变异概率,而在运行后期应用小的变异概率显然是有利的.

§1.5 遗传算法的收敛性理论

本节介绍遗传算法的各种收敛性定义、典型的收敛性分析方法(模型)及相关的遗传算法收敛性结果.

1.5.1 种群序列的收敛性定义及性质

设 $\boldsymbol{H}_L^N$ 为种群空间，P 为 $\boldsymbol{H}_L^N$ 上的概率分布，$\{\vec{X}(t)\}$ 是遗传算法所生成的种群序列，B^* 是问题(1.5)的最优解集，J^* 是相应的最优适应值.

定义 1.17（依概率收敛） 种群序列 $\{\vec{X}(t)\}$ 称为**依概率弱收敛**到最优解集 B^*，如果

$$\lim_{t\to\infty} P\{\vec{X}(t)\cap B^*\neq\varnothing\}=1. \tag{1.123}$$

$\{\vec{X}(t)\}$ 称为**依概率强收敛**到 B^*，如果

$$\lim_{t\to\infty} P\{\vec{X}(t)\subseteq B^*\}=1. \tag{1.124}$$

定义 1.18（几乎必然收敛） 种群序列 $\{\vec{X}(t)\}$ 称为**几乎必然(a.s.)弱收敛**到最优解集 B^*，如果

$$P\{\lim_{t\to\infty}[\vec{X}(t)\cap B^*]\neq\varnothing\}=1. \tag{1.125}$$

$\{\vec{X}(t)\}$ 称为**几乎必然(a.s.)强收敛**到 B^*，如果

$$P\{\lim_{t\to\infty}[\vec{X}(t)\subseteq B^*]\}=1. \tag{1.126}$$

定理 1.11 种群序列 $\{\vec{X}(t)\}$ 的上述四种收敛性有以下关系：

(1) 几乎必然强收敛⇒几乎必然弱收敛→概率弱收敛.

(2) 几乎必然强收敛→概率强收敛⇒概率弱收敛.

证明 注意到事实

$$[\vec{X}(t)\subseteq B^*]\Rightarrow[\vec{X}(t)\cap B^*\neq\varnothing],$$

我们推出

$$P\{[\vec{X}(t)\subseteq B^*]\}\leqslant P\{[\vec{X}(t)\cap B^*\neq\varnothing]\},$$

于是(1.124)⇒(1.123)，(1.126)⇒(1.125). 另一方面，由于

$$\lim_{t\to\infty}[\vec{X}(t)\cap B^*\neq\varnothing]=\bigcup_{t=1}^{\infty}\bigcap_{k=t}^{\infty}[\vec{X}(k)\cap B^*\neq\varnothing],$$

根据概率的单调性，我们有

$$\begin{aligned}P\{\lim_{t\to\infty}[\vec{X}(t)\cap B^*\neq\varnothing]\}&\leqslant\lim_{t\to\infty}P\{\bigcap_{k=t}^{\infty}[\vec{X}(k)\cap B^*\neq\varnothing]\}\\&\leqslant\lim_{t\to\infty}P\{[\vec{X}(k)\cap B^*\neq\varnothing]\},\end{aligned}$$

从而(1.125)⇒(1.123). 同理有(1.126)⇒(1.124).

遗传算法种群序列 $\{\vec{X}(t)\}$ 的收敛性自然与其个体的适应值序列的收敛性相联系，因而我们再引进下列定义.

定义 1.19 设 $\{f_t\}$ 是定义在 $\boldsymbol{H}_L$ 上的实值随机变量序列，称 $\{f_t\}$ **依概率收敛**到 f^*，若对任意 $\varepsilon>0$ 有

$$\lim_{t\to\infty} P\{|f_n-f^*|\leqslant\varepsilon\}=1.$$

称$\{f_n\}$**几乎必然收敛到** f^*,若

$$P\{\lim_{t\to\infty} f_n = f^*\} = 1.$$

给定种群 $\vec{X}=(X_1, X_2, \cdots, X_N)\in \boldsymbol{H}_L^N$,它的**最优个体集** $B(\vec{X})$与**最差个体集** $D(\vec{X})$分别定义为

$$B(\vec{X}) = \{X_i \in \vec{X} \mid J(X_i) = \max_{1\le j\le N} J(X_j)\},$$

$$D(\vec{X}) = \{X_i \in \vec{X} \mid J(X_i) = \min_{1\le j\le N} J(X_j)\}.$$

定义1.20 给定种群序列$\{\vec{X}(t)\}$,并取$b(t)\in B(\vec{X}(t))$, $d(t)\in D(\vec{X}(t))$,则序列$\{J(b(t))\}$称为是$\{\vec{X}(t)\}$的**优值序列**,$\{J(d(t))\}$称为是$\{\vec{X}(t)\}$的**劣值序列**.

$\{\vec{X}(t)\}$的优值序列与劣值序列都是实值随机变量序列,它们可等价地用以刻画种群序列$\{\vec{X}(t)\}$的收敛性.

定理 1.12 (1) 种群序列$\{\vec{X}(t)\}$依概率弱收敛到最优解集 B^*当且仅当存在优值序列$\{J(b(t))\}$使它概率收敛到最优适应值 J^*.

(2)$\{\vec{X}(t)\}$依概率强收敛到最优解集B^*当且仅当任何劣值序列$\{J(d(t))\}$依概率收敛到最优适应值 J^*.

(3)$\{\vec{X}(t)\}$几乎必然弱收敛到最优解集B^*当且仅当存在优值序列$\{J(b(t))\}$使几乎收敛到最优适应值 J^*.

(4)$\{\vec{X}(t)\}$几乎强收敛到最优解集B^*当且仅当任何劣值序列$\{J(d(t))\}$几乎收敛到最优适应值 J^*.

证明 由于 $\boldsymbol{H}_L$ 是有限的,在 $\boldsymbol{H}_L$ 上适应值J 也是有限的,所以对于充分大的 t 有

$$\vec{X}(t)\cap B^* \neq \varnothing \Leftrightarrow \exists\, b(t)\in B(\vec{X}(t)), b(t)\in B^*$$
$$\Leftrightarrow \exists\, b(t)\in B(\vec{X}(t)), J(b(t)) = J^*,$$
$$\vec{X}(t)\subseteq B^* \Leftrightarrow \text{任何 } d(t)\in D(\vec{X}(t)), d(t)\in B^*$$
$$\Leftrightarrow \text{任何 } d(t)\in D(\vec{X}(t)), J(d(t)) = J^*.$$

根据定义 1.5.1~1.5.4,定理结论易证.

对于种群 $\vec{X}=(X_1, X_2, \cdots, X_N)\in \boldsymbol{H}_L^N$,称

$$J_{av}(\vec{X}) = \frac{1}{N}\sum_{i=1}^{N} J(X_i)$$

为 $\vec{X}$ 的**平均适应值**;相应地,对于种群序列$\{\vec{X}(t)\}$,称

$$J_{av}(t) = J_{av}(\vec{X}(t)) = \frac{1}{N}\sum_{i=1}^{N} J(X_i(t))$$

为**种群平均适应值序列**.

定理 1.13 $\{\vec{X}(t)\}$几乎必然强收敛到最优解集 B^*当且仅当它相应的

种群平均适应值序列几乎必然收敛到最优值 J^*；$\{\vec{X}(t)\}$ 依概率强收敛到最优解集 B^* 当且仅当相应的种群平均适应值序列依概率收敛到最优值 J^*.

证明 由于 $\boldsymbol{H}_I^{\wedge}$ 有限，$\{J_{av}(t)\,|\,J_{av}(t)=J_{av}(\vec{X}(t))\}$ 为有限集，于是 $J_{av}(t)=J^*$ 等价于 $\vec{X}(t)\subseteq B^*$（当 t 充分大时），则证.

以下几节，我们基于以上所定义的收敛性来考察遗传算法的收敛性质.

1.5.2 遗传算法的马氏链分析

遗传算法是不断重复选择、交叉与变异的过程，每一种遗传操作都仅与当前状态相关，而与以前的状态无关，因此遗传算法可描述作一马尔可夫链(Markov chain)，从而其收敛性可应用马尔可夫链理论加以研究.

1.5.2.1 马氏链的定义及相关性质

我们首先回顾有关马氏链的定义.

定义 1.21（马氏链） 设 $\{\hat{X}_n: n\geqslant 0\}$ 为一列取值离散的随机变量，离散值的全体记为 $\boldsymbol{H}_L=\{j\}$，称 $\boldsymbol{H}_L$ 为**状态空间**. 若对任意 $n\geqslant 1$，$i_k\in\boldsymbol{H}_L(k\leqslant n+1)$ 有

$$P\{\hat{X}_{n+1}=i_{n+1}/\hat{X}_n=i_n,\cdots,\hat{X}_0=i_0\}=P\{\hat{X}_{n+1}=i_{n+1}/\hat{X}_n=i_n\},\tag{1.127}$$

则称 $\{\hat{X}_n: n\geqslant 0\}$ 为**马氏链**(或**马尔可夫链**).

性质(1.127)是指 $\{\hat{X}_n\}$ 取值的无后效性，其作用在于简化条件概率的计算. 例如，利用这一性质可得

$$\begin{aligned}
&P\{\hat{X}_{n+2}=i_{n+2},\hat{X}_{n+1}=i_{n+1}/\hat{X}_n=i_n\}\\
&=P\{\hat{X}_{n+1}=i_{n+1}/\hat{X}_n=i_n\}\cdot P\{\hat{X}_{n+2}=i_{n+2}/\hat{X}_{n+1}=i_{n+1},\hat{X}_n=i_n\}\\
&=P\{\hat{X}_{n+1}=i_{n+1}/\hat{X}_n=i_n\}\cdot P\{\hat{X}_{n+2}=i_{n+2}/\hat{X}_{n+1}=i_{n+1}\}.
\end{aligned}$$

定义 1.22 对任何正整数 m,n，记马氏链 $\{\hat{X}_n\}$ 在 m 时刻处于状态 i 且经过 n 步转移到状态 j 的概率为

$$P_{ij}(m,n)=P\{\hat{X}_{m+n}=j/\hat{X}_m=i\}.$$

如果上述转移概率与时刻 m 无关，即 $P_{ij}(m,n)\equiv P_{ij}^{(n)}$，则称马氏链 $\{\hat{X}_n\}$ 是**齐次的**. 在这种情形，称 $P_{ij}^{(n)}$ 为马氏链 $\{\hat{X}_n\}$ 的 **n 步转移概率**. 由 $\{\hat{X}_n\}$ 的一步转移概率 $P_{ij}^{(1)}$ 所组成的矩阵

$$\boldsymbol{P}=(P_{ij}^{(1)})\tag{1.128}$$

称为是$\{\hat{X}_n\}$的**转移概率矩阵**.

对于齐次马氏链而言,它的任何步转移概率可由它的一步转移概率惟一确定.事实上,对任何 $n, m \geqslant 0, i, j \in \boldsymbol{H}_L$,由$\{\hat{X}_n\}$的齐次性知

$$\begin{aligned} P_{ij}^{(n+m)} &= P\{\hat{X}_{n+m} = j / \hat{X}_0 = i\} \\ &= \sum_{k \in \boldsymbol{H}_L} P\{\hat{X}_{n+m} = j / \hat{X}_n = k, \hat{X}_0 = i\} P\{\hat{X}_n = k / \hat{X}_0 = i\} \\ &= \sum_{k \in \boldsymbol{H}_L} P\{\hat{X}_n = k / \hat{X}_0 = i\} P\{\hat{X}_{n+m} = j / \hat{X}_n = k\} \\ &= \sum_{k \in \boldsymbol{H}_L} P_{ik}^{(n)} P_{kj}^{(m)}, \end{aligned}$$

由此可推得$\{\hat{X}_n\}$的二步转移概率矩阵$(P_{ij}^{(2)}) = \mathbf{P}^2$,三步转移概率矩阵$(P_{ij}^{(3)}) = \mathbf{P}^3, \cdots, n$ 步转移概率矩阵$(P_{ij}^{(n)}) = \mathbf{P}^n$,等等.于是,如令初始分布

$$p^{(0)} = (p_0^{(0)}, p_1^{(0)}, \cdots, p_{|\boldsymbol{H}_L|-1}^{(0)}),$$

其中 $p_i^{(0)} = P\{\hat{X}_0 = i\}$,则 $\hat{X}_n$ 的分布为

$$p^{(n)} = p^{(0)} \mathbf{P}^n. \tag{1.129}$$

定义 1.23 设$\{\hat{X}_n\}$为有限齐次马氏链,$p_{ij}^{(n)}$为 n 步转移概率,如果存在某个 $n_0 \geqslant 1$ 使得 $p_{ij}^{(n_0)} > 0$,则称**状态 i 可达状态 j**,记为 $i \to j$.否则称 i **不达** j,记作 $i \not\to j$.若有 $i \to j$ 和 $j \to i$ 同时成立,称 i **与 j 互通**,记作 $i \leftrightarrow j$.

互通关系是一个等价关系,即 $i \leftrightarrow j, j \leftrightarrow k$,则 $i \leftrightarrow k$.按互通关系可把 $\boldsymbol{H}_L$ 中的全部状态进行分类.

定义 1.24 若 $i \to j$ 时必有 $j \to i$,则称 i 为**本质状态**;若存在 j 使 $i \to j$ 但 $j \not\to i$,则称 i 为**非本质状态**.

同一类中的状态或全为本质的(本质类),或全为非本质的(非本质类).本质类中的状态不可能达到别的类中,非本质类状态可能达到别的类,不过一旦进入本质类便不再返回.

定义 1.25 $\boldsymbol{H}_L$ 中的子集 C 称为是**闭的**,若对任意 $i \in C$ 有

$$\sum_{j \in C} P_{ij} = 1,$$

即 C 中状态 i 不可到达 C 外状态.

显然本质类是闭集,非本质类不是闭集.若闭集 C 中不存在真闭子集,则称 C 为**最小闭集**.若 $\boldsymbol{H}_L$ 中不存在真闭子集,则称 $\boldsymbol{H}$ **是不可约的**.

例如,一个马氏链$\{\hat{X}_n\}$具有概率转移矩阵

$$\boldsymbol{P}=\begin{pmatrix}0.5 & 0.5 & 0 & 0\\ 0 & 0.5 & 0.5 & 0\\ 0 & 0 & 0.5 & 0.5\\ 0 & 0 & 0.5 & 0.5\end{pmatrix},$$

则状态集 $C=\{3,4\}$ 是闭集，而 $F=\{1,2\}$ 是非本质类. 于是

$$\boldsymbol{H}_l = C \cup F.$$

一般来说，任何马氏链的状态集可分解为闭集 C 和非本质类 F，而闭集 C 可以进一步分解为有限个本质类之并.

$\boldsymbol{H}_l$ 中的状态 i 称为是**常返的**，是指它从 i 出发必然在有限时间内返回 i（其实也必然无限次返回 i）. 对于一个常返状态，如果它的平均返回时间是有限的，则称该状态是**正常返的**，否则称为是**零常返的**. 一个常返状态必然是本质状态，而且如果 i 是一个常返状态，$i\to j$，则 j 也必是常返状态. 所以常返状态是类的性质，即同一类的状态或都是常返的，或都是非常返的. 常返类中任意一个状态出发必须无限次经过类中任何一个状态，而与此相反，非常返类中任何一个状态出发，只能有限次经过类中任意一个状态. 对于有限马氏链来说，非常返类必为非本质类，常返类也必为本质类，而且由于返回 i 的平均时间必然是有限的，从而常返类也必是正常返类. 于是，任何一个有限状态的马氏链其状态空间可分解为有限个正常返类（本质类）和一个非常返类（非本质类）. 对于不可约的有限状态马氏链其状态空间不可分解，本身是一个正常返类.

上述分解可通过 $\{\hat{X}_n\}$ 的概率转移矩阵 $\boldsymbol{P}$ 表达得更为直观. 事实上，假定有限齐次马氏链 $\{\hat{X}_n\}$ 的状态空间 $\boldsymbol{H}_l$ 可分解为 m 个正常返类（本质类）和一个非常返类 F（非本质类），则经过合适置换，$\boldsymbol{P}$ 必然具有形式

$$\boldsymbol{P}=\begin{pmatrix}\boldsymbol{U} & \boldsymbol{O}\\ \boldsymbol{V} & \boldsymbol{W}\end{pmatrix}=\begin{pmatrix}\boldsymbol{U}_1 & 0 & 0 & \cdots & 0 & 0\\ 0 & \boldsymbol{U}_2 & 0 & \cdots & 0 & 0\\ \vdots & \vdots & \ddots & & \vdots & \vdots\\ 0 & 0 & 0 & \ddots & 0 & 0\\ 0 & 0 & 0 & & \boldsymbol{U}_m & 0\\ \boldsymbol{Q}_1 & \boldsymbol{Q}_2 & \boldsymbol{Q}_3 & \cdots & \boldsymbol{Q}_m & \boldsymbol{W}\end{pmatrix},$$

其中 $\boldsymbol{U}_i(i=1,2,\cdots,m)$，$\boldsymbol{W}$ 是方阵，而且每一个 $\boldsymbol{U}_i$ 都是随机矩阵（换言之，元素在[0,1]之间且行和为 1）. 每一个 $\boldsymbol{U}_i$ 所对应的空间状态构成一个正常返类 C_i，它满足：$\forall k\in C_i$

$$\sum_{j\in C_i} p_{kj}=1 \quad (\text{即 } \boldsymbol{U}_i=(p_{kj},k,j\in \boldsymbol{C}_i) \text{ 为随机矩阵});$$

而 W 所对应的空间状态构成一个非常返类 F,它满足:$\forall k \in F$,

$$\sum_{j \in F} p_{ij} \neq 1, \quad \sum_{j \in H_L} p_{ij} = 1.$$

定义 1.26(本原矩阵) 一个随机矩阵 P 称为是**本原的**,如果存在 $k \geqslant 1$ 使 $P^k > 0$(即 P^k 的每一元素大于 0).

本原矩阵的一个重要性质是:对任何本原阵 P,必存在一个平稳分布 π 使 $\pi^{\mathrm{T}} P = \pi^{\mathrm{T}}$,亦即对任何 $j \in H_L$ 有

$$\sum_i \pi_i p_{ij} = \pi_j > 0, \quad \pi = (\pi_1, \pi_2, \cdots, \pi_{H_L})^{\mathrm{T}}.$$

下述定理 1.13 将说明,非周期的不可约有限状态马氏链其概率转移矩阵一定是本原的.

定义 1.27(状态的周期) 对于马氏链的任何状态 i,正整数集 $\{n \geqslant 1 \mid p_{ii}^{(n)} > 0\}$ 的最大公因子 d_i 称为是状态 i 的**周期**.若 $d_i > 1$,称状态 i 是**周期的**,如 $d_i = 1$,则称状态 i 是**非周期的**.

利用简单的整除性质可证明:如果状态 i 与状态 j 是相通的,换言之,$i \leftrightarrow j$,则 i 与 j 必有相同的周期.

定理 1.14 如果马氏链是不可约的,且存在 $j \in [1, |H_L|]$ 使 $p_{jj}^{(1)} > 0$,则该马氏链是非周期的,其概率转移矩阵是本原的,存在平稳分布.

证明 由于 $p_{jj}^{(1)} > 0$,依定义 1.5.11,$d_j = 1$.从而 j 是非周期的(周期为 1).而由于所考虑的马氏链是不可约的,所有状态之间互通,于是 H_L 中的所有状态也是非周期的.由于对于任意状态 i,$i \leftrightarrow j$,故存在 n_{ij} 和 n_{ji} 使 $p_{ij}^{n_{ij}} > 0$ 且 $p_{ji}^{(n_{ji})} > 0$,于是

$$p_{ij}^{n_{ij}+n_{ji}} = \sum_{k \in H_L} p_{ik}^{(n_{ij})} p_{kj}^{(n_{ji})} \geqslant p_{ij}^{(n_{ij})} p_{ji}^{(n_{ji})} > 0,$$

且有

$$p_{ii}^{(n_{ij}+n_{ji}+n)} \geqslant p_{ii}^{(n_{ij})} p_{jj} p_{jj} \cdots p_{jj} p_{ji}^{(n_{ji})} > 0.$$

取 $N_0 = \max\{n_{ij} + n_{ji} : i, j = 1, 2, \cdots, |H_L|\}$,则当 $k \geqslant N_0$ 时有 $p_{ii}^{(k)} > 0$.这即说明 P 是本原矩阵,从而存在平稳分布.

定理 1.15 非周期不可约有限状态的马氏链存在平稳分布.

证明 设 P 是所述马氏链的概率转移矩阵.由于马氏链是不可约的,H_L 中的所有状态是正常返的,而且是互通的.又由假设,马氏链是非周期的,从而对任何 i,$\{n \geqslant 1, p_{ii}^{(n)} > 0\}$ 的最大公因子是 1,于是存在 n_i 使当 $n \geqslant n_i$ 时,$p_{ii}^{(n)} > 0$.取 $N_0 = \max_{1 \leqslant i \leqslant |H_L|} \{n_i\}$,则当 $n \geqslant N_0$ 时,对任何 i 有 $p_{ii}^{(n)} > 0$.由于 $i \leftrightarrow j$,存在 n_{ij} 使 $p_{ij}^{(n_{ij})} > 0$,故当 $n \geqslant N_0$ 时,$p_{ij}^{(n_{ij}+n)} > 0$.取

$$K = N_0 + \max_{i,j} |n_{ij}|,$$

则对任意 $i,j \in \{1,2,\cdots,|\boldsymbol{H}_L|\}$，只要 $k \geqslant K$，总有 $p_{ij}^{(n)} > 0$. 这说明 $\boldsymbol{P}$ 是本原矩阵，于是由本原矩阵性质，所述马氏链存在平稳分布.

进而，可证明非周期不可约马氏链总存在极限分布，这一极限分布恰好给出马氏链的平稳分布，即有

定理 1.16 任何非周期不可约有限状态马氏链 $\{\hat{X}_n\}$ 存在极限分布 π：

$$\lim_{n\to\infty} P\{\hat{X}_n = j\} = \pi_j > 0 (j = 0,1,\cdots,|\boldsymbol{H}_L|),$$

此极限分布是 $\{\hat{X}_n\}$ 的平稳分布，而且与初始分布无关.

该定理的证明可参见[126].

1.5.2.2 标准遗传算法的马氏链分析

我们现在应用马氏链工具来分析标准遗传算法的收敛性态.

假设 $\boldsymbol{H}_L = \{0,1\}^l$ 是个体空间，$\boldsymbol{H}_L^N$ 是种群空间，$\vec{X}(t)$ 是遗传算法所生成的第 t 代种群，则根据定理 1.2－定理 1.3，标准遗传算法的种群生成过程为：

(1) $t=0$ 时随机选取初始种群 $\vec{X}(0)$.

(2) 对于第 t 步 $(t>0)$，在 $\vec{X}(t)$ 中按以下分布独立地选择 N 对母体

$$P\{S(\vec{X}(t)) = (Y_1^{(k)}, Y_2^{(k)})\} = \begin{cases} J(Y_1^{(k)})J(Y_2^{(k)}) \Big/ \left(\sum_{X\in\vec{X}(t)} J(X)\right)^2, & (Y_1^{(k)}, Y_2^{(k)}) \in \vec{X}(t), \\ 0, & \text{否则}. \end{cases} \tag{1.130}$$

(3) 对所选择的 N 对母体进行单点随机交叉，即令

$$P\{C(Y_1^{(k)}, Y_2^{(k)}) = X'_k(t+1)\} = \begin{cases} (1-P_c) + \dfrac{kP_c}{L}, & X'_k(t+1) = Y_1^{(k)}, \\ kP_c/L, & X'_k(t+1) \neq Y_1^{(k)} \text{ 且 } X'_k(t+1) = AY_1^{(k)} + (I-A)Y_2^{(k)}, \\ 0, & \text{其他}, \end{cases} \tag{1.131}$$

这里 P_c 是交叉概率 $(0<P_c\leqslant 1)$，A 是一对角矩阵，它的前 r 个对角元素为 1 而其他元素为 0，r 为交叉点位置.

(4) 对交叉所生成的中间种群 $\vec{X}'(t+1) = (X'_1(t+1), X'_2(t+1), \cdots, X'_N(t+1))$ 通过点变异生成子代种群

$$\vec{X}(t+1) = (X_1(t+1), X_2(t+1), \cdots, X_N(t+1)),$$

其中

$$P\{M(X'_i(t+1)) = X_i(t+1)\}$$

$$= P_m^{d(X_i(t+1),X_j(t+1))}(1-P_m)^{L-d(X_i(t+1),X_j(t+1))}. \tag{1.132}$$

记

$$T = M \circ C \circ S,$$

则标准遗传算法的种群序列$\{\vec{X}(t)\}$满足

$$\vec{X}(t+1) = T\vec{X}(t) = M \circ C \circ S(\vec{X}(t)). \tag{1.133}$$

定理 1.17 标准遗传算法所生成的种群序列$\{\vec{X}(t)\}$是有限、齐次、不可约、非周期的马氏链.

证明 由于$\boldsymbol{H}_L$中有2^L个个体，种群空间$\boldsymbol{H}_L^N$中有2^N个个体，$\boldsymbol{H}_L^N$是种群序列$\{\vec{X}(t)\}$的状态空间，从而有限. 由于在(1.133)中操作M, X, S均与t无关，且$\vec{X}(t+1)$仅与$\vec{X}(t)$有关，故$\{\vec{X}(t)\}$为有限状态马氏链. 由于

$$\begin{aligned} & P\{(T\vec{X}(t))_k = X_k(t+1)\} \\ = & \sum_{X'_k(t+1)\in \boldsymbol{H}_L} \sum_{(Y_1^{(k)}(t),Y_2^{(k)}(t))\in \boldsymbol{H}_L^2} P\{(Y_1^{(k)}(t), Y_2^{(k)}(t)) \in S(\vec{X}(t))\} \\ & \cdot P\{C(Y_1^{(k)}(t), Y_2^{(k)}(t)) = X'_k(t+1)\} \\ & \cdot P\{M(X'_k(t+1)) = X_k(t+1)\}, \end{aligned} \tag{1.134}$$

而且对任意$\vec{X}(t)\in \boldsymbol{H}_L^N$，均存在$(Y_1^{(k)}(t), Y_2^{(k)}(t))\in \boldsymbol{H}_L^2$及$X'_k(t+1)$使得

$$P\{(Y_1^{(k)}(t), Y_2^{(k)}(t)) \in S(\vec{X}(t))\} > 0, \tag{1.135}$$

$$P\{C(Y_1^{(k)}(t), Y_2^{(k)}(t)) = X'_k(t+1)\} > 0, \tag{1.136}$$

$$P\{M(X'_k(t+1)) = X_k(t+1)\} > 0, \tag{1.137}$$

于是

$$P\{(T\vec{X}(t))_k = X_k(t+1)\} > 0. \tag{1.138}$$

由(1.130)～(1.132)知(1.135)，(1.136)和(1.137)均与t无关，从而(1.138)之概率也与t无关，于是

$$\begin{aligned} & P\{T(\vec{X}(t)) = \vec{X}(t+1)\} \\ = & \prod_{i=1}^{N} P\{(T\vec{X}(t))_k = X_k(t+1)\} > 0, \end{aligned}$$

且也与t无关. 这说明$\{\vec{X}(t)\}$是齐次的，不可约的和非周期的.

应用定理 1.15，我们立即得到下述结论.

定理 1.18（标准 GA 的不收敛性，带杰出者记录策略 GA 的收敛性） 设$\{\vec{X}(t)\}$是由标准遗传算法所生成的种群序列，则

(1) $\{\vec{X}(t)\}$存在极限、平稳分布$\pi(\vec{Y})$.

(2) 若初始种群$\vec{X}(0)$不包含最优个体（即$\vec{X}(0)\cap B^* = \varnothing$），则

$$\lim_{t\to\infty} P\{\vec{X}(t)\cap B^* \neq \varnothing\} < 1. \tag{1.139}$$

(3) 若$\{X^*(t)\}$是带杰出者记录策略 GA 所产生的“杰出者”序列，则

$$P\{\lim_{t\to\infty} X^*(t) \subseteq B^*\} = 1. \tag{1.140}$$

证明 根据定理 1.17，$\{\vec{X}(t)\}$是有限齐次不可约非周期的马氏链，从而由定理 1.16，它存在极限分布 $\pi(\vec{Y})$：

$$\lim_{t\to\infty} P\{\vec{X}(t) = \vec{Y}\} = \pi(\vec{Y}), \tag{1.141}$$

而且这一极限分布也是平稳分布，即满足

$$\sum_{\vec{Y}\in \boldsymbol{H}_L^N} \pi(\vec{Y}) P\{\vec{X}(1) = \vec{Z} / \vec{X}(0) = \vec{Y}\} = \pi(\vec{Z}).$$

这即(1)成立.

(2) 取 $\vec{Y} = \vec{X}(0)$，则由(1.141)知

$$\begin{aligned}
&\lim_{t\to\infty} P\{\vec{X}(t) \cap B^* \neq \varnothing\} \\
&= 1 - \lim_{t\to\infty} P\{\vec{X}(t) \cap B^* = \varnothing\} \\
&\leqslant 1 - \lim_{t\to\infty} P\{\vec{X}(t) = \vec{X}(0)\} \\
&= 1 - \pi(\vec{X}(0)) < 1.
\end{aligned}$$

(3) 由于此时状态空间 $\boldsymbol{H}_L^N$ 是正常返的，故它以概率 1 保证$\{\vec{X}(t)\}$可以达到 $\boldsymbol{H}_L^N$ 中任何状态无限多次，特别对任何 $X^* \in B^*$，齐次种群$[X^*]$也可以无限次达到，这自然推出(1.140)成立.

上述定理 1.18 说明：标准遗传算法虽然在分布意义下是收敛的，但并不保证概率收敛性，尽管如此，带杰出者记录策略的遗传算法却总能几乎必然收敛.

我们将在下小节说明，不同于标准遗传算法，杰出者选择遗传算法能保证以概率收敛到问题(1.1)的最优解.

1.5.2.3 杰出者选择与父子混合选择遗传算法的概率收敛性

杰出者选择遗传算法是标准遗传算法的一个简单修正，其惟一差别在于无条件保留上一代种群的最优个体到下一代种群，其运行过程见 1.3.1 节所述.

定理 1.19（杰出者选择 GA 的收敛性） 设$\{\vec{X}(t)\}$是杰出者选择遗传算法所产生的种群序列，B^*是问题(1.5)的最优解集，记

$$\begin{aligned}
B_0 = \{\vec{Y} = (Y_1, Y_2, \cdots, Y_N) \in \boldsymbol{H}_L^N \mid \\
Y_i \in \boldsymbol{H}_L, 1 \leqslant i \leqslant N-1, Y_N \in B^*\},
\end{aligned}$$

则

(1) $\{\vec{X}(t)\}$是 $\boldsymbol{H}_L^N$ 上的有限齐次马氏链；

(2) $\{\vec{X}(t)\}$依概率 1 收敛到种群集 B_0，即

$$\lim_{t\to\infty} P\{\vec{X}(t) \in B_0\} = 1.$$

证明 根据杰出者选择遗传算法的定义(参见1.3.1节),它与标准遗传算法的不同仅在于种群的第N个个体,换言之,依(1.133)的记号,我们有$\vec{X}(t)=(X_1(t),X_2(t),\cdots,X_N(t))$满足

$$\begin{cases} X_i(t+1)=(TX(t))_i, & i=1,2,\cdots,N-1, \\ X_N(t+1)=X^*(t), \end{cases} \tag{1.142}$$

由此易知$\{\vec{X}(t)\}$是有限状态马氏链.该马氏链的状态转移矩阵是

$$P\{\vec{X}(t+1)=\vec{Y}/\vec{X}(t)=\vec{X}\}$$

$$=\begin{cases} \prod_{k=1}^{N} P\{(T\vec{X}(t))_k=Y_k\}, & \text{存在 } i_0\in B(\vec{X}) \text{ 使 } Y_N=X_{i_0}, \\ 0, & \text{否则}, \end{cases}$$

其中

$$B(\vec{X})=\{i: J(X_i)=\max_{1\le j\le N} J(X_j)\}.$$

由此看到它与时间t无关,因而$\{\vec{X}(t)\}$是齐次的.下记$\{\vec{X}(t)\}$的转移概率为

$$P\{\vec{X},\vec{Y}\}=P\{\vec{X}(t+1)=\vec{Y}/\vec{X}(t)=\vec{X}\}.$$

由(1.142)知,$\{\vec{X}(t)\}$的转移概率具有以下性质:

(1) 当$\vec{X},\vec{Y}\in B_0$时,$P\{\vec{X},\vec{Y}\}>0$,$P\{\vec{Y},\vec{X}\}>0$,从而$\vec{X}$与$\vec{Y}$互通;

(2) 当$\vec{X}\in B_0$,$\vec{Y}\notin B_0$时,$P\{\vec{X},\vec{Y}\}=0$,即$\vec{X}\not\to\vec{Y}$.

这说明B_0是$\{\vec{X}(t)\}$的正常返非周期的不可约闭集,而$\boldsymbol{H}_L^N\setminus B_0$是非常返的状态集.于是

$$\lim_{t\to\infty} P\{\vec{X}(t)=\vec{Y}\}=\begin{cases} \pi(\vec{Y}), & \vec{Y}\in B_0, \\ 0, & \vec{Y}\notin B_0, \end{cases}$$

即

$$\lim_{t\to\infty} P\{\vec{X}(t)\in B_0\}=1.$$

定理1.19说明杰出者选择遗传算法是依概率弱收敛的.

定理1.20(父子混合选择GA的收敛性) 父子混合选择遗传算法依概率弱收敛到问题(1.5)的最优解集.

证明 设$\{\vec{X}_e(t)\}$是由杰出者选择GA所生成的有限状态马氏链,$\{\vec{X}_{fse}(t)\}$是由父子混合选择GA所生成的有限状态马氏链,则由定理1.19,$\{\vec{X}_e(t)\}$是依概率弱收敛的,即

$$\lim_{t\to\infty} P\{\vec{X}_e(t)\cap B^*\neq\varnothing\}=1.$$

于是,由定理1.12,存在$\{\vec{X}_e(t)\}$的优值序列$\{J(b_e(t))\}$使它概率收敛到(1.5)的最优值J^*,即

$$\lim_{t\to\infty} P\{|J(b_e(t))-J^*|\le\varepsilon\}=1$$

现令 $b_{f\mathscr{C}_s}(t)\in B(\vec{X}_{f\mathscr{C}_s}(t))$ 是种群 $\vec{X}_{f\mathscr{C}_s}(t)$ 中的最优个体，则显然 $\{J(b_{f\mathscr{C}_s}(t))\}$ 是 $\{\vec{X}_{f\mathscr{C}_s}(t)\}$ 的一个优值序列，而且据父子混合选择的定义，必有

$$J(b_e(t))\leqslant J(b_{f\mathscr{C}_s}(t))\leqslant J^*,$$

于是

$$\begin{aligned}&\lim_{t\to\infty}P\{|J(b_{f\mathscr{C}_s}(t))-J^*|\leqslant\varepsilon\}\\ \geqslant&\lim_{t\to\infty}P\{|J(b_e(t))-J^*|\leqslant\varepsilon\}=1,\end{aligned}$$

即 $\lim_{t\to\infty}P\{|J(b_{f\mathscr{C}_s}(t))-J^*|\leqslant\varepsilon\}=1$. 依定理 1.12，从而 $\{\vec{X}_{f\mathscr{C}_s}(t)\}$ 依概率弱收敛到问题(1.5)的最优解集.

1.5.3 遗传算法的公理化分析

上节所给出的遗传算法马氏链分析只适用于齐次(非时变)遗传算法(换言之，所涉及的选择与繁殖算子不随时间改变). 本节介绍**分**析遗传算法的另一种方法——公理化方法. 这一分析方法基于对模拟进化计算操作的公理化描述，并应用各相关操作的本质特征数来对算法的收敛性直接作出概率估计. 这一方法不仅适用于包括非齐次、自适应等在内的各种遗传算法分析，而且分析方法本身直观、清晰，所导出的结论也对遗传算法的各种参数选择提供参考依据.

1.5.3.1 进化算子的特征数

回忆，在 1.2.1 节我们已经将任何一个模拟进化算法 SEA 抽象地表述作随机过程

$$\vec{X}(t+1)=E\circ S\vec{X}(t),\quad t=0,1,\cdots,$$

其中 $E:\boldsymbol{H}_L^M\to\boldsymbol{H}_L^N$ 是繁殖算子，$S:\boldsymbol{H}_L^N\to\boldsymbol{H}_I^M$ 是选择算子. 而在例 1.1 中我们也已说明，遗传算法是对应于上式 $E=M\circ C$ 的特殊情形，而且此时 $S:\boldsymbol{H}_L^M\to\boldsymbol{H}_L^M$，$E:\boldsymbol{H}_L^M\to\boldsymbol{H}_L^M$ 均为自映象.

定义 1.7 和定义 1.11 分别公理化地刻画了选择算子与繁殖算子的基本特征，而定义 1.11 和定义 1.12 公理化地刻画了变异算子与交叉算子(均作为繁殖算子的特例). 我们现在进一步引进刻画这些进化操作的**特征数**(characteristic numbers).

定义 1.28（选择压与选择强度） 设 $S:\boldsymbol{H}_L^M\to\boldsymbol{H}_L^M$ 是一个抽象选择算子. 对任何 $\vec{X}\in\boldsymbol{H}_L^N$，令 $n(\vec{X})$ 表示 $\vec{X}$ 中包含(1.5)的全局最优个体数目，且令

$$m(\vec{X})=\max\{k\in[0,M]:P\{n(S(\vec{X}))=k\}>0\},\tag{1.143}$$

$$P_S=\min\{m(\vec{X}):\vec{X}\in\boldsymbol{H}_L^N\text{ 并使 }n(\vec{X})\geqslant 1\},\tag{1.144}$$

$$\alpha_S = \min\{P\{n(S(\vec{X})) = P_s\} : n(\vec{X}) \geqslant 1\}, \tag{1.145}$$

称 P_s 为选择算子 S 的**选择压**(selection pressure), α_s 为 S 的**选择强度**(selection intensity).

例 1.32 (比例型选择算子的特征数) 设 S 是由例 1.9 所定义的带尺度变换 σ 的比例选择,则如果 $n(\vec{X}) \geqslant 1$(不妨设 X^* 是最优个体),则必有

$$P\{n(S(\vec{X})) = M\} = \left[\frac{\sigma(J(X^*))}{\sum_{X\in\vec{X}}\sigma(J(X))}\right]^M > 0, \tag{1.146}$$

所以有选择压 $P_s = N$. 如令

$$\rho_\sigma = \max\left\{\frac{\sigma(J(X))}{\sigma(J(Y))} : J(X) < J(Y), X, Y \in \boldsymbol{H}_L\right\}, \tag{1.147}$$

则从(1.146)推出

$$P\{n(S(\vec{X})) = P_s\} = \left[\frac{n(X^*)}{n(X^*) + \sum_{X\in\vec{X}\cap B} \frac{\sigma(J(X))}{\sigma(J(X^*))}}\right]^M$$
$$\geqslant [1 + (N-1)\rho_\sigma]^{-M},$$

于是 S 的选择强度

$$\alpha_s \geqslant [1 + (N-1)\rho_\sigma]^{-M}. \tag{1.148}$$

例 1.33 (锦标赛选择算子的特征数) 设 S 是由例 1.13 所给出的以 s 为竞赛规模的锦标赛选择算子,则易知 $m(\vec{X}) = s$,所以选择压 $P_S = s$. 如果此时的选择为确定型,则显然 $\alpha_S = 1$;而如果选择为随机型,则最优个体 X^* 被一次选择的概率是 s/N,从而 $\alpha_S = (s/N)^s$.

例 1.34 (排序选择算子的特征数) 依例 1.12,排序选择算子的选择压 $P_S = M$,而无论对于线性排序选择还是非线性排序选择,由于最优个体的排序序号必然是 1,从(1.46)和(1.47)可推出 $\alpha_S = q^M$.

类似地可计算出其他各种选择算子的选择压与选择强度.

定义 1.29 (吸收率、散射率与保持率) 设 $E: \boldsymbol{H}_L^M \to \boldsymbol{H}_L^M$ 是一个抽象的繁殖算子,称

$$A_E = \min\{P\{n(E(\vec{X})) \geqslant 1\} : n(\vec{X}) = 0, \vec{X} \in \boldsymbol{H}_L^M\}$$

为 E 的**吸收率**(aggregating rate);称

$$S_E^k = \max\{P\{n(E(\vec{X})) = 0\} : n(\vec{X}) \geqslant k, \vec{X} \in \boldsymbol{H}_L^M\}$$

为 E 的**散射率**(scattering rate);称

$$ST_E^k = \min\{P\{n(E(\vec{X})) \geqslant k\} : n(\vec{X} \geqslant k : \vec{X} \in \boldsymbol{H}_L^M\}$$

为 E 的**保持率**(stability rate).

根据这一定义，吸收率刻画一个繁殖算子将不含最优个体的种群变换到含最优个体种群的最小可能性；散射率刻画一个繁殖算子将已含最优个体种群变换到不含最优个体种群的最大可能性；而保持率则刻画一个繁殖算子保持最优个体数目不减的能力.

例 1.35（点变异算子的特征数） 对于种群 $\vec{X}=(X_1, X_2, \cdots, X_N)\in \boldsymbol{H}_L^M$ 点变异算子 M 的转移概率为

$$P\{M(\vec{X})_{ij}=1-x_{ij}\}=P_m,$$
$$P\{M(\vec{X})_{ij}=x_{ij}\}=1-P_m,$$

这里 P_m 是事先指定的变异概率，x_{ij} 表示个体 X_i 的第 j 位基因值. 如果 $P_m\leqslant\frac{1}{2}$，则 M 的吸收率、散射率和保持率为

$$A_M=1-(1-P_m^L)^M,$$
$$S_M^k=[1-(1-P_m)^L]^k(1-P_m^L)^{M-k},$$
$$ST_M^k=(1-P_m)^{Lk}.$$

下面，证明这一事实. 按照定义，

$$A_M=\min\{P\{M(\vec{X})\cap B^*\neq\varnothing\}:\vec{X}\cap B^*=\varnothing,\vec{X}\in\boldsymbol{H}_L^M\}.$$

不难看到上述极小值在 $B^*=[000\cdots0]$ 和 $\vec{X}=[111\cdots1]$ 时达到. 在这种情况下，A_M 是至少有一个个体“111…1”变异到“000…0”的概率，由于个体“111…1”变异到“000…0”的概率是 P_m^L，所以 $A_M=1-(1-P_m^L)^M$.

为计算

$$S_M^k=\max\{P\{M(\vec{X})\cap B^*=\varnothing\}:|\vec{X}\cap B^*|\geqslant k,\vec{X}\in\boldsymbol{H}_L^M\},$$

我们不妨假定 $|\vec{X}\cap B^*|=k_1\geqslant k$，并注意到，上述极大值将在下述条件下达到：

(1) $B^*=[000\cdots0]$.

(2) $\vec{X}$ 包含 k_1 个个体“000…0”，同时包含 $N-k_1$ 个个体“111…1”，而此时，$S_M^{k_1}$ 是如下事件共同发生的概率：

(a) 每一个个体“000…0”至少有一位被变异到 1；

(b) 每个个体“111…1”不变异到“000…0”.

于是

$$S_M^{k_1}\leqslant[1-(1-P_m)^L]^{k_1}(1-P_m^L)^{M-k_1}.$$

当 $P_m\leqslant\frac{1}{2}$ 时，上式右端关于 P_m 单调减，从而 $S_M^k=[1-(1-P_m)^L]^k\cdot(1-P_m^L)^{M-k}$.

注意到，变异保持每一个体不变的概率是 $(1-P_m)^L$，从而 $ST_M=(1-$

$P_m)^{Lk}$.

例 1.36(遗传算子特征数) 遗传算子 G 是由单点交叉算子 C 与点变异算子 M 复合组成的进化操作.对任何 $\vec{X}\in \boldsymbol{H}_L^M$,令 $\vec{Y}=C(\vec{X})$,$\vec{Z}=M(\vec{Y})$,则 $\vec{Z}=G(\vec{X})$.遗传算子的吸收率、散射率和保持率分别为

$$A_E = 1-(1-P_m^L)^M,$$

$$S_G^M = [1-(1-P_m)^L]^M \leqslant S_G^k \quad (k=1,2,\cdots,N),$$

$$ST_G^k \geqslant \left[1-\frac{(L-1)P_c}{L}\right]^k (1-P_M)^{Lk}.$$

事实上,如例1.35所述,A_G 达到极小当且仅当 $B^*=[000\cdots0]$ 和 $\vec{X}=[111\cdots1]$,而对于齐次种群,交叉作用显然不改变其个体,从而仍有 $A_G=1-(1-P_m^L)^M$.G 的散射率 S_G^M 取到它的极大值仅当 $B^*=[000\cdots0]$ 和 $\vec{X}=[000\cdots0]$,由于交叉不改变齐次种群,从而有

$$S_G^M = [1-(1-P_m)^L]^M.$$

另外,显然有 $S_G^M\leqslant S_G^k$ 对任何 $k\in\{1,2,\cdots,N\}$ 成立.

为了计算 ST_G^k,注意到,定理 1.3 推出

$$P\{C(X,Y)=X\}=1-P_c+k(X,Y)/LP_c \geqslant 1-\frac{L-1}{L}P_C,$$

其中 $k(X,Y)$ 是交叉 X 与 Y 生成 X 的可能交叉基因位位数,故有

$$\begin{aligned} ST_G &= \min\{P\{n(G(\vec{X}))=k\}\mid n(\vec{X})=k\} \\ &\geqslant \min\{P\{G(\vec{X})=\vec{X}\}\mid n(\vec{X})=k\} \\ &\geqslant \min\{P\{C(\vec{X})=\vec{X}\}\mid n(\vec{X})=k\}P\{M(\vec{X})=\vec{X},n(\vec{X})=k\} \\ &\geqslant [1-\frac{L-1}{L}P_c]^k(1-P_m)^{Lk}. \end{aligned}$$

1.5.3.2 抽象模拟进化算法的概率收敛性定理

我们现在应用定义 1.28 和定义 1.29 所引进的进化算子特征数来一般性地刻画抽象模拟进化算法

$$\vec{X}(t+1)=E_t\circ S_t\vec{X}(t) \tag{1.149}$$

的概率收敛性,这里 $\{E_t\}$,$\{S_t\}$ 是一列繁殖算子与选择算子.(1.149)可看作是非齐次,或者自适应遗传算法的抽象.

引理 1.1 设 $\{\vec{X}(t)\}$ 是由(1.149)所定义的种群序列

$$\alpha_t = P\{n(\vec{X}(t+1))=0/n(\vec{X}(t))\neq 0\}, \tag{1.150}$$

$$\beta_t = P\{n(\vec{X}(t+1))\neq 0/n(\vec{X}(t))=0\}, \tag{1.151}$$

$\{\alpha_t\}$,$\{\beta_t\}$ 是任意两个正实数序列,满足

(1) $\alpha_t\geqslant\bar{\alpha}_t$,$\beta_t\leqslant\bar{\beta}_t$ $(t=0,1,2,\cdots)$,

(2) $\sum_{t=1}^{\infty}\beta_t=\infty$,

(3) $\lim_{t\to\infty}\alpha_t/\beta_t=0$(即 $\alpha_t=o(\beta_t)$),

则$\{\vec{X}(t)\}$依概率弱收敛到最优解集 B^*,即

$$\lim_{t\to\infty}P\{\vec{X}(t)\cap B^*\neq\varnothing\}=1.$$

证明 记 $P_0(t)=P\{n(\vec{X}(t))=0\}=P\{\vec{X}(t)\cap B^*=\varnothing\}$,则由贝叶斯(Bayes)公式有

$$\begin{aligned}P_0(t+1)&=P\{n(\vec{X}(t+1))=0\}\\&=P\{n(\vec{X}(t+1))=0/n(\vec{X}(t))\neq0\}P\{n(\vec{X}(t))\neq0\}\\&\quad+P\{n(\vec{X}(t+1))=0/n(\vec{X}(t))=0\}P\{n(\vec{X}(t))=0\}\\&\leqslant\alpha_t+(1-\beta_t)P_0(t)\\&\leqslant\alpha_t+(1-\beta_t)P_0(t).\end{aligned}\tag{1.152}$$

由条件(3),对于任意 $\varepsilon>0$,存在 T_1 使当 $t\geqslant T_1$ 时

$$\alpha_t\leqslant\frac{\varepsilon}{2}\beta_t,\quad t\geqslant T_1,$$

于是由(1.152)得

$$\begin{aligned}&\left[P_0(t+1)-\frac{\varepsilon}{2}\right]-(1-\beta_t)\left[P_0(t)-\frac{\varepsilon}{2}\right]\\&\leqslant P_0(t+1)-(1-\beta_t)P_0(t)-\alpha_t\leqslant0,\end{aligned}$$

从而

$$P_0(t+1)-\frac{\varepsilon}{2}\leqslant(1-\beta_t)\left[P_0(t)-\frac{\varepsilon}{2}\right].$$

由此递推得

$$P_0(t+1)\leqslant\frac{\varepsilon}{2}+\prod_{i=1}^{t}(1-\beta_i)\left[P_0(t)-\frac{\varepsilon}{2}\right].\tag{1.153}$$

条件(2)等价于 $\prod_{i=1}^{\infty}(1-\beta_i)=0$,于是存在 T_2 使当 $t\geqslant T_2$ 时有 $\prod_{i=1}^{t}(1-\beta_i)\leqslant\frac{\varepsilon}{2}$,从而由(1.153),当 $t\geqslant\max\{T_1,T_2\}$ 时有 $P_0(t+1)\leqslant\varepsilon$.由 ε 的任意性即推得

$$\lim_{t\to\infty}P\{n(\vec{X}(t))=0\}=\lim_{t\to\infty}P_0(t)=0,$$

于是

$$\lim_{t\to\infty}P\{n(\vec{X}(t))\cap B^*\neq\varnothing\}=\lim_{t\to\infty}P\{n(\vec{X}(t))\neq0\}=1.$$

值得注意的是,引理 1.1 所给出的收敛条件极其直观:α_t 是度量 $\vec{X}(t)$ 已

进入最优解集时下一步逃离最优解集的概率上界,这个量当然应该越来越小((3)则要求它应该是 β_t 的高阶无穷小);β_t 是度量 $\vec{X}(t)$ 未进入最优解集时下一步进入最优解集的概率下界,这个量自然应该不能太小((2)则要求它不能太小以使级数 $\sum_{t=1}^{\infty}\beta_t$ 收敛,(3)则要求它应该比 α_t 高阶).

引理 1.2 设选择算子列$\{S_t\}$的选择压与选择强度为$\{P_{S(t)}\}$和$\{\alpha_{S(t)}\}$,进化算子列$\{E_t\}$的吸收率与散射率为$\{A_{E(t)}\}$和$\{S^k_{E(t)}\}$,令

$$\beta_t = A_{E(t)}, \quad \alpha_t = 1-(1-S^{P_{S(t)}}_{E(t)})\alpha_{S(t)}, \tag{1.154}$$

则 $\beta_t\leqslant\dot{\beta}_t$, $\alpha_t\geqslant\dot{\alpha}_t$.

证明 依定义 1.29 与(1.151),

$$\begin{aligned}\dot{\beta}_t &= P\{n(\vec{X}(t+1))\neq\varnothing/n(\vec{X}(t))=0\}\\ &= \sum_{\vec{Y}\in H_l^N} P\{S_t(\vec{X}(t))=\vec{Y}\}P\{\vec{Y}, n(E_t(\vec{Y}))\neq 0\}\\ &\geqslant \sum_{\vec{Y}\in H_l^N} P\{S_t(\vec{X}(t))=\vec{Y}\}A_{E(t)}\geqslant A_{E(t)},\end{aligned}$$

即 $\dot{\beta}_t\geqslant A_{E(t)}$. 而据定义 1.28, 定义 1.29 和(1.150), 当 $n(\vec{X}(t))\neq 0$ 时有

$$\begin{aligned}&P\{n(\vec{X}(t+1))=0\}\\ &=\sum_{\vec{Y}\in H_L^N} P\{S_t(\vec{X}(t))=\vec{Y}\}P\{\vec{Y}, n(E_t(\vec{Y}))=0\}\\ &=\sum_{n(\vec{Y})\geqslant P_{S(t)}} P\{S_t(\vec{X}(t))=\vec{Y}\}P\{\vec{Y}, n(E_t(\vec{Y}))=0\}\\ &\quad\cdot P\{n(\vec{Y})\geqslant P_{S(t)}\}\\ &\quad+\sum_{n(\vec{Y})<P_{S(t)}} P\{S_t(\vec{X}(t))=\vec{Y}\}P\{\vec{Y}, n(E_t(\vec{Y}))=0\}\\ &\quad\cdot P\{n(\vec{Y})<P_{S(t)}\}\\ &\leqslant\sum_{n(\vec{Y})\geqslant P_{S(t)}} P\{S_t(\vec{X}(t))=\vec{Y}\}S^{P_{S(t)}}_{E(t)}P\{n(\vec{Y})\geqslant P_{S(t)}\}\\ &\quad+\sum_{n(\vec{Y})<P_{S(t)}} P\{S_t(\vec{X}(t))=\vec{Y}\}[1-P\{n(\vec{Y})\geqslant P_{S(t)}\}]\\ &\leqslant S^{P_{S(t)}}_{E(t)}P\{n(S_t(\vec{X}(t)))\geqslant P_{S(t)}\}+1\quad P\{n(S_t(\vec{X}(t)))\geqslant P_{S(t)}\}\\ &=1-[1-S^{P_{S(t)}}_{E(t)}]P\{n(S_t(\vec{X}(t)))\geqslant P_{S(t)}\}\\ &\leqslant 1-[1-S^{P_{S(t)}}_{E(t)}]\alpha_{S(t)},\end{aligned}$$

此即 $\dot{\alpha}_t\leqslant 1-[1-S^{P_{S(t)}}_{E(t)}]\alpha_{S(t)}=\alpha_t$.

由引理 1.1 和引理 1.2, 我们立即得下述结论.

定理 1.21 (SEA 的概率收敛性) 假定抽象 SEA(1.149)满足以下条件:

(1) $\{S_t\}$的选择压有一致下界 m_0,即存在正整数 m_0 使 $P_{S(t)} \geqslant m_0$.

(2) $\{E_t\}$的吸收率 $\{A_{E(t)}\}$ 满足 $\sum_{t=1}^{\infty} A_{E(t)} = \infty$.

(3) 选择强度$\{\alpha_{S(t)}\}$,吸收率$\{A_{E(t)}\}$和散射率$\{S_{E(t)}^{m_0}\}$之间满足关系

$$\lim_{t\to\infty} \frac{1}{A_{E(t)}} \left(1 - \frac{S_{E(t)}^{m_0}}{A_{E(t)}}\right)^{\alpha_{S(t)}} = 0.$$

则抽象 SEA(1.149)依概率弱收敛到最优解集 B^*.

我们将在下一小节说明,定理 1.21 所给出的收敛性定理是非常一般的,它可方便地具体化到许多类常见遗传算法执行策略.

值得指出的是,定理 1.21 所给出的 SEA 收敛条件(1)~(3)意义十分直观:(1)是说:一个收敛的 SEA 其选择压应该是正的(这一事实对任何已知的选择算子都是成立的);(2)是说:其吸收率虽然可以很小(甚至渐趋于 0),但不可过小或衰减过快(否则算法不可能收敛),而当选择强度渐近于 1 时,条件(3)说:散射率相对于吸收率来说应该为高阶无穷小.换句话说,对于一个收敛的 SEA 而言,其吸收性(收敛性)应该逐渐加强,而散射性(多样性)应该逐渐减弱,而且从量上说,散射性的减弱速度应高于吸收性的速率.

定理 1.21 可以进一步加强为概率强收敛性.例如,令

$$B(m_0) = \{\vec{X} \in \boldsymbol{H}_L^N : n(\vec{X}) \geqslant m_0\},$$

则可证下述定理.

定理 1.22 (SEA 的概率强收敛性) 在定理 1.21 条件下,进一步假设

(1) $P\{n(E_t(\vec{X}_1)) \neq 0\} \geqslant P\{n(E_t(\vec{X}_2)) \neq 0\}$ 如果 $n(\vec{X}_1) \geqslant n(\vec{X}_2)$.

(2) E 的保持率$\{ST_{E(t)}^{m_0}\}$渐趋于 1,即 $\lim_{t\to\infty} ST_{E(t)}^{m_0} = 1$.

则抽象 SEA 依概率强收敛到集合 $B(m_0)$,即

$$\lim_{t\to\infty} P\{\vec{X}(t) \in B(m_0)\} = 1.$$

证明 对任何 t,记

$$\vec{Y}(t) = S_t\vec{X}(t), \qquad t = 0, 1, \cdots, \tag{1.155}$$

则依(1.149),$\{\vec{Y}(t)\}$满足

$$\vec{Y}(t+1) = S_t \circ E_t\vec{Y}(t), \quad \vec{X}(t+1) = E_t\vec{Y}(t). \tag{1.156}$$

我们首先证明:种群序列$\{\vec{Y}(t)\}$依概率强收敛到 $B(m_0)$.为此,记

$$u_t = P\{n(\vec{Y}(t)) \geqslant m_0\},$$

并注意到

$$u_{t+1} = P\{n(S_t \circ E_t\vec{Y}(t)) \geqslant m_0\}$$

$$\geqslant \sum_{n(\vec{X})=1} P\{n(S_t(\vec{X}))\geqslant m_0\}P\{E_t(\vec{Y}(t))=\vec{X}\}$$
$$\geqslant \alpha_{S(t)}\sum_{n(\vec{X})\geqslant 1} P\{E_t(\vec{Y}(t))=\vec{X}\} \tag{1.157}$$
$$\geqslant \alpha_{S(t)}P\{n(E_t(\vec{Y}(t)))\geqslant 1\}.$$

对任何 $\vec{Y}$,依假设(1)有

$$P\{n(E_t(\vec{Y}(t)))\geqslant 1\}\geqslant \min\{P\{n(E_t(\vec{Y}))\geqslant 1\mid n(\vec{Y})=0\}\}$$
$$=A_{E(t)}, \tag{1.158}$$

而当 $n(\vec{Y})\geqslant m_0$ 时,

$$P\{n(E_t(\vec{Y}(t)))\geqslant 1\}=1-P\{n(E_t(\vec{Y}(t)))=0\}$$
$$\geqslant 1-\max\{n(E_t(\vec{Y}(t)))=0\mid n(\vec{Y})\geqslant m_0\}$$
$$=1-S^{m_0}_{E(t)}, \tag{1.159}$$

所以,对任何 t,由(1.157)~(1.159)得

$$u_{t+1}=\alpha_{S(t)}[P\{n(E_t(\vec{Y}(t)))\geqslant 1\}P\{n(\vec{Y}(t))<m_0\}$$
$$+P\{n(E_t(\vec{Y}(t)))\geqslant 1\}P\{n(\vec{Y}(t))\geqslant m_0\}]$$
$$\geqslant \alpha_{S(t)}(1-u_t)A_{E(t)}+\alpha_{S(t)}(1-S^{m_0}_{E(t)})u_t.$$

记 $v_t=1-u_t$,则上式推出

$$v_{t+1}\leqslant 1-\alpha_{S(t)}(1-S^{m_0}_{E(t)})+\alpha_{S(t)}[(1-S^{m_0}_{E(t)})-A_{E(t)}]v_t$$
$$\leqslant (1-A_{E(t)})v_t+1-\alpha_{S(t)}(1-S^{m_0}_{E(t)}),$$

由此应用定理 1.21 之假设(2)和(3)易推出 $\lim_{t\to\infty}v_t=0$. 于是

$$\lim_{t\to\infty}P\{n(\vec{Y}(t))\geqslant m_0\}=\lim_{t\to\infty}u_t=1-\lim_{t\to\infty}v_t=1, \tag{1.160}$$

即 $\{\vec{Y}(t)\}$ 依概率强收敛到集合 $B(m_0)$.

(1.160)推出

$$\lim_{t\to\infty}\sum_{n(\vec{Z})\geqslant m_0}P\{\vec{Y}(t)=\vec{Z}\}$$
$$=\lim_{t\to\infty}P\{n(\vec{Y}(t))\geqslant m_0\}=1,$$

于是应用条件(2)和定义 1.27 得

$$\lim_{t\to\infty}P\{n(\vec{X}(t+1))\geqslant m_0\}=\lim_{t\to\infty}P\{n(E_t\vec{Y}(t))\geqslant m_0\}$$
$$\geqslant \lim_{t\to\infty}\sum_{n(\vec{Z})\geqslant m_0}P\{n(E_t\vec{Z})\geqslant m_0\}P\{\vec{Y}(t)\geqslant\vec{Z}\}$$
$$\geqslant \lim_{t\to\infty}ST^{m_0}_{E(t)}\sum_{n(\vec{Z})\geqslant m_0}P\{\vec{Y}(t)=\vec{Z}\}=1.$$

这即推出 $\{\vec{X}(t)\}$ 依概率强收敛到 $B(m_0)$.

1.5.3.3 应用举例

定理 1.23（时变比例选择 GA 的收敛性） 假定遗传算法由带尺度变换 $\{\sigma_t\}$ 的比例选择算子族 $\{S_t\}$ 和遗传算子族 $\{C_t, M_t\}$ 所定义，$\{\rho_{\sigma(t)}\}$ 是由(1.147)所定义的 $\{S_t\}$ 的特征数，$\{P_m(t)\}$ 是 M_t 所对应的变异概率，且它们满足以下条件

(1) $\rho_{\sigma(t)} = o\left(\frac{1}{t}\right)$.

(2) $P_m(t) = O\left(\sqrt[L]{\frac{1}{t}}\right)$.

(3) $N > L$.

则该遗传算法依概率弱收敛.

证明 由例 1.32 知 $P_{S(t)} = N$，且

$$\alpha_{S(t)} \geqslant (1 + (N-1)\rho_{\sigma(t)})^{-N} = 1 - O(\rho_{\sigma(t)}) = 1 - o\left(\frac{1}{t}\right).$$

又由例 1.36 知

$$A_{G(t)} = 1 - (1 - P_m^L)^N = 1 - \left(1 - O\left(\frac{1}{t}\right)\right)^N = O\left(\frac{N}{t}\right),$$

$$S_{G(t)}^N = (1 - (1 - P_m)^L)^N = \left[1 - \left(1 - O\left(\sqrt[L]{\frac{1}{t}}\right)\right)^L\right]^N$$

$$= O(L^N t^{-\frac{N}{L}}).$$

据假设 $N > L$，$(1 - \frac{N}{L}) < 0$，于是

$$\frac{1 - \alpha_{S(t)}(1 - S_{G(t)}^N)}{A_{G(t)}} = \frac{1 - \alpha_{S(t)}}{A_{G(t)}} + \alpha_{S(t)} \frac{S_{G(t)}^N}{A_{G(t)}}$$

$$= \frac{o\left(\frac{1}{t}\right)}{O\left(\frac{N}{t}\right)} + \left(1 - o\left(\frac{1}{t}\right)\right) \frac{O(L^N t^{-\frac{N}{L}})}{O\left(\frac{N}{t}\right)}$$

$$= o(1) + O\left(\frac{1}{N} L^N t^{1-\frac{N}{L}}\right) \to 0 \quad (t \to \infty).$$

又因为

$$\sum_{t=1}^{\infty} A_{G(t)} = \sum_{t=1}^{\infty} O\left(\frac{N}{t}\right) = \infty,$$

由此定理 1.21 全部条件满足，故由定理 1.21，定理 1.23 得证.

推论 1.2（整体退火选择 GA 的收敛性） 如在定理 1.23 中取 $\sigma_t(X) = \exp(x/T_t)$ 且满足

(1) $T_t = o\left(\frac{1}{\ln(t)}\right)$.

(2) $P_{m(t)}=O\left(\sqrt[L]{\frac{1}{t}}\right)$.

(3) $N>L$.

则遗传算法概率弱收敛到全局最优解.

证明 此时易证

$$\rho_{\sigma(t)}=e^{-\Delta/T_t},$$

其中

$$\Delta=\min\{J(x)-J(y):J(x)>J(y),x,y\in \boldsymbol{H}_L\}>0,$$

而且 $T_t=o\left(\frac{1}{\ln(t)}\right)$ 等价于 $\rho_{\sigma(t)}=o\left(\frac{1}{t}\right)$，得证.

完全类似于定理 1.23，我们可证明下述定理 1.24 和定理 1.25.

定理 1.24（排序选择 GA 收敛性） 假定遗传算法由非线性排序选择算子族 $\{S_t\}$（相应参数为 b_t）和遗传算子族 $\{C_t,M_t\}$ 定义（变异概率为 $P_{m(t)}$），且满足以下条件

(1) $b_t=1-o\left(\frac{1}{t}\right)$.

(2) $P_{m(t)}=O\left(\sqrt[L]{\frac{1}{t}}\right)$.

(3) $N>L$.

则该遗传算法概率收敛到全局最优解集.

定理 1.25（锦标赛选择 GA 收敛性） 假定遗传算法由锦标赛选择遗传算法和变异算子族 $\{M_t\}$（变异概率 $P_{m(t)}$）定义，且满足以下条件：

(1) $P_{m(t)}=O\left(\sqrt[L]{\frac{1}{t}}\right)$.

(2) 竞赛规模 $S\geqslant L$.

则该遗传算法依概率弱收敛到全局最优解集.

类似地，我们也可以应用定理 1.22 来直接给出各种遗传算法的概率全收敛性. 由于基本条件类似（基本上外加交叉概率 $P_{C(t)}$ 趋于 0 的条件），此处从略，有兴趣的读者可作为练习导出.

最后，我们指出：在定理 1.23～1.25 中我们始终要求了变异概率 $P_{m(t)}=O\left(\sqrt[L]{\frac{1}{t}}\right)$. 当编码长度 L 很大时，$\sqrt[L]{\frac{1}{t}}\approx 1$. 这说明，当实际应用中 L 较大时，$P_{m(t)}$ 事实上可取为常数值，即 $P_{m(t)}\equiv P_m$. 这一分析与大量的应用实践相吻合. 另外，定理 1.23～1.24 所给出的条件“$N>L$”对于遗传算法应用中参数 N、L 的设置提供了重要的理论指导.

我们下节进一步应用鞅论来研究遗传算法的几乎必然收敛性.

1.5.4 遗传算法的鞅分析

1.5.4.1 条件期望与鞅

设 E 是一个集合，$\mathscr{F}$ 是由 E 上的部分子集所构成的 **σ 代数**，即满足

(1) $\varnothing \in \mathscr{F}$.

(2) $A \in \mathscr{F}$ 时 $A^c \in \mathscr{F}$.

(3) $A_k \in \mathscr{F}(k = 1, 2, \cdots, n)$，则 $\bigcup_{k=1}^{n} A_k \in \mathscr{F}$.

(4) $A_k \in \mathscr{F}$，$A = \lim_{k \to \infty} A_k \in \mathscr{F}$.

设 P 是 $\mathscr{F}$ 上的**概率测度**，则 $(E, \mathscr{F}, P)$ 构成一个**概率空间**，$(E, \mathscr{F})$ 称为**可测空间**. 若 T 是可测空间 $(E_1, \mathscr{F}_1)$ 到可测空间 $(E_2, \mathscr{F}_2)$ 的映射，且对任意 $A \in \mathscr{F}_2$，有

$$T^{-1}(A) = \{e \mid T(e) \in A\} \in \mathscr{F}_1,$$

则称 T 是**可测映射**. 一个实值可测映射称为**随机变量**.

设 $(E, \mathscr{F}, P)$ 是一个概率空间，$\mathscr{G} \subset \mathscr{F}$ 也是一个 σ 代数，f 是 E 上可测与可积的随机变量，f 关于 $\mathscr{G}$ 的**条件期望** $E(f/\mathscr{G})$ 是 $\mathscr{G}$ 可测的和可积的，且对任意 $A \in \mathscr{G}$ 有

$$\int_A E(f/\mathscr{G}) \mathrm{d}p = \int_A f \mathrm{d}p.$$

条件期望 $E(f/\mathscr{G})$ 具有以下性质：

(1) $E(E(f/\mathscr{G})) = E(f)$ (a.s.).

(2) 若 α, β 是常数，则

$$E(\alpha f + \beta g/\mathscr{G}) = \alpha E(f/\mathscr{G}) + \beta E(g/\mathscr{G}) \quad \text{(a.s.)}.$$

若 $\mathscr{F}_n$ 是单调增的 σ 代数列，f_n 是 E 上的实值函数序列，$(f_n, \mathscr{F}_n)$ 称为是一个**鞅**(martingale)，若 f_n 关于 $\mathscr{F}_n$ 可测且可积，同时对任意 $m < n$ 有

$$E(f_n/\mathscr{F}_n) = f_m \quad \text{(a.s.)}.$$

若 $E(f_n/\mathscr{F}_n) \geqslant f_m$ (a.s.)，称为**下鞅**；若 $E(f_n/\mathscr{F}_n) \leqslant f_m$ (a.s.) 称为**上鞅**. 类似于实分析中的“单调有界序列必有极限”，若 $\{f_n\}$ 是有界的，则对于下鞅、上鞅和下鞅，极限 $\lim_{n \to \infty} f_n$ 几乎处处存在. 利用鞅(特别是离散鞅)的性质，我们可证明遗传算法的几乎必然收敛性.

1.5.4.2 遗传算法的几乎必然收敛性

为了讨论方便，本节考虑表述为如下形式的遗传算法：

$$X(t+1) = C_t \circ S_t \circ M_t X(t), \quad t = 0, 1, 2, \cdots, \tag{1.161}$$

这里 $M_t : \boldsymbol{H}_L^N \to \boldsymbol{H}_L^N$，$S_t : \boldsymbol{H}_L^N \to \boldsymbol{H}_L^{2N}$，$C_t : \boldsymbol{H}_L^{2N} \to \boldsymbol{H}_L^N$ 分别为变异算子、选择算子

与交叉算子.

对任何种群 $\vec{X}, i, j, k \in \vec{X}$, 令

$$P_M^t(i,j) = P\{M_t(i) = j\}, \tag{1.162}$$

$$P_S^*(\vec{X}, i) = P\{i \in S_t(\vec{X})\},$$

$$P_S^t(\vec{X}, i \times j) = P\{i, j \in S_t(\vec{X})\}, \tag{1.163}$$

$$P_C^t(i \times j, k) = P\{C_t(i,j) = k\}, \tag{1.164}$$

并记

$$a_t = \min\{P_M^t(i,i) \mid i \in \boldsymbol{H}_L\}, \tag{1.165}$$

$$b_t = \max\{P_M^t(i,j) \mid i \neq j, i, j \in \boldsymbol{H}_L\}, \tag{1.166}$$

$$d_t = \min\{P_M^t(i,j) \mid i \neq j, i, j \in \boldsymbol{H}_L\}, \tag{1.167}$$

$$e_t = \max\{P_C^t(i \times j, k) \mid k \neq i, i \neq j, i, j \in \boldsymbol{H}_L\}. \tag{1.168}$$

又,对任何尺度变换 σ_t, 如同(1.147)式,定义

$$\rho_t = \max\left\{\frac{\sigma_t(J(i))}{\sigma_t(J(j))} \mid J(i) < J(j), i, j \in \boldsymbol{H}_L\right\}. \tag{1.169}$$

引理 1.3 设 S_t 是带有尺度变换 σ_t 的比例选择, S_0 是最佳值选择(即服从分布 $P_S^0(\vec{X}, i) = X^*(i)/|B(\vec{X})|$, 这里 $B(\vec{X})$ 是 $\vec{X}$ 中最佳个体的全体, $X^*(i)$ 是 $B(\vec{X})$ 中含个体 i 的数目. 令

$$h_t = \max\{|P_S^t(\vec{X}, i \times j) - P_S^0(\vec{X}, i \times j)| \mid \vec{X} \in \boldsymbol{H}_L^N, i, j \in \boldsymbol{H}_L\},$$

则存在仅依赖于种群规模 N 的常数 C 使得

$$h_t \leqslant C\rho_t, \quad t = 1, 2, \cdots \tag{1.170}$$

证明 根据带尺度函数比例选择的定义,当 $i \in B(\vec{X})$ 时有

$$\begin{aligned}
&|P_S^t(\vec{X}, i) - P_S^0(\vec{X}, i)| \\
&= \left|\frac{\sigma_t(J(i))n(i)}{\sum_{k=1}^{N}\sigma_t(J(k))} - \frac{X^*(i)}{|B(\vec{X})|}\right| \\
&= X^*(i)\left|\frac{1}{|B(\vec{X})| + \sum_{j \in \vec{X} \setminus B(\vec{X})} \sigma_t(J(j))/\sigma_t(J(i))} - \frac{1}{|B(\vec{X})|}\right| \\
&\leqslant |\vec{X}| \sum_{j \in \vec{X} \setminus B(\vec{X})} [\sigma_t(J(j))/\sigma_t(J(i))] \\
&\leqslant N^2 \max\left\{\frac{\sigma_t(J(j))}{\sigma_t(J(k))} \mid J(j) < J(k), k \in \boldsymbol{H}_L\right\} \\
&= N^2\rho_t,
\end{aligned}$$

而当 $i\notin B(\vec{X})$时,取 $i_0\in B(\vec{X})$,有

$$|P_S^t(\vec{X},i)-P_S^0(\vec{X},i)|=\frac{\sigma_t(J(i))n(i)}{\sum_{k=1}^{N}\sigma_t(J(k))}$$

$$=n(i)\frac{\sigma_t(J(i))/\sigma_t(J(i_0))}{|B(\vec{X})|+\sum_{j\in\vec{X}\setminus B(\vec{X})}\sigma_t(J(i))/\sigma_t(J(i_0))}$$

$$\leqslant|\vec{X}(t)|\rho_t=N\rho_t.$$

于是

$$|P_S^t(\vec{X},i\times j)-P_S^0(\vec{X},i\times j)|$$

$$=|P_S^t(\vec{X},i)P_S^t(\vec{X},j)-P_S^0(\vec{X},i)P_S^0(\vec{X},j)|$$

$$\leqslant|P_S^t(\vec{X},i)-P_S^0(\vec{X},i)|+|P_S^t(\vec{X},i)-P_S^0(\vec{X},j)|$$

$$\leqslant 2N^2\rho_t.$$

由此,(1.169)得证.

引理 1.4 设$\{X(t)\}$是由遗传算法(1.161)所定义的马氏链,则它的转移概率矩阵满足

$$P\{X(t+1)=\vec{Z}/X(t)=\vec{X}\}$$

$$=\sum_{\vec{Y}}P_M^t(\vec{X},\vec{Y})\sum_{u_i,v_i}\prod_{k=1}^{N}P_S^t(\vec{Y},u_i\times v_i)P_C^t(u_i\times v_i,z_k). \quad (1.171)$$

另外,$X_1(t),X_2(t),\cdots,X_N(t)$具有相同的条件分布,且其共同条件分布是

$$P\{X_1(t+1)=k/X(t)=\vec{X}\}$$

$$=\sum_{\vec{Y}}P_M^t(\vec{X},\vec{Y})\sum_{i,j\in\vec{Y}}P_S^t(\vec{Y},i\times j)P_C^t(i\times j,k). \quad (1.172)$$

证明 显然.

我们以下利用引理 1.3 和引理 1.4 说明遗传算法$\{\vec{X}(t)\}$可化归到一类下鞅来分析.

为此,我们观察到:从直观上说,遗传算法的目的在于生成一列种群$\vec{X}(t)$,它带有概率分布偏向于具有最佳目标函数值(即适应函数值)的候选者.因而,如果我们以种群的平均适应度作为指导原则,则由于一个种群的平均适应度达到全局最大当且仅当该种群的每个个体达到全局最大,我们能够利用平均适应度函数过程的收敛性来研究遗传算法的收敛性.另外,我们希望每次迭代后,新种群的平均适应度关于当前种群的条件期望不低于当前种群的平均适应度,因而,我们可设法把平均适应度函数过程$\{J_{av}(\vec{X}(t))\}$转变为一个下鞅来考察$\{\vec{X}(t)\}$的收敛性.

为了说明如何转化函数过程$\{J_{av}(\vec{X}(t))\}$到一个下鞅,我们先给出遗传算法优化过程的一个直观解释.为方便计,具有高(低)适应值的个体将称之为

是"好"("坏")的个体.变异和交叉算子作用不能确保产生"好"个体,也可能保留"坏"个体而把"好"个体变为"坏"个体,因而在优化过程中利弊相当.然而,选择算子作用总是以大的概率鼓励"好"的个体(特别地,个体适应值越大,它被选择的概率越大),所以经选择作用种群的平均适应值总比当前种群的平均适应值大.由于变异和交叉概率越小,被选取的"好"个体将被保留在种群中的概率就越大,所以对于带有选择算子的遗传算法,为了充分发挥其"保优"机制,我们应设法使变异和杂交概率逐渐变小.根据(1.166)式,$(b_t)^N$ 是在变异算子 M_t 作用下一个种群的每个个体被改变的最大概率.而由(1.168)式,e_t 是通过杂交算子 C_t 每本被改变的最大概率.因此,当 $(b_t)^N$ 和 e_t 渐趋于零时,平均适应度函数列 $\{J_{av}(\vec{X}(t))\}$ 应该具有一种上升趋势.然而,如前所述,变异和交叉算子可能保留"坏"个体且将"好"个体转变为"坏"个体.因此,一次迭代后,下一代种群的平均适应度关于当前种群的条件期望可能不比当前种群的平均适应度大.所以带有三个遗传算子(选择,变异,交叉)的遗传算法的平均适应度函数过程一般来说具有上升趋势,但会有随机波动.显然 b_t 和 e_t 越小,这样的随机波动也会越小.因而,我们的想法是:设法确定一个控制序列(比如说,有界数列 $\{\alpha_n\}$),使这个控制序列迭加到随机过程 $\{J_{av}(\vec{X}(t))\}$ 上可等效抵消其波动作用,从而保证 $\{J_{av}(\vec{X}(t))+\alpha_n\}$ 成为一个下鞅.以下定理1.26将从理论上严格证明这种控制序列的存在性.注意到,如果 b_t 和 e_t 趋于零的速度太快,遗传算法可能出现过早收敛.因而,为了确保种群过程 $\{\vec{X}(t)\}$ 最终能进入最优解集 B^*,我们必须控制 $\{b_t\}$ 和 $\{e_t\}$ 趋于零的速度.以下定理1.27正是基于对这两个参数趋于零速率的控制来刻画遗传算法的几乎必然强收敛的.

定理 1.26 (遗传算法所定义的下鞅) 设 $\{\vec{X}(t)\}$ 是由带比例选择的遗传算法(1.161)所定义的种群序列,$\{a_t\}$,$\{b_t\}$,$\{e_t\}$,$\{\rho_t\}$ 分别由(1.165),(1.166),(1.168)和(1.169)定义,且满足

(1) $\lim_{t\to\infty} a_t = 1$.

(2) $\sum_{t=1}^{\infty}[e_t+\rho_t+(b_t)^N]<\infty$.

则存在一个正的单调增有界控制序列 $\{\alpha_t\}$ 使平均适应值过程 $\{J_{av}(\vec{X}(t))+\alpha_t\}$ 是非负有界下鞅,换言之,

$$E(J_{av}(\vec{X}(t))+\alpha_{t+1}/\vec{X}(0),\cdots,\vec{X}(t))\geqslant J_{av}(\vec{X}(t))+\alpha_t,\ t=1,2,\cdots \tag{1.173}$$

证明 随机过程 $\{J_{av}(\vec{X}(t))\}$ 显然非负、有界,故只需证(1.173).由 $\{\vec{X}(t)\}$ 的马氏性有

$$E(J_{av}(\vec{X}(t+1))/\vec{X}(0),\cdots,\vec{X}(t)) = E(J_{av}(\vec{X}(t+1))/\vec{X}(t)),$$

故又只需证

$$E(J_{av}(\vec{X}(t+1)) + \alpha_{t+1}/\vec{X}(t)) \geqslant J_{av}(\vec{X}(t)) + \alpha_t, \quad t = 1,2,\cdots \tag{1.174}$$

记 B^* 是(1.5)的最优种群集，J^* 是最优适应度，$\boldsymbol{F}$ 是具有相同适应度的种群集，即

$$\boldsymbol{F} = \{\vec{X} \in \boldsymbol{H}_L^N \mid J(X_1) = J(X_2) = \cdots = J(X_N)\},$$

$J_{\max}(\vec{X})$表示 $\vec{X}$ 中最优个体的适应值. 令

$$\delta = \min\{|J(i) - J(j)| \mid J(i) \neq J(j), i,j \in \boldsymbol{H}_L\}, \tag{1.175}$$

$$\begin{aligned}\bar{a}_t &= \min\{P_C^t(i \times j, i) \mid i,j \in \boldsymbol{H}_L\} \\ &= 1 - \max\{1 - P_C^t(i \times j, i) \mid i,j \in \boldsymbol{H}_L\} \\ &= 1 - e_t,\end{aligned} \tag{1.176}$$

则由引理 1.4，我们首先有

$$\begin{aligned}&E(J_{av}(\vec{X}(t+1))/\vec{X}(t) = \vec{X}) \\ &= \frac{1}{N}\sum_{s=1}^{N} E(J_{av}(X_s(t+1))/\vec{X}(t) = \vec{X}) \\ &= E(J_{av}(X_1(t+1))/\vec{X}(t) \quad \vec{X}) \\ &= \sum_l J(l) P\{X_1(t+1) = l/X(t) = \vec{X}\} \\ &= \sum_{\vec{Y}(t)} P_M^t(\vec{X},\vec{Y}) \sum_{i,j \in Y} P_S^t(\vec{Y}, i \times j) \sum_l P_C^t(i \times j, l) J(l),\end{aligned} \tag{1.177}$$

进而由引理 1.5 推得

$$\begin{aligned}&E(J_{av}(\vec{X}(t+1))/\vec{X}(t) = \vec{X}) \\ &= \sum_{\vec{Y}} P_M^t(\vec{X},\vec{Y}) \sum_{i,j \in \vec{Y}} [P_S^t(\vec{Y}, i \times j) - P_S^t(\vec{Y}, i \times j)] \sum_l P_C^t(i \times j, l) J(l) \\ &\quad + \sum_{\vec{Y}} P_M^t(\vec{X},\vec{Y}) \sum_{i,j \in \vec{Y}} P_S^0(\vec{Y}, i \times j) \sum_l P_C^t(i \times j, l) J(l) \\ &\geqslant -\max\{|P_S^t(\vec{Y}, i \times j) - P_S^0(\vec{Y}, i \times j)| \mid \vec{Y} \in \boldsymbol{H}_L^N, i,j \in \boldsymbol{H}_L\} J^* \\ &\quad + \sum_{\vec{Y}} P_M^t(\vec{X},\vec{Y}) \sum_{i,j \in \vec{Y}} P_S^0(\vec{Y}, i \times j) \sum_l P_C^t(i \times j, l) J(l) \\ &\geqslant -C\rho_t J^* + \sum_{\vec{Y}} P_M^t(\vec{X},\vec{Y}) \sum_{i,j \in \vec{Y}} P_S^0(\vec{Y}, i \times j) \sum_l P_C^t(i \times j, l) J(l).\end{aligned} \tag{1.178}$$

由 $P_S^0(\vec{Y}, i \times j)$的定义和(1.176)，当 $i \notin B(\vec{Y})$时，$P_S^0(\vec{Y}, \times j) = 0$，而当 $i \in B(\vec{Y})$时，$J(i) = J_{\max}(\vec{Y})$，所以有

$$\begin{aligned}
&\sum_{\vec{Y}} P_M^t(\vec{X},\vec{Y}) \sum_{i,j\in\vec{Y}} P_S^0(\vec{Y}, i\times j) \sum_l P_C^t(i\times j, l) J(l)\\
=&\sum_{\vec{Y}} P_M^t(\vec{X},\vec{Y}) \sum_{i,j\in B(\vec{Y})} P_S^0(\vec{Y}, i\times j) \sum_l P_C^t(i\times j, l) J(l)\\
\geqslant&\sum_{\vec{Y}} P_M^t(\vec{X},\vec{Y}) \sum_{i,j\in B(\vec{Y})} P_S^0(\vec{Y}, i\times j) P_C^t(i\times j, i) J(i)\\
\geqslant&\bar{a}_t \sum_{\vec{Y}} P_M^t(\vec{X},\vec{Y}) \sum_{i,j\in B(\vec{Y})} P_S^0(\vec{Y}, i\times j) J(i)\\
\geqslant&\bar{a}_t \sum_{\vec{Y}} P_M^t(\vec{X},\vec{Y}) J_{\max}(\vec{Y})\\
=&(\bar{a}_t-1)\sum_{\vec{Y}} P_M^t(\vec{X},\vec{Y}) J_{\max}(\vec{Y}) + \sum_{\vec{Y}} P_M^t(\vec{X},\vec{Y}) J_{\max}(\vec{Y})\\
\geqslant&-e_t J^* + \sum_{\vec{Y}} P_M^t(\vec{X},\vec{Y}) J_{\max}(\vec{Y}).
\end{aligned} \tag{1.179}$$

以下我们分三种情形来估计

$$\Delta_t = \sum_{\vec{Y}} P_M^t(\vec{X},\vec{Y}) J_{\max}(\vec{Y}) - J_{av}(\vec{X}).$$

(i) $\vec{X}\notin \boldsymbol{F}$. 此时由(1.175)有 $J_{\max}(\vec{X}) - J_{av}(\vec{X}) \geqslant \delta/N$, 故由定义(1.165)推得

$$\begin{aligned}
\Delta_t &\geqslant P_M^t(\vec{X},\vec{X}) J_{\max}(\vec{X}) - J_{av}(\vec{X})\\
&\geqslant (a_t)^N J_{\max}(\vec{X}) - J_{av}(\vec{X}) \geqslant (a_t)^N \frac{\delta}{N} \quad [1-(a_t)^N] J^*.
\end{aligned}$$

由定理条件(1), $a_t \to 1 (t\to\infty)$, 所以对充分大的 t 有

$$\Delta_t \geqslant \frac{1}{2}(a_t)^N \frac{\delta}{N} = C_1. \tag{1.180}$$

不失一般性,我们可假定此不等式对任何 $t\geqslant 0$ 成立.

(ii) $\vec{X}\in \boldsymbol{F}\setminus B^*$. 此时有 $J(X_1) = J(X_2) = \cdots = J(X_N)$, $J_{\max}(\vec{X}) - J_{av}(\vec{X}) < J^*$, 从而

$$\begin{aligned}
\Delta_t = &\sum_{\vec{Y}\neq\vec{X},\vec{Y}\cap\vec{X}\neq\varnothing} P_M^*(\vec{X},\vec{Y})(J_{\max}(\vec{Y}) - J_{av}(\vec{X}))\\
&+ \sum_{\vec{Y}\cap\vec{X}=\varnothing} P_M^t(\vec{X},\vec{Y})(J_{\max}(\vec{Y}) - J_{av}(\vec{X})).
\end{aligned}$$

因为当 $\vec{Y}\neq\vec{X}$, $\vec{Y}\cap\vec{X}\neq\varnothing$ 时, $J_{\max}(\vec{X}) - J_{av}(\vec{X}) \geqslant 0$, 如果我们取 $\vec{Z} = (X_1, X_2, \cdots, X_{N-1}, X^*)$, 其中 $X^*\in B^*$, 则据(1.165), (1.167)可得

$$\begin{aligned}
&\sum_{\vec{Y}\neq\vec{X},\vec{Y}\cap\vec{X}\neq\varnothing} P_M^t(\vec{X},\vec{Y})[J_{\max}(\vec{Y}) - J_{av}(\vec{X})]\\
\geqslant& P_M^t(\vec{X},\vec{Y})[J_{\max}(\vec{Z}) - J_{av}(\vec{X})] \geqslant (a_t)^{N-1} d_t \delta.
\end{aligned} \tag{1.181}$$

而当 $\vec{Y}\cap\vec{X} = \varnothing$ 时, 对任何 $k = 1, 2, \cdots, n$, $X_k \neq Y_k$, 据(1.166)式,

$$\sum_{\vec{Y}\cap\vec{X}=\varnothing} P_M^t(\vec{X},\vec{Y})[J_{\max}(\vec{Y}) - J_{av}(\vec{X})]$$

$$\geqslant -J^* \sum_{\vec{Y}\cap\vec{X}=\varnothing} P_M^t(\vec{X},\vec{Y}) \geqslant -J^* \left|\boldsymbol{H}_L^N\right| (b_t)^N. \tag{1.182}$$

由(1.181)和(1.182)得

$$\Delta_t \geqslant (a_t)^{N-1} d_t\delta - J^* \left|\boldsymbol{H}_L^N\right| (b_t)^N \equiv c_2 d_t - c_3 (b_t)^N, \tag{1.183}$$

其中 $c_2=(a_t)^{N-1}\delta$, $c_3=J^*\left|\boldsymbol{H}_L^N\right|$.

(iii) $\vec{X}\in\boldsymbol{F}$. 此时 $J_{\max}(\vec{X})=J^*$, 且当 $\vec{Y}\cap\vec{X}\neq\varnothing$ 时, $J_{\max}(\vec{Y})=J^*$, 故

$$\begin{aligned}\Delta_t &= \sum_{\vec{Y}} P_M^t(\vec{X},\vec{Y}) J_{\max}(\vec{Y}) - J_{av}(\vec{X}) \\ &= \sum_{\vec{Y}\cap\vec{X}=\varnothing} P_M^t(\vec{X},\vec{Y})[J_{\max}(\vec{Y}) - J_{av}(\vec{X})] \\ &\geqslant -J^* \left|\boldsymbol{H}_L^N\right| (b_t)^N = -c_3(b_t)^N.\end{aligned} \tag{1.184}$$

令 $\bar{c}=cJ^*+J^*+2c_3$, 则由(1.178)~(1.184)得

$$\begin{aligned}&E(J_{av}(\vec{X}(t+1))/\vec{X}(t)=\vec{X}) - J_{av}(\vec{X}) \\ &\geqslant -c\rho_t J^* - e_t J^* - 2c_3(b_t)^N \\ &\geqslant -\bar{c}[\rho_t + e_t + (b_t)^N].\end{aligned} \tag{1.185}$$

如果我们定义

$$\alpha_t = c\sum_{k=1}^{t-1}[\rho_k + e_k + (b_k)^N], \tag{1.186}$$

则由(1.185), 我们推得

$$E(J_{av}(\vec{X}(t+1)) + \alpha_{t+1})/\vec{X}(t)=\vec{X}) \geqslant J_{av}(\vec{X}(t)) + \alpha_t, \quad t=1,2,\cdots$$

这即推出 $\{J_{av}(\vec{X}(t)) + \alpha_t\}$ 是下鞅, 另外, 由假设(2), $\{\alpha_t\}$ 显然是一单调增有界序列, 从而定理 1.26 得证.

根据下鞅收敛定理, 上述定理推出: 平均适应度序列 $\{J_{av}(\vec{X}(t)) + \alpha_t\}$ 将几乎必然收敛到一个非负有界随机变量. 由于数列 $\{\alpha_t\}$ 本身收敛, 故随机变量序列 $\{J_{av}(\vec{X}(t))\}$ 几乎必然收敛. 以下我们记

$$\xi = \lim_{t\to\infty} J_{av}(\vec{X}(t)) \quad \text{(a.s.)}.$$

定理 1.27 (遗传算法的几乎必然收敛性) 在定理 1.26 假设下, 增设

(3) $\displaystyle\sum_{t=1}^{\infty} d_t = \infty$.

则

(a) $\xi=J^*$ (a.s.).

(b) $P\{\bigcup_{k=1}^{\infty}\bigcup_{t=k}^{\infty}[\vec{X}(t)\subseteq B^*]\}=1$.

证明 我们分以下三步证明定理结论.

第一步: 由条件期望的性质和(1.178), (1.179), (1.180), (1.183)和(1.184)得

$$
\begin{aligned}
&E(J_{av}(\vec{X}(t+1))) - E(J_{av}(\vec{X}(t))) \\
&= E(E(J_{av}(\vec{X}(t+1))/\vec{X}(t))) - E(J_{av}(\vec{X}(t))) \\
&= \sum_{\vec{X}} P\{\vec{X}(t) = \vec{X}\}\{E(J_{av}(\vec{X}(t+1))/\vec{X}(t) = \vec{X}) - J_{av}(\vec{X})\} \\
&\geqslant c\rho_t J^* - e_t J^* + \sum_{\vec{X}} P\{\vec{X}(t) = \vec{X}\} \sum_{\vec{Y}} [P'_M(\vec{X}, \vec{Y}) J_{\max}(\vec{Y}) - J_{av}(\vec{X})] \\
&= -c\rho_t J^* - e_t J^* + \Big(\sum_{\vec{X} \notin \boldsymbol{F}} + \sum_{\vec{X} \in \boldsymbol{F} \setminus B^*} + \sum_{\vec{X} \in B^*} \Big) P\{\vec{X}(t) \\
&= \vec{X}\{\Big[\sum_{\vec{Y}} P'_M(\vec{X}, \vec{Y}) J_{\max}(\vec{Y}) - J_{av}(\vec{X}) \Big] \\
&\geqslant -c\rho_t J^* - e_t J^* + c_1 P\{\vec{X}(t) \notin \boldsymbol{F}\} \\
&\quad + [c_2 d_t - c_3 (b_t)^N] P\{\vec{X}(t) \in \boldsymbol{F} \setminus B^*\} - c_3 (b_t)^N P\{\vec{X}(t) \in B^*\} \\
&\geqslant -c\rho_t J^* - e_t J^* + c_1 P\{\vec{X}(t) \notin \boldsymbol{F}\} \\
&\quad + c_2 d_t P\{\vec{X}(t) \in \boldsymbol{F} \setminus B^*\} - c_3 (b_t)^N.
\end{aligned}
$$

对上式从 1 到 M 求和得

$$
\begin{aligned}
J^* &\geqslant E(J_{av}(\vec{X}(M+1))) - E(J_{av}(\vec{X}(1))) \\
&\geqslant -\sum_{t=1}^{M} [(c\rho_t + e_t) J^* + c_3 (b_t)^N] + c_1 \sum_{t=1}^{M} P\{\vec{X}(t) \notin \boldsymbol{F}\} \\
&\quad + c_2 \sum_{t=1}^{M} d_t P\{\vec{X}(t) \in \boldsymbol{F} \setminus B^*\}.
\end{aligned}
$$

令 $M \to \infty$,上式推出

$$
\begin{aligned}
&J^* + \sum_{t=1}^{\infty} [(c\rho_t + e_t) J^* + c_3 (b_t)^N] \\
&\geqslant c_1 \sum_{t=1}^{\infty} P\{\vec{X}(t) \notin \boldsymbol{F}\} + c_2 \sum_{t=1}^{\infty} d_t P\{\vec{X}(t) \in \boldsymbol{F} \setminus B^*\}.
\end{aligned}
$$

根据假设(2)和(3),于是我们有

$$
\sum_{t=1}^{\infty} P\{\vec{X}(t) \in \boldsymbol{F}\} < \infty,
$$

$$
\sum_{t=1}^{\infty} d_t P\{\vec{X}(t) \in \boldsymbol{F} \setminus B^*\} < \infty,
$$

从而

$$
\sum_{t=1}^{\infty} d_t P\{\vec{X}(t) \notin B^*\} < \infty. \tag{1.187}
$$

第二步:证明 $\xi = J^*$, a.s.

因为,$\xi \leqslant J^*$, a.s.,只须证明 $P(\xi < J^*) = 0$. 若 $P(\xi < J^*) > 0$,则存在正

数ε和a使$P(\xi<f^*-2\varepsilon)>2a$.因为$J_{av}(\vec{X}(t))$,a.s.收敛到$\xi$,根据Egoroff定理,存在可测集$A$使$P(A)>1-a$且$J_{av}(\vec{X}(t))$在$A$上一致收敛,即对$\varepsilon>0$,存在$N$使对一切$\omega\in A$,当$t\geqslant N$时

$$\xi(\omega)-\varepsilon<J_{av}(\vec{X}(t)(\omega))<\xi(\omega)+\varepsilon.$$

令

$$B=A\cap\{\omega\mid\xi(\omega)<J^*-2\varepsilon\},$$

那么$P(B)\geqslant a$,且对一切$\omega\in B$和一切$t>N$,有

$$J_{av}(\vec{X}(t)(\omega))<\xi(\omega)+\varepsilon<J^*-\varepsilon\Rightarrow\vec{X}(t)(\omega)\notin B^*,$$

所以,对一切$t\geqslant N$,

$$P\{\vec{X}(t)(\omega)\notin B^*\}\geqslant a\Rightarrow\sum_{t=1}^{\infty}d_tP\{\vec{X}(t)(\omega)\notin B^*\}\geqslant a\sum_{t=N}^{\infty}d_t=\infty.$$

这与(1.187)矛盾.这一矛盾说明$\xi=J^*$(a.s.),从而定理结论(a)成立.

第三步:由第一步证知$\lim\limits_{t\to\infty}J_{av}(\vec{X}(t)(\omega))=J^*$(a.s.).因为$|\boldsymbol{H}_l^{\wedge}|$有限,收敛数列$\{J_{av}(\vec{X}(t)(\omega))\mid t\geqslant1,\omega\in\Omega\}$仅包含有限个不同的点,故对几乎所有的$\omega$,存在$N(\omega)$使得当$t\geqslant N(\omega)$时,$J_{av}(\vec{X}(t)(\omega))=J^*\Rightarrow\vec{X}(t)(\omega)\subseteq B^*$,即

$$P\{\bigcup_{k=1}^{\infty}\bigcap_{t=1}^{k}[\vec{X}(t)\subseteq B^*]\}=1.$$

这即推得结论(b)成立.

定理1.27的结论(a)说明:在条件(1)~(3)下,遗传算法(1.161)所生成的种群之适应值必趋于最优值;而(b)说明:算法将以概率1保证在有限步内达到问题的最优解.这里所证明的收敛性显然具有"有限终止"的特征,因而事实上也强于几乎必然收敛.

定理1.27可直接具体化到各类比例选择、杰出者选择以及最佳值选择型遗传算法.特别地,有以下定理.

定理1.28(标准型遗传算法的几乎必然收敛性) 对于使用比例选择、单点变异和单点交叉的遗传算法(1.161),如果其选择压$\{\rho_t\}$、交叉概率$\{P_{C(t)}\}$和变异概率$\{P_{M(t)}\}$满足

$$(\mathrm{p1})\ \sum_{t=1}^{\infty}[\rho_t+P_{C(t)}+(P_{M(t)})^N]<\infty.$$

$$(\mathrm{p2})\ \sum_{t=1}^{\infty}(P_{M(t)})^L=\infty.$$

则$\{\vec{X}(t)\}$几乎必然收敛到最优解集.

证明 根据定理1.2和(1.65)~(1.167),易求出,此时

$$a_t=(1-P_{m(t)})^L,\quad b_t=(1-P_{m(t)})^{L-1}P_{m(t)},\quad d_t=P_{m(t)}^L.$$

而依定理 1.3 和(1.176)

$$e_t = 1 - \bar{a}_t = 1 - \left[1 - \frac{L-1}{L}P_{C(t)}\right] = \frac{L-1}{L}P_{C(t)},$$

于是定理 1.27 推出定理 1.28.

推论 1.3（整体退火 GA 的几乎必然收敛性） 对于使用整体退火选择、单点交叉与点变异的遗传算法，如果其退火因子 $\{T_t\}$、交叉概率 $\{P_{C(t)}\}$ 和变异概率 $\{P_{M(t)}\}$ 满足

(p1) $\sum_{t=1}^{\infty} P_{C(t)} < \infty$.

(p2) $\sum_{t=1}^{\infty} (P_{M(t)})^N < \infty$, $\sum_{t=1}^{\infty} (P_{M(t)})^L = \infty$.

(p3) $T_t = O\left(\frac{\epsilon}{\ln(t)}\right)$, ϵ 为很小正数.

则 $\{\vec{X}(t)\}$ 几乎必然收敛到最优解集 B^*.

证明 整体退火选择相应于带尺度变换 $\sigma_t(x) = \exp(x/T_t)$ 的比例选择，从而由(1.175)易求得

$$\rho_t = e^{-\delta/T_t}.$$

于是，如取 $T_t = \epsilon/\ln(t)$，则 $\rho_t = (t)^{-\frac{\delta}{\epsilon}}$，当 $\epsilon < \delta$ 时 $\sum_{t=1}^{\infty} \rho_t < \infty$，从而条件(p1)～(p3)符合定理1.27中的条件(p1)～(p2)．故定理1.28蕴含推论1.3．从而完成了证明．

定理 1.29（最佳值选择 GA 的几乎必然收敛性） 对于使用最佳值选择、单点交叉与点变异的遗传算法，如果交叉概率 $\{P_{C(t)}\}$ 与变异概率 $\{P_{M(t)}\}$ 满足

(p1) $\sum_{t=1}^{\infty} [P_{C(t)} + (P_{M(t)})^N] < \infty$.

(p2) $\sum_{t=1}^{\infty} (P_{M(t)})^L = \infty$.

则 $\{\vec{X}(t)\}$ 几乎必然收敛到最优解集 B^*.

证明 注意到，此时相应于(1.178)中的 $c=0$，从而类似于定理 1.28 可证.

注意到，如有 $N > L$ 并有 $P_{M(t)} = O\left(\sqrt[L]{\frac{1}{t}}\right)$, $P_{C(t)} = o\left(\frac{1}{t}\right)$，则推论 1.3 和定理 1.29 中的所有条件满足．从而相应遗传算法几乎必然收敛.

完全类似的方法可讨论杰出者选择遗传算法、父子混合选择遗传算法的几乎必然收敛性．有兴趣的读者可参见文献[134]，[135]，[136]，[137]，[138]以及[149].

§1.6 评注与展望

在以上各节中，我们系统介绍了 SEC 的一般框架、基本要素与执行策略，并且针对遗传算法阐述了其搜索机理与收敛性理论. 所有这些无疑是 SEC 的最基础、最核心内容. 但应该注意到，SEC 是正处蓬勃发展中的学科领域，许许多多新的 SEC 执行方案与新的理论不断涌现. 限于篇幅，本章对这些则未能尽述. 作为弥补，本节对 SEC(特别是 GA)的近期发展与研究趋势给出一个综合的评注.

1.6.1 有关理论基础研究

SEC 产生于 20 世纪 60 年代(更具体地，Holland 的遗传算法，Rechenberg 和 Schwefel 的演化策略和 Fogel 的进化规划)，但真正引起普遍关注和广泛应用则始于 20 世纪 80 年代. 除 20 世纪 70 年代初 Holland 本人对遗传算法提出模式理论，Rechenberg 及他的学生们对演化策略所作的收敛性分析之外，对 SEC 的基础理论研究基本上无大的进展，较为系统的工作则出现在近十年[134].

SEC 的理论基础研究主要集中于对 SEC 搜索机理、收敛性、收敛速度、复杂性、有效性、能解性等基本理论问题的探索，其目的在于从理论上阐明 SEC 的工作原理与性态，从而为 SEC 技术的发展、比较与应用提供理论依据.

以遗传算法为例，20 世纪 70 年代到 80 年代初人们所普遍关注的基础问题是搜索机理，即试图澄清遗传算法到底是如何有效工作的. 这方面的代表性工作是由 Holland 本人所提出的模式定理，以及由此所派生的积木块假设与隐含并行性(implicit parallelism)分析(文献[45]). 有关模式定理与积木块假设，我们已在 4.1.1 节中作了介绍，而有关遗传算法的隐含并行性通常则是指“在遗传算法的进化进程中每一代表面上只处理 N 个个体，但实际上并行处理与 N 的立方成比例的模式数”这一论断. 模式定理，积木块假设与隐含并行性一起构成遗传算法所谓的模式理论. 这一理论长期被接受为遗传算法的基本理论(事实上，国内外大部分著作或教材都是以此为据陈述遗传算法的理论基础的)，特别地，模式定理与积木块假设常被用以解释遗传算法的搜索机制，而隐含并行性被用以解释遗传算法的有效性(文献[21]，[36]，[44]，[17]，[69]，[72]，[157]). 然而，遗憾的是，除模式定理(即定理 1.3)外，模式理论中的大部分结论都未得到严格的数学证明，而且在一定意义上也是似是而非的陈述. 所以，用以解释遗传算法的搜索机制与有效性，模式理论难以令人信服(由此引起的大量有关遗传算法欺骗问题的研究从一个侧面说明了这一点).

基于上述认识,本书采用详尽刻画遗传算法诸进化算子搜索能力的角度阐述 GA 的搜索机制.特别 1.4.2--1.4.4 节所介绍的内容是本书作者与他们的同事在 20 世纪 90 年代后期所完成的工作(文献[60],[61],[134]--[138],[149],[152]).这些工作与模式理论不同,所有论断建立在严密的数学论证之基础上,而且它不仅清晰刻画了各个遗传算子的搜索能力,而且也清晰刻画了各遗传操作的合作机制.从这些研究中,我们揭示了一个重要事实:交叉操作的作用是有限的,而变异算子的作用是更为重要而基本的.这一认识与对遗传算法的传统认识有很大区别.

有关遗传算法的收敛性研究是过去十年间遗传算法基础研究的核心,已有一系列重要工作.这些工作依所采用的研究方法与所使用的数学工具可大致分为四类,即马氏链模型,Vose-Liepins 模型、公理化模型与连续(积分算子)模型(文献[134]).马氏链模型是描述遗传算法的最直接和最直观的模型,有表述清晰和精确的优点.已有马氏链理论既可直接应用(例如 Eiben(1991),Nix 和 Vose(1992),Horn(1993),Mahfoua(1993),Dawid(1994),Rudolph(1994),Susuki(1995),文献[8],[16],[48],[54],[65],[76],[101],[104],[105],[114]),也可结合其他方法使用,例如,结合模拟退火算法理论(Davis 与 Principle,1991,文献[18])、结合张量表达与抽样理论(Reynolds 与 Gomatam,1996,文献[87])、结合动力系统随机扰动理论(Cerf,1994,文献[12])等等.然而由于马氏链理论本身的限制,使用马氏链模型通常只能刻画二进制或特殊非二进制遗传算法,既使如此,由于相应的马氏链状态数(从而转移概率矩阵规模)通常很大,具体确定、分析转移矩阵的性态十分困难(更不用说具体描述其平稳分布),因而对于较大规模的 GA,马氏链分析只能基于遍历性考察而得出相应 GA 收敛性的某些"粗糙"结论(例如,所能获得的收敛性通常是相应马氏链趋于某一平稳分布,即分布收敛性).另外,截止目前,运用马氏链分析 GA 的几乎所有研究都只考虑时齐遗传算法,所用方法显然不能推广到自适应型 GA 变形.

Vose-Liepins 模型是 Vose 和 Liepins(1991,文献[104])所发展的分析标准遗传算法的一类确定性方法.这类方法的核心思想是用两个确定型矩阵算子分别描述选择与繁殖操作,而通过研究这两个算子的不动点的存在性与稳定性来刻画相应 GA 的渐近行为.除 Vose 与 Liepins(1991),Koehler(1992,文献[54]),Bhattacharyya 与 Koehler(1994,文献[8]),Wright 和 Vose(1996,文献[114]),Vose(1996,文献[105])等都围绕这一方法作了大量有深度的工作.Vose-Liepins 模型虽然提供了用确定型(非随机)不动点迭代精确描述与分析遗传算法的途径(从而可运用泛函分析与动力系统工具),但遗憾的是相应的非线性算子只能对几个非常特别的遗传算子加以确定,而且即使对这些特别

情形，相应非线性算子的不动点迭代收敛时是否收敛到问题的全局最优仍是不清楚的问题.

公理化模型是本书作者所在研究集体所创立的既可用于一般编码、非时齐遗传算法收敛性分析，又可用于其他 SEA 分析的概率估计方法(文献[60]，[61]，[134]～[138]，[149]).正如本章所介绍的，这一方法的核心思想是：通过公理化描述 SEA 中的各种进化算子(如选择算子、繁殖(交叉与变异等)算子等)，并引进各进化算子的本质特征数(如选择压、选择强度、进化吸收率、散射率等)，而应用进化算子特征数来刻画算法的各种收敛性态.这一分析方法的最大优点是：直接和适应性强(几乎可应用到所用进化算子所组合产生的 GA)，能产生直接指导应用的进化参数设置策略.但缺点是对连续型 SEA，计算相应进化算子特征数比较困难.

对于连续编码遗传算法的收敛性分析，多位作者采用了连续(积分算子)模型.例如，Peck 和 Dhawan(1995，文献[80])将遗传算法纳入一般的全局随机搜索方法框架，而将 GA 迭代过程描述作可行解空间上某些抽象分布的构造与演化，然后运用有关全局随机搜索的已有收敛性理论来研究连续编码遗传算法的收敛性；Qi 和 Palmieri(1994，文献[84])通过导出连续 GA 在使用比例选择、均匀交叉、选择与变异以及三个遗传算子联合作用等情形，当种群规模趋于无穷时，种群的概率分布所对应的密度函数应满足的递归公式，而研究了 GA 种群平均适应度的收敛性.使用连续(积分算子)模型研究遗传算法通常需要或对适应度函数、或对种群规模施加苛刻限制，因而有较少实用价值.

与收敛性分析紧密相关的另一基本理论问题是遗传算法能以多块的速度收敛.这方面的研究不仅可从另一侧面来阐明 GA 的收敛性，而且对于建立合适的停机准则及恰当的度量标准以全面、客观地评判 GA 各种执行策略有重要意义.然而，到目前为止，有关 GA 收敛速度与复杂性研究仅有少量且仅只适用于某些特殊情形的工作.这些工作包括有关收敛速度估计、迭代次数估计和时间复杂性估计等三个方面.

取决于采用何种框架与分析方法，用于估计 GA 收敛速度通常采用不同准则，例如常见的有：以种群平均适应度，以发现最优解的概率，以种群概率分布趋于稳态分布的速率等.对于一类特殊的组合优化问题——1 和问题，Rabinovich 和 Wigderson(1991，文献[85])分析了带比例选择与均匀交叉情形二进制 GA 在种群平均适应度意义下的收敛速度，证明了线性收敛性；以包含最优解的种群出现的概率和趋于 1 为准则并假设交叉的概率为 1，Suzuki(1995，文献[101])利用概率转移矩阵的特征值导出了杰出者选择遗传算法的几何收敛速度

$$q^t \geqslant 1 - C\,|\lambda_*|^t \quad (t = 0, 1, 2, \cdots),$$

这里 q^t 是第 t 次迭代的每个包含最优解的种群出现的概率和，C 是常数，λ_2 是相应遗传算法马氏链转移矩阵的最大特征值(必小于 1)；对于种群规模无限的 GA，Vogel(1996，文献[103])分析了当孤立、重复地应用单个遗传算子(如仅使用交叉或变异算子)情形种群的分布趋于极限分布的速度．另外，对于可分目标函数 $f(x)=\sum_{i=1}^{n} f_i(x_i)$，Salomon(1997，文献[58])分析了只使用变异算子的杰出选择型连续 GA 的收敛速度．

代替直接考虑收敛速度，也有作者通过估计在一定准则下遗传算法满足终止条件所需的迭代次数(或界)来阐明它的渐近行为．例如，通过引进模式的可靠性概念，并建立相应的随机可靠性模型，Chakraborty 和 Dastidar(1993，文献[13])运用可靠性分析方法研究了标准遗传算法收敛所需的演化步数；Aytug 和 Koehlen(1996，文献[5])利用马氏链中的首次访问时间概念，估计出 GA 在一定置信水平下访问到所有可能种群状态所需的进化代数等．

有关 GA 时间复杂性的分析，Ankenbrandt(1991，文献[1])通过引进适应值比率(fitness ratio)的概念并假设其在种群进化中保持不变，给出了二进制无交叉作用 GA 达到收敛所需的时间表达式及相应的平均、最坏情形时间估计；Asoh 和 Muhlenbein(1994，文献[3])就简单抽样(代替选择操作)与均匀交叉这两个特殊情形，给出了计算 GA 平均收敛时间的公式；以种群的平均哈明距离为度量，Louis 和 Rawlins(1993，文献[64])考虑了选择算子收敛的时间界估计．另外，Salomon(1997，文献[96])分析了只带变异的杰出选择连续遗传算法用于可分适应度函数的时间复杂性．

概括地说，目前已有的关于遗传算法收敛速度与复杂性的结果基本限于二进制情形，而且或是对特殊的适应度函数，或是对仅使用某一个或两个遗传算子操作情形的 GA，仍不具有普遍性．

关于遗传算法的有效性与能解性研究，目前尚无理论结果．

遗传算法的理论基础研究无疑是当前 SEC 研究最倍受关注的热点领域，它不仅受理论探索自身的促动，而且也是解决 SEC 算法发展与应用诸多瓶颈问题的关键所在．

从大的方面说，目前尚没有非常好的框架(模型)与方法适用于研究一般 GA 的收敛性．已介绍的四种模型要么只适应于离散(二进制或特殊的二进制)GA、要么只适用于连续 GA、要么要求种群规模为无穷．由于遗传算法不是对单点而是对种群的演化，再加上其本身的随机性与固有的马氏性，我们认为运用测度值马氏过程及鞅收敛理论有望能在统一框架内研究各种形式 GA 的收敛性，并建立 GA 的更一般的收敛性理论．

类似地，对于 GA 收敛速度与复杂性的研究，目前结果不仅只限于若干非

常特殊的 GA，而且还没有一个通用的、合理的准则来度量 GA 的收敛速度．我们感到，一种可能的解决方法是：通过修正种群平均哈明距离使之可描述交叉、变异算子影响，然后将其与适应值函数的信息结合来设计收敛速度度量．由于修正的哈明距离将能充分反映在各个遗传算子作用下种群的变化（如多样性、是否趋于某一稳定状态等），而种群适应值变化反映迭代种群是否收敛到全局最优解，结合这二者预期可给出较合理的收敛速度度量，并有望建立统一的 GA 收敛速度分析方法．

要从根本上解决上述 GA 收敛性所存在的基础问题或许是相当困难的．但作者们以为，目前至少可从解决以下问题入手来扎扎实实推进该方面的研究：

(1)对非标准 GA 发展收敛性理论．当综合考虑三个遗传算子作用时，已有研究基本上均只考虑了“比例选择、单点杂交与单点变异”的标准情形，而大量应用实践已经说明，应用像杰出者选择、锦标赛选择、均匀杂交、多点杂交及非一致变异等非标准 GA 操作的遗传算法有较标准 GA 高得多的计算效率．所以对这些广泛形式的“非标准 GA”发展收敛性理论有重要意义和迫切性．

(2)对已有收敛性分析模型的深化研究．特别地，对 Vose-Liepins 模型可考虑扩大适用范围和通过对其相应算子方程的深入不动点结构分析与稳定性分析来清晰刻画 GA 的收敛性；对 Markov 链模型可考虑：(a)从更精细的层次（例如从个体或基因层次）描述与分析 GA；(b)通过对概率转移矩阵的细致谱分析来研究 GA 的收敛性与收敛速度；(c)发展非遍历性分析方法；(d)通过研究平稳分布的高阶矩信息，获得 GA 收敛状态的精确刻画；对公理化模型可考虑各类 GA 算子复合情形选择压、选择强度、吸收率与散射率等演化参数的精确确定；弱化一般收敛性定理；并最终用于刻画 GA 收敛性态与 GA 参数之间的函数关系，．

(3)对 GA 过早收敛现象的理论分析．GA 的应用目的在于寻找所求解问题的全局最优解，但 GA 的应用实践却表明：GA 常收敛到非最优或局部最优状态（即过早收敛现象）．本书作者（文献[61]，[135]）运用种群多样度概念仔细分析了标准 GA 的过早收敛特征，问题是：这一分析对于非标准 GA 成立吗？特别是，如何从理论上刻画和平衡种群多样度与选择压，使在不发生过早收敛的前提下，GA 尽快收敛？

(4)关于 GA 的效率加速理论．除可有效用于传统优化（搜索）方法所不能求解的问题外，现有 GA 执行策略用于常规问题求解其效率常不明显优于传统方法．我们认为：目前影响 GA 算法效率的主要原因至少包括：(a)GA 的随机操作引起算法执行中不可避免的重复抽样（resampling）；(b)算法过分强化了对种群内部演化机制的模拟，而忽略了在种群演化中环境对种群的反作用；

(c)广泛使用"杰出者选择"所引起的时间复杂性等.目前急需研究在 GA 执行中运用避免(或利用)resampling 的有效策略、模拟在环境影响下受训种群的快速进化机制及建立非杰出者选择型 GA 的收敛性理论.

(5)关于 GA 的有用性(utility)与有效性研究.基于 Wolpert 和 Macready 的文献[64]的 No-Free-Lunch(NFL)定理,近年来有作者对 GA 的有用性与有效性提出质疑(如见 Salomon 的文献[96]).假设所有可能的目标函数服从均匀分布,NFL 定理的基本结论是:相对于所有可能的目标函数,任何最优化方法在平均意义下是同等有效的.Salomon 据此认为:GA 与别的优化方法至多是一样有效的,而通过对简单 GA 的分析,他进而认为:GA 事实上不会比其他确定性算法更有效!果真如此吗?是否 GA 根本就无用?是否 GA 根本就不可能比其他算法有效?回答这些问题显然极具挑战性,需要对 GA 理论本身的透彻理解,需要对 GA 执行策略的不断发展.然而,我们的看法是:基于 NFL 定理来扼杀 GA 明显是错误的.这是因为,首先,NFL 定理所基于的"所有可能目标函数类型服从均匀分布"的假设并不符合实际(例如,线性函数与非线性函数等概率出现吗?);其次,GA 的产生与发展其主要动机(从而应用对象)在于求解那些通常优化方法所无法或难以求解的"困难"优化问题,以平均表现来否定 GA 的效率显然有失公允;再则,GA 是正处发展中的技术,应该说只是有了一个基本的框架,而有关它的搜索机制、基本理论与有效执行策略等还只是正在探索中的问题,只是通过分析"简单 GA"而否定一般 GA 显然是不科学和危险的.当然,目前的问题是,我们急需对 GA 的本质与基础理论作透彻的研究,需要将 GA 研究(特别是算法设计与应用)聚焦于"困难"优化问题,而真正发展出对"困难"问题有效(而其他方法不可用或不有效)的 GA 执行策略.

1.6.2 有关算法设计方面

算法设计是 SEC 的核心,从 SEC 的产生到此后长时期内,它一直是人们所关注的主要方面.该方面的研究始终围绕两个永恒的主题:一是扩大可应用领域;二是使之更加有效.前者旨在设计和发现有效的 SEC 执行策略以解决过去不能解决,或不能有效解决的问题,而后者则在于修正和改进已有算法,使之更加有效或具有所期望的某种特别性态.从方法论上说,算法研究主要是从更宏观、更本质的角度模拟自然进化原理与机制,模拟生物智能的生成过程,并用以求解问题,进而溶合数学、生物、计算机技术等各领域的原理与技巧,使所设计出的 SEC 执行策略有预期性态、有效.

以遗传算法为例,Holland 最初应用生物遗传和进化的思想来研究自然和人工自适应系统的生成以及它们与环境的关系,提出在研究和设计人工自适

应系统时，可以借鉴生物机制，以群体的方式进行自适应搜索；他的思想被他的学生 Bagley(1967)在其博士论文中具体化和系统化，首次提出了“遗传算法”一词，并发展了复制、交叉、变异、显性等遗传算子，在个体编码上使用了双倍体的类生物编码方式. 1975 年，De Jong 首次将遗传算法应用于函数优化，并建立起了目前为人们所熟悉的遗传算法工作框架. 此后，以优化问题为背景，遗传算法的各种改进与推广层出不穷，最典型的例如包括：Goldberg 等(1989，文献[37])的混乱遗传算法(messy GA)，Schraudolph 和 Belew(1992，文献[97])的动态参数编码遗传算法(dynamic parameter encoding GA)，Eshelman 和 Schaffer (1993，文献[65])的实编码遗传算法(real coded GA)，Davis (1991，文献[17])的混合遗传算法(hybrid GA)，Potter 和 De Jong (1994，文献[82])的合作共存演化遗传算法(cooperative coevolutionary GA)，Mathias 和 Whitley (1995，文献[110])的 δ 编码遗传算法(δ-coding GA)，Tsutsui 等(1997，文献[102])的分岔遗传算法(forking GA)等. 这些改进与推广的遗传算法或从模拟特定的生物进化机制，或从改进现有遗传算法性态的意义上发展和丰富了遗传算法执行策略.

从开拓遗传算法的应用领域角度，近年来人们特别关注发展对于多目标优化、多态优化与各种组合问题的遗传算法执行策略. 基于对种群小生境进化的模拟和采用适应值共享策略，Goldberg 和 Richardson(1987，文献[19])，Deb[38]等发展了一系列有效的多目标优化问题遗传算法(详见综述文献[6]). 这些算法已充分显示出较传统多目标优化算法的优越性与有效性. 对于各种各样的组合问题(如 TSP 问题，MDR 问题、最大独立集问题等)，通过耦合与问题相关的启发式信息(即采用混合策略)，已经发展出非常有效的混合遗传算法执行策略. 另外，不限于遗传算法框架，Colori 和 Dorgo[15]等人所发展的蚁群算法(ant colony optimizatin)也是一类值得注意的求解组合问题的模拟进化算法. 这类算法模拟蚂蚁群在搜索食物进程中的信息交换与记忆机制，并结合问题本身所提供的启发式信息求解问题.

针对专门领域发展 SEC 执行策略是 SEC 算法设计的又一侧重点与有效途径. Holland[45]等人所发展的分类系统(classifier system)是基于遗传算法的机器学习系统；Yao 等人[118]所发展的演化神经网络(evolutionary artificial neural networks)是基于 SEC 设计与训练人工神经网络的自适应系统；Dorigo, Schnept, Cliff, Harvey, Husbands 等人[14],[22]所发展的演化机器人学(evolutionany robotics)则是 SEC 与机器人学相互结合的产物. 所有这些系统都可以认为是自适应机器学习系统，它们具有对自身结构进行调整，以改进性能或者改进其内部知识结构的特征. SEC 是这些自适应学习系统中搜索、调整结构的核心技术.

有关SEC执行策略的进一步研究,作者建议以下方面:

(1)关于SEC的效率加速策略与算法.提高现有SEA的计算效率无疑仍是SEC算法研究的当务之急.除应大力研究有克服1.6.1节中所述影响GA效率的新型执行策略外,发掘如何有效执行SEA,以及如何将SEA与其他高效计算方法结合有重要意义.综合运用各种领域的各种技巧(如耦合领域知识、专家知识,采用自适应操作、并行实现、混合非SEC型算法等)应该是一个可行途径.

(2)发展基于仿生与数理分析驱动相结合的新型执行策略.现有SEC算法基本上是以模拟生物进化机制与原理而设计的,这是SEC的出发点和基本点.但由于人们对于生物进化的本质机理还不能说有了透彻认识,再加之,即使在某些方面已有较本质的认识,要用某些简单的操作去模拟如此复杂的生化过程显然也绝非可能,所以,一味地"照搬生物"或者基于仿生去设计SEC执行策略未必总能得到好的效果(尤其对于特定的目标来说),而反之,基于数理分析所能获得的诸多启示,虽然它们不见得有明确的生物意义或解释,但或许能更清晰地对有效算法的设计提供理论指导.举例说,在1.2.4—1.2.5节中我们已经以公理化的形式给出了选择算子与繁殖算子(变异与交叉算子)的定义,而在1.5.2节中我们也已经看到,在这些抽象算子特征数满足一定条件下,相应SEA就必然收敛.这些抽象进化算子的定义与抽象收敛性定理显然与生物进化操作无关,而在这样的一般纯数理分析的框架下,SEA只是它的一种特例.于是,我们的问题自然是:如果不受仿生的束缚,基于这样的一般理论能设计出一些新的、更有效的选择算子与繁殖算子吗?

与此紧密相关的一个研究方面是:如何依据或独立于已有SEC而发展纯粹基于抽样的抽样型SEA?

(3)各种SEC执行策略与其他相关算法的比较研究.尽管在同一类SEC执行策略中(如GA中,ES中等)已有不少的比较工作,但在大类(如GA与ES之间)及SEC类与非SEC类之间的比较工作仍很少见.这样的比较对于澄清SEC的能解性与难易度有意义.特别地,对于给定的一个或一类问题,我们希望回答:它们是适合于GA求解,还是适合于ES或EP求解?哪一个更有效?为什么?

(4)深化专门领域的SEC执行策略研究.已提及的分类系统、演化神经网络、演化机器人学、蚁群算法以及演化模糊系统、人工生命等均是结合专门领域的SEC执行策略,结合相关领域知识深化这些SEC执行策略无论在理论上,还是在应用上都是迫切和重要的.

1.6.3 有关模拟进化计算的应用

SEC提供了一种求解复杂、困难优化问题的通用框架，它不依赖于问题的具体领域，不要求目标函数有明确的解析表达，对问题的种类有很强的鲁棒性，所以已广泛应用于很多学科(文献[17]，[69]，[72])．下面是SEC的一些主要成功应用领域：

(1)多目标规划、多态优化等函数优化问题．函数优化是SEC的经典应用领域，也是对SEC进行性能测试的常用算例．除ES主要应用于函数优化问题外，GA也常应用于离散函数、随机函数、非凸函数等复杂函数的优化．如上节所述，GA在这方面最突出的应用是对多目标规划与多态优化问题．在这些应用中，GA能自然产生问题的群体解(而且常是在Pareto集中均匀分布的一组解)，已显示出较古典方法优越得多的本质优点．

(2)组合优化问题．随着问题规模的增大，组合优化问题的搜索空间也急剧扩大，有时在目前的计算机上用传统的枚举法很难甚至不可能求出其精确最优解．对这类问题，人们已意识到应把主要精力放在寻求其满意解上．由于这类问题常常能以0-1字符串自然编码，而且已存在大量寻找诸如最短路经的经典算法，GA被发现是求解这类问题满意解的最佳工具之一(尤其是与其他启发式算法结合时)．实践证明，GA对于大部分组合优化中的NP完全问题都十分有效．例如，GA已在求解TSP、MDR、背包问题、装箱问题、图着色问题、最大独立集问题等方面得到成功的应用．

(3)生产调度问题．生产调度问题在很多情况下所建立起来的数学模型难以精确求解，既使经过一些简化之后可以求解，也会因简化太多而使求解结果与实际相差甚远．由于可采用符号编码，而且不必使用恰好的目标函数估值，GA也成为解决复杂调度问题的有效工具．在单件生产车间调度、流水线生产车间调度、生产规划、任务分配、虚拟企业中的伙伴选择等方面GA都得到了有效的应用．

(4)自动控制．在自动控制领域有很多与优化相关的问题需要求解，而且这些优化问题通常要么是通过积分表达的，要么是写不出明确而严格的解析表达式(如描述某台机组的状态时)．GA在求解这类自动控制问题方面已显示出其独特优点．例如，用GA进行航空控制系统的优化、用GA优化设计透平机械、设计模糊控制器等，都取得了较好的效果．

(5)反问题求解．地质勘探、石油勘探、水下采矿、医疗诊断等应用自然归结为某个偏微分方程或某个参数模型的反问题求解．反问题求解最终可化归为依据有限输入－输出的参数辨识问题．当用优化方法求解这样的参数辨识问题时，其目标函数常常是不能恰好估值的，因而非常适合于应用GA求解．

目前GA已在模式识别、图像恢复、图像边缘特征提取,以及CT诊断、地震波分析等方面得到应用.

(6)机器人学.机器人是一类复杂的难以精确建模的人工系统,而GA的起源正来自于对人工自适应系统的研究,所以机器人学自然也是SEC的一个重要应用领域.例如,GA已在机器人的运动轨道设计、机器人逆运动学求解、细胞机器人的结构优化和行为协调等方面取得成功应用.

(7)生物计算.生物信息学中的基因拼接涉及以有限字符串(DNA片断)为变量的优化;蛋白质结构预测及药物设计涉及基本的分子计算,而分子计算是典型的大规模、多态优化问题.已有许多作者研究GA在求解这些典型困难优化问题中的应用.

(8)人工生命.人工生命是用计算机、机械等人工媒体模拟或构造出具有自然生物系统特有行为的人造系统.自组织能力与自学习能力是人工生命的两大主要特征.人工生命与GA有密切的关系,基于GA的进化模型是研究人工生命现象的重要基础.虽然人工生命的研究尚处于初级阶段,但GA已在其中的进化模型、学习模型、行为模型、自组织模型等方面显示出了初步的应用能力,并且必将得到更为深入的应用和发展.GA为人工生命提供了一种模型化方法,而人工生命又将为GA提供更为丰富的发展源泉,这二者相辅相成,必将相互促进发展.

(9)程序自动化.Koza[59]发展了遗传编程的概念,他使用了以LISP语言所表示的染色体编码方法,基于对一种树型结构所进行的遗传操作来自动生成计算机程序.虽然遗传编程的理论和方法尚不成熟,但已成功地应用于人工智能与机器学习等领域.

(10)机器学习.学习能力是高级自适应系统所应具备的特征之一.基于GA的机器学习在很多方面都得到成功应用.例如,GA被用来学习模糊控制规则、确定模糊集的隶属函数、改进模糊系统的性能;被用来调整人工神经网络的连接权及网络拓扑优化;分类系统也在学习式多机器人路径规划系统中得到成功应用.

第二章　仿生结构算法：人工神经网络

神经网络是一类由结点相互联接所组成的计算模型，每一结点通过简单的运算完成从输入到输出的计算，然后这一输出结果通过连接传到其他结点（理论上亦可传到自身）．这一相当简单的计算模型被称为“人工神经网络”或简称为“神经网络”，其原因在于它是大脑神经系统的模拟：结点对应神经元，连接对应神经元传递信号的突触．

长期的自然进化赋予了人脑许多现代计算机所不具备的良好性质，这些性质包括

- 巨量并行性
- 分布式表示和计算
- 学习能力
- 推广能力
- 自适应性
- 容错能力
- 低能耗等

人工神经网络的目的是希望基于生物神经网络原理而设计的设备或算法具有这些所希望的性质．

由于神经网络是一计算模型且较之现代数字计算机功能更为强大，因此那些在现行计算机上可完成的工作均可用神经网络来完成，这也是不同学科的专家进入人工神经网络研究和应用领域的主要原因．另外，由于神经网络有着生物模型、数学模型和工程应用以及硬件实现等众多不同的面相，加之这一学科从历史的角度来看仍处于发展的初期阶段，使得我们对于这一学科的彻底理解和建立一致理论几乎没有可能．本章我们将简要地介绍神经网络的生物背景，然后将我们的讨论仅限于几类解决函数逼近，分类和聚类、预测、优化和索址记忆问题的人工神经网络模型的数学表示和性质．

§2.1　引　言

本节我们将简要介绍神经网络的生物背景、数学模型和学习机理．

2.1.1　生物神经元和生物神经网络

人工神经网络直接受神经生理学和生物解剖学研究的启发．一个简单的

神经细胞通常称之为神经元，细胞的胞体是一球形，由胞体延伸出来的主要管状信号传输神经纤维称为轴突(axon)，胞体上其他又细又短的纤维称为树突(dendrities)，整个神经细胞——胞体、轴突和树突——通通包含在细胞膜内.

胞体和树突接受来自其他神经元的信息，突触将一个神经元的信息传给其他神经细胞.

轴突的长度从数毫米到一米不等，而树突仅有一毫米左右.在轴突的终端附近，它通常分成许多分枝，这些分枝的终端与其他神经元的胞体或树突非常接近但不互相接触，在这称之为突触(synapse)的区域，信息从称之为突触前细胞神经元传到突触后神经元.信息通过突触的传递称为化学传递，因其利用化学物质的扩散来完成信息的传递.

神经元有许多不同的种类，具有相似或相关功能的神经元通常相互联接.紧密联接的神经元通常在神经系统中聚集在一起(它们具有明显的解剖学特征)，其明显原因是短突触更有效；它容易生成；所费材料少；占据更小的突间；且传递信息快.这一结构的形成原理可用于城市规划、网络建设和研究各种自然现象的自组织行为.自组织特征映射算法便是基于这一结构的形成原理而设计.

大脑大致包含了数百个这样的细胞聚合块，它们的形状多为球形和盘状.短的连接出现在同一结构中，结构和结构之间由大量长神经纤维形成的束(tract)来联接，球或盘的顺序联接称为通道(pathway).大脑便通过这些以复杂方式联接起来的神经元形成的网络处理各式各样的外部世界送入的信息.

由于现代计算技术的发展，我们对于外部世界的表示通常用一数字向量来表示，这一表示使得我们在自然科学的各领域获得了巨大的成功.那么，大脑是如何利用神经网络表示外部世界刺激，以及如何在这些表示上进行计算呢？下面我们将看到神经网络亦可用一组向量表示外部事件的刺激，但其计算的方式却与现行的数字计算机的运算方式大相径庭.

我们首先就感觉神经元对外部世界刺激的编码开始.

感觉神经元是那些输入是外部世界刺激的神经元.我们的感觉包括味觉、色觉、嗅觉、听觉和体觉等.下面我们简述神经系统是怎样表示“色、香、味”这些日常感觉的.

味觉编码：在舌头上有四种不同的接受细胞，每一种细胞以其自身特殊的方式对任一给定的与它接触的物质作出反应.例如，一个桃子会对四种细胞中的第一个有强烈的作用，面对第二个仅有微小的作用，对其他两个具有中等的作用.由这些作用量值相对大小形成的一种神经“指纹”，它惟一刻画桃子的味道.如果我们将四种细胞分别命名为 a, b, c, d，而相应的刺激水平记为 S_a，S_b, S_c, S_d，那么向量(S_a, S_b, S_c, S_d)便构成了桃子的编码向量.这一表示的

重要意义在于:对于每一种人类可感知的味道,明显地存在着一个惟一的编码向量,也即是说,人类味觉可由四种感觉细胞的反应水平所构成的模式来刻画.

色觉编码:在人类视网膜上,有三种不同的色敏感细胞(锥细胞),这三种细胞分别对短、中、长波敏感,而每一种颜色由这三种细胞的相对兴奋水平,$S_{短}$, $S_{中}$, $S_{长}$ 惟一刻画,因此,五彩缤纷的外部世界在大脑中由向量($S_{短}$, $S_{中}$, $S_{长}$)表示.

嗅觉编码:嗅觉系统包含了6到7种甚至更多类互不相同的感受器,这即是说,嗅觉需要至少六七维向量来表示,因此我们用鼻子可区分巨大数量的不同气味.如果一个警犬具有七种嗅觉细胞且每一种细胞可以区分30种不同水平的刺激,则我们便可推出这一警犬可嗅出 30^7 或228亿种不同的味道.于是,狗能从数百万人中区别一个人的特定气味便不足为奇了.

其他的感觉系统亦用向量表示外部世界的刺激,同时、神经元的位置、激活水平、联接权重等均可用向量表示,因此,整个神经系统对外界的表示、系统的内部状态以及其输出均可由数字向量表示,这便是人工神经网络的基础假设之一.

向量表示提供了一种优美有效的表示方式,它可以表示神经网络的输入、输出以及内部状态,那么神经元和神经网络如何对这些向量进行操作以获得问题的解呢?我们下面将要讨论的人工神经元模型和神经网络模型便是受这一问题启发而设计的数学模型.

2.1.2 人工神经元和神经网络

一个人工神经元是生物神经元的极度简化,它的结构如图2.1.每一神经元 k 对输入向量$(x_1, \cdots, x_p)$进行简单的运算后得到的输出可表示为

$$y_k = \varphi(u_k - \theta_k), \tag{2.1}$$

其中

$$u_k = \sum_{j=1}^{p} w_{kj} x_j. \tag{2.2}$$

这里 x_j 为来自外部环境或其他神经元的信号强度,w_{kj} 为突触对信号的增强和抑制,θ_k 为细胞内阈值,φ 为细胞对信号的加工并称为激活函数,u_k 为线性组合输出,而 y_k 是神经元的最终输出信号.因此,对于任一人工神经元,我们有两种表示方式:图的表示和数学的表示.图的表示来自其生物解剖学的拓扑结构并用以清晰地表示数据信息的流向图,而数学的表示则用作计算处理的数学分析.

人工神经元的另外一个稍许不同但已被证明,可以极为方便的表示如下:

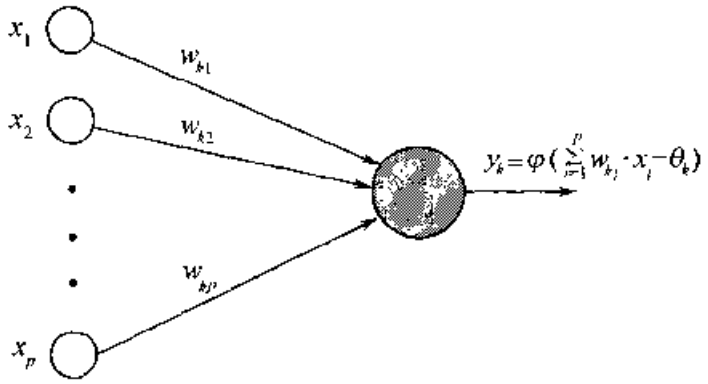


图 2.1 神经元模型

令

$$x_0 = -1. \tag{2.3}$$

且其权重为

$$w_{k_0} = \theta_k, \tag{2.4}$$

则神经元 k 的结构如图 2.2，而其数学表示式如下

$$y_k = \varphi(v_k), \tag{2.5}$$

其中

$$v_k = \sum_{j=0}^{p} w_{kj}x_j \tag{2.6}$$

在这一表示中，阈值 w_{k0}表示来自一个永远是 -1 的输入 x_0 的权重．v_k 称为神经元 k 的内部激活水平．

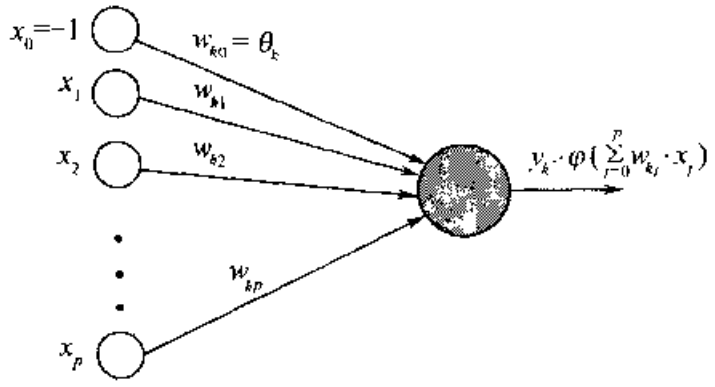


图 2.2 另一种神经元模型

由 φ 定义的激活函数决定神经元的输出，我们可定义三种基本的激活函数类型．

1. 阈值函数

对于这种类型的激活函数，我们有

$$\varphi(v) = \begin{cases} 1, & \text{如果 } v \geqslant 0, \\ 0, & \text{如果 } v < 0. \end{cases}$$

对应地，采用这种激活函数的神经元 k 的输出可表示为

$$y_k = \begin{cases} 1, & \text{如果 } v_k \geqslant 0, \\ 0, & \text{如果 } v_k < 0, \end{cases}$$

其中 v_k 是神经元的内部激活水平，即

$$v_k = \sum_{j=1}^{p} w_{kj} x_j + \theta_k.$$

这样的一个神经元在文献中称为 McCulloch-Pitts 模型，用以纪念 McCulloch 和 Pitts(1943)年关于这一模型的原创性工作. 在这一模型中，一个神经元当其内部激活水平非负时输出为 1，否则其输出为 0. 此即 McCulloch-Pitts 模型的全有或全无性质.

2. 分段线性函数.

分段线性函数的数学表示如下

$$\varphi(v) = \begin{cases} 1, & v \geqslant \frac{1}{2}, \\ v, & \frac{1}{2} > v > -\frac{1}{2}, \\ 0, & v \leqslant -\frac{1}{2}. \end{cases}$$

3. Sigmoid 函数

Sigmoid 函数或 S 形函数是迄今为止在神经网络的构造中最为常用的一种激活函数. 它是一类单增、光滑且具有渐近性质的函数，Sigmoid 函数的一个典型例子便是如下定义的 Logistic 函数

$$\varphi(v) = \frac{1}{1 + e^{-av}}, \tag{2.7}$$

其中 a 是这一 Sigmoid 函数的坡度参数，Sigmoid 函数亦可用双曲正切函数

$$\varphi(v) = \tanh\left(\frac{v}{2}\right) = \frac{1 - e^{-v}}{1 + e^{-v}}. \tag{2.8}$$

这一激活函数具有解析上的优点且具有一定的神经生理学证据支持.

人工神经网络可看成一加权有向图，图的结点为神经元而权为有向边与神经元之间的连接. 基于神经元的连接模式，人工神经网络可分为两大类

·前向网，相应的图无环出现.

·反馈网或回归网，由于反馈连接的出现，相应的图表示中有环出现.

前向网又可分为单层前向网和多层前向网，如图 2.3 和 2.4 所示. 网络的层数一般用可调节参数的层数来度量，如单层网只有一层可调节参数而两层前向网有两层可调参权. 对于那些既不是输入神经元又不是输出神经元的神经元，我们称其为隐神经元. 根据神经网络是否包含隐神经元，回归网又可分为无隐神经元的回归网和有隐神经元的回归网.

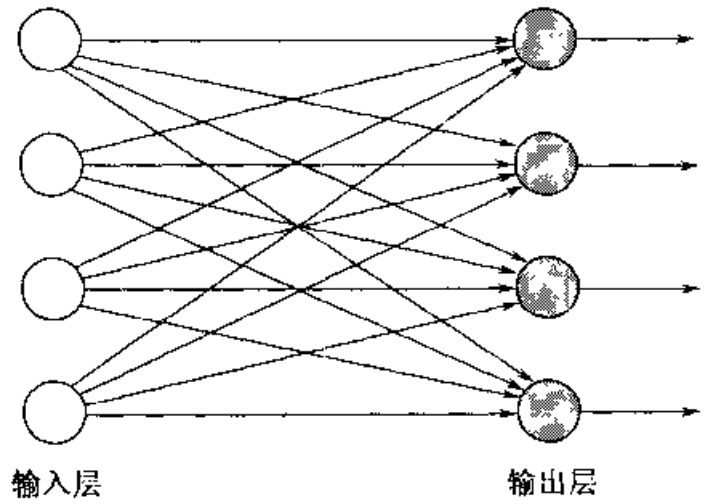


图 2.3 单层前向网

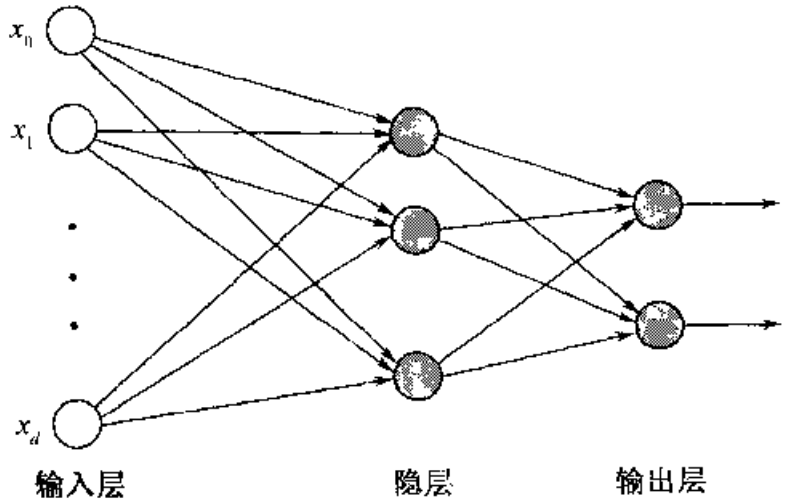


图 2.4 双层前向网

对于每一神经网络，我们亦可将其表示为数学公式. 例如，图 2.3 所示的单层网的公式表示为

$$y_k = \varphi\left(\sum_{j=0}^{p} w_{kj}x_j\right), \tag{2.9}$$

而图 2.4 所示双层前向网的公式表示为

$$y_k = \tilde{\varphi}\left(\sum_{j=0}^{p_2} w_{kj}^{(2)} \varphi\left(\sum_{i=0}^{p_1} w_{ji}^{(1)} x_i\right)\right), \tag{2.10}$$

其中 $\tilde{\varphi}$ 表示输出层的激活函数，而 φ 表示隐层的激活函数.

每一个神经网络有惟一的数学表示公式，而同一数学公式可由不同的网络结构表示，由于我们下面主要讨论神经网络的数学性质，故图的表示只起说明和辅助的作用.

2.1.3 学习过程

神经网络的主要特征是它的学习能力(或称可塑性、灵活性). 尽管神经网络的学习算法因结构不同而互异，但其共同之处在于：网络中的权重参数可进行调节以改进网络完成某项特殊任务的能力.

神经网络的学习通常由一个称之为训练集的数据驱动，训练数据通常可分为三类. 第一类数据仅由一组向量 $\{x^l\}_{l=1}^N \subset R^p$ 表示，第二类数据由一输入向量 x 和一相应的输出向量 y 组成的数据集合 $\{(x^l, y^l)\}_{l=1}^N$ 表示，在这类数据中 y^l 通常称为希望值或目标值. 第三类数据无希望值或目标值未曾给出，但当网络运行时我们却知道网络运行的好坏，这类数据主要出现在控制问题中.

按照数据类型，我们可将学习的方式分为三类. 网络由第一类数据驱动的学习称为无导师学习方式；网络由第二类数据驱动的学习称为有导师学习方式，而基于第三类的数据的学习称为强化学习. 在本书中我们将主要讨论前两类学习方式而不再讨论强化学习.

利用训练数据对权重 w_{kj} 的具体调节公式称为学习规则，这种具有明确定义的学习规则用以发现具体问题的解. 数学上讲，如果在时刻 n，网络的权重为 $w_{kj}(n)$，则学习过程便是利用训练数据调节 $w_{kj}(n)$，调节的公式可写为

$$w_{kj}(n+1) = w_{kj}(n) + \triangle w_{kj}(n). \tag{2.11}$$

调节后的权重将决定以后神经网络的运行方式. 而相应的调节公式便称为学习规则. 本质上，不同的学习算法之间的差别仅在于调节量 $\triangle w_{kj}(n)$ 的计算方式. 如果 $\triangle w_{kj}(n)$ 的计算依赖于所有训练数据，则我们称相应的学习过程为批学习，如果 $\triangle w_{kj}(n)$ 的计算仅依赖于网络的当前输入和输出(如希望输出给出)，则我们称相应的学习为在线学习或串行学习. 就神经网的学习算法而言，大部分为在线学习.

在所有学习规则中，由神经生理学家 Hebb 提出的 Hebb 学习假设最为著名. 在 Hebb 所处的时代，行为科学和神经生理学独立发展，由于 Hebb 的出色工作，他被后世认为是神经生理学在行为科学彼岸印上“蛙印”的第一人，Hebb 的学习假设可叙述为：

1. 如果一个突触两端的神经元同时兴奋或抑制，那么这一突触的强度应

得到加强.

2. 如果突触两端的神经元，一个兴奋而另一个抑制，则这一突触应该减弱或取消.

由于神经元 k 和神经元 j 之间的突触即为神经网络中此二神经元的联接强度 w_{kj}，故 Hebb 的假设事实上是一个调节 w_{kj} 的学习规则. 许多神经网络的学习规则或根据 Hebb 假设而导出，或与 Hebb 假设不谋而合. 设 x_j 和 y_k 为突触联接 w_{kj} 两端神经元的发放值，x_j 为输入变元而 y_k 为输出值. 则下面便是一些常用的满足 Hebb 假设的学习规则.

1. 乘积学习规则

$$\triangle w_{kj}(n) = \eta y_k(n) x_j(n). \tag{2.12}$$

其中 η 为学习速率.

2. 广义乘积学习规则

$$\triangle w_{kj}(n) = \eta y_k(n) x_j(n) - \alpha y_k(n) w_{kj}(n). \tag{2.13}$$

其中第一项为乘积学习规则项，而第二项为遗忘项，它用于防止 w_{kj} 的指数增长.

3. 协方差学习规则

$$\begin{aligned} \triangle w_{kj}(n) &= \eta \mathrm{cov}[y_k(n), x_j(n)] \\ &= \eta E[(y_k(n) - \bar{y})(x_j(n) - \bar{x})]. \end{aligned} \tag{2.14}$$

其中 E 为数学期望而 $\bar{y}$ 和 $\bar{x}$ 为相应神经元输出值的平均值. 这一学习规则是指权重的调节应与两神经元激活值的协方差成正比.

2.1.4 总结

人工神经网络是一由结点相互连接的计算模型，它是大脑神经系统的模拟；结点对应神经元而连接对应神经元传递信号的突触. 生物的神经元具有清晰而明确的信息处理能力，相应的生物神经元构成的网络对外部事件的表示是一数字向量表示，基于此而导出的人工神经元和神经网络的数学模型具有许多生物神经网络具有而传统数字计算机所不具备的良好性质，其最为突出的性质便是其学习能力，它允许网络中的参数根据训练数据进行调节以使网络更好地解决给定问题. 学习方式按训练数据可分为无导师学习，有导师学习和强化学习，而网络参数的具体调节规则称为学习规则，学习规则中最为著名的便是 Hebb 学习规则类，许多已有的学习规则均属此类或与此类的设计思想相吻合. 另外，根据学习规则中对训练数据的不同使用方式，学习算法又可分为批学习算法和在线学习算法. 在批学习算法中，权重的调节量由所有训练数据来确定，而在在线学习中，权重的调节量由当前数据确定.

§2.2 感知器和单层前向网

感知器是一个最为简单的神经网络，它由一个神经元构成，用于线性可分的模式分类(两类模式分别位于一超平面的两侧)．神经元的权重和阈值可以调节，调节这些自由参数的算法由 Rosenblatt(1962)提出，这一学习程序是其为他的感知器脑模型而设计．事实上，Rosenblatt 证明了如果用于训练感知器的模式(通常用向量表示)来自两个线性可分的类，则感知器学习算法收敛且作为决策面的超平面落于两类中间，这一结果通常称为感知器收敛定理．

单层网是对同一输入数据的多个感知器处理，它在 20 世纪 60 年代获得广泛研究，本章将介绍感受器学习算法和单层网的最小二乘算法．

2.2.1 分类问题

我们首先考虑最简单的两个类的分类问题，设 C_1 和 C_2 是由向量组成的两个类，如果存在一个函数 $u(x)$ 使得，当 $u(x)>0$ 时 x 属于类 C_1，而当 $u(x)<0$ 时，x 属于类 C_2，则函数 $u(x)$ 称为判别函数．曲面 $u(x)=0$ 称为决策面．如果对于两个类的分类问题，存在 x 的一个仿射线性函数

$$u(x) = w^{\mathrm{T}}x - \theta_0 = \sum_{i=1}^{d} w_i x_i - \theta_0, \tag{2.15}$$

构成分类问题的判别函数，则称相应的分类问题是线性可分的．

表达式 $u(x)=w^{\mathrm{T}}x-\theta_0$ 具有一个简单的几何解释．首先，我们注意到决策边界 $u(x)=0$ 对应于 d 维空间的 $d-1$ 维超平面，当特征向量 x 是二维空间的向量时，决策边界是一直线．如果 x^A 和 x^B 是超平面上的两个点，那么

$$u(x^A) = u(x^B) = 0. \tag{2.16}$$

利用公式(2.16)我们有

$$w^{\mathrm{T}}(x^B - x^A) = 0. \tag{2.17}$$

因此，w 与超平面上的任一向量相垂直，即 w 是超平面的法向量，它决定了决策边界的方向，如果 x 是超平面的一点，那么原点到超平面的垂直距离由下式给出

$$l = \frac{w^{\mathrm{T}}x}{\|w\|} = \frac{\theta_0}{\|w\|}. \tag{2.18}$$

公式的推导中使用了 $u(x)=0$ 的表达式，因此，θ_0 决定了超平面在 x 空间的位置．

如果我们令 $\tilde{w}=(\theta_0, w)$，而 $\tilde{x}=(-1, x)$，那么 $u(x)$ 可写成下面的形式

$$u(x) = u(\tilde{x}) = \tilde{w}^{\mathrm{T}}\tilde{x}^{\mathrm{T}} = \sum_{i=0}^{d} w_i x_i, \tag{2.19}$$

其中 $x_0=-1, w_0=\theta_0$，如果再令

$$y(x) = \varphi(u(x)) = \begin{cases} +1, & u(x) \geqslant 0, \\ -1, & u(x) < 0, \end{cases} \tag{2.20}$$

则 $y(x)=1$ 表示 x 属于类 C_1，$y(x)=-1$ 表示 x 属于类 C_2，由此定义的神经元

$$y(x) = \varphi(w^{\mathrm{T}}x - \theta_0) \tag{2.21}$$

称为感知器.

感知器的图示形式如图 2.1，输入 $x_1, \cdots, x_d$ 用圆环表示，它由权重 $w_1, \cdots, w_d$ 联接到输出 $y(x)$. 阈值 θ_0 是联接一个输入永远是 -1 的输入神经元 x_0 的权重.

分类问题的一般形式是将 k 个类 $C_1, C_2, \cdots, C_k$ 用判别函数 $u_k(x), k=1, \cdots, k$，分开，对每一个类 C_k 而言，其线性判别函数可写为

$$u_k(x) = w_k^{\mathrm{T}}x - \theta_{k_0}. \tag{2.22}$$

一个新输入的点 x 属于类 C_k 当且仅当 $u_k(x) > u_j(x)$ 对于所有 $j \neq k$ 均成立. 分离 C_k 和 C_j 的超平面由 $u_k(x) - u_j(x)$ 确定，对于线性判别函数，相应的超平面由公式(2.23)给出

$$(w_k - w_j)^{\mathrm{T}}x - (\theta_{k_0} - \theta_{j_0}) = 0. \tag{2.23}$$

类似于前面的讨论，我们知道决策超平面的法向量由 $(w_k - w_j)$ 确定，而原点与超平面的垂直短离为

$$l = -\frac{(\theta_{k_0} - \theta_{j_0})}{\| w_k - w_j \|}. \tag{2.24}$$

多类判别函数亦可用神经网络的图表示来刻画，函数 u_k 称为处理单元，判别函数值的计算可看成从输入到输出的信息流，每一输出 u_k 与一权重向量 w_k 和一阈值 θ_0 相关联，网络的输出形式上可表示为

$$y_k(x) = \sum_{i=0}^{d} w_{ki}x_i. \tag{2.25}$$

其中 $x_0 = -1$，$w_{k_0} = \theta_{k_0}$，激活函数为线性函数.

当网络训练完成后，一个输入向量 x 经处理单元计算后得 $u_k(x)$，然后该向量被赋于 $u_k(x)$ 最大的类，这一分类方法导出的决策区域(即每一个类所在的空间区域)总是一个简单的凸集. 事实上，设 x^A 和 x^B 均属于区域 R_k，它对应于 C_k 所在的类，那么，任一落于 x^A 和 x^B 的连线上的点 x 均可表示为

$$x = \alpha x^A + (1-\alpha)x^B,$$

其中 $0 \leqslant \alpha \leqslant 1$. 由于 x^A 和 x^B 均属于 R_k，故其必须满足

$$y_k(x^A) > y_j(x^A), \qquad j \neq k \text{ 且 } j = 1, \cdots, C,$$

$$y_k(x^B) > y_j(x^A), \qquad j \neq k \text{ 且 } j = 1, \cdots, C.$$

由于 $y_k(\bar{x}) = \alpha y_k(x^A) + (1-\alpha)$，故有

$$y_k(\bar{x}) > y_j(\bar{x}),$$

对所有 $j \neq k$ 成立，因此，连接 x^A 和 x^B 的线段上的所有点均属于 R_k，故 R_k 是一凸集.

迄今为止，我们所讨论的判别函数均为线性函数，它们的决策边界通常是一超平面，决策面的这一限制使得我们不能期望这一模型在实用问题中总给出最优解. 一种推广判别函数的方法是使用一组数目为 M 的预先给定的非线性函数 $\bar{\varphi}_j(x)$，$j = 1, \cdots, M$，对向量 x 首先进行变换，然后将判别函数 $u_k(x)$ 表示成这些函数的线性组合

$$u_k(x) = \sum_{j=1}^{M} w_{kj}\bar{\varphi}_j(x) - \theta_{k_0}. \tag{2.26}$$

这一判别函数允许决策边界具有更复杂的形状，相应的 $u_k(x)$ 可逼近更广类的函数. 事实上，对于适当选取的 $\bar{\varphi}_j(x)$，上述函数可逼近任何连续函数到任意精度. $\bar{\varphi}_j(x)$ 通常称为基函数.

我们也可以将阈值 θ_{k_0} 纳入一个统一的公式

$$u_k(x) = \sum_{j=1}^{M} w_{kj}\bar{\varphi}_j(x), \tag{2.27}$$

其中 $\bar{\varphi}_0(x) = -1$ 为一常值基函数.

在此我们假定基函数 $\bar{\varphi}_j(x)$ 固定，它独立于数据，以后所讨论的多层网可认为是上述广义线性判别函数的推广，在多层网络中，基函数本身在训练过程中可以进行调节.

2.2.2 感知器

具有阈值激活函数的单层网由 Rosenblatt(1958, 1962) 首先研究并被命名为感知器网. Rosenbatt 利用下述的学习算法将网络的学习过程和网络加以硬件实现，这些网络被应用于分类问题. 几乎在同一时期，Widrow(1960) 和其合作者也沿着同样的研究线路展开工作，他们的系统被命名为 Adalines. 术语 Adaline 来自 ASAptive LINear E lement，它本质上与 Rosenblatt 的感知器完全相同.

只有一层权重的神经网络具有极为有限的能力. 为了改进感知器的性能，Rosenblatt 使用了一层固定的处理单元用以转换原始的输入数据，如图 2.5 所示. 这些处理元可看作是广义线性判别函数的基函数，于是感知器的输出为

$$y = \varphi\left[\sum_{j=0}^{M} w_j\bar{\varphi}_j(x)\right] = \varphi(w^{\mathrm{T}}\bar{\varphi}), \tag{2.28}$$

其中 $w=(w_0, w_1, \cdots, w_M)^{\mathrm{T}}$，而 $\tilde{\varphi}=(\tilde{\varphi}_0, \cdots, \tilde{\varphi}_M)^{\mathrm{T}}$. 相应的输出单元的激活函数是一个阈值激活函数

$$\varphi(a)=\begin{cases}-1, & a<0,\\ +1, & a\geqslant 0.\end{cases} \tag{2.29}$$

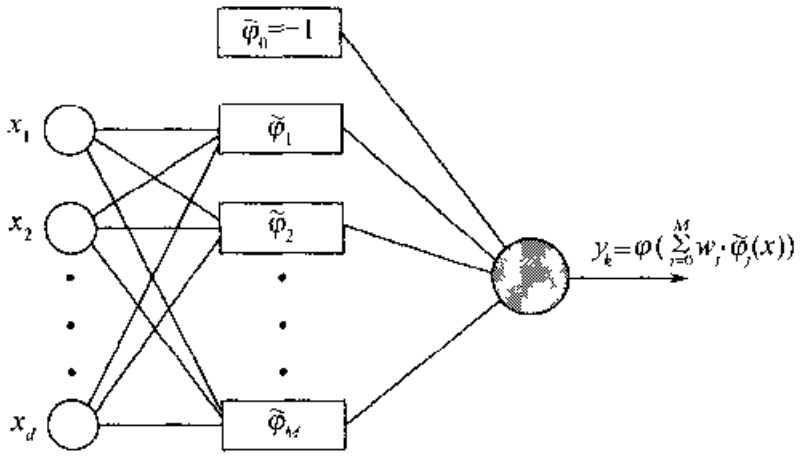


图 2.5 广义感知器模型

2.2.2.1 感知器准则

由于我们的目标是生成一个有效的分类系统，自然地，我们可将训练样本的错分数定义为目标函数. 然而这样的误差度量难以使用，其原因是权重的光滑变化会引起决策边界穿过数据点，从而导致误差函数的不连续变化. 因此，误差函数是分片常数的，从而依赖于梯度下降的优化程序不能使用. 我们必须寻找其他易于优化的误差函数.

本节我们考虑一种称之为感知器准则的连续分片线性函数. 当每一输入向量 x 输入到网络时，网络由第一层处理元产生一个对应的向量 $\tilde{\varphi}^n$. 假设我们将每一输入向量 x^n 与一目标值 t^n 相关联，使得如果输入向量 x^n 属于类 C_1，那么 $t^n=+1$，如果 x^n 属于类 C_2，则 $t^n=-1$，根据感知器激活函数定义，对于属于类 C_1 的向量，我们需要 $w^{\mathrm{T}}\tilde{\varphi}^n>0$，而对于属于类 C_2 的向量，我们需要 $w^{\mathrm{T}}\tilde{\varphi}^n<0$. 于是对于所有的输入向量，我们需要其满足 $w^{\mathrm{T}}(\tilde{\varphi}^n t^n)>0$. 根据这一结果，我们的感知器准则定义为

$$E^{perc}(w)=-\sum_{\tilde{\varphi}^n\in\mu} w^{\mathrm{T}}(\tilde{\varphi}^n t^n), \tag{2.30}$$

其中 μ 是在权重为 w 时的错分集对应的 $\tilde{\varphi}^n$ 的集合. 误差函数 $E^{perc}(w)$ 是有限个正项的和并且当所有数据点被正确分类时，其值为零. 从前面的讨论中我们可以看到，$E^{perc}(w)$ 是错分点到决策面的距离的绝对值和. 在训练中，当决策面移动时，如果一点穿过决策面，则穿越的点对 $E^{perc}(w)$ 的贡献消失，即

$w^{\mathrm{T}}\tilde{\varphi}^n=0$. 因此,感知器准则是一连续的分片线性函数.

2.2.2.2 感知器学习

如果我们使用在线的梯度学习方法,则权重 w 的调节方式为

$$w_j^{(\tau+1)}=w_j^{(\tau)}+\eta\tilde{\varphi}_j^n t^n. \tag{2.31}$$

这一学习算法相当简单,其训练集内的数据循环使用. 当一个数据点被当前网络正确分类时,权重不变,当数据点被错分时,按上式修改 w_j. 由于

$$\begin{aligned} w^{(\tau+1)\mathrm{T}}(\tilde{\varphi}^n t^n) &= w^{(\tau)\mathrm{T}}(\tilde{\varphi}^n t^n)(\tilde{\varphi}^n t^n) \\ &\leqslant w^{(\tau)\mathrm{T}}(\tilde{\varphi}^n t^n), \end{aligned} \tag{2.32}$$

故这一学习方程使得误差函数单减.

对于感知器准则的这种特殊形式,学习速率 η 的大小并不重要,因为 η 的改变等价于权重和阈值的重标度,而且这一改变不影响决策边界的位置,因此,当极小化感知器准则时,我们令 $\eta=1$ 而不失一般性. 但这一性质对其他误差函数的学习并不适用.

2.2.2.3 感知器收敛定理

对于感知器学习算法,我们有下列有趣的性质.

定理 2.1(感知器收敛定理) 对于任何线性可分的数据集,学习规则(2.31)保证可以在有限步内找到问题的解.

证明 由于我们考虑的是线性可分集,故至少存在一权重向量 $\hat{w}$ 使得对所有训练数据均有

$$\hat{w}^{\mathrm{T}}\tilde{\varphi}^n t^n>0. \tag{2.33}$$

学习过程可从任意初始权重向量开始,在不失一般性的情况下,假定初始向量为 $w^{(0)}$,在算法的每一点,权重向量按下述规则修正

$$w^{(\tau+1)}=w^{(\tau)}+\tilde{\varphi}^n t^n, \tag{2.34}$$

其中 $\tilde{\varphi}^n$ 是被感知器错分的向量. 假设算法进行一段时间后,向量 $\tilde{\varphi}^n$ 被错分的次数为 τ^n,那么权向量此时为

$$w=w^{(0)}+\sum_n \tau^n\tilde{\varphi}^n t^n. \tag{2.35}$$

令 $\hat{w}$ 与 W 做内积运算,则有

$$\begin{aligned} \hat{w}^{\mathrm{T}}w &= \hat{w}^{\mathrm{T}}w^{(0)}+\sum_n \tau^n\hat{w}^{\mathrm{T}}\tilde{\varphi}^n t^n \\ &\geqslant \hat{w}^{\mathrm{T}}w^{(0)}+\tau\min_n(\hat{w}^{\mathrm{T}}\tilde{\varphi}^n t^n), \end{aligned} \tag{2.36}$$

其中 $\tau=\sum_n\tau^n$ 是权重修改的总次数,因此,$\hat{w}^{\mathrm{T}}w$ 以 τ 的线性单增函数为其下界.

现在,我们考虑权重 w 的值随 t 的变化规律. 由学习规则,我们有

$$\begin{aligned}\| w^{(\tau+1)} \|^2 &= \| w^{(\tau)} \|^2 + \| \tilde{\varphi}^n \|^2 (t^n)^2 + 2 w^{(\tau)\mathrm{T}} \tilde{\varphi}^n t^n \\ &\leqslant \| w^{(\tau)} \|^2 + \| \tilde{\varphi}^n \|^2 (t^n)^2,\end{aligned} \tag{2.37}$$

其中不等式来自向量 $\tilde{\varphi}^n$ 必须错分，权重 w 才进行调节，相应的 $w^{(\tau)\mathrm{T}} \tilde{\varphi}^n t^n < 0$，由于 $\| \tilde{\varphi}^n \|^2 \leqslant \| \tilde{\varphi} \|^2_{\max}$，其中 $\| \tilde{\varphi} \|_{\max}$ 是范数最大的输入向量的范数，因此，我们有

$$\| w^{(\tau+1)} \|^2 - \| w^{(\tau)} \|^2 \leqslant \| \tilde{\varphi} \|^2_{\max}, \tag{2.38}$$

因此，在 τ 次修改后，权向量 w 满足

$$\| w \|^2 \leqslant \tau \| \tilde{\varphi} \|^2_{\max} + \| w^{(0)} \|^2, \tag{2.39}$$

因此，$\| w \|$ 的增长阶为 $\tau^{1/2}$.

由 $\hat{w}^{\mathrm{T}} w$ 的估计式我们有

$$\| \hat{w}^{\mathrm{T}} \| \| w \| \geqslant \tau \min_n (\hat{w}^{\mathrm{T}} \tilde{\varphi}^n t^n) - \hat{w}^{\mathrm{T}} w^{(0)}, \tag{2.40}$$

故

$$\| w \| \geqslant \tau \frac{\min(\hat{w}^{\mathrm{T}} \tilde{\varphi}^n t^n)}{\| \hat{w} \|} - \frac{\hat{w}^{\mathrm{T}} w^{(0)}}{\| \hat{w} \|}. \tag{2.41}$$

而由 $\| w \|^2$ 的估计，我们有

$$\begin{aligned}\| w \| &\leqslant \sqrt{\tau \| \tilde{\varphi} \|^2_{\max} + \| w^{(0)} \|^2} \\ &\leqslant (\tau+1)^{\frac{1}{2}} \max\{ \| \tilde{\varphi} \|^2_{\max}, \| w^{(0)} \|^2 \},\end{aligned} \tag{2.42}$$

因此，当 τ 充分大时，总有

$$\tau \frac{\min(\hat{w}^{\mathrm{T}} \tilde{\varphi}^n t^n)}{\| \hat{w} \|} - \frac{\hat{w}^{\mathrm{T}} w^{(0)}}{\| \hat{w} \|} > (\tau+1)^{\frac{1}{2}} \max\{ \| \tilde{\varphi} \|^2_{\max}, \| w^0 \|^2 \}, \tag{2.43}$$

故公式(2.41)与公式(2.42)矛盾，这种矛盾隐含 τ 不能无限增长，它必在有限步终止. 按照感知器学习程序，τ 停止增长意味着所有数据均被正确分类，因此，感知器学习算法必在有限步终止.

感知器学习规则的困难之一是当数据不是线性可分时，学习算法将永不停止. 而且如果学习算法任意中止，那么就不能保证权向量对于新的输入数据有效，为了将这一算法推广到线性不可分数据，现已设计了许多启发式算法，它们在数据线性不可分时能保证收敛性. 限于篇幅我们略去对这些算法的叙述.

2.2.3 单层前向网和最小二乘技巧

广义的单层前向网可表示为

$$y_k(x) = \varphi\Big(\sum_{j=0}^{M} w_{kj}\bar{\varphi}_j(x)\Big),$$

其中 φ 为激活函数. 下面为方便起见,我们记第 k 个神经元当权重为 w,输入为 x^n 时的输出为 $y_k(x^n;w)$. 本节将叙述当训练数据中包含期望输出时,神经网络的最小二乘训练技术.

2.2.3.1 平方和误差函数

设网络的训练数据为 $\{(x^n,t^n)\}_{n=1}^{N}$,其中 $x^n\in R^d$ 而 $t^n\in R^C$,t_k^n 表示第 k 个输出元的期望输出. 基于所有训练数据的平方和误差函数定义为

$$E(w) = \frac{1}{2}\sum_{n=1}^{N}\sum_{k=1}^{C}\{y_k(x^n;w) - t_k^n\}^2. \tag{2.44}$$

当激活函数 φ 为光滑函数时,误差函数是权重 w 的光滑函数. 如果激活函数为线性函数,则问题为一最小二乘问题,相应的解可解析地给出,下面我们给出线性激活函数的最小二乘解和非线性光滑激活函数的梯度下降法.

2.2.3.2 伪逆解

设激活函数为线性函数,则最小二乘问题为极小化下求平方和误差函数

$$E(w) = \frac{1}{2}\sum_{n=1}^{N}\sum_{k=1}^{C}\Big\{\sum_{j=0}^{M} w_{kj}\bar{\varphi}_j^n - t_k^n\Big\}^2. \tag{2.45}$$

权重 w 为误差函数的极小值的必要条件为

$$\frac{\partial E(w)}{\partial w_{kj}} = 0, \tag{2.46}$$

即

$$\sum_{n=1}^{N}\Big\{\sum_{j=0}^{M} w_{kj}\bar{\varphi}_j^n - t_k^n\Big\}\bar{\varphi}_i^n = 0. \tag{2.47}$$

为方便求解这一线性方程组,我们将其写成矩阵形式

$$(\Phi^{\mathrm{T}}\Phi)W^{\mathrm{T}} = \Phi^{\mathrm{T}}T, \tag{2.48}$$

其中 Φ 是一 $N\times M$ 矩阵,其第 (n,j) 个元素值为 $\bar{\varphi}_j^n$,W 是一 $C\times M$ 矩阵,其第 (k,j) 个元素为 w_{kj},而 T 是一 $N\times C$ 矩阵其第 (n,k) 个元素的值为 t_k^n,由于矩阵 $\Phi^{\mathrm{T}}\Phi$ 是一 $M\times M$ 矩阵,故当其可逆时我们有

$$W^{\mathrm{T}} = \Phi^{+}T, \tag{2.49}$$

其中 $\Phi^{+} = (\Phi^{\mathrm{T}}\Phi)^{-1}\Phi^{\mathrm{T}}$ 称为 Φ 的广义逆,如果 $\Phi^{\mathrm{T}}\Phi$ 是奇异的,那么,广义逆可定义为

$$\Phi^{+} = \lim_{\varepsilon\to 0^{+}}(\Phi^{\mathrm{T}}\Phi + \varepsilon I)^{-1}\Phi^{\mathrm{T}}. \tag{2.50}$$

理论上可以证明这一极限总存在且相应的由(2.50)决定的 W^{T} 极小化 $E(w)$.

2.2.3.3 梯度下降法

我们已经证明，对于一个线性网络，极小化平方和误差函数的权重可解析地给出，但值得注意的是这一结果仅当误差函数为平方和且网络为线性时才能成立，如果非线性激活函数如 Sigmoid 函数被采用，或其他的误差函数用于确定参数，那么，问题的解便不可能直接给出．然而，如果激活函数是一光滑函数，则误差函数关于权重的导数容易得到，利用这些导数可构造梯度下降类优化方法用于极小化误差函数，下面我们仅介绍最为简单的梯度下降法，其他的优化方法可参见最优化方法教程．

为方便起见，我们将网络中所有参数组成的向量（包括权重和阈值）记为 w，于是误差函数可记为 $E(w)$，假定 E 是 w 的可微函数．则我们可采用下面步骤求解问题．从一随机选取的初始值 w 开始，我们沿 E 下降最快的方向将权向量移动一个很小的距离．重复这一过程，我们将产生一系列权重向量 $w^{(\tau)}$，它的分量 $w_{kj}^{(\tau)}$ 由下式逐步算出

$$w_{kj}^{(\tau+1)} = w_{kj}^{(\tau)} - \eta \frac{\partial E}{\partial w_{kj}}\bigg|_{w^{(\tau)}}, \tag{2.51}$$

其中 η 是一称之为学习速率的参数．在合适的条件下，权重量将收敛到 E 的极小值点，η 的选取相当重要，其原因是如果 η 取得太小，则误差下降会非常缓慢，而如其太大，则会导致发散振荡．

通常，误差函数是单个模式的误差项的和，即

$$E(w) = \sum_n E^n(w), \tag{2.52}$$

其中 E^n 仅由模式 n 确定．就这一情况而言，我们可以一次利用一个模式修改权重 w，其公式如下

$$w^{(\tau+1)} = w^{(\tau)} - \eta \frac{\partial E^n}{\partial w_{kj}}\bigg|_{w^{(\tau)}}. \tag{2.53}$$

其学习过程可通过循环使用训练集中的所有模式来完成，这一技巧在实时自适应应用中极为有用．

为实现梯度下降法，我们需要误差函数关于权重的导数的显式表达，我们首先考虑基于单个模式的修改权重的梯度下降法，对于广义线性网络，其激活函数为线性函数，此时梯度向量为

$$\frac{\partial E^n}{\partial w_{kj}} = (y_k(x^n) - t_k^n)\tilde{\varphi}_j(x^n) = \delta_k^n \tilde{\varphi}_j^n, \tag{2.54}$$

其中 δ_k^n 如下定义

$$\delta_k^n = y_k(x^n) - t_k^n. \tag{2.55}$$

我们看到，对于连接基函数 j 和输出单元 k 的权重 w_{kj} 而言，误差函数的

导数是 δ_k 和 $\tilde{\varphi}_j$ 的乘积.因此导数的计算就网络图而言关于权重 w_{kj} 是局部的,基于导数的这一表示,权向量的修改公式可写为

$$\triangle w_{kj} = -\eta \delta_k^n \tilde{\varphi}_j^n, \tag{2.56}$$

其中 $\triangle w_{kj} = w^{(r+1)} - w^{(r)}$.这一学习规则及其变形被赋以各式各样的名字如最小二乘规则,Adaline 规则,Widrow-Hoff 规则和 delta 规则.

如果网络的激活函数是一可微的非线性激活函数如逻辑 S 形函数,我们可将网络的输出写成下述形式

$$y_k = \varphi(u_k), \tag{2.57}$$

其中 $\varphi(\cdot)$ 是激活函数,那么

$$u_k = \sum_{j=0}^{M} w_{kj}\tilde{\varphi}_j. \tag{2.58}$$

误差函数关于模式 n 的导数公式如下:

$$\frac{\partial E^n}{\partial w_{kj}} = \delta_k^n \tilde{\varphi}_j^n, \tag{2.59}$$

其中

$$\delta_k^n = \varphi'(a_k)(y_k(x^n) - t_k^n). \tag{2.60}$$

对于逻辑函数

$$\varphi(a) = \frac{1}{1+e^{-a}}, \tag{2.61}$$

导数的形式可表示为

$$\varphi'(a) = \varphi(a)(1-\varphi(a)). \tag{2.62}$$

对于基于整体误差的梯度下降法,其导数由所有模式的导数和构成,其公式如下

$$\frac{\partial E}{\partial w_{kj}} = \sum_n \frac{\partial E^n}{\partial w_{kj}}. \tag{2.63}$$

2.2.4 单层前向网的限制

当 20 世纪 60 年代在感知器的实验研究中,人们发现它们可以很快地解决许多问题,但一些明显没有任何困难的问题却不可能用感知器求解.Minsky 和 Papert(1969)证明存在许多感知器不能解决的问题.尽管广义单层前向网可解决边界为曲线的线性不可分分类问题,但问题的真正困难在于,由基函数构成的处理元 $\tilde{\varphi}_j$ 事先固定而不能在所考虑的特殊问题中根据数据进行自动调节,结果导致,为使得感知器对一般问题提供正确的解,基函数的个数必须随问题的维数指数增长.Minsky 和 Papert 利用例子说明了对各种不同形式的感知器减小基函数的个数是不可能的.

解决这一困难最实用的办法是允许 $\bar{\varphi}_j(x)$ 可调节，因此，它们也构成了学习过程的一部分．这一思想导致了下章将要讨论的多层网．

2.2.5 总结

单层前向网可以认为是对传统方法从不同角的发现和再认识，对于神经网络而言，它具有历史和理论的重要性．本节讨论了基于感知器准则的感知器学习算法和基于最小二乘误差函数的单层前向网学习算法，这些算法从数学上讲均为梯度下降算法，但目标函数或误差函数的设计包含着更为深刻的生物背景．

§2.3 多层感知器

在上一节，我们讨论了仅有一层可调节权重的神经网络的性质．这些网络就其所能表示的函数而言具有严重的限制．为了表示更一般的函数，我们应该考虑具有多层可调节参数或权重的神经网络．事实上我们将会看到，只需两层权重我们就可逼近任何连续函数．更为一般地，非层状的网络均可用同样方法处理，因为任一神经网络均可用对应的映射函数表示．惟一的限制是神经网络的图是前向的，即它不包含任何反馈环．这一限制保证网络的输出可用输入和权重显式表达．

我们首先讨论具有阈值激活函数和 S 形激活函数的多层前向神经网络的逼近能力．这类多层前向网亦称为多层感知器网．当网络的激活函数光滑可微时，存在一个功能强大且有效的，称之为误差后向传播的方法．这一方法用于求误差函数关于权重和阈值的导数．由于这些导数在绝大部分的前向网学习算法中具有核心的重要性，且这种求导方法是多层前向网的一个重要特性，因此，本节将用一定的篇幅讨论后向传播方法．我们也将讨论误差函数的二阶导数的计算和逼近技巧．二阶导数由海森阵的元素组成，它在神经网络方面有许多应用．

2.3.1 前向网映射

我们将前向网视作表示非线性函数映射的一个一般框架，网络利用一个称之为激活函数的单变量函数的复合来表示非线性函数．前节我们已经说过，单层前向网基于输入变量的线性组合经一非线性激活函数变换而构成．下面，我们将允许网络具有数层相连的处理单元，连接可从一层中的每个神经元到下层的所有神经元，而不存在其他的连接．这样的层状网络理论容易分析且可更为有效地进行软件模拟．

图 2.4 是一个层状网的例子，既不是输入单元也不是输出单元的神经元称为隐层神经元，在这一网络中有 d 个输入，M 个隐神经元和 C 个输出单元，对应于此图的解析映射函数可如下表示，首先第 j 个隐单元对于 d 个输入值 x_i 的加权线性和可表示

$$a_j = \sum_{i=1}^{d} w_{ji}^{(1)} x_i - \theta_j, \tag{2.64}$$

其中 $w_{ji}^{(1)}$ 为第一层权重中从输入神经元到隐神经元 j 的连接权重，θ_j 为隐单元神经元的阈值，同样令 $x_0 = -1$，$w_{j0}^{(1)} = \theta_j$，则

$$a_j = \sum_{i=0}^{d} w_{j0}^{(1)} x_i. \tag{2.65}$$

第 j 个隐神经元的输出值

$$z_j = \varphi(a_j), \tag{2.66}$$

其中 φ 为隐神经元的激活函数，同样，输出层的神经元以隐层神经元的输出 z_j 为其输入，相应地，记

$$a_k = \sum_{j=0}^{M} w_{kj}^{(2)} z_j, \tag{2.67}$$

则输出神经元的输出值为

$$y_k = \tilde{\varphi}(a_k), \tag{2.68}$$

其中 $w_{kj}^{(2)}$ 为第二层权重和阈值，而 $\tilde{\varphi}$ 为输出神经元的激活函数，$\tilde{\varphi}$ 和 φ 可选取不同的激活函数.

我们可将上面几个公式合并得网络输出函数的一个完全表示

$$y_k = \tilde{\varphi}\Big(\sum_{j=0}^{M} w_{kj}^{(2)} \varphi\Big(\sum_{i=0}^{d} w_{ji}^{(1)} x_i\Big)\Big). \tag{2.69}$$

我们注意到，如果输出层神经元的激活函数 $\tilde{\varphi}$ 为线性函数，$\tilde{\varphi}(a) = a$，则这一函数形式便是一种上章所述的特殊形式的广义线性判别函数，其中基函数由特殊函数 z_j 定义.但一个重要的差别是网络的两层权重均为可调节参数，因此函数 z_j 的参数，从而其形状亦在网络的训练中可以变化.

图 2.4 所示的神经网络所对应的是一具有两层权重的非线性映射，很明显，我们可将这类网络推广成多层网，下面我们称一个神经网络是 L 层神经网络是指该网络以有 L 层可调节权重参数，因此，图 2.4 示的神经网络是一两层网而前节所述的网络称为单层网.

2.3.2 阈值神经元

在多层网中，非线性激活函数有许多选择，并且输出层和隐层的激活函数通常选取的不同，其原因是隐层和输出层起着各自不同的作用.为讨论简单起

见，我们首先考虑网络的所有神经元的激活函数为阶梯函数或称 Heaveside 函数的阈值神经网络，其中 Heaveside 函数定义为

$$\varphi(a) = \begin{cases} 0, & \text{当 } a < 0, \\ 1, & \text{当 } a \geqslant 0. \end{cases} \tag{2.70}$$

下面，我们称相应的神经元为阈值神经元.

当网络的输入为二进输入时，即 $x_i = 0$ 或 1，相应的网络输出亦为 0 或 1，因此网络所计算的是一布尔(Boole)函数，我们可以证明只要隐层单元的神经元个数充分多，则如图 2.4 所示的两层网可生成任何布尔函数.

如果网络的输入为连续值，而神经元的激活函数为阈值函数，则不同层数的网络可表示的决策边界具有不同的限制，前节我们已经证明，单层阈值神经元的决策边界为一超平面，如果网络包含两层权重，那么每一隐单元将输入空间用超平面划分，因此当输入在超平面的一侧时，相应的输出为 $z = 1$，而当输入在超平面的另一侧时，$z = 0$，这样的一个网络可生成包括数据凸集边界在内的许多不同的边界面，但仍有许多决策面不能用二层网生成.理论上可以证明三层网可生成具有任意形状的决策面(其证明参见 Bishop(1995)).

2.3.3 S 形神经元

我们现在考虑可微激活函数.如前所述，逻辑 S 形函数：

$$\varphi(a) = \frac{1}{1 + e^{-a}} \tag{2.71}$$

是一种常用的可微激活函数，这样的一个激活函数使得神经网络的输出具有良好的统计解释.另外，如双曲正切激活函数

$$\varphi(a) = \frac{e^{a} - e^{-a}}{e^{a} + e^{-a}}, \tag{2.72}$$

因其具有一些实用上的优点亦被广泛使用，双曲函数和逻辑 S 形函数可通过线性变换互换，如果令 $\tilde{a} = \frac{a}{2}$ 且 $\tilde{\varphi} = 2\varphi - 1$，则 S 函数 $\varphi(a) = 1/(1 + e^{-a})$ 变为双曲函数，$\tilde{\varphi}(\tilde{a}) = \tanh(\tilde{a})$.因此，一个隐单元使用双曲正切激活函数的神经网络等价于一个隐单元使用逻辑 S 形函数但具有不同权重和阈值的神经网络.实用中经常发现，使用双曲正切激活函数的训练算法快于使用逻辑 S 形激活函数的训练算法.

本节我们将考虑具有线性输出单元的神经网络，我们将会看到，这并未限制这类网络的函数逼近能力.S 形输出神经元的使用可能会将输出值的范围限制到 S 形神经元的输出范围，而在许多情况下这是我们所不希望的.既使是目标输出总是限制在 S 形函数的取值范围，但由于 S 形函数 φ 单调，因此其可逆，从而 S 形输出神经元的希望输出 y 等价于线性输出神经元的网络的希

望输出为 $\varphi^{-1}(y)$，因此，S 形输出神经元可变为线性输出神经元．尽管如此，但在解决概率统计问题的神经网络中，S 形函数仍具有特殊的重要地位．

一个 S 形隐层神经元能以任意精度逼近一个线性隐层神经元．首先，令隐层神经元的输入神经元的权重值和阈值充分小，以使得输入的线性加权和落于 S 形函数位于原点附近的线性部分，隐单元到下层神经元的权重可重新标度以使其恢复原来的大小(如需要，相应的阈值可作适当补偿调节)．类似地，一个 S 形隐单元可逼近一个阶梯函数，只要令该神经元的输入权重具有非常大的值．

我们很快就会看到，隐层为 S 形神经元的二层网能以任意精度表示任何连续函数．由于具有更多层神经元的网络以二层网为其特殊情况，故多层网具有更为广泛的逼近性质．

2.3.4 多层网的逼近能力

我们现在考虑具有 S 形隐神经元的两层网，这是一类实用上非常重要的神经网络．其一般拓扑图如图 2.4 所示，而相应的网络函数由(2.69)表示，我们将证明，只要隐神经元的个数 M 充分多，则这样一个网络可随意逼近任何函数．这一结果的一个重要推论是，就分类问题而言，这一网络能以任意精度逼近任何形状的决策边界．因此，这一网络提供了一个万能非线性判别函数．

定理 2.2 只要隐层神经元的个数充分多，则隐神经元为 S 形神经元而输出元为线性元的二层网可任意逼近任何函数．

证明 在不失一般性的情况下，我们假定输入变量为二维变量 x_1 和 x_2，而输出变量为一维变量 y．对于任一固定的 x_1，函数 $y(x_1, x_2)$ 可按变量 x_2 展成傅里叶(Fourier)级数

$$y(x_1, x_2) = \sum_s A_s(x_1)\cos(sx_2). \tag{2.73}$$

由于系数 $A_s(x_1)$ 是 x_1 的函数，故其亦可展成傅里叶级数，于是我们有

$$y(x_1, x_2) = \sum_s \sum_l A_{sl}\cos(lx_1)\cos(sx_2). \tag{2.74}$$

使用标准的三角恒等式

$$\cos\alpha\cos\beta = \frac{1}{2}\cos(\alpha + \beta) + \frac{1}{2}\cos(\alpha - \beta), \tag{2.75}$$

于是，$y(x_1, x_2)$ 可表示成 $\cos(z_{sl})$ 和 $\cos(z'_{sl})$ 的线性和，其中 $z_{sl} = lx_1 + sx_2$ 且 $z'_{sl} = lx_1 - sx_2$，现在，我们注意到函数 $\cos(z)$ 可用阶梯函数逼近到任一精度，故其用阈值阶梯函数可任意逼近，即

$$f(z) \doteq f_0 + \sum_{i=0}^{N} |f_{i+1} - f_i| H(z - z_i), \tag{2.76}$$

其中 $H(z)$是 Heaveside 阶梯函数，因此，函数 $y(x_1, x_2)$可表示为变量为 x_1 和 x_2 的线性组合的阶梯函数的线性组合．换句话说，函数 $y(x_1, x_2)$可用一具有阈值隐单元和线性输出元的两层网逼近，由于阈值激活函数可用 S 形激活函数充分逼近，我们便得到了我们的最终结论．

事实上，这一结果可更进一步推广至对导数的同时逼近．Hornik(1988, 1991)等证明了一个隐神经元为 S 形神经元的二层神经网络可同时逼近函数值和导数值至任意精度．

上述结果证明了当隐神经元充分多时，网络能以任意精度逼近任何函数．White(1990)，Gallant 和 White(1992)等研究了在保证逼近精度的情况下，隐单元的个数随样本个数的增长情况．

如果我们用具有 M 个隐神经元的网络逼近函数$h(x)$，则必然存在一个残量误差，Jones(1990, 1992)和 Barron(1993)证明了这一误差以速度 $O\left(\frac{1}{M}\right)$ 随 M 的增大而减小．

2.3.5 权重空间的对称性

对于一个具有 M 个隐神经元的两层网，设隐元的激活函数为双曲正切函数．如果我们改变一个隐元的输入权重和阈值的符号，则隐元的输出值的符号就会反转，而这又可通过改变隐元的输出权重的符号进行补偿．因此，改变一个特定群的权重和阈值符号不会影响由神经网络表示的输入—输出函数．于是，我们找到了表示一个函数的两种权重不同的表示．对于 M 个隐元，有 M 个这种“符号反转”对称性，于是，任一权向量将是 2^M 个等价权向量的一个．

类似的，假如我们交换两个隐元所有的输入和输出权重以及阈值，则对应的函数表示仍完全相同，但其权重向量因位置交换而发生变化，对于 M 个神经元，有 $M!$个交换对称性．因此，整个权重空间有 $M!2^M$ 个对称性．这即是说，网络的任一权重向量仅是 $M!2^M$ 个等价表示中的一个．多层网的对称性是每层对称个数的乘积．利用这一结论，我们可得到下述定理．

定理 如果神经网络的误差函数在某一权向量达到极值点，则相应的有 $M!2^M$ 个具有相同极小值的权向量且这些权向量都为极小值．

因此，神经网络的误差函数是一多峰函数，而局部极值点因其数目巨大而对寻找总体最优学习算法构成了极大的障碍．本书讨论的遗传算法就是克服这一困难的一种算法设计．

2.3.6 Kolmogonov 定理

1957 年由 Kolmogonov 给出的一个定理与神经网络有着一个有趣的联

系.定理源于19世纪末希尔伯特提出的23个未解决的数学问题,希尔伯特的第十三个问题涉及函数表示问题,其问题是任一多变量函数是否可表示成变量较少的连续函数的迭加,他猜想存在着一个三个变量的连续函数,其不能表示成两个变元函数的复合.Arnod(1957)否定了这一猜想.但随之Kolmogorov(1957)得到一个更为一般的结果,它证明了任一多变量连续函数均可表示为为数不多的单变量函数的复合.用神经网络的术语可重新将这一结果叙述为:任一d个变量的连续函数$y(x)$可精确表示为三层神经网络,第一隐层包含$d(2d+1)$个隐神经元而第二个隐层包含$(2d+1)$个隐神经元,网络的拓扑如图2.6所示.第一隐层的神经元输出是一单变量函数$h_j(x_i)$,$j=1,\cdots,2d+1$,其中$h_j(x_i)$是一严格单增函数,第二层隐单元的输出为

$$z_j = \sum_{i=1}^{d} \lambda_i h_j(x_i), \tag{2.77}$$

其中$\lambda_i \in (0\quad 1)$是一常数,网络的最终输出为

$$y = \sum_{j=1}^{2d+1} g(z_j), \tag{2.78}$$

其中g是一实值连续函数.函数g依赖于所要表示的函数$y(x)$而h_j却与$y(x)$无关,这一结果用于表示多个输出变量的函数,其中第k个输出y_k可表示为

$$y_k = \sum_{j=1}^{2d+1} g_k(z_j). \tag{2.79}$$

该定理仅保证存在一个合适的网络,函数h_j和g均无构造性算法.

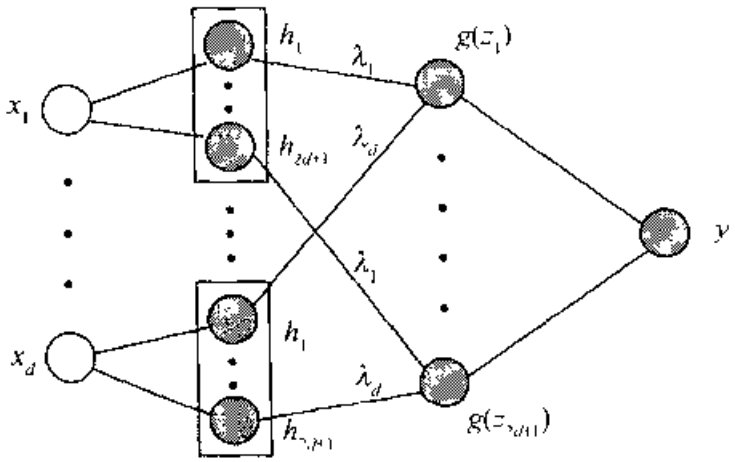


图2.6 Kolmogorov函数逼近模型

尽管Kolmogorov定理是一个杰出的结果,但其在神经元网络方面的应用很是有限的.其原因是,①h_j是不光滑的,而h_j的光滑要求将使定理失效.②

$g(x)$依赖 $y(x)$. $h_j(x)$的不光滑导致网络的不稳定性，且提高了学习的难度，而 $g(x)$依赖于 $y(x)$，这与我们对于神经网络的假设——激活函数事先固定相矛盾.

2.3.7 误差后向传播

迄今为止，我们所讨论的仅是多层网的表示能力，下面我们转而讨论这样一个网络如何从一组给定的数据中学习得到一个适当的映射函数. 如前所述，学习将基于一个适当定义的误差函数，然后在网络中相对于权重和阈值参数极小化这一误差函数.

首先我们考虑由阈值神经元构成的网络. 网络最后一层权重可认为是一感知器，其输入为最后一层隐单元的输出，因而这些权重可利用感知器准则来学习. 然而这样一个方法却不能用于确定其他各层的权重. 尽管原理上每层均可认为是单层感知器，但我们却无法赋于其希望值或目标值，因此感知器学习规则根本无法使用. 这便是熟知的信用配置问题：当网络赋于一个输入变量且其输出神经元产生一个不正确的响应时，我们根本无法确定那一个隐神经元应该为此错误负责，因而我们也不能确定那一个权重应进行调节或调节多少.

对于这一问题的解决相当简单. 如果我们所考虑的网络具有可微的激活函数，那么网络的输出便是输入变量、权重和阈值的可微函数. 如果我们定义的误差函数亦是网络输出变量的可微函数，则误差函数本身亦是权重和阈值的可微函数，于是我们便可利用误差函数的导数寻找使误差函数达到极小值的权重和阈值. 利用误差函数的导数的优化方法包括梯度类方法和牛顿类方法.

误差函数求导的方法称为后向传播，因为求导过程对应误差沿网络的后向传播. 后向传播技巧因 Rumelhart Hinton 和 Williams(1986)的文章而为大众所熟知，但类似的结果早在 1974(Werbos)和 1985(Parker)就被其他研究者所发现.

在神经网络的文献中，后向传播被用于表示许多不同的事情. 例如，多层感知器网有时称为后向传播网. 后向传播也被用来描述基于平方误差函数的多层网的梯度下降学习算法. 为了澄清这一术语的确切含义，我们应对训练过程进行细致分析. 大部分学习算法包含了一个极小误差函数的迭代程序，它们依序列的方式逐步调节权重. 每一个调节步可分为两个不同的步骤. 在第一个步骤中，我们必须求出误差函数相对于权重的导数. 我们将会看到，后向传播技巧的最重要贡献便是提供了这样一个函数的有效求导方法. 由于在这一步骤中，误差沿着网络向后传播，我们将使用术语后向传播特指函数的求导. 在第二个步骤中，所得导数用于对权重的调节. 权重最简单的调节方法便是

Rumelhart 等提出的梯度下降法. 区分这两个步骤相当重要. 第一个步骤中误差沿网络的后向传播不仅可用于其他网络的误差函数求导, 也可用于其他误差函数的求导. 步骤 2 中求得的导数可被用于众多的优化格式以调节权重, 其中有许多优化格式较梯度下降法更为有效.

2.3.7.1 误差函数求导

下面我们对一个具有任意前向拓扑、任意可微激活函数和任意可微误差函数的神经网络, 推导后向传播算法.

在一前向网中, 每一神经元所计算的输入加权线性和为

$$a_j = \sum_i w_{ji} z_i, \tag{2.80}$$

其中 z_i 是向神经元 j 输送信息的第 i 个神经元或输入元, 其连接权重为 w_{ji}. 求和遍及所有向神经元输送信息的单元 i. 由于阈值可通过一个附加的神经元(或称输入元)归入该和式中, 因此我们将不再显式的表示阈值, 通过一非线性激活函数 φ 的作用, 神经元 j 的输出 z_j 为

$$z_j = \varphi(a_j). \tag{2.81}$$

如果在表示式(2.80)中, 某一 z_i 为输入神经元的输出, 则我们记其为 x_i. 类似地, 如果神经元是某一输出神经元的输出值, 则我们记其为 y_j.

如前所述, 我们通过极小化一个适当的误差函数试图确定权重的值. 此处, 我们将考虑可写为训练集的单个模式误差和的误差函数, 即

$$E = \sum_n E^n, \tag{2.82}$$

其中 n 为模式标号. 几乎所有具实用价值的误差函数都取这种形式. 我们总假定误差 E^n 是输出变量的可微函数, 即

$$E^n = E^n(y_1, \cdots, y_c) \tag{2.83}$$

是 $y_1, \cdots, y_c$ 的可微函数. 我们的目的是寻找误差函数关于网络参数的求导方法. 由于导数可表示成单个样本误差的导数和, 故我们以下每次仅考虑一个模式误差的求导.

对于每一个模式, 我们首先将输入向量送入网络, 然后网络中的神经元按(2.80)(2.81)逐步运算, 这一过程通常称为前向传播, 其原因是它可认作是信息流沿网络的前向移动.

现在考虑 E^n 关于某一权重 w_{ji} 的导数, 各类神经元的输出将依赖网络的输入模式 n, 但为了保持符号和公式的简洁, 我们将略去输入和输出中的下标 n. 首先, 我们注意到只有 a_j 中包含权重 w_{ji}, 故 E^n 关于 w_{ji} 的导数需经由 a_j, 相应的链式求导法则为

$$\frac{\partial E^n}{\partial w_{ji}} = \frac{\partial E^n}{\partial a_j} \frac{\partial a_j}{\partial w_{ji}}. \tag{2.84}$$

如果采用记号

$$\delta_j \equiv \frac{\partial E^n}{\partial a_j}, \tag{2.85}$$

其中 δ_j 通常称为误差，使用(2.80)，我们得

$$\frac{\partial a_j}{\partial w_{ji}} = z_i, \tag{2.86}$$

故我们有

$$\frac{\partial E^n}{\partial w_{ji}} = \delta_j z_i. \tag{2.87}$$

注意到这一表达与前面关于单层网的公式完全相同，这一表达式说明输出端的 δ 值和输入端的输入值的乘积给出关于二神经元连接的导数值.因此，为了求导，我们需要对隐神经元和输出神经元计算 δ_j 的值，然后再利用公式(2.87)求解.

关于输出神经元 k 的求导相当直接，根据定义(2.85)，我们有

$$\delta_k \equiv \frac{\partial E^n}{\partial a_k} = \varphi'(a_k)\frac{\partial E^n}{\partial y_k}, \tag{2.88}$$

其中(2.87)式的 z_k 被代之以 y_k.为了给出(2.87)的值，我们只要将 $\varphi'(a)$ 和 $\frac{\partial E^n}{\partial y}$ 的适当表示代入即可.随后我们将给出一个简单例子说明这一求值过程.

对于隐神经元 j，其导数可用链式法则表示为

$$\delta_j \equiv \frac{\partial E^n}{\partial a_j} = \sum_k \frac{\partial E^n}{\partial a_k}\frac{\partial a_k}{\partial a_j}, \tag{2.89}$$

其中，求和遍及神经元 j 向其输送信息的所有神经元 k.如上假定的神经元和权重的布局如图 2.4 所示，其中标号为 k 的神经元包含其他隐神经元和输出神经元，利用表示式(2.80)(2.81)，我们得

$$\delta_j = \varphi'(a_j)\sum_k w_{kj}\delta_k. \tag{2.90}$$

这一公式告诉我们，特定的隐神经元的 δ 值可由高一层的神经元的 δ 值向后传播得到，如图 2.7 所示，由于我们已经知道输出神经元的 δ 值，我们可递归地使用公式(2.90)求出所有隐神经元的 δ 值，而无论其结构如何.

单个模式 n 的误差函数 E^n 关于权重的求导程序可归纳下述四个步骤：

1. 将输入向量 x^n 送入网络，利用公式(2.80)和(2.81)，信息的前向传播可使我们找到隐神经元的输出神经元的输出值.

2. 对输出神经元，利用公式(2.88)求 δ_k.

3. 使用 δ 的后向传播公式(2.90)求隐神经元 j 的 δ_j 值.

4. 使用公式(2.87)得所需要的导数.

整体误差函数 E 的导数可如下得到：1. 对于训练集中的每一模式，利用

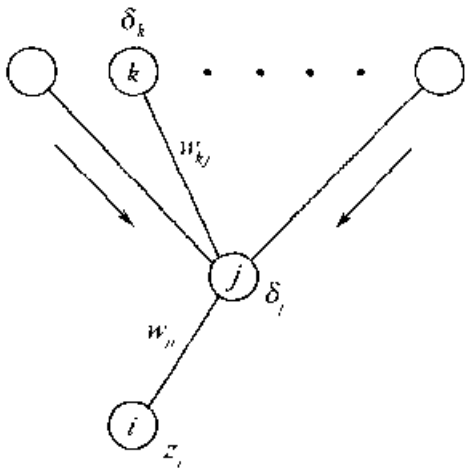


图 2.7 利用后向传播计算隐层
神经元的误差 δ_j 的示意图

上述步骤求出其导数，2. 将所有模式的导数相加即得误差函数 E 的导数，即

$$\frac{\partial E}{\partial w_{ji}} = \sum_n \frac{\partial E^n}{\partial w_{ji}}. \tag{2.91}$$

在上述推导过程中，我们隐含地假定了输出神经元和隐神经元使用了相同的激活函数，但我们可很容易地将上述推导推广至不同的神经元具有不同的激活函数，只要我们在公式中注意每一神经元的激活函数 $\varphi(\cdot)$ 的形式.

2.3.7.2 一个简单例子

上述后向传播程序的推导对一般的误差函数、激活函数和网络拓扑均成立. 为了掌握这一程序，我们考虑一个特殊例子. 网络的选取兼顾了简洁性和实用性. 具体地说，我们将考虑一个形如图 2.4 的两层前向网，其误差函数为平方和误差. 输出神经元的激活函数为线性函数，而隐层神经元为逻辑 S 形神经元，即其激活函数为

$$\varphi(a) = \frac{1}{1 + e^{-a}}. \tag{2.92}$$

这一函数的一个有用性质是其导数可表示为

$$\varphi'(a) = \varphi(a)(1 - \varphi(a)). \tag{2.93}$$

在网络算法的设计中，这一公式允许我们直接利用神经的输出值通过两次算术运算得到其导数值.

对于标准的平方和误差函数，模式 n 的误差为

$$E^n = \frac{1}{2}\sum_{k=1}^{c}(y_k - t_k)^2, \tag{2.94}$$

其中 y_k 是输出神经元的输出，而 t_k 是对应的目标值，相应的输入应为 x^n.

使用前述的后向传播求导公式，我们有下列结果，对于输出神经元 k，其

δ 值为

$$\delta_k = y_k - t_k, \tag{2.95}$$

而对于隐神经元 j，其 δ 值为

$$\delta_j = z_j(1 - z_j)\sum_{k=1}^{c} w_{kj}\delta_k, \tag{2.96}$$

其中求和遍及所有输出神经元，于是 E^n 相对于第一层和第二层权重的导数分别为

$$\frac{\partial E^n}{\partial w_{ji}} = \delta_j x_i, \qquad \frac{\partial E_n}{\partial w_{ji}} = \delta_k z_j. \tag{2.97}$$

至此，我们已讨论了误差函数关于权重和阈值的求导．为了基于这些导数构造算法．我们需要一些利用导数修改权重的方法．其中最为简单的调节权重方法便是固定步长的梯度下降法：如果权重的修改仅基于当前模式，则相应的算法称为在线学习，其学习规则为

$$\triangle w_{ji} = -\eta\delta_j x_i \quad (\text{第一层权重})$$

或

$$\triangle w_{ji} = -\eta\delta_j z_i \quad (\text{第二层权重}), \tag{2.98}$$

而如果权重的修改基于所有模式，则相应的算法称为批学习，其学习规则为

$$\triangle w_{ji} = -\eta\sum_n \delta_j^n x_i^n \quad (\text{第一层权重}) \tag{2.99}$$

或

$$\triangle w_{ji} = -\eta\sum_n \delta_j^n z_i^n \quad (\text{第二层权重}). \tag{2.100}$$

2.3.7.3 后向传播的效率

后向传播法最重要的特性便是它在计算上的高效性．为了理解这一性质，我们将考虑求导所需的计算机运算次数是如何随网络规模而变化的．设 W 是权重和阈值的总个数，那么，对于一个输入模式，误差函数的计算需要 $O(W)$ 次运算，对于 W 个参数，我们需要求 W 个导数，如果直接求导，则每一个求导亦需要 $O(W)$ 运算，因此，利用直接求导法，求出所有 W 个导数需要 $O(W^2)$ 次运算，相比较而言，后向传播方法求导所需运算的总次数为 $O(W)$，这是因为前向和后向传播均需要 $O(W)$ 次运算，因此，后向传播法将求导运算的复杂度从 $O(W^2)$ 减少到 $O(W)$，由于多层感知器的训练极为费时，这种效率上的提高极为重要，它类似于 L 点快速傅里叶变换将算法复杂度从 $O(L^2)$ 减小到 $O(L\ \lg L)$．快速傅里叶变换曾导致傅里叶变换在实际领域的广泛使用．

2.3.7.4 Jacobi 矩阵和 Hessen 矩阵的计算

为了演示后向传播算法的威力，我们再来讨论 Jacobi 矩阵和 Hessen 阵的

计算.

一、Jacobi 矩阵计算

对于一个神经网络,网络输出相对于网络输入的 Jocobi 矩阵的元素为

$$J_{ki} = \frac{\partial y_k}{\partial x_i}. \tag{2.101}$$

Jacobi 矩阵刻画了网络输出相对于网络输入变化的敏感性,它在神经网络的一些实用场合非常有用,例如,如果我们知道输入变量的误差Δx_i,则由此误差所选择的网络输出误差便为

$$\Delta y_k \simeq \sum_i \frac{\partial y_k}{\partial x_i} \Delta x_i. \tag{2.102}$$

通常,Jocobi 矩阵元素是输入变量的函数,我们必须对每一不同的输入向量进行估值.Jocobi 矩阵的计算亦可使用后向传播方法,我们首先根据公式

$$\begin{aligned} J_{ki} = \frac{\partial y_k}{\partial x_i} &= \sum_j \frac{\partial y_k}{\partial a_j} \frac{\partial a_j}{\partial x_i} \\ &= \sum_j w_{ji} \frac{\partial y_k}{\partial a_j}, \end{aligned} \tag{2.103}$$

其中求和遍及接受输入元 i 的输出的所有神经元 j,我们现在可写出确定$\frac{\partial y_k}{\partial a_j}$的递归公式

$$\begin{aligned} \frac{\partial y_k}{\partial a_j} &= \sum_l \frac{\partial y_k}{\partial a_l} \frac{\partial a_l}{\partial a_j} \\ &= \varphi'(a_j) \sum_l w_{lj} \frac{\partial y_k}{\partial a_l}, \end{aligned} \tag{2.104}$$

其中求和遍及接受神经元 j 的输出的所有神经元 l,这种后向的传播始于输出神经元,其相应的导数为

$$\frac{\partial y_k}{\partial a_k} = \varphi'(a_k)\delta_{kk'}, \tag{2.105}$$

其中

$$\delta_{kk'} = \begin{cases} 1, & k = k', \\ 0, & \text{其他}, \end{cases} \tag{2.106}$$

因此,Jocobi 矩阵的求值步骤如下:

1° 对于需要求解 Jocobi 矩阵的输入向量 x,将其输入网络,然后利用前向传播以通常的方式得到隐单元和输出单元的输出.

2° 利用后向传播公式(2.104)和(2.105)求解$\frac{\partial y_k}{\partial a_j}$.

3° 然后利用公式(2.103)求出 Jocobi 阵中的所有元素 J_{ki}.

二、Hessen 阵求值

我们已经讨论了如何利用后向传播法求误差函数相对于权重和阈值的一阶导数，下面，我们将说明利用类似的方法可求出误差函数关于权重和阈值的二阶导数

$$\frac{\partial^2 E}{\partial w_{ji} w_{kl}}, \tag{2.107}$$

这些导数所构成的矩阵称为 Hessen 阵，它在神经计算中起着极为重要的作用，其最为人熟知的应用之一便是构造高阶学习算法．下面我们给出 Hessen 阵的求值方法．同前面一样，我们先求出每一模式误差函数的 Hessen 阵，然后将其相加便得整个训练数据总体误差函数的 Hessen 阵．

根据前面公式(2.87)我们有

$$\frac{\partial E^n}{\partial w_{ik}} = \delta_i z_k, \tag{2.108}$$

这一公式相对于权重 w_{jl} 微分，我们有

$$\frac{\partial^2 E}{\partial w_{jl} \partial w_{ik}} = \frac{\partial a_j}{\partial w_{jl}} \frac{\partial}{\partial a_j}\left(\frac{\partial E^n}{\partial w_{ik}}\right) = z_l \frac{\partial}{\partial a_j}\left(\frac{\partial E^n}{\partial w_{ik}}\right). \tag{2.109}$$

此处，我们设定 w_{ji} 并不出现在通到神经元 l 的前向传播路径上．随后我们将对此再做论述．利用公式(2.108)，和 $z_k = \varphi(a_k)$，我们有

$$\frac{\partial^2 E^n}{\partial w_{jl} \partial w_{ik}} = z_l \delta_i \varphi'(a_k) h_{kj} + z_l z_k b_{ij}, \tag{2.110}$$

其中

$$h_{kj} = \frac{\partial a_k}{\partial a_j}, \tag{2.111}$$

$$b_{ij} = \frac{\partial \delta_i}{\partial a_j}. \tag{2.112}$$

h_{kj} 可通过前向传播求值，使用链式法则，我们有

$$h_{kj} = \sum_r \frac{\partial a_k}{\partial a_r} \frac{\partial a_r}{\partial a_j}, \tag{2.113}$$

其中求和遍及向神经元 k 输送信息的所有神经元 r．利用公式(2.80)和(2.81)，我们得到前向传播方程

$$h_{kj} = \sum_r g'(a_r) w_{kr} h_{rj}, \tag{2.114}$$

h_{kj} 的初始条件来自定义(2.111)．对于网络中的每一神经元 j(输入元除外)，令 $h_{jj} = 1$，且当 k 没有落在神经元 j 的前向传播路径上时 $h_{kj} = 0$，$k \neq j$ 而其他的 h_{kj} 可由前向传播公式(2.114)得到．

类似地，我们可推导 b_{ij} 的后向传播方程，我们已经知道

$$\delta_l = g'(a_l)\sum_s w_{sl}\delta_s, \tag{2.115}$$

根据定义式(2.112),我们有

$$\begin{aligned} b_{lj} &= \frac{\partial}{\partial a_j}\{g'(a_l)\sum_s w_{sl}\delta_s\} \\ &= g''(a_l)h_{lj}\sum_s w_{sl}\delta_l + g'(a_l)\sum_s w_{sl}b_{sj}, \end{aligned} \tag{2.116}$$

求和遍及神经元向其输送信息的所有神经元 s.

但仍有一精微之处我们需要考虑,由于(式(2.116)中)导数$\frac{\partial}{\partial a_j}$来自式(2.109)中导数$\frac{\partial a_l}{\partial w_{ji}}$,从 w_{ji}到a_j 假定了 w_{ji}不会明显地出现在(2.116)右端的括号内.换句话说,权重 w_{ji}不应落在从神经元 l 开始前向传播路径上,其原因是这些路径亦是后向传播估计 δ_l 的路径.实用中,这一问题可如下容易地得到解决.如果 w_{ji}确实出现在后向传播求δ_l 的序列中,那么我们只要转而考虑 Hessen 阵中关于对角线对称的另一元素即可,对于这一元素这样的问题便不会出现,其原因是网络是前向的,然后我们再利用 Hessen 阵的对称性得到原来元素的值.

后向传播公式的初始条件来自公式(2.111)和(2.112),以及 δ 的初始条件(2.88).它们有

$$b_{kj} = \sum_{k'} H_{kk'}h_{kj}, \tag{2.117}$$

其中 $H_{kk'}$ 定义为

$$H_{kk'} = \frac{\partial^2 E^n}{\partial a_k \partial a_{k'}}. \tag{2.118}$$

对于平方和误差函数,我们有

$$H_{kk'} = \delta_{kk'}. \tag{2.119}$$

这一算法表明,前向传播和后向传播方法可用于二阶导数的计算,整个二阶导数的求值算法可归纳为五步.

1. 对于给定的输入向量,计算隐神经元和输出神经元的值,类似地,计算h_{kj}的初始条件和其他h_{kj}.

2. 按通常方式求出输出神经元的 δ_k 和 $H_{kk'}$.

3. 使用后向传播方程求出 δ_j 和 b_{lj},其初始条件由(2.117)给出.

4. 利用(2.110)给出 Hessen 阵元素的值.

5. 对训练集中每一模式,利用上述方法求 Hessen 阵,然后将其全部相加即得总体误差函数的 Hessen 阵.

记误差函数关于权重和阈值参数 w 的梯度为 g,相应的 Hessen 阵为 H,

则 g 的元素为

$$\sum_n \frac{\partial E^n}{\partial w_{ji}}, \tag{2.120}$$

H 的元素为

$$\sum_n \frac{\partial^2 E^n}{\partial w_{ji}\partial w_{lk}}, \tag{2.121}$$

则权重 w 的 Newton 修正法为

$$\triangle w = -H^{-1}g. \tag{2.122}$$

如果 H 为 Hessen 阵的近似，则相应的方法称为拟 Newton 法.

2.3.8 神经网络的学习算法

后向传播方法给出了求解误差函数关于权重的一阶和二阶导数技巧，但一个完整的训练算法还应包含利用导数修改权重的法则，我们在上节简述了如何利用最速下降法，本节我们将叙述这一算法的详细步骤.

基于梯度下降法的学习算法在许多文献中亦称为误差向后传播学习算法.对于输出元为线性元，隐单元为逻辑 S 形神经元且误差函数为平方和误差的二层神经网络，其最速梯度下降法可归纳为下述 7 个步骤.

最速梯度下降学习算法

1. 初始化权重向量.

2. 随机选取输入模式 $x^{(n)}$.

3. 沿网络正向传播求隐单元输出神经元的输出值.

4. 计算输出层神经元的 δ 值

$$\delta_k = y_k - t_k, \qquad k = 1, \cdots, c, \tag{2.123}$$

其中 y_k 为第 k 个输出神经元的输出值，而 t_k 为某目标值.

5. 计算隐神经元的 δ 值，(反向传播)

$$\delta_j = \delta_j(1 - z_j)\sum_{k=1}^{n} w_{kj}\delta_k. \tag{2.124}$$

6. 修正权重

$$\triangle w_{ji} = -\eta\delta_j x_i, \qquad \text{(第一层权重)}, \tag{2.125}$$

$$\triangle w_{kj} = -\eta\delta_j z_j \qquad \text{(第二层权重)}, \tag{2.126}$$

其中 δ_j 为第 j 个隐神经元的输出

7. 重复 2～6 直至停机准则满足.

类似地，我们可利用 Hessen 阵的求值算法和 Newton 法训练神经网络，其相应的算法与上述算法类似，故此不再叙述.

算法中的停机准则可按照优化方法的停机准则设计，亦可用迭代次数的

最大值来控制.

§2.4 径向基函数

前面讨论的神经网络中的神经元输出是输入向量和权向量内积的非线性函数.本节我们考虑另一类神经网络模型,其中的隐神经元的输出是输入向量和一个范型向量的距离的非线性函数.这类称为径向基函数网的神经网络具有一个有趣且重要的性质是其建立了不同概念之间的联系.我们将会看到径向基函数方法可从逼近论,正则化,噪声插值和密度估计等观点来推导.径向基函数网所拥有的这一统一观点,使得我们可提出一个径向基网的训练方法,它较之多层感知器网的训练算法要快得多.这一训练算法来自对隐单元所提供的内部表示的解释,其所形成的算法是一两阶段方法.在第一阶段,对应于隐神经元的径向基函数的范型参数可由快速无导师学习算法确定.在第二阶段,第二层的线性权重系数由线性方程求解确定,因而相应的速度很快.

2.4.1 精确插值

径向基函数方法源于 Powell(1987)的多维空间有限点精确插值方法.精确插值问题要求每一输入向量严格的映到对应的目标值,它提供了径向基函数一个方便的引入途径.

我们考虑一个由 d 维向量空间到一维空间的映射.设数据集由 N 个输入向量 x^n 和相应的目标值 t^n 组成,精确插值的目的是寻找一个函数 $h(x)$ 使得

$$h(x^n) = t^n, \qquad n = 1, \cdots, N. \tag{2.127}$$

径向基函数方法引入了 N 个基函数,每一数据对应一基函数,相应的基函数具有形式

$$\varphi(\| x - x^n \|), \tag{2.128}$$

其中 φ 是一非线性函数,其形式我们随后会进行讨论.由于这样的函数仅依赖于距离 $\| x - x^n \|$,故其各向同性,这也是径向基名字的由来.插值函数 $h(x)$ 定义为基函数的线性组合

$$h(x) = \sum_n w_n \varphi(\| x - x^n \|). \tag{2.129}$$

我们看到这一形式与前述的广义线性判别函数形式相同.于是插值条件(2.127)可写为

$$\Phi W = t, \tag{2.130}$$

其中 $t \equiv (t^n)$, $W = (w_n)$,而方阵 Φ 的元素 $\Phi_{nn'} = \varphi(\| x^n - x^{n'} \|)$.假定矩阵

的逆存在，则

$$W = \Phi^{-1}t. \tag{2.131}$$

Micchelli(1986)证明，对于一大类函数 $\varphi(\cdot)$，只要数据点互不相同，则 Φ 可逆，当(2.131)中的 W 代入(2.129)，则相应的函数 $h(x)$确定了一精确通过所有点的光滑函数.

理论和经验表明，就精确插值问题而言，插值函数的许多性质对于非线性函数 $\varphi(\cdot)$的形式并不敏感.在已考虑过的基函数中，最为常用的是高斯函数

$$\varphi(x) = e^{-\frac{x^2}{2\sigma^2}}, \tag{2.132}$$

其中 σ 控制插值函数平滑性.高斯函数是一局部化基函数，它满足 $\lim_{x\to\infty}\varphi(x)=0$.另一类具有同样性质的基函数为

$$\varphi(x) = (x+\sigma^2)^{-\alpha}, \qquad \alpha > 0. \tag{2.133}$$

当然，基函数不必是局部化的，其他基函数有薄板样条函数

$$\varphi(x) = x^2\ln(x) \tag{2.134}$$

和函数

$$\varphi(x) = (x^2+\sigma^2)^{\beta}, \qquad 0 < \beta < 1. \tag{2.135}$$

另外，立方函数

$$\varphi(x) = x^3 \tag{2.136}$$

和线性函数

$$\varphi(x) = x \tag{2.137}$$

亦可使用，当 $\varphi(x)=x$ 时，$\varphi(\|x-x^n\|)=\|x-x^n\|$，因此相应的插值函数仍为非线性函数.在一维情况下，这一插值函数是一分片线性插值函数.在神经网络理论中，所研究的网络模型中的基函数基本上都是局部化基函数.下面我们将集中讨论高斯基函数.这一方法向多元输出函数的推广相当直接，此时每一向量 x^n 必须精确地映为一输出向量 $t^n=(t_k^n)$，因此，我们必须有

$$h_k(x^n) = t_k^n, \tag{2.138}$$

其中 $h_k(x)$ 是 N 个基函数的线性迭加

$$h_k(x) = \sum_n w_{kn}\varphi(\|x-x^n\|). \tag{2.139}$$

利用公式(2.138)我们得

$$W_{kn} = \sum_n (\Phi^{-1})_{nn} t_k^n, \tag{2.140}$$

其中 Φ 与(2.130)中定义的系数阵相同，它对所有 k 都是相同的.

2.4.2 径向基函数网

上节讨论的径向基函数是一恰好通过各数据点的插值函数，而有噪声数

据的精确插值函数通常是一个剧烈振荡的函数，这样一个插值函数并不是我们希望的.对于一个有噪声的数据，一个好的插值函数应是更为平滑且平均掉数据中的噪声.上述精确插值函数的另一限制是其所需的基函数的个数与数据集中的模式个数相等，因此，当数据量很大时，函数的求值变得极为费时.

通过对精确插值函数的修正，我们得到径向基函数神经网络模型.这一模型提供了一个光滑插值函数，它所用的基函数个数由所要表达的映射的复杂性决定，而不是由数据规模确定.相对于精确插值函数，这一模型引入了下面的修正：

1. 径向基函数的个数 M 与数据点的个数 N 互不相等，且 M 常常远小于 N.

2. 径向基函数的中心不再限制在数据点上，而由训练算法确定.

3. 所有基函数不再拥有共同的 σ，每一基函数具有自己的 σ_j，其值亦由训练算法确定.

4. 阈值参数出现在线性和中，它们用于补偿基函数在数据集上的平均值与目标值的平均值之间的差别.

当精确插值函数引入这些变化后，我们便得到了径向基函数神经网络映射

$$y_k(x) = \sum_{j=1}^{M} w_{kj}\varphi_j(x) - \theta_{k0}. \tag{2.141}$$

如果需要，可令 $\varphi_0 = -1$，而 $w_{k0} = -\theta_{k0}$ 将其并入和式当中，相应的输出函数为

$$y_k(x) = \sum_{j=0}^{M} w_{kj}\varphi_j(x). \tag{2.142}$$

对于高斯基函数，我们有

$$\varphi_j(x) = \mathrm{e}^{-\frac{\|x-\mu_j\|^2}{2\sigma_j^2}}, \qquad j = 1, \cdots, N, \tag{2.143}$$

其中 x 是 d 维输入向量，而 μ_j 是基函数的中心向量.由于所有的因子均可纳入系数，故上述高斯函数并不需要进行归一化处理，这一映射函数的神经网络图与图 2.4 相同，不过此时的隐层神经元输出为基函数表示，具有多于一层隐神经元的径向基函数网络在实用上很少采用.

上章我们讨论了多层感知器的表示能力，对于径向基函数神经网络，我们可以证明，对于一大类基函数，万能逼近性质仍然成立，即：只要径向基函数充分多，则径向基函数网可逼近任何函数到任意精度.如同多层前向感知器网的相应证明，这一证明是一存在性证明，它需要充分多的隐神经元可资使用，因此不能提供建造网络的任何实用程序.然而，这些结果具有重要的理论价值，

它让人们放心地使用这一网络去逼近任何函数.

上述的高斯径向基函数可推广到具有协方差阵 Σ_j 的高斯函数，此时基函数取形式

$$\varphi_j(x) = \mathrm{e}^{-\frac{1}{2}(x-\mu_j)^{\mathrm{T}}\Sigma_j^{-1}(x-\mu_j)}. \tag{2.144}$$

由于协方差阵 Σ_j 是对称的，故每一基函数具有 $d(d+3)/2$ 独立可调节参数（其中 d 为输入变量的维数），而前述高斯基函数(2.143)仅有$(d+1)$个可调参数.实用中，我们可根据问题权衡考虑选取那类函数，若使用具有协方阵的基函数，则基函数个数较小而每一基函数的调节参数增多.若使用高斯函数(2.143)，则基函数个数增加且基函数的灵活度减少，即可调节参数变少.

2.4.3 网络训练

径向基函数网络的一个重要性质是其第一层权重和第二层权重所起的作用完全不同，我们将会看到，根据基函数的解释方式，第一层权重（即那些控制基函数的参数）可用无导师训练方法确定.这便导致了径向基函数网络的二阶段训练程序.在第一阶段，输入数据集$\{x^n\}$被单独用来确定基函数内的参数（当基函数是高斯函数时，这些参数便是 σ_j 和 μ_j）.在训练的第二阶段，基函数固定，第二层权重利用整个数据训练确定.关于优化径向基函数的技巧我们将随后讨论，下面，我们在假定基函数参数已经选定的条件下，先讨论第二层参数的优化问题.

我们假定径向基函数网络映射为

$$y_k(x) = \sum_{j=0}^{M} w_{kj}\varphi_j(x), \tag{2.145}$$

其中 $\varphi_0 = 1$，这一映射可写成向量形式

$$y(x) = W\varphi, \tag{2.146}$$

其中 $W = (w_{kj})$，$\varphi = (\varphi_j)$，由于基函数是固定的，网络等价于一单层网，如前章所述，权重的优化等价于极小化某一误差函数，为了方便起见，我们考虑平方和误差函数

$$E = \frac{1}{2}\sum_n \sum_k \{y^k(x^n) - t_k^n\}^2, \tag{2.147}$$

其中 t_k^n 是当输入为 x^n 时，第 k 个输出元的目标值.由于误差函数是权重的二次函数，它的极小化可通过求解线性方程组得到类似于前章讨论，权重 W 可由下述线性方程求解得到

$$\Phi^{\mathrm{T}}\Phi W^{\mathrm{T}} = \Phi^{\mathrm{T}}T, \tag{2.148}$$

其中$(T)_{nk} = t_k^n$，$(\Phi)_{nj} = \varphi_j(x^n)$，权重的形式解可写为

$$W^{1} = \Phi^{+} T, \tag{2.149}$$

其中 Φ^{+} 是 Φ 的广义逆. 实用中, 线性方程组(2.148)可用奇异值分解求解以避免可能出现的 Φ 的病态性. 因此, 第二层权重总可用快速的矩阵求逆技巧优化.

在本书的大部分情况, 我们所考虑的径向基函数网络的输出是第二层权重的线性函数, 而误差函数是平方和误差函数. 当然, 我们也可考虑具有非线性激活函数输出神经元的网络, 但此时, 第二层参数的优化需要复杂的非线性优化技巧.

2.4.4 正则化理论

函数的径向基函数展开的另一动机来自正则化理论. 正则化技巧是一种控制映射函数光滑性的方法, 它在误差函数后加上了另外一项, 用以惩罚函数的非光滑性. 为简单起见, 我们假设网络仅有一个输入 y, 且其误差函数为平方和误差. 于是需极小化的整体误差函数变为

$$E = \frac{1}{2}\sum_{n} | y(x^{n}) - t^{n} |^{2} + \frac{v}{2}\int \| Py \|^{2} \mathrm{d}x, \tag{2.150}$$

其中 P 是某一微分算子, v 称为正则化常数. 曲率过大的网络函数 $y(x)$ 通常具有较大的 $\| Py \|$ 值, 因此将受到较大的惩罚, v 值控制着正则化项的相对重要性, 从而也控制着函数 $y(x)$ 的光滑度.

我们可使用变分方法求解上述正则化极小二乘问题(2.150). 令(2.150)的泛函导数为零, 我们得到

$$\sum_{n} | y(x^{n}) - t^{n} | \delta(x - x^{n}) = v \hat{P} Py(x), \tag{2.151}$$

其中 $\hat{P}$ 是 P 的共轭微分算子, $\delta(x)$ 是 Dirac δ 函数, 方程(2.151)称为(2.150)的欧拉-拉格朗日(Euler-Lagrange)方程, 算子 $\hat{P}P$ 的格林(Green)函数定义为

$$\hat{P} PG(x, x') = \delta(x - x'). \tag{2.152}$$

如果算子 P 是平移和旋转不变的, 则格林函数仅依赖于距离 $\| x - x' \|$, 因此其为径向基函数. 基于格林函数(2.151)的形式解为

$$y(x) = \sum_{n} w_{n} G(\| x - x^{n} \|). \tag{2.153}$$

将上式代入(2.151)并利用(2.152), 我们得

$$\sum_{n} | y(x^{n}) - t^{n} | \delta(x - x^{n}) + v\sum_{n} w_{n}\delta(x - x^{n}) = 0.$$

在 x^{n} 附近的一个小邻域积分得

$$y(x^{n}) - t^{n} + vw_{n} = 0. \tag{2.154}$$

利用(2.154), 我们得到一线性方程组

$$(G + \upsilon I)w = t, \tag{2.155}$$

其中$(G)_{nn'} = G(\| x^n - x^{n'} \|)$，$(W)_n = w_n$，$(t)_n = t^n$，$I$ 为单位阵.求解这一方程即得 w_n.

如果算子 P 满足

$$\int |Py|^2 \mathrm{d}x = \sum_{l=0}^{\infty} \frac{\sigma^{2l}}{l!2^l} \int |D^l y(x)|^2 \mathrm{d}x, \tag{2.156}$$

其中 $D^{2l} = (\nabla^2)^l$ 且 $D^{2l+1} = \nabla(\nabla^2)^l$，$\nabla$ 和 ∇^2 分别为梯度算子和拉普拉斯(Laplace)算子，那么 P 的格林函数便是参数为 σ 的高斯(Gauss)函数.

我们看到这种形式的基函数展开和前面所述的精确插值基函数法非常类似，其中格林函数数对应基函数，并且每一基函数位于一数据点.当 $\upsilon = 0$，上述方法便退化到精确插值方法，而当 υ 不为零时，我们便再也不能得到一精确插值函数，由于正则化项的作用，网络函数将更加光滑.

实用上，正则化方法也可用于径向基函数神经网络，此时网络的基函数中心不必位于数据点上，基函数的个数也不必与数据据点的个数相等，另外，正则化方法也可用于基函数不是格林函数的场合，如果正则化项是网络映射的二次函数，则第二层参数估计可通过简单的优化方法得到.例如，如果误差函数为平方和误差而正则化项为

$$\frac{\upsilon}{2} \sum_n \sum_k \sum_i \left\{ \frac{\partial^2 y_k^n}{\partial x_i^2} \right\}^2, \tag{2.157}$$

则加上此正则项后，第二层权重由下述方程的解给出

$$MW = \Phi^{\mathrm{T}} T, \tag{2.158}$$

其中

$$M_{jj'} = \sum_n \left\{ \varphi_j^n \varphi_{j'}^n + \upsilon \sum_i \left\{ \frac{\partial^2 \varphi_j^n}{\partial x_i^2} \frac{\partial^2 \varphi_{j'}^n}{\partial x_i^2} \right\} \right\}, \tag{2.159}$$

其中 $\Phi = (\varphi_j^n)$，而 $\varphi_j^n = \varphi_j(x^n)$，其他函数的定义类似.当 $\upsilon = 0$ 时，这一算法退化到一般的径向基函数网络训练算法.加入正则化项并未增加过大的运算量，因为大部分的时间仍用于求解联立线性方程组(2.158).

2.4.5 噪声插值理论

径向基函数展开的另一观点来自噪声数据的插值理论，假设有一单变量函数 $h(x)$，它是一精确函数：对于每一输入 x，有惟一的 u 与之对应.但如果输入数据受到加性噪声的影响而变得不精确，则插值方法便是寻找一函数 $y(x)$使得平方和误差

$$E = \frac{1}{2} \iint |y(x + \xi) - h(x)|^2 \tilde{p}(\xi) p(x) \mathrm{d}\xi \mathrm{d}x, \tag{2.160}$$

其中 $p(x)$是输入数据的概率密度分布函数,而 $\tilde{p}(\xi)$是噪声的概率密度分布函数,令 $z=x+\xi$,则我们有

$$E=\frac{1}{2}\iint\{y(z)-h(x)\}^2\tilde{p}(z-x)p(x)\mathrm{d}z\,\mathrm{d}x. \tag{2.161}$$

使用变分技巧,我们可得

$$y(z)=\frac{\int h(x)\tilde{p}(z-x)p(x)\mathrm{d}x}{\int\tilde{p}(z-x)p(x)\mathrm{d}x}. \tag{2.162}$$

如果我们依分布 $p(x)$抽取有限个数据点$\{x^n\}$,则上式可用下式近似

$$y(x)=\frac{\sum_n h(x^n)\tilde{p}(x-x^n)}{\sum_n\tilde{p}(x-x^n)}. \tag{2.163}$$

上式可看作径向基函数展开,其中 $h(x^n)$为展开系数而基函数为

$$\varphi(x-x^n)=\frac{\tilde{p}(x-x^n)}{\sum_n\tilde{p}(x-x^n)}. \tag{2.164}$$

由于函数 h 未知,系数 $h(x^n)$应认为需利用数据来确定的参数.但我们注意到 $h(x)$是一精确函数,因此 $h(x^n)=t^n$.故(2.163)式中的系数 $h(x^n)$可用目标值替代.由此推出的基函数与前述基函数的差别在于这里的基数是归一的,即

$$\sum_n\varphi(x-x^n)=1. \tag{2.165}$$

就网络的观点而言,归一化需要层内的侧向连接.如果噪声分布是正态的,则 $\tilde{p}(\xi)=\mathrm{e}^{-\frac{\xi^2}{2\sigma^2}}$,于是我们得到高斯基函数展开

$$y(x)=\frac{\sum_n t^n\mathrm{e}^{-\frac{(x-x^n)^2}{2\sigma^2}}}{\sum_n\mathrm{e}^{-\frac{(x-x^n)^2}{2\sigma^2}}}. \tag{2.166}$$

这一展开可直接推广到多个输出变量的情况,此时

$$y_k(x)=\frac{\sum_n t_k^n\mathrm{e}^{-\frac{\|x-x^n\|^2}{2\sigma^2}}}{\sum_n\mathrm{e}^{-\frac{\|x-x^n\|^2}{2\sigma^2}}}. \tag{2.167}$$

2.4.6 与核回归的联系

使用径向基函数对函数进行逼近的另一动机来自核回归理论.这是一个

利用核密度估计方法，从噪声数据中估计回归函数的一个技巧．考虑一个将输入向量变为输出向量 y 的映射，并且假定我们有一批训练数据 $\{x^n, t^n\}_{n=1}^N$．数据的最完整统计描述便是其分布函数 $p(x, t)$，我们可利用核估计来逼近这一分布函数．如果我们考虑高斯核，则密度估计为

$$\hat{p}(x,t)=\frac{1}{N}\sum_{n=1}^{N}\frac{1}{(2\pi h^2)^{\frac{d+c}{l}}}\mathrm{e}^{-\frac{\|x-x^n\|^2}{2h^2}-\frac{\|t-t^n\|^2}{2h^2}}, \tag{2.168}$$

其中 d 和 c 分别是输入和输出空间的维数，就我们现在的情形而言，回归函数可定义为 x 给定时 t 的数学期望，即

$$\begin{aligned} y(x)&=\int tp(t\mid x)\mathrm{d}t \\ &=\frac{\int tp(x,t)\mathrm{d}t}{\int p(x,t)\mathrm{d}t}. \end{aligned} \tag{2.169}$$

如果我们将我们的密度估计式(2.168)代入此式，则有

$$y(x)=\frac{\sum_n t^n \mathrm{e}^{-\frac{\|x-x^n\|^2}{2h^2}}}{\sum_n \mathrm{e}^{-\frac{\|x-x^n\|^2}{2h^2}}}. \tag{2.170}$$

这一公式与前述公式完全相同．

2.4.7 基函数的优化

与多层感知器网相比，径向基函数网的主要优点之一便是隐单元中的参数选取不必借助于网络的整体优化方法．前面我们已经叙述了如何求解网络的第二层权重，本节我们将讨论作为第一层权重的径向基函数参数的选取．而如何选取基函数的个数需要占用较大的篇幅，故我们此处略去讨论．

径向基函数可从函数逼近论、正则化、噪声插值、核估计等观点进行推导，所有这些观点均建议径向基函数的参数应形成输入数据的概率密度表示．这一思想导致了下述优化基函数参数的无导师优化程序，该程序仅依赖来自训练数据的输入数据而略去了相应的目标数据．基函数参数 μ_j 可看作输入向量范型．

在神经网络具有潜在应用的许多领域中，无标号数据相当丰富而有标号数据相对匮乏．例如，网络的原始数据容易收集而对其用目标变量进行标号通常需用大量的人力和财力，在这样的应用场合，两阶段的径向基函数网训练方法具有特殊的优越性，其原因是网络的非线性部分的参数可利用大量富裕的数据来确定，而第二层相对较少的参数可利用有标号数据来确定．

我们已经给出了一些利用无导师方法训练径向基函数网第一层参数的理由，下面，我们给出几个具体的选取技巧.

2.4.7.1 子集选取法

选取基函数中心 μ_j 的一个简单方法便是让基函数中心为输入向量的一个随机选取子集.尽管这一方法明显地不是最优且其可能导致过多径向径函数，但许多迭代优化程序均依此方法产生初值.

另一种选取基函数的方法首先以所有数据点作为基函数中心，然后选择性地剔除那些对系统性态影响最小的中心.

这些方法仅确定了基函数的中心，宽度参数 σ_j 必须使用其他程序选取，通常，令 σ_j 为数据 μ_j 的 L 个最近邻数据的平均距离，其中 L 一般较小.这样一种方法可很快确定基函数的参数，但其通常仅是次最优的.

2.4.7.2 直交最小二乘法

选取数据集的一个子集作为基函数的一个更为原理化的方法是直交最小二乘法，它受下述"蛮干法"的启发.蛮干法是首先假定网络仅有一个基函数，然后我们令每一数据点为此基函数的中心，再利用伪逆方法求出第二层权重，在所有这 N 个网络中，我们选取误差最小的那个.在随后的算法中，基函数的个数逐步增加.如果在当前步中，已有 l 个点被选作基函数的中心，那么我们构选 $N-l$ 个基函数网络，每个网络除已选定的中心外，再加一个未选上的中心，其某一网络经训练后达到误差最小，则相应的新加的中心被选作网络的新中心加入网络中心集内.

上述方法计算上相当费时，因其每一步需对可能的基函数网求其伪逆解.能得到相同结果一个更为有效的程序是直交最小二乘法.概括地说，这是一个逐次增加基函数的方法.同前面一样，每一基函数的中心必须位于某一数据点上.这一方法首先利用隐单元输出值(由输入模式确定)张成线性空间 S，然后生成一组直交向量，利用这组直交向量，我们可直接计算那一数据点可选作基函数中心，从而使得平方和误差函数下降量最大.然后第二层参数估计由伪逆法确定，如果这一方法一直进行下去，那么所有的数据都将会被选到.相应地，误差函数也会下降到零.实用中，我们应在合适的时候终止算法以保证所得结果具有较好的推广性，详细的讨论可参见文献[9]，[41].

求基函数的其他方法还有聚类方法和高斯混合密度方法.

2.4.8 有导师训练

我们已经注意到，确定基函数参数的无导师方法通常不是最优的，其原理是算法并未考虑训练数据所提供的目标值，为了使得网络映射能最好地逼近训练数据赖以产生的映射，我们应将目标数据纳入训练算法.于是，我们的训

练算法便成为有导师训练方法，而不再是无导师方法.

令误差函数为

$$E = \sum_n \sum_k \{ \| y_k(x^n) - t_k^n \|^2 \}, \tag{2.171}$$

则误差函数是基函数参数和第二层线性参数的函数，若基函数为高斯函数，这一误差函数相对于基函数参数的导数为

$$\frac{\partial E}{\partial \sigma_j} = \sum_n \sum_k \{ y_k(x^n) - t_k^n \} w_{kj} \frac{\| x^n - \mu_j \|^2}{\delta_j^3} e^{\frac{-\| x^n - \mu_j \|^2}{2\delta_j^2}}, \tag{2.172}$$

$$\frac{\partial E}{\partial \mu_j} = \sum_n \sum_k [y_k(x^n) - t_k^n] w_{kj} \frac{(x^n - \mu_j)}{\sigma_j^2} e^{-\frac{\| x^n - \mu_j \|^2}{2\sigma_j^2}}. \tag{2.173}$$

利用误差函数关于可调节参数的导数，我们便可基于传统的优化方法构造网络的训练算法.这一算法最为突出的缺点便是失去了径向基函数网络二阶段学习算法的快速收敛性态.

§2.5 自组织特征映射

本章我们讨论一类称之为自组织特征映射的神经网络，这类网络基于竞争学习规则：网络的输出神经元彼此竞争，最终每一时刻仅有一个神经元激活.赢得竞争的神经元称为胜者为王神经元，而相应的规则亦称为胜者为王规则，导出胜者为王竞争原则的方法之一便是使用侧抑制连接，这一方法首先由 Rosenblatt 等(1958)提出.

在自组织特征征映射算法中，神经元通常置于一维和二维的格点.理论上也可置于任意维数的格点，但实用中很少出现.在竞争学习过程中，这些神经元被映入输入数据空间，每一神经元对应输入空间一个称之为范型的模型向量，这些范型构成了输入空间的典型代表，它们联合刻画了数据的统计分布和拓扑特性.因此，自组织特征映射可看作是输入模式的一个拓扑图，格点神经元在输入数据空间中的位置对应输入模式的内在特征，因此，将其命名为“自组织特征映射”.

这类神经元受大脑神经系统的生理结构的启发.在大脑中，不同的感官输入以拓扑图的形式表示，意义相近的输入通常在大脑中的表示位置相邻，这种联接的好处是其可通过相对简单的连接建立高速的数据处理系统.

理论上和实用上，我们都会遇到这样的问题：将大量的甚至无穷多个数据用少量的有限个点(称为范型或中心)来表示.我们希望这种表示有效地刻画原来数据的特征，传统的矢量量化和聚类问题即是此类问题.如果我们给这些表示加上一些结构，则相应的问题会更复杂.自组织特征映射便是在范型之间

加上了格状拓扑结构，因此，自组织特征映射本身便是一类矢量量化和聚类方法.以下我们在简要介绍大脑皮层结构之后，叙述两种特征映射模型，一个模型由 Willshaw 和 Van der Malsburg(1976)发展而另一类由 Kohonen(1982)提出，两种模型具有不同的输入形式.然后，我们在介绍短程激活-长程抑制的侧抑制连接模式后，叙述 Kohonen 自组特征映射的数学表述.

2.5.1 大脑皮层的结构

大脑皮层在大脑神经系统中占据着令人印象深刻的地位.大脑几乎完全被大脑皮层所覆盖，尽管它只有 2 毫米厚，但其展开后的表面积可达 2400 平方厘米(大约有 6 张 16 开纸大).而更加令人惊异的是它包含了数十亿的神经元和数千亿的突触连接.从绝对的复杂性而言，我们的大脑皮层是已知的最为复杂的系统.

整个大脑皮层由柱状结构排列而成，每一个柱内有六层神经元，同一柱内的神经元具有几乎完全相同的性质.由于我们对于外部环境的所有刺激均表示在这张平面上，而外部环境的刺激通常需由一高维向量甚至是无穷维的向量来表示，故大脑皮层为我们提供了自然界如何将高维数据有效地表示到二维空间的一个范例，相应地，大脑皮层的神经生理学特性和解剖学特性为我们提供了这一结构形成的线索.自组织特征映射的目的之一便是寻求这一结构的形成算法，然后将之用于现实问题的求解.

大脑皮层另一令人印象深刻的特征便是它的拓扑特性：相似的刺激通常由相邻的神经元分别表示.这一性质在实用上的应用包括维数压缩和数据可视化等.自组织特征映射的另一目的便是希望在寻找范型向量的同时，记录它们之间的相互拓扑关系.

2.5.2 两个基本的特征映射模型

根据前面的讨论，我们已看到自组织特征映射的目标是将以格状分布的神经元映到输入空间的一个特定区域，并使得格子空间内相邻的神经元表示输入数据空间中相邻的范型.而在格子空间中，每一神经元应与某一组神经元相邻，这种领域关系我们随后将给出定义.

在自组织特征映射中，网络的输入决定了特征映射模型的性质.两种最基本的模型如图 2.8 和图 2.9 所示，其中输出神经元分布在二维格点上，每一输入神经元与所有输出神经元全部相连.这两种模型均受 Von der Malsburg 关于自组织的开创工作的启发.图 2.8 的模型由 Willshaw 和 Von der Malsburg 提出.它基于生物的背景，用此解释从视网膜到视觉皮层的视图映射.这一模型由两个互相分离的二维格点神经元板相互连接而成，其中之一投射到另外

一个之上。一层格点表示输入神经元，而另一层格点表示输出神经元。输出层的神经元使用侧抑制连接方式连接，而两层之间的连接权重用 Hebb 学习规则训练。经学习后的网络兴奋模式与大脑层的兴奋模式非常相似，但这一网络两层神经元具有相同的维数。

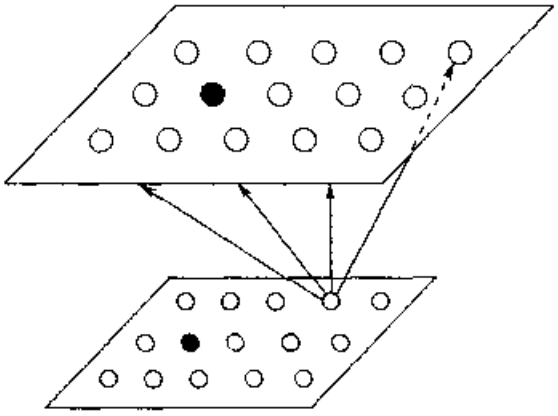


图 2.8 Willshaw Von der Malsburg 模型

图 2.9 所示的模型由 Kohonen 提出，它并未涉及生物细节，但这一模型仍试图抓住大脑拓扑图的特征。Kohonen 讨论了这一模型生物上的可行性，由于其可完成信息压缩，它似乎较 Willshaw-Von der Malsburg 模型更为通用。

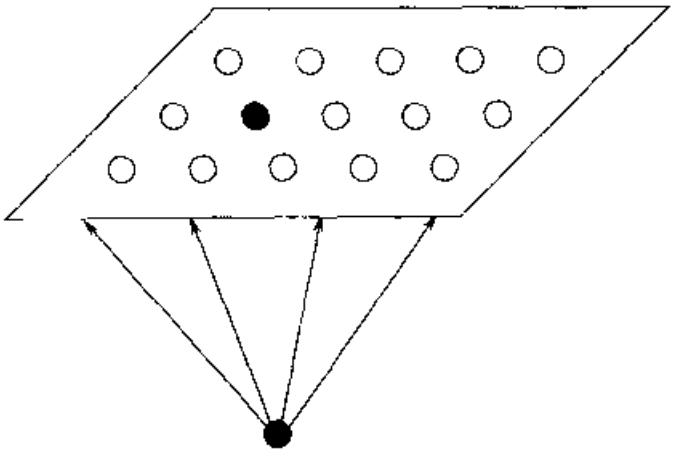


图 2.9 Kohonen 模型

我们已经说过，Kohonen 模型是一保持拓扑结构的向量编码算法，因此，我们既可从生物的观点出发导出这一算法，也可从矢量量化和聚类的观点导出这一算法。下面，我们将分别介绍这两类方法。

较之 Willshaw-Von der Malsburg 模型，Kohonen 模型在文献中受到了更多的研究，其原因是这一模型在模拟和理解大脑皮层方面具有许多有趣的性

质，且在实用上更为有效.

2.5.3 侧向连接

侧向连接是神经网络最有用的性质，它是层间一特定形式的连接.为讨论方便起见，我们假定网络的拓扑图如图 2.8 所示，其中输出层的神经元排在二维格点上.网络中有两类不同类型的连接，从输入层到输出层的前向连接和输出层神经元之间的侧向连接.这两类连接起着不同的作用.输入信号的加权线性和经激活函数作用后的输出用于执行特征提取，因此每一神经元仅响应某些特殊的输出信号.另一方面，侧向连接根据其他神经元与所考虑的神经元之间的距离来抑制和加强神经元的兴奋.

受生物学的启发，侧向连接的权重通常用一个墨西哥帽函数来描述.常用的墨西哥帽函数为 dog 函数，它是两个不同窗宽的高斯函数的差.根据墨西哥帽函数的形状，我们可以区分侧向连接的三个不同区域.

1° 短程激活区.

2° 一个抑制区域.

3° 一个环绕抑制区域的弱激活区域，由于第三个区域通常不予考虑，因此，这一连接通常称为短程激活-长程抑制连接或简称侧抑制连接.

上述神经网络有两种重要特征.第一，神经网络的兴奋输出集中在一个聚集在一起的神经元区域，这一区域通常称之为激活小泡，第二，激活小泡的位置由输入信号的性质决定.根据激活小泡的特性，我们可将神经元 j 的输出理想化为下述形式：

$$y_j = \begin{cases} 1, & \text{神经元 } j \text{ 在激活小泡内,} \\ 0, & \text{神经元 } j \text{ 不在激活小泡内.} \end{cases}$$

另外，由于每一激活小泡有一中心，我们可称相应的激活小泡为该中心神经元的邻域，因此，只要我们为每一神经定义一邻域，则我们便不再需要侧向连接，相应的侧向连接的调节对应邻域大小的调节，下面的自组织特征映射算法中，我们便利用这种简化表达方式.

2.5.4 自组织特征映射算法

我们已经说过，自组织特征映射的两个主要目的是：1°将任意维的输入模式映到由有限个格点神经元构成的一维或二维空间，2°尽可能地使相邻的输入模式激活相邻的神经元.

图 2.9 是一基本的 Kohonen 自组织特征映射网络，它由一组二维格点输出神经元组成，每一神经元与所有输入神经元相连.设输入向量为

$$x = (x_1, \cdots, x_d)^{\mathrm{T}},$$

而输出神经元 j 所对应的权重向量为

$$w_j = (w_{j1}, \cdots, w_{jd})^{\mathrm{T}}.$$

每一输出神经元计算输入向量 x 和权重向量 w_j 之间的距离，然后据此利用竞争学习规则对权向量进行调节．每一神经元的邻域可以是正方形、长方形或圆形，初始的邻域通常为整个网络的一半或三分之二大小，然后，随着算法的进行，邻域按一定规律缩小．在竞争学习中，胜利者和其邻域神经元使用权重调节算法对其权重进行调节．而其他神经元保持权重不变．

在自组织学习中，我们需找到与输入向量 x 最为匹配或相似的权向量 w_j，一种最为简单的办法便是通过计算内积 $w_j^{\mathrm{T}}x$，找出内积最大者为最佳匹配神经元，这一神经元通常定义为获胜者．

在自组织学习算法中，通常令 w_j 为单位向量，在这种情况下，由

$$\begin{aligned} \| w_j - x \|^2 &= \| w_j \|^2 - 2w_j^{\mathrm{T}}x + \| x \|^2 \\ &= 1 - 2w_j^{\mathrm{T}}x + \| x \|^2 \end{aligned} \tag{2.174}$$

知最佳匹配准则 $\max\limits_j w_j^{\mathrm{T}}x$ 等价于最小向量距离 $\min\limits_j \| w_j - x \|$．由于最小距离原则在许多场合下更为有效，故我们以下仅讨论最小距离准则．对于给定的 x，如果 j 为其最佳匹配神经元并记为 $j(x)$，则我们有

$$j(x) = \arg\min_j \| x - w_j \|. \tag{2.175}$$

由这一公式定义的神经元称为获胜者或最佳匹配神经元．根据公式(2.175)，一个连续的输入空间被映到一组离散神经元．

对于每一神经元 j，我们有一邻域 Λ_j，若获胜神经元为 $j(x)$，则相应的邻域便为 $\Lambda_{j(x)}$．另外，邻域函数随学习过程不断变化，故我们记时刻 n 的邻域结构为 $\Lambda_{j(x)}(n)$．

对于自组织特征映射算法，神经元 j 的权向量 w_j 需根据输入向量 x 进行调节．但核心的问题是我们如何调节．Kohonen 受生物研究和 Hebb 学习规则的启发，推出了下列的权重修改规则

$$w_j(n+1) = \begin{cases} w_j(n) + \eta(n)[x - w_j(n)], & j \in \Lambda_{i(x)}(n), \\ w_j(n), & \text{其他 } j, \end{cases} \tag{2.176}$$

其中 x 为时刻 n 的输入向量，$\Lambda_{i(x)}(n)$ 是获胜神经元 $i(x)$ 在时刻 n 的邻域神经元集合，$\eta(n)$ 是相应的学习速率参数．从几何观点来看，上述修正规则是将获胜神经元及其邻域神经元的权重向量 w_j 向输入向量 x 所在的位置移动．自组织特征映射的步骤可归纳如下：

自组织特征映射算法．

1．初始化，随机选取互不相同的 $w_j(0)$，$n=0$．

2. 从一定分布随机抽取一输入向量 $x(n)$或随机地从训练数集中抽取一输入向量 $x(n)$.

3. 求此时刻 n 的最佳匹配神经元$i(x(n))$

$$i(x(n)) = \arg\min_j \| w_j - x(n) \| . \tag{2.177}$$

4. 使用下述公式调节权重

$$w_j(n+1) = \begin{cases} w_j(n) + \eta(n)(x(n) - w_j(n)), & j \in \Lambda_{i(x(n))}(n), \\ w_j(n), & \text{其他 } j, \end{cases} \tag{2.178}$$

其中$\eta(n)$为学习速率参数，$\Lambda_{i(x)}(n)$是环扰获胜神经元的邻域神经元. $\eta(n)$和 $\Lambda_{i(x(n))}(n)$在学习过程中动态变化以得到最好结果.

5. 重复 2～4 直到拓扑图无明显变化.

自组织特征映射算法本身是随机的，它的成功与否与 η 和 Λ 的选取有极大的关系，但遗憾的是，我们现在仍未有一个理论准则用以指导它们的选取，我们只能采用试错法对其进行确定. 但大量的实验和观察表明，让 η 从 1 开始，缓慢地随 n 增大而下降到一个较小的常数(如 0.01)，然后将 η 固定在此常数上进行迭代. 而 $\Lambda_j(n)$随 n 增大缓慢地缩小直至其邻域中除自身外无其他神经元，则算法会产生相对满意的结果. 权重的修正规则用使 w_j 构成数据的范型，而邻域结构的引入是为了保证相邻的神经趋于表示相邻的特征向量，这一性质在神经网络中通常称为保拓扑性.

2.5.5 矢量量化方法和聚类方法

我们已多次强调，自组织特征映射的主要目的之一是利用有限个范型向量 w_j 有效地表示输入空间数据或训练数据. 当数据为一训练数据集时，衡量这一表示好坏的目标函数为

$$J = \sum_{n=1}^{N} \| x^n - w_{i(x^n)} \|^2, \tag{2.179}$$

其中

$$i(x^n) = \arg\min_j \| x^n - w_j \| . \tag{2.180}$$

而当数据为一概率分布密度为 $p(x)$的连续空间时，相应的目标函数为

$$J = \int \| x - w_{i(x^n)} \|^2 p(x) \mathrm{d}x . \tag{2.181}$$

如果范型向量的个数给定，则极小化 J 的问题称为矢量量化问题. 如果范型的个数未定，且希望范型能确切的表示数据类的中心，则相应地极小化 J 的问题称为聚类问题. 由于在聚类问题中我们通常针对给定的范型个数极小化 J，然后采用其他标准选取合适的表示，因此，以下我们不再强调这二者的分

别，并称相应的极小化 J 的算法为聚类方法，另外，由于通常的数据集为具有有限个向量的训练集，故下面我们仅考虑目标函数(2.179).

为表示简洁起见，对于给定的 w_j，令

$$i(x_j, w_1, \cdots, w_c) = \arg\min_j \| x - w_j \|, \tag{2.182}$$

利用迭代式

$$w_j(\tau + 1) = \frac{1}{N_j} \sum_{i(x_j^n w_1(\tau), \cdots, w_c(\tau)) = j} x^n, \tag{2.183}$$

我们可得到 J 的极值点 $(w_1^*, \cdots, w_n^*)^{\mathrm{T}} = \lim_{\tau \to \infty} (w_1(\tau), \cdots, w_n(\tau))$，其中 N_j 为 $i(x_j^n, w_1(\tau), \cdots, w_c(\tau)) = j$ 的数据点 x^n 的个数. 相应的，极小化 J 的在线方法为

$$w_j(\tau + 1) = \begin{cases} w_j(\tau) + \eta(x^n - w_j(n)), & j = i(x), \\ w_j(\tau), & j \neq i(x), \end{cases} \tag{2.184}$$

其中 x^n 为第 n 个时刻的输入向量，$i(x)$ 如式 2.182 定义，我们看到这一算法除无邻域结构外，与自组织特征映射算法完全一致. 这一算法由 Lloyd(1957) 提出，在信息处理中，这一方法及其变形被广泛使用.

2.5.6 保拓扑性度量

自组织特征映射的另一目的是保拓扑性，保拓扑性的确切定义是指输入空间相邻的向量被映到格点上相邻的神经元的权重或范型向量. 衡量保拓扑性有许多标准，就一维格点神经元网络而言，如果神经元按顺序排列，则常用的保拓扑性好坏的度量为

$$J_c = \sum_{j=1}^{l} \| w_j - w_{j+1} \|^2. \tag{2.185}$$

如果神经元按二维格点拓扑分布，位于 (i, j) 位置的神经元权重向量记为 $w_{i,j}$，则可定义保拓扑性度量

$$J_c = \sum_{i,j} \| w_{i,j} - w_{i+1,j} \| \| w_{ij} - w_{i,j+1} \| \tag{2.186}$$

或

$$J_c = \sum_{i,j} \| w_{i-1,j} + w_{i-1,j} + w_{i,j} + w_{i,j+1} - 4w_{i,j} \|^2 \tag{2.187}$$

或

$$J_c = \sum_{i,j} \left| \| w_{i,j} - w_{i-1,j} \|^p + \| w_{i,j} - w_{i,j+1} \|^p \right|, \tag{2.188}$$

其中 p 为一正常数，上述求和遍及所有有意义的 i, j，根据目标函数的定义，J_c 愈小，保拓扑性愈好，因此，保拓扑性可通过极小化这些目标函数得到.

由以上讨论可见，就我们现在的理解而言，保拓扑性和表示的有效性或完

全性由不同的目标函数控制，下面我们将讨论如何利用这两类目标函数构造新的自组织特征映射算法.

2.5.7 设计新的自组织特征映射算法

Kohonen 自组织特征映射的优点是利用简单的算法达到了有效地表示数据和实现保拓扑性的双重目的.这一算法在实用上非常有效，但迄今为止，我们仍未从理论上彻底理解这一算法的运行机理.其主要原因是我们根本给不出这一算法的目标函数.为了改善这一情况，许多学者提出了一些算法复杂度不大，且保持自组织特征映射的算法.这些算法相对而言具有良好的解析性，它们的目标函数具有显式表示式，其具体形式为

$$E = J + \beta J_1, \tag{2.189}$$

其中 β 为一正常数，利用这一表达式，我们可以解决更为广泛的应用问题.这方面最著名的例子便是 Durbin 和 Willshaw(1987)利用这一目标函数求解 TSP 问题.希望对此进一步了解的读者可参见文献[56].

§2.6 回归神经元网络

多层感知器和径向基函数均为非线性层状前向网的重要例子.自组织特征映射尽管隐含地假设了网络的侧向连接，但其算法仍是一前向网训练算法，本章我们考虑另一类非常重要的神经网络——回归网，它的许多思想来自统计物理学，且其与动力系统稳定性理论和传统算法之间有着密切关系.

2.6.1 逐次逼近法

众所周知，数学上可严格给出解析解的明显表达式的问题少之又少，较众多的其他问题而言，它们简直是凤毛麟角，那么，对于一般的问题我们应怎样求解呢?

数值上求解一般问题的核心算法之一便是将一静态问题转化为一动态问题，其具体步骤为

1. 将原问题转化为一不动点问题，即方程

$$x = \varphi(x). \tag{2.190}$$

2. 对于任一初始值 $x(0)$，由迭代公式

$$x(n+1) = \varphi(x(n)). \tag{2.191}$$

产生一个向量序列 $\{x(n)\}_{n=1,2,\cdots}$，当 $x(n)$ 收敛时，则其极限点便为方程 $x = \varphi(x)$ 的解.

方程(2.191)通常称为离散动态系统.在算法理论中，这一方法称为迭代法或

逐次逼近法. 由于这一方法编程简洁且功能强大，因而在日常的应用软件设计中被广泛采用.

若原问题是求解

$$\min f(x), \tag{2.192}$$

则具体的最速下降法为

$$x(n+1) = x(n) - \alpha_n \nabla f(x(n)). \tag{2.193}$$

如果令 $\alpha_n \to 0$，则

$$\lim_{\alpha_n \to 0} \frac{x(n+1) - x(n)}{\alpha_n} = \frac{\mathrm{d}x}{\mathrm{d}t} = -\nabla f(x), \tag{2.194}$$

即迭代法变为

$$\frac{\mathrm{d}x}{\mathrm{d}t} = -\nabla f(x). \tag{2.195}$$

传统的迭代法(2.191)是这一微分方程的欧拉折线法. 在近代算法设计中，利用微分方程构造算法的方法称为连续方法. 连续方法揭示了许多传统迭代法之间的关系并产生了许多新的算法.

诸如

$$\frac{\mathrm{d}x}{\mathrm{d}t} = f(x) \tag{2.196}$$

的方程亦称为连续动力系统，而动力系统稳定性理论研究当 t 或 n 趋于无穷时，方程(2.196)的解 $x(t)$ 或迭代公式(2.191)产生的序列 $x(n)$ 的渐近行为. 例如当 $t \to +\infty$ 时，方程(2.195)对任一初始 $x(0)$ 的解 $x(t)$ 的极限亦均满足极值的必要条件

$$\nabla f(x) = 0. \tag{2.197}$$

在前向网中，我们的目的是逼近一个表示输入－输出关系的连续映射

$$y = f(x), \tag{2.198}$$

而在回归网中，我们则希望网络能够自动地完成迭代运算

$$x(n+1) = \varphi(x(n)) \tag{2.199}$$

或求解(跟踪)微分方程

$$\frac{\mathrm{d}x}{\mathrm{d}t} = f(x(t)). \tag{2.200}$$

下面，我们将讨论回归网完成这些功能的具体细节.

2.6.2 离散 Hopfield 网

回归网中最为人熟知的是 Hopfield 网(Hopfield, 1982)，这一网络由 N 个神经元组成，每对神经元 i 和神经元 j 相互连接，其连接权重满足 $w_{ij} = w_{ji}$ 且 $w_{ii} = 0$. 神经元的激活函数为符号函数

$$\varphi(a) \equiv \operatorname{sgn}(a) = \begin{cases} 1, & \text{如果 } a \geqslant 0, \\ -1, & \text{如果 } a < 0 \end{cases} \tag{2.201}$$

在给定初始状态 $x(0)$ 后，网络按下述方式自发地运行

$$x_j(t+1) = \varphi\Big\{\sum_{i=1}^{N} w_{ji}x_i(t) - \theta_i\Big\}, \tag{2.202}$$

其中 $x_j(t+1)$ 为神经元在 $t+1$ 时刻的输出值，它依赖于网络在 t 时刻的状态 $x(t)=(x_1(t),\cdots,x_N(t))^{\mathrm{T}}$. 当网络按照这种自发地方式运行达到满足下式的稳定态

$$x_j = \varphi\Big\{\sum_{i} w_{ji}x_i - \theta_i\Big\}, \tag{2.203}$$

则宏观上，网络已无变化，此时我们便认为网络运行已经结束并将网络的稳定态作为网络的输出.

对于给定的实际问题，如果我们可以将解表示成具有确定权重的 Hopfield 网的稳定态，则由于网络自发地的运行最终会达到稳定态，故这一运行过程提供了求解问题的一种网络算法，由于这一原因，网络自发地运行通常亦称为神经计算.

对于给定的离散 Hopfield 网，网络的状态有两种变化方式，第一种变化方式是所有神经元 j 同时按公式(2.202)修改其权重，第二种变化方式是每一时刻仅有一个神经元按公式改变其权重. 前一变化方式称为全并行变化方式，而后一变化方式称为串行运行模式. 由于并行运行模式并不能保证网络收敛到其稳定态，而串行模式总收敛到网络的一稳定态，故我们下面仅讨论离散 Hopfield 网络在串行方式下的收敛定理.

引理 2.1 令

$$\varepsilon_i = \min\Big\{\theta_i - \sum_{j=1}^{N} w_{ij}x_j : x_i \in \{-1,1\}, \sum_{j=1}^{N} w_{ij}x_j - \theta_i < 0\Big\}, \tag{2.204}$$

则对于任意给定的初始二值输入 $x(0)$，迭代公式

$$x_j(t+1) = \operatorname{sgn}\Big\{\sum_{i=1}^{N} w_{ji}x_i(t) - \theta_i\Big\} \tag{2.205}$$

和迭代公式

$$x(t+1) = \operatorname{sgn}\Big\{\sum w_{ji}x_i(t) - \bar{\theta}_i\Big\} \tag{2.206}$$

产生相同的序列 $\{x(t)\}$，其中，$\bar{\theta}_i$ 为

$$\bar{\theta}_i = \theta_i - \frac{1}{2}\varepsilon_i. \tag{2.207}$$

证明 根据 ε_i 和 $\bar{\theta}_i$ 的定义，对任意二值向量 x，我们有

$$\operatorname{sgn}\left(\sum_{i=1}^{N} w_{ji}x_i - \theta_j\right) = \operatorname{sgn}\left(\sum_{i=1}^{N} w_{ji}x_i - \bar{\theta}_j\right). \tag{2.208}$$

事实上，如果

$$\operatorname{sgn}\left(\sum_{i=1}^{N} w_{ji}x_i - \theta_j\right) = 1, \tag{2.209}$$

则

$$\sum_{i=1}^{N} w_{ji}x_i - \theta_j \geqslant 0. \tag{2.210}$$

故

$$\begin{aligned}\sum_{i=1}^{N} w_{ji}x_i - \bar{\theta}_j &\equiv \sum_{i=1}^{N} w_{ji}x_i - \theta_j + \frac{1}{2}\varepsilon_j \\ &> \sum_{i=1}^{N} w_{ji}x_i - \theta_j \geqslant 0,\end{aligned} \tag{2.211}$$

因此，我们有

$$\operatorname{sgn}\left(\sum_{i=1}^{N} w_{ji}x_i - \bar{\theta}_j\right) = 1. \tag{2.212}$$

如果

$$\operatorname{sgn}\left(\sum_{i=1}^{N} w_{ji}x - \theta_j\right) = -1, \tag{2.213}$$

则

$$\sum_{i=1}^{N} w_{ji} - \theta_j < 0. \tag{2.214}$$

根据 ε_j 的定义，我们有

$$\sum_{i=1}^{N} w_{ji}x_i - \theta_j < -\frac{1}{2}\varepsilon_j, \tag{2.215}$$

因此

$$\sum_{i=1}^{N} w_{ji}x_i - \bar{\theta}_j \equiv \sum_{i=1}^{N} w_{ji}x_i \quad \bar{\theta}_j + \frac{1}{2}\varepsilon_j < 0, \tag{2.216}$$

故

$$\operatorname{sgn}\left(\sum_{i=1}^{N} w_{ji}x_i - \bar{\theta}_j\right) = -1, \tag{2.217}$$

因此，引理结论成立.

引理 2.2 对于如上定义的 ε_j 和 δ_j，不等式

$$\left|\sum_{i=1}^{N} w_{ji}x_i - \theta_j\right| \geqslant \frac{1}{2}\varepsilon_j \tag{2.218}$$

对任意二值向量 x 成立.

证明 如果 $\sum_{i=1}^{N} w_{ji}x_i - \theta_j \geqslant 0$, 则

$$\begin{aligned}\sum_{i=1}^{N} w_{ji}x_i - \tilde{\theta}_j &= \sum_{i=1}^{N} w_{ji}x_i - \theta_j + \frac{1}{2}\varepsilon_j \\ &\geqslant \frac{1}{2}\varepsilon_j .\end{aligned} \tag{2.219}$$

如果 $\sum_{i=1}^{N} w_{ji} - \theta_j < 0$, 则由 ε_j 的定义, 我们有

$$\begin{aligned}\left|\sum_{i=1}^{N} w_{ji} - \tilde{\theta}_j\right| &= \left|\sum_{i=1}^{N} w_{ji} - \theta_j + \frac{1}{2}\varepsilon_j\right| \\ &\geqslant \left|\sum_{i=1}^{N} w_{ji} - \theta_j\right| - \frac{1}{2}\varepsilon_j \\ &= -\sum_{i=1}^{N} w_{ji} + \theta_j - \frac{1}{2}\varepsilon_j \\ &\geqslant \varepsilon_j - \frac{1}{2}\varepsilon_j \\ &= \frac{1}{2}\varepsilon_j ,\end{aligned} \tag{2.220}$$

故结论成立.

现在, 我们证明离散 Hopfield 网络在串行运行方式下的收敛性定理.

定理 2.3 在串行运行方式下, 离散 Hofield 网在有限步后收敛到一稳定态.

证明 为证明简单起见, 我们假设网络神经元按编号循环顺序逐次依公式(2.202)修改其状态. 由于离散 Hopfield 网

$$x_j(t+1) = \operatorname{sgn}\left(\sum_{i=1}^{N} w_{ji}x_i(t) - \theta_j\right) \tag{2.221}$$

与

$$x_j(t+1) = \operatorname{sgn}\left(\sum_{i=1}^{N} w_{ji}x_i(t) - \tilde{\theta}_j\right) \tag{2.222}$$

产生的序列完全相同, 下面, 我们考虑迭代(2.222)的收敛性.

令

$$E(x) = -\frac{1}{2}\sum_{i=1}^{N}\sum_{j=1}^{N} w_{ji}x_ix_j - \sum_{i=1}^{N}\tilde{\theta}_i x_i , \tag{2.223}$$

由于 $w_{ii}=0$, 当 x_j 的变化为 $\triangle x_j$ 时, 相应地, E 的变化 $\triangle E$ 满足

$$\triangle E = -\triangle x_j\left(\sum_{i=1}^{N} w_{ji}x_i - \theta_j\right). \tag{2.224}$$

于是，如果在时刻t，$x_j(t+1)$由公式(2.222)得到，则当$x_j(t+1)$与$x_j(t)$符号相同时，E值无变化，而当$x_j(t+1)$与$x_j(t)$符号相反时，函数E在t时刻的值$E(t)$和在$t+1$时刻的值$E(t+1)$满足

$$\begin{aligned} E(t+1)-E(t) &= -(x_j(t+1)-x_j(t))\left|\sum_{i=1}^{N} w_{ji}x_i(t)-\theta_j\right| \\ &= -2\operatorname{sgn}\left(\sum_{i=1}^{N} w_{ji}x_i(t)-\theta_j\right)\left|\sum_{i=1}^{N} w_{ji}x_i(t)-\theta_j\right| \\ &= -2\left|\sum_{i=1}^{N} w_{ji}x_i(t)-\theta_j\right| \\ &\leqslant \varepsilon_j. \end{aligned} \tag{2.225}$$

因此，状态每变化一次，函数值E便下降一个常量ε_j，而对于二值向量x，函数值有有限下界，故其不能无限下降，因此，网络在运行规则(2.222)下，其状态不能无限次改变，故状态只能变化有限次．而当网络未达到稳定态时，神经元标号每循环一次，至少有一神经元会改变其状态，由此可知，网络在有限次运行后必然达到稳定态．证毕．

函数E通常称为离散动力系统(2.221)的能量函数，系统的运行总使能量函数下降，利用这一方法分析动力系统渐近行为的方法称为Liapunov方法，相应的能量函数亦称Liapunov函数．

Hopfield网的两个主要用途是离散优化和二值模式的联想记忆．在联想记忆中，一组需记忆的模式被存在Hopfield网的稳定点上，一稳定点的吸引域中的任一模式均可作为回忆或提取存在这一稳定点上的模式的指标．

联想记忆通常分为两步：存贮和提取．在存贮步，我们利用学习算法确定一组权重使得需存贮的模式向量为对应Hopfield网的稳定态．w_{ij}通常利用一类广义Hebb学习规则获得．在模式提取步，一个初始的向量被当作网络的初始状态，然后网络自发地演化直至达到稳定态．这一稳定态便是利用初值所提取的记忆，这一方法的优点之一便是可以利用模糊的线索恢复记忆．

离散优化直接利用Hopfield网络使能量函数下降．根据这一性质，如果我们能将一组合优化问题表述为Hopfield网所对应的能量函数的形式，则网络的自发运行便会找到组合优化问题的解．事实上，任何二次组合优化问题的目标函数均可写成Hopfield网的能量函数，传统的旅行售货员问题便可表述成这一形式．

2.6.3 连续Hopfield网

连续Hopfield网与离散Hopfield网的拓扑连续结构完全相同，但其激活函数φ_j通常为一S形函数，神经元j的输出通常可表示为

$$x_i = \varphi_i(v_i). \tag{2.226}$$

由于 φ_i 是单增函数，因此，网络的状态 x_i 与变量 v_i 一一对应. 下面我们将利用变量 v_i 描述网络的状态.

在权重给定的情况，Hopfield 假定网络按下述方式变化其状态

$$C_i \frac{dv_i}{dt} = \sum_{j=1}^{N} w_{ji}\varphi_j(v_j) - \frac{v_i}{k_i} + \theta_i. \tag{2.227}$$

上述参数 C_i 和 k_i 有着生物和物理的意义. 但我们此处更关注这一网络的稳定性态. 下面，我们总假定 C_i 和 k_i 为正常数.

对于一个函数 $E(v)$，如其变量 v 按方程(2.227)变化时，相应的 $E(v)$ 随 t 的变化满足

$$\frac{dE}{dt} \leqslant 0, \tag{2.228}$$

则称 E 为方程(2.227)的 Liapunov 函数

定理 2.4 函数

$$E = -\frac{1}{2}\sum_{i}\sum_{j} w_{ji}x_i x_j + \sum_{j=1}^{N}\frac{1}{k_j}\int_0^{x_j}\varphi_j^{-1}(x_j)dx_j + \sum_{j=1}^{N}\theta_j x_j \tag{2.229}$$

是微分方程(2.227)的 Liopunov 函数，其中 $x_i = \varphi(v_i)$.

证明 根据微分方程(2.227)，我们有

$$\frac{dE(x)}{dt} = \sum_{i}\frac{\partial E}{\partial x_i}\frac{dx_i}{dt}. \tag{2.230}$$

由于 $w_{ji} = w_{ij}$，故

$$\begin{aligned}\frac{\partial E}{\partial x_i} &= -\sum_{j} w_{ij}x_j + \frac{v_i}{k} + \theta_i \\ &= -\sum_{j} w_{ij}\varphi(v_j) + \frac{v_i}{k} + \theta_i \\ &= -\frac{dv}{dt}.\end{aligned} \tag{2.231}$$

而

$$\frac{dx_i}{dt} = \varphi'(v_i)\frac{dv_i}{dt}, \tag{2.232}$$

因此，E 是方程的一 Liapunov 函数.

根据公式(2.230)，我们进一步有下列推论.

推论 对于如上定义的函数 E，我们有

$$\frac{dE}{dt} \leqslant 0, \tag{2.233}$$

且当且仅当 $\frac{dv_i}{dt} = 0$ 对所有 i 成立时

$$\frac{dE}{dt} = 0. \tag{2.234}$$

下面，我们称满足方程组

$$\frac{dv_i}{dt} = 0, \qquad i = 1, \cdots, N \tag{2.235}$$

的 v_i 或 x_i 为 Hopfield 方程的稳定态. 函数 E 的任一极小值都应满足此方程，故其必为方程(2.227)的稳定态.

利用方程(2.230)知，当网络自发地按照方程(2.227)运行时，能量函数便会随之下降，如果网络未达到稳定态，则能量函数 E 的下降便不会停止，故当时间 t 趋于无穷时，网络状态必趋于某一稳定态. 连续 Hopfield 网的这一性质在理论和应用上具有极为重要的性质，利用 Hopfield 网解决联想记忆问题和优化问题的基础即是这一性质，其基本思想是寻找合适的权重使得所需求解问题的解是相应 Hopfield 网络的稳定态，然后让网络自发的按照(2.227)式演化直至达到某一稳定态. 该稳定态即给出问题的解.

2.6.4 其他回归网

Hopfield 网络是众多的回归网中的一类，其他类似的回归网有

1. Cohen-Grossberg 网. 这一网络运行方程为

$$\frac{dv_i}{dt} = a_i(v_i)b_i(v_i) - \sum_{j=1}^{N} w_{ij}\varphi_j(v_j), \tag{2.236}$$

其中 $a_i(v_i) \geqslant 0$, $w_{ij} = w_{ji}$，对于这一网络，相应的能量函数或 Liapunov 函数为

$$E(v) = \frac{1}{2}\sum_{i=1}^{N}\sum_{j=1}^{N} W_{ij}\varphi_j(v_i) - \sum_{i=1}^{N}\int_0^{\varphi_i(v_i)} b_i(\lambda)\varphi'_i(\lambda)d\lambda. \tag{2.237}$$

2. Brain-state-in-a Box 网(盒中脑网). 这一网络的运行模式为

$$x_i(x+1) = \mathrm{sat}\left[x_i(t) + \beta\sum_{j=1}^{N} w_{ij}x_j(t)\right], \tag{2.238}$$

其中 $w_{ij} = w_{ji}$，sat 为一饱和函数，其通常定义为

$$\mathrm{sat}(x) = \begin{cases} c, & x \geqslant c, \\ x, & -c < x < c, \\ -c, & x \leqslant -c, \end{cases} \tag{2.239}$$

其中 c 为一常数，相应的能量函数为

$$E(x) = -\frac{\beta}{2}\sum_{i=1}^{N}\sum_{j=1}^{N} w_{ij}x_ix_j. \tag{2.240}$$

3. 回归后向传播网

$$\frac{dx_i}{dt} = -x_i(t) + \varphi\left[\sum_{j=1}^{N} w_{ij}x_j(t)\right] + k_i, \tag{2.241}$$

其中 $w_{ij} = w_{ji}$，φ 为一 S 形函数且能量函数为

$$E(x) = -\frac{1}{2}\sum_{i=1}^{N}\sum_{j=1}^{N}W_{ij}v_i(v_j + 2k_j) + \sum_{i=1}^{N}\int_0^{x_i}\varphi^{-1}(\lambda)\mathrm{d}\lambda. \quad (2.242)$$

在所有这些网中,我们有一个由网络所有神经元的可能状态组成的状态空间,一个状态变化方程和一个能量函数网络.能量函数的极小值点对应网络状态方程的稳定态.由于能量函数的存在,利用微分方程的 Liapunov 定理,我们总有结论:状态方程的解趋于方程的稳定态,因此,只要我们的解位于稳定态,网络的自发运行就会提供一种自然的求解算法.

当我们用回归网求解联想记忆问题时,每一需记忆的模式存贮在网络的稳定态,而所有记忆均表示在权重上.直接从模式的权重表示中,我们看不出模式的丝毫特征,但当网络运行时,存贮模式会清晰再现.这样一种既无地址,又无明显特征的记忆存贮称为分布式存贮,这一存贮方式被认为是神经元网络的最主要特征之一.这类网络的另一特点是其具有较强的容错能力:只要一个初始向量落入某一模式所对应的稳定态的吸引域,则当我们将初始向量送入网络后,网络会自动找到这一模式.由于初始向量通常是一有错误或不完全的记忆表示,故网络记忆具有较强的容错性.

理论上讲,任一微分方程都可看作是一神经网络的状态运行方程,但这一网络功能的强大与否在于我们能否将一些有用问题的解有效地嵌入网络的平衡态或稳定态,因此这方面有意义的工作之一便是利用动态的微分方程构造求解静态的应用问题.

§2.7 评注与展望

本章我们介绍了人工神经网络的生物背景,主要功能和一些典型网络.理论上讲,任何神经网络的设计可分为三个部分:网络结构设计,目标函数构造和参数优化学习算法设计.以下我们简要讨论这几部分与数学的关系并指出一些与数学有关的进一步发展方向.

2.7.1 神经网络模型是传统模型的推广

网络结构的设计依赖所需求解的问题的维数和结构.例如,在传统数据拟合或函数逼近方法中,我们利用多项式

$$f(x, w) = \sum_{i=0}^{n} w_i x^i, \qquad w = (w_0, \cdots, w_n)$$

或三角函数

$$f(x, w) = \sum_{i=0}^{n} w_i^{(1)}\sin ix + w_i^{(2)}\cos ix,$$

$$w = (w_1^{(1)}, \cdots, w_n^{(1)}, w_1^{(2)}, \cdots, w_n^{(2)})$$

对数据进行拟合.这些方法均可写为

$$f(x, w) = \sum_i w_i \varphi_i(x)$$

的形式,其中 $\varphi_i(x)$未含任何未知参数,因此,这些方法均可看成激活函数为线性函数的单层前向网.这些方法的一个致命缺陷便是"维数灾难"问题,就多项式而言,三次 d 维多项式为

$$y = w_0 + \sum_{i_1=1}^{d} w_{i_1}^{(1)} x_1 + \sum_{i_1=1}^{d} \sum_{i_2=1}^{d} w_{i_1}^{(2)} w_{i_2}^{(2)} x_{i_1} x_{i_2} + \sum_{i_1=1}^{d} \sum_{i_2=1}^{d} \sum_{i_3=1}^{d} w_{i_1}^{(3)} w_{i_2}^{(3)} w_{i_3}^{(3)} x_{i_1} x_{i_2} x_{i_3}$$

而 M 次 d 维多项式的系数可达 d^M 个,因此,当 M 和 d 变大时,问题的规模很快就会超出我们的控制.三角函数、小波函数均存在同样的问题.

在多层前向网中,上式中的 $\varphi_i(x)$允许包含可调参数,此时一般的数学表达式可写为

$$f(x, w) = \bar{\varphi}\left(\sum w_i^{(2)} \varphi_i(x, w_i^{(1)}) \right).$$

两层可调节参数 $w^{(1)}$和 $w^{(2)}$使得参数的个数由产生数据的系统的复杂性决定,而不由维数或其他因素(如训练数据规模)来确定.从这一意义上讲,人工神经网络是传统逼近模型的推广.

2.7.2 目标函数的设计和学习算法

神经网络模型形式地给出了函数的输入输出关系 $y = f(x, w)$,对于给定的数据集

$$D = \{(x^{(1)}, y^{(1)}), (x^{(1)}, y^{(2)}), \cdots, (x^{(n)}, y^n)\},$$

我们的目的便是寻找 w 使得 $y = f(x, w)$尽可能地逼近输入输出数据所隐含表示的函数关系.模型表示的好坏在许多实际情况中有着自然的度量,它们通常由单一目标如误差、代价或时间来衡量.在此情况下,我们有一个目标函数 $E(w)$,学习的目的便是寻找 w 使得 $E(w)$达到最小.目标函数一般可写为如下形式

$$E(w) = \int V(y, f(x, w)) P(x, y) \mathrm{d}x \mathrm{d}y,$$

其中 $E(w)$称为期望风险函数,V 称为损失函数且通常取为

$$V(y, f(x, w)) = (y - f(x, w))^2.$$

$P(x, y)$为产生数据 D 的联合分布函数.由于 $P(x, y)$未知,故 E 通常由下述的经验风险函数替代,

$$E_{emp}(w) = \frac{1}{n}\sum_{i=1}^{n} V(y_i, f(x_i, w)).$$

因此,对于任何损失函数,我们必须解决下述两个问题:

1. 选择合适的 V 和 f 使得极小化上式所得的解与极小化期望风险函数 $E(w)$ 所得的解相吻合.

2. 优化目标函数 $E_{emp}(w)$.

如果我们不能解决第一个问题,则无论优化算法如何好,我们都不能达到我们的目的,因为两个问题的解根本就不是同一个;反之,如果不能很好地解决第二个问题,则对于第一个问题也难以给予公正的评价,因为我们根本不知道每一问题的解的真正位置所在.

根据 Occam 原理,我们认为 $f(x, w)$ 愈简单,则两个问题的解拟合愈好,而简单性可由下述指标之一度量

- f 的光滑性
- 参数的范围
- 参数个数的多少(隐节点个数的多少)
- V 的 VC 维数

如果记函数复杂度为 k,则统计学习理论可推出在绝大部分情况下,有

$$E(w) \leqslant E_{emp}(w) + G(k),$$

其中 G 为 k 的单增函数,于是解决第一个问题的算法分为两类:

1. 在给定经验风险的情况下,极小化模型复杂度 k,如支撑向量机方法.

2. 在给定模型复杂度下,求经验误差最小,如神经网络方法.

解决第二类问题的传统极小化方法存在易于陷于局部极值的缺点,改进这一缺陷的总体优化方法有模拟退火算法、遗传算法等,解决这类问题的算法在人工智能领域通常称为学习算法.

2.7.3 神经网络的进一步发展

神经网络的进一步发展应包括隐单元个数的确定,高效学习算法的设计,以及将生物神经网络更多的实验结果和理论模型纳入人工神经网络模型的设计.这些方向的研究有望进一步拓广神经网络方法的应用领域.

同时我们也应看到,由于原本希望的神经网络算法的主要优点如巨量并行性和分布式存贮并未在硬件实现和工程应用中取得突破性成果,公众对于人工神经网络的过高希望和过大投资的落空导致了对这一领域的一些偏见.但无论如何,这一学科为数据处理方法的设计和分析提供了新的活力和技术,加深了我们对传统方法的理解并同时对其提出了新的挑战,促使传统方法进一步完善.因此,一种合理的看法似乎应为:神经网络方法是一种与传统方法

相互交触的计算技术.关于神经网络更为细致的讨论参见文献[124],[41],[9],[56].

第三章　仿生行为算法:Fuzzy 逻辑与 Fuzzy 推理

Fuzzy 逻辑是一门崭新的数学分支.它始于 1965 年美国自动控制论专家 L.A.Zadeh 的开创性论文"Fuzzy 集合".它的产生不仅拓广了经典数学的基础,而且使计算机科学和自动化技术向模拟人类思维方式和行为能力等自然机理方向的发展有了重大突破.

本章主要介绍基于 Fuzzy 集运算的 Fuzzy 推理算法,它是迅速发展中的 Fuzzy 逻辑控制技术的数学核心.

§3.1　Fuzzy 逻辑的生物基础

人的各种感觉器官都是 Fuzzy 信息传感器,它们能够感觉和传递来自客观世界的各种 Fuzzy 信息.人的大脑拥有强大的 Fuzzy 信息处理功能,它能接受和存储大量的 Fuzzy 信息,并对各种 Fuzzy 信息进行加工.人脑随时要依据 Fuzzy 信息对事物进行识别、分类、判断、推理、并做出决策,以指挥和控制人自身的行为并影响周围的客观世界.人脑进行 Fuzzy 思维、Fuzzy 推理与 Fuzzy 决策的灵活、简便与高效率是计算机所不能及的.Fuzzy 逻辑是对人脑 Fuzzy 思维功能的一种数学模拟,它是计算机科学和机器智能向 Fuzzy 环境和人的智能方向发展的一种卓有成效的科学探索.

3.1.1　人脑具有 Fuzzy 思维功能

为了识别事物,人们总依据一定的标准对它们进行分类.分类,是人类认识世界的基本能力.

在现实世界中,有许多事物可以依据精确的标准把它们区分为界限分明的类别,一个事物要么属于某一类,要么不属于这一类,非此即彼,明确清晰."地球是行星","石头不是食物","林黛玉是女子",都是关于事物类属的明确断言.我们把事物有明确类属这种特性称为清晰性,把这类事物称为清晰事物.

但是另有一些事物,我们无法找到精确的分类标准,从而对一事物是否属于某一类很难做出明确肯定的断言.高山、大河、远亲、近邻等就是这种事物类.由于这种事物从它属于这一类到不属于这一类是逐步过渡而非突然改变的,所以不同的类别之间不存在截然分明的界限.比如"年轻人"、"中年人"与"老年人","较高的温度"、"适中的温度"与"较低的温度","良好运行状态"、

"可运行状态"与"危险状态"等就不存在截然分明的界限.我们把事物类属的这种不清晰性称为模糊性(Fuzziness),把这类事物称为Fuzzy事物.

Zadeh在其开创性论文"Fuzzy集合"中正是这样描述模糊性的.他考察了"比1大得多的实数类"、"高个子男人类"、"漂亮女子类"等例子,指出经典逻辑与传统数学不能处理Fuzzy事物,其原因是人们尚没有找到能恰当地描写、刻画和表达Fuzzy事物及其模糊性的数学方法.Zadeh创造了"隶属度"这一革命性的观念和方法,提出用Fuzzy集合及其运算来描写、刻画和表达Fuzzy事物及其模糊性,从而将对Fuzzy事物的处理纳入了逻辑的轨道和数学的框架.

计算机是在精确科学的沃土中培育起来的一朵奇葩.计算机解决问题的高速度和高精度,是人脑望尘莫及的.有了计算机,精确方法的可行性大大提高了.但是也正是在使用计算机的实践中,人们认识到人脑具有远胜于计算机的许多能力.人脑能接受和处理Fuzzy信息,能依据少量的Fuzzy信息对事物做出足够准确的识别、判断和推理,能灵活机动地解决复杂的模糊性问题.凭借这种能力,司机可以驱车安全穿越闹市,医生可以依据病人的症状所提供的Fuzzy信息进行准确诊断,画家不用精确的测量计算可以画出栩栩如生的风景和人物,儿童可以辨认潦草的字迹,听懂不完整的言语,甚至婴儿也可以迅速地从人群中识别出自己的母亲.而这一切都是以精确制胜的计算机所望尘莫及的.严格的精确性,使计算机无法接受和处理Fuzzy信息,无法进行Fuzzy推理,不能在Fuzzy环境中正确地识别事物,难以快速有效地做出Fuzzy决策.相反,人脑所拥有的强大的Fuzzy信息处理能力,却显示出其特有的简捷、灵活、快速和有效性.通过人脑与电脑的比较,帮助人们认识到计算机的不足之处,从而积极探索人脑Fuzzy思维的机制,制订设计新型计算机的原理,使计算机能模仿人脑接受和处理Fuzzy信息,从而提高计算机的"活性"和智能水平.

精确方法的逻辑基础是传统的二值逻辑,它要求对每个命题做出要么真、要么假的非此即彼的明确的判断.这是适合于处理清晰概念和命题的逻辑模式.当把经典的二值逻辑用于处理Fuzzy概念和Fuzzy命题时,将会在理论上导致逻辑悖论.

最著名的逻辑悖论是"秃头悖论".秃头显然是个Fuzzy概念,日常生活中,某人是否秃头,不论成人还是儿童都能轻而易举地作出恰当的判断,因为人脑拥有接受和处理Fuzzy信息的能力.

若用精确方法来处理秃头问题会发生什么情况呢?

首先我们都同意以下两条公设.

公设 (1)存在秃头的人和非秃头的人.

(2)若有 n 根头发的人秃,则有 $n+1$ 根头发的人亦秃.

由此便会导致

秃头悖论 所有人都秃.

证明 对 n 用数学归纳法.

(i)$n=0$ 的人显然是秃头.

(ii)假定 $n=k$ 的人是秃头.

(iii)由公设(2),$n=k+1$ 的人也是秃头.

于是由数学归纳法原理知,对于任意的 $n\geqslant 0$,有 n 根头发的人都是秃头.从而所有人都秃.

秃头悖论出现的原因在于,数学归纳法是以通常集合论为基础的推理方法,而秃头是个 Fuzzy 概念,这里把基于通常集合论的推理方法强行用于 Fuzzy 概念,换句话说,是把一个经典的二值逻辑的推理,运用到二值逻辑所不能施行的判断上去,从而导致悖论的产生.

类似的悖论是很多的.

朋友悖论 设命题 A="刚刚结识的朋友是新朋友",命题 B="新朋友过一秒种还是新朋友",从常识看显然都是真命题.但若以 A 和 B 为前提,反复运用精确推理规则进行推理,将会得出命题 C="新朋友过 100 年还是新朋友"这个显然为假的命题.

年龄悖论 由显然为真的两个命题 A="20 岁的人是年轻人"和 B="比年轻人早生一天的人还是年轻人"出发,可以推出显然为假的命题 C="100 岁老翁也是年轻人".

身高悖论 以真命题 A="身高 2 米者为大个子"和 B="比大个子矮 1 毫米者仍是大个子"为前提,可以推出显然为假的命题 C="侏儒也是大个子".

饥饱悖论 从真命题 A="3 日未食者是饥饿者"和 B="比饥饿者多食一粒米者仍是饥饿者"出发,可以推出假命题 C="一个饥饿者日食 3 斤米仍是饥饿者".

量与质是统一的,量的变化包含着质的变化.从头发的根数来区分秃与不秃,其绝对的界限是没有的.但根数的加 1 与减 1 又都必须计较,在这微小的量变之中已经蕴涵着质的差别,而这种差别只简单地用"是"与"非"这两个字是绝对不能刻画出来的.

在逻辑上,把"是"与"非"或"真"与"假"都看作一种值,叫"逻辑值".为了形象,也为了定量化,通常把"是"和"真"记作 1,1=100%,表示一个命题百分之百地可靠,其真确程度是 1;把"非"和"假"记作 0,0=1-100%,表示一个命题百分之百地不可靠,其真确程度为 0.可见,逻辑值是对命题真确程度的一种度量.

二值逻辑是把真与假,是与非绝对化,只允许有1和0两个值."秃头悖论"的谜底告诉我们,对于Fuzzy概念,仅用1和0两个逻辑值是不够的,必须在1与0之间采用其他中间过渡的逻辑值来表示不同的真确程度.比如,逻辑值可以为0.7,表示一个命题三七开,七分真三分假,其真确程度是0.7,逻辑值也可以取0.5,表示一个命题对半开,半真半假,其真确程度是0.5.

由此把经典二值逻辑的逻辑值取值域从仅有两个元素的集合{1,0},即{真,假}或{是,非}扩展到[0,1]整个闭区间,使对命题的真确程度拥有比经典逻辑远为精细的刻画.比如,可以区分出0.998真确度的命题和0.997真确度的命题.而如此的精细程度是经典逻辑所不能及的.这就是Fuzzy逻辑的基本思想.

集合可以表现概念,集合可刻画分类.具有明确外延的概念叫清晰概念.设P是一个清晰概念,A是P的外延,即A是一个集合.a是一个对象,即元素.如果a符合P,即$a\in A$,记为1,否则,a不符合P,即$a\notin A$,记为0.数字1与0可以理解为元素对集合的隶属程度.1=100%,0=1−100%,分别表示元素对集合百分之百地属于或百分之百地不属于,没有中间过渡的余地.

没有明确外延的概念,叫Fuzzy概念.Fuzzy概念不能用经典集合论来刻画.要想表现Fuzzy概念,就需要把元素对集合隶属程度的取值范围从仅有两个值的集合{0,1}扩展为[0,1]整个闭区间(或者更一般地,扩展为某种格L).从而使元素对集合的隶属程度拥有比经典集合远为精细的刻画.比如,可以区分出元素a对某集合A的隶属程度为0.998,元素b对集A的隶属程度为0.997,两者的差异仅为0.001.而如此精细的程度也是经典集合所不能及的.这就是Fuzzy集合论的基本思想.

秃头悖论是古希腊学者早已发现的逻辑矛盾.在那个时代,这种悖论不会对科学技术的发展产生什么影响,尽可以留给逻辑学家们去争论.但是在现代社会中,科学研究和生产活动的深度和广度都极大地发展了,大量的模糊性问题摆在人们面前要求作出处理,从理论上克服这些悖论,从技术上提出解决模糊性问题的方案,这都是不能再回避的了.

但是在传统逻辑的框架内不能解决秃头悖论,用通常集合论无法描写Fuzzy事物,用经典数学方法难以处理模糊性问题.于是,冲破传统逻辑的框架和通常集合论的束缚,模拟人脑的Fuzzy思维功能,建立适合于描写Fuzzy概念和处理模糊性问题的Fuzzy集合论和Fuzzy逻辑,就变得刻不容缓了.于是,Fuzzy集合论和Fuzzy逻辑就这样地出现了.

3.1.2 Fuzzy思维的神经元机制

神经元是神经系统的基本结构和功能单位,其胞体直径约为20～100微

米.它通过细胞突起的树突、轴突以及与其他神经元接触形成的突触来传递信息.其他各种细胞只能接受信息,只有神经元才能传递并储存信息.

神经元按传递信息的不同方向和功能,可以分为三类:(1)直接与感受器相联系,并把信息从感受器传递至中枢的神经元,称为感觉神经元或传入神经元.(2)直接与效应器官相联系,并把神经冲动从中枢传递到外围的神经元,称为运动神经元或传出神经元.(3)介于上述两者之间的神经元,称为中间神经元或联合神经元,其主要功能是传导中枢神经系统内部各区域间的神经兴奋.脑的高级机能主要是通过中间神经元的活动而实现的.人脑中约有 100～160 亿个神经元,其中大量的是中间神经元.

各种神经元传递信息是以电位变化和释放化学递质的方式进行的.

细胞生物学家认为,在静态细胞膜内外液体中离子分布的浓度不平衡,存在电位差,即静态膜电位.膜外主要是 Na^+,膜内主要是 K^+,二者既独立运转又密切联系.由于 Na^+-K^+ 泵的调节作用,离子在膜内外的不均匀分布(相差 14～30 倍)得以维持,从而形成膜电位.

当神经元受到刺激时,膜电位急剧变化,产生神经冲动,神经冲动再通过树突和突触传递给胞体或其他神经元,从而引起活动.经典的理论认为,它遵从英国生物学家谢灵顿(Shelinton)提出的"全"或"无"(all or none)定律.

"全"或"无"定律是谢灵顿根据从弱刺激到强刺激传入神经元时,反射活动所表现出的不同张力数值进行分析后得出的.此后,谢灵顿学派的亚德里安(Adrian)在总结前人成果的基础上,探讨了单突触反射弧兴奋传递的电生理机制和理化机制与微观结构之间的关系,明确提出了神经系统的"全"或"无"定律,认为一切神经反射活动都是遵从这一定律的.

"全"或"无"定律,就是把一个神经元所接受的外界刺激量达到或超过该神经元作出应答所必须的阈值时,它就给出应答,否则它就完全不作出应答.这种应答的信号强弱是一样的.

但是,这种"全"或"无"定律只适用于神经元纤维中的冲动传导,而神经系统的整体活动信号有赖于突触来传递,因此不能把局部的反应与全局(整体)反应相混淆.

突触,即神经元之间通过轴突、树突和胞体相连接的突起区域,它是信息的加工转运站,由前膜、后膜及其间隙组成.每个运动神经元与周围几千个神经元相连接形成突触.估计人脑约有 10^{15} 个突触.

当神经冲动传递到突触时,允许 Na^+ 离子进入前膜,而 Na^+ 又刺激膜内的囊泡并使之破裂,把泡内的神经递质释放出来,扩散于突触间隙,并作用于后膜上的蛋白质受体,从而使后膜对某些离子的渗透性发生改变,并使突触后神经元随之而产生兴奋或抑制的效应.由于神经化学递质在传递神经冲动中

起中介作用,故又称神经介质.

通过化学递质传递神经冲动,是突触传递信息的基本方式,这些传递的代谢水平直接影响到突触传递的效能而参与行为的调节.人脑中每秒时间内会发生大约 10 万种不同的化学反应,形成意识、思想、感情及行动.这主要是神经元内部的变化调控着突触内递质所产生的变化.丁润生等在其《现代思维科学》一书中指出:现在思维科学应该看到,"释放神经递质是实现突触传递机能的中心环节,认清神经元的生物化学机制,对于揭示人们思维活动的生理机制是有重要意义的."

维纳(Wiener)正是从神经递质释放的角度揭示了人脑 Fuzzy 思维产生的神经生理机制的.他说:在神经系统中,仍然有一些不属于我们已经指出的那类"全"或"无"的现象.突触机制中的刺激波不是恒定的,在它的规定中,化学因素也起着重要作用,这种化学因素很可能具有"多"或"少"的性质,而非简单的"全"或"无"的性质."多"或"少"涉及到程度问题,而这正是 Fuzzy 思维活动产生和进行的基本条件.

3.1.3 Fuzzy 思维的神经回路机制

一般认为,抽象和概括是形成概念,进行思维活动的前提和基础.那么脑的高级神经活动是如何实现抽象和概括功能的呢?目前尚不能得出明确的答案,但是一些实验结果表明,这是与神经活动的层次有密切关系的.脑内神经元的分布和彼此之间的联系虽然十分复杂,但并非杂乱无章,而是有着严格的次序,高度的特异性和层次组织的.进入脑内的各种信息通过不同层次的神经回路的活动,进行着不同水平的分析、综合、抽象和概括.

航天医学工程研究所刘觐龙曾以哺乳动物的视觉机能为例说明不同层次神经回路各具不同的机制和功能.他认为,神觉传入通路主要由视网膜、丘脑的外侧膝状体和大脑皮层的枕叶视区三部分组成.光线入眼后,大致依以下顺序向中枢传递:视觉感受器(视锥细胞和视杆细胞)→双极细胞→神经节细胞(以上是在视网膜内)→外侧膝状体细胞(在丘脑)→圆对称型细胞→单纯型细胞→复杂型细胞→超复杂型细胞→……(以上在大脑皮层).视觉信息在上述回路中进行着逐级处理.

首先,视网膜中的感受器将光电磁波转化为细胞上的电位变化,神经节细胞受到光刺激时,感受器细胞膜内外的电位差增大(超极化).光线越强,电位差越大.光线撤走后,膜电位又回复到原来水平.视觉到了双极细胞就开始了初步分析:光线照射到感受野的中心部位时出现超极化;而照射到感受野的周边部位时,则出现去极化,即膜内外电位差的减小.这就是说,随着光线照射部位的不同而出现不同的反应.光线到了神经节细胞开始出现动作电位(即神经

冲动).有些神经节细胞在光线照射开始时发生神经冲动(给光反应);有些在照射结束时发生神经冲动(撤光反应);有些在给光和撤光时都发生神经冲动.由此可见在视网膜水平上,神经回路已经开始对视觉信息进行识辨、分类和选择、分析和综合了.

其次,由两眼传入的信息转换为神经冲动后,又经左右两个外侧膝状体初步的集中,然后再传入大脑皮层进一步集中.左右两眼传入的信息可以汇聚到同一神经细胞上,并进行着进一步的分析与综合.例如,视觉皮层中的单纯型细胞仅对具有特定方位的线段发生反应.有些单纯型细胞只是在呈垂直方向走行的线段映入视野时才发出较多的神经冲动;有的只是当映入的线段呈水平走行时神经冲动才增多;而有的则只是当映入的线段呈某种角度时才放电增多,等等.单纯型细胞已经开始出现"方位"的特异性,已经对"方位"的特异性进行初步的分析和综合.一定方位的线段必须映入视野的一定部位时,才能使这种神经细胞出现反应."方位"信息的识辨、选择已经可以在视觉皮层得到初步实现.

再次,光线到了复杂型细胞时并不要求线段的影像映入视觉的特定部位,只要线段呈一定方向就可以使其放电增多.这些复杂型细胞不受视野的限制,只记录"方位"属性,而舍弃其他属性,可以把这些看作抽象概括"方位"这一概念的过程表现,也可以看作 Fuzzy 识别"方位"信息的过程表现.

此外,在大脑皮层的视觉联合区中,有一种被称为超复杂型的细胞,只有当视觉刺激影像出"角"时,细胞放电才增多,而不受角的大小、朝向、构成角度的线条的长短、粗细以及背景光的阴暗、对比度的强弱等影响.还有些超复杂型细胞分别对"方"、"三角"、"圆"等图像发出反应,似乎这些神经回路已具有形成某些几何概念的功能等.这些超复杂型细胞的存在,足以展示 Fuzzy 思维神经回路机制产生的现实可能性.

刘觐龙在分析他的实验结果时指出:"当然,我们并不能仅仅根据这些动物实验结果,就认为'角'、'方'、'三角'、'方位'等概念就是在初级视觉皮层和视觉联合皮层中形成的,何况我们对实现这种抽象和概括的具体神经过程还很不清楚.不过,这些实验资料表明,神经元在神经回路中的活动是有层次性的.层次越高,抽象和概括的程度就越高.通过不同层次的活动,进行着不同水平的分析、综合、抽象、概括,从而构成人们对客观事物的认识从感性到理性这个过程的神经生理基础.

应当看到,刘觐龙在对实验的分析中强调的是神经回路的层次性及在此基础上思维认识活动进行的一般生理机制.如果从 Fuzzy 思维活动发生和实现的过程来看,我们会发现,哺乳动物的视觉机能活动实质上可以看作一个视觉信息 Fuzzy 处理过程,理由是,(1)视觉感受器接受光刺激后产生的冲动是

有程度上的差别的.(2)双极细胞对视觉信息的初步分析呈现一个连续反应带,该反应带有核,有过渡,有边缘.光线照射到感受野中心部位时出现超极化,照射到感受野周边部位时出现去极化,照射到中心与周边之间的部位时则出现过渡状态.换言之,双极细胞对视觉信息的反应构成了一个 Fuzzy 集.(3)复杂型细胞、超复杂型细胞对视觉信息的反应更带有 Fuzzy 识辨的特征.它们对信息识别所需要的信息量比双极细胞、神经节细胞更弱,但其可靠性不比它们差,甚至更强.刘觐龙提供的实验和分析从某种意义上来说,是对 Fuzzy 思维过程神经回路机制的初步阐述.可以认为,Fuzzy 思维与精确思维并不是神经回路的不同生理过程,而是同一过程的两种不同功能的体现.Fuzzy 思维过程与精确思维过程是互渗互补、相辅相成的.

3.1.4 Fuzzy 思维的大脑生理机制

脑科学研究表明,人脑包括延脑、脑桥、中脑、间脑、小脑和大脑 6 个部分.通常把延脑、脑桥和中脑合称脑干.在脑干中,网状结构占很大的比例.网状结构是脑干中央部分的神经结构,由灰质和白质相混而成,内有许多大小不同,形状各异的细胞小集团,其中神经纤维交错成网,称为网状结构.网状结构依靠其上行到大脑皮层的纤维这一上行系统,和其下行到脊髓前角的纤维这一下行系统,与中枢神经系统的各个部分发生双向联系,所以影响范围很广,功能也相当复杂.

从脑干上行到大脑皮层的传入纤维有两类:一类是特异性传入系统,另一类是非特异性传入系统,它们的作用是不同的.每种感受器都有它的特殊传入通道,通过传导感受器发放神经冲动,并投射到大脑皮层的特定区域中去.这一传入系统称为特异性传入系统,其功能是引起特定的感觉.非特异性传入系统的神经束经过脑干时,都发出侧枝,与脑干网状结构内的神经元发生突触联系.然后经丘脑内侧部弥散地投射到大脑皮层的广泛区域,不产生特定的感觉,故称非特异性传入系统.非特异性传入系统的作用是维持大脑皮层的兴奋,保持机体的觉醒状态.

网状结构在大脑中占有特别重要的地位.来自身体各部分的感觉信号在进入皮层前,有分枝通过网状结构.网状结构受到这些刺激,就向皮层传递觉醒信号.皮层觉醒了才能判断接受的感觉信号,进入意识状态.特别值得注意的是,这种网状结构对特殊刺激物的感受通过学习可以获得选择性.例如,一位母亲可以被她的婴儿最轻微的哭声唤醒;城市居民可以在交通吵闹的噪声中平静地睡眠.这种对特殊刺激物的感受的选择性常常是人脑思维活性得以发挥的基础.有了这个基础,我们就可以理解和探讨人类思维何以能从简明信息中发现更多的信息内容和意义.如人能从简单的特征描述中很快找到所描

述的对象，比如高个子、大胡子，比如大眼睛、长辫子；而机器系统则不能.因此可以认为，网状结构中非特异性系统的存在可能是Fuzzy思维能力得以产生和发展(通过学习)的基本的生理学基础.实验表明，刺激除嗅觉以外的任何感受器，都可以使网状结构的某些神经元得到冲动发放，这些冲动发放可以引起机体的觉醒反应.如果破坏网状结构，机体则长期处于昏睡状态.实验还表明，网状结构中的非特异性系统，即网状激活系统，还能增加其觉醒水平，监测那些叩击我们感觉的无数刺激，接受我们所需要的，而拒绝无关的；同时调节和改进我们的肌肉活动和身体运动，而且以一种重要方式参与最高级的心理过程，包括集中注意力、内省和所有的思维推理形式，它对脑组织进行信息整合起着关键作用.积极地认识并深刻理解大脑神经网状结构中特异性系统和非特异性系统的各种机能，无疑为我们模拟这些结构、系统和机能，深入开展Fuzzy逻辑、Fuzzy推理、Fuzzy决策、Fuzzy控制等Fuzzy信息处理方法的研究挖掘并提供了复杂、生动而精美的蓝本.

现代脑科学还认为，大脑两半球的机能是不对称的，二者之间存在着明显的分工.人脑左半球(左脑)主要地具有语言、分析、数理、抽象思维的功能，其操作是串行的、继时的，是收敛性的因果式的思考程式，循序渐进，合乎逻辑.右半球(右脑)主要地拥有非语言性的、综合的、直观的、音乐的、以及几何图形识别等形象思维功能，其操作是并行的、空间式的，属发散性的非因果式的思考程式，对空间定位、艺术创造、身体印象、面孔辨认等拥有优势.一般来说，语言的高级思维过程主要地由左脑控制，非语言刺激的高级思维过程主要地由右脑控制.美国神经心理学家莱维的研究表明："右半球综合空间，左半球分析时间；右半球注意视觉的相似而排斥概念的相似，左半球则注重概念上的相似而忽视视觉的相似；右半球能知觉形状，左半球能知觉细节；右半球将感觉译成表象，而左半球则把感觉译为语言描述.右半球缺乏语言分析器，而左半球则缺乏完形综合器."这样的认识几乎使我们可以概括地说，人类的右脑是几何的，左脑是代数的.

大脑两半球虽有机能的分工，但是事实证明，两半球的相互联系、相互协同和相互制约才是最正常的智能的可靠保证.在大脑两半球之间，有一个大约由1.75亿根神经纤维组成的结构，叫胼胝体.胼胝体在联系和综合两半球的功能方面起着关键的作用.它每秒种可在两半球之间往返运输140亿个神经冲动，它使两半球的信息处理相互沟通并形成一个整体活动.

据1970年代的研究，胼胝体在人的个体发育中，如果由于各种原因而存有缺陷的话，它的传导、沟通和协同功能就会产生障碍，甚至是严重的障碍.比如使两半球之间的信息传递不畅，或者在传递过程中将信息歪曲，从而破坏两半球机能的协同、完整和统一.特别是对"裂脑人"的研究，更能说明胼胝体对

人脑智力的正常发挥起着重要的作用.如果切断胼胝体,病人就会在智能方面出现自相矛盾的行为:一只手去拥抱孩子,而另一只手却把他推开.

胼胝体的发现,表明大脑两半球是处于"共生"的整体之中的.在正常状态下,它们是紧密结合协同工作的,而不是一个开动着,另一个锁闭着.不论哪侧半球被切除,人的感觉机能、运动机能以及语言机能虽然能大部分保存,但是其心理活动通常只能维持在很低的水平上,并且缺乏驱动力和主动性.即使切除的不是整个半球,而只是损伤了半球的某一重要部位,病人也难以完成复杂的心理操作和思维活动.从整体上看,人脑复杂的心理活动是以两半球的协同工作为前提的,至于极其复杂的高级思维活动更是如此.任何单个半球的功能都不足以保证人脑思维活动的正常进行.

美国康奈尔大学的卡尔·萨根(Carl Sagen)教授认为,像胼胝体这样复杂而重要的"电缆"系统的存在,意味着两半球的交互作用不仅是人维持生命状态所必须的,而且创造性思维活动更是依赖于这种两半球功能的结合.如果没有右脑的直觉对新模式的猜想和推测,即使一个决定性的思想也难以得出结果.另一方面,如果没有经过左半球的详尽分析,就难以判断右半球所猜测的模式是正确的还是错误的.萨根指出:"在骤变的环境中要解决复杂问题就需要两半球的共同活动,通过胼胝体沟通大脑两半球,是通向未来的惟一途径."他还说:"代数方程是大脑左半球的结构原型,而几何曲线则是大脑右半球特有的产物.在一定意义上,解析几何就是数学上的胼胝体."他指出,只有通过大脑左右两半球的协同与合作,才有可能实现人类的科学和艺术方面的创造活动.

如果我们把右脑的思维活动基本上看作是Fuzzy思维活动,而把左脑的思维活动基本上看作是精确思维活动,两种思维活动通过胼胝体的功能而相互渗透、相辅相成,融为一体,那么也许能更好地理解人类思维的两重性,即精确思维和Fuzzy思维及其相互关系和作用,从而也可以在此基础上理解Fuzzy思维发生和进行的大脑生理机制.

§3.2 Fuzzy集合及其运算

L.A.Zadeh创造了"隶属度"这一革命性的观念和方法,并用Fuzzy集合成功地描写、刻画和表达Fuzzy概念,从而把对Fuzzy事物的研究纳入逻辑的轨道和数学的框架.

本节介绍Fuzzy集合及其运算,λ截集与分解定理,通常映射的Fuzzy扩张,以及贴近度,择近原则和最大隶属原则等.它们是Fuzzy集合论的基本内容.

3.2.1 Fuzzy 集合及其表示

人脑只所以拥有计算机所不能及的强大的 Fuzzy 信息处理功能，首先在于人能够基于各种感觉器官所接受的 Fuzzy 信息，熟练灵活而有效地使用 Fuzzy 语言，描述和表达 Fuzzy 事物或 Fuzzy 概念，然后基于 Fuzzy 语言所表达的 Fuzzy 概念，展开一环套一环的 Fuzzy 思维.

那么人究竟是怎样用 Fuzzy 语言表达 Fuzzy 概念的？我们又应当如何用数学的方法来模拟人的这种功能呢？

现实生活中，当人们说“这个班高个子较少”，“那个公司年轻人居多”，“这边走来了几位漂亮姑娘”，“那树上有一些苹果差不多熟了”，“若能见度较低，就把车子开慢一些”，“若室温偏高，就把加热器电压稍许调低”，“ε 是任意小的正实数”，“N 是充分大的正整数”，“方圆几十里”，“在不远的将来”时，受话者一般地都能心领神会，而无须多加解释.

但是若要用传统的数学和经典集合论来表达诸如“高个子”，“年轻人”，“偏高的温度”，“稍低的电压”，“漂亮姑娘”等 Fuzzy 概念时，就会产生麻烦.这是因为首先必须为这些 Fuzzy 概念，比如“高个子”，制定一个标准.如果我们说 1.80 米及其以上者为高个子，那么 1.79 米和 1.78 米高的人就相当冤枉.但是如果约定 1.80 米及其以上者为高个子，且比高个子低 1 厘米的人也为高个子，那么又会推出所有人都是高个子的悖论.这使得经典逻辑和通常集合论陷入了两难境地.

其实人脑中的 Fuzzy 概念并不是按照经典逻辑的轨道和通常集合论的法则形成的，它们是按人脑的 Fuzzy 信息处理方式所形成的.

人脑在构建“高个子”这一 Fuzzy 概念时，并不武断地制定一个标准 1.80 米，使得表达“高个子”的集合

$$A = \{a \mid a \text{ 的身高} \geqslant 1.80 \text{ 米}\},$$

非此即彼，边界分明.人脑允许高个子集合的边界带有模糊性，人脑的思维方式承认某些人隶属于高个子集合的程度比另一些人高，某些人的隶属程度比另一些人低.如果我们说张三隶属于高个子集合 A 的程度为 0.7，李四隶属于 A 的程度为 0.8，王五为 0.9，刘二与赵大均为 1，那么就更好地符合了人脑的思维方式.

又比如“成年人”的概念，如果我们用通常集合

$$B = \{a \mid a \text{ 的年龄} \geqslant 18 \text{ 岁}\}$$

描写这一 Fuzzy 概念，是不符合人脑思维方式的.如果说 20 岁属于成年人集合的程度为 0.9，12 岁对 B 的隶属程度为 0.3，25 岁及其以上对 B 的隶属程度均为 1，10 岁及其以下对 B 的隶属程度皆为 0，那么就更好地符合了人脑通

常的 Fuzzy 思维方式.

由此归纳出 Fuzzy 集合的一般定义,以适应多种 Fuzzy 环境的应用.

定义 3.1 (Fuzzy 集) 设 U 是论域,它是一个非空通常集合.每一个映射 $A: U \to [0,1]$ 都叫做 U 的一个 Fuzzy **子集**,也说是 U 上的 Fuzzy **集**. $A(\cdot)$ 叫 Fuzzy 集 A 的**隶属函数**.对每个 $x \in U$, $A(x)$ 叫元素 x 对 Fuzzy 集 A 的**隶属度**.

对于 Fuzzy 集 A 来说,我们不再谈论"x 是否属于 A",而代之以说"x 对 A 的隶属度是 0.998, 0.997, 或 0.001."若 $A(x_1)=0.998$, $A(x_2)=0.997$,我们就说, x_1 隶属于 A 的程度比 x_2 高.

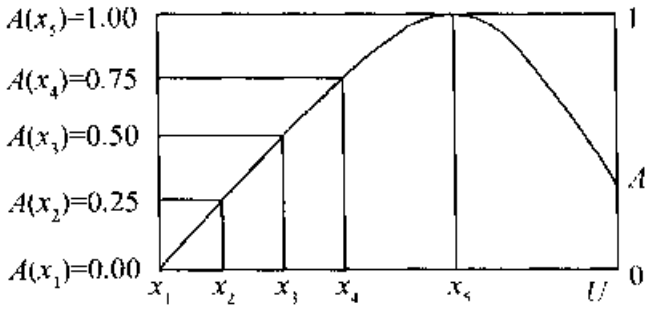


图 3.1 隶属度与 Fuzzy 集

Fuzzy 集有解析法, Zadeh 法,序偶法,向量法,表格法,矩阵法等多种表示法.

1. 解析法

用隶属函数的解析式表示 Fuzzy 集.

比如以年龄为论域,取 $U=[0,150]$. Zadeh 曾给出"年轻" Y 和"年老" O 两个 Fuzzy 集的隶属函数分别为

$$Y(x)=\begin{cases}1, & 0 \leqslant x \leqslant 25,\\ \left[1+\left(\dfrac{x-25}{5}\right)^2\right]^{-1}, & 25 < x \leqslant 150,\end{cases}$$

$$O(x)=\begin{cases}0, & 0 \leqslant x \leqslant 50,\\ \left[1+\left(\dfrac{x-50}{5}\right)^{-2}\right]^{1}, & 50 < x \leqslant 150.\end{cases}$$

当 $x=60$ 时, $Y(60)=0.02$, $O(60)=0.8$,这说明 60 岁已不很年轻,比较年老;当 $x=80$ 时, $Y(80)=0.01$, $O(80)=0.97$,这表明 80 岁比 60 岁更为年老了.

2. Zadeh 法

当 U 是有限论域时, Fuzzy 集可用 Zadeh 记号表示为

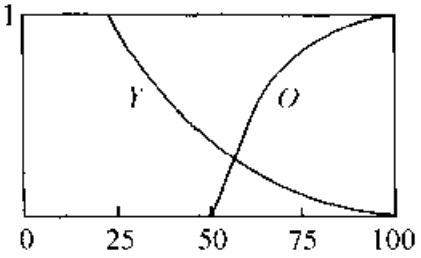


图 3.2 "年轻"和"年老"的隶属函数

$$A = \sum_{i=1}^{n} \frac{A(x_i)}{x_i} = \frac{A(x_1)}{x_1} + \frac{A(x_2)}{x_2} + \cdots + \frac{A_n(x_n)}{x_n},$$

其中 $x_i(i=1,2,\cdots,n)$是论域 U 的元素，$A(x_i)$是相应元素的隶属度. 当隶属度为 0 时，相应项可略去不写.

比如

$$A = \frac{1}{x_1} + \frac{0.75}{x_2} + \frac{0.5}{x_3} + \frac{0.25}{x_4} + \frac{0}{x_5}$$

就表示论域 $U=\{x_1,x_2,x_3,x_4,x_5\}$的一个 Fuzzy 集 A，其中 x_1,x_2,x_3,x_4,x_5 隶属于 A 的程度分别为 1,0.75,0.5,0.25,0.

也可简记为

$$A = \frac{1}{x_1} + \frac{0.75}{x_2} + \frac{0.5}{x_3} + \frac{0.25}{x_4}.$$

应当注意，Zadeh 记号不是分式求和，而仅是一种符号形式，其中分母表示论域 U 的元素名称，分子表示该元素相应的隶属度.

从有限论域推广到一般论域，Zadeh 记号可表示为

$$A = \int_U \frac{A(x)}{x},$$

式中的积分号不是通常的积分，也不是求和，而是表示论域中的各个元素与隶属度对应关系的一个总括形式.

3. 序偶法

当 $U=\{x_1,x_2,\cdots,x_n\}$是有限论域时，将各元素 x_i 及其隶属度 $A(x_i)$配成的序偶一一列出，则得 Fuzzy 集 A 的序偶法表示为

$$A = \{(x_1,A(x_1)),(x_2,A(x_2)),\cdots,(x_n,A(x_n))\}.$$

比如

$$A = \{(x_1,1),(x_2,0.75),(x_3,0.5),(x_4,0.25),(x_5,0)\}$$

表示论域 $U=\{x_1,x_2,x_3,x_4,x_5\}$的一个 Fuzzy 集 A，其中 x_1,x_2,x_3,x_4,x_5 隶属于 A 的程度分别为 1,0.75,0.5,0.25,0.

从有限论域推广到一般论域，序偶法可表示为

$$A = \{(x, A(x)) \mid x \in U\},$$

它是元素与隶属度对应关系的一个总括形式.

4. 向量法

在有限论域 $U=\{x_1, x_2, \cdots, x_n\}$ 的场合，我们简记 Fuzzy 集 A 为

$$A = (A(x_1), A(x_2), \cdots, A(x_n)).$$

比如 $A=(1, 0.75, 0.5, 0.25, 0)$ 就表示论域 $U=\{x_1, x_2, x_3, x_4, x_5\}$ 的元素 x_1, x_2, x_3, x_4, x_5 隶属于 A 的程度分别为 $1, 0.75, 0.5, 0.25, 0$.

我们称此方法为 Fuzzy 集合的向量表示法. 今后，凡取值恒为 0 和 1 的向量称 **Boole 向量**，凡取值均在[0, 1]中的向量称 **Fuzzy 向量**. 任何一个 Fuzzy 向量，均可解释为某论域上一个 Fuzzy 集. 这种观点和方法有很好的实用价值.

5. 表格法

表格法是向量法的自然推广. 在有限论域的场合，表格法可以同时表示多个 Fuzzy 集合. 表 3.1 给出了 U 的三个 Fuzzy 子集.

表 3.1　Fuzzy 集合的表格表示法

U	x_1	x_2	x_3	x_4	x_5	x_6	x_7
A	0	0	0	0.3	0.7	0.9	1
B	0.8	0.9	0.8	0.6	0.4	0.2	0
C	1	0.7	0.3	0	0.3	0.7	1

6. 矩阵法

矩阵法是表格法的矩阵表达. 比如上表可以用矩阵表达为

$$\begin{pmatrix} 0 & 0 & 0 & 0.3 & 0.7 & 0.9 & 1 \\ 0.8 & 0.9 & 0.8 & 0.6 & 0.4 & 0.2 & 0 \\ 1 & 0.7 & 0.3 & 0 & 0.3 & 0.7 & 1 \end{pmatrix}.$$

今后，凡取值总是 0 和 1 的矩阵称**布尔矩阵**. 凡取值均在[0, 1]中的矩阵称 **Fuzzy 矩阵**. 任何一个 $m \times n$ 阶 Fuzzy 矩阵

$$\Phi = (a_{ij})_{m\times n} = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{pmatrix}$$

均可解释为论域 $U=\{x_1, x_2, \cdots, x_n\}$ 上的 m 个 Fuzzy 集

$$A_1 = (a_{11}, a_{12}, \cdots, a_{1n}),$$
$$A_2 = (a_{21}, a_{22}, \cdots, a_{2n}),$$
$$\cdots$$
$$A_m = (a_{m1}, a_{m2}, \cdots, a_{mn}).$$

这种观点将引导我们去尝试把 Fuzzy 集合论的方法应用到更多的场合.

3.2.2 Fuzzy 集合的运算

现在我们来讨论,仿照人脑通常的 Fuzzy 思维方式,表达 Fuzzy 概念的 Fuzzy 集合,其各种基本运算应当是什么样子?

考虑若干女子形成的论域

$$U = \{王丽, 李丽, \cdots, 丁丽, 赵丽\},$$

并给出 U 的两个 Fuzzy 子集如下

A = 美丽女子 = {(王丽,0.8),(李丽,0.9),…,(丁丽,0.6),(赵丽,0.4)},

B = 聪明女子 = {(王丽,0.6),(李丽,0.8),…,(丁丽,0.7),(赵丽,0.9)}.

若用 $A \cap B$, $A \cup B$, A', B' 分别来记既美丽又聪明女子,或美丽或聪明女子,不美丽女子,不聪明女子,那么要问,王丽隶属于 $A \cap B$, $A \cup B$, A', B' 的程度应当是多少呢? 已经知道,王丽对 A = 美丽女子和 B = 聪明女子的隶属程度分别为 0.8 和 0.6. 如果我们选择

$$\min\{0.8, 0.6\} = 0.6,$$
$$\max\{0.8, 0.6\} = 0.8,$$
$$1 - 0.8 = 0.2,$$
$$1 - 0.6 = 0.4.$$

作为王丽分别关于 $A \cap B$ = 既美丽又聪明女子, $A \cup B$ = 或美丽或聪明女子, A' = 不美丽女子, B' = 不聪明女子的隶属程度时,那么就相当好地符合了人脑通常的 Fuzzy 思维方式(这里并不排除或排斥其他的选择). 于是我们得到 U 的如下 Fuzzy 子集

$A \cap B$ = 既美丽又聪明女子
= {(王丽,0.6),(李丽,0.8),…,(丁丽,0.6),(赵丽,0.4)},

$A \cup B$ = 或美丽或聪明女子
= {(王丽,0.8),(李丽,0.9),…,(丁丽,0.7),(赵丽,0.9)},

A' = = 不美丽女子
= {(王丽,0.2),(李丽,0.1),…,(丁丽,0.4),(赵丽,0.6)},

B' = = 不聪明女子
= {(王丽,0.4),(李丽,0.2),…,(丁丽,0.3),(赵丽,0.1)}.

由此我们获得,或说抽象出 Fuzzy 集合并、交、补等基本运算的一般性定

义.

定义 3.2 (Fuzzy 集的运算) 设 A, B 是论域 U 的 Fuzzy 子集,则 A 的**补集** A', A 与 B 的**交集** $A \cap B$, A 与 B 的**并集** $A \cup B$,以及 A 与 B 的**包含关系** $A \subseteq B$ 分别由下式定义

(1) $A'(x) = 1 - A(x)$.

(2) $(A \cap B)(x) = \min\{A(x), B(x)\} = A(x) \wedge B(x)$.

(3) $(A \cup B)(x) = \max\{A(x), B(x)\} = A(x) \vee B(x)$.

(4) $A \subseteq B \Leftrightarrow \forall x \in U, A(x) \leqslant B(x)$.

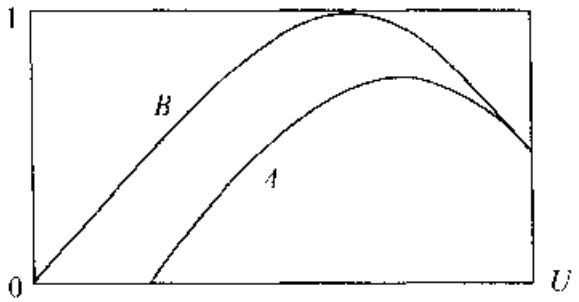


图 3.3 Fuzzy 集 A 与 B 的包含 $A \subseteq B$

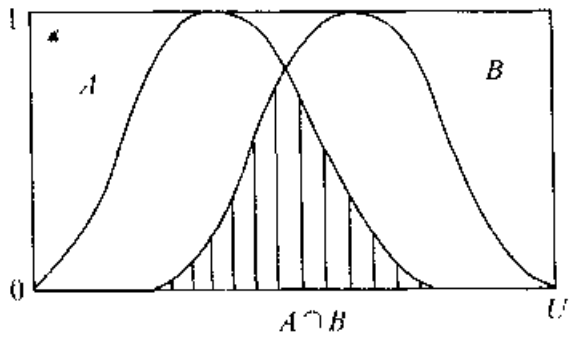


图 3.4 Fuzzy 集 A 与 B 的交集 $A \cap B$

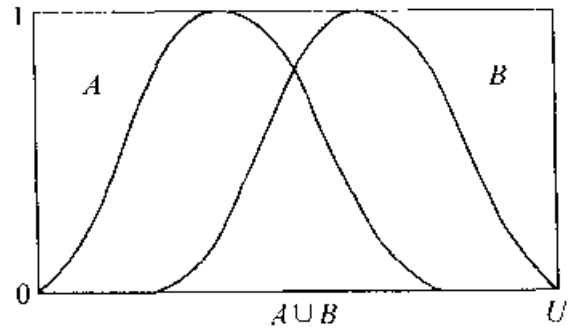


图 3.5 Fuzzy 集 A 与 B 的并集 $A \cup B$

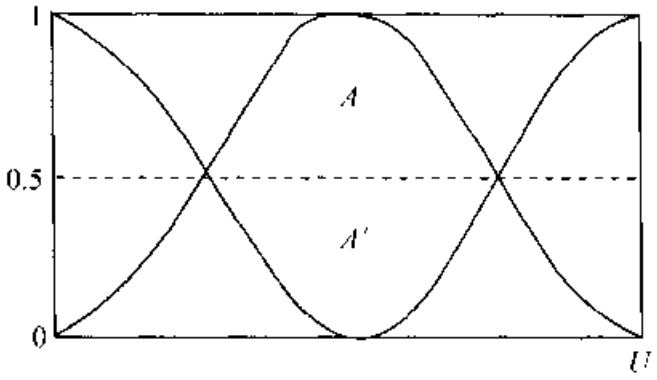


图 3.6 Fuzzy 集 A 的补集 A'

例 3.1 设 $U=\{x_1,x_2,\cdots,x_n\}$ 是 n 个品种巡航导弹所成的论域，且

$$A = \text{速度特快的巡航导弹}$$
$$= \frac{1}{x_1}+\frac{0.9}{x_2}+\cdots+\frac{0.7}{x_n},$$
$$B = \text{精确度特高的巡航导弹}$$
$$= \frac{0.7}{x_1}+\frac{0.8}{x_2}+\cdots+\frac{0.9}{x_n},$$

则

$$A\cap B = \text{又快又准的巡航导弹}$$
$$= \frac{1\wedge 0.7}{x_1}+\frac{0.9\wedge 0.8}{x_2}+\cdots+\frac{0.7\wedge 0.9}{x_n}$$
$$= \frac{0.7}{x_1}+\frac{0.8}{x_2}+\cdots+\frac{0.7}{x_n},$$
$$A\cup B = \text{或快或准的巡航导弹}$$
$$= \frac{1\vee 0.7}{x_1}+\frac{0.9\vee 0.8}{x_2}+\cdots+\frac{0.7\vee 0.9}{x_n}$$
$$= \frac{1}{x_1}+\frac{0.9}{x_2}+\cdots+\frac{0.9}{x_n},$$
$$A' = \text{速度特慢的巡航导弹}$$
$$= \frac{1-1}{x_1}+\frac{1-0.9}{x_2}+\cdots+\frac{1-0.7}{x_n}$$
$$= \frac{0}{x_1}+\frac{0.1}{x_2}+\cdots+\frac{0.3}{x_n},$$
$$B' = \text{精确度特低的巡航导弹}$$
$$= \frac{1-0.7}{x_1}+\frac{1-0.8}{x_2}+\cdots+\frac{1-0.9}{x_n}$$

$$= \frac{0.3}{x_1} + \frac{0.2}{x_2} + \cdots + \frac{0.1}{x_n}.$$

我们用 $\mathcal{F}(U)$ 记论域 U 的所有 Fuzzy 子集构成的族,即

$$\mathcal{F}(U) = \{A \mid A : U \to [0,1]\}$$

称为 U 的 **Fuzzy 幂集**.论域 U 上的空集 $\varnothing$ 和全集 U 由下述条件规定

$$\forall x \in U, \quad \varnothing(x) = 0, \quad U(x) = 1,$$

它们分别是 Fuzzy 幂集 $\mathcal{F}(U)$ 中的最小 Fuzzy 集和最大 Fuzzy 集.

容易证明下述定理.

定理 3.1 Fuzzy 集合的并、交、补运算拥有如下的运算律

(1) 幂等律 $A \cup A = A, A \cap A = A$.

(2) 交换律 $A \cup B = B \cup A, A \cap B = B \cap A$.

(3) 结合律 $(A \cup B) \cup C = A \cup (B \cup C)$,

$(A \cap B) \cap C = A \cap (B \cap C)$.

(4) 吸收律 $A \cup (A \cap B) = A$,

$A \cap (A \cup B) = A$.

(5) 分配律 $A \cap (B \cup C) = (A \cap B) \cup (A \cap C)$,

$A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$.

(6) 复原律 $A'' = A$.

(7) 对偶律 $(A \cup B)' = A' \cap B'$,

$(A \cap B)' = A' \cup B'$.

(8) 两极律 $A \cup U = U, A \cap U = A$,

$A \cup \varnothing = A, A \cap \varnothing = \varnothing$.

定理 3.2 在 Fuzzy 幂集 $\mathcal{F}(U)$ 中,

(1) $A \subseteq B \Leftrightarrow A \cup B = B \Leftrightarrow A \cap B = A$.

(2) $A = B \Leftrightarrow A \subseteq B$ 且 $B \subseteq A$.

应该指出,Fuzzy 集合的并、交运算可以推广到任意一族的情形.

任给一族 Fuzzy 集 $\{A_\alpha \mid \alpha \in D\} \subseteq \mathcal{F}(U)$,其并集 $\bigcup_{\alpha \in D} A_\alpha$ 和交集 $\bigcap_{\alpha \in D} A_\alpha$ 分别由下式确定

$$\left(\bigcup_{\alpha \in D} A_\alpha\right)(x) = \sup\{A_\alpha(x) \mid \alpha \in D\} = \bigvee_{\alpha \in D} A_\alpha(x),$$

$$\left(\bigcap_{\alpha \in D} A_\alpha\right)(x) = \inf\{A_\alpha(x) \mid \alpha \in D\} = \bigwedge_{\alpha \in D} A_\alpha(x).$$

可以证明,$(\mathcal{F}(U), \cup, \cap)$ 构成一个完全分配格,即满足如下完全分配律的完备格

$$\bigcap_{i \in I} \bigcup_{j \in J_i} A_{i,j} = \bigcup_{f \in \prod_{i \in I} J_i} \bigcap_{i \in I} A_{i,f(i)},$$

$$\bigcup_{i \in I} \bigcap_{j \in J_i} A_{i,j} = \bigcap_{f \in \prod_{i \in I} J_i} \bigcup_{i \in I} A_{i,f(i)},$$

且服从如下的 de Morgan 对偶律

$$(\bigcup_{\alpha\in D}A_\alpha)^c=\bigcap_{\alpha\in D}A_\alpha^c,$$
$$(\bigcap_{\alpha\in D}A_\alpha)^c=\bigcup_{\alpha\in D}A_\alpha^c.$$

此外我们还需要来自不同论域的 Fuzzy 集的直积运算.

定义 3.3（笛卡尔直积） 设 $A\in\mathcal{F}(U)$, $B\in\mathcal{F}(V)$. 制作 $U\times V$ 的 Fuzzy 子集 $A\times B$ 如下

$$(A\times B)(x,y)=\min\{A(x),B(y)\}=A(x)\wedge B(y)$$

叫作 Fuzzy 集 A 与 B 的**笛卡尔**(Cartesian)**直积**，简称**直积**.

一般地，设 $A_i\in\mathcal{F}(U_i)$, $i=1,2,\cdots,n$. 可制作 $\prod_{i=1}^{n}U_i=U_1\times U_2\times\cdots\times U_n$ 的 Fuzzy 子集 $\prod_{i=1}^{n}A_i=A_1\times A_2\times\cdots\times A_n$ 如下

$$(A_1\times A_2\times\cdots\times A_n)(x_1,x_2,\cdots,x_n)$$
$$=A_1(x_1)\wedge A_2(x_2)\wedge\cdots\wedge A_n(x_n),$$

即

$$\Big(\prod_{i=1}^{n}A_i\Big)(x_1,x_2,\cdots,x_n)=\min_{1\le i\le n}A_i(x_i)=\bigwedge_{i=1}^{n}A_i(x_i)$$

称之为 Fuzzy 集 $A_1,A_2,\cdots,A_n$ 的笛卡尔直积，简称直积.

注 3.1 在Fuzzy幂集$\mathcal{F}(U)$中，互补律不再成立. 即，一般地，对$A\in\mathcal{F}(U)$来说，未必存在 $B\in\mathcal{F}(U)$，使得

$$A\cup B=U,\quad A\cap B=\varnothing.$$

比如当 $A(x)\equiv\frac{1}{2}$时，就不存在任何 B 使 $A\cup B=U$ 且 $A\cap B=\varnothing$.

在Fuzzy逻辑中，Fuzzy集合的运算实际上是隶属度的按点运算. 于是$\mathcal{F}(U)$中 Fuzzy 集合的运算 $A\cup B$, $A\cap B$, A^c 等，就归结为取值域$[0,1]$中的相应运算

$$a\vee b=\max\{a,b\},$$
$$a\wedge b=\min\{a,b\},$$
$$a^c=1-a,$$

这一组运算叫 **Zadeh 算子**.

作为 Fuzzy 集合基本运算的并、交运算，采用 Zadeh 算子按点“取大取小”，不仅很好地符合人脑通常的 Fuzzy 思维方式，而且在研究和处理模糊性问题时带来了很多方便，因此在迄今有关 Fuzzy 集合论与 Fuzzy 逻辑的文献中，大多数都采用 Zadeh 的取大取小运算进行分析. 然而在有些实际问题中，采用这种算子会造成信息失落较多，难以获得理想的结果. 有些学者认为，只

取两个隶属度中的最大或最小值,忽略了另一个隶属度的值,是造成信息失落较多的根源.因此人们相继提出了不少与 $\vee$, $\wedge$ 相对应的新算子,试图在这方面得以改善.连同 Zadeh 算子一起,归纳如下

1.Zadeh 算子($\vee$, $\wedge$)

$$a \vee b = \max\{a, b\},$$
$$a \wedge b = \min\{a, b\},$$

其中 a 和 b 分别表示 $A(x)$ 和 $B(x)$,下同.

2. 代数算子($\overset{\wedge}{+}$, $\cdot$)

$$a \overset{\wedge}{+} b = a + b - ab,$$
$$a \cdot b = ab.$$

3. 有界算子($\oplus$, $\odot$)

$$a \oplus b = \min\{1, a + b\},$$
$$a \odot b = \max\{0, a + b - 1\}.$$

4.Einstain 算子($\overset{+}{\varepsilon}$, $\dot{\varepsilon}$)

$$a \overset{+}{\varepsilon} b = \frac{a + b}{1 + ab},$$

$$a \dot{\varepsilon} b = \frac{ab}{1 + (1 - a)(1 - b)}.$$

5.Hamacher 算子($\overset{+}{\nu}$, $\dot{\nu}$)

$$a \overset{+}{\nu} b = \frac{a \overset{\wedge}{+} b - (1 - \nu)ab}{\nu + (1 - \nu)(1 - ab)},$$

$$a \dot{\nu} b = \frac{ab}{\nu + (1 - \nu)(a \overset{\wedge}{+} b)},$$

其中 ν 是参数,当 $\nu = 1$ 时,($\overset{+}{\nu}$, $\dot{\nu}$)化为($\overset{\wedge}{+}$, $\cdot$);当 $\nu = 2$ 时,($\overset{+}{\nu}$, $\dot{\nu}$)化为($\overset{+}{\varepsilon}$, $\dot{\varepsilon}$).

6.Yager 算子(Y_p, y_p)

$$aY_pb = \min\{1, (a^p + b^p)^{1/p}\},$$
$$ay_pb = 1 - \min\{1, [(1 - a)^p + (1 - b)^p]^{1/p}\},$$

其中 p 是参数,当 $p = 1$ 时,(Y_p, y_p)化为($\oplus$, $\odot$);当 $p \to \infty$ 时,(Y_p, y_p)化为($\vee$, $\wedge$).

7.λ-γ 算子(λ, γ)

$$a\lambda b = \lambda(ab) + (1 - \lambda)(a + b - ab),$$
$$a\gamma b = (ab)^{1-\gamma}[1 - (1 - a(1 - b))]^{\gamma},$$

其中 $\lambda, \gamma \in [0, 1]$是参数.

新算子中最著名的是λ-γ算子,其主要思想是通过参数λ和γ来调节过

于简单和生硬的决策.

改善后的 Fuzzy 算子尽管在某种意义上更加接近于人类思维,然而由于其变化复杂且失去了许多好的运算性质而很少使用.比如代数算子和有界算子就损失了幂等律,吸收律,以及分配律等重要性质.因而在绝大部分 Fuzzy 芯片中采用的都是 Zadeh 算子.比如 Togai Infra Logic 公司生产的 Fuzzy 处理器 FC110,其 Fuzzy 推理速度达到 100000 规则,每秒 60000 非模糊输出值,最大规则数大于 800,但它宁愿受理任意形状的 Fuzzy 集合,却不愿采用除 Zadeh 算子以外的其他算子.

3.2.3 贴近度、择近原则与模式识别

用基于隶属度的 Fuzzy 集合表达 Fuzzy 概念、Fuzzy 现象、Fuzzy 事物,为模式识别进入 Fuzzy 环境开辟了道路.

定义 3.4(高度与深度) 设 $A\in\mathscr{F}(U)$,

(1) $\mathrm{Supp}A=\{x\in U\mid A(x)\neq 0\}$ 叫 Fuzzy 集 A 的**承集**.

(2) $\mathrm{Ker}A=\{x\in U\mid A(x)=1\}$ 叫 Fuzzy 集 A 的**核**.

(3) $\mathrm{Hgt}A=\sup\{A(x)\mid x\in U\}$ 叫 Fuzzy 集 A 的**高度**.

(4) $\mathrm{Dpn}A=\inf\{A(x)\mid x\in U\}$ 叫 Fuzzy 集 A 的**深度**.

(5) 如果 $\mathrm{Ker}A\neq\varnothing$,则称 A 为**正规 Fuzzy 集**.

注 3.2 对一个 Fuzzy 集 $A\in\mathscr{F}(U)$ 来说,未必一定存在 $x_0\in U$,使 $A(x_0)=\mathrm{Hgt}A$.比如由

$$A(x)=\begin{cases}x, & x\neq 1,\\ 0, & x=1\end{cases}$$

确定的 A 是 $U=[0,1]$ 的一个 Fuzzy 集,这里 $\mathrm{Hgt}A=1$,但不存在 $x_0\in U$ 使 $A(x_0)=\mathrm{Hgt}A$.

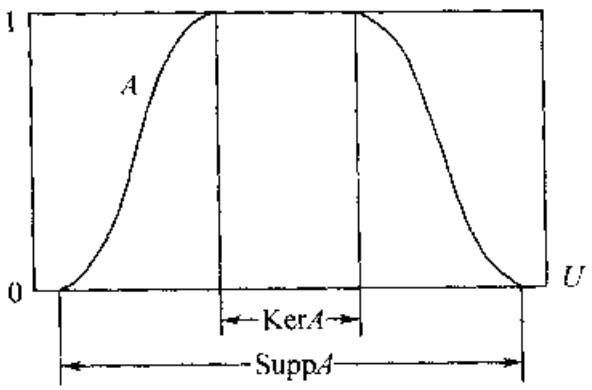


图 3.7 Fuzzy 集的核与承集

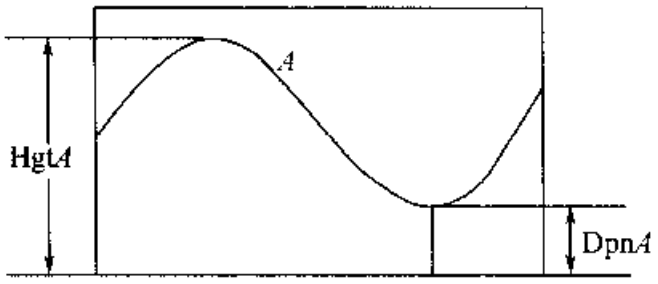


图 3.8 Fuzzy 集的高度与深度

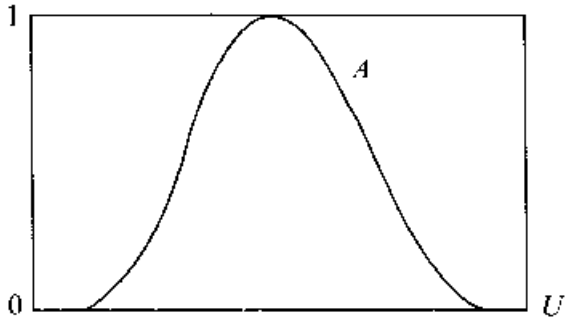


图 3.9 正规 Fuzzy 集

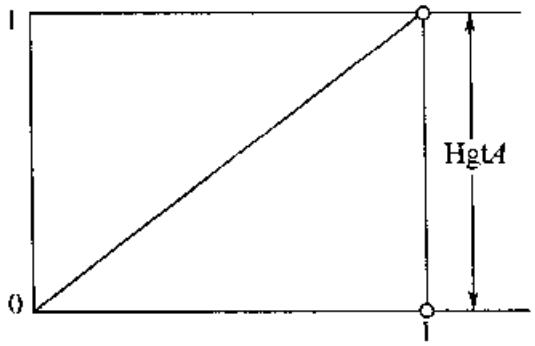


图 3.10 HgtA 未必等于某 $A(x_0)$

定义 3.5(贴近度) 设对每对 $A, B \in \mathscr{F}(U)$,有实数 $q(A, B)$对应,且满足

(1) $0 \leqslant q(A, B) \leqslant 1$.

(2) $q(A, B) = q(B, A)$.

(3) $A \subseteq B \subseteq C$ 时,$q(A, C) \leqslant q(A, B) \wedge q(B, C)$,则称 q 为 $\mathscr{F}(U)$中的**贴近度**,称 $q(A, B)$为 Fuzzy 集 A 与 B 的**贴近度**.

例 3.2 对每对 $A, B \in \mathscr{F}(U)$,记

$$q(A, B) = \mathrm{Hgt}(A \cap B),$$

则 q 是 $\mathscr{F}(U)$中的贴近度.

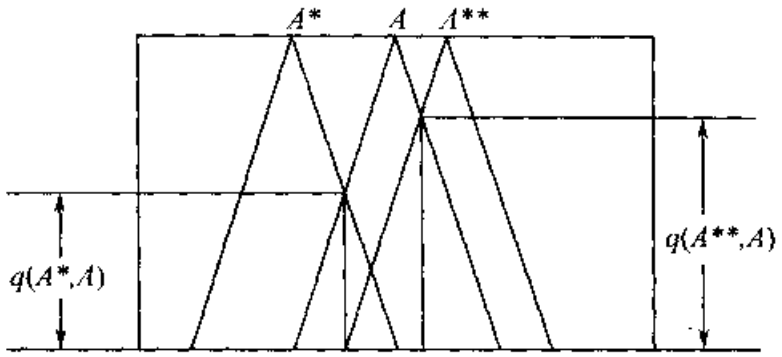


图 3.11 Fuzzy 集的贴近度

例 3.3 对每对 $A, B \in \mathscr{F}(U)$, 记

$$\hat{q}(A,B) = \frac{1}{2}[\mathrm{Hgt}(A \cap B) + (1 - \mathrm{Dpn}(A \cup B))],$$

则 $\hat{q}$ 是 $\mathscr{F}(U)$ 中的贴近度.

例 3.4 设 $U = \{a, b, c, d, e\}$,

$$A = \frac{0.8}{a} + \frac{0.7}{b} + \frac{0.9}{c} + \frac{0.4}{d} + \frac{0.3}{e},$$

$$B = \frac{0.5}{a} + \frac{0.4}{b} + \frac{0.6}{c} + \frac{0.8}{d} + \frac{1}{e},$$

则

$$\begin{aligned}\mathrm{Hgt}(A \cap B) &= (0.8 \wedge 0.5) \vee (0.7 \wedge 0.4) \vee (0.9 \wedge 0.6) \vee \\ &\quad (0.4 \wedge 0.8) \vee (0.3 \wedge 1) \\ &= 0.5 \vee 0.4 \vee 0.6 \vee 0.4 \vee 0.3 = 0.6,\end{aligned}$$

$$\begin{aligned}\mathrm{Dpn}(A \cup B) &= (0.8 \vee 0.5) \wedge (0.7 \vee 0.4) \wedge (0.9 \vee 0.6) \wedge \\ &\quad (0.4 \vee 0.8) \wedge (0.3 \wedge 1) \\ &= 0.8 \wedge 0.7 \wedge 0.9 \wedge 0.8 \wedge 1 = 0.7,\end{aligned}$$

从而

$$\hat{q}(A,B) = \frac{1}{2}[0.6 + (1 - 0.7)] = 0.45.$$

例 3.5 给定 $U = \boldsymbol{R}$ 的两个 Fuzzy 集 A 和 B 如下

$$A(x) = \mathrm{e}^{-\left(\frac{x-a_1}{b_1}\right)^2} \qquad (b_1 > 0),$$

$$B(x) = \mathrm{e}^{-\left(\frac{x-a_2}{b_2}\right)^2} \qquad (b_2 > 0),$$

则

$$\mathrm{Hgt}(A \cap B) = \mathrm{e}^{-\left(\frac{a_1-a_2}{b_1+b_2}\right)^2},$$

$$\mathrm{Dpn}(A \cup B) = 0,$$

从而

$$\hat{q}(A,B) = \frac{1}{2}\left[e^{\left(\frac{a_1 - a_2}{b_1 + b_2}\right)^2} + 1\right].$$

定义 3.6（择近原则）　设 U 为论域，q 是 U 中的贴近度，$\mathcal{A} = \{A_1, A_2, \cdots, A_n\}$ 是 U 的 n 个 Fuzzy 子集，叫 **Fuzzy 模式**．A^* 是 U 的一个 Fuzzy 子集，叫**待识别对象**．如果 $i_0 \leqslant n$ 满足

$$q(A^*, A_{i_0}) = \max_{i \leqslant n} q(A^*, A_i),$$

则说待识别对象 A^* 与 Fuzzy 模式 A_{i_0} 为 $\mathcal{A}$ **最贴近**．

例 3.6　已知知识库

$$A_1 \to B_1$$
$$A_2 \to B_2$$
$$\cdots$$
$$A_n \to B_n$$

现在输入 A^*，问该系统输出的 B^* 应如何？

解　对每个 $i \leqslant n$，计算贴近度 $q(A^*, A_i)$．若 $q(A^*, A_{i_0}) = \max_{i \leqslant n} q(A^*, A_i)$，则输出 $B^* = B_{i_0}$．

例 3.7　设一目标跟踪系统有 5 个 Fuzzy 模式由表 3.2 给出．

表 3.2　目标跟踪系统的 Fuzzy 模式

特征 / 模式	θ_1	θ_2	θ_3	θ_4	θ_5	θ_6
A_1	0.5	0.4	0.3	0.6	0.5	0.4
A_2	0.3	0.2	0.2	0.1	0.2	0.2
A_3	0.2	0.2	0.2	0.1	0.1	0.2
A_4	0	0.1	0.2	0.1	0.1	0.1
A_5	0	0.1	0.1	0.1	0.1	0.1

现发现一目标

$$A^* = (0.4, 0.2, 0.1, 0.4, 0.5, 0.6),$$

计算可得

$$\mathrm{Hgt}(A^* \cap A_1) = (0.4 \wedge 0.5) \vee (0.2 \wedge 0.4) \vee (0.1 \wedge 0.3) \vee (0.4 \wedge 0.6) \vee (0.5 \wedge 0.5) \vee (0.6 \wedge 0.4)$$

$$= 0.4 \vee 0.2 \vee 0.1 \vee 0.4 \vee 0.5 \vee 0.4$$
$$= 0.5,$$
$$\mathrm{Dpn}(A^* \cup A_1) = (0.4 \vee 0.5) \wedge (0.2 \vee 0.4) \vee (0.1 \vee 0.3) \wedge (0.4 \vee 0.6) \wedge (0.5 \vee 0.5) \vee (0.6 \vee 0.4)$$
$$= 0.5 \wedge 0.4 \wedge 0.3 \wedge 0.6 \wedge 0.5 \wedge 0.6$$
$$= 0.3,$$
$$\hat{q}(A^*, A_1) = \frac{1}{2}[\mathrm{Hgt}(A^* \cap A_1) + (1 - \mathrm{Dpn}(A^* \cup A_1)]$$
$$= \frac{1}{2}[0.5 + (1 - 0.3)]$$
$$= 0.6.$$

同理可得

$$\hat{q}(A^*, A_2) = 0.55, \qquad \hat{q}(A^*, A_3) = 0.5,$$
$$\hat{q}(A^*, A_4) = 0.45, \qquad \hat{q}(A^*, A_5) = 0.5,$$

易见

$$\hat{q}(A^*, A_1) = \max_{1 \le i \le 5} \hat{q}(A^*, A_i).$$

根据择近原则判决该目标为 A_1 型目标.

定义 3.7（最大隶属原则） 设 U 为论域，$\mathcal{A} = \{A_1, A_2, \cdots, A_n\}$ 是 U 的 n 个 Fuzzy 子集，叫 **Fuzzy 模式**；x_0 是 U 的某一元素，叫**待识别个体**. 如果 $i_0 \le n$ 满足

$$A_{i_0}(x_0) = \max_{1 \le i \le n} A_i(x_0),$$

则说 x_0 **相对隶属**于 Fuzzy 模式 A_{i_0}，记 $x_0 \hat{\in} A_{i_0}$.

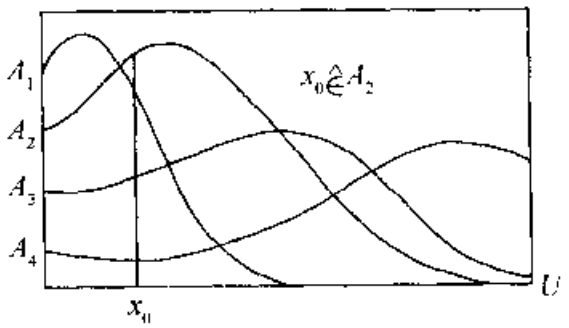


图 3.12 Fuzzy 集合的最大隶属原则

例 3.8 设一温度控制系统置有 5 个 Fuzzy 温度模式 A_1, A_2, A_3, A_4, A_5. 现测得即时温度为 t_0，且计算得到

$$A_1(t_0) = 0.6,\quad A_2(t_0) = 0.8,$$
$$A_3(t_0) = 0.5,\quad A_4(t_0) = 0.3,$$
$$A_5(t_0) = 0.1,$$

易见

$$\max_{1\leqslant i\leqslant 5} A_i(t_0) = 0.8 = A_2(t_0),$$

从而由最大隶属原则判决 $t_0 \overset{\Delta}{\in} A_2$，即 t_0 相对隶属于 Fuzzy 温度模式 A_2.

贴近度与择近原则以及最大隶属原则在目标识别，噪声识别，语音识别，指纹识别，手写文字识别等 Fuzzy 模式识别，以及 Fuzzy 推理，Fuzzy 决策，Fuzzy 控制中有重要应用.

3.2.4　λ 截集与分解定理

Fuzzy 集合可以通过 λ 截集分解为一族通常集合.

定义 3.8（λ 截集）　设 $A\in\mathcal{F}(U)$，$\lambda\in[0,1]$. 称

$$A_\lambda = \{x \in U \mid A(x)\geqslant \lambda\}$$

为 Fuzzy 集 A 的**λ 截集**，它是 U 的通常子集.

例 3.9　设 $U=\{x_1,x_2,x_3,x_4,x_5,x_6\}$

$$A = (0.9,1,0.2,0.5,0.7,0.3),$$

则

$$A_1 = \{x_2\},$$
$$A_{0.8} = \{x_1,x_2\},$$
$$A_{0.6} = \{x_1,x_2,x_5\},$$
$$A_{0.4} = \{x_1,x_2,x_4,x_5\},$$
$$A_{0.2} = \{x_1,x_2,x_3,x_4,x_5,x_6\}.$$

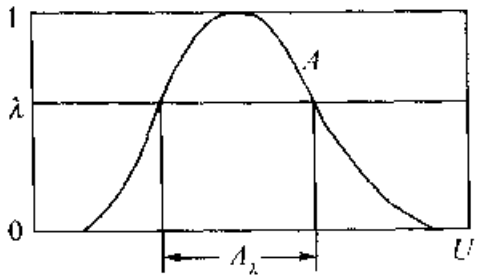


图 3.13　Fuzzy 集合的 λ 截集

显见，λ 截集有如下简单性质

(1) 若 $\lambda_1\leqslant\lambda_2$，则 $A_{\lambda_2}\subseteq A_{\lambda_1}$.

(2) $(A\cup B)_\lambda = A_\lambda \cup B_\lambda, (A\cap B)_\lambda = A_\lambda \cap B_\lambda$.

定义 3.9 (λ 截集的数乘) 设 $A\in\mathcal{F}(U), \lambda\in[0,1]$. 制作 Fuzzy 集 λA_λ 如下

$$\lambda A_\lambda(x) = \begin{cases} \lambda, & x\in A_\lambda, \\ 0, & x\notin A_\lambda, \end{cases}$$

叫 λ 截集的**数乘**.

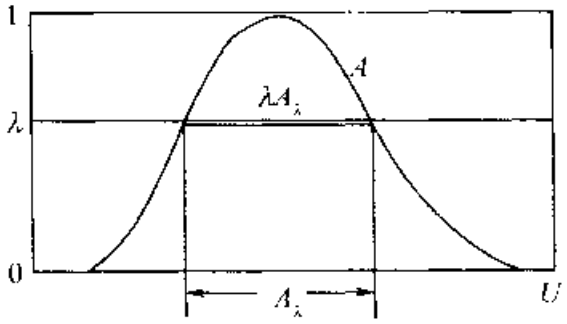


图 3.14 λ 截集的数乘

λA_λ 也即

$$(\lambda A_\lambda)(x) = \begin{cases} \lambda, & A(x)\geqslant\lambda, \\ 0, & A(x)<\lambda. \end{cases}$$

易见,若 $A\subseteq B$, 则 $\lambda A_\lambda \subseteq \lambda B_\lambda$. 但当 $\lambda_1\leqslant\lambda_2$ 时, 并不能保证 $\lambda_1 A\subseteq\lambda_2 A$

定理 3.3 (Fuzzy 集合的分解定理) 设 $A\in\mathcal{F}(U)$, 则

$$A = \bigcup_{\lambda\in[0,1]}(\lambda A_\lambda).$$

即一个复杂 Fuzzy 集 A 可表达为一族简单 Fuzzy 集 $\{\lambda A_\lambda \mid \lambda\in[0,1]\}$ 的并.

证明 任取 $x\in U$, 则

$$\begin{aligned} \left(\bigcup_{\lambda\in[0,1]}(\lambda A_\lambda)\right)(x) &= \sup_{\lambda\in[0,1]}(\lambda A_\lambda)(x) \\ &= \sup\{\lambda\in[0,1] \mid A(x)\geqslant\lambda\} \\ &= \sup[0, A(x)] \\ &= A(x), \end{aligned}$$

从而

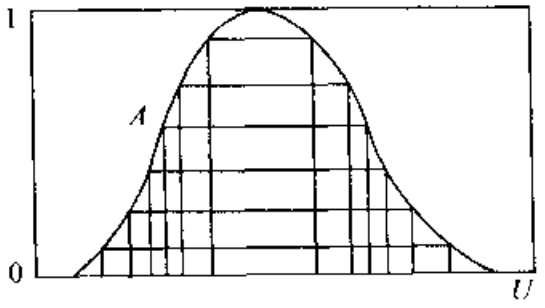


图 3.15 Fuzzy 集合的分解定理

$$\bigcup_{\lambda\in[0,1]}(\lambda A_\lambda)=A.$$

分解定理也常借助于 λ 截集 A_λ 的特征函数 χ_{A_λ} 表达.

定理 3.4 (Fuzzy 集合的分解定理) 设 $A\in\mathcal{F}(U)$,则

$$A(x)=\sup_{\lambda\in[0,1]}(\lambda\wedge\chi_{A_\lambda}(x))=\sup_{\lambda\in[0,1]}(\lambda\chi_{A_\lambda}(x)).$$

事实上,只要注意到

$$(\lambda A_\lambda)(x)=\lambda\wedge\chi_{A_\lambda}(x)=\lambda\chi_{A_\lambda}(x)$$

即可.

3.2.5 通常映射的 Fuzzy 扩张

一个通常映射 $f:U\to V$ 可以扩张为通常幂集之间的两个映射

$$f:\begin{cases}\mathcal{P}(U)\to\mathcal{P}(V),\\ A\mapsto f(A),\end{cases}$$

$$f^{-1}:\begin{cases}\mathcal{P}(V)\to\mathcal{P}(U),\\ B\mapsto f^{-1}(B).\end{cases}$$

这里

$$f(A)=\{f(x)\mid x\in A\}$$

叫 A 在 f 下的**像**,

$$f^{-1}(B)=\{x\mid f(x)\in B\}$$

叫 B 在 f 下的**原像**.

$f(A)$可用特征函数表示为

$$\chi_{f(A)}(y)=\sup\{\chi_A(x)\mid f(x)=y\}.$$

若将通常集合与其特征函数不加区分,则上式可写作

$$f(A)(y)=\sup\{A(x)\mid f(x)=y\}. \qquad (*)$$

在$\{0,1\}$中或$[0,1]$中求上、下确界时,我们约定

$$\sup\varnothing=0,\qquad \inf\varnothing=1,$$

那么若对某 $y\in V$,没有 U 中的元素 x 满足 $f(x)=y$ 时,

$$f(A)(y)=0.$$

类似地,$f^{-1}(B)$也可用特征函数表示为

$$\chi_{f^{-1}(B)}(x)=\chi_B(f(x))=(\chi_B\circ f)(x).$$

若将通常集合与其特征函数不加区分,则上式可写作

$$f^{-1}(B)(x)=B(f(x))=(B\circ f)(x). \qquad (**)$$

现在要问,对通常映射 $f:U\to V$ 来说,若取 U 的一个 Fuzzy 子集 A 来看,它在 f 下的像应当是什么?给定 V 的 Fuzzy 子集 B,它在 f 下的原像又应当是什么?

也就是说，普通集合之间的一个通常映射 $f: U \to V$ 应当怎样扩张到 Fuzzy 幂集 $\mathscr{F}(U)$ 与 $\mathscr{F}(V)$ 之间去？

事实上，上面的分析(*)和(**)已经给出了答案. 这就是 Zadeh 于 1975 年提出的著名的扩张原理.

定义 3.10（通常映射的 Fuzzy 扩张） 一个通常映射 $f: U \to V$ 到 Fuzzy 幂集 $\mathscr{F}(U)$ 与 $\mathscr{F}(V)$ 之间的两个 **Fuzzy 扩张**是指下面的映射

$$f: \begin{cases} \mathscr{F}(U) \to \mathscr{F}(V), \\ A \mapsto f(A), \end{cases}$$

$$f^{-1}: \begin{cases} \mathscr{F}(V) \to \mathscr{F}(U), \\ B \mapsto f^{-1}(B), \end{cases}$$

其中

$$\forall y \in V, \quad f(A)(y) = \sup\{A(x) \mid f(x) = y\},$$

$$\forall x \in U, \quad f^{-1}(B)(x) = B(f(x)) = (B \circ f)(x).$$

称 $f(A)$ 为 A 在 f 下的 **Fuzzy 像**，称 $f^{-1}(B)$ 为 B 在 f 下的 **Fuzzy 逆像**.

扩张原理事实上是说，当 Fuzzy 集 A 被映为 Fuzzy 集 $f(A)$，以及 Fuzzy 集 B 被映为 Fuzzy 集 $f^{-1}(B)$时，相应元素的隶属度都保持不变，从而隶属函数被毫无保留地传递了过去.

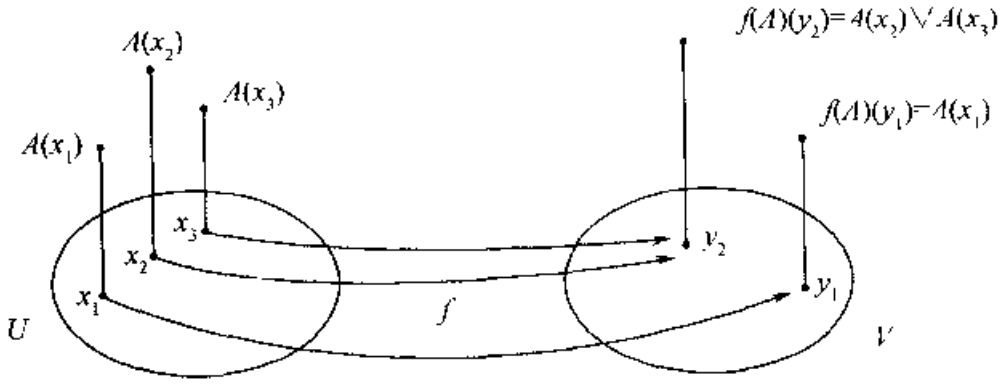


图 3.16 通常映射的 Fuzzy 扩张

当 $f: U \to V$ 是单射时，U 的 Fuzzy 子集 A 在 $f: \mathscr{F}(U) \to \mathscr{F}(V)$ 下的 Fuzzy 像为

$$f(A)(y) = A(x)\big|_{f(x)=y}.$$

如果此时 $U = \{x_1, x_2, \cdots, x_n\}$ 还是有限论域，那么对 U 的 Fuzzy 子集

$$A = \frac{A(x_1)}{x_1} + \frac{A(x_2)}{x_2} + \cdots + \frac{A(x_n)}{x_n}$$

来说，其 Fuzzy 像为

$$f(A)=\frac{A(x_1)}{f(x_1)}+\frac{A(x_2)}{f(x_2)}+\cdots+\frac{A(x_n)}{f(x_n)}.$$

扩张原理也常用强 λ 截集表达.

定义 3.11(强 λ 截集) 设 $A\in\mathcal{F}(U),\lambda\in[0,1]$. 称

$$A_\lambda=\{x\in U\mid A(x)>\lambda\}$$

为 Fuzzy 集 A 的**强 λ 截集**.

定理 3.5 设 $f:U\to V$ 是通常映射,$f:\mathcal{F}(U)\to\mathcal{F}(V)$和 $f^{-1}:\mathcal{F}(V)\to\mathcal{F}(U)$是其 Fuzzy 扩张. 则对每个 $\lambda\in[0,1)$,

(1) $(f(A))_\lambda=f(A_\lambda)$.

(2) $(f^{-1}(B))_\lambda=f^{-1}(B_\lambda)$.

(3) $(f^{-1}(B))_\lambda=f^{-1}(B_\lambda)$.

证明 (1) $y\in(f(A))_\lambda\Leftrightarrow f(A)(y)>\lambda$

$\Leftrightarrow\sup\{A(x)\mid f(x)=y\}>\lambda$

$\Leftrightarrow\exists x$ 满足 $f(x)=y$,使得 $A(x)>\lambda$

$\Leftrightarrow\exists x$ 满足 $f(x)=y$,使得 $x\in A_\lambda$

$\Leftrightarrow y\in f(A_\lambda)$.

(2) $x\in(f^{-1}(B))_\lambda\Leftrightarrow f^{-1}(B)(x)>\lambda$

$\Leftrightarrow B(f(x))>\lambda$

$\Leftrightarrow f(x)\in B_\lambda$

$\Leftrightarrow x\in f^{-1}(B_\lambda)$.

(3) $x\in(f^{-1}(B))_\lambda\Leftrightarrow f^{-1}(B)(x)\geqslant\lambda$

$\Leftrightarrow B(f(x))\geqslant\lambda$

$\Leftrightarrow f(x)\in B_\lambda$

$\Leftrightarrow x\in f^{-1}(B_\lambda)$.

注 3.3

(1) 定理 3.5 中 3 个等式左端的 f,f^{-1}是 f 的 Fuzzy 扩张,3 个等式右端的 f,f^{-1}是 f 的通常扩张.

(2) 等式$(f(A))_\lambda=f(A_\lambda)$一般地不成立. 对照定理 3.5(1)的证明过程可以发现

$$\sup\{A(x)\mid f(x)=y\}\geqslant\lambda$$

与

"$\exists x$ 满足 $f(x)=y$,使得 $A(x)\geqslant\lambda$"

不一定等价. 因为一个数集合的上确界$\geqslant\lambda$,不一定该数集中必有数$\geqslant\lambda$. 比如

$$\sup\left\{1-\frac{1}{n}\mid n\in\mathbf{N}\right\}=1,$$

但$\left\{1-\frac{1}{n}\mid n\in\mathbf{N}\right\}$中每个数都是小于 1 的.

3.2.6 隶属函数的确定

隶属度和隶属函数是 Fuzzy 集合论最基本的概念和出发点.对于一个模糊性问题,只有给出切合实际的隶属函数,才能有效地使用 Fuzzy 集合论的方法.

以下介绍几种确定隶属函数的具体方法,以供选用.

1. Fuzzy 统计法

在某些场合,隶属函数可以通过 Fuzzy 统计的方法来确定.

设 U 是论域,A 是 U 的一个 Fuzzy 子集.为了确定 A 的隶属函数,我们把 A 思考为"U 的一个运动着的、边界可变的通常集合"然后对 $x_0\in U$,经过充分大的试验次数 n,求出 x_0 对 A 的隶属频率.实践表明,随着 n 的增大,隶属频率会渐趋稳定于[0,1]中的某个值,该值即可取作 x_0 对 A 的隶属度,即

$$A(x_0)=\lim_{n\to\infty}\frac{x_0\in A\text{ 的次数}}{n}.$$

例 3.10 设年龄论域 $U=[0,150]$,试利用 Fuzzy 统计法确定 U 的 Fuzzy 子集 $A=$"青年"的隶属函数.

在某学院调查了 129 人见表 3.3,在他们独自认真地思考"青年"的含义以后,提出他们认为"青年"的最适宜的年限.

其中 27 岁对"青年"的隶属频率大致稳定在 0.78 左右.因此,可取其隶属度为 $A(27)=0.78$.

表 3.3 关于 27 岁对"青年"隶属频率的调查

调查人数	10	20	30	40	50	60	70	80	90	100	110	120	129
隶属次数	6	14	23	31	39	47	53	62	68	76	85	95	101
隶属频率	0.60	0.70	0.77	0.78	0.78	0.78	0.76	0.78	0.76	0.76	0.75	0.79	0.78

15～34 岁对"青年"隶属频率的调查如表 3.4 所示,其中调查总人数为 129.

表 3.4 关于 15～34 岁对"青年"隶属频率的调查

年 龄	15	16	17	18	19	20	21	22	23	24	25	26	27	28	29	30	31	32	33	34
隶属次数	27	51	67	124	125	129	129	129	129	129	128	103	101	99	80	77	27	27	26	26
隶属频率	0.21	0.39	0.52	0.69	0.97	1	1	1	1	1	0.99	0.8	0.78	0.77	0.62	0.6	0.21	0.21	0.2	0.2

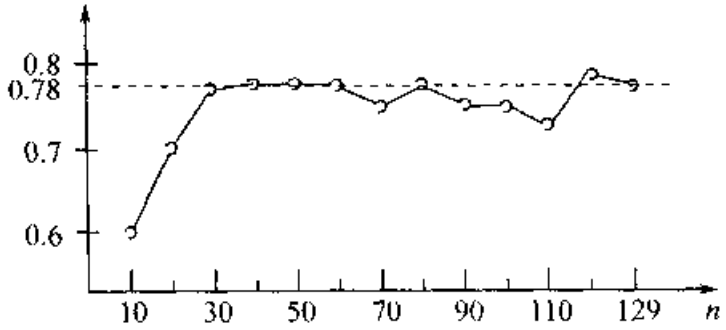


图 3.17 27 岁对"青年"隶属频率的稳定性

对于同一问题,在三所不同学院分别进行 Fuzzy 统计,所得"青年"的隶属函数曲线大致相同.将三次所获结果加以均匀化处理,即可作为 Fuzzy 子集 A ="青年"的隶属函数使用.

2. 二元对比排序法

人们对事物的认识往往从二元对比开始.例如,当我们试图通过品尝来决定桃子、李子、菠萝哪个"最好吃"时,常常会感到桃子比李子好吃,李子比菠萝好吃,而菠萝似乎又比桃子更好吃.这是 Fuzzy 顺序概念的一种特征.二元对比排序法的基本思想就是把事物在两两比较的基础上获得统一顺序,从而确定隶属函数的形状.

二元对比排序法是一种很实用的确定隶属函数的方法,常用的有相对比较法,对比平均法,优先关系定序法和择优比较法 4 种,这里我们只介绍前两种.

(1) 相对比较法

对论域 U 中的元素首先按某种特性两两对比排序,建立二元比较级,然后再按一定规则进行总体排序.

关于元素对(x,y)的二元比较级是指一个数对$(f_y(x),f_x(y))$,它满足

$$0 \leqslant f_y(x) \leqslant 1, \qquad 0 \leqslant f_x(y) \leqslant 1$$

其含义为,在 x 与 y 的二元对比中,如果 x 具有某特性的程度定为 $f_y(x)$的话,那么 y 具有该特性的程度便定为 $f_x(y)$.

例 3.11 设论域 $U=\{a,b,c\}$,其中 a 是长子,b 是次子,c 是幼子.按照"谁最像父亲"这一特性排序,可得

$$(f_b(a),f_a(b)) = (0.8,0.5)$$
$$(f_c(b),f_b(c)) = (0.4,0.7)$$
$$(f_a(c),f_c(a)) = (0.3,0.5)$$

其中第一式表示长子与次子的二元比较级是(0.8,0.5),即,如果把长子像父

亲的程度定为0.8,那么次子像父亲的程度便定为0.5,但这只是他们二人之间的比较,并非所有儿子之间的比较.所有二元比较级可列表如表3.5.

表3.5 二元比较级

$f_y(x)$ \ y / x	a	b	c
a		0.8	0.5
b	0.5		0.4
c	0.3	0.7	

然后根据二元比较级建立排序规则,进行总体排序.

记 $f(x/y)=\dfrac{f_y(x)}{\max\{f_x(y),f_y(x)\}}$,则有

$$f(x/y)=\begin{cases}f_y(x)/f_x(y), & f_y(x)\leqslant f_x(y),\\ 1, & f_y(x)\geqslant f_x(y).\end{cases}$$

以 $f(x/y)$ 为元素的矩阵叫相及矩阵,如表3.6所示,其中 $f(x/x)$ 取为1.

表3.6 相及矩阵

$f_y(x)$ \ y / x	a	b	c	min
a	1	1	1	1
b	5/8	1	4/7	4/7
c	3/5	1	1	3/5

表中最末一列是对相及矩阵的每一行取最小值,按其得到的各值从大到小排列顺序为

$$1>3/5>4/7.$$

由此得出结论:长子最像父亲,幼子次之,次子最不像父亲.

(2) 对比平均法

设论域 U 是需要按某种特性排序的对象全体,定义一个二元函数为

$$g(x,y)=f_y(x),\quad g(y,x)=f_x(y)$$

其中 $(f_y(x),f_x(y))$ 是相对比较法中的二元比较级.

对 U 中元素进行总体排序时,要给各元素赋予一定的权数,并乘以各项二元函数值之和,便得到各元素的隶属度的值.

例3.12 设论域 $U=\{a,b,c\}$ 是三条游艇的集合,要求按外观的美好程度进行排序.

先向一部分有经验的人们进行调查,用二元对比法评分,经整理得到表 3.7,其中 $g(a,a)=g(b,b)=g(c,c)=1$.

表 3.7 游艇的二元对比

$f_y(x)$ y / x	a	b	c
a	1	0.8	0.9
b	0.4	1	0.7
c	0.3	0.5	1

如果对三条游艇没有特殊偏好的话,那么可取权数相同,即都取 1/3 进行判断,则得

$$\text{“美好”}(a)=\frac{1}{3}[g(a,a)+g(a,b)+g(a,c)]=0.9,$$

$$\text{“美好”}(b)=\frac{1}{3}[g(b,a)+g(b,b)+g(b,c)]=0.7,$$

$$\text{“美好”}(c)=\frac{1}{3}[g(c,a)+g(c,b)+g(c,c)]=0.6.$$

由此得到 U 的 Fuzzy 子集“美好”$=A$ 为

$$A=0.9/a+0.7/b+0.6/c.$$

显见,三条游艇外观美好程度的顺序为

$$a>b>c.$$

但是如果对游艇 b 有所偏爱,则可取不同的权数.比如可给 a,b,c 分别赋予权数 0.3,0.4,0.3,则得

$$\text{“美好”}(a)=0.3[g(a,a)+g(a,b)+g(a,c)]=0.81,$$

$$\text{“美好”}(b)=0.4[g(b,a)+g(b,b)+g(b,c)]=0.84,$$

$$\text{“美好”}(c)=0.3[g(c,a)+g(c,b)+g(c,c)]=0.54.$$

此时,Fuzzy 子集“美好”$=A$ 为

$$A=0.81/a+0.84/b+0.54/c.$$

三条游艇外观美好程度的顺序便改为

$$b>a>c.$$

3.Fuzzy 分布

若以实数集 **R** 为论域,则隶属函数又称为 Fuzzy 分布.这是最重要、最常见的情况.在处理实际问题时,可以根据问题的性质合理采用某种典型的函数形式,并确定其中包含的参数.常用的 Fuzzy 分布可分为戒上型、戒下型以及对称型三大类,每类中又各含有六种分布图式.为了清楚起见,分别归纳成表 3.8、表 3.9 和表 3.10,以供选用.

表 3.8 戒上型 Fuzzy 分布

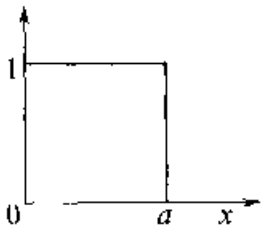
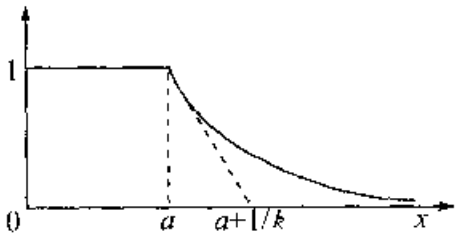
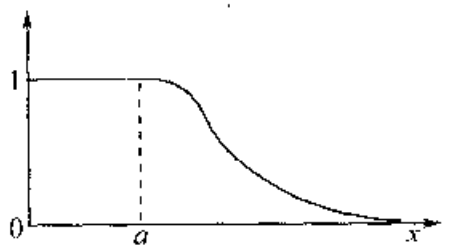
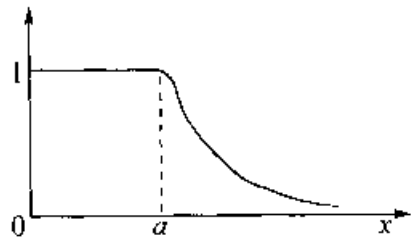
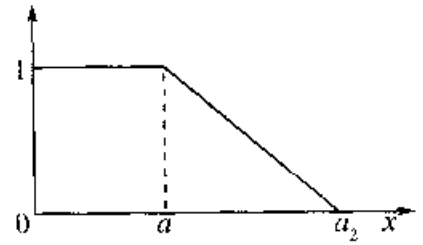
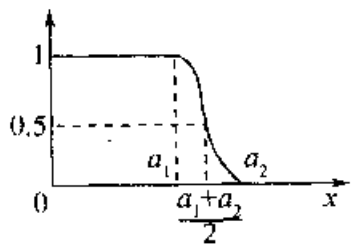
类别	隶属函数公式	图 形
降半矩形分布	$A(x)=\begin{cases}1, & x\leqslant a\\ 0, & x>a\end{cases}$	
降半 Γ 分布	$A(x)=\begin{cases}1, & x\leqslant a\\ e^{-k(x-a)}, & x>a,k>0\end{cases}$	
降半正态分布	$A(x)=\begin{cases}1, & x\leqslant a\\ e^{-k(x-a)^2}, & x>a,k>0\end{cases}$	
降半 Cauchy 分布	$A(x)=\begin{cases}1, & x\leqslant a\\ \dfrac{1}{1+\alpha(x-a)^{\beta}}, & x>a,\alpha,\beta>0\end{cases}$	
降半梯形分布	$A(x)=\begin{cases}1, & x\leqslant a\\ \dfrac{a_2-x}{a_2-a_1}, & a_1<x\leqslant a_2\\ 0, & a_2<x\end{cases}$	
降半岭形分布	$A(x)=\begin{cases}1, & x\leqslant a_1\\ \dfrac{1}{2}-\dfrac{1}{2}\sin\dfrac{\pi}{a_2-a_1}\left(x-\dfrac{a_1+a_2}{2}\right), & a_1<x\leqslant a_2\\ 0, & a_2<x\end{cases}$	

表 3.9　戒下型 Fuzzy 分布

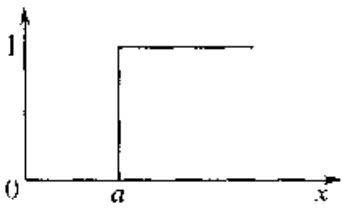
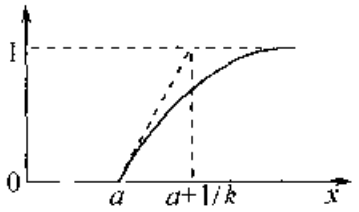
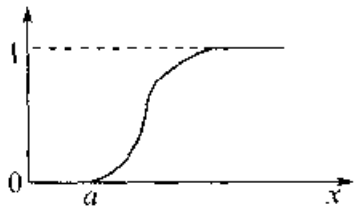
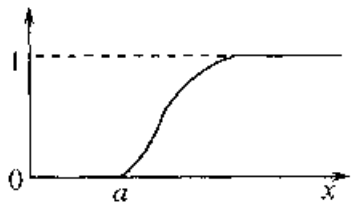
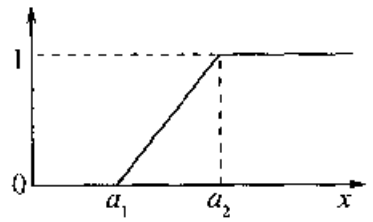
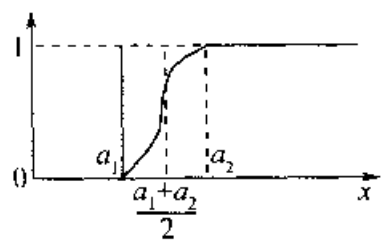
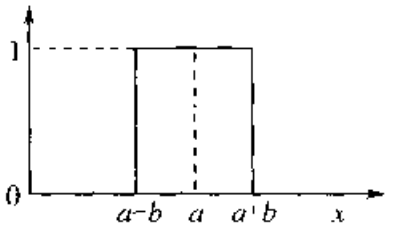
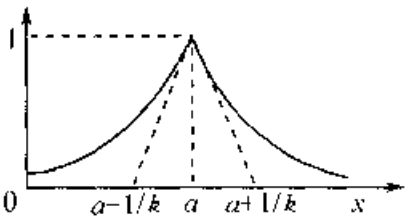
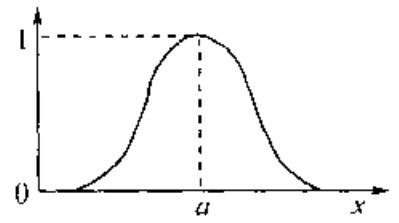
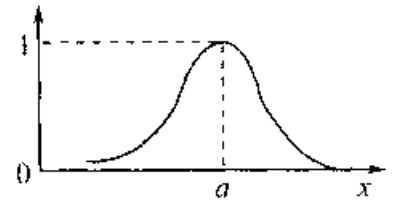
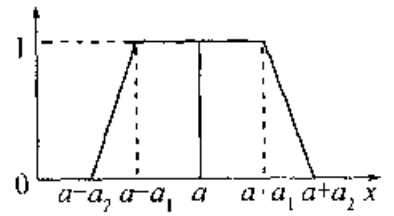
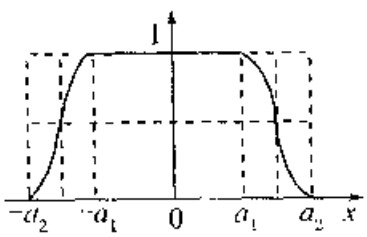
类别	隶属函数公式	图　形
升半矩形分布	$A(x)=\begin{cases}0, & x\leqslant a\\ 1, & x>a\end{cases}$	
升半 Γ 分布	$A(x)=\begin{cases}0, & x\leqslant a\\ 1-e^{-k(x-a)}, & x>a,k>0\end{cases}$	
升半正态分布	$A(x)=\begin{cases}0, & x\leqslant a\\ 1-e^{-k(x-a)^2}, & x>a,k>0\end{cases}$	
升半 Cauchy 分布	$A(x)=\begin{cases}0, & x\leqslant a\\ \dfrac{1}{1+\alpha(x-a)^{-\beta}}, & x>a,\alpha,\beta>0\end{cases}$	
升半梯形分布	$A(x)=\begin{cases}0, & x\leqslant a_1\\ \dfrac{x-a_1}{a_2-a_1}, & a_1<x\leqslant a_2\\ 1, & a_2<x\end{cases}$	
升半岭形分布	$A(x)=\begin{cases}0, & x\leqslant a_1\\ \dfrac{1}{2}+\dfrac{1}{2}\sin\dfrac{\pi}{a_2-a_1}\left(x-\dfrac{a_1+a_2}{2}\right), & a_1<x\leqslant a_2\\ 1, & a_2<x\end{cases}$	

表 3.10 对称型 Fuzzy 分布

类别	隶属函数公式	图 形
矩形分布	$A(x)=\begin{cases}0, & x\leqslant a-b\\ 1, & a-b<x\leqslant a+b\\ 0, & a+b<x\end{cases}$	
尖 Γ 分布	$A(x)=\begin{cases}e^{k(x-a)}, & x\leqslant a\\ e^{-k(x-a)}, & x>a\end{cases}$	
正态分布	$A(x)=e^{-k(x-a)^2}, \quad k>0$	
Cauchy 分布	$A(x)=\dfrac{1}{1+\alpha(x-a)^{\beta}}, \quad \alpha>0, \beta$ 为正偶数	
梯形分布	$A(x)=\begin{cases}0, & x\leqslant a-a_2\\ \dfrac{a_2+x-a}{a_2-a_1}, & a-a_2<x\leqslant a-a_1\\ 1, & a-a_1<x\leqslant a+a_1\\ \dfrac{a_2-x+a}{a_2-a_1}, & a+a_1<x\leqslant a+a_2\\ 0, & a+a_2<x\end{cases}$	
岭形分布	$A(x)=\begin{cases}0, & x\leqslant -a_2\\ \dfrac{1}{2}+\dfrac{1}{2}\sin\dfrac{\pi}{a_2-a_1}\left(x-\dfrac{a_2+a_1}{2}\right), & -a_2<x\leqslant -a_1\\ 1, & -a_1<x\leqslant a_1\\ \dfrac{1}{2}-\dfrac{1}{2}\sin\dfrac{\pi}{a_2-a_1}\left(x-\dfrac{a_2+a_1}{2}\right), & a_1<x\leqslant a_2\\ 0, & a_2<x\end{cases}$	

§3.3 Fuzzy 关系与 Fuzzy 矩阵

关系是集合论中最基本的概念之一.在 Fuzzy 集合论中,Fuzzy 关系占有更加重要的地位.本节介绍 Fuzzy 关系的定义,性质及其合成运算.当论域是有限集时,Fuzzy 关系可以用矩阵表示,这就导致了 Fuzzy 矩阵的理论.Fuzzy 等价关系与 Fuzzy 相似关系是 Fuzzy 关系中最重要的类型,由它们出发可以对事物进行动态的、多层次的 Fuzzy 分类,本节给予了较多的讨论.

3.3.1 通常关系

首先回顾通常关系的定义和运算,由此引出 Fuzzy 关系的思想和话题.

定义 3.12(关系) 设 U, V 是论域,

$$U \times V = \{(x, y) \mid x \in U, y \in V\}$$

是 U 和 V 的笛卡尔直积.$U \times V$ 的每一个子集 R 都叫做从 U 到 V 的一个**关系**.若 $U = V$,则说 R 是 U 中一个关系.若 $(x, y) \in R$,则记 xRy,并说 x 与 y **有关系** R.若 $(x, y) \notin R$,则记 $x\bar{R}y$,并说 x 与 y **无关系** R.

例 3.13

(1) 设 U, V 分别是男子集合和女子集合.取 $R \subseteq U \times V$ 为

$$R = \{(x, y) \mid x 与 y 是夫妻\},$$

则 R 是从 U 到 V 的一个关系,叫夫妻关系.

(2) 设 U 是国家集合.取 $R \subseteq U \times U$ 为

$$R = \{(x, y) \mid x 与 y 有引渡协议\},$$

则 R 是 U 中一个关系,叫引渡关系.

(3) $\boldsymbol{R}$ 是实数集合.取 $< \subseteq \boldsymbol{R} \times \boldsymbol{R}$ 为

$$< = \{(x, y) \mid x 小于 y\},$$

则 $<$ 是 $\boldsymbol{R}$ 中一个关系,叫大小关系.

(4) 设 U 是非空集.取 $\in \subseteq U \times \mathscr{P}(U)$ 为

$$\in = \{(a, A) \mid a 是 A 的元素\},$$

则 $\in$ 是从 U 到 $\mathscr{P}(U)$ 的一个关系,叫隶属关系.

(5) 设 U 是非空集.取“$\subseteq$”$\subseteq \mathscr{P}(U) \times \mathscr{P}(U)$ 为

$$“\subseteq” = \{(A, B) \mid A 包含于 B\},$$

则“$\subseteq$”是 $\mathscr{P}(U)$ 中一个关系,叫包含关系.

定义 3.13 设 R_1 是从 U 到 V 的关系,R_2 是从 V 到 W 的关系.令

$$R_1 \circ R_2 = \{(x, z) \mid \exists y \in V \text{ 使 } (x, y) \in R_1 \text{ 且 } (y, z) \in R_2\},$$

则 $R_1 \circ R_2$ 是从 U 到 W 的关系,叫做 R_1 与 R_2 的**复合关系**.

当论域为有限集时,通常关系可以用图表示.

例 3.14 设 $U=\{1,2,3,4\}$, $V=\{a,b,c\}$, $W=\{\alpha,\beta\}$.从 U 到 V 的关系 R_1,从 V 到 W 的关系 R_2,以及复合关系 $R_1\circ R_2$ 分别为

$$R_1=\{(1,a),(1,b),(2,a),(3,b),(4,b),(4,c)\},$$

$$R_2=\{(a,\alpha),(a,\beta),(b,\beta),(c,\beta)\},$$

$$R_1\circ R_2=\{(1,\alpha),(1,\beta),(2,\alpha),(2,\beta),(3,\beta),(4,\beta)\}.$$

其图示如图 3.18.

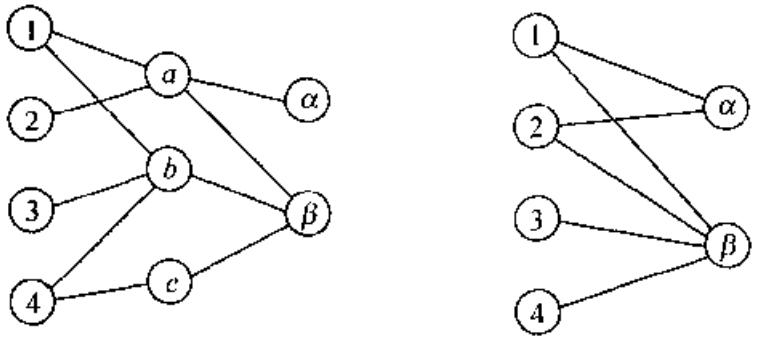


图 3.18 通常关系及其复合

当论域为有限集时,通常关系也可用表格表示.比如上例中的 R_1, R_2, $R_1\circ R_2$ 可表示如表 3.11.

表 3.11 通常关系及其复合

U \ V	a	b	c
1	1	1	0
2	1	0	0
3	0	1	0
4	0	1	1

V \ W	α	β
a	1	1
b	0	1
c	0	1

U \ W	α	β
1	1	1
2	1	1
3	0	1
4	0	1

有限集之间的通常关系还可用矩阵表示.比如上例中的 $R_1\circ R_2$ 可表示为

$$R_1\circ R_2=\begin{pmatrix}1&1&0\\1&0&0\\0&1&0\\0&1&1\end{pmatrix}\circ\begin{pmatrix}1&1\\0&1\\0&1\end{pmatrix}=\begin{pmatrix}1&1\\1&1\\0&1\\0&1\end{pmatrix}.$$

但是这里的矩阵"乘法"不同于通常的矩阵乘法.不过易见,若 $R_1=(a_{ik})_{m\times p}$, $R_2=(b_{kj})_{p\times n}$,则

$$R_1\circ R_2=(c_{ij})_{m\times n},$$

且

$$c_{ij} = \bigvee_{k=1}^{p}(a_{ik} \wedge b_{kj}).$$

对于一个矩阵 $R=(r_{ij})_{m\times n}$来说,如果$\{r_{ij} \mid i\leqslant m, j\leqslant n\}\subseteq\{0,1\}$,则称 R 为一个 $m\times n$ 阶**布尔矩阵**.

定义 3.14(等价关系) 设 R 是 U 中的关系.若满足

(1) 自反性:$\forall x\in U, xRx$;

(2) 对称性:$\forall x, y\in U$,若 xRy,则 yRx;

(3) 传递性:$\forall x, y, z\in U$,若 xRy 且 yRz,则 xRz,则称 R 为 U 中一个**等价关系**.这时,$\forall x\in U, [x]=\{y\in U \mid xRy\}$叫一个 ***R* 等价类**.又称 $U/R=\{[x]\mid x\in U\}$为 U 关于等价关系 R 的**商集**.

易见,$\forall x, y\in U$,要么$[x]=[y]$,要么$[x]\cap[y]=\varnothing$,且 $\bigcup_{x\in U}[x]=U$.从而商集 U/R 构成 U 的一个**分类**.

反过来,U 的一个分类决定 U 中一个等价关系.事实上,设 $\mathcal{A}=\{A_\alpha \mid \alpha\in D\}$是 U 的一个分类,即,$\bigcup_{\alpha\in D}A_\alpha=U$ 且当 $\alpha\neq\beta$ 时 $A_\alpha\cap A_\beta=\varnothing$.令

$$R=\{(x,y)\mid \exists\,\alpha\in D \text{ 使 } x, y\in A_\alpha\},$$

则易证 R 是 U 中的等价关系.

例 3.15 设 $f: U\to V$ 是一个通常映射.令

$$R=\{(x_1,x_2)\mid f(x_1)=f(x_2)\},$$

则 R 是 U 中的一个等价关系.$f^{-1}(\{y\})$是一个 R 等价类.U 关于 R 的商集为

$$U/R=\{f^{-1}(\{y\})\mid y\in V\}.$$

定义 3.15(偏序) 设$\leqslant$是 U 中的关系.若满足

(1) 自反性:$\forall x\in U, x\leqslant x$.

(2) 反对称性:$\forall x, y\in U$,若 $x\leqslant y$ 且 $y\leqslant x$,则 $x=y$.

(3) 传递性:$\forall x, y, z\in U$,若 $x\leqslant y$ 且 $y\leqslant z$,则 $x\leqslant z$.

则称$\leqslant$是 U 中一个**偏序关系**,简称**偏序**,并称$(U,\leqslant)$是一个**偏序集**.

例 3.16 Fuzzy 幂集 $\mathcal{F}(U)$按包含关系$\subseteq$构成偏序集$(\mathcal{F}(U),\subseteq)$.

通常关系 R 要求对 $U\times V$ 中每一个元素对(x,y)明确地作出是否属于 R 的判断,也即有还是无关系 R 的判断.当不能简单地用"是"或"否",或者"有"或"无"作出判断时,就需要把关系进一步拓广,用 Fuzzy 关系加以描述.

3.3.2 Fuzzy 关系

如果我们说,x 与 y 有关系 R 的程度为 0.9,x 与 z 有关系 R 的程度为 0.6,那么就更好地符合广人脑通常的 Fuzzy 思维方式.这就引出了 Fuzzy 关系的定义和有关话题.

定义 3.16（Fuzzy 关系） 设 U, V 是论域，

$$U \times V = \{(x, y) \mid x \in U, y \in V\}$$

是 U 和 V 的笛卡尔直积. $U \times V$ 的每一个 Fuzzy 子集 R 都叫做从 U 到 V 的一个 **Fuzzy 关系**. 若 $U = V$，则说 R 是 U 中的 Fuzzy 关系. 如果 $R(x, y) = a$，我们就说 x 与 y **有关系 R 的程度**为 a.

在谈论 Fuzzy 关系的场合，我们不再使用 $(x, y) \in R$，xRy，$(x, z) \notin R$，xRz 等记号，也不再说 x 与 y 有关系 R，x 与 z 无关系 R，而代之以说 x 与 y 有关系 R 的程度为 $R(x, y)$. 比如当 $R(x, y_1) = 0.998$，$R(x, y_2) = 0.997$，$R(x, y_3) = 0.333$ 时，我们就说 x 与 y_1 有关系 R 的程度为 0.998，x 与 y_2 有关系 R 的程度为 0.997，x 与 y_3 有关系 R 的程度为 0.333 等.

例 3.17

(1) 设 $U = \{a_1, a_2, \cdots, a_m\}$ 表示 m 个工厂的集合，$V = \{b_1, b_2, \cdots, b_n\}$ 表示 n 种原料的集合. 对每个 $a_i \in U$ 和 $b_j \in V$，用

$$R(a_i, b_j) = c_{ij} \in [0, 1]$$

表示工厂 a_i 对原料 b_j 的依赖程度，则 $R \in \mathcal{F}(U \times V)$ 是从 U 到 V 的一个 Fuzzy 关系.

(2) 设 $U = \{a_1, a_2, \cdots, a_n\}$ 是 n 个国家的集合. 对每对 $a_i, a_j \in U$，用

$$R(a_i, a_j) = c_{ij} \in [0, 1]$$

表示 a_i 与 a_j 的友好程度，则 R 是 U 中的 Fuzzy 关系.

(3) 设 $U = \{a_1, a_2, \cdots, a_{50}\}$ 是美国 50 个州的集合，$V = \{b_1, b_2\} = \{$戈尔，小布什$\}$ 是民主、共和两党总统候选人的集合. 用

$$R(a_i, b_j) = c_{ij} \in [0, 1]$$

表示州 a_i 对候选人 b_j 的支持率，则 R 是从 U 到 V 的 Fuzzy 关系，它刻画了美国大选的当前形势.

(4) 设 $U = [t_0, t_1]$ 是温度控制系统中温度的变化区间，$V = [v_0, v_1]$ 是加热器电压的变化区间. 将

$$R = A \to B = \text{“若温度偏低，则把加热器电压调到较大”}$$

看作从 U 到 V 的一个 Fuzzy 关系，$\forall (x, y) \in U \times V$，

$$R(x, y) = (A \to B)(x, y) \in [0, 1]$$

表示温度 x 与电压 y 有关系 $R = A \to B$ 的程度. 其中，U 的 Fuzzy 子集 A 和 V 的 Fuzzy 子集 B 分别表示“温度偏低”和“电压较大”.

作为 $U \times V$ 的 Fuzzy 子集，Fuzzy 关系有如下的运算.

(1) 包含：$R_1 \subseteq R_2$. 即

$$\forall (x, y) \in U \times V, \quad R_1(x, y) \leqslant R_2(x, y).$$

(2) 相等:$R_1 = R_2$. 即

$$R_1 \subseteq R_2 \quad 且 \quad R_2 \subseteq R_1,$$

亦即

$$\forall (x,y) \in U \times V, \quad R_1(x,y) = R_2(x,y).$$

(3) 并:$R_1 \cup R_2$. 即

$$\forall (x,y) \in U \times V, \quad (R_1 \cup R_2)(x,y) = R_1(x,y) \vee R_2(x,y),$$

若$\{R_\alpha \mid \alpha \in D\} \subseteq \mathcal{F}(U \times V)$,则

$$\forall (x,y) \in U \times V, \quad (\bigcup_{\alpha \in D} R_\alpha)(x,y) = \bigvee_{\alpha \in D} R_\alpha(x,y).$$

(4) 交:$R_1 \cap R_2$. 即

$$\forall (x,y) \in U \times V, \quad (R_1 \cap R_2)(x,y) = R_1(x,y) \wedge R_2(x,y),$$

若$\{R_\alpha \mid \alpha \in D\} \subseteq \mathcal{F}(U \times V)$,则

$$\forall (x,y) \in U \times V, \quad (\bigcap_{\alpha \in D} R_\alpha)(x,y) = \bigwedge_{\alpha \in D} R_\alpha(x,y).$$

(5) 补:R'. 即

$$\forall (x,y) \in U \times V, \quad R'(x,y) = 1 - R(x,y).$$

定义 3.17 (λ 截关系) 设 R 是从 U 到 V 的 Fuzzy 关系,$\lambda \in [0,1]$. 记

$$R_\lambda = \{(x,y) \in U \times V \mid R(x,y) \geqslant \lambda\},$$

称 R_λ 为 Fuzzy 关系 R 的**λ 截关系**,它是从 U 到 V 的一个通常关系.

定理 3.6 (Fuzzy 关系的分解定理) 从 U 到 V 的 Fuzzy 关系 R 可作如下分解

$$R = \bigcup_{\lambda \in [0,1]} (\lambda R_\lambda),$$

其中

$$(\lambda R_\lambda)(x,y) = \begin{cases} \lambda, & (x,y) \in R_\lambda, \\ 0, & (x,y) \notin R_\lambda, \end{cases}$$

$$= \begin{cases} \lambda, & R(x,y) \geqslant \lambda, \\ 0, & R(x,y) < \lambda. \end{cases}$$

Fuzzy 关系的分解定理还有另一种表示.

定理 3.7 从 U 到 V 的 Fuzzy 关系 R 可作如下分解

$$R(x,y) = \sup_{\lambda \in [0,1]} [\lambda \wedge \chi_{R_\lambda}(x,y)]$$

$$= \sup_{\lambda \in [0,1]} [\lambda \chi_{R_\lambda}(x,y)].$$

事实上,只要注意到

$$\lambda \wedge \chi_{R_\lambda}(x,y) = \lambda \chi_{R_\lambda}(x,y) = (\lambda R_\lambda)(x,y)$$

即可.

3.3.3 Fuzzy 矩阵

当论域是有限集时，Fuzzy 关系可以用 Fuzzy 关系图，Fuzzy 关系表，Fuzzy 关系矩阵表示.

例 3.18 设 $U=\{1,2,3,4\}$，$V=\{a,b,c\}$，$W=\{\alpha,\beta\}$. 从 U 到 V 的 Fuzzy 关系 R，从 V 到 W 的 Fuzzy 关系 S 如图 3.19(a)所示. 其意义为 $R(1,a)=0.7, R(1,b)=0.5, R(1,c)=0$，如此等等. 依人脑的日常判断，$R$ 与 S 的复合关系 $R\circ S$ 应如图 3.19(b)所示.

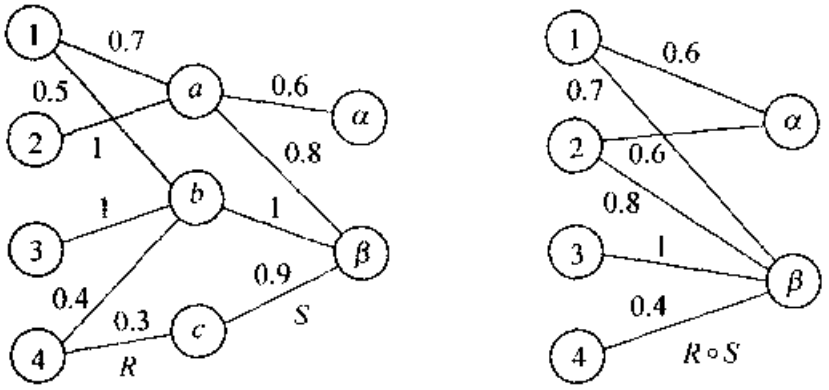


图 3.19 Fuzzy 关系及其复合

由此引导出 Fuzzy 关系复合运算的定义.

定义 3.18（复合 Fuzzy 关系） 设 $U=\{x_1,x_2,\cdots,x_m\}$，$V=\{y_1,y_2,\cdots,y_p\}$，$W=\{z_1,z_2,\cdots,z_n\}$. $R_1\in\mathscr{F}(U\times V)$，$R_2\in\mathscr{F}(V\times W)$. 制作从 U 到 W 的 Fuzzy 关系 $R_1\circ R_2$ 为，$\forall(x_i,z_j)\in U\times W$，

$$(R_1\circ R_2)(x_i,z_j)=\bigvee_{k=1}^{p}[R_1(x_i,y_k)\wedge R_2(y_k,z_j)],$$

称 $R_1\circ R_2$ 为 Fuzzy 关系 R_1 与 R_2 的**复合关系**.

容易推广到论域不必有限的一般场合.

定义 3.19（复合 Fuzzy 关系） 设 U，V，W 是论域，$R_1\in\mathscr{F}(U\times V)$，$R_2\in\mathscr{F}(V\times W)$. 制作从 U 到 W 的 Fuzzy 关系 $R_1\circ R_2$ 为，$\forall(x,z)\in U\times W$，

$$(R_1\circ R_2)(x,z)=\bigvee_{y\in V}[R_1(x,y)\wedge R_2(y,z)],$$

称 $R_1\circ R_2$ 为 Fuzzy 关系 R_1 与 R_2 的**复合关系**.

当论域为有限集时，Fuzzy 关系可以用 Fuzzy 关系表表示，比如例 3.18 中的 Fuzzy 关系 R，S，和 $R\circ S$ 可用 Fuzzy 关系表表示(见表 3.12).

表 3.12　Fuzzy 关系及其复合

U \ V	a	b	c
1	0.7	0.5	0
2	1	0	0
3	0	1	0
4	0	0.4	0.3

V \ W	α	β
a	0.6	0.8
b	0	1
c	0	0.9

U \ W	α	β
1	0.6	0.7
2	0.6	0.8
3	0	1
4	0	0.4

矩阵 $A=(a_{ij})_{m\times n}$ 若满足

$$\{a_{ij}\mid i\leqslant m, j\leqslant n\}\subseteq[0,1],$$

则叫做 $m\times n$ 阶 **Fuzzy 矩阵**.

当论域为有限集时，Fuzzy 关系及其复合运算还可用 Fuzzy 矩阵表示. 比如在例 3.14 中，

$$R\circ S=\begin{pmatrix}0.7 & 0.5 & 0\\ 1 & 0 & 0\\ 0 & 1 & 0\\ 0 & 0.4 & 0.3\end{pmatrix}\circ\begin{pmatrix}0.6 & 0.8\\ 0 & 1\\ 0 & 0.9\end{pmatrix}=\begin{pmatrix}0.6 & 0.7\\ 0.6 & 0.8\\ 0 & 1\\ 0 & 0.4\end{pmatrix}$$

但是这里 Fuzzy 矩阵的运算“$\circ$”不同于通常矩阵的“乘法”运算. 不过它与通常的矩阵“乘法”类似，只要将“$\cdot$”改为“$\wedge$”，将“$+$”改为“$\vee$”即可. 这与 3.3.1 节中对通常关系复合运算矩阵表达的分析是一致的.

由此得到 Fuzzy 矩阵合成运算的一般定义，它与有限论域 Fuzzy 关系的复合运算相对应.

定义 3.20（Fuzzy 矩阵的合成）　由 Fuzzy 矩阵 $R=(r_{ik})_{m\times p}$ 和 $S=(s_{kj})_{p\times n}$ 出发，制作另一 Fuzzy 矩阵 $C=(c_{ij})_{m\times n}$ 使满足

$$c_{ij}=\bigvee_{k=1}^{p}(r_{ik}\wedge s_{kj})\qquad(i\leqslant m, j\leqslant n),$$

并记 $C=R\circ S$. 称 C 为 Fuzzy 矩阵 R 与 S 的**合成**. 称“$\circ$”为 Fuzzy 矩阵的**合成运算**.

例 3.19　用 $U=\{x_1,x_2,x_3\}$ 表示病人集合，$V=\{y_1,y_2,y_3,y_4,y_5\}$ 表示症状集合，$W=\{z_1,z_2,z_3\}$ 表示病名集合. 已知从 U 到 V 的 Fuzzy 关系为

$$R=\begin{pmatrix}0.1 & 0.8 & 0.2 & 0.6 & 0.1\\ 0.7 & 0.2 & 0.1 & 0.1 & 0.8\\ 0.8 & 0.2 & 0.6 & 0.2 & 0.1\end{pmatrix},$$

从 V 到 W 的 Fuzzy 关系为

$$S=\begin{pmatrix}0.3 & 0.7 & 1\\ 1 & 0.3 & 0.2\\ 0.3 & 1 & 1\\ 1 & 0.3 & 0.2\\ 0.3 & 1 & 0.7\end{pmatrix},$$

则得 R 与 S 的复合关系为

$$R \circ S = \begin{pmatrix} 0.8 & 0.3 & 0.2 \\ 0.3 & 0.8 & 0.7 \\ 0.3 & 0.7 & 0.8 \end{pmatrix}.$$

这里,从症状集合 V 到病名集合 W 的 Fuzzy 关系 S 是一个医学诊断知识库,它表明了症状与病名之间的关系程度.

定义 3.21(并、交、补矩阵) 设 $R=(r_{ij})_{m\times n}$, $S=(s_{ij})_{m\times n}$ 是两个 Fuzzy 矩阵,则

(1) R 与 S 的**并矩阵**为 $R\cup S=(r_{ij}\vee s_{ij})_{m\times n}$.

(2) R 与 S 的**交矩阵**为 $R\cap S=(r_{ij}\wedge s_{ij})_{m\times n}$.

(3) R 的**补矩阵**为 $R^{c}=(1-r_{ij})_{m\times n}$.

(4) $R\subseteq S$ 的指 $\forall\, i\leqslant m, j\leqslant n, r_{ij}\leqslant s_{ij}$.

(5) $R=S$ 是指 $\forall\, i\leqslant m, j\leqslant n, r_{ij}=s_{ij}$.

Fuzzy 矩阵的运算有如下的性质.

(1) 结合律:设 $R_1=(r_{ij}^{(1)})_{m\times n}$, $R_2=(r_{jk}^{(2)})_{n\times p}$, $R_3=(r_{kl}^{(3)})_{p\times s}$, 则

$$(R_1\circ R_2)\circ R_3 = R_1\circ(R_2\circ R_3).$$

(2) 对方阵 R,规定 $R^2=R\circ R$, $R^3=R\circ R\circ R$, $\cdots$, $R^m=\underbrace{R\circ R\circ\cdots\circ R}_{m\text{个}}$,则

$$R^m\circ R^n = R^{m+n}, \quad (R^m)^n = R^{mn}.$$

(3) $(R_1\cup R_2)\circ R_3=(R_1\circ R_3)\cup(R_2\circ R_3)$,

$R_1\circ(R_2\cup R_3)=(R_1\circ R_2)\cup(R_1\circ R_3)$.

(4) $(R_1\cap R_2)\circ R_3\subseteq(R_1\circ R_3)\cap(R_2\circ R_3)$,

$R_1\circ(R_2\cap R_3)\subseteq(R_1\circ R_2)\cap(R_1\circ R_3)$.

(5) 若 $R_1\subseteq R_2$,则

$$R_1\circ R_3\subseteq R_2\circ R_3, \quad R_3\circ R_1\subseteq R_3\circ R_2.$$

对于方阵则有 $R_1^n\subseteq R_2^n$.

(6) 若 $R_1\subseteq R_2$, $S_1\subseteq S_2$,则 $R_1\circ S_1\subseteq R_2\circ S_2$.

一般地,Fuzzy 矩阵的合成不满足交换律.比如设

$$R_1=\begin{pmatrix}1 & 0\\ 1 & 1\end{pmatrix}, \quad R_2=\begin{pmatrix}0 & 1\\ 1 & 1\end{pmatrix},$$

则

$$R_1\circ R_2=\begin{pmatrix}0 & 1\\ 1 & 1\end{pmatrix}, \quad R_2\circ R_1=\begin{pmatrix}1 & 1\\ 1 & 1\end{pmatrix}.$$

这里

$$R_1 \circ R_2 \neq R_2 \circ R_1.$$

定义 3.22（λ 截矩阵） 设 $R=(r_{ij})_{m\times n}$ 是 Fuzzy 矩阵，$\lambda\in[0,1]$. 制作矩阵 $R_\lambda=(r_{ij}^{\lambda})_{m\times n}$ 使满足，$\forall i\leqslant m$，$\forall j\leqslant n$，

$$r_{ij}^{\lambda}=\begin{cases}1, & r_{ij}\geqslant\lambda,\\ 0, & r_{ij}<\lambda,\end{cases}$$

称 R_λ 为 R 的**λ 截矩阵**，它是一个布尔矩阵.

例 3.20 设

$$R=\begin{pmatrix}0.8 & 0.3 & 0.6\\ 0.2 & 0.4 & 0.7\\ 0.5 & 0.8 & 1\end{pmatrix},$$

则当 λ 取 0.7 时，有

$$R_\lambda=R_{0.7}=\begin{pmatrix}1 & 0 & 0\\ 0 & 0 & 1\\ 0 & 1 & 1\end{pmatrix}.$$

当 λ 取 0.8 时，有

$$R_\lambda=R_{0.8}=\begin{pmatrix}1 & 0 & 0\\ 0 & 0 & 0\\ 0 & 1 & 1\end{pmatrix}.$$

λ 截矩阵有下列性质.

(1) $R\subseteq S\Leftrightarrow\forall\lambda\in[0,1]$，$R_\lambda\subseteq S_\lambda$.

(2) $(R\cup S)_\lambda=R_\lambda\cup S_\lambda$，$(R\cap S)_\lambda=R_\lambda\cap S_\lambda$.

(3) $\left(\bigcup\limits_{\alpha\in D}R^{(\alpha)}\right)_\lambda\supseteq\bigcup\limits_{\alpha\in D}(R^{(\alpha)})_\lambda$.

(4) $\left(\bigcap\limits_{\alpha\in D}R^{(\alpha)}\right)_\lambda=\bigcap\limits_{\alpha\in D}(R^{(\alpha)})_\lambda$.

(5) $(R\circ Q)_\lambda=R_\lambda\circ Q_\lambda$.

在有限论域的场合，Fuzzy 关系与 Fuzzy 矩阵常不加区分.

3.3.4 Fuzzy 等价关系与 Fuzzy 分类

通常的等价关系其基本功能是实现对事物的分类. 而 Fuzzy 等价关系将会实现对事物的动态的由粗到细多层次的分类. 这种分类不仅很好地符合了人脑的日常思维方式，而且是比通常等价关系所实现的分类远为精细的分类.

Fuzzy 等价关系在目标跟踪、图象辨识、语音认读等模式识别，遥感分析、地质勘探、环境监测、天气预报、癌细胞分类等聚类分析，以及 Fuzzy 决策，Fuzzy 控制，知识发现与约简，海量数据的动态压缩等方面有着重要应用.

定义 3.23（Fuzzy 等价关系） 设 U 中的 Fuzzy 关系 R 满足

(1) 自反性：$\forall x \in U, R(x,x)=1$，

(2) 对称性：$\forall x, y \in U, R(x,y)=R(y,x)$.

(3) 传递性：$\forall x, y, z \in U, \forall \lambda \in [0,1]$，当 $R(x,y) \geqslant \lambda$ 且 $R(y,z) \geqslant \lambda$ 时，$R(x,z) \geqslant \lambda$. 则称 R 为 U 中一个 **Fuzzy 等价关系**.

如果仅满足(1)，则称 R 为 **Fuzzy 自反关系**. 如果仅满足(2)，则称 R 为 **Fuzzy 对称关系**. 如果仅满足(3)，则称 R 为 **Fuzzy 传递关系**.

易见，条件(3)就等于说

$$“(x,y) \in R_\lambda, (y,z) \in R_\lambda \Rightarrow (x,z) \in R_\lambda”,$$

亦即

$$“xR_\lambda y, yR_\lambda z \Rightarrow xR_\lambda z”.$$

因此，Fuzzy 传递关系 R 恰是一族通常传递关系 $\{R_\lambda \mid \lambda \in [0,1]\}$ 的组合. 对于一个固定的 $\lambda \in [0,1]$ 来说，(3)刻画了 Fuzzy 关系 R 具有 λ 水平的传递性.

我们给出 Fuzzy 传递关系的一个充要条件.

定理 3.8 U 中的 Fuzzy 关系 R 是 Fuzzy 传递关系的充要条件是 $R^2 \subseteq R$.

证明 必要性：任取 $x, z \in U$，对每个 $y_0 \in U$，令

$$\lambda = R(x,y_0) \wedge R(y_0,z),$$

则 $R(x,y_0) \geqslant \lambda, R(y_0,z) \geqslant \lambda$. 于是由 R 是 Fuzzy 传递关系知

$$R(x,z) \geqslant \lambda,$$

即

$$R(x,z) \geqslant R(x,y_0) \wedge R(y_0,z).$$

由 y_0 的任意性知

$$R(x,z) \geqslant \bigvee_{y \in U} [R(x,y) \wedge R(y,z)].$$

这表明 $R \supseteq R^2$.

充分性：任取 $\lambda \in [0,1]$. 设对任意的 $x, y, z \in U, R(x,y) \geqslant \lambda$ 且 $R(y,z) \geqslant \lambda$，即

$$R(x,y) \wedge R(y,z) \geqslant \lambda.$$

更有

$$\bigvee_{y \in U} [R(x,y) \wedge R(y,z)] \geqslant \lambda.$$

由 $R \supseteq R^2$ 可知

$$R(x,z) \geqslant \bigvee_{y \in U} [R(x,y) \wedge R(y,z)],$$

于是

$$R(x,z) \geqslant \lambda.$$

这说明 R 是 U 中的 Fuzzy 传递关系.

下面的定理指出,一个 Fuzzy 等价关系 R 对应着一族通常等价关系.

定理 3.9 U 中的 Fuzzy 关系 R 是 Fuzzy 等价关系的充要条件是,对每个 $\lambda\in[0,1]$, R 的 λ 截关系 R_λ 是 U 中的通常等价关系.

证明 必要性:

(1) 由 $R(x,x)=1$ 知,对每个 $\lambda\in[0,1]$, $R(x,x)\geqslant\lambda$,即 $(x,x)\in R_\lambda$,亦即 $xR_\lambda x$.这表明 λ 截关系 R_λ 拥有自反性.

(2) 由 $R(x,y)=R(y,x)$ 知,对每个 $\lambda\in[0,1]$, $R(x,y)\geqslant\lambda$ 当且仅当 $R(y,x)\geqslant\lambda$.即, $(x,y)\in R_\lambda$ 当且仅当 $(y,x)\in R_\lambda$.亦即, $xR_\lambda y$ 当且仅当 $yR_\lambda x$.这表明 λ 截关系 R_λ 拥有对称性.

(3) 由 R 是Fuzzy传递关系知,对每个 $\lambda\in[0,1]$,当 $R(x,y)\geqslant\lambda$ 且 $R(y,z)\geqslant\lambda$ 时必有 $R(x,z)\geqslant\lambda$.即,当 $(x,y)\in R_\lambda$ 且 $(y,z)\in R_\lambda$ 时必有 $(x,z)\in R_\lambda$.亦即,当 $xR_\lambda y$ 且 $yR_\lambda z$ 时必有 $xR_\lambda z$.这表明 λ 截关系 R_λ 拥有传递性.

综上可知,对每个 $\lambda\in[0,1]$来说, λ 截关系 R_λ 都是通常的等价关系.

充分性:利用 Fuzzy 关系的分解定理 3.7.

(1) 任取 $x\in U$,则对每个 $\lambda\in[0,1]$,由 $(x,x)\in R_\lambda$ 知

$$\chi_{R_\lambda}(x,x)=1,$$

$$\lambda\wedge\chi_{R_\lambda}(x,x)=\lambda,$$

$$R(x,x)=\sup_{\lambda\in[0,1]}[\lambda\wedge\chi_{R_\lambda}(x,x)]$$

$$=\sup_{\lambda\in[0,1]}\lambda=\sup[0,1]=1.$$

这表明 Fuzzy 关系 R 拥有自反性.

(2) 任取 $x,y\in U$,则对每个 $\lambda\in[0,1]$,由 $(x,y)\in R_\lambda\Leftrightarrow(y,x)\in R_\lambda$ 知

$$\chi_{R_\lambda}(x,y)=\chi_{R_\lambda}(y,x),$$

$$\lambda\wedge\chi_{R_\lambda}(x,y)=\lambda\wedge\chi_{R_\lambda}(y,x),$$

$$\sup_{\lambda\in[0,1]}[\lambda\wedge\chi_{R_\lambda}(x,y)]=\sup_{\lambda\in[0,1]}[\lambda\wedge\chi_{R_\lambda}(y,x)],$$

即

$$R(x,y)=R(y,x).$$

(3) 任取 $x,y,z\in U$,则对每个 $\lambda\in[0,1]$,由“$(x,y)\in R_\lambda$ 且 $(y,z)\in R_\lambda\Rightarrow(x,z)\in R_\lambda$”知

$$\text{“}R(x,y)\geqslant\lambda\quad\text{且}\quad R(y,z)\geqslant\lambda\rightarrow R(x,z)\geqslant\lambda\text{”}.$$

这表明 Fuzzy 关系 R 拥有传递性.

综上可知, R 是 Fuzzy 等价关系.

由此可见，U 中一个 Fuzzy 等价关系 R 对应着 U 中一族通常等价关系 $\{R_\lambda \mid \lambda\in[0,1]\}$，从而对应着 U 的一族分类 $\{U/R_\lambda \mid \lambda\in[0,1]\}$. 当 λ 从 0 上升为 1 时，这族分类由粗变细，构成一个动态的多层次的分类，叫 **Fuzzy 分类**，它是比通常分类远为精细的分类.

下面的定理表明，当 λ 由小变大时，Fuzzy 分类就由粗变细.

定理 3.10 设 $\lambda_1,\lambda_2\in[0,1]$. 若 $\lambda_1\leqslant\lambda_2$，则对每个 $x\in U$，

$$[x]_{R_{\lambda_2}}\subseteq[x]_{R_{\lambda_1}},$$

即分类 $U/R_{\lambda_2}=\{[x]_{R_{\lambda_2}}\mid x\in U\}$ 比分类 $U/R_{\lambda_1}=\{[x]_{R_{\lambda_1}}\mid x\in U\}$ 细.

证明 任取 $y\in[x]_{R_{\lambda_2}}$，则 $(x,y)\in R_{\lambda_2}$，$R(x,y)\geqslant\lambda_2\geqslant\lambda_1$. 于是 $(x,y)\in R_{\lambda_1}$，即 $y\in[x]_{R_{\lambda_1}}$. 这表明 $[x]_{R_2}\subseteq[x]_{R_1}$.

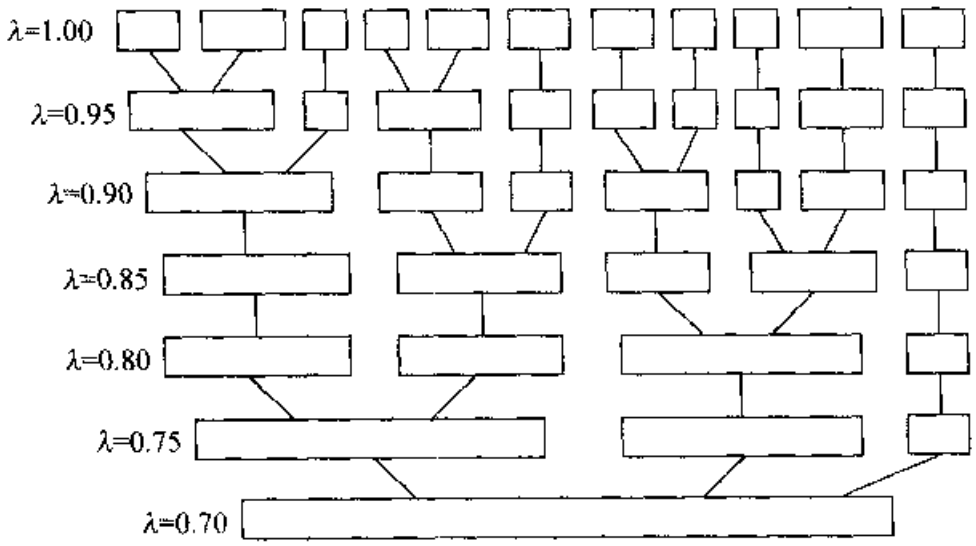


图 3.20 动态的粗到细的多层次的 Fuzzy 分类

我们说一个集族 $\mathscr{A}$ 比另一个集族 $\mathscr{B}$ **细**，或说 $\mathscr{B}$ 比 $\mathscr{A}$ **粗**，并记为 $\mathscr{A}\succ\mathscr{B}$，或 $\mathscr{B}\prec\mathscr{A}$，是指，对每个 $A\in\mathscr{A}$，存在 $B\in\mathscr{B}$，使得 $A\subseteq B$.

在有限论域 $U=\{x_1,x_2,\cdots,x_n\}$ 的场合，Fuzzy 自反关系 R 对应的矩阵 $R=(r_{ij})_{n\times n}$ 叫 **Fuzzy 自反矩阵**，其特征是对角线上的元素全为 1，即 $r_{ii}=1$. Fuzzy 对称关系 R 对应的矩阵 $R=(r_{ij})_{n\times n}$ 叫 **Fuzzy 对称矩阵**，其特征是所有元素关于对角线对称，即 $r_{ij}=r_{ji}$. Fuzzy 传递关系 R 对应的矩阵 $R=(r_{ij})_{n\times n}$ 叫 **Fuzzy 传递矩阵**，其特征是 $R\supseteq R\circ R=R^2$. Fuzzy 等价关系 R 对应的矩阵 $R=(r_{ij})_{n\times n}$ 叫 **Fuzzy 等价矩阵**，其特征归纳为如下的定理.

定理 3.11 Fuzzy 矩阵 $R=(r_{ij})_{n\times n}$ 是 Fuzzy 等价矩阵，当且仅当

(1) 自反性：$r_{ii}=1$.

(2) 对称性：　$r_{ij}=r_{ji}$.

(3) 传递性：　$R^2=R\circ R\subseteq R$.

例 3.21　给定 $U=\{x_1,x_2,x_3,x_4,x_5\}$ 中一个 Fuzzy 关系 R，其 Fuzzy 矩阵为

$$R=\begin{pmatrix}1 & 0.4 & 0.8 & 0.5 & 0.5\\ 0.4 & 1 & 0.4 & 0.4 & 0.4\\ 0.8 & 0.4 & 1 & 0.5 & 0.5\\ 0.5 & 0.4 & 0.5 & 1 & 0.6\\ 0.5 & 0.4 & 0.5 & 0.6 & 1\end{pmatrix}.$$

显见，$R_{ii}=1$ 且 $R_{ij}=R_{ji}$，即，R 拥有自反性和对称性. 又

$$R^2=R\circ R=\begin{pmatrix}1 & 0.4 & 0.8 & 0.5 & 0.5\\ 0.4 & 1 & 0.4 & 0.4 & 0.4\\ 0.8 & 0.4 & 1 & 0.5 & 0.5\\ 0.5 & 0.4 & 0.5 & 1 & 0.6\\ 0.5 & 0.4 & 0.5 & 0.6 & 1\end{pmatrix}=R,$$

即 R 拥有传递性. 从而 R 是 Fuzzy 等价矩阵.

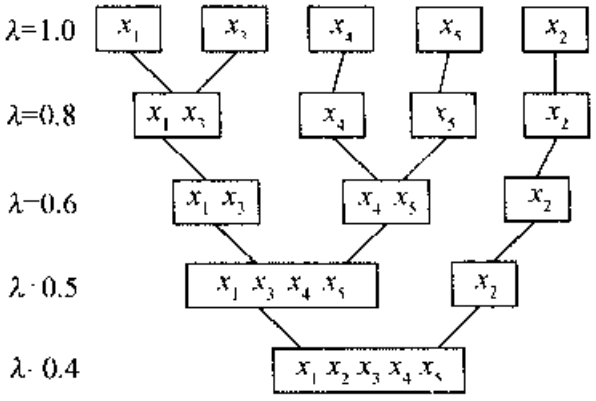


图 3.21　Fuzzy 分类

让 λ 从 0 变到 1，写出 λ 截矩阵或说 λ 截关系 R_λ，再按 R_λ 分类. 这里 x_i 和 x_j 归于同一个 R_λ 等价类当且仅当 $r_{ij}\geqslant\lambda$.

$$R_1=\begin{pmatrix}1 & 0 & 0 & 0 & 0\\ 0 & 1 & 0 & 0 & 0\\ 0 & 0 & 1 & 0 & 0\\ 0 & 0 & 0 & 1 & 0\\ 0 & 0 & 0 & 0 & 1\end{pmatrix},$$

相应的分类为

$$U/R_1 = \{\{x_1\},\{x_2\},\{x_3\},\{x_4\},\{x_5\}\}.$$

它们各自为阵,互不结盟,是最细的分类.

$$R_{0.8} = \begin{pmatrix} 1 & 0 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 1 \end{pmatrix},$$

相应的分类为

$$U/R_{0.8} = \{\{x_1,x_3\},\{x_2\},\{x_4\},\{x_5\}\}.$$

这是一个较细的分类.

$$R_{0.6} = \begin{pmatrix} 1 & 0 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & 1 \\ 0 & 0 & 0 & 1 & 1 \end{pmatrix},$$

相应的分类为

$$U/R_{0.6} = \{\{x_1,x_3\},\{x_2\},\{x_4,x_5\}\}.$$

这是一个适当的分类.

$$R_{0.5} = \begin{pmatrix} 1 & 0 & 1 & 1 & 1 \\ 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 1 & 1 & 1 \\ 1 & 0 & 1 & 1 & 1 \\ 1 & 0 & 1 & 1 & 1 \end{pmatrix},$$

相应的分类为

$$U/R_{0.5} = \{\{x_1,x_3,x_4,x_5\},\{x_2\}\}.$$

这是一个较粗的分类.

$$R_{0.4} = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \end{pmatrix},$$

相应的分类为

$$U/R_{0.4} = \{\{x_1,x_2,x_3,x_4,x_5\}\} = \{U\}.$$

这是一个最粗的分类.

所给 Fuzzy 关系 R 对论域 U 的 Fuzzy 分类动态的由粗到细的层次性由图 3.21 给出.

3.3.5 Fuzzy 相似关系与 Fuzzy 分类

实际问题中更多遇到的是弱于 Fuzzy 等价关系的 Fuzzy 相似关系,它拥有自反性和对称性,但不具备传递性.依据 Fuzzy 相似关系直接分类,往往会得出不协调的结果,比如 x_1 与 x_2 有 R_λ 关系,x_2 与 x_3 有 R_λ 关系,但 x_1 与 x_3 却无 R_λ 关系.这不符合人脑通常的思维方式.为了得到协调的分类,就须将 Fuzzy 相似关系改造成为一个 Fuzzy 等价关系.

定义 3.24 (Fuzzy 相似关系) 设 U 为论域,R 是 U 中一个 Fuzzy 关系,如果拥有

(1) 自反性: $\forall x \in U, R(x,x)=1$;

(2) 对称性: $\forall x,y \in U, R(x,y)=R(y,x)$;

则称 R 为 U 中一个 **Fuzzy 相似关系**.

在有限论域 $U=\{x_1,x_2,\cdots,x_n\}$ 的场合,U 中 Fuzzy 相似关系 R 的矩阵叫 **Fuzzy 相似矩阵**.易见,一个 Fuzzy 矩阵 $R=(r_{ij})_{n\times n}$ 是 Fuzzy 相似矩阵,当且仅当

(1) 自反性: $r_{ii}=1$;

(2) 对称性: $r_{ij}=r_{ji}$.

下面的定理给出 Fuzzy 相似矩阵的一个重要性质.

定理 3.12 若 $R=(r_{ij})_{m\times m}$ 是 Fuzzy 相似矩阵,则对任意的自然数 k,R^k 也是 Fuzzy 相似矩阵.

证明 用数学归纳法证明.

当 $k=1$ 时,$R^k=R$ 是 Fuzzy 相似矩阵.

假设当 $k=n$ 时,R^n 是 Fuzzy 相似矩阵.

以下证明当 $k=n+1$ 时,R^{n+1} 也是 Fuzzy 相似矩阵.

记 $R^n=(r_{ij}^{(n)})_{m\times n}$,$R^{n+1}=(r_{ij}^{(n+1)})_{m\times n}$,因为 $R^{n+1}=R^n\circ R$,注意到 R^n,R 是自反的,所以

$$r_{ii}^{(n+1)}=\bigvee_{p=1}^{m}(r_{ip}^{(n)}\wedge r_{pi})\geqslant r_{ii}^{(n)}\wedge r_{ii}=1,$$

从而 R^{n+1} 拥有自反性.

注意到 R^n,R 是对称的,所以

$$\begin{aligned}r_{ij}^{(n+1)}&=\bigvee_{p=1}^{m}(r_{ip}^{(n)}\wedge r_{pj})\\&=\bigvee_{p=1}^{m}(r_{pi}^{(n)}\wedge r_{jp})\end{aligned}$$

$$= \bigvee_{p=1}^{m} (r_{jp} \wedge r_{pi}^{(n)})$$
$$= r_{ji}^{(n+1)},$$

这里最后一步由结合律

$$R^{n+1} = R^n \circ R = R \circ R^n$$
$$= (\bigvee_{p=1}^{m} (r_{ip}^{(n)} \wedge r_{pj}))_{m \times m}$$
$$= (\bigvee_{p=1}^{m} (r_{ip} \wedge r_{pj}^{(n)}))_{m \times m}$$

保证. 从而 R^{n+1} 拥有对称性.

综上可见, R^{k+1} 也是 Fuzzy 相似关系.

定义 3.25 (传递闭包) 设 $R = (r_{ij})_{n \times n}$ 是 Fuzzy 矩阵. 称包含 R 的最小传递矩阵为 R 的**传递闭包**, 记为 $t(R)$.

定理 3.13 设 $R = (r_{ij})_{n \times n}$ 是 Fuzzy 矩阵, 则 $t(R) = \bigcup_{k=1}^{\infty} R^k$. 即 $\bigcup_{k=1}^{\infty} R^k$ 就是 Fuzzy 方阵 R 的传递闭包.

证明 显见, $R \subseteq \bigcup_{k=1}^{\infty} R^k$, 即 $\bigcup_{k=1}^{\infty} R^k$ 是包含 R 的. 又

$$\left(\bigcup_{k=1}^{\infty} R^k\right) \circ \left(\bigcup_{l=1}^{\infty} R^l\right) = \bigcup_{k=1}^{\infty} \left[R^k \circ \left(\bigcup_{l=1}^{\infty} R^l\right)\right]$$
$$= \bigcup_{k=1}^{\infty} \bigcup_{l=1}^{\infty} (R^k \circ R^l)$$
$$= \bigcup_{k=1}^{\infty} \bigcup_{l=1}^{\infty} R^{k+l}$$
$$= \bigcup_{m=2}^{\infty} R^m \subseteq \bigcup_{p=1}^{\infty} R^p,$$

这表明 $\bigcup_{k=1}^{\infty} R^k$ 是传递的. 从而 $\bigcup_{k=1}^{\infty} R^k$ 是包含 R 的传递矩阵.

今设 Q 是任一包含 R 的传递矩阵, 则由 $Q \subseteq Q^2$ 及 $Q \supseteq R$ 从而 $Q^2 \supseteq R^2$ 可知

$$Q \supseteq Q^2 \supseteq R^2,$$
$$Q \supseteq Q^2 \supseteq Q^3 \supseteq R^3,$$
$$Q \supseteq Q^2 \supseteq Q^3 \supseteq Q^4 \supseteq R^4,$$
$$Q \supseteq Q^2 \supseteq Q^3 \supseteq Q^4 \supseteq Q^5 \supseteq R^5,$$
$$\cdots\cdots$$

由此可知, 对任何自然数 k, 都有

$$Q \supseteq Q^k \supseteq R^k,$$

从而

$$Q \supseteq \bigcup_{k=1}^{\infty} R^k.$$

这就证明了 $\bigcup_{k=1}^{\infty} R^k$ 是包含 R 的最小传递矩阵,即 R 的传递闭包 $t(R)$.

定理 3.14 设 $R=(r_{ij})_{n\times n}$ 是 n 阶 Fuzzy 矩阵,则它的传递闭包为

$$t(R)=\bigcup_{k=1}^{n} R^k.$$

证明 先证

$$R^{n+1} \subseteq \bigcup_{k=1}^{n} R^k.$$

设

$$R^k=(r_{ij}^{(k)})_{n\times n} \qquad (k=1,2,\cdots,n,n+1),$$

这里

$$r_{ij}^{(1)}=r_{ij} \quad (i=1,2,\cdots,n;j=1,2,\cdots,n),$$

只须证明

$$r_{ij}^{(n+1)} \leqslant \bigvee_{k=1}^{n} r_{ij}^{(k)} \qquad (i,j=1,2,\cdots,n).$$

由 Fuzzy 矩阵的合成运算得

$$\begin{aligned} r_{ij}^{(n+1)} &= \bigvee_{m_1=1}^{n}(r_{im_1}^{(1)} \wedge r_{m_1j}^{(n)}) \\ &= \bigvee_{m_1=1}^{n}\left\{r_{im_1} \wedge \left[\bigvee_{m_2=1}^{n}(r_{m_1m_2} \wedge r_{m_2j}^{(n-1)})\right]\right\} \\ &= \bigvee_{m_1=1}^{n}\bigvee_{m_2=1}^{n}(r_{im_1} \wedge r_{m_1m_2} \wedge r_{m_2j}^{(n-1)}) \\ &= \bigvee_{m_1=1}^{n}\bigvee_{m_2=1}^{n}\cdots\bigvee_{m_n=1}^{n}(r_{im_1} \wedge r_{m_1m_2} \wedge \cdots \wedge r_{m_nj}) \\ &= r_{iI_1} \wedge r_{I_1I_2} \wedge \cdots \wedge r_{I_nj}, \end{aligned}$$

必有 $\{I_1,I_2,\cdots,I_n\} \subseteq \{1,2,\cdots,n\}$ 使上式成立. 这样在 $\{1,2,\cdots,n\}$ 内的 $n+1$ 个数 $i,I_1,I_2,\cdots,I_n$ 中至少有两个彼此相等. 如果 $I_h=I_g$,这里 $1\leqslant h\leqslant g\leqslant n$,则

$$r_{ij}^{(n+1)} \leqslant r_{iI_1} \wedge \cdots \wedge r_{I_{h-1}I_h} \wedge r_{I_gI_{g+1}} \wedge \cdots \wedge r_{I_nj} \leqslant r_{ij}^{(p)},$$

其中 $p=n+1-(g-h)\leqslant n$. 如果 $i=I_h$,这里 $1\leqslant h\leqslant n$,则

$$r_{ij}^{(n+1)} \leqslant r_{I_hI_{h+1}} \wedge r_{I_{h+1}I_{h+2}} \wedge \cdots \wedge r_{I_nj} \leqslant r_{ij}^{(p)},$$

其中 $p=n+1-h\leqslant n$. 这样,我们证明了必有自然数 p 满足 $1\leqslant p\leqslant n$,使得 $r_{ij}^{(n+1)}\leqslant r_{ij}^{(p)}$. 从而 $r_{ij}^{(n+1)}\leqslant \bigvee_{k=1}^{n} r_{ij}^{(k)}$,所以 $R^{n+1}\subseteq \bigcup_{k=1}^{n} R^k$.

于是当 $I\geqslant n+1$ 时也有

$$R^l \subseteq \bigcup_{k=1}^{n} R^k,$$

从而 $t(R)=\bigcup_{k=1}^{n} R^k$.

定理 3.15 设 $R=(r_{ij})_{n\times n}$是 Fuzzy 相似矩阵,则存在自然数 $k\leqslant n$,使

$$t(R) = R^k,$$

且对一切大于 k 的自然数 l,有

$$R^l = R^k.$$

证明 因为 R 是 Fuzzy 相似矩阵,所以 $r_{ij}=1$,于是

$$r_{ij}^{(2)} = \bigvee_{j_1=1}^{n}(r_{ij_1} \wedge r_{j_1 j}) \geqslant r_{ii} \wedge r_{ij} = r_{ij},$$

所以 $R\subseteq R^2$. 再利用 Fuzzy 矩阵合成运算的性质得

$$R^3 = R^2 \circ R \supseteq R \circ R = R^2,$$

$$R^p = R^{p-2} \circ R^2 \supseteq R^{p-2} \circ R = R^{p-1},$$

于是

$$R \subseteq R^2 \subseteq R^3 \subseteq \cdots \subseteq R^{p-1} \subseteq R^p \subseteq \cdots$$

即$(R^p \mid p\in \mathbf{N})$是非降的矩阵序列. 于是结合定理 3.14,便有

$$t(R) = \bigcup_{m=1}^{n} R^m = R^n.$$

进一步地,由于 n 是一个有限的自然数,$(R^p \mid p\in \mathbf{N})$是一个非降的矩阵序列,所以必有自然数 $k\leqslant n$ 使 $t(R)=R^k$(当非降矩阵序列 $R\subseteq R^2\subseteq R^3\subseteq\cdots\subseteq R^{p-1}\subseteq R^p\subseteq\cdots$从某个 $i\leqslant n$ 起,$R^i=R^{i+1}=R^{i+2}=\cdots=R^n$ 时,则取 $k=i$).

对于大于 k 的任一自然数 l

$$t(R) = R^k \subseteq R^l \subseteq \bigcup_{m=1}^{\infty} R^m = t(R),$$

从而 $R^l=R^k$.

在定理 3.15 中,由于 R 是 Fuzzy 相似矩阵,由定理 3.12 知,R^k 仍是 Fuzzy 相似矩阵. 而 $t(R)=R^k$ 又是包含 R 的最小传递矩阵,所以 $t(R)=R^k$ 就是包含 R 的最小 Fuzzy 等价矩阵. 这就是说,一个 Fuzzy 相似矩阵 R 的传递闭包 $t(R)=R^k(k\leqslant n)$是包含 R 的最小 Fuzzy 等价矩阵.

定理 3.16 一个 n 阶 Fuzzy 相似矩阵 R 的传递闭包

$$t(R) = R^k \qquad (k \leqslant n)$$

是包含 R 的最小 Fuzzy 等价矩阵.

以上讨论说明,从一个 Fuzzy 相似矩阵 R 出发,可以利用求传递闭包的方法构造一个 Fuzzy 等价矩阵,从而达到 Fuzzy 分类的目的.

为了运算方便和迅速,通常采用**平方法**

$$R \to R^2 \to R^4 \to \cdots \to R^{2^p} \to \cdots$$

经过有限次运算后，一定存在 $k\in\mathbf{N}$ 使得

$$R^{2^k}=R^{2^{k+1}}.$$

于是得到一个 Fuzzy 等价矩阵

$$R^*=t(R)=R^{2^k}=R^{2^{k+1}},$$

由此可以实施协调的 Fuzzy 分类.

例 3.22 设

$$R=\begin{pmatrix}1 & 0.2 & 0.5\\ 0.2 & 1 & 0.7\\ 0.5 & 0.7 & 1\end{pmatrix},$$

它是一个 Fuzzy 相似矩阵，求 R^*.

解 易见

$$R^2=R\circ R=\begin{pmatrix}1 & 0.5 & 0.5\\ 0.5 & 1 & 0.7\\ 0.5 & 0.7 & 1\end{pmatrix},$$

由于 $R^2\neq R$，所以 R 不是 Fuzzy 等价矩阵. 但

$$R^4=R^2\circ R^2=\begin{pmatrix}1 & 0.5 & 0.5\\ 0.5 & 1 & 0.7\\ 0.5 & 0.7 & 1\end{pmatrix}=R^2,$$

从而 $R^*=R^2=R^4$.

例 3.23 设 $U=\{x_1,x_2,x_3,x_4,x_5\}$ 中 Fuzzy 关系 R 的矩阵为

$$R=\begin{pmatrix}1 & 0.8 & 0 & 0.1 & 0.2\\ 0.8 & 1 & 0.4 & 0 & 0.9\\ 0 & 0.4 & 1 & 0 & 0\\ 0.1 & 0 & 0 & 1 & 0.5\\ 0.2 & 0.9 & 0 & 0.5 & 1\end{pmatrix},$$

易见它是 Fuzzy 相似矩阵，但非 Fuzzy 等价矩阵.

如果依此 Fuzzy 相似关系 R 对 U 分类，那么当 $\lambda=0.8$ 时，x_1 与 x_2 属于同一类，x_2 与 x_5 属于同一类，但 x_1 与 x_5 不属于同一类. 这是一种不协调的分类. 因此，由 Fuzzy 相似关系不能直接分类，而应将 Fuzzy 相似关系改造成 Fuzzy 等价关系才能恰当地进行分类.

计算可知

$$R^2 = R \circ R = \begin{pmatrix} 1 & 0.8 & 0.4 & 0.2 & 0.8 \\ 0.8 & 1 & 0.4 & 0.5 & 0.9 \\ 0.4 & 0.4 & 1 & 0 & 0.4 \\ 0.2 & 0.5 & 0 & 1 & 0.5 \\ 0.8 & 0.9 & 0.4 & 0.5 & 1 \end{pmatrix} \not\subseteq R,$$

$$R^4 = R^2 \circ R^2 = \begin{pmatrix} 1 & 0.8 & 0.4 & 0.5 & 0.8 \\ 0.8 & 1 & 0.4 & 0.5 & 0.9 \\ 0.4 & 0.4 & 1 & 0.4 & 0.4 \\ 0.5 & 0.5 & 0.4 & 1 & 0.5 \\ 0.8 & 0.9 & 0.4 & 0.5 & 1 \end{pmatrix} \not\subseteq R^2,$$

$$R^8 = R^4 \circ R^4 = \begin{pmatrix} 1 & 0.8 & 0.4 & 0.5 & 0.8 \\ 0.8 & 1 & 0.4 & 0.5 & 0.9 \\ 0.4 & 0.4 & 1 & 0.4 & 0.4 \\ 0.5 & 0.5 & 0.4 & 1 & 0.5 \\ 0.8 & 0.9 & 0.4 & 0.5 & 1 \end{pmatrix} = R^4,$$

于是选定 $R^* = R^4 = R^8$ 为 Fuzzy 等价关系.由此开始进行分类.

当取 $\lambda = 0.8$ 时,R^* 的 λ 截等价关系为

$$R^*_{0.8} = \begin{pmatrix} 1 & 1 & 0 & 0 & 1 \\ 1 & 1 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 \\ 1 & 1 & 0 & 0 & 1 \end{pmatrix}.$$

这时对 U 的分类为

$$U/R^*_{0.8} = \{\{x_1, x_2, x_5\}, \{x_3\}, \{x_4\}\}.$$

例 3.24 设 $U = \{x_1, x_2, x_3, x_4, x_5, x_6, x_7\}$,$R$ 是 U 中一个 Fuzzy 相似关系,R 对应的 Fuzzy 相似矩阵为

$$R = \begin{pmatrix} 1 & 0 & 0.1 & 0 & 0.8 & 1 & 0.6 \\ 0 & 1 & 0 & 1 & 0 & 0.8 & 1 \\ 0.1 & 0 & 1 & 0.7 & 0.6 & 0 & 0.1 \\ 0 & 1 & 0.7 & 1 & 0 & 0.9 & 0 \\ 0.8 & 0 & 0.6 & 0 & 1 & 0.7 & 0.5 \\ 1 & 0.8 & 0 & 0.9 & 0.7 & 1 & 0.4 \\ 0.6 & 1 & 0.1 & 0 & 0.5 & 0.4 & 1 \end{pmatrix},$$

试对 U 进行分类.

解 先由 R 求 Fuzzy 等价关系.

$$R^2 = R \circ R = \begin{pmatrix} 1 & 0.8 & 0.6 & 0.9 & 0.8 & 1 & 0.6 \\ 0.8 & 1 & 0.7 & 1 & 0.7 & 0.9 & 1 \\ 0.6 & 0.7 & 1 & 0.7 & 0.6 & 0.7 & 0.5 \\ 0.9 & 1 & 0.7 & 1 & 0.7 & 0.9 & 1 \\ 0.8 & 0.7 & 0.6 & 0.7 & 1 & 0.8 & 0.6 \\ 1 & 0.9 & 0.7 & 0.9 & 0.8 & 1 & 0.8 \\ 0.6 & 1 & 0.5 & 1 & 0.6 & 0.8 & 1 \end{pmatrix} \not\subseteq R,$$

$$R^4 = R^2 \circ R^2 = \begin{pmatrix} 1 & 0.9 & 0.7 & 0.9 & 0.8 & 1 & 0.9 \\ 0.9 & 1 & 0.7 & 1 & 0.8 & 0.9 & 1 \\ 0.7 & 0.7 & 1 & 0.7 & 0.7 & 0.7 & 0.7 \\ 0.9 & 1 & 0.7 & 1 & 0.8 & 0.9 & 1 \\ 0.8 & 0.8 & 0.7 & 0.8 & 1 & 0.8 & 0.8 \\ 1 & 0.9 & 0.7 & 0.9 & 0.8 & 1 & 0.9 \\ 0.9 & 1 & 0.7 & 1 & 0.8 & 0.9 & 1 \end{pmatrix} \not\subseteq R^2,$$

$$R^8 = R^4 \circ R^4 = \begin{pmatrix} 1 & 0.9 & 0.7 & 0.9 & 0.8 & 1 & 0.9 \\ 0.9 & 1 & 0.7 & 1 & 0.8 & 0.9 & 1 \\ 0.7 & 0.7 & 1 & 0.7 & 0.7 & 0.7 & 0.7 \\ 0.9 & 1 & 0.7 & 1 & 0.8 & 0.9 & 1 \\ 0.8 & 0.8 & 0.7 & 0.8 & 1 & 0.8 & 0.8 \\ 1 & 0.9 & 0.7 & 0.9 & 0.8 & 1 & 0.9 \\ 0.9 & 1 & 0.7 & 1 & 0.8 & 0.9 & 1 \end{pmatrix} = R^4,$$

所以 $R^* = t(R) = R^4 = R^8$.

R^4 是 U 中一个 Fuzzy 等价关系,利用它可以对 U 进行分类. 当 $\lambda_0 = 1$ 时,U 可分为如下 7 类

$$U/R^*_{\lambda_0} = \{\{x_1\},\{x_2\},\{x_3\},\{x_4\},\{x_5\},\{x_6\},\{x_7\}\}.$$

当 $0.9<\lambda_1<1$ 时,U 可分为如下四类

$$U/R^*_{\lambda_1} = \{\{x_1,x_4\},\{x_2,x_6,x_7\},\{x_3\},\{x_5\}\}.$$

当 $0.8<\lambda_2\leqslant 0.9$ 时,U 可分为如下三类

$$U/R^*_{\lambda_2} = \{\{x_1,x_2,x_4,x_6,x_7\},\{x_3\},\{x_5\}\}.$$

当 $0.7<\lambda_3\leqslant 0.8$ 时,U 可分如下二类

$$U/R^*_{\lambda_3} = \{\{x_1,x_2,x_4,x_5,x_6,x_7\},\{x_3\}\}.$$

当 $0\leqslant\lambda_4\leqslant 0.7$ 时,U 可分为一类

$$U/R^*_{\lambda_4} = \{\{x_1,x_2,x_3,x_4,x_5,x_6,x_7\}\} = \{U\}.$$

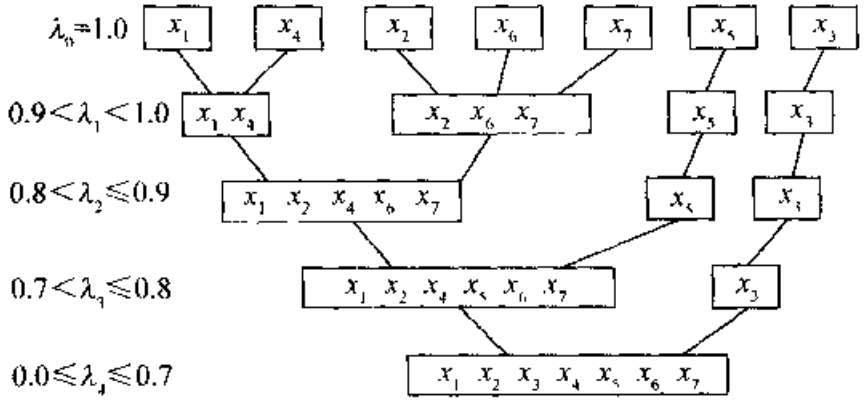


图 3.22 基于 Fuzzy 相似关系的传递闭包的 Fuzzy 分类

3.3.6 Fuzzy 相似矩阵的确定

设 $U=\{x_1, x_2, \cdots, x_n\}$ 为论域，它是待分类对象的集合，其每个元素 x_i 有 m 个特征，这些特征表为一组数据，可简记为

$$x_i = (x_{i1}, x_{i2}, \cdots, x_{im}).$$

为实现 Fuzzy 分类，首先要确定 U 中的 Fuzzy 相似关系 R，为此只要确定相应的 Fuzzy 相似矩阵 $R=(r_{ij})_{n\times n}$，也即确定矩阵 R 的元素 r_{ij}，称 r_{ij} 为 x_i 与 x_j 的**相似系数**，它表达 x_i 与 x_j 的相似程度，用 Fuzzy 关系的语言来说，即 $R(x_i, x_j)=r_{ij}$.

以下给出求相似系数的若干常用方法.

方法 1 数量积法

$$r_{ij}=\begin{cases}1, & i=j,\\ \dfrac{1}{M}\displaystyle\sum_{k=1}^{m}x_{ik}x_{jk}, & i\neq j,\end{cases}$$

其中 $M=\max\limits_{i\neq j}\left(\sum\limits_{k=1}^{m}x_{ik}x_{jk}\right)$. 如果 r_{ij} 中出现负值，则将全部 r_{ij} 同时调整，方法为：取 $\hat{r}_{ij}=\dfrac{r_{ij}+1}{2}$，则 $\hat{r}_{ij}\in[0,1]$.

方法 2 夹角余弦法

$$r_{ij}=\frac{\displaystyle\sum_{k=1}^{m}x_{ik}x_{jk}}{\sqrt{\displaystyle\sum_{k=1}^{m}x_{ik}^2}\sqrt{\displaystyle\sum_{k=1}^{m}x_{jk}^2}},$$

如果 r_{ij} 出现负值，也可以用上面方法调整.

方法 3 相关系数法

$$r_{ij}=\frac{\sum_{k=1}^{m}|x_{ik}-\bar{x}_i||x_{jk}-\bar{x}_j|}{\sqrt{\sum_{k=1}^{m}(x_{ik}-\bar{x}_i)^2}\sqrt{\sum_{k=1}^{m}(x_{jk}-\bar{x}_j)^2}},$$

其中 $\bar{x}_i=\frac{1}{m}\sum_{k=1}^{m}x_{ik}$, $\bar{x}_j=\frac{1}{m}\sum_{k=1}^{m}x_{jk}$.

方法 4 最大最小法

$$r_{ij}=\frac{\sum_{k=1}^{m}(x_{ik}\wedge x_{jk})}{\sum_{k=1}^{m}(x_{ik}\vee x_{jk})}.$$

方法 5 算术平均最小法

$$r_{ij}=\frac{\sum_{k=1}^{m}(x_{ik}\wedge x_{jk})}{\frac{1}{2}\sum_{k=1}^{m}(x_{ik}+x_{jk})}.$$

方法 6 几何平均最小法

$$r_{ij}=\frac{\sum_{k=1}^{m}(x_{ik}\wedge x_{jk})}{\sum_{k=1}^{m}\sqrt{x_{ik}x_{jk}}}.$$

方法 7 绝对值指数法

$$r_{ij}=e^{-\sum_{k=1}^{m}|x_{ik}-x_{jk}|}.$$

方法 8 绝对值倒数法

$$r_{ij}=\begin{cases}1, & i=j,\\ \dfrac{M}{\sum_{k=1}^{m}|x_{ik}-x_{jk}|}, & i\neq j,\end{cases}$$

其中 M 适当选取,使得 $r_{ij}\in[0,1]$.

方法 9 绝对值减数法

$$r_{ij}=\begin{cases}1, & i=j,\\ 1-c\sum_{k=1}^{m}|x_{ik}-x_{jk}|, & i\neq j,\end{cases}$$

其中 c 适当选取,使得 $r_{ij}\in[0,1]$.

方法 10 Euclid 距离法

$$r_{ij}=\sqrt{\frac{1}{m}\sum_{k=1}^{m}(x_{ik}-x_{jk})^2}.$$

例 3.25 环境单元的 Fuzzy 分类.

环境的污染状况是人们极为关心的问题,因为环境的优劣对人的健康和正常生活是很重要的,环境的分类将是我们必须解决的问题.

设论域为 5 个环境单元的集合,即

$$U=\{\text{Ⅰ},\text{Ⅱ},\text{Ⅲ},\text{Ⅳ},\text{Ⅴ}\}$$

关于各环境单元,考虑空气,水分,土壤,和作物等 4 个基本要素,环境单元的污染状况由污染物在 4 要素中含量的超限度加以描述.假设 U 中 5 个单元经测量所得的污染数据按空气,水分,土壤,作物为序排列如下

第Ⅰ单元:$(x_{11},x_{12},x_{13},x_{14})=(5,5,3,2)$,

第Ⅱ单元:$(x_{21},x_{22},x_{23},x_{24})=(2,3,4,5)$,

第Ⅲ单元:$(x_{31},x_{32},x_{33},x_{34})=(5,5,2,3)$,

第Ⅳ单元:$(x_{41},x_{42},x_{43},x_{44})=(1,5,3,1)$,

第Ⅴ单元:$(x_{51},x_{52},x_{53},x_{54})=(2,4,5,1)$.

按绝对值减数法确定相似系数

$$r_{ij}=\begin{cases}1, & i=j,\\ 1-c\sum\limits_{k=1}^{m}|x_{ik}-x_{jk}|, & i\neq j,\end{cases}$$

其中 $i,j=1,2,3,4,5;m=4$;并选取 $c=0.1$. 计算可得

$$\begin{aligned}r_{11}&=1,\\ r_{12}&=1-c\times(|x_{11}-x_{21}|+|x_{12}-x_{22}|+|x_{13}-x_{23}|+|x_{14}-x_{24}|)\\ &=1-0.1\times(|5-2|+|5-3|+|3-4|+|2-5|)\\ &=0.1,\\ &\cdots\\ r_{45}&=1-0.1\times(|1-2|+|5-4|+|3-5|+|1-1|)\\ &=0.6,\\ r_{55}&=1.\end{aligned}$$

于是得到 Fuzzy 关系矩阵

$$R=(r_{ij})_{5\times5}=\begin{pmatrix}1 & 0.1 & 0.8 & 0.5 & 0.3\\ 0.1 & 1 & 0.1 & 0.2 & 0.4\\ 0.8 & 0.1 & 1 & 0.3 & 0.1\\ 0.5 & 0.2 & 0.3 & 1 & 0.6\\ 0.3 & 0.4 & 0.1 & 0.6 & 1\end{pmatrix}.$$

不难看出,R 拥有自反性和对称性,是一个 Fuzzy 相似矩阵.但不满足传递性,不是 Fuzzy 等价矩阵.因而不能直接进行 Fuzzy 分类,必须将其改造成为 Fuzzy 等价矩阵.

$$R^2 = R \circ R = \begin{pmatrix} 1 & 0.3 & 0.8 & 0.5 & 0.5 \\ 0.3 & 1 & 0.2 & 0.4 & 0.4 \\ 0.8 & 0.2 & 1 & 0.5 & 0.3 \\ 0.5 & 0.4 & 0.5 & 1 & 0.6 \\ 0.5 & 0.4 & 0.3 & 0.6 & 1 \end{pmatrix} \not\subseteq R,$$

$$R^4 = R^2 \circ R^2 = \begin{pmatrix} 1 & 0.4 & 0.8 & 0.5 & 0.5 \\ 0.4 & 1 & 0.4 & 0.4 & 0.4 \\ 0.8 & 0.4 & 1 & 0.5 & 0.5 \\ 0.5 & 0.4 & 0.5 & 1 & 0.6 \\ 0.5 & 0.4 & 0.5 & 0.6 & 1 \end{pmatrix} \not\subseteq R^2,$$

$$R^8 = R^4 \circ R^4 = \begin{pmatrix} 1 & 0.4 & 0.8 & 0.5 & 0.5 \\ 0.4 & 1 & 0.4 & 0.4 & 0.4 \\ 0.8 & 0.4 & 1 & 0.5 & 0.5 \\ 0.5 & 0.4 & 0.5 & 1 & 0.6 \\ 0.5 & 0.4 & 0.5 & 0.6 & 1 \end{pmatrix} = R^4.$$

因此取 $R^* = t(R) = R^4$. 由此可以进行分类

$$U/R_1^* = \{\{\mathrm{I}\},\{\mathrm{II}\},\{\mathrm{III}\},\{\mathrm{IV}\},\{\mathrm{V}\}\},$$

$$U/R_{0.8}^* = \{\{\mathrm{I},\mathrm{III}\},\{\mathrm{II}\},\{\mathrm{IV}\},\{\mathrm{V}\}\},$$

$$U/R_{0.6}^* = \{\{\mathrm{I},\mathrm{III}\},\{\mathrm{II}\},\{\mathrm{IV},\mathrm{V}\}\},$$

$$U/R_{0.5}^* = \{\{\mathrm{I},\mathrm{II},\mathrm{IV},\mathrm{V}\},\{\mathrm{III}\}\},$$

$$U/R_{0.4}^* = \{\{\mathrm{I},\mathrm{II},\mathrm{III},\mathrm{IV},\mathrm{V}\}\}.$$

比较各个层次的分类可见,U/R_1^* 和 $U/R_{0.8}^*$ 太细,$U/R_{0.5}^*$ 和 $U/R_{0.4}^*$ 太粗,$U/R_{0.6}^*$ 粗细适当,是一个可供采用的分类.

例 3.26 刀具材料分类

刀具是在很大的切削力和很高的切削温度下工作,并与切屑、工作表面之间不断发生摩擦,因此,刀具材料必须具有一定的切削性能,这种切削性能可用刀具的耐用度(如硬度、强度等性能指标)加以综合反映.这里,选择国内最新生产的 20 种硬质合金刀具材料作为样本,根据 ISO 组织规定的硬质合金性能指标进行 Fuzzy 分类.

为了便于分析和比较,首先要对各项性能指标的原始数据进行标准化处理,将数据压缩到[0,1]闭区间,可采用极值标准化公式

$$x = \frac{x' - x_{\min}}{x_{\max} - x_{\min}},$$

其中 x' 为原始数据，当 $x' = x'_{\max}$ 时，$x = 1$；当 $x' = x'_{\min}$ 时，$x = 0$.

刀具材料样本指标的原始数据及其标准化处理列于表 3.13.

表 3.13 刀具材料样本指标的原始数据及其标准化

样本	刀具牌号	指标原始数据			标准化		
		硬 度 (HRA)	强 度 (10MPa)	密 度 (10^3kg/m^3)	硬度	强度	密度
1	600	93.5	100	14.75	1	0	0.87
2	610	93.0	120	14.65	0.89	0.17	0.83
3	643	93.0	150	13.65	0.89	0.42	0.50
4	726	92.0	140	14.05	0.67	0.33	0.63
5	767	91.5	150	13.50	0.56	0.42	0.45
6	707	92.0	140	12.15	0.67	0.33	0
7	798	91.0	150	12.15	0.44	0.42	0
8	758	91.5	145	13.25	0.56	0.38	0.37
9	YG_3X	91.5	110	15.15	0.56	0.08	1
10	YG_6A	91.5	140	14.8	0.56	0.33	0.88
11	YG_6X	91.0	140	14.8	0.44	0.33	0.88
12	YG_6	89.6	145	14.8	0.13	0.38	0.88
13	YG_8	89.0	150	14.7	0	0.42	0.85
14	YG_8N	89.5	150	14.7	0.11	0.42	0.85
15	$YG_{10}H$	91.5	220	14.4	0.56	1	0.75
16	$YGRM$	92.0	180	15.0	0.67	0.67	0.95
17	YG_8W	92.0	200	14.7	0.67	0.83	0.85
18	YH_1	93.1	190	13.3	0.91	0.75	0.72
19	YH_2	93.3	185	14.0	0.96	0.71	0.62
20	YH_3	93.3	175	14.05	0.96	0.63	0.63

然后，采用夹角余弦法计算相似系数 r_{ij}，得到 Fuzzy 相似矩阵 R.

$$R=\begin{bmatrix}
1\\
0.99\ 1\\
0.91\ 0.94\ 1\\
0.94\ 0.98\ 0.97\ 1\\
0.96\ 0.92\ 0.98\ 0.98\ 1\\
0.68\ 0.71\ 0.89\ 0.76\ 0.83\ 1\\
0.55\ 0.62\ 0.85\ 0.73\ 0.84\ 0.95\ 1\\
0.89\ 0.94\ 1 & 0.98\ 0.99\ 0.87\ 0.85\ 1\\
0.94\ 0.95\ 0.81\ 0.92\ 0.83\ 0.41\ 0.40\ 0.83\ 1\\
0.91\ 0.96\ 0.89\ 0.97\ 0.93\ 0.59\ 0.58\ 0.91\ 0.97\ 1\\
0.88\ 0.92\ 0.85\ 0.94\ 0.90\ 0.52\ 0.53\ 0.88\ 0.97\ 1 & 1\\
0.70\ 0.77\ 0.67\ 0.81\ 0.78\ 0.29\ 0.37\ 0.72\ 0.88\ 0.92\ 0.95\ 1\\
0.59\ 0.67\ 0.57\ 0.73\ 0.71\ 0.20\ 0.31\ 0.64\ 0.81\ 0.85\ 0.90\ 0.99\ 1\\
0.67\ 0.75\ 0.66\ 0.80\ 0.78\ 0.30\ 0.39\ 0.72\ 0.86\ 0.91\ 0.94\ 1 & 0.99\ 1\\
0.67\ 0.77\ 0.86\ 0.88\ 0.94\ 0.69\ 0.80\ 0.90\ 0.73\ 0.88\ 0.87\ 0.84\ 0.81\ 0.86\ 1\\
0.84\ 0.91\ 0.91\ 0.97\ 0.97\ 0.67\ 0.70\ 0.94\ 0.89\ 0.96\ 0.97\ 0.91\ 0.86\ 0.91\ 0.96\ 1\\
0.78\ 0.86\ 0.91\ 0.94\ 0.97\ 0.71\ 0.78\ 0.94\ 0.82\ 0.94\ 0.93\ 0.87\ 0.83\ 0.88\ 0.99\ 0.99\ 1\\
0.84\ 0.90\ 0.97\ 0.97\ 1 & 0.83\ 0.85\ 0.99\ 0.87\ 0.92\ 0.87\ 0.78\ 0.71\ 0.78\ 0.95\ 0.97\ 0.98\ 1\\
0.84\ 0.90\ 0.98\ 0.96\ 1 & 0.87\ 0.88\ 1 & 0.79\ 0.90\ 0.86\ 0.72\ 0.65\ 0.72\ 0.93\ 0.95\ 0.96\ 1 & 1\\
0.87\ 0.92\ 0.99\ 0.98\ 1 & 0.87\ 0.86\ 1 & 0.81\ 0.91\ 0.87\ 0.73\ 0.64\ 0.72\ 0.91\ 0.95\ 0.99\ 0.95\ 1 & 1
\end{bmatrix}$$

再用求传递闭包的方法将 Fuzzy 相似矩阵 R 变换为 Fuzzy 等价矩阵 R^*.

$$R^*=\begin{bmatrix}
1\\
0.99\ 1\\
0.98\ 0.98\ 1\\
0.98\ 0.98\ 0.98\ 1\\
0.98\ 0.98\ 1 & 0.98\ 1\\
0.89\ 0.89\ 0.89\ 0.89\ 0.89\ 1\\
0.89\ 0.89\ 0.89\ 0.89\ 0.89\ 0.95\ 1\\
0.98\ 0.98\ 1 & 0.98\ 1 & 0.89\ 0.89\ 1\\
0.97\ 0.97\ 0.97\ 0.97\ 0.97\ 0.89\ 0.89\ 0.97\ 1\\
0.98\ 0.98\ 0.98\ 0.98\ 0.98\ 0.89\ 0.87\ 0.98\ 0.97\ 1\\
0.98\ 0.98\ 0.98\ 0.98\ 0.98\ 0.89\ 0.89\ 0.98\ 0.97\ 1 & 1\\
0.95\ 0.95\ 0.95\ 0.95\ 0.95\ 0.89\ 0.89\ 0.95\ 0.95\ 0.95\ 0.95\ 1\\
0.95\ 0.95\ 0.95\ 0.95\ 0.95\ 0.89\ 0.89\ 0.95\ 0.95\ 0.95\ 0.95\ 0.99\ 1\\
0.95\ 0.95\ 0.95\ 0.95\ 0.95\ 0.89\ 0.89\ 0.95\ 0.95\ 0.95\ 0.95\ 1 & 0.99\ 1\\
0.98\ 0.98\ 0.98\ 0.98\ 0.98\ 0.89\ 0.89\ 0.98\ 0.97\ 0.98\ 0.98\ 0.95\ 0.95\ 0.95\ 1\\
0.98\ 0.98\ 0.98\ 0.98\ 0.98\ 0.89\ 0.89\ 0.98\ 0.97\ 0.98\ 0.98\ 0.95\ 0.95\ 0.95\ 0.99\ 1\\
0.98\ 0.98\ 0.98\ 0.98\ 0.98\ 0.89\ 0.89\ 0.98\ 0.97\ 0.98\ 0.98\ 0.95\ 0.95\ 0.95\ 0.99\ 0.99\ 1\\
0.98\ 0.98\ 1 & 0.98\ 1 & 0.89\ 0.89\ 1 & 0.97\ 0.98\ 0.98\ 0.95\ 0.95\ 0.95\ 0.98\ 0.98\ 0.98\ 1\\
0.98\ 0.98\ 1 & 0.98\ 1 & 0.89\ 0.89\ 1 & 0.97\ 0.98\ 0.98\ 0.95\ 0.95\ 0.95\ 0.98\ 0.98\ 0.98\ 1 & 1\\
0.98\ 0.98\ 1 & 0.98\ 1 & 0.89\ 0.89\ 1 & 0.97\ 0.98\ 0.98\ 0.95\ 0.95\ 0.95\ 0.98\ 0.98\ 0.98\ 1 & 1 & 1
\end{bmatrix}$$

最后,对 R^* 分别取 $\lambda=1,0.99,0.98,0.96$ 和 0.92 时的截矩阵,作出各层次的分类,并绘成动态 Fuzzy 分类图,如图 3.23 所示.

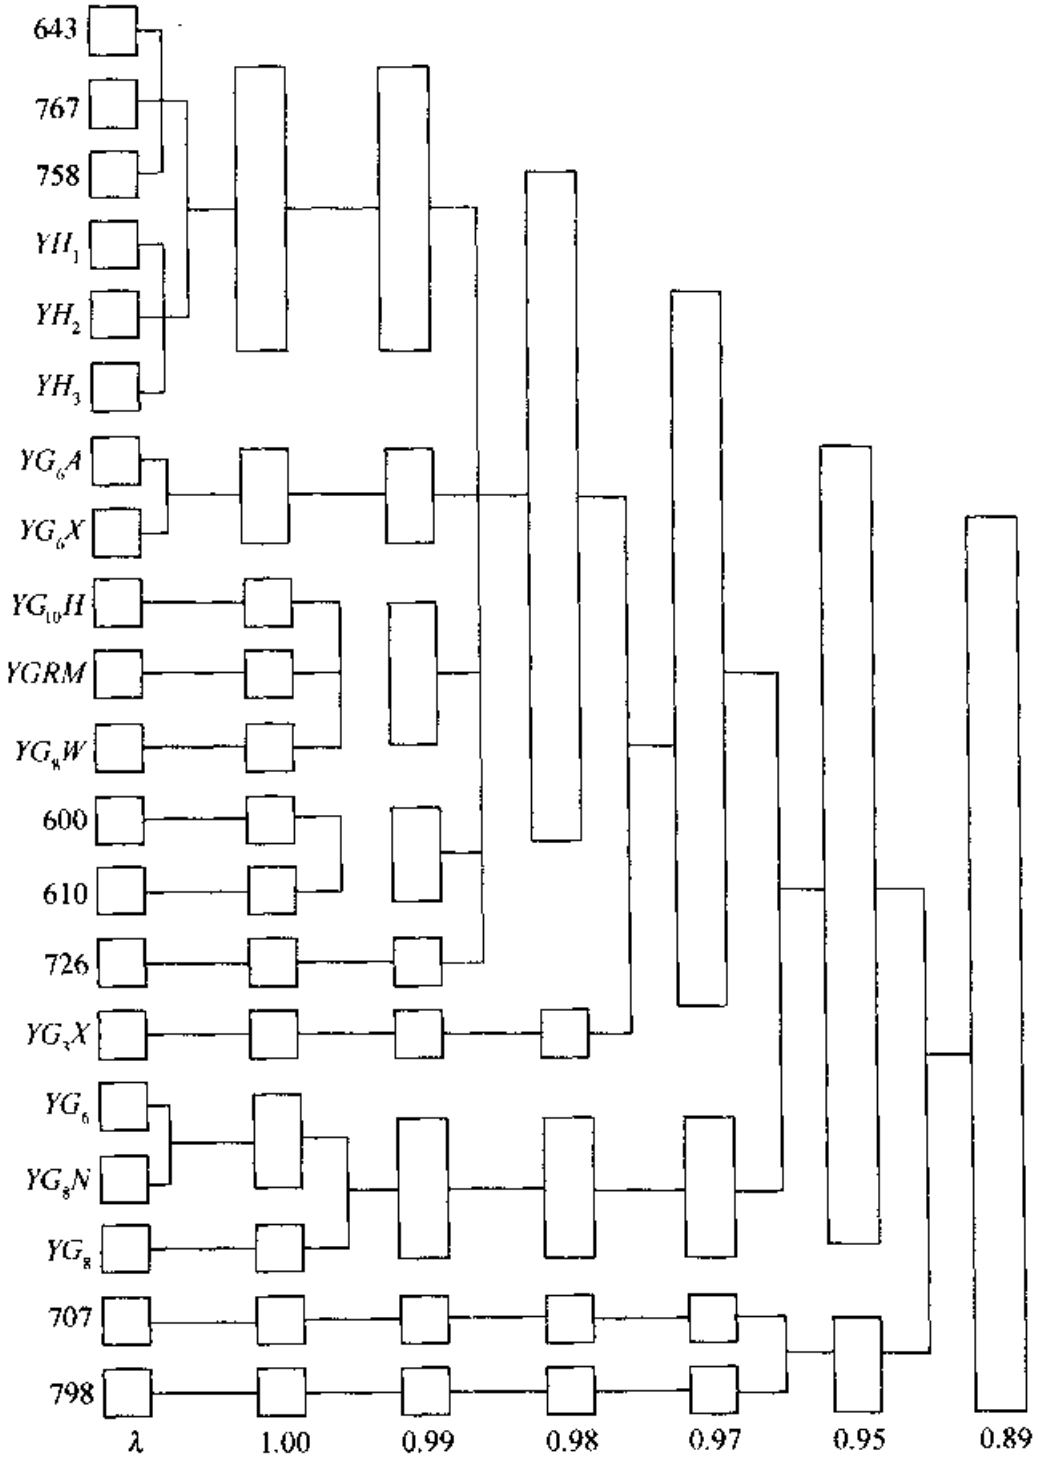


图 3.23 刀具材料 Fuzzy 分类动态图

通过对已知切削性能的刀具材料进行 Fuzzy 分类构成若干组别之后，还可采用 Fuzzy 模式识别的方法对新型刀具材料进行识别和预测.

§3.4 Fuzzy 推理的各种模型

Fuzzy 推理是模拟人脑日常推理方式的一种近似推理,它是蓬勃发展中的 Fuzzy 控制技术的数学核心.1973 年,L.A.Zadeh 首次提出 Fuzzy 推理的基本框架.1974 年,英国科学家 E.H.Mamdani 首次将 Fuzzy 推理技术应用于工业自动控制并获成功.20 世纪 80 年代末,随着计算机技术的飞速发展,Fuzzy 控制技术得以广泛应用并获蓬勃发展.90 年代,基于 Fuzzy 推理的 Fuzzy 控制在全球蔚为大观.

Fuzzy 控制技术其基本出发点是,将人类积累的对复杂系统的经验和认识提炼出来,采用 Fuzzy 控制器的形式来控制复杂系统,从而把人类从繁重的劳动中解放出来.

Fuzzy 推理有多种模型.其中许多模型都可以转化为一种最基本的模型——简单 Fuzzy 推理模型.

3.4.1 简单 Fuzzy 推理模型

经典逻辑最基本的推理规则为

$$\{A \to B, A\} \vdash B,$$

叫作 **Modus Ponens**,简称 **MP 规则**.也常表达为如下的推理模型

$$\frac{A \to B}{\quad A \quad}$$
$$B$$

它只受理小前提 A 与大前提 $A \to B$ 的前件 A 完全重合的情形,这时给出结论 B.如果小前提 A^* 与大前提 $A \to B$ 的前件 A 不完全重合,则拒绝受理.

如果将此模型看作一个推理机的话,那么当专家教给机器一条知识 $A \to B$ 时,当且仅当输入 A 与知识 $A \to B$ 的前件 A 完全重合时,该机器才会作出积极响应并输出 B.如果输入 A^* 与知识 $A \to B$ 的前件 A 不完全重合,则机器拒绝受理.

但是人脑每日每时所必须面对的推理问题远比 MP 模型复杂得多,人脑日常推理所面临的大量的更多的问题是小前提 A^* 与大前提 $A \to B$ 的前件 A 不完全重合的情形,然而人的大脑的智慧活动往往能够轻而易举地完成这种推理.

比如考虑如下的例子,按照人脑日常的 Fuzzy 思维方式,我们有

大前提：如果西红柿红了，则熟了

小前提：这个西红柿有点红

结　论：　　它差不多熟了

大前提：如果室温低，则将加热器电压调大

小前提：现在室温偏低

结　论：　　将加热器电压稍许调大

将上述例子一般化为

大前提：如果 x 是 A，则 y 是 B

小前提：现在 x 是 A^*

结　论：　　y 是 B^*

其中 A 和 A^* 是论域 U 的两个 Fuzzy 子集，B 和 B^* 是论域 V 的两个 Fuzzy 子集. 常将以上模型简记为

$$\begin{array}{l} A \to B \\ \underline{A^*} \\ B^* \end{array}$$

它是 Fuzzy 推理最基本的模型，叫作**简单 Fuzzy 推理模型**. 在 Fuzzy 控制中，这种模型可图示如图 3.24.

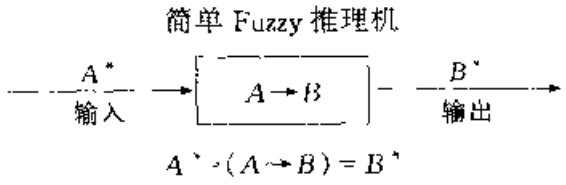


图 3.24　简单 Fuzzy 推理模型

简单 Fuzzy 推理模型也叫作 **Fuzzy Modus Ponens**，简称 **FMP**. 与经典逻辑的推理规则 MP 相比，FMP 具有以下特点：

(1) 这里的 A, A^*, B, B^* 均为 Fuzzy 集合，它们直接反映人的 Fuzzy 语言，表达 Fuzzy 陈述，刻画 Fuzzy 概念、Fuzzy 现象、Fuzzy 事物.

(2) 作为 Fuzzy 命题的 $A \to B$，其真值域已不再局限于 $\{0,1\}$ 二元素集，而是扩展到了整个 $[0,1]$ 闭区间. $A \to B$ 也常看作从 U 到 V 的 Fuzzy 关系，一个元素对 $(x,y) \in U \times V$ 使 $A(x,y)=0.998$，就意味着 x 与 y 有关系 $A \to B$ 的程度为 0.998.

(3) 尽管小前提 A^* 与大前提 $A \to B$ 的前件 A 未必重合，人们也将积极

面对这样的情况，并努力探索模拟人脑 Fuzzy 思维方式，尝试各种方法，给出推理结论 B^*.

3.4.2　多维 Fuzzy 推理模型

简单 Fuzzy 推理模型是单输入单输出的模型. 但在 Fuzzy 推理所面对的问题中，也有多输入与单输出的情况，即就是说，大前提的前件可以有 n 个，比如

大前提：如果水温高，且温度继续上升，则多加一些冷水
小前提：现在水温较高，且温度微量上升
结　论：　　稍加一些冷水

其一般格式如下

大前提：如果 x_1 是 A_1，x_2 是 A_2，$\cdots$，x_n 是 A_n，则 y 是 B
小前提：现在 x_1 是 A_1^*，x_2 是 A_2^*，$\cdots$，x_n 是 A_n^*
结　论：　　y 是 B^*

可简记为

$$\begin{array}{l} A_1, A_2, \cdots, A_n \rightarrow B \\ \underline{A_1^*, A_2^*, \cdots, A_n^*} \\ B^* \end{array}$$

叫作**多维 Fuzzy 推理模型**，其中 A_1 和 A_1^*，A_2 和 A_2^*，$\cdots$，A_n 和 A_n^*，B 和 B^* 分别是论域 $U_1, U_2, \cdots, U_n$，V 的 Fuzzy 子集.

多维 Fuzzy 推理模型在 Fuzzy 控制中可图示如图 3.25.

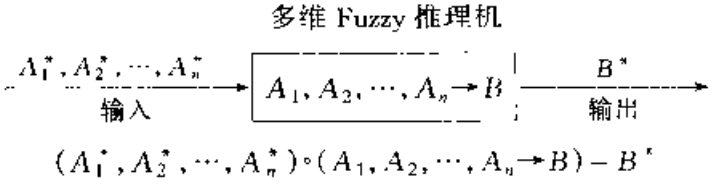


图 3.25　多维 Fuzzy 推理模型

在多维 Fuzzy 推理模型中，为求 B^*，通常有三种方法可供选用，即，Zadeh 法，Tsukamoto 法，和 Sugeno-Takagi 法.

方法 1　Zadeh 法

只需作直积

$$A = A_1 \times A_2 \times \cdots \times A_n,$$
$$A^* = A_1^* \times A_2^* \times \cdots \times A_n^*,$$

它们是论域 $U_1, U_2, \cdots, U_n$ 的笛卡尔直积

$$U = U_1 \times U_2 \times \cdots \times U_n$$

的 Fuzzy 子集，分别由下式确定

$$\begin{aligned} A(x) &= (A_1 \times A_2 \times \cdots \times A_n)(x_1, x_2, \cdots, x_n) \\ &= \min\{A_1(x_1), A_2(x_2), \cdots, A_n(x_n)\} \\ &= A_1(x_1) \wedge A_2(x_2) \wedge \cdots \wedge A_n(x_n), \\ A^*(x) &= (A_1^* \times A_2^* \times \cdots \times A_n^*)(x_1, x_2, \cdots, x_n) \\ &= \min\{A_1^*(x), A_2^*(x), \cdots, A_n^*(x)\} \\ &= A_1^*(x) \wedge A_2^*(x) \wedge \cdots \wedge A_n^*(x). \end{aligned}$$

这样，多维 Fuzzy 推理模型就转化为简单 Fuzzy 推理模型

$$\begin{array}{l} A \to B \\ \hline A^* \\ \hline B^* \end{array}$$

从而求得 B^*，其一般公式为

$$A^* \circ (A \to B) = B^*,$$

即

$$(A_1^* \times A_2^* \times \cdots \times A_n^*) \circ (A_1, A_2, \cdots, A_n \to B) = B^*.$$

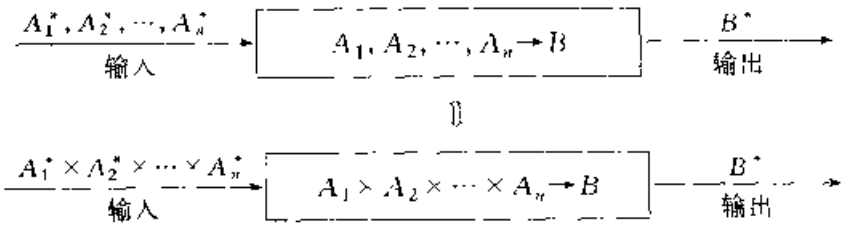


图 3.26 多维 Fuzzy 推理的 Zadeh 法

Zadeh 法实际上是将多维 Fuzzy 推理机通过取“直积”直接转化为一个简单 Fuzzy 推理机.

方法 2 Tsukamoto 法

将 $A_1^*, A_2^*, \cdots, A_n^*$ 分别按简单 Fuzzy 推理处理如下

$$\begin{array}{l} A_1 \to B \\ \hline A_1^* \\ \hline B_1^* \end{array}, \quad \begin{array}{l} A_2 \to B \\ \hline A_2^* \\ \hline B_2^* \end{array}, \cdots, \quad \begin{array}{l} A_n \to B \\ \hline A_n^* \\ \hline B_2^* \end{array}$$

然后将各推理结果取 $\cap$，从而合并为一个最终结果 B^*，即

$$B_1^* \cap B_2^* \cap \cdots \cap B_n^* = B^*.$$

其一般公式为

$$[A_1^* \circ (A_1 \to B)] \cap [A_2^* \circ (A_2 \to B)] \cap \cdots \cap [A_n^* \circ (A_n \to B)] = B^*.$$

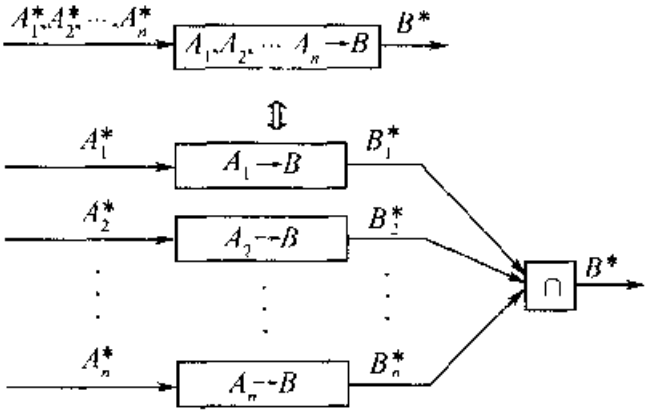


图 3.27　多维 Fuzzy 推理的 Tsukamoto 法

Tsukamoto 法实际上是将多维 Fuzzy 推理机分解为 n 个简单 Fuzzy 推理机的并联.

方法 3　Sugeno-Takagi 法

将 $A_1^*, A_2^*, \cdots, A_n^*$ 依次按串联方式处理，即把第 i 次推理结果 B_i^* 作为新的 B，再进行第 $i+1$ 次推理. 其操作如下

$$\frac{A_1 \to B \quad A_1^*}{B_1^*}, \quad \frac{A_2 \to B_1^* \quad A_2^*}{B_2^*}, \cdots, \quad \frac{A_n \to B_{n-1}^* \quad A_n^*}{B_n^*}$$

这里，$B_n^* = B^*$ 即为所求的最终结果. 其一般公式为

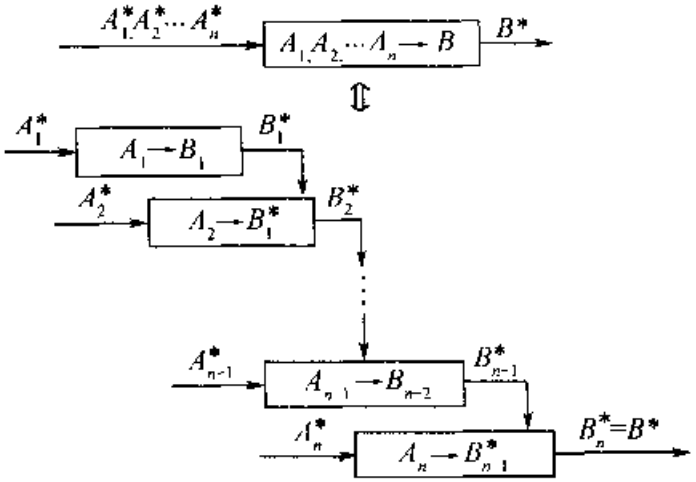


图 3.28　多维 Fuzzy 推理的 Sugeno-Takagi 法

$$A_n^* \circ \{A_n \to [A_{n-1}^* \circ (A_{n-1} \to (A_{n-2}^* \circ (A_{n-2} \to \cdots \to A_2^* \circ (A_2 \to (A_1^* \circ (A_1 \to B)))\cdots)))]\}$$
$$= B_n^* = B^*.$$

Sugeno-Takagi 法实际上是将多维 Fuzzy 推理机分解为 n 个简单 Fuzzy 推理机的串联.

一般地, 三种方法所得结果是有差别的.

3.4.3 多重 Fuzzy 推理模型

在 Fuzzy 推理所面对的问题中, 大前提可以有 n 个, 比如

大前提: 如果室温很低, 则全力加热
如果室温偏低, 则稍许加热
如果室温适中, 则不加热
如果室温偏高, 则稍许降温
如果室温很高, 则大力降温

小前提: 现在室温太高

结　论: 全力降温

其一般格式为

大前提: 若 x 是 A_1, 则 y 是 B_1
若 x 是 A_2, 则 y 是 B_2
……
若 x 是 A_n, 则 y 是 B_n

小前提: 现在 x 是 A^*

结　论: y 是 B^*

可简记为

$$\begin{array}{l} A_1 \to B_1 \\ A_2 \to B_2 \\ \cdots \\ A_n \to B_n \\ \underline{A^*} \\ B^* \end{array}$$

叫作**多重 Fuzzy 推理模型**. 其中,

$$A_1, A_2, \cdots, A_n, A^* \in \mathscr{F}(U), \quad B_1, B_2, \cdots, B_n, B^* \in \mathscr{F}(V).$$

多重 Fuzzy 推理模型在 Fuzzy 控制中可图示如图 3.29.

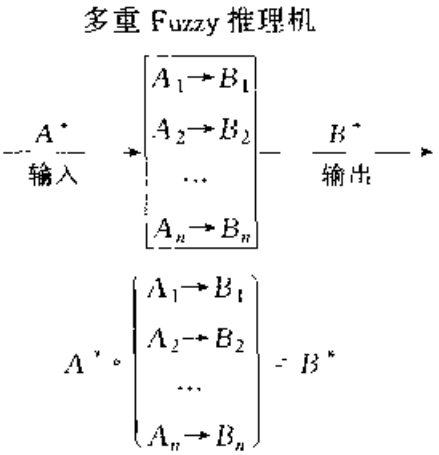


图 3.29　多重 Fuzzy 推理模型

在多重 Fuzzy 推理模型中，为求推理结果 B^*，通常有三条路径可走，它们是 FITA, FATI, 及点火法.

方法 1　FITA

先将输入 A^* 分别与各 $A_i \to B_i$ 按简单 Fuzzy 推理处理，即

$$\frac{A_1 \to B_1}{A^*} \quad \frac{A_2 \to B_2}{A^*} \quad \cdots, \quad \frac{A_n \to B_n}{A^*}$$
$$B_1^* \qquad B_2^* \qquad\qquad B_n^*$$

然后再把所得 n 个中间结果 $B_1^*, B_2^*, \cdots, B_n^*$ 以某种方式聚合为一个最终结果 B^*，即

$$B_1^* \oplus B_2^* \oplus \cdots \oplus B_n^* = B^*,$$

其一般公式为

$$[A^* \circ (A_1 \to B_1)] \oplus [A^* \circ (A_2 \to B_2)] \oplus \cdots \oplus [A^* \circ (A_n \to B_n)] = B^*.$$

通常取聚合⊕为∪，有时也取⊕为∩. J. Buckley 与 Y. Hayashi 把这种方法称为 **FITA**，即就是先推理后聚合(First Infer Then Aggregate).

FITA 实际上是将多重 Fuzzy 推理机分解为 n 个简单 Fuzzy 推理机的并联. 但与多维场合的并联是有区别的，那里通常将聚合取为∩，而这里则更多地是取聚合⊕为∪.

方法 2　FATI

先用某种方式把 n 条规则 $A_i \to B_i$ ($i = 1, 2, \cdots, n$) 聚合为一条规则 $A \to B$，即

$$(A_1 \to B_1) \otimes (A_2 \to B_2) \otimes \cdots \otimes (A_n \to B_n) = A \to B.$$

通常取聚合⊗为∪，有时也取⊗为∩. 这样就将问题转化为简单 Fuzzy 推理模

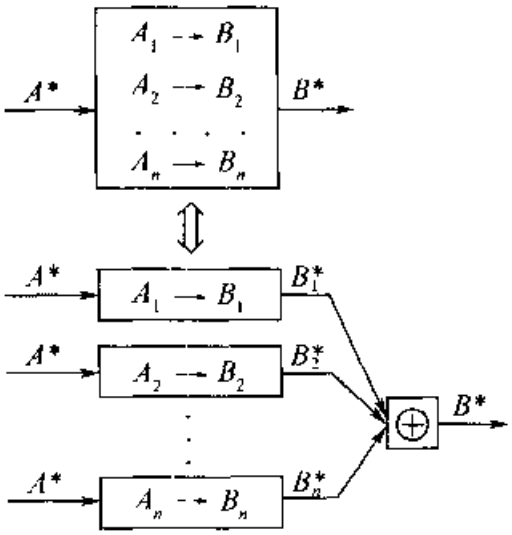


图 3.30 多重 Fuzzy 推理的 FITA 法

型

$$\frac{\begin{array}{l}A \to B\\ A^*\end{array}}{B^*}$$

从而求得最终推理结果 $B^* = A^* \circ (A \to B)$. 其一般公式为

$$A^* \circ [(A_1 \to B_1) \otimes (A_2 \to B_2) \otimes \cdots \otimes (A_n \to B_n)] = B^*.$$

Buckley 与 Hayashi 把这种方法称为 **FATI**, 即就是先聚合后推理(First Aggregate Then Infer).

应当指出, 虽然 FITA 与 FATI 都有聚合, 但二者的聚合对象是不同的. 在 FITA 中被聚合的是 n 个中间推理结果 $B_1^*, B_2^*, \cdots, B_n^*$; 而在 FATI 中被聚合的则是 n 条规则 $A_1 \to B_1, A_2 \to B_2, \cdots, A_n \to B_n$, 它们的涵义是不同的.

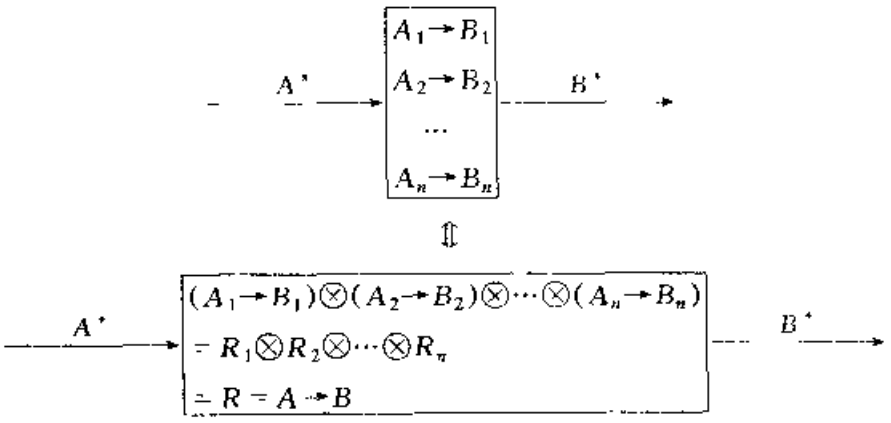


图 3.31 多重 Fuzzy 推理的 FATI 法

方法 3　点火法

对于多重 Fuzzy 推理模型，除过 FITA 和 FATI 外，还有通过衡量 A^* 与各 A_i 之间的“距离”，或“贴近度”，或“相似度”，并让 A^*“激活”n 条规则中前件与 A^* 最接近的那条规则 $A_{i_0} \rightarrow B_{i_0}$，从而求得推理结果 $B^* = B_{i_0}$ 的方法．这种方法就叫作**点火法**．

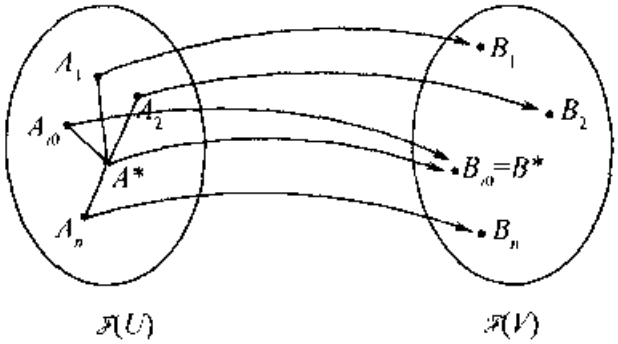


图 3.32　多重 Fuzzy 推理的点火法

以贴近度为例．设

已知　$A_1 \rightarrow B_1$

$A_2 \rightarrow B_2$

…

$A_n \rightarrow B_n$

且给定　A^*

求　　B^*

其中，$A_1, A_2, \cdots, A_n, A^* \in \mathcal{F}(U)$，$B_1, B_2, \cdots, B_n, B^* \in \mathcal{F}(V)$，$q$ 是 $\mathcal{F}(U)$ 中的贴近度．则只须通过计算找到 i_0 使

$$q(A^*, A_{i_0}) = \max_{1 \leqslant i \leqslant n} q(A^*, A_i),$$

这时，自然输出 $B^* = B_{i_0}$．

3.4.4　多重多维 Fuzzy 推理模型

Fuzzy 控制中最常用的是更一般的**多重多维 Fuzzy 推理模型**．比如

大前提：如果室温很低，且继续降低，则全力加热

如果室温偏低，且迅速降低，则大力加热

如果室温偏低，且缓慢回升，则稍许加热

如果室温适中，且不再变化，则不加热

……

如果室温偏高，且缓慢上升，则中等降温

小前提：现在室温太高，且迅速上升

结　论：　　全力降温

其一般格式为

大前提：若 x_1 是 A_{11}, x_2 是 $A_{12}, \cdots, x_n$ 是 A_{1n}，则 y 是 B_1

若 x_1 是 A_{21}, x_2 是 $A_{22}, \cdots, x_n$ 是 A_{2n}，则 y 是 B_2

……

若 x_1 是 A_{m1}, x_2 是 $A_{m2}, \cdots, x_n$ 是 A_{mn}，则 y 是 B_m

小前提：现在 x_1 是 A_1^*, x_2 是 $A_2^*, \cdots, x_n$ 是 A_n^*

结　论：　　y 是 B^*

可简记为

$$\begin{aligned} &A_{11}, A_{12}, \cdots, A_{1n} \to B_1 \\ &B_{21}, B_{22}, \cdots, B_{2n} \to B_2 \\ &\quad \cdots \\ &A_{m1}, A_{m2}, \cdots, A_{mn} \to B_m \\ &\underline{A_1^*, A_2^*, \cdots, A_n^*} \\ &\qquad B^* \end{aligned}$$

其中

$$\begin{aligned} &A_{11}, A_{21}, \cdots, A_{m1}, A_1^* \in \mathcal{F}(U_1), \\ &A_{12}, A_{22}, \cdots, A_{m2}, A_2^* \in \mathcal{F}(U_2), \\ &\quad \cdots \\ &A_{1n}, A_{2n}, \cdots, A_{mn}, A_n^* \in \mathcal{F}(U_n), \\ &B_1, B_2, \cdots, B_m, B^* \in \mathcal{F}(V). \end{aligned}$$

在多重多维Fuzzy推理模型中，为求得推理结果 B^*，有下述多条路径可走.

方法1　多重Zadeh法

可先把 $A_{i1}, A_{i2}, \cdots, A_{in}$ 聚合为 $A_i (i = 1, 2, \cdots, m)$，把 $A_1^*, A_2^*, \cdots, A_n^*$ 聚合为 A^*，即

$$\begin{aligned} &A_{11} \times A_{12} \times \cdots \times A_{1n} = A_1, \\ &A_{21} \times A_{22} \times \cdots \times A_{2n} = A_2, \\ &\quad \cdots \\ &A_{m1} \times A_{m2} \times \cdots \times A_{mn} = A_m, \\ &A_1^* \times A_2^* \times \cdots \times A_n^* = A^*, \end{aligned}$$

从而转化为多重Fuzzy推理模型

$$\begin{array}{l} A_1 \to B_1 \\ A_2 \to B_2 \\ \cdots \\ A_m \to B_m \\ \hline A^* \\ \hline B^* \end{array}$$

再按 FITA,或 FATI,或点火法求得推理结果 B^*.

方法 2 多重 FITA

选定 Zadeh 法,Tsukamoto 法,或 Sugeno-Takagi 法之一,把多维输入 A_1^*, $A_2^*, \cdots, A_n^*$ 与多维规则

$$A_{i1}, A_{i2}, \cdots, A_{in} \to B_i (i = 1, 2, \cdots, m)$$

分别按多维 Fuzzy 推理处理,即

$$\begin{array}{l} A_{11}, A_{12}, \cdots, A_{1n} \to B_1 \\ \hline A_1^*, A_2^*, \cdots, A_n^* \\ \hline B_1^* \end{array}$$

$$\begin{array}{l} A_{21}, A_{22}, \cdots, A_{2n} \to B_2 \\ \hline A_1^*, A_2^*, \cdots, A_n^* \\ \hline B_2^* \end{array}$$

$$\cdots$$

$$\begin{array}{l} A_{m1}, A_{m2}, \cdots, A_{mn} \to B_m \\ \hline A_1^*, A_2^*, \cdots, A_n^* \\ \hline B_m^* \end{array}$$

再将所得中间结果 $B_1^*, B_2^*, \cdots, B_m^*$ 聚合为所求的最终结果 B^*,即

$$B_1^* \oplus B_2^* \oplus \cdots \oplus B_m^* = B^*.$$

方法 3 多重 FATI

可先将 $A_{1j}, A_{2j}, \cdots, A_{mj}$ 聚合为 $A_j (j = 1, 2, \cdots, n)$,将 $B_1, B_2, \cdots, B_m$ 聚合为 B,即

$$\begin{aligned} &A_{11} \oplus A_{21} \oplus \cdots \oplus A_{m1} = A_1, \\ &B_{12} \oplus A_{22} \oplus \cdots \oplus A_{m2} = A_2, \\ &\cdots \\ &A_{1n} \oplus A_{2n} \oplus \cdots \oplus A_{mn} = A_n, \\ &B_1 \oplus B_2 \oplus \cdots \oplus B_m = B, \end{aligned}$$

也即，把 m 条 n 维规则聚合为一条 n 维规则，从而转化为多维 Fuzzy 推理模型

$$\begin{array}{l} A_1, A_2, \cdots, A_n \to B \\ \underline{A_1^*, A_2^*, \cdots, A_n^*} \\ B^* \end{array}$$

再按 Zadeh 法，或 Tsukamoto 法，或 Sugeno-Takagi 法求得推理结果 B^*.

方法 4　多重Ⅰ型 Tsukamoto 法

将 $A_1^*, A_2^*, \cdots, A_n^*$ 分别按多重 Fuzzy 推理处理如下

$$\begin{array}{lll} A_{11} \to B_1 & A_{12} \to B_1 & A_{1n} \to B_1 \\ A_{21} \to B_2 & A_{22} \to B_2 & A_{2n} \to B_2 \\ \cdots & \cdots & \cdots \\ A_{m1} \to B_m & A_{m2} \to B_m & A_{mn} \to B_m \\ \underline{A_1^*} & \underline{A_2^*} & \underline{A_n^*} \\ B_1^* & B_2^* & B_n^* \end{array} \quad , \quad , \cdots , \quad$$

再将各推理结果取 $\cap$，从而合并为一个最终结果，即

$$B_1^* \cap B_2^* \cap \cdots \cap B_n^* = B^*.$$

方法 5　多重Ⅱ型 Tsukamoto 法

将多维输入 $A_1^*, A_2^*, \cdots, A_n^*$ 与多维规则 $A_{i1}, A_{i2}, \cdots, A_{in} \to B_i (i = 1, 2, \cdots, m)$ 分别按多维 Fuzzy 推理的 Tsukamoto 法处理如下

$$\begin{array}{lll} A_{i1} \to B_i & A_{i2} \to B_i & A_{in} \to B_i \\ \underline{A_1^*} & \underline{A_2^*} & \underline{A_n^*} \\ B_{i1}^* & B_{i2}^* & B_{in}^* \end{array} \quad , \quad , \cdots , \quad$$

$$B_{i1}^* \cap B_{i2}^* \cap \cdots \cap B_{in}^* = B_i^*.$$

再将所得结果 $B_1^*, B_2^*, \cdots, B_m^*$ 聚合为最终结果，即

$$B_1^* \oplus B_2^* \oplus \cdots \oplus B_m^* = B^*.$$

方法 6　Sugeno-Takagi 法

将多维输入 $A_1^*, A_2^*, \cdots, A_n^*$ 与多维规则 $A_{i1}, A_{i2}, A_{in} \to B_i (i = 1, 2, \cdots, m)$ 分别按多维 Fuzzy 推理的 Sugeno-Takagi 法处理如下

$$\begin{array}{lll} A_{i1} \to B_i & A_{i2} \to B_{i1}^* & A_{in} \to B_{i,n-1}^* \\ \underline{A_1^*} & \underline{A_2^*} & \underline{A_n^*} \\ B_{i1}^* & B_{i2}^* & B_{in}^* = B_i^* \end{array} \quad , \quad , \cdots , \quad$$

再将所得结果 $B_1^*, B_2^*, \cdots, B_m^*$ 聚合为最终结果 B^*，即

$$B_1^* \oplus B_2^* \oplus \cdots \oplus B_m^* = B^*.$$

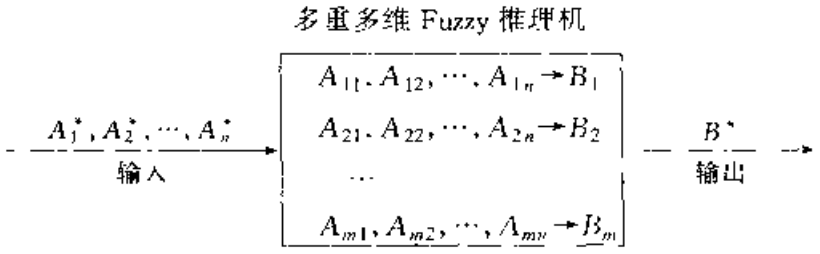


图 3.33　多重多维 Fuzzy 推理模型

3.4.5　多重多维多输出 Fuzzy 推理模型

应用当中也需要考虑**多重多维多输出 Fuzzy 推理模型**

$$\begin{gathered}
A_{11}, A_{12}, \cdots, A_{1n} \to B_{11}, B_{12}, \cdots, B_{1k} \\
A_{21}, A_{22}, \cdots, A_{2n} \to B_{21}, B_{22}, \cdots, B_{2k} \\
\cdots \\
A_{m1}, A_{m2}, \cdots, A_{mn} \to B_{m1}, B_{m2}, \cdots, B_{mk} \\
\underline{A_1^*, A_2^*, \cdots, A_n^*} \\
B_1^*, B_2^*, \cdots, B_k^*
\end{gathered}$$

其中，

$$A_{ij}, A_j^* \in \mathcal{F}(U_j) \quad (i = 1, 2, \cdots, m; j = 1, 2, \cdots, n),$$

$$B_{ij}, B_j^* \in \mathcal{F}(V_j) \quad (i = 1, 2, \cdots, m; j = 1, 2, \cdots, k).$$

为求得推理结果 $B_1^*, B_2^*, \cdots, B_k^*$，只需对每个 $j \leqslant k$，通过多重多维 Fuzzy 推理模型

$$\begin{gathered}
A_{11}, A_{12}, \cdots, A_{1n} \to B_{1j} \\
A_{21}, A_{22}, \cdots, A_{2n} \to B_{2j} \\
\cdots \\
A_{m1}, A_{m2}, \cdots, A_{mn} \to B_{mj} \\
\underline{A_1^*, A_2^*, \cdots, A_n^*} \\
B_j^*
\end{gathered}$$

分别求得 B_j^* 即可。

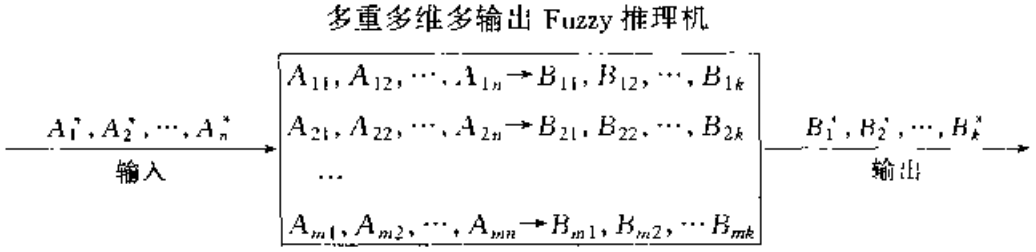


图 3.34 多重多维多输出 Fuzzy 推理模型

上述各种 Fuzzy 推理模型，都可以转化为简单 Fuzzy 推理模型 FMP，即

$$\begin{array}{l} A \to B \\ \underline{A^*} \\ B^* \end{array}$$

§3.5 CRI 方案下的 Fuzzy 推理算法

上述各种 Fuzzy 推理模型，都可以转化为简单 Fuzzy 推理模型

$$\begin{array}{l} A \to B \\ \underline{A^*} \\ B^* \end{array}$$

即 FMP$\{A \to B, A^* \vdash B^*$. 其中，$A$ 和 A^* 是论域 U 的 Fuzzy 子集，B 和 B^* 是论域 V 的 Fuzzy 子集.

为了实现 Fuzzy 推理，有两个问题需要解决：

(1) **关系生成算法**：A 是 U 的 Fuzzy 子集，B 是 V 的 Fuzzy 子集，$A \to B$ 通常看作从 U 到 V 的一个 Fuzzy 关系 R. 来自 U 和 V 的一对元素 (x, y) 如果使 Fuzzy 关系 $R \to B$ 取值为 $R(x, y) = (A \to B)(x, y) = 0.998$，就表明 x 与 y 有关系 $R = A \to B$ 的程度为 0.998. 应当给出算法，使能利用 $A(x)$ 和 $B(y)$ 算出 $R(x, y)$ 即 $(A \to B)(x, y)$. 把这样的算法叫做**关系生成算法**. 这里指出，存在着多种不同的关系生成算法.

(2) **推理合成算法**：$R = A \to B$ 是从 U 到 V 的 Fuzzy 关系，A^* 是 U 的 Fuzzy 子集. 还应当给出算法"$\circ$"，使能由 $R = A \to B$ 和 A^* 合成推理结果 B^*，它是 V 的 Fuzzy 子集. 即

$$A^* \circ (A \to B) = A^* \circ R = B^*.$$

把这样的算法"$\circ$"叫做**推理合成算法**. 这里指出，存在着不同的推理合成算法.

关系生成算法和推理合成算法一旦确定，一种 Fuzzy 推理算法就确定了. 给出不同的关系生成算法和推理合成算法，就得到不同的 Fuzzy 推理算法.

Zadeh 于 1973 年首先提出解决 FMP 问题的这种方案,叫做 Fuzzy 推理算法的**CRI 方案**(Compositional Rule of Inference).

3.5.1 简单 Fuzzy 推理模型的 Mamdani 算法

E.H.Mamdani 于 1974 年首次提出 Fuzzy 逻辑控制,并给出一种基于 CRI 方案的 Fuzzy 推理算法,被称为 Mamdani 算法,至今仍是一种非常有效的算法,并被广泛地使用着.

首先考虑简单 Fuzzy 推理模型 FMP

$$\begin{array}{l} A \to B \\ \underline{A^*} \\ B^* \end{array}$$

按照 CRI 方案的观点,FMP 常被表达为

$$A^* \circ (A \to B) = A^* \circ R = B^*,$$

其中 $A, A^* \in \mathscr{F}(U), B, B^* \in \mathscr{F}(V)$,

$$R = A \to B \in \mathscr{F}(U \times V).$$

Mamdani 的关系生成算法取为 min 运算

$$\begin{aligned} R(x,y) &= (A \to B)(x,y) \\ &= (A \times B)(x,y) \\ &= A(x) \wedge B(y), \end{aligned}$$

即来自 U 和 V 的一对元素 (x,y) 有 Fuzzy 关系 $R = A \to B$ 的程度为

$$\begin{aligned} R(x,y) &= (A \to B)(x,y) = A(x) \wedge B(y) \\ &= \min\{A(x), B(y)\}. \end{aligned}$$

推理合成算法取为 max-min 复合运算

$$\begin{aligned} B^*(y) &= (A^* \circ R)(y) \\ &= \bigvee_{x \in U} [A^*(x) \wedge R(x,y)], \end{aligned}$$

即

$$\begin{aligned} B^*(y) &= [A^* \circ (A \to B)](y) \\ &= \bigvee_{x \in U} [A^*(x) \wedge (A \to B)(x,y)]. \end{aligned}$$

将关系生成算法与推理合成算法合并到一起即得

$$B^*(y) = \bigvee_{x \in U} [A^*(x) \wedge A(x) \wedge B(y)]. \tag{3.1}$$

此为简单 Fuzzy 推理模型的 **Mamdani 算法**.

易见,(3.1)式可以改写如下

$$B^*(y) = \{\bigvee_{x \in U} [A^*(x) \wedge A(x)]\} \wedge B(y)$$

$$
\begin{aligned}
&= [\bigvee_{x\in U}(A^* \cap A)(x)] \wedge B(y)\\
&= [\mathrm{Hgt}(A^* \cap A)] \wedge B(y)\\
&= q(A^*, A) \wedge B(y)\\
&= q \wedge B(y). \qquad (3.2)
\end{aligned}
$$

已经知道

$$q = q(A^*, A) = \mathrm{Hgt}(A^* \cap A)$$

是 $\mathscr{P}(U)$中的贴近度. 因此, Mamdani 算法中的

$$
\begin{aligned}
q &= q(A^*, A)\\
&= \mathrm{Hgt}(A^* \cap A)\\
&= \bigvee_{x\in U}(A^* \cap A)(x)\\
&= \bigvee_{x\in U}[A^*(x) \wedge A(x)],
\end{aligned}
$$

正好刻画了小前提 A^* 与大前提 $A \to B$ 的前件 A 之间的贴近程度.

由于这种贴近度 $q = q(A^*, A)$恰是 A^* 与 A 的交集 $A^* \cap A$ 的高度 $\mathrm{Hgt}(A^* \cap A)$, 所以由 Mamdani 算法(3.1)即(3.2)求得的推理结果 B^* 恰是常值 Fuzzy 集 q 与大前提后件 B 的交集

$$B^* = q \cap B. \qquad (3.3)$$

如图 3.35 所示.

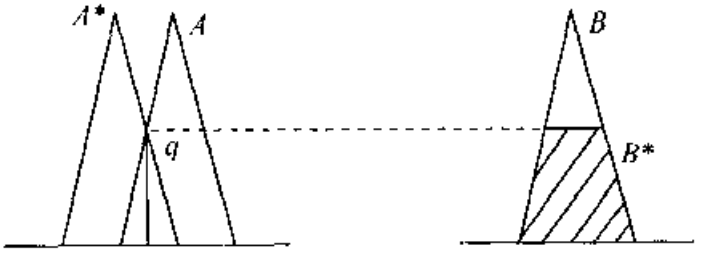


图 3.35 简单 Fuzzy 推理模型的 Mamdani 算法

由式(3.2), 式(3.3), 或图 3.35 可以看出, 当 A^* 与 A 的贴近程度 q 越高时, 按 Mamdani 算法所求得的结论 B^* 就越接近大前提 $A \to B$ 的后件 B. 当 A^* 与 A 的贴近程度 q 达到 1 时, B^* 就与 B 完全重合. 事实上, 只要 $q(A^*, A) \geqslant \mathrm{Hgt}B$, B^* 就一定与 B 完全重合.

特别地, 当 A^* 与 A 都是正规 Fuzzy 集, 且 A^* 与 A 完全重合时,

$$q = q(A^*, A) = 1,$$

$$B^*(y) = q \wedge B(y) = 1 \wedge B(y) = B(y),$$

即 $B^* = B$, 从而 B^* 与 B 完全重合.

由此可见,简单 Fuzzy 推理模型的 Mamdani 算法是经典逻辑中 MP 规则

$$\begin{array}{l} A \to B \\ \underline{A} \\ B \end{array}$$

即 $|A \to B, A| \vdash B$ 的推广.

考虑论域为有限集的情形.设

$$U = |x_1, x_2, \cdots, x_m|, \quad V = |y_1, y_2, \cdots, y_n|,$$

则 Mamdani 的关系生成算法为

$$\begin{aligned} R(x_i, y_j) &= (A \to B)(x_i, y_j) \\ &= (A \times B)(x_i, y_j) \\ &= A(x_i) \wedge B(y_j) \\ &= r_{ij}. \end{aligned}$$

由此得到从 U 到 V 的 Fuzzy 关系 $R = A \to B$ 的 Fuzzy 矩阵

$$R = (r_{ij})_{m \times n}.$$

易见

$$\begin{aligned} R = (r_{ij})_{m \times n} &= A \times B \\ &= \begin{pmatrix} A(x_1) \\ A(x_2) \\ \vdots \\ A(x_m) \end{pmatrix} \circ (B(y_1), B(y_2), \cdots, B(y_n)), \end{aligned}$$

即 $R = (r_{ij})_{m \times n}$ 可以看作是由 $m \times 1$ 阶 Fuzzy 矩阵 $(A(x_1), A(x_2), \cdots, A(x_m))^{\mathrm{T}}$ 与 $1 \times n$ 阶 Fuzzy 矩阵 $(B(y_1), B(y_2), \cdots, B(y_n))$ 的合成矩阵.

又 Mamdani 的推理合成算法为

$$\begin{aligned} B^*(y_j) &= (A^* \circ R)(y_j) \\ &= \bigvee_{i=1}^{m} [A^*(x_i) \wedge R(x_i, y_j)] \\ &= \bigvee_{i=1}^{m} [A^*(x_i) \wedge r_{ij}] \\ &= (A^*(x_1), A^*(x_2), \cdots, A^*(x_m)) \circ \begin{pmatrix} r_{1j} \\ r_{2j} \\ \vdots \\ r_{mj} \end{pmatrix}, \end{aligned}$$

于是得到

$$(B^*(y_1), B^*(y_2), \cdots, B^*(y_n)) = (A^*(x_1), A^*(x_2), \cdots, A^*(x_m))$$

$$\circ \begin{pmatrix} r_{11} & r_{12} & \cdots & r_{1n} \\ r_{21} & r_{22} & \cdots & r_{2n} \\ \vdots & \vdots & \cdots & \vdots \\ r_{m1} & r_{m2} & \cdots & r_{mn} \end{pmatrix},$$

即

$$B^* = A^* \circ R.$$

这里，A^*, B^*, R 都看作 Fuzzy 矩阵，“$\circ$”是 Fuzzy 矩阵的合成运算，这时与推理合成运算“$\circ$”完全重合一致.

从而得到论域为有限集时，简单 Fuzzy 推理模型的 Mamdani 算法

$$B^* = A^* \circ R, \tag{3.4}$$

其中 $R = (r_{ij})_{m \times n}$，$r_{ij} = A(x_i) \wedge B(y_j)$.

例 3.27 设论域 $U = \{a, b, c, d, e\}$，$V = \{\alpha, \beta, \gamma, \delta\}$. 已知 $A \to B$，且给定 A^*，求 B^*. 这里

$$A = (1, 0.8, 0.5, 0.2, 0),$$
$$B = (0.8, 1, 0.4, 0),$$
$$A^* = (0.4, 0.8, 1, 0.5, 0).$$

解

$$R = A \times B = \begin{pmatrix} 0.8 & 1 & 0.4 & 0 \\ 0.8 & 0.8 & 0.4 & 0 \\ 0.5 & 0.5 & 0.4 & 0 \\ 0.2 & 0.2 & 0.2 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix},$$

$$B^* = A^* \circ R = (0.4, 0.8, 1, 0.5, 0) \circ \begin{pmatrix} 0.8 & 1 & 0.4 & 0 \\ 0.8 & 0.8 & 0.4 & 0 \\ 0.5 & 0.5 & 0.4 & 0 \\ 0.2 & 0.2 & 0.2 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix}$$

$$= (0.8, 0.8, 0.4, 0),$$

即按 Mamdani 算法求得的输出为

$$B^* = \frac{0.8}{\alpha} + \frac{0.8}{\beta} + \frac{0.4}{\gamma} + \frac{0}{\delta}.$$

下面给出当论域为无穷集合时，简单 Fuzzy 推理模型 Mamdani 算法的例子.

例 3.28 设论域 $U = \boldsymbol{R}$，$V = \boldsymbol{R}$. 已知 $A \to B$，且给定 A^*，求 B^*. 这里

$$A(x)=\begin{cases}0, & x\leqslant -1,\\ 1-x^2, & -1<x\leqslant 1,\\ 0, & 1<x,\end{cases}\quad B(y)=\begin{cases}0, & y\leqslant -1,\\ 1-y^4, & -1<y\leqslant 1,\\ 0, & 1<y,\end{cases}$$

$$A^*(x)=\begin{cases}0, & x\leqslant -2,\\ 1-(x+1)^2, & -2<x\leqslant 0,\\ 0, & 0<x.\end{cases}$$

解　易见

$$q=q(A^*,A)=\mathrm{Hgt}(A^*\cap A)=A\left(-\frac{1}{2}\right)=\frac{3}{4},$$

于是由

$$B^*(y)=q\wedge B(y)=\frac{3}{4}\wedge B(y),$$

知

$$B^*(y)=\begin{cases}0, & y\leqslant -1,\\ 1-y^4, & -1<y\leqslant -\frac{\sqrt{2}}{2},\\ \frac{3}{4}, & -\frac{\sqrt{2}}{2}<y\leqslant \frac{\sqrt{2}}{2},\\ 1-y^4, & \frac{\sqrt{2}}{2}<y\leqslant 1,\\ 0, & 1\geqslant y.\end{cases}$$

如图 3.36 所示.

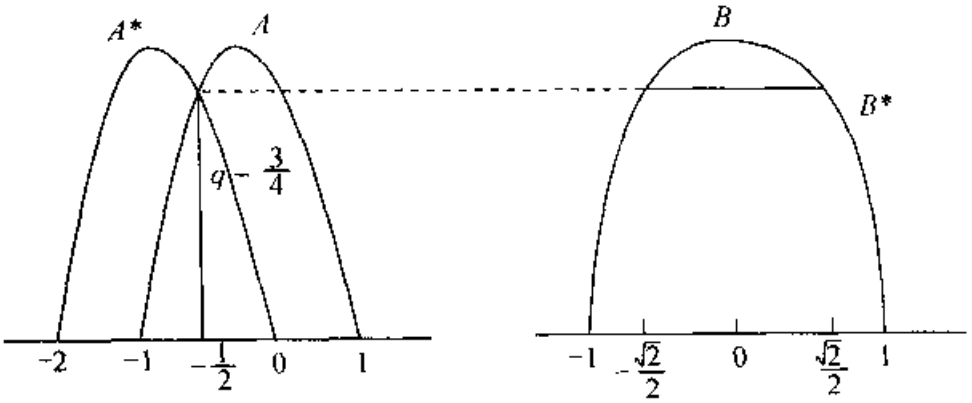


图 3.36　简单 Fuzzy 推理模型的 Mamdani 算法实例

3.5.2　多维 Fuzzy 推理模型的 Mamdani 算法

现在考虑多维 Fuzzy 推理模型

$$\begin{array}{l} A_1, A_2, \cdots, A_n \to B \\ \underline{A_1^*, A_2^*, \cdots, A_n^*} \\ B^* \end{array}$$

的 Mamdani 算法，其中

$$A_1, A_1^* \in \mathscr{F}(U_1), A_2, A_2^* \in \mathscr{F}(U_2), \cdots,$$
$$A_n, A_n^* \in \mathscr{F}(U_n), B, B^* \in \mathscr{F}(V).$$

1. Zadeh 法

取

$$\begin{aligned} A(x) &= (A_1 \times A_2 \times \cdots A_n)(x_1, x_2, \cdots, x_n) \\ &= \min\{A_1(x_1), A_2(x_2), \cdots, A_n(x_n)\} \\ &= A_1(x_1) \wedge A_2(x_2) \wedge \cdots \wedge A_n(x_n) \\ &= \bigwedge_{i=1}^{n} A_i(x_i), \\ A^*(x) &= (A_1^* \times A_2^* \times \cdots \times A_n^*)(x_1, x_2, \cdots, x_n) \\ &= \min\{A_1^*(x_1), A_2^*(x_2), \cdots, A_n^*(x_n)\} \\ &= A_1^*(x_1) \wedge A_2^*(x_2) \wedge \cdots \wedge A_n^*(x_n) \\ &= \bigwedge_{i=1}^{n} A_i^*(x_i), \end{aligned}$$

则多维 Fuzzy 推理模型转化为简单 Fuzzy 推理模型

$$\begin{array}{l} A \to B \\ \underline{A^*} \\ B^* \end{array}$$

其 Mamdani 算法为

$$\begin{aligned} B^*(y) &= \bigvee_{\substack{x_1 \in U_1 \\ x_2 \in U_2 \\ \cdots \\ x_n \in U_n}} \{[\bigwedge_{i=1}^{n} A_i^*(x_i)] \wedge [\bigwedge_{i=1}^{n} A_i(x_i)] \wedge B(y)\} \\ &= \{\bigvee_{\substack{x_1 \in U_1 \\ x_2 \in U_2 \\ \cdots \\ x_n \in U_n}} \bigwedge_{i,j=1}^{n} [A_i^*(x_i) \wedge A_j(x_j)]\} \wedge B(y). \end{aligned}$$

2. Tsukamoto 法

先分别按简单 Fuzzy 推理模型处理如下

$$\frac{A_1 \to B}{A_1^*} \quad \frac{A_2 \to B}{A_2^*} \quad \cdots, \quad \frac{A_n \to B}{A_n^*}$$
$$B_1^* \qquad B_2^* \qquad\qquad B_n^*$$

然后将各推理结果取 $\cap$，从而合并为一个最终结果，即

$$B_1^* \cap B_2^* \cap \cdots \cap B_n^* = B^*.$$

其 Mamdani 算法如下

$$B_1^*(y) = \bigvee_{x_1 \in U_1} [A_1^*(x_1) \wedge A_1(x_1) \wedge B(y)],$$

$$B_2^*(y) = \bigvee_{x_2 \in U_2} [A_2^*(x_2) \wedge A_2(x_2) \wedge B(y)],$$

$$\cdots$$

$$B_n^*(y) = \bigvee_{x_n \in U_n} [A_n^*(x_n) \wedge A_n(x_n) \wedge B(y)],$$

$$B^*(y) = (B_1^* \cap B_2^* \cap \cdots \cap B_n^*)(y)$$

$$= B_1^*(y) \wedge B_2^*(y) \wedge \cdots \wedge B_n^*(y).$$

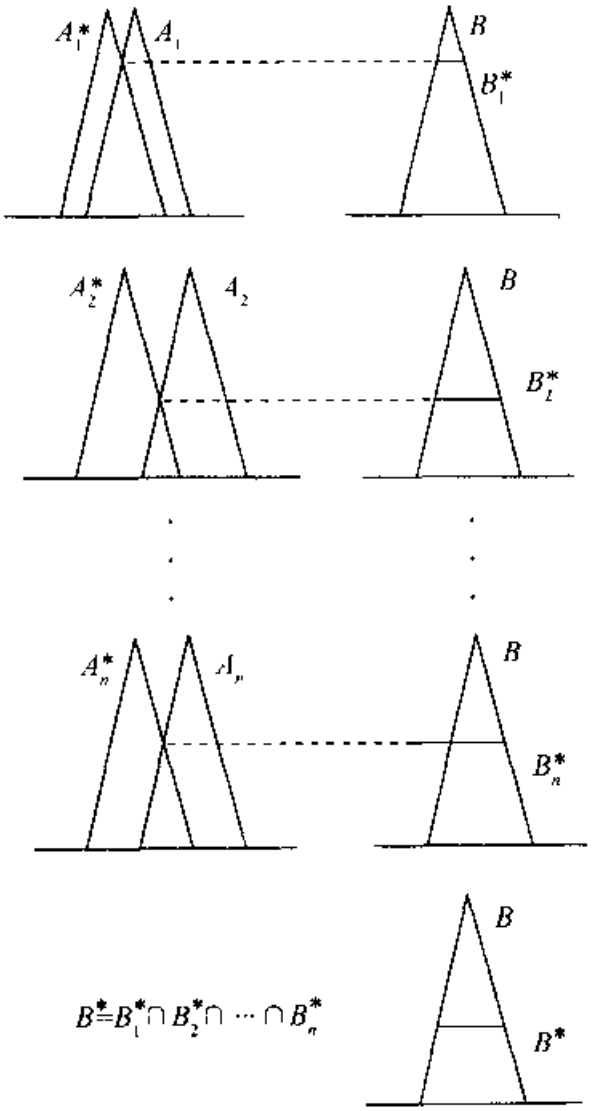


图 3.37　基于 Tsukamoto 法的多维 Fuzzy 推理模型的 Mamdani 算法

如图 3.37 所示.

3. Sugeno-Takagi 法

将多维 Fuzzy 推理模型按串联方式处理如下

$$\frac{A_1 \to B \qquad A_1^*}{B_1^*}, \quad \frac{A_2 \to B_1^* \qquad A_2^*}{B_2^*}, \cdots, \quad \frac{A_n \to B_{n-1}^* \qquad A_n^*}{B_n^*}$$

这里 $B_n^* = B^*$ 即为所求. 其 Mamdani 算法为

$$B_1^*(y) = \bigvee_{x_1 \in U_1} [A_1^*(x_1) \wedge A_1(x_1) \wedge B(y)],$$

$$B_2^*(y) = \bigvee_{x_2 \in U_2} [A_2^*(x_2) \wedge A_2(x_2) \wedge B_1^*(y)],$$

$$B_3^*(y) = \bigvee_{x_3 \in U_3} [A_3^*(x_3) \wedge A_3(x_3) \wedge B_2^*(y)],$$

$$\cdots$$

$$B_n^*(y) = \bigvee_{x_n \in U_n} [A_n^*(x_n) \wedge A_n(x_n) \wedge B_{n-1}^*(y)],$$

$$B^*(y) = B_n^*(y).$$

由于 FMP 模型 Mamdani 算法的简捷特性, 以及[0, 1]中的运算 $\vee$ 与 $\wedge$ 服从完全分配律, 所以易见, 关于多维 Fuzzy 推理模型, 基于 Zadeh 法、Tsukamoto 法、Sugeno-Takagi 法的 Mamdani 算法所得结果是完全一致的.

3.5.3 多重 Fuzzy 推理模型的 Mamdani 算法

考虑多重 Fuzzy 推理模型

$$\frac{\begin{array}{l} A_1 \to B_1 \\ A_2 \to B_2 \\ \cdots \\ A_n \to B_n \\ A^* \end{array}}{B^*}$$

的 Mamdani 算法, 其中

$$A_1, A_2, \cdots, A_n, A^* \in \mathcal{F}(U),$$
$$B_1, B_2, \cdots, B_n, B^* \in \mathcal{F}(V).$$

1. FITA

先分别按简单 Fuzzy 推理模型处理如下

$$\begin{array}{lll} A_1 \to B_1 & A_2 \to B_2 & A_n \to B_n \\ \hline A^* \quad B_1^* & \hline A^* \quad B_2^* & \hline A^* \quad B_n^* \end{array}$$

然后将各推理结果以某种方式聚合为一个最终结果 B^*,即

$$B_1^* \oplus B_2^* \oplus \cdots \oplus B_n^* = B^*.$$

通常取$\oplus = \cup$.其 Mamdani 算法如下

$$B_1^*(y) = \bigvee_{x \in U}[A^*(x) \wedge A_1(x) \wedge B_1(y)],$$

$$B_2^*(y) = \bigvee_{x \in U}[A^*(x) \wedge A_2(x) \wedge B_2(y)],$$

$$\cdots$$

$$B_n^*(y) = \bigvee_{x \in U}[A^*(x) \wedge A_n(x) \wedge B_n(y)],$$

$$B^*(y) = (B_1^* \cup B_2^* \cup \cdots \cup B_n^*)(y)$$

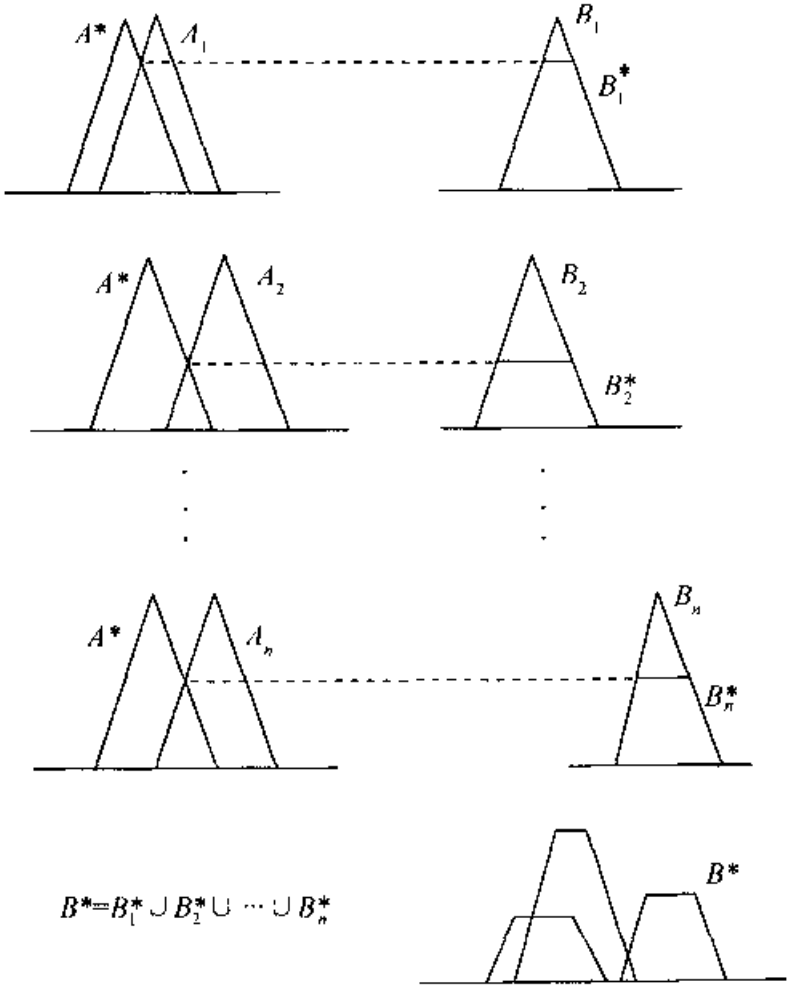


图 3.38 多重 Fuzzy 推理模型沿 FITA 路线的 Mamdani 算法

$$= B_1^*(y) \vee B_2^*(y) \vee \cdots \vee B_n^*(y).$$

如图 3.38 所示.

2.FATI

先按某种方式把 n 条规则聚合为一条规则 $A \to B$, 即

$$(A_1 \to B_1) \otimes (A_2 \to B_2) \otimes \cdots \otimes (A_n \to B_n) = A \to B.$$

通常取 $\otimes = \cup$. 从而转化为简单 Fuzzy 推理模型

$$\begin{array}{l} A \to B \\ \underline{A^*} \\ B^* \end{array}$$

求得推理结果 B^*. 其 Mamdani 算法为

$$(A_1 \to B_1)(x,y) = (A_1 \times B_1)(x,y) = A_1(x) \wedge B_1(y),$$

$$(A_2 \to B_2)(x,y) = (A_2 \times B_2)(x,y) = A_2(x) \wedge B_2(y),$$

$$\cdots$$

$$(A_n \to B_n)(x,y) = (A_n \times B_n)(x,y) = A_n(x) \wedge B_n(y),$$

$$(A \to B)(x,y) = [(A_1 \to B_1) \cup (A_2 \to B_2) \cup \cdots \cup (A_n \to B_n)](x,y)$$

$$= \bigvee_{i=1}^{n} (A_i \to B_i)(x,y)$$

$$= \bigvee_{i=1}^{n} [A_i(x) \wedge B_i(y)],$$

$$B^*(y) = \bigvee_{x \in U} [A^*(x) \wedge (A \to B)(x,y)].$$

易见

$$B^*(y) = \bigvee_{x \in U} \{A^*(x) \wedge [\bigvee_{i=1}^{n} (A_i(x) \wedge B_i(y))]\}$$

$$= \bigvee_{x \in U} \bigvee_{i=1}^{n} [A^*(x) \wedge A_i(x) \wedge B_i(y)]$$

与沿 FITA 路线所得结果殊途同归完全一致.

3.5.4 多重多维 Fuzzy 推理模型的 Mamdani 算法

考虑多重多维 Fuzzy 推理模型

$$\begin{array}{l} A_{11}, A_{12}, \cdots, A_{1n} \to B_1 \\ A_{21}, A_{22}, \cdots, A_{2n} \to B_2 \\ \cdots \\ A_{m1}, A_{m2}, \cdots, A_{mn} \to B_m \\ \underline{A_1^*, A_2^*, \cdots, A_n^*} \\ B^* \end{array}$$

的 Mamdani 算法,其中

$$A_{11}, A_{21}, \cdots, A_{m1}, A_1^* \in \mathcal{F}(U_1),$$
$$A_{12}, A_{22}, \cdots, A_{m2}, A_2^* \in \mathcal{F}(U_2),$$
$$\cdots$$
$$A_{1n}, A_{2n}, \cdots, A_{mn}, A_n^* \in \mathcal{F}(U_n),$$
$$B_1, B_2, \cdots, B_m, B^* \in \mathcal{F}(V).$$

为求得最终结果 B^*,有多条路线可循.我们仅选其一.

第一步 先利用直积运算将各条规则的多维前件聚合为一维前件,并将多维输入聚合为一维输入,即令

$$A_1 = A_{11} \times A_{12} \times \cdots \times A_{1n},$$
$$A_2 = A_{21} \times A_{22} \times \cdots \times A_{2n},$$
$$\cdots$$
$$A_m = A_{m1} \times A_{m2} \times \cdots \times A_{mn},$$
$$A^* = A_1^* \times A_2^* \times \cdots \times A_n^*,$$

从而将多重多维 Fuzzy 推理模型转化为多重 Fuzzy 推理模型

$$\begin{array}{l} A_1 \to B_1 \\ A_2 \to B_2 \\ \cdots \\ A_m \to B_m \\ \hline A^* \\ \hline B^* \end{array}$$

其中,$A_1, A_2, \cdots, A_m, A^* \in \mathcal{F}(U_1 \times U_2 \times \cdots \times U_n) = \mathcal{F}(U)$.

第二步 再将多重 Fuzzy 推理模型分解为 m 个简单 Fuzzy 推理模型分别求解,即

$$\frac{\begin{array}{l} A_1 \to B_1 \\ A^* \end{array}}{B_1^*}, \quad \frac{\begin{array}{l} A_2 \to B_2 \\ A^* \end{array}}{B_2^*}, \cdots, \quad \frac{\begin{array}{l} A_m \to B_m \\ A^* \end{array}}{B_m^*}$$

第三步 最后将各中间结果聚合为一个最终结果,即

$$B_1^* \oplus B_2^* \oplus \cdots \oplus B_m^* = B^*.$$

通常取$\oplus = \cup$.

沿此路线的多重多维 Fuzzy 推理模型的 Mamdani 算法如下

$$A_1(x) = \min\{A_{11}(x_1), A_{12}(x_2), \cdots, A_{1n}(x_n)\},$$
$$A_2(x) = \min\{A_{21}(x_1), A_{22}(x_2), \cdots, A_{2n}(x_n)\},$$
$$\cdots$$
$$A_m(x) = \min\{A_{m1}(x_1), A_{m2}(x_2), \cdots, A_{mn}(x_n)\},$$

$$A^*(x) = \min\{A_1^*(x_1), A_2^*(x_2), \cdots, A_n^*(x_n)\},$$

$$B_1^*(y) = \bigvee_{x\in U}[A^*(x) \wedge A_1(x) \wedge B_1(y)],$$

$$B_2^*(y) = \bigvee_{x\in U}[A^*(x) \wedge A_2(x) \wedge B_2(y)],$$

$$\cdots$$

$$B_m^*(y) = \bigvee_{x\in U}[A^*(x) \wedge A_m(x) \wedge B_m(y)],$$

$$B^*(y) = B_1^*(y) \vee B_2^*(y) \vee \cdots \vee B_m^*(y).$$

3.5.5 CRI 方案下 Fuzzy 推理的其他算法

我们讨论的各种 Fuzzy 推理模型都可以转化为简单 Fuzzy 推理模型

$$\begin{array}{l} A \to B \\ \underline{A^*} \\ B^* \end{array}$$

即 FMP$\{A\to B, A^*\}$ B^*. 这里, $A, A^* \in \mathcal{F}(U)$, $B, B^* \in \mathcal{F}(V)$. 依 CRI 方案的观点,

$$A^* \circ (A \to B) = A^* \circ R = B^*,$$

通常取

$$B^*(y) = \bigvee_{x\in U}[A^*(x) * R(x,y)],$$

其中

$$R(x,y) = (A \to B)(x,y) = A(x) \to B(y).$$

称 $A(x)$与 $B(y)$之间的$\to$为**Fuzzy 蕴涵算子**, 它是 Fuzzy 命题 A 与B 之间**蕴涵连接词**$\to$在真值域$[0,1]$中的反映. 称 $A^*(x)$与 $R(x,y)$之间的 $*$ 为**推理合成算子**, 它是推理合成算法 $A^*\circ(A\to B)$中的运算"$\circ$"在真值域$[0,1]$中的反映. Fuzzy 蕴涵算子$\to$和推理合成算子 $*$ 都是真值域$[0,1]$中的二元算子, 即, 从$[0,1]\times[0,1]$到$[0,1]$的映射

$$\to: \begin{cases} [0,1]\times[0,1] \to [0,1], \\ (a,b), \mapsto a \to b = c, \end{cases}$$

$$*: \begin{cases} [0,1]\times[0,1] \to [0,1], \\ (a,b), \mapsto a * b = c. \end{cases}$$

依我们现在的术语, Mamdani 算法中的 Fuzzy 蕴涵算子和推理合成算子分别为

$$a \to b = a \wedge b = \min\{a,b\},$$

$$a * b = a \wedge b = \min\{a,b\}.$$

给出不同的 Fuzzy 蕴涵算子→与推理合成算子 $*$,即得不同的 Fuzzy 推理算法.

例 3.29 给出 Fuzzy 蕴涵算子→与推理合成算子 $*$ 分别为

$$a \to b = (1 - a + b) \wedge 1,$$
$$a * b = (a + b - 1) \vee 0,$$

即得 Fuzzy 推理的 **Lukasiewicz 算法**

$$\begin{aligned} B^*(y) &= [A^* \circ (A \to B)](y) \\ &= \bigvee_{x \in U} [A(x) * R(x, y)] \\ &= \bigvee_{x \in U} [A^*(x) * (A \to B)(x, y)] \\ &= \bigvee_{x \in U} [A^*(x) * (A(x) \to B(y))] \\ &= \bigvee_{x \in U} \{[A^*(x) + ((1 - A(x) + B(y)) \wedge 1) - 1] \vee 0\} \\ &= \bigvee_{x \in U} \{[(A^*(x) - A(x) + B(y)) \vee 0] \wedge A^*(x)\}. \end{aligned}$$

当 A^* 正规,且 $A^* = A$ 时

$$\begin{aligned} B^*(y) &= \bigvee_{x \in U} (B(y) \wedge A^*(x)) \\ &= B(y) \wedge \left(\bigvee_{x \in U} A^*(x)\right) \\ &= B(y) \wedge 1 \\ &= B(y), \end{aligned}$$

即 $B^* = B$,这表明 Fuzzy 推理的 Lukasiewicz 算法是经典逻辑 MP 规则的推广.

例 3.30 给出 Fuzzy 蕴涵算子→与推理合成算子 $*$ 分别为

$$a \to b = (a \wedge b) \vee (1 - a),$$
$$a * b = a \wedge b,$$

则得 Fuzzy 推理的 **Zadeh 算法**

$$\begin{aligned} B^*(y) &= [A^* \circ (A \to B)](y) \\ &= \bigvee_{x \in U} [A^*(x) * R(x, y)] \\ &= \bigvee_{x \in U} [A^*(x) * (A \to B)(x, y)] \\ &= \bigvee_{x \in U} [A^*(x) * (A(x) \to B(y))] \end{aligned}$$

$$= \bigvee_{x \in U} \{A^*(x) \wedge [A(x) \wedge B(y)) \vee (1 - A(x))]\}.$$

如前所述，Fuzzy 蕴涵算子→是 Fuzzy 命题的蕴涵连接词→即“若……，则……”在 Fuzzy 推理的真值域[0,1]中的反映. 文献中已出现的具体的 Fuzzy 蕴涵算子多达 40 多种. 这里给出较常见的 16 种 Fuzzy 蕴涵算子，见表 3.14.

表 3.14 常见的 16 种 Fuzzy 蕴涵算子

记 号	名 称	表 达 式
θ_1, θ_{KD}	Kleene-Dienes 蕴涵算子	$a \to b = (1-a) \vee b$
θ_2, θ_R	Reichenbach 蕴涵算子	$a \to b = 1 - a + ab$
θ_3, θ_L	Lukasiewicz 蕴涵算子	$a \to b = (1 - a + b) \wedge 1$
θ_4, θ_{GO}	Goguen 蕴涵算子	$a \to b = \frac{b}{a} \wedge 1$，约定 $\frac{b}{0} = 1$
θ_5, θ_G	Gödel 蕴涵算子	$a \to b = \begin{cases} 1, & a \leqslant b \\ b, & a > b \end{cases}$
θ_6		$a \to b = \begin{cases} 1-a, & b = 0 \\ b, & a = 1 \\ 1, & \text{其他} \end{cases}$
θ_7		$a \to b = \begin{cases} 1, & a < 1 \\ b, & a = 1 \end{cases}$
θ_8, θ_Z	Zadeh 蕴涵算子	$a \to b = (1-a) \vee (a \wedge b)$
θ_9		$a \to b = 1 - a + 2ab - a^2 b$
θ_{10}		$a \to b = \begin{cases} 1, & a < 1 \text{ 或 } b = 1 \\ 0, & \text{否则} \end{cases}$
θ_{11}, θ_{GR}	Gaines-Recher 蕴涵算子	$a \to b = \begin{cases} 1, & a \leqslant b \\ 0, & a > b \end{cases}$
θ_{12}, θ_Y	Yager 蕴涵算子	$a \to b = b^a$，约定 $0^0 = 1$
θ_{13}, θ_M	Mamdani 蕴涵算子	$a \to b = a \wedge b$
θ_{14}		$a \to b = ab$
θ_{15}		$a \to b = (a + b - 1) \vee 0$
θ_{16}		$a \to b = \begin{cases} a \wedge b, & a \vee b = 1 \\ 0, & \text{否则} \end{cases}$

在真值域[0,1]中,我们约定 $a' = 1 - a$.

D.Dubois 和 H.Prade 从文献中归纳出 Fuzzy 蕴涵算子的 10 条性质:

(Ⅰ1) 若 $a \leqslant a^*$,则 $a \to b \geqslant a^* \to b$.

(Ⅰ2) 若 $b \geqslant b^*$,则 $a \to b \geqslant a \to b^*$.

(Ⅰ3) $0 \to b = 1$.

(Ⅰ4) $1 \to b = b$.

(Ⅰ5) $a \to b \geqslant b$.

(Ⅰ6) $a \to a = 1$.

(Ⅰ7) $a \to (b \to c) = b \to (a \to c)$.

(Ⅰ8) $a \to b = 1$ 当且仅当 $a \leqslant b$.

(Ⅰ9) $a \to b = b' \to a'$.

(Ⅰ10) $\to$ 是连续的.

这 10 条性质叫 **Dubios-Prade 条件**.

遗憾的是,并不是所有的蕴涵算子都遵守这些规范,如表 3.15 所示.

表 3.15 Fuzzy 蕴涵算子与 Dubios-Prade 条件

	I_1	I_2	I_3	I_4	I_5	I_6	I_7	I_8	I_9	I_{10}
θ_1	√	√	√	√	√	×	√	×	√	√
θ_2	√	√	√	√	√	×	√	×	√	√
θ_3	√	√	√	√	√	√	√	√	√	√
θ_4	√	√	√	√	√	√	√	√	×	√
θ_5	√	√	√	√	√	√	√	√	×	×
θ_6	√	√	√	√	√	×	√	×	√	×
θ_7	√	√	√	√	√	√	√	×	×	×
θ_8	×	√	√	√	×	×	×	×	×	√
θ_9	×	√	√	√	×	×	×	×	×	√
θ_{10}	√	√	√	×	×	√	×	×	×	×
θ_{11}	√	√	√	×	×	√	√	√	√	×
θ_{12}	√	√	√	√	√	×	√	×	×	×
θ_{13}	×	√	×	√	×	×	√	×	×	√
θ_{14}	×	√	×	√	×	×	√	×	×	√
θ_{15}	×	√	×	√	×	×	√	×	×	√
θ_{16}	×	√	×	√	×	×	√	×	×	×

从表 3.15 看出，Lukasiewicz 蕴涵算子 θ_5 是 16 个算子中惟一能使 Dubios-Prade 条件(I 1)～(I 10)都成立的算子. 而性质(I 2)是惟一能被 16 个算子都满足的性质. 在 Fuzzy 推理的应用中，某些被认为异常的算子反而是不能忽视的.

推理合成算子 $*$ 通常取以下两种

$$\circ: \quad a * b = a \wedge b,$$

$$\odot: \quad a * b = (a + b - 1) \vee 0.$$

两种推理合成算子与 16 种 Fuzzy 蕴涵算子相互配合可导出 32 种 Fuzzy 推理算法. 不同的应用环境选用不同的算法，不同的算法所得结果是有差别的.

Fuzzy 推理是对人脑智慧活动的一种模拟，它是一项极富探索性的工作.

3.5.6 Fuzzy 推理算法的 MP 再现分析

Fuzzy 蕴涵算子 $\rightarrow$ 与推理合成算子 $*$ 要相互配合，才能使 Fuzzy 推理有一个好的效果. 考察一种 Fuzzy 推理算法是否能“MP 再现”，即是判断两种算子配合效果的一个重要标准.

定义 3.26（MP 再现算法） 如果 Fuzzy 蕴涵算子 $\rightarrow$ 及推理合成算子 $*$ 使对正规 Fuzzy 集 A 有

$$\begin{array}{l} A \rightarrow B \\ \underline{\quad A \quad} \\ B \end{array}$$

也即 $A \circ (A \rightarrow B) = B$ 或 $|A \rightarrow B, A| \vdash B$，则称这种 Fuzzy 推理算法为 **MP 再现算法**.

Mamdani 算法及 Lukasiewicz 算法都是 MP 再现算法.

例 3.31 给出 Fuzzy 蕴涵算子 $\rightarrow$ 及推理合成算子 $*$ 为

$$a \rightarrow b = (1 - a) \vee b,$$

$$a * b = (a + b - 1) \vee 0,$$

则得 Fuzzy 推理的 **Kleene-Dienes 算法**

$$\begin{aligned} B^*(y) &= (A \circ (A \rightarrow B))(y) \\ &= \bigvee_{x \in U} [A^*(x) * (A \rightarrow B)(x, y)] \\ &= \bigvee_{x \in U} [A^*(x) * (A(x) \rightarrow B(y))] \\ &= \bigvee_{x \in U} |[A^*(x) + ((1 - A(x)) \vee B(y)) - 1| \vee 0| \end{aligned}$$

$$= \bigvee_{A(x)>B(y)} \{[A^*(x) - A(x)] \vee 0\} \vee \bigvee_{A(x)\leqslant B(y)} \{B(y) + A^*(x) - 1\}.$$

易见,若 A^* 是正规的,且 $A^* = A$,则

$$B^*(y) = B(y),$$

即 $B^* = B$. 从而 Kleene-Dienes 算法是 MP 再现算法.

但是若在例 3.31 中取推理合成算子为

$$a * b = a \wedge b,$$

则得 Fuzzy 推理算法为

$$B^*(y) = \bigvee_{x\in U}(A^*(x) \wedge ((1 - A(x)) \vee B(y)))$$

$$= \{\bigvee_{x\in U}(A^*(x) \wedge (1 - A(x)))\} \vee \{(\bigvee_{x\in U} A^*(x)) \wedge B(y)\}.$$

当 $A^* = A$ 时

$$B^*(y) \leqslant \frac{1}{2} \vee B(y).$$

从而这种 Fuzzy 推理算法不是 MP 再现算法.

类似地可以验证,若取 $\rightarrow = \theta_3$ 与 $* = \wedge$ 配合,$\rightarrow = \theta_4$ 与 $* = \wedge$ 配合,所得的 Fuzzy 推理算法都不是 MP 再现算法. 但取 $\rightarrow = \theta_4$ 与 $* = \odot$ 配合所得 Fuzzy 推理算法是 MP 再现算法.

例 3.32 Fuzzy 蕴涵算子 θ_{11} 与两种推理合成算子 $\circ$ 和 $\odot$ 分别配合均得 MP 再现算法.

事实上,由

$$\theta_{11}:\quad a \rightarrow b = \begin{cases} 1, & a \leqslant b, \\ 0, & a > b \end{cases}$$

与

$$\circ:\quad a * b = a \wedge b,$$
$$\odot:\quad a * b = (1 + b - 1) \vee 0,$$

即得

$$\bigvee_{x\in U}(A(x) \wedge (A \rightarrow B)(x,y)) = \bigvee_{A(x)>B(y)} A(x) = B(y),$$

$$\bigvee_{x\in U}(A(x) + (A \rightarrow B)(x,y) - 1) \vee 0 = \bigvee_{A(x)\leqslant B(y)} A(x) = B(y).$$

从而 θ_{11} 与 $\circ$ 和 $\odot$ 分别配合均得 MP 再现算法.

同理可以验证 θ_5, θ_{13} 与两种推理合成算子 $\circ$ 和 $\odot$ 配合均得 MP 再现算法.

例 3.33 Fuzzy 蕴涵算子 $\rightarrow = \theta_8$ 与推理合成算子 $* = \wedge$ 配合所得的

Fuzzy 推理算法不是 MP 再现算法.这是因为由

$$\theta_8:\quad a \to b = (a \wedge b) \vee (1 - a),$$

与

$$*:\quad a * b = a \wedge b,$$

得

$$\begin{aligned}(A \circ (A \to B))(y) &= \bigvee_{x \in U}(A(x) \wedge ((A(x) \wedge B(y)) \vee (1 - A(x))))\\ &= B(y) \vee (\bigvee_{x \in U}(A(x) \wedge (1 - A(x))))\\ &\leqslant \frac{1}{2} \vee B(y).\end{aligned}$$

从而得证.

但是$\to = \theta_8$ 与 $* = \odot$配合可得 MP 再现算法.这是因为

$$\begin{aligned}&(A \circ (A \to B))(y)\\ &= \bigvee_{x \in U}((A(x) + ((A(x) \wedge B(y)) \vee (1 - A(x))) - 1) \vee 0)\\ &= B(y) \vee ((\bigvee_{x \in U}(A(x) \vee (1 - A(x)) - 1) \vee 0)\\ &= B(y).\end{aligned}$$

从而得证.

以上对几种Fuzzy推理算法进行MP再现分析,所得的结果归纳如表3.16.

表 3.16 Fuzzy 推理算法的 MP 再现分析

$\to$ / $*$	θ_1	θ_3	θ_4	θ_5	θ_8	θ_{11}	θ_{13}
$\wedge$	$0.5 \vee B$	$0.5(1 + B)$	$\sqrt{B}$	B	$0.5 \vee B$	B	B
$\odot$	B	B	B	B	B	B	B

上表列出了 7 种 Fuzzy 蕴涵算子与两种推理合成算子配合所得 14 种 Fuzzy 推理算法,当大前提为 A→B,小前提为 $A^* = A$ 时的推理结果.可以看出,推理合成算子⊙优于∧.

§3.6 3I 方案下的 Fuzzy 推理算法

CRI 方案下的 Fuzzy 推理算法在 Fuzzy 控制的许多方面得到了成功的应用,这不仅吸引了控制领域的众多专家投入 Fuzzy 推理技术的研究与开发,而

且也引起了逻辑学家的关注.

考虑简单 Fuzzy 推理模型 FMT

$$\begin{array}{l} A \to B \\ \underline{A^*} \\ B^* \end{array}$$

所求的 B^* 既与 A^* 有关，又与 $A \to B$ 有关. 首先，B^* 是在给定 A^* 的情况下推得的，所以 $A^* \to B^*$ 应当拥有较高的“真度”. 不过这个真度是以 $A \to B$ 为前提而得到的，所以我们自然希望所求的 B^* 能使

$$(A(x) \to B(y)) \to (A^*(x) \to B^*(y))$$

对一切 $x \in U$ 和 $y \in V$ 取得最大值，或者说，我们希望 $A \to B$ 全力支持 $A^* \to B^*$.

这就是 1997 年以来逐渐形成的 Fuzzy 推理新方案的基本思想[106,107]. 由于其中用到了三次 Implication 算子 $\to$，我们称之为 Fuzzy 推理的 **3I 方案**. 研究表明，新方案下的 Fuzzy 推理算法不仅在一定程度上克服了 CRI 方案下 Fuzzy 推理算法的某些不足，而且也能使 Fuzzy 推理更好地纳入逻辑的轨道.

3.6.1　Fuzzy 推理的 FMP3I 方案

FMP3I 方案　设 U, V 是非空集，$A, A^* \in \mathcal{F}(U), B \in \mathcal{F}(V)$. 则 FMP

$$\begin{array}{l} A \to B \\ \underline{A^*} \\ B^* \end{array} \tag{3.5}$$

中要求的 B^* 是 $\mathcal{F}(V)$ 中使

$$(A(x) \to B(y)) \to (A^*(x) \to B^*(y)) \tag{3.6}$$

取最大值的最小 Fuzzy 集，称 B^* 为(3.5)的 **3I 解**. 特别地，当 Fuzzy 蕴涵算子 $\to$ 满足“当 $a \leqslant b$ 时，$a \to b = 1$”时，B^* 是 $\mathcal{F}(V)$ 中使(3.6)式取值恒为 1 的最小 Fuzzy 集.

那么方案中提到的(3.6)式的最大值是多少？$\mathcal{F}(V)$ 中使(3.6)式取最大值的最小 Fuzzy 集是否存在？我们有下面的分析：

以 $\theta(a,b)$ 记 $a \to b$，这里 $a, b \in [0,1]$，一般都要求 $\theta(a,b)$ 关于 b 是增函数，即当 $b_1 \leqslant b_2$ 时，$\theta(a,b_1) \leqslant \theta(a,b_2)$. 可见(3.6)式的最大可能值是

$$M(x,y) = (A(x) \to B(y)) \to (A^*(x) \to 1). \tag{3.7}$$

特别是当 $\to$ 满足“$a \leqslant b$ 时 $a \to b = 1$”时，对任何 x 和 y 都有 $M(x,y) = 1$. $\mathcal{F}(V)$ 中除最大 Fuzzy 集 $V(y) = 1$ 之外，可能还有较小的 Fuzzy 集也使(3.6)式的值等于 $M(x,y)$，暂且称 $\mathcal{F}(V)$ 中的这种 Fuzzy 集为“好集”. 如果 $\theta(a,b) = a \to b$ 关于 b 是右连续的，则可证若干好集的交仍是好集，从而

FMP3I方案中的那个最小集的确存在.即,下面的定理成立.

定理 3.17 设 $\theta(a,b)=a\to b$.

(1)如果$\theta(a,b)$关于b是增函数,则关于固定的$A(x)$,$B(y)$和$A^*(x)$,(3.7)式中的$M(x,y)$是(3.6)式中当B^*变动时的最大可能值.

(2)如果$\theta(a,b)$关于b还是右连续的,则$\mathscr{F}(V)$中有最小的好集B^*.

证明 只须证(2),设

$$\mathscr{B}=\{B_i \mid B_i\in\mathscr{F}(V),B_i\text{是好集}\},$$

则由$V\in\mathscr{B}$知$\mathscr{B}$非空.固定一对(x,y),则对每个$B_i\in\mathscr{B}$,

$$(A(x)\to B(y))\to(A^*(x)\to B_i(y))\geqslant M(x,y). \tag{3.8}$$

令

$$B^*=\bigcap\{B_i\mid B_i\in\mathscr{B}\}, \tag{3.9}$$

则必有某i_0使$B^*(y)=B_{i_0}(y)$,从而

$$(A(x)\to B(y))\to(A^*(x)\to B^*(y))\geqslant M(x,y). \tag{3.10}$$

因为反之,则$\mathscr{B}$中有$B_{i_1},B_{i_2},\cdots$使

$$B^*(y)=\lim_{n\to\infty}B_{i_n}(y).$$

由于$B_{i_k}(y)>B^*(y)$,所以上式表明$B^*(y)$是$\{B_{i_n}(y)\}$的左极限.由$\theta(a,b)=a\to b$关于b右连续以及(3.8)式当$i=i_n$时成立即得(3.10)式,即B^*是好集,从而有i_0使$B^*(y)=B_{i_0}(y)$,矛盾!故由(3.9)式知B^*是$\mathscr{F}(V)$中最小的好集.

当Fuzzy蕴涵算子$\theta(a,b)=a\to b$满足定理3.17的两个条件时,可以按照FMP 3I方案去求B^*.

3.6.2 Fuzzy推理的Zadeh型FMP3I算法

定理 3.18(Zadeh型FMP3I算法) 设U,V是非空集,$A,A^*\in\mathscr{F}(U)$,$B\in\mathscr{F}(V)$.则FMP

$$\begin{array}{l} A\to B \\ \underline{\quad A^*\quad} \\ B^* \end{array}$$

的**Zadeh型3I解**,即$\mathscr{F}(V)$中使

$$(A(x)\to B(y))\to(A^*(x)\to B^*(y))$$

取最大值的最小Fuzzy集B^*的算法为

$$B^*(y)=\sup_{\substack{x\in E_y\\ \theta_z(A(x),B(y))>\frac{1}{2}}}[A^*(x)\wedge\theta_z(A(x),B(y))],\quad y\in V, \tag{3.11}$$

这里 $E_y=\{x\in U\mid (A^*(x))'<\theta_z(A(x),B(y))\}$.

证明 易见,$\theta_z(a,b)$满足定理3.17的两个条件,从而可以使用FMP3I方案求得B^*.我们的目的是要求出$\mathcal{F}(V)$中的最小B^*以使

$$\theta_z(\theta_z(A(x),B(y)),\theta_z(A^*(x),B^*(y))) \tag{3.12}$$

取得最大值.由Zadeh蕴涵算子θ_z的定义

$$\theta_z(a,b)=a\rightarrow b=a'\vee(a\wedge b),$$

知(3.12)式的值为

$$(\theta_z(A(x),B(y)))'\vee[\theta_z(A(x),B(y))\wedge\theta_z(A^*(x),B^*(y))], \tag{3.13}$$

这里设$y,A,B,$与A^*都已固定,要求对一切可能的$x,B^*(y)$能使(3.13)式的值最大.因为y已固定,为书写简便起见,以$M(x)$记$\theta_z(A(x),B(y))$,则(3.13)式可写为

$$M'(x)\vee[M(x)\wedge\theta_z(A^*(x),B^*(y))]. \tag{3.14}$$

如果x使$M'(x)\geqslant M(x)$,即$M(x)\leqslant\frac{1}{2}$,则(3.14)式可简化为$M'(x)$.因为$B^*(y)$不出现,所以(3.14)式是否取最大值与$B^*(y)$的值无关.如果$M'(x)<M(x)$,即$M(x)>\frac{1}{2}$,则由分配律知(3.14)式可化为

$$M(x)\wedge[M'(x)\vee\theta_z(A^*(x),B^*(y))]. \tag{3.15}$$

其最大可能值为$M(x)$,可于

$$\theta_z(A^*(x),B^*(y))=(A^*(x))'\vee[A^*(x)\wedge B'(y)]\geqslant M(x) \tag{3.16}$$

时达到.

(i)设$x\notin E_y$,即$(A^*(x))'\geqslant(x)$,则上式的成立对$B^*(y)$无任何要求.

(ii)设$x\in E_y$,则(3.16)式等价于

$$A^*(x)\wedge B^*(y)\geqslant M(x). \tag{3.17}$$

令

$$G_y=\{x\in E_y\mid A^*(x)\geqslant M(x)\},$$

$$H_y=\{x\in E_y\mid A^*(x)<M(x)\},$$

则$E_y=G_y\cup H_y$.若$x\in G_y$,则$A^*(x)\geqslant M(x)$,从而由(3.17)式知应有$B^*(y)\geqslant M(x)$.这也可写作$B^*(y)\geqslant A^*(x)\wedge M(x)$.若$x\in H_y$,则$A^*(x)<M(x)$.(3.17)式已不可能成立.这时(3.15)式与$\theta_z(A^*(x),B^*(y))$同时取得最大值,为此可令$B^*(y)\geqslant A^*(x)$.这时也可写作$B^*(y)\geqslant A^*(x)\wedge M(x)$.

综上所述,并注意 B^* 应是 $\mathscr{F}(V)$ 中具有上述性质的最小 Fuzzy 集便得(3.11)式.

例 3.34 设 $A, A^* \in \mathscr{F}(U), B \in \mathscr{F}(V)$,这里 $U = V = [0,1]$,

$$A(x) = \frac{x+1}{3}, \quad A^*(x) = 1 - x, \quad x \in U,$$

$$B(y) = 1 - y, \quad y \in V.$$

按 Zadeh 型 FMP3I 算法求 B^*.

解 由 $(A^*(x))' = x$ 及

$$\theta_z(A(x), B(y)) = \frac{2-x}{3} \vee \left| \frac{x+1}{3} \wedge (1-y) \right|,$$

得

$$E_y = \left\{ x \in [0,1] \mid x < \frac{2-x}{3} \vee \left| \frac{x+1}{3} \vee (1-y) \right| \right\}.$$

由 $x < \frac{2-x}{3}$ 得 $x < \frac{1}{2}$,由 $x < \frac{x+1}{3} \wedge (1-y)$ 得 $x < \frac{1}{2}$ 且 $x < 1-y$.所以

$$E_y = \left\{ x \in [0,1] \mid x < \frac{1}{2} \right\}.$$

又,易证当 $x < \frac{1}{2}$ 时 $\theta_z(A(x), B(y)) > \frac{1}{2}$.且这时 $1 - x > \frac{2-x}{3} > \frac{x+1}{3}$.所以

$$B^*(y) = \sup_{x < \frac{1}{2}} \left\{ (1-x) \wedge \left[\frac{2-x}{3} \vee \left| \frac{x+1}{3} \wedge (1-y) \right| \right] \right\}$$

$$= \sup_{x < \frac{1}{2}} \frac{2-x}{3} = \frac{2}{3}.$$

3.6.3 Fuzzy 推理的 θ_0 型 FMP3I 算法

著名的 Kleene-Dienes 蕴涵算子

$$\theta_{KD}(a,b) = a \to b = a' \vee b$$

本来是经典逻辑中的蕴涵算子,它定义在经典逻辑的真值域 $\{0,1\}$ 之上,并且可等价地表达为

$$\theta_{KD}(a,b) = a \to b = \begin{cases} 1, & a \leqslant b, \\ a' \vee b, & a > b. \end{cases}$$

这除过该算子的自身特性外,还由于经典逻辑的真值域 $\{0,1\}$ 按逻辑运算 $\vee$, 和 $\wedge$ 构成布尔代数,并且这里的一元运算"′"重合于该代数的布尔补.

然而当把 Kleene-Dienes 蕴涵算子原封不动地照搬到 Fuzzy 逻辑的场合时,性质

"当 $a \leqslant b$ 时, $a \to b = 1$" (3.18)

不再保持.这是因为 Fuzzy 逻辑的真值域[0,1]按逻辑运算 $\vee$ 和 $\wedge$ 已不再构成 Boole 代数,它是一个带有逆序对合对应"′"的完全分配格,即 Fuzzy 格.在这种格中一般地互补律不再成立,由此易知当 $a \leqslant b$ 时不能保证 $a' \vee b = 1$ 成立.

但是性质(3.18)正是我们希望能够保持的性质,因为它一方面既满足了经典逻辑的基本要求,另一方面又相当好地符合了人脑通常 Fuzzy 思维的一般模式.因此修改 Kleene-Dienes 蕴涵算子为

$$\theta_0(a,b) = a \to b = \begin{cases} 1, & a \leqslant b, \\ a' \vee b, & a > b, \end{cases}$$

叫做 Fuzzy 推理的 **θ_0 蕴涵算子**,或 **θ_0Fuzzy 蕴涵算子**.

现在我们给出 θ_0 型 FMP31 算法.

定理 3.19(θ_0 型 FMP31 算法) 设 U, V 是非空集,$A, A^* \in \mathscr{F}(U)$,$B \in \mathscr{F}(V)$.则 FMP

$$\begin{array}{l} A \to B \\ \underline{A^*} \\ B^* \end{array}$$

的 **θ_0 型 31 解** B^*,即 $\mathscr{F}(V)$中使

$$(A(x) \to B(y)) \to (A^*(x) \to B^*(y))$$

取值恒为 1 的最小 Fuzzy 集 B^* 的算法为

$$B^*(y) = \sup_{x \in E_y} [A^*(x) \wedge \theta_0(A(x), B(y)], \quad y \in V, \tag{3.19}$$

这里

$$E_y = \{x \in U \mid (A^*(x))' < R_0(A(x), B(y))\}. \tag{3.20}$$

证明 首先证明对 U 中任一固定点 x_0 和任一 $y \in V$,由(3.19)式确定的 B^* 满足

$$\theta_0(A^*(x_0), B^*(y)) \geqslant \theta_0(A(x_0), B(y)), \tag{3.21}$$

从而这个 B^* 可以使

$$(A(x_0) \to B(y)) \to (A^*(x_0) \to B^*(y))$$

取最大值 1.

事实上,设 $x_0 \notin E_y$,则$(A^*(x_0))' \geqslant \theta_0(A(x_0), B(y))$,从而由

$$\theta_0(A^*(x_0), B^*(y)) \geqslant (A^*(x_0))' \vee B^*(y) \tag{3.22}$$

知(3.21)成立.设 $x_0 \in E_y$,令

$$G_y = \{x \in E_y \mid A^*(x) \geqslant \theta_0(A(x), B(y))\},$$

$$H_y = \{x \in E_y \mid A^*(x) \geqslant \theta_0(A(x), B(y))\},$$

则 $E_y=G_y\cup H_y$. 若 $x_0\in G_y$, 则 $A^*(x_0)\geqslant\theta_0(A(x_0),B(y))$. 由(3.19)式知

$$B^*(y)\geqslant A^*(x_0)\wedge\theta_0(A(x_0),B(y))=A^*(x_0),$$

这时 $\theta_0(A^*(x_0),B^*(y))=1$, 从而(3.21)式仍成立. 总之(3.21)式恒成立.

其次证明由(3.19)式确定的 B^* 不能再减小. 事实上, 如果 $B^*(y)=0$, 则 B^* 在 y 点的值显然不能再小. 故可设 $B^*(y)>0$. 这时自然 E_y 非空. 任取 ε 使 $0<\varepsilon<B^*(y)$. 注意到

$$\begin{aligned}B^*(y)&=\sup_{x\in G_y}[A^*(x)\wedge\theta_0(A(x),B(y))]\vee\\&\quad\sup_{x\in H_y}[A^*(x)\wedge\theta_0(A(x),B(y))]\\&=\sup_{x\in G_y}\theta_0(A(x),B(y))\vee\sup_{x\in H_y}A^*(x),\end{aligned}$$

则当

$$g=\sup_{x\in G_y}\theta_0(A(x),B(y))\geqslant h=\sup_{x\in H_y}A^*(x)$$

时, $B^*(y)=g>\varepsilon$. 取 $x_0\in G_y$ 使 $\theta_0(A(x_0),B(y))>g-\varepsilon$, 则 $B^*(y)-\varepsilon<\theta_0(A(x_0),B(y))$. 由 $x_0\in E_y$ 知 $(A^*(x_0))'<\theta_0(A(x_0),B(y))$. 且由 $x_0\in G_y$ 知 $A^*(x_0)\geqslant\theta_0(A(x_0),B(y))>B^*(y)-\varepsilon$. 所以

$$\begin{aligned}&\theta_0(A^*(x_0),B^*(y)-\varepsilon)\\&=(A^*(x_0))'\vee(B^*(y)-\varepsilon)\\&<\theta_0(A(x_0),B(y)).\end{aligned}\tag{3.23}$$

当 $g<h$ 时, $B^*(y)=h$, 取 $x_0\in H_y$ 使 $A^*(x_0)>h-\varepsilon$, 则 $B^*(y)-\varepsilon<A^*(x_0)$. 由 $x_0\in E_y$ 知 $(A^*(x_0))'<\theta_0(A(x_0),B(y))$. 从而

$$\begin{aligned}&\theta_0(A^*(x_0),B^*(y)-\varepsilon)\\&=(A^*(x_0))'\vee(B^*(y)-\varepsilon)\\&<\theta_0(A(x_0),B(y)).\end{aligned}\tag{3.24}$$

由(3.23)和(3.24)两式知由(3.19)式确定的 B^* 是使

$$(A(x)\to B(y))\to(A^*(x)\to B^*(y))$$

取值恒为1的 $\mathscr{F}(V)$ 中最小 Fuzzy 集.

例3.35 设 $U=V=[0,1]$,

$$A(x)=\frac{x+2}{3},\qquad B(y)=1-y,$$

$$A^*(x)=1-x,$$

按 θ_0 型 FMP3I 算法求 B^*.

解 (i)设 $y>\frac{1}{3}$, 则 $\frac{x+2}{3}>1-y$, $\theta_0\left(\frac{x+2}{3},1-y\right)=\frac{1-x}{3}\vee(1-y)$,

$$E_y = \{x \in [0,1] \mid x < \frac{1-x}{3} \vee (1-y)\}.$$

注意到 $0 \in E_y$ 便得

$$B^*(y) = \sup_{x \in E_y} \left\{(1-x) \wedge \left[\frac{1-x}{3} \vee (1-y)\right]\right\}$$

$$= \frac{1}{3} \vee (1-y).$$

(ii)设 $y \leqslant \frac{1}{3}$,则 $1 - y \geqslant \frac{2}{3}$.令 $x \to 0$ 得 $\theta_0\left(\frac{0+2}{3}, 1-y\right) = 1$,从而

$$B^*(y) \geqslant (1-0) \wedge 1 = 1.$$

由(i)与(ii)得

$$B^*(y) = \begin{cases} 1, & y \leqslant \frac{1}{3}, \\ \frac{1}{3} \vee (1-y), & y > \frac{1}{3}. \end{cases}$$

例 3.36　设 $U = V = [0,1]$,

$$A(x) = \frac{x+1}{3}, \qquad B(y) = 1-y,$$

$$A^*(x) = 1-x$$

按 θ_0 型 FMP3I 算法求 B^*.

解　$$E_y = \{x \in [0,1] \mid (A^*(x))' < \theta_0(A(x), B(y))\}$$

$$= \left\{x \in [0,1] \mid x < \theta_0\left(\frac{x+1}{3}, 1-y\right)\right\},$$

$$B^*(y) = \sup_{x \in E_y} \left\{(1-x) \wedge \theta_0\left(\frac{x+1}{3}, 1-y\right)\right\}.$$

因为 $1-x$ 与 $\theta_0\left(\frac{x+1}{3}, 1-y\right)$ 都随 x 的减小而增大,且 $0 \in E_y$,所以

$$B^*(y) = (1-0) \wedge \theta_0\left(\frac{0+1}{3}, 1-y\right) = \theta_0\left(\frac{1}{3}, 1-y\right).$$

由此不难算出

$$B^*(y) = \begin{cases} 1, & y \leqslant \frac{2}{3}, \\ \frac{2}{3}, & y > \frac{2}{3}. \end{cases}$$

定理 3.20　θ_0 型 FMP3I 算法是 MP 再现算法,即当 $A^* = A$ 是正规 Fuzzy 集时 $B^* = B$.

证明　设 $A^*(x) = A(x)$,则

$$E_y = \{x \in U \mid A'(x) < \theta_0(A(x), B(y))\}.$$

若 $B(y)=0$，则由 $A'(x)<\theta_0(A(x),0)$ 不成立知 E_y 为空集，从而按 θ_0 型 3I 算法求得的 $B^*(y)=0$. 若 $B(y)\neq 0$，取 $x_0\in U$ 使 $A(x_0)=1$，则由 $A'(x_0)=0<\theta_0(A(x_0),B(y))$ 知 $x_0\in E_y$. 在(3.19)式中令 $A^*=A$ 得 $B^*(y)\geqslant A(x_0)\wedge\theta_0(A(x_0),B(y))=B(y)$. 又，任取 $x\in E_y$，有 $A'(x)<\theta_0(A(x),B(y))$. 若 $A(x)>B(y)$，则有 $A'(x)<A'(x)\vee B(y)$，即

$$A(x)\wedge\theta_0(A(x),B(y))\leqslant B(y).$$

若 $A(x)\leqslant B(y)$，则 $\theta_0(A(x),B(y))=1$，从而仍有

$$A(x)\wedge\theta_0(A(x),B(y))\leqslant B(y).$$

总之，由(3.19)式知 $B^*(y)\leqslant B(y)$. 从而 $B^*(y)=B(y)$.

同理可以讨论 θ_L 型，θ_G 型，以及 θ_{GR} 型 FMP3I 算法，并且易见前两者都是 MP 再现算法.

3.6.4 Fuzzy 推理的 FMPα-3I 方案与 θ_0 型 FMPα-3I 算法

Fuzzy 推理的 FMP3I 方案所求的推理结果 B^* 是使

$$(A(x)\rightarrow B(y))\rightarrow(A^*(x)\rightarrow B^*(y))$$

取最大值的最小 Fuzzy 集. 换言之，是在已知 A，B 以及 A^* 时寻求最优的 B^* 使得 $A\rightarrow B$ 全力支持 $A^*\rightarrow B^*$.

如果所采用的 Fuzzy 蕴涵算子满足

“当 $a\leqslant b$ 时，$a\rightarrow b=1$”.

比如 θ_0 蕴涵算子，则 FMP3I 方案所求的 B^* 是使

$$(A(x)\rightarrow B(y))\rightarrow(A^*(x)\rightarrow B^*(y))=1$$

的最小 Fuzzy 集. 换句话说，是在已知 A，B，以及 A^* 时寻求最优的 B^* 使得 $A\rightarrow B$ 全力支持 $A^*\rightarrow B^*$，其支持程度为 1.

沿此思路再前进一步，我们可以更深入细致地考虑寻求这样的最优的 B^*，它使得对任何 $x\in U$ 和任何 $y\in V$，

$$(A(x)\rightarrow B(y))\rightarrow(A^*(x)\rightarrow B^*(y))\geqslant\alpha,$$

这里 $\alpha\in[0,1]$. 换句话说，寻求 $\mathscr{F}(V)$ 中最小的 Fuzzy 集 B^* 使得 $A\rightarrow B$ 对 $A^*\rightarrow B^*$ 的支持程度为 α.

由此引出了 FMPα-3I 方案，FMPα-3I 算法，以及支持度的话题.

FMPα-3I 方案 设 U，V 是非空集，A，$A^*\in\mathscr{F}(U)$，$B\in\mathscr{F}(V)$. 则 FMP

$$\begin{array}{l} A\rightarrow B \\ \underline{A^*} \\ B^* \end{array} \tag{3.25}$$

中要求的 B^* 是 $\mathscr{F}(V)$ 中使

$$(A(x)\rightarrow B(y))\rightarrow(A^*(x)\rightarrow B^*(y))\geqslant\alpha \tag{3.26}$$

对一切 $x\in U$ 和一切 $y\in V$ 都成立的最小 Fuzzy 集,这里 $\alpha\in[0,1]$. 称 B^* 为 FMP(3.6.25)的 **α-3I 解**.

定理 3.21 当取 Fuzzy 蕴涵算子→为 θ_0 算子时,FMP

$$\begin{array}{l} A\to B \\ \underline{A^*} \\ B^* \end{array}$$

的 α-3I 解一定是存在的.

证明 令 $\mathscr{B}=\{B^*\in\mathscr{F}(V), B^*$ 满足(3.26)$\}$,则由 $V\in\mathscr{B}$ 知 $\mathscr{B}$ 非空. 令 $\hat{B}=\bigcap\{B^*\mid B^*\in\mathscr{B}\}$,则 $\hat{B}\in\mathscr{F}(V)$. 以下只须证明对一切 $x\in U$ 和一切 $y\in V$ 都有

$$(A(x)\to B(y))\to(A^*(x)\to\hat{B}(y))\geqslant\alpha. \tag{3.27}$$

因为 $\hat{B}$的最小性是明显的,反设(3.27)不成立,则有 $x_0\in U$ 和 $y_0\in V$ 使

$$(A(x_0)\to B(y_0))\to(A^*(x_0)\to\hat{B}(y_0))<\alpha. \tag{3.28}$$

因为 $\theta_0(a,b)$关于 b 右连续,即

$$\lim_{\substack{b\to b_0\\ b\geqslant b_0}}\theta_0(a_0,b)=\theta_0(a_0,b_0). \tag{3.29}$$

设$\theta_0(A(x_0),B(y_0))=c$, $\theta_0(A^*(x_0),\hat{B}(y_0))=d$,则(3.28)式左边等于 $\theta_0(c,d)$. 由$\hat{B}=\bigcap\{B^*\mid B^*\in\mathscr{B}\}$知$\mathscr{B}$中有$B_1,B_2,\cdots$使$\lim\limits_{n\to\infty}B_n(y_0)=\hat{B}(y_0)$. 注意 $B_n(y_0)\geqslant\hat{B}(y_0)$,则由(3.29)式得

$$\lim_{n\to\infty}\theta_0(A^*(x_0),B_n(y_0))=\theta_0(A^*(x_0),\hat{B}(y_0))=d.$$

又 $\theta_0(a,b)$是关于 b 的增函数,$\theta_0(A^*(x_0),B_n(y_0))\geqslant d$ 恒成立,所以再次使用(3.29)式得

$$\lim_{n\to\infty}\theta_0(c,\theta_0(A^*(x_0),B_n(y_0)))=\theta_0(c,d),$$

那么由(3.28)式知有 n 使

$$\theta_0(c,\theta_0(A^*(x_0),B_n(y_0)))<\alpha,$$

即

$$(A(x_0)\to B(y_0))\to(A^*(x_0)\to B_n(y_0))<\alpha.$$

这与 $B_n\in\mathscr{B}$ 相矛盾!

在给出 FMPα-3I 算法之前,先来建立支持度的概念. 我们把刚才关于"支持程度"的想法推广到适用于任意两个Fuzzy集之间的情形. 因为$A(x)\to B(y)=(A\to B)(x,y)$与 $A^*(x)\to B^*(y)=(A^*\to B^*)(x,y)$都是 $U\times V$

上的Fuzzy集，令 $W=U\times V$，我们考虑 W 上任两Fuzzy集 C 与 D 之间的支持关系.

定义3.27（支持度） 设 W 是非空集，$C,D\in\mathscr{F}(W)$.若

$$\inf\{C(z)\to D(z)\mid z\in W\}=\alpha,$$

则称 C 对 D 的**支持度**为 α，记作 $\mathrm{sust}(C,D)=\alpha$.

显然，$\alpha\in[0,1]$.又，当取Fuzzy蕴涵算子 $\to$ 为 θ_0 算子时，$\mathrm{sust}(C,D)=1$ 当且仅当 $C\subseteq D$；特别地，$\varnothing$ 对任何 D 的支持度都等于1；任何 C 对 W 的支持度都为1.

当Fuzzy蕴涵算子 $\to$ 取 θ_0 算子时，支持度有以下性质.

定理3.22 对 $\mathscr{F}(W)$ 中的Fuzzy集而言，

(1) 如果 $\mathrm{sust}(A,B)=\alpha>\frac{1}{2}$，$\mathrm{sust}(B,C)=\beta>\frac{1}{2}$，则 $\mathrm{sust}(A,C)\geqslant\alpha\wedge\beta$.

(2) $\mathrm{sust}(\bigvee\limits_{i\in I}A_i,B)=\bigwedge\limits_{i\in I}\mathrm{sust}(A_i,B)$.

(3) $\mathrm{sust}(A,\bigwedge\limits_{i\in I}B_i)=\bigwedge\limits_{i\in I}\mathrm{sust}(A,B_i)$.

(4) $\mathrm{sust}(A,B\to C)=\mathrm{sust}(B,A\to C)$.

(5) $\mathrm{sust}(A,B\to C)=\mathrm{sust}(A,C'\to B')$.

(6) $\mathrm{sust}(A,\bigvee\limits_{i\in I}B_i\to C)=\bigwedge\limits_{i\in I}\mathrm{sust}(A,B_i\to C)$.

(7) $\mathrm{sust}(A,B\to\bigwedge\limits_{i\in I}C_i)=\bigwedge\limits_{i\in I}\mathrm{sust}(A,B\to C_i)$.

现在给出 θ_0 型 FMPα-3I 算法.

定理3.23（θ_0 型 FMPα-3I 算法） 设 U,V 是非空集，$A,A^*\in\mathscr{F}(U)$，$B\in\mathscr{F}(V)$.则FMP

$$\begin{array}{l}A\to B\\ \underline{\quad A^*\quad}\\ B^*\end{array}$$

的 **θ_0 型 α-3I 解** B^*，即 $\mathscr{F}(V)$ 中使

$$(A(x)\to B(y))\to(A^*(x)\to B^*(y))\geqslant\alpha \tag{3.30}$$

的最小Fuzzy集 B^* 的算法为

$$B^*(y)=\sup_{x\in E_y\cap K_y}[A^*(x)\wedge\theta_0(A(x),B(y))]\wedge\alpha, \tag{3.31}$$

这里

$$E_y=\{x\in U\mid(A^*(x))'<\theta_0(A(x),B(y))\}, \tag{3.32}$$

$$K_y=\{x\in U\mid A^*(x)\wedge\theta_0(A(x),B(y))>\alpha'\}. \tag{3.33}$$

证明 先证由(3.31)式确定的 B^* 满足(3.30)式.事实上，令

$$C(y) = \sup_{x\in E_y\cap K_y}[A^*(x)\wedge\theta_0(A(x),B(y))], \tag{3.34}$$

则$B^*(y)=C(y)\wedge\alpha$. 由定理3.22的(7),只须证明$A\to B$时$A^*\to C$的支持度和$A\to B$对$A^*\to\alpha$的支持度都大于或等于α. 但由$A^*(x)\to\alpha=\theta_0(A^*(x),\alpha)\geqslant\alpha$知后者成立.所以以下只须证

$$M_{xy}=(A(x)\to B(y))\to(A^*(x)\to C(y))\geqslant\alpha. \tag{3.35}$$

设$x\in E_y\cap K_y$,则$C(y)\geqslant A^*(x)\wedge\theta_0(A(x),B(y))$.这时

$$\begin{aligned}M_{xy}&=\theta_0(A(x),B(y))\to\theta_0(A^*(x),A^*(x)\wedge\theta_0(A(x),B(y)))\\&=\theta_0(A(x),B(y))\to\theta_0(A^*(x),A^*(x))\wedge\theta_0(A^*(x),\\&\quad\theta_0(A(x),B(y)))\\&=\theta_0(A(x),B(y))\to\theta_0(A^*(x),\theta_0(A(x),B(y))).\end{aligned}$$

注意$\theta_0(a,b)\geqslant a'\vee b\geqslant b$,得

$$M_{xy}\geqslant\theta_0(A(x),B(y))\to\theta_0(A(x),B(y))=1\geqslant\alpha.$$

设$x\notin E_y$,则由(3.32)式有

$$(A^*(x))'\geqslant\theta_0(A(x),B(y)),$$

这时

$$M_{xy}\geqslant\theta_0(A(x),B(y))\to(A^*(x))'\vee C(y)=1\geqslant\alpha.$$

设$x\notin K_y$,则由(3.33)式知$(A^*(x))'\geqslant\alpha$或$(\theta_0(A(x),B(y)))'\geqslant\alpha$,所以仍有

$$\begin{aligned}M_{xy}&\geqslant(\theta_0(A(x),B(y)))'\vee\theta_0(A^*(x),C(y))\\&=(\theta_0(A(x),B(y)))'\vee(A^*(x))'\vee C(y)\geqslant\alpha.\end{aligned}$$

总之(3.35)式从而(3.30)式成立.

其次证明B^*是$\mathcal{F}(V)$中使(3.30)式成立的最小 Fuzzy 集.设$D\in\mathcal{F}(V)$且对某$y\in V$,$D(y)<B^*(y)$,则$D(y)<C(y)$且$D(y)<\alpha$.这时有$x_0\in E_y\cap K_y$使

$$D(y)<A^*(x_0)\wedge\theta_0(A(x_0),B(y)).$$

由$D(y)<A^*(x_0)$知$\theta_0(A^*(x_0),D(y))=(A^*(x_0))'\vee D(y)$.又$x_0\in E_y$,所以$(A^*(x_0))'<\theta_0(A(x_0),B(y))$,从而

$$\theta_0(A^*(x_0),D(y))<\theta_0(A(x_0),B(y)).$$

由此得

$$\begin{aligned}&\theta_0(A(x_0),B(y))\to\theta_0(A^*(x_0),D(y))\\&=(\theta_0(A(x_0),B(y)))'\vee\theta_0(A^*(x_0),D(y))\\&=(\theta_0(A(x_0),B(y)))'\vee(A^*(x_0))'\vee D(y).\end{aligned}$$

又 $x_0\in K_y$, $(\theta_0(A(x_0),B(y)))'<\alpha$ 且 $(A^*(x_0))'<\alpha$, 以及 $D(y)<\alpha$, 所以

$$\theta_0(A(x_0),B(y))\to\theta_0(A^*(x_0),D(y))<\alpha,$$

即

$$(A(x_0)\to B(y))\to(A^*(x_0)\to D(y))<\alpha,$$

也即用 D 取代 B^* 时(3.30)式不恒成立. 这就证明了 B^* 的最小性.

例 3.37 设 $U=V=[0,1]$, $A,A^*\in\mathscr{F}(U)$, $B\in\mathscr{F}(V)$, $A(x)=\frac{x+1}{3}$, $B(y)=1-y$, $A^*(x)=1-x$, $\alpha=\frac{7}{9}$. 按 θ_0 型 FMP3I 算法求 B^*.

解

$$E_y=\left\{x\in[0,1]\mid x<\theta_0\left(\frac{x+1}{3},1-y\right)\right\},$$

$$K_y=\left\{x\in[0,1]\mid(1-x)\wedge\theta_0\left(\frac{x+1}{3},1-y\right)>\frac{2}{9}\right\},$$

$$B^*(y)=\sup_{x\in E_y\cap K_y}\left[(1-x)\wedge\theta_0\left(\frac{x+1}{3},1-y\right)\right]\wedge\frac{7}{9}. \tag{3.36}$$

因为 $1-x$ 与 $\theta_0\left(\frac{x+1}{3},1-y\right)$ 都随 x 的减小而增大, 所以为求(3.31)中的上确界, 只须找出 $E_y\cap K_y$ 中最小的 x. 显然 $0\in E_y$, 又, 由

$$\theta_0\left(\frac{x+1}{3},1-y\right)\geqslant\frac{2-x}{3}\vee(1-y)$$

知 $0\in K_y$. 所以 $0\in E_y\cap K_y$. 从而

$$B^*(y)=(1-0)\wedge\theta_0\left(\frac{1}{3},1-y\right)\wedge\frac{7}{9},$$

化简得

$$B^*(y)=\begin{cases}\frac{7}{9}, & y\leqslant\frac{2}{3},\\ \frac{2}{3}, & y>\frac{2}{3}.\end{cases}$$

3.6.5 Fuzzy 推理的 FMT3I 方案与 θ_0 型 FMT3I 算法

经典逻辑中, Modus Ponens 的反向问题是

$$\frac{A\to B\qquad B}{A} \tag{3.37}$$

叫做 **Modus Tollens**, 简称 **MT**.

Fuzzy 逻辑中, Fuzzy Modus Ponens 的反向问题是

$$\begin{array}{l} A \to B \\ \underline{\quad\quad B^* \quad\quad} \\ A^* \end{array} \tag{3.38}$$

叫做 **Fuzzy Modus Tollens**,简称 **FMT**.这里 A, A^* 是论域 U 上的 Fuzzy 集,B, B^* 是论域 V 上的 Fuzzy 集.

FMP3I 方案的思想也可以用来解决 FMT 问题.

FMT3I 方案 设 U, V 是非空集,$A \in \mathscr{F}(U), B, B^* \in \mathscr{F}(V)$.则 FMT

$$\begin{array}{l} A \to B \\ \underline{\quad\quad B^* \quad\quad} \\ A^* \end{array} \tag{3.39}$$

中要求的 A^* 是 $\mathscr{F}(U)$中使

$$(A(x) \to B(y)) \to (A^*(x) \to B^*(y)) \tag{3.40}$$

取最大值的最大 Fuzzy 集,称 A^* 是(3.39)的 **3I 解**.特别地,当 Fuzzy 蕴涵算子满足"当 $a \leqslant b$ 时,$a \to b = 1$"时,A^* 是使(3.40)式取值恒为 1 的 $\mathscr{F}(U)$中最大 Fuzzy 集.

注 3.4 当 A, B 与 B^* 给定后,令 $A^*(x) \equiv 0$ 就可使(3.40)式的值恒等于 1,这里假定我们采用的 Fuzzy 蕴涵算子满足"当 $a \leqslant b$ 时,$a \to b = 1$".但是这种 A^* 是无用的,因为这时无论怎样改变 A, B 与 B^*,(3.40)式的值总是 1,所以这个 A^* 实际上与 $A \to B$ 以及 B^* 无关,没有为我们提供任何有价值的信息.A^* 越大,(3.40)式的值越不容易等于 1.我们要求的是恰好能使(3.40)式的值等于 1 的 $\mathscr{F}(U)$中的最大 Fuzzy 集.

定理 3.24 (θ_0 型 FMT3I 算法) 设 U, V 是非空集,$A \in \mathscr{F}(U), B, B^* \in \mathscr{F}(V)$.则 FMT

$$\begin{array}{l} A \to B \\ \underline{\quad\quad B^* \quad\quad} \\ A^* \end{array} \tag{3.41}$$

的 **θ_0 型 3I 解** A^*,即使

$$(A(x) \to B(y)) \to (A^*(x) \to B^*(y))$$

取值恒为 1 的 $\mathscr{F}(U)$中最大 Fuzzy 集 A^* 的算法为

$$A^*(x) = \inf_{y \in F_x} [B^*(y) \vee (\theta_0(A(x), B(y)))'], \tag{3.42}$$

这里

$$F_x = \{y \in V \mid B^*(y) < \theta_0(A(x), B(y))\}. \tag{3.43}$$

定理 3.24 的证明将在证明定理 3.26 后作为其特例而给出.

定理 3.25 θ_0 型 FMT3I 算法是 **MT 再现算法**,即当 $B^* = B$ 的补集 B'

是正规Fuzzy集时,按 θ_0 型FMT3I算法求得的 $A^*=A$.

证明 设 $B^*=B$,则由(3.43)式得

$$\begin{aligned}E_x&=\{y\in V\mid B(y)<\theta_0(A(x),B(y))\}\\&=\{y\in V\mid A(x)\leqslant B(y)<1\}\cup\{y\in V\mid B(y)<A(x)\\&\quad\text{且 }B(y)<A'(x)\vee B(y)\}\\&=\{y\in V\mid A(x)\leqslant B(y)<1\}\cup\{y\in V\mid B(y)<A(x)\wedge A'(x)\},\end{aligned}$$

所以由(3.42)式得

$$A^*(x)=\inf_{A(x)\leqslant B(y)<1}B(y)\wedge\inf_{B(y)<A(x)\wedge A'(x)}(B(y)\vee(A(x)\wedge B'(y))).\tag{3.44}$$

上式中右边第1部分当有 y 使 $A(x)\leqslant B(y)<1$ 成立时显然大于或等于 $A(x)$,而当 $A(x)\leqslant B(y)<1$ 不能成立时这部分作为空集的下确界等于1,仍大于 $A(x)$.先设 $A(x)\neq 1$ 且 $A(x)\neq 0$.这时有 $x\in U$ 使 $A(x)>0$ 且 $A'(x)>0$,从而 $A(x)\wedge A'(x)>0$.这时由有 $y_0\in V$ 使 $B(y_0)=0$ 知 $\{y\in V\mid B(y)<A(x)\wedge A'(x)\}$ 非空,从而(3.44)式右边的第2部分等于

$$\inf_{B(y)<A(x)\wedge A'(x)}(B(y)\vee A(x))\wedge\inf_{B(y)<A(x)\wedge A'(x)}(B(y)\vee B'(y)).\tag{3.45}$$

(3.45)式中的第1部分显然等于 $A(x)$,而第2部分则大于或等于

$$\inf_{B(y)<A(x)\wedge A'(x)}B'(y)\geqslant(A(x)\wedge A'(x))'=A'(x)\vee A(x)\geqslant A(x).$$

可见 $A^*(x)$ 等于三部分之交,其中一部分等于 $A(x)$ 而其余两部分都大于或等于 $A(x)$.所以 $A^*(x)=A(x)$.

现在设 $A(x)=1$,这时

$$\{y\in V\mid A(x)\leqslant B(y)<1\}=\{y\in V\mid B(y)<A(x)\wedge A'(x)\}=\varnothing$$

注意[0,1]中空集的下确界等于1,则由(3.44)式得 $A^*(x)=1$.若 $A(x)=0$,则因有 $y_0\in V$ 使 $B(y_0)=0$,(3.44)式右边的第1部分等于0,从而 $A'(x)=0$.

综上所述知 $A^*=A$ 成立.

例3.38 设 $U=V=[0,1]$,$A\in\mathscr{F}(U)$,$B,B^*\in\mathscr{F}(V)$,$A(x)=1-x$,$B(y)=y$,$B^*(y)=y^2$.按 θ_0 型FMT3I算法求 A^*.

解 $E_x=\{y\in[0,1]\mid y^2<\theta_0(1-x,y)\}$,

若 $y\geqslant 1-x$,则 $\theta_0(1-x,y)=1$,所以满足 $1-x\leqslant y<1$ 的 y 都属于 E_x.又若 $y<1-x$,则 $\theta_0(1-x,y)=x\vee y$,这时由 $y<1$ 知 $y^2<x\vee y$ 恒成立,所以满

足 $y<1-x$ 的 y 也属于 E_x，由此可知

$$E_x=\{y\in[0,1]\mid y<1\},$$

所以由(3.42)式得

$$\begin{aligned}A^*(x)&=\inf_{y<1}[y^2\vee(\theta_0(1-x,y))']\\&=\inf_{\substack{y<1\\1-x\leqslant y}}[y^2\vee(\theta_0(1-x,y))']\wedge\inf_{\substack{y<1\\1-x>y}}[y^2\vee(\theta_0(1-x,y))']\\&=(1-x)^2\wedge\inf_{y<1-x}[y^2\vee(1-x)]\wedge\inf_{y<1}[y^2\vee(1-y)].\end{aligned}\tag{3.46}$$

上式中中间部分等于 $1-x$，由 $(1-x)^2\leqslant 1-x$ 知中间部分可以略去，以下计算最后的部分 $\inf_{y<1}[y^2\vee(1-y)]$.

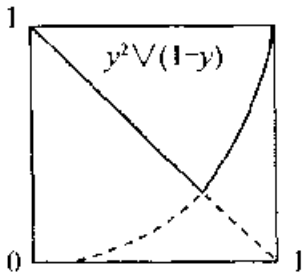


图 3.39　y^2 与 $1-y$ 的并

由图 3.39 易见

$$y^2\vee(1-y)=\begin{cases}1-y, & y<\dfrac{\sqrt{5}-1}{2},\\ y^2, & y\geqslant\dfrac{\sqrt{5}-1}{2},\end{cases}$$

由此得

$$\inf_{y<1}[y^2\vee(1-y)]=\begin{cases}x, & 1-x<\dfrac{\sqrt{5}-1}{2},\\ \left(\dfrac{\sqrt{5}-1}{2}\right)^2, & 1-x\geqslant\dfrac{\sqrt{5}-1}{2},\end{cases}$$

所以由(3.6.41)式得

$$A^*(x)=\begin{cases}x\wedge(1-x)^2, & 1-x<\dfrac{\sqrt{5}-1}{2},\\ \left(\dfrac{\sqrt{5}-1}{2}\right)^2=\dfrac{3-\sqrt{5}}{2}, & 1-x\geqslant\dfrac{\sqrt{5}-1}{2}.\end{cases}$$

例 3.39　设 $U=V=[0,1]$，$A\in\mathcal{F}(U)$，$B,B^*\in\mathcal{F}(V)$，$A(x)=\dfrac{x+1}{3}$，$B(y)=1-y$，

$$B^*(y)=\begin{cases}1, & y\leqslant\dfrac{2}{3},\\ \dfrac{2}{3}, & y>\dfrac{2}{3},\end{cases}\tag{3.47}$$

按 θ_0 型 FMT3I 算法求 A^*.

解 $E_x=\left\{y\in[0,1]\mid B^*(y)<\theta_0\left(\frac{x+1}{3},1-y\right)\right\}$,

若$\frac{x+1}{3}\leqslant 1-y$,则 $\theta_0\left(\frac{x+1}{3},1-y\right)=1$. 这时 $y\leqslant\frac{2-x}{3}\leqslant\frac{2}{3}$,从而由 $B^*(y)$ 的定义知 $B^*(y)=1$. 可见满足条件$\frac{x+1}{3}\leqslant 1$ y 的 y 不属于 E_x. 若$\frac{x+1}{3}>1$ y,则 $\theta_0\left(\frac{x+1}{3},1-y\right)=\frac{2-x}{3}\vee(1$ $y)$. 这时 $\theta_0\left(\frac{x+1}{3},1-y\right)\leqslant\frac{2-x}{3}\vee$ $\frac{x+1}{3}\leqslant\frac{2}{3}$. 由 $B^*(y)$的定义知满足条件$\frac{x+1}{3}>1$ $-y$ 的 y 仍不属于 E_x,所以 $E_x=\varnothing$,从而 $A^*(x)=\inf\varnothing=1$.

3.6.6 Fuzzy推理的FMTα-3I方案与 θ_0 型FMTα-3I算法

与FMPα-3I方案的思想类似地,可以寻求$\mathscr{F}(U)$中最优的 A^*,使得 $A\to B$ 对 $A^*\to B^*$ 的支持程度为 α,即,寻求 $\mathscr{F}(U)$中最大的 Fuzzy 集 A^*,使对任何 $x\in U$ 和任何 $y\in V$,

$$(A(x)\to B(y))\to(A^*(x)\to B^*(y))\geqslant\alpha,$$

这里 $\alpha\in[0,1]$. 这就是 Fuzzy 推理的 FMTα-3I 方案.

FMTα-3I方案 设 U,V 是非空集,$A\in\mathscr{F}(U)$,$B,B^*\in\mathscr{F}(V)$.则 FMT

$$\frac{A\to B}{\underline{\quad B^*\quad}}\qquad(3.48)$$
$$A^*$$

中要求的 A^* 是 $\mathscr{F}(U)$中使

$$(A(x)\to B(y))\to(A^*(x)\to B^*(y))\geqslant\alpha\qquad(3.49)$$

对一切 $x\in U$ 和一切 $y\in V$ 都成立的最大 Fuzzy 集,这里 $\alpha\in[0,1]$. 称 A^* 为 FMT(3.6.43)的 **α-3I解**.

定理 3.26 (θ_0 型 FMTα-3I 算法) 设 U,V 是非空集,$A\in\mathscr{F}(U)$,B,$B^*\in\mathscr{F}(V)$.则 FMT

$$\frac{A\to B}{\underline{\quad B^*\quad}}$$
$$A^*$$

的 **θ_0 型3I解** A^*,即 $\mathscr{F}(U)$中使

$$(A(x)\to B(y))\to(A^*(x)\to B^*(y))\geqslant\alpha$$

的最大 Fuzzy 集 A^* 的算法为

$$A^*(x) = \inf_{y \in E_x \cap K_x} [B^*(y) \vee (\theta_0(A(x), B(y)))'] \vee \alpha', \quad (3.50)$$

这里

$$E_x = \{y \in V \mid B^*(y) < \theta_0(A(x), B(y))\}, \quad (3.51)$$

$$K_x = \{y \in V \mid B^*(y) \vee (\theta_0(A(x), B(y)))' < \alpha\}. \quad (3.52)$$

证明 先证由(3.50)式确定的 A^* 满足(3.49)式. 事实上,令

$$C(x) = \inf_{y \in E_x \cap K_x} [B^*(y) \vee (\theta_0(A(x), B(y)))'],$$

则 $A^*(x) = C(x) \vee \alpha'$. 因为

$$(A(x) \to B(y)) \to (\alpha', B^*(y)) \geqslant \alpha$$

恒成立,所以由定理 3.22 的(6),只须证明

$$N_{xy} = (A(x) \to B(y)) \to ((C(x) \to B^*(y)) \geqslant \alpha \quad (3.53)$$

恒成立

设 $y \in E_x \cap K_x$,则 $C(x) \leqslant B^*(y) \vee (\theta_0(A(x), B(y)))'$,所以

$$N_{xy} \geqslant \theta_0(A(x), B(y)) \to \theta_0(B^*(y) \vee (\theta_0(A(x), B(y)))', B^*(y))$$

$$\geqslant \theta_0(A(x), B(y)) \to \theta_0(\theta_0(A(x), B(y)))', B^*(y))$$

$$\geqslant \theta_0(A(x), B(y)) \to \theta_0(A(x), By)) = 1 \geqslant \alpha.$$

设 $y \notin E_x$,则 $B^*(y) \geqslant \theta_0(A(x), B(y))$,从而

$$N_{xy} \geqslant \theta_0(A(x), B(y)) \to C'(x) \vee B^*(y) = 1 \geqslant \alpha.$$

设 $y \notin K_x$,则 $B^*(y) \vee (\theta_0(A(x), B(y)))' \geqslant \alpha$,从而

$$N_{xy} \geqslant (\theta_0(A(x), B(y)))' \vee C'(x) \vee B^*(y) \geqslant \alpha.$$

总之(3.53)式成立,从而由(3.50)式确定的 A^* 满足(3.49)式.

其次证明 A^* 是 $\mathcal{F}(U)$ 中使(3.49)式成立的最大 Fuzzy 集. 设 $D \in \mathcal{F}(U)$ 且对某 $x \in U$, $D(x) > A^*(x)$,则 $D(x) > C(x)$ 且 $D(x) > \alpha'$,即 $D(x) > C(x)$ 且 $D'(x) < \alpha$. 这时有 $y_0 \in E_x \cap K_x$ 使

$$D(x) > B^*(y_0) \vee (\theta_0(A(x), B(y_0)))',$$

那么 $D'(x) < \theta_0(A(x), B(y_0))$. 由 $D(x) > B^*(y_0)$ 知 $\theta_0(D(x), B^*(y))$ $= D'(x) \vee B^*(y_0)$,又由 $y_0 \in E_x$ 知 $B^*(y_0) < \theta_0(A(x), B(y))$. 那么

$$\theta_0(D(x), B^*(y)) < \theta_0(A(x), B(y)).$$

由此得

$$\theta_0(A(x), B(y)) \to \theta_0(D(x), B^*(y_0))$$

$$= (\theta_0(A(x), B(y_0)))' \vee D'(x) \vee B^*(y_0).$$

又 $y_0 \in K_x$, $B^*(y_0) \vee (\theta_0(A(x), B(y_0)))' < \alpha$, 以及 $D'(x) < \alpha$, 所以 $\theta_0(A(x), B(y_0)) \to \theta_0(D(x), B^*(y_0)) < \alpha$, 即

$$(A(x) \to B(y_0)) \to (D(x) \to B^*(y_0)) < \alpha$$

也即当用 D 取代 A^* 时(3.49)式不恒成立. 这就证明了 A^* 的最大性.

当 $\alpha = 1$ 时,

$$K_x = \{y \in V \mid B^*(y) \vee (\theta_0(A(x), B(y)))' < 1\}.$$

从而(3.50)式成为

$$A^*(x) = \inf\{B^*(y) \vee (\theta_0(A(x), B(y)))' \mid y \in E, \text{ 且 } B^*(y) \vee (\theta_0(A(x), B(y)))' < 1\}.$$

这与(3.42)式等价. 从而证得定理 3.24 成立.

§3.7 应用举例:Fuzzy 逻辑控制

按照 Fuzzy 集合论奠基人 L.A.Zadeh 教授的最初设想, Fuzzy 理论将主要地用于人类主观因素起主导作用的领域如人文科学和社会科学, 在这些领域人们更多地使用 Fuzzy 语言进行分析、判断、推理、决策和交流. 然而 Fuzzy 理论却在自动控制领域得到了最广泛和最成功的应用. 1974 年英国科学家 H.E.Mamdani 首次将 Fuzzy 推理应用于热电厂蒸汽机的自动控制并获成功, 此为 Fuzzy 逻辑控制的开始. 热电厂蒸汽机控制系统是一个非线性的多变量的复杂控制系统, 采用常规控制方法得不到满意的效果, 直到采用 Fuzzy 逻辑控制后才得到圆满的解决. 随着计算机技术的迅速发展, Fuzzy 逻辑控制技术在 20 世纪 90 年代得到蓬勃发展, 并被广泛应用于工业控制、家用电器以及国防军事等诸多领域.

Fuzzy 逻辑控制之所以大获成功, 其主要原因是

(1)Fuzzy 集合的引入改善了经典逻辑中生硬的分类方法, 使用于控制的逻辑更加接近于人类思维方式. 在很多工业控制中, 熟练工人对系统控制的经验可直接用于控制器中.

(2)Fuzzy 控制系统可以解决复杂系统的控制问题. 当系统为多输入多输出、强非线性、时变及滞后系统时, 系统的数学模型非常复杂或根本就不存在, 难以或不能用常规控制方法进行控制. 而 Fuzzy 控制则建立在对过程的语言型经验之上, 不需要确定的数学模型.

(3)Fuzzy 控制也适合于一般控制问题.对于一般的控制问题,尽管可以采用常规控制方法,同样也可以采用 Fuzzy 控制方法.Fuzzy 控制器的控制效果在快速性和鲁棒性等方面都优于常规控制器.

(4)由于在 Fuzzy 控制系统中直接采用人类语言型控制规则,使得控制机理和控制策略易于理解和接受,并且设计简单,便于维护和推广.

(5)由于控制规则可以不断丰富和完善,又加上克服了人类机体自身的不足使得 Fuzzy 控制器优于熟练工人的手动控制.

(6)控制规则之间的 Fuzzy 联接,使得控制器在相互矛盾的控制规则中也能找到折中的选择,使之更接近于人类的智慧.

(7)在常规控制方法中干扰或参数的变动可能会引起整个系统工作不正常.在 Fuzzy 控制中由于采用了 Fuzzy 集概念及 Fuzzy 联接,干扰和参数的变化对控制效果影响非常小.

(8)随着 Fuzzy 控制系统软硬件的开发与发展,Fuzzy 控制系统的设计、维修和保养将变得越来越简单,成本也越来越低.

Fuzzy 逻辑控制技术适用于被控过程没有数学模型或很难建立数学模型的工业过程,这些过程参数变动,时变,呈现极强的非线性特征.Fuzzy 控制不需要确定的数学模型,是解决不确定性系统控制问题的一种有效途径.

3.7.1 Fuzzy 控制器的设计

Fuzzy 控制器的设计就是依据控制问题,确定控制器的使用方式后,设计出适合于被控过程的控制器,使之能达到预定的目标.其具体步骤如下.

1. 选定 Fuzzy 控制器的输入输出变量

根据控制问题确定输入和输出变量.大多数 Fuzzy 控制系统中常选择系统偏差 e 和偏差变化率 ce 作为输入变量,调节量的变化作为输出变量.这有利于通过调节量变化的调整,使系统偏差减少.

2. 确定输入输出变量的语言值域及各语言值的隶属函数

语言值的数目常选为 3 个,5 个和 7 个,比如

3 个语言值

$$\{N, Z, P\} \quad 或 \quad \{-, 0, +\}.$$

5 个语言值

$$\{N_+, N_-, Z, P_-, P_+\} \quad 或 \quad \{--, -, 0, +, ++\}.$$

7 个语言值

$$\{\mathrm{NB}, \mathrm{NM}, \mathrm{NS}, \mathrm{ZR}, \mathrm{PS}, \mathrm{PM}, \mathrm{PB}\},$$

其中字母含义分别为

N:Negative, Z:Zero, P:Positive,

B:Big, M:Middle, S:Small.

隶属函数常常在取值范围内均匀分布.若某个取值范围需要敏感一些,则相应的隶属函数可取"密"一些.

图 3.40 是 Fuzzy 变量

$$A \in \{\text{very low, low, medium, high, very high}\}$$

的隶属函数定义.在取值范围内隶属函数的定义是均匀的,其中 Fuzzy 集 high 的隶属函数为

$$\text{high}(x) = \begin{cases} 0, & x < 50, \\ 0.05(x-50), & 50 \leqslant x < 70, \\ 0.05(90-x), & 70 \leqslant x < 90, \\ 0, & 90 \leqslant x. \end{cases}$$

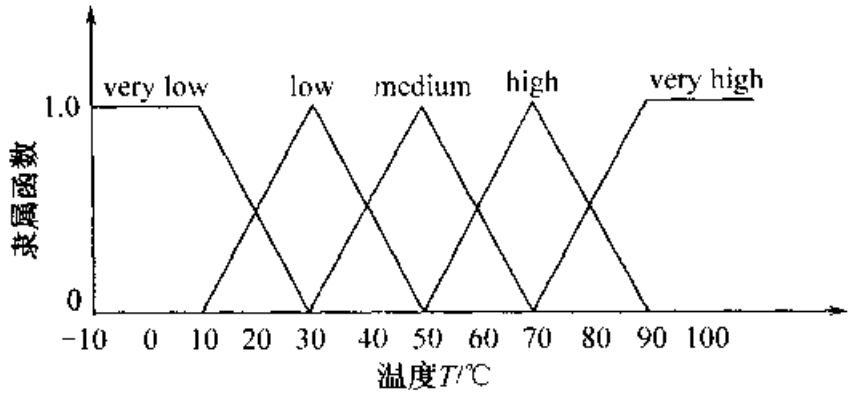


图 3.40 均匀分布的隶属函数

图 3.41 是 Fuzzy 变量

$$B \in \{\text{NB, NM, NS, ZR, PS, PM, PB}\}$$

的隶属函数.在 0 附近隶属函数定义较密,因此在 0 附近结果的变化是很敏感

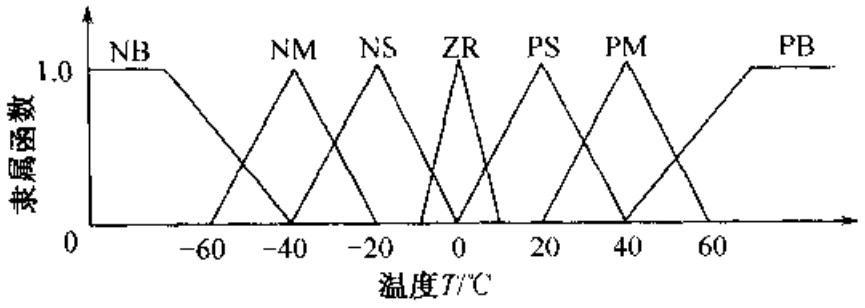


图 3.41 非均匀分布的隶属函数

的.

隶属函数常用的有三角形、梯形和半梯形等，最常采用的是三角形，因为它描述简单，计算方便.此外隶属函数之间应有足够的重叠，一般重叠为25%～50%，以便提高鲁棒性.

3. 建立控制规则库

控制规则库是描述控制器输入输出特性的一组语言型规则.它来自系统设计人员对系统的知识经验.因此设计人员所积累的知识和经验的多少和质量决定了所设计的控制器的优劣.控制规则库是 Fuzzy 控制器的核心部分，它直接影响着控制器的性能和效果.系统的设计人员可以通过与操作工人讨论与问答，提炼操作记录以及进行实验室试验获取对被控系统特性的认识和知识积累.对于复杂系统，知识的积累和控制规则的建立是一项艰苦的工作.此外，随着系统输入和输出数量的增多，所需建立的控制规则也会成倍地增加.对于两个输入一个输出的 Fuzzy 控制器，若每个输入 Fuzzy 变量取 7 个语言值，则控制规则可达 $7\times7=49$ 个.对于三输入单输出的 Fuzzy 控制器，控制规则将达到 $7\times7\times7=343$ 个.控制规则数目的成倍增长将给设计人员带来时间和精力的巨大负担.为了解决这个问题，许多 Fuzzy 技术研究机构正在研究各种方法，其中 National Semiconductor 公司开发了 Fuzzy 控制系统软件包 NeuoFuz4.该软件包采用神经网络技术，可根据系统特性自动生成输入输出变量的隶属函数和控制规则，大大缩短了设计时间，并提高了设计质量.

控制规则库的建立应当保证规则的“完备性”，即规则库中的规则应能覆盖所有的输入状态，使得每一种输入状态都有相应的控制规则起作用.此外，设计控制规则时应尽量避免相互矛盾的控制规则.

4. 选定 Fuzzy 推理算法

尽管有许多种 Fuzzy 推理算法可供选用，但到目前为止，较多使用的仍是 Mamdani 的最大最小推理算法 max-min，即对 Fuzzy 命题连接词 and, or, if…then 分别采用如下逻辑算子

$$\text{and}\Rightarrow\min\text{ 算子},$$

$$\text{or}\Rightarrow\max\text{ 算子},$$

$$\text{if}\cdots\text{then}\Rightarrow\min\text{ 算子}.$$

这种推理算法在 Fuzzy 控制中是使用最广泛的，其优点是

(1)该算法很好地符合了人脑日常 Fuzzy 思维方式.

(2)该方法简便易行，其特性已基本掌握.

(3)该推理方法软硬件的实现相对简单和便宜.

5. 选定去模糊化方法

推理结果**去模糊化**(Defuzzification)的常用方法有**面积重心法**和**最大值平均法**两种.在具备很好的计算能力且时间要求不苛刻的情况下,可采用面积重心法,实行在线控制.而在时间要求苛刻的情况下,则采用最大值平均法去模糊化,并建立控制查询表进行控制.

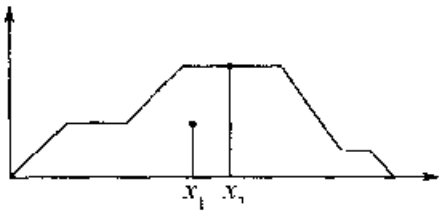


图 3.42 去模糊化方法

x_1:面积重心法 x_2:最大值平均法

6. Fuzzy 控制器的实现

Fuzzy 控制器的实现有硬件实现和软件实现两种,其中软件实现又分为离散式实现和连续式实现两种.对于存储量和计算时间要求高的系统采用离散式实现,即将输入量离散化,针对每一组输入量计算其输出,并制成查询表进行控制.对于精度要求高,通用性强的系统则采用连续式实现,在线计算相应于输入量的输出量.

7. Fuzzy 控制器的修正

在系统运行后,根据其控制效果进一步修正控制器.调整控制规则或比例因子是常用的修正手段.调整隶属函数的位置和形状也有效果.

3.7.2 目标跟踪系统的 Fuzzy 控制

考虑实时目标跟踪系统,比如雷达跟踪系统.它是用水平角与仰角作为输入变量,通过两个马达控制发射台的位置.一般来说,水平角在 $0^\circ \sim 180^\circ$ 之间变化,仰角在 $0^\circ \sim 90^\circ$ 之间变化.我们通过发射台的位置与目标位置计算当前的误差 e_k 和误差变化率 e'_k,并且 e_k 及 e'_k 作为控制变量,从而得到状态方程与观测方程

$$\begin{aligned} x_{k+1} &= \varphi_{k+1,k}x_k + \Psi_{k+1,k}(e_k + e'_k) + \Gamma_{k+1} + W_k, \\ Z_k &= H_k x_k + V_k, \end{aligned} \tag{3.54}$$

其中 W_k 及 V_k 为随机向量.特别是,当我们分别研究水平角与仰角时,上面的方程变为一维方程.通过状态方程和观测方程可以实现 Kalman 滤波控制系统.

目标跟踪系统也可以实现 Fuzzy 控制.仍然分别考虑一维情况,即仅考虑

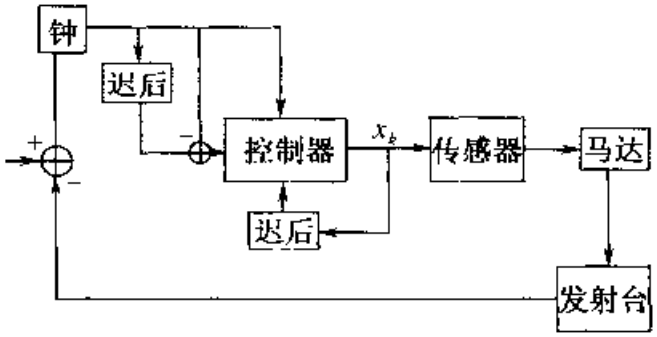


图 3.43 目标跟踪系统

水平角或仰角控制.用 e_k, e'_k 及 x_{k-1} 控制 x_k.我们给出 e_k, e'_k, x_{k-1} 的语言变量值

LN	MN	SN	ZE	SP	MP	LP
负大	负中	负小	零	正小	正中	正大

e_k, e'_k, x_{k-1} 的变化范围为 $[-8,8]$,定义 LN 的隶属函数为

$$\mathrm{LN}(x)=\begin{cases}\alpha(x+8), & -8\leqslant x\leqslant -8+\dfrac{1}{\alpha},\\ 1, & -8+\dfrac{1}{\alpha}\leqslant x\leqslant -4+\dfrac{1}{\alpha},\\ -\alpha(x+4), & -4+\dfrac{1}{\alpha}\leqslant x\leqslant 4.\end{cases}\tag{3.55}$$

其他的语言变量值可经平移 LN 得到.如

$$\begin{aligned}\mathrm{MN}(x)&=\mathrm{LN}(x-2),\\ \mathrm{SN}(x)&=\mathrm{LN}(x-4),\\ \mathrm{ZE}(x)&=\mathrm{LN}(x-6),\\ \mathrm{SP}(x)&=\mathrm{LN}(x-8),\\ \mathrm{MP}(x)&=\mathrm{LN}(x-10),\\ \mathrm{LN}(x)&=\mathrm{LN}(x-12).\end{aligned}$$

为了实现 Fuzzy 控制,我们必须根据经验建立控制规则.比如

若 $e_k=\mathrm{MP}$, $e'_k=\mathrm{SN}$, $x_{k-1}=\mathrm{ZE}$, 则 $x_k=\mathrm{SP}$.

若 $e_k=\mathrm{ZE}$, $e'_k=\mathrm{SP}$, $x_{k-1}=\mathrm{SN}$, 则 $x_k=\mathrm{ZE}$.

如果建立所有的规则,则共有 $7^3=343$ 条规则.仅仅固定 $e_k=\mathrm{ZE}$ 时就可

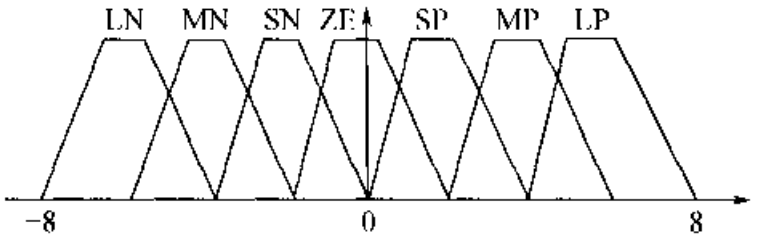


图 3.44 e, e', ε 的语言变量值的隶属函数

建立 49 条规则，如表 3.17.

假定在 $7^3=343$ 条中选取 N 条规则，然后再选择某种 Fuzzy 推理算法，就得到目标跟踪系统的 Fuzzy 控制过程，如图 3.45 所示.

表 3.17 目标跟踪系统 Fuzzy 控制规则表

e'_k \ x_k-1	LN	MN	SN	ZE	SP	MP	LP
LN	LN	LN	LN	LN	MN	SN	ZE
MN	LN	LN	LN	MN	SN	ZE	SP
SN	LN	LN	MN	SN	ZE	SP	MP
ZE	LN	MN	SN	ZE	SP	MP	LP
SP	MN	SN	ZE	SP	MP	LP	LP
MP	SN	ZE	SP	MP	LP	LP	LP
LP	ZE	SP	MP	LP	LP	LP	LP

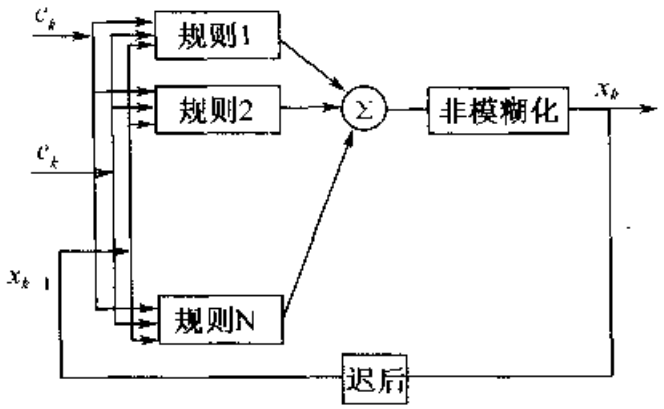


图 3.45 目标跟踪系统的 Fuzzy 控制过程

实验表明，选择 LN 的隶属函数中的系数 α 对 Fuzzy 控制有着不同的效果. 如果 α 太小，则 7 个 Fuzzy 集交叉部分嫌小；如果 α 较大，则 7 个 Fuzzy 集交叉部分嫌大. 选择适当的 α 值，才能使 Fuzzy 控制达到最好的效果.

由目标跟踪系统的 Fuzzy 控制过程可以看出，Fuzzy 控制也可以实现实时

控制，它可以把迟后的状态作为新的输入变量加入 Fuzzy 推理过程，它甚至可以用迟后的几个时刻的状态 $x_{k-1}, x_{k-2}, \cdots$，等作为新的输入变量．但是输入变量越多，Fuzzy 规则就越多，这就更需要对 Fuzzy 规则进行选择．

3.7.3 还原炉氢气流量的 Fuzzy 控制

粉末冶金还原炉是用来对氧化钨或氧化钼粉末进行还原去氧，以得到合格的钨或钼粉末的一种设备．

该设备有以下特征：

(1) 共有 6 个温区，温度分别保持在 500℃～850℃．

(2) 每个温区由固定的电热丝加热和热电偶测温．

(3) 氧化物粉末在一定时间内通过各温区．

(4) 料管内必须有足够的氧气，以保证粉末充分还原．

(5) 人工调节氢气流量稳定在 $15m^3/h$．

该设备的缺点是，人工调节量按氢气出口处的燃烧火焰的状态和流量计指示来决定，既不准确，又不及时，因此稳定性太差，影响粉末产品质量．因此考虑采取 Fuzzy 控制以代替人工控制．以下给出根据氢气流量差控制阀门开度的 Fuzzy 推理 Mamdani 算法的计算过程．

1．确定输入输出变量

输入量为现实氢气流量与设定量之差 e．偏差 e 的论域为

$$U = \{-3, \quad 2, -1, 0, 1, 2, 3\},$$

其 Fuzzy 取值为

$$E = \{\mathrm{NB}, \mathrm{NM}, \mathrm{NS}, 0, \mathrm{PS}, \mathrm{PM}, \mathrm{PB}\}.$$

若偏差值 $x \in [a, b]$，则由下列转换公式

$$y = \frac{6}{b-a}\left(x - \frac{a+b}{2}\right),$$

转换为 $y \in [-3, 3]$．各 Fuzzy 取值的隶属函数如表 3.18 定义．

表 3.18 输入变量 Fuzzy 取值的隶属函数定义

	-3	2	-1	0	1	2	3
PB					0.1	0.4	1.0
PM				0.1	0.4	1.0	0.4
PS			0.1	0.4	1.0	0.4	0.1
0		0.1	0.4	1.0	0.4	0.1	
NS	0.1	0.4	1.0	0.4	0.1		
NM	0.4	1.0	0.4	0.1			
NB	1.0	0.4	0.1				

输出量为阀门开度的变化 f. f 的论域为

$$V = \{-4, -3, -2, -1, 0, 1, 2, 3, 4\}.$$

f 的 Fuzzy 取值为

$$F \in \{\text{NB}, \text{NM}, \text{NS}, 0, \text{PS}, \text{PM}, \text{PB}\}.$$

各 Fuzzy 取值的隶属函数如表 3.19 定义.

表 3.19 输出变量 Fuzzy 取值的隶属函数定义

	-4	-3	-2	1	0	1	2	3	4
PB							0.1	0.4	1.0
PM					0.1	0.4	1.0	0.4	0.1
PS				0.1	0.4	1.0	0.4	0.1	
0			0.1	0.4	1.0	0.4	0.1		
NS		0.1	0.4	1.0	0.4	0.1			
NM	0.1	0.4	1.0	0.4	0.1				
NB	1.0	0.4	0.1						

2. 建立控制规则

—"若氢气流量高于设定值,则关小阀门,差值越大,阀门关小越多,但不是线性的".

—"若氢气流量低于设定值,则开大阀门,差值越大,阀门开大越多,也不是线性的".

……

if $E = \text{NB}_e$ then $F = \text{PB}_f$

if $E = \text{NM}_e$ then $F = \text{PM}_f$

if $E = \text{NS}_e$ then $F = \text{PS}_f$

if $E = \text{O}_e$ then $F = \text{O}_f$

if $E = \text{PS}_e$ then $F = \text{NS}_f$

if $E = \text{PM}_e$ then $F = \text{NF}_f$

if $E = \text{PB}_e$ then $F = \text{NB}_f$

即 $\text{NB}_e \rightarrow \text{PB}_f$

$\text{NM}_e \rightarrow \text{PM}_f$

$\text{NS}_e \rightarrow \text{PS}_f$

$O_e \rightarrow O_f$

$PS_e \rightarrow NS_f$

$PM_e \rightarrow NM_f$

$PB_e \rightarrow NB_f$

3. 计算 Fuzzy 关系矩阵 R

$$R_1 = NB_e \rightarrow PB_f = \begin{pmatrix} 1 \\ 0.4 \\ 0.1 \\ 0 \\ 0 \\ 0 \\ 0 \end{pmatrix} \circ (0,0,0,0,0,0,0.1,0.4,1)$$

$$= \begin{pmatrix} 0 & 0 & 0 & 0 & 0 & 0 & 0.1 & 0.4 & 1 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0.4 & 0.4 & 0.4 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0.1 & 0.1 & 0.1 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \end{pmatrix},$$

$$R_2 = NM_e \rightarrow PM_f = \begin{pmatrix} 0.4 \\ 1 \\ 0.4 \\ 0.1 \\ 0 \\ 0 \\ 0 \end{pmatrix} \circ (0,0,0,0,0.1,0.4,1,0.4,0.1)$$

$$= \begin{pmatrix} 0 & 0 & 0 & 0 & 0.1 & 0.4 & 0.4 & 0.4 & 0.1 \\ 0 & 0 & 0 & 0 & 0.1 & 0.4 & 1 & 0.4 & 0.1 \\ 0 & 0 & 0 & 0 & 0.1 & 0.4 & 0.4 & 0.4 & 0.1 \\ 0 & 0 & 0 & 0 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \end{pmatrix},$$

$$R_3 = \mathrm{NS_e} \to \mathrm{PS_f} = \begin{pmatrix} 0 & 0 & 0 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0 \\ 0 & 0 & 0 & 0.1 & 0.4 & 0.4 & 0.4 & 0.1 & 0 \\ 0 & 0 & 0 & 0.1 & 0.4 & 1 & 0.4 & 0.1 & 0 \\ 0 & 0 & 0 & 0.1 & 0.4 & 0.4 & 0.4 & 0.1 & 0 \\ 0 & 0 & 0 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \end{pmatrix},$$

$$R_4 = \mathrm{O_e} \to \mathrm{O_f} = \begin{pmatrix} 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0 & 0 \\ 0 & 0 & 0.1 & 0.4 & 0.4 & 0.4 & 0.1 & 0 & 0 \\ 0 & 0 & 0.1 & 0.4 & 1 & 0.4 & 0.1 & 0 & 0 \\ 0 & 0 & 0.1 & 0.4 & 0.4 & 0.4 & 0.1 & 0 & 0 \\ 0 & 0 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \end{pmatrix},$$

$$R_5 = \mathrm{PS_e} \to \mathrm{NS_f} = \begin{pmatrix} 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0 & 0 & 0 \\ 0 & 0.1 & 0.4 & 0.4 & 0.4 & 0.1 & 0 & 0 & 0 \\ 0 & 0.1 & 0.4 & 1 & 0.4 & 0.1 & 0 & 0 & 0 \\ 0 & 0.1 & 0.4 & 0.4 & 0.4 & 0.1 & 0 & 0 & 0 \\ 0 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0 & 0 & 0 \end{pmatrix},$$

$$R_6 = \mathrm{PM_e} \to \mathrm{NM_f} = \begin{pmatrix} 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0 & 0 & 0 & 0 \\ 0.1 & 0.4 & 0.4 & 0.4 & 0.1 & 0 & 0 & 0 & 0 \\ 0.1 & 0.4 & 1 & 0.4 & 0.1 & 0 & 0 & 0 & 0 \\ 0.1 & 0.4 & 0.4 & 0.4 & 0.1 & 0 & 0 & 0 & 0 \end{pmatrix},$$

$$R_7 = \mathrm{PB}_e \rightarrow \mathrm{NB}_f = \begin{pmatrix} 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0.1 & 0.1 & 0.1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0.4 & 0.4 & 0.1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0.4 & 0.1 & 0 & 0 & 0 & 0 & 0 & 0 \end{pmatrix},$$

$$R = \bigcup_{i=1}^{7} R_i = \left(\bigvee_{i=1}^{7} r_{jk}^{(i)} \right)_{7\times 9}$$

$$= \begin{pmatrix} 0 & 0 & 0 & 0.1 & 0.1 & 0.4 & 0.4 & 0.4 & 1 \\ 0 & 0 & 0.1 & 0.1 & 0.4 & 0.4 & 1 & 0.4 & 0.4 \\ 0 & 0.1 & 0.1 & 0.4 & 0.4 & 1 & 0.4 & 0.4 & 0.1 \\ 0.1 & 0.1 & 0.4 & 0.4 & 1 & 0.4 & 0.4 & 0.1 & 0.1 \\ 0.1 & 0.4 & 0.4 & 1 & 0.4 & 0.4 & 0.1 & 0.1 & 0 \\ 0.4 & 0.4 & 1 & 0.4 & 0.4 & 0.1 & 0.1 & 0 & 0 \\ 1 & 0.4 & 0.4 & 0.4 & 0.1 & 0.1 & 0 & 0 & 0 \end{pmatrix}.$$

4. 计算 Fuzzy 推理结论

对氢气流量偏差 e 的一个实测结果

$$E = \mathrm{NS} = (0.1, 0.4, 1, 0.4, 0.1, 0, 0),$$

可计算出阀门开度 f 的 Fuzzy 取值为

$$F = E \circ R$$

$$= (0.1, 0.4, 1, 0.4, 0.1, 0, 0) \circ \begin{pmatrix} 0 & 0 & 0 & 0.1 & 0.1 & 0.4 & 0.4 & 0.4 & 1 \\ 0 & 0 & 0.1 & 0.1 & 0.4 & 0.4 & 1 & 0.4 & 0.4 \\ 0 & 0.1 & 0.1 & 0.4 & 0.4 & 1 & 0.4 & 0.4 & 0.1 \\ 0.1 & 0.1 & 0.4 & 0.4 & 1 & 0.4 & 0.4 & 0.1 & 0.1 \\ 0.1 & 0.4 & 0.4 & 1 & 0.4 & 0.4 & 0.1 & 0.1 & 0 \\ 0.4 & 0.4 & 1 & 0.4 & 0.4 & 0.1 & 0.1 & 0 & 0 \\ 1 & 0.4 & 0.4 & 0.4 & 0.1 & 0.1 & 0 & 0 & 0 \end{pmatrix}$$

$$= (0.1, 0.1, 0.4, 0.4, 0.4, 1, 0.4, 0.4, 0.4),$$

其中第一项的计算式为

$$(0.1 \wedge 0) \vee (0.4 \wedge 0) \vee (1 \wedge 0) \vee (0.4 \wedge 0.1) \vee (0.1 \wedge 0.1) \vee (0 \wedge 0.4) \vee (0 \wedge 1)$$

$$= 0.1.$$

所得 Fuzzy 控制量也可写作

$$F=\frac{0.1}{-4}+\frac{0.1}{-3}+\frac{0.4}{-2}+\frac{0.4}{-1}+\frac{0.4}{0}+\frac{1}{1}+\frac{0.4}{2}+\frac{0.4}{3}+\frac{0.4}{4}.$$

显见,F 在 $f=1$ 取得最大隶属度 1. 若按最大值平均法对 Fuzzy 推理结果 F 去 Fuzzy 化,则这时的执行控制量应为 $f-1$,即令阀门开度为 1.

3.7.4 Fuzzy 逻辑的硬件实现

在时间要求非常高的控制问题中,软件实现已不满足控制要求时,常常采用硬件实现,即用 Fuzzy 专用芯片实现 Fuzzy 控制器. 到目前为止已经开发出了许多 Fuzzy 专用芯片,如用模拟电路技术实现的 Fuzzy 控制器,带有特殊 Fuzzy 指令的微处理器,以及带知识存储器的 Fuzzy 逻辑控制器.

Fuzzy 逻辑硬件控制器的设计分为知识库设计,Fuzzy 推理设计和去模糊化设计.

知识库设计

知识库由控制规则存储器和输入输出 Fuzzy 变量存储器组成. 为使 Fuzzy 芯片运用于各种控制问题,控制规则和 Fuzzy 变量隶属函数必须由用户通过程序自行选择. 知识库存储器的大小决定着芯片面积的大小. 为了减少芯片面积,必须对规则存储器的组织进行优化. 另外控制规则,隶属函数应尽量采用无余度存储. 隶属函数常以表格形式存储. 由于隶属函数绝大部分等于零,故常采用重叠方法以充分利用存储空间. 下面是 Togai Infra Logic 生产的 Fuzzy 处理器 FC110 的隶属函数和控制规则的 Fuzzy 编程语言(FPL)的源码程序. 其中隶属函数以离散数组及数学函数描述. 该程度经编译后送入 FC110 内部的 128K RAM 随机存储器作为知识库.

```
VAR Theta
        TYPE signed byte
        MEMBER Low
                POINTS-100 1.0-50 1.0 0 0.0
        END
        MEMBER Medium
                EQUATION exp(-(Theta^2.0))
        END
        MEMBER High
                POINTS 0 0.0 50 1.0 100 1.0
        END
END/ * Theta definition * /
FUZZY Rulebase
        RULE Rule 1
```

```
        IF Theta IS Low AND dTheta IS Low AND Gain IS Low THEN
                Velocity = Low
    END
    RULE Rule 2
        IF Theta IS High AND dTheta IS High AND Gain IS High THEN
                Velocity = High
    END

END / * Rulebase definition * /
```

Fuzzy 推理设计

Fuzzy 推理在硬件实现中常采用 max-min Fuzzy 推理方法. 图 3.46 是西门子公司生产的 Fuzzy 处理器 Fuzzy-166 中最小算子的实现,其输出结果为

$$\mu_{\min} = \min\{\mu_1, \mu_2, \mu_3, \cdots, \mu_n\}.$$

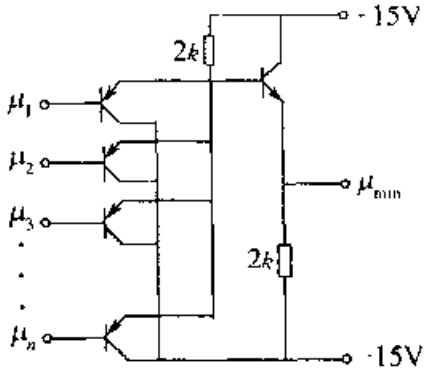


图 3.46 用 Fuzzy 技术实现的 Fuzzy 最小运算

图 3.47 是德国 Dortmund 大学电子技术元件研究所用 CMOS 技术实现的最小和最大运算.

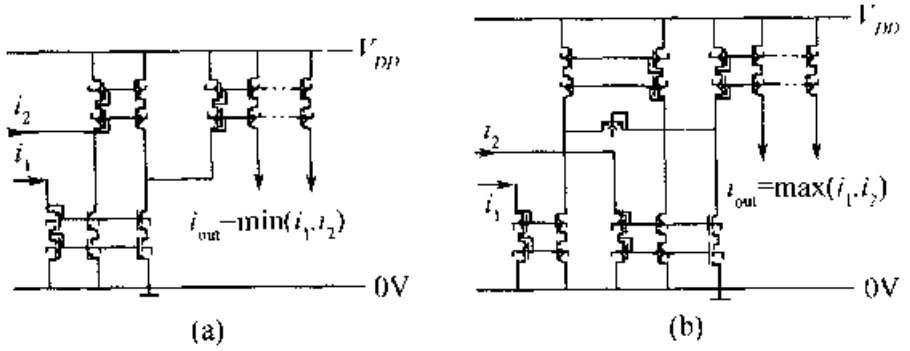


图 3.47 用 CMOS 技术实现的最小最大运算

去模糊化设计

常见的去模糊化在硬件设计中采用的是面积重心法,还有最大值平均法.图 3.48 是西门子公司利用数字 CMOS 技术研制的去模糊化部分,其中 ADD 为 Addierer 加法器,REG 为 Register 寄存器,DIV 为 dividier 除法器.

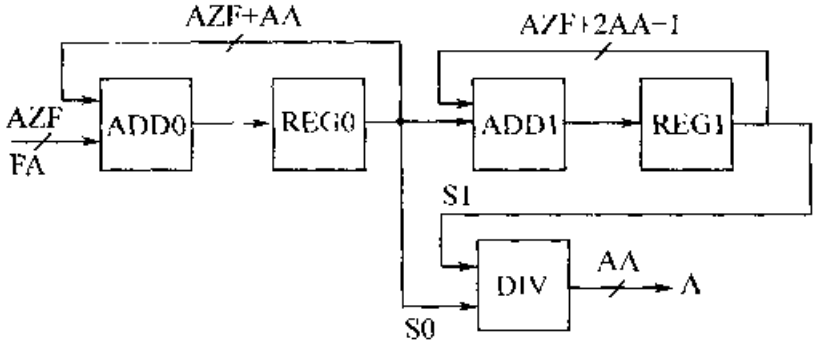


图 3.48 去模糊化线路

图 3.49 是西门子公司设计的 4 输入单输出 Fuzzy 控制器原理方框图.

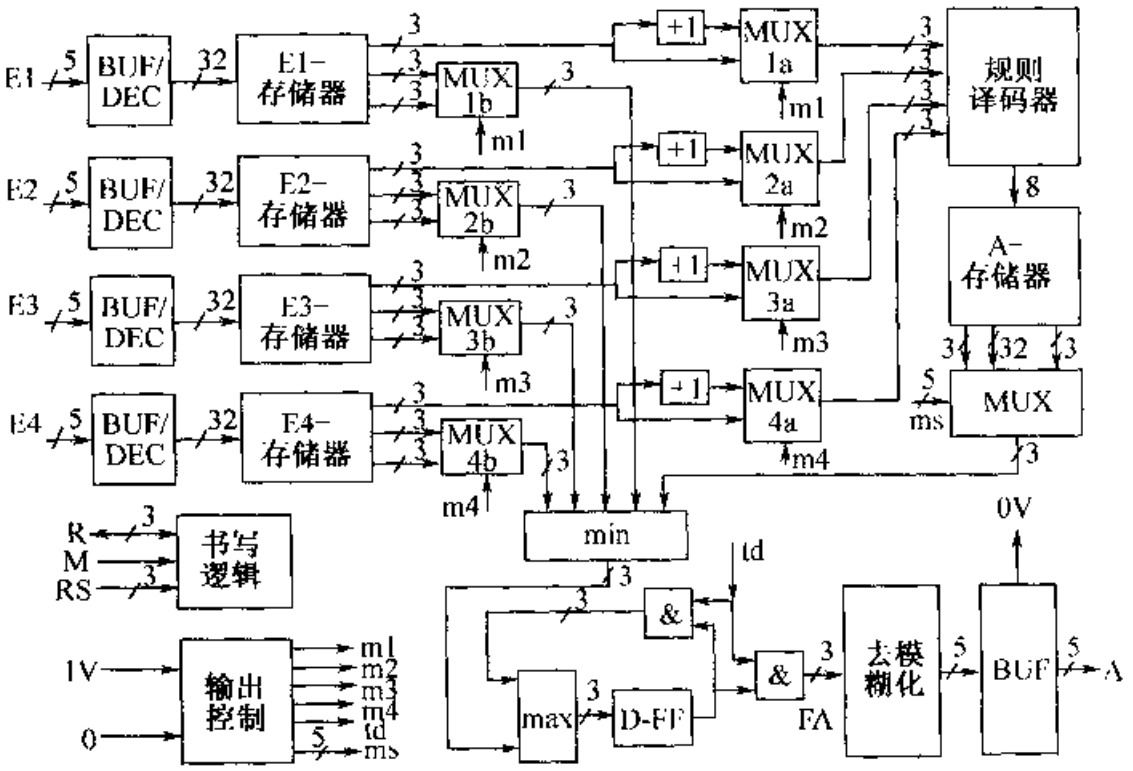


图 3.49 4 输入单输出 Fuzzy 控制器原理示意图

绝大部分 Fuzzy 硬件芯片都配有极强的软件开发系统,如西门子公司生产的 Fuzzy 处理器 Fuzzy-166 配有德国 Inform 公司研制的 Fuzzy Tech 软件包,Togai Infra Logic 公司的 Fuzzy 处理器可用 TIL Shell 软件包开发,使用者

可参考 Fuzzy 硬件使用说明,根据具体 Fuzzy 控制问题开发 Fuzzy 控制器.

Yamakawa 的 Fuzzy 逻辑组件

常用的 Fuzzy 推理算法最终归结为最大最小两种基本运算,如何用硬件实现 Fuzzy 控制器可归结为最大算子和最小算子的实现. T. Yamakawa 于 1989 年和 Apllo Electronic, Hakate 首次研制了 Fuzzy 控制器的硬件组合元件 ZDIS-IC,包括隶属函数组件,最小运算组件,最大运算组件,去模糊化组件.图 3.50 是其 Fuzzy 推理的简化结构.最大最小 Fuzzy 推理由"比较器","最小门"和"最大门"三部分组成,这三部分很容易用数字模拟技术实现.图 3.51 和图 3.52 是用大规模集成线路 VLSI 技术设计的"比较器"和"最小门".

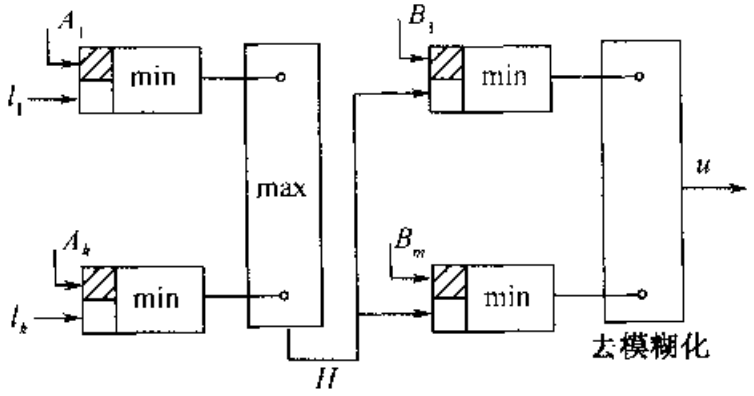


图 3.50 Fuzzy 推理机理简化框图

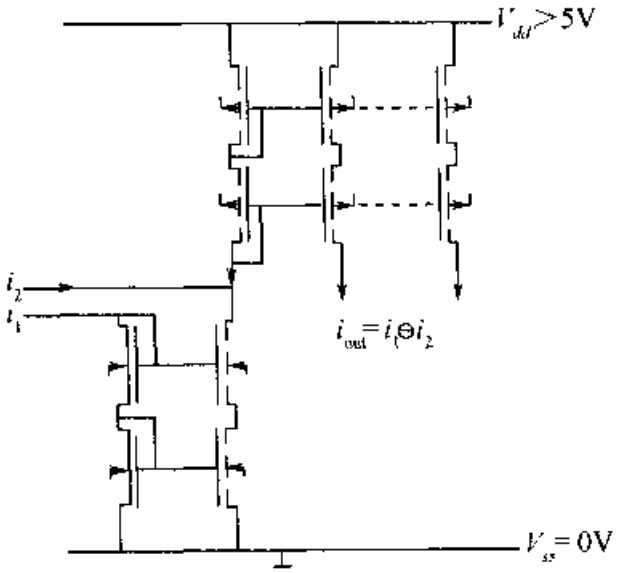


图 3.51 大规模集成线路实现的"比较器"

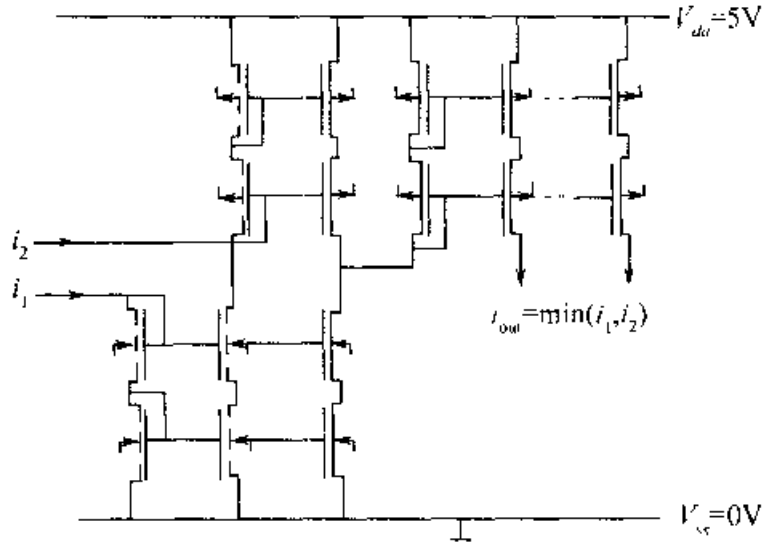


图 3.52 大规模集成线路实现的"最小门"

构成 Fuzzy 推理的电子器件可以是市场上常见的 CPU,微处理器,以及协处理器等.如果使用 CPU,则软件完成 Fuzzy 推理.如果使用微处理器,则 Fuzzy 运算用微机器码完成,在实时工作上具有很多优点.协处理器的使用则介于微处理器与不可编程的纯 Fuzzy 芯片之间.

Omron 公司产品

表 3.20 Omron 公司数字式 Fuzzy 处理器的性能指标

性能指标	FP1000	FP3000
模糊推理速度	3ms/96 规则	0.2MFLIPS
输入输出通道数	8/4	8/4
分辨率	8Bit	12Bit
最大规则数	96	128×3
条件部分隶属函数	三角形、梯形	三角形、梯形
结果部分隶属函数	Singleton	Singleton
模糊推理方法	max-min	max-min
去模糊化方法	面积重心法	面积重心法,最大平均值
芯片存贮单元		208 Byte(Single Mode)
可寻址外部存贮单元		4.3KByte (Expanded Mode)
开发工具	FS-TH1000	FS-1000/10AT
用途	质量保障	控制技术,分类

Omron 公司的 Fuzzy 控制技术非常先进,它的产品代表着 Fuzzy 产品发展的新方向.Omron 公司的 Fuzzy 产品最初只用于本公司其他产品上.由于市场对 Fuzzy 产品的需求量很大,公司才决定在市场上直接提供 Fuzzy 芯片及相应的开发工具.目前市场上可见到的 Fuzzy 芯片有 FP1000, FP3000, FP5000 和 FP7000.在欧洲市场上常见的是 FP1000 和 FP3000,它们都是数字式 Fuzzy 处理器.表 3.20 列出了它们的性能指标.

FP5000 是 FP3000 的新一代 Fuzzy 产品,它的处理速度可高达每秒 1 千万规则.它可同时处理 32000 控制规则.该芯片的开发软件是 FS-10AT,可直接与 FP5000 产生目标程序.

Inform/Siemens 公司产品

德国 Inform 公司在实现 Fuzzy 硬件产品时采用了一种新的方法,即在 Siemens 公司的 16 位标准控制器 80C166 基础上将最优的推理过程编译在 ROM 内.所以 Fuzzy-166 是和 80C166 端脚完全兼容的.所有 80C166 的应用都可直接用 Fuzzy 控制器进行补充优化.Fuzzy-166 的性能指标如下:

模糊推理速度	204μs/51 规则
去模糊化速度	面积重心法 2220μs(3 个语言值)
	最大平均值为 25μs
输入输出通道数	10 输入端,A/D 转换器分辨率
	10Bit,2 个输出端,16 数字 I/O 口
最大规则数	32KB RAM
推理方法	MAX-MIN 和 MAX-PROD 推理
隶属函数形式	线性和 S 型
去模糊化方法	面积重心法,最大平均值法
开发工具	Fuzzy Tech

它还有一个"学习"软件包,可以通过神经网络训练规则.Siemens 公司还推出新的 Fuzzy 开发工具软件包 Profuzzy 和 SiFloc,用于支持该 Fuzzy 芯片.

Togai Infra Logic 公司产品

FC110DFP 是美国 Togai Infra Logic 公司推出的一种数字 Fuzzy 处理器.它的性能指标如下:

模糊推理速度	100000 规则,每秒 60000 非模糊输出值
最大规则数	大于 800
输入输出通道数	256/256
隶属函数形式	任意
模糊推理方式	MAX-MIN
去模糊化	面积重心法,平均最大值法

隶属函数分辨率	8Bit
兼容性	8051,6800 微处理器
开发工具	TIL Shell, FCDS

该数字 Fuzzy 处理器具有芯片 RAM 64 Byte,256 Byte 芯片数据 RAM 和 256 Byte 外部存储器.另外它可寻址外部存储器 128 KB.FC110 DEP 的工作方式很多.它既可以作为微处理器在线工作,也可以作为协处理器和标准微处理器等一起工作.

Neural Logic 公司产品

NLX220 和 NLX230 是 Neural Logic 公司的 VLSI Fuzzy 逻辑芯片,主要用于模式识别领域.其性能指标如下:

推理速度	30MFIPS
输入输出通道数	8/8
最大规则数	64
最大条件数	16
最大结论数	1
推理方法	MAX-MIN
去模糊化方法	MAX
隶属函数形状	三角形
开发工具	ADS 230

除了以上两种 Fuzzy 芯片外,Neural Logic 公司还推出很多专用 Fuzzy 芯片.NLX110 是专门用来进行模式比较的 Fuzzy 微处理器,它可以同时将 8 个已知模式同一个未知模式进行比较.NLX112 是一个 128Bit 的数据修正器,它可以与 8 位微处理器通信.NLX113 是 32 位数据修正器,它可以进行相关分析和互相关分析.

§3.8 评注与展望

进入 20 世纪后,不同领域的学者从各自的实践经验中逐渐提出关于精确性与模糊性的新观点.1923 年,著名的英国逻辑学家 B.Russell 指出:"传统逻辑都习惯于假定使用的是精确符号.因此,它不适合于尘世生活,而仅仅适用于想象的天体存在物……逻辑学较别的学科使我们更接近于天堂."Russell 认为世界上不存在绝对的精确性,二值逻辑只是理想世界的模型,而不是现实世界的模型,或者说,它是现实世界的近似和简化.就像 Euclid 几何是理想空间的模型,而非现实空间的模型一样.Russell 是现代数理逻辑的完成者,他对盲目崇拜精确性的批判是意味深长的[95].

20 世纪 50 年代，控制论的创始人维纳指出，同计算机相比，人脑主要的一个优越性似乎是“能够掌握尚未完全明确的含糊观念”，肯定了 Fuzzy 概念和 Fuzzy 思维的积极意义[130]. 1957 年，美国语言学家 D. Jons 写道：“我们大家，包括凡事追求‘精确无误’的人，在说话和写作时常常使用不精确的、含糊的、难于下定义的术语和原则. 但这并不妨碍我们所用的词是非常有用的，而且确实是必不可少的.”Jons 的话显然是对当时西方学术界鼓吹把一切自然语言的概念都精确化这一浪潮的批判[53]. 60 年代初，英国哲学家 K. Popper 也对这股浪潮提出批判，认为凡事追求精确性可能是一种错误的理想，人们不应当企图获得比实际情形的要求更高的精确性[81]. 从这些引证可以看出，现代科学正孕育着对传统观点的重要突破.

更为有意义的是，20 世纪的学者已经开始把模糊性纳入具体科学考察的范围. Russell 1923 年的论文“含混性”是一个起点. 1937 年，M. Black 以相同的题目著文[10]，进一步探讨含混性. 他们讲的含混性，大体上相当于我们现在说的模糊性. Black 提出的“轮廓一致(consistency profiles)”的概念，可以看作是 Zadeh 的隶属函数概念的原始形态，这是 Black 一个有意义的贡献. 1951 年，法国学者 K. Menger 用法文创造了模糊集合(ensemble flu)这个术语，使用了“max-product”转换 Fuzzy 关系的概念. 不过 Menger 尚不能区分模糊性与随机性，他是用概率论的观点解释他的概念的[75]. 第一个跨出二值逻辑限制的是波兰的逻辑学家和哲学家 Jan Lukasiewicz，他于 1920 年创立了多值逻辑，为以后 Fuzzy 逻辑的产生走出了第一步. 直到 1965 年，Lotfi Asker Zadeh 在他的著名论文“Fuzzy 集合”中把经典集合与 Lukasiewicz 多值逻辑的思想结合在一起，创立了 Fuzzy 集合论，才真正地开辟了解决模糊性问题的科学途径[119].

Zadeh 是一位系统科学家和自动控制论专家，最初他也是只相信精确方法，曾致力于把状态、稳定性、适应性等概念精确化的工作，并富有成果. 长期活跃于系统科学领域，使 Zadeh 对复杂性、精确性、模糊性之间的尖锐矛盾有充分的了解. Zadeh 并不懂得用辩证观点分析这些矛盾，但他是一个富有批判精神和求实态度的学者，面对上述尖锐矛盾，他比别人更早、更清楚地认识到精确方法也有局限性，Fuzzy 方法也有科学性，某些过份复杂的系统不再能够在精确方法的框架内解决问题. 正如 Zadeh 所指出的，在多变量、非线性、时变的大系统中，复杂性与精确性形成了尖锐的矛盾. 当系统日益复杂，人们对它的精密而有意义的描述的能力将相应地降低，以至于达到精密性与有意义成为两个几乎相互排斥的特征的地步. 因此，要想确切地描述复杂现象和复杂系统的任何现实的物理状态，事实上是办不到的. 为了对整个问题的描述有意义，我们必须在准确与简明之间取得平衡. Fuzzy 集合的提出，正是为了适应

这种情况，采用新的观念和方法，对复杂系统作出合乎实际的别开生面的新处理. Zadeh 深入分析了模糊性、近似性、随机性和含混性的异同，准确地阐明了模糊性的含义，从而科学地规定了 Fuzzy 理论的研究对象. Zadeh 制定了刻画模糊性的数学方法，提出了隶属度、隶属函数、Fuzzy 集合等基本概念，在此基础上，建立起一个描述和处理模糊性的概念和技术的框架. 有了这个框架，关于模糊性的研究从先驱们那种思辨的或经验的描述上升为科学的刻画.

如前所述，现代科学对模糊性的研究，开始于 Russell 和 Black 的工作. 但是由于缺乏描述和处理模糊性的得力概念和方法，所以他们的工作并未导致新逻辑理论的出现，逻辑学界的注意力转向了其他方面. Zadeh 的 Fuzzy 集合论的出现，重新激起了人们研究与模糊性有关的逻辑问题的热情. 1966 年，P.N.Marinos 在他的论文"Fuzzy Logic"中首先使用了 Fuzzy 逻辑的概念[74]. 1969 年，J.A.Goguen 研究了不确切概念的逻辑问题[35]. 1972～1974 年，Zadeh 先后提出了 Fuzzy 限制词、语言变量、语言真值、近似推理等关键性概念，制定了 Fuzzy 逻辑的推理合成规则，奠定了 Fuzzy 逻辑的基础. 这些工作标志着 Fuzzy 逻辑作为一个新的研究领域已初步开拓出来了.

其后，Fuzzy 逻辑沿着两个平行的方向迅速地发展起来. 在 Fuzzy 逻辑的纯逻辑的理论研究方面，欧洲的科学家和中国的学者作出了不少杰出的工作，其中 J.Pavelka 的逻辑[79]和 V.Novak 的工作[77]以及 G.Gerla 的格上抽象逻辑标志着这方面的工作达到了一定的高度. 在 Fuzzy 逻辑的应用研究方面，以 Zadeh 的推理合成方案为基础，从 Mamdani 将 Fuzzy 推理首次成功地应用于工业控制为起点，Fuzzy 逻辑控制技术获得了迅速发展，并已转化为可观的经济效益和社会效益. 然而纯逻辑的研究与 Fuzzy 推理的应用之间如何很好地衔接，至今仍是一个严峻的任务. 不过已有一批相当出色的成果出现并形成新的 Fuzzy 逻辑流派[106,107],[140]-[142].

依照 Fuzzy 理论奠基人 L.A.Zadeh 教授的最初设想，Fuzzy 理论应在人类主观因素起主导作用的领域如人文科学和社会科学方面得到应用和发展. 在这些领域里人们更多地使用 Fuzzy 语言进行分析、交流、推理、判断和决策. 人类所使用的信息是语言信息，而语言信息描述的特点是其描述的模糊性，所描述的事物没有明确的分界线，人类主观因素在这里起很大作用. Fuzzy 理论在这些领域确实获得了广泛的应用. 然而 Fuzzy 理论最成功的应用却发生在自动控制领域，并形成了 Fuzzy 逻辑控制技术，其理论核心是基于 Fuzzy 集合论的 Fuzzy 推理算法和技术.

1974 年英国科学家 Mamdani 和 Assilian 首次提出 Fuzzy 逻辑控制理论并成功地应用于热电厂的蒸汽机控制. 1976 年 Mamdani 又将该理论成功地应用于水泥旋转炉的控制，从此 Fuzzy 逻辑控制技术得以发展. Fuzzy 控制在欧洲

主要用于工业自动化,在美国主要用于军事领域,在日本则迅速地发展为新型家用电器的 Fuzzy 控制智能化热潮.1983 年日本 Fuji Electric 公司实现了饮用水处理装置的 Fuzzy 控制.1985 年开始了 Fuzzy 推理集成块的开发.1986 年在日本 Fuzzy 控制器已成为商品后,各种各样的 Fuzzy 控制产品和 Fuzzy 控制系统应运而生.特别是 1987 年在日本,基于 Fuzzy 控制的仙台地铁开通以后,各种家电的 Fuzzy 产品相继研制成功并进入市场,如洗衣机、照像机、摄像机、复印机、吸尘器、电冰箱、微波炉、电饭煲、电视机、淋浴器等.仅 1987—1990 年在日本申报的 Fuzzy 产品专利就达 319 种.这些家电产品在节约资源、方便使用以及使用效果方面更富有"人情味",更符合人的实际生活.同时,各种各样的 Fuzzy 控制系统也被研制成功.比如各种熔炉、电气炉以及水泥生成炉的控制系统,核能发电供水系统,金属板成形控制系统,汽车的控制系统,电梯及升降机的控制系统,机器人的控制系统,以及活跃于航空、航天、通讯等领域里的专家系统.这些 Fuzzy 控制系统的应用取得了明显的效益,并且在日本、美国、西欧、东南亚和中国引起了普遍的重视.

应用是推动科学进步的最有效手段.Fuzzy 逻辑控制技术成为世界上科学技术界和大公司感兴趣的技术之一.世界各国都投入了巨大的人力、物力,用于研究和发展 Fuzzy 逻辑控制技术.日本在工业和商业部(MITI)的支持下成立了国际 Fuzzy 工程研究所,计划投资 30 亿日元,几乎所有的大公司如 NTT, Fujisu, Honda, Shimizu, Omron, Tokyo Electric, Olympus 等都参加了这项工程.欧洲组建了 ELIFE 实验室(Laboratory for International Fuzzy Engineering Research),旨在协调欧洲各国 Fuzzy 技术的发展和推广.1984 年国际 Fuzzy 系统协会成立,并创办会刊《Fuzzy Sets and Systems》.世界上最大的工程师协会 IEEE 从 1992 年起每年举办一届 Fuzzy 系统年会,并于 1993 年创办 IEEE Fuzzy 系统汇刊.美、日、韩、德、比等国积极承办国际 Fuzzy 会议,推动了 Fuzzy 理论和 Fuzzy 技术的交流与发展.

Fuzzy 理论在控制领域取得广泛的成功的应用,完全是由 Fuzzy 控制本身的特点所决定的.Fuzzy 控制器采用人类语言信息,模拟人类思维机制,故它易于接受,设计简便,维护方便.Fuzzy 控制器基于包含 Fuzzy 信息的控制规则,所构成的控制系统比常规控制系统稳定性好,鲁棒性高.在改善系统特性时,Fuzzy 控制系统不必象常规控制系统那样只能调节参数,还可以通过改变控制规则、隶属函数、推理方法及决策方法等来修正系统特性,因此使得 Fuzzy 控制器的设计、调整和维修变得简单.在常规控制算法中,微小的错误和参数漂移都可能引起系统失控.而基于控制规则的 Fuzzy 控制系统对某一规则的变化敏感性很小,系统的抗干扰能力是相当强的.

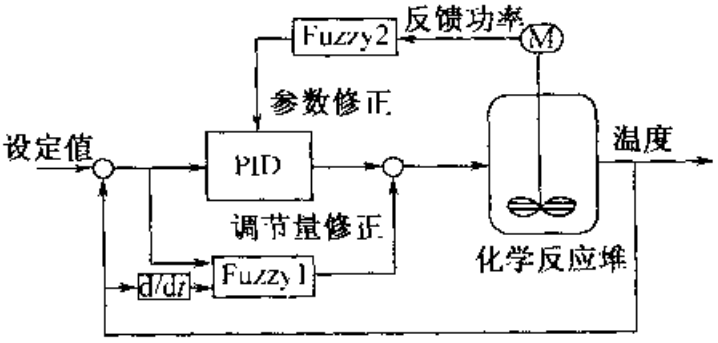


图 3.53 化学反应堆 Fuzzy PID 控制

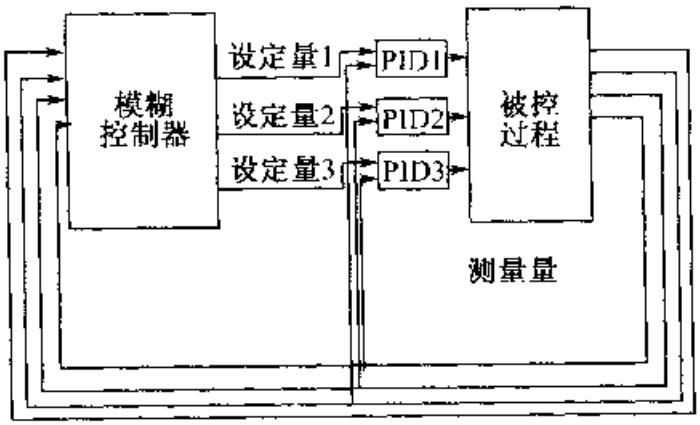


图 3.54 Fuzzy 设定量控制

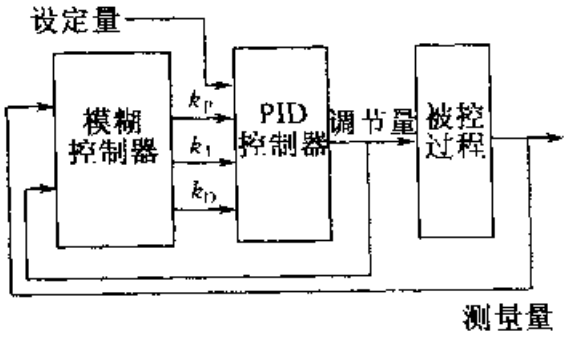


图 3.55 自适应 PID Fuzzy 控制系统

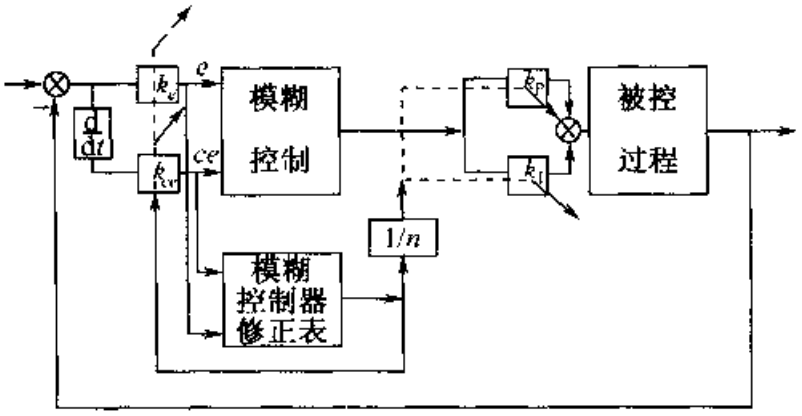


图 3.56 自适应 Fuzzy 控制系统

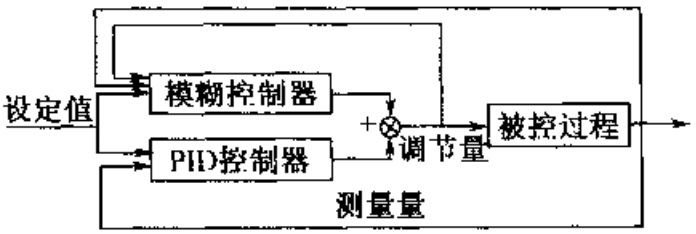


图 3.57 并行 Fuzzy 控制系统

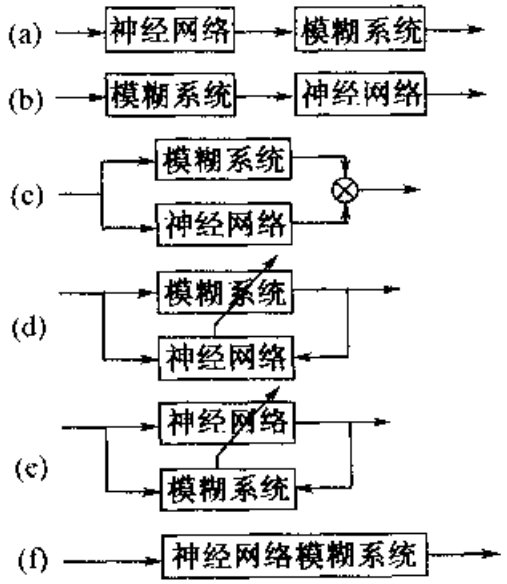


图 3.58 神经网络 Fuzzy 控制系统

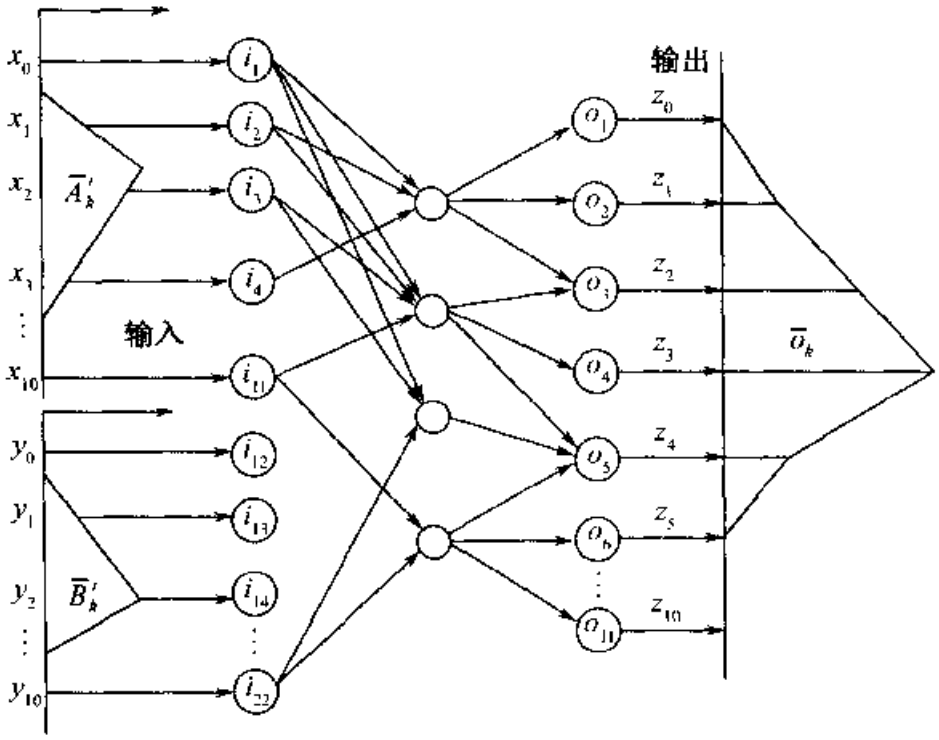


图 3.59 Fuzzy 专家系统隶属函数的学习结构

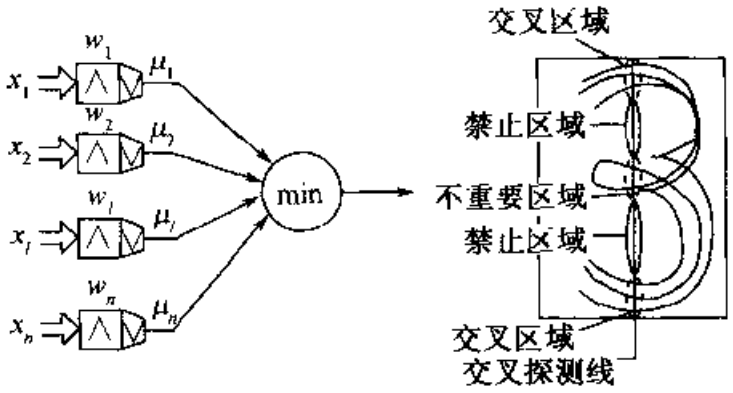


图 3.60 Fuzzy 神经元

目前，Fuzzy 逻辑控制技术已日趋成熟，多年来一直未解决的稳定性分析问题正在逐步解决. Fuzzy 芯片也已研制成功且功能不断加强，成本下降. 直接采用 Fuzzy 芯片开发产品已成趋势. Fuzzy 开发软件包也充满市场. Fuzzy 逻辑控制技术除了在硬件、软件上继续发展，在单纯 Fuzzy 控制技术上发展以外，还将在自适应 Fuzzy 控制、混合 Fuzzy 控制、遗传基因 Fuzzy 控制、以及神经网络 Fuzzy 控制等交叉技术上取得较大的发展. 随着 Fuzzy 理论与其他新理论、新方法、新技术的相互交叉、渗透和融合，Fuzzy 理论的应用将会更加广泛. Fuzzy 理论结合其他新兴技术如遗传基因(Genetic Mechanism)和人工神

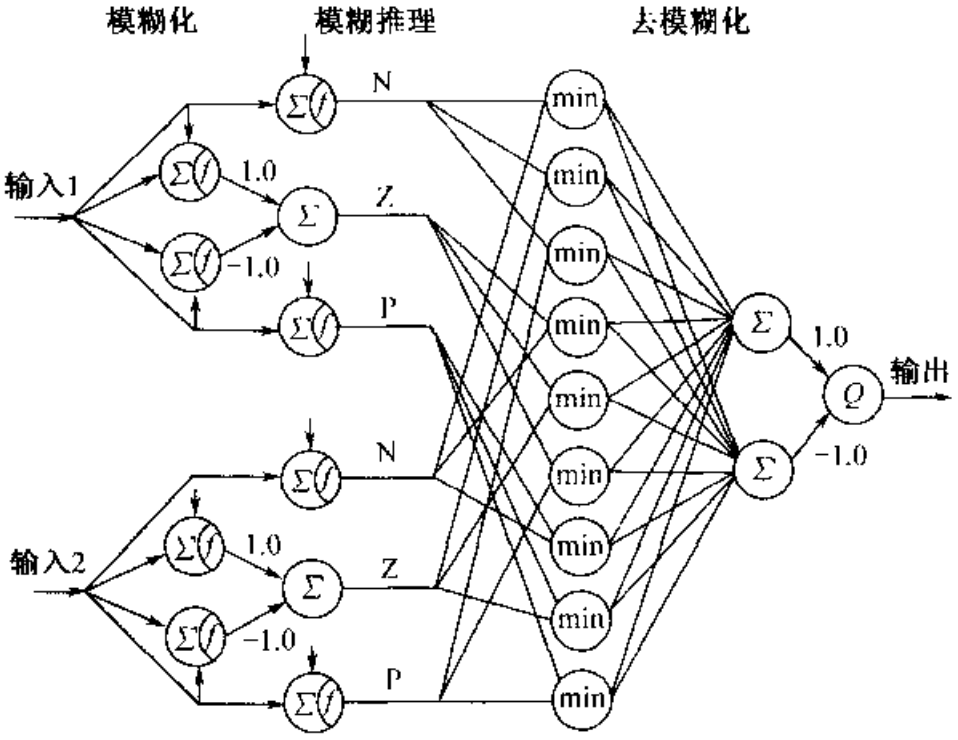


图 3.61 双输入单输出神经 Fuzzy 系统

经网络(Neural Network)形成交叉学科遗传基因 Fuzzy 技术(Genetic Fuzzy Technique)和神经网络 Fuzzy 技术(Neuro-Fuzzy Technique),用于解决单一技术不能解决的问题.Fuzzy 理论在其他学科技术的推动下,正朝着深入广泛的方向发展着.

参 考 文 献

[1] Aukenbrande C A. An extension to the theory of convergence and a proof of the time complexity of genetic algorithms. in Foundations of Genetic Algorithms, San Mateo, Morgan Kaufmann. 1991. pp.53－68

[2] Arnold V I. On functions of three variables. Doklady Akademia Nauk SSSR, 114(4)(1957):679－681

[3] Asoh H and Muhlenbein H. On the mean convergence time of evolutionary algorithms without selection and mutation. in Parallel Problem Solving from Nature, Berlin, Springer-Verlag. 1994. pp.88－97

[4] Assilian S. Artificial intelligence in the control of real dynamical systems. Ph.D. Dissertation, London University. 1974

[5] Aytug H and Koehler G J. Stopping criteria for finite length genetic algorithms. INFORMS Journal on Computing, 8(1996):183－191

[6] Bäck T and Schwefel H P. An Overview of Evolutionary Algorithms for Parameter Optimization. Evolutionary Computation, 1(1)(1993):1－24

[7] Barron A R. Universal approximation bounds for superposition of a sigmoidal function. IEEE Transaction on Information Theory 39(3)(1993):930－945

[8] Bhattacharyya S and Koehler G. An analysis of non-binary genetic algorithms with cardinality 2^v. Complex Systems, 8(1994):227－256

[9] Bishop C M. Neural Networks for Pattern Recognition. Oxford:Clarendon Press. 1995

[10] Black M. Vaguenss. Phil. Sci. 4(1937)

[11] Buckley J, Hayashi Y. Can approximate reasoning be consistent? Fuzzy Sets and Systems, 1994, 65:13－18

[12] Cerf R. Asymptotic convergence of a genetic algorithm. C.R. Acad. Sci. Paris, t.319, Serie I. 1994. pp.272－276

[13] Chakraborty U K. and Dastidar D G. Using reliability analysis to estimate the number of generations to convergence in genetic algorithms. Information Processing Letters, 46(1993):199－209

[14] Cliff D, Harvey I and Husbands P. Explorations in evolutionary robotics. Adaptive Behavior, 2(1993):73－110

[15] Colorni A and Dorigo M. Ant system for job-shop scheduling. JORBEL-Belgian Journal of Operations Research, Statistics and Computer Science, 34(1994):39－53

[16] David H. A Markov chain analysis of genetic algorithms with a state dependent fitness function. Complex Systems, 8(1994):407－417

[17] Davis L. Handbook of Genetic Algorithms. New York: Van Nostrand Reinhold. 1991

[18] Davis T E and Principe J C. A simulated annealing like convergence theory for the simple genetic algorithm. in Proceedings of the Fourth International Conference on Genetic Algorithms, San Mateo, Morgan Kaufmann. 1991. pp.174～181

[19] Deb K. Genetic Algorithms in Multimodal Function Optimization. University of Alabama, Tuscalosa, TCGA Report Number, 89002

[20] Deb K, Kumar A. Real coded Genetic Algorithms with Simulated Binary Crossover: Studies on Multimodal and Multiobjective Problems. Complex Systems, 9(1995):431～454

[21] De Jong K. The Analysis of the Behavior of A Class of Genetic Adaptive Systems. Ph D. thesis, University of Michigan, Ann Harbor. Dissertation Abstract International, 36(10), 5140B. (University Microfilms No 76-9381). 1975

[22] Dorigo M and Schnepf U. Genetic-based machine learning and behavior based robotics: a new synthesis. IEEE Trans. on Systems, Man and Cybernetics, 23(1993):141～154

[23] Dubois D, Prade H, Lang J. Fuzzy sets in approximate reasoning. Fuzzy Sets and Systems, 1991, 40:143～244

[24] Durbin R and Willshaw D. An analogue approach to the traveling salesman problem using an elastic net method. Nature (London), 326(1987):689～691

[25] Eiben A E etc. Global convergence of genetic algorithms: a Markov chain analysis. in Parallel Problem Solving from Nature, Berlin, Springer-Verlag. 1991. pp.4～12

[26] Epstein S L. Toward an ideal trainer. Machine Learning, 15(3)(1995):251～277

[27] Eshelman L and Schaffer J D. Real coded genetic algorithms and interval-schemata. In Whitley L D (Ed.), Foundations of Genetic Algorithms 2, Los ALtos, CA, pp.187～202. Morgan Kaufmann. 1993

[28] Fogel D B. Evolutionary Computation: Toward A New Philosophy of Machine Intelligence. Piscataway, NJ: IEEE Press. 1995

[29] Fogel D B, Fogel L J and Atmar J W. Meta-Evolutionary Programming. in Proc. of the 25th Asilomar Conference on Signals, Systems and Computers, Chen R (ed.), San Jose, CA: Maple Press. 1991. pp.540～545

[30] Fogel D B, Fogel L J, Atmar W and Fogel G B. Hierarchic Methods of Evolutionary Programming. in Proceedings of the First Annual Conference on Evolutionary Programming, Fogel D B and Atmar W (eds.), La Jolla, CA: Evolutionary Programming Society. 1992. pp.175～182

[31] Fogel L, Owens A and Walsh M Artificial Intelligence through Simulated Evolution. New York: John Wiley & Sons. 1966

[32] Fogel L J, Fogel D B. and Angeline P J. A preliminary investigation on extending evolutionary programming to include self adaptatin on finite state machines. Informatica, 18(4)(1994):387～398

[33] Fonseca C M & Fleming P J. An overview of evolutionary algorithms in multiobjective

optimization. Evolutionary Computation, 3(1)(1995):1～16

[34] Galant A R. and White H to learning the derivatives of an unknown mapping with multilayer feedforward networks. Neural Networks, 5(1)(1992):129～138

[35] Goguen J A. The Logic of inexact concepts. Synthese, 19(1969)

[36] Goldberg D E. Genetic Algorithms in Search, Optimization and Machine Learning. Reading, MA: Addison-Wesley. 1989

[37] Goldberg D E, Korb B and Deb K. Messy genetic algorithms: motivation, analysis, and first results. Complex System, 3(1988):493～530

[38] Goldberg D E and Richardson J. Genetic algorithms with sharing for multimodal function optimization. In Grefenstette J J editor, Genetic Algorithms and Their Applications: Proceedings of the Second International Conference on Genetic Algorithms, pages 41～49. Lawrence Erlbaum. 1987

[39] Goldberg D R, Deb K, & Horn J. Massive Multimodality, Deception, and Genetic Algorithms, in Parallel Problems, Solving from Nature Ⅱ, edited by Manna R and Manderick B, North-Holland, Amsterdam. 1992

[40] Grefenstette J J. Optimization of control parameters for genetic algorithms. IEEE Transactions on Systems, Man, and Cybernetics, 16(1)(1986):122～128

[41] Haykin S. Neural Networks: A Comprehensive Foundation. Macmillan College Pub. Com., New York. 1994

[42] Hebb D O. The Organization of Behaviour. New York: JohnWiley. 1949

[43] Hillis. W D. Co-evolving parasites improve simulated evolution as an optimization procedure. pp. 313～324. In Langton C G, Taylor C, Farmer J D & Ramussen S (Eds.), Artificial Life Ⅱ. Reading, MA: Addison-Wesley. 1991

[44] Holland J H. Adaptation in Natural and Artificial Systems. Ann Arbor, MI: University of Michigan Press. 1975

[45] Holland J H. Adaptation in Natural and Artificial Systems. MIT Press, Cambridge. 1992

[46] Hopfield J J. Neural networks and physical systems with emergent collective computational abilities. Proceedings of the National Academy of Sciences of the U.S.A. 79, 2554～2558, 1982

[47] Hopfield J J. Neurons with graded response have collective computational properties like these of two-state neurons. Proc. Nat. Acad. Sci. U.S.A., 81(1984):3088～3092

[48] Horn J. Finite Markov chain analysis of genetic algorithms with niching. in Proceedings of the Fifth International Conference on Genetic Algorithms, San Mateo, Morgan Kaufmann. 1993. pp. 110～117

[49] Hornik K, Stinchcombe M and White H Multilayer feedforward networks are universal approximators. Neural Networks 2(5)(1988):359～475

[50] Hornik K. Approximation capabilities of multilayer feedforward networks. Neural Net-

works, 2(5)(1991):359－366

[51] Jones L K. Constructive approximations for neural networks by sigmoidal functions. Proceedings of the IEEE78(10)(1990):1586－1589

[52] Jones L K. A simple lemma on greedy approximation in Hilbert space and convergence rates for projection pursuit regression and neural network training. Annals of Statistics, 20(1)(1992):608－613

[53] Jons D. The history and meaning of the term "Phoneme". London. 1957

[54] Koehler G J. A proof of the Vose-Liepins conjecture. Annals of Mathematics and Artificial Intelligence. 10(1994):409－422

[55] Kohonen T. Self-organized formation of topologically correct feature maps. Biological Cybernetics, 43(1982):59－69

[56] Kohonen T. Self-Organizing Maps. Springer-Verlag, Berlin, Heidelberg. 1995

[57] Kolmogorov A N. On the representation of continuous functions of several variables by superposition of continuous functions of one variable and addition. Doklady Akademia Nauk SSSR, 114(5)(1957):953－956

[58] Kosko B. Fuzzy Engineering. Prentice Hall. 1997

[59] Koza J R. Genetic Programming: On the Programming of Computers by Means of Natural Selection. MIT Press, Cambridge, MA. 1992

[60] Leung K S, Duan Q, Xu Z B & Kwong C K. A new model of simulated evolutionary computation: convergence analysis & specifications. IEEE Trans. on Evolutionary Computation, 15(1)(1999):1－15

[61] Leung Y, Gao Y, and Xu Z B. Degree of population diversity-a perspective on premature convergence in genetic algorithm and its Markov chain analysis. IEEE Trans. on Neural Networks, 8(4)(1997):1165－1176

[62] Leung Y, Li G & Xu Z B. A genetic algorithm for multiple destination routing problem. IEEE Trans. on Evolutionary Computation. 2(4) (1998):150－161

[63] Leung K S, Sun J Y, & Xu Z B. Efficiency speed up strategies for evolutionary computation: an adaptive implementation. to be appeared in Engineering Computation. 2002

[64] Louis S J and Rawlins G J E. Syntactic analysis of convergence in genetic algorithms. in Foundations of Genetic Algorithms 2, San Mateo, Morgan Kaufmann. 1993. pp.141－151

[65] Mahfoud S W. Finite Markov chain models of an alternative selection strategy for the genetic algorithm. Complex Systems. 7(1993):155－170

[66] Mahfoud S W. Genetic Drift in Sharing Methods. in Proceedings of the First IEEE Conference on Evolutionary Computation, pp.67－72, IEEE Press. 1994

[67] McCulloch W S and Pitts W. A logical calculus of the ideas immanent in nervous activity. Bulletin of Mathematical Biophysics, 5(1943):115－133

[68] Micchelli C A. Interpolation of scattered data: distance matrices and conditionally positive

definite functions. Constructive Approximations. 2(1986):11～22

[69] Michalewicz Z. Genetic Algorithm + Data Structure = Evolutionary Programs. (3rd Ed.). New York: Springer-Verlag. 1996

[70] Miller B L & Shaw M J. Genetic Algorithms with Dynamic Niche Sharing for Multimodal Function Optimizations. IlliGAL Report No. 95010. 1995

[71] Minsky M L and S A. Papert, Perceptrons. Cambridge, MA: MIT Press. 1969

[72] Mitchell M. An Itroduction to Genetic Algorithms. Cambridge, MA: MIT Press. 1996

[73] Mamdani E H. Application of fuzzy logic to approximate reasoning using linguistic synthesis. IEEE Transaction on computers, Vol. C 26, No. 12(1977), 1182～1191

[74] Marinos P N. Fuzzy Logic. Tech. Memo. 66-3344-1, Bell Telephone Labs., Holmdel, NJ, Aug. (1966)

[75] Menger K. Ensembles flous et fonctions aleatoires. C. R. Acad. Sci. (Paris), 232(22), May 28(1951)

[76] Nix A E and Vose M D. Modelling genetic algorithms with Markov chains. Annals of Mathematics and Artificial intelligence, 5(1992): 79 - 88

[77] Novak V. On the synta etic-semantical completeness of first-order fuzzy logic. (Ⅰ), (Ⅱ). Kybernetika, 26(1990):47～66, 134～154

[78] Parker D V. Learning logic. Technical Report TR－47, Cambridge, MA: MIT Center for Research in Computational Economics and Management Science. 1985

[79] Pavelka J. On fuzzy logic, (Ⅰ), (Ⅱ), (Ⅲ). Z. für Mathematik Logic u Grundlagen d Mathematic, 25(1979):45～52, 119～134, 447 - 464

[80] Peck C C. and Dhawan A P. Genetic algorithms as global random search methods: an alternative perspective. Evolutionary Computation, 3(1995):39～80

[81] Popper K. Unened Quest. Foutana/collins, London. 1976

[82] Potter M A and De Jong K A. The coevolution of antibodies for concept learning. In Proceedings of the Parallel Problem Solving from Nature (PPSN), Amsterdam. 1998

[83] Powell M J D. Radial basis functions for multivariable interpolation: a review. In J. C. Mason and M. G. Cox (Eds), Algorithms for Approximation, 143～167, Oxford: Clarendon Press. 1987

[84] Qi. X and Palmieri F. Theoretical analysis of evolutionary algorithms with an infinite population size in continuous space part I: basic properties of selection and mutation. IEEE Trans. on Neural Networks, 5(1994):102～129

[85] Rabinovich Y and Wigderson A. An analysis of a simple genetic algorithm. in Proceedings of the Fourth International Conference on Genetic Algorithms, San Mateo, Morgan Kaufmann. 1991. pp. 215～221

[86] Rechenberg I. Cybernetic Solution Path of An Experimental Problem. Royal Aircraft Establishment, Library Translation No. 1122, Farnborough, England. 1965

[87] Reynolds D and Gomatam J. Stochastic modelling of genetic algorithms. Artificial Intel-

ligence, 82(1996):303 - 330

[88] Rosenblatt F. The Perceptron: A probabilistic model for information storage and organization in the brain. Psychological Review, 65(1958):386～408

[89] Rossenblatt F. Principles of Neurodynamics: Perceptrons and the Theory of Brain Mechanisms. WashingtonDC: Spartan. 1962

[90] Rosenblatt M. Remarks on some nonparametric estimates of a density function. Annals of Mathematical Statistics 27(1956):832～837

[91] Rosin C & Belew R. New methods for competitive coevolution. Evolutionary Computation, 5(1)(1997):1～29

[92] Ross T J. Fuzzy Logic with Engineering Applications. McGraw-Hill Companies, Inc., 1995

[93] Rudolph G. Convergence analysis of canonical genetic algorithms. IEEE Trans. on Neural Networks, 5(1994):96～101

[94] Rumelhart D E, Hinton G. E and Williams R J. Internal representations by error propagation. In Rumelhart D E, McCleling J L: Explorations in the Microstructure of Cognition, Volume 1: Foundations, 318～362, Cambridge, MA: MIT Press. 1986

[95] Russell B. Vagueness. Australian J. Philos. 1(1923)

[96] Salomn. R. Raising theoretical questions about the utility of genetic algorithms. in Evolutionary Programming 4, Lecutre Notes in Computer Science 1213, 1997. pp. 275～284

[97] Schraudolph N N and Belew R K. Dynamic Parameter Encoding for Genetic Algorithms. Machine Learning, 9(1)(1992):9～22

[98] Schwefel H-P. Numerical Optimization of Computer Models. New-York: John Wiley & Sons. 1995-2nd edition. 1981

[99] Shafer C G. The ARGOT System: Adaptive Representation Genetic Optimizing Technique. in Proc. of the Second International Conference on Genetic Algorithms, Grefenstette J J (ed.), Hillsdale, NJ: Lawrence Erlbaum. 1987

[100] Smith R E, Forrest S & Perelson A S. Searching for diverse, cooperative populations with genetic algorithms. Evolutionary Competition, 1(2)(1993):127～149

[101] Suzuki J. A Markov chain analysis on simple genetic algorithms. IEEE Trans. on System, Man and Cybernetics, 25(1995):655～659

[102] Tsutsui S, Fujimoto Y and Ghosh A A. Forking genetic algorithms: GAs with search space division schemes. Evolutionary Computation, 5(1)(1997):61～80

[103] Voget S. Theoretical analysis of genetic algorithms with infinite population size. Complex Systems, 10(1996):167～183

[104] Vose M D and Liepins G E. Punctuated equilibria in genetic search. Complex Systems, 5(1991):31～44

[105] Vose M D. Modelling simple genetic algorithms. Evolutionary Computation, 3(1996):453～472

[106] Wang Guo-Jun. On the logic foundation of FMP and FMT. Int J Fuzzy Mathematics, 1997, 5(1): 229～250

[107] Wang Guo-Jun. On the logic foundation of fuzzy reasoning. Information Sciences, 117 (1999)47～88

[108] Werbos P J. Beyond regression: new tools for prediction and analysis in the behavioural sciences, Ph. D. thesis, Harvard University, Boston, MA. 1974

[109] White H. Connectionist nonparametric regression: multilayer feed－forward networks can learn arbitrary mappings. Neural Networks3(5)(1990): 535～549

[110] Whitley D, Mathias K and Fitzhorn P. Delta coding: an iterative search strategy for genetic algorithms. Proc. of the Fourth International Conference on Genetic Algorithms, Belew R K and Booker L B (eds.), San Mateo, CA: Morgan Kaufmann. 1991. pp. 77～84

[111] Widrow B and Hoff M E. Adaptive switching circuits. In IERWESCON Convention Record, Volume 4(1960): 96～104

[112] Willshaw D J and C. von der Malsburg, How patterned neural connections can be set up by self－organization. Proceedings of the Royal Society of London, Series B 194 (1976): 431～445

[113] Wolpert D and Macreadg W. No free lunch theorem for search. Technical Report 95-02-010, Santa Fe Institute, NM. 1995

[114] Wright A H and Vose M D. Finiteness of the fixed point set for the simple genetic algorithm. Evolutionary Computation, 3(1996): 299～309

[115] Xu Z B, Hu G Q and Kwong C P. Asymmetric Hopfield-type networks: Theory and Applications. Neural Networks, 9(1996): 483～510

[116] Xu Z B, Kwong C K. "Associative Memories," in "Neural Network Systems: Techniques and Applications," ed. by Leondes C T, Vol 3, pp. 183～258, Academic Press, New York. 1998

[117] Xu Z B, Leung K S and Liang Y. Fast-GEA: a genetic evolutionary algorithm based on using splicing/decomposable representation scheme and exclusion-based operators. Submitted to IEEE Trans. on Evolutionary Computation

[118] Yao X. Evolutionary artificial neural networks. in Kent A and Williams J G (eds.), Encyclopedia of Computer Science and Technology, Marcel Dekker Ince., New York, NY 10016, 33(1995), pp. 137～170

[119] Zadeh L A. Fuzzy sets. Information and Control, 8(1965): 338～353

[120] Zheng Yalin and Zhang Winxiu. Fuzzy lattices with shell and dangerous signal recognition logic systems. The International Journal of Fuzzy Mathematics, 8(2000), 2: 283～294

[121] Zheng Yalin, Zhang Wenxiu. Boolean algebra with fuzzy shell and GR$_{\alpha}$-dangerous signal recognition logic. Punjab University Journal of Mathematics, 2000, xxxiii: 83～

104
[122] 陈永义.模糊控制技术及应用实例.北京:北京师范大学出版社.1993
[123] 窦振中.模糊逻辑控制技术及其应用.北京:北京航空航天大学出版社.1995
[124] 焦李成.神经网络系统理论.西安:西安电子科技大学出版社.1990
[125] 苗东升.模糊学导引.北京:中国人民大学出版社.1987
[126] 劳斯 S M(著),何声武,谢盛荣,程依明(译).随机过程.北京:中国统计出版社.1997
[127] 李洪兴.从模糊控制的数学本质看模糊逻辑的成功.模糊系统与数学.1995,4:1--14
[128] 李洪兴.模糊控制的插值机理.中国科学(E辑),28(1998),3:259--267
[129] 刘增良,刘有才.模糊逻辑与神经网络.北京:北京航空航天大学出版社.1996
[130] 诺伯特·维纳(著),钟韧(译).维纳著作选读.上海:上海译文出版社.1978
[131] 孙建永,徐宗本,李有梅.一类求解最大独立集问题的神经演化混合算法.已投计算机学报(2002)
[132] 徐昌文.模糊数学在船舶工程中的应用.北京:国防工业出版社.1992
[133] 徐扬,乔全喜,陈超平,秦克云.不确定性推理.成都:西南交通大学出版社.1994
[134] 徐宗本,陈志平,章祥荪.遗传算法基础理论研究的新近进展.数学进展,29(2)(2001):97～113
[135] 徐宗本,高勇.遗传算法过早收敛现象的特征分析及其预防.中国科学(E),26(4)(1996):364～375
[136] 徐宗本,聂赞坎,张文修.父代种群参与竞争遗传算法的几乎必然收敛性.应用数学学报,25(1)(2002)
[137] 徐宗本,聂赞坎,张文修.遗传算法的模拟退火型收敛性分析.运筹学学报,已接受发表(2002)
[138] 徐宗本,聂赞坎,张文修.遗传算法的几乎必然收敛性:鞅方法.计算机学报,25(8)(2002)
[139] 王国俊.模糊逻辑:推理细致化.国际学术动态,1995,5:33～34
[140] 王国俊.模糊推理与模糊逻辑.系统工程学报,13(1998),2:1～16
[141] 王国俊.模糊推理的全蕴涵三I算法.中国科学(E辑),1999,29(1):43～53
[142] 王国俊.非经典逻辑与近似推理.北京:科学出版社.2000
[143] 王磊,王为民.模糊控制理论及应用.北京:国防工业出版社.1997
[144] 王立新.自适应模糊系统与控制——设计与稳定性分析.北京:国防工业出版社.1995
[145] 吴望名.模糊推理的原理和方法.贵阳:贵州科技出版社.1994
[146] 应明生.近似匹配下的模糊推理.科学通报,1992,37:1060～1061
[147] 应明生.允许修改推理规则的开放逻辑.科学通报,41(1996),11:970--972
[148] 余永权,曾碧.单片机模糊逻辑控制.北京:北京航空航天大学出版社.1995
[149] 张讲社,徐宗本,梁怡.遗传算法的整体退火选择及其收敛充要条件.中国科学

(E),27(2)(1997):154～164

[150] 张乃尧.典型模糊控制器的结构分析.模糊系统与数学,1997,2:10～21

[151] 张文修,梁怡.不确定性推理原理.西安:西安交通大学出版社.1996

[152] 张文修,梁怡.遗传算法的数学基础.西安:西安交通大学出版社.2000

[153] 张文修,梁广锡.模糊控制与系统.西安:西安交通大学出版社.1998

[154] 郑崇友,樊磊,崔宏斌.Frame 与连续格.北京:首都师范大学出版社.1994

[155] 郑亚林.Fuzzy 命题逻辑系统的语义分层方案.系统工程与电子技术.22(2000),4:64～68,80

[156] 郑亚林.L-Fuzzy 命题逻辑系统的语构分层方案.模糊系统与数学,2001,15(1):40～45

[157] 周明,孙树栋.遗传算法原理及应用.北京:国防工业出版社.1999